

第1章 概述

1.1 引言

本章介绍伯克利(Berkeley)联网程序代码。开始我们先看一段源代码并介绍一些通篇要用的印刷约定。对各种不同代码版本的简单历史回顾让我们可以看到本书中的源代码处于什么位置。接下来介绍了两种主要的编程接口，它们在 Unix与非Unix系统中用于编写TCP/IP协议。

然后我们介绍一个简单的用户程序，它发送一个 UDP数据报给一个位于另一主机上的日期/时间服务器，服务器返回一个 UDP数据报，其中包含服务器上日期和时间的 ASCII码字符串。这个进程发送的数据报经过所有的协议栈到达设备驱动器，来自服务器的应答从下向上经过所有协议栈到达这个进程。通过这个例子的这些细节介绍了很多核心数据结构和概念，这些数据结构和概念在后面的章节中还要详细说明。

本章的最后介绍了在本书中各源代码的组织，并显示了联网代码在整个组织中的位置。

1.2 源代码表示

不考虑主题，列举 15 000 行源代码本身就是一件难事。下面是所有源代码都使用的文本格式：

```
-----tcp_subr.c-----  
381 void  
382 tcp_quench(inp, errno)  
383 struct inpcb *inp;  
384 int errno;  
385 {  
386     struct tcpcb *tp = intotcpcb(inp);  
387     if (tp)  
388         tp->snd_cwnd = tp->t_maxseg;  
389 }-----tcp_subr.c-----
```

1.2.1 将拥塞窗口设置为 1

387–388 这是文件 `tcp_subr.c` 中的函数 `tcp_quench`。这些源文件名引用 4.4BSD-Lite发布的文件。4.4BSD 在 1.13 节中讨论。每个非空白行都有编号。正文所描述的代码的起始和结束位置的行号记于行开始处，如本段所示。有时在段前有一个简短的描述性题头，对所描述的代码提供一个概述。

这些源代码同 4.4BSD-Lite 发行版一样，偶尔也包含一些错误，在遇到时我们会提出来并加以讨论，偶尔还包括一些原作者的编者评论。这些代码已通过了 GNU 缩进程序的运行，使它们从版面上看起来具有一致性。制表符的位置被设置成 4 个栏的界线使得这些行在一个页面中显示得很合适。在定义常量时，有些 `#ifdef` 语句和它们的对应语句 `#endif` 被删去(如：`GATEWAY` 和 `MROUTING`，因为我们假设系统被作为一个路由器或多播路由器)。所有 `register` 说

明符被删去。有些地方加了一些注释，并且一些注释中的印刷错误被修改了，但代码的其他部分被保留下。

这些函数大小不一，从几行(如前面的tcp_quench)到最大1100行(tcp_input)。超过大约40行的函数一般被分成段，一段一段地显示。虽然尽量使代码和相应的描述文字放在同一页或对开的两页上，但为了节约版面，不可能完全做到。

本书中有很多对其他函数的交叉引用。为了避免给每个引用都添加一个图号和页码，书封底内页中有一个本书中描述的所有函数和宏的字母交叉引用表和描述的起始页码。因为本书的源代码来自公开的4.4BSD_Lite版，因此很容易获得它的一个拷贝：附录B详细说明了各种方法。当你阅读文章时，有时它会帮助你搜索一个在线拷贝[例如Unix程序grep(1)]。

描述一个源代码模块的各章通常以所讨论的源文件的列表开始，接着是全局变量、代码维护的相关统计以及一个实际系统的一些例子统计，最后是与所描述协议相关的SNMP变量。全局变量的定义通常跨越各种源文件和头文件，因此我们将它们集中到的一个表中以便于参考。这样显示所有的统计，简化了后面当统计更新时对代码的讨论。卷1的第25章提供了SNMP的所有细节。我们在本文中关心的是由内核中的TCP/IP例程维护的、支持在系统上运行的SNMP代理的信息。

1.2.2 印刷约定

通篇的图中，我们使用一个等宽字体表示变量名和结构成员名(`m_next`)，用斜体等宽字体表示定义常量(`NULL`)或常量的值(`512`)的名称，用带花括号的粗体等宽字体表示结构名称(`mbuf{}`)。这里有一个例子：

<code>mbuf{}</code>	
<code>m_next</code>	<i>NULL</i>
<code>m_len</code>	<code>512</code>

在表中，我们使用等宽字体表示变量名称和结构成员名称，用斜体等宽字体表示定义的常量。这里有一个例子：

<code>m_flags</code>	说 明
<code>M_BCAST</code>	以链路层广播发送/接收

通常用这种方式显示所有的#define符号。如果必要，我们显示符号的值(`M_BCAST`的值无关紧要)并且所列符号按字母排序，除非对顺序有特殊要求。

通篇我们会使用像这样的缩进的附加说明来描述历史的观点或实现的细节。

我们用有一个数字在圆括号里的命令名称来表示Unix命令，如`grep(1)`。圆括号中的数字是4.4BSD手册“manual page”中此命令的节号，在那里可以找到其他的信息。

1.3 历史

本书讨论在伯克利的加利福尼亚大学计算机系统研究组的TCP/IP实现的常用引用。历史上，它曾以4.xBSD系统(伯克利软件发行)和“BSD联网版本”发行。这个源代码是很多其他实现的起点，不论是Unix或非Unix操作系统。

图1-1显示了各种BSD版本的年表，包括重要的TCP/IP特征。显示在左边的版本是公开可

用源代码版，它包括所有联网代码：协议本身、联网接口的内核例程及很多应用和实用程序（如Telnet和FTP）。

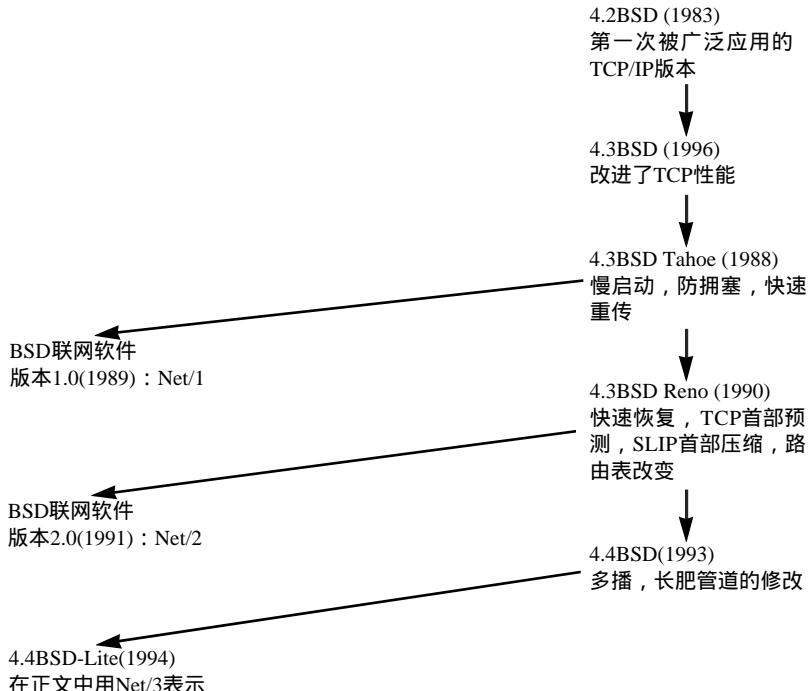


图1-1 带有重要TCP/IP特征的各种BSD版本

虽然本文描述的软件的官方名称为4.4BSD-Lite发行软件，但我们简单地称它为Net/3。

虽然源代码由U. C. Berkeley发行并被称为伯克利软件发行，但TCP/IP代码确实是各种研究者的工作的融合，包括伯克利和其他地区的研究人员。

通篇我们会使用术语源于伯克利的实现来谈及各厂商的实现，如SunOS 4.x、系统V版本4(SVR4)和AIX 3.2，它们的TCP/IP代码最初都是从伯克利源代码发展而来的。这些实现有很多共同之处，通常包括同样的错误！

在图1-1中没有显示的伯克利联网代码的第一版实际上是1982年的4.1cBSD，但是广泛发布的是1983年的版本4.2BSD。

在4.1cBSD之前，BSD版本使用的一个TCP/IP实现，是由Bolt Beranek and Newman(BBN)的Rob Gurwitz和Jack Haverty开发的。[Salus 1994]的第18章提供了另外一些合并到4.2BSD中的BBN代码细节。其他对伯克利TCP/IP代码有影响的实现是由Ballistics研究室的Mike Muuss为PDP-11开发的TCP/IP实现。

描述联网代码从一个版本到下一个版本的变化的文档有限。[Karels and McKusick 1986]描述了从4.2BSD到4.3BSD的变化，并且[Jacobson 1990d]描述了从4.3BSD Tahoe到4.3BSD Reno的变化。

1.4 应用编程接口

在互联网协议中两种常用的应用编程接口(API)是插口(socket)和TLI(运输层接口)。前者

有时称为伯克利插口(Berkeley socket)，因为它被广泛地发布于4.2BSD系统中(见图1-1)。但它已被移植到很多非BSD Unix系统和很多非Unix系统中。后者最初是由AT&T开发的，由于被X/Open承认，有时叫作XTI(X/Open传输接口)。X/Open是一个计算机厂商的国际组织，它制定自己的标准。XTI是TLI的一个有效超集。

虽然本文不是一本程序设计书，但既然在Net/3(和所有BSD版本)中应用编程用插口来访问TCP/IP，我们还是说明一下插口。在各种非Unix系统中也实现了插口。插口和TLI的编程细节在[Stevens 1990]中可以找到。

系统 版本4(SVR4)也为应用编程提供了一组插口API，在实现上与本文中列举的有所不同。在SVR4中的插口基于“流”子系统，在[Rago 1993]中有所说明。

1.5 程序示例

在本章我们用一个简单的C程序(图1-2)来介绍一些BSD网络实现的很多特点。

```
1 /*  
2  * Send a UDP datagram to the daytime server on some other host,  
3  * read the reply, and print the time and date on the server.  
4 */  
  
5 #include    <sys/types.h>  
6 #include    <sys/socket.h>  
7 #include    <netinet/in.h>  
8 #include    <arpa/inet.h>  
9 #include    <stdio.h>  
10 #include   <stdlib.h>  
11 #include   <string.h>  
  
12 #define BUFFSIZE     150          /* arbitrary size */  
13 int  
14 main()  
15 {  
16     struct sockaddr_in serv;  
17     char      buff[BUFFSIZE];  
18     int       sockfd, n;  
19     if ((sockfd = socket(PF_INET, SOCK_DGRAM, 0)) < 0)  
20         err_sys("socket error");  
21     bzero((char *) &serv, sizeof(serv));  
22     serv.sin_family = AF_INET;  
23     serv.sin_addr.s_addr = inet_addr("140.252.1.32");  
24     serv.sin_port = htons(13);  
25     if (sendto(sockfd, buff, BUFFSIZE, 0,  
26                 (struct sockaddr *) &serv, sizeof(serv)) != BUFFSIZE)  
27         err_sys("sendto error");  
28     if ((n = recvfrom(sockfd, buff, BUFFSIZE, 0,  
29                     (struct sockaddr *) NULL, (int *) NULL)) < 2)  
30         err_sys("recvfrom error");  
31     buff[n - 2] = 0;           /* null terminate */  
32     printf("%s\n", buff);  
33     exit(0);  
34 }
```

图1-2 程序示例：发送一个数据报给UDP日期/时间服务器并读取一个应答

1. 创建一个数据报插口

19-20 `socket` 函数创建了一个 UDP 插口，并且给进程返回一个保存在变量 `sockfd` 中的描述符。差错处理函数 `err_sys` 在 [Stevens 1992] 的附录 B.2 中给出。它接收任意数量的参数，并用 `vsprintf` 对它们格式化，将系统调用产生的 `errno` 值对应的 Unix 错误信息打印出来，并中断进程。

我们在不同的地方使用术语插口：(1) 为 4.2BSD 开发的程序用来访问网络协议的 API 通常叫插口 API 或者就叫插口接口；(2) `socket` 是插口 API 中的一个函数的名字；(3) 我们把调用 `socket` 创建的端点叫做一个插口，如评注“创建一个数据报插口”。

但是这里还有一些地方也使用术语插口：(4) `socket` 函数的返回值叫一个插口描述符或者就叫一个插口；(5) 在内核中的伯克利联网协议实现叫插口实现，相比较其他系统如：系统 V 的流实现。(6) 一个 IP 地址和一个端口号的组合叫一个插口，IP 地址和端口号对叫一个插口对。所幸的是引用哪一种术语是很明显的。

2. 将服务器地址放到结构 `sockaddr_in` 中

21-24 在一个互联网插口地址结构中存放日期/时间服务器的 IP 地址(140.252.1.32)和端口号(13)。大多数 TCP/IP 实现都提供标准的日期/时间服务器，它的端口号为 13 [Stevens 1994，图 1-9]。我们对服务器主机的选择是随意的——直接选择了提供此服务的本地主机(图 1-17)。

函数 `inet_addr` 将一个点分十进制表示的 IP 地址的 ASCII 字符串转换成网络字节序的 32 bit 二进制整数。(Internet 协议族的网络字节序是高字节在后)。函数 `htonl` 把一个主机字节序的短整数(可能是低字节在后)转换成网络字节序(高字节在后)。在 Sparc 这种系统中，整数是高字节在后的格式，`htonl` 典型地是一个什么也不做的宏。但是在低字节在后的 80386 上的 BSD/386 系统中，`htonl` 可能是一个宏或者是一个函数，来完成一个 16 bit 整数中的两个字节的交换。

3. 发送数据报给服务器

25-27 程序调用 `sendto` 发送一个 150 字节的数据报给服务器。因为是运行时栈中分配的未初始化数组，150 字节的缓存内容是不确定的。但没有关系，因为服务器根本就不看它收到的报文的内容。当服务器收到一个报文时，就发送一个应答给客户端。应答中包含服务器以可读格式表示的当前时间和日期。

我们选择的 150 字节的客户数据报是随意的。我们有意选择一个报文长度在 100~208 之间的值，来说明在本章的后面要提到的 mbuf 链表的使用。为了避免拥塞，在以太网中，我们希望长度要小于 1472。

4. 读取从服务器返回的数据报

28-32 程序通过调用 `recvfrom` 来读取从服务器发回的数据报。Unix 服务器典型地发回一个如下格式的 26 字节字符串

```
Sat Dec 11 11:28:05 1993\r\n
```

\r 是一个 ASCII 回车符，\n 是 ASCII 换行符。我们的程序将回车符替换成一个空字节，然后调用 `printf` 输出结果。

在本章和下一章我们在分析函数 `socket`、`sendto` 和 `recvfrom` 的实现时，要进入这个例子的一些细节部分。

1.6 系统调用和库函数

所有的操作系统都提供服务访问点，程序可以通过它们请求内核中的服务。各种 Unix 都提供精心定义的有限个内核入口点，即系统调用。我们不能改变系统调用，除非我们有内核的源代码。Unix 第7版提供大约 50 个系统调用，4.4BSD 提供大约 135 个，而 SVR4 大约有 120 个。

在《Unix程序员手册》第2节中有系统调用接口的文档。它是以 C 语言定义的，在任何给定的系统中无需考虑系统调用是如何被调用的。

在各种 Unix 系统中，每个系统调用在标准 C 函数库中都有一个相同名字的函数。一个应用程序用标准 C 的调用序列来调用此函数。这个函数再调用相应的内核服务，所使用的技术依赖于所在系统。例如，函数可能把一个或多个 C 参数放到通用寄存器中，并执行几条机器指令产生一个软件中断进入内核。对于我们来说，可以把系统调用看成 C 函数。

在《Unix程序员手册》的第3节中为程序员定义了一般用途的函数。虽然这些函数可能调用一个或多个内核系统调用但没有进入内核的入口点。如函数 printf 可能调用了系统调用 write 去执行输出，而函数 strcpy(复制一个串)和 atoi(将ASCII码转换成整数)完全不涉及操作系统。

从实现者的角度来看，一个系统调用和库函数有着根本的区别。但在用户看来区别并不严重。例如，在 4.4BSD 中我们运行图 1-2 中的程序。程序调用了三个函数：socket、sendto 和 recvfrom，每个函数最终调用了一个内核中同样名称的函数。在本书的后面我们可以看到这三个系统调用的 BSD 内核实现。

如果我们在 SVR4 中运行这个程序，在那里，用户库中的插口函数调用“流”子系统，那么三个函数同内核的相互作用是完全不同的。在 SVR4 中对 socket 的调用最终调用内核 open 系统调用，操作文件 /dev/udp 并将流模块 sockmod 放置到结果流。调用 sendto 导致一个 putmsg 系统调用，而调用 recvfrom 导致一个 getmsg 系统调用。这些 SVR 4 的细节在本书中并不重要，我们仅仅想指出的是：实现可能不同但都提供相同的 API 给应用程序。

最后，从一个版本到下一个版本的实现技术可能会改变。例如，在 Net/1 中，send 和 sendto 是分别用内核系统调用实现的。但在 Net/3 中，send 是一个调用系统调用 sendto 的库函数：

```
send(int s, char *msg, int len, int flags)
{
    return(sendto(s, msg, len, flags, (struct sockaddr *) NULL, 0));
}
```

用库函数实现 send 的好处是仅调用 sendto，减少了系统调用的个数和内核代码的长度。缺点是由于多调用了一个函数，增加了进程调用 send 的开销。

因为本书是说明 TCP/IP 的伯克利实现的，大多数进程调用的函数（socket、bind、connect 等）是直接由内核系统调用实现的。

1.7 网络实现概述

Net/3 通过同时对多种通信协议的支持来提供通用的底层基础服务。的确，4.4BSD 支持四种不同的通信协议族：

- 1) TCP/IP(互联网协议族)，本书的主题。
- 2) XNS(Xerox 网络系统)，一个与 TCP/IP 相似的协议族；在 80 年代中期它被广泛应用于连

接Xerox设备(如打印机和文件服务器)，通常使用的是以太网。虽然Net/3仍然发布它的代码，但今天已很少使用这个协议了，并且很多使用伯克利TCP/IP代码的厂商把XNS代码删去了(这样他们就不需要支持它了)。

3) OSI协议[Rose 1990；Piscitello and Chapin 1993]。这些协议是在80年代作为开放系统技术的最终目标而设计的，来代替所有其他通信协议。在90年代初它没有什么吸引力，以致于在真正的网络中很少被使用。它的历史地位有待进一步确定。

4) Unix域协议。从通信协议是用来在不同的系统之间交换信息的意义上来说，它还不算是一套真正的协议，但它提供了一种进程间通信(IPC)的形式。

相对于其他IPC，例如系统V消息队列，在同一主机上两个进程间的IPC使用Unix域协议的好处是Unix域协议用与其他三种协议同样的API(插口)访问。另一方面，消息队列和大多数其他形式IPC的API与插口和TLI完全不同。在同一主机上的两进程间的IPC使用网络API，更容易将一个客户/服务器应用程序从一台主机移植到多台主机上。在Unix域中提供两个不同的协议——一个是可靠的，面向连接的，与TCP相似的字节流协议；一个是不可靠的，无连接的，与UDP相似的数据报协议。

虽然Unix域协议可以作为一种同一主机上两进程间的IPC，但也可以用TCP/IP来完成它们之间的通信。进程间通信并不要求使用在不同的主机上的互联网协议。

内核中的联网代码组织成三层，如图1-3所示。在图的右侧我们注明了OSI参考模型[Piscitello和Chapin 1994]的七层分别对应到BSD组织的哪里。

1) 插口层是一个到下面协议相关层的协议无关接口。所有系统调用从协议无关的插口层开始。例如：在插口层中的bind系统调用的协议无关代码包含几十行代码，它们验证的第一个参数是一个有效的插口描述符，并且第二个参数是一个进程中的有效指针。然后调用下层的协议相关代码，协议相关代码可能包含几百行代码。

2) 协议层包括我们前面提到的四种协议族(TCP/IP,XNS,OSI和Unix域)的实现。

每个协议族可能包含自己的内部结构，在图1-3中我们没有显示出来。例如，在Internet协议族中，IP(网络层)是最底层，TCP和UDP两运输层在IP的上面。

3) 接口层包括同网络设备通信的设备驱动程序。

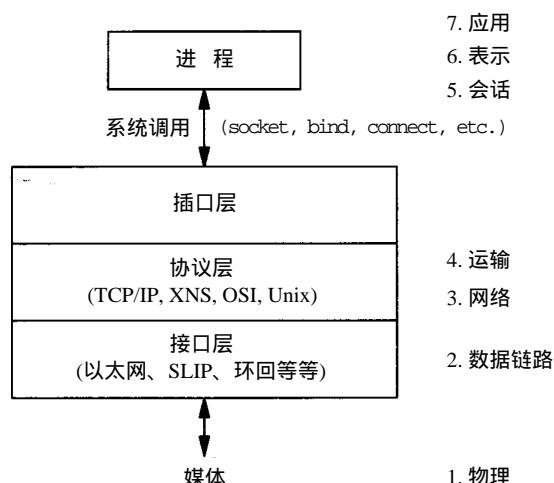


图1-3 Net/3联网代码的大概组织

1.8 描述符

图1-2中，一开始调用socket，这要求定义插口类型。Internet协议族(PF_INET)和数据报插口(SOCK_DGRAM)组合成一个UDP协议插口。

socket的返回值是一个描述符，它具有其他Unix描述符的所有特性：可以用这个描述符调用read和write；可以用dup复制它，在调用了fork后，父进程和子进程可以共享

它；可以调用 `fcntl` 来改变它的属性，可以调用 `close` 来关闭它，等等。在我们的例子中可以看到插口描述符是函数 `sendto` 和 `recvfrom` 的第一个参数。当程序终止时（通过调用 `exit`），所有打开的描述符，包括插口描述符都会被内核关闭。

我们现在介绍在进程调用 `socket` 时被内核创建的数据结构。在后面的几章中会更详细地描述这些数据结构。

首先从进程的进程表表项开始。在每个进程的生存期内都会有一个对应的进程表表项存在。

一个描述符是进程的进程表表项中的一个数组的下标。这个数组项指向一个打开文件表的结构，这个结构又指向一个描述此文件的 i-node 或 v-node 结构。图 1-4 说明了这种关系。

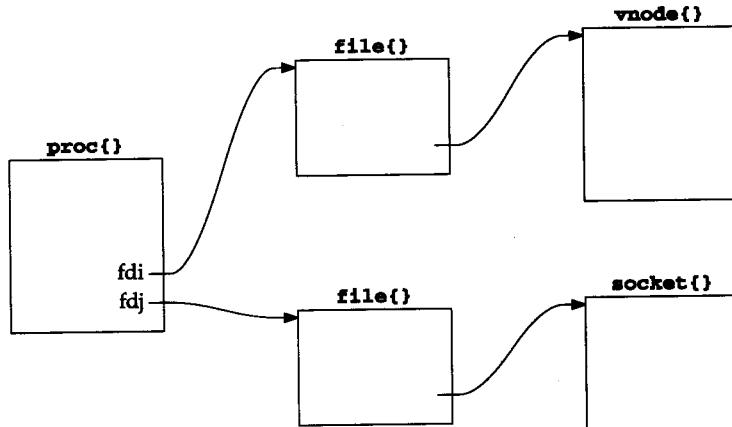


图 1-4 从一个描述符开始的内核数据结构的基本关系

在这个图中，我们还显示了一个涉及插口的描述符，它是本书的焦点。由于进程表表项是由以下 C 语言定义的，我们把记号 `proc{}` 放在进程表项的上面。并且在本书所有的图中都用它来标注这个结构。

```
struct proc {
    ...
}
```

[Stevens 1992, 3.10 节] 显示了当进程调用 `dup` 和 `fork` 时，描述符、文件表结构和 i-node 或 v-node 之间的关系是如何改变的。这三种数据结构的关系存在于所有版本的 Unix 中，但不同的实现细节有所变化。在本书中我们感兴趣的是 `socket` 结构和它所指向的 Internet 专用数据结构。但是既然插口系统调用以一个描述符开始，我们就需要理解如何从一个描述符导出一个 `socket` 结构。

如果程序如此执行

`a.out`

不重定向标准输入（描述符 0）、标准输出（描述符 1）和标准错误处理（描述符 2），图 1-5 显示了程序示例中的 Net/3 数据结构的更多细节。在这个例子中，描述符 0、1 和 2 连接到我们的终端，并且当 `socket` 被调用时未用描述符的最小编号是 3。

当进程执行了一个系统调用，如 `socket`，内核就访问进程表结构。在这个结构中的项 `p_fd` 指向进程的 `filedesc` 结构。在这个结构中有两个我们现在关心的成员：一个是

`fd_ofileflags`，它是一个字符数组指针（每个描述符有一个描述符标志）；一个是指向文件表结构的指针数组的指针。描述符标志有 8 bit，只有两位可为任何描述符设置：close-on-exec 标志和 mapped-from-device 标志。在这里我们显示的所有标志都是 0。

由于 Unix 描述符与很多东西有关，除了文件外，还有：插口、管道、目录、设

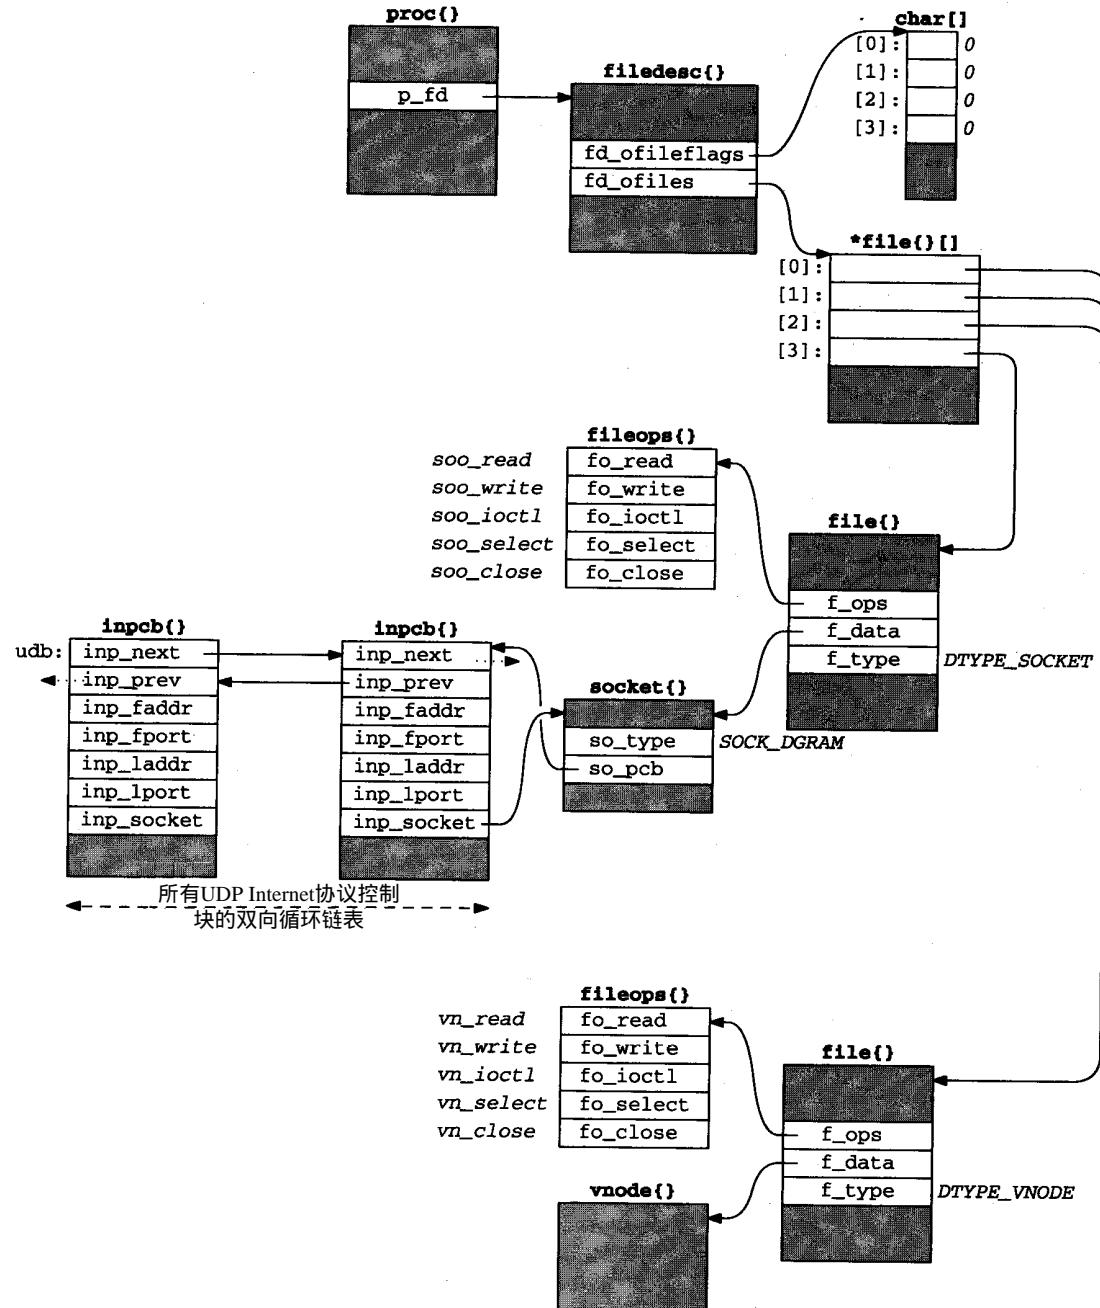


图1-5 在程序示例中调用socket后的内核数据结构

备等等，因此，我们有意把本节叫做“描述符”而不是“文件描述符”。但是很多 Unix 文献在谈到描述符时总是加上“文件”这个修饰词，其实没有必要。虽然我们要说明的是插口描述符，但这个内核数据结构叫 `filedesc{}`。我们尽可能地使用描述符这个未加修饰的术语。

项 `fd_ofiles` 指向的数据结构用 `*file{ }[]` 来表示。它是一个指向 `file` 结构的指针数组。这个数组及描述符标志数组的下标就是描述符本身：0、1、2 等等，是非负整数。在图 1-5 中我们可以看到描述符 0、1、2 对应的项指向图底部的同一个 `file` 结构（由于这三个描述符都对应终端设备）。描述符 3 对应的项指向另外一个 `file` 结构。

结构 `file` 的成员 `f_type` 指示描述符的类型是 `DTYPE_SOCKET` 和 `DTYPE_VNODE`。`vnode` 是一个通用机制，允许内核支持不同类型的文件系统——磁盘文件系统、网络文件系统（如 NFS）、CD-ROM 文件系统、基于存储器的文件系统等等。在本书中关心的不是 `v-node`，因为 TCP/IP 插口的类型总是 `DTYPE_SOCKET`。

结构 `file` 的成员 `f_data` 指向一个 `socket` 结构或者一个 `vnode` 结构，根据描述符类型而定。成员 `f_ops` 指向一个有 5 个函数指针的向量。这些函数指针用在 `read`、`readv`、`write`、`writev`、`ioctl`、`select` 和 `close` 系统调用中，这些系统调用需要一个插口描述符或非插口描述符。这些系统调用每次被调用时都要查看 `f_type` 的值，然后做出相应的跳转，实现者选择了直接通过 `fileops` 结构的相应项来跳转的方式。

我们用一个等宽字体 (`fo_read`) 来醒目地表示一个结构成员的名称，用斜体等宽字体 (`soo_read`) 来表示一个结构成员的内容。注意，有时我们用一个箭头指向一个结构的左上角（如结构 `filedesc`），有时用一个箭头指向右上角（如结构 `file` 和 `fileops`）。我们用这些方法来简化图例。

下面我们来查看结构 `socket`，当描述符的类型是 `DTYPE_SOCKET` 时，结构 `file` 指向结构 `socket`。在我们的例子中，`socket` 的类型（数据报插口的类型是 `SOCK_DGRAM`）保存在成员 `so_type` 中。还分配了一个 Internet 协议控制块 (PCB)：一个 `inpcb` 结构。结构 `socket` 的成员 `so_pcbs` 指向 `inpcb`，并且结构 `inpcb` 的成员 `inp_socket` 指向结构 `socket`。对于一个给定插口的操作可能来自两个方向：“上”或“下”，因此需要有指针来互相指向。

1) 当进程执行一个系统调用时，如 `sendto`，内核从描述符值开始，使用 `fd_ofiles` 索引到 `file` 结构指针向量，直到描述符所对应的 `file` 结构。结构 `file` 指向 `socket` 结构，结构 `socket` 带有指向结构 `inpcb` 的指针。

2) 当一个 UDP 数据报到达一个网络接口时，内核搜索所有 UDP 协议控制块，寻找一个合适的，至少要根据目标 UDP 端口号，可能还要根据目标 IP 地址、源 IP 地址和源端口号。一旦定位所找的 `inpcb`，内核就能通过 `inp_socket` 指针来找到相应的 `socket` 结构。

成员 `inp_faddr` 和 `inp_laddr` 包含远地和本地 IP 地址，而成员 `inp_fport` 和 `inp_lport` 包含远地和本地端口号。IP 地址和端口号的组合经常叫做一个插口。

在图 1-5 的左边，我们用名称 `udb` 来标注另一个 `inpcb` 结构。这是一个全局结构，它是所有 UDP PCB 组成的链表表头。我们可以看到两个成员 `inp_next` 和 `inp_prev` 把所有的 UDP PCB 组成了一个双向环型链表。为了简化此图，我们用两条平行的水平箭头来表示两条链，而不是用箭头指向 PCB 的顶角。右边的 `inpcb` 结构的成员 `inp_prev` 指向结构 `udb`，而不是它的成员 `inp_prev`。来自 `udb.inp_prev` 和另一个 PCB 成员 `inp_next` 的虚线箭头表示这里

还有其他PCB在这个双链表上，但我们没有画出。

在本章，我们已看了不少内核数据结构，大多数还要在后续章节中说明。现在要理解的关键是：

1) 我们的进程调用socket，最后分配了最小未用的描述符（在我们的例子中是3）。在后面，所有针对此socket的系统调用都要用这个描述符。

2) 以下内核数据结构是一起被分配和链接起来的：一个DTYPE_SOCKET类型file结构、一个socket结构和一个inpcb结构。这些结构的很多初始化过程我们并没有说明：file结构的读写标志（因为调用socket总是返回一个可读或可写的描述符）；默认的输入和输出缓存大小被设置在socket结构中，等等。

3) 我们显示了标准输入、输出和标准错误处理的非socket描述符的目的是为了说明所有描述符最后都对应一个file结构，虽然socket描述符和其他描述符之间有所不同。

1.9 mbuf与输出处理

在伯克利联网代码设计中的一个基本概念就是存储器缓存，称作一个mbuf，在整个联网代码中用于存储各种信息。通过我们的简单例子（图1-2）分析一些mbuf的典型用法。在第2章中我们会更详细地说明mbuf。

1.9.1 包含插口地址结构的mbuf

在sendto调用中，第5个参数指向一个Internet插口地址结构（叫serv），第6个参数指示它的长度（后面我们将要看到是16个字节）。插口层为这个系统调用做的第一件事就是验证这些参数是有效的（即这个指针指向进程地址空间的一段存储器），并且将插口地址结构复制到一个mbuf中。图1-6所示的是这个所得到的mbuf。

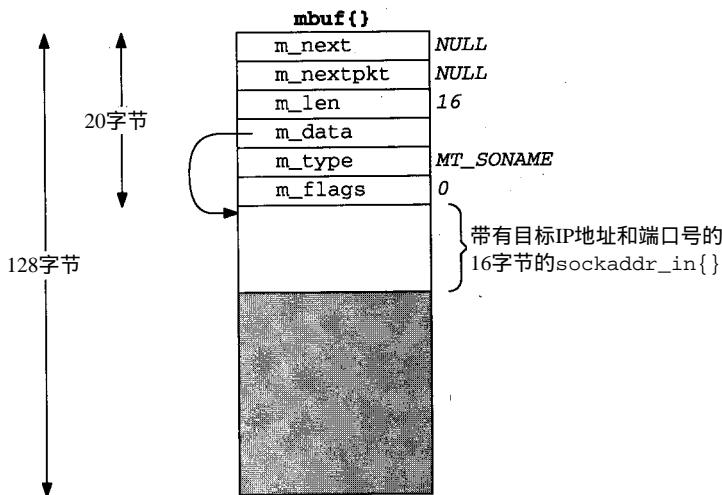


图1-6 mbuf中针对sendto的目的地址

mbuf的前20个字节是首部，它包含关于这个mbuf的一些信息。这20个字节的首部包括四个4字节字段和两个2字节字段。mbuf的总长为128个字节。

稍后我们会看到，mbuf可以用成员m_next和m_nextpkt链接起来。在这个例子中都是

空指针，它是一个独立的 mbuf。

成员 `m_data` 指向 mbuf 中的数据，成员 `m_len` 指示它的长度。对于这个例子，`m_data` 指向 mbuf 中数据的第一个字节（紧接着 mbuf 首部）。mbuf 后面的 92 个字节（108-16）没有用（图 1-6 的阴影部分）。

成员 `m_type` 指示包含在 mbuf 中数据的类型，在本例中是 `MT SONAME`（插口名称）。首部的最后一个成员 `m_flags`，在本例中是零。

1.9.2 包含数据的 mbuf

下面继续讨论我们的例子，插口层将 `sendto` 调用中指定的数据缓存中的数据复制到一个或多个 mbuf 中。`sendto` 的第二个参数指示了数据缓存（buff）的开始位置，第三个参数是它的大小（150 字节）。图 1-7 显示了 150 字节的数据是如何存储在两个 mbuf 中的。

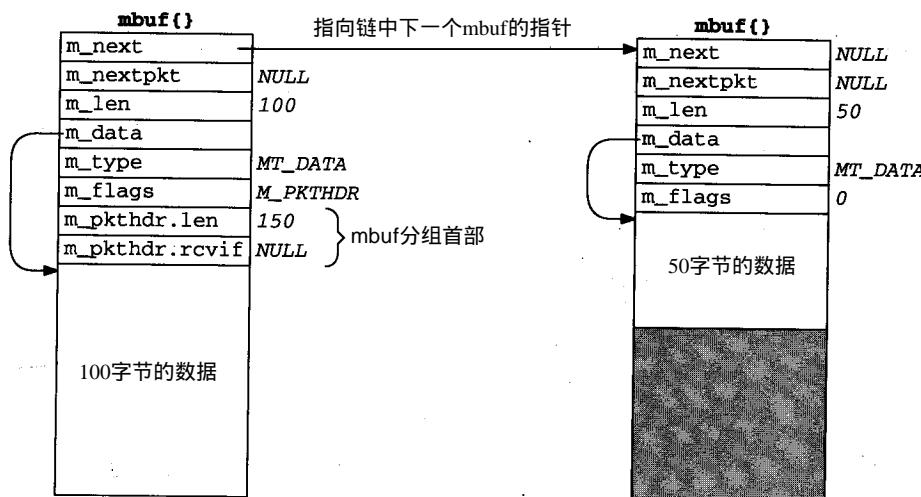


图 1-7 用两个 mbuf 来存储 150 字节的数据

这种安排叫做 mbuf 链表。在每个 mbuf 中的成员 `m_next` 把链表中所有的 mbuf 都链接在一起。

我们看到的另一个变化是链表中第一个 mbuf 的 mbuf 首部的另外两个成员：`m_pkthdr.len` 和 `m_pkthdr.rcvif`。这两个成员组成了分组首部并且只用在链表的第一个 mbuf 中。成员 `m_flags` 的值是 `M_PKTHDR`，指示这个 mbuf 包含一个分组首部。分组首部结构的成员 `len` 包含了整个 mbuf 链表的总长度（在本例中是 150），下一个成员 `rcvif` 在后面我们会看到，它包含了一个指向接收分组的接收接口结构的指针。

因为 mbuf 总是 128 个字节，在链表的第一个 mbuf 中提供了 100 字节的数据存储能力，而后面所有的 mbuf 有 108 字节的存储空间。在本例中的两个 mbuf 需要存储 150 字节的数据。我们稍后会看到当数据超过 208 字节时，就需要 3 个或更多的 mbuf。有一种不同的技术叫“簇”，一种大缓存，典型的有 1024 或 2048 字节。

在链表的第一个 mbuf 中维护一个带有总长度的分组首部的原因是，当需要总长度时可以避免查看所有 mbuf 中的 `m_len` 来求和。

1.9.3 添加IP和UDP首部

在插口层将目标插口地址结构复制到一个 mbuf中，并把数据复制到 mbuf链中后，与此插口描述符(一个 UDP描述符)对应的协议层被调用。明确地说， UDP输出例程被调用，指向mbuf的指针被作为一个参数传递。这个例程要在这 150字节数据的前面添加一个 IP首部和一个 UDP首部，然后将这些 mbuf传递给IP输出例程。

在图1-7中的mbuf链表中添加这些数据的方法是分配另外另一个 mbuf，把它放在链首，并将分组首部从带有100字节数据的mbuf复制到这个mbuf。在图1-8中显示了这三个mbuf。

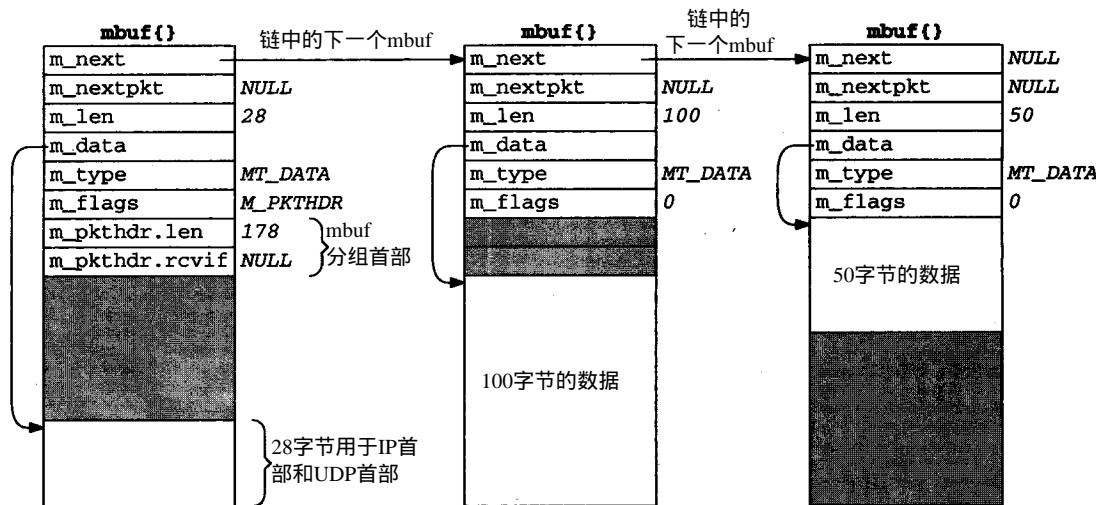


图1-8 在图1-7中的mbuf链表中添加另一个带有IP和UDP首部的mbuf

IP首部和 UDP首部被放置在新 mbuf的最后，这个新 mbuf就成了整个链表的首部。如果需要，它允许任何其他低层协议(例如接口层)在IP首部前添加自己的首部，而不需要再复制IP和 UDP首部。在第一个 mbuf中的m_data指针指向这两个首部的起始位置，m_len的值是28。在分组首部和 IP首部之间有 72字节的未用空间留给以后的首部，通过适当地修改m_data指针和m_len添加在 IP首部的前面。稍后我们会看见以太网首部就是用这种方法建立的。

注意，分组首部已从带有 100字节数据的mbuf中移到新 mbuf中去了。分组首部必须放在mbuf链表的第一个mbuf中。在移动分组首部的同时，在第一个 mbuf设置M_PKTHDR标志并且在第二个mbuf中清除此标志。在第二个 mbuf中分组首部占用的空间现在未用。最后，在此分组首部中的长度成员由于增加了 28 字节而变成了178。

然后 UDP输出例程填写 UDP首部和IP首部中它们所能填写的部分。例如，IP首部中的目标地址可以被设置，但IP检验和要留给IP输出例程来计算和存放。

UDP检验和计算后存储在 UDP首部中。注意，这要求遍历存储在 mbuf链表中的所有150字节的数据。这样，内核要对这 150字节的用户数据做两次遍历：一次是把用户缓存中的数据复制到内核中的 mbuf中，而现在是计算 UDP检验和。对整个数据的额外遍历会降低协议的性能，在后续章节中我们会介绍另一种可选的实现技术，它可以避免不必要的遍历。

接着， UDP输出例程调用IP输出例程，并把此mbuf链表的指针传递给IP输出例程。

1.9.4 IP输出

IP输出例程要填写IP首部中剩余的字段，包括IP检验和；确定数据报应发到哪个输出接口（这是IP路由功能）；必要时，对IP报文分片；以及调用接口输出函数。

假设输出接口是一个以太网接口，再次把此 mbuf链表的指针作为一个参数，调用一个通用的以太网输出函数。

1.9.5 以太网输出

以太网输出函数的第一个功能就是把32位IP地址转换成相应的48位以太网地址。在使用ARP(地址解析协议)时会使用这个功能，并且会在以太网上发送一个ARP请求并等待一个ARP应答。此时，要输出的mbuf链表已得到，并等待应答。

然后以太网输出例程把一个14字节的以太网首部添加到链表的第一个mbuf中，紧接在IP首部的前面(图1-8)。以太网首部包括6字节以太网目标地址、6字节以太网源地址和2字节以太网帧类型。

之后此mbuf链表被加到此接口的输出队列队尾。如果接口不忙，接口的“开始输出”例程立即被调用。若接口忙，在它处理完输出队列中的其他缓存后，它的输出例程会处理队列中的这个新mbuf。

当接口处理它输出队列中的一个mbuf时，它把数据复制到它的传输缓存中，并且开始输出。在我们的例子中，192字节被复制到传输缓存中：14字节以太网首部、20字节IP首部、8字节UDP首部及150字节用户数据。这是内核第三次遍历这些数据。一旦数据从mbuf链表被复制到设备传输缓存，mbuf链表就被以太网设备驱动程序释放。这三个mbuf被放回到内核的自由缓存池中。

1.9.6 UDP输出小结

我们在图1-9中给出了一个进程调用sendto传输一个UDP数据报时的大致处理过程。在图中我们说明的处理过程与三层内核代码(图1-3)的关系也显示出来了。

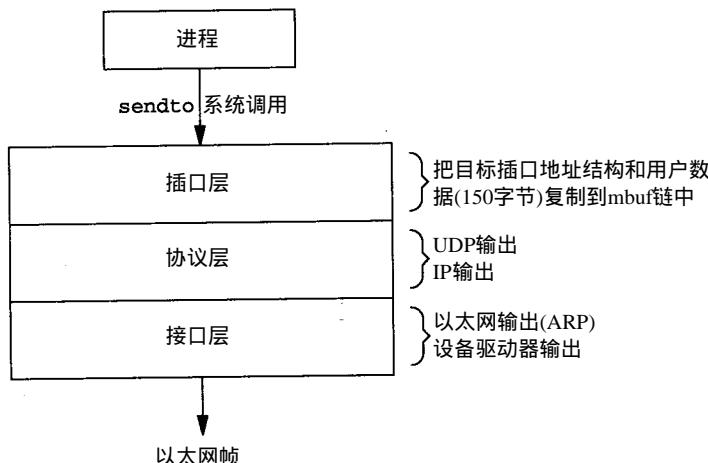


图1-9 三层处理一个简单UDP输出的执行过程

函数调用控制从插口层到 UDP输出例程，到 IP输出例程，然后到以太网输出例程。每个函数调用传递一个指向要输出的 mbuf的指针。在最低层，设备驱动程序层， mbuf链表被放置到设备输出队列并启动设备。函数调用按调用的相反顺序返回，最后系统调用返回给进程。注意，直到 UDP数据报到达设备驱动程序前， UDP数据没有排队。高层仅仅添加它们的协议首部并把mbuf传递给下一层。

这时，在我们的程序示例中调用 recvfrom去读取服务器的应答。因为该插口的输入队列是空的(假设应答还没有到达)，进程就进入睡眠状态。

1.10 输入处理

输入处理与刚讲过的输出处理不同，因为输入是异步的。就是说，它是通过一个接收完成中断驱动以太网设备驱动程序来接收一个输入分组，而不是通过进程的系统调用。内核处理这个设备中断，并调度设备驱动程序进入运行状态。

1.10.1 以太网输入

以太网设备驱动程序处理这个中断，假定它表示一个正常的接收已完成，数据从设备读到一个 mbuf链表中。在我们的例子中，接收了 54 字节的数据并复制到一个 mbuf中：20字节IP首部、8字节UDP首部及26字节数据(服务器的时间与日期)。图1-10所示的是这个mbuf的格式。

这个mbuf是一个分组首部(m_flags被设置成M_PKTHDR)，它是一个数据记录的第一个mbuf。分组首部的成员 len包含数据的总长度，成员 rcvif包含一个指针，它指向接收数据的接口的接口结构(第3章)。我们可以看到成员 rcvif用于接收分组而不是输出分组(图1-7和图1-8)。

mbuf的前16字节数据空间被分配给一个接口层首部，但没有使用。数据就存储在这个 mbuf中，54字节的数据存储在剩余的 84字节的空间中。

设备驱动程序把 mbuf传给一个通用以太网输入例程，它通过以太网帧中的类型字段来确定哪个协议层来接收此分组。在这个例子中，类型字段标识一个 IP数据报，从而 mbuf被加入到IP输入队列中。另外，会产生一个软中断来执行 IP输入例程。这样，这个设备中断处理就完成了。

1.10.2 IP输入

IP输入是异步的，并且通过一个软中断来执行。当接口层在系统的一个接口上收到一个 IP数据报时，它就设置这个软中断。当 IP输入例程执行它时，循环处理在它的输入队列中的每一个IP数据报，并在整个队列被处理完后返回。

IP输入例程处理每个接收到的 IP数据报。它验证IP首部检验和，处理IP选项，验证数据报

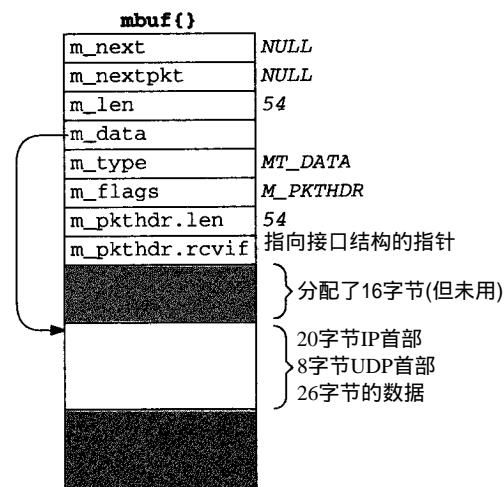


图1-10 用一个mbuf存储输入的以太网数据

被传递到正确的主机(通过比较数据报的目标IP地址与主机IP地址)，并当系统被配置为一个路由器，且数据报被表注为其他的IP地址时，转发此数据报。如果IP数据报到达它的最终目标，调用IP首部中标识的协议的输入例程：ICMP，IGMP，TCP或UDP。在我们的例子中，调用UDP输入例程去处理UDP数据报。

1.10.3 UDP输入

UDP输入例程验证UDP首部中的各字段(长度与可选的检验和)，然后确定是否一个进程应该接收此数据报。在第23章我们要详细讨论这个检查是如何进行的。一个进程可以接收到一指定UDP端口的所有数据报，或让内核根据源与目标IP地址及源与目标端口号来限制数据报的接收。

在我们的例子中，UDP输入例程从一个全局变量`udb`(图1-5)开始，查看所有UDP协议控制块链表，寻找一个本地端口号(`inp_lport`)与接收的UDP数据报的目标端口号匹配的协议控制块。这个PCB是由我们调用`socket`创建的，它的成员`inp_socket`指向相应插口结构，并允许接收的数据在此插口排队。

在程序示例中，我们从未为应用程序指定本地端口号。在习题23.3中，我们会看到在写第一个UDP程序时创建一个插口而不绑定一个本地端口号会导致内核自动地给此插口分配一个本地端口号(称为短期端口)。这就是为什么插口的PCB成员`inp_lport`不是一个空值的原因。

因为这个UDP数据报要传递给我们的进程，发送方的IP地址和UDP端口号被放置到一个mbuf中，这个mbuf和数据(在我们的例子中是26字节)被追加到此插口的接收队列中。图1-11所示的是被追加到这个插口的接收队列中的这两个mbuf。

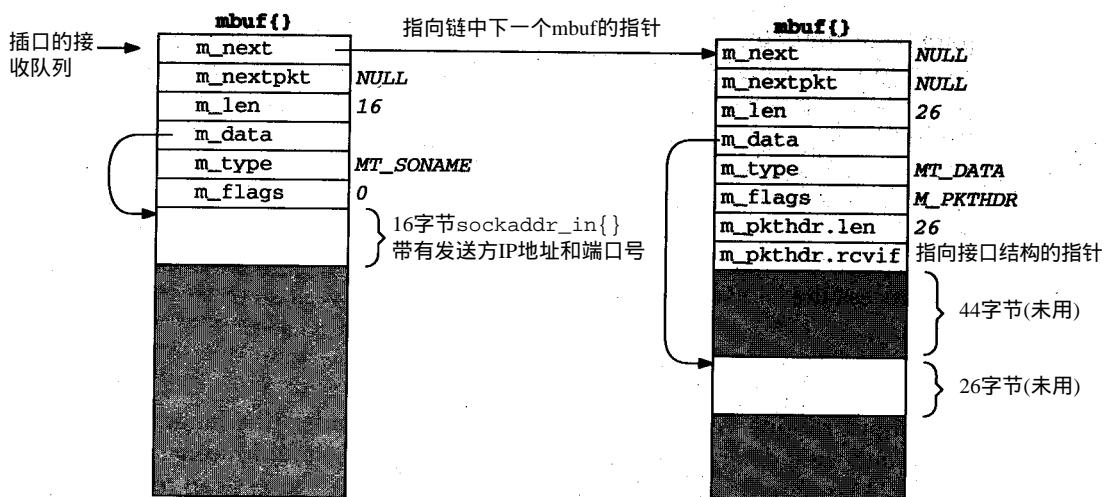


图1-11 发送方地址和数据

比较这个链表中的第二个mbuf(MT_DATA类型)与图1-10中的mbuf，成员`m_len`和`m_pkthdr.len`都减小了28字节(20字节的IP首部和8字节UDP首部)，并且指针`m_data`也减小了28字节。这有效地将IP和UDP首部删去，只保留了26字节数据追加到插口接收队列。

在链表的第一个 mbuf中包括一个 16字节Internet插口地址结构，它带有发送方 IP地址和 UDP端口号。它的类型是 MT SONAME，与图1-6中的mbuf类似。这个mbuf是插口层创建的，将这些信息返回给通过调用系统调用 recvfrom或recvmsg的调用进程。即使在这个链表的第二个mbuf中有空间(16字节)存储这个插口地址结构，它也必须存放到它自己的 mbuf中，因为它们的类型不同(一个是MT SONAME，一个是MT DATA)。

然后接收进程被唤醒。如果进程处于睡眠状态等待数据的到达(我们例子中的情况)，进程被标志为可运行状态等待内核的调度。也可以通过 select系统调用或SIGIO信号来通知进程数据的到达。

1.10.4 进程输入

我们的进程调用 recvfrom时被阻塞，在内核中处于睡眠状态，现在进程被唤醒。 UDP层追加到插口接收队列中的 26字节的数据(接收的数据报)被内核从 mbuf复制到我们程序的缓存中。

注意，我们的程序把 recvfrom的第5，第6个参数设置为空指针，告诉系统在接收过程中不关心发送方的IP地址和UDP端口号。这使得系统调用 recvfrom时，略过链表中的第一个mbuf(图1-11)，仅返回第二个mbuf中的26字节的数据。然后内核的 recvfrom代码释放图1-11中的两个mbuf，并把它们放回到自由mbuf池中。

1.11 网络实现概述(续)

图1-12总结了在各层间为网络输入输出而进行的通信。图 1-12是对图1-3进行了重画，它只考虑Internet协议，并且强调层间的通信。符号 splnet与splimp在下一节讨论。

我们使用复数术语插口队列(socket queues)和接口队列(interface queues)，因为每个插口

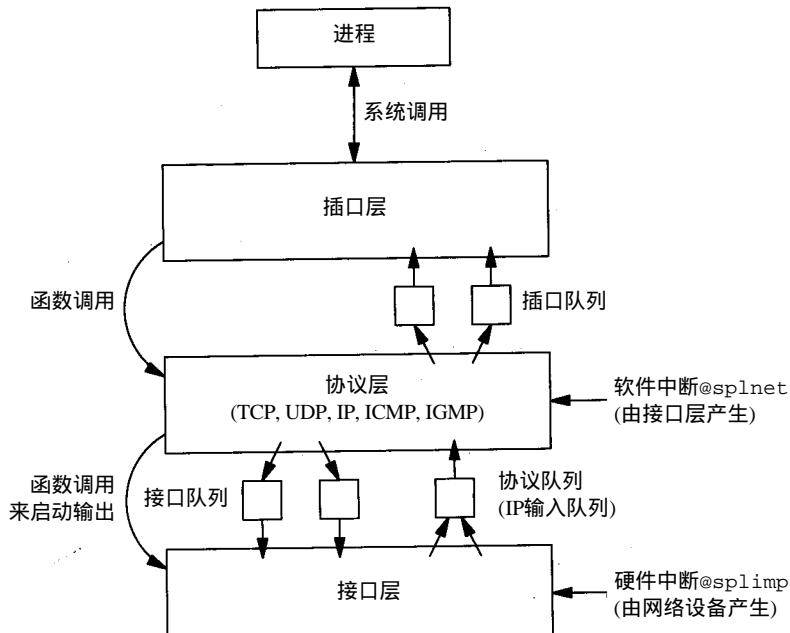


图1-12 网络输入输出的层间通信

和每个接口(以太网、环回、SLIP、PPP等)都有一个队列，但我们使用单数术语协议队列(protocol queue)，因为只有一个IP输入队列。如果考虑其他协议层，我们就会有一个队列用于XNS协议，一个队列用于OSI协议。

1.12 中断级别与并发

我们在1.10节看到网络代码处理输入分组用的是异步和中断驱动的方式。首先，一个设备中断引发接口层代码执行，然后它产生一个软中断引发协议层代码执行。当内核完成这些级别的中断后，执行插口代码。

在这里给每个硬件和软件中断分配一个优先级。图1-13所示的是8个优先级别的顺序，从最低级别(不阻塞中断)到最高级别(阻塞所有中断)。

函数	说明
sp10	正常操作方式，不阻塞中断
Splsoftclock	低优先级时钟处理
splnet	网络协议处理
spltty	终端输入输出
splbio	磁盘与磁带输入输出
splimp	网络设备输入输出
splclock	高优先级时钟处理
splhigh	阻塞所有中断
splx(s)	(见正文)

图1-13 阻塞所选中断的内核函数

[Leffler et al. 1989]的表4-5显示了用于VAX实现的优先级别。386的Net/3的实现使用图1-13所示的8个函数，但splsoftclock与splnet在同一级别，splclock与splhigh也在同一级别。

用于网络接口级的名称*imp*来自于缩写IMP(接口报文处理器)，它是在ARPANET中使用的路由器的最初类型。

不同优先级的顺序意味着高优先级中断可以抢占一个低优先级中断。看图1-14所示的事

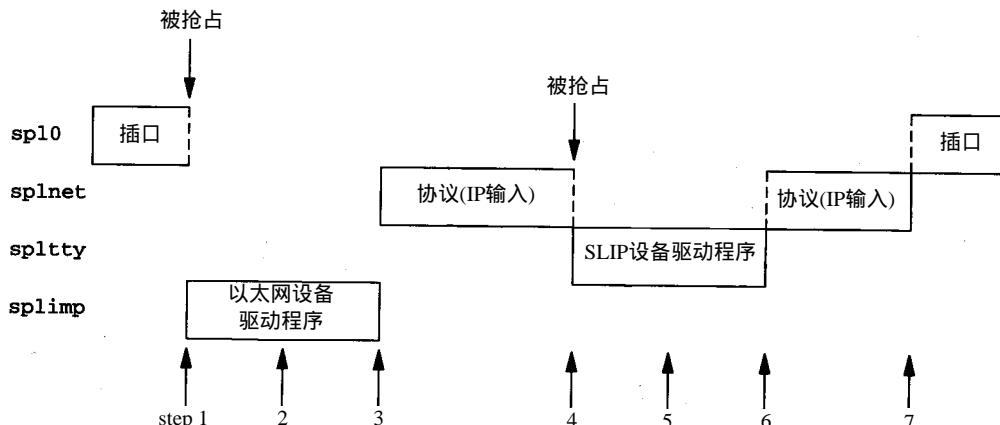


图1-14 优先级示例与内核处理

件顺序。

- 1) 当插口层以级别 spl0 执行时，一个以太网设备驱动程序中断发生，使接口层以级别 splimp 执行。这个中断抢占了插口层代码的执行。这就是异步执行接口输入例程。
- 2) 当以太网设备驱动程序在运行时，它把一个接收的分组放置到 IP 输出队列中并调度一个 splnet 级别的软中断。软中断不会立即有效，因为内核正在一个更高的优先级 (splimp) 上运行。
- 3) 当以太网设备驱动程序完成后，协议层以级别 splnet 执行。这就是异步执行 IP 输入例程。
- 4) 一个终端设备中断发生 (完成一个 SLIP 分组)，它立即被处理，抢占协议层，因为终端输入/输出 (spltty) 优先级比图 1-13 中的协议层 (splnet) 更高。
- 5) SLIP 驱动程序把接收的分组放到 IP 输入队列中并为协议层调度另一个软中断。
- 6) 当 SLIP 驱动程序结束时，被抢占的协议层继续以级别 splnet 执行，处理完从以太网设备驱动程序收到的分组后，处理从 SLIP 驱动程序接收的分组。仅当没有其他输入分组要处理时，它会把控制权交还给被它抢占的进程 (在本例中是插口层)。
- 7) 插口层从它被中断的地方继续执行。

对于这些不同优先级，一个要关心的问题就是如何处理那些在不同级别的进程间共享的数据结构。在图 1-2 中显示了三种在不同优先级进程间共享的数据结构——插口队列、接口队列和协议队列。例如，当 IP 输入例程正在从它的输入队列中取出一个接收的分组时，一个设备中断发生，抢占了协议层，并且那个设备驱动程序可能添加另一个分组到 IP 输入队列。这些共享的数据结构 (本例中的 IP 输入队列，它共享于协议层和接口层)，如果不协调对它们的访问，可能会破坏数据的完整性。

Net/3 的代码经常调用函数 splimp 和 splnet。这两个调用总是与 splx 成对出现，splx 使处理器返回到原来的优先级。例如下面这段代码，被协议层 IP 输入函数执行，去检查是否有其他分组在它的输入队列中等待处理：

```
struct mbuf *m;
int s;
s = splimp ();
IF_DEQUEUE (&ipintrq, m);
splx(s);
if (m == 0)
    return;
```

调用 splimp 把 CPU 的优先级升高到网络设备驱动程序级，防止任何网络设备驱动程序中断发生。原来的优先级作为函数的返回值存储到变量 s 中。然后执行宏 IF_DEQUEUE 把 IP 输入队列 (ipintrq) 头部的第二个分组删去，并把指向此 mbuf 链表的指针放到变量 m 中。最后，通过调用带有参数 s (其保存着前面调用 splimp 的返回值) 的 splx，CPU 的优先级恢复到调用 splimp 前的级别。

由于在调用 splimp 和 splx 之间所有的网络设备驱动程序的中断被禁止，在这两个调用间的代码应尽可能的少。如果中断被禁止过长的时间，其他设备会被忽略，数据会被丢失。因此，对变量 m 的测试 (看是否有其他分组要处理) 被放在调用 splx 之后而不是之前。

当以太网输出例程把一个要输出的分组放到一个接口队列，并测试接口当前是否忙时，若接口不忙则启动接口，这时例程需要调用这些 spl 调用。

```

struct mbuf *m;
int s;

s = splimp();
/*
 * Queue message on interface, and start output if interface not active.
 */
if (IF_QFULL(&ifp->if_snd)) {
    IF_DROP(&ifp->if_snd); /* queue is full, drop packet */
    splx(s);
    error = ENOBUFS;
    goto bad;
}

IF_ENQUEUE(&ifp->if_snd, m); /* add the packet to interface queue */
if ((ifp->if_flags & IFF_OACTIVE) == 0)
    (*ifp->if_start)(ifp); /* start interface */
splx(s);

```

在这个例子中，设备中断被禁止的原因是防止在协议层正在往队列添加分组时，设备驱动程序从它的发送队列中取走下一个分组。设备发送队列是一个在协议层和接口层共享的数据结构。

在整个源代码中到处都会看到 spl函数。

1.13 源代码组织

图1-15所示的是Net/3网络源代码的组织，假设它位于目录 /usr/src/sys。

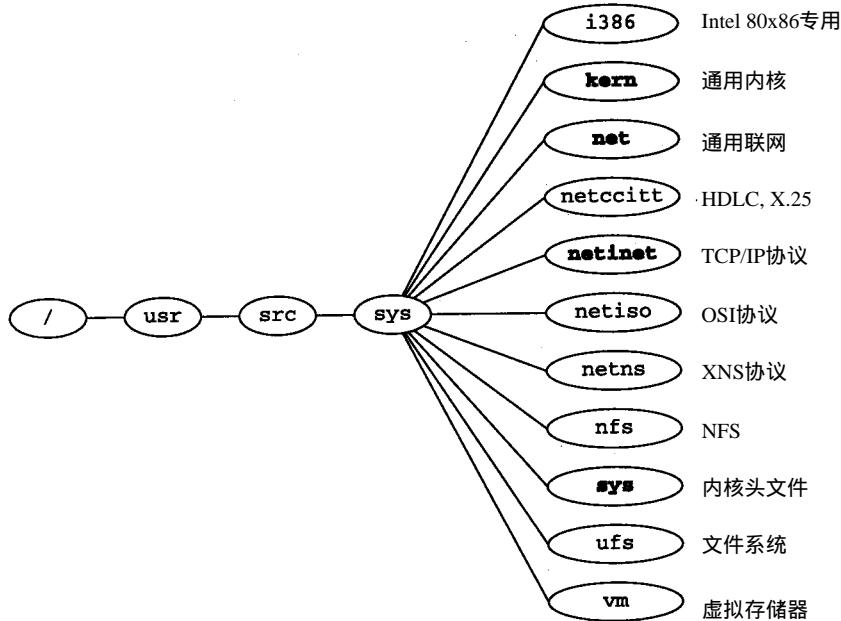


图1-15 Net/3源代码组织

本书的重点在目录netinet，它包含所有TCP/IP源代码。在目录kern和net中我们也可找到一些文件。前者是协议无关的插口代码，而后者是一些通用联网函数，用于 TCP/IP例程，如路由代码。

包含在每个目录中的文件简要地列于下面：

- i386：因特80x86专用目录。例如，目录 `i386/isa` 包含专用于ISA总线的设备驱动程序。目录 `i386/stand` 包含单机引导程序代码。
- kern：通用的内核文件，不属于其他目录。例如，处理系统调用 `fork` 和 `exec` 的内核文件在这个目录。在这个目录中，我们只考察少数几个文件——用于插口系统调用的文件(插口层在图1-3)。
- net：通用联网文件，例如，通用联网接口函数，BPF(BSD分组过滤器)代码、SLIP驱动程序和路由代码。在这个目录中我们考察一些文件。
- netccitt：OSI协议接口代码，包括HDLC(高级数据链路控制)和X.25驱动程序。
- netinet：Internet协议代码：IP，ICMP，IGMP，TCP和UDP。本书的重点集中在这个目录中的文件。
- netiso：OSI协议。
- netns：施乐(Xerox)XNS协议。
- nfs：SUN公司的网络文件系统代码。
- sys：系统头文件。在这个目录中我们考察几个头文件。这个目录中的文件还出现在目录`/usr/include/sys`中。
- ufs：Unix文件系统的代码，有时叫伯克利快速文件系统。它是标准磁盘文件系统。
- vm：虚拟存储器系统代码。

图1-16所示的是源代码组织的另一种表现形式，它映射到我们的三个内核层。忽略`netimp`和`nfs`这样的目录，在本书中我们不关心它们。

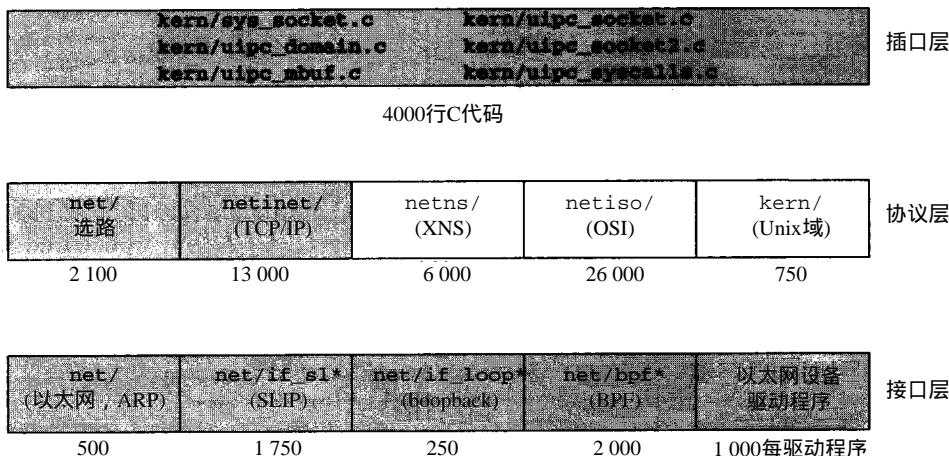


图1-16 映射到三个内核层的Net/3源代码组织

在每个表格框底下的数字是对应功能的C代码的近似行数，包括源文件中的所有注释。

我们不考察图中所有的源代码。显示目录 `netns` 与 `netiso` 是为了与 Internet 协议比较。我们仅考虑有阴影的表格框。

1.14 测试网络

图1-17所示的测试网络用于本书中所有的例子。除了在图顶部的主机 `vangogh`，所有的

IP地址属于B类网络地址140.252，并且所有主机名属于域.tuc.noao.edu (noao代表“国家光学天文台”，tuc代表Tucson)。例如，在右下角的系统的主机全名是svr4.tuc.noao.edu，IP地址是140.252.13.34。在每个框图顶上的记号是运行在此系统上操作系统的名称。

在图顶的主机的全名是vangogh.cs.berkeley.edu，其他主机通过Internet可以连接到它。

这个图与卷1中的测试网络几乎一样，有一些操作系统升级了，在sun与netb之间的拨号链路现在用PPP取代了SLIP。另外，我们用Net/3网络代码代替了BSD/386 V1.1提供的Net/2网络代码。

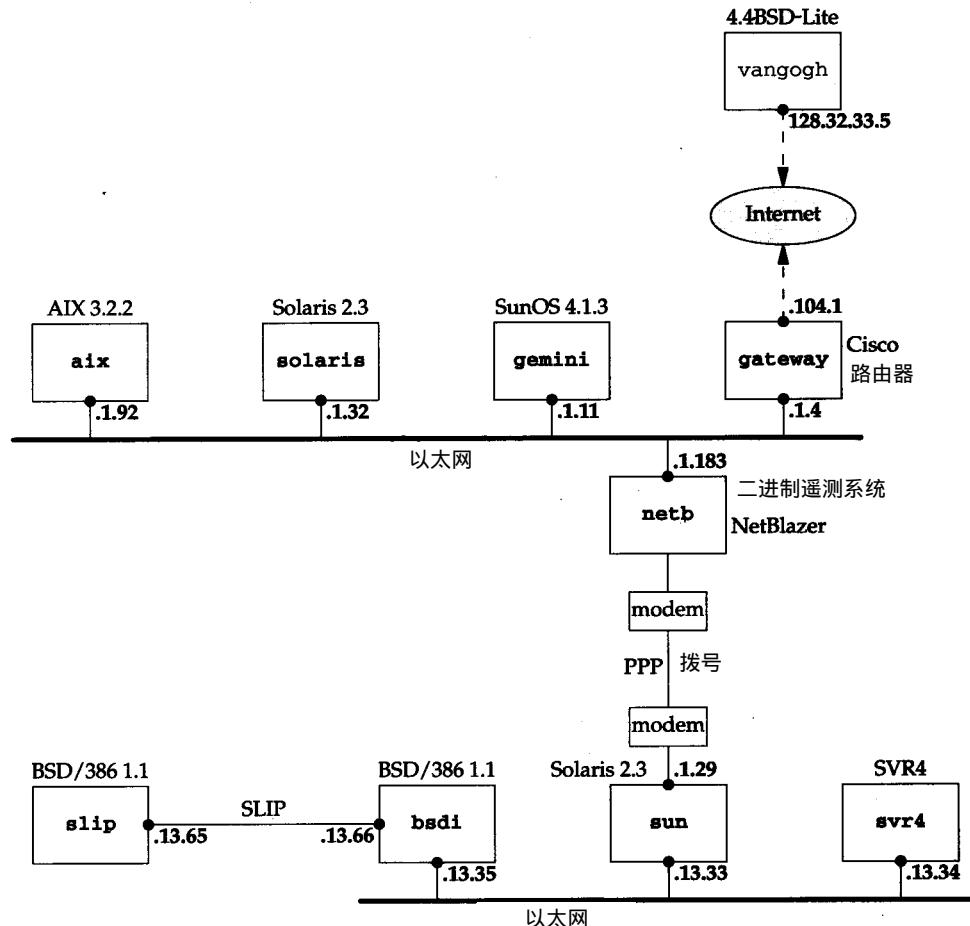


图1-17 用于本书中所有例子的测试网络

1.15 小结

本章是对Net/3网络代码的概述。通过一个简单的程序示例(图1-2)——发送一个UDP数据报给一个日期时间服务器并接收应答，我们分析了通过内核进行输入输出的过程。mbuf中保存要输出的信息和接收的IP数据报。下一章我们要查看mbuf的更多细节。

当进程执行sendto系统调用时，产生UDP输出，而IP输入是异步的。当一个设备驱动程

序接收了一个IP数据报，数据报被放到IP输入队列中并且产生一个软中断使IP输入函数执行。我们考察了在内核中用于联网代码的不同中断级别。由于很多联网数据结构被不同的层所共享，而这些层在不同的中断级别上执行，因此当访问或修改这些共享结构时要特别小心。几乎所有我们要查看的函数中都会遇到spl函数。

本章结束时我们查看了Net/3源代码的整个组织结构，及本书关注的代码。

习题

- 1.1 输入程序示例(图1-2)并在你的系统上运行。如果你的系统有系统调用跟踪能力，如**trace** (SunOS 4.x)、**truss** (SVR4)或**ktrace** (4.4BSD)，用它检测本例中调用的系统调用。
- 1.2 在1.12节调用**IF_DEQUEUE**的例子中，我们注意到调用**splimp**来防止网络设备驱动程序的中断。当以太网驱动程序以这个级别执行时，SLIP驱动程序会发生什么？

第2章 mbuf：存储器缓存

2.1 引言

网络协议对内核的存储器管理能力提出了很多要求。这些要求包括能方便地操作可变长缓存，能在缓存头部和尾部添加数据（如低层封装来自高层的数据），能从缓存中移去数据（如，当数据分组向上经过协议栈时要去掉首部），并能尽量减少为这些操作所做的数据复制。内核中的存储器管理调度直接关系到联网协议的性能。

在第1章我们介绍了普遍应用于Net/3内核中的存储器缓存：mbuf，它是“memory buffer”的缩写。在本章，我们要查看mbuf和内核中用于操作它们的函数的更多的细节，在本书中几乎每一页我们都会遇到mbuf。要理解本书的其他部分必须先要理解mbuf。

mbuf的主要用途是保存在进程和网络接口间互相传递的用户数据。但mbuf也用于保存其他各种数据：源与目标地址、插口选项等等。

图2-1显示了我们要遇到的四种不同类型的mbuf，它们依据在成员m_flags中填写的不同标志M_PKTHDR和M_EXT而不同。图2-1中四个mbuf的区别从左到右罗列如下：

- 1) 如果m_flags等于0，mbuf只包含数据。在mbuf中有108字节的数据空间(m_dat数组)。指针m_data指向这108字节缓存中的某个位置。我们所示的m_data指向缓存的起始，但它能指向缓存中的任意位置。成员m_len指示了从m_data开始的数据的字节数。图1-6是这类mbuf的一个例子。

在图2-1中，结构m_hdr中有六个成员，它的总长是20字节。当我们查看此结构的C语言定义时，会看见前四个成员每个占用4字节而后两个成员每个占用2字节。在图2-1中我们没有区分4字节成员和2字节成员。

- 2) 第二类mbuf的m_flags值是M_PKTHDR，它指示这是一个分组首部，描述一个分组数据的第一个mbuf。数据仍然保存在这个mbuf中，但是由于分组首部占用了8字节，只有100字节的数据可存储在这个mbuf中(在m_pktdat数组中)。图1-10是这种mbuf的一个例子。

成员m_pkthdr.len的值是这个分组的mbuf链表中所有数据的总长度：即所有通过m_next指针链接的mbuf的m_len值的和，如图1-8所示。输出分组没有使用成员m_pkthdr.recvif，但对于接收的分组，它包含一个指向接收接口ifnet结构(图3-6)的指针。

- 3) 下一种mbuf不包含分组首部(没有设置M_PKTHDR)，但包含超过208字节的数据，这时用到一个叫“簇”的外部缓存(设置M_EXT)。在此mbuf中仍然为分组首部结构分配了空间，但没有用——在图2-1中，我们用阴影显示出来。Net/3分配一个大小为1024或2048字节的簇，而不是使用多个mbuf来保存数据(第一个带有100字节数据，其余的每个带有108字节数据)。在这个mbuf中，指针m_data指向这个簇中的某个位置。

Net/3版本支持七种不同的结构。定义了四种1024字节的簇(惯例值)，三种2048字节的

簇。传统上用 1024 字节的原因是为了节约存储器：如果簇的大小是 2048，对于以太网分组(最大 1500 字节)，每个簇大约有四分之一没有用。在 27.5 节中我们会看到 Net/3 TCP 发送的每个 TCP 报文段从来不超过一簇大小，因为当簇的大小为 1024 时，每个 1500 字节的以太网帧几乎三分之一未用。但是 [Mogul 1993，图 15-15] 显示了当在以太网中发送最大帧而不是 1024 字节的帧时能明显提高以太网的性能。这就是一种性能 / 存储器互换。老的系统使用 1024 字节簇来节约存储器，而拥有廉价存储器的新系统用 2048 字节的簇来提高性能。在本书中我们假定一簇的大小是 2048 字节。

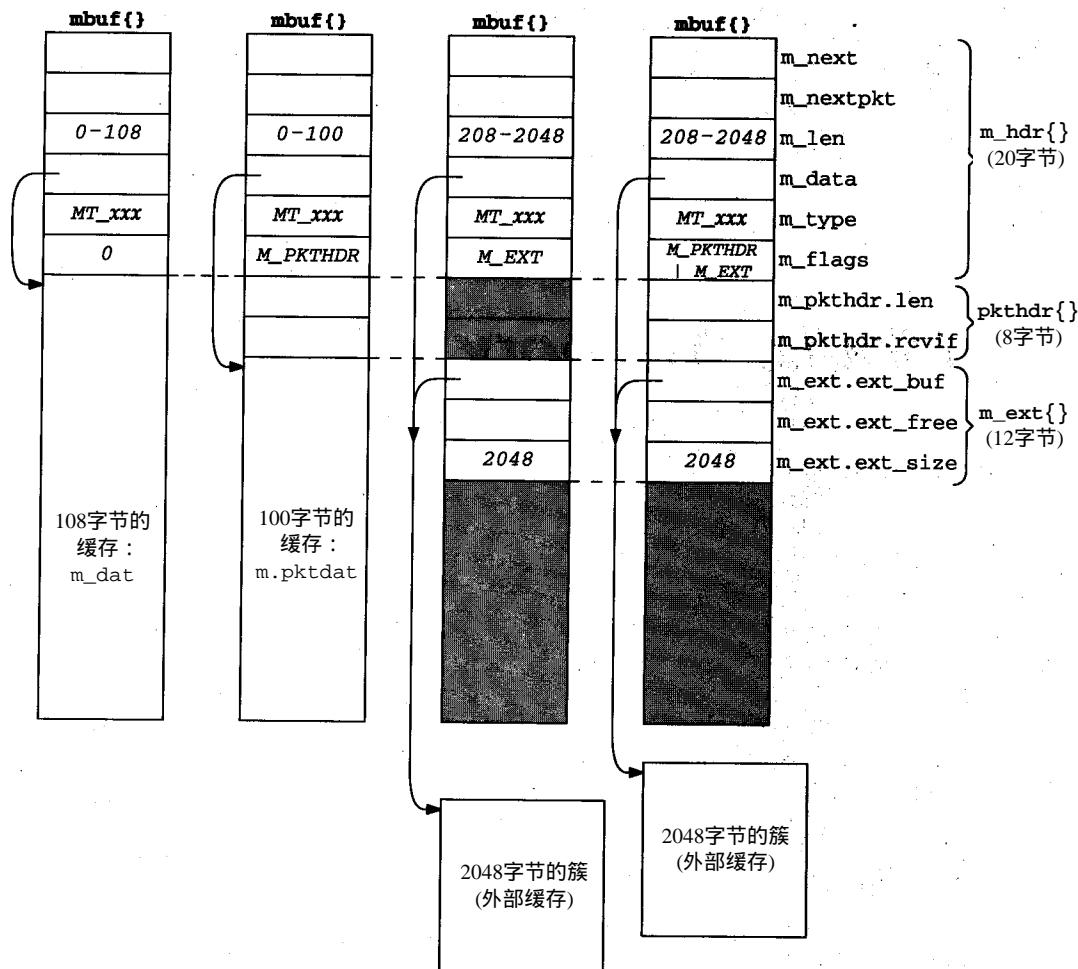


图 2-1 根据不同 m_flags 值的四种不同类型的 mbuf

不幸的是，我们所说的“簇 (cluster)”用过不同的名字。常量 MCLBYTES 是这些缓存 (1024 或 2048) 的大小，操作这些缓存的宏的名字是 MCLGET、MCLALLOC 和 MCLFREE。这就是为什么称它们为“簇”的原因。但我们还看到 mbuf 的标志是 M_EXT，它代表“外部的”缓存。最后，[Leffler et al. 1989] 称它们为映射页 (mapped page)。这后一种称法来源于它们的实现，在 2.9 节我们会看到当要求一个副本时，这些簇是可以共享的。

我们可能会希望这种类型的 mbuf 的 m_len 的最小值是 209 而不是我们在图中所示

的208。这是指，208字节数据的记录是可以存放在两个 mbuf中的，第一个mbuf存放100字节，第二个mbuf存放108字节。但在源代码中有一个差错：若超过或等于 208就分配一个簇。

4) 最后一类 mbuf包含一个分组首部，并包含超过 208字节的数据。同时设置了标志 M_PKTHDR和M_EXT。

对于图2-1，我们还有另外几点需要说明：

- mbuf结构的大小总是 128字节。这意味着图 2-1右边两个 mbuf在结构 m_ext后面的未用空间为88字节(128-20-8-12)。
- 既然有些协议(例如UDP)允许零长记录，当然就可以有 m_len为0的数据缓存。
- 在每个 mbuf中的成员 m_data指向相应缓存的开始(mbuf缓存本身或一个簇)。这个指针能指向相应缓存的任意位置，不一定是起始。

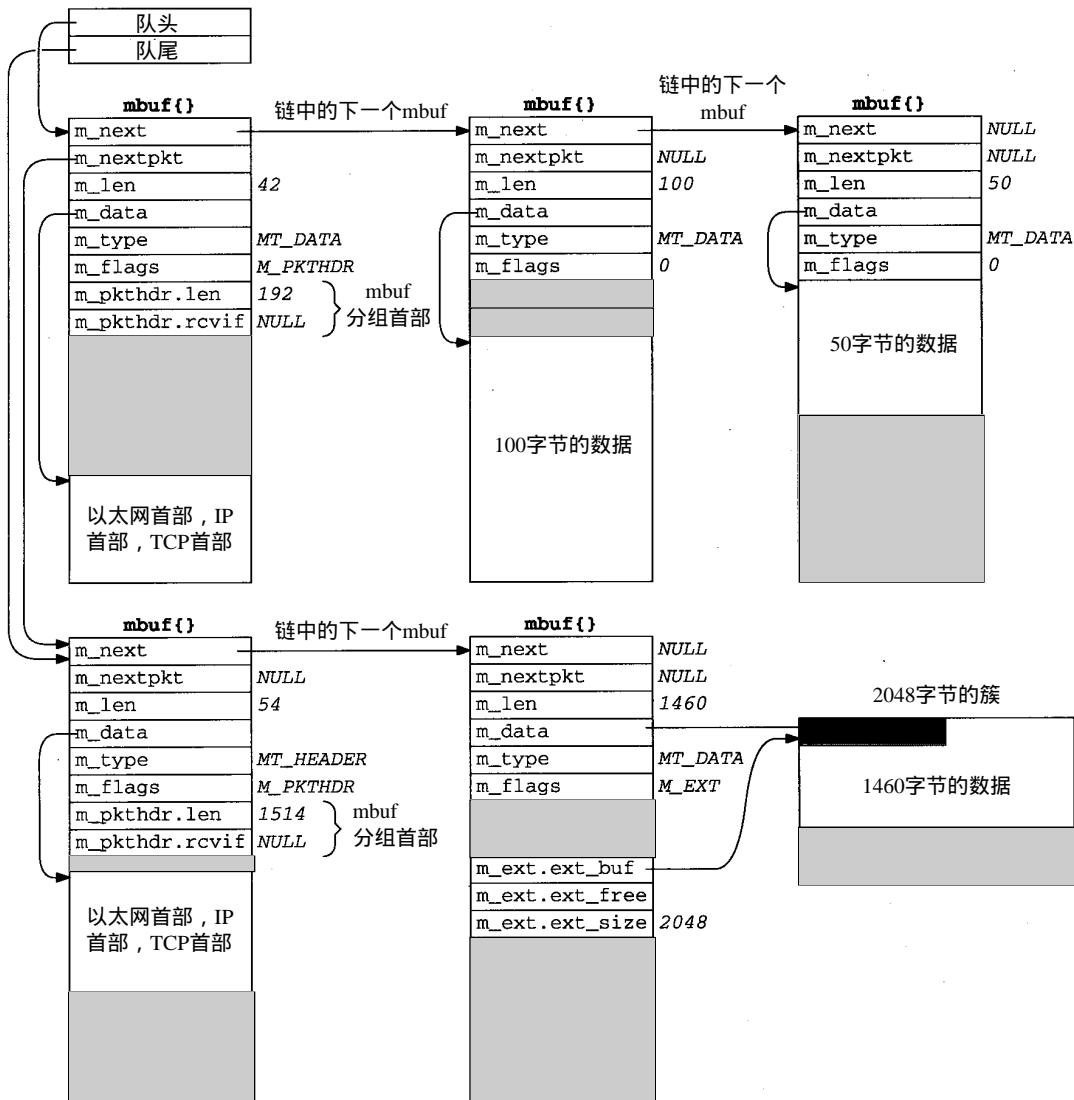


图2-2 在一个队列中的两个分组：第一个带有 192字节数据，第二个带有1514字节数据

- 带有簇的mbuf总是包含缓存的起始地址(`m_ext.ext_buf`)和它的大小(`m_ext.ext_size`)。我们在本书采用的大小为2048。成员`m_data`和`m_ext.ext_buf`值是不同的(如我们所示)，除非`m_data`也指向缓存的第一个字节。结构`m_ext`的第三个成员`ext_free`，Net/3当前未用。
- 指针`m_next`把mbuf链接在一起，把一个分组(记录)形成一条mbuf链表，如图1-8所示。
- 指针`m_nextpkt`把多个分组(记录)链接成一个mbuf链表队列。在队列中的每个分组可以是一个单独的mbuf，也可以是一个mbuf链表。每个分组的第一个mbuf包含一个分组首部。如果多个mbuf定义一个分组，只有第一个mbuf的成员`m_nextpkt`被使用——链表中其他mbuf的成员`m_nextpkt`全是空指针。

图2-2所示的是在一个队列中的两个分组的例子。它是图1-8的一个修改版。我们已经把UDP数据报放到接口输出队列中(显示出14字节的以太网首部已经添加到链表中第一个mbuf的IP首部前面)，并且第二个分组已经被添加到队列中：TCP段包含1460字节的用户数据。TCP数据包含在一个簇中，并且有一个mbuf包含了它的以太网、IP与TCP首部。通过这个簇，我们可以看到指向簇的数据指针(`m_data`)不需要指向簇的起始位置。我们所示的队列有一个头指针和一个尾指针。这就是Net/3处理接口输出队列的方法。我们给有`M_EXT`标志的mbuf还添加了一个`m_ext`结构，并且用阴影表示这个mbuf中未用的`pkthdr`结构。

带有UDP数据报分组首部的第一个mbuf的类型是`MT_DATA`，但带有TCP报文段分组首部的第一个mbuf的类型是`MT_HEADER`。这是由于UDP和TCP采用了不同的方式往数据中添加首部造成的，但没有什么不同。这两种类型的mbuf本质上一样。链表中第一个mbuf的`m_flags`的值`M_PKTHDR`指示了它是一个分组首部。

仔细的读者可能会注意到我们显示一个mbuf的图(Net/3 mbuf，图2-1)与显示一个Net/1 mbuf的图[Leffler et al. 1989, p.290]的区别。这个变化是在Net/2中造成的：添加了成员`m_flags`，把指针`m_act`改名为`m_nextpkt`，并把这个指针移到这个mbuf的前面。

在第一个mbuf中，UDP与TCP协议首部位置的不同是由于UDP调用`M_PREPEND`(图23-15和习题23.1)而TCP调用`MGETHDR`(图26-25)造成的。

2.2 代码介绍

mbuf函数在一个单独的C文件中，并且mbuf宏与各种mbuf定义都在一个单独的头文件中，如图2-3所示。

文 件	说 明
<code>sys/mbuf.h</code>	mbuf结构、mbuf宏与定义
<code>kern/uipc_mbuf.c</code>	mbuf函数

图2-3 本章讨论的文件

2.2.1 全局变量

在本章中有一个全局变量要介绍，如图2-4所示。

变 量	数 �据 类 型	说 明
mbstat	struct mbstat	mbuf的统计信息(图2-5)

图2-4 本章介绍的全局变量

2.2.2 统计

在全局结构mbstat中维护的各种统计，如图2-5所示。

mbstat成员	说 明
m_clfree	自由簇
m_clusters	从页池中获得的簇
m_drain	调用协议的drain函数来回收空间的次数
m_drops	寻找空间(未用)失败的次数
m_mbufs	从页池(未用)中获得的mbuf数
m_mtotypes[256]	当前mbuf的分配数：MT_xxx索引
m_spare	剩余空间(未用)
m_wait	等待空间(未用)的次数

图2-5 在结构mbstat 中维护的mbuf统计

这个结构能被命令netstat -m检测；图2-6所示的是一些输出示例。关于所用映射页的数量的两个值是：m_clusters(34)减m_clfree(32)——当前使用的簇数(2)和m_clusters(34)。

分配给网络的存储器的千字节数是 mbuf存储器(99×128 字节)加上簇存储器(34×2048 字节)再除以1024。使用百分比是 mbuf存储器(99×128 字节)加上所用簇的存储器(2×2048 字节)除以网络存储器总数(80千字节)，再乘100。

netstat -m output	mbstat member
<pre> 99 mbufs in use: 1 mbufs allocated to data 43 mbufs allocated to packet headers 17 mbufs allocated to protocol control blocks 20 mbufs allocated to socket names and addresses 18 mbufs allocated to socket options 2/34 mapped pages in use 80 Kbytes allocated to network (20% in use) 0 requests for memory denied 0 requests for memory delayed 0 calls to protocol drain routines </pre>	<pre> m_mtotypes[MT_DATA] m_mtotypes[MT_HEADER] m_mtotypes[MT_PCB] m_mtotypes[MT_SONAME] m_mtotypes[MT_SOOPTS] (see text) (see text) m_drops m_wait m_drain </pre>

图2-6 mbuf统计例子

2.2.3 内核统计

mbuf统计显示了在Net/3源代码中的一种通用技术。内核在一个全局变量(在本例中是结构mbstat)中保持对某些统计信息的跟踪。当内核在运行时，一个进程(在本例中是netstat程序)可以检查这些统计。

不是提供系统调用来获取由内核维护的统计，而是进程通过读取链接编辑器在内核建立时保存的信息来获得所关心的数据结构在内核中的地址。然后进程调用函数 kvm(3)，通过使用特殊文件 /dev/mem读取在内核存储器中的相应位置。如果内核数据结构从一个版本改变

为下一版本，任何读取这个结构的程序也必须改变。

2.3 mbuf的定义

处理mbuf时，我们会反复遇到几个常量。它们的值显示在图 2-7中。除了MCLBYTES定义在文件 /usr/include/machine/param.h中外，其他所有常量都定义在文件 mbuf.h中。

常量	值(字节数)	说 明
MCLBYTES	2048	一个mbuf簇(外部缓存)的大小
MHLEN	100	带分组首部的mbuf的最大数据量
MINCLSIZE	208	存储到簇中的最小数据量
MLEN	108	在正常mbuf中的最大数据量
MSIZE	128	每个mbuf的大小

图2-7 mbuf.h 中的mbuf常量

2.4 mbuf结构

图2-8所示的是mbuf结构的定义。

```
60 /* header at beginning of each mbuf: */
61 struct m_hdr {
62     struct mbuf *mh_next;           /* next buffer in chain */
63     struct mbuf *mh_nextpkt;        /* next chain in queue/record */
64     int mh_len;                   /* amount of data in this mbuf */
65     caddr_t mh_data;              /* pointer to data */
66     short mh_type;                /* type of data (Figure 2.10) */
67     short mh_flags;                /* flags (Figure 2.9) */
68 };
69 /* record/packet header in first mbuf of chain; valid if M_PKTHDR set */
70 struct pkthdr {
71     int len;                      /* total packet length */
72     struct ifnet *rcvif;           /* receive interface */
73 };
74 /* description of external storage mapped into mbuf, valid if M_EXT set */
75 struct m_ext {
76     caddr_t ext_buf;              /* start of buffer */
77     void (*ext_free) ();          /* free routine if not the usual */
78     u_int ext_size;               /* size of buffer, for ext_free */
79 };
80 struct mbuf {
81     struct m_hdr m_hdr;
82     union {
83         struct {
84             struct pkthdr MH_pkthdr;    /* M_PKTHDR set */
85             union {
86                 struct m_ext MH_ext;    /* M_EXT set */
87                 char MH_databuf[MHLEN];
88             } MH_dat;
89         } MH;
90         char M_databuf[MLEN];        /* !M_PKTHDR, !M_EXT */
91     } M_dat;
92 };
```

图2-8 mbuf 结构

```

93 #define m_next      m_hdr.mh_next
94 #define m_len       m_hdr.mh_len
95 #define m_data      m_hdr.mh_data
96 #define m_type      m_hdr.mh_type
97 #define m_flags     m_hdr.mh_flags
98 #define m_nextpkt   m_hdr.mh_nextpkt
99 #define m_act       m_nextpkt
100 #define m_pkthdr   M_dat.MH.MH_pkthdr
101 #define m_ext      M_dat.MH.MH_dat.MH_ext
102 #define m_pktdat  M_dat.MH.MH_dat.MH_databuf
103 #define m_dat      M_dat.M_databuf

```

mbuf.h

图2-8 (续)

结构mbuf是用一个m_hdr结构跟着一个联合来定义的。如注释所示，联合的内容依赖于标志M_PKTHDR和M_EXT。

93-103 这11个#define语句简化了对mbuf结构中的结构与联合的成员的访问。我们会看到这种技术普遍应用于Net/3源代码中，只要是一个结构包含其他结构或联合这种情况。

我们在前面说明了在结构mbuf中前两个成员的目的：指针m_next把mbuf链接成一个mbuf链表，而指针m_nextpkt把mbuf链表链接成一个mbuf队列。

图1-8显示了每个mbuf的成员m_len与分组首部中的成员m_pkthdr.len的区别。后者是链表中所有mbuf的成员m_len的和。

图2-9所示的是成员m_flags的五个独立的值。

m_flags	说 明
M_BCAST	作为链路层广播发送 / 接收
M_EOR	记录结束
M_EXT	此mbuf带有簇(外部缓存)
M_MCAST	作为链路层多播发送 / 接收
M_PKTHDR	形成一个分组(记录)的第一个mbuf
M_COPYFLAGS	M_PKTHDR/M_EOR/M_BCAST/M_MCAST

图2-9 m_flags 值

我们已经说明了标志M_EXT和M_PKTHDR。M_EOR在一个包含记录尾的mbuf中设置。Internet协议(例如TCP)从来不设置这个标志，因为TCP提供一个无记录边界的字节流服务。但是OSI与XNS运输层要用这个标志。在插口层我们会遇到这个标志，因为这一层是协议无关的，并且它要处理来自或发往所有运输层的数据。

当要往一个链路层广播地址或多播地址发送分组，或者要从一个链路层广播地址或多播地址接收一个分组时，在这个mbuf中要设置接下来的两个标志M_BCAST和M_MCAST。这两个常量是协议层与接口层之间的标志(图1-3)。

对于最后一个标志值M_COPYFLAGS，当一个mbuf包含一个分组首部的副本时，这个标志表明这些标志是复制的。

图2-10所示的常量MT_xxx用于成员m_type，指示存储在mbuf中的数据的类型。虽然我们认为一个mbuf是用来存放要发送或接收的用户数据，但mbuf可以存储各种不同的数据结构。回忆图1-6中的一个mbuf被用来存放一个插口地址结构，其中的目标地址用于系统调用sendto。它的m_type成员被设置为MT SONAME。

不是图2-10中所有的mbuf类型值都用于Net/3。有些已不再使用(MT_HTABLE)，还有一些不用于TCP/IP代码中，但用于内核的其他地方。例如，MT_OOBDATA用于OSI和XNS协议，但是TCP用不同方法来处理带外(out-of-band)数据(我们在29.7节说明)。当我们在本书的后面遇到其他mbuf类型时会说明它们的用法。

Mbuf m_type	用于Net/3 TCP/IP代码	说 明	存储类型
MT_CONTROL	•	外部数据协议报文	M_MBUF
MT_DATA	•	动态数据分配	M_MBUF
MT_FREE		应在自由列表中	M_FREE
MT_FTABLE	•	分片重组首部	M_FTABLE
MT_HEADER	•	分组首部	M_MBUF
MT_HTABLE		IMP主机表	M_HTABLE
MT_IFADDR		接口地址	M_IFADDR
MT_OOBDATA		加速(带外)数据	M_MBUF
MT_PCB		协议控制块	M_PCB
MT_RIGHTS		访问权限	M_MBUF
MT_RTABLE		路由表	M_RTABLE
MT SONAME	•	插口名称	M_MBUF
MT_SOOPTS	•	插口选项	M_SOOPTS
MT_SOCKET		插口结构	M_SOCKET

图2-10 成员m_type 的值

本图的最后一列所示的M_xxx值与内核为不同类型mbuf分配的存储器片有关。这里有大约60个可能的M_xxx值指派给由内核函数malloc和宏MALLOC分配的不同类型的存储器空间。图2-6所示的是来源于命令netstat -m的mbuf分配统计信息，它包括每种MT_xxx类型的统计。命令vmstat -显示了内核的存储分配统计，包括每个M_xxx类型的统计。

由于mbuf有一个固定长度(128字节)，因此对于mbuf的使用有一个限制——包含的数据不能超过108字节。Net/3用一个mbuf来存储一个TCP协议控制块(在第24章我们会涉及到)，这个mbuf的类型为MT_PCB。但是4.4BSD把这个结构的大小从108字节增加到140字节，并为这个结构使用一种不同的内核存储器分配类型。

仔细的读者会注意到图2-10中我们表明未使用MT_PCB类型的mbuf，而图2-6显示这个类型的计数不为零。Unix域协议使用这种类型的mbuf，并且mbuf的统计功能用于所有协议，而不只是Internet协议，记住这一点很重要。

2.5 简单的mbuf宏和函数

有超过两打的宏和函数来处理mbuf(分配一个mbuf，释放一个mbuf，等等)。让我们来查看几个宏与函数的源代码，看看它们是如何实现的。

有些操作既提供了宏也提供了函数。宏版本的名称是以M开头的大写字母名称，而函数是以m_开始的小写字母名称。两者区别是一种典型的时间-空间互换。宏版本在每个被用到的地方都被C预处理器展开(要求更多的代码空间)，但是它在执行时更快，因为它不需要执行函数调用(对于有些体系结构，这是费时的)。而对于函数版本，它在每个被调用的地方变成了一些指令(参数压栈，调用函数等)，要求较少的代码空间，但会花费更多的执行时间。

2.5.1 m_get函数

让我们先看一下图2-11中分配mbuf的函数：m_get。这个函数仅仅就是宏MGET的展开。

```
134 struct mbuf *
135 m_get(nowait, type)
136 int      nowait, type;
137 {
138     struct mbuf *m;
139     MGET(m, nowait, type);
140     return (m);
141 }
```

—uipc_mbuf.c

—uipc_mbuf.c

图2-11 m_get 函数：分配一个mbuf

注意，Net/3代码不使用ANSI C参数声明。但是，如果使用一个ANSI C编译器，所有Net/3系统头文件为所有的内核函数都提供了ANSI C函数原型。例如，<sys/mbuf.h>头文件中包含这样的行：

```
struct mbuf *m_get(int, int);
```

这些函数原型为所有内核函数的调用提供编译期间的参数与返回值的检查。

这个调用表明参数nowait的值为M_WAIT或M_DONTWAIT，它取决于在存储器不可用时是否要求等待。例如，当插口层请求分配一个mbuf来存储sendto系统调用(图1-6)的目标地址时，它指定M_WAIT，因为在此阻塞是没有问题的。但是当以太网设备驱动程序请求分配一个mbuf来存储一个接收的帧时(图1-10)，它指定M_DONTWAIT，因为它是作为一个设备中断处理来执行的，不能进入睡眠状态来等待一个mbuf。在这种情况下，若存储器不可用，设备驱动程序丢弃这个帧比较好。

2.5.2 MGET宏

图2-12所示的是MGET宏。调用MGET来分配存储sendto系统调用(图1-6)的目标地址的mbuf如下所示：

```
MGET(m, M_WAIT, MT_SONAME);
if (m == NULL)
    return(ENOBUFS);

154 #define MGET(m, how, type) { \
155     MALLOC((m), struct mbuf *, MSIZE, mbtypes[type], (how)); \
156     if ((m) { \
157         (m)->m_type = (type); \
158         MBUFLOCK(mbstat.m_mtotypes[type]++); \
159         (m)->m_next = (struct mbuf *)NULL; \
160         (m)->m_nextpkt = (struct mbuf *)NULL; \
161         (m)->m_data = (m)->m_dat; \
162         (m)->m_flags = 0; \
163     } else \
164         (m) = m_retry((how), (type)); \
165 }
```

—mbuf.h

—mbuf.h

图2-12 MGET 宏

虽然调用指定了M_WAIT，但返回值仍然要检查，因为，如图2-13所示，等待一个mbuf并不保证它是可用的。

154-157 MGET一开始调用内核宏 MALLOC，它是通用内核存储器分配器进行的。数组mbtypes把mbuf的MT_xxx值转换成相应的M_xxx值(图2-10)。若存储器被分配，成员m_type被设置为参数中的值。

158 用于跟踪统计每种mbuf类型的内核结构加1(mbstat)。当执行这句时，宏MBUFLOCK把它作为参数来改变处理器优先级(图1-13)，然后把优先级恢复为原值。这防止在执行语句mbstat.m_mtypes[type]++；时被网络设备中断，因为mbuf可能在内核中的各层中被分配。考虑这样一个系统，它用三步来实现一个C中的++运算：(1)把当前值装入一个寄存器；(2)寄存器加1；(3)把寄存器值存入存储器。假设计数器值为77并且MGET在插口层执行。假设执行了步骤1和2(寄存器值为78)，并且一个设备中断发生。若设备驱动也执行MGET来获得同种类型的mbuf，在存储器中取值(77)，加1(78)，并存回在存储器。当被中断执行的MGET的步骤3继续执行时，它将寄存器的值(78)存入存储器。但是计数器应为79，而不是78，这样计数器就被破坏了。

159-160 两个mbuf指针，m_next和m_nextpkt，被设置为空指针。若必要，由调用者把这个mbuf加入到一个链或队列。

161-162 最后，数据指针被设置为指向108字节的mbuf缓存的起始，而标志被设置为0。

163-164 若内核的存储器分配调用失败，调用m_retry(图2-13)。第一个参数是M_WAIT或M_DONTWAIT。

2.5.3 m_retry函数

图2-13所示的是m_retry函数。

```
92 struct mbuf *
93 m_retry(i, t)
94 int      i, t;
95 {
96     struct mbuf *m;
97     m_reclaim();
98 #define m_retry(i, t)    (struct mbuf *)0
99     MGET(m, i, t);
100 #undef m_retry
101     return (m);
102 }
```

uipc_mbuf.c

图2-13 m_retry 函数

92-97 被m_retry调用的第一个函数是m_reclaim。在7.4节我们会看到每个协议都能定义一个“drain”函数，在系统缺乏可用存储器时能被m_reclaim调用。在图10-32中我们还会发现当IP的drain函数被调用时，所有等待重新组成IP数据报的IP分片被丢弃。TCP的drain函数什么都不做，而UDP甚至就没有定义一个drain函数。

98-102 因为在调用了m_reclaim后有可能有机会得到更多的存储器，因此再次调用宏MGET，试图获得mbuf。在展开宏MGET(图2-12)之前，m_retry被定义为一个空指针。这可以防止当存储器仍然不可用时的无休止的循环：这个MGET展开会把m设置为空指针而不是调用m_retry函数。在MGET展开以后，这个m_retry的临时定义就被取消了，以防在此之后

有对MGET的其他引用。

2.5.4 mbuf锁

在本节中我们所讨论的函数和宏并不调用 spl函数，而是调用图2-12中的MBUFLOCK来保护这些函数和宏不被中断。但在宏 MALLOC的开始包含一个 splimp，在结束时有一个 splx。宏MFREE中包含同样的保护机制。由于 mbuf在内核的所有层中被分配和释放，因此内核必须保护那些用于存储器分配的数据结构。

另外，用于分配和释放 mbuf簇的宏 MCLALLOC与MCLFREE要用一个 splimp和一个 splx包括起来，因为它们修改的是一个可用簇链。

因为存储器分配与释放及簇分配与释放的宏被保护起来防止被中断，我们通常在 MGET和m_get这样的函数和宏的前后不再调用 spl函数。

2.6 m_devget和m_pullup函数

我们在讨论IP、ICMP、IGMP、UDP和TCP的代码时会遇到函数m_pullup。它用来保证指定数目的字节(相应协议首部的大小)在链表的第一个mbuf中紧挨着存放；即这些指定数目的字节被复制到一个新的mbuf并紧接着存放。为了理解m_pullup的用法，必须查看它的实现及相关的函数m_devget和宏mtod与dtom。在分析这些问题的同时我们还可以再次领会Net/3中mbuf的用法。

2.6.1 m_devget函数

当接收到一个以太网帧时，设备驱动程序调用函数m_devget来创建一个mbuf链表，并把设备中的帧复制到这个链表中。根据所接收的帧的长度(不包括以太网首部)，可能导致4种不同的mbuf链表。图2-14所示的是前两种。

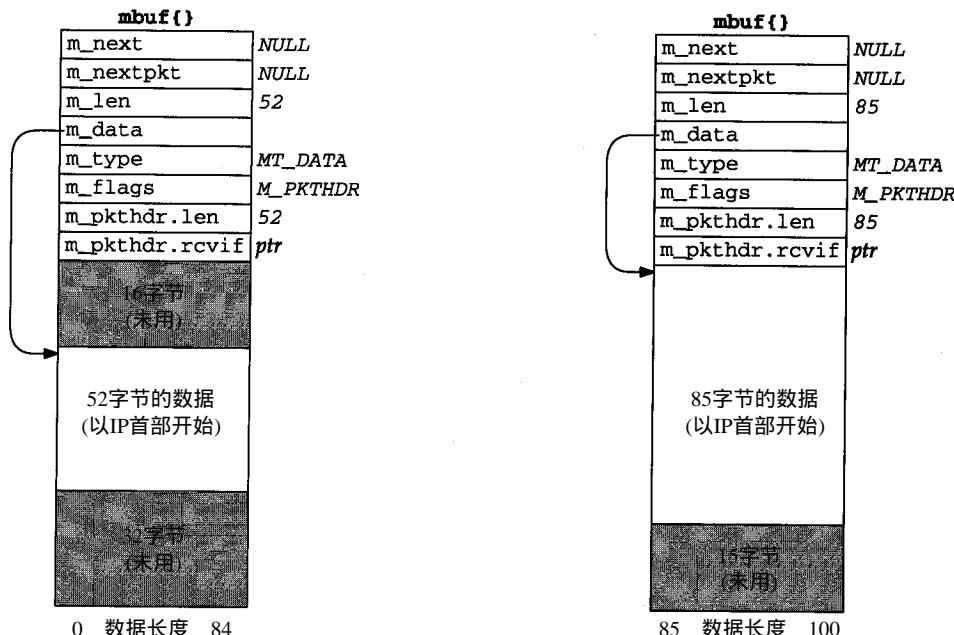


图2-14 m_devget 创建的前两种类型的mbuf

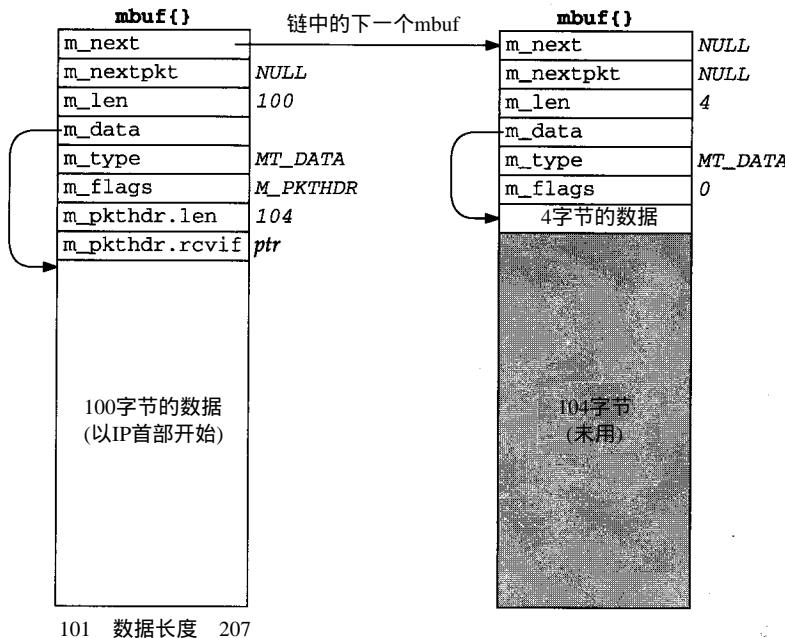


图2-15 m_devget 创建的第3种mbuf

1) 图2-14左边的mbuf用于数据的长度在0~84字节之间的情况。在这个图中，我们假定有52字节的数据：一个20字节的IP首部和一个32字节的TCP首部(标准的20字节的TCP首部加上12字节的TCP选项)，但不包括TCP数据。既然m_devget返回的mbuf数据从IP首部开始，m_len的实际最小值是28：20字节的IP首部，8字节的UDP首部和一个0长度的UDP数据报。m_devget在这个mbuf的开始保留了16字节未用。虽然14字节的以太网首部不存放在那里，还是分配了一个14字节的用于输出的以太网首部，这是同一个mbuf，用于输出。我们会遇到两个函数：icmp_reflect和tcp_respond，它们通过把接收到的mbuf作为输出mbuf来产生一个应答。在这两种情况下，接收的数据报应该少于84字节，因此很容易在前面保留16字节的空间，这样在建立输出数据报时可以节省时间。分配16字节而不是14字节的原因是为了在mbuf中用长字对准方式存储IP首部。

2) 如果数据在85~100字节之间，就仍然存放在一个分组首部mbuf中，但在开始没有16字节

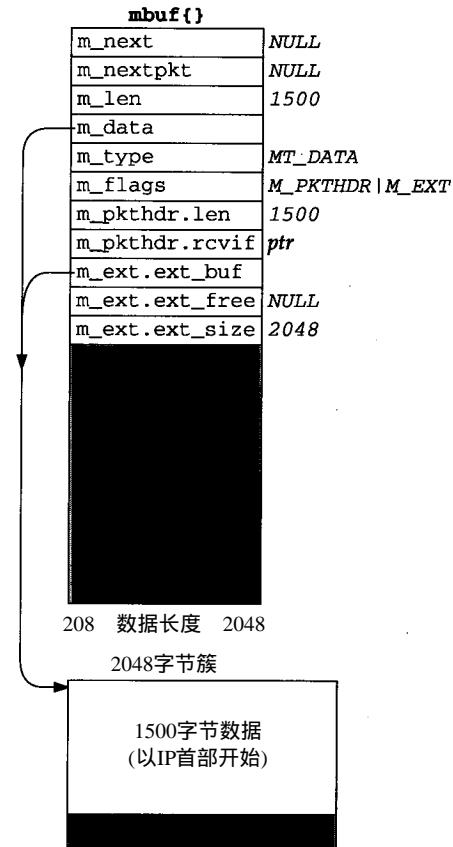


图2-16 m_devget 创建的第4种mbuf

的空间。数据存储在数组 `m_pktdat` 的开始，并且任何未用的空间放在这个数组的后面。例如在图2-14的右边的mbuf显示的就是这个例子，假设有85字节数据。

- 3) 图2-15所示的是 `m_devget` 创建的第3种mbuf。当数据在101~207字节之间时，要求有两个mbuf。前100字节存放在第一个mbuf中(有分组首部的mbuf)，而剩下的存放在第二个mbuf中。在此例中，我们显示的是一个104字节的数据报。在第一个mbuf的开始没有保留16字节的空间。
- 4) 图2-16所示的是 `m_devget` 创建的第四种mbuf。如果数据超过或等于208字节(`MINCLBYTES`)，要用一个或多个簇。图中的例子假设了一个1500字节的以太网帧。如果使用1024字节的簇，本例子需要两个mbuf，每个mbuf都有标志 `M_EXT`，和指向一个簇的指针。

2.6.2 `mtod`和`dtom`宏

宏 `mtod` 和 `dtom` 也定义在文件 `mbuf.h` 中。它们简化了复杂的 mbuf 结构表达式。

```
#define mtod(m,t) ((t)((m)->m_data))
#define dtom(x) ((struct mbuf *)((int)(x) & ~(MSIZE-1)))
```

`mtod` (“mbuf到数据”) 返回一个指向 mbuf 数据的指针，并把指针声明为指定类型。例如代码

```
struct mbuf *m;
struct ip *ip;

ip = mtod(m, struct ip *);
ip->ip_v = IPVERSION;
```

存储在 mbuf 的数据 (`m_data`) 指针 `ip` 中。C 编译器要求进行类型转换，然后代码用指针 `ip` 引用 IP 首部。我们可以看到当一个 C 结构(通常是一个协议首部)存储在一个 mbuf 中时会用到这个宏。当数据存放在 mbuf 本身(图2-14和图2-15)或存放在一个簇中(图2-16)时，可以用这个宏。

宏 `dtom` (“数据到 mbuf”) 取得一个存放在一个 mbuf 中任意位置的数据的指针，并返回这个 mbuf 结构本身的一个指针。例如，若我们知道 `ip` 指向一个 mbuf 的数据区，下面的语句序列

```
struct mbuf *m;
struct ip *ip;

m = dtom(ip);
```

把指向这个 mbuf 开始的指针存放到 `m` 中。我们知道 `MSIZE`(128) 是 2 的幂，并且内核存储器分配器总是为 mbuf 分配连续的 `MSIZE` 字节的存储块，`dtom` 仅仅是清除参数中指针的低位来发现这个 mbuf 的起始位置。

宏 `dtom` 有一个问题：当它的参数指向一个簇，或在一个簇内，如图 2-16 时，它不能正确执行。因为那里没有指针从簇内指向 mbuf 结构，`dtom` 不能被使用。这导致了下一个函数：`m_pullup`。

2.6.3 `m_pullup` 函数和连续的协议首部

函数 `m_pullup` 有两个目的。第一个是当一个协议(IP、ICMP、IGMP、UDP或TCP)发现在第一个 mbuf 的数据量 (`m_len`) 小于协议首部的最小长度(例如：IP 是 20， UDP 是 8， TCP 是 20) 时。调用 `m_pullup` 是基于假定协议首部的剩余部分存放在链表中的下一个 mbuf。

`m_pullup`重新安排 mbuf 链表，使得前 N 字节的数据被连续地存放在链表的第一个 mbuf 中。 N 是这个函数的一个参数，它必须小于或等于 100 ($MHLEN$)。如果前 N 字节连续存放在第一个 mbuf 中，则可以使用宏 `mtod` 和 `dtom`。

例如，我们在 IP 输入例程中会遇到下面这样的代码：

```
if (m->m_len < sizeof(struct ip) &&
    (m = m_pullup(m, sizeof(struct ip))) == 0) {
    ipstat.ips_toosmall++;
    goto next;
}
ip = mtod(m, struct ip *);
```

如果第一个 mbuf 中的数据少于 20(标准 IP 首部的大小)，`m_pullup` 被调用。函数 `m_pullup` 有两个原因会失败：(1) 如果它需要其他 mbuf 并且调用 `MGET` 失败；或者(2) 如果整个 mbuf 链表中的数据总数少于要求的连续字节数(即我们所说的 N ，在本例中是 20)。通常，失败是因为第二个原因。在此例中，如果 `m_pullup` 失败，一个 IP 计数器加 1，并且此 IP 数据报被丢弃。注意，这段代码假设失败的原因是 mbuf 链表中数据少于 20 字节。

实际上，在这种情况下，`m_pullup` 很少能被调用(注意，C 语言的 `&&` 操作符仅当 mbuf 长度小于期待值时才调用它)，并且当它被调用时，它通常会失败。通过查看图 2-14~图 2-16，我们可以找到它的原因：在第一个 mbuf 中，或在簇中，从 IP 首部开始有至少 100 字节的连续字节。这允许 60 字节的最大 IP 首部，并且后面跟着 40 字节的 TCP 首部(其他协议——ICMP、IGMP 和 UDP——它们的协议首部不到 40 字节)。如果 mbuf 链表中的数据可用(分组不小于协议要求的最小值)，则所要求的字节数总能连续地存放在第一个 mbuf 中。但是，如果接收的分组太小(`m_len` 小于期待的最小值)，则 `m_pullup` 被调用，并且它返回一个差错，因为在 mbuf 链表中没有所要求数目的可用数据。

源于伯克利的内核维护一个叫 `MPFail` 的变量，每次 `m_pullup` 失败时，它都加 1。在一个 Net/3 系统中曾经接收了超过 2700 万的 IP 数据报，而 `MPFail` 只有 9。计数器 `ipstat.ips_toosmall` 也是 9，并且所有其他协议计数器(ICMP、IGMP、UDP 和 TCP 等)所计的 `m_pullup` 失败次数为 0。这证实了我们的断言：大多数 `m_pullup` 的失败是因为接收的 IP 数据报太小。

2.6.4 m_pullup 和 IP 的分片与重组

使用 `m_pullup` 的第二个用途涉及到 IP 和 TCP 的重组。假定 IP 接收到一个长度为 296 的分组，这个分组是一个大的 IP 数据报的一个分片。这个从设备驱动程序传到 IP 输入的 mbuf 看起来像我们在图 2-16 中所示的一个 mbuf：296 字节的数据存放在一个簇中。我们将这显示在图 2-17 中。

问题在于，IP 的分片算法将各分片都存放在一个双向链表中，使用 IP 首部中的源与目标 IP 地址来存放向前与向后链表指针(当然，这两个 IP 地址要保存在这个链表的表头中，因为它们还要放回到重组的数据报中。我们在第 10 章讨论这个问题)。但是如果这个 IP 首部在一个簇中，如图 2-17 所示，这些链表指针会存放在这个簇中，并且当以后遍历链表时，指向 IP 首部的指针(即指向这个簇的起始的指针)不能被转换成指向 mbuf 的指针。这是我们在本节前面提到的问题：如果 `m_data` 指向一个簇时不能使用宏 `dtom`，因为没有从簇指回 mbuf 的指针。IP 分片

不能如图2-17所示的把链指针存储在簇中。

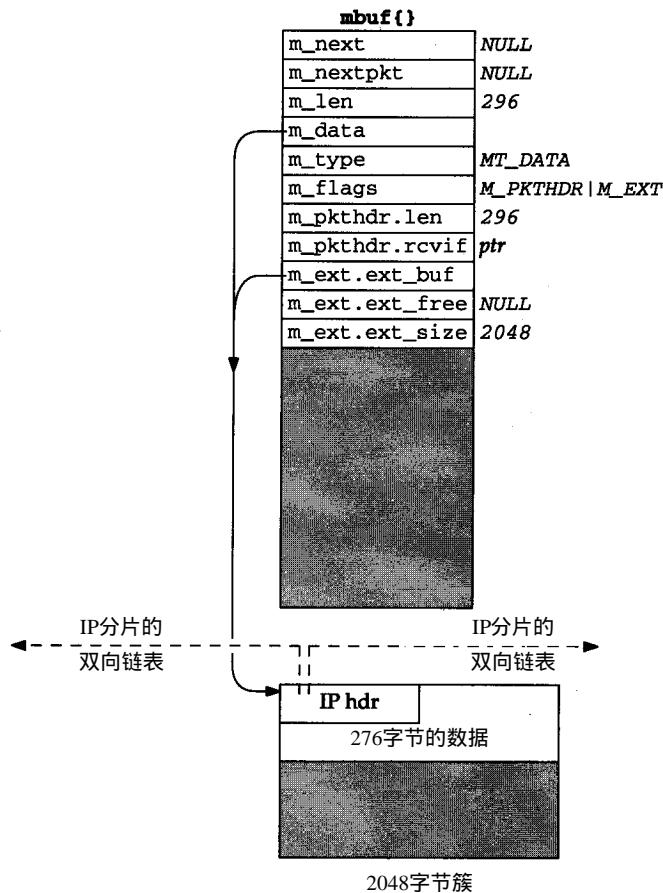


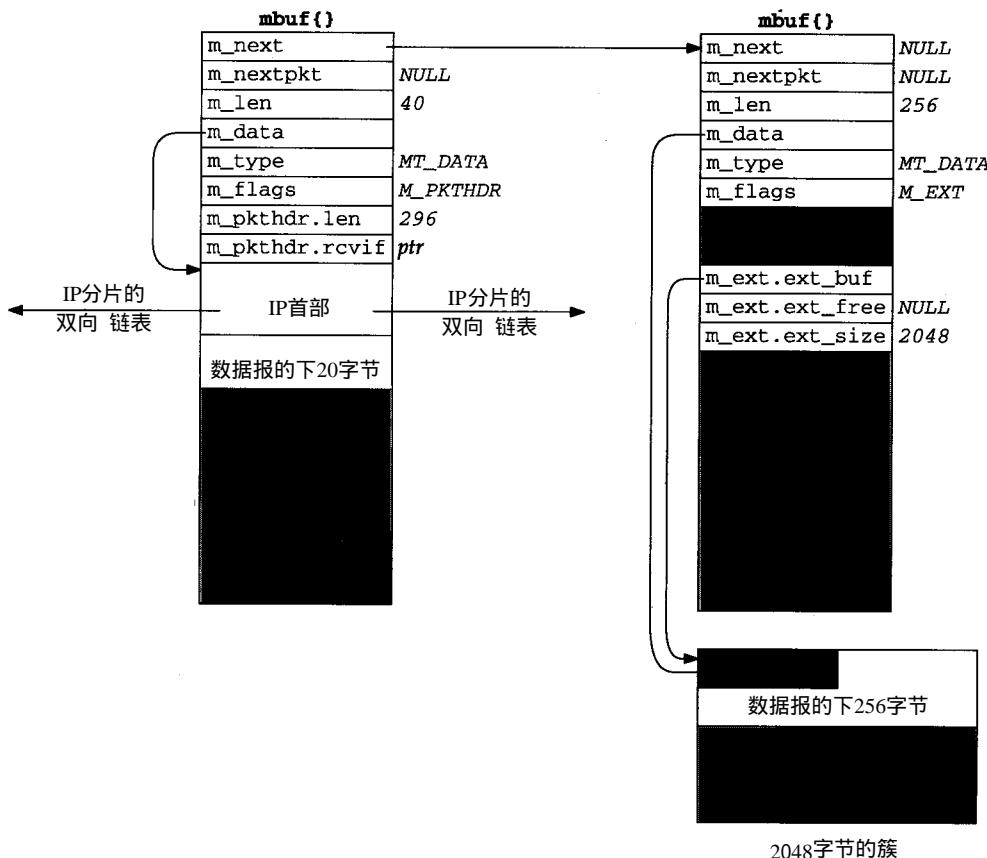
图2-17 一个长度为296的IP分片

为解决这个问题，当接收到一个分片时，若分片存放在一个簇中，IP分片例程总是调用`m_pullup`。它强行将20字节的IP首部放到它自己的mbuf中。代码如下：

```
if (m->m_flags & M_EXT) {
    if ((m = m_pullup(m, sizeof(struct ip))) == 0) {
        ipstat.ips_toosmall++;
        goto next;
    }
    ip = mtod(m, struct ip *);
}
```

图2-18所示的是在调用了`m_pullup`后得到的mbuf链表。`m_pullup`分配了一个新的mbuf，挂在链表的前面，并从簇中取走40字节放入到这个新的mbuf中。之所以取40字节而不是仅要求的20字节，是为了保证以后在IP把数据报传给一个高层协议（例如：ICMP，IGMP，UDP或TCP）时，高层协议能正确处理。采用不可思议的40（图7-17中的`max_protohdr`）是因为最大协议首部通常是一个20字节的IP首部和20字节的TCP首部的组合（这假设其他协议族，例如OSI协议，并不编译到内核中）。

在图2-18中，IP分片算法在左边的mbuf中保存了一个指向IP首部的指针，并且可以用`dtom`将这个指针转换成一个指向mbuf本身的指针。

图2-18 调用`m_pullup` 后的长度为296的IP分片

2.6.5 TCP重组避免调用`m_pullup`

重组TCP报文段使用一个不同的技术而不是调用`m_pullup`。这是因为`m_pullup`开销较大：分配存储器并且数据从一个簇复制到一个`mbuf`中。TCP试图尽可能地避免数据的复制。

卷1的第19章提到大约有一半的TCP数据是批量数据（通常每个报文段有512或更多字节的数据），并且另一半是交互式数据（这里面有大约90%的报文段包含不到10字节的数据）。因此，当TCP从IP接收报文段时，它们通常是如图2-14左边所示的格式（一个小量的交互数据，存储在`mbuf`本身）或图2-16所示的格式（批量数据，存储在一个簇中）。当TCP报文段失序到达时，它们被TCP存储到一个双向链表中。如IP分片一样，在IP首部的字段用于存放链表的指针，既然这些字段在TCP接收了IP数据报后不再需要，这完全可行。但当IP首部存放在一个簇中，要将一个链表指针转换成一个相应的`mbuf`指针时，会引起同样的问题（图2-17）。

为解决这个问题，在27.9节中我们会看到TCP把`mbuf`指针存放在TCP首部中的一些未用的字段中，提供一个从簇指向`mbuf`的指针，来避免对每个失序的报文段调用`m_pullup`。如果IP首部包含在`mbuf`的数据区（图2-18），则这个回指指针是无用的，因为宏`dtom`对这个链表指针会正常工作。但如果IP首部包含在一个簇中，这个回指指针将被使用。当我们在讨论27.9节的`tcp_reass`时，会研究实现这种技术的源代码。

2.6.6 m_pullup使用总结

我们已经讨论了关于使用m_pullup的三种情况：

- 大多数设备驱动程序不把一个IP数据报的第一部分分割到几个mbuf中。假设协议首部都紧挨着存放，则在每个协议（IP、ICMP、IGMP、UDP和TCP）中调用m_pullup的可能性很小。如果调用m_pullup，通常是因为IP数据报太小，并且m_pullup返回一个差错，这时数据报被丢弃，并且差错计数器加1。
- 对于每个接收到的IP分片，当IP数据报被存放在一个簇中时，m_pullup被调用。这意味着，几乎对于每个接收的分片都要调用m_pullup，因为大多数分片的长度大于208字节。
- 只要TCP报文段不被IP分片，接收一个TCP报文段，不论是否失序，都不需调用m_pullup。这是避免IP对TCP分片的一个原因。

2.7 mbuf宏和函数的小结

在操作mbuf的代码中，我们会遇到图2-19中所列的宏和图2-20中所列的函数。图2-19中的宏以函数原型的形式显示，而不是以#define形式来显示参数的类型。由于这些宏和函数主要用于处理mbuf数据结构并且不涉及联网问题，因此我们不查看实现它们的源代码。还有另外一些mbuf宏和函数用于Net/3源代码的其他地方，但由于我们在本书中不会遇到它们，因此没有把它们列入图中。

宏	描述
MCLGET	获得一个簇（一个外部缓存）并将m指向的mbuf中的数据指针（m_data）设置为指向这个簇。如果存储器不可用，返回时不设置mbuf中的M_EXT标志 void MCLGET(struct mbuf *m, int nowait);
MFREE	释放一个m指向的mbuf。若m指向一个簇（设置了M_EXT），这个簇的引用计数器减1，但这个簇并不被释放，直到它的引用计数器降为0（如2.9节所述）。返回m的后继（由m->m_next指向，可以为空）存放在n中 void MFREE(struct mbuf *m, struct mbuf *n);
MGETHDR	分配一个mbuf，并把它初始化为一个分组首部。这个宏与MGET（图2-12）相似，但设置了标志M_PKTHDR，并且数据指针（m_data）指向紧接分组首部后的100字节的缓存 void MGETHDR(struct mbuf *m, int nowait, int type);
MH_ALIGN	设置包含一个分组首部的mbuf的m_data，在这个mbuf数据区的尾部为一个长度为len字节的对象提供空间。这个数据指针也是长字对准方式的 void MH_ALIGN(struct mbuf *m, int len);
M_PREPEND	在m指向的mbuf中的数据的前面添加len字节的数据。如果mbuf有空间，则仅把指针（m_data）减len字节，并将长度（m_len）增加len字节。如果没有足够的空间，就分配一个新的mbuf，它的m_next指针被设置为m。一个新mbuf的指针存放在m中。并且新mbuf的数据指针被设置，这样len字节的数据放置到这个mbuf的尾部（例如，调用MH_ALIGN）。如果一个新mbuf被分配，并且原来的mbuf的分组首部标志被设置，则分组首部从老mbuf中移到新mbuf中 void M_PREPEND(struct mbuf *m, int len, int nowait);
dtom	将指向一个mbuf数据区中某个位置的指针x转换成一个指向这个mbuf的起始的指针。 struct mbuf *dtom(void *x);
mtod	将m指向的mbuf的数据区指针的类型转换成type类型 type mtod(struct mbuf *m, type);

图2-19 我们在本书中会遇到的mbuf宏

函 数	说 明
m_adj	从m指向的mbuf中移走len字节的数据。如果len是正数，则所操作的是紧排在这个mbuf的开始的len字节数据；否则是紧排在这个mbuf的尾部的len绝对值字节数据 <code>void m_adj(struct mbuf *m, int len);</code>
m_cat	把由n指向的mbuf链表链接到由m指向的mbuf链表的尾部。当我们讨论IP重组时(第10章)会遇到这个函数 <code>void m_cat(struct mbuf *m, struct mbuf *n);</code>
m_copy	这是m_copym的三参数版本，它隐含的第4个参数的值为M_DONTWAIT <code>struct mbuf * m_copy(struct mbuf *m, int offset, int len);</code>
m_copydata	从m指向的mbuf链表中复制len字节数据到由cp指向的缓存。从mbuf链表数据区起始的offset字节开始复制 <code>void m_copydata(struct mbuf *m, int offset, int len, caddr_t cp);</code>
m_copyback	从cp指向的缓存复制len字节的数据到由m指向的mbuf，数据存储在mbuf链表起始offset字节后。必要时，mbuf链表可以用其他mbuf来扩充 <code>void m_copyback(struct mbuf *m, int offset, int len, caddr_t cp);</code>
m_copym	创建一个新的mbuf链表，并从m指向的mbuf链表的开始offset处复制len字节的数据。一个新mbuf链表的指针作为此函数的返回值。如果len等于常量M_COPYALL，则从这个mbuf链表的offset开始的所有数据都将被复制。在2.9节中，我们会更详细地介绍这个函数 <code>struct mbuf *m_copym(struct mbuf *m, int offset, int len, int nowait);</code>
m_devget	创建一个带分组首部的mbuf链表，并返回指向这个链表的指针。这个分组首部的len和rcvif字段被设置为len和ifp。调用函数copy从设备接口(由buf指向)将数据复制到mbuf中。如果copy是一个空指针，调用函数bcopy。由于尾部协议不再被支持，off为0。我们在2.6节讨论了这个函数 <code>struct mbuf *m_devget(char *buf, int len, int off, struct ifnet *ifp, void (*copy)(const void *, void *, u_int));</code>
m_free	宏MFREE的函数版本 <code>struct mbuf *m_free(struct mbuf *m);</code>
m_freem	释放m指向的链表中的所有mbuf <code>void m_freem(struct mbuf * m);</code>
m_get	宏MGET的函数版本。我们在图2-12中显示过此函数 <code>struct mbuf *m_get(int nowait, int type);</code>
m_getclr	此函数调用宏MGET来得到一个mbuf，并把108字节的缓存清零 <code>struct mbuf *m_getclr(int nowait, int type);</code>
m_gethdr	宏MGETHDR的函数版本 <code>struct mbuf *m_gethdr(int nowait, int type);</code>
m_pullup	重新排列由m指向的mbuf中的数据，使得前len字节的数据连续地存储在链表中的第一个mbuf中。如果这个函数成功，则宏mtod能返回一个正好指向这个大小为len的结构。我们在2.6节讨论了这个函数 <code>struct mbuf m_pullup(struct mbuf *m, int len);</code>

图2-20 在本书中我们要遇到的mbuf函数

所有原型的参数nowait是M_WAIT或M_DONTWAIT，参数type是图2-10中所示的MT_xxx中的一个。

`M_PREPEND`的一个例子是，从图1-7转换到图1-8的过程中，当IP和UDP首部被添加到数据的前面时要调用这个宏，因为另一个 mbuf要被分配。但当这个宏再次被调用（从图1-8转换成图2-2）来添加以太网首部时，在那个 mbuf中已有存放这个首部的空间。

`M_copydata`的最后一个参数的类型是 `caddr_t`，它代表“内核地址”。这个数据类型通常定义在 `<sys/types.h>` 中，为 `char *`。它最初在内核中使用，但被某些系统调用使用时被外露出来。例如，`mmap` 系统调用，不论是4.4BSD或SVR4都把 `caddr_t` 作为第一个参数的类型并作为返回值类型。

2.8 Net/3联网数据结构小结

本节总结我们在Net/3联网代码中要遇到的数据结构类型。在Net/3内核中用到其他数据结构（感兴趣的读者可以查看头文件 `<sys/queue.h>`），但下面这些是我们在本书中要遇到的。

- 1) 一个mbuf链：一个通过 `m_next` 指针链接的mbuf链表。我们已经看过几个这样的例子。
- 2) 只有一个头指针的mbuf链的链表。mbuf链通过每个链的第一个mbuf中的 `m_nextpkt` 指针链接起来。

图2-21所示的就是这种链表。这种数据结构的例子是一个插口发送缓存和接收缓存。

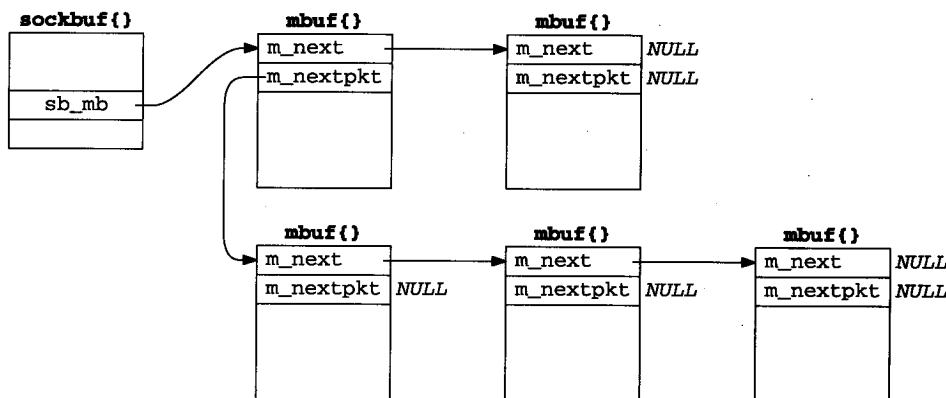


图2-21 只有头指针的mbuf链的链表

顶部的两个mbuf形成这个队列中的第一个记录，底下三个mbuf形成这个队列的第二个记录。对于一个基于记录的协议，如 UDP，我们在每个队列中能遇到多个记录。但对于像TCP这样的协议，它没有记录的边界，每个队列我们只能发现一个记录（一个mbuf链可能包含多个mbuf）。

把一个mbuf追加到队列的第一个记录中要遍历所有第一个记录的mbuf，直到遇到 `m_next` 为空的mbuf。而追加一个包含新记录的mbuf链到这个队列中，要查找所有记录直到遇到 `m_nextpkt` 为空的记录。

- 3) 一个有头指针和尾指针的mbuf链的链表。

图2-22显示的是这种类型的链表。我们在接口队列中会遇到它（图3-13），并且在图2-2中已显示过它的一个例子。

在图2-21中仅有一点改变：增加了一个尾指针，来简化增加一个新记录的操作。

- 4) 双向循环链表。

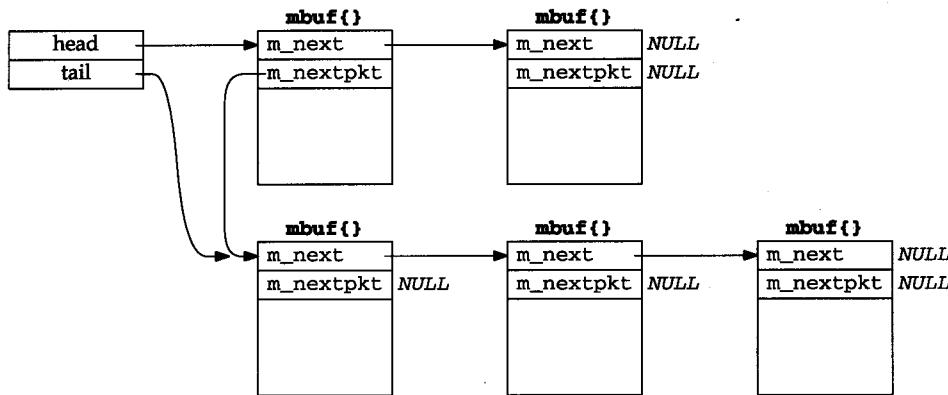


图2-22 有头指针和尾指针的链表

图2-23所示的是这种类型的链表，我们在IP分片与重装(第10章)、协议控制块(第22章)及TCP失序报文段队列(第27.9节)中会遇到这种数据结构。

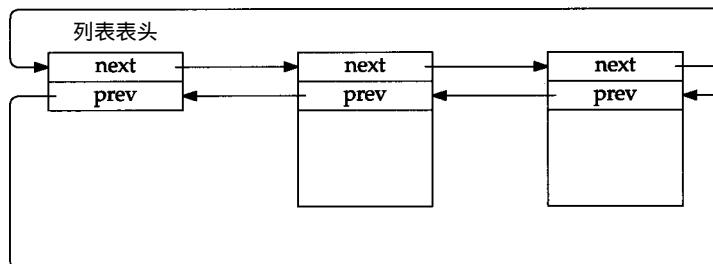


图2-23 双向循环链表

在这个链表中的元素不是 mbuf——它们是一些定义了两个相邻的指针的结构：一个 next指针跟着一个 previous指针。两个指针必须在结构的起始处。如果链表为空，表头的next和previous指针都指向这个表头本身。

在图中我们简单地把向后指针指向另一个向后指针。显然所有的指针应包含它所指向的结构的地址，即向前指针的地址(因为向前和向后指针总是放在结构的起始处)。

这种类型的数据结构能方便地向前向后遍历，并允许方便地在链表中任何位置进行插入与删除。

函数insque和remque(图10-20)被调用来对这个链表进行插入和删除。

2.9 m_copy和簇引用计数

使用簇的一个明显的好处就是在要求包含大量数据时能减少 mbuf的数目。例如，如果不使用簇，要有10个mbuf才能包含1024字节的数据：第一个mbuf带有100字节的数据，后面8个每个存放108字节数据，最后一个存放60字节数据。分配并链接10个mbuf比分配一个包含1024字节簇的mbuf开销要大。簇的一个潜在缺点是浪费空间。在我们的例子中使用一个簇(2048 + 128)要2176字节，而1280字节不到1簇(10 × 128)。

簇的另外一个好处是在多个mbuf间可以共享一个簇。在TCP输出和m_copy函数中我们遇到过这种情况，但现在我们要更详细地说明这个问题。

例如，假设应用程序执行一个 `write`，把4096字节写到TCP插口中。假设插口发送缓存原来是空的，接收窗口至少有 4096，则会发生以下操作。插口层把前 2048字节的数据放在一个簇中，并且调用协议的发送例程。TCP发送例程把这个 mbuf追加到它的发送缓存后，如图 2-24所示，并调用 `tcp_output`。结构 `socket` 中包含 `sockbuf` 结构，这个结构中存储着发送缓存 `mbuf` 链的链表的表头：`so_snd.sb_mb`。

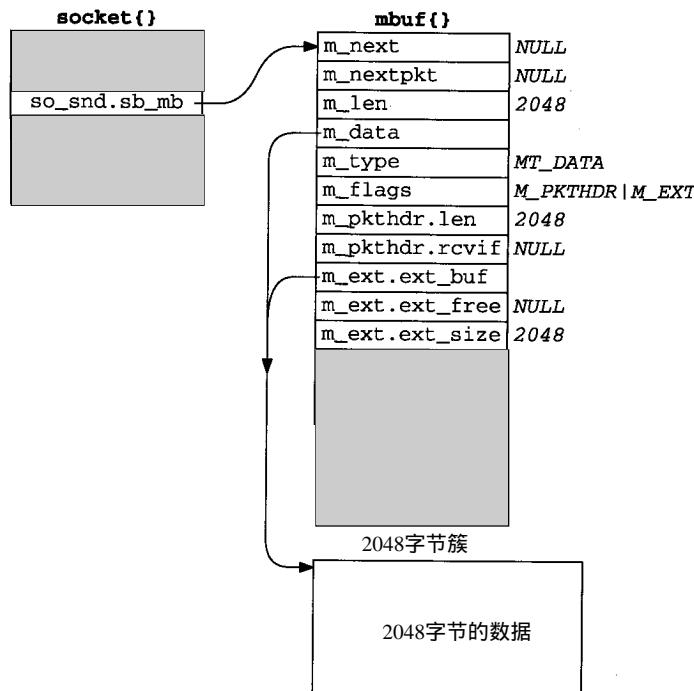


图2-24 包含2048字节数据的TCP插口发送缓存

假设这个连接(典型的是以太网)的一个TCP最大报文段大小(MSS)为1460，`tcp_output` 建立一个报文段来发送包含前 1460字节的数据。它还建立一个包含 IP和TCP首部的 mbuf，为链路层首部(16字节)预留了空间，并将这个 mbuf链传给IP输出。在接口输出队列尾部的 mbuf 链显示在图 2-25中。

在1.9节的UDP例子中，UDP用mbuf链来存放数据报，在前面添加一个 mbuf来存放协议首部，并把此链传给IP输出。UDP并不把这个 mbuf保存在它的发送缓存中。而TCP不能这样做，因为TCP是一个可靠协议，并且它必须维护一个发送数据的副本，直到数据被对方确认。

在这个例子中，`tcp_output`调用函数 `m_copy`，请求复制 1460字节的数据，从发送缓存起始位置开始。但由于数据被存放在一个簇中，`m_copy`创建一个 mbuf(图2-25的右下侧)并且对它初始化，将它指向那个已存在的簇的正确位置(此例中是簇的起始处)。这个 mbuf的长度是1460，虽然有另外 588字节的数据在簇中。我们所示的这个 mbuf链的长度是1514，包括以太网首部、IP首部和TCP首部。

在图2-25的右下侧我们还显示了这个 mbuf包含一个分组首部，但它不是链中的第一个 mbuf。当 `m_copy` 复制一个包含一个分组首部的 mbuf并且从原来 mbuf的起始地址开始复制时，分组首部也被复制下来。因为这个 mbuf不是链中的第一个 mbuf，

这个额外的分组首部被忽略。而在这个额外的分组首部中的 `m_pkthdr.len` 的值 2048 也被忽略。

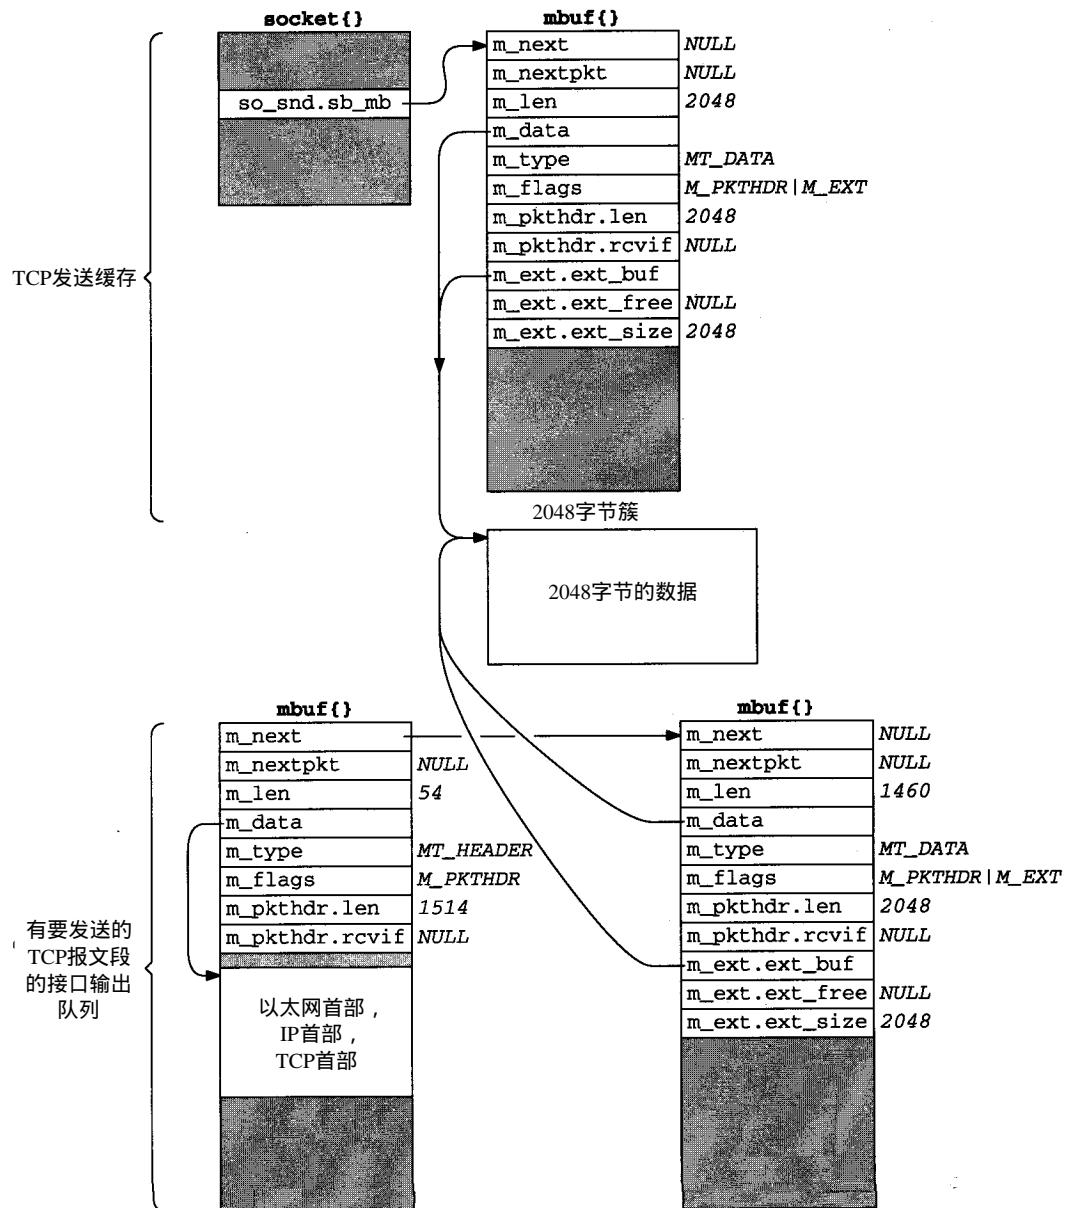


图2-25 TCP插口发送缓存和接口输出队列中的报文段

这个共享的簇避免了内核将数据从一个 mbuf 复制到另一个 mbuf 中——这节约了很多开销。它是通过为每个簇提供一个引用计数来实现的，每次另一个 mbuf 指向这个簇时计数加 1，当一个簇释放时计数减 1。仅当引用计数到达 0 时，被这个簇占用的存储器才能被其他程序使用(见习题2.4)。

例如，当图 2-25 底部的 mbuf 链到达以太网设备驱动程序并且它的内容已被复制给这个设备时，驱动程序调用 `m_freem`。这个函数释放带有协议首部的第一个 mbuf，并注意到链中第

二个mbuf指向一个簇。簇引用计数减1，但由于它的值变成了1，它仍然保存在存储器中。它不能被释放，因为它仍在TCP发送缓存中。

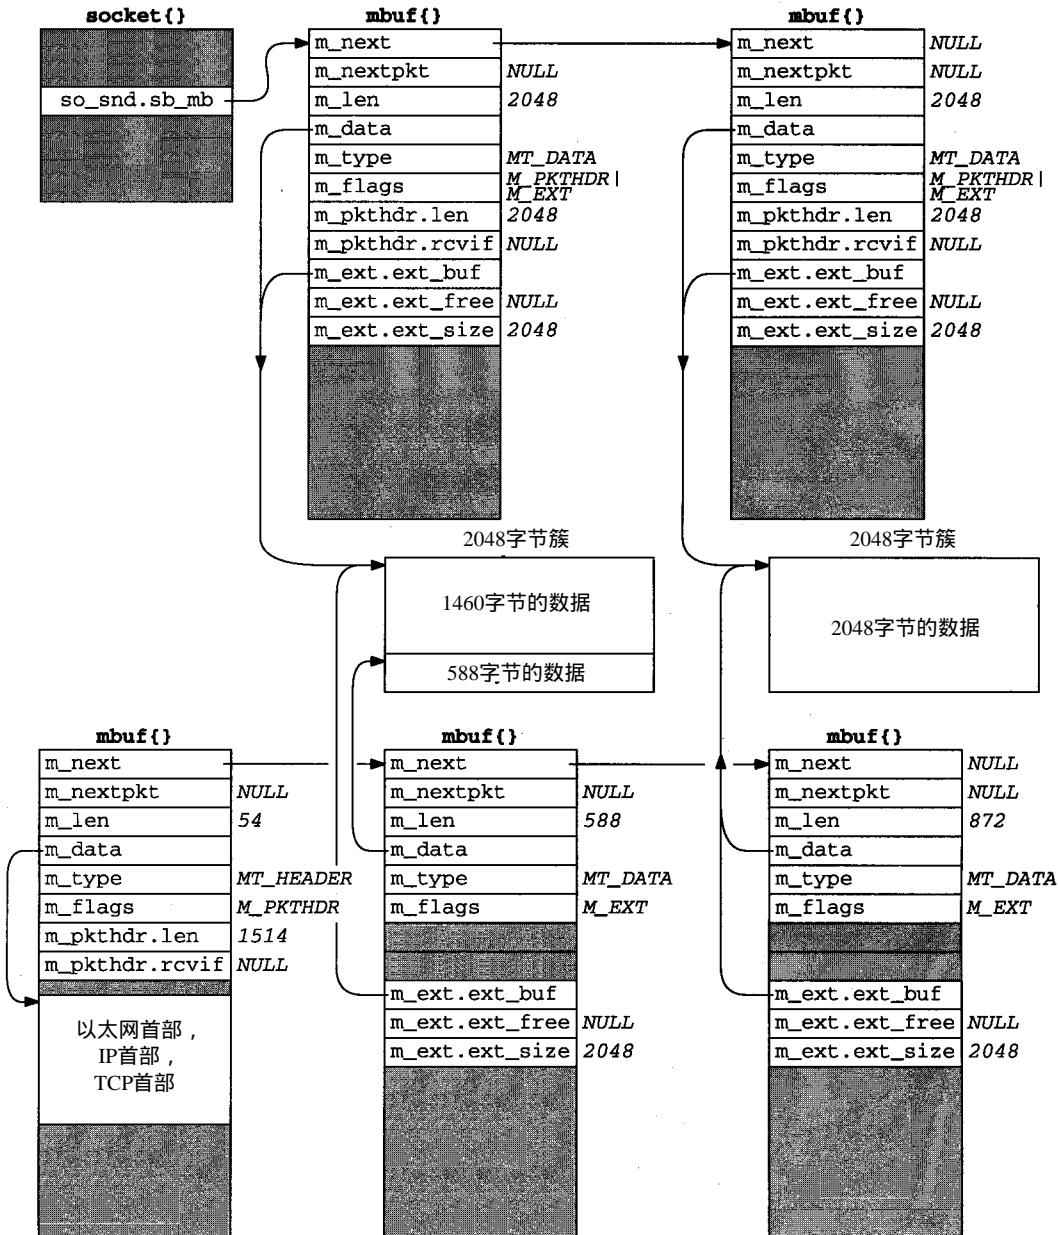


图2-26 用于发送1460字节TCP报文段的mbuf链

继续我们的例子，由于在发送缓存中剩余的588字节不能组成一个报文段，`tcp_output`在把1460字节的报文段传给IP后返回(在第26章我们要详细说明在这种条件下`tcp_output`发送数据的细节)。插口层继续处理来自应用程序的数据：剩下的2048字节被存放到一个带有一个簇的mbuf中，TCP发送例程再次被调用，并且新的mbuf被追加到插口发送缓存中。因为能发送一个完整的报文段，`tcp_output`建立另一个带有协议首部和1460字节数据的mbuf链表。

`m_copy`的参数指定了1460字节的数据在发送缓存中的起始位移和长度(1460字节)。这显示在图2-26中，并假设这个mbuf链在接口输出队列中(这个链中的第一个mbuf的长度反映了以太网首部、IP首部及TCP首部)。

这次1460字节的数据来自两个簇：前588字节来自发送缓存的第一个簇而后面的872字节来自发送缓存的第二个簇。它用两个mbuf来存放1460字节，但`m_copy`还是不复制这1460字节的数据——它引用已存在的簇。

这次我们没有在图2-26右下侧的任何mbuf中显示一个分组首部。原因是调用`m_copy`的起始位移为零。但在插口发送缓存中的第二个mbuf包含一个分组首部，而不是链中的第一个mbuf。这是函数`sosend`的特点，这个额外的分组首部被简单地忽略了。

我们在通篇中会多次遇到函数`m_copy`。虽然这个名字隐含着对数据进行物理复制，但如果数据被包含在一个簇中，却是仅引用这个簇而不是复制。

2.10 其他选择

mbuf远非完美，并且时常遭到批评。但不管怎样，它们形成了所有今天正使用着的伯克利联网代码的基础。

一种由Van Jacobson [Partridge 1993]完成的Internet协议的研究实现，它废除了支持大量连续缓存的复杂的mbuf数据结构。[Jacobson 1993]提出了一种速度能提高一到两个数量级的改进方案，还包括其他改进，及废除mbuf。

这个mbuf的复杂性是一种权衡，以避免分配大的固定长度的缓存，这样的大缓存很少能被装满。而在这种情况下，mbuf要进行设计，一个VAX-11/780有4兆存储器，是一个大系统，并且存储器是昂贵的资源，需要仔细分配。今天存储器已不昂贵了，而焦点已经转向更高的性能和代码的简单性。

mbuf的性能基于存放在mbuf中数据量。[Hutchinson and Peterson 1991]显示了处理mbuf的时间与数据量不是线性关系。

2.11 小结

在本书几乎所有的函数中我们都会遇到mbuf。它们的主要用途是在进程和网络接口之间传递用户数据时用来存放用户数据，但mbuf还用于保存其他各种数据：源地址和目标地址、插口选项等等。

根据`M_PKTHDR`和`M_EXT`标志是否被设置，这里有4种类型的mbuf：

- 无分组首部，mbuf本身带有0~108字节数据；
- 有分组首部，mbuf本身带有0~100字节数据；
- 无分组首部，数据在簇(外部缓存)中；
- 有分组首部，数据在簇(外部缓存)中。

我们查看了几个mbuf宏和函数的源代码，但不是所有的mbuf例程源代码。图2-19和图2-20提供了所有我们在本书中遇到的mbuf例程的函数原型和说明。

查看了我们要遇到的两个函数的操作：`m_devget`，很多网络设备驱动程序调用它来存

储一个收到的帧；`m_pullup`，所有输入例程调用它把协议首部连续放置在一个 `mbuf` 中。

由一个 `mbuf` 指向的簇(外部缓存)能通过 `m_copy` 被共享。例如，用于 TCP 输出，因为一个被传输的数据的副本要被发送端保存，直到数据被对方确认。比起进行物理复制来说，通过引用计数，共享簇提高了性能。

习题

- 2.1 在图2-9中定义了 `M_COPYFLAGS`。为什么不复制标志 `M_EXT`？
- 2.2 在2.6节中，我们列出了两个 `m_pullup` 失败的原因。实际上有三个原因。查看这个函数的源代码(附录B)，并发现另外一个原因。
- 2.3 为避免宏 `dtom` 遇到在2.6节中我们所讨论的问题——当数据在簇中时，为什么不仅仅给每个簇加一个指向 `mbuf` 的回指指针？
- 2.4 既然一个 `mbuf` 簇的大小是2的幂(典型的是1024或2048)，簇内的空间不能用于引用计数。查看Net/3的源代码(附录B)，并确定这些引用计数存储在什么地方。
- 2.5 在图2-5中，我们注意到两个计数器 `m_drops` 和 `m_wait` 现在没有实现。修改 `mbuf` 例程增加这些计数器。

第3章 接 口 层

3.1 引言

本章开始讨论 Net/3 在协议栈底部的接口层，它包括在本地网上发送和接收分组的硬件与软件。

我们使用术语设备驱动程序来表示与硬件及网络接口（或仅仅是接口）通信的软件，网络接口是指在一个特定网络上硬件与设备驱动器之间的接口。

Net/3 接口层试图在网络协议和连接到一个系统的网络设备的驱动器间提供一个与硬件无关的编程接口。这个接口层为所有的设备提供以下支持：

- 一套精心定义的接口函数；
- 一套标准的统计与控制标志；
- 一个与设备无关的存储协议地址的方法；
- 一个标准的输出分组的排队方法。

这里不要求接口层提供可靠的分组传输，仅要求提供最大努力（best-effort）的服务。更高协议层必须弥补这种可靠性缺陷。本章说明为所有网络接口维护的通用数据结构。为了说明相关数据结构和算法，我们参考 Net/3 中三种特定的网络接口：

- 1) 一个 AMD 7990 LANCE 以太网接口：一个能广播局域网的例子。
- 2) 一个串行线 IP(SLIP) 接口：一个在异步串行线上的点对点网络的例子。
- 3) 一个环回接口：一个逻辑网络把所有输出分组作为输入返回。

3.2 代码介绍

通用接口结构和初始化代码可在三个头文件和两个 C 文件中找到。在本章说明的设备专用初始化代码可在另外三个 C 文件中找到。所有的 8 个文件都列于图 3-1 中。

文 件	说 明
sys/socket.h	地址结构定义
net/if.h	接口结构定义
net/if_dl.h	链路层结构定义
kern/init_main.c	系统和接口初始化
net/if.c	通用接口代码
net/if_loop.c	环回设备驱动程序
net/if_sl.c	SLIP 设备驱动程序
hp300/dev/if_le.c	LANCE 以太网设备驱动程序

图 3-1 本章讨论的文件

3.2.1 全局变量

在本章中介绍的全局变量列于图 3-2 中。

变 量	数据类型	说 明
pdevinit	struct pdevinit[]	伪设备如SLIP和环回接口的初始化参数数组
ifnet	struct ifnet *	ifnet结构的列表的表头
ifnet_addrs	struct ifaddr **	指向链路层接口地址的指针数组
if_indexlim	int	数组ifnet_addrs的大小
if_index	int	上一个配置接口的索引
ifq maxlen	int	接口输出队列的最大值
hz	int	这个系统的时钟频率(次/秒)

图3-2 本章中介绍的全局变量

3.2.2 SNMP变量

Net/3内核收集了大量的各种联网统计。在大多数章节中，我们都要总结这些统计并说明它们与定义在简单网络管理协议信息库 (SNMP MIB-II)中的标准TCP/IP信息和统计之间的关系。RFC 1213 [McCloghrie and Rose 1991]说明了SNMP MIB-II，它组织成如图3-3所示的10个不同的信息组。

SNMP组	说 明
System	系统通用信息
Interfaces	网络接口信息
Address Translation	网络地址到硬件地址的映射表(不推荐使用)
IP	IP协议信息
ICMP	ICMP协议信息
TCP	TCP协议信息
UDP	UDP协议信息
EGP	EGP协议信息
Transmission	媒体专用信息
SNMP	SNMP协议信息

图3-3 MIB-II中的SNMP组

Net/3并不包括一个SNMP代理。一个针对Net/3的SNMP代理是作为一个进程来实现的，它根据SNMP的要求通过2.2节描述的机制来访问这些内核统计。

Net/3收集大多数MIB-II变量并且能被SNMP代理直接访问，而其他的变量则要通过间接的方式来获得。MIB-II变量分为三类：(1)简单变量，例如一个整数值、一个时间戳或一个字节串；(2)简单变量的列表，例如一个单独的路由项或一个接口描述项；(3)表的列表，例如整个路由表和所有接口实体的列表。

ISODE包含有一个Net/3 SNMP代理例子。ISODE的信息见附录B。

图3-4所示的是一个为SNMP接口组维护的简单变量。我们在后面的图4-7中描述SNMP接口表。

SNMP变量	Net/3变量	说 明
ifNumber	if_index + 1	if_index是系统中最后一个接口的索引值，并且起始为0；加1来获得系统中接口个数ifNumber

图3-4 在接口组中的一个简单的SNMP变量

3.3 ifnet结构

结构ifnet中包含所有接口的通用信息。在系统初始化期间，分别为每个网络设备分配一个独立的ifnet结构。每个ifnet结构有一个列表，它包含这个设备的一个或多个协议地址。图3-5说明了一个接口和它的地址之间的关系。

在图3-5中的接口显示了3个存放在ifaddr结构中的协议地址。虽然一些网络接口，例如SLIP，仅支持一个协议；而其他接口，如以太网，支持多个协议并需要多个地址。例如，一个系统可能使用一个以太网接口同时用于Internet和OSI两个协议。一个类型字段标识每个以太网帧的内容，并且因为Internet和OSI协议使用不同的编址方式，以太网接口必须有一个Internet地址和一个OSI地址。所有地址用一个链表链接起来（图3-5右侧的箭头），并且每个结构包含一个回指指针指向相关的ifnet结构（图3-5左侧的箭头）。

可能一个网络接口支持同一协议的多个地址。例如，在Net/3中可能为一个以太网接口分配两个Internet地址。

这个特点第一次是出现在Net/2中。当为一个网络重编地址时，一个接口有两个IP地址是有用的。在过渡期间，接口可以接收老地址和新地址的分组。

结构ifnet比较大，我们分五个部分来说明：

- 实现信息
- 硬件信息
- 接口统计
- 函数指针
- 输出队列

图3-6所示的是包含在结构ifnet中的实现信息。

```
80 struct ifnet {
81     struct ifnet *if_next;      /* all struct ifnets are chained */
82     struct ifaddr *if_addrlist; /* linked list of addresses per if */
83     char *if_name;            /* name, e.g. 'le' or 'lo' */
84     short if_unit;            /* sub-unit for lower level driver */
85     u_short if_index;         /* numeric abbreviation for this if */
86     short if_flags;           /* Figure 3.7 */
87     short if_timer;           /* time 'til if_watchdog called */
88     int if_pcount;             /* number of promiscuous listeners */
89     caddr_t if_bpf;            /* packet filter structure */
```

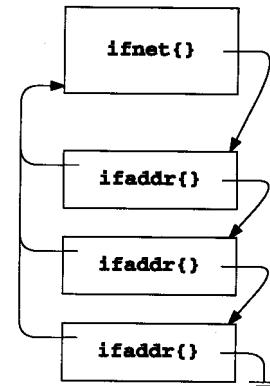


图3-5 每个ifnet结构都有一个ifaddr结构的列表

图3-6 ifnet结构：实现信息

80-82 if_next把所有接口的ifnet结构链接成一个链表。函数if_attach在系统初始化期间构造这个链表。if_addrlist指向这个接口的ifaddr结构列表（图3-16）。每个ifaddr结构存储一个要用这个接口通信的协议的地址信息。

1. 通用接口信息

83-86 `if_name`是一个短字符串，用于标识接口的类型，而 `if_unit`标识多个相同类型的实例。例如，一个系统有两个 SLIP接口，每个都有一个 `if_name`，包含两字节的“`s1`”和一个`if_unit`。对第一个接口，`if_unit`为0；对第二个接口为1。`if_index`在内核中唯一地标识这个接口，这在sysctl系统调用(见19.14节)以及路由域中要用到。

有时一个接口并不被一个协议地址唯一地标识。例如，几个 SLIP连接可以有同样的本地IP地址。在这种情况下，`if_index`明确地指明这个接口。

`if_flags`表明接口的操作状态和属性。一个进程能检查所有的标志，但不能改变在图 3-7 中“内核专用”列中作了记号的标志。这些标志用 4.4 节讨论的命令 `SIOCGIFFLAGS` 和 `SIOCSIFFLAGS` 来访问。

<code>if_flags</code>	内核专用	说 明
<code>IFF_BROADCAST</code>	•	接口用于广播网
<code>IFF_MULTICAST</code>	•	接口支持多播
<code>IFF_POINTOPOINT</code>	•	接口用于点对点网络
<code>IFF_LOOPBACK</code>	•	接口用于环回网络
<code>IFF_OACTIVE</code>	•	正在传输数据
<code>IFF_RUNNING</code>	•	资源已分配给这个接口
<code>IFF_SIMPLEX</code>	•	接口不能接收它自己发送的数据
<code>IFF_LINK0</code>	见正文	由设备驱动程序定义
<code>IFF_LINK1</code>	见正文	由设备驱动程序定义
<code>IFF_LINK2</code>	见正文	由设备驱动程序定义
<code>IFF_ALLMULTI</code>		接口正接收所有多播分组
<code>IFF_DEBUG</code>		这个接口允许调试
<code>IFF_NOARP</code>		在这个接口上不使用 ARP协议
<code>IFF_NOTRAILERS</code>		避免使用尾部封装
<code>IFF_PROMISC</code>		接口接收所有网络分组
<code>IFF_UP</code>		接口正在工作

图3-7 `if_flags` 值

`IFF_BROADCAST` 和 `IFF_POINTOPOINT` 标志是互斥的。

宏 `IFF_CANTCHANGE` 是对所有在“内核专用”列中作了记号的标志进行按位“或”操作。

设备专用标志(`IFF_LINKx`)对于一个依赖这个设备的进程可能是可修改的，也可能是不可修改的。例如，图 3-29 显示了这些标志是如何被 SLIP 驱动程序定义的。

2. 接口时钟

87 `if_timer` 以秒为单位记录时间，直到内核为此接口调用函数 `if_watchdog` 为止。这个函数用于设备驱动程序定时收集接口统计，或用于复位运行不正确的硬件。

3. BSD 分组过滤器

88-89 下面两个成员，`if_pcount` 和 `if_bpf`，支持 BSD 分组过滤器(BPF)。通过 BPF，一个进程能接收由此接口传输或接收的分组的备份。当我们讨论设备驱动程序时，还要讨论分组是如何通过 BPF 的。BPF 在第 31 章讨论。

`ifnet` 结构的下一个部分显示在图 3-8 中，它用来描述接口的硬件特性。

```

90     struct if_data {
91 /* generic interface information */
92         u_char    ifi_type;          /* Figure 3.9 */
93         u_char    ifi_addrlen;       /* media address length */
94         u_char    ifi_hdrlen;        /* media header length */
95         u_long    ifi_mtu;          /* maximum transmission unit */
96         u_long    ifi_metric;        /* routing metric (external only) */
97         u_long    ifi_baudrate;      /* linespeed */

                                         /* other ifnet members */

138 #define if_mtu      if_data.ifi_mtu
139 #define if_type      if_data.ifi_type
140 #define if_addrlen   if_data.ifi_addrlen
141 #define if_hdrlen    if_data.ifi_hdrlen
142 #define if_metric    if_data.ifi_metric
143 #define if_baudrate  if_data.ifi_baudrate

```

图3-8 ifnet 结构：接口特性

Net/3和本书使用第138行~143行的#define语句定义的短语来表示ifnet的成员。

4. 接口特性

90-92 if_type指明接口支持的硬件地址类型。图3-9列出了net/if_types.h中几个公共的if_type值。

if_type	说 明
<i>IFT_OTHER</i>	未指明
<i>IFT_ETHER</i>	以太网
<i>IFT_ISO88023</i>	IEEE 802.3以太网(CSMA/CD)
<i>IFT_ISO88025</i>	IEEE 802.5令牌环
<i>IFT_FDDI</i>	光纤分布式数据接口
<i>IFT_LOOP</i>	环回接口
<i>IFT_SLIP</i>	串行线IP

图3-9 if_type : 数据链路类型

93-94 if_addrlen是数据链路地址的长度，而if_hdrlen是由硬件附加给任何分组的头部的长度。例如，以太网有一个长度为6字节的地址和一个长度为14字节的头部(图4-8)。

95 if_mtu是接口传输单元的最大值：接口在一次输出操作中能传输的最大数据单元的字节数。这是控制网络和传输协议创建分组大小的重要参数。对于以太网来说，这个值是1500。

96-97 if_metric通常是0；其他更大的值不利于路由通过此接口。if_baudrate指定接口的传输速率，只有SLIP接口才设置它。

接口统计由图3-10中显示的下一组ifnet接口成员来收集。

5. 接口统计

98-111 这些统计大多数是不言自明的。当分组传输被共享媒体上其他传输中断时，if_collisions加1。if_noproto统计由于协议不被系统或接口支持而不能处理的分组数

(例如：仅支持IP的系统接收到一个OSI分组)。如果一个非IP分组到达一个SLIP接口的输出队列时，`if_noproto`加1。

```

98 /* volatile statistics */
99     u_long ifi_ipackets;      /* #packets received on interface */
100    u_long ifi_ierrors;       /* #input errors on interface */
101    u_long ifi_opackets;      /* #packets sent on interface */
102    u_long ifi_oerrors;       /* #output errors on interface */
103    u_long ifi_collisions;   /* #collisions on csma interfaces */
104    u_long ifi_ibytes;        /* #bytes received */
105    u_long ifi_obytes;        /* #bytes sent */
106    u_long ifi_imcasts;       /* #packets received via multicast */
107    u_long ifi_omcasts;       /* #packets sent via multicast */
108    u_long ifi_iqdrops;       /* #packets dropped on input, for this
109                                interface */
110    u_long ifi_noproto;       /* #packets destined for unsupported
111                                protocol */
112    struct timeval ifi_lastchange; /* last updated */
113 } if_data;
                                         if.h

                                         /* other ifnet members */

144 #define if_ipackets if_data.ifi_ipackets
145 #define if_ierrors if_data.ifi_ierrors
146 #define if_opackets if_data.ifi_opackets
147 #define if_oerrors if_data.ifi_oerrors
148 #define if_collisions if_data.ifi_collisions
149 #define if_ibytes if_data.ifi_ibytes
150 #define if_obytes if_data.ifi_obytes
151 #define if_imcasts if_data.ifi_imcasts
152 #define if_omcasts if_data.ifi_omcasts
153 #define if_iqdrops if_data.ifi_iqdrops
154 #define if_noproto if_data.ifi_noproto
155 #define if_lastchange if_data.ifi_lastchange
                                         if.h
```

图3-10 结构ifnet：接口统计

这些统计在Net/1中不是ifnet结构的一部分。它们被加入来支持接口的标准SNMP MIB-II变量。

`if_iqdrops`仅被SLIP设备驱动程序访问。当`IF_DROP`被调用时，SLIP和其他网络驱动程序把`if_snd.ifq_drops`(图3-13)加1。在SNMP统计加入前，`ifq_drops`就已经存在于BSD软件中了。ISODE SNMP代理忽略`if_iqdrops`而使用`if_snd.ifq_drops`。

6. 改变时间戳

112-113 `if_lastchange`记录任何统计改变的最近时间。

Net/3和本书又一次用从144行到155行的#define语句定义的短名来指明ifnet的成员。

结构ifnet的下一个部分，显示在图3-11中，它包含指向标准接口层函数的指针，它们把设备专用的细节从网络层分离出来。每个网络接口实现这些适用于特定设备的函数。

```

114 /* procedure handles */
115     int (*if_init)          /* init routine */
116             (int);
117     int (*if_output)        /* output routine (enqueue) */
118             (struct ifnet *, struct mbuf *, struct sockaddr *,
119              struct rtentry *);
120     int (*if_start)         /* initiate output routine */
121             (struct ifnet *);
122     int (*if_done)          /* output complete routine */
123             (struct ifnet *); /* (XXX not used; fake prototype) */
124     int (*if_ioctl)         /* ioctl routine */
125             (struct ifnet *, int, caddr_t);
126     int (*if_reset)
127             (int);           /* new autoconfig will permit removal */
128     int (*if_watchdog)      /* timer routine */
129             (int);

```

if.h

图3-11 结构ifnet：接口过程

7. 接口函数

114-129 在系统初始化时，每个设备驱动程序初始化它自己的 ifnet 结构，包括 7 个函数指针。图 3-12 说明了这些通用函数。

我们在 Net/3 中常会看到注释 /* XXX */。它提醒读者这段代码是易混淆的，包括不明确的副作用，或是一个更难问题的快速解决方案。在这里，它指示 if_done 不在 Net/3 中使用。

函 数	说 明
if_init	初始化接口
if_output	对要传输的输出分组进行排队
if_start	启动分组的传输
if_done	传输完成后的清除(未用)
if_ioctl	处理I/O控制命令
if_reset	复位接口设备
if_watchdog	周期性接口例程

图3-12 结构ifnet：函数指针

在第4章我们要查看以太网、SLIP和环回接口的设备专用函数，内核通过 ifnet 结构中的这些指针直接调用它们。例如，如果 ifp 指向一个 ifnet 结构，

```
(*ifp->if_start)(ifp)
```

调用这个接口的设备驱动程序的 if_start 函数。

结构 ifnet 中剩下的最后一个成员是接口的输出队列，如图 3-13 所示。

130-137 if_snd 是接口输出分组队列，每个接口有它自己的 ifnet 结构，即它自己的输出队列。 ifq_head 指向队列的第一个分组(下一个要输出的分组)， ifq_tail 指向队列最后一个分组， ifq_len 是当前队列中分组的数目，而 ifq_maxlen 是队列中允许的缓存最大个数。除非驱动程序修改它，这个最大值被设置为 50(来源于全局整数 ifq maxlen，它在编译期间根据 IFQ_MAXLEN 初始化而来)。队列作为一个 mbuf 链的链表来实现。 ifq_drops 统计

因为队列满而丢弃的分组数。图3-14列出了那些访问队列的宏和函数。

```

130     struct ifqueue {
131         struct mbuf *ifq_head;
132         struct mbuf *ifq_tail;
133         int     ifq_len;      /* current length of queue */
134         int     ifq_maxlen;   /* maximum length of queue */
135         int     ifq_drops;    /* packets dropped because of full queue */
136     } if_snd;                /* output queue */
137 };

```

图3-13 结构 ifnet : 输出队列

函数	说 明
IF_QFULL	ifq是否满 int IF_QFULL(struct ifqueue *ifq);
IF_DROP	IF_DROP仅将与ifq关联的ifq_drops加1。这个名字会引起误导：调用者丢弃这个分组 void IF_DROP(struct ifqueue *ifq);
IF_ENQUEUE	把分组m追加到ifq队列的后面。分组通过mbuf首部中的m_nextpkt链接在一起 void IF_ENQUEUE(struct ifqueue *ifq, struct mbuf *m);
IF_PREPEND	把分组m插入到ifq队列的前面 void IF_PREPEND(struct ifqueue *ifq, struct mbuf *m);
IF_DEQUEUE	从ifq队列中取走第一个分组。m指向取走的分组，若队列为空，则m为空值 void IF_DEQUEUE(struct ifqueue *ifq, struct mbuf *m);
if_qflush	丢弃队列ifq中的所有分组，例如，当一个接口被关闭了 void if_qflush(struct ifqueue *ifq);

图3-14 fiqueue 例程

前5个例程是定义在net/if.h中的宏，最后一个例程if_qflush是定义在net/if.c中的一个函数。这些宏经常出现在下面这样的程序语句中：

```

s = splimp();
if (IF_QFULL(inq)) {
    IF_DROP(inq);           /* queue is full, drop new packet */
    m_freem(m);
} else
    IF_ENQUEUE(inq, m);  /* there is room, add to end of queue */
splx(s);

```

这段代码试图把一个分组加到队列中。如果队列满，IF_DROP把ifq_drops加1，并且分组被丢弃。可靠协议如TCP会重传丢弃的分组。使用不可靠协议（如UDP）的应用程序必须自己检测和处理重传。

访问队列的语句被splimp和splx括起来，阻止网络中断，并且防止在不确定状态时网络中断服务例程访问此队列。

在splx之前调用m_freem，是因为这段mbuf代码有一个临界区运行在splimp级别上。若在m_freem前调用splx，在m_freem中进入另一个临界区（2.5节）是浪费效率的。

3.4 ifaddr结构

我们要看的下一个结构是接口地址结构，`ifaddr`，它显示在图3-15中。每个接口维护一个`ifaddr`结构的链表，因为一些数据链路，如以太网，支持多于一个的协议。一个单独的`ifaddr`结构描述每个分配给接口的地址，通常每个协议一个地址。支持多地址的另一个原因是很多协议，包括TCP/IP，支持为单个物理接口指派多个地址。虽然Net/3支持这个特性，但很多TCP/IP实现并不支持。

```
217 struct ifaddr {
218     struct ifaddr *ifa_next;      /* next address for interface */
219     struct ifnet *ifa_ifp;        /* back-pointer to interface */
220     struct sockaddr *ifa_addr;   /* address of interface */
221     struct sockaddr *ifa_dstaddr; /* other end of p-to-p link */
222 #define ifa_broadaddr ifa_dstaddr /* broadcast address interface */
223     struct sockaddr *ifa_netmask; /* used to determine subnet */
224     void (*ifa_rtrequest)();    /* check or clean routes */
225     u_short ifa_flags;          /* mostly rt_flags for cloning */
226     short ifa_refcnt;           /* references to this structure */
227     int ifa_metric;             /* cost for this interface */
228 };
```

图3-15 结构`ifaddr`

217-219 结构`ifaddr`通过`ifa_next`把分配给一个接口的所有地址链接起来，它还包括一个指向接口的`ifnet`结构的指针`ifa_ifp`。图3-16显示了结构`ifnet`与`ifaddr`之间的关系。

220 `ifa_addr`指向接口的一个协议地址，而`ifa_netmask`指向一个位掩码，它用于选择`ifa_addr`中的网络部分。地址中表示网络部分的比特在掩码中被设置为1，地址中表示主机的部分被设置为0。两个地址都存放在`sockaddr`结构中(3.5节)。图3-38显示了一个地址及其掩码结构。对于IP地址，掩码选择IP地址中的网络和子网部分。

221-223 `ifa_dstaddr`(或它的别名`ifa_broadaddr`)指向一个点对点链路上的另一端的接口协议地址或指向一个广播网中分配给接口的广播地址(如以太网)。接口的`ifnet`结构中互斥的两个标志`IFF_BROADCAST`和`IFF_POINTOPOINT`(图3-7)指示接口的类型。

224-228 `ifa_rtrequest`、`ifa_flags`和`ifa_metric`支持接口的路由查找。

`ifa_refcnt`统计对结构`ifaddr`的引用。宏`IFAFREE`仅在引用计数降到0时才释放这个结构，例如，当地址被命令`SIOCDIFADDR`删除时。结构`ifaddr`使用引用计数是因为接口和路由数据结构共享这些结构。

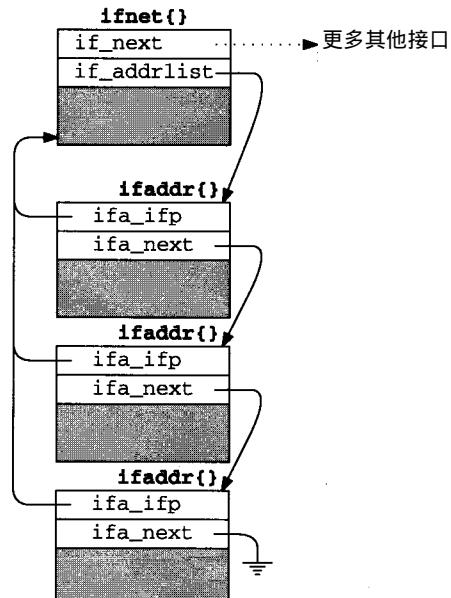


图3-16 结构`ifnet` 和`ifaddr`

如果有其他对 `ifaddr` 的引用，`IFAFREE` 将计数器加1并返回。这是一个通用的方法，除了最后一个引用外，它避免了每次都调用一个函数的开销。如果是最后一个引用，`IFAFREE` 调用函数 `ifafree`，来释放这个结构。

3.5 sockaddr 结构

一个接口的编址信息不仅仅只包括一个主机地址。Net/3在通用的 `sockaddr` 结构中维护主机地址、广播地址和网络掩码。通过使用一个通用的结构，将硬件与协议专用的地址细节相对于接口层隐藏起来。

图3-17显示的是这个结构的当前定义及早期BSD版的定义——结构 `osockaddr`。图3-18说明了这些结构的组织。

```
120 struct sockaddr {
121     u_char    sa_len;           /* total length */
122     u_char    sa_family;        /* address family (Figure 3.19) */
123     char     sa_data[14];       /* actually longer; address value */
124 };
271 struct osockaddr {
272     u_short   sa_family;        /* address family (Figure 3.19) */
273     char     sa_data[14];       /* up to 14 bytes of direct address */
274 };

```

socket.h

socket.h

图3-17 结构 `sockaddr` 和 `osockaddr`

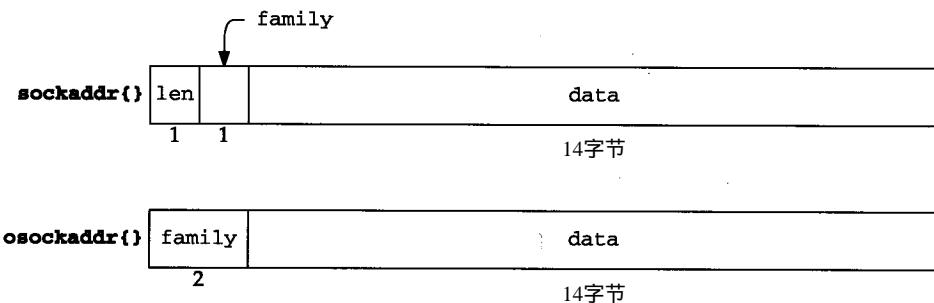


图3-18 结构 `sockaddr` 和 `osockaddr`(省略了前缀 `sa_`)

在很多图中，我们省略了成员名中的公共前缀。在这里，我们省略了 `sa_` 前缀。

1. Sockaddr结构

120-124 每个协议有它自己的地址格式。Net/3在一个 `sockaddr` 结构中处理通用的地址。`sa_len` 指示地址的长度(OSI和Unix域协议有不同长度的地址)，`sa_family` 指示地址的类型。图3-19列出了地址族(address family)常量，其中包括我们遇到的。

当指明为 `AF_UNSPEC` 时，一个 `sockaddr` 的内容要根据情况而定。大多数情况下，它包含一个以太网硬件地址。

成员 `sa_len` 和 `sa_family` 允许协议无关代码操作来自多个协议的变长的 `sockaddr` 结构。剩下的成员 `sa_data`，包含一个协议相关格式的地址。`sa_data` 定义为一个 14 字节的数组，但当 `sockaddr` 结构覆盖更大的内存空间时，`sa_data` 可能会扩展到 253 字节。`sa_len`

仅有一个字节，因此整个地址，包括 `sa_len` 和 `sa_family` 必须不超过 256 字节。

这是 C 语言的一种通用技术，它允许程序员把一个结构中的最后一个成员看成是可变长的。

每个协议定义一个专用的 `sockaddr` 结构，该结构复制成员 `sa_len` 和 `sa_family`，但按那个协议的要求来定义成员 `sa_data`。存储在 `sa_data` 中的地址是一个传输地址；它包含足够的信息来标识同一主机上的多个通信端点。在第 6 章我们要查看 Internet 地址结构 `sockaddr_in`，它包含了一个 IP 地址和一个端口号。

2. Osockaddr 结构

271-274 结构 `osockaddr` 是 4.3BSD Reno 版本以前的 `sockaddr` 定义。因为在这个定义中一个地址的长度不是显式地可用，所以它不能用来写处理可变长地址的协议无关代码。OSI 协议使用可变长地址，为了包括 OSI 协议，使得在 Net/3 的 `sockaddr` 定义中有了我们所见的改变。结构 `osockaddr` 是为了支持对以前编译的程序的二进制兼容。

在本书中我们省略了二进制兼容代码。

3.6 ifnet 与 ifaddr 的专用化

结构 `ifnet` 和 `ifaddr` 包含适用于所有网络接口和协议地址的通用信息。为了容纳其他设备和协议专用信息，每个设备定义了并且每个协议分配了一个专用化版本的 `ifnet` 和 `ifaddr` 结构。这些专用化的结构总是包含一个 `ifnet` 或 `ifaddr` 结构作为它们的第一个成员，这样无须考虑其他专用信息就能访问这些公共信息。

多数设备驱动程序通过分配一个专用化的 `ifnet` 结构的数组来处理同一类型的多个接口，但其他设备（例如环回设备）仅处理一个接口。图 3-20 所示的是我们的例子接口的专用化 `ifnet` 结构的组织。

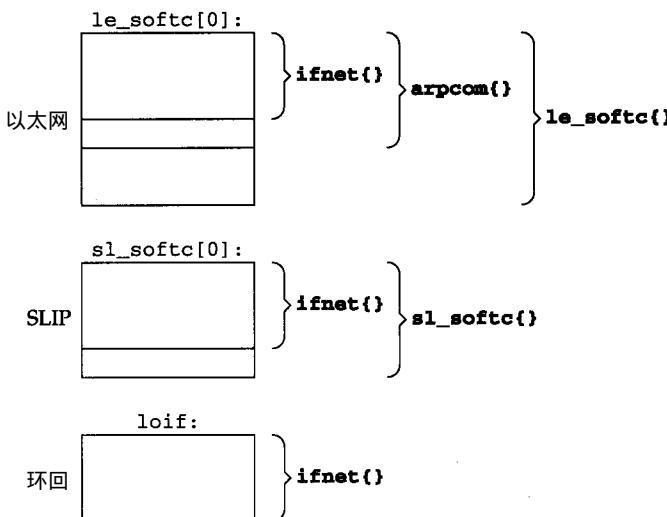


图 3-20 设备相关的结构中的 `ifnet` 结构的组织

sa_family	协 议
<code>AF_INET</code>	Internet
<code>AF_ISO</code> , <code>AF_OSI</code>	OSI
<code>AF_UNIX</code>	Unix
<code>AF_ROUTE</code>	路由表
<code>AF_LINK</code>	数据链路
<code>AF_UNSPEC</code>	(见正文)

图 3-19 `sa_family` 常量

注意，每个设备的结构以一个 `ifnet` 开始，接下来全是设备相关的数据。环回接口只声明了一个 `ifnet` 结构，因为它不要求任何设备相关的数据。在图3-20中，我们显示的以太网和 SLIP 驱动程序的结构 `softc` 带有数组下标 0，因为两个设备都支持多个接口。任何给定类型的接口的最大个数由内核建立时的配置参数来限制。

结构 `arpcom`(图3-26)对于所有以太网设备是通用的，并且包含地址解析协议(ARP)和以太网多播信息。结构 `le_softc`(图3-25)包含专用于LANCE以太网设备驱动器的其他信息。

每个协议把每个接口的地址信息存储在一个专用化的 `ifaddr` 结构的列表中。以太网协议使用一个 `in_ifaddr` 结构(6.5节)，而 OSI 协议使用一个 `iso_ifaddr` 结构。另外，当接口被初始化时，内核为每个接口分配了一个链路层地址，它在内核中标识这个接口。

内核通过分配一个 `ifaddr` 结构和两个 `sockaddr_dl` 结构(一个是链路层地址本身，一个地址掩码)来构造一个链路层地址。结构 `sockaddr_dl` 可被 OSI、ARP 和路由算法访问。图3-21显示的是一个带有一个链路层地址、一个 Internet 地址和一个 OSI 地址的以太网接口。3.11 节说明了链路层地址(`ifaddr` 和两个 `sockaddr_dl` 结构)的构造和初始化。

3.7 网络初始化概述

所有我们说明的结构是在内核初始化时分配和互相链接起来的。在本节我们大致概述一下初始化的步骤。在后面的章节，我们说明特定设备的初始化步骤和特定协议的初始化步骤。

有些设备，例如 SLIP 和环回接口，完全用软件来实现。这些伪设备用存储在全局 `pdevinit` 数组中的一个 `pdevinit` 结构来表示(图3-22)。在内核配置期间构造这个数组。例如：

```

struct pdevinit pdevinit[] = {
    { slattach, 1 },
    { loopattach, 1 },
    { 0, 0 }
};

120 struct pdevinit {
121     void      (*pdev_attach)(int); /* attach function */
122     int       pdev_count;        /* number of devices */
123 };

```

device.h

device.h

图3-22 结构 `pdevinit`

120-123 对于 SLIP 和环回接口，在结构 `pdevinit` 中，`pdev_attach` 分别被设置为

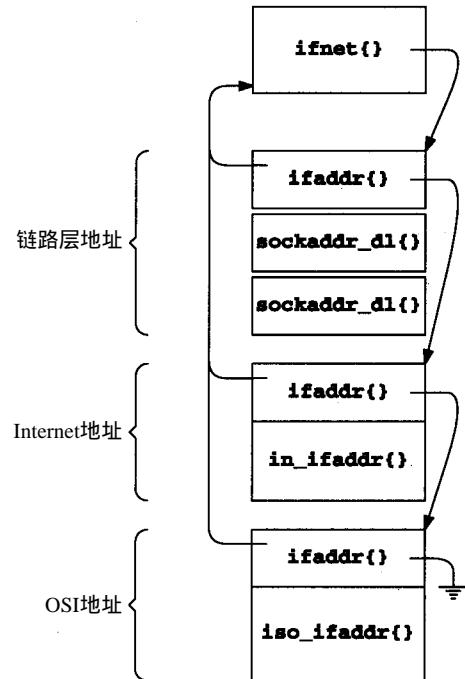


图3-21 一个包含链路层地址、Internet地址和OSI地址的接口地址列表

slattach和loopattach。当调用这个attach函数时，pdev_count作为传递的唯一参数，它指定创建的设备个数。只有一个环回设备被创建，但如果管理员适当配置SLIP项可能有多个SLIP设备被创建。

网络初始化函数从main开始显示在图3-23中。

```
70 main(framep)                                init_main.c
71 void *framep;
72 {
73
74     /* nonnetwork code */
75
76     cpu_startup();                         /* locate and initialize devices */
77
78     /* nonnetwork code */
79
80
81     /* Attach pseudo-devices. (e.g., SLIP and loopback interfaces) */
82     for (pdev = pdevinit; pdev->pdev_attach != NULL; pdev++)
83         (*pdev->pdev_attach) (pdev->pdev_count);
84
85     /*
86      * Initialize protocols. Block reception of incoming packets
87      * until everything is ready.
88      */
89     s = splimp();
90     ifinit();                           /* initialize network interfaces */
91     domaininit();                      /* initialize protocol domains */
92     splx(s);
93
94     /* nonnetwork code */
95
96
97     /* The scheduler is an infinite loop. */
98     scheduler();
99     /* NOTREACHED */
100 }
```

init_main.c

图3-23 main 函数：网络初始化

70-96 cpu_startup查找并初始化所有连接到系统的硬件设备，包括任何网络接口。

97-174 在内核初始化硬件设备后，它调用包含在pdevinit数组中的每个pdev_attach函数。

175-234 ifinit和domaininit完成网络接口和协议的初始化，并且scheduler开始内核进程调度。ifinit和domaininit在第7章讨论。

在下面几节中，我们说明以太网、SLIP和环回接口的初始化。

3.8 以太网初始化

作为cpu_startup的一部分，内核查找任何连接的网络设备。这个进程的细节超出了本书的范围。一旦一个设备被识别，一个设备专用的初始化函数就被调用。图 3-24显示的是我们的3个例子接口的初始化函数。

每个设备驱动程序为一个网络接口初始化一个专用化的ifnet结构，并调用if_attach把这个结构插入到接口链表中。显示在图3-25中的结构le_softc是我们的例子以太网驱动程序的专用化ifnet结构(图3-20)。

设 备	初始化函数
LANCE以太网	leattach
SLIP	slattach
环回	loopattach

图3-24 网络接口初始化函数

69-95 在if_le.c中声明了一个le_softc结构(有NLE成员)的数组。每个结构的第一个成员是sc_ac，一个arpcom结构，它对于所有以太网接口都是通用的，接下来是设备专用成员。宏sc_if和sc_addr简化了对结构ifnet及存储在结构arpcom(sc_ac)中的以太网地址的访问，如图3-26所示。

```
69 struct le_softc {
70     struct arpcom sc_ac;           /* common Ethernet structures */
71 #define sc_if    sc_ac.ac_if      /* network-visible interface */
72 #define sc_addr  sc_ac.ac_enaddr /* hardware Ethernet address */

    /* device-specific members */

95 } le_softc[NLE];
```

图3-25 结构le_softc

```
95 struct arpcom {
96     struct ifnet ac_if;           /* network-visible interface */
97     u_char ac_enaddr[6];         /* ethernet hardware address */
98     struct in_addr ac_ipaddr;    /* copy of ip address - XXX */
99     struct ether_multi *ac_multiaddrs; /* list of ether multicast addrs */
100    int ac_multicnt;            /* length of ac_multiaddrs list */
101};
```

图3-26 结构arpcom

2. arpcom结构

95-101 结构arpcom的第一个成员ac_if是一个ifnet结构，如图3-20所示。ac_enaddr是以太网硬件地址，它是在cpu_startup期间内核检测设备时由LANCE设备驱动程序从硬件上复制的。对于我们的例子驱动程序，这发生在函数leattach中(图3-27)。ac_ipaddr是上一个分配给此设备的IP地址。我们在6.6节讨论地址的分配，可以看到一个接口可以有多个IP地址。见习题6.3。ac_multiaddrs是一个用结构ether_multi表示的以太网多播地址的列表。ac_multicnt统计这个列表的项数。多播列表在第12章讨论。

图3-27所示的是LANCE以太网驱动程序的初始化代码。

106-115 内核在系统中每发现一个LANCE卡都调用一次leattach。

只有一个指向一个hp_device结构的参数，它包含了HP专用信息，因为它是专为HP工作站编写的驱动程序。

le指向此卡的专用化ifnet结构(图3-20)，ifp指向这个结构的第一个成员sc_if，一个通用的ifnet结构。图3-27并不包括设备专用初始化代码，它在本书中不予讨论。

```

106 leattach(hd)                                if_le.c
107 struct hp_device *hd;
108 {
109     struct lereg0 *ler0;
110     struct lereg2 *ler2;
111     struct lereg2 *lemem = 0;
112     struct le_softc *le = &le_softc[hd->hp_unit];
113     struct ifnet *ifp = &le->sc_if;
114     char    *cp;
115     int      i;

/* device-specific code */

126 /*
127  * Read the ethernet address off the board, one nibble at a time.
128  */
129 cp = (char *) (lestd[3] + (int) hd->hp_addr);
130 for (i = 0; i < sizeof(le->sc_addr); i++) {
131     le->sc_addr[i] = (*++cp & 0xF) << 4;
132     cp++;
133     le->sc_addr[i] |= *++cp & 0xF;
134     cp++;
135 }
136 printf("le%d: hardware address %s\n", hd->hp_unit,
137       ether_sprintf(le->sc_addr));

/* device-specific code */

150 ifp->if_unit = hd->hp_unit;
151 ifp->if_name = "le";
152 ifp->if_mtu = ETHERMTU;
153 ifp->if_init = leinit;
154 ifp->if_reset = lereset;
155 ifp->if_ioctl = leioctl;
156 ifp->if_output = ether_output;
157 ifp->if_start = lestart;
158 ifp->if_flags = IFF_BROADCAST | IFF_SIMPLEX | IFF_MULTICAST;
159 bpfattach(&ifp->if_bpf, ifp, DLT_EN10MB, sizeof(struct ether_header));
160 if_attach(ifp);
161 return (1);
162 }

```

if_le.c

图3-27 函数leattach

3. 从设备复制硬件地址

126-137 对于LANCE设备，由厂商指派的以太网地址在这个循环中以每次半个字节(4 bit)从设备复制到sc_addr(即sc_ac.ac_enaddr——见图3-26)。

lest_d是一个设备专用的位移表，用于定位 hp_addr的相关信息，hp_addr指向LANCE专用信息。

通过printf语句将完整的地址输出到控制台，来指示此设备存在并且可操作。

4. 初始化ifnet结构

150-157 leattach从hp_device结构把设备单元号复制到 if_unit来标识同类型的多

个接口。这个设备的 `if_name` 是“`le`”；`if_mtu` 为 1500 字节 (ETHERMTU)，以太网的最大传输单元；`if_init`、`if_reset`、`if_ioctl`、`if_output` 和 `if_start` 都指向控制网络接口的通用函数的设备专用实现。4.1 节说明这些函数。

158 所有的以太网设备都支持 `IFF_BROADCAST`。LANCE 设备不接收它自己发送的数据，因此被设置为 `IFF_SIMPLEX`。支持多播的设备和硬件还要设置 `IFF_MULTICAST`。

159-162 `bpfattach` 登记有 BPF 的接口，在图 31-8 中说明。函数 `if_attach` 把初始化了的 `ifnet` 结构插入到接口的链表中 (3.11 节)。

3.9 SLIP 初始化

依赖标准异步串行设备的 SLIP 接口在调用 `cpu_startup` 时初始化。当 `main` 直接通过 SLIP 的 `pdevinit` 结构中的指针 `pdev_attach` 调用 `slattach` 时，SLIP 伪设备被初始化。

每个 SLIP 接口由图 3-28 中的一个 `sl_softc` 结构来描述。

```
43 struct sl_softc {
44     struct ifnet sc_if;          /* network-visible interface */
45     struct ifqueue sc_fastq;    /* interactive output queue */
46     struct tty *sc_ttyp;        /* pointer to tty structure */
47     u_char *sc_mp;             /* pointer to next available buf char */
48     u_char *sc_ep;             /* pointer to last available buf char */
49     u_char *sc_buf;            /* input buffer */
50     u_int   sc_flags;          /* Figure 3.29 */
51     u_int   sc_escape;         /* =1 if last char input was FRAME_ESCAPE */
52     struct slcompress sc_comp; /* tcp compression data */
53     caddr_t sc_bpf;           /* BPF data */
54 };

```

if_slvar.h

if_slvar.h

图 3-28 结构 `sl_softc`

43-54 与所有接口结构一样，`sl_softc` 有一个 `ifnet` 结构并且后面跟着设备专用信息。

除了在 `ifnet` 结构中的输出队列外，一个 SLIP 设备还维护另一个队列 `sc_fastq`，它用于要求低时延服务的分组——典型地由交互应用产生。

`sc_ttyp` 指向关联的终端设备。指针 `sc_buf` 和 `sc_ep` 分别指向一个接收 SLIP 分组的缓存的第一个字节和最后一个字节。`sc_mp` 指向下一个接收字节的地址，并在另一个字节到达时向前移动。

SLIP 定义的 4 个标志显示在图 3-29 中。

常量	<code>sc_softc</code> 成员	说明
<code>SC_COMPRESS</code>	<code>sc_if.if_flags</code>	<code>IFF_LINK0</code> ；压缩 TCP 通信
<code>SC_NOICMP</code>	<code>sc_if.if_flags</code>	<code>IFF_LINK1</code> ；禁止 ICMP 通信
<code>SC_AUTOCOMP</code>	<code>sc_if.if_flags</code>	<code>IFF_LINK2</code> ；允许 TCP 自动压缩
<code>SC_ERROR</code>	<code>sc_flags</code>	检测到错误；丢弃接收帧

图 3-29 SLIP 的 `if_flags` 和 `sc_flags` 值

SLIP 在 `ifnet` 结构中定义了 3 个接口标志预留给设备驱动程序，另一个标志定义在结构 `sl_softc` 中。

`sc_escape` 用于串行线的 IP 封装机制 (5.3 节)，而 TCP 首部压缩信息 (29.13 节) 保留在

sc_comp中。

指针sc_bpf指向SLIP设备的BPF信息。

结构sl_softc由slattach初始化，如图3-30所示。

135-152 不像leattach一次仅初始化一个接口，内核只调用一次 slattach，并且slattach初始化所有的SLIP接口。硬件设备在内核执行cpu_startup被发现时初始化，而伪设备都是在main为这个设备调用pdev_attach函数时被初始化的。一个SLIP设备的if_mtu为296字节(SLMTU)。这包括标准的20字节IP首部、标准的20字节TCP首部和256字节的用户数据(5.3节)。

```
135 void if_sl.c
136 slattach()
137 {
138     struct sl_softc *sc;
139     int i = 0;
140
141     for (sc = sl_softc; i < NSL; sc++) {
142         sc->sc_if.if_name = "sl";
143         sc->sc_if.if_next = NULL;
144         sc->sc_if.if_unit = i++;
145         sc->sc_if.if_mtu = SLMTU;
146         sc->sc_if.if_flags =
147             IFF_POINTOPOINT | SC_AUTOCOMP | IFF_MULTICAST;
148         sc->sc_if.if_type = IFT_SLIP;
149         sc->sc_if.if_ioctl = slioctl;
150         sc->sc_if.if_output = sloutput;
151         sc->sc_if.snd.ifq_maxlen = 50;
152         sc->sc_fastq.ifq_maxlen = 32;
153         if_attach(&sc->sc_if);
154         bpfattach(&sc->sc_bpf, &sc->sc_if, DLT_SLIP, SLIP_HDRLEN);
155     }
}
```

图3-30 函数slattach

一个SLIP网络由位于一个串行通信线两端的两个接口组成。slattach在if_flags中设置IFF_POINTOPOINT、SC_AUTOCOMP和IFF_MULTICAST。

SLIP接口限制它的输出分组队列if_snd的长度为50，并且它自己的接口队列sc_fastq的长度为32。图3-42显示if_snd队列的长度默认为50(ifqmaxlen)，因此，如果设备驱动程序选择一个长度，这里的初始化是多余的。

以太网设备驱动程序不显式地设置它的输出队列的长度，它依赖于ifinit(图3-42)把它设置为系统的默认值。

if_attach需要一个指向一个ifnet结构的指针，因此slattach将sc_if的地址传递给if_attach，sc_if是一个第一个成员为结构sl_softc的ifnet结构。

专用程序slattach在内核初始化后运行(从初始化文件/etc/netstart)，并通过打开串行设备和执行ioctl命令(5.3节)添加SLIP接口和一个异步串行设备。

153-155 对于每个SLIP设备，slattach调用bpfattach来登记有BPF的接口。

3.10 环回初始化

最后显示环回接口的初始化。环回接口把输出分组放回到相应的输入队列中。接口没有

相关联的硬件设备。环回伪设备在 main 通过环回接口的 pdevinit 结构中的 pdev_attach 指针直接调用 loopattach 时初始化。图 3-31 所示的是函数 loopattach。

```

41 void
42 loopattach(n)
43 int      n;
44 {
45     struct ifnet *ifp = &loif;
46
47     ifp->if_name = "lo";
48     ifp->if_mtu = LOMTU;
49     ifp->if_flags = IFF_LOOPBACK | IFF_MULTICAST;
50     ifp->if_ioctl = loioctl;
51     ifp->if_output = looutput;
52     ifp->if_type = IFT_LOOP;
53     ifp->if_hdrlen = 0;
54     ifp->if_addrlen = 0;
55     if_attach(ifp);
56     bpfattach(&ifp->if_bpf, ifp, DLT_NULL, sizeof(u_int));
56 }

```

if_loop.c

图3-31 环回接口初始化

41-56 环回 if_mtu 被设置为 1536 字节 (LOMTU)。在 if_flags 中设置 IFF_LOOPBACK 和 IFF_MULTICAST。一个环回接口没有链路首部和硬件地址，因此 if_hdrlen 和 if_addrlen 被设置为 0。if_attach 完成 ifnet 结构的初始化并且 bpfattach 登记有 BPF 的环回接口。

环回 MTU 至少有 1576(40 + 3 × 512) 留给一个标准的 TCP/IP 首部。例如 Solaris 2.3 环回 MTU 设置为 8232(40 + 8 × 1024)。这些计算基于 Internet 协议；而其他协议可能有大于 40 字节的默认首部。

3.11 if_attach 函数

前面显示的三个接口初始化函数都调用 if_attach 来完成接口的 ifnet 结构的初始化，并把这个结构插入到先前配置的接口的列表中。在 if_attach 中，内核也为每个接口初始化并分配一个链路层地址。图 3-32 说明了由 if_attach 构造的数据结构。

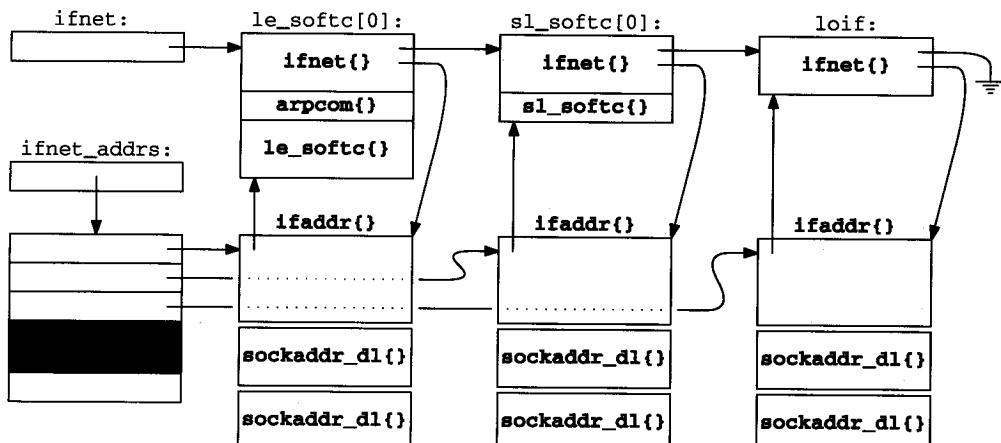


图3-32 ifnet 列表

在图3-32中，`if_attach`被调用了三次：以一个`le_softc`结构为参数从`leattach`调用，以一个`sl_softc`结构为参数从`slattach`调用，以一个通用`ifnet`结构为参数从`loopattach`调用。每次调用时，它向`ifnet`列表中添加一个新的`ifnet`结构，为这个接口创建一个链路层`ifaaddr`结构(包含两个`sockaddr_dl`结构，图3-33)，并且初始化`ifnet_addrs`数组中的一项。

```

55 struct sockaddr_dl {
56     u_char    sdl_len;           /* Total length of sockaddr */
57     u_char    sdl_family;       /* AF_LINK */
58     u_short   sdl_index;        /* if != 0, system given index for
59                                interface */
60     u_char    sdl_type;         /* interface type (Figure 3.9) */
61     u_char    sdl_nlen;         /* interface name length, no trailing 0
62                                reqd. */
63     u_char    sdl_alen;         /* link level address length */
64     u_char    sdl_slen;         /* link layer selector length */
65     char      sdl_data[12];      /* minimum work area, can be larger;
66                                contains both if name and ll address */
67 };
68 #define LLADDR(s) ((caddr_t)((s)->sdl_data + (s)->sdl_nlen))

```

图3-33 结构`sockaddr_dl`

图3-20显示了包含在`le_softc[0]`和`sl_softc[0]`中嵌套的结构。

初始化以后，接口仅配置链路层地址。例如，IP地址直到后面讨论的`ifconfig`程序才配置(6.6节)。

链路层地址包含接口的一个逻辑地址和一个硬件地址(如果网络支持，例如`le0`的一个48bit以太网地址)。在ARP和OSI协议中要用到这个硬件地址，而一个`sockaddr_dl`中的逻辑地址包含一个名称和这个接口在内核中的索引数值，它支持用于在接口索引和关联`ifaaddr`结构(`ifa_ifwithnet`，图6-32)间相互转换的表查找。

结构`sockaddr_dl`显示在图3-33中。

55-57 回忆图3-18，`sdl_len`指明了整个地址的长度，而`sdl_family`指明了地址族类，在此例中为`AF_LINK`。

58 `sdl_index`在内核中标识接口。图3-32中的以太网接口会有一个为1的索引，SLIP接口的索引为2，而环回接口的索引为3。全局整数变量`if_index`包含的是内核最近分配的一个索引值。

60 `sdl_type`根据这个数据链路地址的`ifnet`结构的成员`if_type`进行初始化。

61-68 除了一个数字索引，每个接口有一个由结构`ifnet`的成员`if_name`和`if_unit`组成的文本名称。例如，第一个SLIP接口叫“`s10`”，而第二个叫“`s11`”。文本名称存储在数组`sdl_data`的前面，并且`sdl_nlen`为这个名称的字节长度(在我们的SLIP例子中为3)。

数据链路地址也存储在这个结构中。宏`LLADDR`将一个指向`sockaddr_dl`结构的指针转换成一个指向这个文本名称的第一个字节的指针。`sdl_alen`是硬件地址的长度。对于一个以太网设备，48bit硬件地址位于结构`sockaddr_dl`的这个文本名称的前面。图3-38所示的是一个初始化了的`sockaddr_dl`结构。

Net/3不使用sdl_slen。

if_attach更新两个全局变量。第一个是if_index，它存放系统中的最后一个接口的索引；第二个是ifnet_addrs，它指向一个ifaddr指针的数组。这个数组的每项都指向一个接口的链路层地址。这个数组提供对系统中每个接口的链路层地址的快速访问。

函数if_attach较长，并且有几个奇怪的赋值语句。从图3-34开始，我们分5个部分讨论这个函数。

59-74 if_attach有一个参数：ifp，这是一个指向ifnet结构的指针，由网络设备驱动程序初始化。Net/3在一个链表中维护所有这些ifnet结构，全局指针ifnet指向这个链表的首部。while循环查找链表的尾部，并将链表尾部的空指针的地址存储到p中。在循环后，新ifnet结构被接到这个ifnet链表的尾部，if_index加1，并且将新索引值赋给ifp->if_index。

if.c

```

59 void
60 if_attach(ifp)
61 struct ifnet *ifp;
62 {
63     unsigned socksize, ifasize;
64     int      namelen, unitlen, masklen, ether_output();
65     char    workbuf[12], *unitname;
66     struct ifnet **p = &ifnet; /* head of interface list */
67     struct sockaddr_dl *sdl;
68     struct ifaddr *ifa;
69     static int if_indexlim = 8; /* size of ifnet_addrs array */
70     extern void link_rtrequest();

71     while (*p)           /* find end of interface list */
72         p = &((*p)->if_next);
73     *p = ifp;
74     ifp->if_index = ++if_index; /* assign next index */

75     /* resize ifnet_addrs array if necessary */
76     if (ifnet_addrs == 0 || if_index >= if_indexlim) {
77         unsigned n = (if_indexlim <= 1) * sizeof(ifa);
78         struct ifaddr **q = (struct ifaddr **)
79             malloc(n, M_IFADDR, M_WAITOK);

80         if (ifnet_addrs) {
81             bcopy((caddr_t) ifnet_addrs, (caddr_t) q, n / 2);
82             free((caddr_t) ifnet_addrs, M_IFADDR);
83         }
84         ifnet_addrs = q;
85     }

```

if.c

图3-34 函数if_attach：分配接口索引

1. 必要时调整ifnet_addrs数组的大小

75-85 第一次调用if_attach时，数组ifnet_addrs不存在，因此要分配16(16=8<<1)项的空间。当数组满时，一个两倍大的新数组被分配，并且老数组中的项被复制到新的数组中。

if_indexlim是if_attach私有的一个静态变量。if_indexlim通过<<操作符来更新。

图3-34中的函数malloc和free不是同名的标准C库函数。内核版的第二个参数指明一个

类型，内核中可选的诊断代码用它来检测程序错误。如果 `malloc` 的第三个参数为 `M_WAITOK`，且函数需要等待释放的可用内存，则阻塞调用进程。如果第三个参数为 `M_DONTWAIT`，则当内存不可用时，函数不阻塞并返回一个空指针。

函数 `if_attach` 的下一部分显示在图 3-35 中，它为接口准备一个文本名称并计算链路层地址的长度。

```

86  /* create a Link Level name for this device */
87  unitname = sprint_d((u_int) ifp->if_unit, workbuf, sizeof(workbuf));
88  namelen = strlen(ifp->if_name);
89  unitlen = strlen(unitname);

90  /* compute size of sockaddr_dl structure for this device */
91 #define _offsetof(t, m) ((int)((caddr_t)&((t *)0)->m))
92  masklen = _offsetof(struct sockaddr_dl, sdl_data[0]) +
93  unitlen + namelen;
94  socksiz = masklen + ifp->if_addrlen;
95 #define ROUNDUP(a) (1 + (((a) - 1) | (sizeof(long) - 1)))
96  socksiz = ROUNDUP(socksiz);
97  if (socksiz < sizeof(*sdl))
98      socksiz = sizeof(*sdl);
99  ifasize = sizeof(*ifa) + 2 * socksiz;

```

图3-35 `if_attach` 函数：计算链路层地址大小

2. 创建链路层名称并计算链路层地址的长度

86-99 `if_attach` 用 `if_unit` 和 `if_name` 组装接口的名称。函数 `sprint_d` 将 `if_unit` 的数值转换成一个串并存储到 `workbuf` 中。`masklen` 是 `sockaddr_dl` 数组中 `sdl_data` 前面的信息所占用的字节数加上这个接口的文本名称的大小(`namelen + unitlen`)。函数对 `socksiz` 进行上舍入，`socksiz` 是 `masklen` 加上硬件地址长度(`if_addrlen`)，上舍入为一个长整型(ROUNDUP)。如果它小于一个 `sockaddr_dl` 结构的长度，就使用标准的 `sockaddr_dl` 结构。`ifasize` 是一个 `ifaddr` 结构的大小加上两倍的 `socksiz`，因此，它能容纳结构 `sockaddr_dl`。

在函数的下一个部分中，`if_attach` 分配结构并将结构连接起来，如图 3-36 所示。

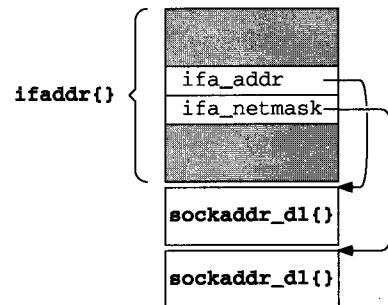


图3-36 在 `if_attach` 中分配的链路层地址和掩码

图3-36中，在 `ifaddr` 结构与两个 `sockaddr_dl` 结构间有一个空隙来说明它们分配在一个连续的内存中但没有定义在一个 C 结构中。

像图3-36所示的组织还出现在结构 `in_ifaddr` 中；这个结构的通用 `ifaddr` 部分中的指针指向在这个结构的设备专用部分中的专用化 `sockaddr` 结构，在本例中是结构 `sockaddr_dl`。图3-37所示的是这些结构的初始化。

3. 地址

100-116 如果有足够的内存可用，`bzero` 把新结构清零，并且 `sdl` 指向紧接着 `ifnet` 结构的第一个 `sockaddr_dl`。若没有可用内存，代码被忽略。

`sdl_len` 被设置为结构 `sockaddr_dl` 的长度，并且 `sdl_family` 被设置为 `AF_LINK`。

用if_name和unitname组成的文本名称存放在 sdl_data中，而它的长度存放在 sdl_nlen中。接口的索引被复制到 sdl_index中，而接口的类型被复制到 sdl_type中。分配的结构被插入到数组 ifnet_addrs中，并通过 ifa_ifp和ifa_addrlist链接到结构ifnet。最后，结构 sockaddr_dl用ifa_addr连接到ifnet结构。以太网接口用 arp_rtrequest取代默认函数link_rtrequest。环回接口装入函数loop_rtrequest。我们在第19章和第21章讨论ifa_rtrequest和arp_rtrequest。而linkrtrequest和loop_rtrequest留给读者自己去研究。以上完成了第一个 sockaddr_dl结构的初始化。

```

100    if (ifa = (struct ifaddr *) malloc(ifasize, M_IFADDR, M_WAITOK)) {
101        bzero((caddr_t) ifa, ifasize);
102        /* First: initialize the sockaddr_dl address */
103        sdl = (struct sockaddr_dl *) (ifa + 1);
104        sdl->sdl_len = socksize;
105        sdl->sdl_family = AF_LINK;
106        bcopy(ifp->if_name, sdl->sdl_data, namelen);
107        bcopy(unitname, namelen + (caddr_t) sdl->sdl_data, unitlen);
108        sdl->sdl_nlen = (namelen += unitlen);
109        sdl->sdl_index = ifp->if_index;
110        sdl->sdl_type = ifp->if_type;
111        ifnet_addrs[if_index - 1] = ifa;
112        ifa->ifa_ifp = ifp;
113        ifa->ifa_next = ifp->if_addrlist;
114        ifa->ifa_rtrequest = link_rtrequest;
115        ifp->if_addrlist = ifa;
116        ifa->ifa_addr = (struct sockaddr *) sdl;
117        /* Second: initialize the sockaddr_dl mask */
118        sdl = (struct sockaddr_dl *) (socksize + (caddr_t) sdl);
119        ifa->ifa_netmask = (struct sockaddr *) sdl;
120        sdl->sdl_len = masklen;
121        while (namelen != 0)
122            sdl->sdl_data[--namelen] = 0xff;
123    }

```

图3-37 函数if_attach：分配并初始化链路层地址

4. 掩码

117-123 第二个sockaddr_dl结构是一个比特掩码，用来选择出现在第一个结构中的文本名称。ifa_netmask从结构 ifaddr指向掩码结构(在这里是选择接口文本名称而不是网络掩码)。while循环把与名称对应的那些字节的每个比特都置为1。

图3-38所示的是我们以太网接口例子的两个初始化了的 sockaddr_dl结构。它的if_name为“le”，if_unit为0，if_index为1。

图3-38中所示的是ether_ifattach对这个结构初始化后的地址(图3-41)。

图3-39所示的是第一个接口被if_attach连接后的结构。

在if_attach的最后，以太网设备的函数ether_ifattach被调用，如图3-40所示。

124-127 开始不调用ether_ifattach(例如：从leattach)，是因为它要把以太网硬件地址复制到if_attach分配的sockaddr_dl中。

XXX注释表示作者发现在此处插入代码比修改所有的以太网驱动程序要容易。

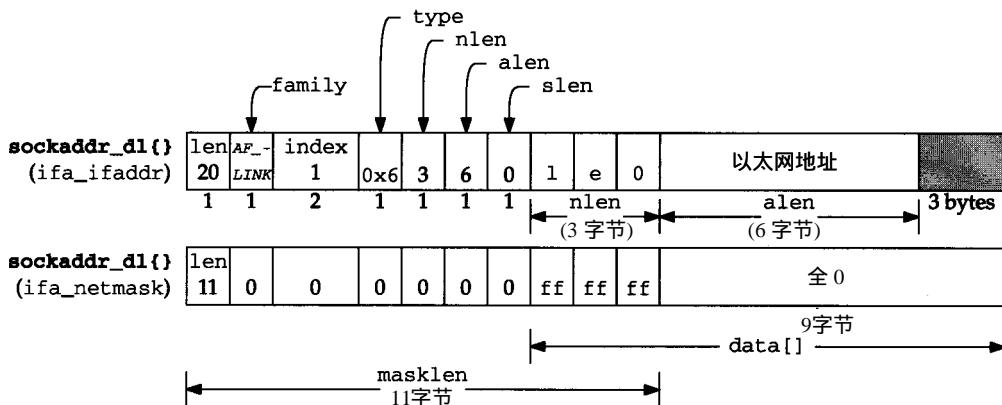


图3-38 初始话了的以太网 sockaddr_dl 结构(省略了前缀 sdl_)

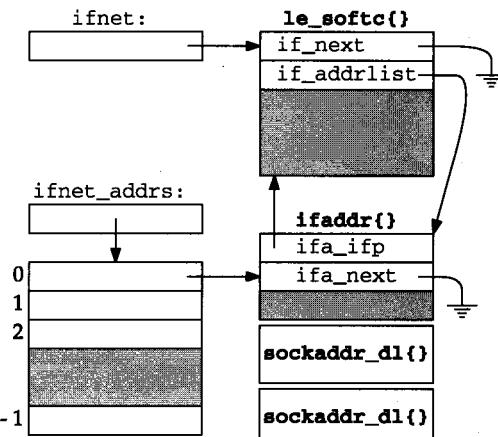


图3-39 第一次调用 if_attach 后的 ifnet 和 sockaddr_dl 结构

```

124     /* XXX -- Temporary fix before changing 10 ethernet drivers */          if.c
125     if (ifp->if_output == ether_output)
126         ether_ifattach(ifp);
127 }

```

图3-40 函数 if_attach : 以太网初始化

```

338 void
339 ether_ifattach(ifp)
340 struct ifnet *ifp;
341 {
342     struct ifaddr *ifa;
343     struct sockaddr_dl *sdl;

344     ifp->if_type = IFT_ETHER;
345     ifp->if_addrlen = 6;
346     ifp->if_hndlens = 14;
347     ifp->if_mtu = ETHERMTU;
348     for (ifa = ifp->if_addrlist; ifa; ifa = ifa->ifa_next)
349         if ((sdl = (struct sockaddr_dl *) ifa->ifa_addr) &&

```

图3-41 函数 ether_ifattach

```

350             sdl->sdl_family == AF_LINK) {
351             sdl->sdl_type = IFT_ETHER;
352             sdl->sdl_alen = ifp->if_addrlen;
353             bcopy((caddr_t) ((struct arpcom *) ifp)->ac_enaddr,
354                   LLADDR(sdl), ifp->if_addrlen);
355             break;
356         }
357     }

```

if_ether_subr.c

图3-41 (续)

5. ether_ifattach函数

函数ether_ifattach执行对所有以太网设备通用的ifnet结构的初始化。

338-357 对于一个以太网设备，if_type为IFT_ETHER，硬件地址为6字节长，整个以太网首部有14字节，而以太网MTU为1500(ETHERMTU)。

leattach已经指派了MTU，但其他以太网设备驱动程序可能没有执行这个初始化。

4.3节讨论以太网帧组织的更多细节。for循环定位接口的链路层地址，然后初始化结构sockaddr_dl中的以太网硬件地址信息。在系统初始化时，以太网地址被复制到结构arpcom中，现在被复制到链路层地址中。

3.12 ifinit函数

接口结构被初始化并链接到一起后，main(图3-23)调用ifinit，如图3-42所示。

```

43 void
44 ifinit()
45 {
46     struct ifnet *ifp;
47
48     for (ifp = ifnet; ifp; ifp = ifp->if_next)
49         if (ifp->if_snd.ifq_maxlen == 0)
50             ifp->if_snd.ifq_maxlen = ifqmaxlen; /* set default length */
51     if_slowtimo(0);

```

if.c

if.c

图3-42 函数ifinit

43-51 for循环遍历接口列表，并把没有被接口的attach函数设置的每个接口输出队列的最大长度设置为50(ifqmaxlen)。

输出队列的大小关键要考虑的是发送最大长度数据报的分组的个数。例如以太网，若一个进程调用sendto发送65 507字节的数据，它被分片为45个数据报片，并且每个数据报片被放进接口的输出队列。若队列非常小，由于队列没有空间，进程可能不能发送大的数据报。

if_slowtimo启动接口的监视计时器。当一个接口时钟到期，内核会调用这个接口的把关定时器函数。一个接口可以提前重设时钟来阻止把关定时器函数的调用，或者，若不需要把关定时器函数，则可以把if_timer设置为0。图3-43所示的是函数if_slowtimo。

338-343 if_slowtimo函数有一个参数arg没有使用，但慢超时函数的原型(7.4节)要求有这个参数。

```

338 void if_slowtimo(arg)
339 if_slowtimo(arg)
340 void *arg;
341 {
342     struct ifnet *ifp;
343     int s = splimp();
344     for (ifp = ifnet; ifp; ifp = ifp->if_next) {
345         if (ifp->if_timer == 0 || --ifp->if_timer)
346             continue;
347         if (ifp->if_watchdog)
348             (*ifp->if_watchdog) (ifp->if_unit);
349     }
350     splx(s);
351     timeout(if_slowtimo, (void *) 0, hz / IFNET_SLOWHZ);
352 }

```

if.c

图3-43 函数if_slowtimo

344-352 if_slowtimo忽略if_timer为0的接口；若if_timer不等于0，if_slowtimo把if_timer减1，并在这个时钟到达0时调用这个接口关联的if_watchdog函数。在调用if_slowtimo时，分组处理进程被splimp阻塞。返回前，ip_slowtimo调用timeout，来以hz/IFNET_SLOWHZ时钟频率调度对它自己的调用。hz是1秒钟内时钟滴答数(通常是100)。它在系统初始化时设置，并保持不变。因为IFNET_SLOWHZ被定义为1，因此内核每赫兹调用一次if_slowtimo，即每秒一次。

函数timeout调度的函数被内核的函数callout回调。详见[Leffler et al. 1989]。

3.13 小结

在本章我们研究了结构ifnet和ifaddr，它们被分配给在系统初始化时发现的每一个网络接口。结构ifnet链接成ifnet链表。每个接口的链路层地址被初始化，并被加到ifnet结构的地址链表中，还存放到数组if_addrs中。

我们讨论了通用sockaddr结构及其成员sa_family和sa_len，它们标识每个地址的类型和长度。我们还查看了一个链路层地址的sockaddr_dl结构的初始化。

在本章中，我们还介绍了在全书中要用到的三个网络接口例子。

习题

- 3.1 很多Unix系统中的netstat程序列出网络接口及其配置信息。在你接触的系统中试一下命令netstat -i。那个网络接口的名称(if_name)是什么？传输单元的最大长度(if_mtu)是多少？
- 3.2 在if_slowtimo(图3-43)中，调用splimp和splx出现在循环的外面。与把这些调用放到循环内部相比，这样安排有何优缺点？
- 3.3 为什么SLIP的交互队列比它的标准输出队列要短？
- 3.4 为什么if_hdrlen和if_addrhlen不在slattach中初始化？
- 3.5 为SLIP和环回设备画一个与图3-38类似的图。

第4章 接口：以太网

4.1 引言

在第3章中，我们讨论了所有接口要用到的数据结构及对这些数据结构的初始化。在本章中，我们说明以太网设备驱动程序在初始化后是如何接收和传输帧的。本章的后半部分介绍配置网络设备的通用 ioctl命令。第5章是SLIP和环回驱动程序。

我们不准备查看整个以太网驱动程序的源代码，因为它有大约 1 000行C代码(其中有一半是一个特定接口卡的硬件细节)，但要研究与设备无关的以太网代码部分，及驱动程序是如何与内核其他部分交互的。

如果读者对一个驱动程序的源代码感兴趣，Net/3版本包括很多不同接口的源代码。要想研究接口的技术规范，就要求能理解设备专用的命令。图 4-1所示的是Net/3提供的各种驱动程序，包括在本章我们要讨论的LANCE驱动程序。

网络设备驱动程序通过 ifnet结构(图3-6)中的7个函数指针来访问。图 4-2列出了指向我们的三个例子驱动程序的入口点。

输入函数不包含在图4-2中，因为它们是网络设备中断驱动的。中断服务例程的配置与硬件相关，并且超出了本书的范围。我们要识别处理设备中断的函数，但不是这些函数被调用的机制。

设 备	文 件
DEC DEUNA接口	vax/if/if_de.c
3Com以太网接口	vax/if/if_ec.c
Excelan EXOS 204接口	vax/if/if_ex.c
Interlan以太网通信控制器	vax/if/if_il.c
Interlan NP100以太网通信控制器	vax/if/if_ix.c
Digital Q-BUS to NI适配器	vax/if/if_qe.c
CMC ENP-20以太网控制器	tahoe/if/if_enp.c
Excelan EXOS 202 (VME) & 203 (QBUS)	tahoe/if/if_ex.c
ACC VERSAbus以太网控制器	tahoe/if/if_ace.c
AMD 7990 LANCE接口	hp300/dev/if_le.c
NE2000以太网	i386/isa/if_ne.c
Western Digital 8003以太网适配器	i386/isa/if_we.c

图4-1 Net/3中可用的以太网驱动程序

ifnet	以 太 网	SLIP	环 回	说 明
if_init	leinit			硬件初始化
if_output	ether_output	sloutput	looutput	接收并对传输的帧进行排队
if_start	lrestart			开始传输帧
if_done				输出完成(未用)
if_ioctl	leiioctl	sliioctl	lcioctl	处理来自一个进程的 ioctl命令
if_reset	lereset			把设备复位到已知的状态
if_watchdog				监视设备故障或收集统计信息

图4-2 例子驱动程序的接口函数

只有函数 `if_output` 和 `if_ioctl` 被经常地调用。而 `if_init`、`if_done` 和 `if_reset` 从来不被调用或仅从设备专用代码调用（例如：`leinit` 直接被 `leioctl` 调用）。函数 `if_start` 仅被函数 `ether_output` 调用。

4.2 代码介绍

以太网设备驱动程序和通用接口 `ioctl` 的代码包含在两个头文件和三个 C 文件中，它们列于图 4-3 中。

文 件	说 明
<code>net/if_ether.h</code>	以太网结构
<code>net/if.h</code>	<code>ioctl</code> 命令定义
<code>net/if_ETHERSUBR.C</code>	通用以太网函数
<code>hp300/dev/if_le.c</code>	LANCE 以太网驱动程序
<code>net/if.c</code>	<code>ioctl</code> 处理

图 4-3 在本章讨论的文件

4.2.1 全局变量

显示在图 4-4 中的全局变量包括协议输入队列、LANCE 接口结构和以太网广播地址。

变 量	数据类型	说 明
<code>arpintrq</code>	<code>struct ifqueue</code>	ARP 输入队列
<code>clnlintrq</code>	<code>struct ifqueue</code>	CLNP 输入队列
<code>ipintrq</code>	<code>struct ifqueue</code>	IP 输入队列
<code>le_softc</code>	<code>struct le_softc[]</code>	LANCE 以太网接口
<code>etherbroadcastaddr</code>	<code>u_char[]</code>	以太网广播地址

图 4-4 本章介绍的全局变量

`le_softc` 是一个数组，因为这里可以有多个以太网接口。

4.2.2 统计量

结构 `ifnet` 中为每个接口收集的统计量如图 4-5 所示。

图 4-6 显示了 `netstat` 命令的一些输出例子，包括 `ifnet` 结构中的一些统计信息。

第 1 列包含显示为一个字符串的 `if_name` 和 `if_unit`。若接口是关闭的（不设置 `IFF_UP`），一个星号显示在这个名字的旁边。在图 4-6 中，`s10`、`s12` 和 `s13` 是关闭的。

第 2 列显示的是 `if_mtu`。在表头“Network”和“Address”底下的输出依赖于地址的类型。对于链路层地址，显示了结构 `sockaddr_dl` 的 `sdl_data` 的内容。对于 IP 地址，显示了子网和单播地址。其余的列是 `if_ipackets`、`if_ierrors`、`if_opackets`、`if_oerrors` 和 `if_collisions`。

- 在输出中冲突的分组大约有 3% ($942\ 798 / 23\ 234\ 729 = 3\%$)。
- 这个机器的 SLIP 输出队列从未满过，因为 SLIP 接口的输出没有差错。
- 在传输中，LANCE 硬件检测到 12 个以太网的输出差错。其中有些差错可能被视为冲突。

ifnet成员	说 明	用于SNMP
if_collisions	在CSMA接口的冲突数	
if_ibytes	接收到的字节总数	•
if_ierrors	接收到的有输入差错分组数	•
if_imcasts	接收到的多播分组数	•
if_ipackets	在接口接收到的分组数	•
if_iqdrops	彼此接口丢失的输入分组数	•
if_lastchange	上一次改变统计的时间	•
if_noproto	指定为不支持协议的分组数	•
if_obytes	发送的字节总数	•
if_oerrors	接口上输出的差错数	•
if_omcasts	发送的多播分组数	•
if_opackets	接口上发送的分组数	•
if_snd.ifq_drops	在输出期间丢失的分组数	•
if_snd.ifq_len	输出队列中的分组数	

图4-5 结构 ifnet 中维护的统计

netstat -i output								
Name	Mtu	Network	Address	Ipkts	Ierrs	Opkts	Oerrs	Coll
le0	1500	<Link>	8.0.9.13.d.33	28680519	814	29234729	12	942798
le0	1500	128.32.33	128.32.33.5	28680519	814	29234729	12	942798
s10*	296	<Link>		54036	0	45402	0	0
s10*	296	128.32.33	128.32.33.5	54036	0	45402	0	0
s11	296	<Link>		40397	0	33544	0	0
s11	296	128.32.33	128.32.33.5	40397	0	33544	0	0
s12*	296	<Link>		0	0	0	0	0
s13*	296	<Link>		0	0	0	0	0
lo0	1536	<Link>		493599	0	493599	0	0
lo0	1536	127	127.0.0.1	493599	0	493599	0	0

图4-6 接口统计的样本

- 硬件检测出 814 个以太网的输入差错，例如分组太短或错误的检验和。

4.2.3 SNMP变量

图4-7所示的是SNMP接口表(ifTable)中的一个接口项对象(ifEntry)，它包含在每个接口的ifnet结构中。

ISODE SNMP代理从if_type获得ifSpeed，并为ifAdminStatus维护一个内部变量。代理的ifLastChange基于结构ifnet中的if_lastchange，但与代理的启动时间相关，而不是与系统的启动时间相关。代理为ifSpecific返回一个空变量。

接口表，索引=<ifIndex>		
SNMP变量	ifnet成员	说 明
ifIndex	if_index	唯一地标识接口
ifDescr	if_name	接口的文本名称
ifType	if_type	接口的类型(例如以太网、SLIP等等)

图4-7 接口表 ifTable 的变量

接口表，索引=<ifIndex>		
SNMP变量	ifnet成员	说 明
ifMtu	if_mtu	接口的MTU(字节)
ifSpeed	(看正文)	接口的正常速率(每秒比特)
ifPhysAddress	ac_enaddr	媒体地址(来自结构arpcom)
ifAdminStatus	(看正文)	接口的期望状态(IF_UP标志)
ifOperStatus	if_flags	接口的操作状态(IF_UP标志)
ifLastChange	(看正文)	上一次统计改变时间
ifInOctets	if_ibytes	输入的字节总数
ifInUcastPkts	if_ipackets - if_imcasts	输入的单播分组数
ifInNUcastPkts	if_imcasts	输入的广播或多播分组数
ifInDiscards	if_iqdrops	因为实现的限制而丢弃的分组数
ifInErrors	if_ierrors	差错的分组数
ifInUnknownProtos	if_noproto	指定为未知协议的分组数
ifOutOctets	if_obytes	输出字节数
ifOutUcastPkts	if_opackets-if_omcasts	输出的单播分组数
ifOutNUcastPkts	if_omcasts	输出的广播或多播分组数
ifOutDiscards	if_snd.ifq_drops	因为实现的限制而丢失的输出分组数
ifOutErrors	if_oerrors	因为差错而丢失的输出分组数
ifOutQLen	if_snd.ifq_len	输出队列长度
ifSpecific	n/a	媒体专用信息的SNMP对象ID(未实现)

图4-7 (续)

4.3 以太网接口

Net/3以太网设备驱动程序都遵循同样的设计。对于大多数 Unix设备驱动程序来说，都是这样，因为写一个新接口卡的驱动程序总是在一个已有的驱动程序的基础上修改而来的。在本节，我们简要地概述一下以太网的标准和一个以太网驱动程序的设计。我们用 LANCE驱动程序来说明这个设计。

图4-8说明了一个IP分组的以太网封装。

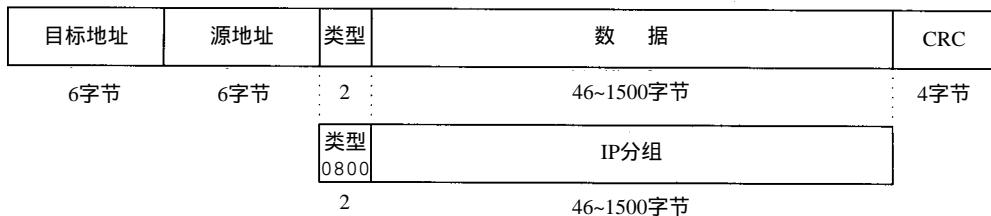


图4-8 一个IP分组的以太网封装

以太网帧包括48 bit的目标地址和源地址，接下来是一个16 bit的类型字段，它标识这个帧所携带的数据的格式。对于IP分组，类型是0x0800(2048)。帧的最后是一个32 bit的CRC(循环冗余检验)，它用来检查帧中的差错。

我们所讨论的最初的以太网组帧的标准在1982年由Digital设备公司、Intel公司及施乐公司发布，并作为今天在TCP/IP网络中最常用的格式。另一个可选的格式是IEEE(电气电子工程师协会)规定的802.2和802.3标准。更多的IEEE标准详见[Stallings 1987]。

对于以太网，IP分组的封装由RFC 894[Hornig 1984]规定，而对于802.3网，却由RFC1042[Postel和Reynolds 1988]规定。

我们用48 bit的以太网地址作为硬件地址。IP地址到硬件地址之间的转换用ARP协议(RFC 826 [Plummer 1982])，这个协议在第21章讨论。而硬件地址到IP地址的转换用RARP协议(RFC 903 [Finlayson et al. 1984])。以太网地址有两种类型：单播和多播。一个单播地址描述一个单一的以太网接口，而一个多播地址描述一组以太网接口。一个以太网广播是一个所有接口都接收的多播。以太网单播地址由设备的厂商分配，也有一些设备的地址允许用软件改变。

一些DECNET协议要求标识一个多接口主机的硬件地址，因此 DECNET必须能改变一个设备的以太网单播地址。

图4-9列举了以太网接口的数据结构和函数。

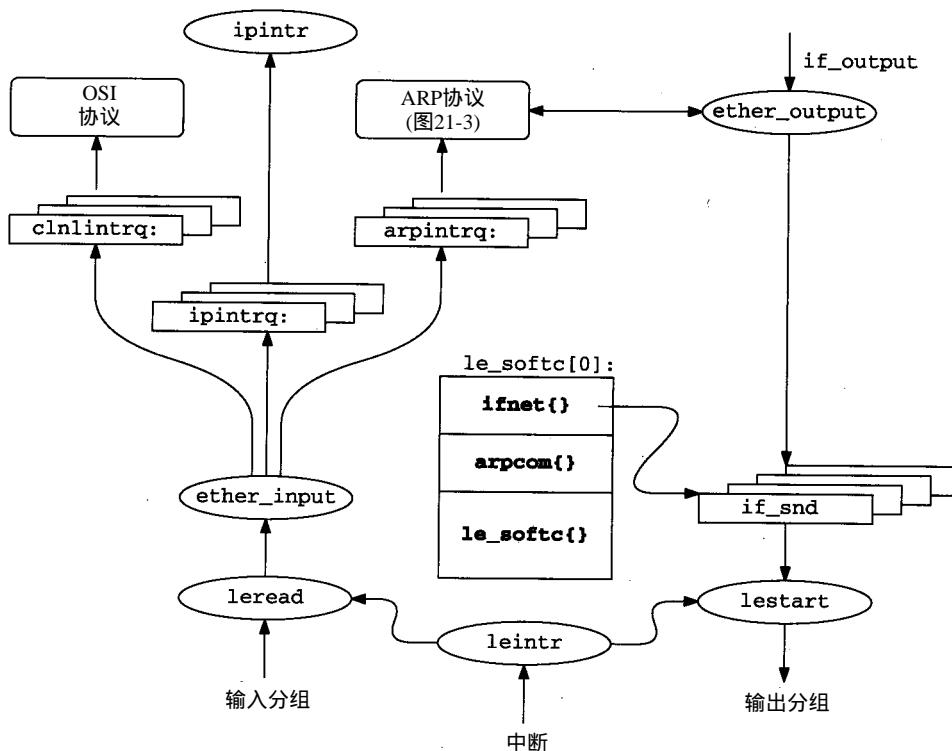


图4-9 以太网设备驱动程序

在图中：用一个椭圆标识一个函数 (**leintr**)、用一个方框标识数据结构 (**le_softc[0]**)、**le_softc**及用圆角方框标识一组函数(ARP协议)。

图4-9左上角显示的是 OSI无连接网络层 (clnl)协议、IP和ARP的输入队列。对于 **clnlintrq**，我们不打算讲更多，将它包含进来是为了强调 **ether_input**要将以太网帧分用到多个协议队列中。

在技术上，OSI使用无连接网络协议(CLNP而不是CLNL)，但我们使用的是Net/3中的术语。CLNP的官方标准是ISO 8473。[Stallings 1993]对这个标准作了概述。

接口结构 `le_softc` 在图 4-9 的中间。我们感兴趣的是这个结构中的 `ifnet` 和 `arpcom`，其他是 LANCE 硬件的专用部分。我们在图 3-6 中显示了结构 `ifnet`，在图 3-26 中显示了结构 `arpcom`。

4.3.1 leintr 函数

我们从以太网帧的接收开始。现在，假设硬件已初始化并且系统已完成配置，当接口产生一个中断时，`leintr` 被调用。在正常操作中，一个以太网接口接收发送到它的单播地址和以太网广播地址的帧。当一个完整的帧可用时，接口就产生一个中断，并且内核调用 `leintr`。

在第 12 章中，我们会看见可能要配置多个以太网接口来接收以太网多播帧（不同于广播）。

有些接口可以配置为运行在混杂方式。在这种方式下，接口接收所有出现在网络上的帧。在卷 1 中讨论的 `tcpdump` 程序可以使用 BPF (BSD 分组过滤程序) 来利用这种特性。

`leintr` 检测硬件，并且如果有一个帧到达，就调用 `leread` 把这个帧从接口转移到一个 `mbuf` 链中（用 `m_devget`）。如果硬件报告一个帧已传输完或发现一个差错（如一个有错误的检验和），则 `leintr` 更新相应的接口统计，复位这个硬件，并调用 `leread` 来传输另一个帧。

所有以太网设备驱动程序将它们接收到的帧传给 `ether_input` 做进一步的处理。设备驱动程序构造的 `mbuf` 链不包括以太网首部，以太网首部作为一个独立的参数传递给 `ether_input`。结构 `ether_header` 显示在图 4-10 中。

38-42 以太网 CRC 并不总是可用。它由接口硬件来计算与检验，接口硬件丢弃到达的 CRC 差错帧。以太网设备驱动程序负责 `ether_type` 的网络和主机字节序间的转换。在驱动程序外，它总是主机字节序。

```

38 struct ether_header {
39     u_char ether_dhost[6];      /* Ethernet destination address */
40     u_char ether_shost[6];      /* Ethernet source address */
41     u_short ether_type;        /* Ethernet frame type */
42 };

```

图 4-10 结构 `ether_header`

4.3.2 leread 函数

函数 `leread`（图 4-11）的开始是由 `leintr` 传给它的一个连续的内存缓冲区，并且构造了一个 `ether_header` 结构和一个 `mbuf` 链。这个链表存储来自以太网帧的数据。`leread` 还将输入帧传给 BPF。

```

528 leread(unit, buf, len)
529 int     unit;
530 char   *buf;
531 int     len;
532 {
533     struct le_softc *le = &le_softc[unit];

```

图 4-11 函数 `leread`

```

534     struct ether_header *et;
535     struct mbuf *m;
536     int      off, resid, flags;
537
538     le->sc_if.if_ipackets++;
539     et = (struct ether_header *) buf;
540     et->ether_type = ntohs((u_short) et->ether_type);
541     /* adjust input length to account for header and CRC */
542     len = len - sizeof(struct ether_header) - 4;
543     off = 0;
544
545     if (len <= 0) {
546         if (ledebug)
547             log(LOG_WARNING,
548                 "le%d: ierror(runt packet): from %s: len=%d\n",
549                 unit, ether_sprintf(et->ether_shost), len);
550         le->sc_runt++;
551         le->sc_if.if_ierrors++;
552         return;
553     }
554     flags = 0;
555     if (bcm((caddr_t) etherbroadcastaddr,
556             (caddr_t) et->ether_dhost, sizeof(etherbroadcastaddr)) == 0)
557         flags |= M_BCAST;
558     if (et->ether_dhost[0] & 1)
559         flags |= M_MCAST;
560
561     /*
562      * Check if there's a bpf filter listening on this interface.
563      * If so, hand off the raw packet to enet.
564      */
565     if (le->sc_if.if_bpf) {
566         bpf_tap(le->sc_if.if_bpf, buf, len + sizeof(struct ether_header));
567
568         /*
569          * Keep the packet if it's a broadcast or has our
570          * physical ethernet address (or if we support
571          * multicast and it's one).
572          */
573
574         /*
575          * Pull packet off interface. Off is nonzero if packet
576          * has trailing header; m_devget will then force this header
577          * information to be at the front, but we still have to drop
578          * the type and length which are at the front of any trailer data.
579          */
580         m = m_devget((char *) (et + 1), len, off, &le->sc_if, 0);
581         if (m == 0)
582             return;
583         m->m_flags |= flags;
584         ether_input(&le->sc_if, et, m);
585     }

```

if_le.c

图4-11 (续)

528-539 函数leintr给leread传了三个参数：unit，它标识接收到此帧的特定接口

卡；buf，它指向接收到的帧；len，它是帧的字节数(包括首部和CRC)。

函数将et指向这个缓存的开始，并且将以太网字节序转换成主机字节序，来构造结构ether_header。

540-551 将len减去以太网首部和CRC的大小得到数据的字节数。短分组(runt packet)是一个长度太短的非法以太网帧，它被记录、统计，并被丢弃。

552-557 接下来，目标地址被检测，并判断是不是以太网广播或多播地址。以太网广播地址是一个以太网多播地址的特例；它的每一比特都被设置了。etherbroadcastaddr是一个数组，定义如下：

```
u_char etherbroadcastaddr[6] = { 0xff, 0xff, 0xff, 0xff, 0xff, 0xff };
```

这是C语言中定义一个48 bit值的简便方法。这项技术仅在我们假设字符是8 bit值时才起作用——ANSI C并不保证这一点。

bcmp比较etherbroadcastaddr和ether_dhost，若相同，则设置标志M_BCAST。一个以太网多播地址由这个地址的首字节的低位比特来标识，如图 4-12 所示。

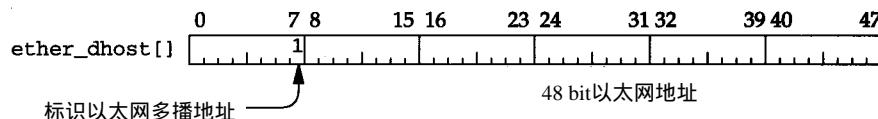


图4-12 检测一个以太网多播地址

在第12章中，我们会看到并不是所有以太网多播帧都是IP多播数据报，并且IP必须进一步检测这个分组。

如果这个地址的多播比特被置位，在mbuf首部中设置M_MCAST。检测的顺序是重要的：首先ether_input将整个48 bit地址和以太网广播地址比较，若不同，则检测标识以太网多播地址的首字节的低位比特(习题4.1)。

558-573 如果接口带有BPF，调用bpf_tap把这个帧直接传给BPF。我们会看见对于SLIP和环回接口，要构造一个特定的BPF帧，因为这些网络没有一个链路层首部(不像以太网)。

当一个接口带有BPF时，它可以配置为运行在混淆模式，并且接收网络上出现的所有以太网帧，而不是通常由硬件接收的帧的子集。如果分组发送给一个不与此接口地址匹配的单播地址，则被leread丢弃。

574-585 m_devget(2.6节)将数据从传给leread的缓存中复制到一个它分配的mbuf链中。传给m_devget的第一个参数指向以太网首部后的第一个字节，它是此帧中的第一个数据字节。如果m_devget内存用完，leread立即返回。另外广播和多播标志被设置在链表中的第一个mbuf中，ether_input处理这个分组。

4.3.3 ether_input函数

函数ether_input显示在图4-13中，它检查结构ether_header来判断接收到的数据的类型，并将接收到的分组加入到队列中等待处理。

1. 广播和多播的识别

196-209 传给ether_input的参数有：ifp，一个指向接收此分组的接口的ifnet结构的指针；eh，一个指向接收分组的以太网首部的指针；m，一个指向接收分组的指针(不包括以太网首部)。

任何到达不工作接口的分组将被丢弃。可能没有为接口配置一个协议地址，或者接口可能被程序ifconfig(8)(6.6节)显式地禁用了。

```

196 void
197 ether_input(ifp, eh, m)
198 struct ifnet *ifp;
199 struct ether_header *eh;
200 struct mbuf *m;
201 {
202     struct ifqueue *inq;
203     struct llc *l;
204     struct arpcom *ac = (struct arpcom *) ifp;
205     int s;

206     if ((ifp->if_flags & IFF_UP) == 0) {
207         m_freem(m);
208         return;
209     }
210     ifp->if_lastchange = time;
211     ifp->if_ibytes += m->m_pkthdr.len + sizeof(*eh);
212     if (bcmpl((caddr_t) etherbroadcastaddr, (caddr_t) eh->ether_dhost,
213             sizeof(etherbroadcastaddr)) == 0)
214         m->m_flags |= M_BCAST;
215     else if (eh->ether_dhost[0] & 1)
216         m->m_flags |= M_MCAST;
217     if (m->m_flags & (M_BCAST | M_MCAST))
218         ifp->if_imcasts++;

219     switch (eh->ether_type) {
220     case ETHERTYPE_IP:
221         schednetisr(NETISR_IP);
222         inq = &ipintrq;
223         break;

224     case ETHERTYPE_ARP:
225         schednetisr(NETISR_ARP);
226         inq = &arpintrq;
227         break;

228     default:
229         if (eh->ether_type > ETHERMTU) {
230             m_freem(m);
231             return;
232         }
233     }

234     /* OST code */
235 }

236     s = splimp();
237     if (IF_QFULL(inq)) {
238         IF_DROP(inq);
239         m_freem(m);
240     } else
241         IF_ENQUEUE(inq, m);
242     splx(s);
243 }

```

if_ETHERSUBR.C

图4-13 函数ether_input

210-218 变量time是一个全局的timeval结构，内核用它维护当前时间和日期，它是从Unix新纪元(1970年1月1日00:00:00，协调通用时间[UTC])开始的秒和微秒数。在[Itano and Ramsey 1993]中可以找到对UTC的简要讨论。我们在Net/3源代码中会经常遇到结构timeval：

```
struct timeval {
    long tv_sec;      /* seconds */
    long tv_usec;     /* and microseconds */
};
```

ether_input用当前时间更新if_lastchange，并且把if_ibytes加上输入分组的长度(分组长度加上14字节的以太网首部)。

然后，ether_input再次用leread去判断分组是否为一个广播或多播分组。

有些内核编译时可能没有包括BPF代码，因此测试必须在ether_input中进行。

2. 链路层分用

219-227 ether_input根据以太网类型字段来跳转。对于一个IP分组，schednetisr调度一个IP软件中断，并选择IP输入队列，ipintrq。对于一个ARP分组，调度ARP软件中断，并选择arpintrq。

一个isr是一个中断服务例程。

在原先的BSD版本中，当处于网络中断级别时，ARP分组通过调用arpinput立即被处理。通过分组排队，它们可以在软件中断级别被处理。

如果要处理其他以太网类型，一个内核程序员应在此增加其他情况的处理。或者，一个进程能用BPF接收其他以太网类型。例如，在Net/3中，RARP服务通常用BPF实现。

228-307 默认情况处理不识别以太网类型或按802.3标准(例如OSI无连接传输)封装的分组。以太网的type字段和802.3的length字段在一个以太网帧中占用同一位置。两种封装能够分辨出来，因为一个以太网封装的类型范围和802.3封装的长度范围是不同的(图4-14)。我们跳过OSI代码，在[Stallings 1993]中有对OSI链路层协议的说明。

范 围	说 明
0~1500	IEEE 802.3 length字段
1501~65535	以太网type字段：
2048	IP分组
2045	ARP分组

图4-14 以太网的type字段和802.3的length字段

有很多其他以太网类型值分配给各种协议；我们没有在图4-14中显示。在RFC 1700 [Reynolds and Postel 1994]中有一个有更多通用类型的列表。

3. 分组排队

308-315 最后，ether_input把分组放置到选择的队列中，若队列为空，则丢弃此分组。我们在图7-23和图21-16中会看到IP和ARP队列的默认限制为每个50个(ipqmaxlen)分组。

当ether_input返回时，设备驱动程序通知硬件它已准备接收下一分组，这时下一分组可能已存在于设备中。当schednetisr调度的软件中断发生时，处理分组输入队列(1.12节)。准确地说，调用ipintr来处理IP输入队列中的分组，调用arpintr来处理ARP输入队列中的分组。

4.3.4 ether_output函数

我们现在查看以太网帧的输出，当一个网络层协议，如 IP，调用此接口 ifnet 结构中指定的函数 if_output 时，开始处理输出。所有以太网设备的 if_output 是 ether_output（图4-2）。ether_output 用 14 字节以太网首部封装一个以太网帧的数据部分，并将它放置到接口的发送队列中。这个函数比较大，我们分 4 个部分来说明：

- 验证；
- 特定协议处理；
- 构造帧；
- 接口排队。

图4-15 包括这个函数的第一个部分。

```

49 int
50 ether_output(ifp, m0, dst, rt0)           if_ETHERSUBR.C
51 struct ifnet *ifp;
52 struct mbuf *m0;
53 struct sockaddr *dst;
54 struct rtentry *rt0;
55 {
56     short type;
57     int s, error = 0;
58     u_char edst[6];
59     struct mbuf *m = m0;
60     struct rtentry *rt;
61     struct mbuf *mcopy = (struct mbuf *) 0;
62     struct ether_header *eh;
63     int off, len = m->m_pkthdr.len;
64     struct arpcom *ac = (struct arpcom *) ifp;

65     if (((ifp->if_flags & (IFF_UP | IFF_RUNNING)) != (IFF_UP | IFF_RUNNING))
66         senderr(ENETDOWN);
67     ifp->if_lastchange = time;
68     if (rt = rt0) {
69         if ((rt->rt_flags & RTF_UP) == 0) {
70             if (rt0 = rt = rtalloc1(dst, 1))
71                 rt->rt_refcnt--;
72             else
73                 senderr(EHOSTUNREACH);
74         }
75         if (rt->rt_flags & RTF_GATEWAY) {
76             if (rt->rt_gwroute == 0)
77                 goto lookup;
78             if (((rt = rt->rt_gwroute)->rt_flags & RTF_UP) == 0) {
79                 rtfree(rt);
80                 rt = rt0;
81             lookup: rt->rt_gwroute = rtalloc1(rt->rt_gateway, 1);
82                 if ((rt = rt->rt_gwroute) == 0)
83                     senderr(EHOSTUNREACH);
84             }
85         }
86         if (rt->rt_flags & RTF_REJECT)
87             if (rt->rt_rmx.rmx_expire == 0 ||
88                 time.tv_sec < rt->rt_rmx.rmx_expire)
89                 senderr(rt == rt0 ? EHOSTDOWN : EHOSTUNREACH);
90     }

```

图4-15 函数 ether_output : 验证

49-64 ether_output的参数有：ifp，它指向输出接口的ifnet结构；m0，要发送的分组；dst，分组的目标地址；rt0，路由信息。

65-67 在ether_output中多次调用宏senderr。

```
#define senderr(e) { error = (e); goto bad; }
```

senderr保存差错码，并跳到函数的尾部bad，在那里分组被丢弃，并且ether_output返回error。

如果接口启动并在运行，ether_output更新接口的上次更改时间。否则，返回ENETDOWN。

1. 主机路由

68-74 rt0指向ip_output找到的路由项，并传递给ether_output。如果从BPF调用ether_output，rt0可以为空。在这种情况下，控制转给图4-16中的代码。否则，验证路由。如果路由无效，参考路由表，并且当路由不能被找到时，返回EHOSTUNREACH。这时，rt0和rt指向一个到下一跳目的地的有效路由。

```
91     switch (dst->sa_family) {
92         case AF_INET:
93             if (!arpresolve(ac, rt, m, dst, edst))
94                 return (0); /* if not yet resolved */
95             /* If broadcasting on a simplex interface, loopback a copy */
96             if ((m->m_flags & M_BCAST) && (ifp->if_flags & IFF_SIMPLEX))
97                 mc当地 = m_copy(m, 0, (int) M_COPYALL);
98             off = m->m_pkthdr.len - m->m_len;
99             type = ETHERTYPE_IP;
100            break;
101        case AF_ISO:
102            /* ISO code */
103        case AF_UNSPEC:
104            eh = (struct ether_header *) dst->sa_data;
105            bcopy((caddr_t) eh->ether_dhost, (caddr_t) edst, sizeof(edst));
106            type = eh->ether_type;
107            break;
108        default:
109            printf("%s%d: can't handle af%d\n", ifp->if_name, ifp->if_unit,
110                  dst->sa_family);
111            senderr(EAFNOSUPPORT);
112    }
113
114
115 }
```

if_ETHERSUBR.C

图4-16 函数ether_output：网络协议处理

2. 网关路由

75-85 如果分组的下一跳是一个网关（而不是最终目的），找到一个到此网关的路由，并且rt指向它。如果不能发现一个网关路由，则返回EHOSTUNREACH。这时，rt指向下一跳目的地的路由。下一跳可能是一个网关或最终目标地址。

3. 避免ARP泛洪

86-90 当目标方不准备响应ARP请求时，ARP代码设置标志RTF_REJECT来丢弃到达目标

方的分组。这在图21-24中描述。

`ether_output`根据此分组的目标地址继续处理。因为以太网设备仅响应以太网地址，要发送一个分组，`ether_output`必须发现下一跳目的地的IP地址所对应的以太网地址。ARP协议(第21章)用来实现这个转换。图4-16显示了驱动程序是如何访问ARP协议的。

4. IP输出

91-101 `ether_output`根据目标地址中的`sa_family`进行跳转。我们在图4-16中仅显示了`case AF_INET`、`AF_ISO`和`AF_UNSPEC`的代码，而略过了`case AF_ISL`的代码。

`case AF_INET`调用`arpresolve`来决定与目标IP地址相对应的以太网地址。如果以太网地址已存在于ARP高速缓存中，则`arpresolve`返回1，并且`ether_output`继续执行。否则，这个IP分组由ARP控制，并且ARP判断地址，从函数`in_arpinput`调用`ether_output`。

假设ARP高速缓存包含硬件地址，`ether_output`检查是否分组要广播，并且接口是否是单向的(例如，它不能接收自己发送的分组)。如果都成立，则`m_copy`复制这个分组。在执行`switch`后，这个复制的分组同到达以太网接口的分组一样进行排队。这是广播定义的要求，发送主机必须接收这个分组的一个备份。

我们在第12章会看到多播分组可能会环回到输出接口而被接收。

5. 显式以太网输出

142-146 有些协议，如ARP，需要显式地指定以太网目的地和类型。地址族类常量`AF_UNSPEC`指出：`dst`指向一个以太网首部。`bcopy`复制`edst`中的目标地址，并把以太网类型设为`type`。它不必调用`arpresolve`(如`AF_INET`)，因为以太网目标地址已由调用者显式地提供了。

6. 未识别的地址族类

147-151 未识别的地址族类产生一个控制台消息，并且`ether_output`返回`EAFNOSUPPORT`。

图4-17所示的是`ether_output`的下一部分：构造以太网帧。

```

152     if (mcopy)
153         (void) looutput(ifp, mcopy, dst, rt);
154     /*
155      * Add local net header.  If no space in first mbuf,
156      * allocate another.
157     */
158     M_PREPEND(m, sizeof(struct ether_header), M_DONTWAIT);
159     if (m == 0)
160         senderr(ENOBUFS);
161     eh = mtod(m, struct ether_header *);
162     type = htons((u_short) type);
163     bcopy((caddr_t) &type, (caddr_t) &eh->ether_type,
164           sizeof(eh->ether_type));
165     bcopy((caddr_t) edst, (caddr_t) eh->ether_dhost, sizeof(edst));
166     bcopy((caddr_t) ac->ac_enaddr, (caddr_t) eh->ether_shost,
167           sizeof(eh->ether_shost));

```

if_ETHERSUBR.C

if_ETHERSUBR.C

图4-17 函数`ether_output`：构造以太网帧

7. 以太网首部

152-167 如果在`switch`中的代码复制了这个分组，这个分组副本同在输出接口上接收到

的分组一样通过调用 `looutput` 来处理。环回接口和 `looutput` 在 5.4 节讨论。

`M_PREPEND` 确保在分组的前面有 14 字节的空间。

大多数协议要在 mbuf 链表的前面留一些空间，因此，`M_PREPEND` 仅需要调整一些指针（例如，16.7 节中 UDP 输出的 `sosend` 和 13.6 节的 `igmp_sendreport`）。

`ether_output` 用 `type`、`edst` 和 `ac_enaddr`（图 3-26）构成以太网首部。`ac_enaddr` 是与此输出接口关联的以太网单播地址，并且是所有从此接口传输的帧的源地址。`ether_header` 用 `ac_enaddr` 重写调用者可能在 `ether_header` 结构中指定的源地址。这使得伪造一个以太网帧的源地址变得困难。

这时，mbuf 包含一个除 32 bit CRC 以外的完整以太网帧，CRC 由以太网硬件在传输时计算。图 4-18 所示的代码对设备要传送的帧进行排队。

```

168     s = splimp();
169     /*
170      * Queue message on interface, and start output if interface
171      * not yet active.
172     */
173     if (IF_QFULL(&ifp->if_snd)) {
174         IF_DROP(&ifp->if_snd);
175         splx(s);
176         senderr(ENOBUFS);
177     }
178     IF_ENQUEUE(&ifp->if_snd, m);
179     if ((ifp->if_flags & IFF_OACTIVE) == 0)
180         (*ifp->if_start) (ifp);
181     splx(s);
182     ifp->ifobytes += len + sizeof(struct ether_header);
183     if (m->m_flags & M_MCAST)
184         ifp->if_omcasts++;
185     return (error);
186
187 bad:
188     if (m)
189         m_free(m);
190 }                                         if_ETHERSUBR.C

```

图 4-18 函数 `ether_output`：输出排队

168-185 如果输出队列为空，`ether_output` 丢弃此帧，并返回 `ENOBUFS`。如果输出队列不为空，这个帧放置到接口的发送队列中，并且若接口未激活，接口的 `if_start` 函数传输下一帧。

186-190 宏 `senderr` 跳到 `bad`，在这里帧被丢弃，并返回一个差错码。

4.3.5 `lrestart` 函数

函数 `lrestart` 从接口输出队列中取出排队的帧，并交给 LANCE 以太网卡发送。如果设备空闲，调用此函数开始发送帧。`ether_output`（图 4-18）的最后是一个例子，直接通过接口的 `if_start` 函数调用 `lrestart`。

如果设备忙，当它完成了当前帧的传输时产生一个中断。设备调用 `lrestart` 来退队并传输下一帧。一旦开始，协议层不再用调用 `lrestart` 来排队帧，因为驱动程序不断退队并传输

帧，直到队列为空为止。

图4-19所示的是函数lestard。lestard假设已调用splimp来阻塞所有设备中断。

```
if_le.c
325 lestart(ifp)
326 struct ifnet *ifp;
327 {
328     struct le_softc *le = &le_softc[ifp->if_unit];
329     struct letmd *tmd;
330     struct mbuf *m;
331     int len;
332
333     if ((le->sc_if.if_flags & IFF_RUNNING) == 0)
334         return (0);
335
336     do {
337
338         /* device specific code */
339
340         IF_DEQUEUE(&le->sc_if.if_snd, m);
341         if (m == 0)
342             return (0);
343         len = leput(le->sc_r2->ler2_tbuf[le->sc_tmd], m);
344         /*
345          * If bpf is listening on this interface, let it
346          * see the packet before we commit it to the wire.
347          */
348         if (ifp->if_bpf)
349             bpf_tap(ifp->if_bpf, le->sc_r2->ler2_tbuf[le->sc_tmd],
350                   len);
351
352         /* device specific code */
353
354     } while (++le->sc_txcnt < LETBUF);
355     le->sc_if.if_flags |= IFF_OACTIVE;
356
357     return (0);
358 }
359 }
```

if_le.c

图4-19 函数lestard

1. 接口必须初始化

325-333 如果接口没有初始化，lestard立即返回。

2. 将帧从输出队列中退队

335-342 如果接口已初始化，下一帧从队列中移去。如果接口输出队列为空，则lestard返回。

3. 传输帧并传递给BPF

343-350 leput将m中的帧复制到leput第一个参数所指向的硬件缓存中。如果接口带有BPF，将帧传给bpf_tap。我们跳过硬件缓存中帧传输的设备专用初始化代码。

4. 如果设备准备好，重复发送多帧

359 当`le->sc_txcnt`等于`LETBUF`时，`lestart`停止给设备传送帧。有些以太网接口能排队多个以太网输出帧。对于 LANCE 驱动器，`LETBUF`是此驱动器硬件传输缓存的可用个数，并且`le->sc_txcnt`保持跟踪有多少个缓存被使用。

5. 将设备标记为忙

360-362 最后，`lestart`在`ifnet`结构中设置`IFF_OACTIVE`来标识这个设备忙于传输帧。

在设备中将多个要传输的帧进行排队有一个负面影响。根据 [Jacobson 1998a]，LANCE 芯片能够在两个帧间以很小的时延传输排队的帧。不幸的是，有些（差的）以太网设备会丢失帧，因为它们不能足够快地处理输入的数据。

在一个应用如 NFS 中，这会很糟糕地互相影响。NFS 发送大的 UDP 数据报（经常是超过 8192 字节），数据报被 IP 分片，并在 LANCE 设备中作为多个以太网帧排队。分片在接收方丢失，当 NFS 重传整个 UDP 数据报时，会导致很多未完成的数据报极大的时延。

Jacobson 提出 Sun 的 LANCE 驱动器一次只排队一个帧就可能避免这一问题。

4.4 ioctl 系统调用

`ioctl` 系统调用提供一个通用命令接口，一个进程用它来访问一个设备的标准系统调用所不支持的特性。`ioctl` 的原型为：

```
int ioctl(int fd, unsigned long com, ...);
```

`fd` 是一个描述符，通常是一个设备或网络连接。每种类型的描述符都支持它自己的一套 `ioctl` 命令，这套命令由第二个参数 `com` 来指定。第三个参数在原型中显示为“...”，因为它是依赖于被调用的 `ioctl` 命令的类型的指针。如果命令要取回信息，第三个参数必须是指向一个足够保存数据的缓存的指针。在本书中，我们仅讨论用于插口描述符的 `ioctl` 命令。

我们显示的系统调用的原型是一个进程进行系统调用的原型。在第 15 章中我们会看见在内核中的这个函数还有一个不同的原型。

我们在第 17 章讨论系统调用 `ioctl` 的实现，但在本书的各个部分讨论 `ioctl` 单个命令的实现。

我们讨论的第一个 `ioctl` 命令提供对讨论过的网络接口结构的访问。我们总结的本书中所有的 `ioctl` 命令如图 4-20 所示。

命 令	第三参数	函 数	说 明
<code>SIOCGIFCONF</code>	<code>struct ifconf</code>	<code>* ifconf</code>	获取接口配置清单
<code>SIOCGIFFLAGS</code>	<code>struct ifreq *</code>	<code>ifioctl</code>	获得接口标志
<code>SIOCGIFMETRIC</code>	<code>struct ifreq *</code>	<code>ifioctl</code>	获得接口度量
<code>SIOCSIFFLAGS</code>	<code>struct ifreq *</code>	<code>ifioctl</code>	设置接口标志
<code>SIOCSIFMETRIC</code>	<code>struct ifreq *</code>	<code>ifioctl</code>	设置接口度量

图 4-20 接口 `ioctl` 的命令

第一列显示的符号常量标识 `ioctl` 命令（第二个参数，`com`）。第二列显示传递给第一列所显示的命令的系统调用的第三个参数的类型。第三列是实现这个命令的函数的名称。

图 4-21 显示处理 `ioctl` 命令的各种函数的组织。带阴影的函数我们在本章中说明。其余

的函数在其他章说明。

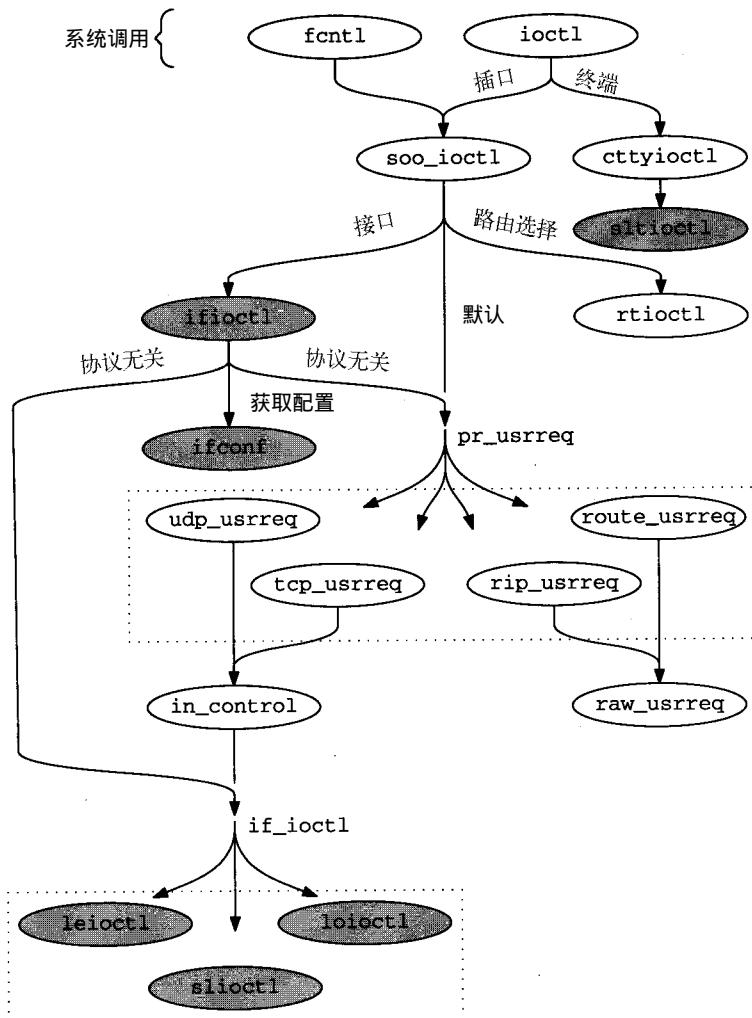


图4-21 在本章说明的 ioctl 函数

4.4.1 ifioctl函数

系统调用 ioctl 将图4-20所列的5种命令传递给图4-22所示的 ifioctl 函数。

394-405 对于命令 SIOCGIFCONF，ifioctl 调用 ifconf 来构造一个可变长 ifreq 结构的表。

406-410 对于其他 ioctl 命令，数据参数是指向一个 ifreq 结构的指针。ifunit 在 ifnet 列表中查找名称为进程在 ifr->ifr_name 中提供的文本名称（例如：“s10”，“le1”或“lo0”）的接口。如果没有匹配的接口，ifioctl 返回 ENXIO。剩下的代码依赖于 cmd，它们在图4-29 中说明。

447-454 如果接口 ioctl 命令不能被识别，ifioctl 把命令发送给与所请求插口关联的协议的用户要求函数。对于 IP，这些命令以一个 UDP 插口发送并调用 udp_usrreq。这一类命

令在图6-10中描述。23.10节将详细讨论函数 `udp_usrreq`。

如果控制到达 `switch` 语句外，返回 0。

```

394 int
395 ifioctl(so, cmd, data, p)
396 struct socket *so;
397 int cmd;
398 caddr_t data;
399 struct proc *p;
400 {
401     struct ifnet *ifp;
402     struct ifreq *ifr;
403     int error;
404     if (cmd == SIOCGIFCONF)
405         return (ifconf(cmd, data));
406     ifr = (struct ifreq *) data;
407     ifp = ifunit(ifr->ifr_name);
408     if (ifp == 0)
409         return (ENXIO);
410     switch (cmd) {
411
412         /* other interface ioctl commands (Figures 4.25 and 12.11) go here */
413
414     default:
415         if (so->so_proto == 0)
416             return (EOPNOTSUPP);
417         return ((*so->so_proto->pr_usrreq) (so, PRU_CONTROL,
418                                              cmd, data, ifp));
419     }
420     return (0);
421 }
```

图4-22 函数 `ifioctl` : 综述与 `SIOCGIFCONF`

4.4.2 `ifconf` 函数

`ifconf` 为进程提供一个标准的方法来发现一个系统中的接口和配置的地址。由结构 `ifreq` 和 `ifconf` 表示的接口信息如图4-23和图4-24所示。

262-279 一个 `ifreq` 结构包含在 `ifr_name` 中一个接口的名称。在联合中的其他成员被各种 `ioctl` 命令访问。通常，用宏来简化对联合的成员的访问语法。

292-300 在结构 `ifconf` 中，`ifc_len` 是 `ifc_buf` 指向的缓存的字节数。这个缓存由一个进程分配，但由 `ifconf` 用一个具有可变长 `ifreq` 结构的数组来填充。对于函数 `ifconf`，`ifr_addr` 是结构 `ifreq` 中联合的相关成员。每个 `ifreq` 结构有一个可变长度，因为 `ifr_addr` (一个 `sockaddr` 结构) 的长度根据地址的类型而变。必须用结构 `sockaddr` 的成员 `sa_len` 来定位每项的结束。图4-25说明了 `ifconf` 所维护的数据结构。

在图4-25中，左边的数据在内核中，而右边的数据在一个进程中。我们用这个图来讨论图4-26中所示的 `ifconf` 函数。

462-474 `ifconf` 的两个参数是：`cmd`，它被忽略；`data`，它指向此进程指定的 `ifconf` 结构的一个副本。

```

262 struct ifreq {
263 #define IFNAMSIZ    16
264     char    ifr_name[IFNAMSIZ];           /* if name, e.g. "en0" */
265     union {
266         struct sockaddr ifru_addr;
267         struct sockaddr ifru_dstaddr;
268         struct sockaddr ifru_broadaddr;
269         short   ifru_flags;
270         int    ifru_metric;
271         caddr_t ifru_data;
272     } ifr_ifru;
273 #define ifr_addr    ifr_ifru.ifru_addr      /* address */
274 #define ifr_dstaddr  ifr_ifru.ifru_dstaddr  /* other end of p-to-p link */
275 #define ifr_broadaddr ifr_ifru.ifru_broadaddr /* broadcast address */
276 #define ifr_flags    ifr_ifru.ifru_flags    /* flags */
277 #define ifr_metric   ifr_ifru.ifru_metric   /* metric */
278 #define ifr_data    ifr_ifru.ifru_data    /* for use by interface */
279 };

```

if.h

图4-23 结构ifreq

```

292 struct ifconf {
293     int ifc_len;                      /* size of associated buffer */
294     union {
295         caddr_t ifcu_buf;
296         struct ifreq *ifcu_req;
297     } ifc_ifcu;
298 #define ifc_buf ifc_ifcu.ifcu_buf /* buffer address */
299 #define ifc_req ifc_ifcu.ifcu_req /* array of structures returned */
300 };

```

if.h

图4-24 结构ifconf

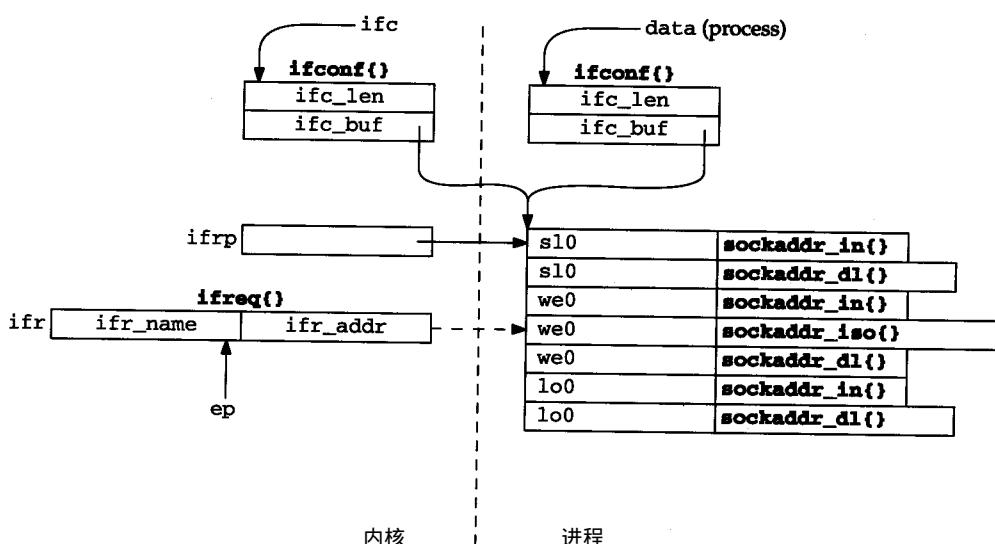


图4-25 ifconf 数据结构

```

462 int ifconf(cmd, data)
463 int cmd;
464 caddr_t data;
465 {
466     struct ifconf *ifc = (struct ifconf *) data;
467     struct ifnet *ifp = ifnet;
468     struct ifaddr *ifa;
469     char *cp, *ep;
470     struct ifreq ifr, *ifrp;
471     int space = ifc->ifc_len, error = 0;
472     ifrp = ifc->ifc_req;
473     ep = ifr.ifr_name + sizeof(ifr.ifr_name) - 2;
474
475     for (; space > sizeof(ifr) && ifp; ifp = ifp->if_next) {
476         strncpy(ifr.ifr_name, ifp->if_name, sizeof(ifr.ifr_name) - 2);
477         for (cp = ifr.ifr_name; cp < ep && *cp; cp++)
478             continue;
479         *cp++ = '0' + ifp->if_unit;
480         *cp = '\0';
481         if ((ifa = ifp->if_addrlist) == 0) {
482             bzero((caddr_t) & ifr.ifr_addr, sizeof(ifr.ifr_addr));
483             error = copyout((caddr_t) & ifr, (caddr_t) ifrp,
484                             sizeof(ifr));
485             if (error)
486                 break;
487             space -= sizeof(ifr), ifrp++;
488         } else
489             for (; space > sizeof(ifr) && ifa; ifa = ifa->ifa_next) {
490                 struct sockaddr *sa = ifa->ifa_addr;
491                 if (sa->sa_len <= sizeof(*sa)) {
492                     ifr.ifr_addr = *sa;
493                     error = copyout((caddr_t) & ifr, (caddr_t) ifrp,
494                                     sizeof(ifr));
495                     ifrp++;
496                 } else {
497                     space -= sa->sa_len - sizeof(*sa);
498                     if (space < sizeof(ifr))
499                         break;
500                     error = copyout((caddr_t) & ifr, (caddr_t) ifrp,
501                                     sizeof(ifr.ifr_name));
502                     if (error == 0)
503                         error = copyout((caddr_t) sa,
504                                         (caddr_t) & ifrp->ifr_addr, sa->sa_len);
505                     ifrp = (struct ifreq *)
506                         (sa->sa_len + (caddr_t) & ifrp->ifr_addr);
507                 }
508                 if (error)
509                     break;
510                 space -= sizeof(ifr);
511             }
512     }
513     ifc->ifc_len -= space;
514     return (error);
515 }

```

图4-26 函数ifconf

ifc是强制为一个ifconf结构指针的data。ifp从ifnet(列表头)开始遍历接口列表，

而ifa遍历每个接口的地址列表。cp和ep控制构造在ifr中的接口文本名称，ifr是一个ifreq结构，它在接口名称和地址复制到进程的缓存前保存接口名称和地址。ifrq指向这个缓存，并且在每个地址被复制后指向下一个。space是进程缓存中剩余字节的个数，cp用来搜寻名称的结尾，而ep标志接口名称数字部分最后的可能位置。

475-488 for循环遍历接口列表。对于每个接口，文本名称被复制到ifr_name，在ifr_name的后面跟着if_unit数的文本表示。如果没有给接口分配地址，一个全0的地址被构造，所得的ifreq结构被复制到进程中，并减小space，增加ifrp。

489-515 如果接口有一个或多个地址，用for循环来处理每个地址。地址加到ifr中的接口名称中，然后ifr被复制到进程中。长度超过标准sockaddr结构的地址不放到ifr中，并且直接复制到进程。在复制完每个地址后，调整space和ifrp的值。所有接口处理完后，更新缓存长度(ifc->ifc_len)，并且ifconf返回。系统调用ioctl负责将结构ifconf中新的内容复制回进程中的结构ifconf。

4.4.3 举例

图4-27显示了以太网、SLIP和环回接口被初始化后的接口结构的配置。

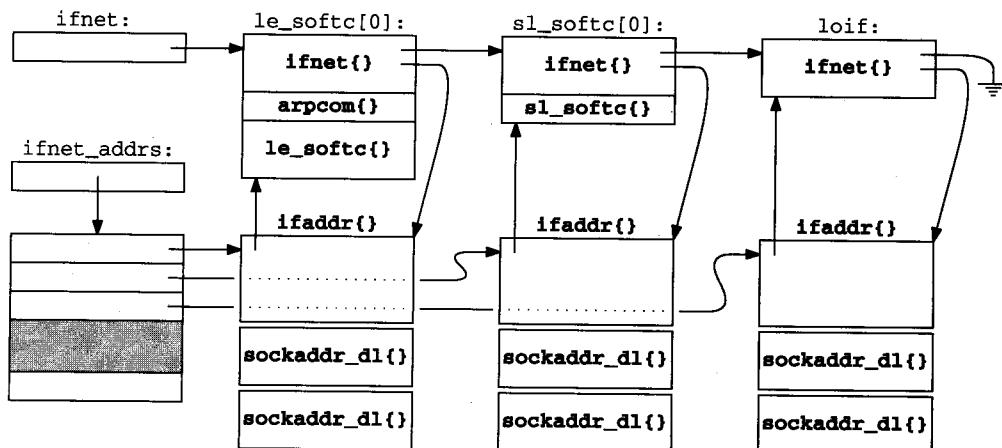


图4-27 接口和地址数据结构

图4-28显示了以下代码执行后的ifc和buffer的内容。

```

struct ifconf ifc;      /* SIOCGIFCONF adjusts this */
char buffer[144];      /* contains interface addresses when ioctl returns */
int s;                  /* any socket */

ifc.ifc_len = 144;
ifc.ifc_buf = buffer;
if (ioctl(s, SIOCGIFCONF, &ifc) < 0 ) {
    perror("ioctl failed");
    exit(1);
}
  
```

这里对命令SIOCGIFCONF操作的插口的类型没有限制，如我们所看到的，这个命令返回所有协议族类的地址。

在图4-28中，因为在缓存中返回的三个地址仅占用108(3×36)字节，ioctl将ifc_len

由144改为108。返回三个sockaddr_dl地址，并且这个缓存后面的36字节未用。每项的前16个字节包含接口的文本名称。在这里，这16字节中只有3个字节被使用。

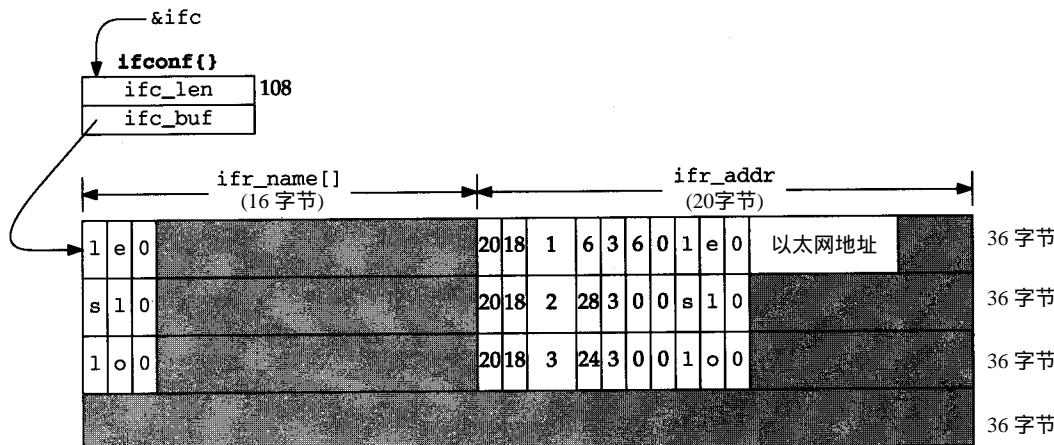


图4-28 SIOCGIFCONF 命令返回的数据

`ifr_addr`为一个`sockaddr`结构的形式，因此第一个值为长度(20字节)，且第二个值为地址的类型(18, AF_LINK)。接下来的一个值为`sdl_index`，与`sdl_type`一样，对于每个接口，它是不同的(与IFT_ETHER、IFT_SLIP和IFT_LOOP相对应的值为6、28和24)。

下面三个值为`sa_nlen`(文本名称的长度)、`sa_alen`(硬件地址的长度)及`sa_slen`(未用)。对于所有三项，`sa_nlen`都为3。以太网地址的`sa_alen`为6，而SLIP和环回接口的`sa_alen`为0。`sa_slen`总是为0。

最后，是接口的文本名称，其后面是硬件地址(仅对于以太网)。SLIP和环回接口在`sockaddr_dl`结构中不存放一个硬件级地址。

在此例中，仅返回`sockaddr_dl`地址(因为在图4-27中没有配置其他地址类型)，因此缓存中的每项大小一样。如果为每个接口配置其他地址(例如：IP或OSI地址)，它们会同`sockaddr_dl`地址一起返回，并且每项的大小根据返回的地址类型的不同而不同。

4.4.4 通用接口 ioctl命令

图4-20中剩下的四个接口命令(SIOCGIFFLAGS、SIOCGIFMETRIC、SIOCSIFFLAGS和SIOCSIFMETRIC)由函数`ifioctl`处理。图4-29所示的是处理这些命令的`case`语句。

1. SIOCGIFFLAGS和SIOCGIFMETRIC

410-416 对于两个SIOCGxxx命令，`ifioctl`将每个接口的`if_flags`或`if_metric`值复制到`ifreq`结构中。对于标志，使用联合的成员`ifr_flags`；而对于度量，使用成员`ifr_metric`(图4-23)。

2. SIOCSIFFLAGS

417-429 为改变接口的标志，调用进程必须有超级用户权限。如果进程正在关闭一个运行的接口或启动一个未运行的接口，分别调用`if_down`和`if_up`。

3. 忽略标志IFF_CANTCHANGE

430-434 回忆图3-7，有些接口标志不能被进程改变。表达式(`ifp -> if_flags & g_s`

`IFF_CANTCHANGE`)清除能被进程改变的接口标志，而表达式 (`ifr->ifr_flags & ~IFF_CANTCHANGE`)清除在请求中不被进程改变的标志。这两个表达式进行或运算并作为新值保存在 `ifp->if_flags` 中。在返回前，请求被传递给与设备相关联的 `if_ioctl` 函数(例如：LANCE驱动器的 `leioctl`——图4-31)。

```

410     switch (cmd) {
411         case SIOCGIFFLAGS:
412             ifr->ifr_flags = ifp->if_flags;
413             break;
414
415         case SIOCGIFMETRIC:
416             ifr->ifr_metric = ifp->if_metric;
417             break;
418
419         case SIOCSIFFLAGS:
420             if (error = suser(p->p_ucred, &p->p_acflag))
421                 return (error);
422             if (ifp->if_flags & IFF_UP && (ifr->ifr_flags & IFF_UP) == 0) {
423                 int      s = splimp();
424                 if_down(ifp);
425                 splx(s);
426             }
427             if (ifr->ifr_flags & IFF_UP && (ifp->if_flags & IFF_UP) == 0) {
428                 int      s = splimp();
429                 if_up(ifp);
430                 splx(s);
431             }
432             ifp->if_flags = (ifp->if_flags & IFF_CANTCHANGE) |
433             (ifr->ifr_flags & ~IFF_CANTCHANGE);
434             if (ifp->if_ioctl)
435                 (void) (*ifp->if_ioctl) (ifp, cmd, data);
436             break;
437
438         case SIOCSIFMETRIC:
439             if (error = suser(p->p_ucred, &p->p_acflag))
440                 return (error);
441             ifp->if_metric = ifr->ifr_metric;
442             break;

```

图4-29 函数 `ifioctl` : 标志和度量

4. SIOCSIFMETRIC

435-439 改变接口的度量要容易些；进程同样要有超级用户权限，`ifioctl` 将接口新的度量复制到 `if_metric` 中。

4.4.5 `if_down` 和 `if_up` 函数

利用程序 `ifconfig`，一个管理员可以通过命令 `SIOCSIFFLAGS` 设置或清除标志 `IFF_UP` 来启用或禁用一个接口。图 4-30 显示了函数 `if_down` 和 `if_up` 的代码。

292-302 当一个接口被关闭时，`IFF_UP` 标志被清除并且对与接口关联的每个地址用 `pfctlinput`(7.7节)发送命令 `PRC_IFDOWN`。这给每个协议一个机会来响应被关闭的接口。有些协议，如 OSI，要使用接口来终止连接。对于 IP，如果可能，要通过其他接口为连接进行重新路由。TCP 和 UDP 忽略失效的接口，并依赖路由协议去发现分组的可选路径。

`if_qflush`忽略接口的任何排队分组。`rt_ifmsg`通知路由系统发生的变化。TCP自动重传丢失的分组；UDP应用必须自己显式地检测这种情况，并对此作出响应。

308-315 当一个接口被启用时，`IFF_UP`标志被设置，并且`rt_ifmsg`通知路由系统接口状态发生变化。

```
292 void if_down(ifp)
293 struct ifnet *ifp;
294 {
295     struct ifaddr *ifa;
296
297     ifp->if_flags &= ~IFF_UP;
298     for (ifa = ifp->if_addrlist; ifa; ifa = ifa->ifa_next)
299         pfctlinput(PRC_IFDOWN, ifa->ifa_addr);
300     if_qflush(&ifp->if_snd);
301     rt_ifmsg(ifp);
302 }
303
304 void if_up(ifp)
305 struct ifnet *ifp;
306 {
307     struct ifaddr *ifa;
308
309     ifp->if_flags |= IFF_UP;
310     rt_ifmsg(ifp);
311 }
```

if.c

图4-30 函数if_down 和if_up

4.4.6 以太网、SLIP和环回

我们看图4-29中处理SIOCSIFFLAGS命令的代码，`ifioctl`调用接口的`if_ioctl`函数。在我们的三个例子接口中，函数`sliioctl`和`loioctl`为这个被`ifioctl`忽略的命令返回`EINVAL`。图4-31显示了函数`leioctl`及LANCE以太网驱动程序的SIOCSIFFLAGS命令的处理。

```
614 leioctl(ifp, cmd, data) if_le.c
615 struct ifnet *ifp;
616 int cmd;
617 caddr_t data;
618 {
619     struct ifaddr *ifa = (struct ifaddr *) data;
620     struct le_softc *le = &le_softc[ifp->if_unit];
621     struct lereg1 *ler1 = le->sc_r1;
622     int s = splimp(), error = 0;
623
624     switch (cmd) {
625
626         /* SIOCSIFADDR code (Figure 6-29) */
627
628     case SIOCSIFFLAGS:
```

图4-31 函数leioctl : SIOCSIFFLAGS

```

639     if ((ifp->if_flags & IFF_UP) == 0 &&
640         ifp->if_flags & IFF_RUNNING) {
641         LERDWR(le->sc_r0, LE_STOP, ler1->ler1_rdp);
642         ifp->if_flags &= ~IFF_RUNNING;
643     } else if (ifp->if_flags & IFF_UP &&
644                 (ifp->if_flags & IFF_RUNNING) == 0)
645         leinit(ifp->if_unit);
646     /*
647      * If the state of the promiscuous bit changes, the interface
648      * must be reset to effect the change.
649      */
650     if (((ifp->if_flags ^ le->sc_iflags) & IFF_PROMISC) &&
651         (ifp->if_flags & IFF_RUNNING)) {
652         le->sc_iflags = ifp->if_flags;
653         lereset(ifp->if_unit);
654         lestart(ifp);
655     }
656     break;
657
658     /* SIOCADDMULTI and SIOCDELMULTI code (Figure 12.31) */
659
660 default:
661     error = EINVAL;
662 }
663 splx(s);
664 return (error);
665 }

```

if_le.c

图4-31 (续)

614-623 leioctl把第三个参数data转换为一个ifaddr结构的指针，并保存在ifa中。le指针引用下标为ifp->if_unit的le_softc结构。基于cmd的switch语句构成了这个函数的主体。

638-656 在图4-31中仅显示了case SIOCSIFFLAGS。这次ifioctl调用leioctl，接口标志被改变。显示的代码强制物理接口进入标志所配置的状态。如果要关闭接口（没有设置IFF_UP），但接口正在工作，则关闭接口。若要启动未操作的接口，接口被初始化并重启。

如果混淆比特被改变，那么就关闭接口，复位，并重启来实现这种变化。

仅当要求改变IFF_PROMISC比特时包含异或和IFF_PROMISC的表达式才为真。

672-677 处理未识别命令的default情况分支发送EINVAL，并在函数的结尾将它返回。

4.5 小结

在本章中，我们说明了LANCE以太网设备驱动程序的实现，这个驱动程序在全书中多处引用。我们还看到了以太网驱动程序如何检测输入中的广播地址和多播地址，如何检测以太网和802.3封装，以及如何将输入的帧分用到相应的协议队列中。在第21章中我们会看到IP地址(单播、广播和多播)是如何在输出转换成正确的以太网地址。

最后，我们讨论了协议专用的 `ioctl` 命令，它用来访问接口层数据结构。

习题

- 4.1 在 `leread` 中，当接收到一个广播分组时，总是设置标志 `M_MCAST`(除了 `M_BCAST` 外)。与 `ether_input` 的代码比较，为什么在 `leread` 和 `ether_input` 中设置此标志？它至关重要吗？哪个正确？
- 4.2 在 `ether_input`(图4-13)中，如果交换广播地址和多播地址检测次序会发生什么情况？如果在检测多播地址的 `if` 语句前加上一个 `else` 会发生什么情况？

第5章 接口：SLIP和环回

5.1 引言

在第4章中，我们查看了以太网接口。在本章中，我们讨论 SLIP和环回接口，同样用 ioctl命令来配置所有网络接口。SLIP驱动程序使用的TCP压缩算法在29.13节讨论。环回驱动程序比较简单，在这里我们要对它进行完整地讨论。

像图4-2一样，图5-1列出了针对我们三个示例驱动程序的入口点。

ifnet	以 太 网	SLIP	环 回	说 明
if_init	leinit			初始化硬件
if_output	ether_output			接收并将要传输的分组进行排队
if_start	lestart			开始传输帧
if_done				输出完成(未用)
if_ioctl	leiioctl	sliioctl	loioctl	从一个进程处理 ioctl命令
if_reset	lerereset			将设备重新设置为一已知状态
if_watchdog				监视设备的故障或采集统计信息

图5-1 例子驱动程序的接口函数

5.2 代码介绍

SLIP和环回驱动程序的代码文件列于图 5-2中。

文 件	说 明
net/if_slvar.h	SLIP定义
net/if_sl.c	SLIP驱动程序函数
net/if_loop.c	环回驱动程序

图5-2 本章讨论的文件

5.2.1 全局变量

在本章讨论SLIP和环回接口结构。全局变量见图 5-3。

变 量	数据类型	说 明
sl_softc	struct sl_softc []	SLIP接口
loif	struct ifnet	环回接口

图5-3 本章中介绍的全局变量

sl_softc是一个数组，因为可能有很多 SLIP接口。loif不是一个数组，因为只可能有一个环回接口。

5.2.2 统计量

在第4章讨论的 ifnet 结构的统计也会被 SLIP 和环回驱动程序更新。采集的另一个统计量(它不在 ifnet 结构中)显示在图 5-4 中。

变 量	说 明	被SNMP使用
tk_nin	被任何串行接口(被SLIP驱动程序更新)接收的字节数	

图 5-4 变量 tk_nin

5.3 SLIP 接口

一个 SLIP 接口通过一个标准的异步串行线与一个远程系统通信。像以太网一样，SLIP 定义了一个标准的方法对传输在串行线上的 IP 分组进行组帧。图 5-5 显示了将一个包含 SLIP 保留字符的 IP 分组封装到一个 SLIP 帧中。

分组用 SLIP END 字符 0xc0 来分割开。如果 END 字符出现在 IP 分组中，则在它前面填充 SLIP ESC 字符 0xdb，并且在传输时将它替换为 0xdc。当 ESC 字符出现在 IP 分组中时，就在它前面填充 ESC 字符 0xdb，并在传输时将它替换为 0xdd。

因为在 SLIP 帧(与以太网比较)中没有类型字段，SLIP 仅适用于传输 IP 分组。

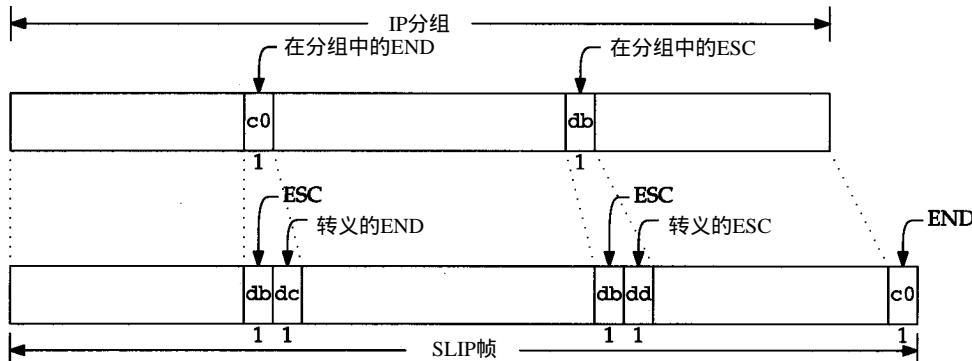


图 5-5 将一个 IP 分组进行 SLIP 封装

在 RFC 1055 [Romkey 1988] 中讨论了 SLIP，陈述了它的很多弱点和非标准情况。卷 1 中包含了 SLIP 封装的详细讨论。

点对点协议(PPP)被设计用来解决 SLIP 的问题，并提供一个标准方法来通过一个串行链路传输帧。PPP 在 RFC 1332 [McGregor 1992] 和 RFC 1548 [Simpson 1993] 中定义。Net/3 不包含一个 PPP 的实现，因此我们不在本书中讨论它。关于 PPP 的更多信息见卷 1 的 2.6 节。附录 B 讨论在哪里获得一个 PPP 实现的参考。

5.3.1 SLIP 线路规程：SLIPDISC

在 Net/3 中，SLIP 接口依靠一个异步串行设备驱动器来发送和接收数据。传统上，这些设备驱动器称为 TTY(电传机)。Net/3 TTY 子系统包括一个线路规程(Line discipline)的概念，这个线路规程作为一个在物理设备和 I/O 系统调用(如 read 和 write)之间的过滤器。一个线路规

程实现以下特性：如行编辑、换行和回车处理、制表符扩展等等。SLIP接口作为TTY子系统的一个线路规程，但它不把输入数据传给从设备读数据的进程，也不接受来自向设备写数据的进程的输出数据。SLIP接口将输入分组传给IP输入队列，并通过SLIP的ifnet结构中的函数if_output来获得要输出的分组。内核通过一个整数常量来标识线路规程，对于SLIP，该常量是SLIPDISC。

图5-6左边显示的是传统的线路规程，右边是SLIP规程。我们在右边用slattach显示进程，因为它是初始化SLIP接口的程序。TTY子系统和线路规程的细节超出了本书的范围。我们仅介绍理解SLIP代码工作的相关信息。对于更多关于TTY子系统的信息见[Leffler et al. 1989]。图5-7列出了实现SLIP驱动程序的函数。中间的列指示函数是否实现线路规程特性和(或)网络接口特性。

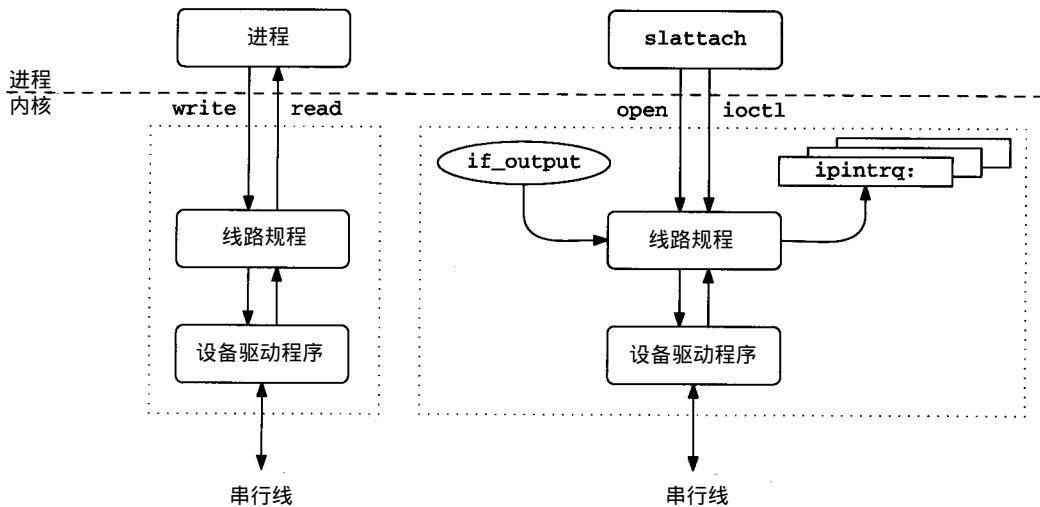


图5-6 SLIP接口作为一个线路规程

函数	网络接口	线路规程	说明
slattach	•		初始化sl_softc结构，并将它连接到ifnet列表
slinit	•		初始化SLIP数据结构
sloutput	•		对相关TTY设备上要传输的输出分组进行排队
sliioctl	•		处理插口ioctl请求
sl_btom	•		将一个设备缓存转换成一个mbuf链表
slopen		•	将sl_softc结构连接到TTY设备，并初始化驱动程序
slclose		•	取消TTY设备与sl_softc结构的连接，标记接口为关闭，并释放存储器
sltioctl		•	处理TTY ioctl命令
slstart	•	•	从队列中取分组，并开始在TTY设备上传输数据
slinput	•	•	处理从TTY设备输入的字节，如果整个帧被接收，就排列输入的分组

图5-7 SLIP设备驱动程序的函数

在Net/3中的SLIP驱动程序通过支持TCP分组首部压缩来得到更好的吞吐量。我们在29.13节讨论分组首部压缩，因此，图5-7跳过实现这些特性的函数。

Net/3 SLIP接口还支持一种转义序列。当接收方检测到这个序列时，就终止SLIP

的处理，并将对设备的控制返回给标准线路规程。我们这里的讨论忽略这个处理。

图5-8显示了作为一个线路规程的SLIP和作为一个网络接口的SLIP间的复杂关系。

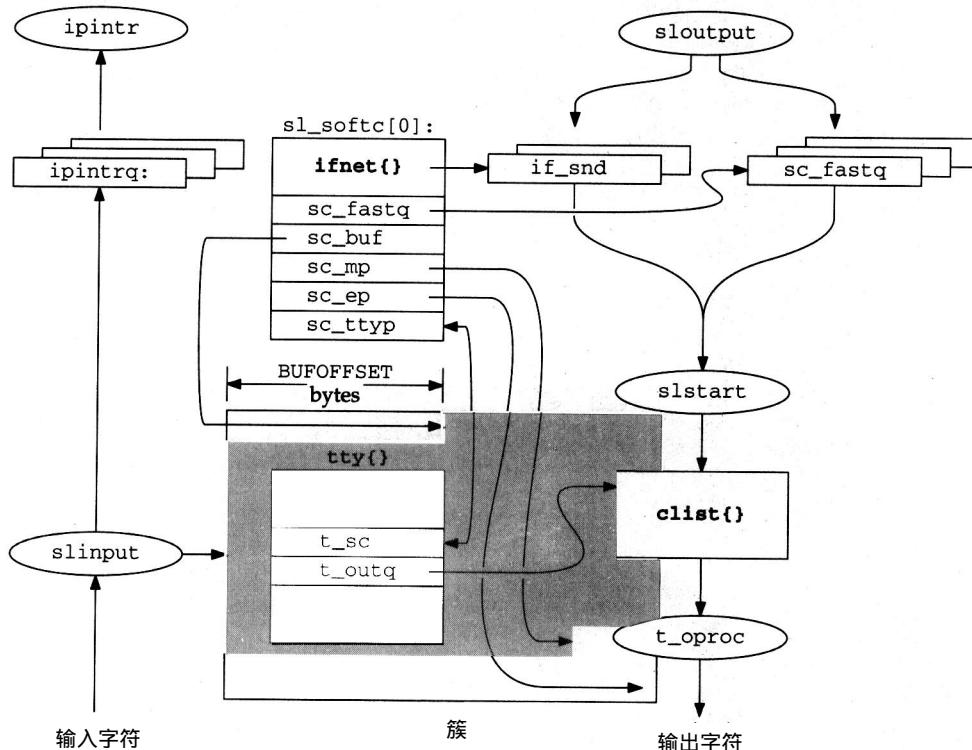


图5-8 SLIP设备驱动程序

在Net/3中，**sc_ttyp**和**t_sc**指向**tty**结构和**sl_softc[0]**结构。由于使用两个箭头会使图显得较乱，我们用一对相反的箭头表示两个指针来说明结构间的双链。

在图5-8中包含很多信息：

- 结构**sl_softc**表示的网络接口和结构**tty**表示的TTY设备。
- 输入字节存放在簇中(显示在结构**tty**后面)。当一个完整的SLIP帧被接收时，封装的IP分组被**slinput**放到**ipintrrq**中。
- 输出分组从**if_snd**或**sc_fastq**退队，转换成SLIP帧，并被**slstart**传给TTY设备。
- TTY缓存将字节输出到结构**clist**。函数**t_oproc**取完，并传输在**clist**结构中的字节。

5.3.2 SLIP初始化：**slopen**和**slinit**

我们在3.7节讨论了**slattach**是如何初始化**sl_softc**结构的。接口虽然被初始化，但还不能操作，直到一个程序(通常是**slattach**)打开一个TTY设备(例如：`/dev/tty01`)，并发送一个*ioctl*命令用SLIP规程代替标准的线路规程才能操作。这时，TTY子系统调用线路规程的打开函数(在此是**slopen**)，此函数在一个特定TTY设备和一个特定SLIP接口间建立关联。**slopen**显示在图5-9中。

```

181 int
182 slopen(dev, tp)
183 dev_t    dev;
184 struct tty *tp;
185 {
186     struct proc *p = curproc; /* XXX */
187     struct sl_softc *sc;
188     int      nsl;
189     int      error;

190     if (error = suser(p->p_ucred, &p->p_acflag))
191         return (error);

192     if (tp->t_line == SLIPDISC)
193         return (0);

194     for (nsl = NSL, sc = sl_softc; --nsl >= 0; sc++)
195         if (sc->sc_ttyp == NULL) {
196             if (slinit(sc) == 0)
197                 return (ENOBUFS);
198             tp->t_sc = (caddr_t) sc;
199             sc->sc_ttyp = tp;
200             sc->sc_if.if_baudrate = tp->t_ospeed;
201             ttyflush(tp, FREAD | FWRITE);
202             return (0);
203         }
204     return (ENXIO);
205 }

```

if_sl.c

图5-9 函数slopen

181-193 传递给slopen的两个参数为：dev，一个内核设备标识，slopen未用此参数；tp，一个指向此TTY设备相关tty结构的指针。最开始是一些预防处理：若进程没有超级用户权限，或TTY的线路规程已经被设置为SLIPDISC，则slopen立即返回。

194-205 for循环在sl_softc结构数组中查找第一个未用的项，调用slinit(5.10节)，通过t_sc和sc_ttyp加进结构tty和sl_softc，并将TTY输出速率(t_ospeed)复制到SLIP接口。ttyflush丢弃任何在TTY队列中追加的输入输出数据。如果一个SLIP接口结构不可用，slopen返回ENXIO。若成功，返回0。

注意，第一个变量sl_softc结构与TTY设备相关。如果系统有多个SLIP线路，在TTY设备和SLIP接口间不需要固定的映射。实际上，这个映射依赖于slattach打开和关闭TTY设备的次序。

显示在图5-10中的函数slinit初始化结构sl_softc。

156-175 函数slinit分配一个mbuf簇，并将它用三个指针连接到结构sl_softc。当一个完整的SLIP帧被接收后，输入字节存储在这个簇中。sc_buf总是指向簇中的这个分组的起始位置，sc_mp指向要接收的下一个字节的位置，并且sc_ep指向这个簇的结束。sl_compress_init为此链路初始化TCP首部的压缩状态(29.13节)。

在图5-8中，我们看到sc_buf不指向簇的第一个字节。slinit保留了148字节(BUFOFFSET)的空间，因为输入分组可能含有一个压缩了的首部，它会扩展来填充这个空间。在簇中已接收的字节用阴影表示。我们看到sc_mp指向接收的最后一个字节的下一个字节，并且sc_ep指向这个簇的结尾。图5-11显示了在几个SLIP常量间的关系。

使这个接口能运行，剩下的要做的工作就是给它分配一个 IP地址。同以太网驱动程序一样，我们将地址分配的讨论推迟到 6.6节。

```

156 static int
157 slinit(sc)
158 struct sl_softc *sc;
159 {
160     caddr_t p;
161
162     if (sc->sc_ep == (u_char *) 0) {
163         MCLALLOC(p, M_WAIT);
164         if (p)
165             sc->sc_ep = (u_char *) p + SLBUFSIZE;
166         else {
167             printf("sl%d: can't allocate buffer\n", sc - sl_softc);
168             sc->sc_if.if_flags &= ~IFF_UP;
169             return (0);
170         }
171         sc->sc_buf = sc->sc_ep - SLMAX;
172         sc->sc_mp = sc->sc_buf;
173         sl_compress_init(&sc->sc_comp);
174         return (1);
175 }

```

图5-10 函数slinit

常量	值	说明
<i>MCLBYTES</i>	2048	一个mbuf簇的大小
<i>SLBUFSIZE</i>	2048	一个未压缩的SLIP分组的最大长度——包括一个BPF首部
<i>SLIP_HDRLEN</i>	16	SLIP BPF首部的大小
<i>BUOFFSET</i>	148	一个扩展的TCP/IP首部的最大长度加上一个BPF首部的大小
<i>SLMAX</i>	1900	一个存储在簇中的压缩SLIP分组的最大长度
<i>SLMTU</i>	296	SLIP分组的最佳长度；导致最小的时延，同时还有较高的批量吞吐量
<i>SLIP_HIWAT</i>	100	在TTY输出队列中排队的最大字节数
BUOFFSET+SLMAX=SLBUFSIZE=MCLBYTES		

图5-11 SLIP常量

5.3.3 SLIP输入处理：slinput

TTY设备驱动程序每次调用 *slinput*，都将输入字符传给 SLIP线路规程。图 5-12显示了函数*slinput*，但跳过了帧结束的处理，对于它我们分开讨论。

527-545 传递给*slinput*的参数为：*c*，下一个输入字符；*tp*，一个指向设备*tty*结构的指针。全局整数*tk_nin*计算所有TTY设备的输入字符数。*slinput*将*tp->t_sc*转换成*sc*，*sc*是指向一个*sl_softc*结构的指针。如果这个TTY设备没有相关联的接口，*slinput*立即返回。

*slinput*的第一个参数是一个整数。除了接收的字符，*c*还包含从 TTY设备驱动程序以高位在前的比特序发送的控制字符。如果在 *c*中指示了一个差错，或调制解调器控制线禁用并且不应该被忽略，则 *SC_ERROR*被置位，并且*slinput*返回。之后，当*slinput*处理END字符时，此帧被丢弃。标志 *CLOCAL*指示系统应该把这个线路视为一个本地线路（即不是一个拨号线程），并且不应该看到调制解调器的控制信号。

if_sl.c

```

527 void
528 slinput(c, tp)
529 int      c;
530 struct tty *tp;
531 {
532     struct sl_softc *sc;
533     struct mbuf *m;
534     int      len;
535     int      s;
536     u_char   chdr[CHDR_LEN];

537     tk_nin++;
538     sc = (struct sl_softc *) tp->t_sc;
539     if (sc == NULL)
540         return;
541     if (c & TTY_ERRORMASK || ((tp->t_state & TS_CARR_ON) == 0 &&
542                               (tp->t_cflag & CLOCAL) == 0)) {
543         sc->sc_flags |= SC_ERROR;
544         return;
545     }
546     c &= TTY_CHARMASK;

547     ++sc->sc_if.if_ibytes;

548     switch (c) {

549     case TRANS_FRAME_ESCAPE:
550         if (sc->sc_escape)
551             c = FRAME_ESCAPE;
552         break;
553     case TRANS_FRAME_END:
554         if (sc->sc_escape)
555             c = FRAME_END;
556         break;

557     case FRAME_ESCAPE:
558         sc->sc_escape = 1;
559         return;

560     case FRAME_END:
561
562         /* FRAME_END code (Figure 5-13) */
563
564     }
565     if (sc->sc_mp < sc->sc_ep) {
566         *sc->sc_mp++ = c;
567         sc->sc_escape = 0;
568         return;
569     }
570     /* can't put lower; would miss an extra frame */
571     sc->sc_flags |= SC_ERROR;

572     error:
573         sc->sc_if.if_ierrors++;
574     newpack:
575         sc->sc_mp = sc->sc_buf = sc->sc_ep - SLMAX;
576         sc->sc_escape = 0;
577     }

```

if_sl.c

图5-12 函数slinput

546-636 slinput丢弃c中的控制比特，并用TTY_CHARMASK来屏蔽掉，更新接口上接收字节数的计数，同时跳过接收到的字符：

- 如果c是一个转义的ESC字符，并且前一字符为ESC，则slinput用一个ESC字符替代c。
- 如果c是一个转义的END字符，并且前一字符为ESC，则slinput用一个END字符代替c。
- 如果c是SLIP ESC字符，则将sc_escape置位，并且slinput立即返回(即，ESC字符被丢弃)。
- 如果c是SLIP END字符，则将分组放到IP输入队列。处理SLIP帧结束字符的代码显示在图5-13中。

```
if sl.c
560     case FRAME_END:
561         if (sc->sc_flags & SC_ERROR) {
562             sc->sc_flags &= ~SC_ERROR;
563             goto newpack;
564         }
565         len = sc->sc_mp - sc->sc_buf;
566         if (len < 3)
567             /* less than min length packet - ignore */
568             goto newpack;

569         if (sc->sc_bpf) {
570             /*
571              * Save the compressed header, so we
572              * can tack it on later. Note that we
573              * will end up copying garbage in some
574              * cases but this is okay. We remember
575              * where the buffer started so we can
576              * compute the new header length.
577             */
578             bcopy(sc->sc_buf, chdr, CHDR_LEN);
579         }
580         if ((c = (*sc->sc_buf & 0xf0)) != (IPVERSION << 4)) {
581             if (c & 0x80)
582                 c = TYPE_COMPRESSED_TCP;
583             else if (c == TYPE_UNCOMPRESSED_TCP)
584                 *sc->sc_buf &= 0x4f; /* XXX */
585             /*
586              * We've got something that's not an IP packet.
587              * If compression is enabled, try to decompress it.
588              * Otherwise, if auto-enable compression is on and
589              * it's a reasonable packet, decompress it and then
590              * enable compression. Otherwise, drop it.
591             */
592             if (sc->sc_if.if_flags & SC_COMPRESS) {
593                 len = sl_uncompress_tcp(&sc->sc_buf, len,
594                                         (u_int) c, &sc->sc_comp);
595                 if (len <= 0)
596                     goto error;
597             } else if ((sc->sc_if.if_flags & SC_AUTOCOMP) &&
598                         c == TYPE_UNCOMPRESSED_TCP && len >= 40) {
599                 len = sl_uncompress_tcp(&sc->sc_buf, len,
600                                         (u_int) c, &sc->sc_comp);
601                 if (len <= 0)
602                     goto error;
603                 sc->sc_if.if_flags |= SC_COMPRESS;
604             } else

```

图5-13 函数slinput：帧结束处理

```

605             goto error;
606         }
607         if (sc->sc_bpf) {
608             /*
609             * Put the SLIP pseudo-"link header" in place.
610             * We couldn't do this any earlier since
611             * decompression probably moved the buffer
612             * pointer. Then, invoke BPF.
613             */
614         u_char *hp = sc->sc_buf - SLIP_HDRLEN;
615
616         hp[SLX_DIR] = SLIPDIR_IN;
617         bcopy(chdr, &hp[SLX_CHDR], CHDR_LEN);
618         bpf_tap(sc->sc_bpf, hp, len + SLIP_HDRLEN);
619     }
620     m = sl_btom(sc, len);
621     if (m == NULL)
622         goto error;
623
624     sc->sc_if.if_ipackets++;
625     sc->sc_if.if_lastchange = time;
626     s = splimp();
627     if (IF_QFULL(&ipintrq)) {
628         IF_DROP(&ipintrq);
629         sc->sc_if.if_ierrors++;
630         sc->sc_if.if_iqdrops++;
631         m_freem(m);
632     } else {
633         IF_ENQUEUE(&ipintrq, m);
634         schednetisr(NETISR_IP);
635     }
636     splx(s);
637     goto newpack;

```

if_sl.c

图5-13 (续)

通过这个switch语句的普通控制流会落到switch外(这里没有default情况)。大多数字节是数据，并且不与这4种情况中的任何一种匹配。前两个case的控制也会落到这个switch外。
637-649 如果控制落到switch外，接收的字符为IP分组中的一部分。这个字符被存储到簇中(如果还有空间)，指针增加，*sc_escape*被清除，并且*sliinput*返回。

如果簇满，字符被丢弃，并且*sliinput*设置SC_ERROR。如果簇满或在处理帧结束时检测到一个差错，则控制跳到 error。程序在 newpack 为一个新的分组重设簇指针，*sc_escape*被清除，并且*sliinput*返回。

图5-13显示了图5-12中跳过的FRAME_END代码。

560-579 如果SC_ERROR被设置，同时正在接收分组或如果分组长度小于3字节(记住，分组可能被压缩)，则*sliinput*立即丢弃此输入SLIP分组。

如果SLIP接口带有BPF，*sliinput*在chdr数组中保存这个首部的一个备份(可能被压缩)。

580-606 通过检查分组的第一个字节，*sliinput*判断它是一个未压缩的IP分组，还是一个压缩的TCP分段，或者一个未压缩的TCP分段。类型存放在c中，并且类型信息从数据的第一个字节中移去(29.13节)。如果分组以压缩形式出现，并且允许压缩，*sl_uncompress_tcp*对分组进行解压缩。如果禁止压缩，自动允许压缩被设置，并且如果分组足够大，则仍然调

用`sl_uncompress_tcp`。如果是一个压缩的TCP分组，则设置压缩标志。

若分组不被识别，`sliinput`跳到`error`，丢弃此分组。29.13节详细讨论了首部压缩技术。现在簇中包含一个完整的未压缩分组。

607-618 SLIP解压缩分组后，首部和数据传给BPF。图5-14显示了`sliinput`构造的缓存格式。

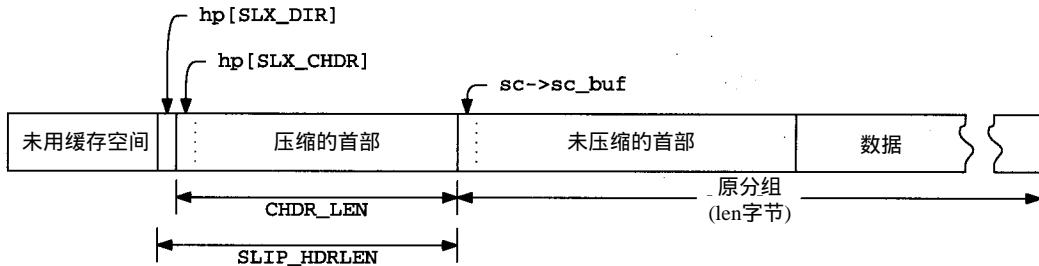


图5-14 BPF格式的SLIP分组

BPF首部的第一个字节是分组方向的编码，在此例中是输入(`SLIPDIR_IN`)。接下来的15字节包含压缩的首部。整个分组被传给`bpf_tap`。

619-635 `sl_btom`将簇转换为一个mbuf链表。如果分组足够小，能放到一个单独的mbuf中，`sl_btom`就将分组从簇复制到一个新分配的mbuf的分组首部；否则`sl_btom`将这个簇连接到一个mbuf，并为这个接口分配一个新簇。这样比从一个簇复制到另一个簇要快。我们在本书中不显示`sl_btom`的代码。

因为在SLIP接口上只能传输IP分组，`sliinput`不必选择协议队列(如以太网驱动程序所做)。分组在`ipintrq`中排队，一个IP软件中断被调度，并且`sliinput`跳到`newpack`，更新簇的分组指针，并清除`sc_escape`。

如果分组不能在`ipintrq`上排队，SLIP驱动程序增加`if_ierrors`，而在这种情况下，以太网或环回驱动程序都不增加这个统计量。

即使在`spltty`调用`sliinput`，访问IP输入队列必须用`splimp`保护。回忆图1-14，一个`splimp`中断能抢占`spltty`进程。

5.3.4 SLIP输出处理：`sloutput`

如所有的网络接口，当一个网络层协议调用接口的`if_output`函数时，开始处理输出。对于以太网驱动程序，此函数是`ether_output`。而对于SLIP，此函数是`sloutput`(图5-15)。

259-289 `sloutput`的4个参数为：`ifp`，指向SLIP`ifnet`结构(在此例中是一个`sl_softc`结构)的指针；`m`，指向排队等待输出的分组的指针；`dst`，分组下一跳的目标地址；`rtp`，指向一个路由表项的指针。`sloutput`未用第4个参数，但却是要求的，因为`sloutput`必须匹配在`ifnet`结构中的`if_output`函数原型。

`sloutput`确认`dst`是一个IP地址，接口被连接到一个TTY设备，并且这个TTY设备是正在运行的(即有载波信号，或应忽略它)。如果任何检测失败，则返回差错。

290-291 SLIP为输出分组维护两个队列。默认选择标准队列`if_snd`。

292-295 如果输出分组包含一个ICMP报文，并且接口的`SC_NOICMP`被置位，则丢弃此分组。这防止一个SLIP链路被一个恶意用户发送的无关ICMP分组(例如ECHO分组)所淹没(第11章)。

```

259 int
260 sloutput(ifp, m, dst, rtp)
261 struct ifnet *ifp;
262 struct mbuf *m;
263 struct sockaddr *dst;
264 struct rtentry *rtp;
265 {
266     struct sl_softc *sc = &sl_softc[ifp->if_unit];
267     struct ip *ip;
268     struct ifqueue *ifq;
269     int     s;
270
271     /*
272      * Cannot happen (see slioctl). Someday we will extend
273      * the line protocol to support other address families.
274      */
275     if (dst->sa_family != AF_INET) {
276         printf("sl%d: af%d not supported\n", sc->sc_if.if_unit,
277               dst->sa_family);
278         m_free(m);
279         sc->sc_if.if_noproto++;
280         return (EAFNOSUPPORT);
281     }
282     if (sc->sc_ttyp == NULL) {
283         m_free(m);
284         return (ENETDOWN); /* sort of */
285     }
286     if ((sc->sc_ttyp->t_state & TS_CARR_ON) == 0 &&
287         (sc->sc_ttyp->t_cflag & CLOCAL) == 0) {
288         m_free(m);
289         return (EHOSTUNREACH);
290     }
291     ifq = &sc->sc_if.if_snd;
292     ip = mtod(m, struct ip *);
293     if (sc->sc_if.if_flags & SC_NOICMP && ip->ip_p == IPPROTO_ICMP) {
294         m_free(m);
295         return (ENETRESET); /* XXX ? */
296     }
297     if (ip->ip_tos & IPTOS_LOWDELAY)
298         ifq = &sc->sc_fastq;
299     s = splimp();
300     if (IF_QFULL(ifq)) {
301         IF_DROP(ifq);
302         m_free(m);
303         splx(s);
304         sc->sc_if.if_oerrors++;
305         return (ENOBUFS);
306     }
307     IF_ENQUEUE(ifq, m);
308     sc->sc_if.if_lastchange = time;
309     if (sc->sc_ttyp->t_outq.c_cc == 0)
310         slstart(sc->sc_ttyp);
311     splx(s);
312     return (0);
313 }

```

if_sl.c

图5-15 函数sloutput

差错码ENETRESET指示分组因决策而被丢弃(相对于网络故障)。我们在第11章会看到除

了在本地产生一个ICMP报文外，此差错简单地被忽略，在这种情况下，一个差错返回给发送此报文的进程。

Net/2在这种情况返回一个0。对于一个诊断工具，如ping或traceroute，会出现这种情况：好像这个分组消失了，因为输出操作会报告成功完成。

通常，ICMP报文可以被丢弃。对于正确的操作，它们并不必要，但丢弃它们会造成更多的麻烦，可能导致不佳的路由决定和较差的性能，并且会浪费网络资源。

296-297 如果在输出分组的TOS字段指明低时延服务(IPTOS_LOWDELAY)，则输出队列改为sc_fastq。

RFC 1700和RFC 1349 [Almquist 1992]规定了标准协议的TOS设置。为Telnet、Rlogin、FTP(控制)、TFTP、SMTP(命令阶段)和DNS(UDP查询)指明了低时延服务。更多细节见卷1的3.2节。

在以前的BSD版本中，ip_tos不由应用程序设置。SLIP驱动程序通过检查在IP分组中的传输首部来实现TOS排队。如果发现FTP(命令)、Telnet或Rlogin端口的TCP分组，分组就如指明了IPTOS_LOWDELAY一样被排队。很多路由器仍然这样，因为很多这些交互服务的实现仍然不设置ip_tos。

298-312 现在分组被放到所选择的队列中，接口统计被更新，并且(如果TTY输出队列为空)sloutput调用slstart来发起对此分组的传输。

如果接口队列满，则SLIP增加if_oerrors；而对于ether_output，则不是这样做的。

不像以太网输出函数(ether_output)，sloutput不为输出分组构造一个数据链路首部。因为在SLIP网络上的另一系统在串行链路的另一端，所以不需要硬件地址或一个协议(如ARP)在IP地址和硬件地址间进行转换。协议标识符(如以太网类型字段)也是多余的，因为一个SLIP链路仅承载IP分组。

5.3.5 slstart函数

除了被sloutput调用外，当TTY取完它的输出队列并要传输更多的字节时，TTY设备调用slstart。TTY子系统通过一个clist结构管理它的队列。在图5-8中，输出clist t_outq显示在slstart下面和设备的t_oproc函数的上面。slstart把字节添加到队列中，而t_oproc将队列取完并传输这些字节。

函数slstart显示在图5-16中。

318-358 当slstart函数被调用时，tp指向设备的tty结构。slstart的主体由一个for循环构成。如果输出队列t_outq不空，slstart调用设备的输出函数t_oproc，此函数传输设备所能接收的字节数。如果TTY输出队列中剩余的字节超过100字节(SLIP_HIWAT)，则slstart返回而不是将另一分组的字节添加到队列中。当传输完所有字节，输出设备产生一个中断，并且当输出列表为空时，TTY子系统调用slstart。

如果TTY输出队列为空，则一个分组从sc_fastq中退队，或者，若sc_fastq为空，则从if_snd队列中退队，这样在其他分组前传输所有交互的分组。

没有标准的SNMP变量来统计根据TOS字段排队的分组。在353行的XXX注释表示SLIP驱动程序在if_omcasts中统计低时延分组数，而不是多播分组数。

359-383 如果SLIP接口带有BPF，slstart在任何首部压缩前为输出分组产生一个备份。这个备份存储在bpfbuf数组的栈中。

384-388 如果允许压缩，并且分组包含一个TCP报文段，则sloutput调用sl_compress_tcp来压缩这个分组。得到的分组类型被返回，并与IP首部的第一个字节(29.13节)进行逻辑或运算。

389-398 压缩的头部现在复制到BPF首部，并且方向标记为SLIPDIR_OUT。完整的BPF分组传给bpf_tap。

483-484 如果for循环终止，则slstart返回。

```

318 void
319 slstart(tp)
320 struct tty *tp;
321 {
322     struct sl_softc *sc = (struct sl_softc *) tp->t_sc;
323     struct mbuf *m;
324     u_char *cp;
325     struct ip *ip;
326     int s;
327     struct mbuf *m2;
328     u_char bpfbuf[SLMTU + SLIP_HDRLEN];
329     int len;
330     extern int cfreecount;

331     for (;;) {
332         /*
333          * If there is more in the output queue, just send it now.
334          * We are being called in lieu of ttstart and must do what
335          * it would.
336          */
337         if (tp->t_outq.c_cc != 0) {
338             (*tp->t_oproc) (tp);
339             if (tp->t_outq.c_cc > SLIP_HIWAT)
340                 return;
341         }
342         /*
343          * This happens briefly when the line shuts down.
344          */
345         if (sc == NULL)
346             return;
347         /*
348          * Get a packet and send it to the interface.
349          */
350         s = splimp();
351         IF_DEQUEUE(&sc->sc_fastq, m);
352         if (m)
353             sc->sc_if.if_omcasts++; /* XXX */
354         else
355             IF_DEQUEUE(&sc->sc_if.if_snd, m);
356         splx(s);
357         if (m == NULL)
358             return;

```

图5-16 函数slstart：分组退队

```

359      /*
360      * We do the header compression here rather than in sloutput
361      * because the packets will be out of order if we are using TOS
362      * queueing, and the connection id compression will get
363      * munged when this happens.
364      */
365      if (sc->sc_bpf) {
366          /*
367          * We need to save the TCP/IP header before it's
368          * compressed. To avoid complicated code, we just
369          * copy the entire packet into a stack buffer (since
370          * this is a serial line, packets should be short
371          * and/or the copy should be negligible cost compared
372          * to the packet transmission time).
373          */
374          struct mbuf *m1 = m;
375          u_char *cp = bpfbuf + SLIP_HDRLEN;
376
377          len = 0;
378          do {
379              int      mlen = m1->m_len;
380
381              bcopy(mtod(m1, caddr_t), cp, mlen);
382              cp += mlen;
383              len += mlen;
384          } while (m1 = m1->m_next);
385
386          if ((ip = mtod(m, struct ip *))->ip_p == IPPROTO_TCP) {
387              if (sc->sc_if.if_flags & SC_COMPRESS)
388                  *mtod(m, u_char *) |= sl_compress_tcp(m, ip,
389                                              &sc->sc_comp, 1);
390
391          if (sc->sc_bpf) {
392              /*
393              * Put the SLIP pseudo-"link header" in place. The
394              * compressed header is now at the beginning of the
395              * mbuf.
396              */
397              bpfbuf[SLX_DIR] = SLIPDIR_OUT;
398              bcopy(mtod(m, caddr_t), &bpfbuf[SLX_CHDR], CHDR_LEN);
399              bpf_tap(sc->sc_bpf, bpfbuf, len + SLIP_HDRLEN);
400          }
401
402      }
403  }
404 }
```

if_sl.c

图5-16 (续)

slstart的下一部分(图5-17)在系统存储器容量不足时丢弃分组，并且采用一种简单的技术来丢弃由于串行线上的噪声产生的数据。这些代码在图5-16中忽略了。

399-409 如果系统缺少clist结构，则分组被丢弃，并且作为一个冲突被统计。通过不断地循环而不是返回，slstart快速地丢弃所有剩余的排队输出的分组。由于设备仍然有太多字节为输出排队，每次迭代都要丢弃一个分组。高层协议必须检测丢失的分组并重传它们。

410-418 如果TTY输出队列为空，则通信线路可能有一段时间空闲，并且接收方在另一端

可能接收了线路噪声产生的无关数据。slstart在输出队列中放置一个额外的SLIP END字符。一个长度为0的帧或一个由线路噪声产生的帧应该被接收方SLIP接口或IP协议丢弃。

```

399     sc->sc_if.if_lastchange = time;                                if_sl.c
400
401     /*
402      * If system is getting low on clists, just flush our
403      * output queue (if the stuff was important, it'll get
404      * retransmitted).
405      */
406     if (cframerelease < CLISTRESERVE + SLMTU) {
407         m_freem(m);
408         sc->sc_if.if_collisions++;
409         continue;
410     }
411     /*
412      * The extra FRAME-END will start up a new packet, and thus
413      * will flush any accumulated garbage. We do this whenever
414      * the line may have been idle for some time.
415      */
416     if (tp->t_outq.c_cc == 0) {
417         ++sc->sc_if.if_oBYTES;
418         (void) putc(FRAME-END, &tp->t_outq);
419     }

```

图5-17 函数slstart：资源缺乏和线路噪声

图5-18说明了这个丢弃线路噪声的技术，它来源于由Phil Karn撰写的RFC 1055。在图5-18中，传输第二个帧结束符(END)，因为线路空闲了一段时间。由噪声产生的无效帧和这个END字节被接收系统丢弃。

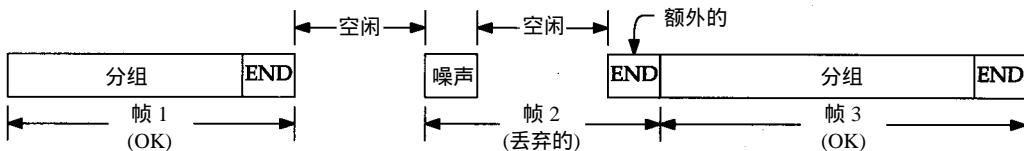


图5-18 Karn的丢弃SLIP线路噪声的方法

在图5-19中，线路上没有噪声并且0长度帧被接收系统丢弃。

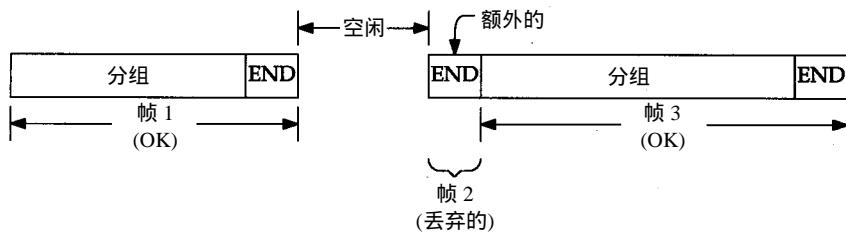


图5-19 无噪声的Karn方法

slstart的下一部分(图5-20)将数据从一个mbuf传给TTY设备的输出队列。

419-467 在这部分的外部while循环对链表中的每个mbuf执行一次。中间的while循环将数据从每个mbuf传给输出设备。内部的while循环不断递增cp，直到它找到一个END或ESC字符。b_to_q传输bp到cp之间的数据。END和ESC字符被转义，并且两次通过调用putc放

入队列。中间的循环直到 mbuf的所有字节都传给 TTY设备输出队列才停止。图 5-21说明了对包含了一个SLIP END字符和一个SLIP ESC字符的mbuf的处理。

bp标记用b_to_q传输的mbuf的第一部分的开始，cp标记这个部分的结束。ep标记这个mbuf中数据的结束位置。

```

419         while (m) {
420             u_char *ep;
421
422             cp = mtod(m, u_char *);
423             ep = cp + m->m_len;
424             while (cp < ep) {
425                 /*
426                  * Find out how many bytes in the string we can
427                  * handle without doing something special.
428                 */
429                 u_char *bp = cp;
430
431                 while (cp < ep) {
432                     switch (*cp++) {
433                         case FRAME_ESCAPE:
434                         case FRAME_END:
435                             --cp;
436                             goto out;
437                         }
438                     if (cp > bp) {
439                         /*
440                          * Put n characters at once
441                          * into the tty output queue.
442                         */
443                         if (b_to_q((char *) bp, cp - bp,
444                                 &tp->t_outq))
445                             break;
446                         sc->sc_if.if_obytes += cp - bp;
447                     }
448                     /*
449                      * If there are characters left in the mbuf,
450                      * the first one must be special..
451                      * Put it out in a different form.
452                     */
453                     if (cp < ep) {
454                         if (putc(FRAME_ESCAPE, &tp->t_outq))
455                             break;
456                         if (putc(*cp++ == FRAME_ESCAPE ?
457                                 TRANS_FRAME_ESCAPE : TRANS_FRAME_END,
458                                 &tp->t_outq)) {
459                             (void) unputc(&tp->t_outq);
460                             break;
461                         }
462                         sc->sc_if.if_obytes += 2;
463                     }
464                 }
465                 MFREE(m, m2);
466                 m = m2;
467             }

```

图5-20 函数slstart：传输分组

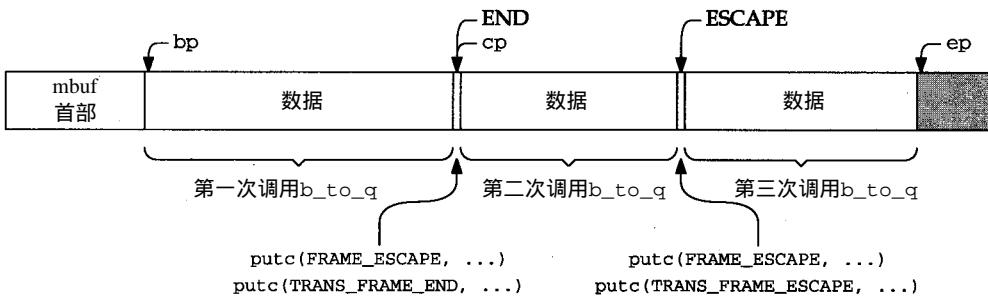


图5-21 单个mbuf的SLIP传输

如果b_to_q或putc失败(即，数据不能在TTY设备排队)，则break导致slstart退出内部while循环。这种失败表示内核clist资源用完。在每个mbuf被复制到TTY设备后，或者当一个差错发生时，mbuf被释放，m增加到链表的下一个mbuf，并且外部while循环继续执行直到链表中所有mbuf被处理。

图5-22显示了slstart完成输出帧的处理。

```

468     if (putc(FRAME_END, &tp->t_outq)) {
469     /*
470      * Not enough room. Remove a char to make room
471      * and end the packet normally.
472      * If you get many collisions (more than one or two
473      * a day) you probably do not have enough clists
474      * and you should increase "nclist" in param.c.
475      */
476      (void) unputc(&tp->t_outq);
477      (void) putc(FRAME_END, &tp->t_outq);
478      sc->sc_if.if_collisions++;
479    } else {
480      ++sc->sc_if.if_obytes;
481      sc->sc_if.if_opackets++;
482    }

```

图5-22 函数slstart：帧结束处理

468-482 当外部while循环处理完对输出队列中的字节排队时，控制到达这段代码。驱动程序发送一个SLIP END字符，来终止这个帧。

如果这些字节在排队时发生差错，则输出帧无效，并会因为“无效的检验和”或“无效的长度”被接收系统检测出来。

无论这个帧是不是因为一个差错而终止，如果END字符没有填充到输出队列中，队列的最后一个字符就要被丢弃，并且slstart将使这个帧结束。这保证传输了一个END字符。这个无效帧在目标站被丢弃。

5.3.6 SLIP分组丢失

SLIP接口提供了一个尽最大努力服务的好例子。如果TTY超载，则SLIP丢弃分组；在分组开始传输后，如果资源不可用，则它截断分组，并且为了检测和丢弃线路噪声插入无关的空分组。对以上的每一种情况都不产生差错报文。SLIP依靠IP层和运输层来检测损坏的和丢失的分组。

在一个路由器上从一个高速接口例如以太网，发送帧到一个低速的 SLIP线路上。如果发送方不能意识到瓶颈并相应调节数据速率，则会有大比例的分组被丢弃。在 25.11节我们会看到TCP是如何检测并对此响应的。应用程序使用一个无流量控制的协议，如 UDP，必须自己识别和响应这种情况(习题5.8)。

5.3.7 SLIP性能考虑

一个SLIP帧的MTU(SLMTU)、clist高水位标记(high-water mark)(SLIP_HIWAT)和SLIP的TOS排队策略都是用来设计交互通信的低速串行链，使得固有的时延最小。

1) 一个小的MTU能够改进交互数据的时延(如敲键和回显)，但有损批量数据传输的吞吐量。一个大的MTU能改进批量数据的吞吐量，但增加了交互时延。SLIP链路的另一个问题是键入一个字符就要有40字节的开销来写入TCP首部和IP首部的信息，这就增加了通信的时延。

解决办法是挑选一个足够大的MTU来提供好的交互响应时间和适当的批量数据吞吐量，并压缩TCP/IP首部来减小每个分组的负荷。RFC 1144 [Jacobson 1990a]描述了一个压缩方案和时间计算，它为一个典型的9600 b/s异步SLIP链路选择了一个数值为296的MTU。我们在29.13节讨论压缩的SLIP(CSLIP)。卷1的2.10节和7.2节总结了这种定时考虑，并说明了在SLIP链路上的时延。

2) 如果有太多的字节缓存在clist中(因为SLIP_HIWAT设置得太高)，TOS排队会受到阻碍，因为新的交互式通信等在大量缓存数据的后面。如果SLIP一次传给TTY驱动程序一个字节(因为SLIP_HIWAT设置得太低)，设备为每个字节调用slstart，并在每个字节传输后线路空闲一段时间。把SLIP_HIWAT设置为100可使在设备排队的数据量最小化，并且减小了TTY子系统调用slstart的频率，大约每100字符必须调用slstart一次。

3) 如前所述，SLIP驱动程序提供了TOS排队，其策略是先从sc_fastq队列中发送交互式通信数据，然后在标准接口队列if_snd中发送其他的通信数据。

5.3.8 slclose函数

为了完整性，我们显示函数slclose。当slattach程序关闭SLIP的TTY设备，并且中断对远程系统的连接时，调用它。

```

210 void
211 slclose(tp)
212 struct tty *tp;
213 {
214     struct sl_softc *sc;
215     int      s;

216     ttywflush(tp);
217     s = splimp();           /* actually, max(spltty, splnet) */
218     tp->t_line = 0;
219     sc = (struct sl_softc *) tp->t_sc;
220     if (sc != NULL) {
221         if_down(&sc->sc_if);
222         sc->sc_ttyp = NULL;
223         tp->t_sc = NULL;

```

图5-23 函数slclose

```

224     MCLFREE((caddr_t) (sc->sc_ep - SLBUFSIZE));
225     sc->sc_ep = 0;
226     sc->sc_mp = 0;
227     sc->sc_buf = 0;
228 }
229 splx(s);
230 }

```

if_sl.c

图5-23 (续)

210-230 tp指向要关闭的TTY设备。slclose清除任何残留在串行设备中的数据，中断TTY和网络处理，并且将TTY复位到默认的线路规程。如果TTY设备被连接到一个SLIP接口，则关闭这个接口，在这两个结构间的链接被切断，与此接口关联的mbuf簇被释放，并且指向现在被丢弃的簇的指针被复位。最后，splx重新允许TTY中断和网络中断。

5.3.9 sltioctl函数

回忆一下，SLIP在内核中有两种作用：

- 作为一个网络接口；
- 作为一个TTY线路规程。

图5-7显示了sliioctl处理通过一个插口描述符发送给一个SLIP接口的ioctl命令。在4.4节中，我们显示了ifioctl是如何调用sliioctl的。我们会看到一个处理 ioctl命令的相似模型，并且在后面的章节中会讨论到。

图5-7还表示了sltioctl处理发送给与一个SLIP网络接口关联的TTY设备的ioctl命令。这个被sltioctl识别的命令显示在图5-24中。

命 令	参 数	函 数	说 明
SLIOCGUNIT	int *	sltioctl	返回与TTY设备关联的接口联合

图5-24 sliioctl 命令

函数sltioctl显示在图5-25中。

```

236 int
237 sltioctl(tp, cmd, data, flag)
238 struct tty *tp;
239 int cmd;
240 caddr_t data;
241 int flag;
242 {
243     struct sl_softc *sc = (struct sl_softc *) tp->t_sc;
244     switch (cmd) {
245         case SLIOCGUNIT:
246             *(int *) data = sc->sc_if.if_unit;
247             break;
248         default:
249             return (-1);
250     }
251     return (0);
252 }

```

if_sl.c

图5-25 函数sltioctl

236-252 tty结构的t_sc指针指向关联的sl_softc结构。这个SLIP接口的设备号从if_unit被复制到*data，它最后返回给进程(17.5节)。

当系统被初始化时，slattach初始化if_unit，并且当slattach程序为此TTY设备选择SLIP线路规程时，slopen初始化t_sc。因为一个TTY设备和一个SLIP sl_softc结构间的关系是在运行时建立的，一个进程能通过SLIOCGUNIT命令发现所选择的接口结构。

5.4 环回接口

任何发送给环回接口(图5-26)的分组立即排入输入队列。接口完全用软件实现。

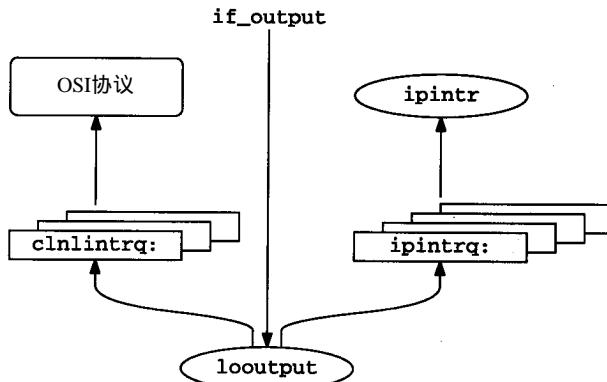


图5-26 环回设备驱动程序

环回接口的if_output指向的函数looutput，将输出分组放置到分组的目的地址指明的协议的输入队列中。

我们已经看到当设备被设置为IFF_SIMPLEX时，ether_output会调用looutput来排队一个输出广播分组。在第12章中，我们会看到多播分组也可能以这种方式环回。looutput显示在图5-27中。

```

57 int
58 looutput(ifp, m, dst, rt)                                if_loop.c
59 struct ifnet *ifp;
60 struct mbuf *m;
61 struct sockaddr *dst;
62 struct rtentry *rt;
63 {
64     int      s, isr;
65     struct ifqueue *ifq = 0;
66
67     if ((m->m_flags & M_PKTHDR) == 0)
68         panic("looutput no HDR");
69     ifp->if_lastchange = time;
70     if (loif.if_bpf) {
71         /*
72          * We need to prepend the address family as
73          * a four byte field. Cons up a dummy header
74          * to pacify bpf. This is safe because bpf
75          * will only read from the mbuf (i.e., it won't
76          * try to free it or keep a pointer a to it).
77         */
78     }
  
```

图5-27 函数looutput

```

77     struct mbuf m0;
78     u_int af = dst->sa_family;
79
80     m0.m_next = m;
81     m0.m_len = 4;
82     m0.m_data = (char *) &af;
83
84     bpf_mtap(loif.if_bpf, &m0);
85 }
86 m->m_pkthdr.rcvif = ifp;
87
88 if (rt && rt->rt_flags & (RTF_REJECT | RTF_BLACKHOLE)) {
89     m_freem(m);
90     return (rt->rt_flags & RTF_BLACKHOLE ? 0 :
91             rt->rt_flags & RTF_HOST ? EHOSTUNREACH : ENETUNREACH);
92 }
93 ifp->if_opackets++;
94 ifp->if_obytes += m->m_pkthdr.len;
95 switch (dst->sa_family) {
96 case AF_INET:
97     ifq = &ipintrq;
98     isr = NETISR_IP;
99     break;
100
101 case AF_ISO:
102     ifq = &clnlintrq;
103     isr = NETISR_ISO;
104     break;
105
106 default:
107     printf("lo%d: can't handle af%d\n", ifp->if_unit,
108           dst->sa_family);
109     m_freem(m);
110     return (EAFNOSUPPORT);
111 }
112 s = splimp();
113 if (IF_QFULL(ifq)) {
114     IF_DROP(ifq);
115     m_freem(m);
116     splx(s);
117     return (ENOBUFS);
118 }
119 IF_ENQUEUE(ifq, m);
120 schednetisr(isr);
121 ifp->if_ipackets++;
122 ifp->if_obytes += m->m_pkthdr.len;
123 splx(s);
124 return (0);
125 }

```

if_loop.c

图5-27 (续)

57-66 looutput的参数同ether_output一样，因为都是通过它们的ifnet结构中的if_output指针直接调用的。ifp，指向输出接口的ifnet结构的指针；m，要发送的分组；dst，分组的目的地址；rt，路由信息。如果链表中的第一个mbuf不包含一个分组，looutput调用panic。

图5-28所示的是一个BPF环回分组的逻辑格式。

69-83 驱动程序在堆栈上的m0中构造BPF环回分组，并且把m0连接到包含原始分组的mbuf

链表中。注意m0的声明不同往常。它是一个 mbuf，而不是一个 mbuf指针。m0的m_data指向af，它也分配在这个堆栈中。图 5-29 显示了这种安排。

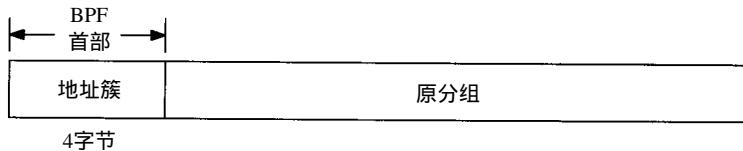


图 5-28 BPF 环回分组：逻辑格式

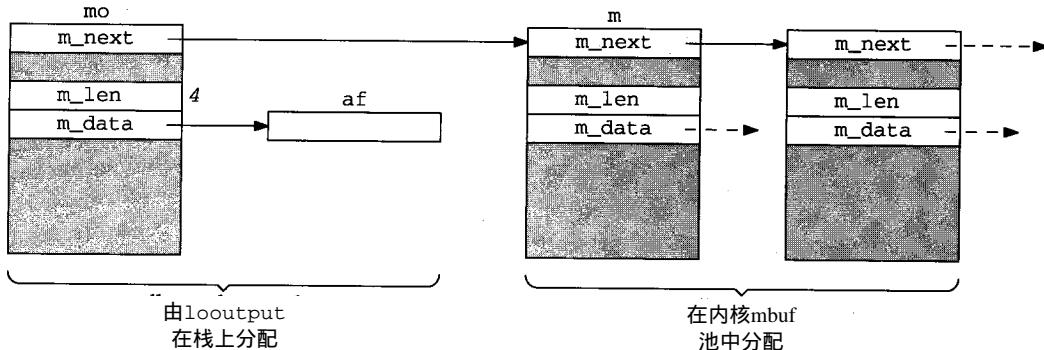


图 5-29 BPF 环回分组：mbuf 格式

looutput 将目的地址族复制到 af，并且将新 mbuf 链表传递给 bpf_mtap，去处理这个分组。与 bpf_tap 相比，它在一个单独的连续缓存中接收这个分组而不是在一个 mbuf 链表中。如图中注释所示，BPF 从来不释放一个链表中的 mbuf，因此将 m0 (它指向栈中的一个 mbuf) 传给 bpf_mtap 是安全的。

84-89 looutput 剩下的代码包含 input 对此分组的处理。虽然这是一个输出函数，但分组被环回到输入。首先，m->m_pkthdr.rcvif 设置为指向接收接口。如果调用方提供一个路由项，looutput 检查是否它指示此分组应该被拒绝 (RTF_REJECT) 或直接被丢弃 (RTF_BLACKHOLE)。通过丢弃 mbuf 并返回 0 来实现一个黑洞。从调用者看来就好像分组已经被传输了。要拒绝一个分组，如果路由是一个主机，则 looutput 返回 EHOSTUNREACH；如果路由是一个网络则返回 ENETUNREACH。

各种 RTF_xxx 标志在图 18-25 中描述。

90-120 然后 looutput 通过检查分组目的地址中的 sa_family 来选择合适的协议输入队列和软件中断。接着把识别的分组进行排队，并用 schednetisr 来调度一个软件中断。

5.5 小结

我们讨论了两个剩下的接口，它们在书中多次引用：s10，一个 SLIP 接口；lo0，标准的环回接口。

我们显示了在 SLIP 接口和 SLIP 线路规程之间的关系，讨论了 SLIP 封装方法，并且讨论了 TOS 处理交互式通信和 SLIP 驱动程序的其他性能考虑。

我们显示了环回接口是如何按目的地址分用输出分组及将分组放到相应的输入队列中去。

习题

- 5.1 为什么环回接口没有输入函数？
- 5.2 你认为为什么图5-27中的m0要分配在堆栈中？
- 5.3 分析一个19 200 b/s的串行线的SLIP特性。对于这个线路，SLIP MTU应该改变吗？
- 5.4 导出一个根据串行线速率选择 SLIP MTU的公式。
- 5.5 如果一个分组对于 SLIP输入缓存太大，会发生什么情况？
- 5.6 一个slinput的早期版本，当一个分组在输入缓存溢出时，不将 SC_ERROR置位。
在这种情况下如何检测这种差错？
- 5.7 在图4-31中le被下标为ifp->if_unit的le_softc数组项初始化。你能想出另一种初始化le的方法吗？
- 5.8 当分组因为网络瓶颈被丢弃时，一个 UDP应用程序如何知道？

第6章 IP 编址

6.1 引言

本章讨论Net/3如何管理IP地址信息。我们从`in_ifaddr`和`sockaddr_in`结构开始，它们基于通用的`ifaddr`和`sockaddr`结构。

本章其余部分讨论IP地址的指派和几个查询接口数据结构与维护IP地址的实用函数。

6.1.1 IP地址

虽然我们假设读者熟悉基本的Internet编址系统，仍然有几点值得指出。

在IP模型中，地址是指派给一个系统（一个主机或路由器）中的网络接口而不是系统本身。在系统有多个接口的情况下，系统有多重初始地址，并有多个IP地址。一个路由器被定义为有多重初始地址。如我们所看到的，这个体系特点有几个小分支。

IP地址定义了5类。A、B和C类地址支持单播通信。D类地址支持IP多播。在一个多播通信中，一个单独的源方发送一个数据报给多个目标方。D类地址和多播协议在第12章说明。E类地址是试验用的。接收的E类地址分组被不参与试验的主机丢弃。

我们强调IP多播和硬件多播间的区别是重要的。硬件多播的特点是数据链路硬件用来将帧传输给多个硬件接口。有些网络硬件，如以太网，支持数据链路多播。其他硬件可能不支持。

IP多播是一个在IP系统内实现的软件特性，将分组传输给多个可能在Internet中任何位置的IP地址。

我们假设读者熟悉IP网络的子网划分(RFC 950 [Mogul and Postel 1985]和卷1的第3章)。我们会看到每个网络接口有一个相关的子网掩码，它是判断一个分组是否到达它最后的目的地或还需要被转发的关键。通常，当提及一个IP地址的网络部分时，我们包括任何可能定义的子网。当需要区分网络和子网时，我们就要明确地指出来。

环回网络，127.0.0.0，是一个特殊的A类网络。这种格式的地址是不会出现在一个主机的外部的。发送到这个网络的分组被环回并被这个主机接收。

RFC 1122要求所有在环回网络中的地址被正确地处理。因为环回接口必须指派一个地址，很多系统选择127.0.0.1作为环回地址。如果系统不能正确识别，像127.0.0.2这样的地址可能不能被路由到环回接口而被传输到一个连接的网络，这是不允许的。有些系统可能正确地路由这个到环回接口的分组，但由于目标地址与地址127.0.0.1不匹配，分组被丢弃。

图18-2显示了一个Net/3系统配置为拒绝接收发送到一个不是127.0.0.1的环回地址的分组。

6.1.2 IP地址的印刷规定

我们通常以点分十进制数表示法来显示一个IP地址。图6-1列出了每类IP地址的范围。

地址类	范 围	类 型
A	0.0.0.0到127.255.255.255	
B	128.0.0.0到191.255.255.255	单播
C	192.0.0.0到223.255.255.255	
D	224.0.0.0到239.255.255.255	多播
E	240.0.0.0到247.255.255.255	试验性

图6-1 不同IP地址类的范围

对于我们的有些例子，子网字段不按一个字节对齐（即，一个网络/子网/主机在一个B类网络中分为16/11/5）。从点分十进制数表示法很难表示这样的地址，因此我们还是用方块图来说明IP地址的内容。我们用三个部分显示每个地址：网络、子网和主机。每个部分的阴影指示它的内容。图6-2用我们网络示例（1.14节）中的主机sun的以太网接口来同时说明块表示法和点分十进制数表示法。

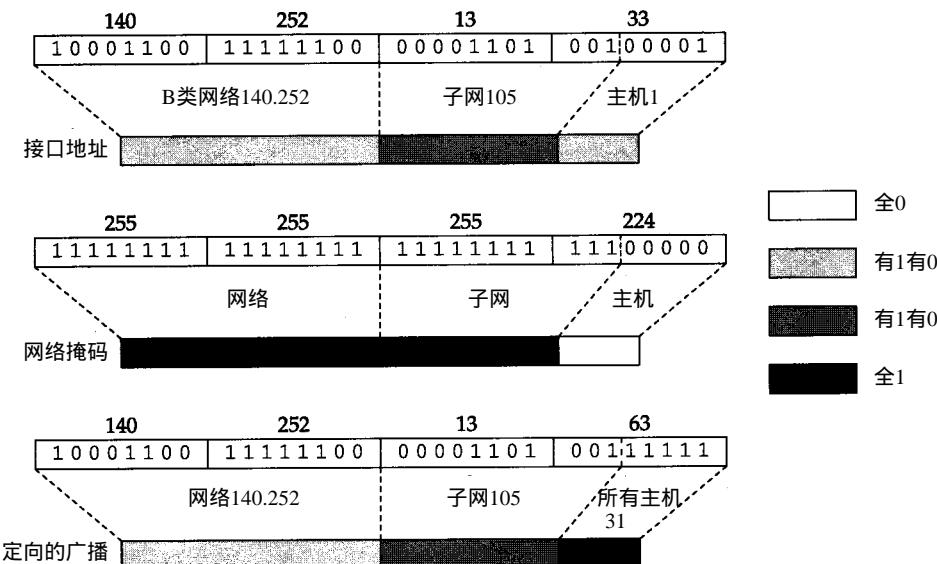


图6-2 可选的IP地址表示法

当地址的一个部分不是全为0或1时，我们使用两个中等程度的阴影。有两种中等程度的阴影，这样我们就能区分网络和子网部分或用来显示如图 6-31所示的地址组合。

6.1.3 主机和路由器

在一个Internet上的系统通常能划分为两类：主机和路由器。一个主机通常有一个网络接口，并且是一个IP分组的源或目标方。一个路由器有多个网络接口，当分组向它的目标方移动时将分组从一个网络转发到下一个网络。为执行这个功能，路由器用各种专用路由协议来交换关于网络拓扑的信息。IP路由问题比较复杂，在第18章开始讨论它们。

如果一个有多个网络接口的系统不在网络接口间路由分组，仍然叫一个主机。一个系统可能既是一个主机又是一个路由器。这种情况经常发生在当一个路由器提供运输层服务如用

于配置的 Telnet 访问，或用于网络管理的 SNMP 时。当区分一个主机和路由器间的意义并不重要时，我们使用术语系统。

不谨慎地配置一个路由器会干扰一个网络的正常运转，因此 RFC 1122 规定一个系统必须默认为一个主机来操作，并且必须显式地由一个管理员来配置作为一个路由器操作。这样做是不鼓励管理员将通用主机作为路由器来操作而没有仔细地配置。在 Net/3 中，如果全局整数 `ipforwarding` 不为 0，则一个系统作为一个路由器；如果 `ipforwarding` 为 0（默认），则系统作为一个主机。

在 Net/3 中，一个路由器通常称为网关，虽然术语网关现在更多的是与一个提供应用层路由的系统相关，如一个电子邮件网关，而不是转发 IP 分组的系统。我们在本书中使用术语路由器，并假设 `ipforwarding` 非 0。在编译 Net/3 内核期间，当 GATEWAY 被定义时，我们还有条件地包括所有代码，它们将 `ipforwarding` 定义为 1。

6.2 代码介绍

图 6-3 所列的两个头文件和两个 C 文件包含本章中讨论的结构定义和实用函数。

文 件	说 明
<code>netinet/in.h</code>	Internet 地址定义
<code>netinet/in_var.h</code>	Internet 接口定义
<code>netinet/in.c</code>	Internet 初始化和实用函数
<code>netinet/if.c</code>	Internet 接口实用函数

图 6-3 本章讨论的文件

全局变量

图 6-4 所列的是本章中介绍的两个全局变量。

变 量	数据类型	说 明
<code>in_ifaddr</code>	<code>struct in_ifaddr</code>	<code>in_ifaddr</code> 结构列表的首部
<code>in_interfaces</code>	<code>int</code>	有 IP 能力的接口个数

图 6-4 在本章中介绍的全局变量

6.3 接口和地址小结

在本章讨论的所有接口和地址结构的一个例子配置如图 6-5 所示。

图 6-5 显示了我们的三个接口例子：以太网接口、SLIP 接口和环回接口。它们都有一个链路层地址作为地址列表中的第一个结点。显示的以太网接口有两个 IP 地址，SLIP 接口有一个 IP 地址，并且环回接口有一个 IP 地址和一个 OSI 地址。

注意所有的 IP 地址被链接到 `in_ifaddr` 列表中，并且所有链路层地址能从 `ifnet_addrs` 数组访问。

为了清楚起见，图 6-5 没有画出每个 `ifaddr` 结构中的指针 `ifa_ifp`。这些指针回指包含此 `ifaddr` 结构的列表的首部 `ifnet` 结构。

接下来的部分讨论图 6-5 中的数据结构及用来查看和修改这些结构的 IP 专用 `ioctl` 命令。

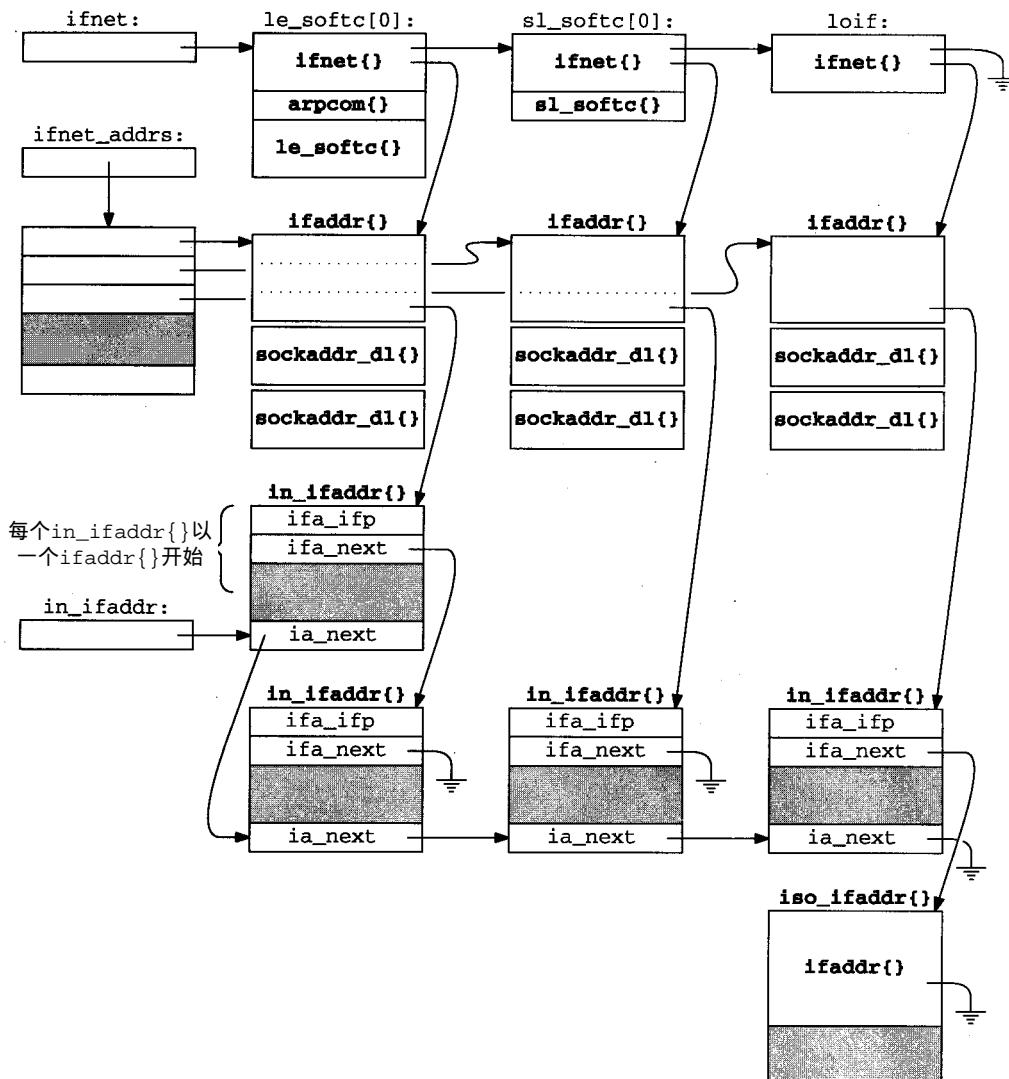


图6-5 接口和地址数据结构

6.4 sockaddr_in结构

我们在第3章讨论了通用的 **sockaddr** 和 **ifaddr** 结构。现在我们显示 IP专用的结构：**sockaddr_in** 和 **in_ifaddr**。在 Internet 域中的地址存放在一个 **sockaddr_in** 结构：

由于历史原因，Net/3以网络字节序将Internet地址存储在一个 **in_addr** 结构中。这个结构只有一个成员 **s_addr**，它包含这个地址。虽然这是多余和混乱的，但在 Net/3中一直保持这种组织方式。

106-112 **sin_len** 总是 16(结构 **sockaddr_in** 的大小)，并且 **sin_family** 为 **AF_INET**。
sin_port 是一个网络字节序(不是主机字节序)的 16 bit 值，用来分用运输层报文。
sin_addr 标识一个 32 bit Internet 地址。

图6-6显示了 **sockaddr_in** 的成员 **sin_port**、**sin_addr** 和 **sin_zero** 覆盖 **sockaddr**

的成员 `sa_data`。在 Internet 域中，`sin_zero` 未用，但必须由全 0 字节组成(2.7节)。将它追加到 `sockaddr_in` 结构后面，以得到与一个 `sockaddr` 结构一样的长度。

```
68 struct in_addr {
69     u_long s_addr;           /* 32-bit IP address, net byte order */
70 };
71
106 struct sockaddr_in {
107     u_char sin_len;          /* sizeof (struct sockaddr_in) = 16 */
108     u_char sin_family;        /* AF_INET */
109     u_short sin_port;         /* 16-bit port number, net byte order */
110     struct in_addr sin_addr;
111     char sin_zero[8];         /* unused */
112 };
113
114 #endif /* _SOLARIS_SOURCE */
115
116 #endif /* _INET_SOURCE */
117
118 #endif /* _NETINET_SOURCE */
```

图6-6 结构 `sockaddr_in`

通常，当一个 Internet 地址存储在一个 `u_long` 中时，它以主机字节序存储，以便于地址的压缩和位操作。在 `in_addr` 结构(图6-7)中的 `s_addr` 是一个值得注意的例外。

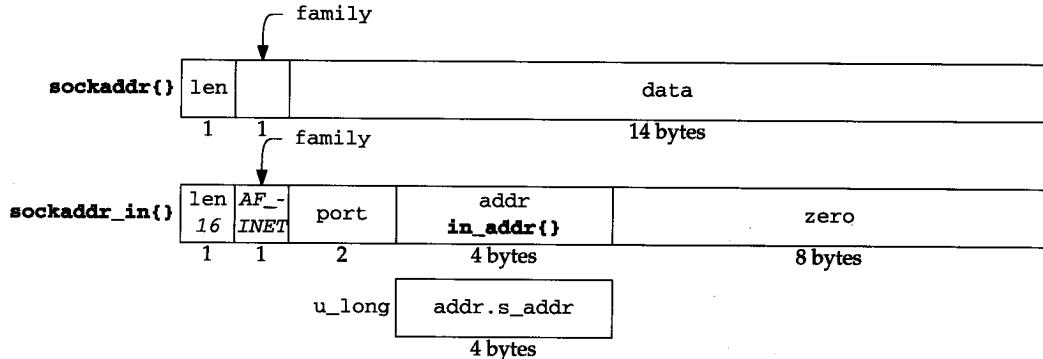


图6-7 一个 `sockaddr_in` 结构(省略 `sin_`)的组织

6.5 in_ifaddr 结构

图6-8显示了为 Internet 协议定义的接口地址结构。对于每个指派给一个接口的 IP 地址，分配了一个 `in_ifaddr` 结构，并且添加到接口地址列表中和 IP 地址全局列表中(图6-5)。

41-45 `in_ifaddr` 开始是一个通用接口地址结构 `ia_ifa`，跟着是 IP 专用成员。`ifaddr` 结构显示在图3-15中。两个宏 `ia_ifp` 和 `ia_flags` 简化了对存储在通用 `ifaddr` 结构中的接口指针和接口地址标志的访问。`ia_next` 维护指派给任意接口的所有 Internet 地址的链接列表。这个列表独立于每个接口关联的链路层 `ifaddr` 结构列表，并且通过全局列表 `in_ifaddr` 来访问。

46-54 其余的成员(除了 `ia_multiaddrs`)显示在图6-9中，它显示了在我们的 B 类网络例子中 `sun` 的三个接口的相应值。地址按主机字节序以 `u_long` 变量存储；变量 `in_addr` 和 `sockaddr_in` 按照网络字节序存储。`sun` 有一个 PPP 接口，但显示在本表中的信息对于一个 PPP 或 SLIP 接口是一样的。

55-56 结构 `in_ifaddr` 的最后一个成员指向一个 `in_multi` 结构的列表(12.6节)，其中每项包含与此接口有关的一个 IP 多播地址。

```

41 struct in_ifaddr {                                     in_var.h
42     struct ifaddr ia_ifa;                            /* protocol-independent info */
43 #define ia_ifp          ia_ifa.ifa_ifp
44 #define ia_flags         ia_ifa.ifa_flags
45     struct in_ifaddr *ia_next;           /* next internet addresses list */
46     u_long    ia_net;                  /* network number of interface */
47     u_long    ia_netmask;             /* mask of net part */
48     u_long    ia_subnet;              /* subnet number, including net */
49     u_long    ia_subnetmask;          /* mask of subnet part */
50     struct in_addr ia_netbroadcast; /* to recognize net broadcasts */
51     struct sockaddr_in ia_addr;      /* space for interface name */
52     struct sockaddr_in ia_dstaddr;   /* space for broadcast addr */
53 #define ia_broadaddr    ia_dstaddr
54     struct sockaddr_in ia_sockmask; /* space for general netmask */
55     struct in_multi *ia_mult��addrs; /* list of multicast addresses */
56 };

```

*in_var.h*图6-8 结构*in_ifaddr*

变 量	类 型	以 太 网	P P P	环 回	说 明
ia_addr	sockaddr_in	[] [] [] 140.252.13.33	[] [] [] 140.252.1.29	[] [] [] 127.0.0.1	网络 , 子网和主机号
ia_net	u_long	[] [] [] 140.252.0.0	[] [] [] 140.252.0.0	[] [] [] 127.0.0.0	网络号
ia_netmask	u_long	[] [] [] 255.255.0.0	[] [] [] 255.255.0.0	[] [] [] 255.0.0.0	网络号掩码
ia_subnet	u_long	[] [] [] 140.252.13.32	[] [] [] 140.252.1.0	[] [] [] 127.0.0.0	网络和子网号
ia_subnetmask	u_long	[] [] [] 255.255.255.224	[] [] [] 255.255.255.0	[] [] [] 255.0.0.0	网络和子网掩码
ia_netbroadcast	in_addr	[] [] [] 140.252.255.255	[] [] [] 140.252.255.255	[] [] [] 127.255.255.255	网络广播地址
ia_broadaddr	sockaddr_in	[] [] [] 140.252.13.63			定向广播地址
ia_dstaddr	sockaddr_in		[] [] [] 140.252.1.183	[] [] [] 127.0.0.1	目的地址
ia_sockmask	sockaddr_in	[] [] [] 255.255.255.224	[] [] [] 255.255.255.0	[] [] [] 255.0.0.0	像ia_subnetmask 但是用网络字节序

图6-9 sun 上的以太网、PPP和环回*in_ifaddr* 结构

6.6 地址指派

在第4章中，我们显示了当接口结构在系统初始化期间被识别时的初始化。在 Internet协议能通过这个接口进行通信前，必须指派一个 IP地址。一旦Net/3内核运行，程序*ifconfig*就配置这些接口，*ifconfig*通过在某个插口上的*ioctl*系统调用来发送配置命令。这通常通过/*etc/netstart* she脚本来实现，这个脚本在系统引导时执行。

图6-10显示了本章中讨论的*ioctl*命令。命令相关的地址必须是此命令指定插口所支持的地址族类(即，你不能通过一个 UDP插口配置一个 OSI地址)。对于IP地址，*ioctl*命令在一

个UDP插口上发送。

命 令	参 数	函 数	说 明
<i>SIOCGIFADDR</i>	<i>struct ifreq *</i>	<i>in_control</i>	获得接口地址
<i>SIOCGIFNETMASK</i>	<i>struct ifreq *</i>	<i>in_control</i>	获得接口网络掩码
<i>SIOCGIFDSTADDR</i>	<i>struct ifreq *</i>	<i>in_control</i>	获得接口目标地址
<i>SIOCGIFBRDADDR</i>	<i>struct ifreq *</i>	<i>in_control</i>	获得接口广播地址
<i>SIOCSIFADDR</i>	<i>struct ifreq *</i>	<i>in_control</i>	设置接口地址
<i>SIOCSIFNETMASK</i>	<i>struct ifreq *</i>	<i>in_control</i>	设置接口网络掩码
<i>SIOCSIFDSTADDR</i>	<i>struct ifreq *</i>	<i>in_control</i>	设置接口目标地址
<i>SIOCSIFBRDADDR</i>	<i>struct ifreq *</i>	<i>in_control</i>	设置接口广播地址
<i>SIOCDIFADDR</i>	<i>struct ifreq *</i>	<i>in_control</i>	删除接口地址
<i>SIOCAIFADDR</i>	<i>struct in_aliasreq *</i>	<i>in_control</i>	添加接口地址

图6-10 接口 ioctl 命令

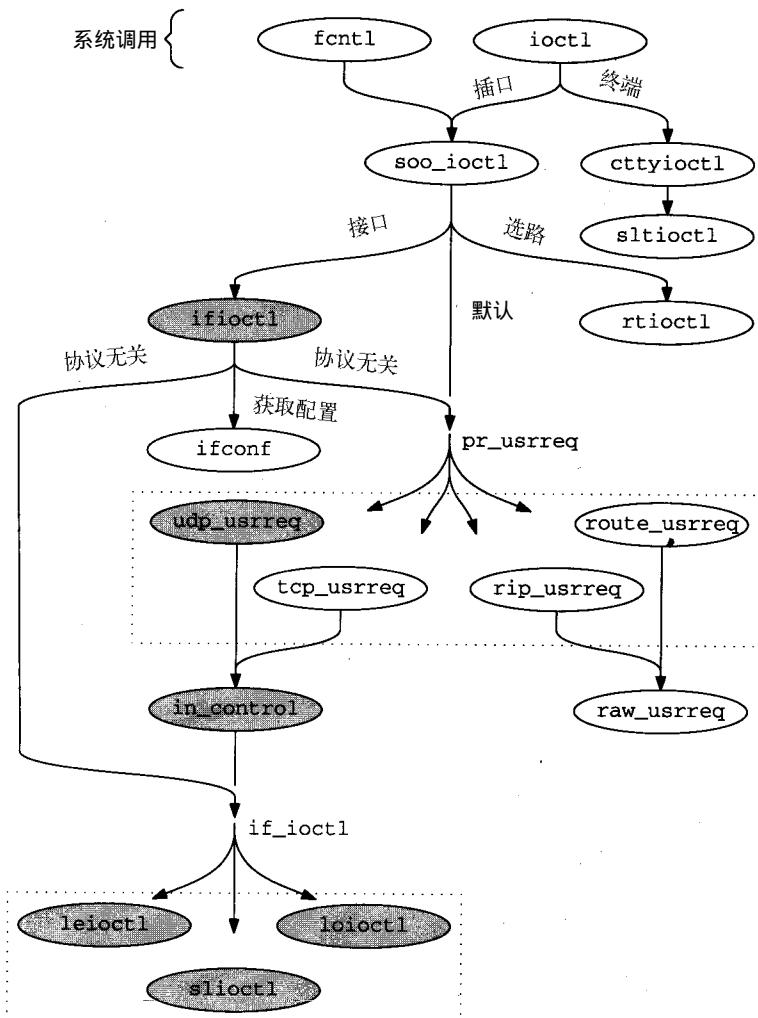


图6-11 本章中说明的 ioctl 函数

获得地址信息的命令从 SIOCG开始，设置地址信息的命令从 SIOCS 开始。SIOC代表socket ioctl，G代表get，而S代表set。

在第4章中，我们看到了5个与协议无关的 ioctl命令。图6-10中的命令修改一个接口的相关地址信息。由于地址是特定协议使用的，因此，命令处理是与协议相关的。图 6-11强调了与这些命令关联的 ioctl相关函数。

6.6.1 ifioctl函数

如图6-11所示，ifioctl将协议无关的 ioctl命令传递给此插口关联协议的pr_usrreq函数。将控制交给udp_usrreq，并且又立即传给in_control，在in_control中进行大部分的处理。如果在一个TCP插口上发送同样的命令，控制最后也会到达 in_control。图6-12再次显示了ifioctl中的default代码，第一次显示在图4-22中。

```
447     default:
448         if (so->so_proto == 0)
449             return (EOPNOTSUPP);
450         return ((*so->so_proto->pr_usrreq) (so, PRU_CONTROL,
451                                         cmd, data, ifp));
452     }
453     return (0);
454 }
```

图6-12 函数ifioctl：特定协议的命令

447-454 函数将图6-10中所列 ioctl命令的所有相关数据传给与请求指定的插口相关联的协议的用户请求函数。对于一个 UDP插口，调用udp_usrreq。23.10节讨论udp_usrreq函数的细节。现在，我们仅需要查看 udp_usrreq中的PRU_CONTROL代码：

```
if (req == PRU_CONTROL)
    return (in_control(so, (int)m, (caddr_t)addr, (struct ifnet *)control));
```

6.6.2 in_control函数

图6-11显示了通过soo_ioctl中的default或ifioctl中的与协议相关的情况，控制能到达 in_control。在这两种情况下， udp_usrreq调用 in_control，并返回 in_control的返回值。图6-13显示了in_control。

132-145 so指向这个 ioctl命令(由第二个参数cmd标识)指定的插口。第三个参数data指向命令所用或返回的数据(图6-10的第二列)。最后一个参数 ifp为空(来自soo_ioctl的无接口 ioctl)或指向结构ifreq或in_aliasreq中命名的接口(来自ifioctl的接口 ioctl)。in_control初始化ifr和ifra来访问作为一个ifreq或in_aliasreq结构的数据。

146-152 如果ifp指向一个ifnet结构，这个for循环找到与此接口关联的 Internet地址列表中的第一个地址。如果发现一个地址， ia指向它的in_ifaddr结构；否则 ia为空。

若ifp为空， cmd就不会匹配第一个 switch中的任何情况；或第二个 switch中任何非默认情况。在第二个switch中的default情况下，当 ifp为空时，返回EOPNOTSUPP。

153-330 in_control中的第一个 switch确保在第二个switch处理命令之前每个命令的前提条件都满足。在后面的章节会单独说明各个情况。

```

132 in_control(so, cmd, data, ifp)                                in.c
133 struct socket *so;
134 int      cmd;
135 caddr_t data;
136 struct ifnet *ifp;
137 {
138     struct ifreq *ifr = (struct ifreq *) data;
139     struct in_ifaddr *ia = 0;
140     struct ifaddr *ifa;
141     struct in_ifaddr *oia;
142     struct in_aliasreq *ifra = (struct in_aliasreq *) data;
143     struct sockaddr_in oldaddr;
144     int      error, hostIsNew, maskIsNew;
145     u_long   i;

146     /*
147      * Find address for this interface, if it exists.
148      */
149     if (ifp)
150         for (ia = in_ifaddr; ia; ia = ia->ia_next)
151             if (ia->ia_ifp == ifp)
152                 break;

153     switch (cmd) {


218 }
219     switch (cmd) {


326     default:
327         if (ifp == 0 || ifp->if_ioctl == 0)
328             return (EOPNOTSUPP);
329         return ((*ifp->if_ioctl) (ifp, cmd, data));
330     }
331     return (0);
332 }

```

in.c

图6-13 函数in_control

如果在第二个switch中的default情况被执行，ifp指向一个接口结构；并且如果接口有一个if_ioctl函数，则in_control将ioctl命令传给这个接口进行设备的特定处理。

Net/3不定义任何会被default情况处理的接口命令。但是，一个特定设备的驱动程序可能会定义它自己的接口 ioctl命令，并通过这个case来处理它们。

331-332 我们会看到这个switch语句中的很多情况都直接返回了。如果控制落到两个switch语句外，则in_control返回0。第二个switch中有几个case执行了跳出语句。

我们按照下面的顺序查看这个接口 ioctl命令：

- 指派一个地址、网络掩码或目标地址；
- 指派一个广播地址；

- 取回一个地址、网络掩码、目标地址或广播地址；
- 给一个接口指派多播地址；
- 删除一个地址。

对于每组命令，在第一个 switch 语句中进行前提条件处理，然后在第二个 switch 语句中处理命令。

6.6.3 前提条件：SIOCSIFADDR、SIOCSIFNETMASK和SIOCSIFDSTADDR

图6-14显示了对 SIOCSIFADDR、SIOCSIFNETMASK 和 SIOCSIFDSTADDR 的前提条件检验。

```

166     case SIOCSIFADDR:
167     case SIOCSIFNETMASK:
168     case SIOCSIFDSTADDR:
169         if ((so->so_state & SS_PRIV) == 0)
170             return (EPERM);
171
172         if (ifp == 0)
173             panic("in_control");
174         if (ia == (struct in_ifaddr *) 0) {
175             oia = (struct in_ifaddr *)
176                 malloc(sizeof *oia, M_IFADDR, M_WAITOK);
177             if (oia == (struct in_ifaddr *) NULL)
178                 return (ENOBUFS);
179             bzero((caddr_t) oia, sizeof *oia);
180             if (ia = in_ifaddr) {
181                 for (; ia->ia_next; ia = ia->ia_next)
182                     continue;
183                 ia->ia_next = oia;
184             } else
185                 in_ifaddr = oia;
186             ia = oia;
187             if (ifa = ifp->if_addrlist) {
188                 for (; ifa->ifa_next; ifa = ifa->ifa_next)
189                     continue;
190                 ifa->ifa_next = (struct ifaddr *) ia;
191             } else
192                 ifp->if_addrlist = (struct ifaddr *) ia;
193
193             ia->ia_ifa.ifa_addr = (struct sockaddr *) &ia->ia_addr;
194             ia->ia_ifa.ifa_dstaddr
195                 = (struct sockaddr *) &ia->ia_dstaddr;
196             ia->ia_ifa.ifa_netmask
197                 = (struct sockaddr *) &ia->ia_sockmask;
198             ia->ia_sockmask.sin_len = 8;
199             if (ifp->if_flags & IFF_BROADCAST) {
200                 ia->ia_broadaddr.sin_len = sizeof(ia->ia_addr);
201                 ia->ia_broadaddr.sin_family = AF_INET;
202             }
203             ia->ia_ifp = ifp;
204             if (ifp != &loif)
205                 in_interfaces++;
206         }
206         break;

```

图6-14 函数 in_control : 地址指派

1. 仅用于超级用户

166-172 如果这个插口不是由一个超级用户进程创建的，这些命令被禁止，并且 `in_control` 返回 `EPERM`。如果此请求没有关联的接口，内核调用 `panic`。由于如果 `ifioctl` 不能找到一个接口，它就返回(图4-22)，因此，`panic`从来不会被调用。

当一个超级用户进程创建一个插口时，`socreate`(图15-16)设置标志 `SS_PRIV`。因为这里的检验是针对标志而不是有效的进程用户 ID的，所以一个设置用户 ID的根进程能创建一个插口，并且放弃它的超级用户权限，但仍然能发送有特权的 `ioctl` 命令。

2. 分配结构

173-191 如果 `ia` 为空，命令请求一个新的地址。`in_control` 分配一个 `in_ifaddr` 结构，用 `bzero` 清除它，并且将它链接到系统 的 `in_ifaddr` 列表中和此接口的 `if_addrlist` 列表中。

3. 初始化结构

192-206 代码的下一部分初始化 `in_ifaddr` 结构。首先，在此结构的 `ifaddr` 部分的通用指针被初始化为指向结构 `in_ifaddr` 中的结构 `sockaddr_in`。必要时，此函数还初始化结构 `ia_sockmask` 和 `ia_broadaddr`。图6-15说明了初始化后的结构 `in_ifaddr`。

202-206 最后，`in_control` 建立从 `in_ifaddr` 到此接口的 `ifnet` 结构的回指指针。Net/3在 `in_interfaces` 中只统计非环回接口。

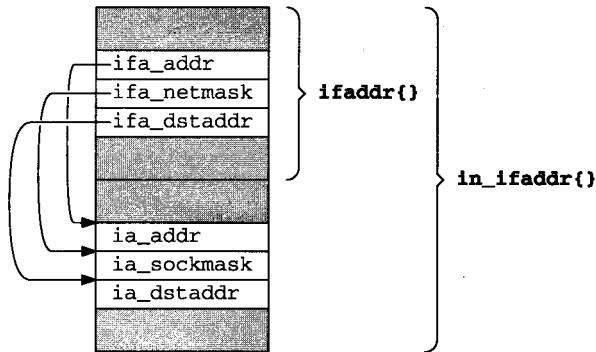


图6-15 被 `in_control` 初始化后的一个 `in_ifaddr` 结构

6.6.4 地址指派：SIOCSIFADDR

前提条件处理代码保证 `ia` 指向一个要被 `SIOCSIFADDR` 命令修改的 `in_ifaddr` 结构。图 6-16 显示了 `in_control` 第二个 `switch` 中处理这个命令的执行代码。

```

259     case SIOCSIFADDR:
260         return (in_ifinit(ifp, ia,
261                         (struct sockaddr_in *) &ifr->ifr_addr, 1));

```

图6-16 函数 `in_control`：地址指派

159-261 `in_ifinit` 完成所有的工作。IP地址包含在 `ifreq` 结构(`ifr_addr`)里传递给 `in_ifinit`。

6.6.5 in_ifinit函数

`in_ifinit`的主要步骤是：

- 将地址复制到此结构并将此变化通知硬件；

- 忽略原地址配置的任何路由；
- 为这个地址建立一个子网掩码；
- 建立一个默认路由到连接的网络(或主机)；
- 将此接口加入到所有主机组。

从图6-17开始分三个部分讨论这段代码。

353-357 in_ifinit的四个参数为：ifp，指向接口结构的指针；ia，指向要改变的in_ifaddr结构的指针；sin，指向请求的IP地址的指针；scrub，指示这个接口如果存在路由应该被忽略。i保存主机字节序的IP地址。

```

353 in_ifinit(ifp, ia, sin, scrub)           in.c
354 struct ifnet *ifp;
355 struct in_ifaddr *ia;
356 struct sockaddr_in *sin;
357 int      scrub;
358 {
359     u_long i = ntohl(sin->sin_addr.s_addr);
360     struct sockaddr_in oldaddr;
361     int      s = splimp(), flags = RTF_UP, error, ether_output();
362     oldaddr = ia->ia_addr;
363     ia->ia_addr = *sin;
364     /*
365      * Give the interface a chance to initialize
366      * if this is its first address,
367      * and to validate the address if necessary.
368      */
369     if (ifp->if_ioctl &&
370         (error = (*ifp->if_ioctl) (ifp, SIOCSIFADDR, (caddr_t) ia))) {
371         splx(s);
372         ia->ia_addr = oldaddr;
373         return (error);
374     }
375     if (ifp->if_output == ether_output) { /* XXX: Another Kludge */
376         ia->ifa_ifa_rtrequest = arp_rtrequest;
377         ia->ifa_ifa_flags |= RTF_CLONING;
378     }
379     splx(s);
380     if (scrub) {
381         ia->ifa_ifa_addr = (struct sockaddr *) &oldaddr;
382         in_ifscrub(ifp, ia);
383         ia->ifa_ifa_addr = (struct sockaddr *) &ia->ia_addr;
384     }

```

图6-17 函数in_ifinit：地址指派和路由初始化

1. 指派地址并通知硬件

358-374 in_control将原来的地址保存在oldaddr中，万一发生差错时，必须恢复它。如果接口定义了一个if_ioctl函数，则in_control调用它。相同接口的三个函数le ioctl、sli ioctl和lo ioctl在下一节讨论。如果发生差错，恢复原来的地址，并且in_control返回。

2. 以太网配置

375-378 对于以太网设备，arp_rtrequest作为链路层路由函数被选择，并且设置RTF_CLONING标志。arp_rtrequest在21.13节讨论，而RTF_CLONING在19.4节的最后

讨论。如xxx注释所建议，在此加入代码以避免改变所有以太网驱动程序。

3. 忽略原来的路由

379-384 如果调用者要求已存在的路由被清除，原地址被重新连接到 `ifa_addr`，同时 `in_ifscrub` 找到并废除任何基于老地址的路由。`in_ifscrub` 返回后，新地址被恢复。

`in_ifinit` 显示在图 6-18 中的部分构造网络和子网掩码。

```

385     if (IN_CLASSA(i))
386         ia->ia_netmask = IN_CLASSA_NET;
387     else if (IN_CLASSB(i))
388         ia->ia_netmask = IN_CLASSB_NET;
389     else
390         ia->ia_netmask = IN_CLASSC_NET;
391     /*
392      * The subnet mask usually includes at least the standard network part,
393      * but may be smaller in the case of supernetting.
394      * If it is set, we believe it.
395     */
396     if (ia->ia_subnetmask == 0) {
397         ia->ia_subnetmask = ia->ia_netmask;
398         ia->ia_sockmask.sin_addr.s_addr = htonl(ia->ia_subnetmask);
399     } else
400         ia->ia_netmask &= ia->ia_subnetmask;
401     ia->ia_net = i & ia->ia_netmask;
402     ia->ia_subnet = i & ia->ia_subnetmask;
403     in_socktrim(&ia->ia_sockmask);

```

in.c

图 6-18 函数 `in_ifinit`：网络和子网掩码

4. 构造网络掩码和默认子网掩码

385-400 根据地址是一个 A 类、B 类或 C 类地址，在 `ia_netmask` 中构造了一个尝试性网络掩码。如果这个地址没有子网掩码，`ia_subnetmask` 和 `ia_sockmask` 被初始化为 `ia_netmask` 中的尝试性掩码。

如果指定了一个子网，`in_ifinit` 将这个尝试性网络掩码和这个已存在的子网掩码进行逻辑与运算来获得一个新的网络掩码。这个操作可能会清除该尝试性网络掩码的一些 1 bit（它从来不设置 0 bit，因为 0 逻辑与任何值都得到 0）。在这种情况下，网络掩码比所考虑的地址类型所期望的要少一些 1 bit。

这叫作超级联网，它在 RFC 1519 [Fuller et al. 1993] 中作了描述。一个超级网络是几个 A 类、B 类或 C 类网络的一个群组。卷 1 的 10.8 节也讨论了超级联网。

一个接口默认配置为不划分子网（即，网络和子网的掩码相同）。一个显式请求（用 `SIOCSIFNETMASK` 或 `SIOCAIFADDR`）用来允许子网划分（或超级联网）。

5. 构造网络和子网数量

401-403 网络和子网数量通过网络和子网掩码从新地址中获得。函数 `in_socktrim` 通过查找掩码中包含 1 bit 的最后一个字节来设置 `in_sockmask`（是一个 `sockaddr_in` 结构）的长度。

图 6-19 显示了 `in_ifinit` 的最后一部分，它为接口添加了一个路由，并加入所有主机多播组。

6. 为主机或网络建立路由

404-422 下一步是为新地址所指定的网络创建一个路由。`in_control` 从接口将路由度量

复制到结构 `in_ifaddr` 中。如果接口支持广播，则构造广播地址，并且把目的地址强制为分配给环回接口的地址。如果一个点对点接口没有一个指派给链路另一端的 IP 地址，则 `in_control` 在试图为这个无效地址建立路由前返回。

`in_ifinit` 将 `flags` 初始化为 `RTF_UP`，并与环回和点对点接口的 `RTF_HOST` 进行逻辑或。`rtinit` 为此接口给这个网络（不设置 `RTF_HOST`）或主机（设置 `RTF_HOST`）安装一个路由。若 `rtinit` 安装成功，则设置 `ia_flags` 中的标志 `IFA_ROUTE`，指示已给此地址安装了一个路由。

```

404     /*
405      * Add route for the network.
406      */
407     ia->ia_ifa.ifa_metric = ifp->if_metric;
408     if (ifp->if_flags & IFF_BROADCAST) {
409         ia->ia_broadaddr.sin_addr.s_addr =
410             htonl(ia->ia_subnet | ~ia->ia_subnetmask);
411         ia->ia_netbroadcast.s_addr =
412             htonl(ia->ia_net | ~ia->ia_netmask);
413     } else if (ifp->if_flags & IFF_LOOPBACK) {
414         ia->ia_ifa.ifa_dstaddr = ia->ia_ifa.ifa_addr;
415         flags |= RTF_HOST;
416     } else if (ifp->if_flags & IFF_POINTOPOINT) {
417         if (ia->ia_dstaddr.sin_family != AF_INET)
418             return (0);
419         flags |= RTF_HOST;
420     }
421     if ((error = rtinit(&(ia->ia_ifa), (int) RTM_ADD, flags)) == 0)
422         ia->ia_flags |= IFA_ROUTE;
423     /*
424      * If the interface supports multicast, join the "all hosts"
425      * multicast group on that interface.
426      */
427     if (ifp->if_flags & IFF_MULTICAST) {
428         struct in_addr addr;
429         addr.s_addr = htonl(INADDR_ALLHOSTS_GROUP);
430         in_addmulti(&addr, ifp);
431     }
432     return (error);
433 }
```

图6-19 函数 `in_ifinit`：路由和多播组

7. 加入所有主机组

423 - 433 最后，一个有多播能力的接口当它被初始化时必须加入所有主机多播组。`in_addmulti` 完成此工作，并在 12.11 节讨论。

6.6.6 网络掩码指派：`SIOCSIFNETMASK`

图6-20显示了网络掩码命令的处理。

```

262     case SIOCSIFNETMASK:
263         i = ifra->ifra_addr.sin_addr.s_addr;
264         ia->ia_subnetmask = ntohl(ia->ia_sockmask.sin_addr.s_addr = i);
265         break;
```

图6-20 函数 `in_control`：网络掩码指派

262-265 `in_control`从`ifreq`结构中获取网络掩码，并将它以网络字节序保存在`ia_sockmask`中，以主机字节序保存在`ia_subnetmask`中。

6.6.7 目的地址指派：SIOCSIFDSTADDR

对于点对点接口，在链路另一端的系统的地址用`SIOCSIFDSTADDR`命令指定。图6-14显示了图6-21中的代码的前提条件处理。

```

236     case SIOCSIFDSTADDR:
237         if ((ifp->if_flags & IFF_POINTOPOINT) == 0)
238             return (EINVAL);
239         oldaddr = ia->ia_dstaddr;
240         ia->ia_dstaddr = *(struct sockaddr_in *) &ifr->ifr_dstaddr;
241         if (ifp->if_ioctl && (error = (*ifp->if_ioctl)
242                                  (ifp, SIOCSIFDSTADDR, (caddr_t) ia))) {
243             ia->ia_dstaddr = oldaddr;
244             return (error);
245         }
246         if (ia->ia_flags & IFA_ROUTE) {
247             ia->ia_ifa.ifa_dstaddr = (struct sockaddr *) &oldaddr;
248             rtinit(&(ia->ia_ifa), (int) RTM_DELETE, RTF_HOST);
249             ia->ia_ifa.ifa_dstaddr =
250                 (struct sockaddr *) &ia->ia_dstaddr;
251             rtinit(&(ia->ia_ifa), (int) RTM_ADD, RTF_HOST | RTF_UP);
252         }
253     break;

```

图6-21 函数`in_control`：目的地址指派

236-245 只有点对点网络才有目的地址，因此对于其他网络，`in_control`返回`EINVAL`。将当前目的地址保存在`oldaddr`后，代码设置新地址，并通过函数`if_ioctl`通知硬件。如果发生差错，则恢复原地址。

246-253 如果地址原来有一个关联的路由，首先调用`rtinit`删除这个路由，并再次调用`rtinit`为新地址安装一个新路由。

6.6.8 获取接口信息

图6-22显示了命令`SIOCSIFBRDADDR`的前提条件处理，它同将接口信息返回给调用进程的`ioctl`命令一样。

```

207     case SIOCSIFBRDADDR:
208         if ((so->so_state & SS_PRIV) == 0)
209             return (EPERM);
210         /* FALLTHROUGH */
211
211     case SIOCGIFADDR:
212     case SIOCGIFNETMASK:
213     case SIOCGIFDSTADDR:
214     case SIOCGIFBRDADDR:
215         if (ia == (struct in_ifaddr *) 0)
216             return (EADDRNOTAVAIL);
217         break;

```

图6-22 函数`in_control`：前提条件处理

207-217 广播地址只能通过一个超级用户进程创建的插口来设置。命令 SIOCSIFBRDADDR 和4个SIOCGxxx命令仅当已经为此接口定义了一个地址时才起作用，在这种情况下，ia不会为空(ia被in_control设置，图6-13)。如果ia为空，返回EADDRNOTAVAIL。

这5个命令(4个get命令和一个set命令)的处理显示在图6-23中。

```

220    case SIOCGIFADDR:
221        *((struct sockaddr_in *) &ifr->ifr_addr) = ia->ia_addr;
222        break;
223
224    case SIOCGIFBRDADDR:
225        if ((ifp->if_flags & IFF_BROADCAST) == 0)
226            return (EINVAL);
227        *((struct sockaddr_in *) &ifr->ifr_dstaddr) = ia->ia_broadaddr;
228        break;
229
230    case SIOCGIFDSTADDR:
231        if ((ifp->if_flags & IFF_POINTOPOINT) == 0)
232            return (EINVAL);
233        *((struct sockaddr_in *) &ifr->ifr_dstaddr) = ia->ia_dstaddr;
234        break;
235
236    case SIOCGIFNETMASK:
237        *((struct sockaddr_in *) &ifr->ifr_addr) = ia->ia_sockmask;
238        break;
239
240    /* processing for SIOCSIFDSTADDR command (Figure 6.21) */
241
242
243
244
245    case SIOCSIFBRDADDR:
246        if ((ifp->if_flags & IFF_BROADCAST) == 0)
247            return (EINVAL);
248        ia->ia_broadaddr = *((struct sockaddr_in *) &ifr->ifr_broadaddr);
249        break;

```

*in.c**in.c*

图6-23 函数in_control : 处理

220-235 将单播地址、广播地址、目的地址或者网络掩码复制到 ifreq结构。只有网络接口支持广播，广播地址才有效；并且只有点对点接口，目的地址才有效。

254-258 仅当接口支持广播，才从结构 ifreq中复制广播地址。

6.6.9 每个接口多个IP地址

SIOCGxxx和SIOCSxxx命令只操作与一个接口关联的第一个IP地址——在in_control开头的循环找到的第一个地址（图6-25）。为支持每个接口的多个IP地址，必须用SIOCAIFADDR命令指派和配置其他的地址。实际上，SIOCAIFADDR能完成所有SIOCGxxx和SIOCSxxx命令能完成的操作。程序ifconfig使用SIOCAIFADDR来配置一个接口的所有地址信息。

如前所述，每个接口有多个地址便于在主机或网络改号时过渡。一个容错软件系统可能使用这个特性来准许一个备份系统充当一个故障系统的IP地址。

Net/3的ifconfig程序的-alias选项将存放在一个in_aliasreq中的其他地址的相关信息传递给内核，如图6-24所示。

```

59 struct in_aliasreq {
60     char ifra_name[IFNAMSIZ]; /* interface name, e.g. "en0" */
61     struct sockaddr_in ifra_addr;
62     struct sockaddr_in ifra_broadaddr;
63 #define ifra_dstaddr ifra_broadaddr
64     struct sockaddr_in ifra_mask;
65 };

```

in_var.h

图6-24 结构in_aliasreq

59-65 注意，不像结构 `ifreq`，在结构 `in_aliasreq` 中没有定义联合。在一个单独的 `ioctl` 调用中可以为 `SIOCAIFADDR` 指定地址、广播地址和掩码。

`SIOCAIFADDR` 增加一个新地址或修改一个已存在地址的相关信息。`SIOCDIFADDR` 删除匹配的 IP 地址的 `in_ifaddr` 结构。图 6-25 显示命令 `SIOCAIFADDR` 和 `SIOCDIFADDR` 的前提条件处理，它假设在 `in_control`（图 6-13）开头的循环已经将 `ia` 设置为指向与 `ifra_name`（如果存在）指定的接口关联的第一个 IP 地址。

```

154     case SIOCAIFADDR:
155     case SIOCDIFADDR:
156         if (ifra->ifra_addr.sin_family == AF_INET)
157             for (oia = ia; ia; ia = ia->ia_next) {
158                 if (ia->ia_ifp == ifp &&
159                     ia->ia_addr.sin_addr.s_addr ==
160                     ifra->ifra_addr.sin_addr.s_addr)
161                     break;
162             }
163         if (cmd == SIOCDIFADDR && ia == 0)
164             return (EADDRNOTAVAIL);
165 /* FALLTHROUGH to Figure 6.14 */

```

in.c

图6-25 函数in_control：添加和删除地址

154-165 因为 `SIOCDIFADDR` 代码只查看 `*ifra` 的前两个成员，图 6-25 所示的代码用于处理 `SIOCAIFADDR`（当 `ifra` 指向一个 `in_aliasreq` 结构时）和 `SIOCDIFADDR`（当 `ifra` 指向一个 `ifreq` 结构时）。结构 `in_aliasreq` 和 `ifreq` 的前两个成员是一样的。

对于这两个命令，`in_control` 开头的循环启动 `for` 循环不断地查找与 `ifra->ifra_addr` 指定的 IP 地址相同的 `in_ifaddr` 结构。对于删除命令，如果地址没有找到，则返回 `EADDRNOTAVAIL`。

在这个处理删除命令的循环和检验后，控制落到我们在图 6-14 中讨论的代码之外。对于添加命令，图 6-14 的代码若找不到一个与 `in_aliasreq` 结构中地址匹配的地址，就分配一个新 `in_ifaddr` 结构。

6.6.10 附加IP地址：`SIOCAIFADDR`

这时 `ia` 指向一个新的 `in_ifaddr` 结构或一个包含与请求地址匹配的 IP 地址的旧 `in_ifaddr` 结构。`SIOCAIFADDR` 的处理显示在图 6-26 中。

266-277 因为 `SIOCAIFADDR` 能创建一个新地址或修改一个已存在地址的相关信息，标志 `maskIsNew` 和 `hostIsNew` 跟踪变化的情况。这样，在这个函数结束时，如果必要，能更新路由。

```

266     case SIOCAIFADDR:
267         maskIsNew = 0;
268         hostIsNew = 1;
269         error = 0;
270         if (ia->ia_addr.sin_family == AF_INET) {
271             if (ifra->ifra_addr.sin_len == 0) {
272                 ifra->ifra_addr = ia->ia_addr;
273                 hostIsNew = 0;
274             } else if (ifra->ifra_addr.sin_addr.s_addr ==
275                         ia->ia_addr.sin_addr.s_addr)
276                 hostIsNew = 0;
277         }
278         if (ifra->ifra_mask.sin_len) {
279             in_ifscrub(ifp, ia);
280             ia->ia_sockmask = ifra->ifra_mask;
281             ia->ia_subnetmask =
282                 ntohl(ia->ia_sockmask.sin_addr.s_addr);
283             maskIsNew = 1;
284         }
285         if ((ifp->if_flags & IFF_POINTOPOINT) &&
286             (ifra->ifra_dstaddr.sin_family == AF_INET)) {
287             in_ifscrub(ifp, ia);
288             ia->ia_dstaddr = ifra->ifra_dstaddr;
289             maskIsNew = 1; /* We lie; but the effect's the same */
290         }
291         if (ifra->ifra_addr.sin_family == AF_INET &&
292             (hostIsNew || maskIsNew))
293             error = in_ifinit(ifp, ia, &ifra->ifra_addr, 0);
294         if ((ifp->if_flags & IFF_BROADCAST) &&
295             (ifra->ifra_broadaddr.sin_family == AF_INET))
296             ia->ia_broadaddr = ifra->ifra_broadaddr;
297         return (error);

```

in.c

图6-26 函数in_control : SIOCAIFADDR 处理

代码在默认方式下取一个新的IP地址指派给接口(hostIsNew以1开始)。如果新地址的长度为0，in_control将当前地址复制到请求中，并将hostIsNew修改为0。如果长度不是0，并且新地址与老地址匹配，则这个请求不包含一个新地址，并且hostIsNew被设置为0。

278-284 如果在这个请求中指定一个网络掩码，则任何使用此当前地址的路由被忽略，并且in_control安装此新掩码。

285-290 如果接口是一个点对点接口，并且此请求包括一个新目的地址，则in_scrub忽略任何使用此地址的路由，新目的地址被安装，并且maskIsNew被设置为1，以强制调用in_ifinit来重配置接口。

291-297 如果配置了一个新地址或指派了一个新掩码，则in_ifinit作适当的修改来支持新的配置(图6-17)。注意，in_ifinit的最后一个参数为0。这表示已注意到这一点，不必刷新所有路由。最后，如果接口支持广播，则从in_aliasreq结构复制广播地址。

6.6.11 删除IP地址 : SIOCDIFADDR

命令SIOCDIFADDR从一个接口删除IP地址，如图6-27所示。记住，ia指向要被删除的in_ifaddr结构(即，与请求匹配的)。

```

298     case SIOCDIFADDR:
299         in_ifscrub(ifp, ia);
300         if ((ifa = ifp->if_addrlist) == (struct ifaddr *) ia)
301             /* ia is the first address in the list */
302             ifp->if_addrlist = ifa->ifa_next;
303         else {
304             /* ia is *not* the first address in the list */
305             while (ifa->ifa_next &&
306                   (ifa->ifa_next != (struct ifaddr *) ia))
307                 ifa = ifa->ifa_next;
308             if (ifa->ifa_next)
309                 ifa->ifa_next = ((struct ifaddr *) ia)->ifa_next;
310             else
311                 printf("Couldn't unlink inifaddr from ifp\n");
312         }
313         oia = ia;
314         if (oia == (ia = in_ifaddr))
315             in_ifaddr = ia->ia_next;
316         else {
317             while (ia->ia_next && (ia->ia_next != oia))
318                 ia = ia->ia_next;
319             if (ia->ia_next)
320                 ia->ia_next = oia->ia_next;
321             else
322                 printf("Didn't unlink inifaddr from list\n");
323         }
324         IFAFREE(&oia->ia_ifa));
325     break;

```

*in.c*图6-27 *in_control* 函数：删除地址

298-323 前提条件处理代码将 ia 指向要删除的地址。in_ifscrub 删除任何与此地址关联的路由。第一个 if 删 除接口地址列表的结构。第二个 if 删 除来自 Internet 地址列表 (in_ifaddr) 的结构。

324-325 IFAFREE 只在引用计数降到 0 时才释放此结构。

其他引用可能来自路由表中的各项。

6.7 接口 *ioctl* 处理

我们现在查看当一个地址被分配给接口时的专用 *ioctl* 处理，对于我们的每个例子接口，这个处理分别在函数 leioctl、slioctl 和 loioctl 中。

in_ifinit 通过图 6-16 中的 SIOCSIFADDR 代码和图 6-26 中的 SIOCAIFADDR 代码调用。in_ifinit 总是通过接口的 if_ioctl 函数发送 SIOCSIFADDR 命令(图 6-17)。

6.7.1 leioctl 函数

图 4-31 显示了 LANCE 驱动程序的 SIOCSIFFLAGS 命令的处理。图 6-28 显示了 SIOCSIFADDR 命令的处理。

614-637 在处理命令前，data 转换成一个 ifaddr 结构指针，并且 ifp->if_unit 为此请求选择相应的 le_softc 结构。

leinit 将接口标志为启动并初始化硬件。对于 Internet 地址，IP 地址保存在 arpcom 结构

中，并且为此地址发送一个免费 ARP。免费 ARP 在 21.5 节和卷 1 的 4.7 节中讨论。

未识别命令

627-677 对于未识别命令，返回 EINVAL。

```
if_le.c
```

```

614 leioctl(ifp, cmd, data)
615 struct ifnet *ifp;
616 int cmd;
617 caddr_t data;
618 {
619     struct ifaddr *ifa = (struct ifaddr *) data;
620     struct le_softc *le = &le_softc[ifp->if_unit];
621     struct lereg1 *ler1 = le->sc_r1;
622     int s = splimp(), error = 0;

623     switch (cmd) {
624         case SIOCSIFADDR:
625             ifp->if_flags |= IFF_UP;
626             switch (ifa->ifa_addr->sa_family) {
627                 case AF_INET:
628                     leinit(ifp->if_unit); /* before arpwhohas */
629                     ((struct arpcom *) ifp)->ac_ipaddr =
630                         IA_SIN(ifa)->sin_addr;
631                     arpwhohas((struct arpcom *) ifp, &IA_SIN(ifa)->sin_addr);
632                     break;
633                 default:
634                     leinit(ifp->if_unit);
635                     break;
636             }
637             break;

638             /* SIOCSIFFLAGS command (Figure 4.31) */
639             /* SIOCADDMULTI and SIOCDELMULTI commands (Figure 12.31) */

640         default:
641             error = EINVAL;
642     }
643     splx(s);
644     return (error);
645 }
646 }
```

```
if_le.c
```

图 6-28 函数 leioctl

6.7.2 slioctl 函数

函数 slioctl(图 6-29) 为 SLIP 设备驱动器处理命令 SIOCSIFADDR 和 SIOCSIFDSTADDR。

```
if_sl.c
```

```

653 int
654 slioctl(ifp, cmd, data)
655 struct ifnet *ifp;
656 int cmd;
657 caddr_t data;
658 {
659     struct ifaddr *ifa = (struct ifaddr *) data;
660     struct ifreq *ifr;
661     int s = splimp(), error = 0;

662     switch (cmd) {
```

图 6-29 函数 slioctl : 命令 SIOCSIFADDR 和 SIOCSIFDSTADDR

```

663     case SIOCSIFADDR:
664         if (ifa->ifp->sa_family == AF_INET)
665             ifp->if_flags |= IFF_UP;
666         else
667             error = EAFNOSUPPORT;
668         break;
669
670     case SIOCSIFDSTADDR:
671         if (ifa->ifp->sa_family != AF_INET)
672             error = EAFNOSUPPORT;
673         break;

```

/* SIOCADDMULTI and SIOCDELMULTI commands (Figure 12.29) */

```

688     default:
689         error = EINVAL;
690     }
691     splx(s);
692     return (error);
693 }

```

if_sl.c

图6-29 (续)

663-672 对于这两个命令，如果地址不是一个 IP地址，则返回 EAFNOSUPPORT。
SIOCSIFADDR命令设置 IFF_UP。

未识别命令

688-693 对于未识别命令，返回 EINVAL。

6.7.3 loioctl函数

函数loioctl和它的SIOCSIFADDR命令的实现显示在图6-30中。

```

135 int
136 loioctl(ifp, cmd, data)
137 struct ifnet *ifp;
138 int      cmd;
139 caddr_t data;
140 {
141     struct ifaddr *ifa;
142     struct ifreq *ifr;
143     int      error = 0;
144
145     switch (cmd) {
146         case SIOCSIFADDR:
147             ifp->if_flags |= IFF_UP;
148             ifa = (struct ifaddr *) data;
149             /*
150             * Everything else is done at a higher level.
151             */
152             break;

```

/* SIOCADDMULTI and SIOCDELMULTI commands (Figure 12.30) */

图6-30 函数loioctl：命令 SIOCSIFADDR

```

167     default:
168         error = EINVAL;
169     }
170     return (error);
171 }

```

if_loop.c

图6-30 (续)

135-151 对于Internet地址，`lo ioctl`设置IFF_UP，并立即返回。

未识别命令

167-171 对于未识别命令，返回EINVAL。

注意，对于所有这三个例子驱动程序，指派一个地址会导致接口被标记为启用 (IFF_UP)。

6.8 Internet实用函数

图6-31列出了几个操作Internet地址或依赖于图6-5中ifnet结构的函数，它们通常用于发现不能单从32 bit IP地址中获得的子网信息。这些函数的实现主要包括数据结构的转换和操作位掩码。读者在netinet/in.c中可以找到这些函数。

函数	说明
<code>in_netof</code>	返回 <code>in</code> 中的网络和子网部分。主机比特被设置为0。对于D类地址，返回D类首标比特和用于多播组的0比特 <code>u_long in_netof(struct in_addr in);</code>
<code>in_canforward</code>	如果地址为 <code>in</code> 的IP分组有资格转发，则返回真。D类和E类地址、环回网络地址和有一个为0网络号的地址不能转发 <code>int in_canforward(struct in_addr in);</code>
<code>in_localaddr</code>	如果主机 <code>in</code> 被定位在一个直接连接的网络，则返回真。如果全局变量 <code>subnetsarelocal</code> 非0，则所有直接连接的网络的子网也被认为是本地的 <code>int in_localaddr(struct in_addr in);</code>
<code>in_broadcast</code>	如果 <code>in</code> 是一个由 <code>ifp</code> 指向的接口所关联的广播地址，则返回真 <code>int in_broadcast(struct in_addr in, struct ifnet *ifp);</code>

图6-31 Internet地址函数

Net/2在`in_canforward`中有一个错误：它允许转发环回地址。因为大多数Net/2系统被配置为只承认一个环回地址，如127.0.0.1，Net/2系统常沿着默认路由在环回网络中转发其他地址(例如127.0.0.2)。

一个到127.0.0.2的telnet可能不是你所希望的！(习题6.6)

6.9 ifnet实用函数

几个查找数据结构的函数显示在图6-5中。列于图6-32的函数接受任何协议族类的地址，因为它们的参数是指向一个`sockaddr`结构的指针，这个结构中包含有地址族类。与图6-31中的函数比较，在那里的每个函数将32 bit的IP地址作为一个参数。这些函数定义在文件net/if.c中。

函 数	说 明
ifa_ifwithaddr	在ifnet列表中查找有一个单播或广播地址 addr的接口。返回一个指向这个匹配的ifaddr结构的指针；或者若没有找到，则返回一个空指针 <code>struct ifaddr *ifa_ifwithaddr(struct sockaddr *addr);</code>
ifa_ifwithdstaddr	在ifnet列表中查找目的地址为addr的接口。返回一个指向这个匹配的ifaddr结构的指针；或者若没有找到，则返回一个空指针 <code>struct ifaddr *ifa_ifwithdstaddr(struct sockaddr *addr);</code>
ifa_ifwithnet	在ifnet列表中查找与addr同一网络的地址。返回匹配的ifaddr结构的指针；或者若没有找到，则返回一个空指针 <code>struct ifaddr *ifa_ifwithnet(struct sockaddr *addr);</code>
ifa_ifwithaf	在ifnet列表中查找与add具有相同地址族类的第一个地址。返回匹配的ifaddr结构的指针；或者若没有找到，则返回一个空指针 <code>struct ifaddr *ifa_ifwithaf(struct sockaddr *addr);</code>
ifaof_ifpforaddr	在ifp列表中查找与addr匹配的地址。用于精确匹配的引用次序为：一个点对点链路上的目的地址、一个同一网络上的地址和一个在同一地址族类的地址，则返回匹配的ifaddr结构的指针；或者若没有找到，则返回一个空指针 <code>struct ifaddr *ifaof_ifpforaddr(struct sockaddr *addr, struct ifnet *ifp);</code>
ifa_ifwithroute	返回目的地址(dst)和网关地址(gateway)指定的相应的本地接口的ifaddr结构的指针 <code>struct ifaddr *ifa_ifwithroute(int flags, struct sockaddr *dst, struct sockaddr *gateway);</code>
ifunit	返回与name关联的ifnet结构的指针 <code>struct ifnet *ifunit(char *name);</code>

图6-32 ifnet 实用函数

6.10 小结

在本章中，我们概述了IP编址机制，并且说明了IP专用的接口地址结构和协议地址结构：结构in_ifaddr和sockaddr_in。

我们讨论了如何通过程序ifconfig和ioctl接口命令来配置接口的IP专用信息。

最后，我们总结了几个操作IP地址和查找接口数据结构的实用函数。

习题

- 6.1 你认为为什么在结构sockaddr_in中的sin_addr最初定义为一个结构？
- 6.2 ifunit("s10")返回的指针指向图6-5中的哪个结构？
- 6.3 当IP地址已经包含在接口的地址列表中的一个ifaddr结构中时，为什么还要在ac_ipaddr中备份？
- 6.4 你认为为什么IP接口地址要通过一个UDP插口而不是一个原始的IP插口来访问？
- 6.5 为什么in_socktrim要修改sin_len来匹配掩码的长度，而不使用一个sockaddr_in结构的标准长度？
- 6.6 当一个telnet 127.0.0.0命令中的连接请求部分被一个Net/2系统错误地转发，并且最后被认可，同时还被默认路由上的一个系统所接收时，会发生什么情况？

第7章 域和协议

7.1 引言

在本章中，我们讨论支持同时操作多个网络协议的 Net/3数据结构。用 Internet协议来说明在系统初始化时这些数据结构的构造和初始化。本章为我们讨论 IP协议处理层提供必要的背景资料，IP协议处理层在第8章讨论。

Net/3组把协议关联到一个域中，并且用一个协议族常量来标识每个域。Net/3还通过所使用的编址方法将协议分组。回忆图 3-19，地址族也有标识常量。当前，在一个域中的每个协议使用同类地址，并且每种地址只被一个域使用。作为结果，一个域能通过它的协议族或地址族常量唯一标识。图 7-1列出了我们讨论的协议和常量。

协议族	地址族	协议
PF_INET	AF_INET	Internet
PF_OSI, PF_ISO	AF_OSI, AF_ISO	OSI
PF_LOCAL, PF_UNIX	AF_LOCAL, AF_UNIX	本地IPC(Unix)
PF_ROUTE	AF_ROUTE	路由表
n/a	AF_LINK	链路层(例如以太网)

图7-1 公共的协议和地址族常量

PF_LOCAL和AF_LOCAL是支持同一主机上进程间通信的协议的主要标识，它们是POSIX.12标准的一部分。在 Net/3以前，用PF_UNIX和AF_UNIX标识这些协议。在Net/3中保留UNIX常量，用于向后兼容，并且要在本书中讨论。

PF_UNIX域支持在一个单独的 Unix主机上的进程间通信。细节见 [Stevens 1990]。PF_ROUTE域支持在一个进程和内核中路由软件间的通信(第18章)。我们偶尔引用PF_OSI协议，它作为 Net/3特性仅支持 OSI协议，但我们不讨论它们的细节。大多数讨论是关于PF_INET协议的。

7.2 代码介绍

本章涉及两个头文件和两个C文件。图7-2描述了这4个文件。

文件	说明
netinet/domain.h netinet/protosw.h	domain结构定义 protosw结构定义
netinet/in_proto.c kern/uipc_domain.c	IP domain和protosw结构 初始化和查找函数

图7-2 在本章中讨论的文件

7.2.1 全局变量

图7-3描述了几个重要的全局数据结构和系统参数，它们在本章中讨论，并经常在Net/3中引用。

变 量	数 �据 类 型	说 明
domain	struct domain *	链接的域列表
inetdomain	struct domain	Internet协议的domain结构
inetsw	struct protosw[]	Internet协议的protosw结构数组
max_linkhdr	int	见图7-17
max_protohdr	int	见图7-17
max_hdr	int	见图7-17
max_datalen	int	见图7-17

图7-3 在本章中介绍的全局变量

7.2.2 统计量

除了图7-4显示的由函数ip_init分配和初始化的统计量表，本章讨论的代码没有收集其他统计量。通过一个内核调试工具是查看这个表的唯一方法。

变 量	数 据 类 型	说 明
ip_ifmatrix	int[][]	二维数组，用来统计在任意两个接口间传送的分组数

图7-4 在本章中收集的统计量

7.3 domain结构

一个协议域由一个图7-5所示的domain结构来表示。

```
42 struct domain {
43     int      dom_family;           /* AF_XXX */
44     char    *dom_name;
45     void    (*dom_init)();        /* initialize domain data structures */
46             (void);
47     int      (*dom_externalize)();/* externalize access rights */
48             (struct mbuf *);
49     int      (*dom_dispose)();    /* dispose of internalized rights */
50             (struct mbuf *);
51     struct protosw *dom_protosw, *dom_protoswNPROTOSW;
52     struct domain *dom_next;
53     int      (*dom_rtattach)();   /* initialize routing table */
54             (void **, int);
55     int      dom_rtoffset;        /* an arg to rtattach, in bits */
56     int      dom_maxrtkey;        /* for routing layer */
57 };

```

domain.h

```
58 };

```

domain.h

图7-5 结构domain 的定义

42-57 dom_family是一个地址族常量(例如AF_INET)，它指示在此域中协议使用的编址方式。dom_name是此域的一个文本名称(例如“internet”)。

除了程序 `fstat(1)` 在它格式化插口信息时使用 `dom_name` 外，成员 `dom_name` 不被 Net/3 内核的任何部分访问。

`dom_init` 指向初始化此域的函数。`dom_externalize` 和 `dom_dispose` 指向那些管理通过此域内通信路径发送的访问权限的函数。 Unix 域实现这个特性在进程间传递文件描述符。 Internet 域不实现访问权限。

`dom_protosw` 和 `dom_protoswNPROTOSW` 指向一个 `protosw` 结构的数组的起始和结束。`dom_next` 指向在一个内核支持的域链表中的下一个域。 包含所有域的链表通过全局指针 `domains` 来访问。

接下来的三个成员，`dom_rtattach`、`dom_rtoffset` 和 `dom_maxrtkey` 保存此域的路由信息。 它们在第 18 章讨论。

图 7-6 显示了一个 `domains` 列表的例子。

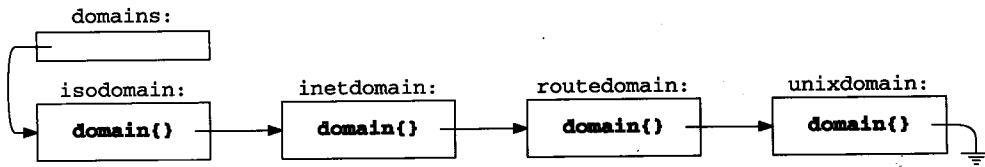


图 7-6 domains 列表

7.4 protosw 结构

在编译期间，Net/3 为内核中的每个协议分配一个 `protosw` 结构并初始化，同时将在一个域中的所有协议的这个结构组织到一个数组中。每个 `domain` 结构引用相应的 `protosw` 结构数组。一个内核可以通过提供多个 `protosw` 项为同一协议提供多个接口。 `Protosw` 结构的定义见图 7-7。

```

57 struct protosw {
58     short    pr_type;           /* see (Figure 7.8) */
59     struct domain *pr_domain;  /* domain protocol a member of */
60     short    pr_protocol;      /* protocol number */
61     short    pr_flags;         /* see Figure 7.9 */
62 /* protocol-protocol hooks */
63     void    (*pr_input) ();    /* input to protocol (from below) */
64     int     (*pr_output) ();   /* output to protocol (from above) */
65     void    (*pr_ctlinput) (); /* control input (from below) */
66     int     (*pr_ctloutput) ();/* control output (from above) */
67 /* user-protocol hook */
68     int     (*pr_usrreq) ();   /* user request from process */
69 /* utility hooks */
70     void    (*pr_init) ();     /* initialization hook */
71     void    (*pr_fasttimo) (); /* fast timeout (200ms) */
72     void    (*pr_slowtimo) (); /* slow timeout (500ms) */
73     void    (*pr_drain) ();    /* flush any excess space possible */
74     int     (*pr_sysctl) ();   /* sysctl for protocol */
75 };

```

protosw.h

图 7-7 protosw 结构的定义

57-61 此结构中的前 4 个成员用来标识和表征协议。`pr_type` 指示协议的通信语义。 图 7-8

列出了pr_type可能的值和对应的Internet协议。

pr_type	协议语义	Internet协议
<i>SOCK_STREAM</i>	可靠的双向字节流服务	TCP
<i>SOCK_DGRAM</i>	最好的运输层数据报服务	UDP
<i>SOCK_RAW</i>	最好的网络层数据报服务	ICMP, IGMP, 原始IP
<i>SOCK_RDM</i>	可靠的数据报服务(未实现)	n/a
<i>SOCK_SEQPACKET</i>	可靠的双向记录流服务	n/a

图7-8 pr_type 指明协议的语义

pr_domain指向相关的domain结构，pr_protocol为域中协议的编号，pr_flags标识协议的附加特征。图7-9列出了pr_flags的可能值。

pr_flags	说明
<i>PR_ATOMIC</i>	每个进程请求映射为一个单个的协议请求
<i>PR_ADDR</i>	协议在每个数据报中都传递地址
<i>PR_CONNREQUIRED</i>	协议是面向连接的
<i>PR_WANTRCVD</i>	当一个进程接收到数据时通知协议
<i>PR_RIGHTS</i>	协议支持访问权限

图7-9 pr_flags 的值

如果一个协议支持 PR_ADDR，必须也支持 PR_ATOMIC。PR_ADDR和PR_CONNREQUIRED是互斥的。

当设置了PR_WANTRCVD，并当插口层将插口接收缓存中的数据传递给一个进程时(即当在接收缓存中有更多空间可用时)，它通知协议层。

PR_RIGHTS指示访问权限控制报文能通过连接来传递。访问权限要求内核中的其他支持来确保在接收进程没有销毁报文时能完成正确的清除工作。仅 Unix域支持访问权限，在那里它们用来在进程间传递描述符。

图7-10所示的是协议类型、协议标志和协议语义间的关系。

pr_type	PR_			是否有记录边界	可靠否	举例	
	ADDR	ATOMIC	CONNREQUIRED			Internet	其他
<i>SOCK_STREAM</i>			•	否	•	TCP	SPP
<i>SOCK_SEQPACKET</i>		•	• •	显式 隐式	• •		TP4 SPP
<i>SOCK_RDM</i>		•	•	隐式	见正文		RDP
<i>SOCK_DGRAM</i>	•	•		隐式		UDP	
<i>SOCK_RAW</i>	•	•		隐式		ICMP	

图7-10 协议特征和举例

图7-10不包括标志PR_WANTRCVD和PR_RIGHTS。对于可靠的面向连接的协议，PR_WANTRCVD总是被设置。

为了理解Net/3中一个proto_sw项的通信语义，我们必须要一起考虑 PRxxx标志和pr_type。在图7-10中，我们用两列(“是否有记录边界”和“可靠否”)来描述由pr_type

隐式指示的语义。图 7-10 显示了可靠协议的三种类型：

- 面向连接的字节流协议，如 TCP 和 SPP(源于 XNS 协议族)。这些协议用 SOCK_STREAM 标识。
- 有记录边界的面向连接的流协议用 SOCK_SEQPACKET 标识。在这种协议类型中，PR_ATOMIC 指示记录是否由每个输出请求隐式地指定，或者显式地通过在输出中设置标志 MSG_EOR 来指定。

SPP 同时支持语义 SOCK_STREAM 和 SOCK_SEQPACKET。

- 第三种可靠协议提供一个有隐式记录边界的面向连接服务，它由 SOCK_RDM 标识。RDP 不保证按照记录发送的顺序接收记录。RDP 在 [Partridge 1987] 中讨论并在 RFC 115 [Partridge and Hinden 1990] 中被描述。

两种不可靠协议显示在图 7-10 中：

- 一个运输层数据报协议，如 UDP，它包括复用和检验和，由 SOCK_DGRAM 指定。
- 一个网络层数据报协议，如 ICMP，它由 SOCK_RAW 指定。在 Net/3 中，只有超级用户进程才能创建一个 SOCK_RAW 插口(图15-8)。

62-68 接着的 5 个成员是函数指针，用来提供从其他协议对此协议的访问。pr_input 处理从一个低层协议输入的数据，pr_output 处理从一个高层协议输出的数据，pr_ctlinput 处理来自下层的控制信息，而 pr_ctoutput 处理来自上层的控制信息。pr_usrreq 处理来自进程的所有通信请求。如图 7-11 所示。

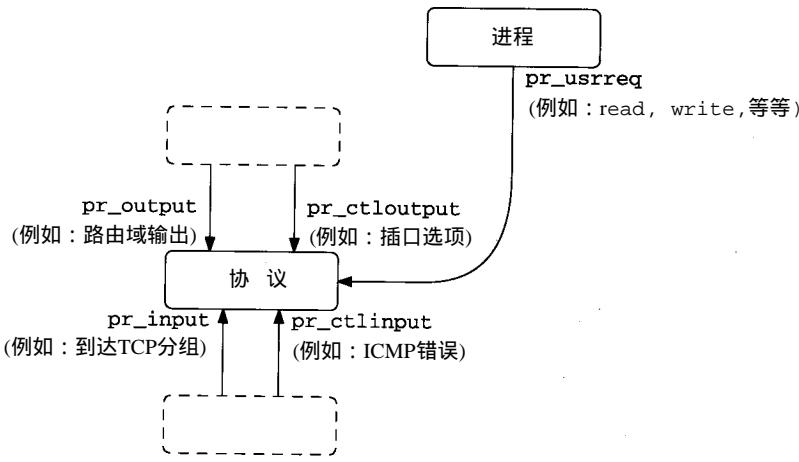


图 7-11 一个协议的 5 个主要入口点

69-75 剩下的 5 个成员是协议的实用函数。pr_init 处理初始化。pr_fasttimo 和 pr_slowtimo 分别每 200 ms 和 500 ms 被调用来执行周期性的协议函数，如更新重传定时器。pr_drain 在内存缺乏时被 m_reclaim 调用(图 2-13)。它请求协议释放尽可能多的内存。pr_sysctl 为 sysctl(8) 命令提供一个接口，一种修改系统范围的参数的方式，如允许转发分组或 UDP 检验和计算。

7.5 IP 的 domain 和 protosw 结构

声明所有协议的结构 domain 和 protosw，并进行静态初始化。对于 Internet 协议，inetsw 数组包含 protosw 结构。图 7-12 总结了在数组 inetsw 中的协议信息。图 7-13 显示了

Internet协议的数组定义和domain结构的定义。

inetsw[]	pr_protocol	pr_type	说 明	缩 写
0	0	0	Internet协议	IP
1	IPPROTO_UDP	SOCK_DGRAM	用户数据报协议	UDP
2	IPPROTO_TCP	SOCK_STREAM	传输控制协议	TCP
3	IPPROTO_RAW	SOCK_RAW	Internet协议(原始)	IP(原始)
4	IPPROTO_ICMP	SOCK_RAW	Internet控制报文协议	ICMP
5	IPPROTO_IGMP	SOCK_RAW	Internet组管理协议	IGMP
6	0	SOCK_RAW	Internet协议(原始、默认)	IP(原始)

图7-12 Internet域协议

```

39 struct protosw inetsw[] =                                in_proto.c
40 {
41     {0, &inetdomain, 0, 0,
42      0, ip_output, 0, 0,
43      0,
44      ip_init, 0, ip_slowtimo, ip_drain, ip_sysctl
45    },
46    {SOCK_DGRAM, &inetdomain, IPPROTO_UDP, PR_ATOMIC | PR_ADDR,
47      udp_input, 0, udp_ctlinput, ip_ctloutput,
48      udp_usrreq,
49      udp_init, 0, 0, 0, udp_sysctl
50    },
51    {SOCK_STREAM, &inetdomain, IPPROTO_TCP, PR_CONNREQUIRED | PR_WANTRCVD,
52      tcp_input, 0, tcp_ctlinput, tcp_ctloutput,
53      tcp_usrreq,
54      tcp_init, tcp_fasttimo, tcp_slowtimo, tcp_drain,
55    },
56    {SOCK_RAW, &inetdomain, IPPROTO_RAW, PR_ATOMIC | PR_ADDR,
57      rip_input, rip_output, 0, rip_ctloutput,
58      rip_usrreq,
59      0, 0, 0, 0,
60    },
61    {SOCK_RAW, &inetdomain, IPPROTO_ICMP, PR_ATOMIC | PR_ADDR,
62      icmp_input, rip_output, 0, rip_ctloutput,
63      rip_usrreq,
64      0, 0, 0, 0, icmp_sysctl
65    },
66    {SOCK_RAW, &inetdomain, IPPROTO_IGMP, PR_ATOMIC | PR_ADDR,
67      igmp_input, rip_output, 0, rip_ctloutput,
68      rip_usrreq,
69      igmp_init, igmp_fasttimo, 0, 0,
70    },
71    /* raw wildcard */
72    {SOCK_RAW, &inetdomain, 0, PR_ATOMIC | PR_ADDR,
73      rip_input, rip_output, 0, rip_ctloutput,
74      rip_usrreq,
75      rip_init, 0, 0, 0,
76    },
77 };
78 struct domain inetdomain =
79 {AF_INET, "internet", 0, 0, 0,
80  inetsw, &inetsw[sizeof(inetsw) / sizeof(inetsw[0])], 0,
81  rn_inithead, 32, sizeof(struct sockaddr_in)};

```

in_proto.c

图7-13 Internet 的domain 和protosw 结构

39-77 在inetsw数组中的3个protosw结构提供对IP的访问。第一个：inetsw[0]，标识IP的管理函数并且只能由内核访问。其他两项：inetsw[3]和inetsw[6]，除了pr_protocol值以外它们是一样的，都提供到IP的一个原始接口。inetsw[3]处理接收到的任何未识别协议的分组。inetsw[6]是默认的原始协议，当没有找到其他可匹配的项时，这个结构由函数pffindproto返回(7.6节)。

在Net/3以前的版本中，通过inetsw[3]传输不带IP首部的分组，由进程负责构造正确的首部。由内核通过inetsw[6]传输带IP首部的分组。4.3BSD Reno引入了IP_HDRINCL插口选项(32.8节)，这样在inetsw[3]和inetsw[6]之间的区别就不再重要了。

原始接口允许一个进程发送和接收不涉及运输层的IP分组。原始接口的一个用途是实现内核外的传输协议。一旦这个协议稳定下来，就能移植到内核中改进它的性能和对其他进程的可用性。另一个用途就是作为诊断工具，如traceroute，它使用原始IP接口来直接访问IP。第32章讨论原始IP接口。图7-14总结了IP protosw结构。

protosw	inetsw[0]	inetsw[3和6]	说 明
pr_type	0	SOCK_RAW	IP提供原始分组服务
pr_domain	&inetdomain	&inetdomain	两协议都是Internet域的一部分
pr_protocol	0	IPPROTO_RAW或0	IPPROTO_RAW(255)和0都是预留的(RFC 1700)，并且不应在一个IP数据报中出现
pr_flags	0	PR_ATOMIC/PR_ADDR	插口层标志，IP不使用
pr_input	null	rip_input	从IP、ICMP或IGMP接收未识别的数据报
pr_output	ip_output	rip_output	分别准备并发送数据报到IP和硬件层
pr_ctlinput	null	null	IP不使用
pr_ctloutput	null	rip_ctloutput	响应来自进程的配置请求
pr_usrreq	null	rip_usrreq	响应来自进程的协议请求
pr_init	ip_init	null或rip_init	ip_init完成所有初始化
pr_fasttimo	null	null	IP不使用
pr_slowtimo	ip_slowtimo	null	用于IP重装算法的慢超时
pr_drain	ip_drain	null	如果可能，释放内存
pr_sysctl	ip_sysctl	null	修改系统范围参数

图7-14 IP inetsw 的条目

78-81 Internet协议的domain结构显示在图7-13的下部。Internet域使用AF_INET风格编址，文本名称为“internet”，没有初始化和控制报文函数，它的protosw结构在inetsw数组中。

Internet协议的路由初始化函数是rn_inithead。一个IP地址的最大有效位数为32，并且一个Internet选路键的大小为一个sockaddr_in结构的大小(16字节)。

inetsw[3]和inetsw[6]的唯一区别是它们的pr_protocol号和初始化函数rip_init，它仅在inetsw[6]中定义，因此只在初始化期间被调用一次。

domaininit函数

在系统初始化期间(图3-23),内核调用domaininit来链接结构domain和protosw。domaininit显示在图7-15中。

```

37 /* simplifies code in domaininit */
38 #define ADDDOMAIN(x) { \
39     extern struct domain __CONCAT(x, domain); \
40     __CONCAT(x, domain.dom_next) = domains; \
41     domains = &__CONCAT(x, domain); \
42 }
43 domaininit()
44 {
45     struct domain *dp;
46     struct protosw *pr;
47     /* The C compiler usually defines unix. We don't want to get
48     * confused with the unix argument to ADDDOMAIN
49     */
50 #undef unix
51     ADDDOMAIN(unix);
52     ADDDOMAIN(route);
53     ADDDOMAIN/inet;
54     ADDDOMAIN(iso);
55     for (dp = domains; dp; dp = dp->dom_next) {
56         if (dp->dom_init)
57             (*dp->dom_init) ();
58         for (pr = dp->dom_protosw; pr < dp->dom_protosw+NPROTOSW; pr++)
59             if (pr->pr_init)
60                 (*pr->pr_init) ();
61     }
62     if (max_linkhdr < 16)           /* XXX */
63         max_linkhdr = 16;
64     max_hdr = max_linkhdr + max_protohdr;
65     max_datalen = MHLEN - max_hdr;
66     timeout(pf_fasttimo, (void *) 0, 1);
67     timeout(pf_slowtimo, (void *) 0, 1);
68 }

```

uipc_domain.c

图7-15 函数domaininit

37-42 ADDDOMAIN宏声明并链接一个domain结构。例如,ADDDOMAIN(unix)展开为:

```

extern struct domain unixdomain;
unixdomain.dom_next = domains;
domains = &unixdomain;

```

宏__CONCAT定义在sys/defs.h中,并且连接两个符号名。例如__CONCAT(unix, domain)产生unixdomain。

43-54 domaininit通过调用ADDDOMAIN为每个支持的域构造域列表。

因为符号unix常常被C预处理器预定义,因此,Net/3在这里显式地取消它的定义,使ADDDOMAIN能正确工作。

图7-16显示了链接的结构 domain 和 protosw，它们配置在内核中来支持 Internet、Unix 和 OSI 协议族。

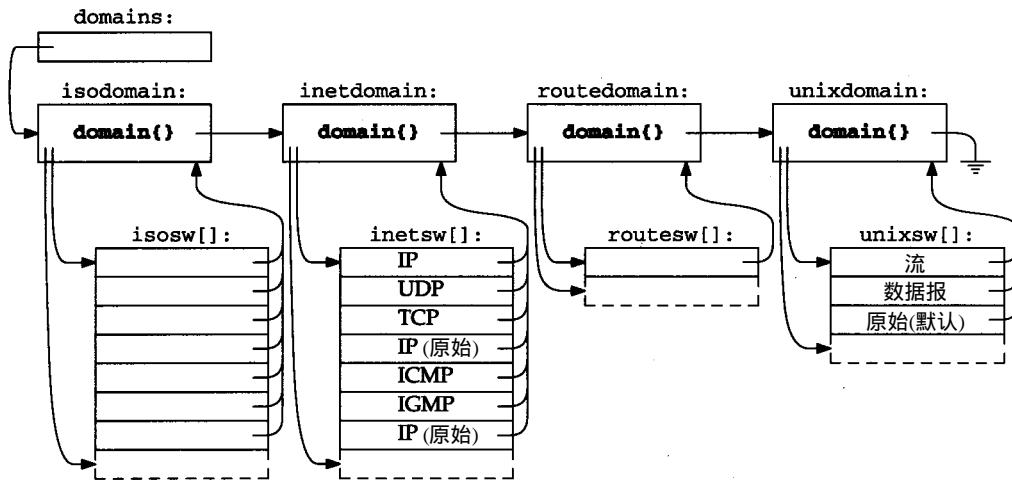


图7-16 初始化后的 domain 链表和 protosw 数组

55-61 两个嵌套的 for 循环查找内核中的每个域和协议，并且若定义了初始化函数 dom_init 和 pr_init，则调用它们。对于 Internet 协议，调用下面的函数（图7-13）：ip_init、udp_init、tcp_init、igmp_init 和 rip_init。

62-65 在 domaininit 中计算这些参数，用来控制 mbuf 中分组的格式，以避免对数据的额外复制。在协议初始化期间设置了 max_linkhdr 和 max_protohdr。这里，domaininit 将 max_linkhdr 强制设置为一个下限 16。16 字节用于给带有 4 字节边界的 14 字节以太网首部留出空间。图 7-17 和图 7-18 列出了这些参数和典型的取值。

变量	值	说 明
max_linkhdr	16	由链路层添加的最大字节数
max_protohdr	40	由网络和运输层添加的最大字节数
max_hdr	56	max_linkhdr + max_protohdr
max_datalen	44	在计算了链路和协议首部后的分组首部 mbuf 中的可用数据字节数

图7-17 用来减少协议数据复制的参数

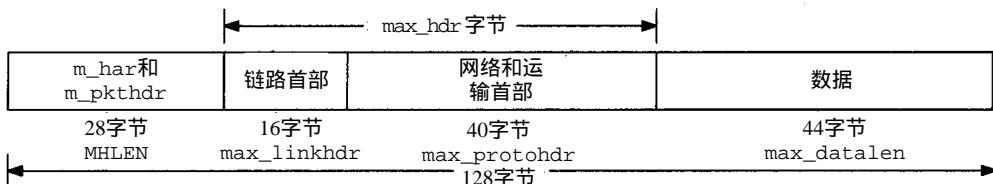


图7-18 mbuf 和相关的最大首部长度

max_protohdr 是一个软限制，估算预期的协议首部大小。在 Internet 域中，IP 和 TCP 首部长度通常为 20 字节，但都可达到 60 字节。长度超过 max_protohdr 的代价是花时间将数据向后移动，以留出比预期的协议首部更大的空间。

66-68 domaininit通过调用timeout启动pfslowtimo和pffasttimo。第3个参数指明何时内核应该调用这个函数，在这里是在1个时钟滴答内。两个函数都显示在图7-19中。

```

153 void
154 pfslowtimo(arg)
155 void *arg;
156 {
157     struct domain *dp;
158     struct protosw *pr;
159
160     for (dp = domains; dp; dp = dp->dom_next)
161         for (pr = dp->dom_protosw; pr < dp->dom_protoswNPROTOSW; pr++)
162             if (pr->pr_slowtimo)
163                 (*pr->pr_slowtimo) ();
164     timeout(pfslowtimo, (void *) 0, hz / 2);
165 }
166
167 void
168 pffasttimo(arg)
169 void *arg;
170 {
171     struct domain *dp;
172     struct protosw *pr;
173
174     for (dp = domains; dp; dp = dp->dom_next)
175         for (pr = dp->dom_protosw; pr < dp->dom_protoswNPROTOSW; pr++)
176             if (pr->pr_fasttimo)
177                 (*pr->pr_fasttimo) ();
178     timeout(pffasttimo, (void *) 0, hz / 5);
179 }
```

uipc_domain.c

图7-19 函数pfslowtimo 和pffasttimo

153-176 这两个相近的函数用两个for循环分别为每个协议调用函数pr_slowtimo和pr_fasttimo，前提是如果定义了这两个函数。这两个函数每500 ms和200 ms通过调用timeout调度自己一次，timeout在图3-43中讨论过。

7.6 pffindproto和pffindtype函数

如图7-20所示，函数pffindproto和pffindtype通过编号(例如IPPROTO_TCP)或类型(例如SOCK_STREAM)来查找一个协议。如我们在第15章要看到的，当进程创建一个插口时，这两个函数被调用来查找相应的protosw项。

69-84 pffindtype线性搜索domains，查找指定的族，然后在域内搜索第一个为此指定类型的协议。

85-107 pffindproto像pffindtype一样搜索domains，查找由调用者指定的族、类型和协议。如果pffindproto在指定的协议族中没有发现一个(protocol, type)匹配项，并且type为SOCK_RAW，而此域有一个默认的原始协议(pr_protocol等于0)，则pffindproto选择默认的原始协议而不是完全失败。例如，一个调用如下：

```
pffindproto(PF_INET, 27, SOCK_RAW);
```

它返回一个指向inetsw[6]的指针，默认的原始IP协议，因为Net/3不包括对协议27的支持。通过访问原始IP，一个进程可以使用内核来管理IP分组的发送和接收，从而自己实现协议27。

服务。

协议27预留给可靠的数据报协议(RFC 1151)。

两个函数都返回一个所选协议的 protosw 结构的指针；或者，如果没有找到匹配项，则返回一个空指针。

```

69 struct protosw *
70 pffindtype(family, type)
71 int      family, type;
72 {
73     struct domain *dp;
74     struct protosw *pr;
75     for (dp = domains; dp; dp = dp->dom_next)
76         if (dp->dom_family == family)
77             goto found;
78     return (0);
79 found:
80     for (pr = dp->dom_protosw; pr < dp->dom_protoswNPROTOSW; pr++)
81         if (pr->pr_type && pr->pr_type == type)
82             return (pr);
83     return (0);
84 }

85 struct protosw *
86 pffindproto(family, protocol, type)
87 int      family, protocol, type;
88 {
89     struct domain *dp;
90     struct protosw *pr;
91     struct protosw *maybe = 0;
92     if (family == 0)
93         return (0);
94     for (dp = domains; dp; dp = dp->dom_next)
95         if (dp->dom_family == family)
96             goto found;
97     return (0);
98 found:
99     for (pr = dp->dom_protosw; pr < dp->dom_protoswNPROTOSW; pr++) {
100         if ((pr->pr_protocol == protocol) && (pr->pr_type == type))
101             return (pr);
102         if (type == SOCK_RAW && pr->pr_type == SOCK_RAW &&
103             pr->pr_protocol == 0 && maybe == (struct protosw *) 0)
104             maybe = pr;
105     }
106     return (maybe);
107 }

```

uipc_domain.c

图7-20 函数pffindproto 和pffindtype

举例

我们在15.6节中会看到，当一个应用程序进行下面的调用时：

```
socket(PF_INET, SOCK_STREAM, 0); /* TCP 插口 */
```

pffindtype被调用如下：

```
pffindtype(PF_INET, SOCK_STREAM);
```

图7-12显示pffindtype会返回一个指向inetsw[2]的指针，因为TCP是此数组中第一个SOCK_STREAM协议。同样，

```
socket(PF_INET, SOCK_DGRAM, 0); /* UCP 插口 */
```

会导致

```
pffindtype(PF_INET, SOCK_DGRAM);
```

它返回一个指向inetsw[1]中UDP的指针。

7.7 pfctlinput函数

函数pfctlinput给每个域中的每个协议发送一个控制请求(图7-21)。当可能影响每个协议的事件发生时，使用这个函数，例如一个接口被关闭，或路由表发生改变。当一个ICMP重定向报文到达时，ICMP调用pfctlinput(图11-14)，因为重定向会影响所有Internet协议(例如UDP和TCP)。

```
142 pfctlinput(cmd, sa)                                     uipc_domain.c
143 int cmd;
144 struct sockaddr *sa;
145 {
146     struct domain *dp;
147     struct protosw *pr;
148     for (dp = domains; dp; dp = dp->dom_next)
149         for (pr = dp->dom_protosw; pr < dp->dom_protoswNPROTOSW; pr++)
150             if (pr->pr_ctlinput)
151                 (*pr->pr_ctlinput) (cmd, sa, (caddr_t) 0);
152 }
```

uipc_domain.c

图7-21 函数pfctlinput

142-152 两个嵌套的for循环查找每个域中的每个协议。pfctlinput通过调用每个协议的pr_ctlinput函数来发送由cmd指定的协议控制命令。对于UDP，调用udp_ctlinput；而对于TCP，调用tcp_ctlinput。

7.8 IP初始化

如图7-13所示，Internet域没有一个初始化函数，但单个Internet协议有。现在，我们仅查看IP初始化函数ip_init。在第23章和第24章中，我们讨论UDP和TCP初始化函数。在讨论这些代码前，需要说明一下数组ip_protosw。

7.8.1 Internet传输分用

一个网络层协议像IP必须分用输入数据报，并将它们传递到相应的运输层协议。为了完成这些，相应的protosw结构必须通过一个在数据报中出现的协议编号得到。对于Internet协议，这由数组ip_protosw来完成，如图7-22所示。

数组ip_protosw的下标是来自IP首部的协议值(ip_p，图8-8)。被选项是inetsw数组中处理此数据报的协议的下标。例如，一个协议编号为6的数据报由inetsw[2]处理，协议为TCP。内核在协议初始化时构造ip_protosw，如图7-23所示。

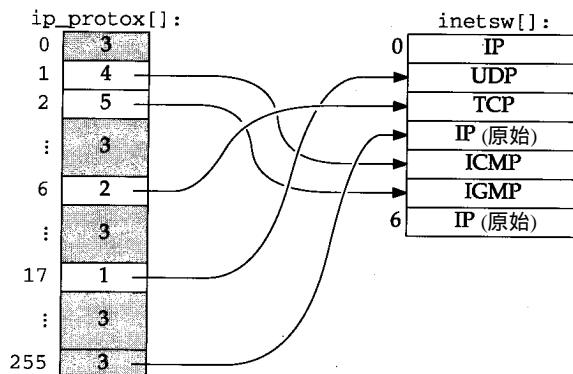


图7-22 数组 ip_protox 将协议编号映射到数组 inetsw 中的一项

```

71 void
72 ip_init() ip_input.c
73 {
74     struct protosw *pr;
75     int i;
76
77     pr = pffindproto(PF_INET, IPPROTO_RAW, SOCK_RAW);
78     if (pr == 0)
79         panic("ip_init");
80     for (i = 0; i < IPPROTO_MAX; i++)
81         ip_protox[i] = pr - inetsw;
82     for (pr = inetdomain.dom_protosw;
83          pr < inetdomain.dom_protosw+NPROTOSW; pr++)
84         if (pr->pr_domain->dom_family == PF_INET &&
85             pr->pr_protocol && pr->pr_protocol != IPPROTO_RAW)
86             ip_protox[pr->pr_protocol] = pr - inetsw;
87     ipq.next = ipq.prev = &ipq;
88     ip_id = time.tv_sec & 0xffff;
89     ipintrq.ifq_maxlen = ipq maxlen;
90     ip_ifmatrix = (u_long *) malloc(i, M_RTABLE, M_WAITOK);
91     bzero((char *) ip_ifmatrix, i);
92 }

```

ip_input.c

图7-23 函数 ip_init

7.8.2 ip_init函数

domaininit(图7-15)在系统初始化期间调用函数 ip_init。

71-78 pffindproto返回一个指向原始协议(inetsw[3], 图7-14)的指针。如果找不到原始协议，Net/3就调用panic，因为这是内核要求的部分。如果找不到原始协议，内核一定被错误配置了。IP将传输到一个未知传输协议的到达分组传递给此协议，在那里它们由内核外部的一个进程来处理。

79-85 接着的两个循环初始化数组 ip_protox。第一个循环将数组中的每项设置为 pr，即默认协议的下标(图7-22中为3)。第二个循环检查 inetsw 中的每个协议(而不是协议编号为0或 IPPROTO_RAW 的项)，并且将 ip_protox 中的匹配项设置为引用相应的 inetsw 项。为此，每个 protosw 结构中的 pr_protocol 必须是期望出现在输入数据报中的协议编号。

86-92 `ip_init` 初始化 IP 重装队列 `ipq`(10.6节)，用系统时钟植入 `ip_id`，并将 IP 输入队列 (`ipinrq`) 的最大长度设置为 50(`ipq maxlen`)。`ip_id` 用系统时钟设置，为数据报标识符提供一个随机起点(10.6节)。最后，`ip_init` 分配一个两维数组 `ip_ifmatrix`，统计在系统接口之间路由的分组数。

在 Net/3 中，有很多变量可以被一个系统管理员修改。为了允许在运行时改变这些变量而不需重新编译内核，一个常量(在此例中是 `IFQ_MAXLEN`)表示的默认值在编译时指派给一个变量(`ipq maxlen`)。一个系统管理员能使用一个内核调试器如 `adb`，来修改 `ipq maxlen`，并用新值重启内核。如果图 7-23 直接使用 `IFQ_MAXLEN`，它会要求内核重新编译来改变这个限制。

7.9 sysctl 系统调用

系统调用 `sysctl` 访问并修改 Net/3 系统范围参数。系统管理员通过程序 `sysctl(8)` 修改这些参数。每个参数由一个分层的整数列表来标识，并有一个相应的类型。此系统调用的原型为：

```
int sysctl(int * name, u_int namelen, void *old, size_t * oldlenp, void *new, size_t newlen);
```

`*name` 指向一个包含 `namelen` 个整数的数组。`*old` 指向在此范围内返回的旧值，`*new` 指向在此范围内传递的新值。

图 7-24 总结了关于联网名称的组织。

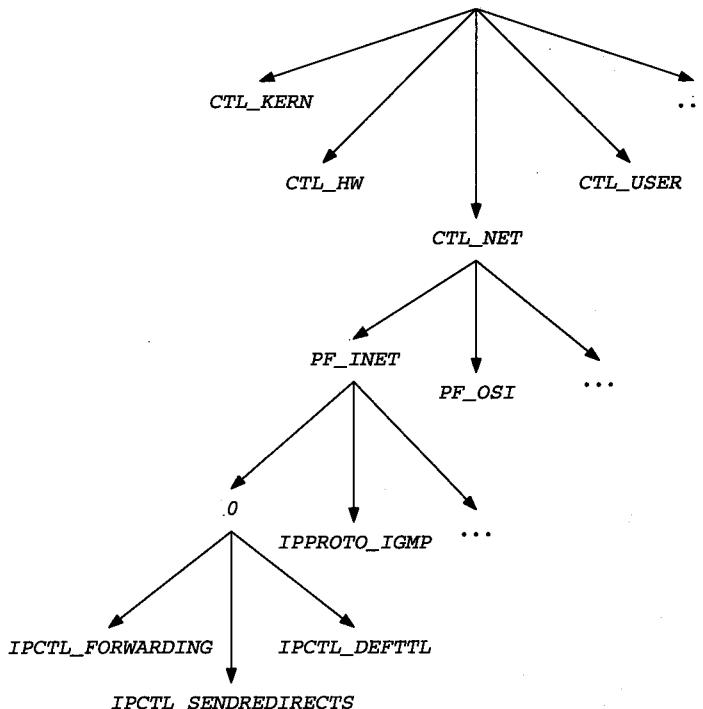


图 7-24 sysctl 的名称组织

在图 7-24 中，IP 转发标志的全名为

`CTL_NET`、`PF_INET`、`0`、`IPCTL_FORWARDING`

用4个整数存储在一个数组中。

net_sysctl函数

每层的sysctl命名方案通过不同函数处理。图7-25显示了处理这些Internet参数的函数。

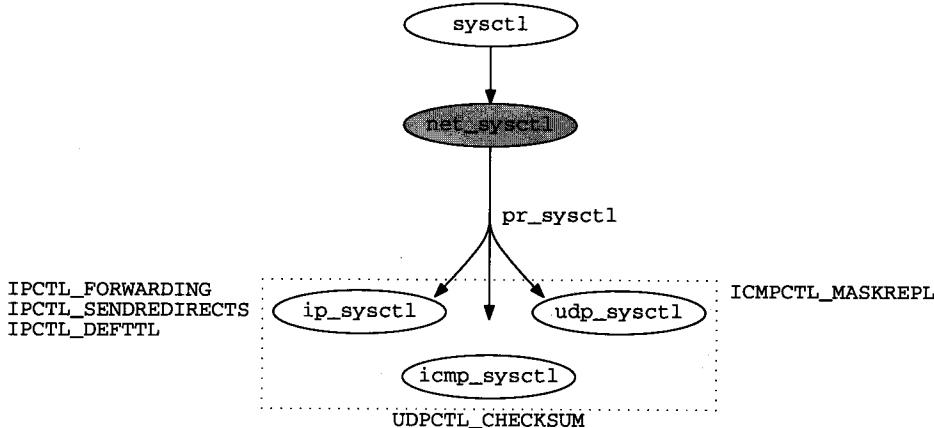


图7-25 处理Internet参数的sysctl函数

顶层名称由sysctl处理。网络层名称由net_sysctl处理，它根据族和协议将控制转给此协议的protosw项指定的pr_sysctl函数。

sysctl在内核中通过_sysctl函数实现，函数_sysctl不在本书中讨论。它包含将sysctl参数传给内核和从内核取出sysctl参数的代码及一个switch语句，这个switch语句选择相应的函数来处理这些参数，在这里是net_sysctl。

图7-26所示的是函数net_sysctl。

```

108 net_sysctl(name, namelen, oldp, oldlenp, newp, newlen, p)           uipc_domain.c
109 int      *name;
110 u_int     namelen;
111 void     *oldp;
112 size_t   *oldlenp;
113 void     *newp;
114 size_t   newlen;
115 struct proc *p;
116 {
117     struct domain *dp;
118     struct protosw *pr;
119     int      family, protocol;

120     /*
121      * All sysctl names at this level are nonterminal;
122      * next two components are protocol family and protocol number,
123      * then at least one additional component.
124      */
125     if (namelen < 3)
126         return (EISDIR);          /* overloaded */
127     family = name[0];
128     protocol = name[1];

129     if (family == 0)

```

图7-26 函数net_sysctl

```

130         return (0);
131     for (dp = domains; dp; dp = dp->dom_next)
132         if (dp->dom_family == family)
133             goto found;
134     return (ENOPROTOOPT);
135 found:
136     for (pr = dp->dom_protosw; pr < dp->dom_protoswNPROTOSW; pr++)
137         if (pr->pr_protocol == protocol && pr->pr_sysctl)
138             return ((*pr->pr_sysctl) (name + 2, namelen - 2,
139                                         oldp, oldlenp, newp, newlen));
140     return (ENOPROTOOPT);
141 }

```

uipc_domain.c

图7-26 (续)

108-119 net_sysctl的参数除了增加了p外，同系统调用sysctl一样，p指向当前进程结构。

120-134 在名称中接下来的两个整数被认为是在结构domain和protosw中指定的协议族和协议编号成员的值。如果没有指定族，则返回0。如果指定了族，for循环在域列表中查找一个匹配的族。如果没有找到，则返回ENOPROTOOPT。

135-141 如果找到匹配域，第二个for循环查找第一个定义了函数pr_sysctl的匹配协议。当找到匹配项，将请求传递给此协议的pr_sysctl函数。注意，把(name+2)指向的整数传递给下一级。如果没有找到匹配的协议，返回ENOPROTOOPT。

图7-27所示的是为Internet协议定义的pr_sysctl函数。

pr_protocol	inetsw[]	pr_sysctl	说 明	参 考
0	0	<i>ip_sysctl</i>	IP	8.9节
<i>IPIPproto_UDP</i>	1	<i>udp_sysctl</i>	UDP	23.11节
<i>IPIPproto_ICMP</i>	4	<i>icmp_sysctl</i>	ICMP	11.14节

图7-27 Internet协议族的pr_sysctl 函数

在路由选择域中，pr_sysctl指向函数sysctl_rtable，它在第19章中讨论。

7.10 小结

本章从说明结构domain和protosw开始，这两个结构在Net/3内核中描述及组织协议。我们看到一个域的所有protosw结构在编译时分配在一个数组中，inetdomain和数组inetsw描述Internet协议。我们仔细查看了三个描述IP协议的inetsw项：一个用于内核访问IP，其他两个用于进程访问IP。

在系统初始化时，domainint将域链接到domains列表中，调用域和协议初始化函数，并调用快速和慢速超时函数。

两个函数pffindproto和pffindtype通过协议号或类型搜索域和协议列表。pfctlinput发送一个控制命令给所有协议。

最后，我们说明了IP初始化程序，它通过数组ip_protos完成传输分用。

习题

7.1 由谁调用pfsfindproto会返回一个指向inetsw[6]指针？

第8章 IP：网际协议

8.1 引言

本章我们介绍IP分组的结构和基本的IP处理过程，包括输入、转发和输出。假定读者熟悉IP协议的基本操作，其他IP的背景知识见卷1的第3、9和12章。RFC 791 [Postel 1981a] 是IP的官方规范，RFC 1122 [Braden 1989a] 中有RFC 791的说明。

第9章将讨论选项的处理，第10章讨论分片和重装。图8-1显示了IP层常见的组织形式。

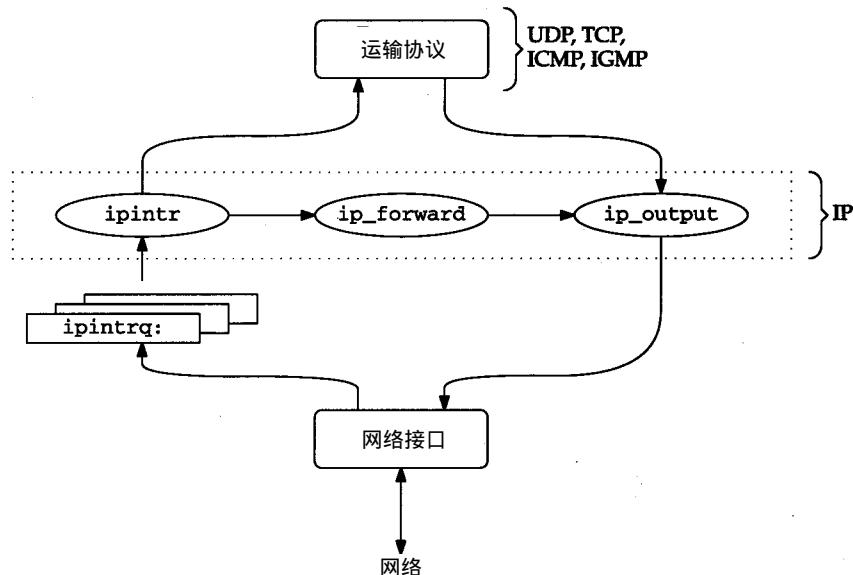


图8-1 IP层的处理

在第4章中，我们看到网络接口如何把到达的IP分组放到IP输入队列`ipintrq`中去，并如何调用一个软件中断。因为硬件中断的优先级比软件中断的要高，所以在发生一次软件中断之前，有的分组可能会被放到队列中。在软件中断处理中，`ipintr`函数不断从`ipintrq`中移走和处理分组，直到队列为空。在最终的目的地，IP把分组重装为数据报，并通过函数调用把该数据报直接传给适当的运输层协议。如果分组没有到达最后的目的地，并且如果主机被配置成一个路由器，则IP把分组传给`ip_forward`。传输协议和`ip_forward`把要输出的分组传给`ip_output`，由`ip_output`完成IP首部、选择输出接口以及在必要时对分组分片。最终的分组被传给合适的网络接口输出函数。

当产生差错时，IP丢弃该分组，并在某些条件下向分组的源站发出一个差错报文。这些报文是ICMP(第11章)的一部分。Net/3通过调用`icmp_error`发出ICMP差错报文，`icmp_error`接收一个mbuf，其中包含差错分组、发现的差错类型以及一个选项码，提供依赖于差错类型的附加信息。

本章我们讨论 IP 为什么以及何时发送 ICMP 报文，至于有关 ICMP 本身的详细讨论将在第 11 章进行。

8.2 代码介绍

本章讨论两个头文件和三个 C 文件。如图 8-2 所示。

文 件	描 述
net/route.h	路由入口
netinet/ip.h	IP 首部结构
netinet/ip_input.c	IP 输入处理
netinet/ip_output.c	IP 输出处理
netinet/ip_cksum.c	Internet 检验和算法

图 8-2 本章描述的文件

8.2.1 全局变量

在 IP 处理代码中出现了几个全局变量，见图 8-3。

变 量	数据类型	描 述
in_ifaddr	struct in_ifaddr	IP 地址清单
ip_defttl	int	IP 分组的默认 TTL
ip_id	int	赋给输出的 IP 分组的上一个 ID
ip_protox	int[]	IP 分组的分路矩阵
ipforwarding	int	系统是否转发 IP 分组？
ipforward_rt	struct route	大多数最近转发的路由的缓存
ipintrq	struct ifqueue	IP 输入队列
ipqmaxlen	int	IP 输入队列的最大长度
ipsendredirects	int	系统是否发送 ICMP 重定向？
ipstat	struct ipstat	IP 统计

图 8-3 本章中引入的全局变量

8.2.2 统计量

IP 收集的所有统计量都放在图 8-4 描述的 ipstat 结构中。图 8-5 显示了由 netstat-s 命令得到的一些统计输出样本。统计是在主机启动 30 天后收集的。

ipstat 成员	描 述	SNMP 使用的
ips_badhlen	IP 首部长度无效的分组数	•
ips_badlen	IP 首部和 IP 数据长度不一致的分组数	•
ips_badoptions	在选项处理中发现差错的分组数	•
ips_badsum	检验和差错的分组数	•
ips_badvers	IP 版本不是 4 的分组数	•
ips_cantforward	目的站不可到达的分组数	•
ips_delivered	向高层交付的数据报数	•

图 8-4 本章收集的统计

ipstat成员	描述	SNMP使用的
ips_forward	转发的分组数	•
ips_fragdropped	分片丢失数(副本或空间不足)	•
ips_fragments	收到分片数	•
ips_fragtimeout	超时的分片数	•
ips_noproto	具有未知或不支持的协议的分组数	•
ips_reassembled	重装的数据报数	•
ips_tooshort	具有无效数据长度的分组数	•
ips_toosmall	无法包含IP分组的太小的分组数	•
ips_total	全部接收到的分组数	•
ips_cantfrag	由于不分片比特而丢弃的分组数	•
ips_fragmented	成功分片的数据报数	•
ips_localout	系统生成的数据报数(即没有转发的)	•
ips_noroute	丢弃的分组数——到目的地没有路由	•
ips_odropped	由于资源不足丢掉的分组数	•
ips_ofragments	为输出产生的分片数	•
ips_rawout	全部生成的原始ip分组数	•
ips_redirectsent	已发送的重定向报文数	•

图8-4 (续)

netstat -s 输出	ipstat 成员
27,881,978 total packets received 6 bad header checksums 9 with size smaller than minimum 14 with data size < data length 0 with header length < data size 0 with data length < header length 0 with bad options 0 with incorrect version number 72,786 fragments received 0 fragments dropped (dup or out of space) 349 fragments dropped after timeout 16,557 packets reassembled ok 27,390,665 packets for this host 330,882 packets for unknown/unsupported protocol	ips_total ips_badsum ips_tooshort ips_toosmall ips_badhlen ips_badlen ips_badoptions ips_badvers ips_fragments ips_fragdropped ips_fragtimeout ips_reassembled ips_delivered ips_noproto
97,939 packets forwarded 6,228 packets not forwardable 0 redirects sent	ips_forward ips_cantforward ips_redirectsent
29,447,726 packets sent from this host 769 packets sent with fabricated ip header 0 output packets dropped due to no bufs, etc. 0 output packets discarded due to no route 260,484 output datagrams fragmented 796,084 fragments created 0 datagrams that can't be fragmented	ips_localout ips_rawout ips_odropped ips_noroute ips_fragmented ips_ofragments ips_cantfrag

图8-5 IP统计样本

ips_noproto的值很高，因为当没有进程准备接收报文时，它能对ICMP主机不可达报文进行计数。见第32.5节的详细讨论。

8.2.3 SNMP变量

图8-6显示了IP组和Net/3收集的统计中的SNMP变量之间的关系。

SNMP变量	Ipstat成员	描述
ipDefaultTTL ipForwarding ipReasmTimeout	ip_defttl ipforwarding IPFRAGTTL	数据报的默认 TTL(64跳) 系统是路由器吗? 分片的重装超时(30秒)
ipInReceives	ips_total	收到的全部IP分组数
ipInHdrErrors	ips_badsum+ ips_tooshort+ ips_toosmall+ ips_badhlen+ ips_badlen+ ips_badoptions+ ips_badvers	IP首部出错的分组数
ipInAddrErrors ipForwDatagrams ipReasmReqds ipReasmFails ipReasmOKs ipInDiscards ipInUnknownProtos ipInDelivers	ips_cantforward ips_forward ips_fragments ips_fragdropped+ ips_fragtimeout ips_reassembled (未实现) ips_noproto ips_delivered	由于错误交付而丢弃的IP分组数(ip_output也失败) 转发的IP分组数 收到的分片数 丢失的分片数 成功地重装的数据报数 由于资源限制而丢弃的数据报数 具有未知或不支持的协议的数据报数 交付到运输层的数据报数
ipOutRequests ipFragOKs ipFragFails ipFragCreates ipOutDiscards ipOutRoutes	ips_localout ips_fragmented ips_cantfrag ips_ofragments ips_odropped ips_noroute	由运输层产生的数据报数 分片成功的数据报数 由于不分片比特丢弃的IP分组数 为输出产生的分片数 由于资源短缺丢失的IP分组数 由于没有路由丢弃的IP分组数

图8-6 IP组中SNMP变量的例子

8.3 IP分组

为了更准确地讨论 Internet协议处理，我们必须定义一些名词。图 8-7显示了在不同的Internet层之间传递数据时用来描述数据的名词。

我们把传输协议交给 IP的数据称为报文。典型的报文包含一个运输层首部和应用程序数据。图8-7所示的传输协议是 UDP。IP在报文的首部前加上它自己的首部形成一个数据报。如果在选定的网络中，数据报的长度太大，IP就把数据报分裂成几个分片，每个分片中含有它自己的IP首部和一段原来数据报的数据。图 8-7显示了一个数据报被分成三个分片。

当提交给数据链路层进行传送时，一个 IP分片或一个很小的无需分片的 IP数据报称为分组。数据链路层在分组前面加上它自己的首部，并发送得到的帧。

IP只考虑它自己加上的 IP首部，对报文本身既不检查也不修改 (除非进行分片)。图8-8显示了IP首部的结构。

图8-8包括 ip 结构(如图8-9)中各成员的名字，Net/3通过该结构访问IP首部。

47-67 因为在存储器中，比特字段的物理顺序依机器和编译器的不同而不同，所以由 #ifs 保证编译器按照 IP标准排列结构成员。从而，当 Net/3把一个 ip 结构覆盖到存储器中的一个 IP

分组上时，结构成员能够访问到分组中正确的比特。

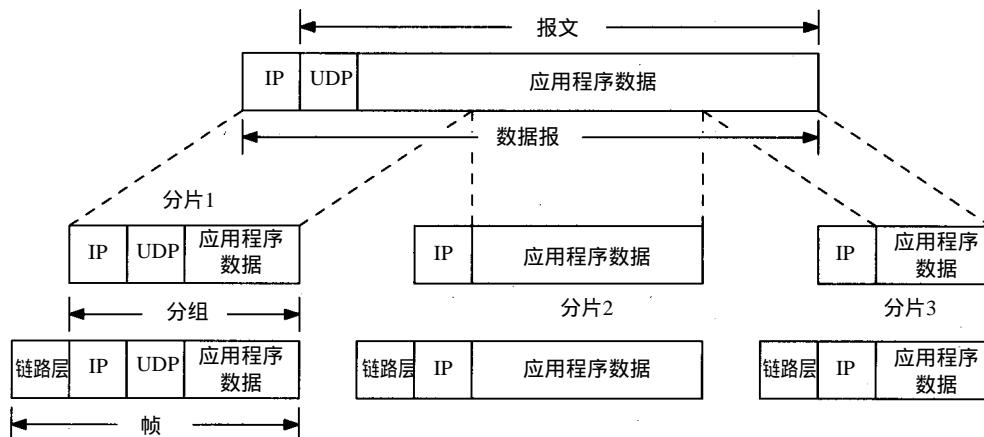


图8-7 帧、分组、分片、数据报和报文

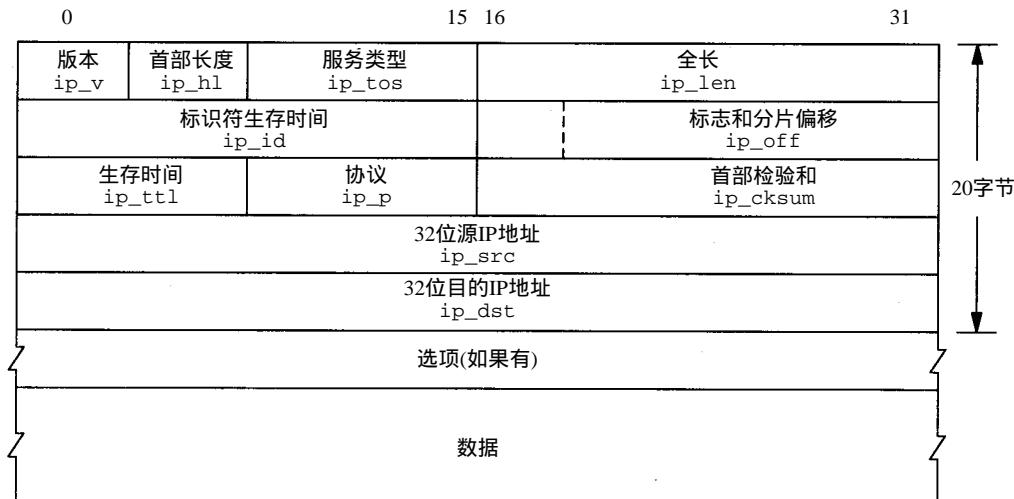


图8-8 IP数据报，包括 ip 结构名

```
40 /*
41 * Structure of an internet header, naked of options.
42 *
43 * We declare ip_len and ip_off to be short, rather than u_short
44 * pragmatically since otherwise unsigned comparisons can result
45 * against negative integers quite easily, and fail in subtle ways.
46 */
47 struct ip {
48 #if BYTE_ORDER == LITTLE_ENDIAN
49     u_char    ip_hl:4,           /* header length */
50             ip_v:4;            /* version */
51 #endif
52 #if BYTE_ORDER == BIG_ENDIAN
53     u_char    ip_v:4,           /* version */
54             ip_hl:4;           /* header length */
55 #endif

```

图8-9 ip 结构

```

56     u_char   ip_tos;           /* type of service */
57     short    ip_len;          /* total length */
58     u_short  ip_id;          /* identification */
59     short    ip_off;          /* fragment offset field */
60 #define IP_DF 0x4000          /* dont fragment flag */
61 #define IP_MF 0x2000          /* more fragments flag */
62 #define IP_OFFMASK 0xffff      /* mask for fragmenting bits */
63     u_char   ip_ttl;          /* time to live */
64     u_char   ip_p;            /* protocol */
65     u_short  ip_sum;          /* checksum */
66     struct in_addr ip_src, ip_dst; /* source and dest address */
67 };

```

ip.h

图8-9 (续)

IP首部中包含IP分组格式、内容、寻址、路由选择以及分片的信息。

IP分组的格式由版本 *ip_v* 指定，通常为4；首部长度 *ip_hl*，通常以4字节单元度量；分组长度 *ip_len* 以字节为单位度量；传输协议 *ip_p* 生成分组内数据；*ip_sum* 是检验和，检测在发送中首部的变化。

标准的IP首部长度是20个字节，所以 *ip_hl* 必须大于或等于5。大于5表示IP选项紧跟在标准首部后。如 *ip_hl* 的最大值为15 ($2^4 - 1$)，允许最多40个字节的选项 ($20 + 40 = 60$)。IP数据报的最大长度为65535 ($2^{16} - 1$)字节，因为 *ip_len* 是一个16 bit的字段。图8-10是整个构成。

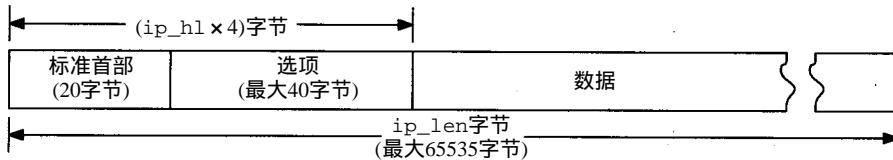


图8-10 有选项的IP分组构成

因为 *ip_hl* 是以4字节为单元计算的，所以IP选项必须常常被填充成4字节的倍数。

8.4 输入处理：*ipintr*函数

在第3、第4和第5章中，我们描述了示例的网络接口如何对到达的数据报排队以等待协议处理：

- 1) 以太网接口用以太网首部中的类型字段分路到达帧(见4.3节)；
- 2) SLIP接口只处理IP分组，所以无需分用(见5.3节)；
- 3) 环回接口在 *looutput* 函数中结合输入和输出处理，用目的地址中的 *sa_family* 成员对数据报分用(见5.4节)。

在以上情况中，当接口把分组放到 *ipintrq* 上排队后，通过 *schednetisr* 调用一个软中断。当该软中断发生时，如果IP处理过程已经由 *schednetisr* 调度，则内核调用 *ipintr*。在调用 *ipintr* 之前，CPU的优先级被改变成 *splnet*。

8.4.1 *ipintr*概观

*ipintr*是一个大函数，我们将在4个部分中讨论：(1)对到达分组验证；(2)选项处理及转发；(3)分组重装；(4)分用。在 *ipintr* 中发生分组的重装，但比较复杂，我们将单独放在第

10章中讨论。图8-11显示了ipintr的整体结构。

```

100 void
101 ipintr()
102 {
103     struct ip *ip;
104     struct mbuf *m;
105     struct ipq *fp;
106     struct in_ifaddr *ia;
107     int hlen, s;

108     next:
109     /*
110      * Get next datagram off input queue and get IP header
111      * in first mbuf.
112      */
113     s = splimp();
114     IF_DEQUEUE(&ipintrq, m);
115     splx(s);
116     if (m == 0)
117         return;

118     /* Input packet processing */
119     /* Figures 8.12, 8.13, 8.15, 8.16, and 8.17 */
120
121     goto next;
122     bad:
123     m_freem(m);
124     goto next;
125 }
```

ip_input.c

图8-11 ipintr 函数

100-117 标号next标识主要的分组处理循环的开始。ipintr从ipintrq中移走分组，并对之加以处理直到整个队列空为止。如果到函数最后控制失败，goto把控制权传回给next中最上面的函数。ipintr把分组阻塞在splimp内，避免当它访问队列时，运行网络的中断程序(例如slinput和ether_input)。

332-336 标号bad标识由于释放相关mbuf并返回到next中处理循环的开始而自动丢弃的分组。在整个ipintr中，都是跳到bad来处理差错。

8.4.2 验证

我们从图8-12开始：把分组从ipintrq中取出，验证它们的内容。损坏和有差错的分组被自动丢弃。

```

118     /*
119      * If no IP addresses have been set yet but the interfaces
120      * are receiving, can't do anything with incoming packets yet.
121      */
122     if (in_ifaddr == NULL)
123         goto bad;
124     ipstat.ips_total++;
125     if (m->m_len < sizeof(struct ip) &&
```

ip_input.c

图8-12 ipintr 函数

```

126         (m = m_pullup(m, sizeof(struct ip))) == 0) {
127             ipstat.ips_toosmall++;
128             goto next;
129         }
130         ip = mtod(m, struct ip *);
131         if (ip->ip_v != IPVERSION) {
132             ipstat.ips_badvers++;
133             goto bad;
134         }
135         hlen = ip->ip_hl << 2;
136         if (hlen < sizeof(struct ip)) { /* minimum header length */
137             ipstat.ips_badhlen++;
138             goto bad;
139         }
140         if (hlen > m->m_len) {
141             if ((m = m_pullup(m, hlen)) == 0) {
142                 ipstat.ips_badhlen++;
143                 goto next;
144             }
145             ip = mtod(m, struct ip *);
146         }
147         if (ip->ip_sum = in_cksum(m, hlen)) {
148             ipstat.ips_badsum++;
149             goto bad;
150         }
151         /*
152          * Convert fields to host representation.
153          */
154         NTOHS(ip->ip_len);
155         if (ip->ip_len < hlen) {
156             ipstat.ips_badlen++;
157             goto bad;
158         }
159         NTOHS(ip->ip_id);
160         NTOHS(ip->ip_off);
161         /*
162          * Check that the amount of data in the buffers
163          * is as at least much as the IP header would have us expect.
164          * Trim mbufs if longer than we expect.
165          * Drop packet if shorter than we expect.
166          */
167         if (m->m_pkthdr.len < ip->ip_len) {
168             ipstat.ips_tooshort++;
169             goto bad;
170         }
171         if (m->m_pkthdr.len > ip->ip_len) {
172             if (m->m_len == m->m_pkthdr.len) {
173                 m->m_len = ip->ip_len;
174                 m->m_pkthdr.len = ip->ip_len;
175             } else
176                 m_adj(m, ip->ip_len - m->m_pkthdr.len);
177         }

```

ip_input.c

图8-12 (续)

1. IP版本

118-134 如果in_ifaddr表(见第6.5节)为空，则该网络接口没有指派IP地址，*ipintr*必须丢掉所有的IP分组；没有地址，*ipintr*就无法决定该分组是否要到该系统。通常这是一种

暂时情况，是当系统启动时，接口正在运行但还没有配置好时发生的。我们在 6.3 节中介绍了地址是如何分配的问题。

在 `ipintr` 访问任何 IP 首部字段之前，它必须证实 `ip_v` 是 4(`IPVERSION`)。RFC 1122 要求某种实现丢弃那些具有无法识别版本号的分组而不回显信息。

Net/2 不检查 `ip_v`。目前大多数正在使用的 IP 实现，包括 Net/2，都是在 IP 的版本 4 之后产生的，因此无需区分不同 IP 版本的分组。因为目前正在对 IP 进行修正，所以不久将来的实现都将检查 `ip_v`。

IEN 119 [Forgie 1979] 和 RFC 1190 [Topolcic 1990] 描述了使用 IP 版本 5 和 6 的实验协议。版本 6 还被选为下一个正式的 IP 标准 (IPv6)。保留版本 0 和 15，其他的没有赋值。

在 C 中，处理位于一个无类型存储区域中数据的最简单的方法是：在该存储区域上覆盖一个结构，转而处理该结构中的各个成员，而不再对原始的字节进行操作。如第 2 章所言，mbuf 链把一个字节的逻辑序列，例如一个 IP 分组，储存在多个物理 mbuf 中，各 mbuf 相互连接在一个链表上。因为覆盖技术也可用于 IP 分组的首部，所以首部必须驻留在一段连续的存储区内（也就是说，不能把首部分开放在不同的存储器缓存区）。

135-146 下面的步骤保证 IP 首部（包括选项）位于一段连续的存储器缓存区上：

- 如果在第一个 mbuf 中的数据小于一个标准的 IP 首部（20 字节），`m_pullup` 会重新把该标准首部放到一个连续的存储器缓存区上去。

链路层不太可能会把最大的（60 字节）IP 首部分在两个 mbuf 中从而使用上面的 `m_pullup`。

- `ip_h1` 通过乘以 4 得到首部字节长度，并将其保存在 `hlen` 中。
- 如果 IP 分组首部的字节数长度 `hlen` 小于标准首部（20 字节），将是无效的并被丢弃。
- 如果整个首部仍然不在第一个 mbuf 中（也就是说，分组包含了 IP 选项），则由 `m_pullup` 完成其任务。

同样，这不一定是必需的。

检验和计算是所有 Internet 协议的重要组成。所有的协议均使用相同的算法（由函数 `in_cksum` 完成），但应用于分组的不同部分。对 IP 来说，检验和只保证 IP 的首部（以及选项，如果有的话）。对传输协议，如 UDP 或 TCP，检验和覆盖了分组的数据部分和运输层首部。

2. IP 检验和

147-150 `ipintr` 把由 `in_cksum` 计算出来的检验和保存首部的 `ip_sum` 字段中。一个未被破坏的首部应该具有 0 检验和。

正如我们将在 8.7 节中看到的，在计算到达分组的检验和之前，必须对 `ip_sum` 清零。通过把 `in_cksum` 中的结果储存在 `ip_sum` 中，就为分组转发作好了准备（尽管还没有减小 TTL）。`ip_output` 函数不依赖这项操作；它为转发的分组重新计算检验和。

如果结果非零，则该分组被自动丢弃。我们将在 8.7 节中详细讨论 `in_cksum`。

3. 字节顺序

151-160 Internet标准在指定协议首部中多字节整数值的字节顺序时非常小心。NTOHS把IP首部中所有16 bit的值从网络字节序转换成主机字节序：分组长度(ip_len)、数据报标识符(ip_id)和分片偏移(ip_off)。如果两种格式相同，则NTOHS是一个空的宏。在这里就转换成主机字节序，以避免Net/3每次检查该字段时必须进行一次转换。

4. 分组长度

161-177 如果分组的逻辑长度(ip_len)比储存在mbuf中的数据量(m_pkthdr.len)大，并且有些字节被丢失了，就必须丢弃该分组。如果mbuf比分组大，则去掉多余的字节。

丢失字节的一个常见原因是由于数据到达某个没有或只有很少缓存的串口设备，例如许多个人计算机。设备丢弃到达的字节，而IP丢弃最后的分组。

多余的字节可能产生，如在某个以太网设备上，当一个IP分组的大小比以太网要求的最小长度还小时。发送该帧时加上的多余字节就在这里被丢掉。这就是为什么IP分组的长度被保存在首部的原因之一；IP允许链路层填充分组。

现在，有了完整的IP首部，分组的逻辑长度和物理长度相同，检验和表明分组的首部无损地到达。

8.4.3 转发或不转发

图8-13显示了ipintr的下一部分，调用ip_dooptions(见第9章)来处理IP选项，然后决定分组是否到达它最后的目的地。如果分组没有到达最后目的地，Net/3会尝试转发该分组(如果系统被配置成路由器)。如果分组到达最后目的地，就被交付给合适的运输层协议。

ip_input.c

```

178     /*
179      * Process options and, if not destined for us,
180      * ship it on. ip_dooptions returns 1 when an
181      * error was detected (causing an icmp message
182      * to be sent and the original packet to be freed).
183      */
184     ip_nhops = 0;           /* for source routed packets */
185     if (hlen > sizeof(struct ip) && ip_dooptions(m))
186         goto next;

187     /*
188      * Check our list of addresses, to see if the packet is for us.
189      */
190     for (ia = in_ifaddr; ia; ia = ia->ia_next) {
191 #define satosin(sa) ((struct sockaddr_in *) (sa))

192         if (IA_SIN(ia)->sin_addr.s_addr == ip->ip_dst.s_addr)
193             goto ours;

194         /* Only examine broadcast addresses for the receiving interface */
195         if (ia->ia_ifp == m->m_pkthdr.rcvif &&
196             (ia->ia_ifp->if_flags & IFF_BROADCAST)) {
197             u_long t;

198             if (satosin(&ia->ia_broadaddr)->sin_addr.s_addr ==
199                 ip->ip_dst.s_addr)
200                 goto ours;
201             if (ip->ip_dst.s_addr == ia->ia_netbroadcast.s_addr)

```

图8-13 续ipintr

```

202         goto ours;
203     /*
204      * Look for all-0's host part (old broadcast addr),
205      * either for subnet or net.
206      */
207     t = ntohl(ip->ip_dst.s_addr);
208     if (t == ia->ia_subnet)
209         goto ours;
210     if (t == ia->ia_net)
211         goto ours;
212     }
213 }
```

/* multicast code (Figure 12-39) */

```

258     if (ip->ip_dst.s_addr == (u_long) INADDR_BROADCAST)
259         goto ours;
260     if (ip->ip_dst.s_addr == INADDR_ANY)
261         goto ours;
262     /*
263      * Not for us; forward if possible and desirable.
264      */
265     if (ipforwarding == 0) {
266         ipstat.ips_cantforward++;
267         m_freem(m);
268     } else
269         ip_forward(m, 0);
270     goto next;
271 ours:
```

ip_input.c

图8-13 (续)

1. 选项处理

178-186 通过对 `ip_nhops`(见9.6节)清零，丢掉前一个分组的原路由。如果分组首部大于默认首部，它必然包含由 `ip_dooptions` 处理的选项。如果 `ip_dooptions` 返回 0，`ipintr` 将继续处理该分组；否则，`ip_dooptions` 通过转发或丢弃分组完成对该分组的处理，`ipintr` 可以处理输入队列中的下一个分组。我们把对选项的进一步讨论放到第 9 章进行。

处理完选项后，`ipintr` 通过把 IP 首部内的 `ip_dst` 与配置的所有本地接口的 IP 地址比较，以决定分组是否已到达最终目的地。`ipintr` 必须考虑与接口相关的几个广播地址、一个或多个单播地址以及任意个多播地址。

2. 最终目的地

187-261 `ipintr` 通过遍历 `in_ifaddr`(图6-5)，配置好的 Internet 地址表，来决定是否有与分组的目的地址的匹配。对清单中的每个 `in_ifaddr` 结构进行一系列的比较。要考虑 4 种常见的几种情况：

- 与某个接口地址的完全匹配(图8-14中的第一行)，
- 与某个与接收接口相关的广播地址的匹配(图8-14的中间4行)，
- 与某个与接收接口相关的多播组之一的匹配(图12-39)，或
- 与两个受限的广播地址之一的匹配(图8-14的最后一行)。

图8-14显示的是当分组到达我们的示例网络里的主机 sun上的以太网接口时要测试的地址，将在第12章中讨论的多播地址除外。

变量	以太网	SLIP	环回	线路 (图8.13)
ia_addr	[140.252.13.33]	[140.252.1.29]	[127.0.0.1]	192–193
ia_broadaddr	[140.252.13.224]			198–200
ia_netbroadcast	[140.252.255.255]			201–202
ia_subnet	[140.252.13.32]			207–209
ia_net	[140.252.0.0]			210–211
INADDR_BROADCAST		[255.255.255.255]		258–259
INADDR_ANY		[0.0.0.0]		260–261

图8-14 为判定分组是否到达最终目的地进行的比较

对ia_subnet、ia_net和INADDR_ANY的测试不是必需的，因为它们表示的是4.2BSD使用的已经过时的广播地址。但不幸的是，许多TCP/IP实现是从4.2BSD派生而来的，所以，在某些网络中能够识别出这些旧广播地址可能十分重要。

3. 转发

262–271 如果ip_dst与所有地址都不匹配，分组还没有到达最终目的地。如果还没有设置ipforwarding，就丢弃分组。否则，ip_forward尝试把分组路由到它的最终目的地。

当分组到达的某个地址不是目的地址指定的接口时，主机会丢掉该分组。在这种情况下，Net/3将搜索整个in_ifaddr表；只考虑那些分配给接收接口的地址。RFC 1122称此为强端系统(strong end system)模型。

对多主主机而言，很少出现分组到达接口地址与其目的地址不对应的情况，除非配置了特定的主机路由。主机路由强迫相邻的路由器把多主主机作为分组的下一跳路由器。弱端系统(weak end system)模型要求该主机接收这些分组。实现人员可以随意选择两种模型。Net/3实现弱端系统模型。

8.4.4 重装和分用

最后，我们来看ipintr的最后一部分(图8-15)，在这里进行重装和分用。我们略去了重装的代码，推迟到第10章讨论。当无法重装完全的数据报时，略去的代码将把指针ip设成空。否则，ip指向一个已经到达目的地的完整数据报。

运输分用

325–332 数据报中指定的协议被ip_p用ip_protosw数组(图7-22)映射到inet_sw数组的下

标。ipintr调用选定的protosw结构中的pr_input函数来处理数据报包含的运输报文。当pr_input返回时，ipintr继续处理ipintronq中的下一个分组。

注意，运输层对分组的处理发生在ipintr处理循环的内部。在IP和传输协议之间没有到达分组的排队，这与TCP/IP中SVR4流实现的排队不同。

```
----- ip_input.c -----
```



```

325  /*
326   * If control reaches here, ip points to a complete datagram.
327   * Otherwise, the reassembly code jumps back to next (Figure 8.11)
328   * Switch out to protocol's input routine.
329   */
330   ipstat.ips_delivered++;
331   (*inetsw[ip_protox[ip->ip_p]].pr_input) (m, hlen);
332   goto next;
----- ip_input.c -----

```

图8-15 续ipintr

8.5 转发：ip_forward函数

到达非最终目的地系统的分组需要被转发。只有当ipforwarding非零(6.1节)或当分组中包含源路由(9.6节)时，ipintr才调用实现转发算法的ip_forward函数。当分组中包含源路由时，ip_dooptions调用ip_forward，并且第2个参数srcrt设为1。

ip_forward通过图8-16中显示的route结构与路由表接口。

```
----- route.h -----
```

```

46 struct route {
47     struct rtentry *ro_rt;      /* pointer to struct with information */
48     struct sockaddr ro_dst;    /* destination of this route */
49 };
----- route.h -----

```

图8-16 route 结构

46-49 route结构有两个成员：ro_rt，指向rtentry结构的指针；ro_dst，一个sockaddr结构，指定与ro_rt所指的路由项相关的目的地。目的地是在内核的路由表中用来查找路由信息的关键字。第18章对rtentry结构和路由表有详细的描述。

我们分两部分讨论ip_forward。第一部分确定允许系统转发分组，修改IP首部，并为分组选择路由。第二部分处理ICMP重定向报文，并把分组交给ip_output进行发送。见图8-17。

1. 分组适合转发吗

867-871 ip_forward的第一个参数是指向一个mbuf链的指针，该mbuf中包含了要被转发的分组。如果第2个参数srcrt为非零，则分组由于源路由选项(见9.6节)正在被转发。

879-884 if语句识别并丢弃以下分组。

- 链路层广播

任何支持广播的网络接口驱动器必须为收到的广播分组把M_BCAST标志置位。如果分组寻址是到以太网广播地址，则ether_input(图4-13)就把M_BCAST置位。不转发链路层的广播分组。

RFC 1122不允许以链路层广播的方式发送一个寻址到单播 IP地址的分组，并在这里将该分组丢掉。

- 环回分组

对寻址到环回网络的分组，`in_canforward`返回0。这些分组将被`ipintr`提交给`ip_forward`，因为没有正确配置反馈接口。

- 网络0和E类地址

对这些分组，`in_canforward`返回0。这些目的地址是无效的，而且因为没有主机接收这些分组，所以它们不应该继续在网络中流动。

- D类地址

寻址到D类地址的分组应该由多播函数`ip_mforward`而不是由`ip_forward`处理。`in_canforward`拒绝D类(多播)地址。

RFC 791 规定处理分组的所有系统都必须把生存时间(TTL)字段至少减去1，即使TTL是以秒计算的。由于这个要求，TTL通常被认为是对IP分组在被丢掉之前能经过的跳的个数的界限。从技术角度说，如果路由器持有分组超过1秒，就必须把`ip_ttl`减去多于1。

```

867 void ip_forward(m, srcrt)
868 {
869     struct mbuf *m;
870     int srcrt;
871 }
872     struct ip *ip = mtod(m, struct ip *);
873     struct sockaddr_in *sin;
874     struct rtentry *rt;
875     int error, type = 0, code;
876     struct mbuf *mcopy;
877     n_long dest;
878     struct ifnet *destifp;
879     dest = 0;
880     if (m->m_flags & M_BCAST || in_canforward(ip->ip_dst) == 0) {
881         ipstat.ips_cantforward++;
882         m_free(m);
883         return;
884     }
885     HTONS(ip->ip_id);
886     if (ip->ip_ttl <= IPTTLDEC) {
887         icmp_error(m, ICMP_TIMXCEED, ICMP_TIMXCEED_INTRANS, dest, 0);
888         return;
889     }
890     ip->ip_ttl -= IPTTLDEC;
891     sin = (struct sockaddr_in *) &ipforward_rt.ro_dst;
892     if ((rt = ipforward_rt.ro_rt) == 0 ||
893         ip->ip_dst.s_addr != sin->sin_addr.s_addr) {
894         if (ipforward_rt.ro_rt) {
895             RTFREE(ipforward_rt.ro_rt);
896             ipforward_rt.ro_rt = 0;
897         }
898         sin->sin_family = AF_INET;
899         sin->sin_len = sizeof(*sin);
900         sin->sin_addr = ip->ip_dst;
901         rtalloc(&ipforward_rt);

```

图8-17 `ip_forward` 函数：路由选择

```

902         if (ipforward_rt.ro_rt == 0) {
903             icmp_error(m, ICMP_UNREACH, ICMP_UNREACH_HOST, dest, 0);
904             return;
905         }
906         rt = ipforward_rt.ro_rt;
907     }
908     /*
909      * Save at most 64 bytes of the packet in case
910      * we need to generate an ICMP message to the src.
911      */
912     mcopy = m_copy(m, 0, imin((int) ip->ip_len, 64));
913     ip_ifmatrix[rt->rt_ifp->if_index +
914                 if_index * m->m_pkthdr.rcvif->if_index]++;
ip_input.c

```

图8-17 (续)

这就产生了一个问题：在 Internet 上，最长的路径有多长？这个度量称为网络的直径(diameter)。除了通过实验外无法知道直径的大小。[Olivier 1994]中有37跳的路径。

2. 减小TTL

885-890 由于转发时不再需要分组的标识符，所以标识符又被转换回网络字节序。但是当 ip_forward 发送包含无效 IP 首部的 ICMP 差错报文时，分组的标识符又应该是正确的顺序。

Net/3 漏做了对已被 ipintr 转换成主机字节序的 ip_len 的转换。作者注意到在大头机器上，这不会产生问题，因为从未对字节进行过转换。但在小头机器如 386 上，这个小的漏洞允许交换了字节的值在 ICMP 差错中的 IP 首部中。返回从运行在 386 上的 SVR4(可能是 Net/1 码)和 AIX3.2(4.3BSD Reno 码)返回的 ICMP 分组中可以观察到这个小的漏洞。

如果 ip_ttl 达到 1(IP TTL DEC)，则向发送方返回一个 ICMP 超时报文，并丢掉该分组。否则，ip_forward 把 ip_ttl 减去 IPTTLDEC。

系统不接受 TTL 为 0 的 IP 数据报，但 Net/3 在即使出现这种情况时也能生成正确的 ICMP 差错，因为 p_ttl 是在分组被认为是在本地交付之后和被转发之前检测的。

3. 定位下一跳

891-907 IP 转发算法把最近的路由缓存在全局 route 结构的 ipforward_rt 中，在可能时应用于当前分组。研究表明连续分组趋向于同一目的地址 ([Jain 和 Routhier 1986] 和 [Mogul 1991])，所以这种向后一个 (one-behind) 的缓存使路由查询的次数最少。如果缓存为空 (ipforward_rt) 或当前分组的目的地不是 ipforward_rt 中的路由，就取消前面的路由，ro_dst 被初始化成新的目的地，rtalloc 为当前分组的目的地找一个新路由。如果找不到路由，则返回一个 ICMP 主机不可达差错，并丢掉该分组。

908-914 由于在产生差错时，ip_output 要丢掉分组，所以 m_copy 复制分组的前 64 个字节，以便 ip_forward 发送 ICMP 差错报文。如果调用 m_copy 失败，ip_forward 并不终止。在这种情况下，不发送差错报文。ip_ifmatrix 记录在接口之间进行路由选择的分组的个数。具有接收和发送接口索引的计数器是递增的。

重定向报文

当主机错误地选择某个路由器作为分组的第一跳路由器时，该路由器向源主机返回一个 ICMP重定向报文。IP网络互连模型假定主机相对地并不知道整个互联网的拓扑结构，把维护正确路由选择的责任交给路由器。路由器发出重定向报文是向主机表明它为分组选择了一个不正确的路由。我们用图 8-18说明重定向报文。

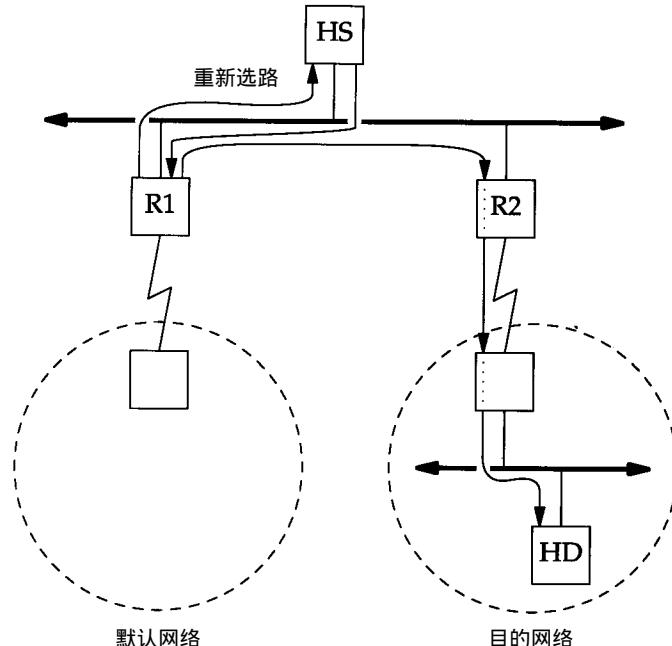


图8-18 路由器R1重定向主机HS使用路由器R2到达HD

通常，管理员对主机的配置是：把到远程网络的分组发送到某个默认路由器上。在图 8-18 中，主机 HS 上 R1 被配置成它的默认路由器。当 HS 首次向 HD 发送分组时，它不知道 R2 是合适的选择，而把分组发给 R1。R1 识别出差错，就把分组转发给 R2，并向 HS 发回一个重定向报文。接收到重定向报文后，HS 更新它的路由表，下一次发往 HD 的分组就直接发给 R2。

RFC 1122 推荐只有路由器才发重定向报文，而主机在接收到 ICMP重定向报文后必须更新它们的路由表(11.8节)。因为 Net/3 只在系统被配置成路由器时才调用 `ip_forward`，所以 Net/3 采用 RFC 1122 的推荐。

在图8-19中，`ip_forward`决定是否发重定向报文。

1. 在接收接口上离开吗

`915-929` 路由器识别重定向情况的规则很复杂。首先，只有在同一接口 (`rt_ifp`和 `rcvif`) 上接收或重发分组时，才能应用重定向。其次，被选择的路由本身必须没有被 ICMP重定向报文创建或修改过 (`RTF_DYNAMIC | RTF_MODIFIED`)，而且该路由也不能是到默认目的地的 (0.0.0.0)。这就保证系统在未授权时不会生成路由选择信息，并且不与其他系统共享自己的默认路由。

通常，路由选择协议使用特殊目的地址 0.0.0.0 定位默认路由。当到某目的地的某个路由不能使用时，与目的地 0.0.0.0 相关的路由就把分组定向到一个默认路由器上。

第18章对默认路由有详细的讨论。

全局整数 `ipsendredirects` 指定系统是否被授权发送重定向（第8.9节），`ipsendredirects`的默认值为1。当传给 `ip_forward` 的参数 `srcrt` 指明系统是对分组路由选择的源时，禁止系统重定向，因为假定源主机要覆盖中间路由器的选择。

```
ip_input.c
915  /*
916   * If forwarding packet is using same interface that it came in on,
917   * perhaps should send a redirect to sender to shortcut a hop.
918   * Only send redirect if source is sending directly to us,
919   * and if packet was not source routed (or has any options).
920   * Also, don't send redirect if forwarding using a default route
921   * or a route modified by a redirect.
922   */
923 #define satosin(sa) ((struct sockaddr_in *) (sa))
924     if (rt->rt_ifp == m->m_pkthdr.rcvif &&
925         (rt->rt_flags & (RTF_DYNAMIC | RTF_MODIFIED)) == 0 &&
926         satosin(rt_key(rt))->sin_addr.s_addr != 0 &&
927         ipsendredirects && !srcrt) {
928 #define RTA(rt) ((struct in_ifaddr *)(rt->rt_ifa))
929     u_long src = ntohl(ip->ip_src.s_addr);

930     if (RTA(rt) &&
931         (src & RTA(rt)->ia_subnetmask) == RTA(rt)->ia_subnet) {
932         if (rt->rt_flags & RTF_GATEWAY)
933             dest = satosin(rt->rt_gateway)->sin_addr.s_addr;
934         else
935             dest = ip->ip_dst.s_addr;
936         /* Router requirements says to only send host redirects */
937         type = ICMP_REDIRECT;
938         code = ICMP_REDIRECT_HOST;
939     }
940 }
```

ip_input.c

图8-19 `ip_forward` (续)

2. 发送重定向吗

930-931 这个测试决定分组是否产生于本地子网。如果源地址的子网掩码位和输出接口的地址相同，则两个地址位于同一IP网络中。如果源接口和输出的接口位于同一网络中，则该系统就不应该接收这个分组，因为源站可能已经把分组发给正确的第一跳路由器了。ICMP重定向报文告诉主机正确的第一跳目的地。如果分组产生于其他子网，则前一系统是个路由器，这个系统就不应该发重定向报文；差错由路由选择协议纠正。

在任何情况下，都要求路由器忽略重定向报文。尽管如此，当 `ipforwarding` 被置位时（也就是说，当它被配置成路由器时），Net/3并不丢掉重定向报文。

3. 选择合适的路由器

932-940 ICMP重定向报文中包含正确的下一个系统的地址，如果目的主机不在直接相连的网络上时，该地址是一个路由器的地址；当目的主机在直接相连的网络中时，该地址是主机地址。

RFC 792描述了重定向报文的4种类型：(1)网络；(2)主机；(3)TOS和网络；(4)TOS和主机。RFC 1009推荐在任何时候都不发送网络重定向报文，因为无法保证接收到重定向报文的主机能为目的网络找到合适的子网掩码。RFC 1122推荐主机把网络重定向看作是主机重定向，

以避免二义性。Net/3只发送主机重定向报文，并省略所有对TOS的考虑。在图8-20中，`ipintr`把分组和所有的ICMP报文提交给链路层。

```

941     error = ip_output(m, (struct mbuf *) 0, &ipforward_rt,
942                         IP_FORWARDING | IP_ALLOWBROADCAST, 0);
943     if (error)
944         ipstat.ips_cantforward++;
945     else {
946         ipstat.ips_forward++;
947         if (type)
948             ipstat.ips_redirectsent++;
949         else {
950             if (mcopy)
951                 m_freem(mcopy);
952             return;
953         }
954     }
955     if (mcopy == NULL)
956         return;
957     destifp = NULL;

958     switch (error) {

959     case 0:                      /* forwarded, but need redirect */
960         /* type, code set above */
961         break;

962     case ENETUNREACH:            /* shouldn't happen, checked above */
963     case EHOSTUNREACH:
964     case ENETDOWN:
965     case EHOSTDOWN:
966     default:
967         type = ICMP_UNREACH;
968         code = ICMP_UNREACH_HOST;
969         break;

970     case EMSGSIZE:
971         type = ICMP_UNREACH;
972         code = ICMP_UNREACH_NEEDFRAG;
973         if (ipforward_rt.ro_rt)
974             destifp = ipforward_rt.ro_rt->rt_ifp;
975         ipstat.ips_cantfrag++;
976         break;

977     case ENOBUFS:
978         type = ICMP_SOURCEQUENCH;
979         code = 0;
980         break;
981     }
982     icmp_error(mcopy, type, code, dest, destifp);
983 }
```

ip_input.c

图8-20 `ip_forward`(续)

重定向报文的标准化是在子网化之前，在一个非子网化的互联网中，网络重定向很有用，但在一个子网化的互联网中，由于重定向报文中没有有关子网掩码的信息，所以容易产生二义性。

4. 转发分组

941-954 现在，`ip_forward`有一个路由，并决定是否需要 ICMP重定向报文。`Ip_output`把分组发送到路由`ipforward_rt`所指定的下一跳。`IP_ALLOWBROADCAST`标志位允许被转发分组是个到某局域网的广播。如果`ip_output`成功，并且不需要发送任何重定向报文，则丢掉分组的前64字节，`ip_forward`返回。

5. 发送ICMP差错报文？

955-983 `ip_forward`可能会由于`ip_output`失败或重定向而发送ICMP报文。如果没有原始分组的复制（可能当要复制时，曾经缓存不足），则无法发送重定向报文，`ip_forward`返回。如果有重定向，`type`和`code`以前又被置位，但如果`ip_output`失败，`switch`语句基于从`ip_output`返回的值重新设置新的ICMP类型和码值。`icmp_error`发送该报文。来自失败的`ip_output`ICMP报文将覆盖任何重定向报文。

处理来自`ip_output`的差错的`switch`语句非常重要。它把本地差错翻译成适当的ICMP差错报文，并返回给分组的源站。图8-21对差错作了总结。第11章更详细地描述了ICMP报文。

当`ip_output`返回ENOBUFS时，Net/3通常生成ICMP源站抑制报文。Router Requirements(路由器需求)RFC [Almquist和Kastenholz 1994]不赞成源站抑制并要求路由器不产生这种报文。

来自 <code>ip_output</code> 的差错码	生成的ICMP报文	描述
EMSGSIZE	<code>ICMP_UNREACH_NEEDFRAG</code>	对所选的接口来说，发出的分组太大，并且禁止分片（第10章）
ENOBUFS	<code>ICMP_SOURCEQUENCH</code>	接口队列满或内核运行内存不足。本报文向源主机指示降低数据率
EHOSTUNREACH		找不到到主机的路由
ENETDOWN		路由指明的输出接口没在运行
EHOSTDOWN	<code>ICMP_UNREACH_HOST</code>	接口无法把分组发给选定的主机
default		所有不识别的差错均作为 <code>ICMP_UNREACH_HOST</code> 差错报告

图8-21 来自`ip_output` 的差错

8.6 输出处理：`ip_output`函数

IP输出代码从两处接收分组：`ip_forward`和运输协议（图8-1）。让`inet_sw[0].pr_output`能访问到IP输出操作似乎很有道理，但事实并非如此。标准的Internet传输协议（ICMP、IGMP、UDP和TCP）直接调用`ip_output`，而不查询`inet_sw`表。对标准Internet传输协议而言，`protosw`结构不必具有一般性，因为调用函数并不是在与协议无关的情况下接入IP的。在第20章中，我们将看到与协议无关的路由选择插口调用`pr_output`接入IP。

我们分三个部分描述`ip_output`：

- 首部初始化；
- 路由选择；和
- 源地址选择和分片。

8.6.1 首部初始化

图8-22显示了ip_output的第一部分，把选项与外出的分组合并，完成传输协议提交（不是ip_forward提交的）的分组首部。

44-59 传给ip_output的参数包括：m0，要发送的分组；opt，包含的IP选项；ro，缓存到目的地的路由；flags，见图8-23；imo，指向多播选项的指针，见第12章。

IP_FORWARDING被ip_forward和ip_mforward（多播分组转发）设置，并禁止ip_output重新设置任何IP首部字段。

```
ip_output.c
44 int
45 ip_output(m0, opt, ro, flags, imo)
46 struct mbuf *m0;
47 struct mbuf *opt;
48 struct route *ro;
49 int     flags;
50 struct ip_moptions *imo;
51 {
52     struct ip *ip, *mhip;
53     struct ifnet *ifp;
54     struct mbuf *m = m0;
55     int      hlen = sizeof(struct ip);
56     int      len, off, error = 0;
57     struct route iproute;
58     struct sockaddr_in *dst;
59     struct in_ifaddr *ia;

60     if (opt) {
61         m = ip_insertoptions(m, opt, &len);
62         hlen = len;
63     }
64     ip = mtod(m, struct ip *);
65     /*
66      * Fill in IP header.
67      */
68     if ((flags & (IP_FORWARDING | IP_RAWOUTPUT)) == 0) {
69         ip->ip_v = IPVERSION;
70         ip->ip_off &= IP_DF;
71         ip->ip_id = htons(ip_id++);
72         ip->ip_hl = hlen >> 2;
73         ipstat.ips_localout++;
74     } else {
75         hlen = ip->ip_hl << 2;
76     }

```

ip_output.c

图8-22 函数ip_output

标 志	描 述
<i>IP_FORWARDING</i>	这是一个转发过的分组
<i>IP_ROUTETOIF</i>	忽略路由表，直接路由到接口
<i>IP_ALLOWBROADCAST</i>	允许发送广播分组
<i>IP_RAWOUTPUT</i>	包含一个预构IP首部的分组

图8-23 ip_output : flag 值

`send`、`sendto`和`sendmsg`的`MSG_DONTROUTE`标志使`IP_ROUTETOIF`有效，并进行一次写操作(见16.4)，而`SO_DONTROUTE`插口选项使`IP_ROUTETOIF`有效，并在某个特定插口上进行任意的写操作(见8.8节)。该标志被传输协议传给`ip_output`。

`IP_ALLOWBROADCAST`标志可以被`SO_BROADCAST`插口选项(见8.8节)设置，但只被`UDP`提交。原来的`IP`默认地设置`IP_ALLOWBROADCAST`。`TCP`不支持广播，所以`IP_ALLOWBROADCAST`不能被`TCP`提交给`ip_output`。不存在广播的预请求标志。

1. 构造IP首部

60-73 如果调用程序提供任何`IP`选项，它们将被`ip_insertoptions`(见9.8节)与分组合并，并返回新的首部长度。

我们将在8.8节中看到，进程可以设置`IP_OPTIONS`插口选项来为一个插口指定`IP`选项。插口的运输层(`TCP`或`UDP`)总是把这些选项提交给`ip_output`。

被转发分组(`IP_FORWARDING`)或有预构首部(`IP_RAWOUTPUT`)分组的`IP`首部不能被`ip_output`修改。任何其他分组(例如，产生于这个主机的`UDP`或`TCP`分组)需要有几个`IP`首部字段被初始化。`ip_output`把`ip_v`设置成4(`IPVERSION`)，把DF位需要的`ip_off`清零，并设置成调用程序提供的值(见第10章)，给来自全局整数的`ip->ip_id`赋一个唯一的标识符，把`ip_id`加1。`ip_id`是在协议初始化时由系统时钟设置的(见7.8节)。`ip_h1`被设置成用32 bit字度量的首部长度。

`IP`首部的其他字段——长度、偏移、`TTL`、协议、`TOS`和目的地址——已经被传输协议初始化了。源地址可能没被设置，因为是在确定了到目的地的路由后选择的(图8-25)。

2. 分组已经包括首部

74-76 对一个已转发的分组(或一个有首部的原始`IP`分组)，首部长度(以字节数度量)被保存在`hlen`中，留给将来分片算法使用。

8.6.2 路由选择

在完成`IP`首部后，`ip_output`的下一个任务就是确定一条到目的地的路由。见图8-24所示。

```

77      /*
78      * Route packet.
79      */
80      if (ro == 0) {
81          ro = &iproute;
82          bzero((caddr_t) ro, sizeof(*ro));
83      }
84      dst = (struct sockaddr_in *) &ro->ro_dst;
85      /*
86      * If there is a cached route,
87      * check that it is to the same destination
88      * and is still up. If not, free it and try again.
89      */
90      if (ro->ro_rt && ((ro->ro_rt->rt_flags & RTF_UP) == 0 ||
91          dst->sin_addr.s_addr != ip->ip_dst.s_addr)) {
92          RTFREE(ro->ro_rt);
93          ro->ro_rt = (struct rtentry *) 0;
94      }

```

图8-24 `ip_output` (续)

```

95     if (ro->ro_rt == 0) {
96         dst->sin_family = AF_INET;
97         dst->sin_len = sizeof(*dst);
98         dst->sin_addr = ip->ip_dst;
99     }
100    /*
101     * If routing to interface only,
102     * short circuit routing lookup.
103    */
104 #define ifatoia(ifa)    ((struct in_ifaddr *)(ifa))
105 #define sintosa(sin)    ((struct sockaddr *) (sin))
106     if (flags & IP_ROUTETOIF) {
107         if ((ia = ifatoia(ifa_ifwithdstaddr(sintosa(dst)))) == 0 &&
108             (ia = ifatoia(ifa_ifwithnet(sintosa(dst)))) == 0) {
109             ipstat.ips_noroute++;
110             error = ENETUNREACH;
111             goto bad;
112         }
113         ifp = ia->ia_ifp;
114         ip->ip_ttl = 1;
115     } else {
116         if (ro->ro_rt == 0)
117             rtalloc(ro);
118         if (ro->ro_rt == 0) {
119             ipstat.ips_noroute++;
120             error = EHOSTUNREACH;
121             goto bad;
122         }
123         ia = ifatoia(ro->ro_rt->rt_ifa);
124         ifp = ro->ro_rt->rt_ifp;
125         ro->ro_rt->rt_use++;
126         if (ro->ro_rt->rt_flags & RTF_GATEWAY)
127             dst = (struct sockaddr_in *) ro->ro_rt->rt_gateway;
128     }

```

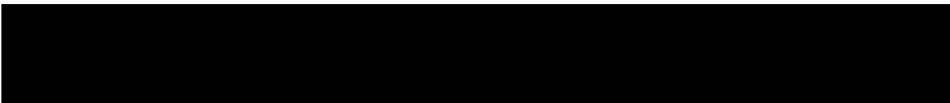

ip_output.c

图8-24 (续)

1. 验证高速缓存中的路由

77-99 `ip_output`可能把一条在高速缓存中的路由作为 `ro`参数来提供。在第24章中，我们将看到UDP和TCP维护一个与各插口相关的路由缓存。如果没有路由，则 `ip_output`把`ro`设置成指向临时`route`结构`iproute`。

如果高速缓存中的目的地不是去当前分组的目的地，就把该路由丢掉，新的目的地址放在`dst`中。

2. 旁路路由选择

100-114 调用方可通过设置`IP_ROUTE_TO_I`标志(见8.8节)禁止对分组进行路由选择。`ip_output`必须找到一个与分组中指定目的地网络直接相连的接口。`ifa_ifwithdstaddr`搜索点到点接口，而`in_ifwithnet`搜索其他接口。如果任一函数找到与目的网络相连的接口，就返回`ENETUNREACH`；否则，`ifp`指向选定的接口。

这个选项允许路由选择协议绕过本地路由表，并使分组通过某特定接口退出系

统。通过这个方法，即使本地路由表不正确，也可以与其他路由器交换路由选择信息。

3. 本地路由

115-122 如果分组正被路由选择(`IP_ROUTETOIF`为关状态)，并且没有其他缓存的路由，则`rtalloc`找到一条到`dst`指定地址的路由。如果`rtalloc`没找到路由，则`ip_output`返回`EHOSTUNREACH`。如果`ip_forward`调用`ip_output`，就把`EHOSTUNREACH`转换成ICMP差错。如果某个传输协议调用`ip_output`，就把差错传回给进程(图8-21)。

123-128 `ia`被设成指向选定接口的地址(`ifaddr`结构)，而`ifp`指向接口的`ifnet`结构。如果下一跳不是分组的最终目的地，则把`dst`改成下一跳路由器地址，而不再是分组最终目的地址。IP首部内的目的地址不变，但接口层必须把分组提交给`dst`，即下一跳路由器。

8.6.3 源地址选择和分片

`ip_output`的最后一部分如图 8-25所示，保证IP首部有一个有效源地址，然后把分组提交给与路由相关的接口。如果分组比接口的 MTU大，就必须对分组分片，然后一片一片地发送。像前面的重装代码一样，我们省略了分片代码，并推迟到第 10章再讨论。

ip_output.c

```

212     /*
213      * If source address not specified yet, use address
214      * of outgoing interface.
215      */
216     if (ip->ip_src.s_addr == INADDR_ANY)
217         ip->ip_src = IA_SIN(ia)->sin_addr;
218     /*
219      * Look for broadcast address and
220      * verify user is allowed to send
221      * such a packet.
222      */
223     if (in_broadcast(dst->sin_addr, ifp)) {
224         if (((ifp->if_flags & IFF_BROADCAST) == 0) { /* interface check */
225             error = EADDRNOTAVAIL;
226             goto bad;
227         }
228         if (((flags & IP_ALLOWBROADCAST) == 0) { /* application check */
229             error = EACCES;
230             goto bad;
231         }
232         /* don't allow broadcast messages to be fragmented */
233         if ((u_short) ip->ip_len > ifp->if_mtu) {
234             error = EMSGSIZE;
235             goto bad;
236         }
237         m->m_flags |= M_BCAST;
238     } else
239         m->m_flags &= ~M_BCAST;

240     sendit:
241     /*
242      * If small enough for interface, can just send directly.
243      */
244     if ((u_short) ip->ip_len <= ifp->if_mtu) {

```

图8-25 ip_output(续)

```

245     ip->ip_len = htons((u_short) ip->ip_len);
246     ip->ip_off = htons((u_short) ip->ip_off);
247     ip->ip_sum = 0;
248     ip->ip_sum = in_cksum(m, hlen);
249     error = (*ifp->if_output) (ifp, m,
250                                 (struct sockaddr *) dst, ro->ro_rt);
251     goto done;
252 }

[REDACTED]

339 done:
340     if (ro == &iproute && (flags & IP_ROUTETOIF) == 0 && ro->ro_rt)
341         RTFREE(ro->ro_rt);
342     return (error);
343 bad:
344     m_freem(m0);
345     goto done;
346 }

```

ip_output.c

图8-25 (续)

1. 选择源地址

212-239 如果没有指定 `ip_src`，则 `ip_output` 选择输出接口的 IP 地址 `ia` 作为源地址。这不能在早期填充其他 IP 首部字段时做，因为那时还没有选定路由。转发的分组通常都有一个源地址，但是，如果发送进程没有明确指定源地址，产生于本地主机的分组可能没有源地址。

如果目的 IP 地址是一个广播地址，则接口必须支持广播 (`IFF_BROADCAST`, 图3-7)，调用方必须明确使能广播 (`IP_ALLOWBROADCAST`, 图8-23)，而分组必须足够小，无需分片。

最后的测试是一个策略决定。IP 协议规范中没有明确禁止对广播分组的分片。但是，要求分组适合接口的 MTU，就增加了广播分组被每个接口接收的机会，因为接收一个未损坏的分组的机会要远大于接收两个或多个未损坏分组的机会。

如果这些条件都不满足，就扔掉该分组，把 `EADDRNOTAVAIL`、`EACCES` 和 `EMSGSIZE` 返回给调用方。否则，设置输出分组的 `M_BCAST`，告诉接口输出函数把该分组作为链路级广播发送。21.20 节中，我们将看到 `arpresolve` 把 IP 广播地址翻译成以太网广播地址。

如果目的地址不是广播地址，则 `ip_output` 把 `M_BCAST` 清零。

如果 `M_BCAST` 没有清零，则对一个作为广播到达的请求分组的应答将可能作为一个广播被返回。我们将在第 11 章中看到，ICMP 应答将以这种方式作为 TCP RST 分组(见26.9节)在请求分组内构造。

2. 发送分组

240-252 如果分组对所选择的接口足够小，`ip_len` 和 `ip_off` 被转换成网络字节序，IP 检验和与 `in_cksum`(见8.7节)一起计算，把分组提交给所选接口的 `if_output` 函数。

3. 分片分组

253-338 大分组在被发送之前必须分片。这里我们省略这段代码，推迟到第 10 章讨论。

4. 清零

339-346 对每一路由入口都有一个引用计数。我们提到过，如果参数 `ro` 为空，`ip_`

output 可能会使用一个临时的 route 结构(iproute)。如果需要，RTFREE 发布 iproute 内的路由入口，并把引用计数减 1。Bad 处的代码在返回前扔掉当前分组。

引用计数是一个存储器管理技术。程序员必须对一个数据结构的外部引用计数；当计数返回为 0 时，就可以安全地把存储器返回给空存储器池。引用计数要求程序员遵守一些规定，在恰当的时机增加或减小引用计数。

8.7 Internet 检验和：in_cksum 函数

有两个操作占据了处理分组的主要时间：复制数据和计算检验和 ([Kay 和 Pasquale 1993])。mbuf 数据结构的灵活性是 Net/3 中减少复制操作的主要方法。由于对硬件的依赖，所以检验和的有效计算相对较难。Net/3 中有几种 in_cksum 的实现(图 8-26)。

版 本	源 文件
portable C	sys/netinet/in_cksum.c
SPARC	net3/sparc/sparc/in_cksum.c
68k	net3/luna68k/luna68k/in_cksum.c
VAX	sys/vax/vax/in_cksum.c
Tahoe	sys/tahoe/tahoe/in_cksum.c
HP 3000	sys/hp300/hp300/in_cksum.c
Intel 80386	sys/i386/i386/in_cksum.c

图 8-26 在 Net/3 中的几个 in_cksum 版本

即使是可移植 C 实现也已经被相当好地优化了。RFC 1071 [Braden、Borman 和 Partridge 1988] 和 RFC 1141 [Mallory 和 Kullberg 1990] 讨论了 Internet 检验和函数的设计和实现。RFC 1141 被 RFC 1624 [Rijsinghani 1994] 修正。从 RFC 1071：

- 1) 把被检验的相邻字节成对配成 16 bit 整数，就形成了这些整数的二进制反码的和。
- 2) 为生成检验和，把检验和字段本身清零，把 16 bit 的二进制反码的和以及这个和的二进制反码放到检验和字段。
- 3) 为检验检验和，对同一组字节计算它们的二进制反码的和。如果结果为全 1 (在二进制反码运算中 -0，见下面的解释)，则检验成功。

简而言之，当对用二进制反码表示的整数进行加法运算时，把两个整数相加后再加上进位就得到加法的结果。在二进制反码运算中，只要把每一位求补就得到一个数的反。所以在二进制反码运算中，0 有两种表示方法：全 0，和全 1。有关二进制反码的运算和表示的详细讨论见 [Mano 1982]。

检验和算法在发送分组之前计算出要放在 IP 首部检验和字段的值。为了计算这个值，先把首部的检验和字段设为 0，然后计算整个首部 (包括选项) 的二进制反码的和。把首部作为一个 16 bit 整数数组来处理。让我们把这个计算结果称为 a 。因为检验和字段被明确设为 0，所以 a 是除了检验和字段外所有 IP 首部字段的和。 a 的二进制反码，用 $-a$ 表示，被放在检验和字段中，发送该分组。

如果在传输过程中没有比特位被改变，则在目的地计算的检验和应该等于 $(a + -a)$ 的二进制反码。在二进制反码运算中 $(a + -a)$ 的和是 -0 (全 1)，而它的二进制反码应该等于 0 (全 0)。所以在目的地，一个没有损坏分组计算出来的检验和应该总是为 0。这就是我们在图 8-12 中看到

的。下面的C代码(不是Net/3的内容)是这个算法的一种原始的实现：

```

1 unsigned short
2 cksum(struct ip *ip, int len)
3 {
4     long      sum = 0;           /* assume 32 bit long, 16 bit short */
5
6     while (len > 1) {
7         sum += *((unsigned short *) ip)++;
8         if (sum & 0x80000000) /* if high-order bit set, fold */
9             sum = (sum & 0xFFFF) + (sum >> 16);
10        len -= 2;
11    }
12
13    if (len)                  /* take care of left over byte */
14        sum += (unsigned short) *(unsigned char *) ip;
15
16    while (sum >> 16)
17        sum = (sum & 0xFFFF) + (sum >> 16);
18
19    return ~sum;
20 }
```

图8-27 IP检验和计算的一种原始的实现

1-16 这里唯一提高性能之处在于累计sum高16 bit的进位。当循环结束时，累计的进位被加在低16 bit上，直到没有其他进位发生。RFC 1071称此为延迟进位(deferred carries)。在没有有进位加法指令或检测进位代价很大的机器上，这个技术非常有效。

现在我们显示Net/3的可移植C版本。它使用了延迟进位技术，作用于存储在一个 mbuf链中的分组。

42-140 我们的新检验和实现假定所有被检验字节存储在一个连续缓存而不是 mbuf中。这个版本的检验和计算采用相同的底层算法来正确地处理 mbuf：用32bit整数的延迟进位对16 bit字作加法。对奇数个字节的 mbuf，多出来的一个字节被保存起来，并与下一个 mbuf的第一个字节配对。因为在大多数体系结构中，对16 bit字的不对齐访问是无效的，甚至会产生严重差错，所以不对齐字节将被保存，in_cksum继续加上下一个对齐的字。当这种情况发生时，in_cksum总是很小心地交换字节，保证位于奇数和偶数位置的字节被放在单独的和字节中，以满足检验和算法的要求。

循环展开

93-115 函数中的三个while循环在每次迭代中分别在和中加上16个字、4个字和1个字。展开的循环减小了循环的耗费，在某些体系结构中可能比一个直接循环要快得多。但代价是代码长度和复杂性增大。

```

42 #define ADDCARRY(x)  (x > 65535 ? x -= 65535 : x)
43 #define REDUCE {l_util.l = sum; sum = l_util.s[0] + l_util.s[1]; ADDCARRY(sum);}
44 int
45 in_cksum(m, len)
46 struct mbuf *m;
47 int      len;
48 {
49     u_short *w;
50     int      sum = 0;
```

图8-28 IP检验和计算的一个优化的可移植C程序

```

51     int      mlen = 0;
52     int      byte_swapped = 0;
53
54     union {
55         char    c[2];
56         u_short s;
57     } s_util;
58     union {
59         u_short s[2];
60         long    l;
61     } l_util;
62
63     for ( ; m && len; m = m->m_next) {
64         if (m->m_len == 0)
65             continue;
66         w = mtod(m, u_short *);
67         if (mlen == -1) {
68             /*
69              * The first byte of this mbuf is the continuation of a
70              * word spanning between this mbuf and the last mbuf.
71              *
72              * s_util.c[0] is already saved when scanning previous mbuf.
73              */
74             s_util.c[1] = *(char *) w;
75             sum += s_util.s;
76             w = (u_short *) ((char *) w + 1);
77             mlen = m->m_len - 1;
78             len--;
79         } else
80             mlen = m->m_len;
81         if (len < mlen)
82             mlen = len;
83         len -= mlen;
84         /*
85          * Force to even boundary.
86          */
87         if ((1 & (int) w) && (mlen > 0)) {
88             REDUCE;
89             sum <= 8;
90             s_util.c[0] = *(u_char *) w;
91             w = (u_short *) ((char *) w + 1);
92             mlen--;
93             byte_swapped = 1;
94         }
95         /*
96          * Unroll the loop to make overhead from
97          * branches &c small.
98          */
99         while ((mlen -= 32) >= 0) {
100             sum += w[0]; sum += w[1]; sum += w[2]; sum += w[3];
101             sum += w[4]; sum += w[5]; sum += w[6]; sum += w[7];
102             sum += w[8]; sum += w[9]; sum += w[10]; sum += w[11];
103             sum += w[12]; sum += w[13]; sum += w[14]; sum += w[15];
104             w += 16;
105         }
106         mlen += 32;
107         while ((mlen -= 8) >= 0) {
108             sum += w[0]; sum += w[1]; sum += w[2]; sum += w[3];
109             w += 4;

```

图8-28 (续)

```

108         }
109         mlen += 8;
110         if (mlen == 0 && byte_swapped == 0)
111             continue;
112         REDUCE;
113         while ((mlen -= 2) >= 0) {
114             sum += *w++;
115         }
116         if (byte_swapped) {
117             REDUCE;
118             sum <= 8;
119             byte_swapped = 0;
120             if (mlen == -1) {
121                 s_util.c[1] = *(char *) w;
122                 sum += s_util.s;
123                 mlen = 0;
124             } else
125                 mlen = -1;
126             } else if (mlen == -1)
127                 s_util.c[0] = *(char *) w;
128         }
129         if (len)
130             printf("cksum: out of data\n");
131         if (mlen == -1) {
132             /* The last mbuf has odd # of bytes. Follow the standard (the odd
133                byte may be shifted left by 8 bits or not as determined by
134                endian-ness of the machine) */
135             s_util.c[1] = 0;
136             sum += s_util.s;
137         }
138         REDUCE;
139         return (~sum & 0xffff);
140     }

```

in_cksum.c

图8-28 (续)

其他优化

RFC 1071提到两个在Net/3中没有出现的优化：联合的有检验和的复制操作和递增的检验和更新。对IP首部检验和来说，把复制和检验和操作结合起来并不像对TCP和UDP那么重要，因为后者覆盖了更多的字节。在23.12节中对这个合并的操作进行了讨论。[Partridge和Pink 1993]报告了IP首部检验和的一个内联版本比调用更一般的*in_cksum*函数要快得多，只需6~8个汇编指令就可以完成(标准的20字节IP首部)。

检验和算法设计允许改变分组，并在不重新检查所有字节的情况下更新检验和。RFC 1071对该问题进行简明的讨论。RFC 1141和1624中有更详细的讨论。该技术的一个典型应用是在分组转发的过程中。通常情况下，当分组没有选项时，转发过程中只有TTL字段发生变化。在这种情况下，可以只用一次循环进位，重新计算检验和。

为了进一步提高效率，递增的检验和也有助于检测到被有差错的软件破坏的首部。如果递增地计算检验和，则下一个系统可以检测到被破坏的首部。但是如果不是递增计算检验和，那么检验和中就包含了差错的字节，检测不到有问题的首部。UDP和TCP使用的检验和算法在最终目的主机检测到该差错。我们将在第23和25章看到UDP和TCP检验和包含了IP首部的几个部分。

使用硬件有进位加法指令一次性计算 32 bit 检验和的检验和函数，可参见 `./sys/vax/vax/in_cksum.c` 文件中 VAX 实现的 `in_cksum`。

8.8 `setsockopt` 和 `getsockopt` 系统调用

Net/3 提供 `setsockopt` 和 `getsockopt` 两个系统调用来访问一些网络互连的性质。这两个系统调用支持一个动态接口，进程可用该动态接口来访问某种网络互连协议的一些性质，而标准系统调用通常不支持该协议。这两个调用的原型是：

```
int setsockopt(int s, int level, int optname, void *optval, int optlen);
int getsockopt(int s, int level, int optname, const void *optval, int optlen);
```

大多数插口选项只影响它们在其上发布的插口。与 `sysctl` 参数相比，后者影响整个系统。与多播相关的插口选项是一个明显的例外，将在第 12 章中讨论。

`setsockopt` 和 `getsockopt` 设置和获取通信栈所有层上的选项。Net/3 按照与 `s` 相关的协议和由 `level` 指定的标识符处理选项。图 8-29 列出了在我们讨论的协议中 `level` 可能取得的值。

在第 17 章中，我们描述了 `setsockopt` 和 `getsockopt` 的实现，但在其他适当章节中讨论有关选项的实现。本章讨论访问 IP 性质的选项。

字段	协议	level	函数	参考
任意	任意	<code>SOL_SOCKET</code>	<code>soisetopt</code> 和 <code>sogetopt</code>	图 17-5 和 图 17-11
IP	UDP	<code>IPPROTO_IP</code>	<code>ip_ctloutput</code>	图 8-31
	TCP	<code>IPPROTO_TCP</code> <code>IPPROTO_IP</code>	<code>tcp_ctloutput</code> <code>ip_ctloutput</code>	30.6 节 图 8-31
	原始 IP ICMP IGMP	<code>IPPROTO_IP</code>	<code>rip_ctloutput</code> 和 <code>ip_ctloutput</code>	32.8 节

图 8-29 `soisetopt` 和 `sogetopt` 参数

我们把本书中出现的所有插口选项总结在图 8-30 中。该图显示了 `IPPROTO_IP` 级的选项。选项出现在第 1 列，`optval` 指向变量的数据类型出现在第 2 列，第 3 列显示的是处理该选项的函数。

选 项 名	Optval 类型	函 数	描 述
<code>IP_OPTIONS</code>	<code>void*</code>	<code>in_pcbopts</code>	设置或获取发出的数据报中的 IP 选项
<code>IP_TOS</code>	<code>int</code>	<code>ip_ctloutput</code>	设置或获取发出的数据报中的 IP TOS
<code>IP_TTL</code>	<code>int</code>	<code>ip_ctloutput</code>	设置或获取发出的数据报中的 IP TTL
<code>TP_RECVDSTADDR</code>	<code>int</code>	<code>ip_ctloutput</code>	使能或禁止 IP 目的地址(只有 UDP)的排队
<code>IP_RECVOPTS</code>	<code>int</code>	<code>ip_ctloutput</code>	使能或禁止对到达 IP 选项作为控制信息的排队(只对 UDP；还没有实现)
<code>IP_RECVRETOPTS</code>	<code>int</code>	<code>ip_ctloutput</code>	使能或禁止与到达数据报相关的逆源路由(只对 UDP；还没有实现)

图 8-30 插口选项：`SOCK_RAW`、`SOCK_DGRAM` 和 `SOCK_STREAM` 插口的 `IPPROTO_IP` 级

图 8-31 显示了用于处理大部分 `IPPROTO_IP` 选项的 `ip_ctloutput` 函数的整个结构。在 32.8 节中我们给出与 `SOCK_RAW` 插口一起使用的 `IPPROTO_IP` 选项。

ip_output.c

```

431 int
432 ip_ctloutput(op, so, level, optname, mp)
433 int     op;
434 struct socket *so;
435 int     level, optname;
436 struct mbuf **mp;
437 {
438     struct inpcb *inp = sotoinpcb(so);
439     struct mbuf *m = *mp;
440     int     optval;
441     int     error = 0;
442     if (level != IPPROTO_IP) {
443         error = EINVAL;
444         if (op == PRCO_SETOPT && *mp)
445             (void) m_free(*mp);
446     } else
447         switch (op) {
448             case PRCO_SETOPT:
449                 switch (optname) {
450
451                     /* PRCO_SETOPT processing (Figures 8.32 and 12.17) */
452
453
454                 freeit:
455                 default:
456                     error = EINVAL;
457                     break;
458                 }
459                 if (m)
460                     (void) m_free(m);
461                 break;
462
463             case PRCO_GETOPT:
464                 switch (optname) {
465
466                     /* PRCO_SETOPT processing (Figures 8.33 and 12.17) */
467
468
469                 default:
470                     error = ENOPROTOOPT;
471                     break;
472                 }
473                 break;
474             }
475         }
476     return (error);
477 }

```

*ip_output.c*图8-31 *ip_ctloutput* 函数：概貌

431-447 *ip_ctloutput*的第一个参数`op`，可以是`PRCO_SETOPT`或者`PRCO_GETOPT`。第二个参数`so`，指向向其发布请求的插口。`level`必须是`IPPROTO_IP`。`Optname`是要改变或要检索的选项，`mp`间接地指向一个含有与该选项相关数据的`mbuf`，`m`被初始化为指向由`*mp`引用的`mbuf`。

448-500 如果在调用`setsockopt`时指定了一个无法识别的选项(因此，在`switch`中调用`PRCO_SETOPT`语句)，*ip_ctloutput*释放掉所有调用方传来的缓存，并返回`EINVAL`。

501-553 getsockopt传来的无法识别的选项导致ip_ctloutput返回ENOPROTOOPT。在这种情况下，调用方释放mbuf。

8.8.1 PRCO_SETOPT的处理

对PRCO_SETOPT的处理如图8-32所示。

```

450         case IP_OPTIONS:
451             return (ip_pcbopts(&inp->inp_options, m));
452         case IP_TOS:
453         case IP_TTL:
454         case IP_RECVOPTS:
455         case IP_RECVRETOPTS:
456         case IP_RECVDSTADDR:
457             if (m->m_len != sizeof(int))
458                 error = EINVAL;
459             else {
460                 optval = *mtod(m, int *);
461                 switch (optname) {
462                     case IP_TOS:
463                         inp->inp_ip.ip_tos = optval;
464                         break;
465                     case IP_TTL:
466                         inp->inp_ip.ip_ttl = optval;
467                         break;
468 #define OPTSET(bit) \
469     if (optval) \
470         inp->inp_flags |= bit; \
471     else \
472         inp->inp_flags &= ~bit;
473                     case IP_RECVOPTS:
474                         OPTSET(INP_RECVOPTS);
475                         break;
476                     case IP_RECVRETOPTS:
477                         OPTSET(INP_RECVRETOPTS);
478                         break;
479                     case IP_RECVDSTADDR:
480                         OPTSET(INP_RECVDSTADDR);
481                         break;
482                 }
483             }
484         break;

```

ip_output.c

图8-32 ip_ctloutput 函数：处理PRCO_SETOPT

450-451 IP_OPTIONS是由ip_pcbopts处理的(图9-32)。

452-484 IP_TOS、IP_TTL、IP_RECVOPTS、IP_RECVRETOPTS以及IP_RECVDSTADDR选项都需要在由m指向的mbuf中有一个整数。该整数储存在optval中，用来改变与插口有关的ip_tos和ip_ttl的值，或者用来设置或复位与插口相关的INP_RECVOPTS、INP_RECVRETOPTS和INP_RECVDSTADDR标志位。如果optval是非零(或0)，则宏OPTSET设置(或复位)指定的比特。

图8-30中显示没有实现IP_RECVOPTS和IP_RECVRETOPTS。在第23章中，我

们将看到UDP忽略了这些选项的设置。

8.8.2 PRCO_GETOPT的处理

图8-33显示的一段代码完成了当指定 PRCO_GETOPT时对IP选项的检索。

```

503         case IP_OPTIONS:
504             *mp = m = m_get(M_WAIT, MT_SOOPTS);
505             if (inp->inp_options) {
506                 m->m_len = inp->inp_options->m_len;
507                 bcopy(mtod(inp->inp_options, caddr_t),
508                       mtod(m, caddr_t), (unsigned) m->m_len);
509             } else
510                 m->m_len = 0;
511             break;
512
513         case IP_TOS:
514         case IP_TTL:
515         case IP_RECVOPTS:
516         case IP_RECVRETOPTS:
517         case IP_RECVDSTADDR:
518             *mp = m = m_get(M_WAIT, MT_SOOPTS);
519             m->m_len = sizeof(int);
520             switch (optname) {
521                 case IP_TOS:
522                     optval = inp->inp_ip.ip_tos;
523                     break;
524                 case IP_TTL:
525                     optval = inp->inp_ip.ip_ttl;
526                     break;
527 #define OPTBIT(bit) (inp->inp_flags & bit ? 1 : 0)
528                 case IP_RECVOPTS:
529                     optval = OPTBIT(INP_RECVOPTS);
530                     break;
531                 case IP_RECVRETOPTS:
532                     optval = OPTBIT(INP_RECVRETOPTS);
533                     break;
534                 case IP_RECVDSTADDR:
535                     optval = OPTBIT(INP_RECVDSTADDR);
536                     break;
537             }
538             *mtod(m, int *) = optval;
539             break;

```

ip_output.c

图8-33 ip_ctloutput 函数：PRCO_GETOPT 的处理

503-538 对IP_OPTIONS，ip_ctloutput返回一个缓存，该缓存中包含了与该插口相关的选项的备份。对其他选项，ip_ctloutput返回ip_tos和ip_ttl的值，或与该选项相关标志的状态。返回的值放在由m指向的mbuf中。如果在inp_flags中的bit是打开(或关闭)的，则宏OPTBIT将返回1(或0)。

8.9 ip_sysctl函数

图7-27显示，在调用sysctl中，当协议和协议族的标识符是0时，就调用ip_sysctl函

数。图8-34显示了ip_sysctl支持的三个函数。

sysctl常量	Net/3变量	描述
IPCTL_FORWARDING	ipforwarding	系统是否转发IP分组？
IPCTL_SENDREDIRECTS	ipsendredirects	系统是否发ICMP重定向？
IPCTL_DEFTTL	ip_defttl	IP分组的默认TTL

图8-34 sysctl 参数

图8-35显示了ip_sysctl函数。

```

984 int
985 ip_sysctl(name, namelen, oldp, oldlenp, newp, newlen)
986 int     *name;
987 u_int    namelen;
988 void    *oldp;
989 size_t   *oldlenp;
990 void    *newp;
991 size_t   newlen;
992 {
993     /* All sysctl names at this level are terminal. */
994     if (namelen != 1)
995         return (ENOTDIR);
996
997     switch (name[0]) {
998         case IPCTL_FORWARDING:
999             return (sysctl_int(oldp, oldlenp, newp, newlen, &ipforwarding));
1000        case IPCTL_SENDREDIRECTS:
1001            return (sysctl_int(oldp, oldlenp, newp, newlen,
1002                                &ipsendredirects));
1003        case IPCTL_DEFTTL:
1004            return (sysctl_int(oldp, oldlenp, newp, newlen, &ip_defttl));
1005        default:
1006            return (EOPNOTSUPP);
1007    }
1008 } 
```

ip_input.c

图8-35 ip_sysctl 函数

因为ip_sysctl并不把sysctl请求转发给其他函数，所以在name中只能有一个成员。否则返回ENOTDIR。

Switch语句选择恰当的调用sysctl_int，它访问或修改ipforwarding、ipsendredirects或ip_defttl。对无法识别的选项返回EOPNOTSUPP。

8.10 小结

IP是一个最佳的数据报服务，它为所有其他Internet协议提供交付机制。标准IP首部长度为20字节，但可跟最多40字节的选项。IP可以把大的数据报分片发送，并在目的地重装分片。对选项处理的讨论放在第9章和第10章讨论分片和重装。

ipintr保证IP首部到达时未经破坏，通过把目的地址与系统接口地址及其他几个广播地址比较来确定它们是否到达最终目的地。ipintr把到达最终目的地的数据报传给分组内指定的运输层协议。如果系统被配置成路由器，就把还没有到达最终目的地的分组发给

`ip_forward`转发到最终目的地。分组有一个受限的生命期。如果 TTL 字段变成 0，则 `ip_forward` 就丢掉该分组。

许多 Internet 协议都使用 Internet 检验和函数，Net/3 用 `in_cksum` 实现。IP 检验和只覆盖头部(和选项)，不覆盖数据，数据必须由传输协议级的检验和保护。作为 IP 中最耗时的操作，检验和函数通常要对不同的平台进行优化。

习题

- 8.1 当没有为任何接口分配 IP 地址时，IP 是否该接收广播分组？
- 8.2 修改 `ip_forward` 和 `ip_output`，当转发一个没有选项的分组时，对 IP 检验和进行递增的更新。
- 8.3 当拒绝转发分组时，为什么需要检测链路级广播（某缓存中的 `M_BCAST` 标志）和 IP 级广播(`in_canforward`)？在何种情况下，把一个具有 IP 单播目的地的分组作为一个链路层广播接收？
- 8.4 当一个 IP 分组到达时有检验和差错，为什么不向发送方返回一个差错信息？
- 8.5 假定一个多接口主机上的某个进程为它发出的分组选择了一个明确的源地址。而且，假定是通过一个接口而不是作为分组源地址所选择的地址到达的。当第一跳路由器发现分组应该到另一个路由器时，会发生什么情况？会向主机发送重定向报文吗？
- 8.6 一个新的主机被连到一个已划分子网的网络中，并被配置成完成路由选择的功能 (`ipforwarding` 等于 1)，但它的网络接口没有分配子网掩码。当该主机接收一个子网广播分组时会出现什么情况？
- 8.7 图 8-17 中，在检测 `ip_ttl` 后(与之前相比)，为什么需要把它减 1？
- 8.8 如果两个路由器都认为对方是分组的最佳下一跳目的地，将发生什么情况？
- 8.9 图 8-14 中，对一个到达 SLIP 接口的分组，不检测哪些地址？有没有其他在图 8-14 中没有列出的地址被检测？
- 8.10 `ip_forward` 在调用 `icmp_error` 之前，把分片的 `id` 从主机字节序转换成网络字节序。为什么它不对分片的偏移进行转换？

第9章 IP选项处理

9.1 引言

第8章中提到，IP输入函数(ipintr)将在验证分组格式(检验和，长度等)之后，确定分组是否到达目的地之前，对选项进行处理。这表明，分组所遇到的每个路由器以及最终的目的主机都要对分组的选项进行处理。

RFC 791和1122指定了IP选项和处理规则。本章将讨论大多数IP选项的格式和处理。我们也将显示运输协议如何指定IP数据报内的IP选项。

IP分组内可以包含某些在分组被转发或被接收之前处理的可选字段。IP实现可以用任意顺序处理选项；Net/3按照选项在分组中出现的顺序处理选项。图9-1显示，标准IP首部之后最多可跟40字节的选项。

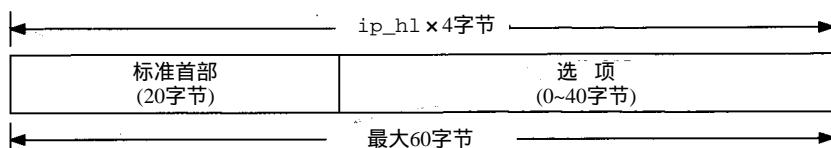


图9-1 一个IP首部可以有0~40字节的IP选项

9.2 代码介绍

两个首部描述了IP选项的数据结构。选项处理的代码出现在两个C文件中。图9-2列出了相关的文件。

文 件	描 述
netinet/ip.h	ip_timestamp结构
netinet/ip_var.h	ipoption结构
netinet/ip_input.c	选项处理
netinet/ip_output.c	ip_insertoptions函数

图9-2 本章讨论的文件

9.2.1 全局变量

图9-3描述了两个全局变量支持源路由的逆(reversal)。

变 量	数据类型	描 述
ip_nhops	int	以前的源路由跳计数
ip_srcrt	struct ip_srcrt	以前的源路由

图9-3 本章引入的全局变量

9.2.2 统计量

选项处理代码更新的唯一的统计量是 ipstat 结构中的 ips_badoptions，如图 8-4 所示。

9.3 选项格式

IP 选项字段可能包含 0 个或多个单独选项。选项有两种类型，单字节和多字节，如图 9-4 中所示。

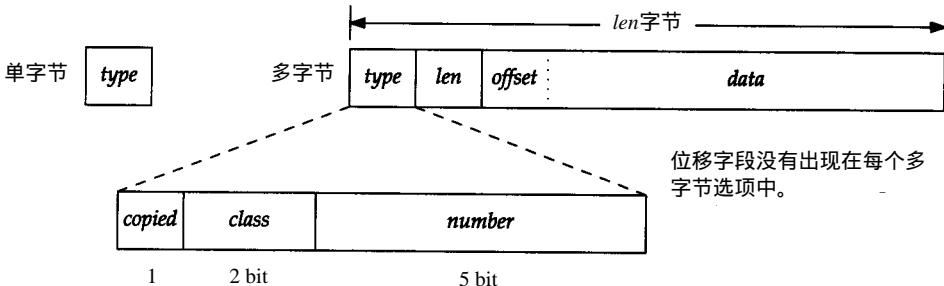


图 9-4 单字节和多字节 IP 选项的结构

所有选项都以 1 字节类型 (*type*) 字段开始。在多字节选项中，类型字段后面紧接着一个长度 (*len*) 字段，其他的字节是数据 (*data*)。许多选项数据字段的第一个字节是 1 字节的位移 (*offset*) 字段，指向数据字段内的某个字节。长度字节的计算覆盖了类型、长度和数据字段。类型被继续分成三个子字段：1 bit 备份 (*copied*) 标志、2 bit 类 (*class*) 字段和 5 bit 数字 (*number*) 字段。图 9-5 列出了目前定义的 IP 选项。前两个选项是单字节选项；其他的是多字节选项。

常量	类型		长度 (字节)	Net/3	描述
	十进制	二进制			
IPOPT_EOL	0-0-0 0	0-00-00000	1	•	选项表的结尾(EOL)
IPOPT_NOP	0-0-1 1	0-00-00001	1	•	无操作(NOP)
IPOPT_RR	0-0-7 7	0-00-00111	可变	•	记录路由
IPOPT_TS	0-2-4 68	0-10-00100	可变	•	时戳
IPOPT_SECURITY	1-0-2 130	1-00-00010	11	•	基本的安全
IPOPT_LSRR	1-0-3 131	1-00-00011	可变	•	宽松源路由和记录路由(LSRR)
	1-0-5 133	1-00-00101	可变	•	扩展的安全
IPOPT_SATID	1-0-8 136	1-00-01000	4		流标识符
IPOPT_SSRR	1-0-9 137	1-00-01001	可变	•	严格源路由和记录路由(SSRR)

图 9-5 RFC 791 定义的 IP 选项

第 1 列显示了 Net/3 的选项常量，第 2 列和第 3 列是该类型的十进制和二进制值，第 4 列是选项的长度。Net/3 列显示的是在 Net/3 中由 ip_dooptions 实现的选项。IP 必须自动忽略所有它不识别的选项。我们不描述 Net/3 没有实现的选项：安全和流 ID。流 ID 选项是过时的，安全选项主要只由美国军方使用。RFC 791 中有更多的讨论。

当 Net/3 对一个有选项的分组进行分片时（10.4 节），它将检查 copied 标志位。该标志位指出是否把所有选项都备份到每个分片的 IP 首部。*class* 字段把相关的

<i>class</i>	描述
0	控制
1	保留
2	查错和措施
3	保留

图 9-6 IP 选项内的
class 字段

选项按如图9-6所示进行分组。图9-5中，除时戳选项具有*class*为2外，所有选项都是*class*为0。

9.4 ip_dooptions函数

在图8-13中，我们看到 `ipintr` 在检测分组的目的地址之前调用 `ip_dooptions`。`ip_dooptions` 被传给一个指针 `m`，该指针指向某个分组，`ip_dooptions` 处理分组中它所知道的选项。如果 `ip_dooptions` 转发该分组，如在处理 LSRR 和 SSRR 选项时，或由于某个差错而丢掉该分组时，它返回 1。如果它不转发分组，`ip_dooptions` 返回 0，由 `ipintr` 继续处理该分组。

`ip_dooptions` 是一个长函数，所以我们分步地显示。第一部分初始化一个 `for` 循环，处理首部中的各选项。

当处理每个选项时，`cp` 指向选项的第一个字节。图 9-7 显示，当可用时，如何从 `cp` 的常量位移访问 `type`、`length` 和 `offset` 字段。

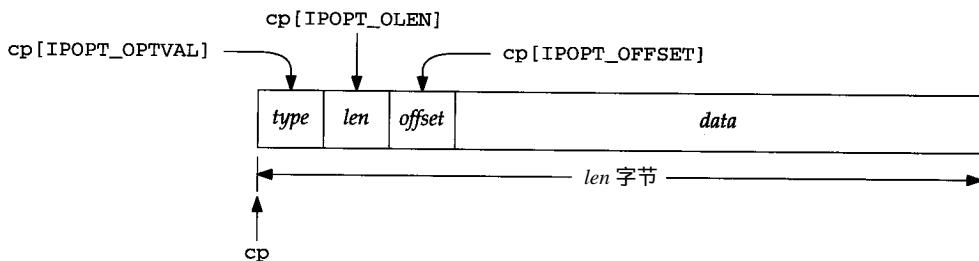


图9-7 用常量位移访问IP选项字段

RFC把位移(`offset`)字段描述作指针(`pointer`)，指针比位移的描述性略强一些。`offset`的值是某个字节在该选项内的序号(从`type`开始，序号为1)，不是从`type`开始的、且以零开始的计数。位移的最小值是4(`IPOPT_MINOFF`)，它指向的是多字节选项中数据字段的第一个字节。

图9-8显示了`ip_dooptions`函数的整体结构。

555-566 `ip_dooptions` 把ICMP差错类型 `type` 初始化为 `ICMP_PARAMPROB`，对任何没有特定差错类型的差错，这是一个一般值。对于 `ICMP_PARAMPROB`，`code` 指的是出错字节在分组内的位移。这是默认的 ICMP 差错报文。某些选项将改变这些值。

`ip` 指向一个 20 字节大小的 `ip` 结构，所以 `ip+1` 指向的是跟在 IP 首部后面的下一个 `ip` 结构。因为 `ip_dooptions` 需要 IP 首部后面字节的地址，所以就把结果指针转换成为指向一个无符号字节(`u_char`)的指针。因此，`cp` 指向标准 IP 首部以外的第一个字节，就是 IP 选项的第一个字节。

1. EOL和NOP过程

567-582 `for` 循环按照每个选项在分组中出现的顺序分别对它们进行处理。EOL 选项以及一个无效的选项长度(也即选项长度表明选项数据超过了 IP 首部)都将终止该循环。当出现 NOP 选项时，忽略它。`switch`语句的`default`情况隐含要求系统忽略未知的选项。

下面的内容描述了 `switch`语句处理的每个选项。如果 `ip_dooptions`在处理分组选项时没有出错，就把控制交给 `switch`下面的代码。

2. 源路由转发

719-724 如果分组需要被转发，SSRR或LSRR选项处理代码就把forward置位。分组被传给ip_forward，并且第2个参数为1，表明分组是按源路由选择的。

```

553 int
554 ip_dooptions(m)
555 struct mbuf *m;
556 {
557     struct ip *ip = mtod(m, struct ip *);
558     u_char *cp;
559     struct ip_timestamp *ipt;
560     struct in_ifaddr *ia;
561     int opt, optlen, cnt, off, code, type = ICMP_PARAMPROB, forward = 0;
562     struct in_addr *sin, dst;
563     n_time ntime;

564     dst = ip->ip_dst;
565     cp = (u_char *) (ip + 1);
566     cnt = (ip->ip_hl << 2) - sizeof(struct ip);
567     for (; cnt > 0; cnt -= optlen, cp += optlen) {
568         opt = cp[IPOPT_OPTVAL];
569         if (opt == IPOPT_EOL)
570             break;
571         if (opt == IPOPT_NOP)
572             optlen = 1;
573         else {
574             optlen = cp[IPOPT_OLEN];
575             if (optlen <= 0 || optlen > cnt) {
576                 code = &cp[IPOPT_OLEN] - (u_char *) ip;
577                 goto bad;
578             }
579         }
580     }
581     switch (opt) {
582     default:
583         break;
584     }

585     /* option processing */
586 }

587     }
588     if (forward) {
589         ip_forward(m, 1);
590         return (1);
591     }
592     return (0);

593 bad:
594     ip->ip_len -= ip->ip_hl << 2; /* XXX icmp_error adds in hdr length */
595     icmp_error(m, type, code, 0, 0);
596     ipstat.ips_badoptions++;
597     return (1);
598 }
599 }
```

ip_input.c

图9-8 ip_dooptions 函数

我们在8.5节中讲到，并不为源路由选择分组生成ICMP重定向——这就是为什么在传给ip_forward时设置第2个参数的原因。

如果转发了分组，则 `ip_dooptions` 返回 1。如果分组中没有源路由，则返回 0 给 `ipintr`，表明需要对该数据报进一步处理。注意，只有当系统被配置成路由器时 (`ipforwarding` 等于 1)，才发生源路由转发。

从某种程度上说，这是一个有些矛盾的策略，但却是 RFC 1122 的书面要求。RFC 1127 [Braden 1989c] 把它作为一个公开问题加以阐述。

3. 差错处理

725-730 如果在 `switch` 语句里出现了错误，`ip_dooptions` 就跳到 `bad`。从分组长度中把 IP 首部长度减去，因为 `icmp_error` 假设首部长度不包含在分组长度里。`icmp_error` 发出适当的差错报文，`ip_dooptions` 返回 1，避免 `ipintr` 处理被丢弃的分组。

下一节描述 Net/3 处理的所有选项。

9.5 记录路由选项

记录路由选项使得分组在穿过互联网时所经过的路由被记录在分组内部。项的大小是源主机在构造时确定的，必须足够保存所有预期的地址。我们记得在 IP 分组的首部，选项最多只能有 40 字节。记录路由选项可以有 3 个字节的开销，后面紧跟地址的列表（每个地址 4 字节）。如果该选项是唯一的选项，则最多可以有 9 个 ($3 + 4 \times 9 = 39$) 地址出现。一旦分配给该选项的空间被填满，就按通常的情况对分组进行转发，中间的系统就不再记录地址。

图 9-9 说明了一个记录路由选项的格式，图 9-10 是其源程序。

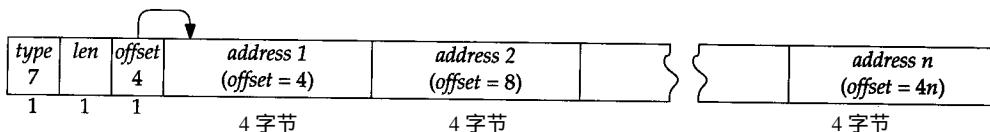


图 9-9 记录路由选项，其中 n 必须 9

```

647     case IPOPT_RR:                                ip_input.c
648         if ((off = cp[IPOPT_OFFSET]) < IPOPT_MINOFF) {
649             code = &cp[IPOPT_OFFSET] - (u_char *) ip;
650             goto bad;
651         }
652         /*
653          * If no space remains, ignore.
654          */
655         off--;           /* 0 origin */
656         if (off > optlen - sizeof(struct in_addr))
657             break;
658         bcopy((caddr_t)(&ip->ip_dst), (caddr_t) & ipaddr.sin_addr,
659               sizeof(ipaddr.sin_addr));
660         /*
661          * locate outgoing interface; if we're the destination,
662          * use the incoming interface (should be same).
663          */
664         if ((ia = (INA) ifa_ifwithaddr((SA) & ipaddr)) == 0 &&
665             (ia = ip_rtaddr(ipaddr.sin_addr)) == 0) {
666             type = ICMP_UNREACH;
667             code = ICMP_UNREACH_HOST;

```

图 9-10 函数 `ip_dooptions`：记录路由选项的处理

```

668         goto bad;
669     }
670     bcopy((caddr_t) & (IA_SIN(ia)->sin_addr),
671           (caddr_t) (cp + off), sizeof(struct in_addr));
672     cp[IPOPT_OFFSET] += sizeof(struct in_addr);
673     break;

```

ip_input.c

图9-10 (续)

647-657 如果位移选项太小，则 ip_dooptions 就发送一个ICMP参数问题差错。如果变量 code 被设置成分组内无效选项的字节位移量，并且 bad 标号(图9-8)语句的执行产生错误，则发出的ICMP参数问题差错报文中就具有该 code 值。如果选项中没有附加地址的空间，则忽略该选项，并继续处理下一个选项。

记录地址

658-673 如果 ip_dst 是某个系统地址(分组已到达目的地)，则把接收接口的地址记录在选项中；否则把 ip_rtaddr 提供的外出接口的地址记录下来。把位移更新为选项中下一个可用地址位置。如果 ip_rtaddr 无法找到到目的地的路由，就发送一个ICMP主机不可达差错报文。

卷1的7.3节举了一些记录路由选项的例子。

ip_rtaddr函数

函数 ip_rtaddr 查询路由缓存，必要时查询完整的路由表，来找到到给定 IP 地址的路由。它返回一个指向 in_ifaddr 结构的指针，该指针与该路由的外出接口有关。图 9-11 显示了该函数。

```

735 struct in_ifaddr *
736 ip_rtaddr(dst)
737 struct in_addr dst;
738 {
739     struct sockaddr_in *sin;
740     sin = (struct sockaddr_in *) &ipforward_rt.ro_dst;
741     if (ipforward_rt.ro_rt == 0 || dst.s_addr != sin->sin_addr.s_addr) {
742         if (ipforward_rt.ro_rt) {
743             RTFREE(ipforward_rt.ro_rt);
744             ipforward_rt.ro_rt = 0;
745         }
746         sin->sin_family = AF_INET;
747         sin->sin_len = sizeof(*sin);
748         sin->sin_addr = dst;
749         rtalloc(&ipforward_rt);
750     }
751     if (ipforward_rt.ro_rt == 0)
752         return ((struct in_ifaddr *) 0);
753     return ((struct in_ifaddr *) ipforward_rt.ro_rt->rt_ifa);
754 }

```

ip_input.c

图9-11 函数 ip_rtaddr : 寻找外出的接口

1. 检查IP转发缓存

735-741 如果路由缓存为空，或者如果 ip_rtaddr 的唯一参数 dest 与路由缓存中的目的

地不匹配，则必须查询路由表选择一个外出的接口。

2. 确定路由

742-750 旧的路由（如果有的话）被丢弃，并把新的路由储存在 *sin（这是转发缓存的 ro_dst 成员）。rtalloc 搜索路由表，寻找到目的地的路由。

3. 返回路由信息

751-754 如果没有路由可用，就返回一个空指针；否则，就返回一个指针，指向与所选路由相关联的接口地址结构。

9.6 源站和记录路由选项

通常是在中间路由器所选择的路径上转发分组。源站和记录路由选项允许源站明确指定一条到目的地的路由，覆盖掉中间路由器的路由选择决定。而且，在分组到达目的地的过程中，把该路由记录下来。

严格路由包含了源站和目的站之间的每个中间路由器的地址；宽松路由只指定某些中间路由器的地址。在宽松路由中，路由器可以自由选择两个系统之间的任何路径；而在严格路由中，则不允许路由器这样做。我们用图 9-12 说明源路由处理。

A、B 和 C 是路由器，而 HS 和 HD 是源和目的主机。因为每个接口都有自己的 IP 地址，所以我们看到路由器 A 有三个地址：A₁、A₂ 和 A₃。同样，路由器 B 和 C 也有多个地址。图 9-13 显示了源站和记录路由选项的格式。

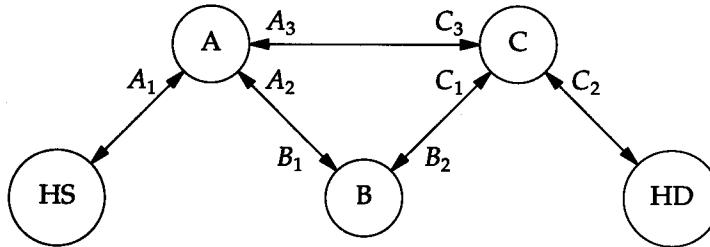


图 9-12 源路由举例

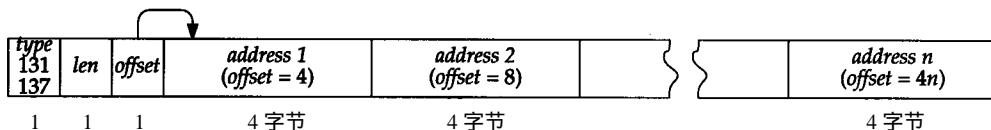


图 9-13 严格和宽松源路由选项

IP 首部的源和目的地址以及在选项中列出的位移和地址表，指定了路由以及分组目前在该路由中所处的位置。图 9-14 显示，当分组按照这个宽松源路由从 HS 经 A、B、C 到 HD 时，信息是如何改变的。每行代表当分组被第 1 列显示的系统发送时的状态。最后一行显示分组被 HD 接收。图 9-15 显示了相关的代码。

符号 “•” 表示位移与路由中地址的相对位置。注意，每个系统都把出接口的地址放到选项去。特别地，原来的路由指定 A₃ 为第一跳目的地，但是外出接口 A₂ 被记录在路由中。通过这种方法，分组所采用的路由被记录在选项中。被记录的路由将被目的地系统倒转过来放到所有应答分组上，让它们沿着原始的路由的逆方向发送。

除了 UDP，Net/3 在应答时总是把收到的源路由逆转过来。

系统	IP首部		源路由选项		
	ip_src	ip_dst	位移	地址	
HS	HS	A_3	4	B_1	C_1
A	HS	B_1	8	A_2	C_1
B	HS	C_1	12	A_2	B_2
C	HS	HD	16	A_2	B_2
HD	HS	HD	16	A_2	C_2

图9-14 当分组通过该路由时，源路由选项被修改。

```

583     /*
584      * Source routing with record.
585      * Find interface with current destination address.
586      * If none on this machine then drop if strictly routed,
587      * or do nothing if loosely routed.
588      * Record interface address and bring up next address
589      * component. If strictly routed make sure next
590      * address is on directly accessible net.
591      */
592     case IPOPT_LSRR:
593     case IPOPT_SSRR:
594         if ((off = cp[IPOPT_OFFSET]) < IPOPT_MINOFF) {
595             code = &cp[IPOPT_OFFSET] - (u_char *) ip;
596             goto bad;
597         }
598         ipaddr.sin_addr = ip->ip_dst;
599         ia = (struct in_ifaddr *)
600             ifa_ifwithaddr((struct sockaddr *) &ipaddr);
601         if (ia == 0) {
602             if (opt == IPOPT_SSRR) {
603                 type = ICMP_UNREACH;
604                 code = ICMP_UNREACH_SRCFAIL;
605                 goto bad;
606             }
607             /*
608              * Loose routing, and not at next destination
609              * yet; nothing to do except forward.
610              */
611             break;
612         }
613         off--;           /* 0 origin */
614         if (off > optlen - sizeof(struct in_addr)) {
615             /*
616              * End of source route. Should be for us.
617              */
618             save_rte(cp, ip->ip_src);
619             break;
620         }
621         /*
622          * locate outgoing interface
623          */
624         bcopy((caddr_t) (cp + off), (caddr_t) &ipaddr.sin_addr,
625               sizeof(ipaddr.sin_addr));
626         if (opt == IPOPT_SSRR) {
627 #define INA struct in_ifaddr *
628 #define SA  struct sockaddr *
629             if ((ia = (INA) ifa_ifwithdstaddr((SA) & ipaddr)) == 0)

```

图9-15 函数ip_dooptions : LSRR和SSRR选项处理

```

630             ia = (INA) ifa_ifwithnet((SA) & ipaddr);
631     } else
632         ia = ip_rtaddr(ipaddr.sin_addr);
633     if (ia == 0) {
634         type = ICMP_UNREACH;
635         code = ICMP_UNREACH_SRCFAIL;
636         goto bad;
637     }
638     ip->ip_dst = ipaddr.sin_addr;
639     bcopy((caddr_t) & (IA_SIN(ia)->sin_addr),
640           (caddr_t) (cp + off), sizeof(struct in_addr));
641     cp[IPOPT_OFFSET] += sizeof(struct in_addr);
642     /*
643      * Let ip_intr's mcast routing check handle mcast pkts
644      */
645     forward = !IN_MULTICAST(ntohl(ip->ip_dst.s_addr));
646     break;

```

ip_input.c

图9-15 (续)

583-612 如果选项位移小于4(IPOPT_MINOFF)，则Net/3发送一个ICMP参数问题差错，并带上相应的code值。如果分组的目的地址与本地地址没有一个匹配，且选项是严格源路由(IPOPT_SSRR)，则发送一个源路由失败差错。如果本地地址不在路由中，则上一个系统把分组发送到错误的主机上了。对宽松路由(IPOPT_LSRR)来说，这不是错误；仅意味着IP必须把分组转发到目的地。

1. 源路由的结束

613-620 减小off，把它转换成从选项开始的字节位移。如果IP首部的ip_dst是某个本地地址，并且off所指向的超过了源路由的末尾，源路由中没有地址了，则分组已经到达了目的地。save_rte复制在静态结构ip_srcrt中的路由，并保存在全局ip_nhops(图9-18)里路由中的地址个数。

ip_srcrt被定义成为一个外部静态结构，因为它只能被在*ip_input.c*中定义的函数访问。

2. 为下一跳更新分组

621-637 如果ip_dst是一个本地地址，并且offset指向选项内的一个地址，则该系统是源路由中指定的一个中间系统，分组也没有到达目的地。在严格路由中，下一个系统必须位于某个直接相连的网络上。ifa_ifwithdst和ifa_ifwithnet通过在配置的接口中搜索匹配的目的地址(一个点到点的接口)或匹配的网络地址(广播接口)来寻找一条到下一个系统的路由。而在宽松路由中，ip_rtaddr(图9-11)通过查询路由表来寻找下一个系统的路由。如果没有找到到下一系统的接口或路由，就发送一个ICMP源路由失败差错报文。

638-644 如果找到一个接口或一条路由，则ip_dooptions把ip_dst设置成off指向的IP地址。在源路由选项内，用外出接口的地址代替中间系统的地址，把位移增加，指向路由中的下一个地址。

3. 多播目的地

645-646 如果新的目的地址不是多播地址，就将forward设置成1，表明在处理完所有选项后，应该把分组转发而不是返回给ipintr。

源路由中的多播地址允许两个多播路由器通过不支持多播的中间路由器进行通信。第14章详细描述了这一技术。

卷1的8.5节有更多的源路由选项的例子。

9.6.1 save_rte函数

RFC 1122要求，在最终目的地，运输协议必须能够使用分组中被记录下来的路由。运输协议必须把该路由倒过来并附在所有应答的分组上。图 9-18 中显示的 save_rte 函数，把源路由保存在如图 9-16 所示的 ip_srcrt 结构中。

```
57 int      ip_nhops = 0;                                ip_input.c
58 static struct ip_srcrt {
59     struct in_addr dst;           /* final destination */
60     char    nop;                /* one NOP to align */
61     char    srcopt[IPOPT_OFFSET + 1]; /* OPTVAL, OLEN and OFFSET */
62     struct in_addr route[MAX_IPOPTLEN / sizeof(struct in_addr)];
63 } ip_srcrt;
```

```
ip_input.c
```

图9-16 结构 ip_srcrt

Route 的声明是不正确的，尽管这不是个恶性错误。应该是

```
Struct in_addr route[(MAX_IPOPTLEN - 3)/sizeof(struct in_addr)];
```

对图9-26和图9-27的讨论详细地说明了这个问题。

57-63 该代码定义了 ip_srcrt 结构，并声明了静态变量 ip_srcrt。只有两个函数访问 ip_srcrt：save_rte，把到达分组中的源路由复制到 ip_srcrt 中；ip_srcroute，创建一个与源路由方向相逆的路由。图 9-17 说明了源路由处理过程。

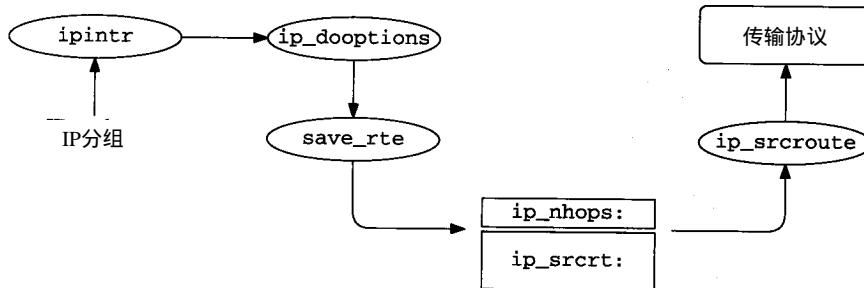


图9-17 对求逆后的源路由的处理

```
759 void
760 save_rte(option, dst)
761 u_char *option;
762 struct in_addr dst;
763 {
764     unsigned olen;
765
766     olen = option[IPOPT_OLEN];
767     if (olen > sizeof(ip_srcrt) - (1 + sizeof(dst)))
768         return;
769     bcopy((caddr_t) option, (caddr_t) ip_srcrt.srcopt, olen);
770     ip_nhops = (olen - IPOPT_OFFSET - 1) / sizeof(struct in_addr);
771     ip_srcrt.dst = dst;
771 }
```

```
ip_input.c
```

图9-18 函数 save_rte

759-771 当一个源路由选择的分组到达目的地时，`ip_dooptions`调用`save_rte`。`option`是一个指向分组的源路由选项的指针，`dst`是从分组首部来的`ip_src`（也就是，返回路由的目的地，图9-12中的HS）。如果选项的长度超过`ip_srcrt`结构，`save_rte`立即返回。

永远也不可能发生这种情况，因为`ip_srcrt`结构比最大选项长度(40字节)要大。

`save_rte`把该选项复制到`ip_srcrt`，计算并保存`ip_nhops`中源路由的跳数，把返回路由的目的地保存在`dst`中。

9.6.2 ip_srcroute函数

当响应某个分组时，ICMP和标准的运输层协议必须把分组带的任意源路由逆转。逆转源路由是通过`ip_srcroute`保存的路由构造的，如图9-19所示。

```
777 struct mbuf *
778 ip_srcroute()
779 {
780     struct in_addr *p, *q;
781     struct mbuf *m;
782     if (ip_nhops == 0)
783         return ((struct mbuf *) 0);
784     m = m_get(M_DONTWAIT, MT_SOOPTS);
785     if (m == 0)
786         return ((struct mbuf *) 0);
787 #define OPTSIZ  (sizeof(ip_srcrt.nop) + sizeof(ip_srcrt.srcopt))
788     /* length is (nhops+1)*sizeof(addr) + sizeof(nop + srcrt header) */
789     m->m_len = ip_nhops * sizeof(struct in_addr) + sizeof(struct in_addr) +
790     OPTSIZ;
791     /*
792      * First save first hop for return route
793      */
794     p = &ip_srcrt.route[ip_nhops - 1];
795     *(mtod(m, struct in_addr *)) = *p--;
796     /*
797      * Copy option fields and padding (nop) to mbuf.
798      */
799     ip_srcrt.nop = IPOPT_NOP;
800     ip_srcrt.srcopt[IPOPT_OFFSET] = IPOPT_MINOFF;
801     bcopy((caddr_t) & ip_srcrt.nop,
802           mtod(m, caddr_t) + sizeof(struct in_addr), OPTSIZ);
803     q = (struct in_addr *) (mtod(m, caddr_t) +
804                           sizeof(struct in_addr) + OPTSIZ);
805 #undef OPTSIZ
806     /*
807      * Record return path as an IP source route,
808      * reversing the path (pointers are now aligned).
809      */
810     while (p >= ip_srcrt.route) {
811         *q++ = *p--;
812     }
813     /*
814      * Last hop goes to final destination.
```

图9-19 ip_srcroute 函数

```

815     */
816     *q = ip_srcrt.dst;
817     return (m);
818 }

```

ip_input.c

图9-19 (续)

777-783 ip_srcroute把保存在ip_srcrt结构中的源路由逆转后，返回与 ipoption 结构(图9-26)格式类似的结果。如果 ip_nhops 是 0，则没有保存的路由，所以 ip_srcroute 返回一个指针。

记得在图8-13中，当一个无效分组到达时，ipintr把ip_nhops清零。运输层协议必须调用 ip_srcroute，并在下一个分组到达之前自己保存逆转后的路由。正如以前我们注意到的，这样做是正确的，因为 ipintr在处理分组时，在IP输入队列的下一个分组被处理之前都会调用运输层(TCP或UDP)的。

为源路由分配存储器缓存

784-786 如果 ip_nhops 非 0，ip_srcroute 就分配一个 mbuf，并把 m_len 设置成足够大，以便包含第一跳目的地、选项首部信息(OPTSIZ)以及逆转后的路由。如果分配失败，则返回一个空指针，跟没有源路由一样。

p 被初始化为指向到达路由的末尾，ip_srcroute 把最后记录的地址复制到 mbuf 的前面，在这里它为外出的第一跳目的地开始逆转后的路由。然后该函数把一份 NOP 选项(习题9.4)和源路由信息复制到 mbuf 中。

805-818 While 循环把其余的 IP 地址从源路由中以相反的顺序复制到 mbuf 中。路由的最后一个地址被设置成到达分组中被 save_rte 放在 ip_srcrt.dst 中的源站地址。返回一个指向 mbuf 的指针。图9-20说明了对图9-12的路由如何构造逆转的路由。

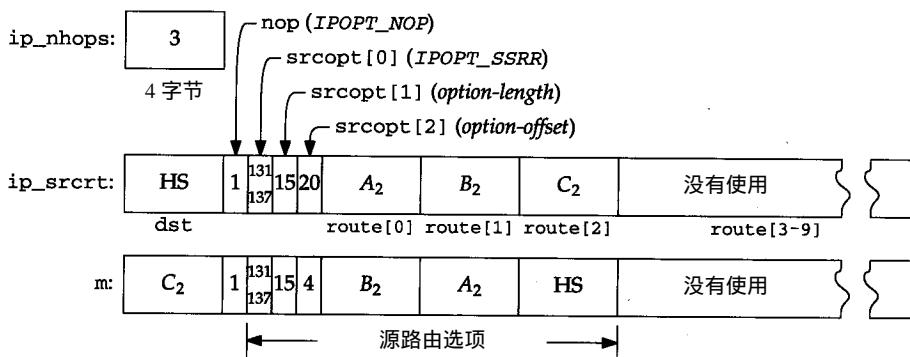


图9-20 ip_srcroute 逆转 ip_srcrt 中的路由

9.7 时间戳选项

当分组穿过一个互联网时，时间戳选项使各个系统把它当前的时间表示记录在分组的选项内。时间是以从 UTC 的午夜开始计算的毫秒计，被记录在一个 32 bit 的字段里。

如果系统没有准确的 UTC(几分钟以内)或没有每秒更新至少 15 次，就不把它作为标准时间。非标准时间必须把时间戳字段的高比特位置位。

有三种时间戳选项类型，Net/3通过如图9-22所示的ip_timestamp结构访问。

114-133 如同ip结构(图8-10)一样，#ifs保证比特字段访问选项中正确的比特位。图9-21中列出了由ipt_flg指定的三种时戳选项类型。

ipt_flg	值	描述
IPOOPT_TS_TSONLY	0	记录时间戳
IPOPT_TS_TSANDADDR	1	记录地址和时间戳
	2	保留
IPOPT_TS_PRESPEC	3	只在预先指定的系统记录时间戳
	4-15	保留

图9-21 ipt_flg 可能的值

```
114 struct ip_timestamp {
115     u_char    ipt_code;           /* IPOPT_TS */
116     u_char    ipt_len;          /* size of structure (variable) */
117     u_char    ipt_ptr;          /* index of current entry */
118 #if BYTE_ORDER == LITTLE_ENDIAN
119     u_char    ipt_flg:4,        /* flags, see below */
120             ipt_oflw:4;          /* overflow counter */
121 #endif
122 #if BYTE_ORDER == BIG_ENDIAN
123     u_char    ipt_oflw:4,        /* overflow counter */
124             ipt_flg:4;          /* flags, see below */
125 #endif
126     union ip_timestamp {
127         n_long   ipt_time[1];
128         struct ip_tu {
129             struct in_addr ipt_addr;
130             n_long   ipt_time;
131         } ip_tu[1];
132     } ip_timestamp;
133 };

```

图9-22 ip_timestamp 结构和常量

初始主机必须构造一个具有足够大的数据区存放可能的时间戳和地址的时间戳选项。对于ipt_flg为3的时间戳选项，初始主机在构造该选项时，填写要记录时间戳的系统的地址。图9-23显示了三种时间戳选项的结构。

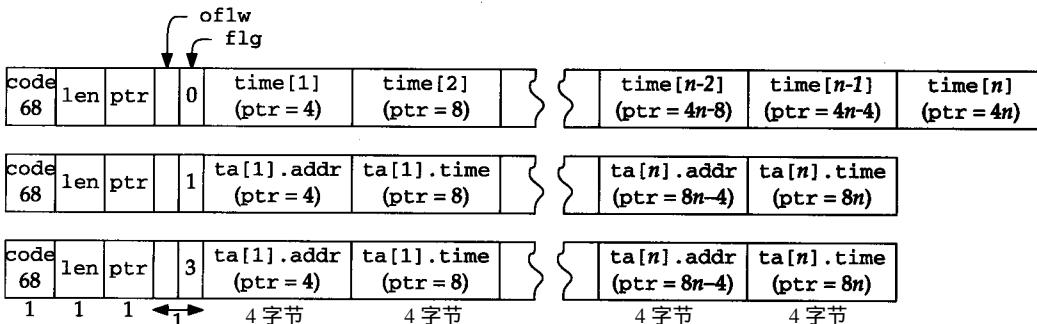


图9-23 三种时间戳选项(省略ipt_)

因为IP选项只能有40个字节，所以时戳选项限制只能有9个时戳(ipt_flg等于0)或4个地

址和时间戳对(ipt_flg等于1或3)。图9-24显示了对三种不同的时戳选项类型的处理。

674-684 如果选项长度小于5个字节(时戳选项的最小长度),则ip_dooptions发出一个ICMP参数问题差错报文。oflw字段统计由于选项数据区满而无法登记时戳的系统个数。如果数据区满,则oflw加1;当它本身超过16(它是一个4 bit的字段)而溢出时,发出一个ICMP参数问题差错报文。

```

674     case IPOPT_TS:
675         code = cp - (u_char *) ip;
676         ipt = (struct ip_timestamp *) cp;
677         if (ipt->ipt_len < 5)
678             goto bad;
679         if (ipt->ipt_ptr > ipt->ipt_len - sizeof(long)) {
680             if (++ipt->ipt_oflw == 0)
681                 goto bad;
682             break;
683         }
684         sin = (struct in_addr *) (cp + ipt->ipt_ptr - 1);
685         switch (ipt->ipt_flg) {
686
686     case IPOPT_TS_TSONLY:
687         break;
688
688     case IPOPT_TS_TSANDADDR:
689         if (ipt->ipt_ptr + sizeof(n_time) +
690             sizeof(struct in_addr) > ipt->ipt_len)
691             goto bad;
692         ipaddr.sin_addr = dst;
693         ia = (INA) ifao_ifpforaddr((SA) & ipaddr,
694                                     m->m_pkthdr.rcvif);
695         if (ia == 0)
696             continue;
697         bcopy((caddr_t) & IA_SIN(ia)->sin_addr,
698               (caddr_t) sin, sizeof(struct in_addr));
699         ipt->ipt_ptr += sizeof(struct in_addr);
700         break;
701
701     case IPOPT_TS_PRESPEC:
702         if (ipt->ipt_ptr + sizeof(n_time) +
703             sizeof(struct in_addr) > ipt->ipt_len)
704             goto bad;
705         bcopy((caddr_t) sin, (caddr_t) & ipaddr.sin_addr,
706               sizeof(struct in_addr));
707         if (ifa_ifwithaddr((SA) & ipaddr) == 0)
708             continue;
709         ipt->ipt_ptr += sizeof(struct in_addr);
710         break;
711
711     default:
712         goto bad;
713     }
714     ntime = iptime();
715     bcopy((caddr_t) & ntime, (caddr_t) cp + ipt->ipt_ptr - 1,
716           sizeof(n_time));
717     ipt->ipt_ptr += sizeof(n_time);
718 }
719 }
```

ip_input.c

图9-24 函数 ip_dooptions : 时间戳选项处理

1. 只有时间戳

685-687 对于 `ipt_flg` 为 0 的时间戳选项 (IPOPT_TS_TS ONLY) , 所有的工作都在 `switch` 语句之后再做。

2. 时间戳和地址

688-700 对于 `ipt_flg` 为 1 的时间戳选项 (IPOPT_TS_TSANDADDR) , 接收接口的地址被记录下来 (如果数据区还有空间) , 选项的指针前进一步。因为 Net/3 支持一个接收接口上的多 IP 地址 , 所以 `ip_dooptions` 调用 `ifaof_ifpforaddr` 选择与分组的初始目的地址 (也就是在任何源路由选择发生之前的目的地) 最匹配的地址。如果没有匹配 , 则跳过时间戳选项 (INA 和 SA 定义如图 9-15 所示)。

3. 预定地址上的时间戳

701-710 如果 `ipt_flg` 为 3 (IPOPT_TS_PRESPEC) , `ifa_ifwithaddr` 确定选项中指定的下一个地址是否与系统的某个地址匹配。如果不匹配 , 该选项要求在这个系统上不处理 ; `continue` 使 `ip_dooptions` 继续处理下一个选项。如果下一个地址与系统的某个地址匹配 , 则选项的指针前进到下一个位置 , 控制交给 `switch` 的后面。

4. 插入时间戳

711-713 `default` 截获无效的 `ipt_flg` 值 , 并把控制传递到 `bad`。

714-719 时间戳用 `switch` 语句后面的代码写入到选项中。 `iptime` 返回自从 UTC 午夜起到现在的毫秒数 , `ip_dooptions` 记录此时间戳 , 并增加此选项相对于下一个位置的偏移。

`iptime` 函数

图 9-25 显示了 `iptime` 的实现。

```

458 n_time
459 iptime()
460 {
461     struct timeval atv;
462     u_long t;
463     microtime(&atv);
464     t = (atv.tv_sec % (24 * 60 * 60)) * 1000 + atv.tv_usec / 1000;
465     return (htonl(t));
466 }
```

ip_icmp.c

图 9-25 函数 `iptime`

458-466 `microtime` 返回从 UTC 1970 年 1 月 1 日午夜以来的时间 , 放在 `timeval` 结构中。从午夜以来的毫秒数用 `atv` 计算 , 并以网络字节序返回。

卷 1 的 7.4 节有几个时间戳选项的例子。

9.8 `ip_insertoptions` 函数

我们在 8.6 节看到 , `ip_output` 函数接收一个分组和选项。当 `ip_forward` 调用该函数时 , 选项已经是分组的一部分 , 所以 `ip_forward` 总是把一个空选项指针传给 `ip_output`。但是 , 运输层协议可能会把由 `ip_insertoptions` (由图 8-22 中的 `ip_output` 调用) 合并到分组中的选项传递给 `ip_forward`。

ip_insertoptions 希望选项在 ipoption 结构中被格式化，如图 9-26 所示。

```
92 struct ipoption { ip_var.h
93     struct in_addr ipopt_dst; /* first-hop dst if source routed */
94     char    ipopt_list[MAX_IPOPTLEN]; /* options proper */
95 };
```

图9-26 结构 ipoption

92-95 该结构只有两个成员：ipopt_dst，如果选项表中有源路由，则其中有第一跳目的地，ipopt_list，是一个最多 40(MAX_IPOPTLEN)字节的选项矩阵，其格式我们在本章中已做了描述。如果选项表中没有源路由，则 ipopt_dst 全为 0。

注意，ip_srcrt 结构(图9-16)和由 ip_srcroute(图9-19)返回的 mbuf 都符合由 ipoption 结构所指定的格式。图 9-27 把结构 ip_srcrt 和 ipoption 作了比较。

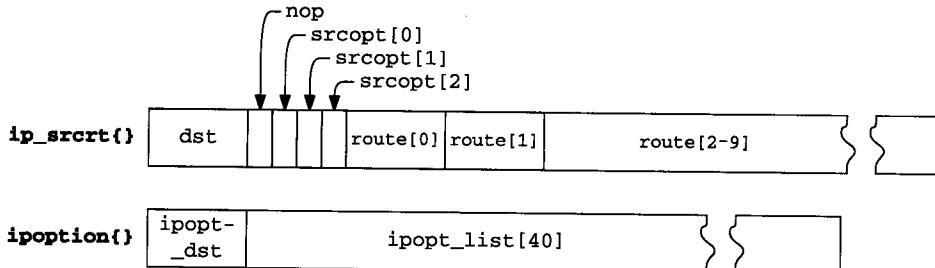


图9-27 结构 ip_srcrt 和 ipoption

结构 ip_srcrt 比 ipoption 多 4 个字节。路由矩阵的最后一个入口(route[9])永远都不会填上，因为这样的话，源路由选项将会有 44 字节长，比 IP 首部所能容纳的要大(图9-16)。

函数 ip_insertoptions 如图 9-28 所示。

```
352 static struct mbuf *
353 ip_insertoptions(m, opt, phlen) ip_output.c
354 struct mbuf *m;
355 struct mbuf *opt;
356 int    *phlen;
357 {
358     struct ipoption *p = mtod(opt, struct ipoption *);
359     struct mbuf *n;
360     struct ip *ip = mtod(m, struct ip *);
361     unsigned optlen;
362
363     optlen = opt->m_len - sizeof(p->ipopt_dst);
364     if (optlen + (u_short) ip->ip_len > IP_MAXPACKET)
365         return (m); /* XXX should fail */
366     if (p->ipopt_dst.s_addr)
367         ip->ip_dst = p->ipopt_dst;
368     if (m->m_flags & M_EXT || m->m_data - optlen < m->m_pktdat) {
369         MGETHDR(n, M_DONTWAIT, MT_HEADER);
370         if (n == 0)
371             return (m);
```

图9-28 函数 ip_insertoptions

```

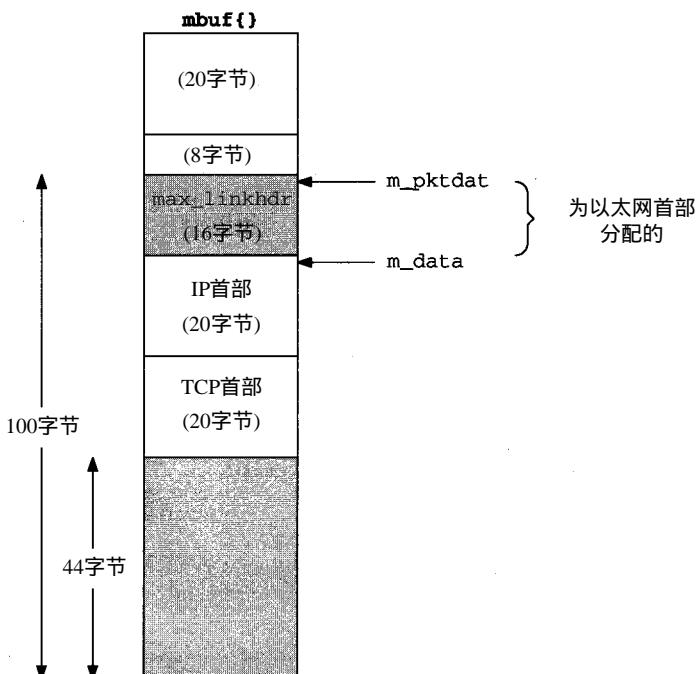
370     return (m);
371     n->m_pkthdr.len = m->m_pkthdr.len + optlen;
372     m->m_len -= sizeof(struct ip);
373     m->m_data += sizeof(struct ip);
374     n->m_next = m;
375     m = n;
376     m->m_len = optlen + sizeof(struct ip);
377     m->m_data += max_linkhdr;
378     bcopy((caddr_t) ip, mtod(m, caddr_t), sizeof(struct ip));
379 } else {
380     m->m_data -= optlen;
381     m->m_len += optlen;
382     m->m_pkthdr.len += optlen;
383     ovbcopy((caddr_t) ip, mtod(m, caddr_t), sizeof(struct ip));
384 }
385 ip = mtod(m, struct ip *);
386 bcopy((caddr_t) p->ipopt_list, (caddr_t) (ip + 1), (unsigned) optlen);
387 *phlen = sizeof(struct ip) + optlen;
388 ip->ip_len += optlen;
389 return (m);
390 }

```

ip_output.c

图9-28 (续)

352-364 `ip_insertoptions`有三个参数：`m`，外出的分组；`opt`，在结构中格式化的选项；`phlen`，一个指向整数的指针，在这里返回新首部的长度（在插入选项之后）。如果插入选项分组长度超过最大分组长度 65 535(`IP_MAXPACKET`)字节，则自动将选项丢弃。`ip_dooptions`认为`ip_insertoptions`永远都不会失败，所以无法报告差错。幸好，很少有应用程序会试图发送最大长度的数据报，更别说选项了。

图9-29 函数`ip_insertoptions` : TCP报文段

365~366 如果`ipopt_dst.s_addr`指定了一个非零地址，则选项中包括了源路由，并且分组首部的`ip_dst`被源路由中的第一跳目的地代替。

在26.2节中，我们将看到TCP调用`MGETHDR`为IP和TCP首部分配一个单独的mbuf。图9-29显示了在第367~378行代码执行之前，一个TCP报文段的mbuf结构。

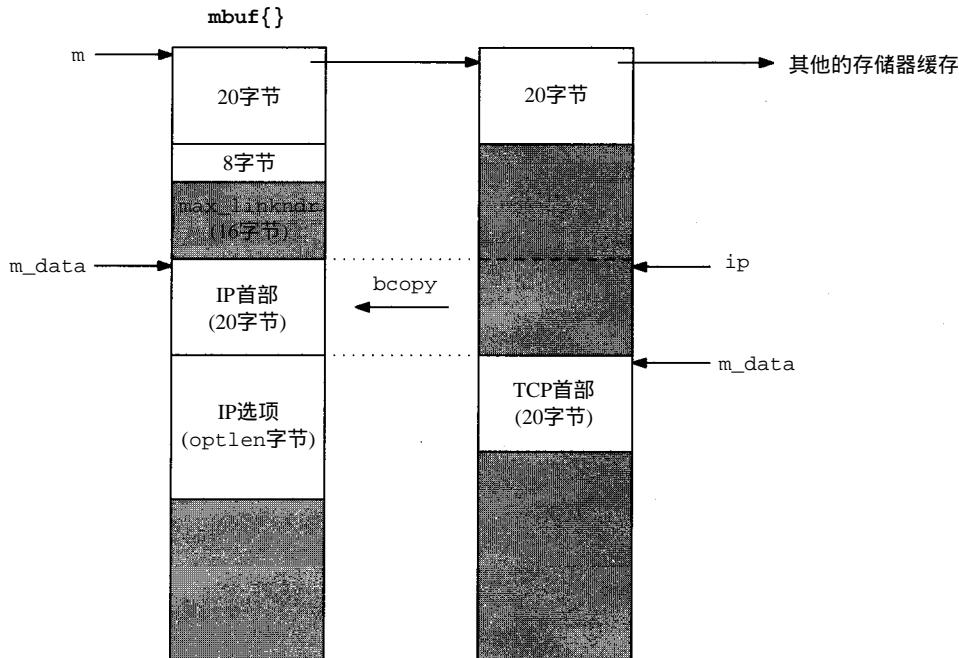


图9-30 函数`ip_insertoptions`：在选项被复制后的TCP报文段

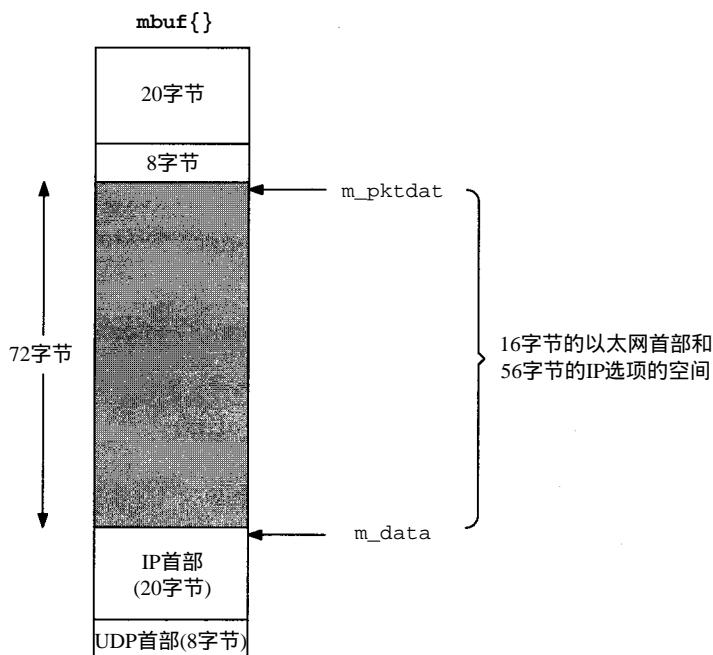


图9-31 函数`ip_insertoptions`：UDP报文段

如果被插入的选项占据了多于 16的字节数，则第 367行的测试为真，并调用 MGETHDR分配另一个mbuf。图9-30显示了选项被复制到新的mbuf后，该缓存的结构。

367-378 如果分组首部被存放在一簇，或者第一个缓存中没有多余选项的空间，则 ip_insertoptions 分配一个新的分组首部 mbuf，初始化它的长度，从旧的缓存中把该 IP 首部截取下来，并把该首部从旧缓存中移动到新缓存中。

如23.6节中所述，UDP使用M_PREPEND把UDP和IP首部放置到缓存的最后，与数据分离。如图9-31所示。因为首部是放在缓存的最后，所以在缓存中总有空间存放选项，对 UDP来说，第367行的条件总为假。

379-384 如果分组在缓存数据区的开始部分有存放选项的空间，则修改 m_data 和 m_len，以包含 optlen更多的字节。并且当前的 IP首部被 ovbcopy(能够处理源站和目的站的重叠问题)移走，为选项腾出位置。

385-390 ip_insertoptions现在可以把 ipoption 结构的成员 ipopt_list 直接复制到紧接在 IP首部后面的缓存中。把新的首部长度存放在 *phlen 中，修改数据报长度(ip_len)，并返回一个指向分组首部缓存的指针。

9.9 ip_pcbopts函数

函数 ip_pcbopts 把IP选项表及 IP_OPTIONS 插口选项转换成 ip_output 希望的格式： ipoption 结构。如图9-32所示。

```

559 int ip_pcbopts(pcbopt, m)
560 struct mbuf **pcbopt;
561 struct mbuf *m;
562 struct mbuf *cp;
563 {
564     cnt, optlen;
565     u_char *cp;
566     u_char opt;
567     /* turn off any old options */
568     if (*pcbopt)
569         (void) m_free(*pcbopt);
570     *pcbopt = 0;
571     if (m == (struct mbuf *) 0 || m->m_len == 0) {
572         /*
573          * Only turning off any previous options.
574          */
575         if (m)
576             (void) m_free(m);
577         return (0);
578     }
579     if (m->m_len % sizeof(long))
580         goto bad;
581     /*
582      * IP first-hop destination address will be stored before
583      * actual options; move other options back
584      * and clear it when none present.
585      */
586     if (m->m_data + m->m_len + sizeof(struct in_addr) >= &m->m_dat[MLEN])
587         goto bad;
588     cnt = m->m_len;
589     m->m_len += sizeof(struct in_addr);

```

图9-32 函数 ip_pcbopts

```

590     cp = mtod(m, u_char *) + sizeof(struct in_addr);
591     ovbcopy(mtod(m, caddr_t), (caddr_t) cp, (unsigned) cnt);
592     bzero(mtod(m, caddr_t), sizeof(struct in_addr));
593     for (; cnt > 0; cnt -= optlen, cp += optlen) {
594         opt = cp[IPOPT_OPTVAL];
595         if (opt == IPOPT_EOL)
596             break;
597         if (opt == IPOPT_NOP)
598             optlen = 1;
599         else {
600             optlen = cp[IPOPT_OLEN];
601             if (optlen <= IPOPT_OLEN || optlen > cnt)
602                 goto bad;
603         }
604         switch (opt) {
605             default:
606                 break;
607             case IPOPT_LSRR:
608             case IPOPT_SSRR:
609                 /*
610                  * user process specifies route as:
611                  * ->A->B->C->D
612                  * D must be our final destination (but we can't
613                  * check that since we may not have connected yet).
614                  * A is first hop destination, which doesn't appear in
615                  * actual IP option, but is stored before the options.
616                  */
617             if (optlen < IPOPT_MINOFF - 1 + sizeof(struct in_addr))
618                 goto bad;
619             m->m_len -= sizeof(struct in_addr);
620             cnt -= sizeof(struct in_addr);
621             optlen -= sizeof(struct in_addr);
622             cp[IPOPT_OLEN] = optlen;
623             /*
624              * Move first hop before start of options.
625              */
626             bcopy((caddr_t) & cp[IPOPT_OFFSET + 1], mtod(m, caddr_t),
627                   sizeof(struct in_addr));
628             /*
629              * Then copy rest of options back
630              * to close up the deleted entry.
631              */
632             ovbcopy((caddr_t) (&cp[IPOPT_OFFSET + 1] +
633                               sizeof(struct in_addr)),
634                     (caddr_t) & cp[IPOPT_OFFSET + 1],
635                     (unsigned) cnt + sizeof(struct in_addr));
636             break;
637         }
638     }
639     if (m->m_len > MAX_IPOPTLEN + sizeof(struct in_addr))
640         goto bad;
641     *pcbopt = m;
642     return (0);
643     bad:
644     (void) m_free(m);
645     return (EINVAL);
646 }

```

ip_output.c

图9-32 (续)

559-562 第一个参数，`pcbopt`引用指向当前选项表的指针。然后该函数用一个指向新的选项表的指针来代替该指针，这个新选项表是由第二个参数 `m`指向的缓存链所指定的选项构造而来。该过程所准备的选项表，将被包含在 `IP_OPTIONS` 插口选项中，除了 LSRR 和 SSRR 选项的格式外，看起来象一个标准的 IP 选项表。对这些选项，第一跳目的地址是作为路由的第一个地址出现的。图 9-14 显示，在外出的分组中，第一跳目的地址是作为目的地址出现的，而不是路由的第一个地址。

1. 扔掉以前的选项

563-580 所有被 `m_free` 和 `*pcbopt` 扔掉的选项都被清除。如果该过程传来一个空缓存或者根本不传递缓存，则该函数不安装任何新的选项，并立即返回。

如果新选项表没有填充到 4 bit 的边界，则 `ip_pcbopts` 跳到 `bad`，扔掉该表，并返回 `EINVAL`。

该函数的其余部分重新安排该表，使其看起来象一个 `ipooption` 结构。图 9-33 显示了这个过程。

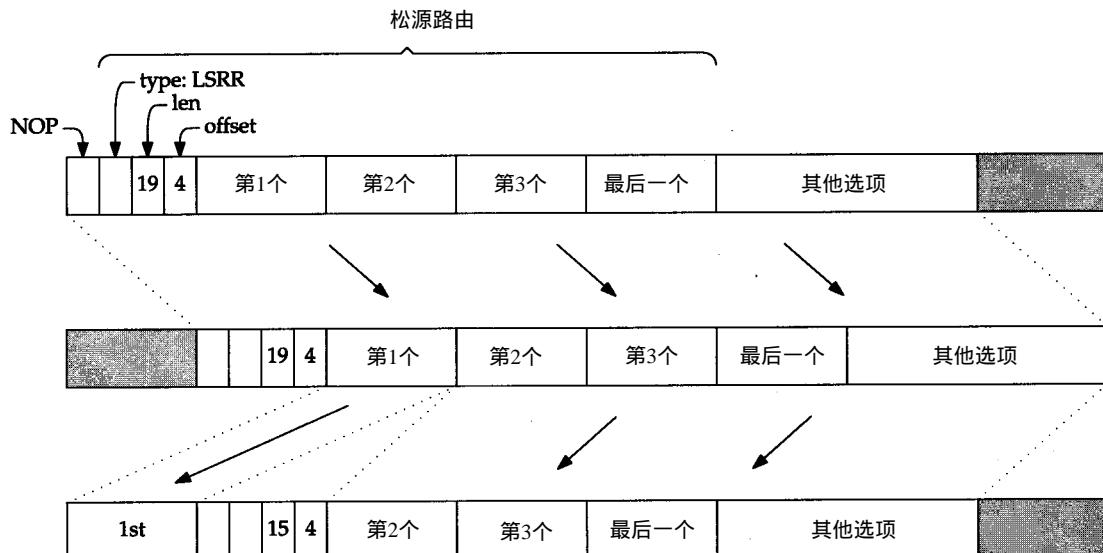


图9-33 ip_pcbopts 选项表处理

2. 为第一跳目的地腾出位置

581-592 如果缓存中没有位置，则把所有的数据都向缓存的末尾移动 4 个字节（是一个 `in_addr` 结构的大小）。`ovbcopy` 完成复制。`bzero` 清除缓存开始的 4 个字节。

3. 扫描选项表

593-606 `for` 循环扫描选项表，寻找 LSRR 和 SSRR 选项。对多字节选项，该循环也验证选项的长度是否合理。

4. 重新安排 LSRR 和 SSRR 选项

607-638 当该循环找到一个 LSRR 或 SSRR 选项时，它把缓存的大小、循环变量和选项长度减去 4，因为选项的每一个地址将被移走，并被移到缓存的前面。

`bcopy` 把第一个地址移走，`ovbcopy` 把选项的其他部分移动 4 个字节，来填补第一个地

址留下的空隙。

5. 清除

639-646 循环结束后，选项表的大小(包括第一跳地址)必须不超过44 (MAX_IPOPTLEN + 4)字节。更长的选项表无法放入 IP分组的首部。该表被保存在 *pcbopt 中，函数返回。

9.10 一些限制

除了管理和诊断工具生成的 IP数据报外，很少出现选项。卷 1讨论了两个最常用的工具，ping和traceroute。使用IP选项的应用程序很难写。编程接口的文档很少，也没有很好地标准化。许多厂商提供的应用程序，比如 Telnet和FTP，并没有为用户提供方法，来指定如源路由等的选项。

在大的互联网上，记录路由、时间戳和源路由选项的用途被 IP首部的最大长度所限制。许多路由含有的跳数远多于 40选项字节所能表示的。当多选项在同一分组中出现时，所能得到的空间是几乎没有用的。IPv6用一个更为灵活的选项首部设计强调了这个问题。

在分片过程中，IP只把某些选项复制到非初始片上，因为重组时会扔掉非初始片上的选项。在目的主机上，运输层协议只能用到初始片上的选项 (10.6节)。但有些选项，如源路由，即使在目的主机上，被非初始片丢弃，依然必须被复制到每个分片。

9.11 小结

本章中我们显示了 IP选项的格式和处理过程。我们没有讨论安全和流 ID选项，因为Net/3没有实现它们。

我们看到，多字节选项的大小是由源主机在构造它们时确定的。最大选项首部长度只有 40字节，这严格限制了IP选项的使用。

源路由选项要求最多的支持。到达的源路由被 save_rte 保存，并保留在 ip_srcroute 中。通常不转发分组的主机可能转发源路由选择的分组，但是 RFC 1122默认要求不允许这种功能。Net/3没有对这种特性的判断，总是转发源路由选择的分组。

最后，我们看到 ip_insertoptions是如何把选项插入到一个外出的分组中去的。

习题

- 9.1 如果一个分组中有两个不同的源路由选项会发生什么情况？
- 9.2 一些商用路由器可以被配置成按照分组的 IP目的地址扔掉它们。通过种方式，可以把一台或一组主机通过路由器隔离在更大的互联网之外。请描述源路由选择的分组如何绕过这个机制。假定网络中至少有一个主机，路由器没有阻塞，并转发源路由选择的数据报。
- 9.3 某些主机可能没有被配置成默认路由。这样主机就无法路由选择到其他与它直接相连的网络。请描述源路由如何与这种类型的主机通信。
- 9.4 为什么NOP采用如图9-16所示的 ip_srcrt 结构？
- 9.5 时间戳选项中非标准时间值会和标准时间值混淆吗？
- 9.6 ip_dooptions在处理其他选项之前要把分组的目的地址保存在 dest 中(图9-8)。为什么？

第10章 IP的分片与重装

10.1 引言

我们将第8章的IP的分片与重装处理问题推迟到本章来讨论。

IP具有一种重要功能，就是当分组过大而不适合在所选硬件接口上发送时，能够对分组进行分片。过大的分组被分成两个或多个大小适合在所选定网络上发送的IP分片。而在去目的主机的路途中，分片还可能被中间的路由器继续分片。因此，在目的主机上，一个IP数据报可能放在一个IP分组内，或者，如果在发送时被分片，就放在多个IP分组内。因为各个分片可能以不同的路径到达目的主机，所以只有目的主机才有机会看到所有分片。因此，也只有目的主机才能把所有分片重装成一个完整的数据报，提交给合适的运输层协议。

图8-5显示在被接收的分组中，0.3%(72 786/27 881 978)是分片，0.12% (264 484/(29 447 726-796 084))的数据报是被分片后发送的。在world.std.com上，被接收分组的9.5%是被分片的。world有更多的NFS活动，这是IP分片的主要来源。

IP首部内有三个字段实现分片和重装：标识字段(ip_id)、标志字段(ip_off的3个高位比特)和偏移字段(ip_off的13个低位比特)。标志字段由三个1 bit标志组成。比特0是保留的，必须为0；比特1是“不分片”(DF)标志；比特2是“更多分片”(MF)标志。Net/3中，标志和偏移字段结合起来，由ip_off访问，如图10-1所示。



图10-1 ip_off 控制IP分组的分片

Net/3通过用IP_DF和IP_MF掩去ip_off来访问DF和MF。IP实现必须允许应用程序请求在输出的数据报中设置DF比特。

当使用UDP或TCP时，Net/3并不提供对DF比特的应用程序级的控制。

进程可以用原始IP接口(第32章)构造和发送它自己的IP首部。运输层必须直接设置DF比特。例如，当TCP运行“路径MTU发现(path MTU discovery)”时。

ip_off的其他13 bit指出在原始数据报内分片的位置，以8字节为单元计算。因而，除最后一个分片外，其他每个分片都希望是一个8字节倍数的数据，从而使后面的分片从8字节边界开始。图10-2显示了在原始数据报内的字节偏移关系，以及在分片的IP首部内分片的偏移(ip_off的低位13 bit)。

图10-2显示了把一个最大的IP数据报分成8190个分片，除最后一个分片包含3个字节外，其他每个分片都包含8个字节。图中还显示，除最后一个分片外，设置了其余分片的MF比特。这是一个不太理想的例子，但它说明了一些实现中存在的问题。

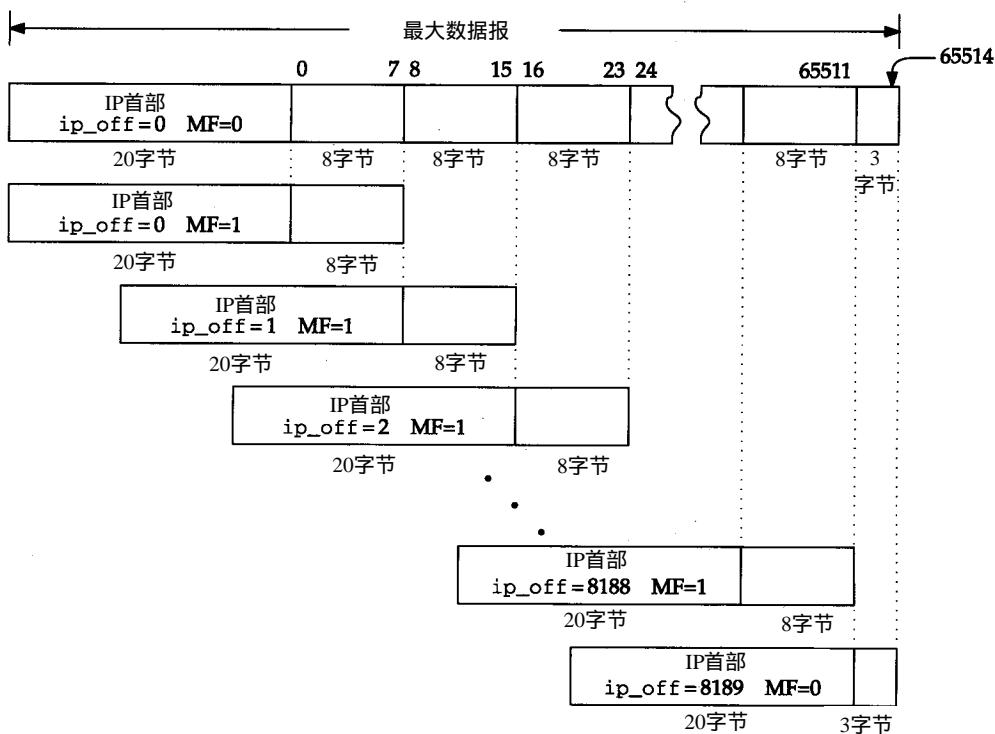


图10-2 65535字节的数据报的分片

原始数据报上面的数字是该数据部分在数据报内的字节偏移。分片偏移 (`ip_off`)是从数据报的数据部分开始计算的。分片不可能含有偏移超过 65514 的字节，因为如果这样的话，重装的数据报会大于 65535 字节——这是 `ip_len` 字段的最大值。这就限制了 `ip_off` 的最大值为 8189 ($8189 \times 8 = 65512$)，只为最后一个分片留下 3 字节空间。如果有 IP 选项，则偏移还要小些。

因为 IP 互联网是无连接的，所以，在目的主机上，来自一个数据报的分片必然会与来自其他数据报的分片交错。`ip_id` 唯一地标识某个特定数据报的分片。源系统用相同的源地址 (`ip_src`)、目的地址 (`ip_dst`) 和协议 (`ip_p`) 值，作为数据报在互联网上生命期的值，把每个数据报的 `ip_id` 设置成一个唯一的值。

总而言之，`ip_id` 标识了特定数据报的分片，`ip_off` 确定了分片在原始数据报内的位置，除最后一个分片外，MF 标识每个分片。

10.2 代码介绍

重装数据结构出现在一个头文件里。两个 C 文件中有重装和分片处理的代码。这三个文件列在图 10-3 中。

文 件	描 述
<code>netinet/ip_var.h</code>	重装数据结构
<code>netinet/ip_output.c</code>	分片代码
<code>netinet/ip_input.c</code>	重装代码

图10-3 本章讨论的文件

10.2.1 全局变量

本章中只有一个全局变量，`ipq`。如图10-4所示。

变 量	类 型	描 述
<code>ipq</code>	<code>struct ipq *</code>	重装表

图10-4 本章介绍的全局变量

10.2.2 统计量

分片和重装代码修改的统计量如图 10-5 所示。它们是图 8-4 的 `ipstat` 结构中所包含统计量的子集。

ipstat成员	描 述
<code>ips_cantfrag</code>	要求分片但被 DF 比特禁止而没有发送的数据报数
<code>ips_odropped</code>	因为内存不够而被丢弃的分组数
<code>ips_ofragments</code>	被发送的分片数
<code>ips_fragmented</code>	为输出分片的分组数

图10-5 本章收集的统计量

10.3 分片

我们现在返回到 `ip_output`，分析分片代码。记得在图 8-25 中，如果分组正好适合选定出接口的 MTU，就在一个链路级帧中发送它。否则，必须对分组分片，并在多个帧中将其发送。分组可以是一个完整的数据报或者它自己也是前边系统创建的分片。我们分三个部分讨论分片代码：

- 确定分片大小(图10-6)；
- 构造分片表(图10-7)；以及
- 构造第一个分片并发送分片(图10-8)。

```

253     /*                                         ip_output.c
254      * Too large for interface; fragment if possible.
255      * Must be able to put at least 8 bytes per fragment.
256      */
257      if (ip->ip_off & IP_DF) {
258          error = EMSGSIZE;
259          ipstat.ips_cantfrag++;
260          goto bad;
261      }
262      len = (ifp->if_mtu - hlen) & ~7;
263      if (len < 8) {
264          error = EMSGSIZE;
265          goto bad;
266      }

```

ip_output.c

图10-6 函数 `ip_output`：确定分片大小

253-261 分片算法很简单，但由于对 mbuf 结构和链的操作使实现非常复杂。如果 DF 比特禁

止分片，则 `ip_output` 丢弃该分组，并返回 `EMSGSIZE`。如果该数据报是在本地生成的，则运输层协议把该错误传回该进程；但如果分组是被转发的，则 `ip_forward` 生成一个ICMP目的地不可达差错报文，并指出不分片就无法转发该分组（图8-21）。

Net/3没有实现“路径MTU发现”算法，该算法用来搜索到目的主机的路径，并发现所有中间网络支持的最大传送单元。卷1的11.8节和24.2节讨论了UDP和TCP的路径MTU发现。

262-266 每个分片中的数据字节数，`len`的计算是用接口的MTU减去分组首部的长度后，舍去低位的3个比特(&~7)。后成为8字节倍数。如果MTU太小，使每个分片中无法含有8字节的数据，则 `ip_output` 返回 `EMSGSIZE`。

每个新的分片中都包含：一个IP首部、某些原始分组中的选项以及最多 `len` 长度的数据。

图10-7中的代码，以一个C的复合语句开始，构造了从第2个分片开始的分片表。在表生成后（图10-8），原来的分组被转换成第一个分片。

```

267  {
268      int      mhlen, firstlen = len;
269      struct mbuf **mnnext = &m->m_nextpkt;
270
271      /*
272      * Loop through length of segment after first fragment,
273      * make new header and copy data of each part and link onto chain.
274      */
275      m0 = m;
276      mhlen = sizeof(struct ip);
277      for (off = hlen + len; off < (u_short) ip->ip_len; off += len) {
278          MGETHDR(m, M_DONTWAIT, MT_HEADER);
279          if (m == 0) {
280              error = ENOBUFS;
281              ipstat.ips_odropped++;
282              goto sendorfree;
283          }
284          m->m_data += max_linkhdr;
285          mhip = mtod(m, struct ip *);
286          *mhip = *ip;
287          if (hlen > sizeof(struct ip)) {
288              mhlen = ip_optcopy(ip, mhip) + sizeof(struct ip);
289              mhip->ip_hl = mhlen >> 2;
290          }
291          m->m_len = mhlen;
292          mhip->ip_off = ((off - hlen) >> 3) + (ip->ip_off & ~IP_MF);
293          if (ip->ip_off & IP_MF)
294              mhip->ip_off |= IP_MF;
295          if (off + len >= (u_short) ip->ip_len)
296              len = (u_short) ip->ip_len - off;
297          else
298              mhip->ip_off |= IP_MF;
299          mhip->ip_len = htons((u_short) (len + mhlen));
300          m->m_next = m_copy(m0, off, len);
301          if (m->m_next == 0) {
302              (void) m_free(m);
303              error = ENOBUFS; /* ??? */
304              ipstat.ips_odropped++;
305              goto sendorfree;
306          }
307          m->m_pkthdr.len = mhlen + len;

```

图10-7 函数 `ip_output`：构造分片表

```

307     m->m_pkthdr.rcvif = (struct ifnet *) 0;
308     mhip->ip_off = htons((u_short) mhip->ip_off);
309     mhip->ip_sum = 0;
310     mhip->ip_sum = in_cksum(m, mhlen);
311     *mnnext = m;
312     mnnext = &m->m_nextpkt;
313     ipstat.ips_ofragments++;
314 }

```

ip_output.c

图10-7 (续)

```

315     /*
316      * Update first fragment by trimming what's been copied out
317      * and updating header, then send each fragment (in order).
318      */
319     m = m0;
320     m_adj(m, hlen + firstlen - (u_short) ip->ip_len);
321     m->m_pkthdr.len = hlen + firstlen;
322     ip->ip_len = htons((u_short) m->m_pkthdr.len);
323     ip->ip_off = htons((u_short) (ip->ip_off | IP_MF));
324     ip->ip_sum = 0;
325     ip->ip_sum = in_cksum(m, hlen);
326     sendorfree:
327     for (m = m0; m; m = m0) {
328         m0 = m->m_nextpkt;
329         m->m_nextpkt = 0;
330         if (error == 0)
331             error = (*ifp->if_output) (ifp, m,
332                                         (struct sockaddr *) dst, ro->ro_rt);
333         else
334             m_free(m);
335     }
336     if (error == 0)
337         ipstat.ips_fragmented++;
338 }

```

*ip_output.c*图10-8 函数 *ip_output* : 发送分片

267-269 外部块允许在函数中离使用点更近一点的地方定义 mhlen、firstlen 和 mnnext。这些变量的范围一直到块的末尾，它们隐藏其他在块外定义的有相同名字的变量。

270-276 因为原来的缓存链现在成了第一个分片，所以 for 循环从第 2 个分片的偏移开始：hlen+len。对每个分片，*ip_output*采取以下动作：

- 277-284 分配一个新的分组缓存，调整 m_data 指针，为一个 16 字节链路层首部 (max_linkhdr)腾出空间。如果 *ip_output*不这么做，则网络接口驱动器就必须再分配一个mbuf来存放链路层首部或移动数据。两种工作都很耗时，在这里就很容易避免。
- 285-290 从原来的分组中把IP首部和IP选项复制到新的分组中。前者复制在一个结构中。*ip_optcopy*只复制那些将被复制到每个分片中的选项(10.4节)。
- 291-297 设置分片包括MF比特的偏移字段(ip_off)。如果原来分组中已设置了MF比特，则在所有分片中都把MF置位。如果原来分组中没有设置MF比特，则除了最后一个分片外，其他所有分片中的MF都置位。
- 298 为分片设置长度，解决首部小一些(*ip_optcopy*可能没有复制所有选项)，以及最后一个分片的数据区小一些的问题。以网络字节序存储长度。

- 299-305 从原始分组中把数据复制到该分片中。如果必要，`m_copy`会再分配一个`mbuf`。如果`m_copy`失败，则发出`ENOBUFS`。`sendorfree`丢弃所有已被分配的缓存。
- 306-314 调整新创建的分片的`mbuf`分组首部，使其具有正确的全长。把新分片的接口指针清零，把`ip_off`转换成网络字节序，计算新分片的检验和。通过`m_nextpkt`把该分片与前面的分片链接起来。

在图10-8中，`ip_output`构造了第一个分片，并把每个分片传递到接口层。

315-325 把末尾多余的数据截断后，原来的分组就被转换成第一个分片，同时设置MF比特，把`ip_len`和`ip_off`转换成网络字节序，计算新的检验和。在这个分片中，保留所有的IP选项。在目的主机重装时，只保留数据报的第一个分片的IP选项(图10-28)。某些选项，如源路由选项，必须被复制到每个分片中，即使在重装时都被丢弃了。

326-338 此时，`ip_output`可能有一个完整的分片表，或者已经产生了错误，都必须把生成的那部分分片表丢弃。`for`循环遍历该表，发送分片或者由于`error`而丢弃分片。在发送期间遇到的所有错误都会使后面的分片被丢弃。

10.4 ip_optcopy函数

在分片过程中，`ip_optcopy`(图10-9)复制到达分组(如果分组是被转发的)或者原始数据报中(如果该数据报是在本地生成的)中的选项到外出的分片中。

```
395 int ip_optcopy(ip, jp)
396 struct ip *ip, *jp;
397
398 {
399     u_char *cp, *dp;
400     int opt, optlen, cnt;
401
402     cp = (u_char *) (ip + 1);
403     dp = (u_char *) (jp + 1);
404     cnt = (ip->ip_hl << 2) - sizeof(struct ip);
405     for (; cnt > 0; cnt -= optlen, cp += optlen) {
406         opt = cp[0];
407         if (opt == IPOPT_EOL)
408             break;
409         if (opt == IPOPT_NOP) {
410             /* Preserve for IP mcast tunnel's LSRR alignment. */
411             *dp++ = IPOPT_NOP;
412             optlen = 1;
413             continue;
414         } else
415             optlen = cp[IPOPT_OLEN];
416         /* bogus lengths should have been caught by ip_dooptions */
417         if (optlen > cnt)
418             optlen = cnt;
419         if (IPOPT_COPIED(opt)) {
420             bcopy((caddr_t) cp, (caddr_t) dp, (unsigned) optlen);
421             dp += optlen;
422         }
423         for (optlen = dp - (u_char *) (jp + 1); optlen & 0x3; optlen++)
424             *dp++ = IPOPT_EOL;
425     }
426 }
```

ip_output.c

图10-9 函数：确定分片大小

395-422 `ip_optcopy`的参数是：`ip`，一个指向外出分组的IP首部的指针；`jp`，一个指向新生成的分片的IP首部的指针；`ip_optcopy`初始化`cp`和`dp`指向每个分组的第一个选项，并在处理每个选项时把`cp`和`dp`向前移动。第一个`for`循环在每次重复时复制一个选项，当它遇到EOL选项或已经检查完所有选项时。`NOP`选项被复制，用来维持后继选项的对齐限制。

Net/2版本废除了`NOP`选项。

如果`IPOPT_COPIED`指示`copied`比特被置位，则`ip_optcopy`把选项复制到新片中。图9-5显示了哪些选项的`copied`比特是被置位的。如果某个选项的长度太大，就被截断；`ip_dooptions`应该已经发现这种错误了。

423-426 第2个`for`循环把选项表填充到4字节的边界。由于分组首部长度(`ip_hlen`)是以4字节为单位计算的，所以需要这个操作。这也保证了后面跟着的运输层首部与4字节边界对齐。这样会提高性能，因为在许多运输层协议的设计中，如果运输层首部从一个32 bit边界开始，那么32 bit首部字段将按照32 bit边界对齐。在某些机器上，CPU访问32 bit对齐的字有困难，这时，这种字节安排就提高了CPU的性能。

图10-10显示了`ip_optcopy`的运行。

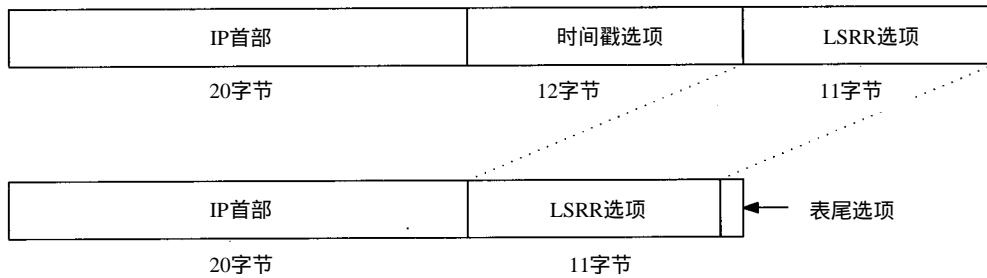


图10-10 在分片中并不复制所有选项

在图10-10中，我们看到`ip_optcopy`不复制时间戳选项(它的`copied`比特为0)，但却复制LSRR选项(它的`copied`比特为1)。为了把新选项与4字节边界对齐，`ip_optcopy`也增加了一个EOL选项。

10.5 重装

到目前为止，我们已经讨论了数据报(或片)的分片，现在再回到`ipintr`讨论重装过程。在图8-15中，我们把`ipintr`中的重装代码省略了，并推迟对它的讨论。`ipintr`可以把数据报整个地交给运输层处理。`ipintr`接收的分片被传给`ip_reass`，由它尝试把分片重装成一个完整的数据报。图10-11显示了`ipintr`的代码。

271-279 我们知道`ip_off`包含DF比特、MF比特以及分片偏移。如果MF比特或分片偏移非零，则DF就被掩盖掉了，分组就是一个必须被重装的分片。如果两者都为零，则分组就是一个完整的数据报。跳过重装代码，执行图10-11中最后的`else`语句，它从全部数据报长度中排除了首部长度。

280-286 `m_pullup`把位于外部簇上的数据移动到`mbuf`的数据区。我们记得，如果一个缓存区无法容纳外部簇上的一个IP分组，则SLIP接口(5.3节)可能会把该分组整个返回。

`m_devget`也会全部返回外部簇上的某个IP分组(2.6节)。在`mtod`宏(2.6节)开始工作之前，

m_pullup必须把IP首部从外部簇上移到mbuf的数据区中去。

ip_input.c

```

271 ours:
272 /*
273 * If offset or IP_MF are set, must reassemble.
274 * Otherwise, nothing need be done.
275 * (We could look in the reassembly queue to see
276 * if the packet was previously fragmented,
277 * but it's not worth the time; just let them time out.)
278 */
279 if (ip->ip_off & ~IP_DF) {
280     if (m->m_flags & M_EXT) { /* XXX */
281         if ((m = m_pullup(m, sizeof(struct ip))) == 0) {
282             ipstat.ips_toosmall++;
283             goto next;
284         }
285         ip = mtod(m, struct ip *);
286     }
287     /*
288      * Look for queue of fragments
289      * of this datagram.
290     */
291     for (fp = ipq.next; fp != &ipq; fp = fp->next)
292         if (ip->ip_id == fp->ipq_id &&
293             ip->ip_src.s_addr == fp->ipq_src.s_addr &&
294             ip->ip_dst.s_addr == fp->ipq_dst.s_addr &&
295             ip->ip_p == fp->ipq_p)
296             goto found;
297     fp = 0;
298 found:
299     /*
300      * Adjust ip_len to not reflect header,
301      * set ip_mff if more fragments are expected,
302      * convert offset of this to bytes.
303     */
304     ip->ip_len -= hlen;
305     ((struct ipasfrag *) ip)->ipf_mff &= ~1;
306     if (ip->ip_off & IP_MF)
307         ((struct ipasfrag *) ip)->ipf_mff |= 1;
308     ip->ip_off <= 3;
309     /*
310      * If datagram marked as having more fragments
311      * or if this is not the first fragment,
312      * attempt reassembly; if it succeeds, proceed.
313     */
314     if (((struct ipasfrag *) ip)->ipf_mff & 1 || ip->ip_off) {
315         ipstat.ips_fragments++;
316         ip = ip_reass((struct ipasfrag *) ip, fp);
317         if (ip == 0)
318             goto next;
319         ipstat.ips_reassembled++;
320         m = dtom(ip);
321     } else if (fp)
322         ip_freef(fp);
323 } else
324     ip->ip_len -= hlen;

```

ip_input.c

图10-11 函数 ipintr : 分片处理

287-297 Net/3在一个全局双向链表 ipq 上记录不完整的数据报。这个名字可能容易产生误解，因为这个数据结构并不是一个队列。也就是说，可以在表的任何地方插入和删除，并不限制一定要在末尾。我们将用名词“表 (list)”来强调这个事实。

ipintr 对表进行线性搜索，为当前分片找到合适的数据报。记住分片是由 4 元组 {ip_id、ip_src、ip_dst 和 ip_p} 唯一标识的。ipq 的每个入口是一个分片表，如果 ipintr 找到一个匹配，则 fp 指向匹配的表。

Net/3 采用线性搜索来访问它的许多数据结构。尽管简单，但是当主机支持大量网络连接时，这种方法就成为瓶颈。

298-303 在 found 语句，ipintr 为方便重装，修改了分组：

- 304 ipintr 修改 ip_len，从中减去标准 IP 首部和任何选项。我们必须牢记这一点，以免混淆对标准 ip_len 解释的理解。标准 ip_len 中包含了标准首部、选项和数据。如果跳过重装代码，ip_len 也会被改变，因为这个分组不是一个分片。
- 305-307 ipintr 把 MF 标志复制到 ipf_mff 的低位，把 ip_tos 覆盖掉 (&=1 只清除低位)。注意，在 ipf_mff 成为一个有效成员之前，必须把 ip 指一个 ipasfrag 结构。10.6 节和图 10-14 描述了 ipasfrag 结构。

尽管 RFC 1122 要求 IP 层提供某种机制，允许运输层为每个外出的数据报设置 ip_tos 比特。但它只推荐，在目的主机，IP 层把 ip_tos 值传给运输层。因为 TOS 字段的低位字节必须总是 0，所以当重装算法使用 ip_off(通常在这里找到 MF 比特) 时，可以得到 MF 比特。

现在，可以把 ip_off 作为一个 16 bit 偏移，而不是 3 个标志比特和一个 13 bit 偏移来访问了。

- 308 用 8 乘 ip_off，把它从以 8 字节为单元转换成以 1 字节为单元。

ipf_mff 和 ip_off 决定 ipintr 是否应该重装。图 10-12 描述了不同的情况及相应的动作，其中 fp 指向的是系统以前为该数据报接收的分片表。许多工作是由 ip_reass 做的。

309-322 如果 ip_reass 通过把当前分片与以前收到的分片组合在一起，能重装成一个完整的数据报，它就返回指向该重装好的数据报的指针。如果没有重装好，则 ip_reass 保存该分片，ipintr 跳到 next 去处理下一个分片(图 8-12)。

ip_off	ipf_mff	fp	描述	动作
0	假	空	完整数据报	没有要求重装
0	假	非空	完整数据报	丢弃前面的分片
任意	真	空	新数据报的分片	用这个分片初始化新的分片表
任意	真	非空	不完整新数据报的分片	插入到已有的分片表中，尝试重装
非零	假	空	新数据报的末尾分片	初始化新的分片表
非零	假	非空	不完整新数据报的末尾分片	插入到已有的分片表中，尝试重装

图 10-12 ipintr 和 ip_reass 中的 IP 分片处理

323-324 当到达一个完整的数据报时，就选择这个 else 分支，并按照前面的叙述修改 ip_hlen。这是一个普通的流，因为收到的大多数数据报都不是分片。

如果重装处理产生一个完整的数据报，ipintr 就把这个完整的数据报上传给合适的运输

层协议(图8-15)：

```
(*inetsw[ip_protos[ip->ip_p]].pr_input)(m,hlen);
```

10.6 ip_reass函数

ipintr把一个要处理的分片和一个指针传给 ip_reass，其中指针指向的是 ipq 中匹配的重装首部。ip_reass 可能重装成功并返回一个完整的数据报，可能把该分片链接到数据报的重装链表上，等待其他分片到达后重装。每个重装链表的表头是一个 ipq 结构，如图 10-13 所示。

```
52 struct ipq { ip_var.h
53     struct ipq *next, *prev; /* to other reass headers */
54     u_char ipq_ttl; /* time for reass q to live */
55     u_char ipq_p; /* protocol of this fragment */
56     u_short ipq_id; /* sequence id for reassembly */
57     struct ipasfrag *ipq_next, *ipq_prev;
58     /* to ip headers of fragments */
59     struct in_addr ipq_src, ipq_dst;
60 };
```

ip_var.h

图10-13 ipq 结构

52-60 用来标识一个数据报分片的四个字段，ip_id、ip_src、ip_dst 和 ip_p，被保存在每个重装链表表头的 ipq 结构中。Net/3 用 next 和 prev 构造数据报链表，用 ipq_next 和 ipq_prev 构造分片的链表。

到达分组的 IP 首部在被放在重装链表之前，首先被转换成一个 ipasfrag 结构(图10-14)。

```
66 struct ipasfrag { ip_var.h
67 #if BYTE_ORDER == LITTLE_ENDIAN
68     u_char ip_hl:4,
69         ip_v:4;
70 #endif
71 #if BYTE_ORDER == BIG_ENDIAN
72     u_char ip_v:4,
73         ip_hl:4;
74 #endif
75     u_char ipf_mff; /* XXX overlays ip_tos: use low bit
76                         * to avoid destroying tos;
77                         * copied from (ip_off&IP_MF) */
78     short ip_len;
79     u_short ip_id;
80     short ip_off;
81     u_char ip_ttl;
82     u_char ip_p;
83     u_short ip_sum;
84     struct ipasfrag *ipf_next; /* next fragment */
85     struct ipasfrag *ipf_prev; /* previous fragment */
86 };
```

ip_var.h

图10-14 ipasfrag 结构

66-86 ip_reass 在一个由 ipf_next 和 ipf_prev 链接起来的双向循环链表上，收集某个数据报的分片。这些指针覆盖了 IP 首部的源地址和目的地址。ipf_mff 成员覆盖 ip 结构中的

ip_tos。其他成员是相同的。

图10-15显示了分片首部链表(ipq)和分片(ipasfrag)之间的关系。

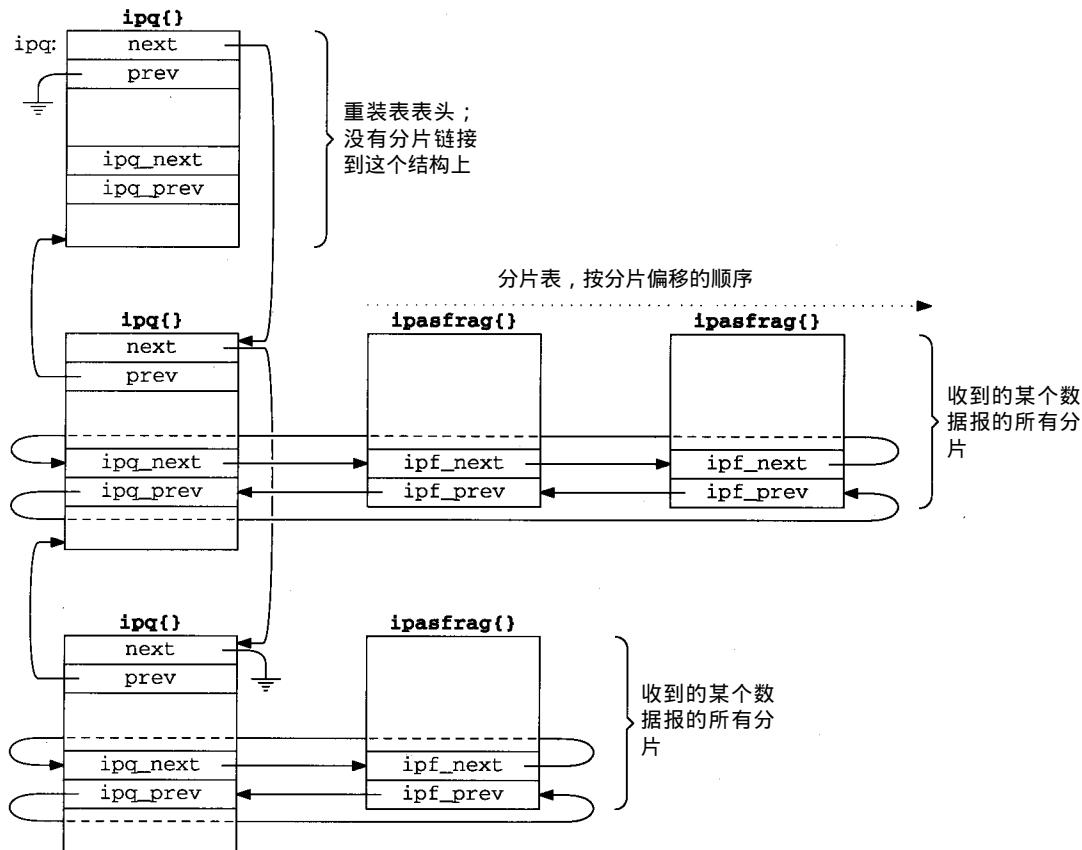


图10-15 分片首部链表 ipq 和分片

图10-15的左下部是重装首部的链表。表中第一个节点是全局 ipq 结构，ipq。它永远不会有自己的相关分片表。ipq 表是一个双向链表，用于支持快速插入和删除。next 和 prev 指针指向前一个和后一个 ipq 结构，用终止结构的角上的箭头表示。

图10-15仍然没有显示重装结构的所有复杂性。重装代码很难跟踪，因为它完全依靠把指针指向底层 mbuf 上的三个不同的结构。我们已经接触过这个技术了，例如，当一个 ip 结构覆盖某个缓存的数据部分时。

图10-16显示了 mbuf、ipq 结构、ipasfrag 结构和 ip 结构之间的关系。

图10-16中含有大量信息：

- 所有结构都放在一个 mbuf 的数据区内。
- ipq 链表由 next 和 prev 链接起来的 ipq 结构组成。每个 ipq 结构保存了唯一标识一个 IP 数据报的四个字段(图10-16中的阴影部分)。
- 当作为分片首部链表的头访问时，每个 ipq 结构被看成是一个 ipasfrag 结构。这些分片由 ipf_next 和 ipf_prev 链接起来，分别覆盖了 ipq 结构的 ipq_next 和 ipq_prev 成员。
- 每个 ipasfrag 结构都覆盖了到达分片的 ip 结构，与分片一起到达的数据在缓存中跟在该结构之后。ipasfrag 结构的阴影部分的成员的含义与其在 ip 结构中不太相同。

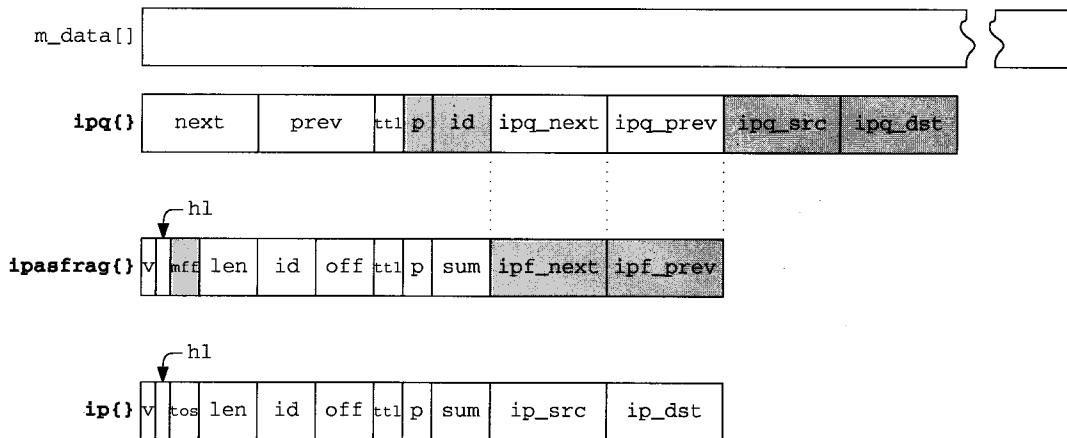


图10-16 可通过多种结构访问的一段内存区

图10-15显示了这些重装结构之间的物理连接，图10-16显示了ip_reass使用的覆盖技术。图10-17从逻辑的观点说明重装结构：该图显示了三个数据报的重装，以及ipq链表和ipasfrag结构之间的关系。

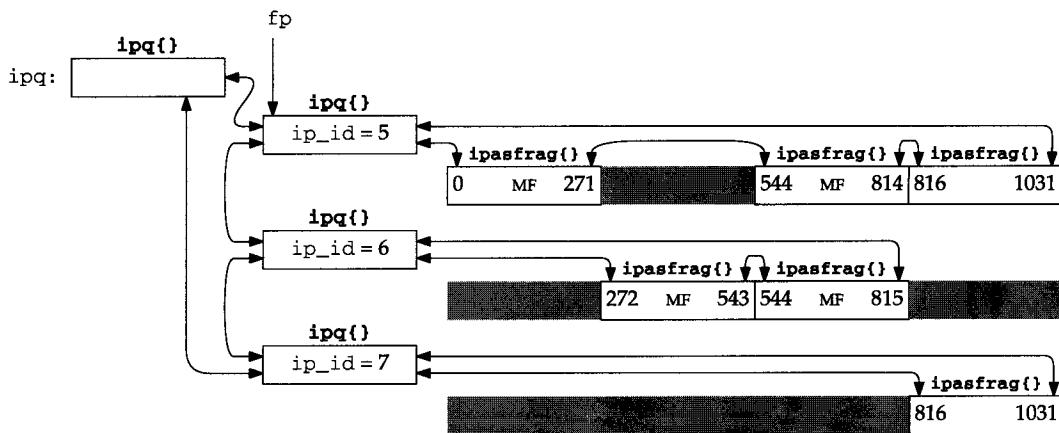


图10-17 三个IP数据报的重装

每个重装链表的表头包含原始数据报的标识符、协议、源和目的地址。图中只显示了ip_id字段。分片表通过偏移字段排序，如果MF比特被置位，则用MF标志分片，缺少的分片出现在阴影里。每个分片内的数字显示了该分片的开始和结束字节相对于原始数据报数据区的相对偏移，而不是相对于原始数据报的IP首部。

这个例子是用来说明三个没有IP选项的UDP数据报，其中每个数据报都有1024字节的数据。每个数据报的全长是 $1052(20+8+1024)$ 字节，正好适合1500字节以太网MTU。在到目的主机的途中，这些数据报会遇到一个SLIP链路，该链路上的路由器对数据报分片，使其大小适于放在典型的296字节的SLIP MTU中。每个数据报分4个分片到达。第1个分片中包含一个标准的20字节IP首部，8字节UDP首部和264字节数据。第2个和第3个分片中包含一个20字节IP首部和272字节数据。最后一个分片中有一个20字节首部和216字节数据($1032=272 \times 3 + 216$)。

在图10-17中，数据报5缺少一个包含272~543字节的分片。数据报6缺少第一个分片，

0~271字节，以及最后一个从偏移816开始的分片。数据报7缺少前三个分片，0~815。

图10-18列出了ip_reass。前面讲到，当目的地是本主机的某个IP分片到达时，在处理完所有选项后，ipintr会调用ip_reass。

```

337 /*
338  * Take incoming datagram fragment and try to
339  * reassemble it into whole datagram. If a chain for
340  * reassembly of this datagram already exists, then it
341  * is given as fp; otherwise have to make a chain.
342 */
343 struct ip *
344 ip_reass(ip, fp)
345 struct ipasfrag *ip;
346 struct ipq *fp;
347 {
348     struct mbuf *m = dtom(ip);
349     struct ipasfrag *q;
350     struct mbuf *t;
351     int hlen = ip->ip_hl << 2;
352     int i, next;
353     /*
354      * Presence of header sizes in mbufs
355      * would confuse code below.
356      */
357     m->m_data += hlen;
358     m->m_len -= hlen;
359
360     /* XXX */
361
362     if (m->m_pkthdr.hlen <= 0) {
363         /* XXX */
364         if (m->m_pkthdr.hlen <= 0) {
365             /* XXX */
366             if (m->m_pkthdr.hlen <= 0) {
367                 /* XXX */
368                 if (m->m_pkthdr.hlen <= 0) {
369                     /* XXX */
370                     if (m->m_pkthdr.hlen <= 0) {
371                         /* XXX */
372                         if (m->m_pkthdr.hlen <= 0) {
373                             /* XXX */
374                             if (m->m_pkthdr.hlen <= 0) {
375                                 /* XXX */
376                                 if (m->m_pkthdr.hlen <= 0) {
377                                     /* XXX */
378                                     if (m->m_pkthdr.hlen <= 0) {
379                                         /* XXX */
380                                         if (m->m_pkthdr.hlen <= 0) {
381                                             /* XXX */
382                                             if (m->m_pkthdr.hlen <= 0) {
383                                                 /* XXX */
384                                                 if (m->m_pkthdr.hlen <= 0) {
385                                                     /* XXX */
386                                                     if (m->m_pkthdr.hlen <= 0) {
387                                                         /* XXX */
388                                                         if (m->m_pkthdr.hlen <= 0) {
389                                                             /* XXX */
390                                                             if (m->m_pkthdr.hlen <= 0) {
391                                                                 /* XXX */
392                                                                 if (m->m_pkthdr.hlen <= 0) {
393                                                                     /* XXX */
394                                                                     if (m->m_pkthdr.hlen <= 0) {
395                                                                         /* XXX */
396                                                                         if (m->m_pkthdr.hlen <= 0) {
397                                                                             /* XXX */
398                                                                             if (m->m_pkthdr.hlen <= 0) {
399                                                                                 /* XXX */
400                                                                                 if (m->m_pkthdr.hlen <= 0) {
401                                                                 /* XXX */
402                                                                 if (m->m_pkthdr.hlen <= 0) {
403                                                                     /* XXX */
404                                                                     if (m->m_pkthdr.hlen <= 0) {
405                                                                         /* XXX */
406                                                                         if (m->m_pkthdr.hlen <= 0) {
407                                                                             /* XXX */
408                                                                             if (m->m_pkthdr.hlen <= 0) {
409                                                                                 /* XXX */
410                                                                                 if (m->m_pkthdr.hlen <= 0) {
411                                                                 /* XXX */
412                                                                 if (m->m_pkthdr.hlen <= 0) {
413                                                                     /* XXX */
414                                                                     if (m->m_pkthdr.hlen <= 0) {
415                                                                         /* XXX */
416                                                                         if (m->m_pkthdr.hlen <= 0) {
417                                                                             /* XXX */
418                                                                             if (m->m_pkthdr.hlen <= 0) {
419                                                                                 /* XXX */
420                                                                                 if (m->m_pkthdr.hlen <= 0) {
421                                                                 /* XXX */
422                                                                 if (m->m_pkthdr.hlen <= 0) {
423                                                                     /* XXX */
424                                                                     if (m->m_pkthdr.hlen <= 0) {
425                                                                         /* XXX */
426                                                                         if (m->m_pkthdr.hlen <= 0) {
427                                                                             /* XXX */
428                                                                             if (m->m_pkthdr.hlen <= 0) {
429                                                                                 /* XXX */
430                                                                                 if (m->m_pkthdr.hlen <= 0) {
431                                                                 /* XXX */
432                                                                 if (m->m_pkthdr.hlen <= 0) {
433                                                                     /* XXX */
434                                                                     if (m->m_pkthdr.hlen <= 0) {
435                                                                         /* XXX */
436                                                                         if (m->m_pkthdr.hlen <= 0) {
437                                                                             /* XXX */
438                                                                             if (m->m_pkthdr.hlen <= 0) {
439                                                                                 /* XXX */
440                                                                                 if (m->m_pkthdr.hlen <= 0) {
441                                                                 /* XXX */
442                                                                 if (m->m_pkthdr.hlen <= 0) {
443                                                                     /* XXX */
444                                                                     if (m->m_pkthdr.hlen <= 0) {
445                                                                         /* XXX */
446                                                                         if (m->m_pkthdr.hlen <= 0) {
447                                                                             /* XXX */
448                                                                             if (m->m_pkthdr.hlen <= 0) {
449                                                                                 /* XXX */
450                                                                                 if (m->m_pkthdr.hlen <= 0) {
451                                                                 /* XXX */
452                                                                 if (m->m_pkthdr.hlen <= 0) {
453                                                                     /* XXX */
454                                                                     if (m->m_pkthdr.hlen <= 0) {
455                                                                         /* XXX */
456                                                                         if (m->m_pkthdr.hlen <= 0) {
457                                                                             /* XXX */
458                                                                             if (m->m_pkthdr.hlen <= 0) {
459                                                                                 /* XXX */
460                                                                                 if (m->m_pkthdr.hlen <= 0) {
461                                                                 /* XXX */
462                                                                 if (m->m_pkthdr.hlen <= 0) {
463                                                                     /* XXX */
464                                                                     if (m->m_pkthdr.hlen <= 0) {
465                                                                         /* XXX */
466                                                                         if (m->m_pkthdr.hlen <= 0) {
467                                                                             /* XXX */
468                                                                             if (m->m_pkthdr.hlen <= 0) {
469                                                                                 /* XXX */
470
471     dropfrag:
472     ipstat.ips_fragdropped++;
473     m_free(m);
474     return (0);
475 }
```

ip_input.c

图10-18 函数ip_reass：数据报重装

343-358 当调用ip_reass时，ip指向分片fp或者指向匹配的ipq结构或者为空。

因为重装只涉及每个分片的数据部分，所以ip_reass调整含有该分片的mbuf的m_data和m_len，减去每个分片的IP首部。

465-469 在重装过程中，如果产生错误，该函数就跳到dropfrag。dropfrag增加ips_fragdropped，丢弃该分片，并返回一个空指针。

在运输层丢弃分片通常会严重降低性能，因为必须重传整个数据报。TCP谨慎地避免分片，但是UDP应用程序必须采取步骤以避免对自己分片。[Kent和Mogul 1987]解释了为什么应该避免分片。

所有IP实现必须能够重装最多576字节的数据报。没有通用的方法来确定远程主机能重装的最大数据报的大小。我们将在27.5节中看到TCP提供了一个机制，可以确定远程主机所能处理的最大数据报的大小。UDP没有这样的机制，所以许多基于UDP的协议(例如，RIP、TFTP、BOOTP、SNMP和DNS)，都限制在576字节左右。

我们将分7个部分显示重装代码，从图10-19开始。

```

359  /*
360   * If first fragment to arrive, create a reassembly queue.
361   */
362  if (fp == 0) {
363      if ((t = m_get(M_DONTWAIT, MT_FTABLE)) == NULL)
364          goto dropfrag;
365      fp = mtod(t, struct ipq *);
366      insque(fp, &ipq);
367      fp->ipq_ttl = IPFRAGTTL;
368      fp->ipq_p = ip->ip_p;
369      fp->ipq_id = ip->ip_id;
370      fp->ipq_next = fp->ipq_prev = (struct ipasfrag *) fp;
371      fp->ipq_src = ((struct ip *) ip)->ip_src;
372      fp->ipq_dst = ((struct ip *) ip)->ip_dst;
373      q = (struct ipasfrag *) fp;
374      goto insert;
375  }

```

ip_input.c

图10-19 函数 ip_reass : 创建重装表

1. 创建重装表

359-366 当fp为空时，ip_reass用新的数据报的第一个分片创建一个重装表。它分配一个mbuf来存放新表的头(一个ipq结构)，并调用insque，把该结构插入到重装表的链表中。

图10-20列出了操作数据报和分片链表的函数。

Net/3的386版本是在machdep.c文件中定义insque和remque函数的。每台机器都有自己的文件，在其中定义核心函数，通常是为提高性能。该文件也包括与机器体系结构有关的函数，包括中断处理支持、CPU和设备配置以及内存管理函数。

insque和remque的存在主要是为了维护内核执行队列。Net/3可把它们用于数据报重装链表，因为链表具有下一个和前一个两个指针，分别作为各自节点结构的前两个成员。对任何类型结构的链表，这些函数同样可以用，尽管编译器可能会发出一些警告。这也是另一个通过两个不同结构访问内存的例子。

在所有内核结构里，下一个指针通常位于前一个指针的前面（例如，图10-14）。这是因为insque和remque最早是在VAX上用insque和remque硬件指令实现的，这些指令要求前向和后向指针具有这种顺序。

分片表不是用ipasfrag结构的前两个成员链接起来的（图10-14），所以Net/3调用ip_deq和ip_enq而不是insque和remque。

函数	描述
insque	紧接在prev后面插入node void insque (void *node, void *prev);
Remque	把node从表中移走 void remque (void *node);
ip_enq	紧接在分片prev后面插入分片p void ip_enq (struct ipasfrag *, Struct ipasfrag *prev);
ip_deq	移走分片p void ip_deq (struct ipasfrag *);

图10-20 ip_reass 采用的队列函数

2. 重装超时

367 RFC 1122要求有生命期字段(ipq_ttl)，并限制Net/3等待分片以完成一个数据报的时间。这与IP首部的TTL字段是不同的，IP首部的TTL字段是为了限制分组在互联网中循环的时间。重用IP首部的TTL字段作为重装超时的原因在于，一旦分片到达它的最终目的地，就不再需要首部TTL。

在Net/3中，重装超时的初始值设为60(IPFRAGTTL)。因为每次内核调用ip_slowtimo时，ipq_ttl就减去1，而内核每500 ms调用ip_slowtimo一次。如果系统在接收到数据报的任一分片30秒后，还没有组装好一个完整的IP数据报，那么系统就丢弃该IP重装链表。重装定时器在链表被创建后的第一次调用ip_slowtimo时开始计时。

RFC 1122推荐重装时间在60~120秒内，并且当收到数据报的第一个分片且定时器超时时，向源主机发出一个ICMP超时差错报文。重装后，总是丢弃其他分片的首部和选项，并且在ICMP差错报文中必须包含出错数据报的前64 bit(或者，如果该数据报短于8字节，就可以少一些)。所以，如果内核还没有接收到分片0，它就不能发ICMP报文。

Net/3的定时器要短一些，并且当丢弃分片时，Net/3不发送ICMP报文。要求返回数据报的前64 bit保证含有运输层首部的前端，这样就可以把差错报文返回给发生错误的应用程序。注意，因为这个原因，TCP和UDP有意把它们的端口号放在首部的前8个字节。

3. 数据报标识符

368-375 ip_reass在分配给该数据报的ipq结构中保存ip_p、ip_id、ip_src和ip_dst，让ipq_next和ipq_prev指针指向该ipq结构(也就是说，它用一个节点构造一个循环链表)，让q指向这个结构，并跳到insert(图10-25)，把第一个分片ip插入到新的重装表中去。

ip_reass的下一个部分(图10-21)是当fp不空，并已当前表中为新的分片找到正确位置后执行的。

```

376  /*
377   * Find a fragment which begins after this one does.
378   */
379   for (q = fp->ipq_next; q != (struct ipasfrag *) fp; q = q->ipf_next)
380     if (q->ip_off > ip->ip_off)
381       break;

```

ip_input.c

ip_input.c

图10-21 函数ip_reass：在重装链表中找位置

376-381 因为fp不空，所以for循环搜索数据报的分片链表，找到一个偏移大于ip_off的分片。

在目的主机上，分片包含的字节范围可能会相互覆盖。发生这种情况的原因是，当一个运输层协议重传某个数据报时，采用与原来数据报不同的路由；而且，分片的模式也可能不同，这就导致在目的主机上的相互覆盖。传输协议必须能强制IP使用原来的ID字段，确保目的主机识别出该数据报是重传的。

Net/3并不为运输层协议提供机制保证在重传的数据报中重用IP ID字段。在准备

新数据报时，`ip_output`通过增加全局整数 `ip_id` 来赋一个新值(图8-22)。尽管如此，Net/3系统也能从让运输层用相同ID字段重传IP数据报的系统上接收重叠的分片。

图10-22说明分片可能会以不同的方式与已经到达的分片重叠。分片是按照它们到达目的主机的顺序编号的。重装的分片在图 10-22 底部显示，分片的阴影部分是被丢弃的多余字节。

在下面的讨论中，早到(*earlier*)分片是指先前到达主机的分片。

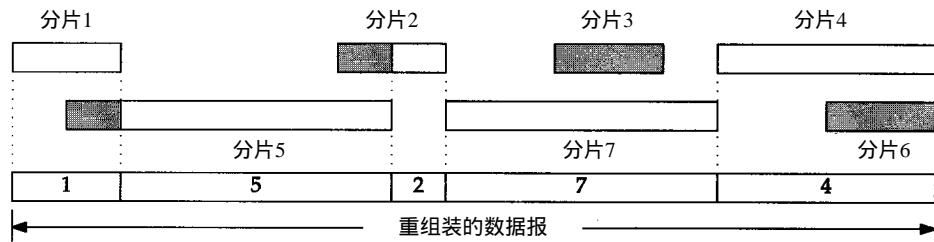


图10-22 可能在目的主机重叠的分片的字节范围

图10-23中代码截断或丢弃到达的分片。

382-396 `ip_reass` 把新片中与早到分片末尾重叠的字节丢弃，截断重复的部分(图10-22中分片5的前部)，或者，如果新分片的所有字节已经在早先的分片中(分片4)出现，就丢弃整个新分片(分片6)。

```

382     /*
383      * If there is a preceding fragment, it may provide some of
384      * our data already. If so, drop the data from the incoming
385      * fragment. If it provides all of our data, drop us.
386      */
387     if (q->ipf_prev != (struct ipasfrag *) fp) {
388         i = q->ipf_prev->ip_off + q->ipf_prev->ip_len - ip->ip_off;
389         if (i > 0) {
390             if (i >= ip->ip_len)
391                 goto dropfrag;
392             m_adj(dtom(ip), i);
393             ip->ip_off += i;
394             ip->ip_len -= i;
395         }
396     }

```

ip_input.c

图10-23 函数 `ip_reass`：截断到达分组

图10-24中的代码截断或丢弃已有的分片。

397-412 如果当前分片部分地与早到分片的前端部分重叠，就把早到分片中重复的数据截掉(图10-22中分片2的前部)。丢弃所有与当前分片完全重叠的早到分片(分片3)。

图10-25中，到达分片被插入到重装链表。

413-426 在截断后，`ip_enq`把该分片插入链表，并扫描整个链表，确定是否所有分片全部到达。如果还缺少分片，或链表最后一个分片的 `ipf_mff` 被置位，`ip_reass` 就返回0，并等待更多的分片。

当目前的分片完成一个数据报后，整个链表被图 10-26 所示的代码转换成一个 mbuf 链。

427-440 如果某个数据报的所有分片都被接收下来，`while` 循环用 `m_cat` 把分片重新构造

成数据报。

```
397  /*
398   * While we overlap succeeding fragments trim them or,
399   * if they are completely covered, dequeue them.
400   */
401  while (q != (struct ipasfrag *) fp && ip->ip_off+ip->ip_len > q->ip_off) {
402      i = (ip->ip_off + ip->ip_len) - q->ip_off;
403      if (i < q->ip_len) {
404          q->ip_len -= i;
405          q->ip_off += i;
406          m_adj(dtom(q), i);
407          break;
408      }
409      q = q->ipf_next;
410      m_freem(dtom(q->ipf_prev));
411      ip_deq(q->ipf_prev);
412  }
```

ip_input.c

图10-24 函数 ip_reass : 截断已有分组

```
413  insert:
414  /*
415   * Stick new fragment in its place;
416   * check for complete reassembly.
417   */
418  ip_enq(ip, q->ipf_prev);
419  next = 0;
420  for (q = fp->ipq_next; q != (struct ipasfrag *) fp; q = q->ipf_next) {
421      if (q->ip_off != next)
422          return (0);
423      next += q->ip_len;
424  }
425  if (q->ipf_prev->ipf_mff & 1)
426      return (0);
```

ip_input.c

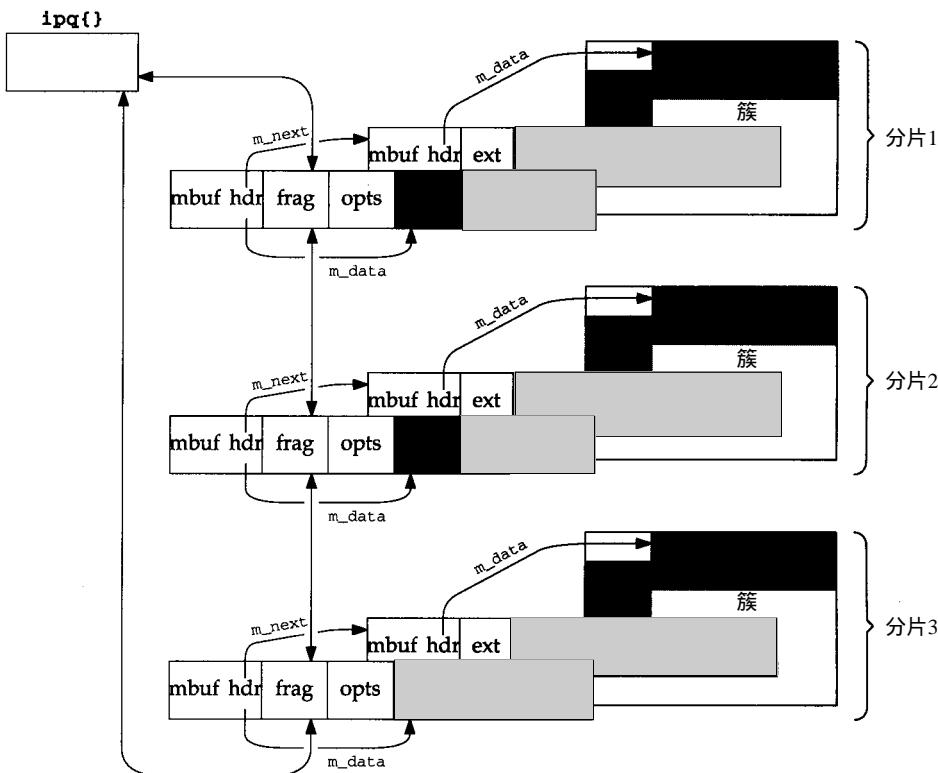
图10-25 函数 ip_reass : 插入分组

```
427  /*
428   * Reassembly is complete; concatenate fragments.
429   */
430  q = fp->ipq_next;
431  m = dtom(q);
432  t = m->m_next;
433  m->m_next = 0;
434  m_cat(m, t);
435  q = q->ipf_next;
436  while (q != (struct ipasfrag *) fp) {
437      t = dtom(q);
438      q = q->ipf_next;
439      m_cat(m, t);
440  }
```

ip_input.c

图10-26 函数 ip_reass : 重装数据报

图10-27显示了一个有三个分片的数据报的mbuf和ipq结构之间的关系。

图10-27 `m_cat` 重装缓存内的分片

图中最暗的区域是分组的数据部分，稍淡的阴影部分是 mbuf中未用的部分。有三个分片，每个分片都被存放在一个有两个 mbuf的链上：一个分组首部和一个簇。每个分片的第一个缓存上的`m_data`指针指向分组数据，而不是分组的首部。因此，由 `m_cat`构造的缓存链只包含分片的数据部分。

当一个分片含有大于208字节的数据时，情况通常是这样的(2.6节)。缓存的“frag”部分是分片的IP首部。由于图10-18中的代码，各缓存链第一个缓存的`m_data`指针指向“opts”之后。

图10-28显示了用所有分片的缓存重装的数据报。注意，分片 2和3的IP部分和选项不在重装的数据报里。

第一个分片的首部仍然被用作 `ipasfrag`结构。它被图 10-29中的代码恢复成一个有效的IP数据报首部。

4. 重建数据报首部

441-456 `ip_reass`把`ip`指向链表的第一个分片，将 `ipasfrag`结构恢复成 `ip`结构：把数据报长度恢复成 `ip_len`，源站地址恢复成 `ip_src`，目的地址恢复成 `ip_dst`；并把 `ipf_mff`的低位清零(从图10-14可以知道，`ipasfrag`结构的 `ipf_mff`覆盖了 `ip`结构的 `ipf_tos`)。

`ip_reass`用`remque`把整个分组从重装链表中移走，丢弃链表头 `ipq`结构，调整第一个缓存中的`m_len`和`m_data`，将前面被隐藏起来的第一个分片的首部和选项包含进来。

5. 计算分组长度

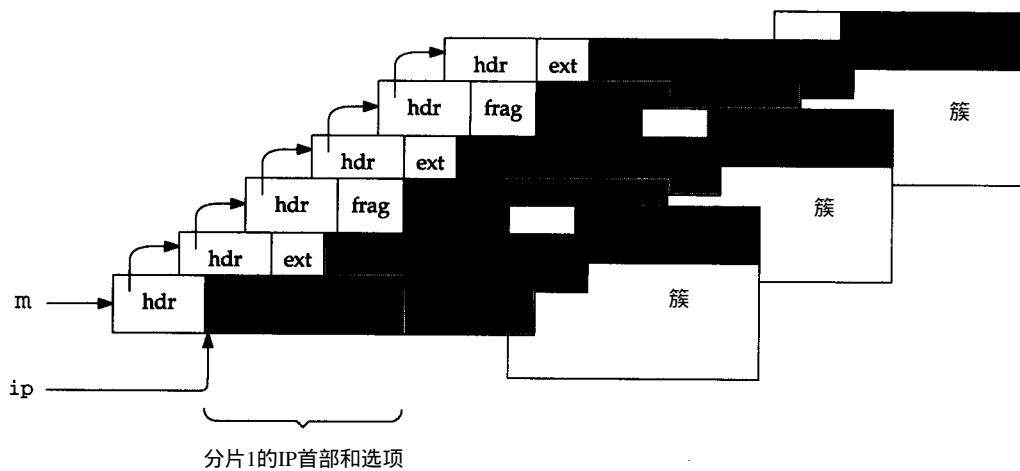


图10-28 重装的数据报

```

441  /*
442   * Create header for new ip packet by
443   * modifying header of first packet;
444   * dequeue and discard fragment reassembly header.
445   * Make header visible.
446   */
447  ip = fp->ipq_next;
448  ip->ip_len = next;
449  ip->ipf_mff &= ~1;
450  ((struct ip *) ip)->ip_src = fp->ipq_src;
451  ((struct ip *) ip)->ip_dst = fp->ipq_dst;
452  remque(fp);
453  (void) m_free(dtom(fp));
454  m = dtom(ip);
455  m->m_len += (ip->ip_hl << 2);
456  m->m_data -= (ip->ip_hl << 2);
457  /* some debugging cruft by sklower, below, will go away soon */
458  if (m->m_flags & M_PKTHDR) { /* XXX this should be done elsewhere */
459      int plen = 0;
460      for (t = m; m = m->m_next)
461          plen += m->m_len;
462      t->m_pkthdr.len = plen;
463  }
464  return ((struct ip *) ip);

```

ip_input.c

图10-29 函数 ip_reass : 数据报重装

457-464 此处的代码总被执行，因为数据报的第一个缓存总是一个分组首部。for循环计算缓存链中数据的字节数，并把值保存在 *m_pkthdr.len* 中。

在选项类型字段中，*copied*比特的意义现在应该很明白了。因为目的主机只保留那些出现在第一个分片中的选项，而且只有那些在分组去往目的主机的途中控制分组处理的选项才被复制下来。不复制那些在传送过程中收集信息的选项，因为当分组在目的主机上被重装时，所有收集的信息都被丢弃了。

10.7 ip_slowtimo函数

如7.4节所述，Net/3的各项协议可能指定每500 ms调用一个函数。对IP而言，这个函数是ip_slowtimo，如图10-30所示，为重装链表上的分片计时。

```
515 void ip_slowtimo(void) ip_input.c
516 {
517     struct ipq *fp;
518     int s = splnet();
519     fp = ipq.next;
520     if (fp == 0) {
521         splx(s);
522         return;
523     }
524     while (fp != &ipq) {
525         --fp->ipq_ttl;
526         fp = fp->next;
527         if (fp->prev->ipq_ttl == 0) {
528             ipstat.ips_fragtimeout++;
529             ip_freef(fp->prev);
530         }
531     }
532     splx(s);
533 }
```

图10-30 ip_slowtimo 函数

515-534 ip_slowtimo遍历部分数据报的链表，减少重装TTL字段。当该字段减为0时，就调用ip_freef，把与该数据报相关的分片都丢弃。在splnet处运行ip_slowtimo，避免到达分组修改链表。

ip_freef显示如图10-31。

470-486 ip_freef移走并释放链表上fp指向的各分片，然后释放链表本身。

```
474 void ip_freef(fp) ip_input.c
475 struct ipq *fp;
476 {
477     struct ipasfrag *q, *p;
478     for (q = fp->ipq_next; q != (struct ipasfrag *) fp; q = p) {
479         p = q->ipf_next;
480         ip_deq(q);
481         m_free(dtom(q));
482     }
483     remque(fp);
484     (void) m_free(dtom(fp));
485 }
```

图10-31 ip_freef 函数

ip_drain函数

在图7-14中，我们讲到IP把ip_drain定义成一个当内核需要更多内存时才调用的函数。

这种情况通常发生在我们讨论过的(图2-13)分配缓存时。`ip_drain`显示如图10-32。

```
538 void ip_drain() ip_input.c
539 {
540     ipq.next = &ipq;
541     while (ipq.next != &ipq) {
542         ipstat.ips_fragdropped++;
543         ip_freef(ipq.next);
544     }
545 }
```

图10-32 `ip_drain` 函数

538-545 IP释放内存的最简单办法就是丢弃重装链表上的所有IP分片。对属于某个TCP报文段的分片，TCP最终会重传该数据。属于UDP数据报的IP分片就丢失了，基于UDP的协议必须在应用程序层处理这种情况。

10.8 小结

本章展示了当一个外出的数据报过大而不适于在选定网络上传送时，`ip_output`如何对数据报分片。由于分片在向目的地传送的途中可能会被继续分片，也有可能走不同的路径，所以只有目的主机才能组装原来的数据报。

`ip_reass`接收到达分片，并试图重装数据报。如果重装成功，就把数据报传回`ipintr`，然后提交给恰当的运输层协议。所有IP实现必须能够重装最多576字节的数据报。Net/3的唯一限制就是可以得到的mbuf的个数。如果在一段合理的时间内，没有接收完数据报的所有分片，`ip_slowtimo`就丢弃不完整的数据报。

习题

- 10.1 修改`ip_slowtimo`，当它丢弃一个不完整数据报时(图11-1)，发出一个ICMP超时差错报文。
- 10.2 在分片的数据报中，各分片记录的路由可能互不相同。在目的主机上重装某个数据报时，返回给运输层的哪一个路由？
- 10.3 画一个图说明图10-17中ID为7的分片的`ipq`结构所涉及的mbuf和相关的分片链表。
- 10.4 [Auerbach 1994] 建议在对数据报分片后，应该首先传送最后的分片。如果接收系统先收到最后的分片，它就可以利用偏移值为数据报分配一个大小合适的缓冲区。请修改`ip_output`，首先发送最后的分片。

[Auerbach 1994] 注意到某些商用TCP/IP实现如果先收到最后的分片，就会出现崩溃。

- 10.5 用图8-5中的统计回答下面的问题。什么是每个重装的数据报的平均分片数？当一个外出的数据报被分片时，创建的平均分片数是多少？
- 10.6 如果`ip_off`的保留比特被置位，分组会发生什么情况？

第11章 ICMP：Internet控制报文协议

11.1 引言

ICMP在IP系统间传递差错和管理报文，是任何IP实现必需和要求的组成部分。ICMP的规范见RFC 792 [Postel 1981b]。RFC 950 [Mogul和Postel 1985]和RFC 1256 [Deering 1991a]定义了更多的ICMP报文类型。RFC 792 [Braden 1989a]提供了重要的ICMP细节。

ICMP有自己的传输协议号(1)，允许ICMP报文在IP数据报内携带。应用程序可以直接从第32章讨论的原始IP接口发送或接收ICMP报文。

我们可把ICMP报文分成两类：差错和查询。查询报文是用一对请求和回答定义的。ICMP差错报文通常包含了引起错误的IP数据报的第一个分片的IP首部(和选项)，加上该分片数据部分的前8个字节。标准假定这8个字节包含了该分组运输层首部的所有分用信息，这样运输层协议可以向正确的进程提交ICMP差错报文。

TCP和UDP端口号在它们首部的前8个字节内出现。

图11-1显示了所有目前定义的ICMP报文。双线上面的是ICMP请求和回答报文；双线下面的是ICMP差错报文。

type和code	描述	PRC_
<i>ICMP_ECHO</i> <i>ICMP_ECHOREPLY</i>	回显请求 回显回答	
<i>ICMP_TSAMP</i> <i>ICMP_TSTAMPREPLY</i>	时间戳请求 时间戳回答	
<i>ICMP_MASKREQ</i> <i>ICMP_MASKREPLY</i>	地址掩码请求 地址掩码回答	
<i>ICMP_IREQ</i> <i>ICMP_IREQREPLY</i>	信息请求(过时的) 信息回答(过时的)	
<i>ICMP_ROUTERADVERT</i> <i>ICMP_ROUTESOLICIT</i>	路由器通告 路由器请求	
<i>ICMP_REDIRECT</i> <i>ICMP_REDIRECT_NET</i> <i>ICMP_REDIRECT_HOST</i> <i>ICMP_REDIRECT_TOSNET</i> <i>ICMP_REDIRECT_TOSHOST</i> 其他	有更好的路由 网络有更好的路由 主机有更好的路由 TOS和网络有更好的路由 TOS和主机有更好的路由 不识别码	PRC_REDIRECT_HOST PRC_REDIRECT_HOST PRC_REDIRECT_HOST PRC_REDIRECT_HOST PRC_REDIRECT_HOST
<i>ICMP_UNREACH</i> <i>ICMP_UNREACH_NET</i> <i>ICMP_UNREACH_HOST</i>	目的主机不可达 网络不可达 主机不可达	PRC_UNREACH_NET PRC_UNREACH_HOST

图11-1 ICMP报文类型和代码

type和code	描述	PRC_
<i>ICMP_UNREACH_PROTOCOL</i> <i>ICMP_UNREACH_PORT</i> <i>ICMP_UNREACH_SRCFAIL</i> <i>ICMP_UNREACH_NEEDFRAG</i> <i>ICMP_UNREACH_NET_UNKNOWN</i> <i>ICMP_UNREACH_HOST_UNKNOWN</i> <i>ICMP_UNREACH_ISOLATED</i> <i>ICMP_UNREACH_NET_PROHIB</i> <i>ICMP_UNREACH_HOST_PROHIB</i> <i>ICMP_UNREACH_TOSNET</i> <i>ICMP_UNREACH_TOSHOST</i> 13 14 15 其他	目的主机上协议不能用 目的主机上端口没有被激活 源路由失败 需要分片并设置DF比特 目的网络未知 目的主机未知 源主机被隔离 从管理上禁止与目的网络通信 从管理上禁止与目的主机通信 对服务类型，网络不可达 对服务类型，主机不可达 用过滤从管理上禁止通信 主机优先违规 事实上优先切断 不识别码	PRC_UNREACH_PROTOCOL PRC_UNREACH_PORT PRC_UNREACH_SRCFAIL PRC_MSGSIZE PRC_UNREACH_NET PRC_UNREACH_HOST PRC_UNREACH_HOST PRC_UNREACH_NET PRC_UNREACH_HOST PRC_UNREACH_NET PRC_UNREACH_HOST PRC_UNREACH_HOST PRC_UNREACH_HOST PRC_UNREACH_HOST PRC_UNREACH_HOST
<i>ICMP_TIMXCEED</i> <i>ICMP_TIMXCEED_INTRANS</i> <i>ICMP_TIMXCEED_REASS</i> 其他	超时 传送过程中IP生存期到期 重装生存期到期 不识别码	PRC_TIMXCEED_INTRANS PRC_TIMXCEED_REASS
<i>ICMP_PRRAMPROB</i> 0 <i>ICMP_PRRAMPROB_OPTABSENT</i> 其他	IP首部的问题 未指明首部差错 丢失需要的选项 无效字节的字节偏移	PRC_PARAMPROB PRC_PARAMPROB
<i>ICMP_SOURCEQUENCH</i>	要求放慢发送	PRC_QUENCH
其他	不识别类型	

图11-1 (续)

图11-1和图11-2中含有大量信息：

- PRC_栏显示了Net/3处理的与协议无关的差错码(11.6节)和ICMP报文之间的映射。对请求和回答，这一列是空的。因为在这种情况下不会产生差错。如果对一个ICMP差错，这一行为空，说明Net/3不识别该码，并自动丢弃该差错报文。
- 图11-3显示了我们讨论图11-2所列函数的位置。
- icmp_input栏是icmp_input为每个ICMP报文调用的函数。
- UDP栏是为UDP插口处理ICMP报文的函数。
- TCP栏是为TCP插口处理ICMP报文的函数。注意，是tcp_quench处理ICMP源站抑制差错，而不是tcp_notify。
- 如果errno栏为空，内核不向进程报告ICMP报文。
- 表的最后一行显示，在用于接收ICMP报文的进程的接收点上，不识别的ICMP报文被提交给原来的IP协议。

在Net/3中，ICMP是作为IP之上的一个运输层协议实现的，它不产生差错或请求；它代表

其他协议格式化并发送报文。ICMP传递到达的差错，并向适当的传输协议或等待 ICMP报文的进程发出回答。另一方面，ICMP用一个合适的ICMP回答响应大多数ICMP请求。图11-4对此作了总结。

type 和 code	icmp_input	UDP	TCP	errno
ICMP_ECHO ICMP_ECHOREPLY	icmp_reflect rip_input			
ICMP_TSTAMP ICMP_TSTAMPREPLY	icmp_reflect rip_input			
ICMP_MASKREQ ICMP_MASKREPLY	icmp_reflect rip_input			
ICMP_IREQ ICMP_IREQREPLY	rip_input rip_input			
ICMP_ROUTERADVERT ICMP_ROUTERSOLICIT	rip_input rip_input			
ICMP_REDIRECT				
ICMP_REDIRECT_NET ICMP_REDIRECT_HOST ICMP_REDIRECT_TOSNET ICMP_REDIRECT_TOSHOST 其他	pfctlinput pfctlinput pfctlinput pfctlinput rip_input	in_rtchange in_rtchange in_rtchange in_rtchange in_rtchange	in_rtchange in_rtchange in_rtchange in_rtchange in_rtchange	
ICMP_UNREACH				
ICMP_UNREACH_NET ICMP_UNREACH_HOST ICMP_UNREACH_PROTOCOL ICMP_UNREACH_PORT ICMP_UNREACH_SRCFAIL ICMP_UNREACH_NEEDFRAG ICMP_UNREACH_NET_UNKNOWN ICMP_UNREACH_HOST_UNKNOWN ICMP_UNREACH_ISOLATED ICMP_UNREACH_NET_PROHIB ICMP_UNREACH_HOST_PROHIB ICMP_UNREACH_TOSNET ICMP_UNREACH_TOSHOST 13 14 15 其他	pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput pr_ctlinput rip_input rip_input rip_input rip_input	udp_notify udp_notify udp_notify udp_notify udp_notify udp_notify udp_notify udp_notify udp_notify udp_notify udp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify tcp_notify	tcp_notify tcp_notify	EHOSTUNREACH EHOSTUNREACH ECONNREFUSED ECONNREFUSED EHOSTUNREACH EMSGSIZE EHOSTUNREACH
ICMP_TIMXCEED				
ICMP_TIMXCEED_INTRANS ICMP_TIMXCEED_REASS 其他	pr_ctlinput pr_ctlinput rip_input	udp_notify udp_notify	tcp_notify tcp_notify	
ICMP_PARAMPROB				
0 ICMP_PARAMPROB_OPTABSENT 其他	pr_ctlinput pr_ctlinput rip_input	udp_notify udp_notify	tcp_notify tcp_notify	ENOPROTOOPT ENOPROTOOPT
ICMP_SOURCEQUENCH	pr_ctlinput	udp_notify	tcp_quench	
其他	rip_input			

图11-2 ICMP报文类型和代码(续)

函数	描述	引用
icmp_reflect	为ICMP生成回答	11.12节
in_rtchange	更新IP路由表	图22-34
pfctlinput	向所有协议报告差错	7.7节
pr_ctlinput	向与插口有关的协议报告差错	7.4节
rip_input	进程不识别的ICMP报文	32.5节
tcp_notify	向进程报告差错或忽略	图27-12
tcp_quench	放慢输出	图27-13
udp_notify	向进程报告差错	图23-31

图11-3 ICMP输入处理时调用的函数

ICMP报文类型	到 达	输 出
请求	向ICMP请求生成回答	由某个进程生成
回答	传给原始IP	由内核生成
差错	传给传输协议和原始IP	由IP或传输协议生成
未知	传给原始IP	由某个进程生成

图11-4 ICMP报文处理

11.2 代码介绍

图11-5的两个文件中有本章讨论的ICMP数据结构、统计量和处理的程序。

文 件	描 述
netinet/ip_icmp.h	ICMP结构定义
netinet/ip_icmp.c	ICMP处理

图11-5 本章定义的文件

11.2.1 全局变量

本章介绍的全局变量如图11-6所示。

变 量	类 型	描 述
icmpmaskrepl	int	使ICMP地址掩码回答的返回有效
icmpstat	struct icmpstat	ICMP统计量(图11-7)

图11-6 本章介绍的全局变量

11.2.2 统计量

统计量是由图11-7所示的icmpstat结构的成员收集的。

icmpstat成员	描 述	SNMP使用的
icps_oldicmp	因为数据报是一个ICMP报文而丢弃的差错数	•
icps_oldshort	因为IP数据报太短而丢弃的差错数	•

图11-7 本章收集的统计信息

icmpstat成员	描述	SNMP使用的
icps_badcode	由于无效码而丢弃的ICMP报文数	•
icps_badlen	由于无效的ICMP体而丢弃的ICMP报文数	•
icps_checksum	由于坏的ICMP检验和而丢弃的ICMP报文数	•
icps_tooshort	由于ICMP首部太短而丢弃的报文数	•
icps_outhist[]	输出计数器数组;每种ICMP类型对应一个	•
icps_inhist[]	输入计数器数组;每种ICMP类型对应一个	•
icps_error	icmp_error的调用(重定向除外)数	
icps_reflect	内核反映的ICMP报文数	

图11-7 (续)

在分析程序时，我们会看到计数器是递增的。

图11-8显示的是执行netstat -s命令输出的统计信息的例子。

netstat -s 输出	icmpstat 成员
<pre>84124 calls to icmp_error 0 errors not generated 'cuz old message was icmp Output histogram: echo reply: 11770 destination unreachable: 84118 time exceeded: 6 6 messages with bad code fields 0 messages < minimum length 0 bad checksums 143 messages with bad length Input histogram: echo reply: 793 destination unreachable: 305869 source quench: 621 routing redirect: 103 echo: 11770 time exceeded: 25296 11770 message responses generated</pre>	<pre>icps_error icps_olddicmp icps_outhist[] ICMP_ECHOREPLY ICMP_UNREACH ICMP_TIMXCEED icps_badcode icps_badlen icps_checksum icps_tooshort icps_inhist[] ICMP_ECHOREPLY ICMP_UNREACH ICMP_SOURCEQUENCH ICMP_REDIRECT ICMP_ECHO ICMP_TIMXCEED icps_reflect</pre>

图11-8 ICMP统计信息示例

11.2.3 SNMP变量

图11-9显示了SNMP ICMP组的变量与Net/3收集的统计量之间的关系。

SNMP变量	icmpstat成员	描述
icmpInMsgs	见正文	
icmpInErrors	icps_badcode + icps_badlen + icps_checksum + icps_tooshort	收到的ICMP报文数 由于错误丢弃的ICMP报文数
icmpInDestUnreachs icmpInTimeExcds icmpInParmProbs icmpInSrcQuenches icmpInRedirects icmpInEchos	icps_inhist[] 计数器	每一类收到的ICMP报文数

图11-9 ICMP组内的简单SNMP变量

icmpInEchoReps icmpInTimestamps icmpInTimestampReps icmpInAddrMasks icmpInAddrMaskReps		
icmpOutMsgs icmpOutErrors	见正文 <code>icps_oldicmp + icps_oldshort</code>	发送的ICMP报文数 由于一个错误而没有发送的ICMP错误数
icmpOutDestUnreachs icmpOutTimeExcds icmpOutParmProbs icmpOutSrcQuenches icmpOutRedirects icmpOutEchos icmpOutEchoReps icmpOutTimestamps icmpOutTimestampReps icmpOutAddrMasks icmpOutAddrMaskReps	<code>icps_outhist[]</code> 计数器	每一类发送的ICMP报文数

图11-9 (续)

`icmpInMsgs`是`icps_inhist`数组和`icmpInErrors`中的计数之和，`icmpOutMsgs`是`icps_outhist`数组和`icmpOutErrors`中的计数之和。

11.3 icmp结构

Net/3通过图11-10中的`icmp`结构访问某个ICMP报文。

42-45 `icmp_type`标识特定报文，`icmp_code`进一步指定该报文(图11-1的第1栏)。计算`icmp_cksum`的算法与IP首部检验和相同，保护整个ICMP报文(像IP一样，不仅仅保护首部)。

46-79 联合`icmp_hun`(首部联合)和`icmp_dun`(数据联合)按照`icmp_type`和`icmp_code`访问多种ICMP报文。每种ICMP报文都使用`icmp_hun`；只有一部分报文用`icmp_dun`。没有使用的字段必须设置为0。

80-86 我们已经看到，利用其他嵌套的结构(例如`mbuf`、`le_softc`和`ether_arp`)，`#define`宏可以简化对结构成员的访问。

图11-11显示了ICMP报文的整体结构，并再次强调ICMP报文是封装在IP数据报里的。我们将在分析程序时，分析所遇报文的特定结构。

```
ip_icmp.h
42 struct icmp {
43     u_char    icmp_type;           /* type of message, see below */
44     u_char    icmp_code;          /* type sub code */
45     u_short   icmp_cksum;         /* ones complement cksum of struct */
46     union {
47         u_char    ih_pptr;        /* ICMP_PARAMPROB */
48         struct in_addr ih_gwaddr; /* ICMP_REDIRECT */
49         struct ih_idseq {
50             n_short  icd_id;
51             n_short  icd_seq;
52         } ih_idseq;
53         int      ih_void;
54         /* ICMP_UNREACH_NEEDFRAG -- Path MTU Discovery (RFC1191) */
55         struct ih_pmtu {
```

图11-10 icmp 结构

```

56         n_short ipm_void;
57         n_short ipm_nextmtu;
58     } ih_pmtu;
59 } icmp_hun;
60 #define icmp_pptr    icmp_hun.ih_pptr
61 #define icmp_gwaddr  icmp_hun.ih_gwaddr
62 #define icmp_id      icmp_hun.ih_idseq.icd_id
63 #define icmp_seq     icmp_hun.ih_idseq.icd_seq
64 #define icmp_void    icmp_hun.ih_void
65 #define icmp_pmvoid  icmp_hun.ih_pmtu.ipm_void
66 #define icmp_nextmtu  icmp_hun.ih_pmtu.ipm_nextmtu
67 union {
68     struct id_ts {
69         n_time its_otime;
70         n_time its_rtime;
71         n_time its_ttime;
72     } id_ts;
73     struct id_ip {
74         struct ip idi_ip;
75         /* options and then 64 bits of data */
76     } id_ip;
77     u_long id_mask;
78     char id_data[1];
79 } icmp_dun;
80 #define icmp_otime   icmp_dun.id_ts.its_otime
81 #define icmp_rtime   icmp_dun.id_ts.its_rtime
82 #define icmp_ttime   icmp_dun.id_ts.its_ttime
83 #define icmp_ip     icmp_dun.id_ip.idi_ip
84 #define icmp_mask   icmp_dun.id_mask
85 #define icmp_data   icmp_dun.id_data
86 };

```

ip_icmp.h

图11-10 (续)

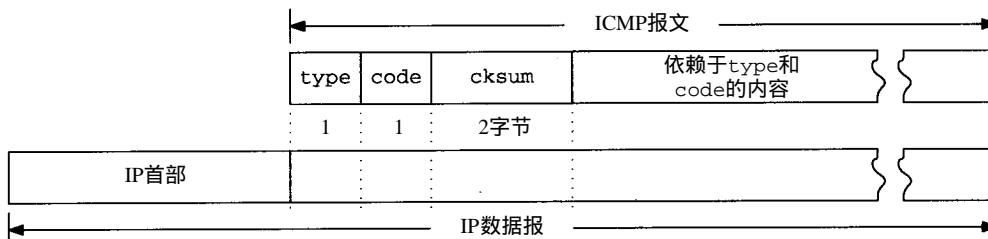


图11-11 一个ICMP报文(省略icmp_)

11.4 ICMP 的protosw结构

inetsw[4](图11-13)的protosw结构描述了ICMP，并支持内核和进程对协议的访问。图11-12显示了该结构。在内核里，`icmp_input`处理到达的ICMP报文，进程产生的外出ICMP报文由`rip_output`处理。以`rip_`开头的三个函数将在第32章中讨论。

成 员	inetsw[4]	描 述
<code>pr_type</code> <code>pr_domain</code>	<code>SOCK_RAW</code> <code>&inetdomain</code>	ICMP提供原始分组服务 ICMP是Internet域的一部分

图11-12 ICMP 的inetsw 项

成 员	inetsw[4]	描 述
pr_protocol	<i>IPIPproto_ICMP (1)</i>	出现在IP首部的ip_p字段中
pr_flags	<i>PR_ATOMIC / PR_ADDR</i>	插口层标志，ICMP不使用
pr_input	<i>icmp_input</i>	从IP层接收ICMP报文
pr_output	<i>rip_output</i>	将ICMP报文发送到IP层
pr_ctlinput	0	ICMP不使用
pr_ctloutput	<i>rip_ctloutput</i>	响应来自一个进程的管理请求
pr_usrreq	<i>rip_usrreq</i>	响应来自一个进程的通信请求
pr_init	0	ICMP不使用
pr_fasttimo	0	ICMP不使用
pr_slowtimo	0	ICMP不使用
pr_drain	0	ICMP不使用
pr_sysctl	0	ICMP不使用

图11-12 (续)

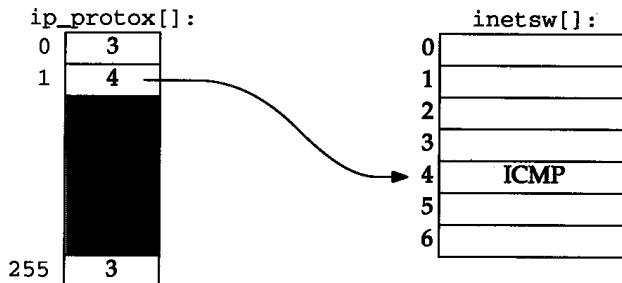


图11-13 数值为1的ip_p选择了inetsw[4]

11.5 输入处理：icmp_input函数

回想起ipintr对数据报进行分用是根据IP首部中的传输协议编号ip_p。对于ICMP报文，ip_p是1，并通过ip_protox选择inetsw[4]。

当一个ICMP报文到达时，IP层通过inetsw[4]的pr_input函数，间接调用icmp_input（图10-11）。

我们将看到，在icmp_input中，每一个ICMP报文要被处理3次：被icmp_input处理一次；被与ICMP差错报文中的IP分组相关联的传输协议处理一次；被记录收到ICMP报文的进程处理一次。ICMP输入处理过程的总的构成情况如图11-14所示。

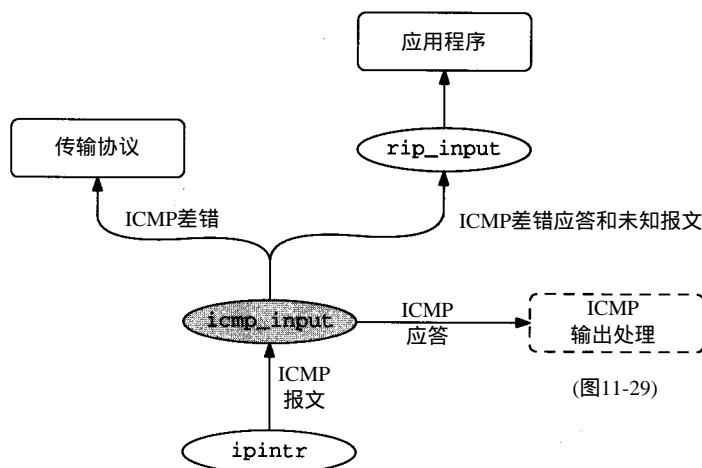


图11-14 ICMP的输入处理过程

我们将在以下5节(11.6~11.10)讨论icmp_input:(1)验证收到的报文;(2)ICMP差错报文;(3)ICMP请求报文;(4)ICMP重定向报文;(5)ICMP回答报文。icmp_input函数的第一部分如图11-15所示。

ip_icmp.c

```

131 static struct sockaddr_in icmpsaddr = { sizeof (struct sockaddr_in), AF_INET };
132 static struct sockaddr_in icmpdst = { sizeof (struct sockaddr_in), AF_INET };
133 static struct sockaddr_in icmpgw = { sizeof (struct sockaddr_in), AF_INET };
134 struct sockaddr_in icmpmask = { 8, 0 };

135 void
136 icmp_input(m, hlen)
137 struct mbuf *m;
138 int     hlen;
139 {
140     struct icmp *icp;
141     struct ip *ip = mtod(m, struct ip *);
142     int      icmplen = ip->ip_len;
143     int      i;
144     struct in_ifaddr *ia;
145     void    (*ctlfunc) (int, struct sockaddr *, struct ip *);
146     int      code;
147     extern u_char ip_proto[];

148     /*
149      * Locate icmp structure in mbuf, and check
150      * that not corrupted and of at least minimum length.
151      */
152     if (icmplen < ICMP_MINLEN) {
153         icmpstat.icps_tooshort++;
154         goto freeit;
155     }
156     i = hlen + min(icmplen, ICMP_ADVLENMIN);
157     if (m->m_len < i && (m = m_pullup(m, i)) == 0) {
158         icmpstat.icps_tooshort++;
159         return;
160     }
161     ip = mtod(m, struct ip *);
162     m->m_len -= hlen;
163     m->m_data += hlen;
164     icp = mtod(m, struct icmp *);
165     if (in_cksum(m, icmplen)) {
166         icmpstat.icps_checksum++;
167         goto freeit;
168     }
169     m->m_len += hlen;
170     m->m_data -= hlen;

171     if (icp->icmp_type > ICMP_MAXTYPE)
172         goto raw;
173     icmpstat.icps_inhist[icp->icmp_type]++;
174     code = icp->icmp_code;
175     switch (icp->icmp_type) {

```

图11-15 icmp_input 函数

```

317     default:
318         break;
319     }
320     raw:
321     rip_input(m);
322     return;
323 freeit:
324     m_free(m);
325 }

```

ip_icmp.c

图11-15 (续)

1. 静态结构

131-134 因为 `icmp_input` 是在中断时调用的，此时堆栈的大小是有限的。所以，为了在每次调用 `icmp_input` 时，避免动态分配造成的延迟，以及使堆栈最小，这 4 个结构是动态分配的。`icmp_input` 把这 4 个结构用作临时变量。

`icmpsrc` 的命名容易引起误解，因为 `icmp_input` 把它用作临时 `sockaddr_in` 变量，而它也从未包含过源站地址。在 Net/2 版本的 `icmp_input` 中，在报文被 `raw_input` 函数提交给原始 IP 之前，报文的源站地址在函数的最后被复制到 `icmpsrc` 中。而 Net/3 调用只需要一个指向该分组的指针的 `rip_input`，而不是 `raw_input`。虽然有这个改变，但是 `icmpsrc` 仍然保留了在 Net/2 中的名字。

2. 确认报文

135-139 `icmp_input` 希望收到的 ICMP 报文(`m`)中含有一个指向该数据报的指针，以及该数据报 IP 首部的字节长度(`hlen`)。图 11-16 列出了几个在 `icmp_input` 里用于简化检测无效 ICMP 报文的常量。

常量 / 宏	值	描述
<code>ICMP_MINLEN</code>	8	ICMP 报文大小的最小值
<code>ICMP_TSLEN</code>	20	ICMP 时间戳报文大小
<code>ICMP_MASKLEN</code>	12	ICMP 地址掩码报文大小
<code>ICMP_ADVLENMIN</code>	36	ICMP 差错(建议)报文大小的最小值 ($IP + ICMP + BADIP = 20 + 8 + 8 = 36$)
<code>ICMP_ADVLEN(p)</code>	$36 + optsize$	ICMP 差错报文的大小，包含无效分组 <code>p</code> 的 IP 选项的 <code>optsize</code> 字节

图11-16 ICMP引用的用来验证报文的常量

140-160 `icmp_input` 从 `ip_len` 取出 ICMP 报文的大小，并把它存放在 `icmplen` 中。第 8 章讲过，`ipintr` 从 `ip_len` 中排除了 IP 首部的长度。如果报文长度太短，不是有效报文，就生成 `icps_tooshort`，并丢弃该报文。如果在第一个 `mbuf` 中，ICMP 首部和 IP 首部不是连续的，则由 `m_pullup` 保证 ICMP 首部以及封闭的 IP 分组的 IP 首部在同一个 `mbuf` 中。

3. 验证检验和

161-170 `icmp_input` 隐藏 `mbuf` 中的 IP 首部，并用 `in_cksum` 验证 ICMP 的检验和。如果报文被破坏，就增加 `icps_checksum`，并丢弃该报文。

4. 验证类型

171-175 如果报文类型 (`icmp_type`) 不在识别范围内，`icmp_input` 就跳过 `switch` 执行

raw语句(图11-9)。如果在识别范围内，`icmp_input`复制`icmp_code`，`switch`按照`icmp_type`处理该报文。

在ICMP `switch`语句处理完后，`icmp_input`向`rip_input`发送ICMP报文，后者把ICMP报文发布给准备接收的进程。只有那些被破坏的报文(长度或检验和出错)以及只由内核处理的ICMP请求报文才不传给`rip_input`。在这两种情况下，`icmp_input`都立即返回，并跳过raw处的源程序。

5. 原始ICMP输入

317-325 `icmp_input`把到达的报文传给`rip_input`，`rip_input`依据报文里含有的协议及源站和目的站地址信息(32章)，把报文发布给正在监听的进程。

原始IP机制允许进程直接发送和接收ICMP报文，这样做有几个原因：

- 新ICMP报文可由进程处理而无需修改内核(例如，路由器通告，图11-28)。
- 可以用进程而无需用内核模块来实现发送ICMP请求和处理回答的机制(`ping`和`traceroute`)。
- 进程可以增加对报文的内核处理。与此类似，内核在更新完它的路由表后，会把ICMP重定向报文传给一个路由守护程序。

11.6 差错处理

我们首先考虑ICMP差错报文。当主机发出的数据报无法成功地提交给目的主机时，它就接收这些报文。目的主机或中间的路由器生成这些报文，并将它们返回到原来的系统。图11-17显示了多种ICMP差错报文的格式。

不可达 超时 源抑制	<code>type</code>	<code>len</code>	<code>cksum</code>	<code>pmvoid</code> (必须是0)	<code>ip</code> 被破坏分组的IP首部
	4字节				
需要分片	<code>type</code>	<code>len</code>	<code>cksum</code>	<code>pmvoid</code> (必须是0)	<code>nextmtu</code> 被破坏分组的IP首部
	2字节		2字节		
参数问题	<code>type</code>	<code>len</code>	<code>cksum</code>	<code>pptr</code> (必须是0)	<code>ip</code> 被破坏分组的IP首部
	1	1	2字节	3字节	8字节

图11-17 ICMP差错报文(省略`icmp_`)

图11-18中的源程序来自图11-15中的`switch`语句。

```
176     case ICMP_UNREACH:
177         switch (code) {
178             case ICMP_UNREACH_NET:
179             case ICMP_UNREACH_HOST:
180             case ICMP_UNREACH_PROTOCOL:
181             case ICMP_UNREACH_PORT:
182             case ICMP_UNREACH_SRCHFAIL:
183                 code += PRC_UNREACH_NET;
184                 break;
185
186             case ICMP_UNREACH_NEEDFRAG:
```

图11-18 `icmp_input` 函数：差错报文

```

186         code = PRC_MSGSIZE;
187         break;

188     case ICMP_UNREACH_NET_UNKNOWN:
189     case ICMP_UNREACH_NET_PROHIB:
190     case ICMP_UNREACH_TOSNET:
191         code = PRC_UNREACH_NET;
192         break;

193     case ICMP_UNREACH_HOST_UNKNOWN:
194     case ICMP_UNREACH_ISOLATED:
195     case ICMP_UNREACH_HOST_PROHIB:
196     case ICMP_UNREACH_TOSHOST:
197         code = PRC_UNREACH_HOST;
198         break;

199     default:
200         goto badcode;
201     }
202     goto deliver;

203 case ICMP_TIMXCEED:
204     if (code > 1)
205         goto badcode;
206     code += PRC_TIMXCEED_INTRANS;
207     goto deliver;
208 case ICMP_PARAMPROB:
209     if (code > 1)
210         goto badcode;
211     code = PRC_PARAMPROB;
212     goto deliver;

213 case ICMP_SOURCEQUENCH:
214     if (code)
215         goto badcode;
216     code = PRC_QUENCH;

217 deliver:
218 /*
219 * Problem with datagram; advise higher level routines.
220 */
221 if (icmplen < ICMP_ADVLENMIN || icmplen < ICMP_ADVLEN(icp) ||
222     icp->icmp_ip.ip_hl < (sizeof(struct ip) >> 2)) {
223     icmpstat.icps_badlen++;
224     goto freeit;
225 }
226 NTOHS(icp->icmp_ip.ip_len);
227 icmpsrc.sin_addr = icp->icmp_ip.ip_dst;
228 if (ctlfunc = inetsw[ip_protox[icp->icmp_ip.ip_p]].pr_ctlinput)
229     (*ctlfunc) (code, (struct sockaddr *) &icmpsrc,
230                 &icp->icmp_ip);
231     break;

232 badcode:
233     icmpstat.icps_badcode++;
234     break;

```

ip_icmp.c

图11-18 (续)

176-216 对ICMP差错的处理是最少的，因为这主要是运输层协议的责任。 `imcp_input` 把 `icmp_type` 和 `icmp_code` 映射到一个与协议无关的差错码集上，该差错码是由 `PRC_常量`

(图11-19)表示的。PRC_常量有一个隐含的顺序，正好与 ICMP的code相对应。这就解释了为什么code是按一个PRC_常量递增的。

217-225 如果识别出类型和码，`icmp_input`就跳到`deliver`。如果没有识别出来，`icmp_input`就跳到`badcode`。

如果对所报告的差错而言，报文长度不正确，`icps_badlen`的值就加1，并丢弃该报文。Net/3总是丢弃无效的ICMP报文，也不生成有关该无效报文的ICMP差错。这样，就避免在两个有缺陷的实现之间形成无限的差错报文序列。

226-231 `icmp_input`调用运输层协议的`pr_ctlinput`函数，该函数根据原始数据报的`ip_p`，把到达分组分用到正确的协议，从而构造出原始的IP数据报。差错码(`code`)、原始IP数据报的目的地址(`icmps_rsrc`)以及一个指向无效数据报的指针(`icmp_ip`)被传给`pr_ctlinput`(如果是为该协议定义的)。图23-31和图27-12讨论这些差错。

232-234 最后，`icps_badcode`的值增加1，并终止switch语句的执行。

常量	描述
<code>PRC_HOSTDEAD</code>	主机似乎已关闭
<code>PRC_IFDOWN</code>	网络接口关闭
<code>PRC_MSGSIZE</code>	无效报文大小
<code>PRC_PRRAMPROB</code>	首部不正确
<code>PRC_QUENCH</code>	某人说要放慢
<code>PRC_QUENCH2</code>	阻塞比特要求放慢
<code>PRC_REDIRECT_HOST</code>	主机路由选择重定向
<code>PRC_REDIRECT_NET</code>	网络路由选择重定向
<code>PRC_REDIRECT_TOSHOST</code>	TOS和主机的重定向
<code>PRC_REDIRECT_TOSNET</code>	TOS和网络的重定向
<code>PRC_ROUTEDEAD</code>	如果可能，选择新的路由
<code>PRC_TIMXCEED_INTRANS</code>	传送过程中分组生命期到期
<code>PRC_TIMXCEED_REASS</code>	分片在重装过程中生命期到期
<code>PRC_UNREACH_HOST</code>	没有到主机的路由
<code>PRC_UNREACH_NET</code>	没有到网络的路由
<code>PRC_UNREACH_PORT</code>	目的主机称端口未激活
<code>PRC_UNREACH_PROTOCOL</code>	目的主机称协议不可用
<code>PRC_UNREACH_SRCFAIL</code>	源路由失败

图11-19 与协议无关的差错码

尽管PRC_常量表面上与协议无关，但它们主要还是基于Internet协议族。其结果是，当某个Internet协议族以外的协议把自己的差错映射到PRC_常量时，会失去可指性。

11.7 请求处理

Net/3响应具有正确格式的ICMP请求报文，但把无效ICMP请求报文传给`rip_input`。第32章讨论了应用程序如何生成ICMP请求报文。

除路由器通告报文外，大多数Net/3所接收的ICMP请求报文都生成回答报文。为避免为回答报文分配新的mbuf，`icmp_input`把请求的缓存转换成回答的缓存，并返回给发送方。我

们将分别讨论各个请求。

11.7.1 回显询问：ICMP_ECHO和ICMP_ECHOREPLY

尽管ICMP非常简单，但是ICMP回显请求和回答却是网络管理员最有力的诊断工具。发出ICMP回显请求称为“ping”一个主机，也就是调用ping程序一次。许多系统提供该程序来手工发送ICMP回显请求。卷1的第7章详细讨论了ping。

ping程序的名字依照了声纳脉冲(soar ping)，用其他物体对声纳脉冲的反射所产生的回声确定它们的位置。卷1把这个名字解释成Packet InterNet Groper，是不正确的。

图11-20是ICMP回显请求和回答报文的结构。

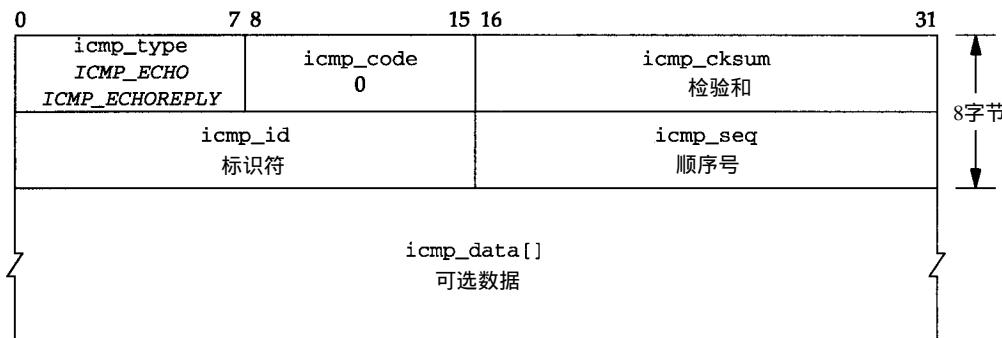


图11-20 ICMP回显请求和回答

icmp_code总是0。icmp_id和icmp_seq设置成请求的发送方，回答中也不做修改。源系统可以用这些字段匹配请求和回答。icmp_data中到达的所有数据也被反射。图11-21是ICMP回显处理和icmp_input实现反射ICMP请求的源程序。

```

235     case ICMP_ECHO:                                ip_icmp.c
236         icp->icmp_type = ICMP_ECHOREPLY;
237         goto reflect;

277     reflect:
278         ip->ip_len += hlen;      /* since ip_input deducts this */
279         icmpstat.icps_reflect++;
280         icmpstat.icps_outhist[icp->icmp_type]++;
281         icmp_reflect(m);
282         return;                ip_icmp.c

```

图11-21 icmp_input 函数：回显请求和回答

235-237 通过把icmp_type变成ICMP_ECHOREPLY，并跳转到reflect发送回答，icmp_input把回显请求转换成了回显回答。

277-282 在为每个ICMP 请求构造完回答之后，icmp_input执行reflect处的程序。在这里，存储数据报正确的长度被恢复，在icps_reflect和icps_outhist[]中分别计算请求的数量和ICMP报文的类型。icps_reflect(11.12节)把回答发回给请求方。

11.7.2 时间戳询问：ICMP_TSTAMP和ICMP_TSTAMPREPLY

ICMP时间戳报文如图 11-22 所示。

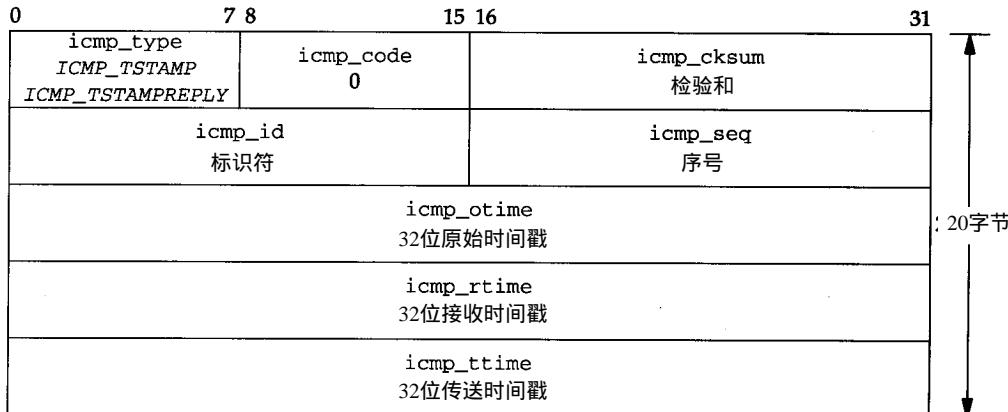


图11-22 ICMP时间戳请求和回答

icmp_code总是0。icmp_id和icmp_seq的作用与它们在ICMP回显报文中的一样。请求的发送方设置icmp_otime(发出请求的时间)；icmp_rttime(收到请求的时间)和icmp_ttime(发出回答的时间)由回答的发送方设置。所有时间都是从UTC午夜开始的毫秒数。如果时间值没有以标准单位记录，就把高位置位，与IP时间戳选项一样。

图11-23是实现时间戳报文的程序。

```
238     case ICMP_TSTAMP:                                ip_icmp.c
239         if (icmpalen < ICMP_TSLEN) {
240             icmpstat.icps_badlen++;
241             break;
242         }
243         icp->icmp_type = ICMP_TSTAMPREPLY;
244         icp->icmp_rttime = iptime();
245         icp->icmp_ttime = icp->icmp_rttime; /* bogus, do later! */
246         goto reflect;
```

ip_icmp.c

图11-23 icmp_input 函数：时间戳请求和回答

238-246 icmp_input对ICMP的响应，包括：把icmp_type改成ICMP_TSTAMPREPLY，记录当前icmp_rttime和icmp_ttime，并跳转到reflect发送回答。

很难精确地设置icmp_rttime和icmp_ttime。当系统执行这段程序时，报文可能已经在IP输入队列中等待处理，这时设置icmp_rttime已经太晚了。类似地，数据报也可能在要求处理时在网络接口的传输队列中被延迟，这时设置icmp_ttime又太早了。为了把时间戳设置得更接近真实的接收和发送时间，必须修改每个网络的接口驱动程序，使其能理解CMP报文(习题11.8)。

11.7.3 地址掩码询问：ICMP_MASKREQ和ICMP_MASKREPLY

ICMP 地址掩码请求和回答如图 11-24 所示。

RFC 950 [Mogul和Postel 1985]在原来的ICMP规范说明中增加了地址掩码报文，使系统能发现某个网络上使用的子网掩码。

除非系统被明确地配置成地址掩码的授权代理，否则，RFC 1122禁止向其发送掩码回答。这样，就避免系统与所有向它发出请求的系统共享不正确的地址掩码。如果没有管理员授权回答，系统也要忽略地址掩码请求。

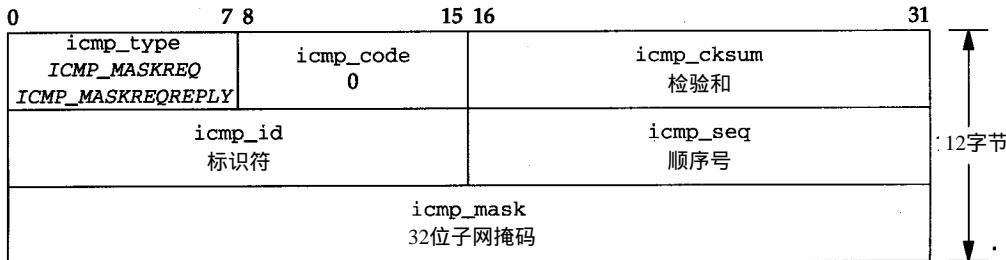


图11-24 ICMP地址掩码请求和回答

如果全局整数 `icmpmaskrepl` 非零，Net/3会响应地址掩码请求。`icmpmaskrepl` 的默认值是0，`icmp_sysctl`可以通过`sysctl(8)`程序(11.14节)修改它。

Net/2系统中没有控制回答地址掩码请求的机制。其结果是，必须非常正确地配置Net/2接口的地址掩码；该信息是与网络上所有发出地址掩码请求的系统共享的。

地址掩码报文的处理如图11-25所示。

```
247     case ICMP_MASKREQ:                                     ip_icmp.c
248 #define satosin(sa) ((struct sockaddr_in *)(sa))
249     if (icmpmaskrepl == 0)
250         break;
251     /*
252      * We are not able to respond with all ones broadcast
253      * unless we receive it over a point-to-point interface.
254      */
255     if (icmplen < ICMP_MASLEN)
256         break;
257     switch (ip->ip_dst.s_addr) {
258
259     case INADDR_BROADCAST:
260     case INADDR_ANY:
261         icmpdst.sin_addr = ip->ip_src;
262         break;
263
264     default:
265         icmpdst.sin_addr = ip->ip_dst;
266     }
267     ia = (struct in_ifaddr *) ifaof_ifpforaddr(
268             (struct sockaddr *) &icmpdst, m->m_pkthdr.rcvif);
269     if (ia == 0)
270         break;
271     icp->icmp_type = ICMP_MASKREPLY;
272     icp->icmp_mask = ia->ia_sockmask.sin_addr.s_addr;
273     if (ip->ip_src.s_addr == 0) {
274         if (ia->ia_ifp->if_flags & IFF_BROADCAST)
275             ip->ip_src = satosin(&ia->ia_broadaddr)->sin_addr;
276         else if (ia->ia_ifp->if_flags & IFF_POINTOPOINT)
277             ip->ip_src = satosin(&ia->ia_dstaddr)->sin_addr;
278     }

```

ip_icmp.c

图11-25 `icmp_input` 函数：地址掩码请求和回答

247-256 如果没有配置响应掩码请求，或者该请求太短，这段程序就中止 switch的执行，并把报文传给rip_input(图11-15)。

在这里 Net/3无法增加 icps_badlen。对其他 ICMP 长度差错，它却增加 icps_badlen。

1. 选择子网掩码

257-267 如果地址掩码请求被发到 0.0.0或255.255.255.255，源地址被保存在 icmpdst 中。在这里，ifaof_offoraddr 把 icmpdst 作为源站地址，在同一网络上查找 in_ofaddr 结构。如果源站地址是 0.0.0或255.255.255.255，ifaof_offoraddr 返回一个指针，该指针指向与接收接口相关的第一 IP 地址。

default情况(针对单播或有向广播)为ifaof_ifpforaddr 保存目的地址。

2. 转换成回答

269-270 通过改变 icmp_type，并把所选子网掩码 ia_sockmask 复制到 icmp_mask，就完成了把请求转换成回答的工作。

3. 选择目的地址

271-276 如果请求的源站地址全 0(“该网络上的这台主机”，只在引导时用作源站地址，RFC 1122)，并且源站不知道自己的地址，Net/3必须广播这个回答，使源站系统接收到这个报文。在这种情况下，如果接收接口位于某个广播或点到点网络上，该回答的目的地址将分别是 ia_broadaddr 和 ia_dstaddr。icmp_input 把回答的目的地址放在 ip_src 里，因为 reflect 处的程序(图 11-21)会把源站和目的站地址倒过来。不改变单播请求的地址。

11.7.4 信息询问：ICMP_IREQ和ICMP_IREQREPLY

ICMP 信息报文已经过时了。它们企图广播一个源和目的站地址字段的网络部分为全 0 的请求，使系统发现连接的 IP 网络的数量。响应该请求的主机将返回一个填好网络号的报文。主机还需要其他办法找到地址的主机部分。

RFC 1122 推荐主机不要实现 ICMP 信息报文，因为 RARP(RFC 903 [Finlayson et al., 1984]) 和 BOOTP(RFC 951 [Croft 和 Gilmore 1985]) 更适于发现地址。RFC 1541 [Droms 1993] 描述的一个新协议，动态主机配置协议(Dynamic Host Configuration Protocol, DHCP)，可能会取代或增强 BOOTP 的功能。它现在是一个建议的标准。

Net/2 响应 ICMP 信息请求报文。但是，Net/3 把它们传给 rip_input。

11.7.5 路由器发现：ICMP_ROUTERADVERT和ICMP_ROUTEERSOLICIT

RFC 1256 定义了 ICMP 路由器发现报文。Net/3 内核不直接处理这些报文，而由 rip_input 把它们传给一个用户级守护程序，由它发送和响应这种报文。

卷 1 的 9.6 节 讨论了这种报文的设计和运行。

11.8 重定向处理

图 11-26 显示了 ICMP 重定向报文的格式。

icmp_input 中要讨论的最后一个 case 是 ICMP_REDIRECT。如 8.5 节 的讨论，当分组

被发给错误的路由器时，产生重定向报文。该路由器把分组转发给正确的路由器，并发回一个ICMP重定向报文，系统把信息记入它自己的路由表。

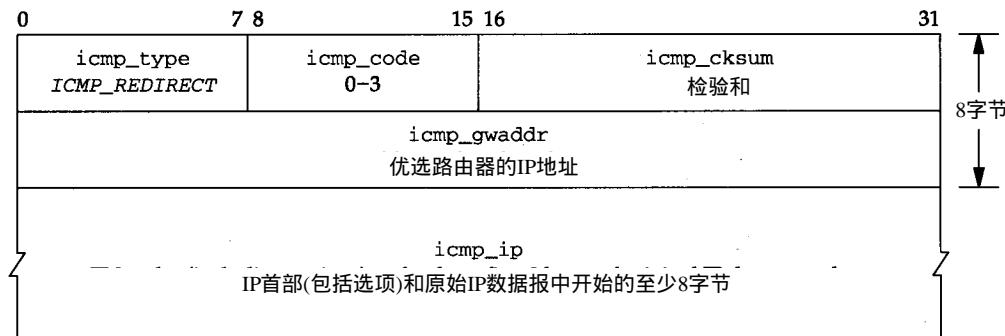


图11-26 ICMP重定向报文

图11-27显示了icmp_input用来处理重定向报文的程序。

```

283     case ICMP_REDIRECT:
284         if (code > 3)
285             goto badcode;
286         if (icmplen < ICMP_ADVLENMIN || icmplen < ICMP_ADVLEN(icp) ||
287             icp->icmp_ip.ip_hl < (sizeof(struct ip) >> 2)) {
288             icmpstat.icps_badlen++;
289             break;
290         }
291         /*
292          * Short circuit routing redirects to force
293          * immediate change in the kernel's routing
294          * tables. The message is also handed to anyone
295          * listening on a raw socket (e.g. the routing
296          * daemon for use in updating its tables).
297          */
298         icmpgw.sin_addr = ip->ip_src;
299         icmpdst.sin_addr = icp->icmp_gwaddr;
300         icmpsrc.sin_addr = icp->icmp_ip.ip_dst;
301         rtredirect((struct sockaddr *) &icmpsrc,
302                    (struct sockaddr *) &icmpdst,
303                    (struct sockaddr *) 0, RTF_GATEWAY | RTF_HOST,
304                    (struct sockaddr *) &icmpgw, (struct rtentry **) 0);
305         pfctlinput(PRC_REDIRECT_HOST, (struct sockaddr *) &icmpsrc);
306         break;

```

ip_icmp.c

图11-27 icmp_input 函数：重定向报文

1. 验证

283-290 如果重定向报文中含有未识别的ICMP码，icmp_input就跳到badcode(图11-18的232行)；如果报文具有无效长度或封闭的IP分组具有无效首部长度，则中止switch。图11-16显示了ICMP差错报文的最小长度是36(ICMP_ADVLENMIN)。ICMP_ADVLEN(icp)是当icp所指向的分组有IP选项时，ICMP差错报文的最小长度。

291-300 icmp_input分别把重定向报文的源站地址(发送该报文的网关)、为原始分组推荐的路由器(第一跳目的地)和原始分组的最终目的地址分配给 icmpgw、icmpdst 和 icmpsrc。

这里，`icmpsra`并不包含源站地址——这是方便存放目的地址的位置，无需再定义一个`sockaddr`结构。

2. 更新路由

301-306 Net/3按照RFC 1122的推荐，等价地对待网络重定向和主机重定向。重定向信息被传给`rtredirect`，由这个函数更新路由表。重定向的目的地址(保存在`icmpsra`)被传给`pfcctlinput`，由它通告重定向的所有协议域(7.3节)，使协议有机会把缓存的到目的站的路由作废。

按照RFC 1122，应该把网络重定向作为主机重定向对待，因为当目的网络划分了子网时，它们会提供不正确的路由信息。事实上，RFC 1009要求，在网络划分子网的情况下，不发送网络重定向。不幸的是，许多路由器违背了这个要求。Net/3从不发重定向报文。

ICMP重定向报文是IP路由选择体系结构的基本组成部分。尽管被划分到差错报文类，但它却是在任何有多个路由器的网络正常运行时出现的。第18章更详细讨论了IP路由选择问题。

11.9 回答处理

内核不处理任何ICMP回答报文。ICMP请求由进程产生，内核从不产生请求。所以，内核把它接收的所有回答传给等待ICMP报文的进程。另外，ICMP路由器发现报文被传给`rip_input`。

```
ip_icmp.c
```

```

307     /*
308      * No kernel processing for the following;
309      * just fall through to send to raw listener.
310      */
311     case ICMP_ECHOREPLY:
312     case ICMP_ROUTERADVERT:
313     case ICMP_ROUTERSOLICIT:
314     case ICMP_TSTAMPREPLY:
315     case ICMP_IREQREPLY:
316     case ICMP_MASKREPLY:
317     default:
318         break;
319     }
320 raw:
321     rip_input(m);
322     return;
```

```
ip_icmp.c
```

图11-28 `icmp_input` 函数：回答报文

307-322 内核无需对ICMP回答报文做出任何反应，所以在`raw`处的`switch`语句后继续执行(图11-15)。注意，`switch`语句的`default`情况(未识别的ICMP报文)也把控制传给在`raw`处的代码。

11.10 输出处理

有几种方法产生外出的ICMP报文。第8章讲到IP调用`icmp_error`来产生和发送ICMP差错报文。`icmp_reflect`发送ICMP回答报文，同时，进程也可能通过原始ICMP协议生成ICMP报文。图11-29显示了这些函数与ICMP外出处理之间的关系。

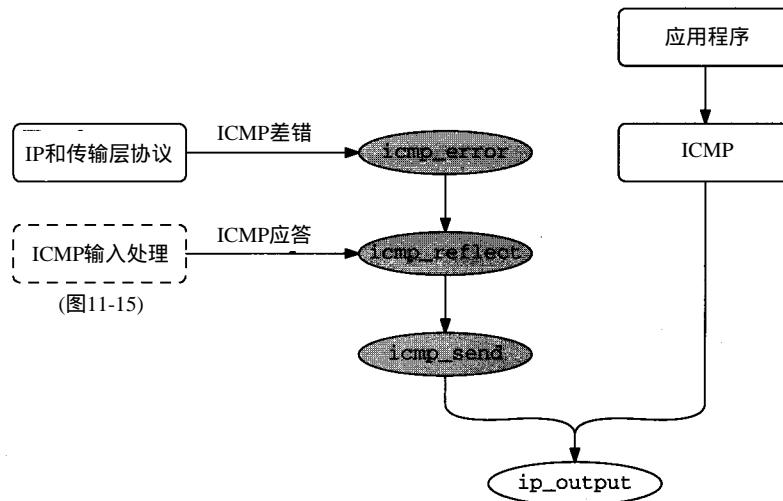


图11-29 ICMP外出处理

11.11 icmp_error函数

icmp_error在IP或运输层协议的请求下，构造一个 ICMP差错请求报文，并把它传给 icmp_reflect，在那里该报文被返回无效数据报的源站。我们分三部分分析这个函数：

```

46 void
47 icmp_error(n, type, code, dest, destifp) ip_icmp.c
48 struct mbuf *n;
49 int type, code;
50 n_long dest;
51 struct ifnet *destifp;
52 {
53     struct ip *oip = mtod(n, struct ip *), *nip;
54     unsigned oiplen = oip->ip_hl << 2;
55     struct icmp *icp;
56     struct mbuf *m;
57     unsigned icmplen;
58
59     if (type != ICMP_REDIRECT)
60         icmpstat.icps_error++;
61     /*
62      * Don't send error if not the first fragment of message.
63      * Don't error if the old packet protocol was ICMP
64      * error message, only known informational types.
65      */
66     if (oip->ip_off & ~(IP_MF | IP_DF))
67         goto freeit;
68     if (oip->ip_p == IPPROTO_ICMP && type != ICMP_REDIRECT &&
69         n->m_len >= oiplen + ICMP_MINLEN &&
70         !ICMP_INFOTYPE(((struct icmp *)((caddr_t) oip + oiplen))->icmp_type)) {
71         icmpstat.icps_oldicmp++;
72         goto freeit;
73     /* Don't send error in response to a multicast or broadcast packet */
74     if (n->m_flags & (M_BCAST | M_MCAST))
75         goto freeit;

```

ip_icmp.c

图11-30 icmp_error 函数：验证

- 确认该报文(图11-30)；
- 构造头部(图11-32)；并
- 把原来的数据报包含进来(图11-33)。

46-57 参数是：n，指向包含无效数据报缓存链的指针；type和code，ICMP差错类型和代码；dest，ICMP重定向报文中的下一跳路由器地址；以及 destifp，指向原始IP分组外出接口的指针。mtood把缓存链指针n转换成oip，oip是指向缓存中ip结构的指针。原始IP分组的字节长度保存在ioplent中。

58-75 icmp_error统计除重定向报文外的所有ICMP差错。Net/3不把重定向报文看作错误，而且icmp_error也不是一个SNMP变量。

icmp_error丢弃无效数据报oip，并且在以下情况下，不发送差错报文：

- 除IP_MF和IP_DF外，ip_off的某些位非零(习题11.10)。这表明oip不是数据报的第一个分片，而且ICMP决不能为跟踪数据报的分片而生成差错报文。
- 无效数据报本身是一个ICMP差错报文。如果icmp_type是ICMP请求或响应类型，则ICMP_INFOTYPE返回真；如果icmp_type是一个差错类型，则ICMP_INFOTYPE返回假。

Net/3不考虑ICMP重定向报文差错，尽管RFC 1122要求考虑。

- 数据报作为链路层广播或多播到达(由M_BCAST和M_MCAST标志表明)。

在以下两种其他情况下，不能发送ICMP差错报文：

- 该数据报是发给IP广播和IP多播地址的。
- 数据报的源站地址不是单播IP地址(也即，这个源站地址是一个全零地址、环回地址、广播地址、多播地址或E类地址)。

Net/3无法检查第一种情况。icmp_reflect函数强调了第二种情况(11.12节)。

有趣的是，Net/2的Deering多播扩展并不丢弃第一种类型的数据报。因为Net/3的多播程序来自Deering多播扩展，所以，检测似乎被删去了。

这些限制的目的是为了避免有错的广播数据报触发网络上所有主机都发出ICMP差错报文。当网络上所有主机同时要发送差错报文时，产生的广播风暴会使整个网络的通信崩溃。

这些规则适用于ICMP差错报文，但不适用于ICMP回答。如RFC 1122和RFC 1127的讨论，允许响应广播请求，但既不推荐也不鼓励。Net/3只响应具有单播源地址的广播请求，因为ip_output会把返回到广播地址的ICMP报文丢弃(图11-39)。

图11-31是ICMP差错报文的构造。

图11-32的程序构造差错报文。

76-106 icmp_error以下面的方式构造ICMP差错报文的首部：

- m_gethdr分配一个新的分组首部缓存。MH_ALIGN定位缓存的数据指针，使无效数据报的ICMP首部、IP首部(和选项)和最多8字节的数据被放在缓存的最后。
- icmp_type、icmp_code、icmp_gwaddr(用于重定向)、icmp_pptr(用于参数问题)和icmp_nextmtu(用于要求分片报文)被初始化。icmp_nextmtu字段实现了RFC 1191中描述的要求分片报文的扩展。卷1的24.2节描述的“路径MTU发现算法”依赖于这个报文。

一旦构造好ICMP首部，就必须把原始数据报的一部分附到首部上，如图11-33所示。

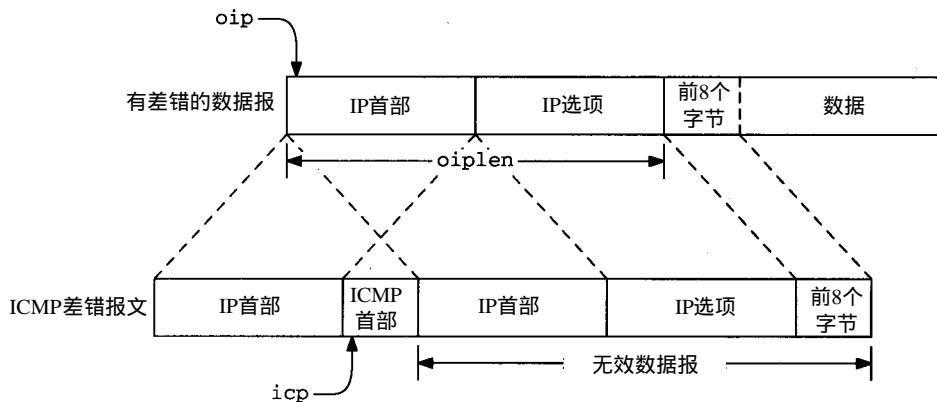


图11-31 ICMP差错报文的构造

```

76  /*
77   * First, formulate icmp message
78   */
79  m = m_gethdr(M_DONTWAIT, MT_HEADER);
80  if (m == NULL)
81      goto freeit;
82  icmplen = oiplen + min(8, oip->ip_len);
83  m->m_len = icmplen + ICMP_MINLEN;
84  MH_ALIGN(m, m->m_len);
85  icp = mtod(m, struct icmp *);
86  if ((u_int) type > ICMP_MAXTYPE)
87      panic("icmp_error");
88  icmpstat.icps_outhist[type]++;
89  icp->icmp_type = type;
90  if (type == ICMP_REDIRECT)
91      icp->icmp_gwaddr.s_addr = dest;
92  else {
93      icp->icmp_void = 0;
94      /*
95       * The following assignments assume an overlay with the
96       * zeroed icmp_void field.
97       */
98      if (type == ICMP_PARAMPROB) {
99          icp->icmp_pptr = code;
100         code = 0;
101     } else if (type == ICMP_UNREACH &&
102                code == ICMP_UNREACH_NEEDFRAG && destifp) {
103         icp->icmp_nextmtu = htons(destifp->if_mtu);
104     }
105 }
106 icp->icmp_code = code;

```

ip_icmp.c

图11-32 icmp_error 函数：报文头部构造

107-125 无效数据报的IP首部、选项和数据(一共是 icmplen个字节)被复制到ICMP差错报文中。同时，首部的长度被加回到无效数据报的 ip_len中。

在udp_usrreq中，UDP也把首部长度加回到无效数据报的 ip_len。其结果是一个ICMP报文，该报文具有无效分组 IP首部内的不正确的数据报长度。作者发现，许多基于Net/2程序的系统都有这个问题，Net/1系统没有这个问题。

```

107    bcopy((caddr_t) oip, (caddr_t) & icp->icmp_ip, icmpplen);           ip_icmp.c
108    nip = &icp->icmp_ip;
109    nip->ip_len = htons((u_short) (nip->ip_len + oiplen));
110
111    /*
112     * Now, copy old ip header (without options)
113     * in front of icmp message.
114     */
115    if (m->m_data - sizeof(struct ip) < m->m_pktdat)
116        panic("icmp len");
117    m->m_data -= sizeof(struct ip);
118    m->m_len += sizeof(struct ip);
119    m->m_pkthdr.len = m->m_len;
120    m->m_pkthdr.rcvif = n->m_pkthdr.rcvif;
121    nip = mtod(m, struct ip *);
122    bcopy((caddr_t) oip, (caddr_t) nip, sizeof(struct ip));
123    nip->ip_len = m->m_len;
124    nip->ip_hl = sizeof(struct ip) >> 2;
125    nip->ip_p = IPPROTO_ICMP;
126    nip->ip_tos = 0;
127    icmp_reflect(m);
128
129 }                                         ip_icmp.c

```

图11-33 icmp_error 函数：包含原始数据报

因为MH_ALIGN把ICMP报文分配在缓存的最后，所以缓存的前面应该有足够的空间存放IP首部。无效数据报的IP首部(除选项外)被复制到ICMP报文的前面。

Net/2版本的这部分有一个错误：函数的最后一个 bcopy移动oiplen个字节，其中包括无效数据报的选项。应该只复制没有选项的标准首部。

在恢复正常的数据报长度(ip_len)、首部长度(ip_hl)和协议(ip_p)后，IP首部就完整了。TOS字段(ip_tos)被清除。

RFC 792和RFC 1122推荐在ICMP报文中，把TOS字段设为0。

126-129 完整的报文被传给icmp_reflect，由icmp_reflect把它发回源主机。丢掉无效数据报。

11.12 icmp_reflect函数

icmp_reflect把ICMP回答或差错发回给请求或无效数据报的源站。必须牢记，icmp_reflect在发送数据报之前，把它的源站地址和目的地址倒过来。与ICMP报文的源站和目的站地址有关的规则非常复杂，图11-34对其中几个函数的作用作了小结。

我们分三部分讨论icmp_reflect函数：源站和目的站地址选择、选项构造及组装和发送。图11-35显示了该函数的第一部分。

1. 设置目的地址

329-345 icmp_reflect一开始，就复制ip_dst，并把请求或差错报文的源站地址ip_src移到ip_dst。icmp_error和icmp_reflect保证：ip_src对差错报文而言是有效的目的地址。ip_output丢掉所有发往广播地址的分组。

函数	小结
icmp_input	在地址掩码请求中，用接收接口的广播或目的地址代替全0地址
icmp_error	把作为链路级广播或多播发送的数据报引起的差错报文丢弃。应该丢弃(但没有)发往IP广播或多播地址的数据报引起的报文
icmp_reflect	丢弃报文，而不是把它返回给多播或实验地址 把非单播目的地址转换成接收接口的地址，对返回的报文来说，目的地址就是一个有效的源地址 交换源站和目的站的地址
ip_output	按照ICMP的请求丢弃输出的广播(也就是说，丢弃由发往广播地址的分组产生的差错报文)

图11-34 ICMP丢弃和地址小结

2. 选择源站地址

346-371 icmp_reflect在in_ifaddr中找到具有单播或广播地址的接口，该接口地址与原始数据报的目的地址匹配，这样，icmp_reflect就为报文选好了源地址。在多接口主机上，匹配的接口可能不是接收该数据报的接口。如果没有匹配，就选择正在接收的接口的in_ifaddr结构，或者in_ifaddr中的第一个地址(如果该接口没有被配置成IP可用的)。该函数把ip_src设成所选的地址，并把ip_ttl改为255(MAXTTL)，因为这是一个新的数据报。

RFC 1700推荐把所有IP分组的TTL字段设成64。但是现在，许多系统把ICMP报文的TTL设成255。

TTL的取值有一个折衷。小的TTL避免分组在路由回路里面循环，但也有可能使分组无法到达远一点的节点(有很多跳)。大的TTL允许分组到达远距离的主机，但却让分组在路由回路里循环较长时间。

ip_icmp.c

```

329 void
330 icmp_reflect(m)
331 struct mbuf *m;
332 {
333     struct ip *ip = mtod(m, struct ip *);
334     struct in_ifaddr *ia;
335     struct in_addr t;
336     struct mbuf *opts = 0, *ip_srcroute();
337     int     optlen = (ip->ip_hl << 2) - sizeof(struct ip);

338     if (!in_canforward(ip->ip_src) &&
339         ((ntohl(ip->ip_src.s_addr) & IN_CLASSA_NET) !=
340          (IN_LOOPBACKNET << IN_CLASSA_NSHIFT))) {
341         m_freem(m); /* Bad return address */
342         goto done; /* Ip_output() will check for broadcast */
343     }
344     t = ip->ip_dst;
345     ip->ip_dst = ip->ip_src;
346     /*
347      * If the incoming packet was addressed directly to us,
348      * use dst as the src for the reply. Otherwise (broadcast
349      * or anonymous), use the address which corresponds
350      * to the incoming interface.
351      */
352     for (ia = in_ifaddr; ia; ia = ia->ia_next) {

```

图11-35 icmp_reflect 函数：地址选择

```

353     if (t.s_addr == IA_SIN(ia)->sin_addr.s_addr)
354         break;
355     if ((ia->ia_ifp->if_flags & IFF_BROADCAST) &&
356         t.s_addr == satosin(&ia->ia_broadaddr)->sin_addr.s_addr)
357         break;
358     }
359     icmpdst.sin_addr = t;
360     if (ia == (struct in_ifaddr *) 0)
361         ia = (struct in_ifaddr *) ifaof_ifpforaddr(
362             (struct sockaddr *) &icmpdst, m->m_pkthdr.rcvif);
363     /*
364      * The following happens if the packet was not addressed to us,
365      * and was received on an interface with no IP address.
366      */
367     if (ia == (struct in_ifaddr *) 0)
368         ia = in_ifaddr;
369     t = IA_SIN(ia)->sin_addr;
370     ip->ip_src = t;
371     ip->ip_ttl = MAXTTL;

```

ip_icmp.c

图11-35 (续)

RFC 1122提出，对到达的回显请求或时间戳请求，要求把其中的源路由选项及记录路由和时间戳选项的建议，附到回答报文中。在这个过程期间，源路由必须被逆转过来。RFC 1122没有涉及在其他ICMP回答报文中如何处理这些选项。Net/3把这些规则应用于地址掩码请求，因为它在构造地址掩码回答后调用了 `icmp_reflect`(图11-21)。

程序的下一部分(图11-36)为ICMP报文构造选项。

```

372     if (optlen > 0) {
373         u_char *cp;
374         int opt, cnt;
375         u_int len;
376         /*
377          * Retrieve any source routing from the incoming packet;
378          * add on any record-route or timestamp options.
379          */
380         cp = (u_char *) (ip + 1);
381         if ((opts = ip_srcroute()) == 0 &&
382             (opts = m_gethdr(M_DONTWAIT, MT_HEADER)) != 0) {
383             opts->m_len = sizeof(struct in_addr);
384             mtod(opts, struct in_addr *)->s_addr = 0;
385         }
386         if (opts) {
387             for (cnt = optlen; cnt > 0; cnt -= len, cp += len) {
388                 opt = cp[IPOPT_OPTVAL];
389                 if (opt == IPOPT_EOL)
390                     break;
391                 if (opt == IPOPT_NOP)
392                     len = 1;
393                 else {
394                     len = cp[IPOPT_OLEN];
395                     if (len <= 0 || len > cnt)
396                         break;
397                 }
398             }

```

*ip_icmp.c*图11-36 `icmp_reflect` 函数：选项构造

```

399             * Should check for overflow, but it "can't happen"
400             */
401         if (opt == IPOPT_RR || opt == IPOPT_TS ||
402             opt == IPOPT_SECURITY) {
403             bcopy((caddr_t) cp,
404                   mtod(opts, caddr_t) + opts->m_len, len);
405             opts->m_len += len;
406         }
407     }
408     /* Terminate & pad, if necessary */
409     if (cnt = opts->m_len % 4) {
410         for (; cnt < 4; cnt++) {
411             *(mtod(opts, caddr_t) + opts->m_len) =
412                 IPOPT_EOL;
413             opts->m_len++;
414         }
415     }
416 }
```

ip_icmp.c

图11-36 (续)

3. 取得逆转后的源路由

372-385 如果到达的数据报没有选项，控制被传给 430行(图11-37)。*icmp_error*传给*icmp_reflect*的差错报文从来没有IP选项，所以后面的程序只用于那些被转换成回答并直接传给*icmp_reflect*的ICMP请求。

*cp*指向回答的选项的开始。*ip_srcroute*逆转并返回所有在*ipintr*处理数据报时保存下来的源路由选项。如果*ip_srcroute*返回0，即请求中没有源路由选项，*icmp_reflect*分配并初始化一个mbuf，作为空的*ipooption*结构。

4. 加上记录路由和时间戳选项

386-416 如果*opts*指向某个缓存，*for*循环搜索原始IP首部的选项，在*ip_srcroute*返回的源路由后面加上记录路由和时间戳选项。

在ICMP报文发送之前必须移走原始首部里的选项。这由图 11-37中的程序完成。

```

417     /*
418      * Now strip out original options by copying rest of first
419      * mbuf's data back, and adjust the IP length.
420      */
421     ip->ip_len -= optlen;
422     ip->ip_hl = sizeof(struct ip) >> 2;
423     m->m_len -= optlen;
424     if (m->m_flags & M_PKTHDR)
425         m->m_pkthdr.len -= optlen;
426     optlen += sizeof(struct ip);
427     bcopy((caddr_t) ip + optlen, (caddr_t) (ip + 1),
428           (unsigned) (m->m_len - sizeof(struct ip)));
429 }
430 m->m_flags &= ~(M_BCAST | M_MCAST);
431 icmp_send(m, opts);
432 done:
433     if (opts)
434         (void) m_free(opts);
435 }
```

*ip_icmp.c*图11-37 *icmp_reflect* 函数：最后的组装

5. 移走原始选项

417-429 `icmp_reflect` 把ICMP报文移到IP首部的后面，这样就从原始请求中移走了选项。如图11-38所示。新选项在 `opts` 所指向的 `mbuf` 里，被 `ip_output` 再次插入。

6. 发送报文和清除

430-435 在报文和选项被传给 `icmp_send` 之前，要明确地清除广播和多播标志位。此后释放掉存放选项的缓存。

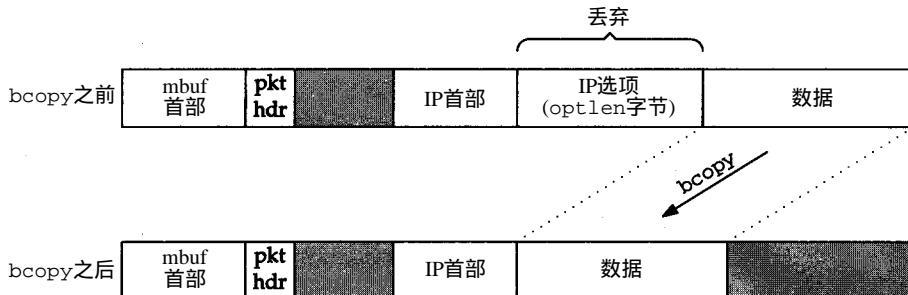


图11-38 `icmp_reflect` : 移走选项

11.13 `icmp_send` 函数

`icmp_send`(图11-39)处理所有输出的ICMP报文，并在把它们传给IP层之前计算ICMP检验和。

```

440 void ip_icmp.c
441 icmp_send(m, opts)
442 struct mbuf *m;
443 struct mbuf *opts;
444 {
445     struct ip *ip = mtod(m, struct ip *);
446     int hlen;
447     struct icmp *icp;

448     hlen = ip->ip_hl << 2;
449     m->m_data += hlen;
450     m->m_len -= hlen;
451     icp = mtod(m, struct icmp *);
452     icp->icmp_cksum = 0;
453     icp->icmp_cksum = in_cksum(m, ip->ip_len - hlen);
454     m->m_data -= hlen;
455     m->m_len += hlen;
456     (void) ip_output(m, opts, NULL, 0, NULL);
457 }
```

ip_icmp.c

图11-39 `icmp_send` 函数

440-457 与 `icmp_input` 检测ICMP检验和一样，Net/3调整缓存的数据指针和长度，隐藏IP首部，让 `in_cksum` 只看到ICMP报文。计算好的检验和放在首部的 `icmp_cksum`，然后把数据报和所有选项传给 `ip_output`。ICMP层并不维护路由高速缓存，所以 `icmp_send` 只传给 `ip_output` 一个空指针(第4个参数)，而不是控制标志。特别是不传 `IP_ALLOWBROADCAST`，所以 `ip_output` 丢弃所有具有广播目的地址的ICMP报文(也就是说，到达原始数据报的具有无效的源地址)。

11.14 icmp_sysctl函数

IP的icmp_sysctl函数只支持图11-40列出的选项。系统管理员可以用sysctl程序修改该选项。

Sysctl常量	Net/3变量	描述
ICMPCTL_MASKREPL	icmpmaskrepl	系统是否响应ICMP地址掩码请求

图11-40 icmp_sysctl 参数

图11-41显示了icmp_sysctl函数。

```
ip_icmp.c
467 int
468 icmp_sysctl(name, nameLEN, oldp, oldlenP, newp, newlen)
469 int *name;
470 u_int namelen;
471 void *oldp;
472 size_t *oldlenP;
473 void *newp;
474 size_t newlen;
475 {
476     /* All sysctl names at this level are terminal. */
477     if (namelen != 1)
478         return (ENOTDIR);
479     switch (name[0]) {
480     case ICMPCTL_MASKREPL:
481         return (sysctl_int(oldp, oldlenP, newp, newlen, &icmpmaskrepl));
482     default:
483         return (ENOPROTOOPT);
484     }
485     /* NOTREACHED */
486 }
```

ip_icmp.c

图11-41 icmp_sysctl 函数

467-478 如果缺少所要求的ICMP sysctl名，就返回ENOTDIR。

479-486 ICMP级以下没有选项，所以，如果不识别选项，该函数就调用sysctl_int修改icmpmaskrepl或返回ENOPROTOOPT。

11.15 小结

ICMP协议是作为IP上面的运输层实现的，但它与IP层紧密结合一起。我们看到，内核直接响应ICMP请求报文，但把差错与回答传给合适的运输层协议或应用程序处理。当一个ICMP重定向报文到达时，内核立刻重定向表，并且也把重定向传给所有等待的进程，比如典型地传给一个路由守护程序。

我们将在23.9和27.6节看到UDP和TCP协议如何响应ICMP差错报文，在第32章看到进程如何产生ICMP请求。

习题

11.1 一个目的地址是0.0.0.0的请求所产生的ICMP地址掩码回答报文的源地址是什么？

-
- 11.2 试描述一个具有假的单播源地址的分组在链路级的广播会如何影响网络上另一个主机的运行。
 - 11.3 RFC 1122建议，如果新的第一跳路由器与旧的第一跳路由器位于不同的子网，或者如果发送报文的路由器不是报文最终目的地的当前第一跳路由器，那么主机应该丢弃ICMP重定向报文。为什么要采纳这个建议？
 - 11.4 如果ICMP信息请求是过时的，为什么 `icmp_inout` 要把它传给 `rip_input` 而不是丢弃它呢？
 - 11.5 我们指出，Net/3在把IP分组放入一个ICMP差错报文之前，并不把它的偏移和长度字段转换成网络字节序。为什么这对IP位移字段来说是无关紧要的？
 - 11.6 描述某种情况，使图11-25的 `ifaof_ifpforaddr` 返回一个空指针。
 - 11.7 在一次时间戳询问中，时间戳后面的数据会怎么样？
 - 11.8 实现以下改变，改进ICMP时间戳程序：
在缓存分组首部加上一个时间戳字段，让设备驱动程序把接收分组的确切时间记录在这个字段内，并用ICMP时间戳程序把该值复制到 `icmp_rttime` 字段。
在输出端，让ICMP时间戳程序保存分组中的某个字节偏移，该位置用于保存时间戳里的当前时间。修改设备驱动程序，在发送分组之前插入时间戳。
 - 11.9 修改 `icmp_error`，使ICMP差错报文中返回最多64字节(像Solaris 2.x一样)的原始数据。
 - 11.10 图11-30中，`ip_off`的高位被置位的分组会发生什么情况？
 - 11.11 为什么图11-39中丢弃了 `ip_output` 返回的值？

第12章 IP 多 播

12.1 引言

第8章讲到，D类IP地址(224.0.0.0到239.255.255.255)不识别互联网内的单个接口，但识别接口组。因为这个原因，D类地址被称为多播组(multicast group)。具有D类目的地址的数据报被提交给互联网内所有加入相应多播组的各个接口。

Internet上利用多播的实验性应用程序包括：音频和视频会议应用程序、资源发现工具和共享白板等。

多播组的成员由于接口加入或离开组而动态地变化，这是根据各系统上运行的进程的请求决定的。因为多播组成员与接口有关，所以多接口主机可能针对每个接口，都有不同的多播组成员关系表。我们称一个特定接口上的组成员关系为一对{接口，多播组}。

单个网络上的组成员利用IGMP协议(第13章)在系统之间通信。多播路由器用多播选路协议(第14章)，如DVMRP(Distance Vector Multicast Routing Protocol，距离向量多播路由选择协议)传播成员信息。标准IP路由器可能支持多播选路，或者用一专用路由器处理多播选路。

如以太网、令牌环和FDDI一类的网络直接支持硬件多播。在Net/3中，如果某个接口支持多播，那么在接口的ifnet结构(图3-7)中的if_flags标志的IFF_MULTICAST比特就被打开。因为以太网被广泛使用，并且Net/3有以太网驱动器程序，所以我们将以以太网为例说明硬件支持的IP多播。多播业务通常在如SLIP和环回接口等的点到点网络上实现。

如果本地网络不支持硬件级多播，那么在某个特定接口上就得不到IP多播业务。RFC 1122并不反对接口层提供软件级的多播业务，只要它对IP是透明的。

RFC 1112 [Deering 1989]描述了多播对主机的要求。分三个级别：

0级：主机不能发送或接收IP多播。

这种主机应该自动丢弃它收到的具有D类目的地址的分组。

1级：主机能发送但不能接收IP多播。

在向某个IP多播组发送数据报之前，并不要求主机加入该组。多播数据报的发送方式与单播一样，除了多播数据报的目的地址是IP多播组之外。网络驱动器必须能够识别出这个地址，把在本地网络上多播数据报。

2级：主机能发送和接收IP多播。

为了接收IP多播，主机必须能够加入或离开多播组，而且必须支持IGMP，能够在至少一个接口上交换组成员信息。多接口主机必须支持在它的接口的一个子网上的多播。

Net/3符合2级主机要求，可以完成多播路由器的工作。与单播IP选路一样，我们假定所描述的系统是一个多播路由器，并加上了Net/3多播选路的程序。

知名的IP多播组

和UDP、TCP的端口号一样，互联网号授权机构IANA(Internet Assigned Numbers

Authority)维护着一个注册的IP多播组表。当前的表可以在RFC 1700中查到。有关IANA的其他信息可以在RFC 1700中找到。图12-1只给出了一些知名的多播组。

组	描述	Net/3常量
224.0.0.0	预留	<i>INADDR_UNSPEC_GROUP</i>
224.0.0.1	这个子网上的所有系统	<i>INADDR_ALLHOSTS_GROUP</i>
224.0.0.2	这个子网上的所有路由器	
224.0.0.3	没有分配	<i>INADDR_MAX_LOCAL_GROUP</i>
224.0.0.4	DVMRP路由器	
224.0.0.255	没有分配	
224.0.1.1	NTP网络时间协议	
224.0.1.2	SGI-Dogfight	

图12-1 一些注册的IP多播组

前256个组(224.0.0.0到224.0.0.255)是为实现IP单播和多播选路机制的协议预留的。不管发给其中任意一个组的数据报内IP首部的TTL值如何变化，多播路由器都不会把它转发出本地网络。

RFC 1075只对224.0.0.0组和224.0.0.1组有这个要求，但最常见的多播选路实现mrouted限制这里讨论的其他组。组224.0.0.0(*INADDR_UNSPEC_GROUP*)被预留，组224.0.0.255(*INADDR_MAX_LOCAL_GROUP*)标志着本地最后一个多播组。

对于符合2级的系统，要求其在系统初始化时(图6-17)，在所有的多播接口上加入224.0.0.1组(*INADDR_ALLHOSTS_GROUP*)，并且保持为该组成员，直到系统关闭。在一个互联网上，没有多播组与每个接口都对应。

想像一下，如果你的语音邮件系统有一个选项，可以向公司里的所有语音邮箱发一个消息。可能你就有这个选项。你发现它有用吗？对更大的公司适用吗？是否有人能向“所有邮箱”组发邮件，或者是否限制这么做？

单播和多播路由可能会加入224.0.0.2组进行互相通信。ICMP路由器请求报文和路由器通告报文可能被分别发往224.0.0.2(“所有路由器”组)和224.0.0.1(“所有主机”组)，而不是受限的广播地址(255.255.255.255)。

224.0.0.4组支持在实现DVMRP的多播路由器之间的通信。本地多播组范围内的其他组被类似地指派给其他路由选择协议。

除了前256个组外，其他组(224.0.1.0~239.255.255.255)或者被分配给多个多播应用程序协议，或者仍然没有被分配。图12-1中有两个例子，网络时间协议(224.0.1.1)和SGI-Dogfight(224.0.1.2)。

在本章中，我们注意到，是主机上的运输层发送和接收多播分组。尽管多播程序并不知道具体是哪个传输协议发送和接收多播数据报，但唯一支持多播的Internet传输协议是UDP。

12.2 代码介绍

本章中讨论的基本多播程序与标准IP程序在相同的文件里。图12-2列出了我们研究的文件。

文件	描述
net/if_either.h	以太网多播数据结构和宏定义
netinet/in.h	其他Internet多播数据结构
netinet/in_var.h	Internet多播数据结构和宏定义
netinet/ip_var.h	IP多播数据结构
net/if_ethersubr.c	以太网多播函数
netinet/in.c	组成员函数
netinet/ip_input.c	输入多播处理
netinet/ip_output.c	输出多播处理

图12-2 本章讨论的文件

12.2.1 全局变量

本章介绍了三个新的全局变量(图12-3)。

变量	数据类型	描述
ether_ipmulticast_min	u_char []	为IP预留的最小以太网多播地址
ether_ipmulticast_max	u_char []	为IP预留的最大以太网多播地址
ip_mrrouter	struct socket *	多播选路守护程序创建的指向插口的指针

图12-3 本章引入的全局变量

12.2.2 统计量

本章讨论的程序更新全局 ipstat 结构中的几个计数器。

ipstat成员	描述
ips_forward	被这个系统转发的分组数
ips_cantforward	不能被系统转发的分组数——系统不是一个路由器
ips_noroute	由于无法访问到路由器而无法转发的分组数

图12-4 多播处理统计量

链路级多播统计放在 ifnet 结构中(图4-5)，还可能统计除 IP 以外的其他协议的多播。

12.3 以太网多播地址

IP多播的高效实现要求IP充分利用硬件级多播，因为如果没有硬件级多播，就不得不在网络上广播每个多播IP数据报，而每台主机也不得不检查每个数据报，把那些不是给它的丢掉。硬件在数据报到达IP层之前，就把没有用的过滤掉了。

为了保证硬件过滤器能正常工作，网络接口必须把IP多播组目的地址转换成网络硬件识别的链路级多播地址。在点到点网络上，如SLIP和环回接口，必须明确给出地址映射，因为只能有一个目的地址。在其他网络上，如以太网，也需要有一个明确地完成映射地址的函数。以太网的标准映射适用于任何使用802.3寻址方式的网络。

图4-12显示了以太网单播和多播地址的区别：如果以太网地址的高位字节的最低位是1，则它是一个多播地址；否则，它是一个单播地址。单播以太网地址由接口制造商分配，多播

地址由网络协议动态分配。

IP到以太网地址映射

因为以太网支持多种协议，所以要采取措施分配多播地址，避免冲突。IEEE管理以太网多播地址分配。IEEE把一块以太网多播地址分给IANA以支持IP多播。块的地址都以01:00:5e开头。

以00:00:5e开头的以太网单播也被分配给IANA，但为将来使用预留。

图12-5显示了从一个D类IP地址构造出一个以太网多播地址。

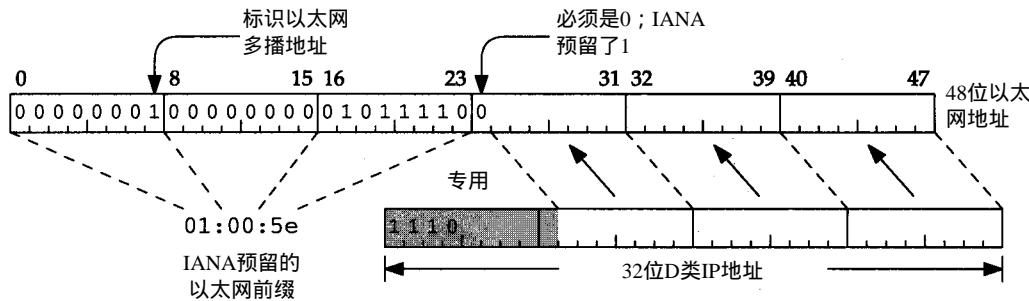


图12-5 IP和以太网地址之间的映射

图12-5显示的映射是一个多到一的映射。在构造以太网地址时，没有使用D类IP地址的高位9比特。32个IP多播组映射到一个以太网多播地址（习题12.3）。我们将在12.14节看到这将如何影响输入的处理。图12-6显示了Net/3中实现这个映射的宏。

```
if_ether.h
61 #define ETHER_MAP_IP_MULTICAST(ipaddr, enaddr) \
62     /* struct in_addr *ipaddr; */ \
63     /* u_char enaddr[6]; */ \
64 { \
65     (enaddr)[0] = 0x01; \
66     (enaddr)[1] = 0x00; \
67     (enaddr)[2] = 0x5e; \
68     (enaddr)[3] = ((u_char *)ipaddr)[1] & 0x7f; \
69     (enaddr)[4] = ((u_char *)ipaddr)[2]; \
70     (enaddr)[5] = ((u_char *)ipaddr)[3]; \
71 }
```

if_ether.h

图12-6 ETHER_MAP_IP_MULTICAST 宏

IP到以太网多播映射

61-71 ETHER_MAP_IP_MULTICAST实现图12-5所示的映射。ipaddr指向D类多播地址，enaddr构造匹配的以太网地址，用6字节的数组表示。该以太网多播地址的前3个字节是0x01，0x00和0x5e，后面跟着0比特，然后是D类IP地址的低23位。

12.4 ether_multi结构

Net/3为每个以太网接口维护一个该硬件接收的以太网多播地址范围表。这个表定义了该设备要实现的多播过滤。因为大多数以太网设备能选择地接收的地址是有限的，所以IP层必须要准备丢弃那些通过了硬件过滤的数据报。地址范围被保存在ether_multi结构中（图12-7）：

```

147 struct ether_multi {
148     u_char enm_addrlo[6];      /* low or only address of range */
149     u_char enm_addrhi[6];      /* high or only address of range */
150     struct arpcom *enm_ac;    /* back pointer to arpcom */
151     u_int enm_refcount;        /* no. claims to this addr/range */
152     struct ether_multi *enm_next; /* ptr to next ether_multi */
153 };

```

if_ether.h

图12-7 ether_multi 结构

1. 以太网多播地址

147-153 enm_addrlo和enm_addrhi指定需要被接收的以太网多播地址的范围。当enm_addrlo和enm_addrhi相同时，就指定一个以太网地址。ether_multi的完整列表附在每个以太网接口的arpcom结构中(图3-26)。以太网多播独立于ARP——使用arpcom结构只是为了方便，因为该结构已经存在于所有以太网接口结构中。

我们将看到，这个范围的开头和结尾总是相同的，因为在Net/3中，进程无法指定地址范围。

enm_ac指向相关接口的arpcom结构，enm_refcount跟踪对ether_multi结构的使用。当引用计数变成0时，就释放arpcom结构。enm_next把单个接口的ether_multi结构做成链表。图12-8显示出，有三个ether_multi结构的链表附在le_softc[0]上，这是我们以太网接口示例的ifnet结构。

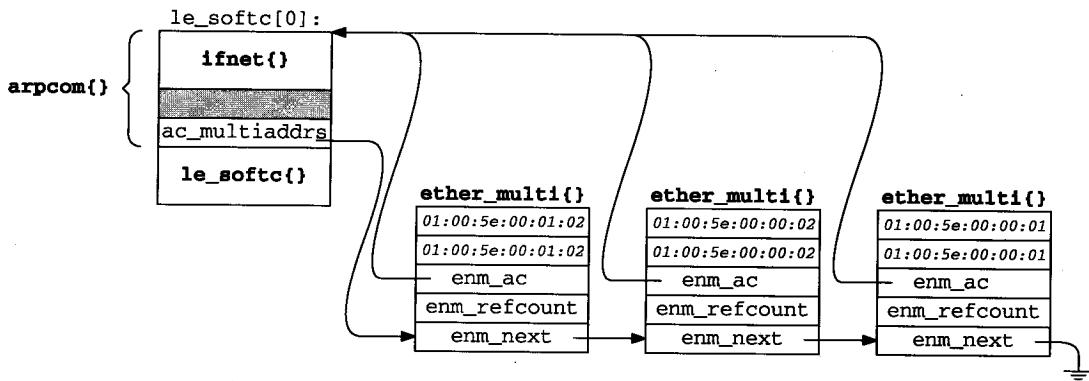


图12-8 有三个ether_multi 结构的LANCE接口

在图12-8中，我们看到：

- 接口已经加入了三个组。很有可能是 224.0.0.1(所有主机)、224.0.0.2(所有路由器)和 224.0.1.2(SGI-dogfight)。因为以太网到IP地址的映射是一到多的，所以只看到以太网多播地址的结果，无法确定确切的 IP多播地址。比如，接口可能已经加入了 225.0.0.1、225.0.0.2和226.0.1.2组。
- 有了enm_ac后向指针，就很容易找到链表的开始，释放某个 ehter_multi结构，无需再实现双向链表。
- ether_multi只适用于以太网设备。其他多播设备可能有其他实现。

图12-9中的ETHER_LOOKUP_MULTI宏，搜索某个ether_multi结构，找到地址范围。

2. 以太网多播查找

166-177 addrlo和addrhi指定搜索的范围，ac指向包含了要搜索链表的arpcom结构。

for循环完成线性搜索，在表的最后结束，或者当 enm_addrlo和enm_addrhi都分别与所提供的addrlo和addrhi匹配时结束。当循环终止时，enm为空或者指向某个匹配的ether_multi结构。

```
166 #define ETHER_LOOKUP_MULTI(addrlo, addrhi, ac, enm) \
167     /* u_char addrlo[6]; */ \
168     /* u_char addrhi[6]; */ \
169     /* struct arpcom *ac; */ \
170     /* struct ether_multi *enm; */ \
171 { \
172     for ((enm) = (ac)->ac_multiaddrs; \
173         (enm) != NULL && \
174         (bcmpl((enm)->enm_addrlo, (addrlo), 6) != 0 || \
175          bcmpl((enm)->enm_addrhi, (addrhi), 6) != 0); \
176         (enm) = (enm)->enm_next); \
177 }
```

if_ether.h

图12-9 ETHER_LOOKUP_MULTI 宏

12.5 以太网多播接收

从本节以后，本章只讨论IP多播。但是，在Net/3中，也有可能把系统配置成接收所有以太网多播分组。虽然对IP协议族没有用，但内核的其他协议族可能准备接收这些多播分组。发出图12-10中的ioctl命令，就可以明确地进行多播配置。

命 令	参 数	函 数	描 述
SIOCADDMULTI	struct ifreq *	ifioctl	在接收表里加上多播地址
SIOCDELMULTI	struct ifreq *	ifioctl	从接收表里删去多播地址

图12-10 多播ioctl命令

这两个命令被ifioctl(图12-11)直接传给ifreq结构(图6-12)中所指定的接口的设备驱动程序。

```
440 case SIOCADDMULTI:
441 case SIOCDELMULTI:
442     if (error = suser(p->p_ucred, &p->p_acflag))
443         return (error);
444     if (ifp->if_ioctl == NULL)
445         return (EOPNOTSUPP);
446     return ((*ifp->if_ioctl) (ifp, cmd, data));
```

*if.c**if.c*

图12-11 ifioctl 函数：多播命令

440-446 如果该进程没有超级用户权限，或者如果接口没有if_ioctl结构，则ifioctl返回一个错误；否则，把请求直接传给该设备驱动程序。

12.6 in_multi结构

12.4节描述的以太网多播数据结构并不专用于IP；它们必须支持所有内核支持的任意协议族的多播活动。在网络级，IP维护着一个与接口相关的IP多播组表。

为了实现方便，把这个IP多播表附在与该接口有关的in_ifaddr结构中。6.5节讲到，这

个结构中包含了该接口的单播地址。除了它们都与同一个接口相关以外，这个单播地址与所附的多播组表之间没有任何关系。

这是Net/3实现的产品。也可以在一个不接收IP单播分组的接口上，支持IP多播组。

图12-12中的in_multi结构描述了每个IP多播{接口，组}对。

```
111 struct in_multi {
112     struct in_addr inm_addr;      /* IP multicast address */
113     struct ifnet *inm_ifp;        /* back pointer to ifnet */
114     struct in_ifaddr *inm_ia;     /* back pointer to in_ifaddr */
115     u_int    inm_refcount;       /* no. membership claims by sockets */
116     u_int    inm_timer;          /* IGMP membership report timer */
117     struct in_multi *inm_next;   /* ptr to next multicast address */
118 };
```

图12-12 in_multi 结构

1. IP多播地址

111-118 inm_addr是一个D类多播地址(如224.0.0.1，所有主机组)。inm_ifp指向相关接口的ifnet结构，而inm_ia指回接口的in_ifaddr结构。

只有当系统中的某个进程通知内核，它要在某个特定的{接口，组}对上接收多播数据报时，才存在一个in_multi结构。由于可能会有多个进程要求接收发往同一个对上的数据报，所以inm_refcount跟踪对该对的引用次数。当没有进程对某个特定的对感兴趣时，inm_refcount就变成0，in_multi结构就被释放掉。这个动作可能会引起相关的ether_multi结构也被释放，如果此时它的引用计数也变成了0。

inm_timer是第13章描述的IGMP协议实现的一部分，最后，inm_next指向表中的下一个in_multi结构。

图12-13用接口示例le_softc[0]显示了接口，即它的单播地址和它的IP多播组表之间的关系。

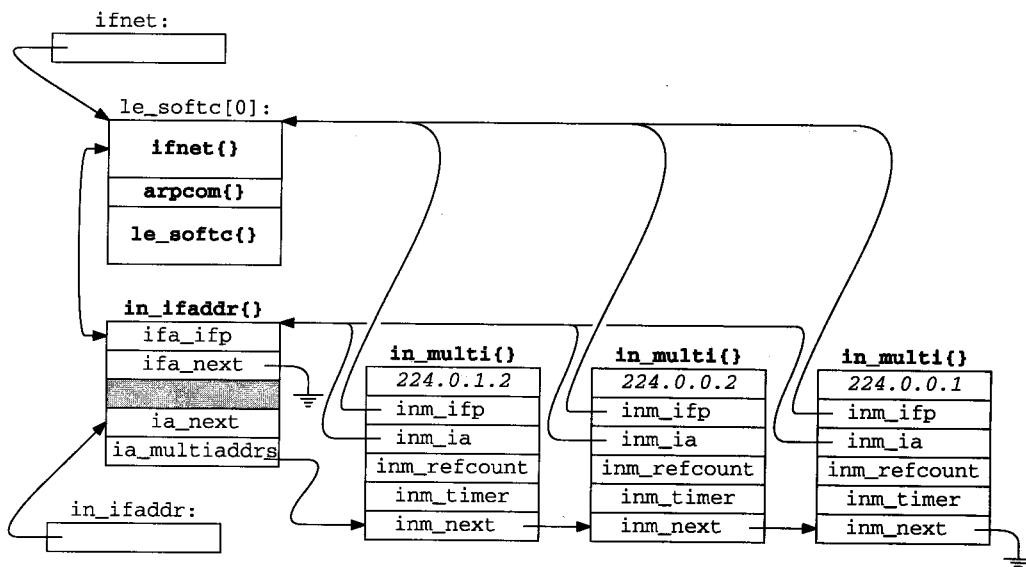


图12-13 le接口的一个IP多播组表

为了清楚起见，我们已经省略了对应的 ether_multi 结构(图12-34)。如果系统有两个以太网网卡，第二个可能由 le_softc[1]管理，还可能有它自己的附在 arpcom 结构的多播组表。IN_LOOKUP_MULTI宏(图12-14)搜索IP多播表寻找某个特定多播组。

2. IP多播查找

131-146 IN_LOOKUP_MULTI 在与接口 ifp 相关的多播组表中查找多播组 addr。IFP_TO_IA 搜索 Internet 地址表 in_ifaddr，寻找与接口 ifp 相关的 in_ifaddr 结构。如果 IFP_TO_IA 找到一个接口，则 for 循环搜索它的 IP 多播表。循环结束后，inm 为空或指向匹配的 in_multi 结构。

```
131 #define IN_LOOKUP_MULTI(addr, ifp, inm) \
132     /* struct in_addr addr; */ \
133     /* struct ifnet *ifp; */ \
134     /* struct in_multi *inm; */ \
135 { \
136     struct in_ifaddr *ia; \
137 \
138     IFP_TO_IA((ifp), ia); \
139     if (ia == NULL) \
140         (inm) = NULL; \
141     else \
142         for ((inm) = ia->ia_multiaddrs; \
143             (inm) != NULL && (inm)->inm_addr.s_addr != (addr).s_addr; \
144             (inm) = inm->inm_next) \
145             continue; \
146 }
```

in_var.h

图12-14 IN_LOOKUP_MULTI 宏

12.7 ip_moptions 结构

运输层通过 ip_moptions 结构包含的多播选项控制多播输出处理。例如， UDP 调用 ip_output 是：

```
error = ip_output(m, inp->inp_options, &inp->inp_route,
                  inp->inp_socket->so_options & (SO_DONTROUTE|SO_BROADCAST),
                  inp->inp_moptions);
```

在第22章中我们将看到，inp 指向某个 Internet 协议控制块(PCB)，并且 UDP 为每个由进程创建的 socket 关联一个 PCB。在 PCB 内，inp_moptions 是指向某个 ip_moptions 结构的指针。这里我们看到，对每个输出的数据报，都可以给 ip_output 传一个不同的 ip_moptions 结构。图12-15是 ip_moptions 结构的定义。

```
100 struct ip_moptions {
101     struct ifnet *imo_multicast_ifp; /* ifp for outgoing multicasts */
102     u_char imo_multicast_ttl;        /* TTL for outgoing multicasts */
103     u_char imo_multicast_loop;       /* 1 => hear sends if a member */
104     u_short imo_num_memberships;    /* no. memberships this socket */
105     struct in_multi *imo_membership[IP_MAX_MEMBERSHIPS];
106 };
```

ip_var.h

图12-15 ip_moptions 结构

多播选项

100-106 ip_output通过imo_multicast_ifp指向的接口对输出的多播数据报进行选路。如果imo_multicast_ifp为空，就通过目的站多播组的默认接口(第14章)。

imo_multicast_ttl为外出的多播数据报指定初始的IP TTL。默认值是1，把多播数据报保留在本地网络内。

如果imo_multicast_loop是0，就不回送数据报，也不把数据报提交给正在发送的接口，即使该接口是多播组的成员。如果imo_multicast_loop是1，并且如果正在发送的接口是多播组的成员，就把多播数据报回送给该接口。

最后，整数imo_num_memberships和数组imo_membership维护与该结构相关的{接口，组}对。所有对该表的改变都转告给IP，由IP在所连到的本地网络上宣布成员的变化。imo_membership数组的每个入口都是指向一个in_multi结构的指针，该in_multi结构附在适当接口的in_ifaddr结构上。

12.8 多播的插口选项

图12-16显示了几个IP级的插口选项，提供对ip_moptions结构的进程级访问。

命 令	参 数	函 数	描 述
IP_MULTICAST_IF	struct in_addr	ip_ctloutput	为外出的多播选择默认接口
IP_MULTICAST_TTL	u_char	ip_ctloutput	为外出的多播选择默认的TTL
IP_MULTICAST_LOOP	u_char	ip_ctloutput	允许或使能回送外出的多播
IP_ADD_MEMBERSHIP	struct ip_mreq	ip_ctloutput	加入一个多播组
IP_DROP_MEMBERSHIP	struct ip_mreq	ip_ctloutput	离开一个多播组

图12-16 多播插口选项

我们在图8-31中看到ip_ctloutput函数的整体结构。图12-17显示了与改变和检索多播选项有关的情况语句。

```

448     case PRCO_SETOPT:
449         switch (optname) {

486             case IP_MULTICAST_IF:
487             case IP_MULTICAST_TTL:
488             case IP_MULTICAST_LOOP:
489             case IP_ADD_MEMBERSHIP:
490             case IP_DROP_MEMBERSHIP:
491                 error = ip_setmoptions(optname, &inp->inp_moptions, m);
492                 break;
493                 freeit:
494             default:
495                 error = EINVAL;
496                 break;
497             }
498         if (m)

```

图12-17 ip_ctloutput 函数：多播选项

```

499             (void) m_free(m);
500         break;

501     case PRCO_SETOPT:
502         switch (optname) {
503             /* other set cases */
504
539         case IP_MULTICAST_IF:
540         case IP_MULTICAST_TTL:
541         case IP_MULTICAST_LOOP:
542         case IP_ADD_MEMBERSHIP:
543         case IP_DROP_MEMBERSHIP:
544             error = ip_getmoptions(optname, inp->inp_moptions, mp);
545             break;
546
547         default:
548             error = ENOPROTOOPT;
549         }

```

ip_output.c

图12-17 (续)

486-491 所有多播选项都由 `ip_setmoptions` 和 `ip_getmoptions` 函数处理。
`ip_moptions` 结构由引用传给

539-549 `ip_getmoptions` 和 `ip_setmoptions`，该结构与发布 `ioctl` 命令的那个插口关联。

对于 `PRCO_SETOPT` 和 `PRCO_GETOPT` 两种情况，选项不识别时返回的差错码是不一样的。`ENOPROTOOPT` 是更合理的选择。

12.9 多播的TTL值

多播的TTL值难以理解，因为它们有两个作用。TTL值的基本作用，如IP分组一样，是限制分组在互联网内的生存期，避免它在网络内部无限地循环。第二个作用是，把分组限制在管理边界所指定的互联网的某个区域内。管理区域是由一些主观的词语指定的，如“这个结点”，“这个公司”，“这个州”等，并与分组开始的地方有关。与多播分组有关的区域叫做它的辖域(scope)。

RFC 1122的标准实现把生存期和辖域这两个概念合并在 IP首部的一个 TTL值里。当IP TTL变成0时，除了丢弃该分组外，多播路由器还给每个接口关联了一个 TTL阈值，限制在该接口上的多播传输。一个要在该接口上传输的分组必须具有大于或等于该接口阈值的 TTL。由于这个原因，多播分组可能会在它的 TTL到0之前就被丢弃了。

阈值是管理员在配置多播路由器时分配的，这些值确定了多播分组的辖域。管理员使用的阈值策略以及数据报的源站与多播接口之间的距离定义多播数据报的初始 TTL值的意义。

图12-18显示了多种应用程序的推荐TTL值和推荐的阈值。

第一栏是IP首部中的 `ip_ttl` 初始值。第二栏是应用程序专用阈值 ([Casner 1993])。第三栏是与该TTL值相关的推荐的辖域。

例如，一个要与本地结点外的网络通信的接口，多播阈值要被配置成 32。所有开始时

TTL为32(或小于32)的数据报到达该接口时，TTL都小于32(假定源站和路由器之间至少有一跳)，所以它们在被转发到外部网络之前，都被丢弃了——即使TTL远大于0。

TTL初始值是128的多播数据报可以通过阈值为32的结点接口(只要它以少于 $128 - 32 = 96$ 跳到达接口)，但将被阈值为128的洲际接口丢弃。

ip_ttl	应用 程序	辖 域
0		同一接口
1		同一子网
31	本地事件视频	
32		同一地点
63	本地事件音频	
64		同一区域
95	IETF频道2视频	
127	IETF频道1视频	
128		同一州
159	IETF频道2音频	
191	IETF频道1音频	
223	IETF频道2低速率音频	
255	IETF频道1低速率音频，辖域不受限	

图12-18 IP多播数据报的TTL值

12.9.1 MBONE

Internet上有一个路由器子网支持IP多播选路。这个多播骨干网称为MBONE,[Casner 1993] 对其作了描述。它是为了支持用IP多播的实验——尤其是用音频和视频数据流的实验。在MBONE里，阈值限制了多种数据流传播的距离。在图12-18中，我们看到本地事件视频分组总是以TTL 31开始。阈值为32的接口总是阻止本地事件视频。另外，IETF频道1低速率音频，只受到IP TTL固有的最大255跳的限制。它能传播通过整个MBONE。MBONE内的路由器的管理员可以选择阈值，有选择地接受或丢弃MBONE数据流。

12.9.2 扩展环搜索

多播TTL的另一种用处是，只要改变探测数据报的初始TTL值，就能在互联网上探测资源。这个技术叫做扩展环搜索(expanding-ring search,[Boggs 1982])。初始TTL为0的数据报只能到达与外出接口相关的本地网络上的一个资源；TTL为1，则到达本地子网(如果存在)上的资源；TTL为2，则到达相距2跳的资源。应用程序指数地增加TTL的值，迅速地在大的互联网上探测资源。

RFC 1546 [Partridge、Mendez和Milliken 1993] 描述了一种相关业务的任播(anycasting)。任播依赖一组显著的IP地址来表示更像多播的多个主机的组。与多播地址不同，网络必须传播所有任播的分组，直到它被至少一个主机接收。这样简化了应用程序的实现，不再进行扩展环搜索。

12.10 ip_setmoptions函数

ip_setmoptions函数块包括一个用来处理各选项的switch语句。图12-19是

ip_setmoptions的开始和结束。下面几节讨论switch的语句体。

ip_output.c

```

650 int
651 ip_setmoptions(optname, imop, m)
652 int      optname;
653 struct ip_moptions **imop;
654 struct mbuf *m;
655 {
656     int      error = 0;
657     u_char   loop;
658     int      i;
659     struct in_addr addr;
660     struct ip_mreq *mreq;
661     struct ifnet *ifp;
662     struct ip_moptions *imo = *imop;
663     struct route ro;
664     struct sockaddr_in *dst;
665     if (imo == NULL) {
666         /*
667          * No multicast option buffer attached to the pcb;
668          * allocate one and initialize to default values.
669          */
670         imo = (struct ip_moptions *) malloc(sizeof(*imo), M_IPMOPTS,
671                                             M_WAITOK);
672         if (imo == NULL)
673             return (ENOBUFS);
674         *imop = imo;
675         imo->imo_multicast_ifp = NULL;
676         imo->imo_multicast_ttl = IP_DEFAULT_MULTICAST_TTL;
677         imo->imo_multicast_loop = IP_DEFAULT_MULTICAST_LOOP;
678         imo->imo_num_memberships = 0;
679     }
680     switch (optname) {
681         /* switch cases */
682     default:
683         error = EOPNOTSUPP;
684         break;
685     }
686     /*
687      * If all options have default values, no need to keep the mbuf.
688      */
689     if (imo->imo_multicast_ifp == NULL &&
690         imo->imo_multicast_ttl == IP_DEFAULT_MULTICAST_TTL &&
691         imo->imo_multicast_loop == IP_DEFAULT_MULTICAST_LOOP &&
692         imo->imo_num_memberships == 0) {
693         free(*imop, M_IPMOPTS);
694         *imop = NULL;
695     }
696     return (error);
697 }
```

ip_output.c

图12-19 ip_setmoptions 函数

650-664 第一个参数，optname，指明正在改变哪个多播参数。第二个参数，imop，是指向某个ip_moptions结构的指针。如果*imop不空，ip_setmoptions修改它所指向的

结构。否则，`ip_setmoptions`分配一个新的`ip_moptions`结构，并把它的地址保存在`*imop`里。如果没有内存了，`ip_setmoptions`立即返回`ENOBUFS`。后面的所有错误都通告`error`，`error`在函数的最后被返回给调用方。第三个参数，`m`，指向存放要改变选项数据的mbuf(图12-16的第二栏)。

1. 构造默认值

665-679 当分配一个新的`ip_moptions`结构时，`ip_setmoptions`把默认的多播接口指针初始化为空，把默认 TTL 初始化为 1(`IP_DEFAULT_MULTICAST_TTL`)，使能多播数据报的回送，并清除组成员表。有了这些默认值后，`ip_output`查询路由表选择一个输出的接口，多播被限制在本地网络中，并且，如果输出的接口是目的多播组的成员，则系统将接收它自己的多播发送。

2. 进程选项

680-860 `ip_setmoptions`体由一个`switch`语句组成，其中对每种选项都有一个`case`语句。`default`情况(对未知选项)把`error`设成`EOPNOTSUPP`。

3. 如果默认值是OK，丢弃结构

861-872 `switch`语句之后，`ip_setmoptions`检查`ip_moptions`结构。如果所有多播选项与它们对应的默认值匹配，就不再需要该结构，将其释放。`ip_setmoptions`返回0或公布的差错码。

12.10.1 选择一个明确的多播接口：`IP_MULTICAST_IF`

当`optname`是`IP_MULTICAST_IF`时，传给`ip_setmoptions`的mbuf中就包含了多播接口的单播地址，该地址指定了在这个插口上发送的多播所使用的特定接口。图 12-20是这个选项的程序。

```
ip_output.c
681     case IP_MULTICAST_IF:
682         /*
683          * Select the interface for outgoing multicast packets.
684          */
685         if (m == NULL || m->m_len != sizeof(struct in_addr)) {
686             error = EINVAL;
687             break;
688         }
689         addr = *(mtod(m, struct in_addr *));
690         /*
691          * INADDR_ANY is used to remove a previous selection.
692          * When no interface is selected, a default one is
693          * chosen every time a multicast packet is sent.
694          */
695         if (addr.s_addr == INADDR_ANY) {
696             imo->imo_multicast_ifp = NULL;
697             break;
698         }
699         /*
700          * The selected interface is identified by its local
701          * IP address. Find the interface and confirm that
702          * it supports multicasting.
703          */
```

图12-20 `ip_setmoptions` 函数：选择多播输出接口

```

704     INADDR_TO_IFP(addr, ifp);
705     if (ifp == NULL || (ifp->if_flags & IFF_MULTICAST) == 0) {
706         error = EADDRNOTAVAIL;
707         break;
708     }
709     imo->imo_multicast_ifp = ifp;
710     break;

```

ip_output.c

图12-20 (续)

1. 验证

681-698 如果没有提供 mbuf，或者 mbuf中的数不是一个 in_addr结构的大小，则 ip_setmoptions通告一个 EINVAL差错；否则把数据复制到 addr。如果接口地址是 INADDR_ANY，则丢弃所有前面选定的接口。对后面用这个 ip_moptions结构的多播，将根据它们的目的多播组进行选路，而不再通过一个明确命名的接口（图12-40）。

2. 选择默认接口

699-710 如果addr中有地址，就由 INADDR_TO_IFP找到匹配接口的位置。如果找不到匹配或接口不支持多播，就发布 EADDRNOTAVAIL。否则，匹配接口 ifp成为与这个 ip_moptions结构相关的输出请求的多播接口。

12.10.2 选择明确的多播TTL：IP_MULTICAST_TTL

当optname是IP_MULTICAST_TTL时，缓存中有一个字节指定输出多播的 IP TTL。这个TTL是ip_output在每个发往相关插口的多播数据报中插入的。图 12-21是该选项的程序。

```

711     case IP_MULTICAST_TTL:
712         /*
713          * Set the IP time-to-live for outgoing multicast packets.
714          */
715         if (m == NULL || m->m_len != 1) {
716             error = EINVAL;
717             break;
718         }
719         imo->imo_multicast_ttl = *(mtod(m, u_char *));
720         break;

```

ip_output.c

图12-21 ip_setmoptions 函数：选择明确的多播TTL

验证和选项默认的TTL

711-720 如果缓存中有一个字节的数据，就把它复制到 imo_multicast_ttl。否则，发布EINVAL。

12.10.3 选择多播环回：IP_MULTICAST_LOOP

通常，多播应用程序有两种形式：

- 一个系统内一个发送方和多个远程接收方的应用程序。这种配置中，只有一个本地进程向多播组发送数据报，所以无需回送输出的多播。这样的例子有多播选路守护进程和会议系统。
- 一个系统内的多个发送方和接收方。必须回送数据报，确保每个进程接收到系统其他发

送方的传送。

IP_MULTICAST_LOOP选项(图12-22)为ip_moptions结构选择回送策略。

```
721     case IP_MULTICAST_LOOP:
722         /*
723          * Set the loopback flag for outgoing multicast packets.
724          * Must be zero or one.
725         */
726         if (m == NULL || m->m_len != 1 ||
727             (loop = *(mtod(m, u_char *))) > 1) {
728             error = EINVAL;
729             break;
730         }
731         imo->imo_multicast_loop = loop;
732         break;
```

ip_output.c

ip_output.c

图12-22 ip_setmoptions 函数：选择多播环回

验证和选择环回策略

721-732 如果m为空，或者没有1字节数据，或者该字节不是0或1，就发布EINVAL。否则，把该字节复制到imo_multicast_loop。0指明不要把数据报回送，1允许环回机制。

图12-23显示了多播数据报的最大管辖域值之间的关系：imo_multicast_ttl和imo_multicast_loop。

imo_multicast-		Recipients			
		Outgoing Interface?	Local Network?	Remote Networks?	Other Interfaces?
_loop	_ttl				
1	0	•			
1	1	•	•		
1	>1	•	•	•	see text

图12-23 环回和TTL对多播管辖域的影响

图12-23显示了根据发送的环回策略，指定的 TTL值接收多播分组的接口的设置。如果硬件接收自己的发送，则不管采用什么环回策略，都接收分组。数据报可能通过选路穿过该网络，并到达与系统相连的其他接口(习题12.6)。如果发送系统本身是一个多播路由器，输出的分组可能被转发到其他接口，但是，只有一个接口接受它们进行输入处理(第14章)。

12.11 加入一个IP多播组

除了内核自动加入(图6-17)的IP所有主机组外，其他组成员是由进程明确发出请求产生的。加入(或离开)多播组选项比其他选项更多使用。必须修改接口的in_multi表以及其他链路层多播结构，如我们在以太网中讨论的ether_multi。

当optname是IP_ADDMEMBERSHIP时，mbuf中的数据是一个如图12-24所示的ip_mreq结构。

```
148 struct ip_mreq {
149     struct in_addr imr_multiaddr; /* IP multicast address of group */
150     struct in_addr imr_interface; /* local IP address of interface */
151 };
```

in.h

in.h

图12-24 ip_mreq 结构

148-151 imr_multiaddr指定多播组，imr_interface用相关的单播IP地址指定接口。ip_mreq结构指定{接口，组}对表示成员的变化。

图12-25显示了加入和离开与我们的以太网接口例子相关的多播组时，所调用的函数。

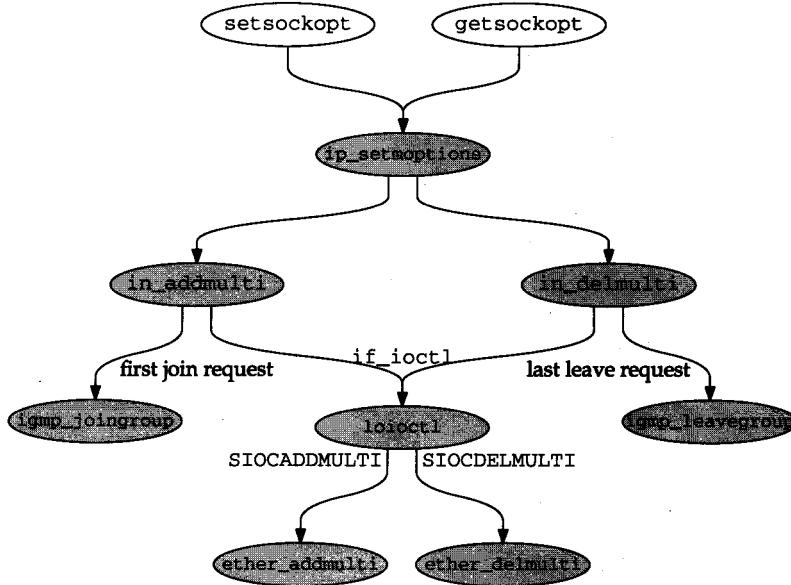


图12-25 加入和离开一个多播组

我们从 ip_setmoptions(图12-26)的IP_ADD_MEMBERSHIP情况开始，在这里修改 ip_moptions结构。然后我们跟踪请求通过IP层、以太网驱动程序，一直到物理设备——在这里，是LANCE以太网网卡。

```

733     case IP_ADD_MEMBERSHIP:
734         /*
735          * Add a multicast group membership.
736          * Group must be a valid IP multicast address.
737          */
738         if (m == NULL || m->m_len != sizeof(struct ip_mreq)) {
739             error = EINVAL;
740             break;
741         }
742         mreq = mtod(m, struct ip_mreq *);
743         if (!IN_MULTICAST(ntohl(mreq->imr_multiaddr.s_addr))) {
744             error = EINVAL;
745             break;
746         }
747         /*
748          * If no interface address was provided, use the interface of
749          * the route to the given multicast address.
750          */
751         if (mreq->imr_interface.s_addr == INADDR_ANY) {
752             ro.ro_rt = NULL;
753             dst = (struct sockaddr_in *) &ro.ro_dst;
754             dst->sin_len = sizeof(*dst);
755             dst->sin_family = AF_INET;
  
```

图12-26 ip_setmoptions 函数：加入一个多播组

```

756         dst->sin_addr = mreq->imr_multiaddr;
757         rtalloc(&ro);
758         if (ro.ro_rt == NULL) {
759             error = EADDRNOTAVAIL;
760             break;
761         }
762         ifp = ro.ro_rt->rt_ifp;
763         rtfree(ro.ro_rt);
764     } else {
765         INADDR_TO_IFP(mreq->imr_interface, ifp);
766     }
767     /*
768      * See if we found an interface, and confirm that it
769      * supports multicast.
770      */
771     if (ifp == NULL || (ifp->if_flags & IFF_MULTICAST) == 0) {
772         error = EADDRNOTAVAIL;
773         break;
774     }
775     /*
776      * See if the membership already exists or if all the
777      * membership slots are full.
778      */
779     for (i = 0; i < imo->imo_num_memberships; ++i) {
780         if (imo->imo_membership[i]->inm_ifp == ifp &&
781             imo->imo_membership[i]->inm_addr.s_addr
782             == mreq->imr_multiaddr.s_addr)
783             break;
784     }
785     if (i < imo->imo_num_memberships) {
786         error = EADDRINUSE;
787         break;
788     }
789     if (i == IP_MAX_MEMBERSHIPS) {
790         error = ETTOOMANYREFS;
791         break;
792     }
793     /*
794      * Everything looks good; add a new record to the multicast
795      * address list for the given interface.
796      */
797     if ((imo->imo_membership[i] =
798         in_addmulti(&mreq->imr_multiaddr, ifp)) == NULL) {
799         error = ENOBUFS;
800         break;
801     }
802     ++imo->imo_num_memberships;
803     break;

```

ip_output.c

图12-26 (续)

1. 验证

733-746 ip_setmoptions从验证该请求开始。如果没有传给 mbuf，或缓存的大小不对，或结构的地址(imr_multiaddr)不是一个多播组地址，则 ip_setmoptions发布ENIVAL。Mreq指向有效 ip_mreq地址。

2. 找到接口

747-774 如果接口的单播地址(imr_interface)是INADDR_ANY，则 ip_setmoptions

必须找到指定组的默认接口。该多播组构造一个 route 结构，作为目的地址，并传给 rtalloc，由 rtalloc 为多播组找到一个路由器。如果没有路由器可用，则请求失败，产生错误 EADDRNOTAVAIL。如果找到路由器，则在 ifp 中保存指向路由器外出接口的指针，而不再需要路由器入口，将其释放。

如果 imr_interface 不是 INADDR_ANY，则请求一个明确的接口。INADDR_TO_IFP 宏用请求的单播地址搜索接口。如果没有找到接口或者它支持多播，则请求失败，产生错误 EADDRNOTAVAIL。

8.5 节描述了 route 结构，19.2 节描述了 rtalloc 函数，第 14 章描述了用路由选择表选择多播接口。

3. 已经是成员了？

775-792 对请求做的最后检查是检查 imo_membership 数组，看看所选接口是否已经是请求组的成员。如果 for 循环找到一个匹配，或者成员数组为空，则发布 EADDRINUSE 或 ETOOMANYREFS，并终止对这个选项的处理。

4. 加入多播组

793-803 此时，请求似乎是合理的了。in_addrmulti 安排 IP 开始接收该组的多播数据报。in_addrmulti 返回的指针指向一个新的或已存在的 in_multi 结构（图 12-12），该结构位于接口的多播组表中。这个结构被保存在成员数组中，并且把数组的大小加 1。

12.11.1 in_addrmulti 函数

in_addrmulti 和相应的 in_delmulti（图 12-27 和图 12-36）维护接口已加入多播组的表。加入请求或者在接口表中增加一个新的 in_multi 结构，或者增加对某个已有结构的引用次数。

```

469 struct in_multi *
470 in_addrmulti(ap, ifp)                                in.c
471 struct in_addr *ap;
472 struct ifnet *ifp;
473 {
474     struct in_multi *inm;
475     struct ifreq ifr;
476     struct in_ifaddr *ia;
477     int      s = splnet();

478     /*
479      * See if address already in list.
480      */
481     IN_LOOKUP_MULTI(*ap, ifp, inm);
482     if (inm != NULL) {
483         /*
484          * Found it; just increment the reference count.
485          */
486         ++inm->inm_refcount;
487     } else {

```

图 12-27 in_addrmulti 函数：前半部分

1. 已经是一个成员了

469-487 ip_setoptions 已经证实 ap 指向一个 D 类多播地址，ifp 指向一个能够多播的

接口。IN_LOOKUP_MULTI(图12-14)确定接口是否已经是该组的一个成员。如果是，则in_addmulti更新引用计数后返回。

如果接口还不是该组的成员，则执行图12-28中的程序。

```

487 } else {
488     /*
489      * New address; allocate a new multicast record
490      * and link it into the interface's multicast list.
491      */
492     inm = (struct in_multi *) malloc(sizeof(*inm),
493                                         M_IPMADDR, M_NOWAIT);
494     if (inm == NULL) {
495         splx(s);
496         return (NULL);
497     }
498     inm->inm_addr = *ap;
499     inm->inm_ifp = ifp;
500     inm->inm_refcount = 1;
501     IFP_TO_IA(ifp, ia);
502     if (ia == NULL) {
503         free(inm, M_IPMADDR);
504         splx(s);
505         return (NULL);
506     }
507     inm->inm_ia = ia;
508     inm->inm_next = ia->ia_multiaddrs;
509     ia->ia_multiaddrs = inm;
510     /*
511      * Ask the network driver to update its multicast reception
512      * filter appropriately for the new address.
513      */
514     ((struct sockaddr_in *) &ifr.ifr_addr)->sin_family = AF_INET;
515     ((struct sockaddr_in *) &ifr.ifr_addr)->sin_addr = *ap;
516     if ((ifp->if_ioctl == NULL) ||
517         (*ifp->if_ioctl) (ifp, SIOCADDMULTI, (caddr_t) & ifr) != 0) {
518         ia->ia_multiaddrs = inm->inm_next;
519         free(inm, M_IPMADDR);
520         splx(s);
521         return (NULL);
522     }
523     /*
524      * Let IGMP know that we have joined a new IP multicast group.
525      */
526     igmp_joingroup(inm);
527 }
528     splx(s);
529     return (inm);
530 }
```

in.c

图12-28 in_addmulti 函数：后半部分

2. 更新in_multi表

487-509 如果接口还不是成员，则in_addmulti分配并初始化一个新的in_multi结构，把该结构插到接口的in_ifaddr(图12-13)结构中ia_multiaddrs表的前端。

3. 更新接口，通告变化

510-530 如果接口驱动程序已经定义了一个if_ioctl函数，则in_addmulti构造一个

包含了该组地址的 `ifreq` 结构(图4-23)，并把 `SIOCADDMULTI` 请求传给接口。如果接口拒绝该请求，则把 `in_multi` 结构从链表中断开，释放掉。最后，`in_addmulti` 调用 `igmp_joingroup`，把成员变化信息传播给其他主机和路由器。

`in_addmulti` 返回一个指针，该指针指向 `in_multi` 结构，或者如果出错，则为空。

12.11.2 slioctl 和 lioctl 函数：SIOCADDMULTI 和 SIOCDELMULTI

SLIP和环回接口的多播组处理很简单：除了检查差错外，不做其他事情。图 12-29显示了 SLIP 处理。

```
673     case SIOCADDMULTI:
674     case SIOCDELMULTI:
675         ifr = (struct ifreq *) data;
676         if (ifr == 0) {
677             error = EAFNOSUPPORT; /* XXX */
678             break;
679         }
680         switch (ifr->ifr_addr.sa_family) {
681             case AF_INET:
682                 break;
683             default:
684                 error = EAFNOSUPPORT;
685                 break;
686             }
687         break;
```

if_sl.c

if_sl.c

图12-29 slioctl 函数：多播处理

673-687 不管请求为空还是不适用于 AF_INET 协议族，都返回 EAFNOSUPPORT。

图12-30显示了环回处理。

```
152     case SIOCADDMULTI:
153     case SIOCDELMULTI:
154         ifr = (struct ifreq *) data;
155         if (ifr == 0) {
156             error = EAFNOSUPPORT; /* XXX */
157             break;
158         }
159         switch (ifr->ifr_addr.sa_family) {
160             case AF_INET:
161                 break;
162             default:
163                 error = EAFNOSUPPORT;
164                 break;
165             }
166         break;
```

if_loop.c

if_loop.c

图12-30 lioctl 函数：多播处理

152-166 环回接口的处理等价于图 12-29 中 SLIP 的程序。不管请求为空还是不适用于 AF_INET 协议族，都返回 EAFNOSUPPORT。

12.11.3 leioctl函数：SIOCADDMULTI和SIOCDELMULTI

在图4-2中，我们讲到LANCE以太网驱动程序的leioctl和if_ioctl函数。图12-31是处理SIOCADDMULTI和SIOCDELMULTI的程序。

```

657     case SIOCADDMULTI:
658     case SIOCDELMULTI:
659         /* Update our multicast list */
660         error = (cmd == SIOCADDMULTI) ?
661             ether_addmulti((struct ifreq *) data, &le->sc_ac) :
662             ether_delmulti((struct ifreq *) data, &le->sc_ac);
663
664         if (error == ENETRESET) {
665             /*
666              * Multicast list has changed; set the hardware
667              * filter accordingly.
668              */
669             lereset(ifp->if_unit);
670             error = 0;
671         }
671     break;

```

if_le.c
if_le.c

图12-31 leioctl 函数：多播处理

657-671 leioctl把增加和删除请求直接传给ether_addmulti或ether_delmulti函数。如果请求改变了该物理硬件必须接收的IP多播地址集，则两个函数都返回ENETRESET。如果发生了这种情况，则leioctl调用lereset，用新的多播接收表重新初始化该硬件。

我们没有显示lereset，因为它是LANCE以太网硬件专用的。对多播来说，lereset安排硬件接收所有寻址到ether_multi中与该接口相关的多播地址的帧。如果多播表中的每个入口是一个地址，则LANCE驱动程序采用散列机制。散列程序使硬件可以有选择地接收分组。如果驱动程序发现某个入口是一个地址范围，它废除散列策略，配置硬件接收所有多播分组。如果驱动程序必须回到接收所有以太网多播地址的状态，lereset就在返回时把IFP_ALLMULTI标志位置位。

12.11.4 ether_addmulti函数

所有以太网驱动程序都调用ether_addmulti函数处理SIOCADDMULTI请求。这个函数把IP D类地址映射到合适的以太网多播地址(图12-5)上，并更新ether_multi表。图12-32是ether_multi函数的前半部。

1. 初始化地址范围

366-399 首先，ether_addmulti初始化addrlo和addrhi(两者都是六个无符号字符)中的多播地址范围。如果所请求的地址来自AF_UNSPEC族，ether_addmulti假定该地址是一个明确的以太网多播地址，并把它复制到addrlo和addrhi中。如果地址属于AF_INET族，并且是INADDR_ANY(0.0.0.0)，ether_addmulti把addrlo初始化成ether_ipmulticast_min，把addrhi初始化成ether_ipmulticast_max。这两个以太网地址常量定义为：

```

u_char ether_ipmulticast_min[6] = { 0x01, 0x00, 0x5e, 0x00, 0x00, 0x00 };
u_char ether_ipmulticast_max[6] = { 0x01, 0x00, 0x5e, 0x7f, 0xff, 0xff };

```

if_ether_subr.c

```

366 int
367 ether_addmulti(ifr, ac)
368 struct ifreq *ifr;
369 struct arpcom *ac;
370 {
371     struct ether_multi *enm;
372     struct sockaddr_in *sin;
373     u_char    addrlo[6];
374     u_char    addrhi[6];
375     int        s = splimp();
376
377     switch (ifr->ifr_addr.sa_family) {
378
379         case AF_UNSPEC:
380             bcopy(ifr->ifr_addr.sa_data, addrlo, 6);
381             bcopy(addrlo, addrhi, 6);
382             break;
383
384         case AF_INET:
385             sin = (struct sockaddr_in *) &(ifr->ifr_addr);
386             if (sin->sin_addr.s_addr == INADDR_ANY) {
387                 /*
388                  * An IP address of INADDR_ANY means listen to all
389                  * of the Ethernet multicast addresses used for IP.
390                  * (This is for the sake of IP multicast routers.)
391                 */
392                 bcopy(ether_ipmulticast_min, addrlo, 6);
393                 bcopy(ether_ipmulticast_max, addrhi, 6);
394             } else {
395                 ETHER_MAP_IP_MULTICAST(&sin->sin_addr, addrlo);
396                 bcopy(addrlo, addrhi, 6);
397             }
398             break;
399
400         default:
401             splx(s);
402             return (EAFNOSUPPORT);
403     }

```

if_ether_subr.c

图12-32 ether_addmulti 函数：前一半

与etherbroadcastaddr(4.3节)一样，这是一个很方便地定义一个48 bit常量的方法。

IP多播路由器必须监听所有IP多播。把组指定为INADDR_ANY，被认为是请求加入所有IP多播组。在这种情况下，所选择的以太网地址范围跨越了分配给IANA的整个IP多播地址块。

当mrouted(8)守护程序开始对到多播接口的分组进行路选时，它用INADDR_ANY发布一个SIOCADDMULTI请求。

ETHER_MAP_IP_MULTICAST把其他特定的IP多播组映射到合适的以太网多播地址。当发生EAFNOSUPPORT错误时，将拒绝对其他地址族的请求。

尽管以太网多播表支持地址范围，但是除了列举出所有地址外，进程或内核无法对某个特定范围提出请求，因为总是把addrlo和addrhi设成同一值。

ether_addmulti的第二部分，显示如图12-33，证实地址范围，并且，如果该地址是

新的，就把它加入表中。

```

400  /*
401   * Verify that we have valid Ethernet multicast addresses.
402   */
403   if ((addrlo[0] & 0x01) != 1 || (addrhi[0] & 0x01) != 1) {
404     splx(s);
405     return (EINVAL);
406   }
407   /*
408   * See if the address range is already in the list.
409   */
410   ETHER_LOOKUP_MULTI(addrlo, addrhi, ac, enm);
411   if (enm != NULL) {
412     /*
413      * Found it; just increment the reference count.
414      */
415     ++enm->enm_refcount;
416     splx(s);
417     return (0);
418   }
419   /*
420   * New address or range; malloc a new multicast record
421   * and link it into the interface's multicast list.
422   */
423   enm = (struct ether_multi *) malloc(sizeof(*enm), M_IFMADDR, M_NOWAIT);
424   if (enm == NULL) {
425     splx(s);
426     return (ENOBUFS);
427   }
428   bcopy(addrlo, enm->enm_addrlo, 6);
429   bcopy(addrhi, enm->enm_addrhi, 6);
430   enm->enm_ac = ac;
431   enm->enm_refcount = 1;
432   enm->enm_next = ac->ac_multiaddrs;
433   ac->ac_multiaddrs = enm;
434   ac->ac_multicnt++;
435   splx(s);
436   /*
437   * Return ENETRESET to inform the driver that the list has changed
438   * and its reception filter should be adjusted accordingly.
439   */
440   return (ENETRESET);
441 }

```

if_ether_subr.c

图12-33 ether_addmulti 函数：后一半

2. 已经在接收

400-418 ether_addmulti 检查高地址和低地址的多播比特位(图4-12)，保证它们是真正的以太网多播地址。ETHER_LOOKUP_MULTI(图12-9)确定硬件是否已经对指定的地址开始监听。如果是，则增加匹配的 ether_multi 结构中的引用计数(enm_refcount)，并且 ether_addmulti 返回0。

3. 更新ether_multi表

419-441 如果这是一个新的地址范围，则分配并初始化一个新的 ether_multi 结构，把它链到接口 arpcom 结构(图12-8)中的 ac_multiaddrs 表上。如果 ether_addmulti 返回

ENETRESET，则调用它的设备驱动程序就知道多播表被改变了，必须更新硬件接收过滤器。

图12-34显示在LANCE以太网接口加入所有主机组后，ip_moptions、in_multi和ether_multi结构之间的关系。

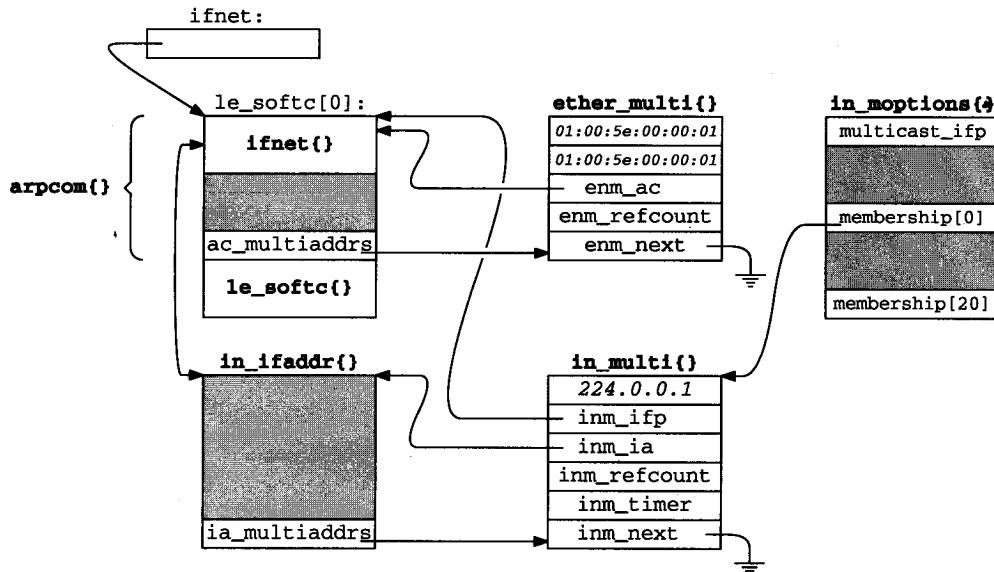


图12-34 多播数据结构的整体图

12.12 离开一个IP多播组

通常情况下，离开一个多播组的步骤是加入一个多播组的步骤的反序。更新ip_moptions结构中的成员表、IP接口的in_multi表和设备的ether_multi表。首先，我们回到ip_setmoptions中的IP_DROP_MEMBERSHIP情况语句，如图12-35所示。

```

804     case IP_DROP_MEMBERSHIP:                                ip_output.c
805         /*
806          * Drop a multicast group membership.
807          * Group must be a valid IP multicast address.
808          */
809         if (m == NULL || m->m_len != sizeof(struct ip_mreq)) {
810             error = EINVAL;
811             break;
812         }
813         mreq = mtod(m, struct ip_mreq *);
814         if (!IN_MULTICAST(ntohl(mreq->imr_multiaddr.s_addr))) {
815             error = EINVAL;
816             break;
817         }
818         /*
819          * If an interface address was specified, get a pointer
820          * to its ifnet structure.
821          */
822         if (mreq->imr_interface.s_addr == INADDR_ANY)
823             ifp = NULL;
824         else {
825             INADDR_TO_IFP(mreq->imr_interface, ifp);

```

图12-35 ip_setmoptions 函数：离开一个多播组

```

826         if (ifp == NULL) {
827             error = EADDRNOTAVAIL;
828             break;
829         }
830     }
831     /*
832      * Find the membership in the membership array.
833      */
834     for (i = 0; i < imo->imo_num_memberships; ++i) {
835         if ((ifp == NULL ||
836             imo->imo_membership[i]->inm_ifp == ifp) &&
837             imo->imo_membership[i]->inm_addr.s_addr ==
838             mreq->imr_multiaddr.s_addr)
839             break;
840     }
841     if (i == imo->imo_num_memberships) {
842         error = EADDRNOTAVAIL;
843         break;
844     }
845     /*
846      * Give up the multicast address record to which the
847      * membership points.
848      */
849     in_delmulti(imo->imo_membership[i]);
850     /*
851      * Remove the gap in the membership array.
852      */
853     for (++i; i < imo->imo_num_memberships; ++i)
854         imo->imo_membership[i - 1] = imo->imo_membership[i];
855     --imo->imo_num_memberships;
856     break;

```

ip_output.c

图12-35 (续)

1. 验证

804-830 存储器缓存中必然包含一个 ip_mreq结构，其中的 imr_multiaddr必须是一个多播组，而且必须有一个接口与单播地址 imr_interface相关。如果这些条件不满足，则发布EINVAL和EADDRNOTAVAIL错误信息，继续到该switch语句的最后进行处理。

2. 删除成员引用

831-856 for循环用请求的{接口，组}对在组成员表中寻找一个 in_multi结构。如果没有找到，则发布EADDRNOTAVAIL错误信息。如果找到了，则 in_delmulti更新in_multi表，并且第二个for循环把成员数组中不用的入口删去，把后面的入口向前移动。数组的大小也被相应更新。

12.12.1 in_delmulti函数

因为可能会有多个进程接收多播数据报，所以调用 in_delmulti(图12-36)的结果是，当对in_multi结构没有引用时，只离开指定的多播组。

更新in_multi结构

534-567 in_delmulti一开始就减少in_multi结构的引用计数，如果该计数非零，则返回。如果该计数减为0，则表明在指定的{接口，组}对上，没有其他进程等待多播数据报。调用igmp_leavegroup，但该函数不做任何事情，我们将在13.8节中看到。

for循环遍历in_multi结构的链表，找到匹配的结构。

```

534 int
535 in_delmulti(inm)
536 struct in_multi *inm;
537 {
538     struct in_multi **p;
539     struct ifreq ifr;
540     int     s = splnet();
541
542     if (--inm->inm_refcount == 0) {
543         /*
544          * No remaining claims to this record; let IGMP know that
545          * we are leaving the multicast group.
546          */
547         igmp_leavegroup(inm);
548         /*
549          * Unlink from list.
550          */
551         for (p = &inm->inm_ia->ia_multiaddrs;
552              *p != inm;
553              p = &(*p)->inm_next)
554             continue;
555         *p = (*p)->inm_next;
556         /*
557          * Notify the network driver to update its multicast reception
558          * filter.
559          */
560         ((struct sockaddr_in *) &(ifr.ifr_addr))->sin_family = AF_INET;
561         ((struct sockaddr_in *) &(ifr.ifr_addr))->sin_addr =
562             inm->inm_addr;
563         (*inm->inm_ifp->if_ioctl) (inm->inm_ifp, SIOCDELMULTI,
564                                     (caddr_t) & ifr);
565         free(inm, M_IPMADDR);
566     }
567     splx(s);
568 }

```

图12-36 in_delmulti 函数

for循环体只包含一个continue语句。但所有工作都由循环上面的表达式做了，不需要continue语句，只是因为它比只有一个分号更清楚一些。

图12-9中的宏ETHER_LOOKUP_MULTI不用continue语句，仅有一个分号几乎是不可检测的。

循环结束后，把匹配的 in_multi 结构从链表上断开，in_delmulti 向接口发布 SIOCDELMULTI 请求，以便更新所有设备专用的数据结构。对以太网接口来说，这意味着更新 ether_multi 表。最后释放 in_multi 结构。

LANCE 驱动程序的 SIOCDELMULTI 情况语句包括在图 12-31 中，这里我们也讨论了 SIOCADDRMULTI 情况。

12.12.2 ether_delmulti 函数

当 IP 释放与某个以太网设备相关的 in_multi 结构时，该设备也可能释放匹配的 ether_multi 结构。我们说“可能”是因为 IP 忽略其他监听 IP 多播的软件。当 ether_

multi结构的引用计数变成0时，就释放该结构。图12-37是ether_delmulti函数。

```

445 int
446 ether_delmulti(ifr, ac)
447 struct ifreq *ifr;
448 struct arpcom *ac;
449 {
450     struct ether_multi *enm;
451     struct ether_multi **p;
452     struct sockaddr_in *sin;
453     u_char    addrlo[6];
454     u_char    addrhi[6];
455     int      s = splimp();
456
457     switch (ifr->ifr_addr.sa_family) {
458
459         case AF_UNSPEC:
460             bcopy(ifr->ifr_addr.sa_data, addrlo, 6);
461             bcopy(addrlo, addrhi, 6);
462             break;
463
464         case AF_INET:
465             sin = (struct sockaddr_in *) &(ifr->ifr_addr);
466             if (sin->sin_addr.s_addr == INADDR_ANY) {
467                 /*
468                  * An IP address of INADDR_ANY means stop listening
469                  * to the range of Ethernet multicast addresses used
470                  * for IP.
471                 */
472                 bcopy(ether_ipmulticast_min, addrlo, 6);
473                 bcopy(ether_ipmulticast_max, addrhi, 6);
474             } else {
475                 ETHER_MAP_IP_MULTICAST(&sin->sin_addr, addrlo);
476                 bcopy(addrlo, addrhi, 6);
477             }
478             break;
479
480         default:
481             splx(s);
482             return (EAFNOSUPPORT);
483     }
484
485     /*
486      * Look up the address in our list.
487      */
488     ETHER_LOOKUP_MULTI(addrlo, addrhi, ac, enm);
489     if (enm == NULL) {
490         splx(s);
491         return (ENXIO);
492     }
493     if (--enm->enm_refcount != 0) {
494         /*
495          * Still some claims to this record.
496          */
497         splx(s);
498         return (0);
499     }
500
501     /*
502      * No remaining claims to this record; unlink and free it.
503      */

```

图12-37 ether_delmulti 函数

```

498     for (p = &enm->enm_ac->ac_multiaddrs;
499         *p != enm;
500         p = &(*p)->enm_next)
501     continue;
502     *p = (*p)->enm_next;
503     free(enm, M_IFMADDR);
504     ac->ac_multicnt--;
505     splx(s);
506     /*
507      * Return ENETRESET to inform the driver that the list has changed
508      * and its reception filter should be adjusted accordingly.
509      */
510     return (ENETRESET);
511 }

```

if_ethersubr.c

图12-37 (续)

445-479 ether_delmulti函数用ether_addrmulti函数采用的同一方法初始化addrlo和addrhi数组。

1. 寻找ether_multi结构

480-494 ETHER_LOOKUP_MULTI寻找匹配的ether_multi结构。如果没有找到，则返回ENXIO。如果找到匹配的结构，则把引用计数减去1。如果此时引用计数非零，ether_delmulti立即返回。在这种情况下，可能会由于其他协议也要接收相同的多播分组而释放该结构。

2. 删除ether_multi结构

495-511 for循环搜索ether_multi表，寻找匹配的地址范围，并从链表中断开匹配的结构，将它释放掉。最后，更新链表的长度，返回ENETRESET，使设备驱动程序可以更新它的硬件接收过滤器。

12.13 ip_getmoptions函数

取得当前的选项设置比设置它们要容易。ip_getmoptions完成所有的工作，如图12-38所示。

复制选项数据和返回

876-914 ip_getmoptions的三个参数是：optname，要取得的选项；imo，ip_moptions结构；mp，一个指向mbuf的指针。m_get分配一个mbuf存放该选项数据。这三个选项的指针(分别是addr、ttl和loop)被初始化为指向mbuf的数据域，而mbuf的长度被设成选项数据的长度。

对IP_MULTICAST_IF，返回IFP_TO_IA发现的单播地址，或者如果没有选择明确的多播接口，则返回INADDR_ANY。

对IP_MULTICAST_TTL，返回imo_multicast_ttl，或者如果没有选择明确的TTL，则返回1(IP_DEFAULT_MULTICAST_TTL)。

对IP_MULTICAST_LOOP，返回imo_multicast_loop，或者如果没有选择明确的多播环回策略，则返回1(IP_DEFAULT_MULTICAST_LOOP)。

最后，如果不识别该选项，则返回EOPNOTSUPP。

```

876 int ip_getmoptions(optname, imo, mp)
877 int optname;
878 struct ip_moptions *imo;
879 struct mbuf **mp;
880
881 {
882     u_char *ttl;
883     u_char *loop;
884     struct in_addr *addr;
885     struct in_ifaddr *ia;
886
887     *mp = m_get(M_WAIT, MT_SOOPTS);
888
889     switch (optname) {
890
891         case IP_MULTICAST_IF:
892             addr = mtod(*mp, struct in_addr *);
893             (*mp)->m_len = sizeof(struct in_addr);
894             if (imo == NULL || imo->imo_multicast_ifp == NULL)
895                 addr->s_addr = INADDR_ANY;
896             else {
897                 IFP_TO_IA(imo->imo_multicast_ifp, ia);
898                 addr->s_addr = (ia == NULL) ? INADDR_ANY
899                               : IA_SIN(ia)->sin_addr.s_addr;
900             }
901             return (0);
902
903         case IP_MULTICAST_TTL:
904             ttl = mtod(*mp, u_char *);
905             (*mp)->m_len = 1;
906             *ttl = (imo == NULL) ? IP_DEFAULT_MULTICAST_TTL
907                   : imo->imo_multicast_ttl;
908             return (0);
909
910         case IP_MULTICAST_LOOP:
911             loop = mtod(*mp, u_char *);
912             (*mp)->m_len = 1;
913             *loop = (imo == NULL) ? IP_DEFAULT_MULTICAST_LOOP
914                   : imo->imo_multicast_loop;
915             return (0);
916
917         default:
918             return (EOPNOTSUPP);
919     }
920 }

```

*ip_output.c*图12-38 *ip_getmoptions* 函数

12.14 多播输入处理：*ipintr*函数

到目前为止，我们已经讨论了多播选路，组成员关系，以及多种与IP和以太网多播有关的数据结构，现在转入讨论对多播数据报的处理。

在图4-13中，我们看到ether_input检测到达的以太网多播分组，在把一个IP分组放到IP输入队列之前(ipintrq)，把mbuf首部的M_MCAST标志位置位。ipintr函数按顺序处理每个分组。我们在ipintr中省略的多播处理程序如图12-39所示。

该段代码来自于ipintr程序，用来确定分组是寻址到本地网络还是应该被转发。此时，已经检测到分组中的错误，并且已经处理完分组的所有选项。ip指向分组内的IP首部。

如果被配置成多播路由器，就转发分组

214-245 如果目的地址不是一个IP多播组，则跳过整个这部分代码。如果地址是一个多播组，并且系统被配置成 IP多播路由器 (*ip_mrouter*)，就把 *ip_id*转换成网络字节序 (*ip_mforward*希望的格式)，并把分组传给 *ip_mforward*。如果出现错误或者分组是通过一个多播隧道(multicast tunnel)到达的，则 *ip_mforward*返回一个非零值。分组被丢弃，且 *ips_cantforward*的值加1。

我们在第14章中描述了多播隧道。它们在两个被标准IP路由器隔开的多播路由器之间传递分组。通过隧道到达的分组必须由 *ip_mforward*处理，而不是由 *ipintr*处理。

如果 *ip_mforward*返回0，则把 *ip_id*转换回主机字节序，由 *ipintr*继续处理分组。

如果 *ip*指向一个IGMP分组，则接受该分组，并在 *ours*处(图10-11的 *ipintr*)继续执行。不管到达接口的每个目的组或组成员是什么，多播路由器必须接受所有 IGMP分组。IGMP分组中有组成员变化的信息。

246-257 根据系统是否被配置成多播路由器来确定是否执行图 12-39中的其余程序。*IN_LOOKUP_MULTI*搜索接口加入的多播组表。如果没有找到匹配，则丢弃该分组。当硬件过滤器接受不需要的分组时，或者当与接口相关的多播组与分组中的目的多播地址映射到同一个以太网地址时，才出现这种情况。

如果接受了该分组，就继续执行 *ipintr*(图10-11)的 *ours*标号处的语句。

```

214     if (IN_MULTICAST(ntohl(ip->ip_dst.s_addr))) {                                ip_input.c
215         struct in_multi *inm;
216         extern struct socket *ip_mrouter;

217         if (ip_mrouter) {
218             /*
219             * If we are acting as a multicast router, all
220             * incoming multicast packets are passed to the
221             * kernel-level multicast forwarding function.
222             * The packet is returned (relatively) intact; if
223             * ip_mforward() returns a non-zero value, the packet
224             * must be discarded, else it may be accepted below.
225             *
226             * (The IP ident field is put in the same byte order
227             * as expected when ip_mforward() is called from
228             * ip_output(..)
229             */
230             ip->ip_id = htons(ip->ip_id);
231             if (ip_mforward(m, m->m_pkthdr.rcvif) != 0) {
232                 ipstat.ips_cantforward++;
233                 m_freem(m);
234                 goto next;
235             }
236             ip->ip_id = ntohs(ip->ip_id);

237             /*
238             * The process-level routing demon needs to receive
239             * all multicast IGMP packets, whether or not this
240             * host belongs to their destination groups.
241             */

```

图12-39 *ipintr* 函数：多播输入处理

```

242         if (ip->ip_p == IPPROTO_IGMP)
243             goto ours;
244         ipstat.ips_forward++;
245     }
246     /*
247      * See if we belong to the destination multicast group on the
248      * arrival interface.
249      */
250     IN_LOOKUP_MULTI(ip->ip_dst, m->m_pkthdr.rcvif, inm);
251     if (inm == NULL) {
252         ipstat.ips_cantforward++;
253         m_free(m);
254         goto next;
255     }
256     goto ours;
257 }

```

ip_input.c

图12-39 (续)

12.15 多播输出处理：*ip_output*函数

当我们在第8章讨论*ip_output*时，推迟了对*ip_output*的mp参数和多播处理程序的讨论。在*ip_output*中，如果mp指向一个*ip_moptions*结构，它就覆盖多播输出处理的默认值。*ip_output*中省略的程序在图12-40和图12-41中显示。*ip*指向输出的分组，*m*指向包含该分组的mbuf，*ifp*指向路由表为多播组选择的接口。

```

129     if (IN_MULTICAST(ntohl(ip->ip_dst.s_addr))) {                               ip_output.c
130         struct in_multi *inm;
131         extern struct ifnet loif;
132
133         m->m_flags |= M_MCAST;
134         /*
135          * IP destination address is multicast. Make sure "dst"
136          * still points to the address in "ro". (It may have been
137          * changed to point to a gateway address, above.)
138          */
139         dst = (struct sockaddr_in *) &ro->ro_dst;
140         /*
141          * See if the caller provided any multicast options
142          */
143         if (imo != NULL) {
144             ip->ip_ttl = imo->imo_multicast_ttl;
145             if (imo->imo_multicast_ifp != NULL)
146                 ifp = imo->imo_multicast_ifp;
147             } else
148                 ip->ip_ttl = IP_DEFAULT_MULTICAST_TTL;
149             /*
150              * Confirm that the outgoing interface supports multicast.
151              */
152             if ((ifp->if_flags & IFF_MULTICAST) == 0) {
153                 ipstat.ips_noroute++;
154                 error = ENETUNREACH;
155                 goto bad;
156             }
157         /*

```

图12-40 *ip_output* 函数：默认和源地址

```

157     * If source address not specified yet, use address
158     * of outgoing interface.
159     */
160     if (ip->ip_src.s_addr == INADDR_ANY) {
161         struct in_ifaddr *ia;
162
163         for (ia = in_ifaddr; ia; ia = ia->ia_next)
164             if (ia->ia_ifp == ifp) {
165                 ip->ip_src = IA_SIN(ia)->sin_addr;
166                 break;
167             }

```

ip_output.c

图12-40 (续)

```

168     IN_LOOKUP_MULTI(ip->ip_dst, ifp, inm);
169     if (inm != NULL &&
170         (imo == NULL || imo->imo_multicast_loop)) {
171         /*
172         * If we belong to the destination multicast group
173         * on the outgoing interface, and the caller did not
174         * forbid loopback, loop back a copy.
175         */
176         ip_mloopback(ifp, m, dst);
177     } else {
178         /*
179         * If we are acting as a multicast router, perform
180         * multicast forwarding as if the packet had just
181         * arrived on the interface to which we are about
182         * to send. The multicast forwarding function
183         * recursively calls this function, using the
184         * IP_FORWARDING flag to prevent infinite recursion.
185         *
186         * Multicasts that are looped back by ip_mloopback(),
187         * above, will be forwarded by the ip_input() routine,
188         * if necessary.
189         */
190         extern struct socket *ip_mrouter;
191         if (ip_mrouter && (flags & IP_FORWARDING) == 0) {
192             if (ip_mforward(m, ifp) != 0) {
193                 m_freem(m);
194                 goto done;
195             }
196         }
197     }
198     /*
199     * Multicasts with a time-to-live of zero may be looped-
200     * back, above, but must not be transmitted on a network.
201     * Also, multicasts addressed to the loopback interface
202     * are not sent -- the above call to ip_mloopback() will
203     * loop back a copy if this host actually belongs to the
204     * destination group on the loopback interface.
205     */
206     if (ip->ip_ttl == 0 || ifp == &loif) {
207         m_freem(m);
208         goto done;
209     }
210     goto sendit;
211 }

```

ip_output.c

图12-41 ip_output 函数：环回、转发和发送

1. 建立默认值

129-155 只有分组是到一个多播组时，才执行图 12-40 中的程序。此时，`ip_output` 把 `mbuf` 中的 `M_MCAST` 置位，并把 `dst` 重设成最终目的地址，因为 `ip_output` 可能曾把它设成下一跳路由器(图8-24)。

如果传递了一个 `ip_moptions` 结构，则相应地改变 `ip_ttl` 和 `ifp`。否则，把 `ip_ttl` 设成 1(`IP_DEFAULT_MULTICAST_TTL`)，避免多播分组到达某个远程网络。查询路由表或 `ip_moptions` 结构所得到的接口必须支持多播。如果不支持，则 `ip_output` 丢弃该分组，并返回 `ENETUNREACH`。

2. 选择源地址

156-167 如果没有指定源地址，则由 `for` 循环找到与输出接口相关的单播地址，并填入 IP 首部的 `ip_src`。

与单播分组不同，如果系统被配置成一个多播路由器，则必须在一个以上的接口上发送输出的多播分组。即使系统不是一个多播路由器，输出的接口也可能是目的多播组的一个成员，也会需要接收该分组。最后，我们需要考虑一下多播环回策略和环回接口本身。把所有这些都考虑进去，共有三个问题：

- 是否要在输出的接口上接收该分组？
- 是否向其他接口转发该分组？
- 是否在出去的接口发送该分组？

图12-41显示了 `ip_output` 中解决这三个问题的程序。

3. 是否环回？

168-176 如果 `IN_LOOKUP_MULTI` 确定输出的接口是目的多播组的成员，而且 `imo_multicast_loop` 非零，则分组被 `ip_mloopback` 放到输出接口上排队，等待输入。在这种情况下，不考虑转发原始分组，因为在输入过程中如果需要，分组的复制会被转发的。

4. 是否转发？

178-197 如果分组不是环回的，但系统被配置成一个多播路由器，并且分组符合转发的条件，则 `ip_mforward` 向其他多播接口分发该分组的备份。如果 `ip_mforward` 没有返回 0，则 `ip_output` 丢弃该分组，不发送它。这表明分组中有错误。

为了避免 `ip_mforward` 和 `ip_output` 之间的无限循环，`ip_mforward` 在调用 `ip_output` 之前，总是把 `IP_FORWARDING` 打开。在本系统上产生的数据报是符合转发条件的，因为运输层不打开 `IF_FORWARDING`。

5. 是否发送？

198-209 TTL 是 0 的分组可能被环回，但从不转发它们 (`ip_mforward` 丢弃它们)，也从不被发送。如果 TTL 是 0 或者如果输出接口是环回接口，则 `ip_output` 丢弃该分组，因为 TTL 超时，或者分组已经被 `ip_mloopback` 环回了。

6. 发送分组

210-211 到这个时候，分组应该已经从物理上在输出接口上被发送了。`sendit(ip_output, 图8-25)` 处的程序在把分组传给接口的 `if_output` 函数之前可能已经把它分片了。我们将在 21.10 节中看到，以太网输出函数 `ether_output` 调用 `arpresolve`，

arpresolve又调用ETHER_MAP_MULTICAST，由ETHER_MAP_MULTICAST根据IP多播目的地址构造一个以太网多播目的地址。

ip_mloopback函数

ip_mloopback依靠looutput(图5-27)完成它的工作。ip_mloopback传递的looutput不是指向环回接口的指针，而是指向输出多播接口的指针。图 12-42显示了ip_mloopback函数。

```

935 static void
936 ip_mloopback(ifp, m, dst)
937 struct ifnet *ifp;
938 struct mbuf *m;
939 struct sockaddr_in *dst;
940 {
941     struct ip *ip;
942     struct mbuf *copym;

943     copym = m_copy(m, 0, M_COPYALL);
944     if (copym != NULL) {
945         /*
946          * We don't bother to fragment if the IP length is greater
947          * than the interface's MTU. Can this possibly matter?
948          */
949         ip = mtod(copym, struct ip *);
950         ip->ip_len = htons((u_short) ip->ip_len);
951         ip->ip_off = htons((u_short) ip->ip_off);
952         ip->ip_sum = 0;
953         ip->ip_sum = in_cksum(copym, ip->ip_hl << 2);
954         (void) looutput(ifp, copym, (struct sockaddr *) dst, NULL);
955     }
956 }
```

ip_output.c

图12-42 ip_mloopback 函数

复制并把分组放到队列中

929-956 仅仅复制分组是不够的；必须看起来分组已经被输出接口接收了，所以ip_mloopback把ip_len和ip_off转换成网络字节序，并计算分组的检验和。looutput把分组放到IP输入队列。

12.16 性能的考虑

Net/3的多播实现有几个潜在的性能瓶颈。因为许多以太网网卡并不能完美地实现对多播地址的过滤，所以操作系统必须能够丢弃那些通过硬件过滤器的分组。在最坏的情况下，以太网网卡可能会接收所有分组，而其中大部分可能会被ipintr发现不具有合法的IP多播组地址。

IP用简单的线性表和线性搜索过滤到达的IP数据报。如果表增长到一定长度后，某些高速缓存技术，如移动最近接收地址到表的最前面，将有助于提高性能。

12.17 小结

本章我们讨论了一个主机如何处理IP多播数据报。我们看到，在IP的D类地址和以太网多

播地址的格式及它们之间的映射关系。

我们讨论了 `in-multi` 和 `ether_multi` 结构，每个 IP 多播接口都维护一个它自己的组成员表，而每个以太网接口都维护一个以太网多播地址。

在输入处理中，只有到达接口是目的多播组的成员时，该 IP 多播才被接受下来。尽管如果系统被配置成多播路由器，它们也可能被继续转发到其他接口。

被配置成多播路由器的系统必须接受所有接口上的所有多播分组。只要为 `INADDR_ANY` 地址发布 `SIOCADDMULTI` 命令，就可以迅速做到这一点。

`ip_moptions` 结构是多播输出处理的基础。它控制对输出接口的选择、多播数据报 TTL 辖域值的设置以及环回策略。它也控制对 `in_multi` 结构的引用计数，从而决定接口加入或离开某个 IP 多播组的时机。

我们也讨论了多播 TTL 值实现的两个概念：分组生存期和分组辖域。

习题

- 12.1 发送IP广播分组到255.255.255.255和发送IP多播给所有主机组224.0.0.1的区别是什么？
- 12.2 为什么用多播代码中的IP单播地址标识接口？如果接口能发送和接收多播地址，但没有一个单播IP地址，必须做什么改动？
- 12.3 在12.3节中，我们讲到32个IP组地址被映射到同一个以太网地址上。因为32 bit地址中的9 bit不在映射中。为什么我们不说512(2^9)个IP组被映射到一个以太网地址上？
- 12.4 你认为为什么把`IP_MAX_MEMBERSHIPS`设成20？能被设得更大一些吗？提示：考虑`ip_moptions`结构(图12-15)的大小。
- 12.5 当一个多播数据报被IP环回并且被发送它的硬件接口接收(即一个非单工接口)时，会发生什么情况？
- 12.6 画一个有一个多接口主机的网络图，即使该主机没有被配置成多播路由器，其他接口也能接收到在某个接口上发送的多播分组。
- 12.7 通过SLIP和环回接口而不是以太网接口跟踪成员增加请求。
- 12.8 进程如何请求内核加入多于`IP_MAX_MEMBERSHIPS`个组？
- 12.9 计算环回分组的检验和是多余的。设计一个方法，避免计算环回分组的检验和。
- 12.10 接口在不重用以太网地址的情况下，最多可加入多少个IP多播组中？
- 12.11 细心的读者可能已经注意到`in_delmulti`在发布`SIOCDELMULTI`请求时，假定接口已经定义了`ioctl`函数。为什么这样不会出错？
- 12.12 如果请求一个未识别的选项，则`ip_getmoptions`中分配的mbuf将会发生什么情况？
- 12.13 为什么把组成员机制与用于接收单播和广播数据报的绑定机制分离开来？

第13章 IGMP : Internet组管理协议

13.1 引言

IGMP在本地网络上的主机和路由器之间传达组成员信息。路由器定时向“所有主机组”多播IGMP查询。主机多播IGMP报告报文以响应查询。IGMP规范在RFC 1112中。卷1的第13章讨论了IGMP的规范，并给出了一些例子。

从体系结构的观点来看，IGMP是位于IP上面的运输层协议。它有一个协议号(2)，它的报文是由IP数据报运载的(与ICMP一样)。与ICMP一样，进程通常不直接访问IGMP，但进程可以通过IGMP插口发送或接收IGMP报文。这个特性使得能够把多播选路守护程序作为用户级进程实现。

图13-1显示了Net/3中IGMP协议的整体结构。

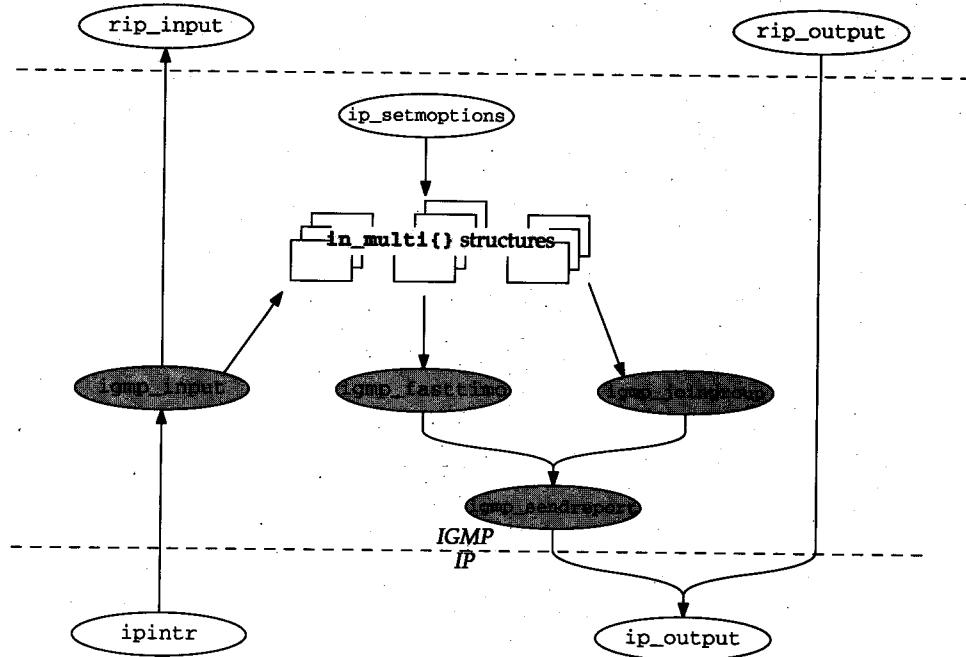


图13-1 IGMP处理概要

IGMP处理的关键是一组在图13-1中心显示的`in_multi`结构。到达的IGMP查询使`igmp_input`为每个`in_multi`结构初始化一个递减定时器。该定时器由`igmp_fasttimo`更新，当每个定时器超时时，`igmp_fasttimo`调用`igmp_sendreport`。

我们在第12章中看到，当创建一个新的`in_multi`结构时，`ip_setoptions`调用`igmp_joingroup`。`igmp_joingroup`调用`igmp_sendreport`来发布新的组成员信息，使组的定时器能够在短时间内安排第二次通告。`igmp_sendreport`完成对IGMP报文的格式

化，并把它传给 ip_output。

在图13-1的左边和右边，我们看到一个原始插口可以直接发送和接收 IGMP报文。

13.2 代码介绍

图13-2中列出了实现IGMP协议的4个文件。

文 件	描 述
netinet/igmp.h	IGMP协议定义
netinet/igmp_var.h	IGMP实现定义
netinet/in_var.h	IP多播数据结构
netinet/igmp.c	IGMP协议实现

图13-2 本章讨论的文件

13.2.1 全局变量

本章中介绍的新的全局变量显示在图 13-3中。

变 量	数 据 类 型	描 述
igmp_all_hosts_group	u_long	网络字节序的“所有主机组”地址
igmp_timer_are_running	int	如果所有IGMP定时器都有效，则为真；否则为假
igmp_stat	struct igmpstat	IGMP统计(图13-4)

图13-3 本章介绍的全局变量

13.2.2 统计量

IGMP统计信息是在图 13-4的 igmpstat 变量中维护的。

Igmpstat成员	描 述
igps_rcv_badqueries	作为无效查询接收的报文数
igps_rcv_badreports	作为无效报告接收的报文数
igps_rcv_badsum	接收的报文检验和错误数
igps_rcv_ourreports	作为逻辑组的报告接收的报文数
igps_rcv_queries	作为成员关系查询接收的报文数
igps_rcv_reports	作为成员关系报告接收的报文数
igps_rcv_tooshort	字节数太少的报文数
igps_rcv_total	接收的全部报文数
igps_snd_reports	作为成员关系报告发送的报文数

图13-4 IGMP统计

图13-5是在vangogh.cs.berkeley.edu上执行 netstat -p igmp命令后，输出的统计信息。

在图13-5中，我们看到 vangogh是连到一个使用 IGMP的网络上的，但是 vangogh没有加入任何多播组，因为 igps_snd_reports是0。

netstat -p igmp 输出	igmpstat 成员
18774 messages received	igps_rcv_total
0 messages received with too few bytes	igps_rcv_tooshort
0 messages received with bad checksum	igps_rcv_badsum
18774 membership queries received	igps_rcv_queries
0 membership queries received with invalid field(s)	igps_rcv_badqueries
0 membership reports received	igps_rcv_reports
0 membership reports received with invalid field(s)	igps_rcv_badreports
0 membership reports received for groups to which we belong	igps_rcv_ourreports
0 membership reports sent	igps_snd_reports

图13-5 IGMP统计示例

13.2.3 SNMP变量

IGMP没有标准的SNMP MIB，但 [McCloghrie Farinacci 1994a]描述了一个IGMP的实验MIB。

13.3 igmp结构

IGMP报文只有8字节长。图13-6显示了Net/3使用的igmp结构。

```
43 struct igmp {
44     u_char    igmp_type;          /* version & type of IGMP message */
45     u_char    igmp_code;         /* unused, should be zero */
46     u_short   igmp_cksum;        /* IP-style checksum */
47     struct in_addr igmp_group;  /* group address being reported */
48 };                                /* (zero for queries) */
```

*igmp.h**igmp.h*

图13-6 igmp结构

igmp_type包括一个4 bit 的版本码和一个4 bit 的类型码。图13-7显示了标准值。

版本	类型	igmp_type	描述
1	1	0x11(IGMP_HOST_MEMBERSHIP_QUERY)	成员关系查询
1	2	0x11 (IGMP_HOST_MEMBERSHIP_REPORT)	成员关系报告
1	3	0x13	DVMRP报文(第14章)

图13-7 IGMP报文类型

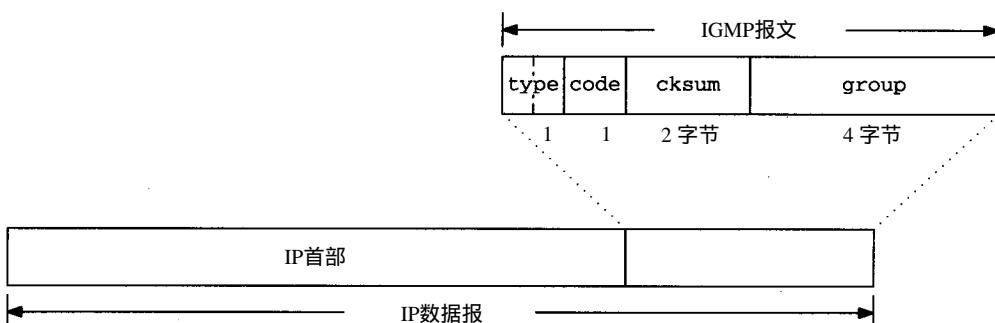


图13-8 IGMP 报文(省略igmp_)

43-44 Net/3只使用版本1的报文。多播路由器发送1类报文(IGMP_HOST_MEMBERSHIP_QUERY)向本地网络上所有主机请求成员关系报告。对1类IGMP报文的响应是主机的一个2类报文(IGMP_HOST_MEMBERSHIP_REPORT)，报告它们的多播成员信息。3类报文在路由器之间传输多播选路信息(第14章)。主机不处理3类报文。本章后面部分只讨论1类和2类报文。

45-46 在IGMP版本1中没有使用igmp_code。igmp_cksum与IP类似，计算IGMP报文的所有8个字节。

47-48 对查询，igmp_group是0。对回答，它包括报告的多播组。

图13-8是相对于IP数据报的IGMP报文结构。

13.4 IGMP的protosw的结构

图13-9是IGMP的protosw结构。

成 员	Inetsw[5]	描 述
pr_type	<i>SOCK_RAW</i>	IGMP提供原始分组服务
pr_domain	<i>&inetdomain</i>	IGMP是Internet域的一部分
pr_protocol	<i>IPPROTO_IGMP (2)</i>	显示在IP首部的 <i>ip_p</i> 字段
pr_flags	<i>PR_ATOMIC / PR_ADDR</i>	插口层标志，协议处理不使用从IP层接收报文
pr_input	<i>igmp_input</i>	向IP层发送IGMP报文
pr_output	<i>rip_output</i>	IGMP没有使用
pr_ctlinput	<i>0</i>	响应来自进程的管理请求
pr_ctloutput	<i>rip_ctloutput</i>	响应来自进程的通信请求
pr_usrreq	<i>rip_usrreq</i>	为IGMP初始化
pr_init	<i>igmp_init</i>	进程挂起成员关系报告
pr_fasttimo	<i>igmp_fasttimo</i>	IGMP没有使用
pr_slowtimo	<i>0</i>	IGMP没有使用
pr_drain	<i>0</i>	IGMP没有使用
pr_sysctl	<i>0</i>	IGMP没有使用

图13-9 IGMP protosw 的结构

尽管进程有可能通过IGMP protosw入口发送原始IP分组，但在本章，我们只考虑内核如何处理IGMP报文。第32章讨论进程如何用原始插口访问IGMP。

三种事件触发IGMP处理：

- 一个本地接口加入一个新的多播组(13.5节)；
- 某个IGMP定时器超时(13.6节)；和
- 收到一个IGMP查询(13.7节)。

还有两种事件也触发本地IGMP处理，但结果不发送任何报文：

- 收到一个IGMP报告(13.7节)；和
- 某个本地接口离开一个多播组(13.8节)。

下一节将讨论这五种事件。

13.5 加入一个组：igmp_joingroup函数

在第12章中我们看到，当一个新的in_multi结构被创建时，in_addmulti调用igmp_joingroup。后面加入同一多播组的请求只增加in_multi结构里的引用计数；不调

用igmp_joininggroup。igmp_joininggroup如图13-10所示。

```

164 void
165 igmp_joininggroup(inm)
166 struct in_multi *inm;
167 {
168     int      s = splnet();
169     if (inm->inm_addr.s_addr == igmp_all_hosts_group ||
170         inm->inm_ifp == &loif)
171         inm->inm_timer = 0;
172     else {
173         igmp_sendreport(inm);
174         inm->inm_timer = IGMP_RANDOM_DELAY(inm->inm_addr);
175         igmp_timers_are_running = 1;
176     }
177     splx(s);
178 }
```

igmp.c

图13-10 igmp_joininggroup 函数

164-178 inm指向组的新in_multi结构。如果新的组是“所有主机组”，或成员关系请求是环回接口的，则inm_timer被禁止，igmp_joininggroup返回。不报告“所有主机组”的成员关系，因为假定每个多播主机都是该组的成员。没必要向环回接口发送组成员报告，因为本地主机是在回路网络上的唯一系统，它已经知道它的成员状态了。

在其他情况下，新组的报告被立即发送，并根据组的情况为组定时器选择一个随机的值。全局标志位igmp_timers_are_running被设置，表明至少使能一个定时器。igmp_fasttimo(13.6节)检查这个变量，避免不必要的处理。

59-73 当新组的定时器超时，就发布第2次成员关系报告。复制报告是无害的，当第一次报告丢失或被破坏时，有了它就保险了。IGMP_RANDOM_DELAY(13-11图)计算报告时延。

```

59 /*
60  * Macro to compute a random timer value between 1 and (IGMP_MAX_REPORTING_
61  * DELAY * countdown frequency). We generate a "random" number by adding
62  * the total number of IP packets received, our primary IP address, and the
63  * multicast address being timed-out. The 4.3 random() routine really
64  * ought to be available in the kernel!
65 */
66 #define IGMP_RANDOM_DELAY(multiaddr) \
67     /* struct in_addr multiaddr; */ \
68     ( (ipstat.ips_total + \
69       ntohs(JA_SIN(in_ifaddr)->sin_addr.s_addr) + \
70       ntohs((multiaddr).s_addr) \
71     ) \
72     % (IGMP_MAX_HOST_REPORT_DELAY * PR_FASTHZ) + 1 \
73   )
```

igmp_var.h

图13-11 IGMP_RANDOM_DELAY 函数

根据RFC 1122，报告定时器必须设成0到10之间的随机秒数(IGMP_MAX_HOST_REPORT_DELAY)。因为IGMP定时器每秒被减去5次(PR_FASTHZ)，所以IGMP_RANDOM_DELAY必须选择一个在1~50之间的随机数。如果r是把接到的所有IP分组数、主机的原始地址和多播组相加后得到的随机数，则

0 (rmod50) 49

且

1 (rmod50)+1 50

要避免为0，因为这会禁止定时器，并且不发送任何报告。

13.6 igmp_fasttimo函数

在讨论igmp_fasttimo之前，我们需要描述一下遍历in_multi结构的机制。

为找到各个in_multi结构，Net/3必须遍历每个接口的in_multi表。在遍历过程中，in_multistep结构(如图13-12所示)记录位置。

```
123 struct in_multistep {
124     struct in_ifaddr *i_ia;
125     struct in_multi *i_inm;
126 };
```

in_var.h

in_var.h

图13-12 in_multistep 函数

123-126 i_ia指向下一个in_ifaddr接口结构，i_inm指向当前接口的in_multi结构。

IN_FIRST_MULTI和IN_NEXT_MULTI宏(显示如图13-13)遍历该表。

```
147 /* 
148  * Macro to step through all of the in_multi records, one at a time.
149  * The current position is remembered in "step", which the caller must
150  * provide. IN_FIRST_MULTI(), below, must be called to initialize "step"
151  * and get the first record. Both macros return a NULL "inm" when there
152  * are no remaining records.
153 */
154 #define IN_NEXT_MULTI(step, inm) \
155     /* struct in_multistep step; */ \
156     /* struct in_multi *inm; */ \
157 { \
158     if (((inm) = (step).i_inm) != NULL) \
159         (step).i_inm = (inm)->inm_next; \
160     else \
161         while ((step).i_ia != NULL) { \
162             (inm) = (step).i_ia->ia_multiaddrs; \
163             (step).i_ia = (step).i_ia->ia_next; \
164             if ((inm) != NULL) { \
165                 (step).i_inm = (inm)->inm_next; \
166                 break; \
167             } \
168         } \
169 }
170 #define IN_FIRST_MULTI(step, inm) \
171     /* struct in_multistep step; */ \
172     /* struct in_multi *inm; */ \
173 { \
174     (step).i_ia = in_ifaddr; \
175     (step).i_inm = NULL; \
176     IN_NEXT_MULTI((step), (inm)); \
177 }
```

in_var.h

图13-13 IN_FIRST_MULTI 和IN_NEXT_MULTI 结构

154-169 如果in_multi表有多个入口，i_inm就前进到下一个入口。当IN_NEXT_MULTI到达多播表的最后时，i_ia就指向下一个接口，i_inm指向与该接口相关的一个in_multi结构。如果该接口没有多播结构，while循环继续遍历整个接口表，直到搜索完所有接口。

170-177 in_multistep数组初始化时，指向in_ifaddr表的第一个in_ifaddr结构，i_inm设成空。IN_NEXT_MULTI找到第一个in_multi结构。

从图13-9我们知道，igmp_fasttimo是IGMP的快速超时函数，每秒被调用5次。igmp_fasttimo(如图13-14)递减多播报告定时器，并在定时器超时时发送一个报告。

```

187 void igmp_fasttimo()
188 {
189     struct in_multi *inm;
190     int s;
191     struct in_multistep step;
192
193     /*
194      * Quick check to see if any work needs to be done, in order
195      * to minimize the overhead of fasttimo processing.
196      */
197     if (!igmp_timers_are_running)
198         return;
199
200     s = splnet();
201     igmp_timers_are_running = 0;
202     IN_FIRST_MULTI(step, inm);
203     while (inm != NULL) {
204         if (inm->inm_timer == 0) {
205             /* do nothing */
206         } else if (--inm->inm_timer == 0) {
207             igmp_sendreport(inm);
208         } else {
209             igmp_timers_are_running = 1;
210         }
211         IN_NEXT_MULTI(step, inm);
212     }
213     splx(s);
214 }
```

igmp.c

图13-14 igmp_fasttimo 结构

187-198 如果igmp_timers_are_running为假，igmp_fasttimo立即返回，不再浪费时间检查各个定时器。

199-213 igmp_fasttimo重新设置运行标志位，用IN_FIRST_MULTI初始化step和inm。igmp_fasttimo函数用while循环找到各个in_multi结构和IN_NEXT_MULTI宏。对每个结构：

- 如果定时器是0，什么都不做。
- 如果定时器不是0，则将其递减。如果到达0，则发送一个IGMP组成员关系报告。
- 如果定时器还不是0，则至少还有一个定时器在运行，所以把igmp_timers_are_running设成1。

igmp_sendreport函数

igmp_sendreport函数(图13-15)为一个多播组构造和发送IGMP报告报文。

```

214 static void
215 igmp_sendreport(inm)
216 struct in_multi *inm;
217 {
218     struct mbuf *m;
219     struct igmp *igmp;
220     struct ip *ip;
221     struct ip_moptions *imo;
222     struct ip_moptions simo;
223
224     MGETHDR(m, M_DONTWAIT, MT_HEADER);
225     if (m == NULL)
226         return;
227     /*
228      * Assume max_linkhdr + sizeof(struct ip) + IGMP_MINLEN
229      * is smaller than mbuf size returned by MGETHDR.
230      */
231     m->m_data += max_linkhdr;
232     m->m_len = sizeof(struct ip) + IGMP_MINLEN;
233     m->m_pkthdr.len = sizeof(struct ip) + IGMP_MINLEN;
234
235     ip = mtod(m, struct ip *);
236     ip->ip_tos = 0;
237     ip->ip_len = sizeof(struct ip) + IGMP_MINLEN;
238     ip->ip_off = 0;
239     ip->ip_p = IPPROTO_IGMP;
240     ip->ip_src.s_addr = INADDR_ANY;
241     ip->ip_dst = inm->inm_addr;
242
243     igmp = (struct igmp *) (ip + 1);
244     igmp->igmp_type = IGMP_HOST_MEMBERSHIP_REPORT;
245     igmp->igmp_code = 0;
246     igmp->igmp_group = inm->inm_addr;
247     igmp->igmp_cksum = 0;
248     igmp->igmp_cksum = in_cksum(m, IGMP_MINLEN);
249
250     imo = &simo;
251     bzero((caddr_t) imo, sizeof(*imo));
252     imo->imo_multicast_ifp = inm->inm_ifp;
253     imo->imo_multicast_ttl = 1;
254
255     /*
256      * Request loopback of the report if we are acting as a multicast
257      * router, so that the process-level routing demon can hear it.
258      */
259     {
260         extern struct socket *ip_mrouter;
261         imo->imo_multicast_loop = (ip_mrouter != NULL);
262     }
263     ip_output(m, NULL, NULL, 0, imo);
264     ++igmpstat.igps_snd_reports;
265 }
```

igmp.c

图13-15 igmp_sendreport 函数

214-232 唯一的参数 inm 指向被报告组的 in_multi 结构。 igmp_sendreport 分配一个
新的 mbuf，准备存放一个 IGMP 报文。 igmp_sendreport 为链路层首部留下空间，把 mbuf

的长度和分组的长度设成IGMP报文的长度。

233-245 每次构造IP首部和IGMP报文的一个字段。数据报的源地址设成INADDR_ANY，目的地址是被报告的多播组。ip_output用输出接口的单播地址替换INADDR_ANY。每个组成员和所有多播路由器都接收报告(因为路由器接收所有IP多播)。

246-260 最后，igmp_sentreport构造一个ip_moptions结构，并把它与报文一起传给ip_output。与in_multi结构相关的接口被选做输出的接口；TTL被设成1，使报告只在本地网络上；如果本地系统被配置成路由器，则允许这个请求的多播环回。

进程级的多播路由器必须监听成员关系报告。在12.14节中我们看到，当系统被配置成多播路由器时，总是接收IGMP数据报。通过普通的运输层分用程序把报文传给IGMP的igmp_input和pr_input函数(图13-9)。

13.7 输入处理：igmp_input函数

在12.14节中，我们描述了ipintr的多播处理部分。我们看到，多播路由器接受所有IGMP报文，但多播主机只接受那些到达接口是目的多播组成员的IGMP报文(也即，那些接收它们的接口是组成员的查询和成员关系报告)。

标准协议分用机制把接受的报文传给igmp_input。igmp_input的开始和结束如图13-16所示。下面几节描述每种IGMP报文类型码。

igmp.c

```

52 void
53 igmp_input(m, iphlen)
54 struct mbuf *m;
55 int     iphlen;
56 {
57     struct igmp *igmp;
58     struct ip *ip;
59     int      igmplen;
60     struct ifnet *ifp = m->m_pkthdr.rcvif;
61     int      minlen;
62     struct in_multi *inm;
63     struct in_ifaddr *ia;
64     struct in_multistep step;

65     ++igmpstat.igps_rcv_total;

66     ip = mtod(m, struct ip *);
67     igmplen = ip->ip_len;

68     /*
69      * Validate lengths
70      */
71     if (igmplen < IGMP_MINLEN) {
72         ++igmpstat.igps_rcv_tooshort;
73         m_free(m);
74         return;
75     }
76     minlen = iphlen + IGMP_MINLEN;
77     if ((m->m_flags & M_EXT || m->m_len < minlen) &&
78         (m = m_pullup(m, minlen)) == 0) {
79         ++igmpstat.igps_rcv_tooshort;
80         return;
81 }
```

图13-16 igmp_input 函数

```

82     /*
83      * Validate checksum
84      */
85     m->m_data += iphlen;
86     m->m_len -= iphlen;
87     igmp = mtod(m, struct igmp *);
88     if (in_cksum(m, igmpplen)) {
89         ++igmpstat.igps_rcv_badsum;
90         m_freem(m);
91         return;
92     }
93     m->m_data -= iphlen;
94     m->m_len += iphlen;
95     ip = mtod(m, struct ip *);
96     switch (igmp->igmp_type) {

157 }
158 /*
159  * Pass all valid IGMP packets up to any process(es) listening
160  * on a raw IGMP socket.
161  */
162 rip_input(m);
163 }

```

igmp.c

图13-16 (续)

1. 验证IGMP报文

52-96 函数ipintr传递一个指向接受分组(存放在一个mbuf中)的指针m，和数据报IP首部的大小iphlen。

数据报的长度必须足够容纳一个IGMP报文(IGMP_MIN_LEN)，并能被放在一个标准的mbuf首部中(m_pullup)，而且还必须有正确的IGMP检验和。如果发现有任何错误，统计错误的个数，并自动丢弃该数据报，igmp_input返回。

igmp_input进程体根据igmp_type内的代码处理无效报文。记得在图13-6中，igmp_type包含一个版本码和一个类型码。switch语句基于igmp_type(图13-7)中两个值的结合。下面几节分别讨论几种情况。

2. 把IGMP报文传给原始IP

157-163 这个switch语句没有default情况。所有有效报文(也就是，格式正确的报文)被传给rip_input，在rip_input里被提交给所有监听IGMP报文的进程。监听进程可以自由处理或丢弃那些具有内核不识别的版本或类型的IGMP报文。

mouted依靠对rip_input的调用接收成员关系查询和报告。

13.7.1 成员关系查询：[IGMP_HOST_MEMBERSHIP_QUERY](#)

RFC 1075推荐多播路由器每120秒至少发布一次IGMP成员关系查询。把查询发到224.0.0.1组(“所有主机组”)。图13-17显示了主机如何处理报文。

97-122 到达环回接口上的查询报文被自动丢弃(习题13.1)。查询报文被定义成发给“所有

主机组”，到达其他地址的查询报文由 `igps_rcv_badqueries` 统计数量，并被丢弃。

```

97     case IGMP_HOST_MEMBERSHIP_QUERY:
98         ++igmpstat.igps_rcv_queries;
99
100        if (ifp == &loif)
101            break;
102
103        if (ip->ip_dst.s_addr != igmp_all_hosts_group) {
104            ++igmpstat.igps_rcv_badqueries;
105            m_freem(m);
106            return;
107        }
108        /*
109         * Start the timers in all of our membership records for
110         * the interface on which the query arrived, except those
111         * that are already running and those that belong to the
112         * "all-hosts" group.
113         */
114        IN_FIRST_MULTI(step, inm);
115        while (inm != NULL) {
116            if (inm->inm_ifp == ifp && inm->inm_timer == 0 &&
117                inm->inm_addr.s_addr != igmp_all_hosts_group) {
118                inm->inm_timer =
119                    IGMP_RANDOM_DELAY(inm->inm_addr);
120                igmp_timers_are_running = 1;
121            }
122            IN_NEXT_MULTI(step, inm);
123        }
124    }

```

igmp.c

图13-17 IGMP查询报文的输入处理

接受查询报文并不会立即引起IGMP成员报告。相反，`igmp_input`为与接收查询的接口相关的各个组定时器设置一个随机的值 `IGMP_RANDOM_DELAY`。当某组的定时器超时，则 `igmp_fasttimo`发送一个成员关系报告，与此同时，其他所有收到查询的主机也进行同一动作。一旦某个主机上的某个特定组的随机定时器超时，就向该组多播一个报告。这个报告将取消其他主机上的定时器，保证只有一个报告在网络上多播。路由器与其他组成员一样，接收该报告。

这个情况的一个例外就是“所有主机组”。这个组不设定时器，也不发送报告。

13.7.2 成员关系报告：IGMP_HOST_MEMBERSHIP_REPORT

接收一个IGMP成员关系报告是我们在 13.1节中提到的不会产生IGMP报文的两种事件之一。该报文的效果限于接收它的接口本地。图 13-18显示了报文处理。

`123-146` 和发送到不正确多播组的成员关系报告一样，发到环回接口上的报告被丢弃。也就是说，报文必须寻址到报文内标识的组。

不完整地初始化的主机的源地址中可能没有网络号或主机号（或两者都没有）。`igmp_report`查看地址的A类网络部分，如果地址的网络或子网部分是0，这部分一定为0。如果是这种情况，则把源地址设成子网地址，其中包含正在接收接口的网络标识符和子网标识符。这样做的唯一原因是为了通知子网号所标识的正在接收接口上的某个进程级守护程序。

如果接收接口属于被报告的组，就把相关的报告定时器重新设成0。从而使发给该组的第一个报告能够制止其他主机发布报告。路由器只需知道网络上至少有一个接口是组的成员，

就无需维护一个明确的组成员表或计数器。

```

123     case IGMP_HOST_MEMBERSHIP_REPORT:
124         ++igmpstat.igps_rcv_reports;
125
126         if (ifp == &loif)
127             break;
128
129         if (!IN_MULTICAST(ntohl(igmp->igmp_group.s_addr)) ||
130             igmp->igmp_group.s_addr != ip->ip_dst.s_addr) {
131             ++igmpstat.igps_rcv_badreports;
132             m_freem(m);
133             return;
134         }
135         /*
136          * KLUDGE: if the IP source address of the report has an
137          * unspecified (i.e., zero) subnet number, as is allowed for
138          * a booting host, replace it with the correct subnet number
139          * so that a process-level multicast routing demon can
140          * determine which subnet it arrived from. This is necessary
141          * to compensate for the lack of any way for a process to
142          * determine the arrival interface of an incoming packet.
143          */
144         if ((ntohl(ip->ip_src.s_addr) & IN_CLASSA_NET) == 0) {
145             IFP_TO_IA(ifp, ia);
146             if (ia)
147                 ip->ip_src.s_addr = htonl(ia->ia_subnet);
148             /*
149              * If we belong to the group being reported, stop
150              * our timer for that group.
151              */
152             IN_LOOKUP_MULTI(igmp->igmp_group, ifp, inm);
153             if (inm != NULL) {
154                 inm->imm_timer = 0;
155                 ++igmpstat.igps_rcv_ourreports;
156             }
157             break;

```

igmp.c

图13-18 IGMP报告报文的输入处理

13.8 离开一个组：igmp_leavegroup函数

我们在12章中看到，当in_multi结构中的引用计数器跳到0时，in_delmulti调用igmp_leavegroup。如图13-19所示。

```

179 void
180 igmp_leavegroup(inm)
181 struct in_multi *inm;
182 {
183     /*
184      * No action required on leaving a group.
185      */
186 }

```

igmp.c

图13-19 igmp_leavegroup 函数

179-186 当一个接口离开一个组时，IGMP没有采取任何动作。不发明确的通知——下一次多播路由器发布IGMP查询时，接口不为该组生成IGMP报告。如果没有为某个组生成报告，则多播路由器就假定所有接口已经离开该组，并停止把到该组的分组在网络上多播。

如果当一个报告被挂起时，接口离开了该组（就是说，此时组的报告定时器正在计时），就不再发送该报告，因为当`icmp_leavegroup`返回时，`in_delmulti`（图12-36）已经把组的定时器及其相关的`in_multi`结构丢掉了。

13.9 小结

本章我们讲述了IGMP，IGMP在一个网络上的主机和路由器之间传递IP多播成员信息。当一个接口加入一个组时，或按照多播路由器发布的IGMP报告查询报文的要求，生成IGMP成员关系报告。

设计IGMP使交换成员信息所需要的报文数最少：

- 当主机加入一个组时，宣布它们的成员关系；
- 对成员关系查询的响应被推迟一个随机的时间，而且第一个响应抑制了其他的响应；
- 当主机离开一个组时，不发通知报文；
- 每分钟发的成员查询不超过一次。

多播路由器与其他路由器共享自己收集的IGMP信息（第14章），以便于把多播数据报传给多播目的组的远程成员。

习题

- 13.1 为什么不需要响应在环回接口上到达的IGMP查询？
- 13.2 验证图13-15中226到229行的假设。
- 13.3 对在点到点网络接口上到达的成员关系查询，是否有必要设置随机的延迟时间？

第14章 IP多播选路

14.1 引言

前面两章讨论了在一个网络上的多播。本章我们讨论在整个互联网上的多播。我们将讨论mrouted程序的执行，该程序计算多播路由表，以及在网络之间转发多播数据报的内核函数。

从技术上说，多播分组(packet)被转发。本章我们假定每个多播分组中都包含一个完整数据报(也就是说，没有分片)，所以我们只用名词数据报(datagram)。Net/3转发IP分片，也转发IP数据报。

图14-1是mrouted的几个版本及它们和BSD版本的对应关系。mrouted版本包括用户级守护程序和内核级多播程序。

mrouted版本	描述
1.2	修改4.3 BSD Tahoe版本
2.0	包括在4.4 BSD和Net/3中
3.3	修改SunOS 4.1.3

IP多播技术是一个活跃的研究和开发领域。本章讨论包括在Net/3中的多播软件的2.0版，但被认为已经过时了。3.3版的发行还有一段时间，因此无法在本书中完整地讨论，但我们在整个过程中将指出3.3版本的一些特点。

因为还没有广泛安装商用多播路由器，所以常用多播隧道连接标准IP单播互联网上的两个多播路由器，构造多播网络。Net/3支持多播隧道，并采用宽松源站记录路由(LSRR，Loose Source Record Route)选项(9.6节)构造多播隧道。一种更好的隧道技术把IP多播数据报封装在一个单播数据报里，3.3版的多播程序支持这一技术，但Net/3不支持。

与第12章一样，我们用通常名称运输层协议代指发送和接收多播数据报的协议，但UDP是唯一支持多播的Internet协议。

14.2 代码介绍

本章讨论的三个文件显示在图14-2中。

文件	描述
netinet/ip_mroute.h	多播结构定义
netinet/ ip_mroute.c	多播选路函数
netinet/raw_ip.c	多播选路选项

图14-2 本章讨论的文件

14.2.1 全局变量

多播选路程序所使用的全局变量显示在图14-3中。

变 量	数 �据 类 型	描 述
cached_mrt	struct mrt	多播选路的“后面一个”高速缓存
cached_origin	u_long	“后面一个”高速缓存的多播组
cached_originmask	u_long	“后面一个”高速缓存的多播组的掩码
mrtstat	struct mrtstat	多播选路统计
mrttable	struct mrt * [指向多播路由器的指针的散列表
numvifs	vifi_t	允许的多播接口数
viftable	struct vif []	虚拟多播接口的数组

图14-3 本章介绍的全局变量

14.2.2 统计量

多播选路程序收集的所有统计信息都放在图 14-4 的 mrtstat 结构中。图 14-5 是在执行 netstat -g 命令后，输出的统计信息。

mrtstat 成员	描 述	SNMP 使用的
mrts_mrt_lookups	查找的多播路由数	
mrts_mrt_misses	高速缓存丢失的多播路由数	
mrts_grp_lookups	查找的组地址数	
mrts_grp_misses	高速缓存丢失的组地址数	
mrts_no_route	查找失败的多播路由数	
mrts_bad_tunnel	有错误的隧道选项的分组数	
mrts_cant_tunnel	没有空间存放隧道选项的分组数	

图14-4 本章收集的统计量

netstat -gs 输出	mrtstat 成员
<pre>multicast routing: 329569328 multicast route lookups 9377023 multicast route cache misses 242754062 group address lookups 159317788 group address cache misses 65648 datagrams with no route for origin 0 datagrams with malformed tunnel options 0 datagrams with no room for tunnel options</pre>	mrts_mrt_lookups mrts_mrt_misses mrts_grp_lookups mrts_grp_misses mrts_no_route mrts_bad_tunnel mrts_cant_tunnel

图14-5 IP多播路由选择统计的例子

这些统计信息来自一个有两个物理接口和一个隧道接口的系统。它们说明，98%的时间，在高速缓存中发现多播路由。组地址高速缓存的效率稍低一些，最高只有 34%。图 14-34 描述了路由缓存，图 14-21 描述了组地址高速缓存。

14.2.3 SNMP 变量

多播选路没有标准的 SNMP MIB，但 [McCloghrie 和 Farinacci 1994a] 和 [McCloghrie 和 Farinacci 1994b] 描述一些多播路由器的实验 MIB。

14.3 多播输出处理(续)

12.15 节讲到如何为输出的多播数据报选择接口。我们看到在 ip_moptions 结构中

`ip_output`被传给一个明确的接口，或者`ip_output`在路由表中查找目的组，并使用在路由入口中返回的接口。

如果在选择了输出的接口后，`ip_output`回送该数据报，就把它放在所选输出接口等待输入处理，当`ipintr`处理它时，把它当作是要转发的数据报。图14-6显示了这个过程。

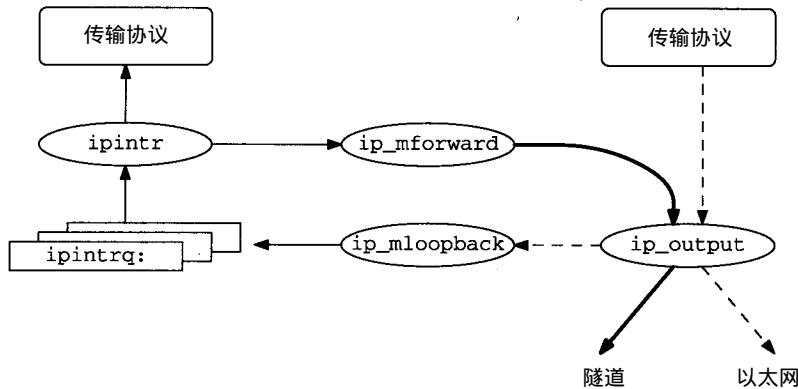


图14-6 有环回的多播输出处理

在图14-6中，虚线箭头代表原始输出的数据报，本例是本地以太网上的多播。`ip_mloopback`创建的备份由带箭头的细线表示；并作为输入被传给运输层协议。当`ip_mforward`决定通过系统上的另一个接口转发该数据报时，就产生第三个备份。图14-6中最粗的箭头代表第三个备份，在多播隧道上发送。

如果数据报不是回送的，则`ip_output`把它直接传给`ip_mforward`，`ip_mforward`复制并处理该数据报，就像它是从`ip_output`选定的接口上收到的一样。图14-7显示了这个过程。

一旦`ip_mforward`调用`ip_output`发送多播数据报，它就把`IP_FORWARDING`置位，这样，`ip_output`就不再把数据报传回给`ip_mforward`，以免导致无限循环。

图12-42显示了`ip_mloopback`。14.8节描述了`ip_mforward`。

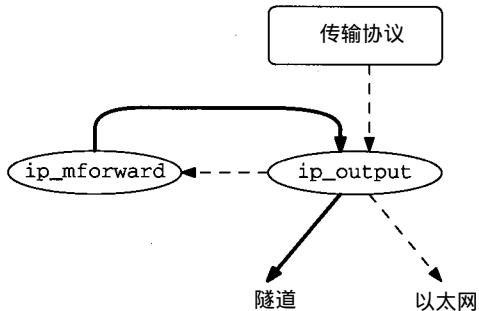


图14-7 没有环回的多播输出处理

14.4 mrouted守护程序

用户级进程`mrouted`守护程序允许和管理多播路由选择。`mrouted`实现IGMP协议的路由部分，并与其他多播路由器通信，实现网络间的多播路由选择。路由算法在`mrouted`上实现，但内核维护多播路由选择表，并转发数据报。

本书中我们只讨论支持`mrouted`的内核数据结构和函数——不讨论`mrouted`本身。我们讨论用于为数据报选择路由的截断逆向路径广播TRPB(Truncated Reverse Path Broadcast)算法[Deering和Cheriton 1990]，以及用于在多播路由器之间传递信息的距离向量多播选路协议DVMRP。我们力求使读者了解内核多播程序的工作原理。

RFC 1075 [Waitzman、Partidge 和 Deering 1988] 是DVMRP的一个老版本。mrouted实现了一个新的 DVMRP，还没有用 RFC 文档写出来。目前，该算法和协议的最好的文档是 mrouted发布的源代码。附录 B指出在哪里能找到源代码。

mrouted守护程序通过在一个IGMP插口上设置选项与内核通信(第32章)。这些选项总结在图14-8中。

optname	optval类型	函数	描述
DVMRP_INIT		ip_mrouted_init	mrouted开始
DVMRP_DONE		ip_mrouted_done	mrouted被关闭
DVMRP_ADD_VIF	struct vifctl	add_vif	增加虚拟接口
DVMRP_DEL_VIF	vifi_t	del_vif	删除虚拟接口
DVMRP_ADD_LGRP	struct lgrpctl	add_lgrp	为某个接口增加多播组入口
DVMRP_DEL_LGRP	struct lgrpctl	del_lgrp	为某个接口删除多播组入口
DVMRP_ADD_MRT	struct mrtctl	add_mrt	增加多播路由
DVMRP_DEL_MRT	struct in_addr	del_mrt	删除多播路由

图14-8 多播路由插口选项

图14-8显示的插口选项被setsockopt系统调用传给rip_ctloutput(32.8节)。图14-9显示了处理DVMRP_xxx选项的rip_ctloutput部分。

```
173     case DVMRP_INIT:
174     case DVMRP_DONE:
175     case DVMRP_ADD_VIF:
176     case DVMRP_DEL_VIF:
177     case DVMRP_ADD_LGRP:
178     case DVMRP_DEL_LGRP:
179     case DVMRP_ADD_MRT:
180     case DVMRP_DEL_MRT:
181         if (op == PRCO_SETOPT) {
182             error = ip_mrouted_cmd(optname, so, *m);
183             if (*m)
184                 (void) m_free(*m);
185         } else
186             error = EINVAL;
187     return (error);
```

raw_ip.c

raw_ip.c

图14-9 rip_ctloutput 函数：DVMRP_xxx 插口选项

173-187 当调用setsockopt时，op等于PRCO_SETOPT，而且所有选项都被传给ip_mrouted_cmd函数。对于getsockopt系统调用，op等于PRCO_GETOPT；对所有选项都返回EINVAL。

图14-10显示了ip_mrouted_cmd函数。

```
84 int
85 ip_mrouted_cmd(cmd, so, m)
86 int      cmd;
87 struct socket *so;
88 struct mbuf *m;
89 {
90     int      error = 0;
```

ip_mroute.c

图14-10 ip_mrouted_cmd 函数

```

91     if (cmd != DVMRP_INIT && so != ip_mrouter)
92         error = EACCES;
93     else
94         switch (cmd) {
95
95         case DVMRP_INIT:
96             error = ip_mrouter_init(so);
97             break;
98
99         case DVMRP_DONE:
100            error = ip_mrouter_done();
101            break;
102
103         case DVMRP_ADD_VIF:
104             if (m == NULL || m->m_len < sizeof(struct vifctl))
105                 error = EINVAL;
106             else
107                 error = add_vif(mtod(m, struct vifctl *));
108             break;
109
110         case DVMRP_DEL_VIF:
111             if (m == NULL || m->m_len < sizeof(short))
112                 error = EINVAL;
113             else
114                 error = del_vif(mtod(m, vifi_t *));
115             break;
116
117         case DVMRP_ADD_LGRP:
118             if (m == NULL || m->m_len < sizeof(struct lgrpctl))
119                 error = EINVAL;
120             else
121                 error = add_lgrp(mtod(m, struct lgrpctl *));
122             break;
123
124         case DVMRP_DEL_LGRP:
125             if (m == NULL || m->m_len < sizeof(struct lgrpctl))
126                 error = EINVAL;
127             else
128                 error = del_lgrp(mtod(m, struct lgrpctl *));
129             break;
130
131         case DVMRP_ADD_MRT:
132             if (m == NULL || m->m_len < sizeof(struct mrtctl))
133                 error = EINVAL;
134             else
135                 error = add_mrt(mtod(m, struct mrtctl *));
136             break;
137
138         case DVMRP_DEL_MRT:
139             if (m == NULL || m->m_len < sizeof(struct in_addr))
140                 error = EINVAL;
141             else
142                 error = del_mrt(mtod(m, struct in_addr *));
143             break;
144
145         default:
146             error = EOPNOTSUPP;
147             break;
148     }
149
150     return (error);
151 }
152 }
```

ip_mroute.c

图14-10 (续)

这些“选项”更像命令，因为它们引起内核更新多个数据结构。本章后面我们将使用命令(command)一词强调这个事实。

84-92 mouted发布的第一个命令必须是 DVMRP_INIT。后续命令必须来自发布DVMRP_INIT的同一插口。当在其他插口上发布其他命令时，返回 EACCES。

94-142 switch语句的每个case语句检查每条命令中的数据量是否正确，然后调用匹配函数。如果不能识别该命令，则返回 EOPNOTSUPP。任何从匹配函数返回的错误都在 error 中发布，并在函数的最后返回。

初始化时，mouted发布DVMRP_INIT命令，调用图14-11显示的ip_mrouter_init。

```
ip_mrouted.c
146 static int
147 ip_mrouted_init(so)
148 struct socket *so;
149 {
150     if (so->so_type != SOCK_RAW || 
151         so->so_proto->pr_protocol != IPPROTO_IGMP)
152         return (EOPNOTSUPP);
153 
154     if (ip_mrouted != NULL)
155         return (EADDRINUSE);
156 
157 }
```

ip_mrouted.c

图14-11 ip_mrouted_init 函数：DVMRP_INIT 命令

146-157 如果不是在某个原始IGMP插口上发布命令，或者如果 DVMRP_INIT已经被置位，则分别返回 EOPNOTSUPP 和 EADDRINUSE。全局变量 ip_mrouted 保存指向某个插口的指针，初始化命令就是在该插口上发布的。必须在该插口上发布后续命令。以避免多个 mouted 进程的并行操作。

下面几节讨论其他 DVMRP_xxx 命令。

14.5 虚拟接口

当作为多播路由器运行时，Net/3接收到达的多播数据报，复制它们，并在一个或多个接口上转发备份。通过这种方式，数据报被转发给互联网上的其他多播路由器。

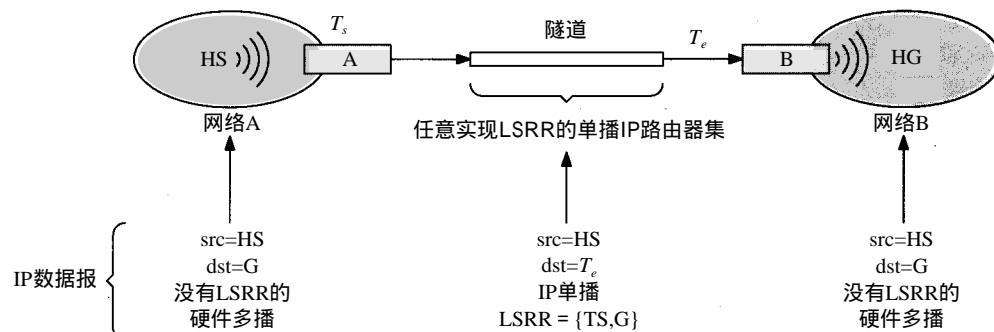


图14-12 多播隧道

输出的接口可以是一个物理接口，也可以是一个多播隧道。多播隧道的两端都与一个多播路由器上的某个物理接口相关。多播隧道使两个多播路由器，即使被不能转发多播数据报的路由器分隔，也能够交换多播数据报。图 14-12 是一个多播隧道连接的两个多播路由器。

图 14-12 中，网络 A 上的源主机 HS 正在向组 G 多播数据报。组 G 的唯一成员在网络 B 上，并通过一个多播隧道连接到网络 A。路由器 A 接收多播（因为多播路由器接收所有多播），查询它的多播路由选择表，并通过多播隧道转发该数据报。

隧道的开始是路由器 A 上的一个物理接口，以 IP 单播地址 T_s 标识。隧道的结束是网络 B 上的一个物理接口，以 IP 单播地址 T_e 标识。隧道本身是一个任意复杂的网络，由实现 LSRR 选项的 IP 单播路由器连接起来。图 14-13 显示 IP LSRR 选项如何实现多播隧道。

系统	IP首部		源路由选项		描述
	ip_src	ip_dst	偏移	地 址	
HS	HS	G			在网络 A 上
T_s	HS	T_e	8	$T_s \bullet G$	在隧道上
T_e	HS	G	12	T_s 见正文	在路由器 B 上 ip_dooptions 之后
T_e	HS	G			在路由器 B 上 ip_mforward 之后

图 14-13 LSRR 多播隧道选项

图 14-13 的第一行是 HS 在网络 A 上发送的多播数据报。路由器 A 全部接收，因为多播路由器接收本地连接的网络上的所有数据报。

为通过隧道发送数据报，路由器 A 在 IP 首部插入一个 LSRR 选项。第二行是在隧道上离开 A 时的数据报。LSRR 选项的第一个地址是隧道的源地址，第二个地址是目的多播组地址。数据报的目的地址是 T_e ——隧道的另一端。LSRR 偏移指向目的组。

经过隧道的数据报被转发，通过互联网，直到它到达路由器 B 上的隧道的另一端。

该图中的第三行是被路由器 B 上的 ip_dooptions 处理之后的数据报。记得第 9 章中讲到，ip_dooptions 在 ipintr 检查数据报的目的地址之前处理 LSRR 选项。因为数据报的目的地址 (T_e) 和路由器 B 上的一个接口匹配，所以 ip_dooptions 把由选项偏移（本例中是 G）标识的地址复制到 IP 首部的目的地址字段。在选项内，G 被 ip_rtaddr 返回的地址取代，ip_rtaddr 通常根据 IP 目的地址（本例中是 G）为数据报选择输出的接口。这个地址是不相关的，因为 ip_mforward 将丢弃整个选项。最后，ip_dooptions 把选项偏移向前移动。

图 14-13 的第四行是 ipintr 调用 ip_mforward 之后的数据报。在那里，LSRR 选项被识别，并从数据报首部中移走。得到的数据报看起来就象原始多播数据报，由 ip_mforward 处理它，把它作为多播数据报在网络 B 上转发，并被 HG 收到。

用 LSRR 构造的多播隧道已经过时了。因为 1993 年 3 月发布了 mrouted 程序，该程序通过在 IP 多播数据报的首部前面加上另一个 IP 首部来构造隧道。新 IP 首部的协议设置为 4，表明分组的内容是另一个 IP 分组。有关这个值的文档在 RFC 1700——“IP 中的 IP”协议中。新版本的 mrouted 程序为了向后兼容，也支持 LSRR 隧道。

14.5.1 虚拟接口表

无论物理接口还是隧道接口，内核都为其在虚拟接口（virtual interface）表中维护一个入口，其中包含了只有多播使用的信息。每个虚拟接口都用一个 vif 结构表示（图 14-14）。全局变量

viftable是一个这种结构的数组。数组的下标保存在无符号短整数 vifi_t 变量中。

```

105 struct vif {
106     u_char v_flags;           /* VIFF_ flags */
107     u_char v_threshold;      /* min ttl required to forward on vif */
108     struct in_addr v_lcl_addr; /* local interface address */
109     struct in_addr v_rmt_addr; /* remote address (tunnels only) */
110     struct ifnet *v_ifp;      /* pointer to interface */
111     struct in_addr *v_lcl_grps; /* list of local grps (phyints only) */
112     int v_lcl_grps_max;      /* malloc'ed number of v_lcl_grps */
113     int v_lcl_grps_n;        /* used number of v_lcl_grps */
114     u_long v_cached_group;   /* last grp looked-up (phyints only) */
115     int v_cached_result;     /* last look-up result (phyints only) */
116 };

```

ip_mroute.h

图14-14 vif 结构

105-110 为 `v_flags` 定义的唯一的标志位是 `VIFF_TUNNEL`。被置位时，该接口是一个到远程多播路由器的隧道。没有置位时，接口是在本地系统上的一个物理接口。`v_threshold` 是我们在 12.9 节描述的多播阈值。`v_lcl_addr` 是与这个虚拟接口相关的本地接口的 IP 地址。`v_rmt_addr` 是一个 IP 多播隧道远端的单播 IP 地址。`v_lcl_addr` 或者 `v_rmt_addr` 为非零，但不会两者都为非零。对物理接口，`v_ifp` 非空，并指向本地接口的 `ifnet` 结构。对隧道，`v_ifp` 是空的。

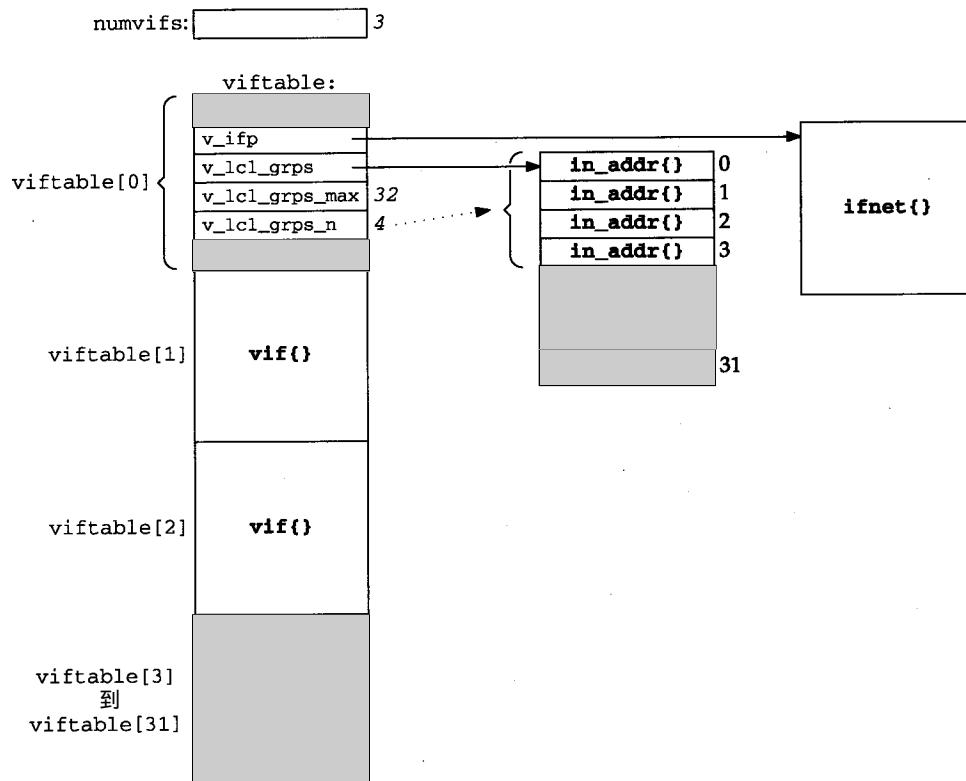


图14-15 viftable 数组

111-116 v_lcl_grps指向一个IP多播组地址数组，这个数组记录了在连到的接口上的成员组列表。对隧道来说，v_lcl_grps总是空的。数组的大小保存在v_lcl_grps_max中，被使用的入口数保存在v_lcl_grps_n中。数组随着组成员关系表的增长而增长。v_cached_group和v_cached_result实现“一个入口”高速缓存，其中记录的是最近一次查找得到的组。

图14-15说明了viftable，它最多有32个(MAXVIFS)入口。viftable[2]是正在使用的最后一个入口，所以numvifs是3。编译内核时固定了表的大小。图中还显示了表的第一个入口的vif结构的几个成员。v_ifp指向一个ifnet结构，v_lcl_grps指向in_addr结构中的一个数组。数组有32(v_lcl_grps_max)个入口，其中只用了4个(v_lcl_grps_n)。

mrouted通过DVMRP_ADD_VIF和DVMRP_DEL_VIF命令维护viftable。通常，当mrouted开始运行时，会把本地系统上有多播能力的接口加入表中。当mrouted阅读自己的配置文件，通常是/etc/mrouted.conf时，会把多播隧道加入表中。这个文件中的命令也可能从虚拟接口表中删除物理接口，或者改变与接口有关的多播信息。

mrouted用DVMRP_ADD_VIF命令把ctl结构(图14-16)传给内核。它指示内核在虚拟接口表中加入一个接口项。

```

76 struct vifctl {
77     vifi_t vifc_vifi;           /* the index of the vif to be added */
78     u_char vifc_flags;          /* VIFF_ flags (Figure 14.14) */
79     u_char vifc_threshold;      /* min ttl required to forward on vif */
80     struct in_addr vifc_lcl_addr; /* local interface address */
81     struct in_addr vifc_rmt_addr; /* remote address (tunnels only) */
82 };

```

图14-16 vifctl 结构

78-82 vifc_vifi识别viftable中虚拟接口的下标。其他4个成员，vifc_flags、vifc_threshold、vifc_lcl_addr和vifc_rmt_addr，被add_vif函数复制到vif函数中。

14.5.2 add_vif函数

图14-17是add_vif函数。

```

202 static int
203 add_vif(vifcp)
204 struct vifctl *vifcp;
205 {
206     struct vif *vifp = viftable + vifcp->vifc_vifi;
207     struct ifaddr *ifa;
208     struct ifnet *ifp;
209     struct ifreq ifr;
210     int     error, s;
211     static struct sockaddr_in sin =
212         {sizeof(sin), AF_INET};

213     if (vifcp->vifc_vifi >= MAXVIFS)
214         return (EINVAL);
215     if (vifp->v_lcl_addr.s_addr != 0)
216         return (EADDRINUSE);

```

图14-17 add_vif 函数：DVMRP_ADD_VIF 命令

```

217     /* Find the interface with an address in AF_INET family */
218     sin.sin_addr = vifcp->vifc_lcl_addr;
219     ifa = ifa_ifwithaddr((struct sockaddr *) &sin);
220     if (ifa == 0)
221         return (EADDRNOTAVAIL);
222
223     s = splnet();
224
225     if (vifcp->vifc_flags & VIFF_TUNNEL)
226         vifp->v_rmt_addr = vifcp->vifc_rmt_addr;
227     else {
228         /* Make sure the interface supports multicast */
229         ifp = ifa->ifa_ifp;
230         if ((ifp->if_flags & IFF_MULTICAST) == 0) {
231             splx(s);
232             return (EOPNOTSUPP);
233         }
234         /*
235          * Enable promiscuous reception of all IP multicasts
236          * from the interface.
237         */
238         satosin(&ifr.ifr_addr)->sin_family = AF_INET;
239         satosin(&ifr.ifr_addr)->sin_addr.s_addr = INADDR_ANY;
240         error = (*ifp->if_ioctl) (ifp, SIOCADDMULTI, (caddr_t) &ifr);
241         if (error) {
242             splx(s);
243             return (error);
244         }
245         vifp->v_flags = vifcp->vifc_flags;
246         vifp->v_threshold = vifcp->vifc_threshold;
247         vifp->v_lcl_addr = vifcp->vifc_lcl_addr;
248         vifp->v_ifp = ifa->ifa_ifp;
249
250         /* Adjust numvifs up if the wifi is higher than numvifs */
251         if (numvifs <= vifcp->vifc_wifi)
252             numvifs = vifcp->vifc_wifi + 1;
253     }

```

ip_mroute.c

图14-17 (续)

1. 验证下标

202-216 如果mrouted指定的vifc_wifi中的下标太大，或者该表入口已经被使用，则分别返回EINVAL或EADDRINUSE。

2. 本地物理接口

217-221 ifa_ifwithaddr取得vifc_lcl_addr中的单播IP地址，并返回一个指向相关ifnet结构的指针。这就标识出这个虚拟接口要用的物理接口。如果没有匹配的接口，返回EADDRNOTAVAIL。

3. 配置隧道接口

222-224 对于隧道，它的远端地址被从vifctl结构中复制到接口表的vif结构中。

4. 配置物理接口

225-243 对于物理接口，链路级驱动程序必须支持多播。SIOCADDMULTI命令与

INADDR_ANY一起配置接口，开始接收所有IP多播数据报(图12-32)，因为它是一个多播路由器。当ipintr把到达数据报传给ip_mforward时，被ip_mforward转发。

5. 保存多播信息

244-253 其他接口信息被从vifctl结构复制到vif结构。如果需要，更新numvifs，记录正在使用的虚拟接口数。

14.5.3 del_vif函数

图14-18显示的del_vif函数从虚拟接口表中删除表项。当mrouted设置DVMRP_DEL_VIF命令时，调用该函数。

1. 验证下标

257-268 如果传给del_vif的下标大于正在使用的最大下标，或者指向一个没有使用的入口，则分别返回EINVAL和EADDRNOTAVAIL。

```

257 static int
258 del_vif(vifip)
259 vifi_t *vifip;
260 {
261     struct vif *vifp = viftable + *vifip;
262     struct ifnet *ifp;
263     int i, s;
264     struct ifreq ifr;

265     if (*vifip >= numvifs)
266         return (EINVAL);
267     if (vifp->v_lcl_addr.s_addr == 0)
268         return (EADDRNOTAVAIL);

269     s = splnet();

270     if (!(vifp->v_flags & VIFF_TUNNEL)) {
271         if (vifp->v_lcl_grps)
272             free(vifp->v_lcl_grps, M_MRTABLE);
273         satosin(&ifr.ifr_addr)->sin_family = AF_INET;
274         satosin(&ifr.ifr_addr)->sin_addr.s_addr = INADDR_ANY;
275         ifp = vifp->v_ifp;
276         (*ifp->if_ioctl) (ifp, SIOCDELMULTI, (caddr_t) & ifr);
277     }
278     bzero((caddr_t) vifp, sizeof(*vifp));

279     /* Adjust numvifs down */
280     for (i = numvifs - 1; i >= 0; i--)
281         if (viftable[i].v_lcl_addr.s_addr != 0)
282             break;
283     numvifs = i + 1;

284     splx(s);
285     return (0);
286 }
```

ip_mroute.c

图14-18 del_vif 函数：DVMRP_DEL_VIF 命令

2. 删除接口

269-278 对于物理接口，释放本地多播组表，SIOCADDMULTI禁止接收所有多播数据报，bzero对viftable的入口清零。

3. 调整接口计数

279-286 for循环从以前活动的最大入口开始向后直到第一个入口为止，搜索出第一个活动的入口。对没有使用的入口，v_lcl_addr(一个in_addr结构)的成员s_addr是0。相应地更新numvifs，函数返回。

14.6 IGMP(续)

第13章侧重于IGMP协议的主机部分，mrouted实现了这个协议的路由器部分。mrouted必须为每个物理接口记录哪个多播组有成员在连到的网络上。mrouted每120秒多播一个IGMP_HOST_MEMBERSHIP_QUERY数据报，并把IGMP_HOST_MEMBERSHIP_REPORT的结果汇编到与每个网络相关的成员关系数组中。这个数组不是我们在第13章讲的成员关系表。

mrouted根据收集到的信息构造多播路由选择表。多播组表也提供信息，用来抑制向没有目的组成员的多播互联网区进行多播。

只为物理接口维护这样的成员关系数组。对其他多播路由器来说，隧道是点到点接口，所以无需组成员关系信息。

我们在图14-14中看到，v_lcl_grps指向一个IP多播组数组。mrouted用DVMRP_ADD_LGRP和DVMRP_DEL_LGRP命令维护这个表。两个命令都带了一个lgrpctl结构(图14-19)。

```
87 struct lgrpctl {                                ip_mroute.h
88     vifi_t lgc_vifi;
89     struct in_addr lgc_gaddr;
90 };
```

```
                                ip_mroute.h
-----
```

图14-19 lgrpctl 结构

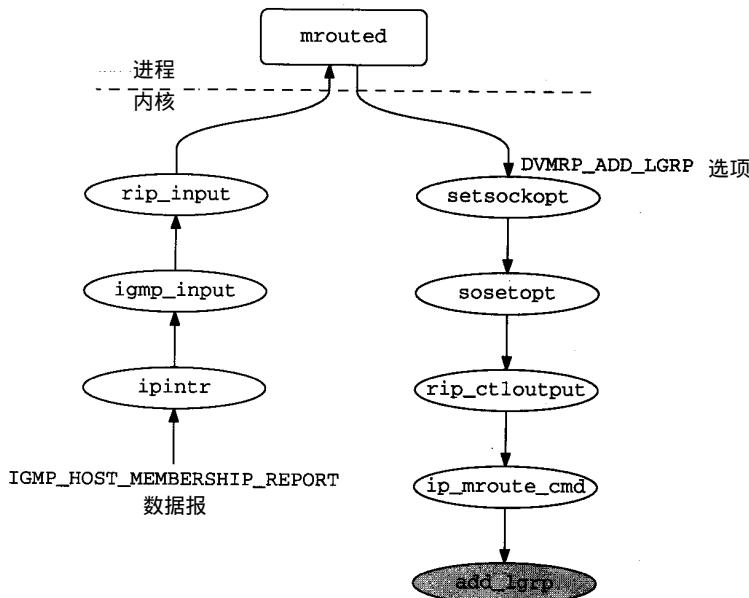


图14-20 IGMP报告处理

87-90 lgc_vifi 和 lgc_gaddr 标识 {接口，组} 对。接口下标(无符号短整数 lgc_vifi) 标识一个虚拟接口，而不是物理接口。

当收到一个 IGMP_HOST_MEMBERSHIP_REPORT 时，调用图 14-20 所示的函数。

14.6.1 add_lgrp 函数

mroute 检查到达 IGMP 报告的源地址，确定是哪个子网，从而确定报告是哪个接口接

ip_mroute.c

```

291 static int
292 add_lgrp(gcp)
293 struct lgrpctl *gcp;
294 {
295     struct vif *vifp;
296     int     s;
297
298     if (gcp->lgc_vifi >= numvifs)
299         return (EINVAL);
300
301     vifp = viftable + gcp->lgc_vifi;
302     if (vifp->v_lcl_addr.s_addr == 0 || (vifp->v_flags & VIFF_TUNNEL))
303         return (EADDRNOTAVAIL);
304
305     /* If not enough space in existing list, allocate a larger one */
306     s = splnet();
307     if (vifp->v_lcl_grps_n + 1 >= vifp->v_lcl_grps_max) {
308         int     num;
309         struct in_addr *ip;
310
311         num = vifp->v_lcl_grps_max;
312         if (num <= 0)
313             num = 32;           /* initial number */
314         else
315             num += num;        /* double last number */
316         ip = (struct in_addr *) malloc(num * sizeof(*ip),
317                                         M_MRTABLE, M_NOWAIT);
318         if (ip == NULL) {
319             splx(s);
320             return (ENOBUFS);
321         }
322         bzero((caddr_t) ip, num * sizeof(*ip));    /* XXX paranoid */
323         bcopy((caddr_t) vifp->v_lcl_grps, (caddr_t) ip,
324               vifp->v_lcl_grps_n * sizeof(*ip));
325
326         vifp->v_lcl_grps_max = num;
327         if (vifp->v_lcl_grps)
328             free(vifp->v_lcl_grps, M_MRTABLE);
329         vifp->v_lcl_grps = ip;
330
331         splx(s);
332     }
333     vifp->v_lcl_grps[vifp->v_lcl_grps_n++] = gcp->lgc_gaddr;
334
335     if (gcp->lgc_gaddr.s_addr == vifp->v_cached_group)
336         vifp->v_cached_result = 1;
337
338     splx(s);
339     return (0);
340 }
```

ip_mroute.c

图 14-21 add_lgrp 函数：DVMRP_ADD_GGRP 命令

收的。根据这个信息，`mROUTED`为该接口设置`DVMRP_ADD_LGRP`命令，更新内核中的成员关系表。这个信息也被送到多播路由选择算法，更新路由选择表。图 14-21 显示了`add_lgrp`函数。

1. 验证增加请求

291-301 如果该请求标识了一个无效接口，就返回`EINVAL`。如果没有使用该接口或它是一个隧道，则返回`EADDRNOTAVAIL`。

2. 如果需要，扩展组数组

302-326 如果新组无法放在当前的组数组中，就分配一个新的数组。第一次为接口调用`add_lgrp`函数时，分配一个能装 32 个组的数组。

每次数组被填满后，`add_lgrp`就分配一个两倍于前面数组大小的新数组。`malloc`负责分配，`bzero`负责清零，`bcopy`把旧数组中的内容复制到新数组中。更新最大入口数`v_lcl_grps_max`，释放旧数组(如果有的话)，把新数组和`v_lcl_grps`连接到`vif`入口。

“偏执狂(paranoid)”评论指出，无法保证`malloc`分配的内存全部是 0。

3. 增加新的组

327-332 新组被复制到下一个可用的入口，如果高速缓存中已经存放了新组，就把高速缓存标记为有效。

查找高速缓存中包含一个地址`v_cached_group`，以及一个高速缓存的查找结果`v_cached_result`。`grpList_member`函数在搜索成员关系数组之前，总是先查一下这个高速缓存。如果给定的组与`v_cached_group`匹配，就返回高速缓存的查找结果；否则，搜索成员关系数组。

14.6.2 `del_lgrp`函数

如果在 270 秒内，没有收到该组任何成员关系的报告，则每个接口的组信息超时。

`mROUTED`维护适当的定时器，并当信息超时后，发布`DVMRP_DEL_LGRP`命令。图 14-22 显示了`del_lgrp`。

1. 验证接口下标

337-347 如果请求标识无效接口，叫返回`EINVAL`。如果该接口没有使用或是一个隧道，则返回`EADDRNOTAVAIL`。

2. 更新查找高速缓存

348-350 如果要删除的组在高速缓存里，就把查找结果设成 0(假)。

3. 删除组

351-364 如果在成员关系表中没有找到该组，则在`error`中发布`EADDRNOTAVAIL`。`for`循环搜索与该接口相关的成员关系数组。如果`same`(是一个宏，用`bcmp`比较两个地址)为真，则清除`error`，把组计数器加 1。`bcopy`移动后续的数组入口，删除该组，`del_lgrp`跳出该循环。

如果循环结束，没有找到匹配，则返回`EADDRNOTAVAIL`；否则返回 0。

```

337 static int ip_mroute.c
338 del_lgrp(gcp)
339 struct lgrplctl *gcp;
340 {
341     struct vif *vifp;
342     int i, error, s;
343
344     if (gcp->lgc_vifi >= numvifs)
345         return (EINVAL);
346     vifp = viftable + gcp->lgc_vifi;
347     if (vifp->v_lcl_addr.s_addr == 0 || (vifp->v_flags & VIFF_TUNNEL))
348         return (EADDRNOTAVAIL);
349
350     s = splnet();
351
352     if (gcp->lgc_gaddr.s_addr == vifp->v_cached_group)
353         vifp->v_cached_result = 0;
354
355     error = EADDRNOTAVAIL;
356     for (i = 0; i < vifp->v_lcl_grps_n; ++i)
357         if (same(&gcp->lgc_gaddr, &vifp->v_lcl_grps[i])) {
358             error = 0;
359             vifp->v_lcl_grps_n--;
360             bcopy((caddr_t) & vifp->v_lcl_grps[i + 1],
361                   (caddr_t) & vifp->v_lcl_grps[i],
362                   (vifp->v_lcl_grps_n - i) * sizeof(struct in_addr));
363             error = 0;
364             break;
365         }
366     splx(s);
367     return (error);
368 }

```

*ip_mroute.c*图14-22 `del_lgrp` 函数：DVMRP_ DEL_LGRP命令

14.6.3 `grplst_member`函数

在转发多播时，查询成员关系数组，以免把数据报发到没有目的组成员的网络上。图 14-23显示的`grplst_member`函数，搜索整个表，寻找给定组地址。

```

368 static int ip_mroute.c
369 grplst_member(vifp, gaddr)
370 struct vif *vifp;
371 struct in_addr gaddr;
372 {
373     int i, s;
374     u_long addr;
375
376     mrtstat.mrts_grp_lookups++;
377
378     if (addr == vifp->v_cached_group)
379         return (vifp->v_cached_result);
380
381     mrtstat.mrts_grp_misses++;
382
383     for (i = 0; i < vifp->v_lcl_grps_n; ++i)

```

图14-23 `grplst_member` 函数

```

381     if (addr == vifp->v_lcl_grps[i].s_addr) {
382         s = splnet();
383         vifp->v_cached_group = addr;
384         vifp->v_cached_result = 1;
385         splx(s);
386         return (1);
387     }
388     s = splnet();
389     vifp->v_cached_group = addr;
390     vifp->v_cached_result = 0;
391     splx(s);
392     return (0);
393 }
```

ip_mroute.c

图14-23 (续)

1. 检查高速缓存

368-379 如果请求的组在高速缓存中，则返回高速缓存的结果，不搜索成员关系数组。

2. 搜索成员关系数组

380-390 对数组进行线性搜索，确定组是否在其中。如果找到，就更新高速缓存以记录匹配的值，并返回1；如果没有找到，就更新高速缓存记录丢失的，并返回0。

14.7 多播选路

正如在本章开始提到的，我们不给出 `mouted` 实现的 TRPB 算法，但给出一个有关该机制的综述，描述内核的多播路由选择表和多播路由选择函数。图 14-24 显示了一个我们用于解释该算法的示例多播网络。

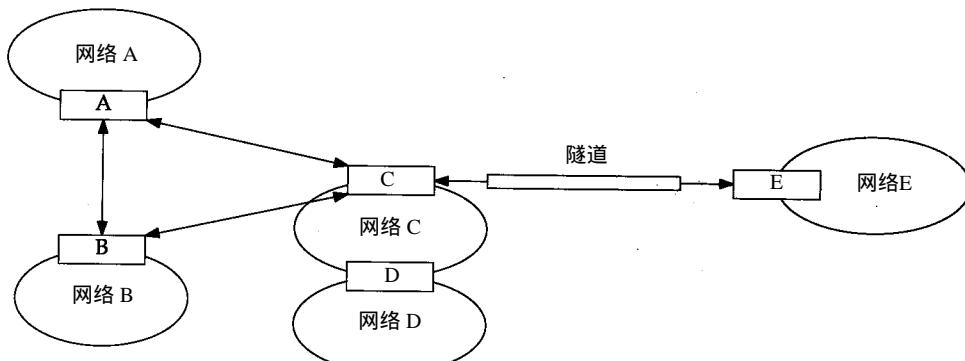


图14-24 多播网络示例

图14-24中，方框代表路由器，椭圆代表连接到路由器的多播网络。例如，路由器 D 可以在网络 D 和网络 C 上多播。路由器 C 可以向网络 C 多播，通过点到点接口向路由器 A 和 B 多播，并可以通过一个多播隧道向路由器 E 多播。

最简单的路由选择办法是，从互联网拓扑中选出一个子网，形成一个生成树。如果每个路由器都沿着生成树转发多播，则各路由器最终会收到数据报。图 14-25 显示了示例网络的一个生成树。其中，网络 A 上的主机 S 是多播数据报的源。

有关生成树的讨论，参见 [Tanenbaum 1989] 或 [Perlman 1992]。

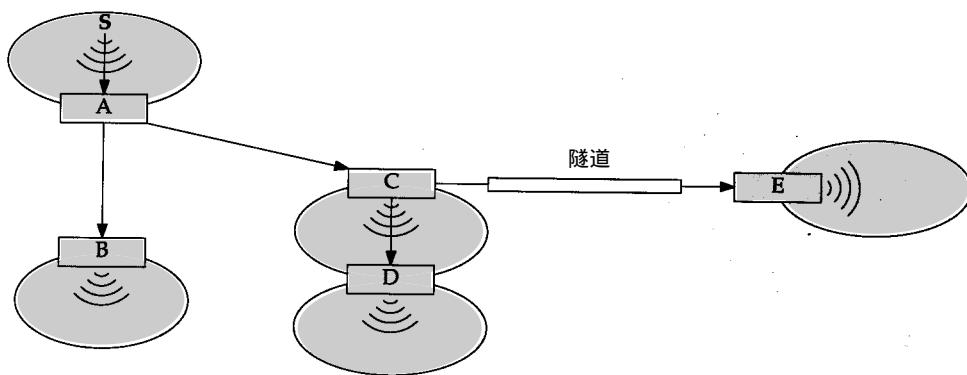


图14-25 网络A的生成树

这个生成树是根据从各网络回到网络 A 上的源站的最短逆向路径 (*reverse path*) 构造的。图 14-25 的生成树中，省略了路由器 B 和 C 之间的线路。路由器 A 和路由器 B 之间的箭头，以及路由器 B 和 C 之间的箭头，强调了多播网络是生成树的一部分。

如果用同一生成树转发来自网络 C 的数据报，为了在网络 B 上收到，数据报经过的转发路径将大于需要的长度。RFC 1075 提出的算法为每个潜在的源站计算了一个单独的生成树，以避免这种情况。路由选择表为每条路由记录了一个网络号和子网掩码，所以一条路由可以应用到源子网内的任意主机。

因为构造生成树是为了给源站的数据报提供最短逆向路径，而每个网络都接收所有多播数据报，所以这个过程称为逆向路径广播 (*reverse path broadcast*) 即 RPB。

RPB 没有任何多播组成员信息，使许多数据报被不必要的转发到没有目的组成员的网络上。如果，除了计算生成树外，该路由选择算法还能记录哪些网络是叶子，注意到每个网络上的组成员关系，那么，连到叶子网络的路由器就可以避免把数据报转发到没有目的组成员的网络上去。这称为截断逆向路径广播 (TRPB)，2.0 版的 mrouted 在 IGMP 帮助下记录叶子网络上的成员关系，从而实现这一算法。

图 14-26 显示了 TRPB 算法的应用。多播来自网络 C 上的源站，并在网络 B 上有一个目的组成员。

我们用图 14-26 说明 Net/3 多播路由选择表中使用的名词。在这个例子中，有阴影的网络和

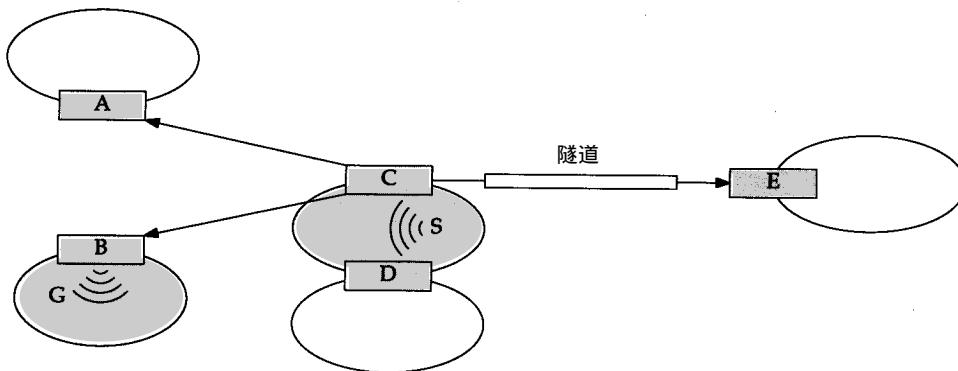


图14-26 网络C的TRPB路由选择

路由器收到来自网络C上源站的数据报。A和B之间的线路不属于生成树，C与D之间没有连接，因为C和D直接收到源站发送的多播。

在这个图中，网络A、B、D和E是叶子网络。路由器C接收多播，并通过连到路由器A、B和E的接口将其转发——尽管把它发给A和E都是浪费。这是TRPB算法的缺点。

路由器C上与网络C相关的接口叫做父亲，因为路由器C期望用它接收来自网络C的多播。从路由器C到路由器A、B和E的接口叫做儿子接口。对路由器A来说，点到点接口是来自C的源分组的父亲，到网络A的接口是儿子。接口相对于数据报的源站，被标识为父亲和儿子。只在相关的儿子接口上转发多播数据报，不在父亲接口上转发多播。

继续我们的例子，因为网络A、D和E是叶子网络，并且没有目的组成员，所以它们没有阴影。在路由器处截断生成树，也不把数据报转发到这些网络上去。路由器B把数据报转发到网络B上，因为B上有一个目的组成员。为实现截断算法，接收数据报的所有路由器都在自己的`viftable`中查询与每个虚拟接口相关的组表。

对该多播路由选择算法的最后一个改进叫做逆向路径多播（reverse path multicasting，RPM）。RPM的目的是修剪(prune)各生成树，避免在没有目的组成员的分支上发送数据报。在图14-26中，RPM可以避免路由器C向A和E发送数据报，因为在这两个分支上没有目的多播组的成员。3.3版的mrouted实现了RPM。

图14-27是我们的示例网络，但这一次，只有那些RPM算法选路数据报能到达的路由器和网络才有阴影。

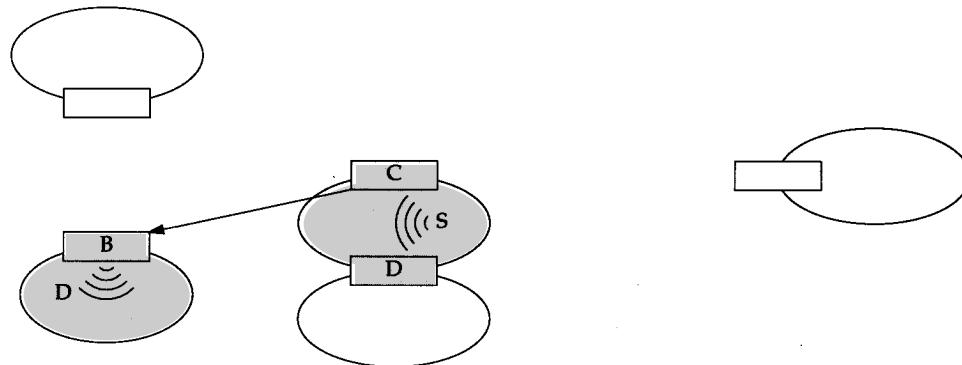


图14-27 网络C的RMP路由选择

为了计算生成树对应的路由表，多播路由器和邻近的多播路由器通信，发现多播互联网拓扑和多播组成员的位置。在Net/3中，用DVMRP进行这种通信。DVMRP作为IGMP数据报传送，发给224.0.0.4组，该组是给DVMRP通信保留的(图12-1)。

在图12-39中，我们看到，多播路由器总是接受到达的IGMP分组，把它们传给`igmp_input`和`rip_input`，然后`mrouted`在一个原始IGMP插口上读它们。`mrouted`把DVMRP报文发送到同一原始IGMP插口上的其他多播路由器。

实现这些算法需要的有关RPB、TRPB、RPM以及DVMRP报文的其他细节参见[Deering and Cheriton 1990]和`mrouted`的源代码。

Internet上还使用了其他多播路由选择协议。Proteon路由器实现了RFC 1584 [Moy 1994]提出的MOSPF协议。Cisco从操作软件的10.2版开始实现了PIM(Protocol Independent

Multicasting)。[Deering et al 1994]描述了PIM。

14.7.1 多播选路表

现在我们描述Net/3中实现的多播路由选择。内核的多播路由选择表是作为一个有64个入口的散列表实现的(MRTHASHIZ)。该表保存在全局数组mrttable中，每个入口指向一个mrt结构的链表，如图14-28所示。

```
ip_mroute.h
120 struct mrt {
121     struct in_addr mrt_origin; /* subnet origin of multicasts */
122     struct in_addr mrt_originmask; /* subnet mask for origin */
123     vifi_t mrt_parent; /* incoming vif */
124     vifbitmap_t mrt_children; /* outgoing children vifs */
125     vifbitmap_t mrt_leaves; /* subset of outgoing children vifs */
126     struct mrt *mrt_next; /* forward link */
127 };
ip_mroute.h
```

图14-28 mrt 结构

120-127 mrtc_origin和mrtc_originmask标识表中的一个入口。mrtc_parent是虚拟接口的下标，该虚拟接口上预期有来自起点的所有多播数据报。mrtc_children是一个位图，标识外出的接口。mrtc_leaves也是一个位图，里面标识多播路由选择树中也是叶子的外出接口。当多条路由散列到同一个数组入口时，最后一个成员mrt_next实现该入口的一个链表。

图14-29是多播选路表的整体结构。各mrt结构都放在一个散列链上，该散列链与nethash(图14-31)函数返回的值对应。

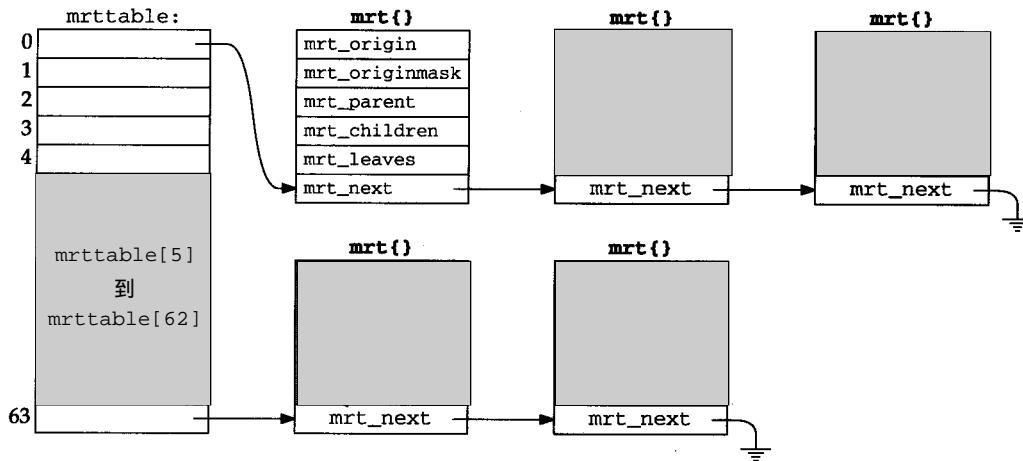


图14-29 多播选路表

内核维护的多播选路表是mrouted维护的多播选路表的一个子集，其中的信息足够内核支持多播转发。发送内核表更新和DVMRP_ADD_MRT命令，其中包含图14-30显示的mrtctl结构。

95-101 mrtctl结构的5个成员携带了我们谈到的mrouted和内核之间的信息(图14-28)。

多播选路表的键值是多播数据报的源IP地址。nethash(图14-31)实现该用于该表的散列

算法。它接受源IP地址，并返回0~63之间的一个值(MRTHASHSIZ-1)。

```
ip_mroute.h
95 struct mrtctl {
96     struct in_addr mrtc_origin; /* subnet origin of multicasts */
97     struct in_addr mrtc_originmask; /* subnet mask for origin */
98     vifi_t mrtc_parent; /* incoming vif */
99     vifbitmap_t mrtc_children; /* outgoing children vifs */
100    vifbitmap_t mrtc_leaves; /* subset of outgoing children vifs */
101 };
ip_mroute.h
```

图14-30 mrtctl 结构

```
ip_mroute.c
398 static u_long
399 nethash(in)
400 struct in_addr in;
401 {
402     u_long n;
403     n = in_netof(in);
404     while ((n & 0xff) == 0)
405         n >>= 8;
406     return (MRTHASHMOD(n));
407 }
ip_mroute.c
```

图14-31 nethash 结构

398-407 in_netof返回in，主机部分设置为全0，在n中仅留下发送主机的A、B和C类网络。右移结果，直到低8位非零为止。MRTHASHMOD是

```
#define MRTHASHMOD(h) ((h) & (MRTHASHSIZ - 1))
```

把低8位与63进行逻辑与运算，留下低6位，这是0~63之间的一个整数。

用两个函数调用(nethash和in_netof)计算散列值，作为散列32 bit地址值太过昂贵了。

14.7.2 del_mrt函数

mrouted守护程序通过DVMRP_ADD_MRT和DVMRP_DEL_MRT命令在内核的多播选路表中增加或删除表项。图14-32显示了del_mrt函数。

```
ip_mroute.c
451 static int
452 del_mrt(origin)
453 struct in_addr *origin;
454 {
455     struct mrt *rt, *prev_rt;
456     u_long hash = nethash(*origin);
457     int s;
458     for (prev_rt = rt = mrttable[hash]; rt; prev_rt = rt, rt = rt->mrt_next)
459         if (origin->s_addr == rt->mrt_origin.s_addr)
460             break;
461     if (!rt)
462         return (ESRCH);
463     s = splnet();
```

图14-32 del_mrt 函数：DVMRP_DEL_MRT 命令

```

464     if (rt == cached_mrt)
465         cached_mrt = NULL;
466
467     if (prev_rt == rt)
468         mrttable[hash] = rt->mrt_next;
469     else
470         prev_rt->mrt_next = rt->mrt_next;
471     free(rt, M_MRTABLE);
472
473 }

```

ip_mroute.c

图14-32 (续)

1. 找到路由入口

451-462 for循环从hash标识的入口开始(在nethash中定义时初始化)。如果没有找到入口，则返回ESRCH。

2. 删除路由入口

463-473 如果该入口在高速缓存中，则高速缓存也无效了。从散列链上把该入口断开，并且释放。当匹配入口在表的最前面时，需要if语句处理这一特殊情况。

14.7.3 add_mrt函数

add_mrt函数如图14-33所示。

ip_mroute.c

```

411 static int
412 add_mrt(mrtcp)
413 struct mrtctl *mrtcp;
414 {
415     struct mrt *rt;
416     u_long hash;
417     int s;
418
419     if (rt = mrtfind(mrtcp->mrtc_origin)) {
420         /* Just update the route */
421         s = splnet();
422         rt->mrt_parent = mrtcp->mrtc_parent;
423         VIFM_COPY(mrtcp->mrtc_children, rt->mrt_children);
424         VIFM_COPY(mrtcp->mrtc_leaves, rt->mrt_leaves);
425         splx(s);
426         return (0);
427     }
428     s = splnet();
429
430     rt = (struct mrt *) malloc(sizeof(*rt), M_MRTABLE, M_NOWAIT);
431     if (rt == NULL) {
432         splx(s);
433         return (ENOBUFS);
434     }
435     /*
436      * insert new entry at head of hash chain
437      */
438     rt->mrt_origin = mrtcp->mrtc_origin;
439     rt->mrt_originmask = mrtcp->mrtc_originmask;
440     rt->mrt_parent = mrtcp->mrtc_parent;

```

图14-33 add_mrt 函数：处理DVMRP_ADD_MRT 命令

```

439     VIFM_COPY(mrtcp->mrtc_children, rt->mrt_children);
440     VIFM_COPY(mrtcp->mrtc_leaves, rt->mrt_leaves);
441     /* link into table */
442     hash = nethash(mrtcp->mrtc_origin);
443     rt->mrt_next = mrttable[hash];
444     mrttable[hash] = rt;
445
446     splx(s);
447     return (0);
448 }

```

ip_mroute.c

图14-33 (续)

1. 更新存在的路由

411-427 如果请求的路由已经在路由表中，则把新的信息复制到该路由中，`add_mrt`返回。

2. 分配新路由

428-447 在新分配的mbuf中，根据增加请求传递的`mrtctl`结构，构造一个`mrt`结构。从`mrtc_origin`计算出散列下标，并把新路由插入散列链的第一个入口。

14.7.4 `mrtfind`函数

`mrtfind`函数负责搜索多播选路表。如图14-34所示。把数据报的源站地址传给`mrtfind`，`mrtfind`返回一个指向匹配`mrt`结构的指针；如果没有匹配，则返回一个空指针。

1. 检查路由查询高速缓存

477-488 把给定的源IP地址(`origin`)与高速缓存中的原始掩码做逻辑与运算。如果结果与`cached_origin`匹配，则返回高速缓存的入口。

```

477 static struct mrt *
478 mrtfind(origin)
479 struct in_addr origin;
480 {
481     struct mrt *rt;
482     u_int    hash;
483     int      s;
484
485     mrtstat.mrts_mrt_lookups++;
486
487     if (cached_mrt != NULL &&
488         (origin.s_addr & cached_originmask) == cached_origin)
489     return (cached_mrt);
490
491     mrtstat.mrts_mrt_misses++;
492
493     hash = nethash(origin);
494     for (rt = mrttable[hash]; rt; rt = rt->mrt_next)
495         if ((origin.s_addr & rt->mrt_originmask.s_addr) ==
496             rt->mrt_origin.s_addr) {
497             s = splnet();
498             cached_mrt = rt;
499             cached_origin = rt->mrt_origin.s_addr;
500             cached_originmask = rt->mrt_originmask.s_addr;
501             splx(s);
502             return (rt);
503         }
504     return (NULL);
505 }

```

*ip_mroute.c**ip_mroute.c*图14-34 `mrtfind`函数

2. 检查散列表

489-501 nethash返回该路由入口的散列下标。for循环搜索散列链找到匹配的路由。当找到一个匹配时，更新高速缓存，返回一个指向该路由的指针。如果没有找到匹配，则返回一个空指针。

14.8 多播转发：ip_mforward函数

内核实现了整个多播转发。我们在图 12-39 中看到，当 ip_mrouted 非空时，也就是 mrouted 在运行时，ipintr 把到达数据报传给 ip_mforward。

我们在图 12-40 中看到，ip_output 可以把本地主机产生的多播数据报传给 ip_mforward，由 ip_mforward 为这些数据报选路到除 ip_output 选定的接口以外的其他接口上去。

与单播转发不同，每当多播数据报被转发到某个接口上时，就为该数据报产生一个备份。例如，如果本地主机是一个多播路由器，并且连接到三个不同的网络，则系统产生的多播数据报被分别复制三份，在三个接口上等待输出。另外，如果应用程序设置了多播环回标志位，或者任何输出的接口也接收它自己的传送，则数据报也将被复制，等待输入。

图14-35显示了一个到达某个物理接口的多播数据报。

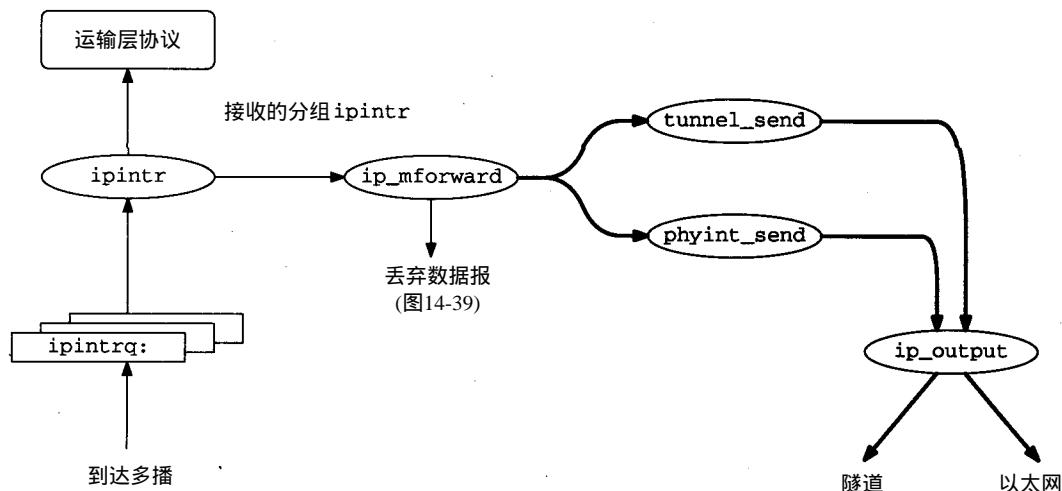


图14-35 到达某个物理接口的多播数据报

在图14-35中，数据报到达的接口是目的多播组的一个成员，所以数据报被传给运输层协议等待输入处理。该数据报也被传给 ip_mforward，在这里它被复制和转发到一个物理接口和一个隧道上(带粗线的箭头)，这两个必须都不和接收接口相同。

图14-36显示了一个到达某隧道的多播数据报。

在图14-36中，用带虚线的箭头表示与该隧道的本地端有关的物理接口，数据报就在这一接口上到达。数据报被传给 ip_mforward，我们将在图14-37看到，因为分组到达一个隧道，所以 ip_mforward 返回一个非零值。这导致 ipintr 不再把该分组传给运输层协议。

ip_mforward 从分组中取出隧道选项，查询多播选路表，并且，在本例中，还把分组转发到另一个隧道以及到达的物理接口上去，用带细线的箭头表示。这是可行的，因为多播选

路表是根据虚拟接口，而不是物理接口。

在图14-36中，我们假定物理接口是目的多播组的成员，所以 `ip_output` 把该数据报传给 `ip_mloopback`，`ip_mloopback` 把它送到队列中等待 `ipintr` 的处理(带粗线的箭头)。然后，分组又被传给 `ip_mforward`，并被这个函数丢弃 (练习 14.4)。这一次，`ip_mforward` 返回0(因为分组是在物理接口上到达的)，所以 `ipintr` 接受该数据报，并进行输入处理。

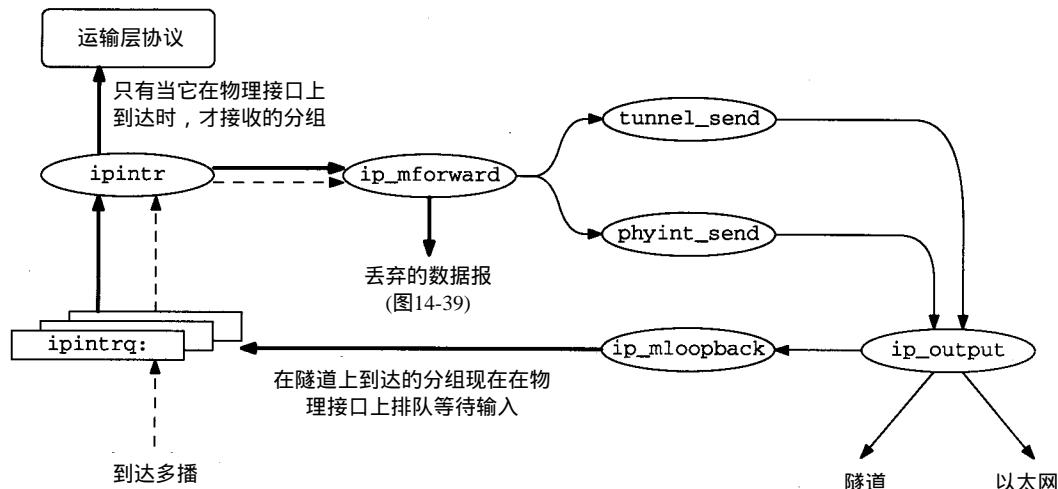


图14-36 到达某个隧道的多播数据报

我们分三部分说明多播转发程序：

- 隧道输入处理(图14-37)；
- 转发条件合格(图14-39)；和
- 转发到出去的接口上(图14-40)。

ip_mroute.c

```

516 int
517 ip_mforward(m, ifp)
518 struct mbuf *m;
519 struct ifnet *ifp;
520 {
521     struct ip *ip = mtod(m, struct ip *);
522     struct mrt *rt;
523     struct vif *vifp;
524     int vifi;
525     u_char *ipoptions;
526     u_long tunnel_src;

527     if (ip->ip_hl < (IP_HDR_LEN + TUNNEL_LEN) >> 2 ||
528         (ipoptions = (u_char *) (ip + 1))[1] != IPOPT_LSRR) {
529         /* Packet arrived via a physical interface. */
530         tunnel_src = 0;
531     } else {
532         /*
533          * Packet arrived through a tunnel.
534          * A tunneled packet has a single NOP option and a

```

图14-37 `ip_mforward` 函数：到达隧道

```

535     * two-element loose-source-and-record-route (LSRR)
536     * option immediately following the fixed-size part of
537     * the IP header. At this point in processing, the IP
538     * header should contain the following IP addresses:
539     *
540     * original source      - in the source address field
541     * destination group   - in the destination address field
542     * remote tunnel end-point - in the first element of LSRR
543     * one of this host's addrs - in the second element of LSRR
544     *
545     * NOTE: RFC-1075 would have the original source and
546     * remote tunnel end-point addresses swapped. However,
547     * that could cause delivery of ICMP error messages to
548     * innocent applications on intermediate routing
549     * hosts! Therefore, we hereby change the spec.
550     */
551 /* Verify that the tunnel options are well-formed. */
552 if (ipoptions[0] != IPOPT_NOP ||
553     ipoptions[2] != 11 || /* LSRR option length */
554     ipoptions[3] != 12 || /* LSRR address pointer */
555     (tunnel_src = *(u_long *)(&ipoptions[4])) == 0) {
556     mrtstat.mrts_bad_tunnel++;
557     return (1);
558 }
559 /* Delete the tunnel options from the packet. */
560 ovbcopy((caddr_t) (ipoptions + TUNNEL_LEN), (caddr_t) ipoptions,
561         (unsigned) (m->m_len - (IP_HDR_LEN + TUNNEL_LEN)));
562 m->m_len -= TUNNEL_LEN;
563 ip->ip_len -= TUNNEL_LEN;
564 ip->ip_hl -= TUNNEL_LEN >> 2;
565 }

```

ip_mroute.c

图14-37 (续)

516-526 `ip_mforward`的两个参数是：一个指向包含该数据报的 mbuf链的指针；另一个是指向接收接口 `ifnet`结构的指针。

1. 到达物理接口

527-530 为了区分在同一物理接口上到达的多播数据报是否经过隧道，要检查 IP首部的特征LSRR选项。如果首部太小，无法包含该选项；或者该选项不是以一个后面跟着一个 LSRR选项的NOP开始，就假定该数据报是在一个物理接口上到达的，并把 `tunnel_src`设为0。

2. 到达隧道

531-558 如果数据报看起来像是从隧道上到达的，就检查选项，验证格式是否正确。如果选项的格式不符合多播隧道，则 `ip_mforward`返回1，指示应该把该数据报丢弃。图 14-38是隧道选项的结构。

在图14-38中，我们假定数据报里没有其他选项，但不是必须这样的。任何其他IP选项都可能出现在 LSRR选项的后面，因为隧道开始端的多播路由器总是把 LSRR选项插在所有其他选项之前。

3. 删除隧道选项

559-565 如果选项正确，就把后面的选项和数据向前移动，调整 mbuf首部的 `m_len`和IP首部的 `ip_len`和 `ip_hl`的值，然后删除隧道选项(图14-38)。

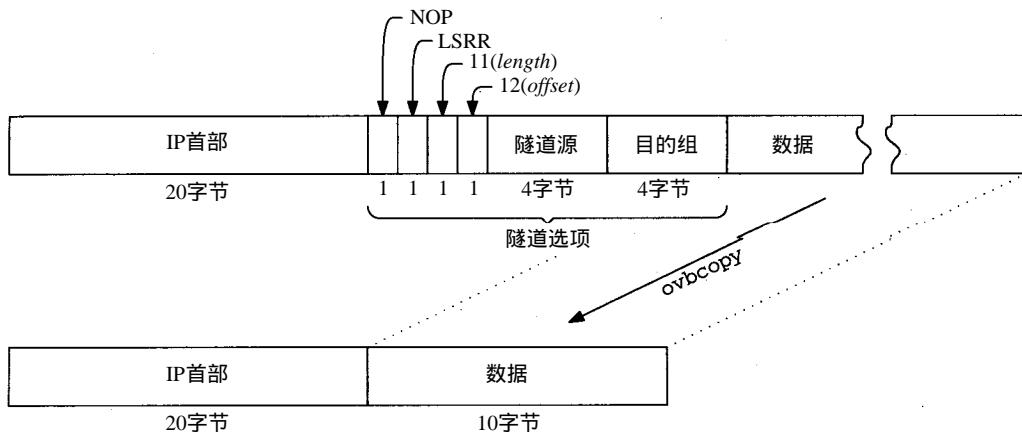


图14-38 多播隧道选项

`ip_mforward`经常把`tunnel_source`作为返回值。当数据报从隧道上到达时，这个值只能是非零的。当`ip_mforward`返回非零值时，它的调用方就丢弃该数据报。对`ipintr`来说，这意味着在隧道上到达的一个数据报被传给`ip_mforward`，并且被`ipintr`丢弃。转发程序取出隧道信息，复制数据报，用`ip_output`将其发送出去；如果接口是目的多播组的成员，则`ip_output`调用`ip_mloopback`。

`ip_mforward`的下一部分显示在图14-39中，在这部分程序中，如果数据报不符合转发的条件，就丢弃它。

```

566  /*
567   * Don't forward a packet with time-to-live of zero or one,
568   * or a packet destined to a local-only group.
569   */
570  if (ip->ip_ttl <= 1 ||
571      ntohl(ip->ip_dst.s_addr) <= INADDR_MAX_LOCAL_GROUP)
572      return ((int) tunnel_src);

573  /*
574   * Don't forward if we don't have a route for the packet's origin.
575   */
576  if (! (rt = mrtfind(ip->ip_src))) {
577      mrtstat.mrts_no_route++;
578      return ((int) tunnel_src);
579  }
580  /*
581   * Don't forward if it didn't arrive from the parent vif for its origin.
582   */
583  vifi = rt->mrt_parent;
584  if (tunnel_src == 0) {
585      if ((viftable[vifi].v_flags & VIFF_TUNNEL) ||
586          viftable[vifi].v_ifp != ifp)
587          return ((int) tunnel_src);
588  } else {
589      if (!(viftable[vifi].v_flags & VIFF_TUNNEL) ||
590          viftable[vifi].v_rmt_addr.s_addr != tunnel_src)
591          return ((int) tunnel_src);
592  }

```

ip_mroute.c

图14-39 ip_mforward 函数：转发可行性检查

4. 超时的TTL或本地多播

566-572 如果 ip_ttl 是 0 或 1，那么数据报已经到了生存期的最后，不再转发它。如果目的组小于或等于 INADDR_MAX_LOCAL_GROUP(几个 224.0.0.x 组，图 12-1)，则不允许数据报离开本地网络，也不转发它。在两种情况下，都把 tunnel_src 返回给调用方。

3.3 版的 mrouted 支持对某些目的多播组的管理辖域。可把接口配置成丢弃所有寻址到这些组的数据报，与 224.0.0.x 组的自动辖域类似。

5. 没有路由可用

573-579 如果 mrtfind 无法根据数据报中的源地址找到一条路由，则函数返回。没有路由，多播路由器无法确定把数据报转发到哪个接口上去。这种情况可能发生在，比如，多播数据报在 mrouted 更新多播选路表之前到达。

6. 在没有想到的接口上到达

580-592 如果数据报到达某个物理接口，但系统本来预想它应该到达某个隧道或其他物理接口，则 ip_mforward 返回；如果数据报到达某个隧道，但系统本来预想它应该在某个物理接口或其他隧道上到达，则 ip_mforward 也返回。产生这些情况的原因是，当组成员关系或网络的物理拓扑发生变化后，正在更新选路表时，数据报到达。

ip_mforward 的最后一部分（图 14-40）把该数据报在多播路由入口所指定的每个输出接口上发送。

```

593  /*
594   * For each vif, decide if a copy of the packet should be forwarded.
595   * Forward if:
596   *   - the ttl exceeds the vif's threshold AND
597   *   - the vif is a child in the origin's route AND
598   *   - ( the vif is not a leaf in the origin's route OR
599   *         the destination group has members on the vif )
600   *
601   * (This might be speeded up with some sort of cache -- someday.)
602   */
603  for (vifp = viftable, vifi = 0; vifi < numvifs; vifp++, vifi++) {
604      if (ip->ip_ttl > vifp->v_threshold &&
605          VIFM_ISSET(vifi, rt->mrt_children) &&
606          (!VIFM_ISSET(vifi, rt->mrt_leaves) ||

607          grplst_member(vifp, ip->ip_dst))) {
608              if (vifp->v_flags & VIFF_TUNNEL)
609                  tunnel_send(m, vifp);
610              else
611                  phyint_send(m, vifp);
612          }
613      }

614  return ((int) tunnel_src);
615 }
```

ip_mroute.c

图 14-40 ip_mforward 函数：转发

593-615 对 viftable 中的每个接口，如果以下条件满足，则在该接口上发送数据报：

- 数据报的 TTL 大于接口的多播阈值；
- 接口是该路由的子接口；以及
- 接口没有和某个叶子网络相连。

如果该接口是一个叶子，那么只有当网络上有目的多播组成员时(也就是说，`grplst_member`返回一个非零值)，才输出该数据报。

`tunnel_send`在隧道接口上转发该数据报；用`phyint_send`在物理接口上转发。

14.8.1 phyint_send函数

为在物理接口上发送多播数据报，`phyint_send`(图14-41)在它传给`ip_output`的`ip_moptions`结构中，明确指定了输出接口。

```
616 static void
617 phyint_send(m, vifp)
618 struct mbuf *m;
619 struct vif *vifp;
620 {
621     struct ip *ip = mtod(m, struct ip *);
622     struct mbuf *mb_copy;
623     struct ip_moptions *imo;
624     int error;
625     struct ip_moptions simo;
626
627     mb_copy = m_copy(m, 0, M_COPYALL);
628     if (mb_copy == NULL)
629         return;
630
631     imo = &simo;
632     imo->imo_multicast_ifp = vifp->v_ifp;
633     imo->imo_multicast_ttl = ip->ip_ttl - 1;
634     imo->imo_multicast_loop = 1;
635
636     error = ip_output(mb_copy, NULL, NULL, IP_FORWARDING, imo);
637 }
```

ip_mroute.c

图14-41 phyint_send 函数

616-634 `m_copy`复制输出的数据报。`ip_moptions`结构设置为强制在选定的接口上传送该数据报。递减TTL，允许多播环回。

数据报被传给`ip_output`。`IP_FORWARDING`标志位避免产生无限回路，使`ip_output`再次调用`ip_mforward`。

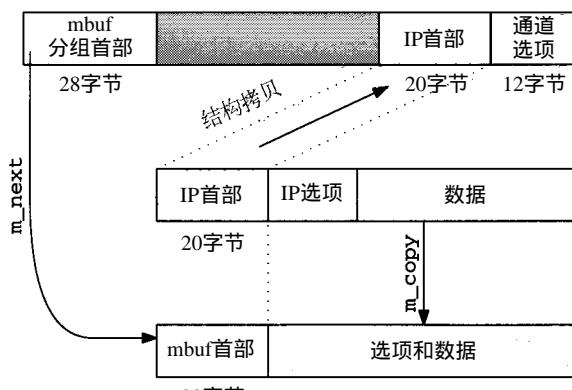


图14-42 插入隧道选项

14.8.2 tunnel_send函数

为了在隧道上发送数据报，tunnel_send(图14-43)必须构造合适的隧道选项，并将其插到输出数据报的首部。图14-42显示了tunnel_send如何为隧道准备分组。

```

635 static void
636 tunnel_send(m, vifp)
637 struct mbuf *m;
638 struct vif *vifp;
639 {
640     struct ip *ip = mtod(m, struct ip *);
641     struct mbuf *mb_copy, *mb_opts;
642     struct ip *ip_copy;
643     int     error;
644     u_char *cp;

645     /*
646     * Make sure that adding the tunnel options won't exceed the
647     * maximum allowed number of option bytes.
648     */
649     if (ip->ip_hl > (60 - TUNNEL_LEN) >> 2) {
650         mrtstat.mrts_cant_tunnel++;
651         return;
652     }
653     /*
654     * Get a private copy of the IP header so that changes to some
655     * of the IP fields don't damage the original header, which is
656     * examined later in ip_input.c.
657     */
658     mb_copy = m_copy(m, IP_HDR_LEN, M_COPYALL);
659     if (mb_copy == NULL)
660         return;
661     MGETHDR(mb_opts, M_DONTWAIT, MT_HEADER);
662     if (mb_opts == NULL) {
663         m_free(mb_copy);
664         return;
665     }
666     /*
667     * Make mb_opts be the new head of the packet chain.
668     * Any options of the packet were left in the old packet chain head
669     */
670     mb_opts->m_next = mb_copy;
671     mb_opts->m_len = IP_HDR_LEN + TUNNEL_LEN;
672     mb_opts->m_data += MSIZE - mb_opts->m_len;

```

ip_mroute.c

图14-43 tunnel_send 函数：验证和分配新首部

1. 隧道选项合适吗

635-652 如果IP首部内没有隧道选项的空间，tunnel_send立即返回，不再在隧道上转发该数据报。可能在其他接口上转发。

2. 复制数据报，为新首部和隧道选项分配 mbuf

653-672 在调用m_copy时，复制的开始偏移是20(IP_HDR_LEN)。产生的mbuf链中包含了数据报的选项和数据报，但没有IP首部。mb_opts指向MGETHDR分配的一个新的数据报首部，这个新的数据报首部被放在mb_copy的前面。然后调整m_len和m_data的值，以容纳IP首部和隧道选项。

tunnel_send的第二部分，如图14-44所示，修改输出分组的头部，并发送该分组。

```

673     ip_copy = mtod(mb_opts, struct ip *);
674     /*
675      * Copy the base ip header to the new head mbuf.
676      */
677     *ip_copy = *ip;
678     ip_copy->ip_ttl--;
679     ip_copy->ip_dst = vifp->v_rmt_addr;      /* remote tunnel end-point */
680     /*
681      * Adjust the ip header length to account for the tunnel options.
682      */
683     ip_copy->ip_hl += TUNNEL_LEN >> 2;
684     ip_copy->ip_len += TUNNEL_LEN;
685     /*
686      * Add the NOP and LSRR after the base ip header
687      */
688     cp = (u_char *) (ip_copy + 1);
689     *cp++ = IPOPT_NOP;
690     *cp++ = IPOPT_LSRR;
691     *cp++ = 11;                      /* LSRR option length */
692     *cp++ = 8;                      /* LSSR pointer to second element */
693     *(u_long *) cp = vifp->v_lcl_addr.s_addr; /* local tunnel end-point */
694     cp += 4;
695     *(u_long *) cp = ip->ip_dst.s_addr; /* destination group */
696     error = ip_output(mb_opts, NULL, NULL, IP_FORWARDING, NULL);
697 }

```

ip_mroute.c

图14-44 tunnel_send 函数：构造头部和发送

3. 修改IP首部

673-679 从原始mbuf链中把原始IP首部复制到新分配的mbuf首部中。减少该首部的TTL，把目的地址改成隧道另一端的接口地址。

4. 构造隧道选项

680-664 调整ip_hl和ip_len的值以容纳隧道选项。隧道选项紧跟在IP首部的后面：一个NOP，后面是LSRR码，LSRR选项的长度(11字节)，以及一个指向选项第二个地址的指针(8字节)。源路由包括了本地隧道端点和后面的目的多播组地址(图14-13)。

5. 发送经过隧道处理的数据报

665-697 现在，这个数据报看起来像一个有LSRR选项的单播数据报，因为它的目的地址是隧道另一端的单播地址。ip_output发送该数据报。当数据报到达隧道的另一端时，隧道选项被剥离，另一端可能会通过其他隧道将数据报继续转发。

14.9 清理：ip_mrouted_done函数

当mrouted结束时，它发布DVMRP_DONE命令，ip_mrouted_done函数(图14-45)处理这个命令。

161-186 这个函数在splnet上运行，避免与多播转发代码的任何交互。对每个物理多播接口，释放本地组表，并发布SIOCDELMULTI命令，阻止接收多播数据报(练习14.3)。bzero清零整个viftable数组，并把numvifs设置成0。

187-198 释放多播选路表中的所有活动入口，`bzero`清零整个表，清零缓存，置位`ip_mrouter`。

多播选路表中的每个入口都可能是入口链表的第一个。这段代码只释放表的第一个入口，引起内存泄露。

```

161 int
162 ip_mroutedone()
163 {
164     wifi_t    wifi;
165     int       i;
166     struct ifnet *ifp;
167     int       s;
168     struct ifreq ifr;
169     s = splnet();
170     /*
171      * For each phyint in use, free its local group list and
172      * disable promiscuous reception of all IP multicasts.
173     */
174     for (wifi = 0; wifi < numvifs; wifi++) {
175         if (viftable[wifi].v_lcl_addr.s_addr != 0 &&
176             !(viftable[wifi].v_flags & VIFF_TUNNEL)) {
177             if (viftable[wifi].v_lcl_grps)
178                 free(viftable[wifi].v_lcl_grps, M_MRTABLE);
179             satosin(&ifr.ifr_addr)->sin_family = AF_INET;
180             satosin(&ifr.ifr_addr)->sin_addr.s_addr = INADDR_ANY;
181             ifp = viftable[wifi].v_ifp;
182             (*ifp->if_ioctl) (ifp, SIOCDELMULTI, (caddr_t) & ifr);
183         }
184     }
185     bzero((caddr_t) viftable, sizeof(viftable));
186     numvifs = 0;
187     /*
188      * Free any multicast route entries.
189     */
190     for (i = 0; i < MRTHASHSIZ; i++)
191         if (mrtable[i])
192             free(mrtable[i], M_MRTABLE);
193     bzero((caddr_t) mrtable, sizeof(mrtable));
194     cached_mrt = NULL;
195     ip_mrouted = NULL;
196     splx(s);
197     return (0);
198 }
```

ip_mrouted.c

图14-45 `ip_mroutedone` 函数：`DVMRP_DONE` 命令

14.10 小结

本章我们描述了网际多播的一般概念和支持它的 Net/3内核中心专用函数。我们没有讨论`mrouted`的实现，有兴趣的读者可以得到源代码。

我们描述了虚拟接口表，讨论了物理接口和隧道之间的区别，以及 Net/3中用于实现隧道的LSRR选项。

我们说明了RPB、TRPB和RPM算法，描述了根据TRPB转发多播数据报的内核表，还讨论了父网络和叶子网络。

习题

- 14.1 在图14-25中，需要多少多播路由？
- 14.2 为什么splnet和splx保护对图14-23中组成员关系高速缓存的更新？
- 14.3 当某个接口用IP_ADD_MEMBERSHIP选项明确加入一个多播组后，如果向它发布SIOCDELMULTI，会发生什么？
- 14.4 当某个上隧道上到达一个数据报，并被ip_mforward接收后，可能会在转发到某个物理接口时，被ip_output环回。为什么当环回分组到达该物理接口时，ip_mforward会丢弃它呢？
- 14.5 重新设计组地址高速缓存，提高它的效率。

第15章 插 口 层

15.1 引言

本书共有三章介绍 Net/3的插口层代码，本章是第一章。插口概念最早出现于 1983年的 4.2BSD版本中，它的主要目的是提供一个统一的访问网络和进程间通信协议的接口。这里讨论的Net/3版基于4.3BSD Reno版，该版本与大多数 Unix供应商使用的早期的4.2版有些细小的差别。

如第1.7节所介绍的，插口层的主要功能是将进程发送的与协议有关的请求映射到产生插口时指定的与协议有关的实现。

为了允许标准的 Unix I/O系统调用，如 `read` 和 `write`，也能读写网络连接，在 BSD版本中将文件系统和网络功能集成在系统调用级。与通过一个描述符访问一个打开的文件一样，进程也是通过一个描述符(一个小整数)来访问插口上的网络连接。这个特点使得标准的文件系统调用，如 `read` 和 `write`，以及与网络有关的系统调用，如 `sendmsg` 和 `recvmsg`，都能通过描述符来处理插口。

我们的重点是插口及相关的系统调用的实现而不是讨论如何使用插口层来实现网络应用。关于进程级的插口接口和如何编写网络应用的详细讨论，请参考 [Stevens 1990] 和 [Rago 1990]。

图15-1说明了进程中的插口接口与内核中的协议实现之间的层次关系。

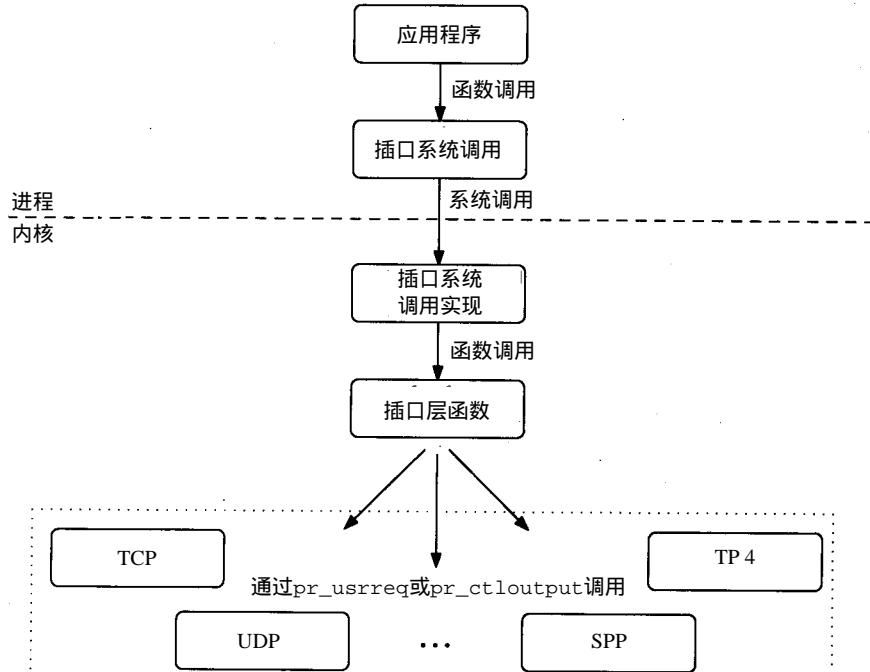


图15-1 插口层将一般的请求转换为指定的协议操作

splnet处理

插口包含很多对splnet和splx的成对调用。正如第1.12节中介绍的，这些调用保护访问在插口层和协议处理层间共享的数据结构的代码。如果不使用splnet，初始化协议处理和改变共享的数据结构的软件中断将使得插口层代码恢复执行时出现混乱。

我们假定读者理解了这些调用，因而在以后讨论中一般不再特别说明它们。

15.2 代码介绍

本章讨论涉及的三个文件在图15-2中列出。

文 件	描 述
sys/socketvar.h	socket结构定义
kern/uipc_syscalls.c	系统调用实现
kern/uipc_socket.c	插口层函数

图15-2 本章讨论涉及的源文件

全局变量

本章讨论涉及到的两个全局变量如图15-3所示。

变 量	数据类型	描 述
socketps	struct fileops	I/O系统调用的socket实现
sysent	struct sysent	系统调用入口数组

图15-3 本章介绍的全局变量

15.3 socket结构

插口代表一条通信链路的一端，存储或指向与链路有关的所有信息。这些信息包括：使用的协议、协议的状态信息(包括源和目的地址)、到达的连接队列、数据缓存和可选标志。图15-5中给出了插口和与插口相关的缓存的定义。

41-42 so_type由产生插口的进程来指定，它指明插口和相关协议支持的通信语义。

so_type的值等于图7-8所示的pr_type。对于UDP，so_type等于SOCK_DGRAM，而对于TCP，so_type则等于SOCK_STREAM。

43 so_options是一组改变插口行为的标志。图15-4列出了这些标志。

通过getsockopt和setsockopt系统调用进程能修改除SO_ACCEPTCONN外所有的插口选项。当在插口上发送listen系统调用时，SO_ACCEPTCONN被内核设置。

44 so_linger等于当关闭一条连接时插口继续发送数据的时间间隔(单位为一个时钟滴答)(第15.15节)。

45 so_state表示插口的内部状态和一些其他的特点。图15-6列出了so_state可能的取值。

so_options	仅用于内核	描述
<i>SO_ACCEPTCONN</i>	•	插口接受进入的连接
<i>SO_BROADCAST</i>		插口能够发送广播报文
<i>SO_DEBUG</i>		插口记录排错信息
<i>SO_DONTROUTE</i>		输出操作旁路选路表
<i>SO_KEEPALIVE</i>		插口查询空闲的连接
<i>SO_OOBINLINE</i>		插口将带外数据同正常数据存放在一起
<i>SO_REUSEADDR</i>		插口能重新使用一个本地地址
<i>SO_REUSEPORT</i>		插口能重新使用一个本地地址和端口
<i>SO_USELOOPBACK</i>		仅针对选路域插口；发送进程收到它自己的选路请求

图15-4 so_options 的值

socketvar.h

```

41 struct socket {
42     short    so_type;           /* generic type, Figure 7.8 */
43     short    so_options;        /* from socket call, Figure 15.5 */
44     short    so_linger;         /* time to linger while closing */
45     short    so_state;          /* internal state flags, Figure 15.6 */
46     caddr_t  so_pcb;           /* protocol control block */
47     struct protosw *so_proto;   /* protocol handle */
48 /*
49  * Variables for connection queueing.
50  * Socket where accepts occur is so_head in all subsidiary sockets.
51  * If so_head is 0, socket is not related to an accept.
52  * For head socket so_q0 queues partially completed connections,
53  * while so_q is a queue of connections ready to be accepted.
54  * If a connection is aborted and it has so_head set, then
55  * it has to be pulled out of either so_q0 or so_q.
56  * We allow connections to queue up based on current queue lengths
57  * and limit on number of queued connections for this socket.
58 */
59     struct socket *so_head;      /* back pointer to accept socket */
60     struct socket *so_q0;        /* queue of partial connections */
61     struct socket *so_q;         /* queue of incoming connections */
62     short    so_q0len;          /* partials on so_q0 */
63     short    so qlen;           /* number of connections on so_q */
64     short    so qlimit;          /* max number queued connections */
65     short    so_timeo;          /* connection timeout */
66     u_short  so_error;          /* error affecting connection */
67     pid_t    so_pgid;           /* pgid for signals */
68     u_long   so_oobmark;         /* chars to oob mark */
69 /*
70  * Variables for socket buffering.
71 */
72     struct sockbuf {
73         u_long   sb_cc;            /* actual chars in buffer */
74         u_long   sb_hiwat;         /* max actual char count */
75         u_long   sb_mbcnt;         /* chars of mbufs used */
76         u_long   sb_mbmmax;        /* max chars of mbufs to use */
77         long    sb_lowat;          /* low water mark */
78         struct mbuf *sb_mb;        /* the mbuf chain */
79         struct selinfo sb_sel;     /* process selecting read/write */
80         short   sb_flags;          /* Figure 16.5 */
81         short   sb_timeo;          /* timeout for read/write */
82     } so_rcv, so_snd;
83     caddr_t  so_tpcb;           /* Wisc. protocol control block XXX */

```

图15-5 struct socket 定义

```

84     void      (*so_upcall) (struct socket * so, caddr_t arg, int waitf);
85     caddr_t  so_upcallarg;           /* Arg for above */
86 };

```

socketvar.h

图15-5 (续)

so_state	仅用于内核	描述
<code>SS_ASYNC</code>		插口应该I/O事件的异步通知
<code>SS_NBIO</code>		插口操作不能阻塞进程
<code>SS_CANTRCVMORE</code>	•	插口不能再从对方接收数据
<code>SS_CANTSENDMORE</code>	•	插口不能再发送数据给对方
<code>SS_ISCONFIRMING</code>	•	插口正在协商一个连接请求
<code>SS_ISCONNECTED</code>	•	插口被连接到外部插口
<code>SS_ISCONNECTING</code>	•	插口正在连接一个外部插口
<code>SS_ISDISCONNECTING</code>	•	插口正在同对方断连
<code>SS_NOFDREF</code>	•	插口没有同任何描述符相连
<code>SS_PRIV</code>	•	插口由拥有超级用户权限的进程所产生
<code>SS_RCVATMARK</code>	•	在最近的带外数据到达之前，插口已处理完所有收到的数据

图15-6 so_state 的值

从图 15-6 的第二列中可以看出，进程可以通过 `fcntl` 和 `ioctl` 系统调用直接修改 `SS_ASYNC` 和 `SS_NBIO`。对于其他的标志，进程只能在系统调用的执行过程中间接修改。例如，如果进程调用 `connect`，当连接被建立时，`SS_ISCONNECTED` 标志就会被内核设置。

SS_NBIO 和 SS_ASYNC 标志

在默认情况下，进程在发出 I/O 请求后会等待资源。例如，对一个插口发 `read` 系统调用，如果当前没有网络上来的数据，则 `read` 系统调用就会被阻塞。同样，当一个进程调用 `write` 系统调用时，如果内核中没有缓存来存储发送的数据，则内核将阻塞进程。如果设置了 `SS_NBIO`，在对插口执行 I/O 操作且请求的资源不能得到时，内核并不阻塞进程，而是返回 `EWOULDBLOCK`。

如果设置了 `SS_ASYNC`，当因为下列情况之一而使插口状态发生变化时，内核发送 `SIGIO` 信号给 `so_pgid` 标识的进程或进程组：

- 连接请求已完成；
- 断连请求已被启动；
- 断连请求已完成；
- 连接的一个通道已被关闭；
- 插口上有数据到达；
- 数据已被发送(即，输出缓存中有闲置空间)；或
- UDP 或 TCP 插口上出现了一个异步差错。

46 `so_pcb` 指向协议控制块，协议控制块包含与协议有关的状态信息和插口参数。每一种协议都定义了自己的控制块结构，所以 `so_pcb` 被定义成一个通用的指针。图 15-7 列出了我们讨论的控制块结构。

`so_pcb` 从来不直接指向 `tcp pcb` 结构；参考图 22-1。

协议	控制块	参考章节
UDP	struct inpcb	第22.3节
TCP	struct inpcb	第22.3节
	struct tcpcb	第24.5节
ICMP、IGMP和原始IP	struct inpcb	第22.3节
路由	struct rawcb	第20.3节

图15-7 协议控制块

47 so_proto指向进程在socket系统调用(第7.4节)中选择的协议的protosw结构。

48-64 设置了SO_ACCEPTCONN标志的插口维护两个连接队列。还没有完全建立的连接(如TCP的三次握手还没完成)被放在队列so_q0中。已经建立的连接或将被接受的连接(例如，TCP的三次握手已完成)被放入队列so_q中。队列的长度分别为so_q0len和so_qlen。每一个被排队的连接由它自己的插口来表示。在每一个被排队的插口中，so_head指向设置了SO_ACCEPTCONN的源插口。

插口上可排队的连接数通过so_qlimit来控制，进程可以通过listen系统调用来设置so_qlimit。内核隐含设置的上限为5(SOMAXCONN，图15-24)和下限为0。图15-29中显示的有点晦涩的公式使用so_qlimit来控制排队的连接数。

图15-8说明了有三个连接将被接受、一个连接已被建立的情况下队列的内容。

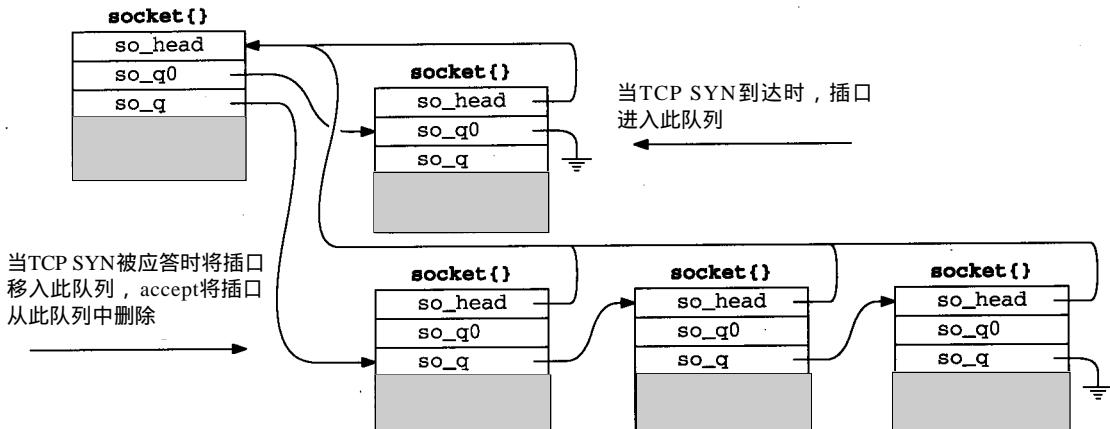


图15-8 插口连接队列

65 so_timeo用作accept、connect和close处理期间的等待通道(wait channel，第15.10节)。

66 so_error保存差错代码，直到在引用该插口的下一个系统调用期间差错代码能送给进程。

67 如果插口的SS_ASYNC被设置，则SIGIO信号被发送给进程(如果so_pgid大于0)或进程组(如果so_pgid小于0)。可以通过ioctl的SIOCSPGRP和SIOCGPGRP命令来修改或检查so_pgid的值。关于进程组的更详细信息请参考 [Stevens 1992]。

68 so_oobmark标识在输入数据流中最近收到的带外数据的开始点。第16.11节将讨论插口对带外数据的支持，第29.7节将讨论TCP中的带外数据的语义。

69-82 每一个插口包括两个数据缓存，`so_rcv`和`so_snd`，分别用来缓存接收或发送的数据。`so_rcv`和`so_snd`是包含在插口结构中的结构而不是指向结构的指针。我们将在第16章中描述插口缓存的结构和使用。

83-86 在Net/3中不使用`so_tpcb`。`so_upcall`和`so_upcallarg`也仅用于Net/3中的NFS软件。

NFS与通常的软件不太一样。在很大程度上它是一个进程级的应用但却在内核中运行。当数据到达接收缓存时，通过`so_upcall`来触发NFS的输入处理。在这种情况下，`tsleep`和`wakeup`机制是不合适的，因为NFS协议是在内核中运行而不是作为一个普通进程。

文件`socketvar.h`和`uipc_socket2.c`定义了几个简化插口层代码的宏和函数。图15-9对它们进行了描述。

名 称	描 述
<code>sosendallonce</code>	<code>so</code> 中指定的协议要求每一个发送系统调用产生一个协议请求吗？ <code>int sosendallonce(struct socket *so);</code>
<code>soisconnecting</code>	将插口状态设置为 <code>SO_ISCONNECTING</code> <code>int soisconnecting(struct socket *so);</code>
<code>soisconnected</code>	参考图15-30
<code>soreadable</code>	插口 <code>so</code> 上的读调用不阻塞就返回信息吗？ <code>int soreadable(struct socket *so);</code>
<code>sowriteable</code>	插口 <code>so</code> 上的写调用不阻塞就返回吗？ <code>int sowriteable(struct socket *so);</code>
<code>socantsendmore</code>	设置插口标志 <code>SO_CANTSENDMORE</code> 。唤醒所有等待在发送缓存上的进程 <code>int socantsendmore(struct socket *so);</code>
<code>socantrcvmore</code>	设置插口标志 <code>SO_CANTRCVMORE</code> 。唤醒所有等待在接收缓存上的进程 <code>int socantrcvmore(struct socket *so);</code>
<code>soisdisconnecting</code>	清除 <code>SS_ISCONNECTING</code> 标志。设置 <code>SS_ISDISCONG</code> 、 <code>SS_CANTRCVMORE</code> 和 <code>SS_CANTSENDMORE</code> 标志。唤醒所有等待在插口上的进程 <code>int soisdisconnecting(struct socket *so);</code>
<code>soisdisconnected</code>	清除 <code>SS_ISCONNECTING</code> 、 <code>SS_ISCONNECTED</code> 和 <code>SS_ISDISCONNECTING</code> 标志。设置 <code>SS_CANTRCVMORE</code> 和 <code>SS_CANTSENDMORE</code> 标志。唤醒所有等待在插口上的进程或等待 <code>close</code> 完成的进程 <code>int soisdisconnected(struct socket *so);</code>
<code>soqinsque</code>	将 <code>so</code> 插入 <code>head</code> 指向的队列中。如果 <code>q</code> 等于0，插口被插到存放未完成的连接的 <code>so_q0</code> 队列的后面。否则，插口被插到存放准备接受的连接的队列 <code>so_q</code> 的后面。Net/1错误地将插口插到队列的前面 <code>int soqinsque(struct socket * head, struct socket * so, int q);</code>
<code>soqremque</code>	从队列 <code>q</code> 中删除 <code>so</code> 。通过 <code>so->so_head</code> 来定位插口队列 <code>int soqremque(struct socket *so, int q);</code>

图15-9 插口的宏和函数

15.4 系统调用

进程同内核交互是通过一组定义好的函数来进行的，这些函数称为系统调用。在讨论支持网络的系统调用之前，我们先来看看系统调用机制的本身。

从进程到内核中的受保护的环境的转换是与机器和实现相关的。在下面的讨论中，我们使用Net/3在386上的实现来说明如何实现有关的操作。

在BSD内核中，每一个系统调用均被编号，当进程执行一个系统调用时，硬件被配置成仅传送控制给一个内核函数。将标识系统调用的整数作为参数传给该内核函数。在386实现中，这个内核函数为`syscall`。利用系统调用的编号，`syscall`在表中找到请求的系统调用的`sysent`结构。表中的每一个单元均为一个`sysent`结构。

```
struct sysent {
    int sy_narg;           /* number of arguments */
    int (*sy_call) ();     /* implementing function */
};                         /* system call table entry */
```

表中有几个项是从`sysent`数组中来的，该数组是在`kern/init_sysent.c`中定义的。

```
struct sysent sysent[] = {
    /* ... */
    { 3, recvmsg },          /* 27 = recvmsg */
    { 3, sendmsg },         /* 28 = sendmsg */
    { 6, recvfrom },        /* 29 = recvfrom */
    { 3, accept },          /* 30 = accept */
    { 3, getpeername },     /* 31 = getpeername */
    { 3, getsockname },     /* 32 = getsockname */
    /* ... */
}
```

例如，`recvmsg`系统调用在系统调用表中的第27个项，它有两个参数，利用内核中的`recvmsg`函数实现。

`syscall`将参数从调用进程复制到内核中，并且分配一个数组来保存系统调用的结果。然后，当系统调用执行完成后，`syscall`将结果返回给进程。`syscall`将控制交给与系统调用相对应的内核函数。在386实现中，调用有点像：

```
struct sysent *callp;
error = (*callp->sy_call) (p, args, rval);
```

这里指针`callp`指向相关的`sysent`结构；指针`p`则指向调用系统调用的进程的进程表项；`args`作为参数传给系统调用，它是一个32 bit长的字数组；而`rval`则是一个用来保存系统调用的返回结果的数组，数组有两个元素，每个元素是一个32 bit长的字。当我们用“系统调用”这个词时，我们指的是被`syscall`调用的内核中的函数，而不是应用调用的进程中的函数。

`syscall`期望系统调用函数(即`sy_call`指向的函数)在没有差错时返回0，否则返回非0的差错代码。如果没有差错出现，内核将`rval`中的值作为系统调用(应用调用的)的返回值传送给进程。如果有差错，`syscall`忽略`rval`中的值，并以与机器相关的方式返回差错代码给进程，使得进程能从外部变量`errno`中得到差错代码。应用调用的函数则返回-1或一个空指针表示应用应该查看`errno`获得差错信息。

在386上的实现，设置进位比特(carry bit)来表示`syscall`的返回值是一个差错代码。进程中的系统调用残桩将差错代码赋给`errno`，并返回-1或空指针给应用。如果没有设置进位

比特，则将 `syscall` 返回的值返回给进程中的系统调用的残桩。

总之，实现系统调用的函数“返回”两个值：一个给 `syscall` 函数；在没有差错的情况下，`syscall` 将另一个（在 `rval` 中）返回给调用进程。

15.4.1 举例

`socket` 系统调用的原型是：

```
int socket(int domain, int type, int protocol);
```

实现 `socket` 系统调用的内核函数的原型是：

```
struct socket_args {
    int domain;
    int type;
    int protocol;
};

socket(struct proc *p, struct socket_args *uap, int *retval);
```

当一个应用调用 `socket` 时，进程用系统调用机制将三个独立的整数传给内核。`syscall` 将参数复制到 32bit 值的数组中，并将数组指针作为第二个参数传给 `socket` 的内核版。内核版的 `socket` 将第二个参数作为指向 `socket_args` 结构的指针。图 15-10 显示了上述过程。

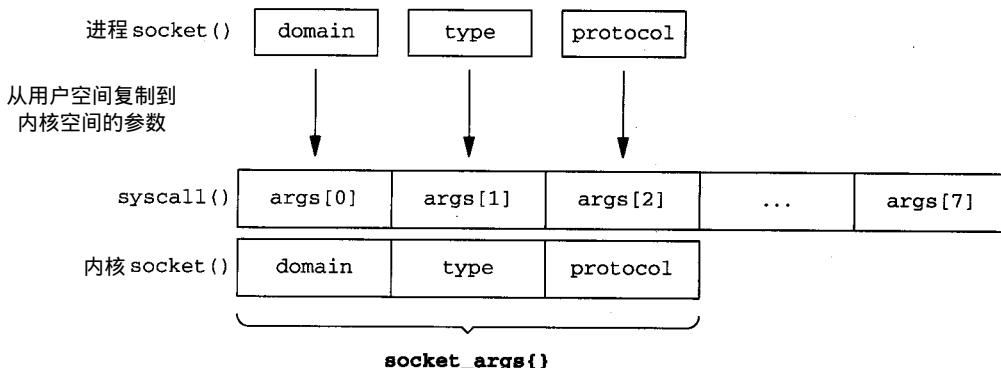


图 15-10 `socket` 参数处理

同 `socket` 类似，每一个实现系统调用的内核函数将 `args` 说明成一个与系统调用有关的结构指针，而不是一个指向 32 bit 的字的数组的指针。

当原型无效时，隐式的类型转换仅在传统的 K&R C 中或 ANSI C 中是合法的。如果原型是有效的，则编译器将产生一个警告。

`syscall` 在执行内核系统调用函数之前将返回值置为 0。如果没有差错出现，系统调用函数直接返回而不需清除 `*retval`，`syscall` 返回 0 给进程。

15.4.2 系统调用小结

图 15-11 对与网络有关的系统调用进行了小结。

我们将在本章中讨论建立、服务器、客户和终止类系统调用。输入、输出类系统调用将在第 16 章中介绍，管理类系统调用将在第 17 章中介绍。

类别	名称	功能
建立	socket bind	在指明的通信域内产生一个未命名的插口 分配一个本地地址给插口
服务器	listen accept	使插口准备接收连接请求 等待并接受连接
客户	connect	同外部插口建立连接
输入	read readv recv recvfrom recvmsg	接收数据到一个缓存中 接收数据到多个缓存中 指明选项接收数据 接收数据和发送者的地址 接收数据到多个缓存中，接收控制信息和发送者地址；指明接收选项
输出	write writev send sendto sendmsg	发送一个缓存中的数据 发送多个缓存中的数据 指明选项发送数据 发送数据到指明的地址 从多个缓存发送数据和控制信息到指明的地址；指明发送选项
I/O	select	等待I/O事件
终止	shutdown close	终止一个或两个方向上的连接 终止连接并释放插口
管理	fcntl ioctl setsockopt getsockopt getsockname getpeername	修改I/O语义 各类插口操作 设置插口或协议选项 得到插口或协议选项 得到分配给插口的本地地址 得到分配给插口的远端地址

图15-11 Net/3中的网络系统调用

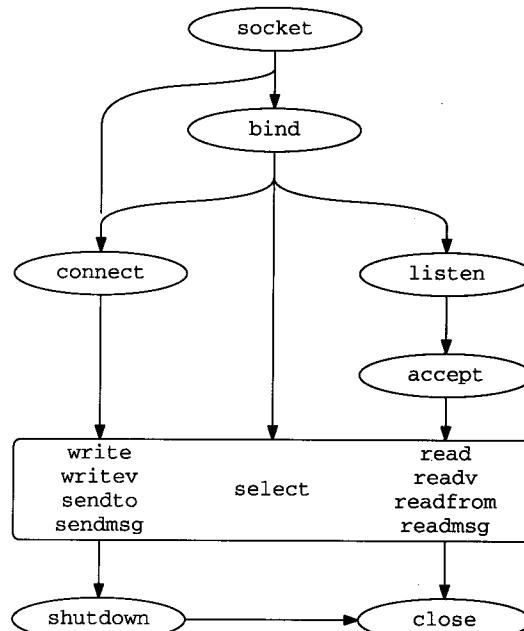


图15-12 网络系统调用流程图

图15-12画出了应用使用这些系统调用的顺序。大方块中的 I/O 系统调用可以在任何时候调用。该图不是一个完整的状态流程图，因为一些正确的转换在本图中没有画出；仅显示了一些常见的转换。

15.5 进程、描述符和插口

在描述插口系统调用之前，我们需要介绍将进程、描述符和插口联系在一起的数据结构。图15-13给出了这些结构以及与我们的讨论有关的结构成员。关于文件结构的更复杂的解释请参考[Leffer ea al. 1989]。

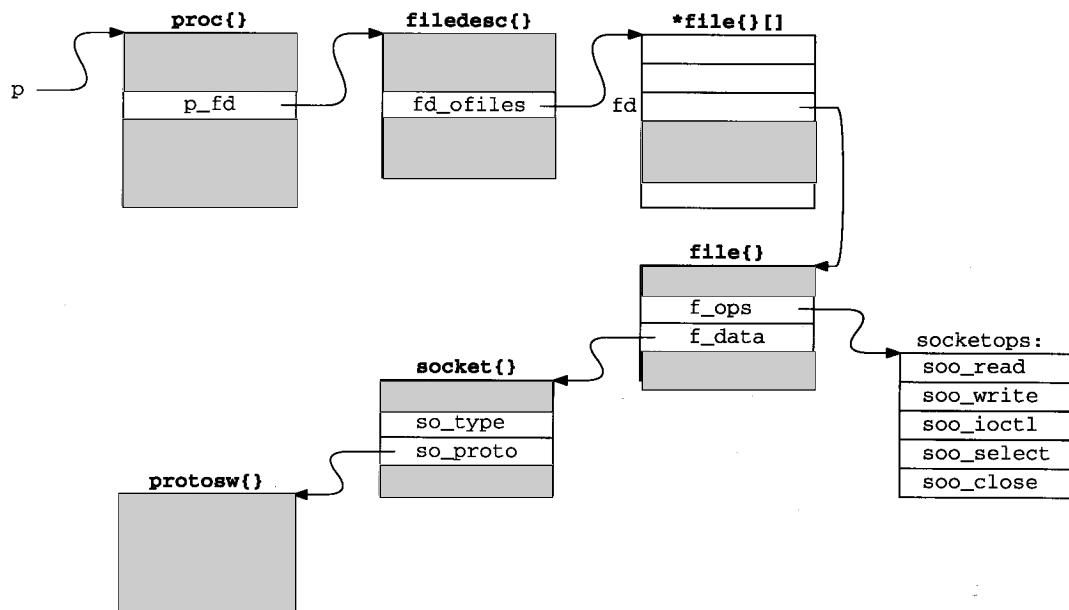


图15-13 进程、文件和插口结构

实现系统调用的函数的第一个参数总为 *p*，即指向调用进程的 *proc* 结构的指针。内核利用 *proc* 结构记录进程的有关信息。在 *proc* 结构中，*p_fd* 指向 *filedesc* 结构，该结构的主要功能是管理 *fd_ofiles* 指向的描述符表。描述符表的大小是动态变化的，由一个指向 *file* 结构的指针数组组成。每一个 *file* 结构描述一个打开的文件，该结构可被多个进程共享。

图15-13仅显示了一个 *file* 结构。通过 *p->p_fd->fd_ofiles[fd]* 访问到该结构。在 *file* 结构中，有两个结构成员是我们感兴趣的：*f_ops* 和 *f_data*。I/O 系统调用(如 *read* 和 *write*)的实现因描述符中的 I/O 对象类型的不同而不同。*f_ops* 指向 *fileops* 结构，该结构包含一张实现 *read*、*write*、*ioctl*、*select* 和 *close* 系统调用的函数指针表。图 15-13 显示 *f_ops* 指向一个全局的 *fileops* 结构，即 *socketops*，该结构包含指向插口用的函数的指针。

f_data 指向相关 I/O 对象的专用数据。对于插口而言，*f_data* 指向与描述符相关的 *socket* 结构。最后，*socket* 结构中的 *so_proto* 指向产生插口时选中的协议的 *protosw* 结构。回想一下，每一个 *protosw* 结构是由与该协议关联的所有插口共享的。

下面我们开始讨论系统调用。

15.6 socket系统调用

socket系统调用产生一个新的插口，并将插口同进程在参数 domain、type 和 protocol 中指定的协议联系起来。该函数（如图15-14所示）分配一个新的描述符，用来在后续的系统调用中标识插口，并将描述符返回给进程。

```

42 struct socket_args {
43     int      domain;
44     int      type;
45     int      protocol;
46 };
47 socket(p, uap, retval)
48 struct proc *p;
49 struct socket_args *uap;
50 int      *retval;
51 {
52     struct filedesc *fdp = p->p_fd;
53     struct socket *so;
54     struct file *fp;
55     int      fd, error;
56     if (error = falloc(p, &fp, &fd))
57         return (error);
58     fp->f_flag = FREAD | FWRITE;
59     fp->f_type = DTTYPE_SOCKET;
60     fp->f_ops = &socketops;
61     if (error = socreate(uap->domain, &so, uap->type, uap->protocol)) {
62         fdp->fd_ofiles[fd] = 0;
63         ffree(fp);
64     } else {
65         fp->f_data = (caddr_t) so;
66         *retval = fd;
67     }
68     return (error);
69 }
```

uipc_syscalls.c

图15-14 socket 系统调用

42-55 在每一个系统调用的前面，都定义了一个描述进程传递给内核的参数的结构。在这种情况下，参数是通过 socket_args 传入的。所有插口层系统调用都有三个参数：p，指向调用进程的 proc 结构；uap，指向包含进程传送给系统调用的参数的结构；retval，用来接收系统调用的返回值。在通常情况下，忽略参数 p 和 retval，引用 uap 所指的结构中的内容。

56-60 falloc 分配一个新的 file 结构和 fd_ofiles 数组（图15-13）中的一个元素。fp 指向新分配的结构，fd 则为结构在数组 fd_ofiles 中的索引。socket 将 file 结构设置成可读、可写，并且作为一个插口。将所有插口共享的全局 fileops 结构 socketops 连接到 f_ops 指向的 file 结构中。socketops 变量在编译时被初始化，如图15-15所示。

60-69 socreate 分配并初始化一个 socket 结构。如果 socreate 执行失败，将差错代码赋给 error，释放 file 结

成 员	值
fo_read	soo_read
fo_write	soo_write
fo_ioctl	soo_ioctl
fo_select	soo_select
fo_close	soo_close

图15-15 socketops : 插口
用全局 fileops 结构

构，清除存放描述符的数组元素。如果 `socreate` 执行成功，将 `f_data` 指向 `socket` 结构，建立插口和描述符之间的联系。通过 `*retval` 将 `fd` 返回给进程。`socket` 返回 0 或返回由 `socreate` 返回的差错代码。

15.6.1 `socreate` 函数

大多数插口系统调用至少被分成两个函数，与 `socket` 和 `socreate` 类似。第一个函数从进程那里获取需要的数据，调用第二个函数 `soxxx` 来完成功能处理，然后返回结果给进程。这种分成多个函数的做法是为了第二个函数能直接被基于内核的网络协议调用，如 NFS。`socreate` 的代码如图 15-16 所示。

```

43 socreate(dom, aso, type, proto)           - uipc_socket.c
44 int      dom;
45 struct socket **aso;
46 int      type;
47 int      proto;
48 {
49     struct proc *p = curproc;    /* XXX */
50     struct protosw *prp;
51     struct socket *so;
52     int      error;
53
54     if (proto)
55         prp = pffindproto(dom, proto, type);
56     else
57         prp = pffindtype(dom, type);
58     if (prp == 0 || prp->pr_usrreq == 0)
59         return (EPROTONOSUPPORT);
60     if (prp->pr_type != type)
61         return (EPROTOTYPE);
62     MALLOC(so, struct socket *, sizeof(*so), M_SOCKET, M_WAIT);
63     bzero((caddr_t) so, sizeof(*so));
64     so->so_type = type;
65     if (p->p_ucred->cr_uid == 0)
66         so->so_state = SS_PRIV;
67     so->so_proto = prp;
68     error =
69         (*prp->pr_usrreq) (so, PRU_ATTACH,
70                             (struct mbuf *) 0, (struct mbuf *) proto, (struct mbuf *) 0);
71     if (error) {
72         so->so_state |= SS_NOFDREF;
73         sofref(so);
74     }
75     *aso = so;
76     return (0);
77 }
```

uipc_socket.c

图 15-16 `socreate` 函数

43-52 `socreate` 共有四个参数：`dom`，请求的协议域(如，`PF_INET`)；`aso`，保存指向一个新的 `socket` 结构的指针；`type`，请求的插口类型(如，`SOCK_STREAM`)；`proto`，请求的协议。

1. 发现协议交换表

53-60 如果proto等于非0值，pffindproto查找进程请求的协议。如果proto等于0，pffindtype用由type指定的语义在指定域中查找一种协议。这两个函数均返回一个指向匹配协议的protosw结构的指针或空指针(参考第7.6节)。

2. 分配并初始化socket结构

61-66 socreate分配一个新的socket结构，并将结构内容全清成0，记录下type。如果调用进程有超级用户权限，则设置插口结构中的SS_PRIV标志。

3. PRU_ATTACH请求

67-69 在与协议无关的插口层中发送与协议有关的请求的第一个例子出现在socreate中。回想在第7.4节和图15-13中，so->so_proto->pr_usrreq是一个指向与插口so相关联的协议的用户请求函数指针。每一个协议均提供了一个这样的函数来处理从插口层来的通信请求。函数原型是：

```
int pr_usrreq(struct socket *so, int req, struct mbuf *mo, *m1, *m2);
```

第一个参数是一个指向相关插口的指针，req是一个标识请求的常数。后三个参数(m0, m1, m2)因请求不同而异。它们总是被作为一个mbuf结构指针传递，即使它们是其他的类型。在必要的时候，进行类似转换以避免编译器的警告。

图15-17列出了pr_usrreq函数提供的通信请求。每一个请求的语义起决于服务请求的协议。

请 求	参 数			描 述
	m0	m1	m2	
PRU_ABORT				异常终止每一个存在的连接
PRU_ACCEPT				等待并接受连接
PRU_ATTACH				产生了一个新的插口
PRU_BIND				绑定地址到插口
PRU_CONNECT				同地址建立关联或连接
PRU_CONNECT2				将两个插口连在一起
PRU_DETACH				插口被关闭
PRU_DISCONNECT				切断插口和另一地址间的关联
PRU_LISTEN				开始监听连接请求
PRU_PEERADDR				返回与插口关联的对方地址
PRU_RCVD				进程已收到一些数据
PRU_RCVOOB	buffer	flags		接收OOB数据
PRU_SEND	data	flags		发送正常数据
PRU_SENDOOB	data	address	control	发送OOB数据
PRU_SHUTDOWN		address	control	结束同另一地址的通信
PRU_SOCKADDR		buffer		返回与插口相关联的本地地址

图15-17 pr_usrreq 函数

PRU_CONNECT2请求只用于Unix域，它的功能是将两个本地插口连接起来。Unix的管道(pipe)就是通过这种方式来实现的。

4. 退出处理

70-77 回到socreate，函数将协议交换表连接到插口，发送PRU_ATTACH请求通知协议

已建立一个新的连接端点。该请求引起大多数协议，如 TCP和UDP，分配并初始化所有支持新的连接端点的数据结构。

15.6.2 超级用户特权

图15-18列出了要求超级用户权限的网络操作。

函 数	超级用户		描 述	参考图
	进 程	插 口		
in_control		•	分配接口地址、网络掩码、目的地址	图6-14
in_control		•	分配广播地址	图6-22
in_pcbbind	•		绑定到一个小于1024的Internet端口	图22-22
ifioctl	•		改变接口配置	图4-29
ifioctl	•		配置多播地址(见下面的说明)	图12-11
rip_usrreq	•		产生一个ICMP、IGMP或原始IP插口	图32-10
slopen	•		将一个SLIP设备与一个tty设备联系起来	图5-9

图15-18 Net/3中的超级用户特权

当多播 ioctl命令(SIOCADDMULTI和SIOCDELMULTI)是被IP_ADD_MEMBERSHIP和IP_DROP_MEMBERSHIP插口选项间接激活时，它可以被非超级用户访问。

在图15-18中，“进程”栏表示请求必须由超级用户进程来发起，“插口”栏表示请求必须是针对由超级用户产生的插口(也就是说，进程不需要超级用户权限，而只需有访问插口的权限，习题15.1)。在Net/3中，suser函数用来判断调用进程是否有超级用户权限，通过SS_PRIV标志来判断一个插口是否由超级用户进程产生。

因为rip_usrreq在用socreate产生插口后立即检查SS_PRIV标志，所以我们认为只有超级用户进程才能访问这个函数。

15.7 getsock和sockargs函数

这两个函数重复出现在插口系统调用中。getsock的功能是将描述符映射到一个文件表项，sockargs将进程传入的参数复制到内核中的一个新分配的mbuf中。这两个函数都要检查参数的正确性，如果参数不合法，则返回相应的非0差错代码。

图15-19列出了getsock函数的代码。

754-767 getsock函数利用fdp查找描述符fdes指定的文件表项，fdp是指向filedesc结构的指针。getsock将打开的文件结构指针赋给fpp，并返回，或者当出现下列情况时返回差错代码：描述符的值超过了范围而不是指向一个打开的文件；描述符没有同插口建立联系。

图15-20列出了sockargs函数的代码。

768-783 如图15-4中所描述的，sockargs将进程传给系统调用的参数的指针从进程复制到内核而不是复制指针指向的数据，这样做是因为每一个参数的语义只有相对应的系统调用才知道，而不是针对所有的系统调用。多个系统调用在调用sockargs复制参数指针后，将指针指向的数据从进程复制到内核中新分配的mbuf中。例如，sockargs将bind的第二个参

数指向的本地插口地址从进程复制到一个 mbuf中。

```

754 getsock(fdः, fdes, fpp)
755 struct filedesc *fdः;
756 int fdes;
757 struct file **fpp;
758 {
759     struct file *fp;
760     if ((unsigned) fdes >= fdः->fd_nfiles || 
761         (fp = fdः->fd_ofiles[fdes]) == NULL)
762         return (EBADF);
763     if (fp->f_type != DTTYPE_SOCKET)
764         return (ENOTSOCK);
765     *fpp = fp;
766     return (0);
767 }  
uipc_syscalls.c

```

图15-19 getsock 函数

```

768 sockargs(mp, buf, buflen, type)
769 struct mbuf **mp;
770 caddr_t buf;
771 int buflen, type;
772 {
773     struct sockaddr *sa;
774     struct mbuf *m;
775     int error;
776     if ((u_int) buflen > MLEN) {
777         return (EINVAL);
778     }
779     m = m_get(M_WAIT, type);
780     if (m == NULL)
781         return (ENOBUFS);
782     m->m_len = buflen;
783     error = copyin(buf, mtod(m, caddr_t), (u_int) buflen);
784     if (error)
785         (void) m_free(m);
786     else {
787         *mp = m;
788         if (type == MT_SONAME) {
789             sa = mtod(m, struct sockaddr *);
790             sa->sa_len = buflen;
791         }
792     }
793     return (error);
794 }  
uipc_syscalls.c

```

图15-20 sockargs 函数

如果数据不能存入一个 mbuf中或无法分配 mbuf，则 sockargs返回EINVAL或ENOBUFS。注意，这里使用的是标准的 mbuf而不是分组首部的 mbuf。copyin的功能是将数据从进程复制到mbuf中。copyin返回的最常见的差错是EACCES，它表示进程提供的地址不正确。

784-785 当出现差错时，丢弃 mbuf，并返回差错代码。如果没有差错，通过 mp返回指向 mbuf的指针，sockargs返回0。

786-794 如果type等于MT_SONAME，则进程传入的是一个 sockaddr结构。sockargs

将刚复制的参数的长度赋给内部长度变量 `sa_len`。这一点确保即使进程没有正确地初始化结构，结构内的大小也是正确的。

Net/3确实包含了一段代码来支持在 pre-4.3BSD Reno系统上编译的应用，这些应用的sockaddr结构中并没有 `sa_len` 字段，但是图15-20中没有显示这段代码。

15.8 bind系统调用

`bind`系统调用将一个本地的网络运输层地址和插口联系起来。一般来说，作为客户的进程并不关心它的本地地址是什么。在这种情况下，进程在进行通信之前没有必要调用 `bind`；内核会自动为其选择一个本地地址。

服务器进程则总是需要绑定到一个已知的地址上。所以，进程在接受连接 (TCP)或接收数据报(UDP)之前必须调用 `bind`，因为客户进程需要同已知的地址建立连接或发送数据报到已知的地址。

插口的外部地址由 `connect` 指定或由允许指定外部地址的写调用 (`sendto`或`sendmsg`) 指定。

图15-21列出了`bind`调用的代码。

```
70 struct bind_args {
71     int      s;
72     caddr_t name;
73     int      namelen;
74 };
75 bind(p, uap, retval)
76 struct proc *p;
77 struct bind_args *uap;
78 int      *retval;
79 {
80     struct file *fp;
81     struct mbuf *nam;
82     int      error;
83     if (error = getsock(p->p_fd, uap->s, &fp))
84         return (error);
85     if (error = sockargs(&nam, uap->name, uap->namelen, MT_SONAME))
86         return (error);
87     error = sobind((struct socket *) fp->f_data, nam);
88     m_freem(nam);
89     return (error);
90 }
```

uipc_syscalls.c

图15-21 `bind` 函数

70-82 `bind`调用的参数有(在`bind_args`结构中)：`s`，插口描述符；`name`，包含传输地址(如，`sockaddr_in`结构)的缓存指针；和`namelen`，缓存大小。

83-90 `getsock`返回描述符的`file`结构，`sockargs`将本地地址复制到`mbuf`中，`sobind`将进程指定的地址同插口联系起来。在`bind`返回`sobind`的结果之前，释放保存地址的`mbuf`。

从技术上讲，一个描述符，如 `s`，标识一个同 socket 结构相关联的`file`结构，而它本身并不是一个 socket 结构。将这种描述符看作插口是为了简化我们的讨论。

我们将在下面的讨论中经常看到这种模式：进程指定的参数被复制到 `mbuf`，必要时还要

进行处理，然后在系统调用返回之前释放 mbuf。虽然 mbuf 是为方便处理网络数据分组而设计的，但是将它们用作一般的动态内存分配机制也是有效的。

bind 说明的另一种模式是：许多系统调用不使用 `retval`。在第 15.4 节中我们已提到过，在 `syscall` 将控制交给相应的系统调用之前总是将 `retval` 清 0。如果 0 不是合适的返回值，系统调用并不需要修改 `retval`。

sobind 函数

如图 15-22 所示，`sobind` 是一个封装器，它给与插口相关联的协议发送 PRU_BIND 请求。

uipc_socket.c

```

78 sobind(so, nam)
79 struct socket *so;
80 struct mbuf *nam;
81 {
82     int      s = splnet();
83     int      error;
84
85     error =
86         (*so->so_proto->pr_usrreq) (so, PRU_BIND,
87                                     (struct mbuf *) 0, nam, (struct mbuf *) 0);
88     splx(s);
89     return (error);
90 }
```

uipc_socket.c

图 15-22 `sobind` 函数

78-89 `sobind` 发送 PRU_BIND 请求。如果请求成功，将本地地址 `nam` 同插口联系起来；否则，返回差错代码。

15.9 listen 系统调用

listen 系统调用的功能是通知协议进程准备接收插口上的连接请求，如图 15-23 所示。它同时也指定插口上可以排队等待的连接数的门限值。超过门限值时，插口层将拒绝进入的连接请求排队等待。当这种情况出现时，TCP 将忽略进入的连接请求。进程可以通过调用 accept（第 15.11 节）来得到队列中的连接。

```

91 struct listen_args {
92     int      s;
93     int      backlog;
94 };
95
96 listen(p, uap, retval)
97 struct proc *p;
98 struct listen_args *uap;
99 int      *retval;
100
101     struct file *fp;
102     int      error;
103
104     if (error = getsock(p->p_fd, uap->s, &fp))
105         return (error);
106     return (solisten((struct socket *) fp->f_data, uap->backlog));
107 }
```

uipc_syscalls.c

图 15-23 `listen` 系统调用

91-98 listen系统调用有两个参数：一个指定插口描述符；另一个指定连接队列门限值。
99-105 getsock返回描述符s的file结构，solisten将请求传递给协议层。

solisten函数

solisten函数发送PRU_LISTEN请求，并使插口准备接收连接，如图15-24所示。
90-109 在solisten发送PRU_LISTEN请求且pr_usrreq返回后，标识插口处于准备接收连接状态。如果当pr_usrreq返回时有连接正在连接队列中，则不设置SS_ACCEPTCONN标志。
计算存放进入连接的队列的最大值，并赋给so_qlimit。Net/3默认设置下限为0，上限为5(SOMAXCONN)条连接。

```

90 solisten(so, backlog)
91 struct socket *so;
92 int      backlog;
93 {
94     int      s = splnet(), error;
95
96     error =
97         (*so->so_proto->pr_usrreq) (so, PRU_LISTEN,
98                                     (struct mbuf *) 0, (struct mbuf *) 0, (struct mbuf *) 0);
99     if (error) {
100         splx(s);
101         return (error);
102     }
103     if (so->so_q == 0)
104         so->so_options |= SO_ACCEPTCONN;
105     if (backlog < 0)
106         backlog = 0;
107     so->so_qlimit = min(backlog, SOMAXCONN);
108     splx(s);
109 }                                         -uipc_socket.c

```

-uipc_socket.c

图15-24 solisten 函数

15.10 tsleep和wakeup函数

当一个在内核中执行的进程因为得不到内核资源而不能继续执行时，它就调用tsleep等待。tsleep的原型是：

```
int tsleep(caddr_t chan, int pri, char *mesg, int timeo);
```

tsleep的第一个参数chan，被称之为等待通道。它标志进程等待的特定资源或事件。许多进程能同时在同一个等待通道上睡眠。当资源可用或事件出现时，内核调用wakeup，并将等待通道作为唯一的参数传入。wakeup的原型是：

```
void wakeup(caddr_t chan);
```

所有等待在该通道上的进程均被唤醒，并被设置成运行状态。当每一个进程均恢复执行时，内核安排tsleep返回。

当进程被唤醒时，tsleep的第二个参数pri指定被唤醒进程的优先级。pri中还包括几个用于tsleep的可选的控制标志。通过设置pri中的PCATCH标志，当一个信号出现时，tsleep也返回。mesg是一个说明调用tsleep的字符串，它将被放在调用报文或ps的输出中。

*timeo*设置睡眠间隔的上限值，其单位是时钟滴答。

图15-25列出了`tsleep`的返回值。

因为所有等待在同一等待通道上的进程均被`wakeup`唤醒，所以我们总是看到在一个循环中调用`tsleep`。每一个被唤醒的进程在继续执行之前必须检查等待的资源是否可得到，因为另一个被唤醒的进程可能已经先一步得到了资源。如果仍然得不到资源，进程再调用`tsleep`等待。

<code>tsleep()</code>	描述
0	进程被一个匹配的 <code>wakeup</code> 唤醒
<code>EWOULDBLOCK</code>	进程在睡眠 <i>timeo</i> 个时钟滴答后，在匹配的 <code>wakeup</code> 调用之前被唤醒
<code>ERESTART</code>	在睡眠期间信号被进程处理，应重新启动挂起的系统调用
<code>EINTR</code>	在睡眠期间信号被进程处理，挂起的系统调用失败

图15-25 `tsleep` 的返回值

多个进程在一个插口上睡眠等待的情况是不多见的，所以，通常情况下，一次调用`wakeup`只有一个进程被内核唤醒。

关于睡眠和唤醒机制的详细讨论请参考 [Leffler et al. 1989]。

举例

多个进程在同一个等待通道上睡眠的一个例子是：让多个服务器进程读同一个 UDP插口。每一个服务器都调用`recvfrom`，并且只要没有数据可读就在`tsleep`中等待。当一个数据报到达插口时，插口层调用`wakeup`，所有等待进程均被放入运行队列。第一个运行的服务器读取了数据报而其他的服务器则再次调用`tsleep`。在这种情况下，不需要每一个数据报启动一个新的进程，就可将进入的数据报分发到多个服务器。这种技术同样可以用来处理 TCP的连接请求，只需让多个进程在同一个插口上调用`accept`。这种技术在[Comer and Stevens 1993]中描述。

15.11 `accept`系统调用

调用`listen`后，进程调用`accept`等待连接请求。`accept`返回一个新的描述符，指向一个连接到客户的新的插口。原来的插口 `s`仍然是未连接的，并准备接收下一个连接。如果`name`指向一个正确的缓存，`accept`就会返回对方的地址。

处理连接的细节由与插口相关联的协议来完成。对于TCP而言，当一条连接已经被建立(即，三次握手已经完成)时，就通知插口层。对于其他的协议，如 OSI的TP4，只要一个连接请求到达，`tsleep`就返回。当进程通过在插口上发送或接收数据来显式证实连接后，连接则算完成。

图15-26说明`accept`的实现。

```

106 struct accept_args {
107     int      s;
108     caddr_t  name;
109     int      *anamelen;
110 };
111 accept(p, uap, retval)
112 struct proc *p;
113 struct accept_args *uap;
114 int      *retval;

```

图15-26 `accept` 系统调用

```
115 {
116     struct file *fp;
117     struct mbuf *nam;
118     int namelen, error, s;
119     struct socket *so;
120
121     if (uap->name && (error = copyin((caddr_t) uap->aname, (caddr_t) &namelen, sizeof(namelen))) != 0)
122         return (error);
123     if (error = getsock(p->p_fd, uap->s, &fp))
124         return (error);
125     s = splnet();
126     so = (struct socket *) fp->f_data;
127     if ((so->so_options & SO_ACCEPTCONN) == 0) {
128         splx(s);
129         return (EINVAL);
130     }
131     if ((so->so_state & SS_NBIO) && so->so_qlen == 0) {
132         splx(s);
133         return (EWOULDBLOCK);
134     }
135     while (so->so_qlen == 0 && so->so_error == 0) {
136         if (so->so_state & SS_CANTRCVMORE) {
137             so->so_error = ECONNABORTED;
138             break;
139         }
140         if (error = tsleep((caddr_t) &so->so_timeo, PSOCK | PCATCH,
141                             netcon, 0)) {
142             splx(s);
143             return (error);
144         }
145     }
146     if (so->so_error) {
147         error = so->so_error;
148         so->so_error = 0;
149         splx(s);
150         return (error);
151     }
152     if (error = falloc(p, &fp, retval)) {
153         splx(s);
154         return (error);
155     }
156     { struct socket *aso = so->so_q;
157       if (soqremque(aso, 1) == 0)
158           panic("accept");
159       so = aso;
160     }
161     fp->f_type = DTTYPE_SOCKET;
162     fp->f_flag = FREAD | FWRITE;
163     fp->f_ops = &socketops;
164     fp->f_data = (caddr_t) so;
165     nam = m_get(M_WAIT, MT SONAME);
166     (void) soaccept(so, nam);
167     if (uap->name) {
168         if (namelen > nam->m_len)
169             namelen = nam->m_len;
170         /* SHOULD COPY OUT A CHAIN HERE */
171         if ((error = copyout(mtod(nam, caddr_t), (caddr_t) uap->name,
172                             (u_int) namelen)) != 0)
```

图15-26 (续)

```

173         error = copyout((caddr_t) & namelen,
174                           (caddr_t) uap->anamelen, sizeof(*uap->anamelen));
175     }
176     m_free(nam);
177     splx(s);
178     return (error);
179 }

```

uipc_syscalls.c

图15-26 (续)

106-114 accept有三个参数：s为插口描述符；name为缓存指针，accept将把外部主机的运输地址填入该缓存；anamelen是一个保存缓存大小的指针。

1. 验证参数

116-134 accept将缓存大小(*anamelen)赋给namelen，getsock返回插口的file结构。如果插口还没有准备好接收连接(即，还没有调用listen)，或已经请求了非阻塞的I/O，且没有连接被送入队列，则分别返回EINVAL或EWOULDBLOCK。

2. 等待连接

135-145 当出现下列情况时，while循环退出：有一条连接到达；出现差错；或插口不能再接收数据。当信号被捕获之后(tsleep返回EINTR)，accept并不自动重新启动。当协议层通过sonewconn将一条连接插入队列后，唤醒进程。

在循环内，进程在tsleep中等待，当有连接到达时，tsleep返回0。如果tsleep被信号中断或插口被设置成非阻塞，则accept返回EINTR或EWOULDBLOCK(图15-25)。

3. 异步差错

146-151 如果进程在睡眠期间出现差错，则将插口中的差错代码赋给accept中的返回码，清除插口中的差错码后，accept返回。

异步事件改变插口状态是比较常见的。协议处理层通过设置so_error或唤醒在插口上等待的所有进程来通知插口层插口状态的改变。因为这一点，插口层必须在每次被唤醒后检查so_error，查看是否在进程睡眠期间有差错出现。

4. 将插口同描述符相关联

152-164 falloc为新的连接分配一个描述符；调用soqremque将插口从接收队列中删除，放到描述符的file结构中。习题15.4讨论调用panic。

5. 协议处理

167-179 accept分配一个新的mbuf来保存外部地址，并调用soaccept来完成协议处理。在连接处理期间产生的新的插口的分配和排队在第15.12中描述。如果进程提供了一个缓存来接收外部地址，copyout将地址和地址长度分别从nam和namelen中复制给进程。如果有必要，copyout还可能将地址截掉，如果进程提供的缓存不够大。最后，释放mbuf，使能协议处理，accept返回。

因为仅仅分配了一个mbuf来存放外部地址，运输地址必须能放入一个mbuf中。因为Unix域地址是文件系统中的路径名(最长可达1023个字节)，所以要受到这个限制，但这对Internet域中的16字节长的sockaddr_in地址没有影响。第170行的注释说明可以通过分配和复制一个mbuf链的方式来去掉这个限制。

soaccept函数

soaccept函数通过协议层获得新的连接的客户地址，如图15-27所示。

```

184 soaccept(so, nam)
185 struct socket *so;
186 struct mbuf *nam;
187 {
188     int      s = splnet();
189     int      error;
190
191     if ((so->so_state & SS_NOFDREF) == 0)
192         panic("soaccept: !NOFDREF");
193     so->so_state &= ~SS_NOFDREF;
194     error = (*so->so_proto->pr_usrreq) (so, PRU_ACCEPT,
195                                         (struct mbuf *) 0, nam, (struct mbuf *) 0);
196     splx(s);
197 }

```

—uipc_socket.c

图15-27 soaccept 函数

184-197 soaccept 确保插口与一个描述符相连，并发送 PRU_ACCEPT 请求给协议。pr_usrreq 返回后，nam 中包含外部插口的名字。

15.12 sonewconn和soisconnected函数

从图15-26中可以看出，accept 等待协议层处理进入的连接请求，并且将它们放入 so_q 中。图15-28利用TCP来说明这个过程。

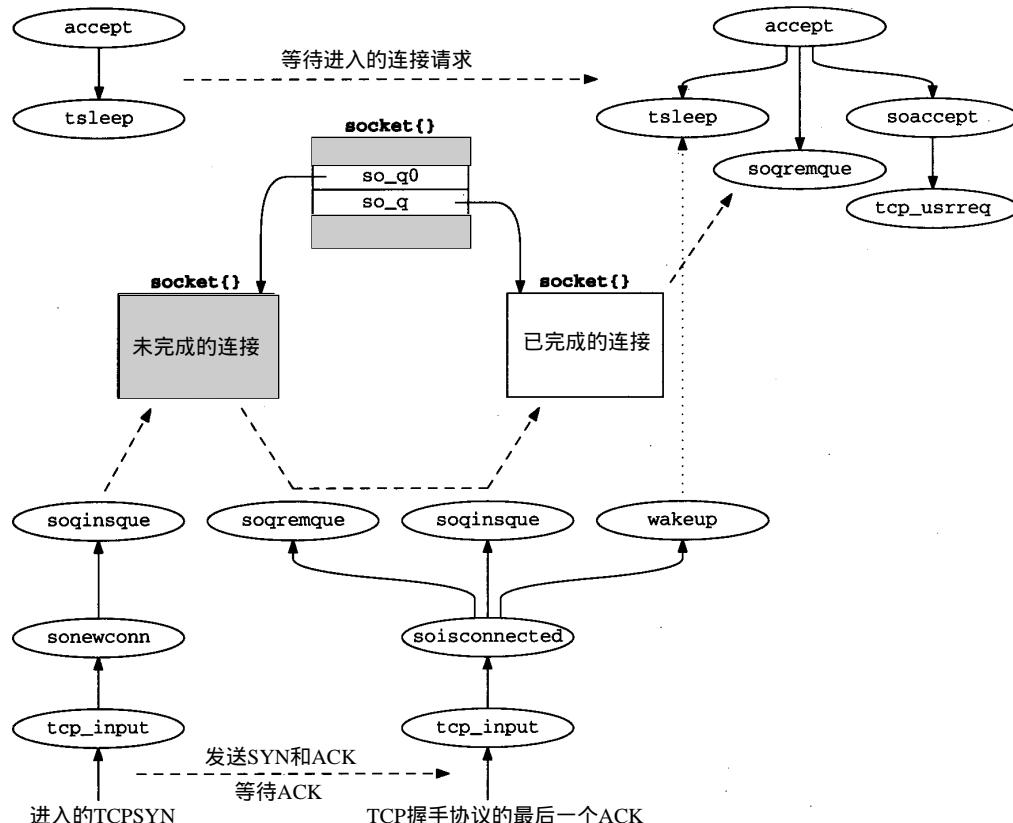


图15-28 处理进入的TCP连接

在图15-28的左上角，accept调用tsleep等待进入的连接。在左下角，tcp_input调用sonewconn为新的连接产生一个插口来处理进入的TCP SYN(图28-7)。sonewconn将产生的插口放入so_q0排队，因为三次握手还没有完成。

当TCP握手协议的最后一个ACK到达时，tcp_input调用soisconnected(图29-2)来更新产生的插口，并将它从so_q0中移到so_q中，唤醒所有调用accept等待进入的连接的进程。

图的右上角说明我们在图15-26中描述的函数。当tsleep返回时，accept从so_q中得到连接，发送PRU_ATTACH请求。插口同一个新的文件描述符建立了联系，accept也返回到调用进程。

图15-29显示了sonewconn函数。

```

123 struct socket *
124 sonewconn(head, connstatus)
125 struct socket *head;
126 int connstatus;
127 {
128     struct socket *so;
129     int soqueue = connstatus ? 1 : 0;
130
131     if (head->so_qlen + head->so_q0len > 3 * head->so_qlimit / 2)
132         return ((struct socket *) 0);
133     MALLOC(so, struct socket *, sizeof(*so), M_SOCKET, M_DONTWAIT);
134     if (so == NULL)
135         return ((struct socket *) 0);
136     bzero((caddr_t) so, sizeof(*so));
137     so->so_type = head->so_type;
138     so->so_options = head->so_options & ~SO_ACCEPTCONN;
139     so->so_linger = head->so_linger;
140     so->so_state = head->so_state | SS_NOFDREF;
141     so->so_proto = head->so_proto;
142     so->so_timeo = head->so_timeo;
143     so->so_pgid = head->so_pgid;
144     (void) soreserve(so, head->so_snd.sb_hiwat, head->so_rcv.sb_hiwat);
145     soqinsque(head, so, soqueue);
146     if ((*so->so_proto->pr_usrreq) (so, PRU_ATTACH,
147             (struct mbuf *) 0, (struct mbuf *) 0, (struct mbuf *) 0)) {
148         (void) sqremque(so, soqueue);
149         (void) free((caddr_t) so, M_SOCKET);
150         return ((struct socket *) 0);
151     }
152     if (connstatus) {
153         sorwakeup(head);
154         wakeup((caddr_t) & head->so_timeo);
155         so->so_state |= connstatus;
156     }
157 } 
```

uipc_socket2.c

图15-29 sonewconn 函数

123-129 协议层将head(指向正在接收连接的插口的指针)和connstatus(指示新连接的状态的标志)传给sonewconn。对于TCP而言，connstatus总是等于0。

对于TP4，connstatus总是等于SS_ISCONFIRMING。当一个进程开始从插口上接收或发送数据时隐式证实连接。

1. 限制进入的连接

130-131 当下面的不等式成立时，sonewconn不再接收任何连接：

$$\text{so_qlen} + \text{so_q0len} > \frac{3 \times \text{so_qlimit}}{2}$$

这个不等式为一直没有完成的连接提供了一个令人费解的因子，且该不等式确保listen(fd, 0)允许一条连接。有关这个不等式的详细情况请参考卷1的图18-23。

2. 分配一个新的插口

132-143 一个新的socket结构被分配和初始化。如果进程对处理接收连接状态的插口调用了setsockopt，则新产生的socket继承好几个插口选项，因为so_options、so_linger、so_pgid和sb_hiwat的值被复制到新的socket结构中。

3. 排队连接

144 在第129行的代码中，根据connstatus的值设置soqueue。如果soqueue为0（如，TCP连接），则将新的插口插入到so_q0中；若connstatus等于非0值，则将其插入到so_q中（如，TP4连接）。

4. 协议处理

145-150 发送PRU_ATTACH请求，启动协议层对新的连接的处理。如果处理失败，则将插口从队列中删除并丢弃，然后sonewconn返回一个空指针。

5. 唤醒进程

151-157 如果connstatus等于非0值，所有在accept中睡眠或查询插口的可读性的进程均被唤醒。将connstatus对so_state执行或操作。TCP协议从来不会执行这段代码，因为对TCP而言，connstatus总是等于0。

某些将进入的连接首先插入so_q0队列中的协议在连接建立阶段完成时调用soisconnected，如TCP。对于TCP，当第二个SYN被应答时，就出现这种情况。

图15-30显示了soisconnected的代码。

```

78 soisconnected(so)                                     kern/uipc_socket2.c
79 struct socket *so;
80 {
81     struct socket *head = so->so_head;
82     so->so_state &= ~(SS_ISCONNECTING | SS_ISDISCONNECTING | SS_ISCONFIRMING);
83     so->so_state |= SS_ISCONNECTED;
84     if (head && soqremque(so, 0)) {
85         soqinsque(head, so, 1);
86         sorwakeups(head);
87         wakeup((caddr_t) & head->so_timeo);
88     } else {
89         wakeup((caddr_t) & so->so_timeo);
90         sorwakeups(so);
91         sowakeups(so);
92     }
93 }
```

kern/uipc_socket2.c

图15-30 soisconnected 函数

6. 排队未完成的连接

78-87 通过修改插口的状态来表明连接已经完成。当对进入的连接调用soisconnected

(即，本地进程正在调用 accept)时，head为非空。

如果 soqremque 返回1，就将插口放入 so_q 队列，sorwakeup 唤醒通过调用 select 测试插口的可读性来监控插口上连接到达的进程。如果进程在 accept 中因等待连接而阻塞，则 wakeup 使得相应的 tsleep 返回。

7. 唤醒等待新连接的进程

88-93 如果 head 为空，就不需要调用 soqremque，因为进程用 connect 系统调用初始化连接，且插口不在队列中。如果 head 非空，且 soqremque 返回 0，则插口已经在 so_q 队列中。在某些协议中，如 TP4，就出现这种情况，因为在 TP4 中，连接完成之前就已插入到 so_q 队列中。wakeup 唤醒所有阻塞在 connect 中的进程，sorwakeup 和 sowakeup 负责唤醒那些调用 select 等待连接完成的进程。

15.13 connect 系统调用

服务器进程调用 listen 和 accept 系统调用等待远程进程初始化连接。如果进程想自己初始化一条连接(即客户端)，则调用 connect。

对于面向连接的协议如 TCP，connect 建立一条与指定的外部地址的连接。如果进程没有调用 bind 来绑定地址，则内核选择并且隐式地绑定一个地址到插口。

对于无连接协议如 UDP 或 ICMP，connect 记录外部地址，以便发送数据报时使用。任何以前的外部地址均被新的地址所代替。

图15-31显示了 UDP 或 TCP 调用 connect 时涉及到的函数。

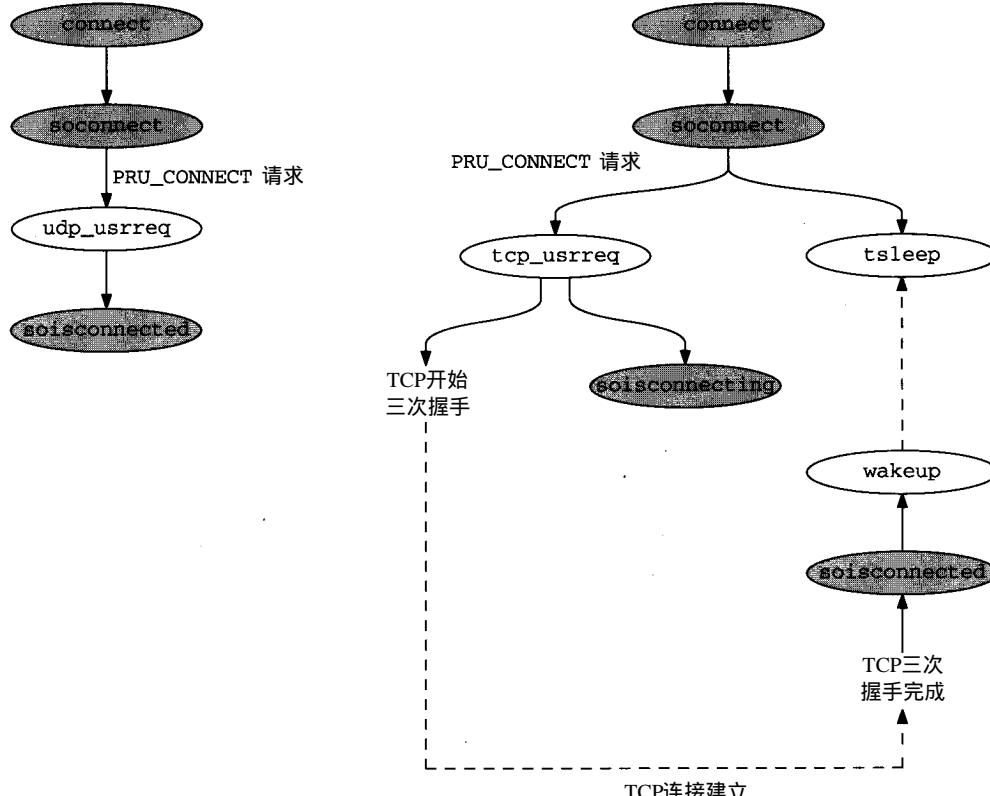


图15-31 connect 处理过程

图的左边说明 connect 如何处理无连接协议，如 UDP。在这种情况下，协议层调用 soisconnected 后 connect 系统调用立即返回。

图的右边说明 connect 如何处理面向连接的协议，如 TCP。在这种情况下，协议层开始建立连接，调用 soisconnecting 指示连接将在某个时候完成。如果插口是非阻塞的，soconnect 调用 tsleep 等待连接完成。对于 TCP，当三次握手完成时，协议层调用 soisconnected 将插口标识为已连接，然后调用 wakeup 唤醒等待的进程，从而完成 connect 系统调用。

图15-32列出了connect系统调用的代码。

```

180 struct connect_args {
181     int      s;
182     caddr_t name;
183     int      namelen;
184 };
185 connect(p, uap, retval)
186 struct proc *p;
187 struct connect_args *uap;
188 int      *retval;
189 {
190     struct file *fp;
191     struct socket *so;
192     struct mbuf *nam;
193     int      error, s;
194     if (error = getsock(p->p_fd, uap->s, &fp))
195         return (error);
196     so = (struct socket *) fp->f_data;
197     if ((so->so_state & SS_NBIO) && (so->so_state & SS_ISCONNECTING))
198         return (EALREADY);
199     if (error = sockargs(&nam, uap->name, uap->namelen, MT SONAME))
200         return (error);
201     error = soconnect(so, nam);
202     if (error)
203         goto bad;
204     if ((so->so_state & SS_NBIO) && (so->so_state & SS_ISCONNECTING)) {
205         m_freem(nam);
206         return (EINPROGRESS);
207     }
208     s = splnet();
209     while ((so->so_state & SS_ISCONNECTING) && so->so_error == 0)
210         if (error = tsleep((caddr_t) & so->so_timeo, PSOCK | PCATCH,
211                             netcon, 0))
212             break;
213     if (error == 0) {
214         error = so->so_error;
215         so->so_error = 0;
216     }
217     splx(s);
218 bad:
219     so->so_state &= ~SS_ISCONNECTING;
220     m_freem(nam);
221     if (error == ERESTART)
222         error = EINTR;
223     return (error);
224 }
```

uipc_syscalls.c

图15-32 connect 系统调用

180-188 connect的三个参数(在connect_args结构中)是：s为插口描述符；name是一个指针，指向存放外部地址的缓存；namelen为缓存的长度。

189-200 getsock获取插口描述符对应的file结构。可能已有连接请求在非阻塞的插口上，若出现这种情况，则返回EALREADY。函数sockargs将外部地址从进程复制到内核。

1. 开始连接处理

201-208 连接是从调用soconnect开始的。如果soconnect报告差错出现，connect跳转到bad。如果soconnect返回时连接还没有完成且使能了非阻塞的I/O，则立即返回EINPROGRESS以免等待连接完成。因为通常情况下，建立连接要涉及同远程系统交换几个分组，因而这个过程可能需要一些时间才能完成。如果连接没完成，则下次对connect调用就返回EALREADY。当连接完成时，soconnect返回EISCONN。

2. 等待连接建立

208-217 while循环直到连接已建立或出现差错时才退出。splnet防止connect在测试插口状态和调用tsleep之间错过wakeup。循环完成后，error包含0、tsleep中的差错代码或插口中的差错代码。

218-224 清除SS_ISCONNECTING标志，因为连接已完成或连接请求已失败。释放存储外部地址的mbuf，返回差错代码。

15.13.1 soconnect函数

soconnect函数确保插口处于正确的连接状态。如果插口没有连接或连接没有被挂起，则连接请求总是正确的。如果插口已经连接或连接正等待处理，则新的连接请求将被面向连接的协议(如TCP)拒绝。对于无连接协议，如UDP，多个连接是允许的，但是每一个新的请求

```

198 soconnect(so, nam)                                     uipc_socket.c
199 struct socket *so;
200 struct mbuf *nam;
201 {
202     int      s;
203     int      error;
204     if (so->so_options & SO_ACCEPTCONN)
205         return (EOPNOTSUPP);
206     s = splnet();
207     /*
208      * If protocol is connection-based, can only connect once.
209      * Otherwise, if connected, try to disconnect first.
210      * This allows user to disconnect by connecting to, e.g.,
211      * a null address.
212     */
213     if (so->so_state & (SS_ISCONNECTED | SS_ISCONNECTING) &&
214         ((so->so_proto->pr_flags & PR_CONNREQUIRED) ||
215          (error = sodisconnect(so))))
216         error = EISCONN;
217     else
218         error = (*so->so_proto->pr_usrreq) (so, PRU_CONNECT,
219                                         (struct mbuf *) 0, nam, (struct mbuf *) 0);
220     splx(s);
221     return (error);
222 }
```

uipc_socket.c

图15-33 soconnect 函数

中的外部地址会取代原来的外部地址。

图15-33列出了soconnect函数的代码。

198-222 如果插口被标识准备接收连接，则 soconnect返回EOPNOTSUPP，因为如果已经对插口调用了listen，则进程不能再初始化连接。如果协议是面向连接的，且一条连接已经被初始化，则返回 EISCONN。对于无连接协议，任何已有的同外部地址的联系都被 sodisconnect切断。

PRU_CONNECT请求启动相应的协议处理来建立连接或关联。

15.13.2 切断无连接插口和外部地址的关联

对于无连接协议，可以通过调用 connect，并传入一个不正确的name参数，如指向内容为全0的结构指针或大小不对的结构，来丢弃同插口相关联的外部地址。 sodisconnect删除同插口相关联的外部地址， PRU_CONNECT返回差错代码，如 EAFNOSUPPORT或EADDRNOTAVAIL，留下没有外部地址的插口。这种方式虽然有点晦涩，但却是一种比较有用的断连方式，在无连接插口和外部地址之间断连，而不是替换。

15.14 shutdown系统调用

shutdown系统调用关闭连接的读通道、写通道或读写通道，如图 15-34所示。对于读通道，shutdown丢弃所有进程还没有读走的数据以及调用 shutdown之后到达的数据。对于写通道，shutdown使协议作相应的处理。对于 TCP，所有剩余的数据将被发送，发送完成后发送FIN。这就是TCP的半关闭特点(参考卷1的第18.5节)。

为了删除插口和释放描述符，必须调用 close。可以在没有调用 shutdown的情况下，直接调用close。同所有描述符一样，当进程结束时，内核将调用 close，关闭所有还没有被关闭的插口。

```

550 struct shutdown_args {
551     int      s;
552     int      how;
553 };
554 shutdown(p, uap, retval)
555 struct proc *p;
556 struct shutdown_args *uap;
557 int      *retval;
558 {
559     struct file *fp;
560     int      error;
561     if (error = getsock(p->p_fd, uap->s, &fp))
562         return (error);
563     return (soshutdown((struct socket *) fp->f_data, uap->how));
564 }

```

uipc_syscalls.c

图15-34 shutdown 系统调用

550-557 在shutdown_args结构中，s为插口描述符，how指明关闭连接的方式。图 15-35列出了how和how++(在图15-36中用到的)的期望值。

how	how++	描 述
0	<i>FREAD</i>	关闭连接的读通道
1	<i>FWRITE</i>	关闭连接的写通道
2	<i>FREAD/FWRITE</i>	关闭连接的读写通道

图15-35 shutdown 系统调用选项

注意，在how和常数*FREAD*和*FWRITE*之间有一种隐含的数值关系。

558-564 shutdown是函数soshutdown的包装函数(wrapper function)。由getsock返回与描述符相关联的插口，调用soshutdown，并返回其值。

soshutdown和sorflush函数

关闭连接的读通道是由插口层调用 sorflush处理的，写通道的关闭是由协议层的PRU_SHUTDOWN请求处理的。soshutdown函数如图15-36所示。

```
720 soshutdown(so, how)
721 struct socket *so;
722 int      how;
723 {
724     struct protosw *pr = so->so_proto;
725
726     how++;
727     if (how & FREAD)
728         sorflush(so);
729     if (how & FWRITE)
730         return ((*pr->pr_usrreq) (so, PRU_SHUTDOWN,
731             (struct mbuf *) 0, (struct mbuf *) 0, (struct mbuf *) 0));
731     return (0);
732 }
```

— *uipc_socket.c*

图15-36 soshutdown 函数

720-732 如果是关闭插口的读通道，则sorflush丢弃插口接收缓存中的数据，禁止读连接(如图15-37所示)。如果是关闭插口的写通道，则给协议发送PRU_SHUTDOWN请求。

733-747 进程等待给接收缓存加锁。因为SB_NOINTR被设置，所以当中断出现时，sblock并不返回。在修改插口状态时，splimp阻塞网络中断和协议处理，因为协议层在接收到进入的分组时可能要访问接收缓存。

socantrcvmore标识插口拒绝接收进入的分组。将sockbuf结构保存在asb中，当splx恢复中断后，要使用asb。调用bzero清除原始的sockbuf结构，使得接收队列为空。

释放控制mbuf

748-751 当shutdown被调用时，存储在接收队列中的控制信息可能引用了一些内核资源。通过sockbuf结构的副本中的sb_mb仍然可以访问mbuf链。

如果协议支持访问权限，且注册了一个dom_dispose函数，则调用该函数来释放这些资源。

在Unix域中，用控制报文在进程间传递描述符是可能的。这些报文包含一些引用计数的数据结构的指针。dom_dispose函数负责去掉这些引用，如果必要，还释放相关的数据缓存以避免产生一些未引用的结构和导致内存漏洞。有关在 Unix域内传递文件描述符的细节请参考[Stevens 1990]和[Leffler et al. 1989]。

```

733 sorflush(so)                                     uipc_socket.c
734 struct socket *so;
735 {
736     struct sockbuf *sb = &so->so_rcv;
737     struct protosw *pr = so->so_proto;
738     int s;
739     struct sockbuf asb;

740     sb->sb_flags |= SB_NOINTR;
741     (void) sblock(sb, M_WAITOK);
742     s = splimp();
743     socantrcvmore(so);
744     sbunlock(sb);
745     asb = *sb;
746     bzero((caddr_t) sb, sizeof(*sb));
747     splx(s);

748     if (pr->pr_flags & PR_RIGHTS && pr->pr_domain->dom_dispose)
749         (*pr->pr_domain->dom_dispose) (asb.sb_mb);
750     sbrelease(&asb);
751 }

```

*uipc_socket.c*图15-37 *sorflush* 函数

当sbrelease释放接收队列中的所有mbuf时，丢弃所有调用shutdown时还没有被处理的数据。

注意，连接的读通道的关闭完全由插口层来处理（习题15.6），连接的写通道的关闭通过发送PRU_SHUTDOWN请求交由协议处理。TCP协议收到PRU_SHUTDOWN请求后，发送所有排队的数据，然后发送一个FIN来关闭TCP连接的写通道。

15.15 close系统调用

close系统调用能用来关闭各类描述符。当fd是引用对象的最后的描述符时，与对象有关的close函数被调用：

```
error = (*fp->f_ops->fo_close)(fp,p);
```

如图15-13所示，插口的fp->f_ops->fo_close是soo_close函数。

15.15.1 soo_close函数

soo_close函数是soclose函数的封装器，如图15-38所示。

```

152 soo_close(fp, p)                               sys_socket.c
153 struct file *fp;
154 struct proc *p;
155 {
156     int error = 0;

157     if (fp->f_data)
158         error = soclose((struct socket *) fp->f_data);
159     fp->f_data = 0;
160     return (error);
161 }

```

*sys_socket.c*图15-38 *soo_close* 函数

15.2-161 如果socket结构与file相关联，则调用soclose，清除f_data，返回已出现的差错。

15.15.2 soclose函数

soclose函数取消插口上所有未完成的连接（即，还没有完全被进程接受的连接），等待数据被传输到外部系统，释放不需要的数据结构。

soclose函数的代码如图15-39所示。

```

130 struct socket *so;
131 {
132     int      s = splnet();           /* conservative */
133     int      error = 0;
134
135     if (so->so_options & SO_ACCEPTCONN) {
136         while (so->so_q0)
137             (void) soabort(so->so_q0);
138         while (so->so_q)
139             (void) soabort(so->so_q);
140     }
141     if (so->so_pcb == 0)
142         goto discard;
143     if (so->so_state & SS_ISCONNECTED) {
144         if ((so->so_state & SS_ISDISCONNECTING) == 0) {
145             error = sodisconnect(so);
146             if (error)
147                 goto drop;
148         }
149         if (so->so_options & SO_LINGER) {
150             if ((so->so_state & SS_ISDISCONNECTING) &&
151                 (so->so_state & SS_NBIO))
152                 goto drop;
153             while (so->so_state & SS_ISCONNECTED)
154                 if (error = tsleep((caddr_t) & so->so_timeo,
155                                     PSOCK | PCATCH, netcls, so->so_linger))
156                     break;
157     }
158 drop:
159     if (so->so_pcb) {
160         int      error2 =
161         (*so->so_proto->pr_usrreq) (so, PRU_DETACH,
162                                     (struct mbuf *) 0, (struct mbuf *) 0, (struct mbuf *) 0);
163         if (error == 0)
164             error = error2;
165     }
166 discard:
167     if (so->so_state & SS_NOFDREF)
168         panic("soclose: NOFDREF");
169     so->so_state |= SS_NOFDREF;
170     sofree(so);
171     splx(s);
172     return (error);
173 }
```

uipc_socket.c

图15-39 soclose 函数

1. 丢弃未完成的连接

129-141 如果插口正在接收连接，`soclose`遍历两个连接队列，并且调用`soabort`取消每一个挂起的连接。如果协议控制块为空，则协议已同插口分离，`soclose`跳转到`discard`进行退出处理。

`soabort`发送`PRU_ABORT`请求给协议，并返回结果。本书中没有介绍`soabort`的代码。图23-38和图30-7讨论了UDP和TCP如何处理`PRU_ABORT`请求。

2. 断开已建立的连接或关联

142-157 如果插口没有同任何外部地址相连接，则跳转到`drop`处继续执行。否则，必须断开插口与对等地址之间的连接。如果断连没有开始，则`sodisconnect`启动断连进程。如果设置了`SO_LINGER`插口选项，`soclose`可能要等到断连完成后才返回。对于一个非阻塞的插口，从来不需要等待断连完成，所以在这种情况下，`soclose`立即跳转到`drop`。否则，连接终止正在进行且`SO_LINGER`选项指示`soclose`必须等待一段时间才能完成操作。直到出现下列情况时`while`才退出：断连完成；拖延时间(`so_linger`)到；或进程收到了一个信号。

如果滞留时间被设为0，`tsleep`仅当断连完成(也许因为一个差错)或收到一个信号时才返回。

3. 释放数据结构

158-173 如果插口仍然同协议相连，则发送`PRU_DETACH`请求断开插口与协议的联系。最后，插口被标记为同任何描述符没有关联，这意味着可以调用`sofree`释放插口。

`sofree`函数代码如图15-40所示。

```
110 sofree(so)
111 struct socket *so;
112 {
113     if (so->so_pcb || (so->so_state & SS_NOFDREF) == 0)
114         return;
115     if (so->so_head) {
116         if (!soqremque(so, 0) && !soqremque(so, 1))
117             panic("sofree dq");
118         so->so_head = 0;
119     }
120     sbrelease(&so->so_snd);
121     sorflush(so);
122     FREE(so, M_SOCKET);
123 }
```

uipc_socket.c

```
110 sofree(so)
111 struct socket *so;
112 {
113     if (so->so_pcb || (so->so_state & SS_NOFDREF) == 0)
114         return;
115     if (so->so_head) {
116         if (!soqremque(so, 0) && !soqremque(so, 1))
117             panic("sofree dq");
118         so->so_head = 0;
119     }
120     sbrelease(&so->so_snd);
121     sorflush(so);
122     FREE(so, M_SOCKET);
123 }
```

uipc_socket.c

图15-40 `sofree` 函数

4. 如果插口仍在用则返回

110-114 如果仍然有协议同插口相连，或如果插口仍然同描述符相连，则`sofree`立即返回。

5. 从连接队列中删除插口

115-119 如果插口仍在连接队列上(`so_head`非空)，则插口的队列应该为空。如果不空，则插口代码和内核`panic`中有差错。如果队列为空，清除`so_head`。

6. 释放发送和接收队列中的缓存

120-123 sorelease 释放发送队列中的所有缓存，sorflush 释放接收队列中的所有缓存。最后，释放插口本身。

15.16 小结

本章中我们讨论了所有与网络操作有关的系统调用。描述了系统调用机制，并且跟踪系统调用直到它们通过 pr_usrreq 函数进入协议处理层。

在讨论插口层时，我们避免涉及地址格式、协议语义或协议实现等问题。在接下来的章节中，我们将通过协议处理层中的 Internet 协议的实现将链路层处理和插口层处理联系在一起。

习题

- 15.1 一个没有超级用户权限的进程怎样才能获取对超级用户进程产生的插口的访问权？
- 15.2 一个进程怎样才能判断它提供给 accept 的 sockaddr 缓存是不是太小以至不能存放调用返回的外部地址？
- 15.3 IPv6 的插口有一个特点：使 accept 和 recvfrom 返回一个 128 bit 的 IPv6 地址的数组作为源路由，而不是仅返回一个对等地址。因为数组不能存放在一个 mbuf 中，所以修改 accept 和 recvfrom，使得它们能够处理协议层来的 mbuf 链而不是仅仅一个 mbuf。如果协议在 mbuf 簇中返回一个数组而不是一个 mbuf 链，已有的代码仍然能正常工作吗？
- 15.4 为什么在图 15-26 中当 soqremque 返回一个空指针时要调用 panic？
- 15.5 为什么 sorflush 要复制接收缓存？
- 15.6 在 sorflush 将插口的接收缓存清 0 后，如果还有数据到达会出现什么现象？在做这个习题之前请阅读第 16 章的内容。

第16章 插 口 I/O

16.1 引言

本章讨论有关从网络连接上读写数据的系统调用，分三部分介绍。

第一部分介绍四个用来发送数据的系统调用：write、writev、sendto和sendmsg。第二部分介绍四个用来接收数据的系统调用：read、readv、recvfrom和recvmsg。第三部分介绍select系统调用，select调用的作用是监控通用描述符和特殊描述符(插口)的状态。

插口层的核心是两个函数：sosend和soreceive。这两个函数负责处理所有插口层和协议层之间的I/O操作。在后续的章节中我们将看到，因为这两个函数要处理插口层和各种类型的协议之间的I/O操作，使得这两个函数特别长和复杂。

16.2 代码介绍

图16-1中列出了本章后续章节要用到的三个头文件和四个C源文件。

文 件 名	说 明
sys/socket.h	插口API中的结构和宏定义
sys/socketvar.h	socket结构和宏定义
sys/uio.h	uio结构定义
kern/uipc_syscalls.c	socket系统调用
kern/uipc_socket.c	插口层处理
kern/sys_generic.c	select系统调用
kern/sys_socket.c	select对插口的处理

图16-1 本章涉及的头文件和C源文件

全局变量

图16-2列出了三个全局变量。前两个变量由select系统调用使用，第三个变量控制分配给插口的存储器大小。

变 量	数据类型	说 明
selwait	int	select调用的等待通道
nseccoll	int	避免select调用中出现竞争的标志
sb_max	u_long	插口发送或接收缓存的最大字节数

图16-2 本章涉及的全局变量

16.3 插口缓存

从第15.3节我们已经知道，每一个插口都有一个发送缓存和一个接收缓存。缓存的类型为

sockbuf。图16-3中列出了sockbuf结构的定义(重复图15-5)。

```

72     struct sockbuf {
73         u_long    sb_cc;           /* actual chars in buffer */
74         u_long    sb_hiwat;        /* max actual char count */
75         u_long    sb_mbcnt;        /* chars of mbufs used */
76         u_long    sb_mbmax;        /* max chars of mbufs to use */
77         long      sb_lowat;        /* low water mark */
78         struct mbuf *sb_mb;        /* the mbuf chain */
79         struct selinfo sb_sel;    /* process selecting read/write */
80         short     sb_flags;        /* Figure 16.5 */
81         short     sb_timeo;        /* timeout for read/write */
82     } so_rcv, so_snd;

```

socketvar.h

图16-3 sockbuf 结构

72-78 每一个缓存均包含控制信息和指向存储数据的 mbuf链的指针。sb_mb指向mbuf链的第一个mbuf，sb_cc的值等于存储在mbuf链中的数据字节数。sb_hiwat和sb_lowat用来调整插口的流控算法。sb_mbcnt等于分配给缓存中的所有mbuf的存储器数量。

在前面的章节中提到过每一个 mbuf可存储0~2048个字节的数据(如果使用了外部簇)。sb_mbmax是分配给插口mbuf缓存的存储器数量的上限。默认的上限在socket系统调用中发送PRU_ATTACH请求时由协议设置。只要内核要求的每个插口缓存的大小不超过 262,144个字节的限制(sb_max)，进程就可以修改缓存的上限和下限。流控算法将在 16.4节和16.8节中讨论。图16-4显示了Internet协议的默认设置。

协 议	so_snd			so_rcv		
	sb_hiwat	sb_lowat	sb_mbmax	sb_hiwat	sb_lowat	sb_mbmax
UDP	9×1024	2048(忽略)	2×sb_hiwat	40×(1024+16)	1	2×sb_hiwat
TCP	8×1024	2048	2×sb_hiwat	8×1024	1	2×sb_hiwat
原始IP						
ICMP	8×1024	2048(忽略)	2×sb_hiwat	8×1024	1	2×sb_hiwat
IGMP						

图16-4 Internet协议的默认的插口缓存限制

因为每一个进入的 UDP报文的源地址同数据一起排队，所以 UDP协议的sb_hiwat的默认值设置为能容纳40个1K字节长的数据报和相应的sockaddr_in结构(每个16字节)。

79 sb_sel是一个用来实现select系统调用的selinfo结构(16.13节)。

80 图16-5列出了sb_flags的所有可能的值。

sb-flags	说 明
<i>SB_LOCK</i>	一个进程已经锁定了插口缓存
<i>SB_WANT</i>	一个进程正在等待给插口缓存加锁
<i>SB_WAIT</i>	一个进程正在等待接收数据或发送数据所需的缓存
<i>SB_SEL</i>	一个或多个进程正在选择这个缓存
<i>SB_ASYNC</i>	为这个缓存产生异步I/O信号
<i>SB_NOINTR</i>	信号不取消加锁请求
<i>SB_NOTIFY</i>	(<i>SB_WAIT</i> <i>SB_AEL</i> <i>SB_ASYNC</i>) 一个进程正在等待缓存的变化，如果缓存发生任何改变，用 wakeup通知该进程

图16-5 sb_flags 的值

8.1-8.2 `sb_timeo` 用来限制一个进程在读写调用中被阻塞的时间，单位为时钟滴答 (tick)。默认值为 0，表示进程无限期的等待。`SO_SNDFTIMEO` 和 `SO_RCVTIMEO` 插口选项可以改变或读取 `sb_timeo` 的值。

插口宏和函数

有许多宏和函数用来管理插口的发送和接收缓存。图 16-6 中列出了与缓存加锁和同步有关的宏和函数。

名 称	说 明
<code>sblock</code>	申请给 <code>sb</code> 加锁，如果 <code>wf</code> 等于 <code>M_WAITOK</code> ，则进程睡眠等待加锁；否则，如果不能立即给缓存加锁，就返回 <code>EWOULDBLOCK</code> 。如果进程睡眠被一个信号中断，则返回 <code>EINTR</code> 或 <code>ERESTART</code> ；否则返回 0 <code>int sblock(struct sockbuf *sb, intf);</code>
<code>sbunlock</code>	释放加在 <code>sb</code> 上的锁。所有等待给 <code>sb</code> 加锁的进程被唤醒 <code>void sbunlock(struct sockbuf *sb);</code>
<code>sbwait</code>	调用 <code>tsleep</code> 等待 <code>sb</code> 上的协议动作。返回 <code>tsleep</code> 返回的结果 <code>int sbwait(struct sockbuf *sb);</code>
<code>sowakeup</code>	通知插口有协议动作出现。唤醒所有匹配的调用 <code>sbwait</code> 的进程或在 <code>sb</code> 上调用 <code>tsleep</code> 的进程 <code>void sowakeup(struct socket *sb, struct sockbuf *sb);</code>
<code>sorwakeup</code>	唤醒等待 <code>sb</code> 上的读事件的进程，如果进程请求了 I/O 事件的异步通知，则还应给该进程发送 <code>SIGIO</code> 信号 <code>void sorwakeup(struct socket *sb);</code>
<code>sowwakeup</code>	唤醒等待 <code>sb</code> 上的写事件的进程，如果进程请求了 I/O 事件的异步通知，则还应给该进程发送 <code>SIGIO</code> 信号 <code>void sowwakeup(struct socket *sb);</code>

图 16-6 与缓存加锁和同步有关的宏和函数

图 16-7 显示了设置插口资源限制、往缓存中写数据和从缓存中删除数据的宏和函数。在该表中，`m`、`m0`、`n` 和 `control` 都是指向 `mbuf` 链的指针。`sb` 指向插口的发送或接收缓存。

名 称	说 明
<code>sbspace</code>	<code>sb</code> 中可用的空间 (字节数)： <code>min(sb_hiwat - sb_cc), (sb_mbmax - sb_mbcnt)</code> <code>long sbspace(struct sockbuf *sb);</code>
<code>sballoc</code>	将 <code>m</code> 加到 <code>sb</code> 中，同时修改 <code>sb</code> 中的 <code>sb_cc</code> 和 <code>sb_mbcnt</code> <code>void sballoc(struct sockbuf *sb, struct mbuf *m);</code>
<code>sbfree</code>	从 <code>sb</code> 中删除 <code>m</code> ，同时修改 <code>sb</code> 中的 <code>sb_cc</code> 和 <code>sb_mbcnt</code> <code>int sbfree(struct sockbuf *sb, struct mbuf *m);</code>
<code>sbappend</code>	将 <code>m</code> 中的 <code>mbuf</code> 加到 <code>sb</code> 的最后面 <code>int sbappend(struct sockbuf *sb, struct mbuf *m);</code>
<code>sbappendrecord</code>	将 <code>m0</code> 中的记录加到 <code>sb</code> 的最后面。调用 <code>sbcompress</code> <code>int sbappendrecord(struct sockbuf *sb, struct mbuf *m0);</code>

图 16-7 与插口缓存分配与操作有关的宏和函数

名 称	说 明
sbappendaddr	将asa的地址放入一个mbuf。将地址、control和m0连接成一个mbuf链，并将该链放在sb的最后面 <pre>int abappendaddr(struct sb, struct sockaddr*, struct mbuf m0, struct mbuf control);</pre>
sbappendcontrol	将control和m0连接成一个mbuf链，并将该链放在sb的最后面 <pre>int abappendcontrol(struct sb, struct mbuf m0, struct mbuf control);</pre>
sbinsertoob	将m0插在没有带外数据的sb的第一个记录的前面 <pre>int abinsertoob(struct sockbuf* sb, struct mbuf m0);</pre>
sbcompress	将m合并到n中并压缩没用的空间 <pre>void abcompress(struct sockbuf* sb, struct mbuf m, struct mbuf n);</pre>
sbdrop	删除sb的前len个字节 <pre>void sbdrop(struct sockbuf* sb, int len);</pre>
sbdroprecord	删除sb的第一个记录，将下一个记录移作第一个记录 <pre>void sbdroprecord(struct sockbuf* sb);</pre>
sbrelease	调用sbflush释放sb中所有的mbuf。并将sb_hiwat和sb_mbmax清0 <pre>void sbrelease(struct sockbuf* sb);</pre>
sbflush	释放sb中的所有mbuf <pre>void sbflush(struct sockbuf* sb);</pre>
soreserve	设置插口缓存高、低水位标记 (high-water and low-water mark) 对于发送缓存，调用 sbreserve 并传入参数 sndcc。对于接收缓存，调用 sbreserve 并传入参数 rcvcc。将发送缓存和接收缓存的 sb_lowat 初始化成默认值(图16-4)。如果超过系统限制，则返回 ENOBUFS <pre>int soreserve(struct socket* s, int sndcc, int rcvcc);</pre>
sbreserve	将sb的高水位标记设置成cc。同时将低水位标记降到cc。本函数不分配存储器 <pre>int sbreserve(struct sockbuf* sb, int cc);</pre>

图16-7 (续)

16.4 write、writev、sendto和sendmsg系统调用

我们将write、writev、sendto和sendmsg四个系统调用统称为写系统调用，它们的作用是往网络连接上发送数据。相对于最一般的调用 sendmsg而言，前三个系统调用是比较简单的接口。

所有的写系统调用都要直接或间接地调用 sosend。sosend的功能是将进程来的数据复制到内核，并将数据传递给与插口相关的协议。图 16-8给出了sosend的工作流程。

在下面的章节中，我们将讨论图 16-8 中带阴影的函数。其余的四个系统调用和 sooo_write 留给读者自己去了解。

图16-9说明了这四个系统调用和一个相关的库函数 (send) 的特点。

在Net/3中，send被实现成一个调用 sendto的库函数。为了与以前编译的程序二进制兼容，内核将旧的 send调用映射成函数 osend，该函数不在本书中讨论。

从图16-9的第二栏中可以看出，write和writev系统调用适用于任何描述符，而其他的系统调用只适用于插口描述符。

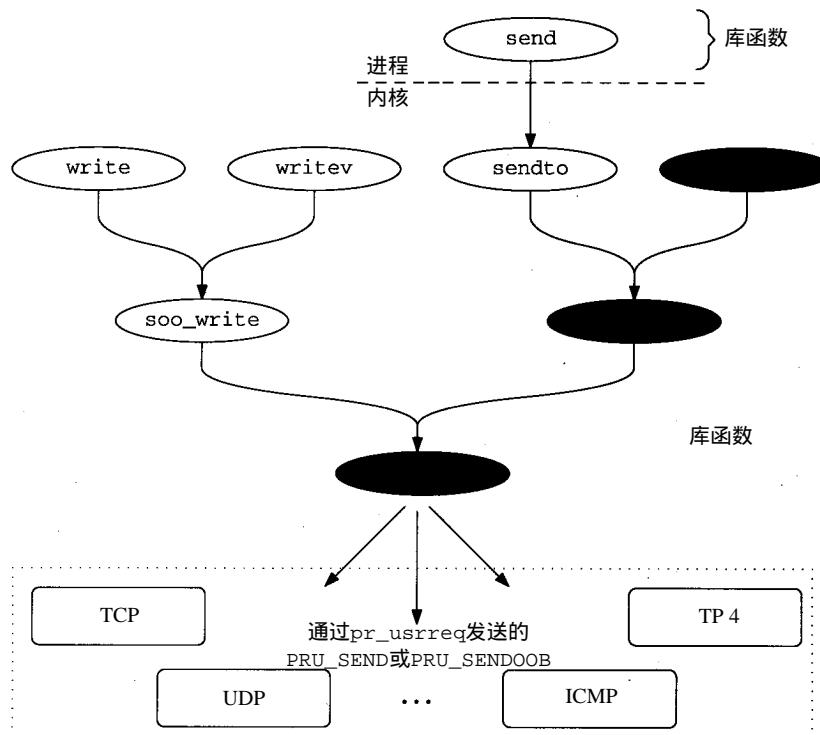


图16-8 所有的插口输出均由 soosend 处理

函 数	描 述 符 类 型	缓 存 数 量	是 否 指 明 目 的 地 址	标 志 ?	控 制 信 息 ?
write	任 何 类 型	1			
writev	任 何 类 型	[1..UIO_MAXIOV]			
send	插 口	1		•	
sendto	插 口	1	•	•	
sendmsg	插 口	[1..UIO_MAXIOV]	•	•	•

图16-9 写系统调用

从图16-9的第三栏中可以看出，writev和sendmsg系统调用可以接收从多个缓存中来的数据。从多个缓存中写数据称为收集（gathering），同它相对应的读操作称为分散（scattering）。执行收集操作时，内核按序接收类型为 iovec 的数组中指定的缓存中的数据。数组最多有 UIO_MAXIOV 个单元。图16-10显示了类型 iovec 的结构。

```

41 struct iovec {
42     char    *iov_base;           /* Base address */
43     size_t   iov_len;           /* Length */
44 };

```

*uio.h**uio.h*

图16-10 iovec 结构

41-44 在图16-10中，iov_base指向长度为iov_len个字节的缓存的开始。

如果没有这种接口，一个进程将不得不将多个缓存复制到一个大的缓存中，或调用多个

写系统调用来发送从多个缓存来的数据。相对于用一个系统调用传送类型为 `iovec` 的数组，这两种方法的效率更低。对于数据报协议而言，调用一次 `writev` 就是发送一个数据报，数据报的发送不能用多个写动作来实现。

图16-11说明了 `iovec` 结构在 `writev` 系统调用中的应用，图中 `iov` 指向数组的第一个元素，`iovcnt` 等于数组的大小。

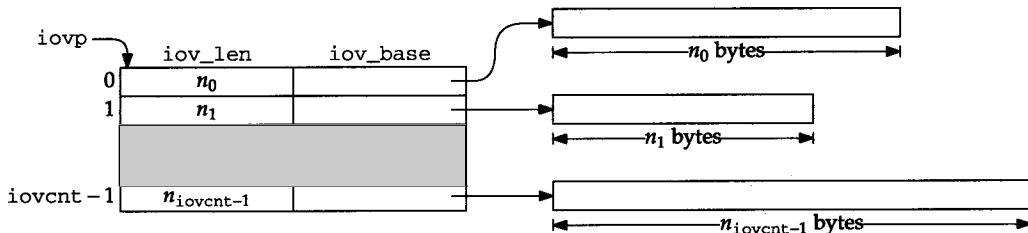


图16-11 `writev` 系统调用中的 `iovec` 参数

数据报协议要求每一个写调用必须指定一个目的地址。因为 `write`、`writev` 和 `send` 调用接口不支持对目的地址的指定，因此这些调用只能在调用 `connect` 将目的地址同一个无连接的插口联系起来后才能被调用。调用 `sendto` 或 `sendmsg` 时必须提供目的地址，或在调用它们之前调用 `connect` 来指定目的地址。

图16-9的第五栏显示 `send xxx` 系统调用接收一个可选的控制标志，这些标志在图 16-12 中定义。

flags	描述	参考
<code>MSG_DONTROUTE</code>	发送本报文时，不查路由表	图16-23
<code>MSG_DONTWAIT</code>	发送本报文时，不等待资源	图16-22
<code>MSG_EOR</code>	标志一个逻辑记录的结束	图16-25
<code>MSG_OOB</code>	发送带外数据	图16-26

图16-12 `send xxx` 系统调用：flags 值

如图16-9的最后一栏所示，只有 `sendmsg` 系统调用支持控制信息。控制信息和另外几个参数是通过结构 `msghdr` (图16-13) 一次传递给 `sendmsg`，而不是分别传递。

```

228 struct msghdr {
229     caddr_t msg_name;           /* optional address */
230     u_int   msg_namelen;        /* size of address */
231     struct iovec *msg_iov;       /* scatter/gather array */
232     u_int   msg_iovlen;         /* # elements in msg_iov */
233     caddr_t msg_control;        /* ancillary data, see below */
234     u_int   msg_controllen;      /* ancillary data buffer len */
235     int     msg_flags;          /* Figure 16.33 */
236 };
  
```

socket.h

图16-13 `msghdr` 结构

`msg_name` 应该被说明成一个指向 `sockaddr` 结构的指针，因为它包含网络地址。

228-236 `msghdr` 结构包含一个目的地址 (`msg_name` 和 `msg_namelen`)、一个分散/收集数组 (`msg_iov` 和 `msg_iovlen`)、控制信息 (`msg_control` 和 `msg_controllen`) 和接收标志

(msg_flags)。控制信息的类型为 cmsghdr结构，如图16-14所示。

```
251 struct cmsghdr {
252     u_int    cmsg_len;           /* data byte count, including hdr */
253     int      cmsg_level;        /* originating protocol */
254     int      cmsg_type;         /* protocol-specific type */
255 /* followed by u_char cmsg_data[]; */
256 };
```

图16-14 cmsghdr 结构

251-256 插口层并不解释控制信息，但是报文的类型被置为 cmsg_type，且报文长度为 cmsg_len。多个控制报文可能出现在控制信息缓存中。

举例

图16-15说明了在调用 sendmsg时msghdr的结构。

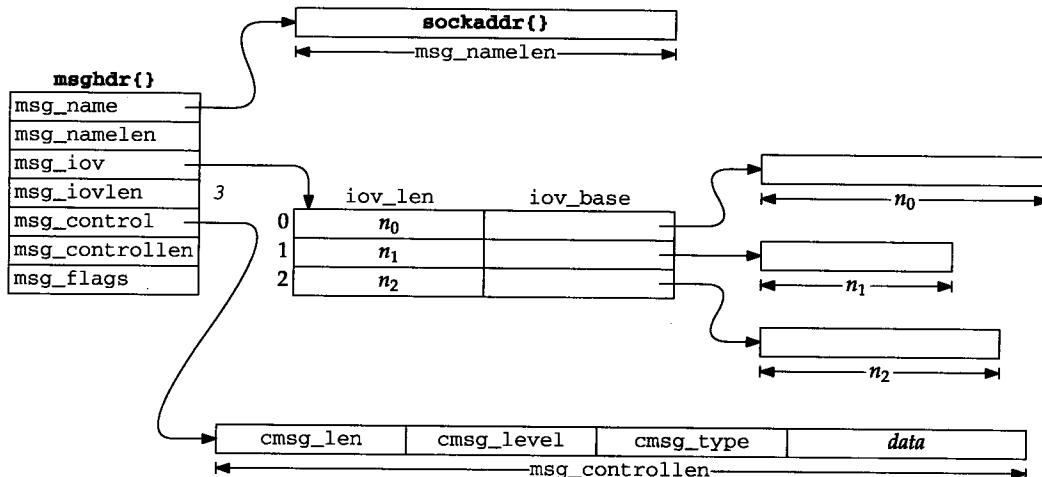


图16-15 sendmsg 系统调用的msghdr 结构

16.5 sendmsg系统调用

只有通过 sendmsg系统调用才能访问到与插口 API的输出有关的所有功能。sendmsg和 sendit函数准备 sosend系统调用所需的数据结构，然后由 sosend调用将报文发送给相应的协议。对 SOCK_DGRAM协议而言，报文就是数据报。对 SOCK_STREAM协议而言，报文是一串字节流。对于 SOCK_SEQPACKET协议而言，报文可能是一个完整的记录(隐含的记录边界)或一个大的记录的一部分(显式的记录边界)。对于 SOCK_PDM协议而言，报文总是一个完整的记录(隐含的记录边界)。

即使一般的 sosend代码处理 SOCK_SEQPACKET和SOCK_PDK协议，但是在 Internet域中没有这样的协议。

图16-16显示了 sendmsg系统调用的源代码。

307-319 sendmsg有三个参数：插口描述符；指向 msghdr结构的指针；几个控制标志。函数copyin将msghdr结构从用户空间复制到内核。

```

307 struct sendmsg_args {
308     int      s;
309     caddr_t msg;
310     int      flags;
311 };
312 sendmsg(p, uap, retval)
313 struct proc *p;
314 struct sendmsg_args *uap;
315 int      *retval;
316 {
317     struct msghdr msg;
318     struct iovec aiov[UIO_SMALLIOV], *iov;
319     int      error;
320
321     if (error = copyin(uap->msg, (caddr_t) &msg, sizeof(msg)))
322         return (error);
323     if ((u_int) msg.msg_iovlen >= UIO_SMALLIOV) {
324         if ((u_int) msg.msg_iovlen >= UIO_MAXIOV)
325             return (EMSGSIZE);
326         MALLOC(iov, struct iovec *,
327                sizeof(struct iovec) * (u_int) msg.msg_iovlen, M_IOV,
328                M_WAITOK);
329     } else
330         iov = aiov;
331     if (msg.msg_iovlen &&
332         (error = copyin((caddr_t) msg.msg iov, (caddr_t) iov,
333                         (unsigned) (msg.msg_iovlen * sizeof(struct iovec))))) {
334         goto done;
335     msg.msg iov = iov;
336     error = sendit(p, uap->s, &msg, uap->flags, retval);
337 done:
338     if (iov != aiov)
339         FREE(iov, M_IOV);
340     return (error);
341 }

```

uipc_syscalls.c

图16-16 sendmsg 系统调用

1. 复制iov数组

320-334 一个有8个元素(UIO_SMALLIOV)的iovec数组从栈中自动分配。如果分配的数组不够大，sendmsg将调用MALLOC分配更大的数组。如果进程指定的数组单元大于1024(UIO_MAXIOV)，则返回EMSGSIZE。copyin将iovec数组从用户空间复制到栈中的数组或一个更大的动态分配的数组中。

这种技术避免了调用malloc带来的高代价，因为大多数情况下，数组的单元数小于等于8。

2. sendit和cleanup

335-340 如果sendit返回，则表明数据已经发送给相应的协议或出现差错。sendmsg释放iovec数组(如果它是动态分配的)，并且返回sendit调用返回的结果。

16.6 sendit函数

sendit函数是被sendto和sendmsg调用的公共函数。sendit初始化一个uio结构，

将控制和地址信息从进程空间复制到内核。在讨论 `sosend` 之前，我们必须先解释 `uiomove` 函数和 `uio` 结构。

16.6.1 uiomove函数

`uiomove` 函数的原型为：

```
int uiomove(caddr_t cp, int n, struct uio *uio);
```

`uiomove` 函数的功能是在由 `cp` 指向的缓存与 `uio` 指向的类型为 `iovec` 的数组中的多个缓存之间传送 `n` 个字节。图 16-7 说明了 `uio` 结构的定义，该结构控制和记录 `uiomove` 的行为。

```

45 enum uio_rw {
46     UIO_READ, UIO_WRITE
47 };
48 enum uio_seg {                                /* Segment flag values */
49     UIO_USERSPACE,                            /* from user data space */
50     UIO_SYSSPACE,                            /* from system space */
51     UIO_USERISPACE                           /* from user instruction space */
52 };
53 struct uio {
54     struct iovec *uio_iov;                      /* an array of iovec structures */
55     int      uio_iovcnt;                        /* size of iovec array */
56     off_t    uio_offset;                        /* starting position of transfer */
57     int      uio_resid;                         /* remaining bytes to transfer */
58     enum uio_seg uio_segflg;                   /* location of buffers */
59     enum uio_rw uio_rw;                         /* direction of transfer */
60     struct proc *uio_procp;                    /* the associated process */
61 };

```

图 16-17 `uio` 结构

在 `uio` 结构中，`uio_iov` 指向类型为 `iovec` 结构的数组，`uio_offset` 记录 `uiomove` 传送的字节数，`uio_resid` 记录剩余的字节数。每次调用 `uiomove`，`uio_offset` 增加 `n`，`uio_resid` 减去 `n`。同时，`uiomove` 根据传送的字节数调整 `uio_iov` 数组中的基指针和缓存长度，从而从缓存中删除每次调用时传送的字节。最后，每当从 `uio_iov` 中传送一块缓存，`uio_iov` 数组的每个单元就向前进一个数组单元。`uio_segflg` 指向 `uio_iov` 数组的基指针指向的缓存的位置。`uio_rw` 指定数据传送的方向。缓存可能在用户数据空间、用户指令空间或内核数据空间。图 16-18 对 `uiomove` 函数的操作进行了小结。图中对操作的描述用到了 `uiomove` 函数原型中的参数名。

uio_segflg	uio_rw	描 述
<code>UIO_USERSPACE</code>	<code>UIO-READ</code>	从内核缓存 <code>cp</code> 中分散 <code>n</code> 个字节到进程缓存
<code>UIO_USERISPACE</code>		
<code>UIO_USERSPACE</code>	<code>UIO-WRITE</code>	从进程缓存中收集 <code>n</code> 个字节到内核缓存 <code>cp</code>
<code>UIO_USERISPACE</code>		
<code>UIO_SYSSPACE</code>	<code>UIO-READ</code>	从内核缓存 <code>cp</code> 中分散 <code>n</code> 个字节到多个内核缓存
	<code>UIO-WRITE</code>	从多个内核缓存中收集 <code>n</code> 个字节到内核缓存 <code>cp</code> 中

图 16-18 `uiomove` 操作

16.6.2 举例

图16-19显示了一个调用uiomove之前的uio结构。

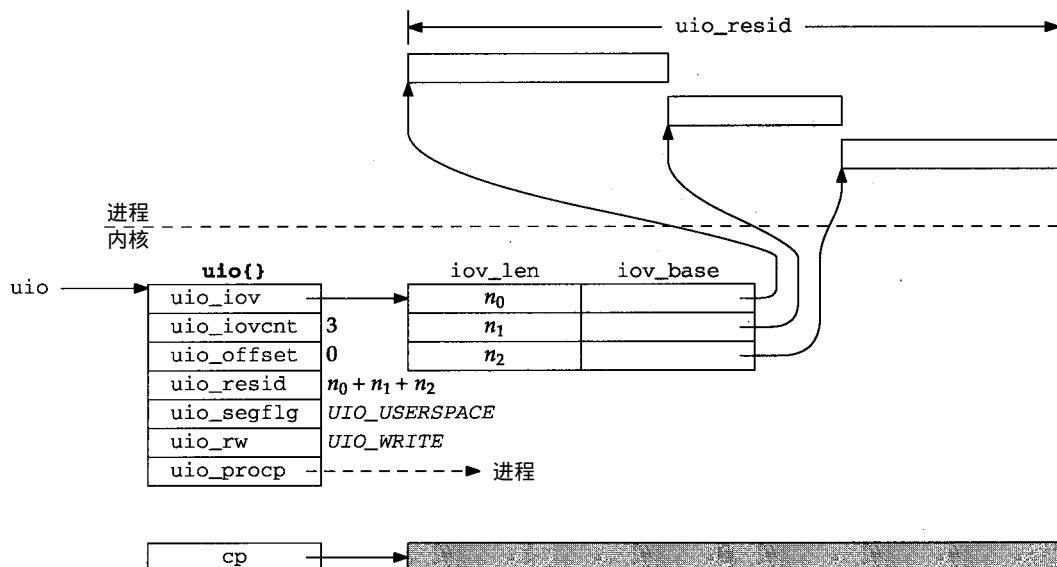


图16-19 调用uiomove 前的uio 结构

uio iov指向iovec数组的第一个单元。iov_base指针数组的每一个单元分别指向它们在进程地址空间中的缓存的起始地址。uio_offset等于0，uio_resid等于三块缓存的总的大小。cp指向内核中的一块缓存，一般来说，这块缓存是一个mbuf的数据区。图16-20显示了调用uiomove之后同一个uio结构的内容。

```
uiomove(cp, n, uio);
```

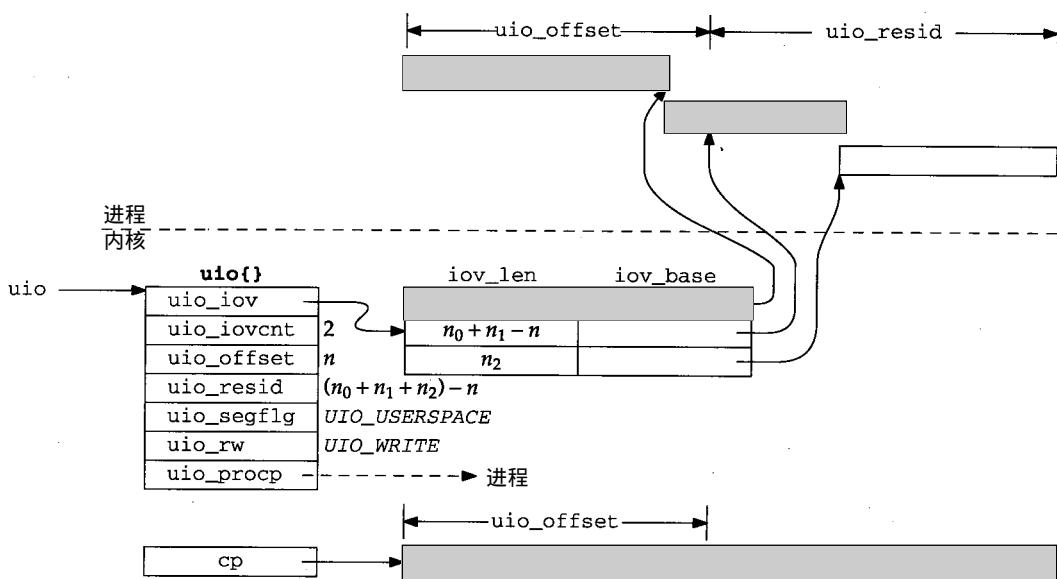


图16-20 调用uiomove 后的uio 结构

在上述调用中， n 包括第一块缓存中的所有字节和第二块缓存中的部分字节（即， $n_0 < n < n_0 + n_1$ ）。

调用uiomove后，第一块缓存的长度变为0，且它的基指针指向缓存的末端。uio iov现在指向iovec数组的下一个单元。单元指针也前进了一个单元，长度也减少了，减少的字节数等于缓存中被传送的字节数。同时，uio_offset增加了 n ，uio_resid减少了 n 。数据已经从进程中的缓存传送到内核缓存，因为uio_rw等于UIO_WRITE..。

16.6.3 sendit代码

现在开始讨论sendit的代码，如图16-21所示。

1. 初始化auio

341-368 sendit调用getsock函数获取描述符对应的file结构，初始化uio结构，并将进程指定的输出缓存中的数据收集到内核缓存中。传送的数据的长度通过一个for循环来计算，并将结果保存在uio_resid。循环内的第一个if保证缓存的长度非负。第二个if保证uio_resid不溢出，因为uio_resid是一个有符号的整数，且iov_len要求非负。

2. 从进程复制地址和控制信息

369-385 如果进程提供了地址和控制信息，则sockargs将地址和控制信息复制到内核缓存中。

uipc_syscalls.c

```

341 sendit(p, s, mp, flags, rtsize)
342 struct proc *p;
343 int      s;
344 struct msghdr *mp;
345 int      flags, *rtsize;
346 {
347     struct file *fp;
348     struct uio auio;
349     struct iovec *iov;
350     int      i;
351     struct mbuf *to, *control;
352     int      len, error;
353     if (error = getsock(p->p_fd, s, &fp))
354         return (error);
355     auio.uio_iov = mp->msg_iov;
356     auio.uio_iovcnt = mp->msg_iovlen;
357     auio.uio_segflg = UIO_USERSPACE;
358     auio.uio_rw = UIO_WRITE;
359     auio.uio_procp = p;
360     auio.uio_offset = 0;           /* XXX */
361     auio.uio_resid = 0;
362     iov = mp->msg_iov;
363     for (i = 0; i < mp->msg_iovlen; i++, iov++) {
364         if (iov->iov_len < 0)
365             return (EINVAL);
366         if ((auio.uio_resid += iov->iov_len) < 0)
367             return (EINVAL);
368     }
369     if (mp->msg_name) {
370         if (error = sockargs(&to, mp->msg_name, mp->msg_namerlen,
371                         MT_SONAME))

```

图16-21 sendit 函数

```

372         return (error);
373     } else
374         to = 0;
375     if (mp->msg_control) {
376         if (mp->msg_controllen < sizeof(struct cmsghdr))
377             {
378                 error = EINVAL;
379                 goto bad;
380             }
381         if (error = sockargs(&control, mp->msg_control,
382                             mp->msg_controllen, MT_CONTROL))
383             goto bad;
384     } else
385         control = 0;
386     len = auio.uio_resid;
387     if (error = sosend((struct socket *) fp->f_data, to, &auio,
388                         (struct mbuf *) 0, control, flags)) {
389         if (auio.uio_resid != len && (error == ERESTART ||
390                                         error == EINTR || error == EWOULDBLOCK))
391             error = 0;
392         if (error == EPIPE)
393             psignal(p, SIGPIPE);
394     }
395     if (error == 0)
396         *retsize = len - auio.uio_resid;
397     bad:
398     if (to)
399         m_freem(to);
400     return (error);
401 }

```

uipc_syscalls.c

图16-21 (续)

3. 发送数据和清除缓存

386-401 为了防止sosend不接受所有数据而无法计算传送的字节数，将uio_resid的值保存在len中。将插口、目的地址、uio结构、控制信息和标志全部传给函数sosend。当sosend返回后，sendit响应如下：

- 如果sosend传送了部分数据后，传送被信号或阻塞条件所中断，差错被丢弃，报告传送了部分数据。
 - 如果sosend返回EPIPE，则发送信号SIGPIPE给进程。error设置成非0，所以如果进程捕捉到了该信号，并且从信号处理程序中返回，或进程忽略信号，写调用返回EPIPE。
 - 如果没有差错出现(或差错被丢弃)，则计算传送的字节数，并将其保存在*retsize中。如果sendit返回0，syscall(第15.4节)返回*retsize给进程而不是返回差错代码。
 - 如果任何其他类型的差错出现，返回相应差错代码给进程。
- 在返回之前，sendit释放包含目的地址的缓存。sosend负责释放control缓存。

16.7 sosend函数

sosend是插口层中最复杂的函数之一。在图16-8中已提到过所有五个写系统调用最终都要调用sosend。sosend的功能就是：根据插口指明的协议支持的语义和缓存的限制，将数

据和控制信息传递给插口指明的协议的 pr_usrreq 函数。 sosend 从不将数据放在发送缓存中；存储和移走数据应由协议来完成。

sosend 对发送缓存的 sb_hiwat 和 sb_lowat 值的解释，取决于对应的协议是否实现可靠或不可靠的数据传送功能。

16.7.1 可靠的协议缓存

对于提供可靠的数据传送协议，发送缓存保存了还没有发送的数据和已经发送但还没有被确认的数据。 sb_cc 等于发送缓存的数据的字节数，且 $0 \leq sb_cc \leq sb_hiwat$ 。

如果有带外数据发送，则 sb_cc 有可能暂时超过 sb_hiwat。

sosend 应该确保在通过 pr_usrreq 函数将数据传递给协议层之前有足够的发送缓存。协议层将数据放到发送缓存中。 sosend 通过下面两种方式之一将数据传送给协议层：

- 如果设置了 PR_ATOMIC，sosend 就必须保护进程和协议层之间的边界。在这种情况下，sosend 等待得到足够的缓存来存储整个报文。当获取到足够的缓存后，构造存储整个报文的 mbuf 链，并用 pr_usrreq 函数一次性传送给协议层。 RDP 和 SPP 就是这种类型的协议。
- 如果没有设置 PR_ATOMIC，sosend 每次传送一个存有报文的 mbuf 给协议，可能传送部分 mbuf 给协议层以防止超过上限。这种方法在 SOCK_STREAM 类协议如 TCP 中和 SOCK_SEQPACKET 类协议如 TP4 中被采用。在 TP4 中，记录边界通过 MSG_EOR 标志（图 16-12）来显式指定，所以 sosend 没有必要保护报文边界。

TCP 应用程序对外出的 TCP 报文段的大小没有控制。例如，在 TCP 插口上发送一个长度为 4096 字节的报文，假定发送缓存中有足够的缓存，则插口层将该报文分成两部分，每一部分长度为 2048 个字节，分别存放在一个带外部簇的 mbuf 中。然后，在协议处理时，TCP 将根据连接上的最大报文段大小将数据分段，通常情况下，最大报文段大小为 2048 个字节。

当一个报文因为太大而没有足够的缓存时，协议允许报文被分成多段，但 sosend 仍然不将数据传送给协议层直到缓存中的闲置空间大小大于 sb_lowat。对于 TCP 而言，sb_lowat 的默认值为 2048（图 16-4），从而阻止插口层在发送缓存快满时用小块数据干扰 TCP。

16.7.2 不可靠的协议缓存

对于提供不可靠的数据传输的协议（如 UDP）而言，发送缓存不需保存任何数据，也不等待任何确认。每一个报文一旦被排队等待发送到相应的网络设备，插口层立即将它传送到协议。在这种情况下，sb_cc 总是等于 0，sb_hiwat 指定每一次写的最大长度，间接指明数据报的最大长度。

图 16-4 显示了 UDP 协议的 sb_hiwat 的默认值为 9216 (9×1024)。如果进程没有通过 SO_SNDBUF 插口选项改变 sb_hiwat 的值，则发送长度大于 9216 个字节的数据报将导致差错。不仅如此，其他的协议限制也可能不允许一个进程发送大的数据报报文。卷 1 的第 11.10 节中已讨论了在其他的 TCP/IP 实现中的这些选项和限制。

对于 NFS 写而言，9216 已足够大，NFS 写的数据加上协议首部的长度一般默认为 8192 个字节。

图16-22显示了sosend函数的概况。下面分别讨论图中四个带阴影的部分。

```

271 sosend(so, addr, uio, top, control, flags)           — uipc_socket.c
272 struct socket *so;
273 struct mbuf *addr;
274 struct uio *uio;
275 struct mbuf *top;
276 struct mbuf *control;
277 int     flags;
278 {

    /* initialization (Figure 16.23) */

305 restart:
306     if (error = sblock(&so->so_snd, SBLOCKWAIT(flags)))
307         goto out;
308     do {                                /* main loop, until resid == 0 */

        /* wait for space in send buffer (Figure 16.24) */

342     do {
343         if (uio == NULL) {
344             /*
345             * Data is prepackaged in "top".
346             */
347             resid = 0;
348             if (flags & MSG_EOR)
349                 top->m_flags |= M_EOR;
350         } else
351             do {

                /* fill a single mbuf or an mbuf chain (Figure 16.25) */

396         } while (space > 0 && atomic);

            /* pass mbuf chain to protocol (Figure 16.26) */

412         } while (resid && space > 0);
413     } while (resid);

414     release:
415     sbunlock(&so->so_snd);
416     out:
417     if (top)
418         m_freem(top);
419     if (control)
420         m_freem(control);
421     return (error);
422 }

```

— uipc_socket.c

图16-22 sosend 函数：概述

271-278 sosend的参数有如下几个：so，指向相应插口的指针；addr，指向目的地址的指针；uio，指向描述用户空间的I/O缓存的uio结构；top，保存将要发送的数据的mbuf链；control，保存将要发送的控制信息的mbuf链；flags，包含本次写调用的一些选项。

正常情况下，进程通过 uio 机制将数据提供给插口层，top 为空。当内核本身正在使用插口层时(如 NFS)，数据将作为一个 mbuf 链传送给 sosend，top 指向该 mbuf 链，而 uio 为空。

279-304 初始化代码分别如下所述。

1. 给发送缓存加锁

305-308 sosend 的主循环从 restart 开始，在循环的开始调用 sblock 给发送缓存加锁。通过加锁确保多个进程按序互斥访问插口缓存。

如果在 flags 中 MSG_DONTWAIT 被设置，则 SBLOCKWAIT 将返回 M_NOWAIT。M_NOWAIT 告知 sblock，如果不能立即加锁，则返回 EWOULDBLOCK。

MSG_DONTWAIT 仅用于 Net/3 中的 NFS。

主循环直到将所有数据都传送给协议(即 resid=0)后才退出。

2. 检查空间

309-341 在传送数据给协议之前，需要对各种差错情况进行检查，并且 sosend 实现前面讨论的流控和资源控制算法。如果 sosend 阻塞等待输出缓存中的更多的空间，则它跳回 restart 等待。

3. 使用 top 中的数据

342-350 一旦有了足够的空间并且 sosend 也获得了发送缓存上的锁，则准备传送给协议的数据。如果 uio 等于空(即数据在 top 指向的 mbuf 链中)，则 sosend 检查 MSG_EOR，并且在链中设置 M_EOR 来标志逻辑记录的结束。mbuf 链是准备发送给协议层的。

4. 从进程复制数据

351-396 如果 uio 不空，则 sosend 必须从进程间复制数据。当 PR_ATOMIC 被设置时(例如，UDP)，循环继续，直到所有数据都被复制到一个 mbuf 链中。当 sosend 从进程得到所有数据后，通过循环中的 break(图 16-22 中没有显示这个 break)跳出循环。跳出循环后，sosend 将整个数据链一次传送给相应协议。

5. 传送数据给协议

395-414 对于 PR_ATOMIC 协议，当整个数据链被传送给协议后，resid 总是等于 0，并且控制跳出两个循环后至 release 处。如果 PR_ATOMIC 没有被置位，且当还有数据要发送并有缓存空间时，则 sosend 继续往 mbuf 中写数据。如果缓存中没有闲置空间，但仍然有数据要发送，则 sosend 回到循环开始，等待闲置空间来写下一个 mbuf。如果所有数据都发送完，则两个循环结束。

6. 释放缓存

414-422 当所有数据都传送给协议后，给插口缓存解锁，释放多余的 mbuf 缓存，然后返回。

sosend 的详细情况将分四个部分来描述：

- 初始化(图 16-23)
- 差错和资源检查(图 16-24)
- 数据传送(图 16-25)
- 协议处理(图 16-26)

sosend 的第一部分初始化变量，如图 16-23 所示。

7. 计算传送大小和语义

279-284 如果 sosend_all_at_once 等于 true(任何设置了 PR_ATOMIC 的协议)或数据已经

通过top中的mbuf链传送给sosend，则将设置atomic。这个标志控制数据是作为一个mbuf链还是作为多个独立的mbuf传送给协议。

285-297 resid等于iovec缓存中的数据字节数或top中的mbuf链中的数据字节数。习题16.1讨论为什么resid可能等于负数的问题。

```

279     struct proc *p = curproc; /* XXX */
280     struct mbuf **mp;
281     struct mbuf *m;
282     long space, len, resid;
283     int clen = 0, error, s, dontroute, mlen;
284     int atomic = sosendallatonce(so) || top;

285     if (uio)
286         resid = uio->uio_resid;
287     else
288         resid = top->m_pkthdr.len;
289     /*
290      * In theory resid should be unsigned.
291      * However, space must be signed, as it might be less than 0
292      * if we over-committed, and we must use a signed comparison
293      * of space and resid. On the other hand, a negative resid
294      * causes us to loop sending 0-length segments to the protocol.
295     */
296     if (resid < 0)
297         return (EINVAL);
298     dontroute =
299         (flags & MSG_DONTROUTE) && (so->so_options & SO_DONTROUTE) == 0 &&
300         (so->so_proto->pr_flags & PR_ATOMIC);
301     p->p_stats->p_ru.ru_msgsnd++;
302     if (control)
303         clen = control->m_len;
304 #define snderr(errno) { error = errno; splx(s); goto release; }

```

uipc_socket.c

图16-23 sosend 函数：初始化

8. 关闭路由

298-303 如果仅仅要求对这个报文不通过路由表进行路由选择，则设置dontroute。clen等于在可选的控制缓存中的字节数。

304 宏snderr传送差错代码，重新使能协议处理，控制跳转到out执行解锁和释放缓存的工作。这个宏简化函数内的差错处理工作。

图16-24显示的sosend代码功能是检查差错条件和等待发送缓存中的闲置空间。

309 当检查差错情况时，为防止缓存发生改变，协议处理被挂起。在每一次数据传送之前，sosend要检查以下几种差错情况：

310-311 •如果插口输出被禁止(即，TCP连接的写道通已经被关闭)，则返回EPIPE。

312-313 •如果插口正处于差错状态(例如，前一个数据报可能已经产生了一个ICMP不可达的差错)，则返回so_error。如果差错出现之前数据已经被收到，则sendit忽略这个差错(图16-21的第389行)。

314-318 •如果协议请求连接且连接还没有建立或连接请求还没有启动，则返回ENOTCONN。sosend允许只有控制信息但没有数据的写操作，即使连接还没有建立。

Internet协议并不使用这个特点，但TP4用它在连接请求中发送数据，证实连接请

求，在断连请求中发送数据。

319-321 • 如果在无连接协议中没有指定目的地址（例如，进程调用 send但并没有用 connect建立目的地址），则返回 EDESTADDRREQ。

```

309      s = splnet();
310      if (so->so_state & SS_CANTSENDMORE)
311          snderr(EPIPE);
312      if (so->so_error)
313          snderr(so->so_error);
314      if ((so->so_state & SS_ISCONNECTED) == 0) {
315          if (so->so_proto->pr_flags & PR_CONNREQUIRED) {
316              if ((so->so_state & SS_ISCONFIRMING) == 0 &&
317                  !(resid == 0 && clen != 0))
318                  snderr(ENOTCONN);
319          } else if (addr == 0)
320              snderr(EDESTADDRREQ);
321      }
322      space = sbinspace(&so->so_snd);
323      if (flags & MSG_OOB)
324          space += 1024;
325      if (atomic && resid > so->so_snd.sb_hiwat ||
326          clen > so->so_snd.sb_hiwat)
327          snderr(EMSGSIZE);
328      if (space < resid + clen && uio &&
329          (atomic || space < so->so_snd.sb_lowat || space < clen)) {
330          if (so->so_state & SS_NBIO)
331              snderr(EWOULDBLOCK);
332          sbunlock(&so->so_snd);
333          error = sbwait(&so->so_snd);
334          splx(s);
335          if (error)
336              goto out;
337          goto restart;
338      }
339      splx(s);
340      mp = &top;
341      space -= clen;

```

uipc_socket.c

图16-24 sosend 函数：差错和资源检查

9. 计算可用空间

322-324 sbinspace函数计算发送缓存中剩余的闲置空间字节数。这是一个基于缓存高水位标记的管理上的限制，但也是 sb_mbmax对它的限制，其目的是为了防止太多的小报文消耗太多的mbuf缓存(图16-6)。sosend通过放宽缓存限制到1024个字节来给予带外数据更高的优先级。

10. 强制实施报文大小限制

325-327 如果atomic被置位，并且报文大于高水位标记(high-watermark)，则返回 EMSGSIZE；报文因为太大而不被协议接受，即使缓存是空的。如果控制信息的长度大于高水位标记，同样返回 EMSGSIZE。这是限制数据或记录大小的测试代码。

11. 等待更多的空间吗？

328-329 如果发送缓存中的空间不够，数据来源于进程(而不是来源于内核中的top)，并且下列条件之一成立，则sosend必须等待更多的空间：

- 报文必须一次传送给协议(`atomic`为真)；或
- 报文可以分段传送，但闲置空间大小低于低水位标记；或
- 报文可以分段传送，但可用空间存放不下控制信息。

当数据通过 `top` 传送给 `sosend` (即，`uioc` 为空) 时，数据已经在 `mbuf` 缓存中。因此，`sosend` 忽略缓存高、低水位标记限制，因为不需要附加的缓存来保存数据。

如果在测试中，忽略发送缓存的低水位标记，在插口层和运输层之间将出现一种有趣的交互过程，它将导致性能下降。[\[Crowcroft et al. 1992\]](#) 提供了有关这个问题的详细情况。

12. 等待空间

330-338 如果 `sosend` 必须等待缓存且插口是非阻塞的，则返回 `EWOULDBLOCK`。同时，缓存锁被释放，`sosend` 调用 `sbswait` 等待，直到缓存状态发生变化。当 `sbswait` 返回后，`sosend` 重新使能协议处理，并且跳转到 `restart` 获取缓存锁，检查差错和缓存空间。如果条件满足，则继续执行。

默认情况下，`sbswait` 阻塞直到可以发送数据。通过 `SO_SNDDTIMEO` 插口选项改变缓存中的 `sb_timeo`，进程可以设置等待时间的上限。如果定时器超时，则返回 `EWOULDBLOCK`。回想一下图 16-21，如果数据已经被成功发送给协议，则 `sendit` 忽略这个差错。这个定时器并不限制整个调用的时间，而仅仅是限制写两个 `mbuf` 缓存之间的不活动时间。

339-341 在这点上，`sosend` 已经知道一些数据已传送给协议。`splx` 使能中断，因为 `sosend` 从进程复制数据到内核相对较长的时间间隔内不应该被阻塞。`mp` 包含一个指针，用来构造 `mbuf` 链。在 `sosend` 从进程复制任何数据之前，可用缓存的数量需减去控制信息的大小(`clen`)。

图 16-25 显示了 `sosend` 从进程复制数据到一个或多个内核中的 `mbuf` 中的代码段。

13. 分配分组首部或标准 `mbuf`

351-360 当 `atomic` 被置位时，这段代码在第一次循环时分配一个分组首部，随后分配标准的 `mbuf` 缓存。如果 `atomic` 没有被置位，则这段代码总是分配一个分组首部，因为进入循环之前，`top` 总是被清除。

14. 尽可能用簇

361-371 如果报文足够大使得为其分配一个簇是值得的，并且 `space` 大于或等于 `MCLBYTES`，则调用 `MCLGET` 分配一个簇同 `mbuf` 连在一起。当 `space` 小于 `MCLBYTES` 时，额外的 2048 个字节将超过缓存分配限制，因为即使 `resid` 小于 `MCLBYTES`，整个簇也将被分配。

如果调用 `MCLGET` 失败，`sosend` 跳转到 `nopages`，用一个标准的 `mbuf` 替代一个外部簇。

对 `MINCLSIZE` 的测试应该用 `>`，而不是 `=`，因为 208(`MINCLSIZE`) 个字节的写操作只适合小于两个 `mbuf` 的情况。

如果 `atomic` 被设置(例如，`UDP`)，则 `mbuf` 链表示一个数据报或记录，并且在第一个簇的前面为协议首部保留 `max_hdr` 个字节。而后续的簇因为是同一条链的一部分，所以不需要再为协议首部保留空间。

如果 `atomic` 没有被置位(如，`TCP`)，则不需要保留空间，因为 `sosend` 不知道协议如何将发送的数据进行分段。

需要注意的是，`space` 由簇大小(2048 个字节)而不是 `len` 来决定，`len` 等于放在簇中的数据的字节数(习题 16-2)。

—uipc_socket.c

```

351     do {
352         if (top == 0) {
353             MGETHDR(m, M_WAIT, MT_DATA);
354             mlen = MHLEN;
355             m->m_pkthdr.len = 0;
356             m->m_pkthdr.rcvif = (struct ifnet *) 0;
357         } else {
358             MGET(m, M_WAIT, MT_DATA);
359             mlen = MLEN;
360         }
361
361         if (resid >= MINCLSIZE && space >= MCLBYTES) {
362             MCLGET(m, M_WAIT);
363             if ((m->m_flags & M_EXT) == 0)
364                 goto nopages;
365             mlen = MCLBYTES;
366             if (atomic && top == 0) {
367                 len = min(MCLBYTES - max_hdr, resid);
368                 m->m_data += max_hdr;
369             } else
370                 len = min(MCLBYTES, resid);
371             space -= MCLBYTES;
372         } else {
373             nopages:
374                 len = min(min(mlen, resid), space);
375                 space -= len;
376                 /*
377                  * For datagram protocols, leave room
378                  * for protocol headers in first mbuf.
379                  */
380                 if (atomic && top == 0 && len < mlen)
381                     MH_ALIGN(m, len);
382             }
383
383             error = uiomove(mtod(m, caddr_t), (int) len, uio);
384             resid = uio->uio_resid;
385             m->m_len = len;
386             *mp = m;
387             top->m_pkthdr.len += len;
388             if (error)
389                 goto release;
390             mp = &m->m_next;
391             if (resid <= 0) {
392                 if (flags & MSG_EOR)
393                     top->m_flags |= M_EOR;
394                 break;
395             }
396         } while (space > 0 && atomic);
    
```

—uipc_socket.c

图16-25 sosend 函数：数据传送

15. 准备mbuf

372-382 如果不用簇，存储在 mbuf中的字节数受下面三个量中最小一个量的限制：(1) mbuf中的可用空间；(2) 报文的字节数；(3) 缓存的空间。

如果atomic被置位，则利用MH_ALIGN可知数据在链中的第一个缓存的尾部。如果数据占居整个mbuf，则忽略MH_ALIGN。这一点可能导致没有足够的空间来存放协议首部，主要取决于有多少数据存放在mbuf中。如果atomic没有被置位，则没有为协议首部保留空间。

16. 从进程复制数据

383-395 uiomove从进程复制len个字节的数据到mbuf。传送完成后，更新mbuf的长度，前面的mbuf连接到新的mbuf(或top指向第一个mbuf)，更新mbuf链的长度。如果在传送过程中发生差错，则sosend跳转到release。

一旦最后一个字节传送完毕，如果进程设置了MSG_EOR，则设置分组中的M_EOR，然后sosend跳出循环。

MSG_EOR仅用于有显式的记录边界的协议，如OSI协议簇中的TP4。TCP不支持逻辑记录因而忽略MSG_EOR标志。

17. 写另一个缓存吗？

396 如果设置了atomic，sosend回到循环开始，写另一个mbuf。

对space>0的测试好像无关紧要。当atomic没有被设置时，space也是无关紧要的，因为一次只传送一个mbuf给协议。如果设置了atomic，只有当有足够的缓存空间来存放整个报文时才进入这个循环。参考习题16-2。

sosend的最后一段代码的功能是传送数据和控制mbuf给插口指定的协议，如图16-26所示。

```

397             if (dontroute)
398                 so->so_options |= SO_DONTROUTE;
399                 s = splnet(); /* XXX */
400                 error = (*so->so_proto->pr_usrreq) (so,
401                                         (flags & MSG_OOB) ? PRU_SENDOOB : PRU_SEND,
402                                         top, addr, control);
403                 splx(s);
404                 if (dontroute)
405                     so->so_options &= ~SO_DONTROUTE;
406                 clen = 0;
407                 control = 0;
408                 top = 0;
409                 mp = &top;
410                 if (error)
411                     goto release;
412             } while (resid && space > 0);
413         } while (resid);

```

uipc_socket.c

uipc_socket.c

图16-26 sosend函数：协议分散

397-405 在传送数据到协议层的前后，可能通过SO_DONTROUTE选项选择是否利用路由表为这个报文选择路由。这是唯一的一个针对单个报文的选项，如图16-23所示，在写期间通过MSG_DONTROUTE标志来控制路由选择。

为了防止协议在处理报文期间pr_usrreq阻塞中断，pr_usrreq被放在splnet函数和splx函数之间执行。一些协议(如UDP)可能在进行输出处理期间并不阻塞中断，但插口层得不到这些信息。

如果进程传送的是带外数据，则sosend发送PRU_SENDOOB请求；否则，它发送PRU_SEND请求。同时将地址和控制mbuf传送给协议。

406-413 因为控制信息只需传送给协议一次，所以将clen、control、top和mp初始化，然后为传送报文的下一部分构造新的mbuf链。只有atomic没有被设置时(如TCP)，resid才

可能等于非0。在这种情况下，如果缓存中仍然有空间，则 `sosend` 回到循环开始，继续写另一个 `mbuf`。如果没有可用空间，则 `sosend` 回到循环开始，等待可用空间(图16-24)。

在第23章我们将了解到不可靠的协议，如 UDP，立即将数据排队等待发送。第 26章描述可靠的协议，如TCP，将数据放到插口发送缓存直到数据被发送和确认。

16.7.3 `sosend`函数小结

`sosend`是一个比较复杂的函数。它共有 142行，包含3个嵌套的循环，一个利用 `goto` 实现的循环，两个基于是否设置 `PR_ATOMIC` 的代码分支，两个并行锁。像许多其他软件一样，复杂性是多年积累的结果。NFS加入`MSG_DONTWAIT`功能以及从 `mbuf`链接收数据而不是从进程那里接收数据。`SS_ISCONFIRMING`状态和`MSG_EOR`标志是为处理OSI协议连接和记录功能而加入的。

比较好的做法是为每一种协议实现一个独立的 `sosend`函数，通过分散指针 `pr_send`给 `proto_sw`入口来实现。[Partridge and Pink 1993]中提出并实现了这种方法。

16.7.4 性能问题

如图16-25所描述的，`sosend`尽可能地以 `mbuf`为单位将报文传送到协议层。与将一个报文用一个 `mbuf`链的形式一次建立并传送给协议层的方法相比，这种做法导致了更多的调用，但是[Jacobson 1998a]说明了这种做法增加了并行性，因而获得了较好的性能。

一次传送一个 `mbuf`(2048个字节)允许CPU在网络硬件传输数据的同时准备一个分组。同发送一个大的 `mbuf`链相比：构造一个大的 `mbuf`链的同时，网络和接收系统是空闲的。在 [Jacobson 1998a]描述的系统中，这种改变导致了网络吞吐量增加 20%。

有一点非常重要，即确保发送缓存的大小总是大于连接的带宽和时延的乘积(卷1的第20.7节)。例如，如果 TCP认为一条连接在收到确认之前能保留 20个报文段，那么发送缓存必须大到足够存储20个未被确认的报文段。如果发送缓存太小，TCP在收到第一个确认之前将用完数据，连接将在一段时间内是空闲的。

16.8 `read`、`readv`、`recvfrom`和`recvmmsg`系统调用

我们将 `read`、`readv`、`recvfrom`和`recvmmsg` 系统调用统称为读系统调用，从网络连接上接收数据。同 `recvmmsg` 相比，前三个系统调用比较简单。`recvmmsg`因为比较通用而复杂得多。图16-27给出了这四个系统调用和一个库函数(`recv`)的特点。

函 数	描述符类型	缓 存 数 量	返 回 发 送 者 的 地 址 吗？	标 志？	返 回 控 制 信 息？
<code>read</code>	任何类型	1			
<code>readv</code>	任何类型	[1...UIO_MAXIOV]			
<code>recv</code>	插 口	1		•	
<code>recvfrom</code>	插 口	1	•	•	
<code>recvmmsg</code>	插 口	[1...UIO_MAXIOV]	•	•	•

图16-27 读系统调用

在Net/3中，`recv`是一个库函数，通过调用 `recvfrom`来实现的。为了同以前编

译的程序二进制兼容，内核将旧的 `recv` 系统调用映射到函数 `orecv`。我们仅仅讨论 `recvfrom` 的内核实现。

只有 `read` 和 `readv` 系统调用适用于各类描述符，其他的调用只适用于插口描述符。

同写调用一样，通过 `iovec` 结构数组来指定多个缓存。对数据报协议，`recvfrom` 和 `recvmsg` 返回每一个收到的数据报的源地址。对于面向连接的协议，`getpeername` 返回连接对方的地址。与接收调用相关的标志参考第 16.11 节。

同写调用一样，读调用利用一个公共函数 `soreceive` 来做所有工作。图 16-28 说明读系统调用的流程。

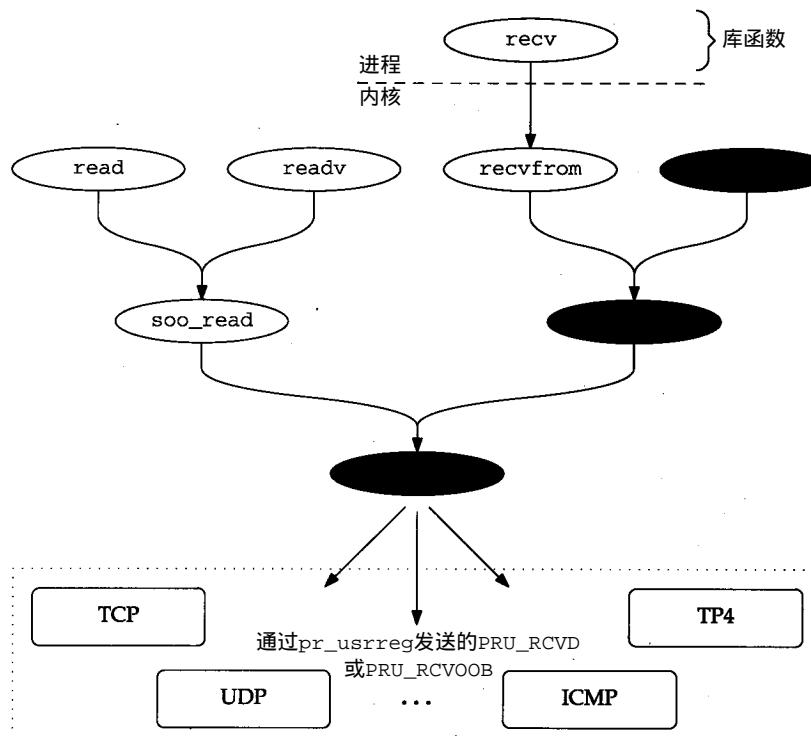


图 16-28 所有插口输入都由 `soreceive` 处理

我们仅仅讨论图 16-28 中的带阴影的函数。其余的函数读者可以自己查阅有关资料。

16.9 `recvmsg` 系统调用

`recvmsg` 函数是最通用的读系统调用。如果一个进程使用任何一个其他的读系统调用，且地址、控制信息和接收标志的值还未定，则系统可能在没有任何通知的情况下丢弃它们。图 16-29 显示了 `recvmsg` 函数。

433-445 `recvmsg` 的三个参数是：插口描述符；类型为 `msghdr` 的结构指针，几个控制标志。

1. 复制 `iocb` 数组

446-461 同 `sendmsg` 一样，`recvmsg` 将 `msghdr` 结构复制到内核，如果自动分配的数组

aiov太小，则分配一个更大的iovec数组，并且将数组单元从进程复制到由iov指向的内核数组(第16.4节)。将第三个参数复制到msghdr结构中。

```

433 struct recvmsg_args {
434     int      s;
435     struct msghdr *msg;
436     int      flags;
437 };
438 recvmsg(p, uap, retval)
439 struct proc *p;
440 struct recvmsg_args *uap;
441 int      *retval;
442 {
443     struct msghdr msg;
444     struct iovec aiov[UIO_SMALLIOV], *uiov, *iov;
445     int      error;
446
447     if (error = copyin((caddr_t) uap->msg, (caddr_t) &msg, sizeof(msg)))
448         return (error);
449     if ((u_int) msg.msg_iovlen >= UIO_SMALLIOV) {
450         if ((u_int) msg.msg_iovlen >= UIO_MAXIOV)
451             return (EMSGSIZE);
452         MALLOC(iov, struct iovec *,
453                sizeof(struct iovec) * (u_int) msg.msg_iovlen, M_IOV,
454                M_WAITOK);
455     } else
456         iov = aiov;
457     msg.msg_flags = uap->flags;
458     uiouv = msg.msg_iov;
459     msg.msg_iov = iov;
460     if (error = copyin((caddr_t) uiouv, (caddr_t) iov,
461                        (unsigned) (msg.msg_iovlen * sizeof(struct iovec))))
462         goto done;
463     if ((error = recvit(p, uap->s, &msg, (caddr_t) 0, retval)) == 0) {
464         msg.msg_iov = uiouv;
465         error = copyout((caddr_t) &msg, (caddr_t) uap->msg, sizeof(msg));
466     }
467 done:
468     if (iov != aiov)
469         FREE(iov, M_IOV);
470 }

```

uipc_syscalls.c

图16-29 recvmsg 系统调用

2. recvit和释放缓存

462-470 recvit收完数据后，将更新过的缓存长度和标志的msghdr结构再复制到进程。如果分配了一个更大的iovec结构，则返回之前释放它。

16.10 recvit函数

recvit函数被recv、recvfrom和recvmsg调用，如图16-30所示。基于recv xxx调用提供的msghdr结构，recvit函数为soreceive的处理准备了一个uio结构。

471-500 getsock为描述符s返回一个file结构，然后recvit初始化uio结构，该结构描述从内核到进程之间的一次数据传送。通过对iovec数组中的msg_iovlen字段求和得到

传送的字节数。结果保留在 `uio_resid` 中的 `len` 中。

```

471 recvit(p, s, mp, namelenp, rtsize)           ————— uipc_syscalls.c
472 struct proc *p;
473 int      s;
474 struct msghdr *mp;
475 caddr_t namelenp;
476 int      *rtsize;
477 {
478     struct file *fp;
479     struct uio auio;
480     struct iovec *iov;
481     int      i;
482     int      len, error;
483     struct mbuf *from = 0, *control = 0;
484     if (error = getsock(p->p_fd, s, &fp))
485         return (error);
486     auio.uio_iov = mp->msg iov;
487     auio.uio_iovcnt = mp->msg iovlen;
488     auio.uio_segflg = UIO_USERSPACE;
489     auio.uio_rw = UIO_READ;
490     auio.uio_procp = p;
491     auio.uio_offset = 0;          /* XXX */
492     auio.uio_resid = 0;
493     iov = mp->msg iov;
494     for (i = 0; i < mp->msg iovlen; i++, iov++) {
495         if (iov->iov_len < 0)
496             return (EINVAL);
497         if ((auio.uio_resid += iov->iov_len) < 0)
498             return (EINVAL);
499     }
500     len = auio.uio_resid;

```

————— uipc_syscalls.c

图16-30 `recvit` 函数：初始化 `uio` 结构

`recvit` 的第二部分调用 `soreceive`，并且将结果复制到进程，如图 16-31 所示。

```

501     if (error = soreceive((struct socket *) fp->f_data, &from, &auio,
502                           (struct mbuf **) 0, mp->msg_control ? &control : (struct mbuf **) 0,
503                           &mp->msg_flags)) {
504         if (auio.uio_resid != len && (error == ERESTART ||
505                                         error == EINTR || error == EWOULDBLOCK))
506             error = 0;
507     }
508     if (error)
509         goto out;
510     *rtsize = len - auio.uio_resid;
511     if (mp->msg_name) {
512         len = mp->msg_namelen;
513         if (len <= 0 || from == 0)
514             len = 0;
515         else {
516             if (len > from->m_len)
517                 len = from->m_len;
518             /* else if len < from->m_len ??? */
519             if (error = copyout(mtod(from, caddr_t),

```

图16-31 `recvit` 函数：返回结果

```

520                               (caddr_t) mp->msg_name, (unsigned) len))
521             goto out;
522         }
523         mp->msg_namerlen = len;
524         if (namelenp &&
525             (error = copyout((caddr_t) & len, namelenp, sizeof(int)))) {
526             goto out;
527         }
528     }
529     if (mp->msg_control) {
530         len = mp->msg_controllen;
531         if (len <= 0 || control == 0)
532             len = 0;
533         else {
534             if (len >= control->m_len)
535                 len = control->m_len;
536             else
537                 mp->msg_flags |= MSG_CTRUNC;
538             error = copyout((caddr_t) mtod(control, caddr_t),
539                             (caddr_t) mp->msg_control, (unsigned) len);
540         }
541         mp->msg_controllen = len;
542     }
543     out:
544     if (from)
545         m_freem(from);
546     if (control)
547         m_freem(control);
548     return (error);
549 }

```

uipc_syscalls.c

图16-31 (续)

1. 调用soreceive

501-510 soreceive实现从插口缓存中接收数据的最复杂的功能。传送的字节数保存在 *retsize中，并且返回给进程。如果有些数据已经被复制到进程后信号出现或阻塞出现 (len不等于uio_resid)，则忽略差错，并返回已经传送的字节。

2. 将地址和控制信息复制到进程

511-542 如果进程传入了一个存放地址或控制信息或两者都有的缓存，则 recvit将结果写入该缓存，并且根据soreceive返回的结果调整它们的长度。如果缓存太小，则地址信息可能被截掉。如果进程在发送读调用之前保留缓存的长度，将该长度同内核返回的namelenp变量(或sockaddr结构的长度域)相比较就可以发现这个差错。通过设置msg_flags中的MSG_CTRUNC标志来报告这种差错，参考习题16-7。

3. 释放缓存

543-549 从out开始，释放存储源地址和控制信息的mbuf缓存。

16.11 soreceive函数

soreceive函数将数据从插口的接收缓存传送到进程指定的缓存。某些协议还提供发送者的地址，地址可以同可能的附加控制信息一起返回。在讨论它的代码之前，先来讨论接收操作，带外数据和插口接收缓存的组织的含义。

图16-32 列出了在执行 `soreceive` 期间内核知道的一些标志。

flags	描述	参考
<code>MSG_DONTWAIT</code>	在调用期间不等待资源	图16-38
<code>MSG_OOB</code>	接收带外数据而不是正常的数据	图16-39
<code>MSG_PEEK</code>	接收数据的副本而不取走数据	图16-43
<code>MSG_WAITALL</code>	在返回之前等待数据写缓存	图16-50

图16-32 `recv xxx` 系统调用：传递给内核的标志值

`recvmsg` 是唯一返回标志字段给进程的读系统调用。在其他的系统调用中，控制返回给进程之前，这些信息被内核丢弃。图 16-33 列出了在 `msghdr` 中 `recvmsg` 能设置的标志。

msg_flags	描述	参考
<code>MSG_CTRUNC</code>	控制信息的长度大于提供的缓存长度	图16-31
<code>MSG_EOR</code>	收到的数据标志一个逻辑记录的结束	图16-48
<code>MSG_OOB</code>	缓存中包含带外数据	图16-45
<code>MSG_TRUNC</code>	收到的报文的长度大于提供的缓存长度	图16-51

图16-33 `recvmsg` 系统调用：内核返回的 `msg_flag` 值

16.11.1 带外数据

带外数据(OOB)在不同的协议中有不同的含义。一般来说，协议利用已建立的通信连接来发送 OOB 数据。OOB 数据可能与已发送的正常数据同序。插口层支持两种与协议无关的机制来实现对 OOB 数据的处理：标记和同步。本章讨论插口层实现的抽象的 OOB 机制。UDP 不支持 OOB 数据。TCP 的紧急数据机制与插口层的 OOB 数据之间的关系在 TCP 一章中描述。

发送进程通过在 `sendxxx` 调用中设置 `MSG_OOB` 标志将数据标记为 OOB 数据。`sosend` 将这个信息传递给插口协议，插口层收到这个信息后，对数据进行特殊处理，如加快发送数据或使用另一种排队策略。

当一个协议收到 OOB 数据后，并不将它放进插口的接收缓存而是放在其他地方。进程通过设置 `recvxxx` 调用中的 `MSG_OOB` 标志来接收到达的 OOB 数据。另一种方法是，通过设置 `SO_OOBINLINE` 插口选项(见第 17.3 节)，接收进程可以要求协议将 OOB 数据放在正常的数据之内。当 `SO_OOBINLINE` 被设置时，协议将收到的 OOB 数据放进正常数据的接收缓存。在这种情况下，`MSG_OOB` 不用来接收 OOB 数据。读调用要么返回所有的正常数据，要么返回所有的 OOB 数据。两种类型的数据从来不会在一个输入调用的输入缓存中混淆。进程使用 `recvmsg` 来接收数据时，可以通过检查 `MSG_OOB` 标志来决定返回的数据是正常数据还是 OOB 数据。

插口层支持 OOB 数据和正常数据的同步接收，采用的方法是允许协议在正常数据流中标记 OOB 数据起始点。接收者可以在每一个读系统调用的后面，通过 `SIOCATMARK` `ioc` 命令来检查是否已经达到 OOB 数据的起始点。当接收正常的数据时，插口层确保在一个报文中只有在标记前的正常数据才会收到，使得接收者接收的数据不会超过标记。如果在接收者到达标记之前收到一些附加的 OOB 数据，标记就自动向前移。

16.11.2 举例

图 16-34 说明两种接收带外数据的方法。在两个例子中，字节 A~I 作为正常数据接收，字

节J作为带外数据接收，字节K~L作为正常数据接收。接收进程已经接收了A之前(不包括A)的所有数据。

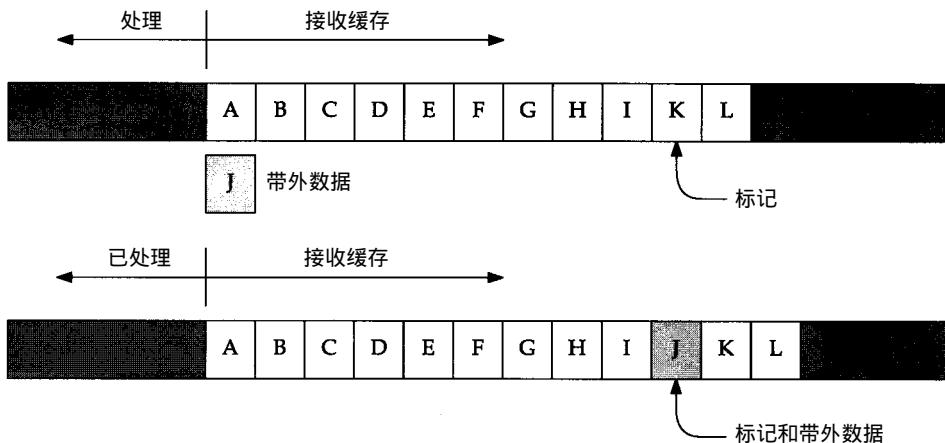


图16-34 接收带外数据

在第一个例子中，进程能够正确读出字节A~I，或者如果设置MSG_OOB，也能读出字节J。即使读请求的长度大于9个字节(A~I)，插口层也只返回9个字节，以免超过带外数据的同步标记。当读出字节I后，SIOCATMARK为真；对于到达带外数据标记的进程，不必读出字节J。

在第二个例子中，在SIOCATMARK为真时只能读字节A~I。第二次调用读字节J~L。

在图16-34中，字节J不是TCP的紧急数据指针指示的字节。在本例中，紧急指针指向的是字节K。有关细节请参考第29.7节。

16.11.3 其他的接收操作选项

进程能够通过设置标志MSG_PEEK来查看是否有数据到达。而数据仍然留在接收队列中，被下一个不设置MSG_PEEK的读调用读出。

标志MSG_WAITALL指示读调用只有在读到指定数量的数据后才返回。即使soreceive中有一些数据可以返回给进程，但它仍然要等到收到剩余的数据后才返回。

当标志MSG_WAITALL被设置后，soreceive只有在下列情况下可以在没有读完指定长度的数据时返回：

- 连接的读通道被关闭；
- 插口的接收缓存小于所读数据的大小；
- 在进程等待剩余的数据时差错出现；
- 带外数据到达；或
- 在读缓存被写满之前，一个逻辑记录的结尾出现。

NFS是Net/3中唯一使用MSG_WAITALL和MSG_DONTWAIT标志的软件。进程可以通过不通过ioctl或fcntl来选择非阻塞的I/O操作而是设置MSG_DONTWAIT标志来实现非阻塞的读系统调用。

16.11.4 接收缓存的组织：报文边界

对于支持报文边界的协议，每一个报文存放在一个mbuf链中。接收缓存中的多个报文通

过`m_nextpkt`指针链接成一个 mbuf队列(图2-21)。协议处理层加数据到接收队列，插口层从接收队列中移走数据。接收缓存的高水位标记限制了存储在缓存中的数据量。

如果`PR_ATOMIC`没有被置位，协议层尽可能多地在缓存中存放数据，丢弃输入数据中的不合要求的部分。对于 TCP，这就意味着到达的任何数据如果在接收窗口之外都将被丢弃。如果`PR_ATOMIC`被置位，缓存必须能够容纳整个报文，否则协议层将丢弃整个报文。对于 UDP而言，如果接收缓存已满，则进入的数据报都将被丢弃，缓存满的原因可能是进程读数据报的速度不够快。

`PR_ADDR`被置位的协议使用`sbappendaddr`构造一个 mbuf链，并将其加入到接收队列。缓存链包含一个存放报文源地址的 mbuf，0个或更多的控制 mbuf，后面跟着0个或更多的包含数据的 mbuf。

对于`SOCK_SEQPACKET`和`SOCK_RDM`协议，它们为每一个记录建立一个 mbuf链。如果`PR_ATOMIC`被置位，则调用`sbappendrecord`，将记录加到接收缓存的尾部。如果`PR_ATOMIC`没有被置位(OSI的TP4)，则用`sbappendrecord`产生一个新的记录，其余的数据用`sbappend`加到这个记录中。

假定`PR_ATOMIC`就是表示缓存的组织结构是不正确的。例如，TP4中并没有`PR_ATOMIC`，而是用`M_EOR`标志来支持记录边界。

图16-35说明了由三个 mbuf链(即三个数据报)组成的UDP接收缓存的结构。每一个 mbuf中都标有`m_type`的值。

在图16-35中，第三个数据报中有一些控制信息。三个 UDP插口选项能够导致控制信息被存入接收缓存。详细情况参考图 22-5 和图 23-7。

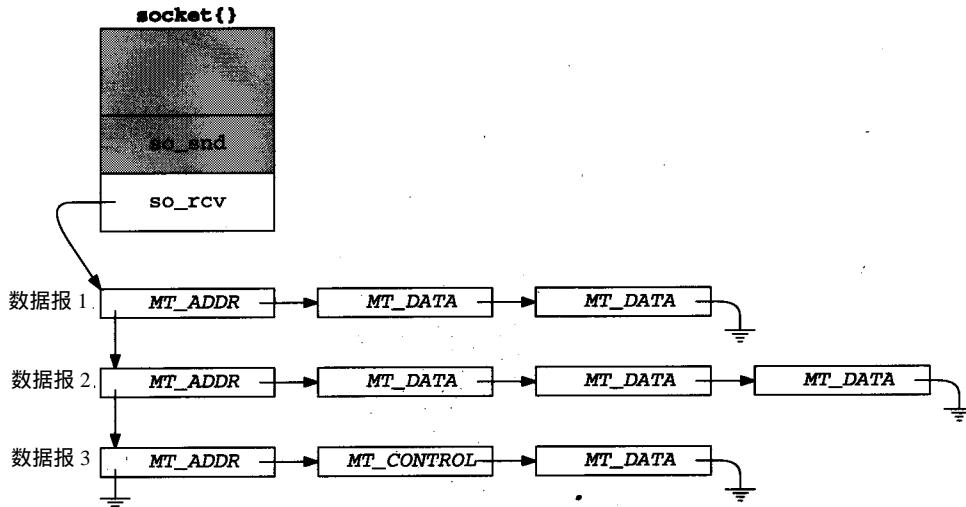


图16-35 包含三个数据报的 UDP接收缓存

对于`PR_ATOMIC`协议，当收到数据时，`sb_lowat`被忽略。当没有设置`PR_ATOMIC`时，`sb_lowat`的值等于读系统调用返回的最小的字节数。但也有一些例外，如图 16-41所示。

16.11.5 接收缓存的组织：没有报文边界

当协议不需维护报文边界(即`SOCK_STREAM`协议，如 TCP)时，通过`sbappend`将进入的

数据加到缓存中的最后一个 mbuf链的尾部。如果进入的数据长度大于缓存的长度，则数据将被截掉，`sb_lowat`为一个读系统调用返回的字节数设置了一个下限。

图16-36说明了仅仅包含正常数据的TCP接收缓存的结构。

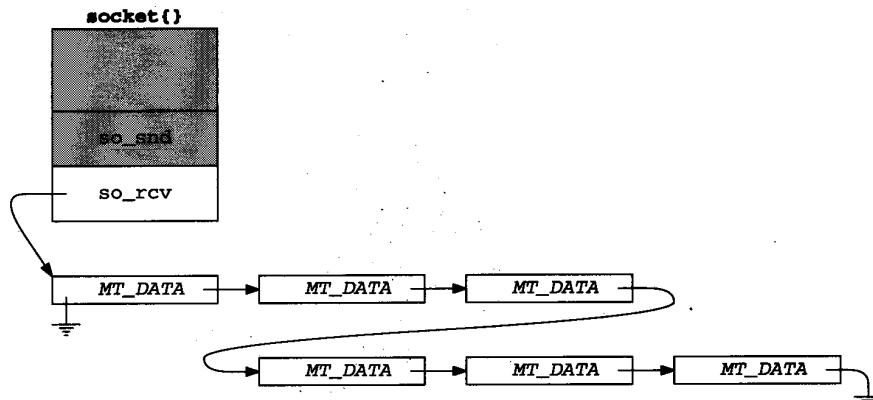


图16-36 TCP的`so_rcv` 缓存

16.11.6 控制信息和带外数据

不像TCP，一些流协议支持控制信息，并且调用 `sbappendcontrol` 将控制信息和相关数据作为一个新的 mbuf 链加入接收缓存。如果协议支持内含 OOB 数据，则调用 `sbinserttob` 插入一个新的 mbuf 链到任何包含 OOB 数据的 mbuf 链之后，但在任何包含正常数据的 mbuf 链之前。这一点确保进入的 OOB 数据总是排在正常数据之前。

图16-37说明包含控制信息和OOB数据的接收缓存的结构。

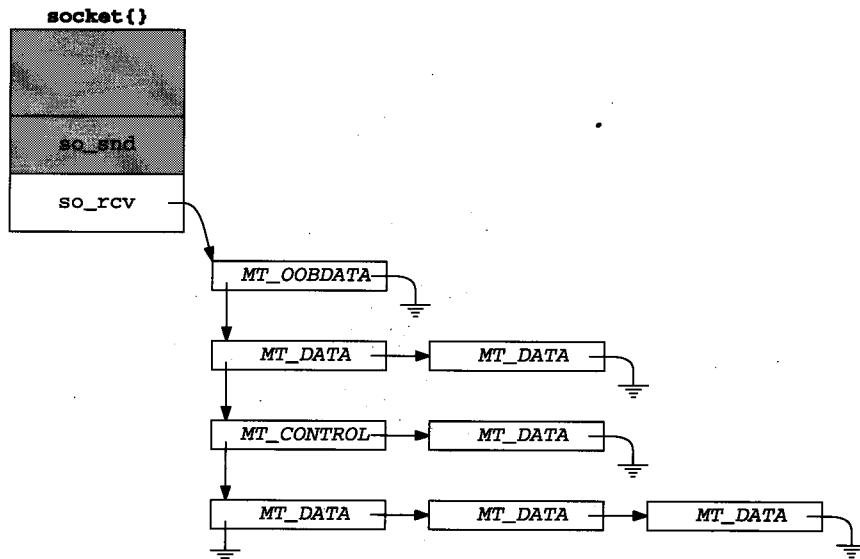


图16-37 带有控制信息和OOB数据的`so_rcv` 缓存

Unix域流协议支持控制信息，OSI TP4协议支持 `MT_OOBDATA` mbuf。TCP既不支持控制信息，也不支持 `MT_OOBDATA` 形式的带外数据。如果 TCP的紧急指针指向的字节存储在数据内(`SO_OOBINLINE`被设置)，那么该字节是正常数据而不是 OOB数据。TCP对紧急指针和相

关数据的处理在第29.7节中讨论。

16.12 soreceive代码

我们现在有足够的背景信息来详细讨论 soreceive函数。在接收数据时，soreceive必须检查报文边界，处理地址和控制信息以及读标志所指定的任何特殊操作（图16-32）。一般来说，soreceive的一次调用只处理一个记录，并且尽可能返回要求读的字节数。图 16-38 显示了soreceive函数的大概情况。

```
439 soreceive(so, paddr, uio, mp0, controlp, flagsp)           ————— uipc_socket.c
440 struct socket *so;
441 struct mbuf **paddr;
442 struct uio *uio;
443 struct mbuf **mp0;
444 struct mbuf **controlp;
445 int *flagsp;
446 {
447     struct mbuf *m, **mp;
448     int flags, len, error, s, offset;
449     struct protosw *pr = so->so_proto;
450     struct mbuf *nextrecord;
451     int moff, type;
452     int orig_resid = uio->uio_resid;

453     mp = mp0;
454     if (paddr)
455         *paddr = 0;
456     if (controlp)
457         *controlp = 0;
458     if (flagsp)
459         flags = *flagsp & ~MSG_EOR;
460     else
461         flags = 0;

                                         /* MSG_OOB processing and */
                                         /* implicit connection confirmation */

483     restart:
484     if (error = sblock(&so->so_rcv, SBLOCKWAIT(flags)))
485         return (error);
486     s = splnet();
487     m = so->so_rcv.sb_mb;

                                         /* if necessary, wait for data to arrive */

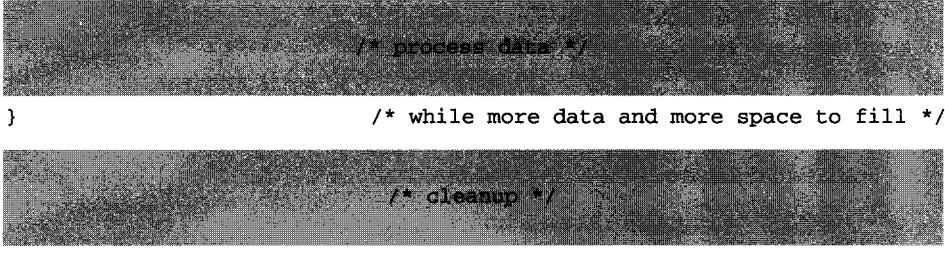
542     dontblock:
543     if (uio->uio_procp)
544         uio->uio_procp->p_stats->p_ru.ru_msgrcv++;
545     nextrecord = m->m_nextpkt;

                                         /* process address and control information */

591     if (m) {
```

图16-38 soreceive 函数：概述

```

592     if ((flags & MSG_PEEK) == 0)
593         m->m_nextpkt = nextrecord;
594     type = m->m_type;
595     if (type == MT_OOBDATA)
596         flags |= MSG_OOB;
597 }

693 } /* while more data and more space to fill */

715 release:
716     sbunlock(&so->so_rcv);
717     splx(s);
718     return (error);
719 }

```

uipc_socket.c

图16-38 (续)

439-446 *soreceive*有六个参数。指向插口的`so`指针。指向存放接收地址信息的`mbuf`缓存的指针`*paddr`。如果`mp0`指向一个`mbuf`链，则`soreceive`将接收缓存中的数据传送到`*mp0`指向的`mbuf`缓存链。在这种情况下，`uio`结构中只有用来记数的`uio_resid`字段是有意义的。如果`mp0`为空，则`soreceive`将数据传送到`uio`结构中指定的缓存。`*controlp`指向包含控制信息的`mbuf`缓存。`soreceive`将图16-33中描述的标志存放在`*flagsp`。

447-453 *soreceive*一开始将`pr`指向插口协议的交换结构，并将`uio_resid`(接收请求的大小)保存在`orig_resid`。如果将控制或地址信息从内核复制到进程，则将`orig_resid`清0。如果复制的是数据，则更新`uio_resid`。不管哪一种情况，`orig_resid`都不可能等于`uio_resid`。`soreceive`函数的最后处理要利用这一事实(图16-51)。

454-461 在这一段代码中，首先将`*paddr`和`*controlp`置空。在将`MSG_EOR`标志清0后，将传给`soreceive`的`*flagsp`的值保存在`flags`中(习题16.8)。`flagsp`是一个用来返回结果的参数，但是只有`recvmsg`系统调用才能收到结果。如果`flagsp`为空，则将`flags`清0。

483-487 在访问接收缓存之前，调用`sblock`给缓存加锁。如果`flags`中没有设置`MSG_DONTWAIT`标志，则`soreceive`必须等待加锁成功。

支持在内核中从NFS发调用到插口层带来了另一个负作用。

挂起协议处理，使得在检查缓存过程中`soreceive`不被中断。`m`是接收缓存中的第一个`mbuf`链上的第一个`mbuf`。

1. 如果需要，等待数据

488-541 *soreceive*要检查几种情况，并且如果需要，它可能要等待接收更多的数据才继续往下执行。如果`soreceive`在这里进入睡眠状态，则在它醒来后跳转到`restart`查看是否有足够的数据到达。这个过程一直继续，直到收到足够的数据为止。

542-545 当`soreceive`已收到足够的数据来满足读请求所要求的数据量时，就跳转到`dontblock`。并将指向接收缓存中的第二个`mbuf`链的指针保存在`nextrecord`中。

2. 处理地址和控制信息

542-545 在传送数据之前，首先处理地址信息和控制信息。

3. 建立数据传送

591-597 因为只有OOB数据或正常数据是在一次soreceive调用中传送，这段代码的功能就是记住队列前端的数据的类型，这样在类型改变时，soreceive能够停止传送。

4. 传送数据循环

598-692 只要缓存中还有mbuf（m不空），请求的数据还没有传送完毕(uio_resid>0)，且没有差错出现，本循环就不会退出。

退出处理

693-719 剩余的代码主要是更新指针、标志和偏移；释放插口缓存锁；使能协议处理并返回。

图16-39说明soreceive对OOB数据的处理。

```
462     if (flags & MSG_OOB) {                                     — uipc_socket.c
463         m = m_get(M_WAIT, MT_DATA);
464         error = (*pr->pr_usrreq) (so, PRU_RCVOOB,
465             m, (struct mbuf *) (flags & MSG_PEEK), (struct mbuf *) 0);
466         if (error)
467             goto bad;
468         do {
469             error = uiomove(mtod(m, caddr_t),
470                 (int) min(uio->uio_resid, m->m_len), uio);
471             m = m_free(m);
472         } while (uio->uio_resid && error == 0 && m);
473     bad:
474         if (m)
475             m_freem(m);
476         return (error);
477     }
```

— uipc_socket.c

图16-39 soreceive 函数：带外数据

5. 接收OOB数据

462-477 因为OOB数据不存放在接收缓存中，所以soreceive为其分配一块标准的mbuf，并给协议发送PRU_RCVOOB请求。while循环将协议返回的数据复制到uio指定的缓存中。复制完成后，soreceive返回0或差错代码。

对于PRU_RCVOOB请求，UDP协议总是返回EOPNOTSUPP。关于TCP的紧急数据的处理的详细情况参考第30.2节。图16-40说明soreceive对连接信息的处理。

```
478     if (mp)                                         — uipc_socket.c
479         *mp = (struct mbuf *) 0;
480     if (so->so_state & SS_ISCONFIRMING && uio->uio_resid)
481         (*pr->pr_usrreq) (so, PRU_RCVD, (struct mbuf *) 0,
482             (struct mbuf *) 0, (struct mbuf *) 0);
```

— uipc_socket.c

图16-40 soreceive 函数：连接信息

6. 连接证实

478-482 如果返回的数据存放在mbuf链中，则将*mp初始化成空。如果插口处于

SO_ISCONFIRMING状态，PRU_RCVD请求告知协议进程想要接收数据。

SO_ISCONFIRMING状态仅用于OSI的流协议，TP4。在TP4中，直到一个用户级进程通过发送或接收数据的方式来证实连接，该连接才被认为已完全建立。在通过调用getpeername来获取对方的身份后，进程可能调用shutdown或close来拒绝连接。

图16-38显示了图16-41中的代码在检查接收缓存时，接收缓存被加锁。soreceive的这部分代码的功能是查看接收缓存中的数据是否能满足读系统调用的要求。

```
488     /*  
489      * If we have less data than requested, block awaiting more  
490      * (subject to any timeout) if:  
491      *   1. the current count is less than the low water mark, or  
492      *   2. MSG_WAITALL is set, and it is possible to do the entire  
493      *      receive operation at once if we block (resid <= hiwat).  
494      *   3. MSG_DONTWAIT is not set  
495      *  
496      * If MSG_WAITALL is set but resid is larger than the receive buffer,  
497      * we have to do the receive in sections, and thus risk returning  
498      * a short count if a timeout or signal occurs after we start.  
499      */  
500  if (m == 0 || ((flags & MSG_DONTWAIT) == 0 &&  
501      so->so_rcv.sb_cc < uio->uio_resid) &&  
502      (so->so_rcv.sb_cc < so->so_rcv.sb_lowat ||  
503      ((flags & MSG_WAITALL) && uio->uio_resid <= so->so_rcv.sb_hiwat)) &&  
504      m->m_nextpkt == 0 && (pr->pr_flags & PR_ATOMIC) == 0) {  
    uipc_socket.c
```

图16-41 soreceive 函数：数据够吗？

7. 读调用的请求能满足吗？

488-504 一般情况下，soreceive要等待直到接收缓存中有足够的数据来满足整个读请求。但是，有几种情况可能导致差错或返回比读请求要求少的数据。

- 接收缓存没有数据(m等于0)。
- 缓存中的数据不能满足读请求要求的数量 (sb_cc<uio_resid) 并且没有设置MSG_DONTWAIT标志，最少的数据也得不到(sb_cc<sb_lowat)，且当该链到达时更多的数据能够加到链的后面(m_nextpkt等于0，且没有设置PR_ATOMIC)。
- 缓存中的数据不能满足读请求要求的数量，能得到最少的数据量，数据能够加到链中来，但是MSG_WAITALL指示soreceive必须等待直到缓存中的数据能满足读请求。

如果最后一种情况的条件能够满足，但是因为读请求的数据太大以至如果不阻塞等待就不能满足(uio_resid sb_hiwat)，soreceive就不等待而是继续往下执行。

如果接收缓存有数据，并且设置了MSG_DONTWAIT，则soreceive不等待更多的数据。

有几种原因使得等待更多的数据是不合适的。在图 16-42中，soreceive要么检查三种情况，然后返回；要么等待更多的数据到达。

8. 等待更多的数据吗？

505-534 在此处，soreceive已经决定等待更多的数据来满足读请求。在等待之前，它需要检查以下几种情况：

505-512 • 如果插口处于差错状态，且缓存为空(m为空)，则soreceive返回差错代码。如

如果有差错，但是接收缓存中有数据（m非空），则返回缓存的数据；当下一个读调用来时，如果没有数据，就返回差错。如果设置了 MSG_PEEK，就不清除差错，因为设置了 MSG_PEEK的读调用不能改变插口的状态。

513-518 • 如果连接的读通道已经被关闭并且数据仍在接收缓存中，则 sosend不等待而是将数据返回给进程（在dontblock的情况下）。如果接收缓存为空，则 soreceive跳转到 release，读系统调用返回0，表示连接的读通道已经被关闭。

519-523 • 如果接收缓存中包含带外数据或出现一个逻辑记录的结尾，则 soreceive不等待，而是跳转到dontblock。

524-528 • 如果协议请求中的连接不存在，则设置差错代码为 ENOTCONN，函数跳转到 release。

529-534 • 如果读请求读0字节或插口是非阻塞的，则函数跳转到 release，并返回0或 EWOULDBLOCK（后一种情况）。

```

505     if (so->so_error) {
506         if (m)
507             goto dontblock;
508         error = so->so_error;
509         if ((flags & MSG_PEEK) == 0)
510             so->so_error = 0;
511         goto release;
512     }
513     if (so->so_state & SS_CANTRCVMORE) {
514         if (m)
515             goto dontblock;
516         else
517             goto release;
518     }
519     for (; m; m = m->m_next)
520         if (m->m_type == MT_OOBDATA || (m->m_flags & M_EOR)) {
521             m = so->so_rcv.sb_mb;
522             goto dontblock;
523         }
524     if ((so->so_state & (SS_ISCONNECTED | SS_ISCONNECTING)) == 0 &&
525         (so->so_proto->pr_flags & PR_CONNREQUIRED)) {
526         error = ENOTCONN;
527         goto release;
528     }
529     if (uio->uio_resid == 0)
530         goto release;
531     if ((so->so_state & SS_NBIO) || (flags & MSG_DONTWAIT)) {
532         error = EWOULDBLOCK;
533         goto release;
534     }
535     sbunlock(&so->so_rcv);
536     error = sbwait(&so->so_rcv);
537     spix(s);
538     if (error)
539         return (error);
540     goto restart;
541 }
```

-uipc_socket.c

图16-42 soreceive 函数：等待更多的数据吗？

9. 是，等待更多的数据

535-541 此处soreceive已决定等待更多的数据，并且有理由这么做（即，将有数据到达）。在进程调用sbwait进入睡眠期间，缓存被解锁。如果因为差错或信号出现使得sbwait返回，则soreceive返回相应的差错；否则soreceive跳转到restart，查看接收缓存中的数据是否能够满足读请求。

同sosend中一样，进程能够利用SO_RCVTIMEO插口选项为sbwait设置一个接收定时器。如果在数据到达之前定时器超时，则sbwait返回EWOULDBLOCK。

定时器并不能总令人满意。因为当插口上有活动时，定时器每次都被重置。如果在一个超时间隔内至少有一个字节到达，则定时器从来不会超时，一直到设置了更长的超时值的读系统调用返回。sb_timeo是一个不活动定时器，并不要求超时值上限，但为了满足读系统调用，超时值的上限可能是必要的。

在此处，soreceive准备从接收缓存中传送数据。图16-43说明了地址信息的传送。

```
542 dontblock:
543     if (uio->uio_procp)
544         uio->uio_procp->p_stats->p_ru.ru_msgrcv++;
545     nextrecord = m->m_nextpkt;
546     if (pr->pr_flags & PR_ADDR) {
547         orig_resid = 0;
548         if (flags & MSG_PEEK) {
549             if (*paddr)
550                 *paddr = m_copy(m, 0, m->m_len);
551             m = m->m_next;
552         } else {
553             sbfree(&so->so_rcv, m);
554             if (*paddr) {
555                 *paddr = m;
556                 so->so_rcv.sb_mb = m->m_next;
557                 m->m_next = 0;
558                 m = so->so_rcv.sb_mb;
559             } else {
560                 MFREE(m, so->so_rcv.sb_mb);
561                 m = so->so_rcv.sb_mb;
562             }
563         }
564     }
```

—uipc_socket.c

—uipc_socket.c

图16-43 soreceive 函数：返回地址信息

10. dontblock

542-545 nextrecord指向接收缓存中的下一条记录。在soreceive的后面，当第一个链被丢弃后，该指针被用来将剩余的mbuf放入插口缓存。

11. 返回地址信息

546-564 如果协议提供地址信息，如UDP，则将从mbuf链中删除包含地址的mbuf，并通过*paddr返回。如果paddr为空，则地址被丢弃。

在soreceive中，如果设置了MSG_PEEK，则数据仍留在缓存中。

图16-44中的代码处理缓存中的控制mbuf。

12. 返回控制信息

565-590 每一个包含控制信息的 mbuf都将从缓存中删除(如果设置了MSG_PEEK，则不删除而是复制)，并连到*controlp。如果controlp为空，则丢弃控制信息。

```
565     while (m && m->m_type == MT_CONTROL && error == 0) {
566         if (flags & MSG_PEEK) {
567             if (controlp)
568                 *controlp = m_copy(m, 0, m->m_len);
569             m = m->m_next;
570         } else {
571             sbfree(&so->so_rcv, m);
572             if (controlp) {
573                 if (pr->pr_domain->dom_externalize &&
574                     mtod(m, struct cmsghdr *)->cmsg_type ==
575                     SCM_RIGHTS)
576                     error = (*pr->pr_domain->dom_externalize) (m);
577                 *controlp = m;
578                 so->so_rcv.sb_mb = m->m_next;
579                 m->m_next = 0;
580                 m = so->so_rcv.sb_mb;
581             } else {
582                 MFREE(m, so->so_rcv.sb_mb);
583                 m = so->so_rcv.sb_mb;
584             }
585         }
586         if (controlp) {
587             orig_resid = 0;
588             controlp = &(*controlp)->m_next;
589         }
590     }
```

uipc_socket.c

图16-44 soreceive 函数：处理控制信息

如果进程准备接收控制信息，则协议定义了一个dom_externalize函数，一旦控制信息mbuf中包含SCM_RIGHTS(访问权限)，就调用dom_externalize函数。该函数执行内核中所有接收访问权限的操作。只有 Unix域协议支持访问权限，有关细节在第 7.3节已讨论过。如果进程不准备接收控制信息(controlp为空)，则丢弃控制mbuf。

直到处理完所有包含控制信息的mbuf或出现差错时，循环才退出。

对于Unix协议域，dom_externalize函数通过修改接收进程的文件描述符表来实现文件描述符的传送。

处理完所有的控制mbuf后，m指向链中的下一个mbuf。如果在地址或控制信息的后面，链中没有其他的mbuf，则m为空。例如，当一个长度为0的数据报进入接收缓存时就会出现这种情况。图16-45说明了soreceive准备从mbuf链中传送数据。

```
591     if (m) {
592         if ((flags & MSG_PEEK) == 0)
593             m->m_nextpkt = nextrecord;
594         type = m->m_type;
595         if (type == MT_OOBDATA)
596             flags |= MSG_OOB;
597     }
```

uipc_socket.c

图16-45 soreceive 函数：准备传送mbuf

13. 准备传送数据

591-597 处理完控制 mbuf 后，链中应该只剩下正常数据、带外数据 mbuf 或没有任何 mbuf。如果 m 为空，则 soreceive 完成处理，控制跳到 while 循环的底部。如果 m 不空，所有剩余的 mbuf 链(nextrecord)都将重新连接到 m，并将下一个 mbuf 的类型赋给 type。如果下一个 mbuf 包含 OOB 数据，则设置 flags 中的 MSG_OOB 标志，并在最后返回给进程。因为 TCP 不支持 MT_OOBDATA 形式的带外数据，所以 MSG_OOB 不会返回给 TCP 插口上的读调用。

图 16-47 显示了传送 mbuf 循环的第一部分。图 16-46 列出了循环中更新的变量。

变 量	描 述
moff	当 MSG_PEEK 被置位时，将被传送的下一个字节的偏移位置
offset	当 MSG_PEEK 被置位时，OOB 标记的偏移位置
uioc_resid	还未传送的字节数
len	从本 mbuf 中将要传送的字节数；如果 uioc_resid 比较小或靠 OOB 标记比较近，则 len 可能小于 m_len。

图 16-46 soreceive 函数：循环内的变量

```
598     moff = 0;
599     offset = 0;
600     while (m && uioc_resid > 0 && error == 0) {
601         if (m->m_type == MT_OOBDATA) {
602             if (type != MT_OOBDATA)
603                 break;
604         } else if (type == MT_OOBDATA)
605             break;
606         so->so_state &= ~SS_RCVATMARK;
607         len = uioc_resid;
608         if (so->so_oobmark && len > so->so_oobmark - offset)
609             len = so->so_oobmark - offset;
610         if (len > m->m_len - moff)
611             len = m->m_len - moff;
612         /*
613          * If mp is set, just pass back the mbufs.
614          * Otherwise copy them out via the uioc, then free.
615          * Sockbuf must be consistent here (points to current mbuf,
616          * it points to next record) when we drop priority;
617          * we must note any additions to the sockbuf when we
618          * block interrupts again.
619          */
620         if (mp == 0) {
621             splx(s);
622             error = uiomove(mtod(m, caddr_t) + moff, (int) len, uioc);
623             s = splnet();
624         } else
625             uioc_resid -= len;
```

uipc_socket.c

图 16-47 soreceive 函数：uiomove

598-600 while 循环的每一次循环中，一个 mbuf 中的数据被传送到输出链或 uioc 缓存中。一旦链中没有 mbuf 或进程的缓存已满或出现差错，就退出循环。

14. 检查 OOB 和正常数据之前的变换

600-605 如果在处理 mbuf 链的过程中，mbuf 的类型发生变化，则立即停止传送，以确保正常数据和带外数据不会混合在一个返回的报文中。但是，这种检查不适用于 TCP。

15. 更新OOB标记

606-611 计算当前字节到oobmark之间的长度来限制传送的大小，所以oobmark的前一个字节为传送的最后一个字节。传送的大小同时还要受mbuf大小的限制。这段代码同样适用于TCP。

612-625 如果将数据传送到uio缓存，则调用uiomove。如果数据是作为一个mbuf链返回的，则更新uio_resid的值，使其等于传送的字节数。

为了避免在传送数据过程中协议处理挂起的时间太长，在调用uiomove过程中使能协议处理。所以，在uiomove运行的过程中，接收缓存中可能会出现新的数据。

图16-48中描述的代码说明调整指针和偏移准备传送下一个mbuf。

```

626     if (len == m->m_len - moff) {
627         if (m->m_flags & M_EOR)
628             flags |= MSG_EOR;
629         if (flags & MSG_PEEK) {
630             m = m->m_next;
631             moff = 0;
632         } else {
633             nextrecord = m->m_nextpkt;
634             sbfree(&so->so_rcv, m);
635             if (mp) {
636                 *mp = m;
637                 mp = &m->m_next;
638                 so->so_rcv.sb_mb = m = m->m_next;
639                 *mp = (struct mbuf *) 0;
640             } else {
641                 MFREE(m, so->so_rcv.sb_mb);
642                 m = so->so_rcv.sb_mb;
643             }
644             if (m)
645                 m->m_nextpkt = nextrecord;
646         }
647     } else {
648         if (flags & MSG_PEEK)
649             moff += len;
650         else {
651             if (mp)
652                 *mp = m_copym(m, 0, len, M_WAIT);
653             m->m_data += len;
654             m->m_len -= len;
655             so->so_rcv.sb_cc -= len;
656         }
657     }

```

- uipc_socket.c

图16-48 soreceive 函数：更新缓存

16. mbuf处理完毕了吗

626-646 如果mbuf中的所有字节都已传送完毕，则必须丢弃mbuf或将指针向前移。如果mbuf中包含了一个逻辑记录的结尾，还应设置MSG_EOR。如果将MSG_PEEK置位，则so_receive跳到下一个缓存。在没有将MSG_PEEK置位的情况下，如果数据已通过uiomove复制完成，则丢弃这块缓存；或者如果数据是作为一个mbuf链返回，则将缓存添加到mp中。

图16-49包含处理OOB偏移和MSG_EOR的代码段。

```

658     if (so->so_oobmark) {
659         if ((flags & MSG_PEEK) == 0) {
660             so->so_oobmark -= len;
661             if (so->so_oobmark == 0) {
662                 so->so_state |= SS_RCVATMARK;
663                 break;
664             }
665         } else {
666             offset += len;
667             if (offset == so->so_oobmark)
668                 break;
669         }
670     }
671     if (flags & MSG_EOR)
672         break;

```

```
uipc_socket.c
```

图16-49 soreceive 函数：带外数据标记

17. 更新OOB标记

658-670 如果带外数据标志等于非0，则将其减去已传送的字节数。如果已到达标记处，则将SS_RCVATMARK置位，soreceive跳出while循环。如果没有将MSG_PEEK置位，则更新offset，而不是so_oobmark。

18. 逻辑记录结束

671-672 如果已到达一个逻辑记录的结尾，则soreceive跳出mbuf处理循环，因而不会将下一个逻辑记录也作为这个报文的一部分返回。

在图16-50中，当设置了MSG_WAITALL标志，并且读请求还没有完成，则循环将等待更多的数据到达。

```

673     /*
674      * If the MSG_WAITALL flag is set (for non-atomic socket),
675      * we must not quit until "uio->uio_resid == 0" or an error
676      * termination. If a signal/timeout occurs, return
677      * with a short count but without error.
678      * Keep sockbuf locked against other readers.
679      */
680     while (flags & MSG_WAITALL && m == 0 && uio->uio_resid > 0 &&
681           !sosendallatonce(so) && !nextrecord) {
682         if (so->so_error || so->so_state & SS_CANTRCVMORE)
683             break;
684         error = sbwait(&so->so_rcv);
685         if (error) {
686             sbunlock(&so->so_rcv);
687             splx(s);
688             return (0);
689         }
690         if (m = so->so_rcv.sb_mb)
691             nextrecord = m->m_nextpkt;
692     }

```

```
uipc_socket.c
```

图16-50 soreceive 函数：MSG_WAITALL 处理

19. MSG_WAITALL

673-681 如果将MSG_WAITALL置位，而缓存中没有数据(m等于0)，调用者需要更多的数据，`sosendallatonce`为假，并且这是接收缓存中的最后一个记录(`nextrecord`为空)，则`soreceive`必须等待新的数据。

20. 差错或没有数据到达

682-683 如果差错出现或连接被关闭，则退出循环。

21. 等待数据到达

684-689 当接收缓存被协议层改变时`sbwait`返回。如果`sbwait`是被信号中断(error非0)，则`soreceive`立即返回。

22. 用接收缓存同步m和nextrecord

690-692 更新m和`nextrecord`，因为接收缓存被协议层修改了。如果数据到达`mbuf`，则m等于非0，while循环结束。

23. 处理下一个`mbuf`

693 本行是`mbuf`处理循环的结尾。控制返回到循环开始的第600行(图16-47)。一旦接收缓存中有数据，有新的缓存空间，没有差错出现，则循环继续。

如果`soreceive`停止复制数据，则执行图16-51所示的代码段。

```
694     if (m && pr->pr_flags & PR_ATOMIC) {
695         flags |= MSG_TRUNC;
696         if ((flags & MSG_PEEK) == 0)
697             (void) sbdroprecord(&so->so_rcv);
698     }
699     if ((flags & MSG_PEEK) == 0) {
700         if (m == 0)
701             so->so_rcv.sb_mb = nextrecord;
702         if (pr->pr_flags & PR_WANTRCVD && so->so_pcb)
703             (*pr->pr_usrreq) (so, PRU_RCVD, (struct mbuf *) 0,
704                                 (struct mbuf *) flags, (struct mbuf *) 0,
705                                 (struct mbuf *) 0);
706     }
707     if (orig_resid == uio->uio_resid && orig_resid &&
708         (flags & MSG_EOR) == 0 && (so->so_state & SS_CANTRCVMORE) == 0) {
709         sbunlock(&so->so_rcv);
710         splx(s);
711         goto restart;
712     }
713     if (flagsp)
714         *flagsp |= flags;
```

uipc_socket.c

uipc_socket.c

图16-51 `soreceive` 函数：退出处理

24. 被截断的报文

694-698 如果因为进程的接收缓存太小而收到一个被截断的报文(数据报或记录)，则插口层将这种情况通过设置MSG_TRUNC来通知进程，报文的被截断部分被丢弃。同其他接收标志一样，进程只有通过`recvmsg`系统调用才能获得MSG_TRUNC，即使`soreceive`总是设置这个标志。

25. 记录结尾的处理

699-706 如果没有将MSG_PEEK置位，则下一个`mbuf`链将被连接到接收缓存，并且如果发送了PRU_RCVD协议请求，则通知协议接收操作已经完成。TCP通过这种机制来完成对连接

接收窗口的更新。

26. 没有传送数据

707-712 如果soreceive运行完成，没有传送任何数据，没有到达记录的结尾，且连接的读通道是活动的，则将接收缓存解锁，soreceive跳回到restart继续等待数据。

713-714 soreceive中设置的任何标志都在*flagsp中返回，缓存被解锁，soreceive返回。

讨论

soreceive是一个复杂的函数。导致其复杂性的主要原因是繁锁的指针操作及对多种类型的数据(带外数据、地址、控制信息和正常数据)和多目标(进程缓存，mbuf链)的处理。

同sosend类似，soreceive的复杂性是多年积累的结果。为每一种协议编写一个特殊的接收函数将会模糊插口层和协议层之间的边界，但是可以大大简化代码。

[Partridge and Pink 1993]描述了一个专门为UDP编写的soreceive函数，其功能是将数据报从接收缓存复制到进程缓存中时给数据报求检验和。他们给出的结论是：修改通用的soreceive函数来支持这一功能将“使本来已经很复杂的插口子程序变得更加复杂。”

16.13 select系统调用

在下面的讨论中，我们假定读者熟悉select调用的基本操作和含义。关于select的应用接口的详细描述参考[Stevens 1992]。

图16-52列出了select能够监控的插口状态。

描 述	select监控的操作		
	读	写	例外
有数据可读	•		
连接的读通道被关闭	•		
listen插口已经将连接排队	•		
插口差错未处理	•		
缓存可供写操作用，且一个连接存在或还没有连接请求		•	
连接的写通道被关闭		•	
插口差错未处理		•	
OOB同步标记未处理			•

图16-52 select 系统调用：插口事件

我们从select系统调用的第一部分开始讨论，如图16-53所示。

1. 验证和初始化

390-410 在堆栈中分配两个数组：ibits和obits，每个数组有三个单元，每个单元为一个描述符集合。用bzero将它们清0。第一个参数，nd，必须不大于进程的描述符的最大数量。如果nd大于当前分配给进程的描述符个数，将其减少到当前分配给进程的描述符的个数。ni等于用来存放nd个比特(1个描述符占1个比特)的比特掩码所需的字节数。例如，假设最多有256个描述符(FD_SETSIZE)，falset表示一个32 bit的整型(NFDBITS)数组，且nd等于65，那么：

$$ni = \text{howmany}(65, 32) \times 4 = 3 \times 4 = 12$$

在上面的公式中，howmany(x, y)返回存储x比特所需要的长度为y比特的对象的数量。

sys_generic.c

```

390 struct select_args {
391     u_int    nd;
392     fd_set *in, *ou, *ex;
393     struct timeval *tv;
394 };
395 select(p, uap, retval)
396 struct proc *p;
397 struct select_args *uap;
398 int    *retval;
399 {
400     fd_set ibits[3], obits[3];
401     struct timeval atv;
402     int      s, ncoll, error = 0, timo;
403     u_int    ni;
404     bzero((caddr_t) ibits, sizeof(ibits));
405     bzero((caddr_t) obits, sizeof(obits));
406     if (uap->nd > FD_SETSIZE)
407         return (EINVAL);
408     if (uap->nd > p->p_fd->fd_nfiles)
409         uap->nd = p->p_fd->fd_nfiles; /* forgiving; slightly wrong */
410     ni = howmany(uap->nd, NFDBITS) * sizeof(fd_mask);
411 #define getbits(name, x) \
412     if (uap->name && \
413         (error = copyin((caddr_t)uap->name, (caddr_t)&ibits[x], ni))) \
414         goto done;
415     getbits(in, 0);
416     getbits(ou, 1);
417     getbits(ex, 2);
418 #undef getbits
419     if (uap->tv) {
420         error = copyin((caddr_t) uap->tv, (caddr_t) & atv,
421                         sizeof(atv));
422         if (error)
423             goto done;
424         if (itimerfix(&atv)) {
425             error = EINVAL;
426             goto done;
427         }
428         s = splclock();
429         timevaladd(&atv, (struct timeval *) &time);
430         timo = hzto(&atv);
431         /*
432          * Avoid inadvertently sleeping forever.
433          */
434         if (timo == 0)
435             timo = 1;
436         splx(s);
437     } else
438         timo = 0;

```

sys_generic.c

图16-53 Select 函数：初始化

2. 从进程复制文件描述符集

411-418 getbits宏用copyin从进程那里将文件描述符集合传送到 ibits中的三个描述符集合。如果描述符集合指针为空，则不需复制。

3. 设置超时值

419-438 如果tv为空，则将timeo置成0，select将无限期等待。如果tv非空，则将超时值复制到内核，并调用 itimerfix将超时值按硬件时钟的分辨率取整。调用 timevaladd将当前时间加到超时值中。调用 hzto计算从启动到超时之间的时钟滴答数，并保存在 timo中。如果计算出来的结果为0，将timeo置1，从而防止select阻塞，实现利用全0的timeval结构来实现非阻塞操作。

select的第二部分代码，如图 16-54所示。其作用是扫描进程指示的文件描述符，当一个或多个描述符处于就绪状态或定时器超时或信号出现时返回。

```

439    retry:
440        ncoll = nselcoll;
441        p->p_flag |= P_SELECT;
442        error = selscan(p, ibits, obits, uap->nd, retval);
443        if (error || *retval)
444            goto done;
445        s = splhigh();
446        /* this should be timercmp(&time, &atv, >=) */
447        if (uap->tv && (time.tv_sec > atv.tv_sec || 
448                         time.tv_sec == atv.tv_sec && time.tv_usec >= atv.tv_usec)) {
449            splx(s);
450            goto done;
451        }
452        if ((p->p_flag & P_SELECT) == 0 || nselcoll != ncoll) {
453            splx(s);
454            goto retry;
455        }
456        p->p_flag &= ~P_SELECT;
457        error = tsleep((caddr_t) & selwait, PSOCK | PCATCH, "select", timo);
458        splx(s);
459        if (error == 0)
460            goto retry;
461    done:
462        p->p_flag &= ~P_SELECT;
463        /* select is not restarted after signals... */
464        if (error == ERESTART)
465            error = EINTR;
466        if (error == EWOULDBLOCK)
467            error = 0;
468 #define putbits(name, x) \
469     if (uap->name && \
470         (error2 = copyout((caddr_t)&obits[x], (caddr_t)uap->name, ni))) \
471         error = error2;
472     if (error == 0) {
473         int      error2;
474         putbits(in, 0);
475         putbits(ou, 1);
476         putbits(ex, 2);
477 #undef putbits
478     }
479     return (error);
480 }
```

sys_generic.c

图16-54 select 函数：第二部分

4. 扫描文件描述符

439-442 从retry开始的循环直到select能够返回时退出。在调用进程的控制块中保存

全局整数nsecoll的当前值和P_SELECT标志。如果在selscan(图16-55)扫描文件描述符期间出现任何一种变化，则这种变化表明描述符的状态因为中断处理而发生改变，select必须重新扫描文件描述符。selscan查看三个输入的描述符集合中的每一个描述符集合，如果描述符处于就绪状态，则在输出的描述符集合中设置匹配的描述符。

```

481 selscan(p, ibits, obits, nfd, retval)           sys_generic.c
482 struct proc *p;
483 fd_set *ibits, *obits;
484 int     nfd, *retval;
485 {
486     struct filedesc *fdp = p->p_fd;
487     int      msk, i, j, fd;
488     fd_mask bits;
489     struct file *fp;
490     int      n = 0;
491     static int flag[3] =
492         {FREAD, FWRITE, 0};
493
494     for (msk = 0; msk < 3; msk++) {
495         for (i = 0; i < nfd; i += NFDBITS) {
496             bits = ibits[msk].fds_bits[i / NFDBITS];
497             while ((j = ffs(bits)) && (fd = i + --j) < nfd) {
498                 bits &= ~(1 << j);
499                 fp = fdp->fd_ofiles[fd];
500                 if (fp == NULL)
501                     return (EBADF);
502                 if ((*fp->f_ops->fo_select) (fp, flag[msk], p)) {
503                     FD_SET(fd, &obits[msk]);
504                     n++;
505                 }
506             }
507         }
508     *retval = n;
509     return (0);
510 }
```

sys_generic.c

图16-55 selscan 函数

5. 差错或一些描述符准备就绪

443-444 如果差错出现或描述符处于就绪状态，就立即返回。

6. 超时了吗

445-451 如果进程提供的时间限制和当前时间已经超过了超时值，则立即返回。

7. 在执行selscan期间状态发生变化

452-455 selscan可以被协议处理中断。如果在中断期间插口状态改变，则将P_SELECT和nsecoll置位，且selscan必须重新扫描所有描述符。

8. 等待缓存发生变化

456-460 所有调用select的进程均在调用tsleep时用selwait作为等待通道。如图16-60所示，这种做法在多个进程等待同一个插口缓存的情况下将导致效率降低。如果tsleep正确返回，则select跳转到retry，重新扫描所有描述符。

9. 准备返回

461-480 在done处清除P_SELECT，如果差错代码为ERESTART，则修改为EINTR；如果差错代码为EWOULDBLOCK，则将差错代码置成0。这些改变确保在select调用期间若信号出现时能返回EINTR；若超时，则返回0。

16.13.1 selscan函数

select函数的核心是图16-55所示的selscan函数。对于任意一个描述符集合中设置的每一个比特，selscan找出同它相关联的描述符，并且将控制分散给与描述符相关联的so_select函数。对于插口而言，就是soo_select函数。

1. 定位被监视的描述符

481-496 第一个for循环依次查看三个描述符集合：读，写和例外。第二个for循环在每个描述符集合内部循环，这个循环在集合中每隔32 bit(NFDBITS)循环一次。

最里面的while循环检查所有被32 bit的掩码标记的描述符，该掩码从当前描述符集合中获取并保存在bits中。函数ffs返回bits中的第一个被设置的比特的位置，从最低位开始。例如，如果bits等于1000（省略了前面的28个0），则ffs(bits)等于4。

2. 轮询描述符

497-500 从i到ffs函数的返回值，计算与比特相关的描述符，并保存在fd中。在bits中（而不是在输入描述符集合中）清除比特，找到与描述符相对应的file结构，调用fo_select。

fo_select的第二个参数是flag数组中的一个元素。msk是外层的for循环的循环变量。所以，第一次循环时，第二个参数等于FREAD，第二次循环时等于FWRITE，第三次循环时等于0。如果描述符不正确，则返回EBADF。

3. 描述符准备就绪

501-504 当发现某个描述符的状态为准备就绪时，设置输出描述符集合中相对应的比特位。并将n（状态就绪的描述符的个数）加1。

505-510 循环继续直到轮询完所有描述符。状态就绪的描述符的个数通过*retval返回。

16.13.2 soo_select函数

对于selscan在输入描述符集合中发现的每一个状态就绪的描述符，selscan调用与描述符相关的fileops结构（参考第15.5节）中的fo_select指针引用的函数。在本书中，我们只对插口描述符和图16-56所示的soo_select函数感兴趣。

```

105 soo_select(fp, which, p)                                ---sys_socket.c
106 struct file *fp;
107 int      which;
108 struct proc *p;
109 {
110     struct socket *so = (struct socket *) fp->f_data;
111     int      s = splnet();
112     switch (which) {
113         case FREAD:
114             if (soreadable(so)) {

```

图16-56 soo_select 函数

```

115         splx(s);
116         return (1);
117     }
118     selrecord(p, &so->so_rcv.sb_sel);
119     so->so_rcv.sb_flags |= SB_SEL;
120     break;
121
122     case FWRITE:
123         if (sowriteable(so)) {
124             splx(s);
125             return (1);
126         }
127         selrecord(p, &so->so_snd.sb_sel);
128         so->so_snd.sb_flags |= SB_SEL;
129         break;
130
131     case 0:
132         if (so->so_oobmark || (so->so_state & SS_RCVATMARK)) {
133             splx(s);
134             return (1);
135         }
136         selrecord(p, &so->so_rcv.sb_sel);
137         so->so_rcv.sb_flags |= SB_SEL;
138         break;
139     }
140 }
```

sys_socket.c

图16-56 (续)

105-112 `soo_select`每次被调用时，它只检查一个描述符的状态。如果相对于`which`中指定的条件，描述符处于就绪状态，则立即返回1。如果描述符没有处于就绪状态，就用`selrecord`标记插口的接收缓存或发送缓存，指示进程正在选择该缓存，然后`soo_select`返回0。

图16-52显示了插口的读、写和例外情况。我们将看到`soo_select`使用了`soreadable`和`sowriteable`宏，这些宏在`sys/socketvar.h`中定义。

1. 插口可读吗

113-120 `soreadable`宏的定义如下：

```
#define soreadable(so) \
    ((so)->so_rcv.sb_cc >= (so)->so_rcv.sb_lowat || \
    ((so)->so_state & SS_CANTRCVMORE) || \
    (so)->so_qlen || (so)->so_error)
```

因为UDP和TCP的接收下限默认值为1(图16-4)，下列情况表示插口是可读的：接收缓存中有数据，连接的读通道被关闭，可以接受任何连接或有挂起的差错。

2. 插口可写吗

121-128 `sowriteable`宏的定义如下：

```
#define sowriteable(so) \
    (sspace(&(so)->so_snd) >= (so)->so_snd.sb_lowat && \
    (((so)->so_state&SS_ISCONNECTED) || \
    ((so)->so_proto->pr_flags&PR_CONNREQUIRED)==0) || \
    ((so)->so_state & SS_CANTSENDMORE) || \
    (so)->so_error)
```

TCP和UDP默认的发送低水位标记是2048。对于UDP而言，`sowriteable`总是为真，因

为sbspace总是等于sb_hiwat，当然也总是大于或等于so_lowat，且不要求连接。

对于TCP而言，当发送缓存中的可用空间小于2048个字节时，插口不可写。其他的情况在图16-52中讨论。

3. 还有挂起的例外情况吗

129-140 对于例外情况，需检查标志so_oobmark和SS_RECVATMARK。直到进程读完数据流中的同步标记后，例外情况才可能存在。

16.13.3 selrecord函数

图16-57显示同发送和接收缓存存储在一起的selinfo结构的定义(图16-3中的sb_sel成员)。

```
41 struct selinfo {
42     pid_t    si_pid;           /* process to be notified */
43     short    si_flags;        /* 0 or SI_COLL */
44 };
```

select.h

图16-57 selinfo 结构

41-44 当只有一个进程对某一给定的插口缓存调用select时，sl_pid等于等待进程的进程标志符。当其他的进程对同一缓存调用select时，设置sl_flags中的SI_COLL标志。将这种情况称为冲突。这个标志是目前sl_flags中唯一已定义的标志。

当soo_select发现描述符不在就绪状态时就调用selrecord函数，如图16-58所示。该函数记录了足够的信息，使得缓存内容发生变化时协议处理层能够唤醒进程。

```
522 void
523 selrecord(selector, sip)
524 struct proc *selector;
525 struct selinfo *sip;
526 {
527     struct proc *p;
528     pid_t mypid;
529     mypid = selector->p_pid;
530     if (sip->si_pid == mypid)
531         return;
532     if (sip->si_pid && (p = pfind(sip->si_pid)) &&
533         p->p_wchan == (caddr_t) & selwait)
534         sip->si_flags |= SI_COLL;
535     else
536         sip->si_pid = mypid;
537 }
```

sys_generic.c

图16-58 selrecord 函数

1. 重复选择描述符

522-531 selrecord的第一个参数指向调用select进程的proc结构。第二个参数指向selinfo记录，该记录的so_snd.sb_sel和so_rcv.sb_sel可能会被修改。如果selinfo中已记录了该进程的信息，则立即返回。例如，进程对同一个描述符调用select查询读和例外情况时，函数就立即返回。

2. 同另一个进程的操作冲突？

532-534 如果另一个进程已经对同一插口缓存执行 select 操作，则设置 SI_COLL。

3. 没有冲突

535-537 如果调用没有发生冲突，则 si_pid 等于 0，将当前进程的进程标志符赋给 si_pid。

16.13.4 selwakeup函数

当协议处理改变插口缓存的状态，并且只有一个进程选择了该缓存时，Net/3就能根据 selinfo 结构中记录的信息立即将该进程放入运行队列。

当插口缓存发生变化但是有多个进程选择同一插口缓存时（设置了 SI_COLL），Net/3就无法确定哪些进程对这种缓存变化感兴趣。我们在讨论图 16-54 中的代码段时就已经指出，每一个调用 select 的进程在调用 tsleep 时使用 selwait 作为等待通道。这意味着对应的 wakeup 将唤醒所有阻塞在 select 上的进程——甚至是缓存的变化不关心的进程。

图 16-59 说明如何调用 selwakeup。

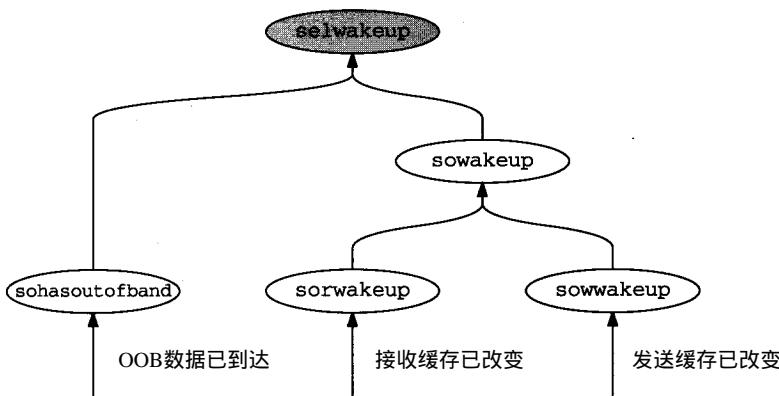


图 16-59 selwakeup 处理

当改变插口状态的事件出现时，协议处理层负责调用图 16-59 的底部列出的一个函数来通知插口层。图 16-59 底部显示的三个函数都将导致 selwakeup 被调用，在插口上选择的任何进程将被调度运行。

selwakeup 函数如图 16-60 所示。

541-548 如果 si_pid 等于 0，表明没有进程对该缓存执行 select 操作，函数立即返回。

在冲突中唤醒所有进程

549-553 如果多个进程对同一插口执行 select 操作，将 nselcoll 加 1，清除冲突标志，唤醒所有阻塞在 select 上的进程。正如图 16-54 中讨论的，进程在 tsleep 中阻塞之前若缓存发生改变，nselcoll 能使 select 重新扫描描述符（习题 16.9）。

554-567 如果 si_pid 标识的进程正在 selwait 中等待，则调度该进程运行。如果进程是在其他等待通道中，则清除 P_SELECT 标志。如果对一个正确的描述符执行 selrecord，则调用进程可能正在其他的等待通道中等待，然后，selscan 在描述符集合中发现一个差错的文件描述符，并返回 EBADF，不清除以前修改的 selinfo 记录。到 selwakeup 运行时，selwakeup

可能会发现sel_pid标识的进程不再在插口缓存等待，从而忽略selinfo中的信息。

如果没有出现多个进程共享同一个描述符的情况（也就是同一块插口缓存），当然这种情况很少，则只有一个进程被selwakeup唤醒。在作者使用的机器上，nseccoll总是等于0，这说明select冲突是很少发生的。

```

541 void
542 selwakeup(sip)
543 struct selinfo *sip;
544 {
545     struct proc *p;
546     int     s;
547     if (sip->si_pid == 0)
548         return;
549     if (sip->si_flags & SI_COLL) {
550         nseccoll++;
551         sip->si_flags &= ~SI_COLL;
552         wakeup((caddr_t) & selwait);
553     }
554     p = pfind(sip->si_pid);
555     sip->si_pid = 0;
556     if (p != NULL) {
557         s = splhigh();
558         if (p->p_wchan == (caddr_t) & selwait) {
559             if (p->p_stat == SSLEEP)
560                 setrunnable(p);
561             else
562                 unsleep(p);
563         } else if (p->p_flag & P_SELECT)
564             p->p_flag &= ~P_SELECT;
565         splx(s);
566     }
567 }
```

sys_generic.c

图16-60 selwakeup 函数

16.14 小结

本章介绍了插口的读、写和选择系统调用。

我们了解到sosend处理插口层与协议处理层之间的所有输出，而soreceive处理所有输入。

本章还介绍了发送缓存和接收缓存的组织结构，以及缓存的高、低水位标记的默认值和含义。

本章的最后一部分介绍了select系统调用。从这部分内容中我们了解到，当只有一个进程对描述符执行select调用时，协议处理层仅仅唤醒selinfo结构中标识的那个进程。当有多个进程对同一个描述符执行select操作而发生冲突时，协议层只能唤醒所有等待在该描述符上的进程。

习题

16.1 当将一个大于最大的正的有符号整数的无符号整数传给 write系统调用时，

sosend中的resid如何变化？

- 16.2 当sosend将小于MCLBYTES个字节的数据放入簇中时，space被减去MCLBYTES，可能会成为一个负数，这会导致为atomic协议填写mbuf的循环结束。这种结果是正常的吗？
- 16.3 数据报和流协议有着不同的语义。将sosend和soreceive函数分别分成两个函数，一个用来处理报文，另一个用来处理流。除了使得代码清晰外，这样做还有什么好处？
- 16.4 对于PR_ATOMIC协议，每一个写调用都指定了一个隐含的报文边界。插口层将这个报文作为一个整体交给协议。MSG_EOR标志允许进程显式指定报文边界。为什么仅有隐含的报文边界是不够的？
- 16.5 如果插口描述符没有标记为非阻塞，且进程也没有指定MSG_DONTWAIT，当sosend不能立即获取发送缓存上的锁时，结果如何？
- 16.6 在什么情况下，虽然sb_cc<sb_hiwat，但sbspace仍然报告没有闲置空间？为什么在这种情况下进程应该被阻塞？
- 16.7 为什么recvit不将控制报文的长度而是将名字长度返回给进程？
- 16.8 为什么soreceive要清除MSG_EOR？
- 16.9 如果将nse1coll代码从select和selwakeup中删除，会有什么问题？
- 16.10 修改select系统调用，使得select返回时返回定时器的剩余时间。

第17章 插口选项

17.1 引言

本章讨论修改插口行为的几个系统调用，以此来结束插口层的介绍。

setsockopt和getsockopt系统调用已在第8.8节中介绍过，主要描述访问IP特点的选项。在本章中，我们将介绍这两个系统调用的实现以及通过它们来控制的插口级选项。

ioctl函数在第4.4节中已介绍过，在第4.4节中，我们描述了用于网络接口配置的与协议无关的ioctl命令。在第6.7节中，我们描述了用来分配网络掩码以及单播、多播和目的地址的IP专用的ioctl命令。本章我们将介绍ioctl的实现和fcntl函数的相关特点。

最后，我们介绍getsockname和getpeername系统调用，它们用来返回插口和连接的地址信息。

图17-1列出了实现插口选项系统调用的函数。本章描述带阴影的函数。

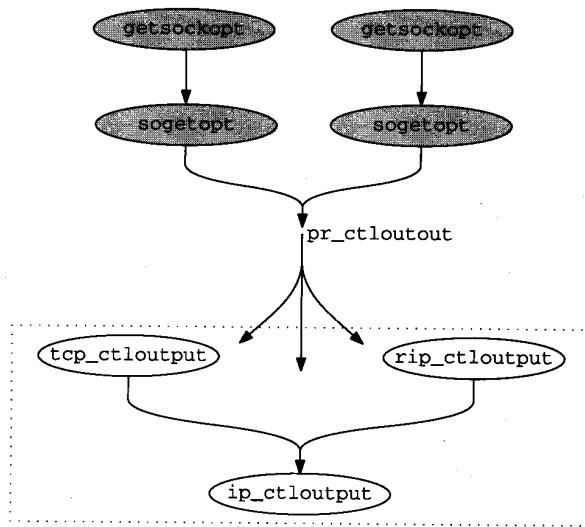


图17-1 setsockopt 和getsockopt 系统调用

17.2 代码介绍

本章中涉及的源代码来自于图17-2中列出的四个文件。

文件名	说 明
kern/kern_descrip.c	fcntl系统调用
kern/uipc_syscalls.c	setsockopt、getsockopt、getsockname和getpeername系统调用
kern/uipc_socket.c	插口层对setsockopt和getsockopt的处理
kern/sys_socket.c	ioctl系统调用对插口的处理

图17-2 本章讨论的源文件

全局变量和统计量

本章中描述的系统调用没有定义新的全局变量，也没有收集任何统计量。

17.3 setsockopt系统调用

图8-29列出了函数setsockopt(和getsockopt)能够访问的各种不同的协议层。本章主要集中在SOL_SOCKET级的选项，这些选项在图17-3中列出。

<i>optname</i>	<i>optval</i> 类型	变 量	说 明
<i>SO_SNDBUF</i>	int	<i>so_snd.sb_hiwat</i>	发送缓存高水位标记
<i>SO_RCVBUF</i>	int	<i>so_rcv.sb_hiwat</i>	接收缓存高水位标记
<i>SO SNDLOWAT</i>	int	<i>so_snd.sb_lowat</i>	发送缓存低水位标记
<i>SO RCVLOWAT</i>	int	<i>so_rcv.sb_lowat</i>	接收缓存低水位标记
<i>SO_SNDTIMEO</i>	struct timeval	<i>lso_snd.sb_timeo</i>	发送超时值
<i>SO_RCVTIMEO</i>	struct timeval	<i>lso_rcv.sb_timeo</i>	接收超时值
<i>SO_DEBUG</i>	int	<i>so_options</i>	记录插口调试信息
<i>SO_REUSEADDR</i>	int	<i>so_options</i>	插口能重新使用一个本地地址
<i>SO_REUSEPORT</i>	int	<i>so_options</i>	插口能重新使用一个本地端口
<i>SO_KEEPALIVE</i>	int	<i>so_options</i>	协议查询空闲的连接
<i>SO_DONTROUTE</i>	int	<i>so_options</i>	旁路路由表
<i>SO_BROADCAST</i>	int	<i>so_options</i>	插口支持广播报文
<i>SO_USELOOPBACK</i>	int	<i>so_options</i>	仅用于选路域插口；发送进程接收自己的选路报文
<i>SO_OOBINLINE</i>	int	<i>so_options</i>	协议排队内联的带外数据
<i>SO_LINGER</i>	struct linger	<i>so_linger</i>	插口关闭但仍发送剩余数据
<i>SO_ERROR</i>	int	<i>so_error</i>	获取差错状态并清除；只用于getsockopt
<i>SO_TYPE</i>	int	<i>so_type</i>	获取插口类型；只用于getsockopt
其他			返回ENOPROTOOPT

图17-3 setsockopt 和getsockopt 选项

setsockopt函数原型为：

```
int setsockopt(int s, int level, int optname, void *optval, int optlen);
```

图17-4显示了setsockopt调用的源代码。

565-597 getsock返回插口描述符的file结构。如果val非空，则将valsizel个字节的数据从进程复制到用m_get分配的mbuf中。与选项对应的数据长度不能超过MLEN个字节，所以，如果valsizel大于MLEN，则返回EINVAL。调用so_setopt，并返回其值。

```
565 struct setsockopt_args {
566     int      s;
567     int      level;
568     int      name;
569     caddr_t  val;
570     int      valsizel;
571 };
572 setsockopt(p, uap, retval)
573 struct proc *p;
574 struct setsockopt_args *uap;
575 int      *retval;
```

图17-4 setsockopt 系统调用

```

576 {
577     struct file *fp;
578     struct mbuf *m = NULL;
579     int     error;
580
581     if (error = getsock(p->p_fd, uap->s, &fp))
582         return (error);
583     if (uap->valsize > MLEN)
584         return (EINVAL);
585     if (uap->val) {
586         m = m_get(M_WAIT, MT_SOOPTS);
587         if (m == NULL)
588             return (ENOBUFS);
589         if (error = copyin(uap->val, mtod(m, caddr_t),
590                            (u_int) uap->valsize)) {
591             (void) m_free(m);
592             return (error);
593         }
594         m->m_len = uap->valsize;
595     }
596     return (sosetopt((struct socket *) fp->f_data, uap->level,
597                      uap->name, m));
597 }

```

uipc_syscalls.c

图17-4 (续)

sosetopt函数

sosetopt函数处理所有插口级的选项，并将其他的选项传给与插口关联的协议的pr_ctloutput函数。图17-5列出了sosetopt函数的部分代码。

```

752 sosetopt(so, level, optname, m0)
753 struct socket *so;
754 int    level, optname;
755 struct mbuf *m0;
756 {
757     int     error = 0;
758     struct mbuf *m = m0;
759
760     if (level != SOL_SOCKET) {
761         if (so->so_proto && so->so_proto->pr_ctloutput)
762             return ((*so->so_proto->pr_ctloutput)
763                     (PRCO_SETOPT, so, level, optname, &m0));
764         error = ENOPROTOOPT;
765     } else {
766         switch (optname) {

```

/ socket option processing */*

```

841     default:
842         error = ENOPROTOOPT;
843         break;
844     }
845     if (error == 0 && so->so_proto && so->so_proto->pr_ctloutput) {
846         (void) ((*so->so_proto->pr_ctloutput)
847                  (PRCO_SETOPT, so, level, optname, &m0));

```

图17-5 sosetopt 函数

```

848             m = NULL;           /* freed by protocol */
849         }
850     }
851     bad:
852     if (m)
853         (void) m_free(m);
854     return (error);
855 }

```

—uipc_socket.c

图17-5 (续)

752-764 如果选项不是插口级的(SOL_SOCKET)选项，则给底层协议发送PRCO_SETOPT请求。注意：调用的是协议的pr_ctloutput函数，而不是它的pr_usrreq函数。图17-6说明了Internet协议调用的pr_ctloutput函数。

协议	pr_ctloutput函数	参考
UDP	ip_ctloutput	第8.8节
TCP	tcp_ctloutput	第30.6节
ICMP		
IGMP	rip_ctloutput和ip_ctloutput	第8.8节和第32.8节
原始IP		

图17-6 pr_ctloutput 函数

765 switch语句处理插口级的选项。

841-844 对于不认识的选项，在保存它的mbuf被释放后返回ENOPROTOOPT。

845-855 如果没有出现差错，则控制总是会执行到switch。在switch语句中，如果协议层需要响应请求或插口层，则将选项传送给相应的协议。Internet协议中没有一个预期处理插口级的选项。

注意，如果协议收到不预期的选项，则直接将其pr_ctloutput函数的返回值丢弃。并将m置空，以免调用m_free，因为协议负责释放缓存。

图17-7说明了linger选项和在插口结构中设置单一标志的选项。

766-772 linger选项要求进程传入linger结构：

```

struct linger {
    int l_onoff;    /* option on/off */
    int l_linger;   /* linger time in seconds */
};

```

确保进程已传入长度为linger结构大小的数据后，将结构成员l_linger复制到so_linger中。在下一组case语句后决定是使能还是关闭该选项。so_linger和close系统调用在第15.15节中已介绍过。

773-789 当进程传入一个非0值时，设置选项对应的布尔标志；当进程传入的是0时，将对应标志清除。第一次检查确保一个整数大小(或更大)的对象在mbuf中，然后设置或清除对应的选项。

图17-8显示了插口缓存选项的处理。

790-815 这组选项改变插口的发送和接收缓存的大小。第一个if语句确保提供给四个选项的变量是整型。对于SO_SNDBUF和SO_RCVBUF，sbreserve只调整缓存的高水位标记而不

分配缓存。对于SO_SNDLOWAT和SO_RCVLOWAT，调整缓存的低水位标记。

```
766     case SO_LINGER:
767         if (m == NULL || m->m_len != sizeof(struct linger)) {
768             error = EINVAL;
769             goto bad;
770         }
771         so->so_linger = mtod(m, struct linger *)->l_linger;
772         /* fall thru... */
773
774     case SO_DEBUG:
775     case SO_KEEPALIVE:
776     case SO_DONTROUTE:
777     case SO_USELOOPBACK:
778     case SO_BROADCAST:
779     case SO_REUSEADDR:
780     case SO_REUSEPORT:
781     case SO_OOBINLINE:
782         if (m == NULL || m->m_len < sizeof(int)) {
783             error = EINVAL;
784             goto bad;
785         }
786         if (*mtod(m, int *))
787             so->so_options |= optname;
788         else
789             so->so_options &= ~optname;
790         break;
```

—uipc_socket.c

图17-7 soisetopt 函数：linger 和标志选项

```
790     case SO_SNDBUF:
791     case SO_RCVBUF:
792     case SO SNDLOWAT:
793     case SO_RCVLOWAT:
794         if (m == NULL || m->m_len < sizeof(int)) {
795             error = EINVAL;
796             goto bad;
797         }
798         switch (optname) {
799
800             case SO_SNDBUF:
801             case SO_RCVBUF:
802                 if (sbreserve(optname == SO_SNDBUF ?
803                               &so->so_snd : &so->so_rcv,
804                               (u_long) * mtod(m, int *)) == 0) {
805                     error = ENOBUFS;
806                     goto bad;
807                 }
808                 break;
809
810             case SO SNDLOWAT:
811                 so->so_snd.sb_lowat = *mtod(m, int *);
812                 break;
813             case SO_RCVLOWAT:
814                 so->so_rcv.sb_lowat = *mtod(m, int *);
815                 break;
816         }
817         break;
```

—uipc_socket.c

图17-8 soisetopt 函数：插口缓存选项

图17-9说明超时选项。

```

816     case SO_SNDDTIMEO:
817     case SO_RCVTIMEO:
818     {
819         struct timeval *tv;
820         short val;
821
822         if (m == NULL || m->m_len < sizeof(*tv)) {
823             error = EINVAL;
824             goto bad;
825         }
826         tv = mtod(m, struct timeval *);
827         if (tv->tv_sec > SHRT_MAX / hz - hz) {
828             error = EDOM;
829             goto bad;
830         }
831         val = tv->tv_sec * hz + tv->tv_usec / tick;
832         switch (optname) {
833             case SO_SNDDTIMEO:
834                 so->so_snd.sb_timeo = val;
835                 break;
836             case SO_RCVTIMEO:
837                 so->so_rcv.sb_timeo = val;
838                 break;
839         }
840     }

```

—uipc_socket.c

图17-9 soisetopt 函数：超时选项

816-824 进程在timeval结构中设置SO_SNDDTIMEO和SO_RCVTIMEO选项的超时值。如果传入的数值不正确，则返回EINVAL。

825-830 存储在timeval结构中的时间间隔值不能太大，因为sb_timeo是一个短整数，当时间间隔值的单位为一个时钟滴答时，时间间隔值的大小就不能超过一个短整数的最大值。

第826行代码是不正确的。在下列条件下，时间间隔不能表示为一个短整数：

$$tv_sec \times hz + \frac{tv_usec}{tick} > SHRT_MAX$$

其中， $tick=1\ 000\ 000$ 和 $SHRT_MAX=32767$

所以，如果下列不等式成立，则返回。

$$tv_sec > \frac{SHRT_MAX}{hz} - \frac{tv_usec}{tick \times hz} = \frac{SHRT_MAX}{hz} - \frac{tv_usec}{1\ 000\ 000}$$

等式的最后一项不是代码指明的hz。正确的测试代码应该是：

```

if ((tv->tv_sec * hz + tv->tv_usec / tick) > SHRT_MAX)
    error = EDOM;

```

习题17.3中有更详细的讨论。

831-840 将转换后的时间，val，保存在请求的发送或接收缓存中。sb_timeo限制了进程等待接收缓存中的数据或发送缓存中的闲置空间的时间。详细讨论参考第16.7和16.11节。

超时值是传给tsleep的最后一个参数，因为tsleep要求超时值为一个整数，所以进程最多只能等待65535个时钟滴答。假设时钟频率为100 Hz，则等待时间小于11分钟。

17.4 getsockopt系统调用

getsockopt返回进程请求的插口和协议选项。函数原型是：

```
int getsockopt(int s, int level, int name, caddr_t val, int *valsize);
```

该调用的源代码如图17-10所示。

```
598 struct getsockopt_args {
599     int      s;
600     int      level;
601     int      name;
602     caddr_t  val;
603     int      *avalsize;
604 };
605 getsockopt(p, uap, retval)
606 struct proc *p;
607 struct getsockopt_args *uap;
608 int      *retval;
609 {
610     struct file *fp;
611     struct mbuf *m = NULL;
612     int      valsiz, error;
613
614     if (error = getsock(p->p_fd, uap->s, &fp))
615         return (error);
616     if (uap->val) {
617         if (error = copyin((caddr_t) uap->avalsize, (caddr_t) & valsiz,
618                             sizeof(valsiz)))
619             return (error);
620     } else
621         valsiz = 0;
622     if ((error = so getopt((struct socket *) fp->f_data, uap->level,
623                           uap->name, &m)) == 0 && uap->val && valsiz && m != NULL) {
624         if (valsiz > m->m_len)
625             valsiz = m->m_len;
626         error = copyout(mtod(m, caddr_t), uap->val, (u_int) valsiz);
627         if (error == 0)
628             error = copyout((caddr_t) & valsiz,
629                             (caddr_t) uap->avalsize, sizeof(valsiz));
630     }
631     if (m != NULL)
632         (void) m_free(m);
633 }


---


```

uipc_syscalls.c

图17-10 getsockopt 系统调用

598-633 这段代码现在看上去应该很熟悉了。getsock获取插口的file结构，将选项缓存的大小复制到内核，调用so getopt来获取选项的值。将so getopt返回的数据复制到进程提供的缓存，可能还需修改缓存长度。如果进程提供的缓存不够大，则返回的数据可能会被截掉。通常情况下，存储选项数据的mbuf在函数返回后被释放。

so getopt函数

同so getopt一样，so getopt函数处理所有插口级的选项，并将其他的选项传给与插口关联的协议。图17-11列出了so getopt函数的开始和结束部分的代码。

```

856 so getopt(so, level, optname, mp)
857 struct socket *so;
858 int      level, optname;
859 struct mbuf **mp;
860 {
861     struct mbuf *m;
862
863     if (level != SOL_SOCKET) {
864         if (so->so_proto && so->so_proto->pr_ctloutput) {
865             return ((*so->so_proto->pr_ctloutput)
866                     (PRCO_GETOPT, so, level, optname, mp));
867         } else
868             return (ENOPROTOOPT);
869     } else {
870         m = m_get(M_WAIT, MT_SOOPTS);
871         m->m_len = sizeof(int);
872
873         switch (optname) {
874
875             /* socket option processing */
876
877             default:
878                 (void) m_free(m);
879                 return (ENOPROTOOPT);
880             }
881             *mp = m;
882             return (0);
883         }
884     }
885 }
```

— uipc_socket.c

图17-11 so getopt 函数：概述

856-871 同 sosetopt一样，函数将那些与插口级选项无关的选项立即通过PRCO_GETOPT协议请求传递给相应的协议级。协议将被请求的选项保存在mp指向的mbuf中。

对于插口级的选项，分配一块标准的mbuf缓存来保存选项值，选项值通常是一个整数，所以将m_len设成整数大小。相应的选项值通过switch语句复制到mbuf中。

918-925 如果执行的是switch中的default情况下的语句，则释放mbuf，并返回ENOPROTOOPT。否则，switch语句执行完成后，将指向mbuf的指针赋给*mp。当函数返回后，getsockopt从该mbuf中将数据复制到进程提供的缓存，并释放mbuf。

图17-12说明对SO_LINGER选项和作为布尔型标志实现的选项的处理。

872-877 SO_LINGER选项请求返回两个值：一个是标志值，赋给l_onoff；另一个是拖延时间，赋给l_linger。

878-887 其余的选项作为布尔标志实现。将so_options和optname执行逻辑与操作，如果选项被打开，则与操作的结果为非0值；反之则结果为0。注意：标志被打开并不表示返回值等于1。

so getopt的下一部分代码(图17-13)将整型值选项的值复制到mbuf中。

888-906 将每一个选项作为一个整数复制到mbuf中。注意：有些选项在内核中是作为一个短整数存储的(如缓存高低水位标记)，但是作为整数返回。一旦将so_error复制到mbuf中后，即清除so_error，这是唯一的一次getsockopt调用修改插口状态。

```

872     case SO_LINGER:
873         m->m_len = sizeof(struct linger);
874         mtod(m, struct linger *)->l_onoff =
875             so->so_options & SO_LINGER;
876         mtod(m, struct linger *)->l_linger = so->so_linger;
877         break;
878
879     case SO_USELOOPBACK:
880     case SO_DONTROUTE:
881     case SO_DEBUG:
882     case SO_KEEPALIVE:
883     case SO_REUSEADDR:
884     case SO_REUSEPORT:
885     case SO_BROADCAST:
886     case SO_OOBINLINE:
887         *mtod(m, int *) = so->so_options & optname;
888         break;

```

—uipc_socket.c

图17-12 so getopt 选项：SO_LINGER 选项和布尔选项

```

888     case SO_TYPE:
889         *mtod(m, int *) = so->so_type;
890         break;
891
892     case SO_ERROR:
893         *mtod(m, int *) = so->so_error;
894         so->so_error = 0;
895         break;
896
897     case SO_SNDBUF:
898         *mtod(m, int *) = so->so_snd.sb_hiwat;
899         break;
900
901     case SO_RCVBUF:
902         *mtod(m, int *) = so->so_rcv.sb_hiwat;
903         break;
904
905     case SO_SNDLOWAT:
906         *mtod(m, int *) = so->so_snd.sb_lowat;
907         break;
908
909     case SO_RCVLOWAT:
910         *mtod(m, int *) = so->so_rcv.sb_lowat;
911         break;

```

—uipc_socket.c

图17-13 so getopt 函数：整型值选项

```

907     case SO SNDTIMEO:
908     case SO RCVTIMEO:
909     {
910         int      val = (optname == SO SNDTIMEO ?
911                     so->so_snd.sb_timeo : so->so_rcv.sb_timeo);
912
913         m->m_len = sizeof(struct timeval);
914         mtod(m, struct timeval *)->tv_sec = val / hz;
915         mtod(m, struct timeval *)->tv_usec =
916             (val % hz) / tick;
917         break;
918     }

```

—uipc_socket.c

图17-14 so getopt 函数：超时选项

图17-14列出了so getopt的第三和第四部分代码，它们的作用分别是处理SO_SNDTIMEO和SO_RCVTIMEO选项。

907-917 将发送或接收缓存中的sb_timeo值赋给var。基于val中的时钟滴答数，在mbuf中构造一个timeval结构。

计算tv_usec的代码有一个差错。表达式应该为：“(val % hz * tick)。”

17.5 fcntl和ioctl系统调用

因为历史的原因而非有意这么做，插口API的几个特点既能通过ioctl也能通过fcntl来访问。关于ioctl命令，我们已经讨论了很多。我们也几次提到fcntl。

图17-15显示了本章描述的函数。

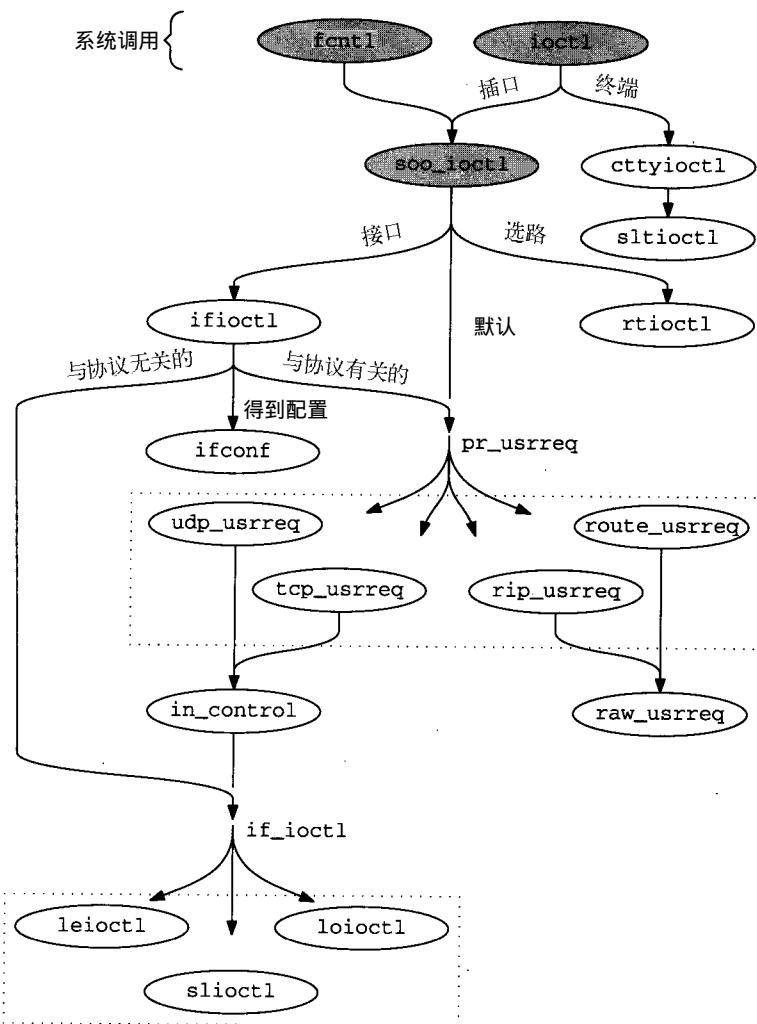


图17-15 fcntl 和 ioctl 函数

ioctl和fcntl的原型分别为：

```
int ioctl(int fd, unsigned long result, char *argp);
int fcntl(int fd, int cmd, ... /* int arg */);
```

图17-16总结了这两个系统调用与插口有关的特点。我们在图 17-16中还列出了一些传统的常数，因为它们出现在代码中。考虑与 Posix的兼容性，可以用 O_NONBLOCK来代替 FNONBLOCK，用O_ASYNC来代替FASYNC。

描述	fcntl	ioctl
通过打开或关闭 so_state 中的 SS_NBIO 来使能或禁止非阻塞功能	FNONBLOCK 文件状态标志	FIONBIO 命令
通过打开或关闭 sb_flags 中的 SB_ASYNC 来使能或禁止异步通知功能	FASYNC 文件状态标志	FIOASYNC 命令
设置或得到 so_pgid，它是 SIGIOG 和 SIGURG 信号的目标进程或进程组	F_SETOWN 或 F_GETOWN	SIOCSPGRP 或 SIOCGPGRP 命令
得到接收缓存中的字节数；返回 so_rcv.sb_cc		FIONREAD
返回 OOB 同步标记；即 so_state 中的 SS_RCVATMARK 标志		SIOCATMARK

图17-16 fcntl 和 ioctl 命令

17.5.1 fcntl 代码

图17-17列出了 fcntl 函数的部分代码。

```

133 struct fcntl_args {
134     int      fd;
135     int      cmd;
136     int      arg;
137 };
138 /* ARGSUSED */
139 fcntl(p, uap, retval)
140 struct proc *p;
141 struct fcntl_args *uap;
142 int      *retval;
143 {
144     struct filedesc *fdp = p->p_fd;
145     struct file *fp;
146     struct vnode *vp;
147     int      i, tmp, error, flg = F_POSIX;
148     struct flock fl;
149     u_int      newmin;
150     if ((unsigned) uap->fd >= fdp->fd_nfiles ||
151         (fp = fdp->fd_ofiles[uap->fd]) == NULL)
152         return (EBADF);
153     switch (uap->cmd) {
154         /* command processing */
155     default:
156         return (EINVAL);
157     }
158     /* NOTREACHED */
159 }
```

kern_descrip.c

图17-17 fcntl 系统调用：概况

133-153 验证完指向打开文件的描述符的正确性后，switch语句处理请求的命令。

253-257 对于不认识的命令，fcntl返回EINVAL。

图17-18仅显示fcntl中与插口有关的代码。

```

168     case F_GETFL:
169         *retval = OFLAGS(fp->f_flag);
170         return (0);
171
172     case F_SETFL:
173         fp->f_flag &= ~FCNTLFLAGS;
174         fp->f_flag |= FFLAGS(uap->arg) & FCNTLFLAGS;
175         tmp = fp->f_flag & FNONBLOCK;
176         error = (*fp->f_ops->fo_ioctl) (fp, FIONBIO, (caddr_t) & tmp, p);
177         if (error)
178             return (error);
179
180         tmp = fp->f_flag & FASYNC;
181         error = (*fp->f_ops->fo_ioctl) (fp, FIOASYNC, (caddr_t) & tmp, p);
182         if (!error)
183             return (0);
184
185         fp->f_flag &= ~FNONBLOCK;
186         tmp = 0;
187         (void) (*fp->f_ops->fo_ioctl) (fp, FIONBIO, (caddr_t) & tmp, p);
188         return (error);
189
190     case F_GETOWN:
191         if (fp->f_type == DTTYPE_SOCKET) {
192             *retval = ((struct socket *) fp->f_data)->so_pgid;
193             return (0);
194         }
195         error = (*fp->f_ops->fo_ioctl)
196             (fp, (int) TIOCGRPGRP, (caddr_t) retval, p);
197         *retval = -*retval;
198         return (error);
199
200     case F_SETOWN:
201         if (fp->f_type == DTTYPE_SOCKET) {
202             ((struct socket *) fp->f_data)->so_pgid = uap->arg;
203             return (0);
204         }
205         if (uap->arg <= 0) {
206             uap->arg = -uap->arg;
207         } else {
208             struct proc *p1 = pfind(uap->arg);
209             if (p1 == 0)
210                 return (ESRCH);
211             uap->arg = p1->p_pgrp->pg_id;
212         }
213         return ((*fp->f_ops->fo_ioctl)
214             (fp, (int) TIOCSPGRP, (caddr_t) & uap->arg, p));

```

kern_descrip.c

图17-18 fcntl 系统调用：插口处理

168-185 F_GETFL返回与描述符相关的当前文件状态标志，F_SETFL设置状态标志。通过调用fo_ioctl将FNONBLOCK和FASYNC的新设置传递给对应的插口，而插口的新设置是通过图17-20中描述的soo_ioctl函数来传递的。只有在第二个fo_ioctl调用失败后，才第三次调用fo_ioctl。该调用的功能是清除FNONBLOCK标志，但是应该改为将这个标志恢复

到原来的值。

186-194 F_GETOWN返回与插口相关联的进程或进程组的标识符，so_pgid。对于非插口描述符，将TIOCGRP_IOCTL命令传给对应的fo_ioctl函数。F_SETOWN的功能是给so_pgid赋一个新值。

17.5.2 ioctl代码

我们跳过ioctl系统调用本身而先从soo_ioctl开始讨论，如图17-20所示，因为ioctl的代码中的大部分是从图17-17所示的代码中复制的。我们已经说过，soo_ioctl函数将选路命令发送给rtioctl，接口命令发送给ifioctl，任何其他的命令发送给底层协议的pr_usrreq函数。

55-68 有几个命令是由soo_ioctl直接处理的。如果*data非空，则FIONBIO打开非阻塞方式，否则关闭非阻塞方式。正于我们已经了解的，这个标志将影响到accept、connect和close系统调用，也包括其他的读和写系统调用。

69-79 FIOASYNC使能或禁止异步I/O通知功能。如果设置了SS_ASYNC，则无论什么时候插口上有活动，就调用 sowakeup，将信号SIGIO发送给相应的进程或进程组。

80-88 FIONREAD返回接收缓存中的可读字节数。SIOCSPGRP设置与插口相关的进程组，SIOCGPGRP则是得到它。so_pgid作为我们刚讨论过的SIGIO信号的目标进程或进程组，当有带外数据到达插口时，则作为SIGURG信号的目标进程或进程组。

89-92 如果插口正处于带外数据的同步标记，则SIOCATMARK返回真；否则返回假。

ioctl命令，FIOxxx和SIOxxx常量，有一个内部结构，如图17-19所示。

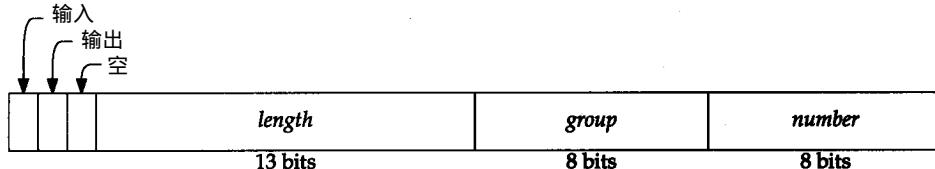


图17-19 ioctl 命令的内部结构

```

55 soo_ioctl(fp, cmd, data, p)                                sys_socket.c
56 struct file *fp;
57 int cmd;
58 caddr_t data;
59 struct proc *p;
60 {
61     struct socket *so = (struct socket *) fp->f_data;
62     switch (cmd) {
63     case FIONBIO:
64         if (*(int *) data)
65             so->so_state |= SS_NBIO;
66         else
67             so->so_state &= ~SS_NBIO;
68         return (0);
69     case FIOASYNC:
70         if (*(int *) data) {
71             so->so_state |= SS_ASYNC;
72             so->so_rcv.sb_flags |= SB_ASYNC;

```

图17-20 soo_ioctl 函数

```

73         so->so_snd.sb_flags |= SB_ASYNC;
74     } else {
75         so->so_state &= ~SS_ASYNC;
76         so->so_rcv.sb_flags &= ~SB_ASYNC;
77         so->so_snd.sb_flags &= ~SB_ASYNC;
78     }
79     return (0);
80
81     case FIONREAD:
82         *(int *) data = so->so_rcv.sb_cc;
83         return (0);
84
85     case SIOCSPGRP:
86         so->so_pgid = *(int *) data;
87         return (0);
88
89     case SIOCGPGRP:
90         *(int *) data = so->so_pgid;
91         return (0);
92
93     case SIOCATMARK:
94         *(int *) data = (so->so_state & SS_RCVATMARK) != 0;
95         return (0);
96
97 }
98 */
99 * Interface/routing/protocol specific ioctls:
100 * interface and routing ioctls should have a
101 * different entry since a socket's unnecessary
102 * /
103 if (IOCGROUP(cmd) == 'i')
104     return (ifioctl(so, cmd, data, p));
100 if (IOCGROUP(cmd) == 'r')
101     return (rtioctl(cmd, data, p));
102 return ((*so->so_proto->pr_usrreq) (so, PRU_CONTROL,
103         (struct mbuf *) cmd, (struct mbuf *) data, (struct mbuf *) 0));
104 }

```

sys_socket.c

图17-20 (续)

如果将 `ioctl` 的第三个参数作为输入，则设置 `input`。如果该参数作为输出，则 `output` 被置位。如果不使用该参数，则 `void` 被置位。`length` 是参数的大小(字节)。相关的命令在同一个 `group` 中但每一个命令在组中都有各自的 `number`。图17-21中的宏用来解析 `ioctl` 命令中的元素。

93-104 宏 `IOCGROUP` 从命令中得到 8 bit 的 `group`。接口命令由 `ifioctl` 处理。选路命令由 `rtioctl` 处理。通过 `PRU_CONTROL` 请求将所有其他的命令传递给插口协议。

正如我们在第19章中描述的，Net/2 定义了一个新的访问路由选择表接口，在该接口中，报文是通过一个在 `PF_ROUTE` 域中产生的插口传递给路由选择子系统。用这种方法来代替这里讨论的 `ioctl`。在不兼容的内核中，`rtioctl` 总是返回 `ENOTSUPP`。

宏	描述
<code>IOCPARM_LEN(cmd)</code>	返回 <code>cmd</code> 中的 <code>length</code>
<code>IOCBASECMD(cmd)</code>	<code>length</code> 设为 0 的命令
<code>IOCGROUP(cmd)</code>	返回 <code>cmd</code> 中的 <code>group</code>

图17-21 `ioctl` 命令宏

17.6 getsockname 系统调用

`getsockname` 系统调用的原型是：

```
int getsockname(int fd, caddr_t asa, int *alen);
```

getsockname得到绑定在插口fd上的本地地址，并将它存入asa指向的缓存中。当在一个隐式的绑定中内核选择了一个地址，或在一个显式的bind调用中进程指定了一个通配符地址(2.2.5节)时，该函数就很有用。getsockname系统调用如图17-22所示。

```

682 struct getsockname_args {
683     int      fdes;
684     caddr_t  asa;
685     int      *alen;
686 };
687 getsockname(p, uap, retval)
688 struct proc *p;
689 struct getsockname_args *uap;
690 int      *retval;
691 {
692     struct file *fp;
693     struct socket *so;
694     struct mbuf *m;
695     int      len, error;
696     if (error = getsock(p->p_fd, uap->fdes, &fp))
697         return (error);
698     if (error = copyin((caddr_t) uap->alen, (caddr_t) &len, sizeof(len)))
699         return (error);
700     so = (struct socket *) fp->f_data;
701     m = m_getclr(M_WAIT, MT_SONAME);
702     if (m == NULL)
703         return (ENOBUFS);
704     if (error = (*so->so_proto->pr_usrreq) (so, PRU_SOCKETADDR, 0, m, 0))
705         goto bad;
706     if (len > m->m_len)
707         len = m->m_len;
708     error = copyout(mtod(m, caddr_t), (caddr_t) uap->asa, (u_int) len);
709     if (error == 0)
710         error = copyout((caddr_t) &len, (caddr_t) uap->alen,
711                         sizeof(len));
712     bad:
713     m_freem(m);
714     return (error);
715 }

```

uipc_syscalls.c

图17-22 getsockname 系统调用

682-715 getsock返回描述符的file结构。将进程指定的缓存的长度赋给len。这是我们第一次看到对m_getclr的调用：该函数分配一个标准的mbuf，并调用bzero清零。当协议收到PRU_SOCKETADDR请求时，协议处理层负责将本地地址存入m。

如果地址长度大于进程提供的缓存的长度，则返回的地址将被截掉。`*alen`等于实际返回的字节数。最后，释放mbuf，并返回。

17.7 getpeername系统调用

getpeername系统调用的原型是：

```
int getpeername(int fd, caddr_t asa, int *alen);
```

getpeername系统调用返回指定插口上连接的远端地址。当一个调用 accept的进程通过fork和exec启动一个服务器时(即，任何被inetd启动的服务器)，经常要调用这个函数。服务器不能得到accept返回的远端地址，而只能调用getpeername。通常，要在应用的访问地址表查找返回地址，如果返回地址不在访问表中，则连接将被关闭。

某些协议，如TP4，利用这个函数来确定是否拒绝或证实一个进入的连接。在TP4中，accept返回的插口上的连接是不完整的，必须经证实之后才算连接成功。基于getpeername返回的地址，服务器能够关闭连接或通过发送或接收数据来间接证实连接。这一特点与TCP无关，因为TCP必须在三次握手完成之后，accept才能建立连接。图17-23列出了getpeername函数的代码。

```

719 struct getpeername_args {
720     int      fdes;
721     caddr_t  asa;
722     int      *alen;
723 };
724 getpeername(p, uap, retval)
725 struct proc *p;
726 struct getpeername_args *uap;
727 int      *retval;
728 {
729     struct file *fp;
730     struct socket *so;
731     struct mbuf *m;
732     int      len, error;
733     if (error = getsock(p->p_fd, uap->fdes, &fp))
734         return (error);
735     so = (struct socket *) fp->f_data;
736     if ((so->so_state & (SS_ISCONNECTED | SS_ISCONFIRMING)) == 0)
737         return (ENOTCONN);
738     if (error = copyin((caddr_t) uap->alen, (caddr_t) & len, sizeof(len)))
739         return (error);
740     m = m_getclr(M_WAIT, MT_SONAME);
741     if (m == NULL)
742         return (ENOBUFS);
743     if (*so->so_proto->pr_usrreq) (so, PRU_PEERADDR, 0, m, 0))
744         goto bad;
745     if (len > m->m_len)
746         len = m->m_len;
747     if (error = copyout(mtod(m, caddr_t), (caddr_t) uap->asa, (u_int) len))
748         goto bad;
749     error = copyout((caddr_t) & len, (caddr_t) uap->alen, sizeof(len));
750     bad:
751     m_freem(m);
752     return (error);
753 }

```

uipc_syscalls.c

图17-23 getpeername 系统调用

719-753 图中列出的代码与getsockname的代码是一样的。getsock获取插口对应的file结构，如果插口还没有同对方建立连接或连接还没有证实(如，TP4)，则返回ENOTCONN。如果已建立连接，则从进程那里得到缓存的大小，并分配一块mbuf来存储地址。发送PRU_PEERADDR请求给协议层来获取远端地址。将地址和地址的长度从内核的mbuf中复制到

进程提供的缓存中。释放 mbuf，并返回。

17.8 小结

本章中，我们讨论了六个修改插口功能的函数。插口选项由 `setsockopt` 和 `getsockopt` 函数处理。其他的选项，其中有些不仅仅用于插口，由 `fcntl` 和 `ioctl` 处理。最后，通过 `getsockname` 和 `getpeername` 来获取连接信息。

习题

- 17.1 为什么选项受标准 mbuf 大小(MHLEN, 128 个字节)的限制?
- 17.2 为什么图 17-7 中的最后一段代码能处理 SO_LINGER 选项?
- 17.3 图 17-9 中用来测试 `timeval` 结构的代码有些问题，因为 `tv->tv_sec * hz` 可能会溢出。请对这段代码作些修改来解决这个问题。

第18章 Radix树路由表

18.1 引言

由IP完成的路由选择是一种选路机制，它通过搜索路由表来确定从哪个接口把分组发送出去。它与选路策略(routing policy)不一样，选路策略是一组规则的集合，这些规则用来确定哪些路由可以编入到路由表中。Net/3内核实现选路机制，而选路守护进程，典型地如 routed或gated，实现选路策略。由于分组转发是频繁发生的(一个繁忙的系统每秒要转发成百上千个分组)，相对而言，选路策略的变化要少些，因此路由表的结构必须能够适应这种情况。

关于路由选择的详细情况，我们分三章进行讨论：

- 本章将讨论Net/3分组转发代码所使用的Radix树路由表的结构。每次发送或转发分组时，IP都将查看该表(发送时分组需要查看该表，是因为IP必须决定哪个本地接口将接收该分组)。
- 第19章着重讨论内核与Radix树之间的接口函数以及内核与选路进程(通常指实现选路策略的选路守护进程)之间交换的选路消息。进程可以通过这些消息来修改内核的路由表(添加路由、删除路由等)，并且当发生了一个异步事件，可能影响到路由策略(如收到重定向，接口断开等)时，内核也通过这些消息来通知守护进程。
- 第20章给出了内核与进程之间交换选路消息时使用的选路插口。

18.2 路由表结构

在讨论Net/3路由表的内部结构之前，我们需要了解一下路由表中包含的信息类型。图18-1是图1-17(作者以太网中的四个系统)的下半部分。

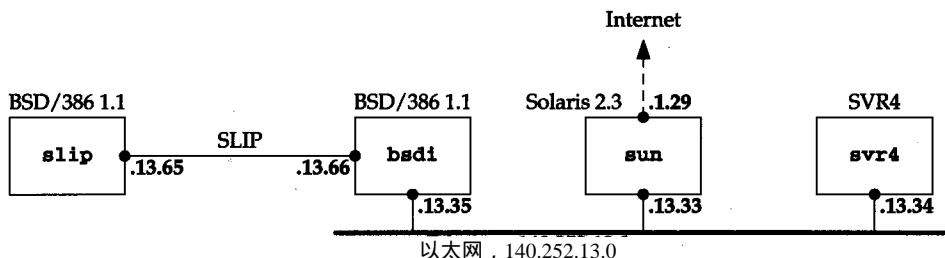


图18-1 路由表例子中使用子网

图18-2给出了图18-1中bsdi上的路由表。

为了能够更容易地看出每个表项中所设置的标志，我们已经对 netstat输出的“Flags”列进行了修改。

该表中的路由是按照下列过程添加的。其中，第1、3、5、8和第9步是在系统的初始化阶段执行 /etc/netstart she脚本时完成的。

```
bsdi $ netstat -rn
Routing tables

Internet:
Destination      Gateway          Flags    Refs      Use   Interface
default          140.252.13.33   UG S            0        3  le0
127              127.0.0.1       UG S R         0        2  lo0
127.0.0.1        127.0.0.1       U H             1       55  lo0
128.32.33.5      140.252.13.33   UGHS           2       16  le0
140.252.13.32    link#1          U C             0        0  le0
140.252.13.33    8:0:20:3:f6:42  U H L           11     55146  le0
140.252.13.34    0:0:c0:c2:9b:26  U H L           0        3  le0
140.252.13.35    0:0:c0:6f:2d:40  U H L           1       12  lo0
140.252.13.65    140.252.13.66   U H             0       41  s10
224              link#1          U C             0        0  le0
224.0.0.1        link#1          U H L           0        5  le0
```

图18-2 主机bsdi 上的路由表

1) 默认路由是由 route命令添加的。该路由通往主机 sun(140.252.13.33)，主机 sun 拥有一条到 Internet 的路由表项。

2) 到网络 127 的路由表项通常是由选路守护进程 (如 gated) 创建的，也可以通过 /etc/netstart 文件中的 route 命令将其添加到路由表中。该表项使得所有发往该网络的分组都将被环回驱动器 (图 5-27) 拒绝，但发往主机 127.0.0.1 的分组除外，因为对于该类分组，在下一步中添加的一条更特殊的路由将屏蔽本路由表项的作用。

3) 到环回接口 (127.0.0.1) 的表项是由 ifconfig 命令配置的。

4) 到 vangogh.cs.berkeley.edu(128.32.33.5) 的表项是用 route 命令手工创建的。该路由指定的路由器与默认路由所指定的相同 (都是 140.252.13.33)。但是在拥有一条替代默认路由的通往特定主机的路由之后，我们就能把路由度量存储在该路由表项中。这些度量能够由管理者选择设置。每次 TCP 建立一条到达目的主机的连接时都使用该度量，并且在连接关闭时，由 TCP 对其进行更新。我们将在图 27-3 中详细描述这些度量。

5) 接口 1e0 的初始化是由 ifconfig 命令完成的。该命令会在路由表中增加一条到 140.252.13.32 网络的表项。

6) 到以太网上另两台主机 sun(140.252.13.33) 和 svr4(140.252.13.34) 的路由表项是由 ARP 创建的，见第 21 章。它们都是临时路由，经过一段时间后，如果还未被使用，它们就会被自动删除。

7) 到本机 (140.252.13.35) 的表项是在第一次引用本机 IP 地址时创建的。该接口是一个环回，也就是说，任何发往本机 IP 地址的数据报将从内部反送回来。4.4BSD 中包含了自动创建该路由的新功能，见第 21.13 节。

8) 到主机 140.252.13.65 的表项是在 ifconfig 配置 SLIP 接口时创建的。

9) 通过以太网接口到达网络 244 的路由是由 route 命令添加的。

10) 到多播组 224.0.0.1 (所有主机的组，all-host group) 的表项是 Ping 程序在连接 224.0.0.1 即“Ping 224.0.0.1”时创建的。它也是一条临时路由，如果在一段时间内未被使用，就会被自动删除。

图 18-2 中的“Flags”列需要简单地说明一下。图 18-25 列出了所有可能的标志。

U 该路由存在。

- G 该路由通向一个网关(路由器)。这种路由被称为间接路由。如果没有设置本标志，则表明路由的目的地与本机直接相连，称为直接路由。
- H 该路由通往一台主机，也就是说，目的地址是一个完整的主机地址。如果没有设置本标志，则路由通往一个网络，目的地址是一个网络地址：一个网络号，或一个网络号与子网号的组合。`netstat`命令并不区分这一点，但每一条网络路由中都包含一个网络掩码，而主机路由中则隐含了一个全1的掩码。
- S 该路由是静态的。图18-2中`route`命令创建的三个路由表项是静态的。
- C 该路由可被克隆(clone)以产生新的路由。在本路由表中有两条路由设置了这个标志：一条是到本地以太网(140.252.13.32)的路由，ARP通过克隆该路由创建到以太网中其他特定主机的路由；另一条是到多播组224的路由，克隆该路由可以创建到特定多播组(如224.0.0.1)的路由。
- L 该路由含有链路层地址。本标志应用于单播地址和多播地址。由ARP从以太网路由克隆而得到的所有主机路由都设置了本标志。
- R 环回驱动器(为设有本标志的路由而设计的普通接口)将拒绝所有使用该路由的数据报。

添加带有拒绝标志的路由的功能由NET/2提供。它提供了一种简单的方法，来防止主机向外发送以网络127为目的地的数据报。参见习题6.6。

在4.3BSD Reno之前，内核将为IP地址维护两个不同的路由表：一个针对主机路由，另一个针对网络路由。对于给定的路由，将根据它的类型添加到相应的路由表中。默认路由被存储在网络路由表中，其目的地址是0.0.0.0。查找过程隐含了这样一种层次关系：首先查看主机路由表；如果找不到，则查找网络路由表；如果仍找不到，则查找默认路由。仅当三次查找都失败时，才认为目的地不可达。[Leffler et al. 1998]的第11.5节描述了一种带链表结构的hash表，该hash表同时用于Net/1中的主机路由表和网络路由表。

4.3BSD Reno [Sklower 1991]的变化主要与路由表的内部表示有关。这些变化允许相同的路由表函数访问不同协议栈的路由表，如OSI协议，它的地址是变长的，这一点与长度固定为32位的IP地址不同。为了提高查询速度，路由表的内部结构也做了变动。

Net/3路由表采用Patricia树结构[Sedgewick 1990]来表示主机地址和网络地址(Patricia支持“从文字数字的编码中提取信息的Patricia算法”)。待查找的地址和树中的地址都被看成比特序列。这样就可以用相同的函数来查找和维护不同类型的树，如：含有32 bit定长IP地址的树、含有48 bit定长XNS地址的树以及一棵含有变长OSI地址的树。

使用Patricia树构造路由表的思想应归功于Van Jacobson的[Sklower 1991]。

举个例子就可以很容易地描述出这个算法。查找路由表的目标就是为了找到一个最能匹配给定目标的特定地址。我们称这个给定的目标为查找键(search key)。所谓最能匹配的地址，也就是说，一个能够匹配的主机地址要优于一个能够匹配的网络地址；而一个能够匹配的网络地址要优于默认地址。

每条路由表项都有一个对应的网络掩码，尽管在主机路由中没有存储掩码，但它隐含了一个全1比特的掩码。我们对查找键和路由表项的掩码进行逻辑与运算，如果得到的值与该路由表项的目的地址相同，则称该路由表项是匹配的。对于某个给定的查找键，可能会从路由表中找到多条这样的匹配路由，所以在单个表同时包含网络路由和主机路由的情况下，我们

必须有效地组织该表，使得总能先找到那个更能匹配的路由。

让我们来讨论图18-3给出的例子。图中给出了两个查找键，分别是127.0.0.1和127.0.0.2。为了更容易地说明逻辑与运算，图中同时给出了它们的十六进制值。图中给出的两个路由表项分别是主机路由127.0.0.1(它隐含了一个全1的掩码0xffffffff)和网络路由127.0.0.0(它的掩码是0xffff000000)。

		查找键=127.0.0.1		查找键=127.0.0.2	
		主机路由	网络路由	主机路由	网络路由
1	查找键	7f000001	7f000001	7f000002	7f000002
2	路由表键	7f000001	7f000001	7f000001	7f000000
3	路由表掩码	ffffffffff	ff000000	ffffffffff	ff000000
4	1和3的逻辑与	7f000001	7f000000	7f000002	7f000000
	2和4相等？	相等	相等	不等	相等

图18-3 分别以127.0.0.1和127.0.0.2为查找键的路由表查找示例

其中两个路由表项都能够匹配查找键127.0.0.1，这时路由表的结构必须确保能够先找到更能匹配该查找键的表项(127.0.0.1)。

图18-4给出了对应于图18-2的Net/3路由表的内部表示。执行带-A标志的netstat命令可以导出路由表的树型结构，图18-4就是根据导出的结果而建立的。

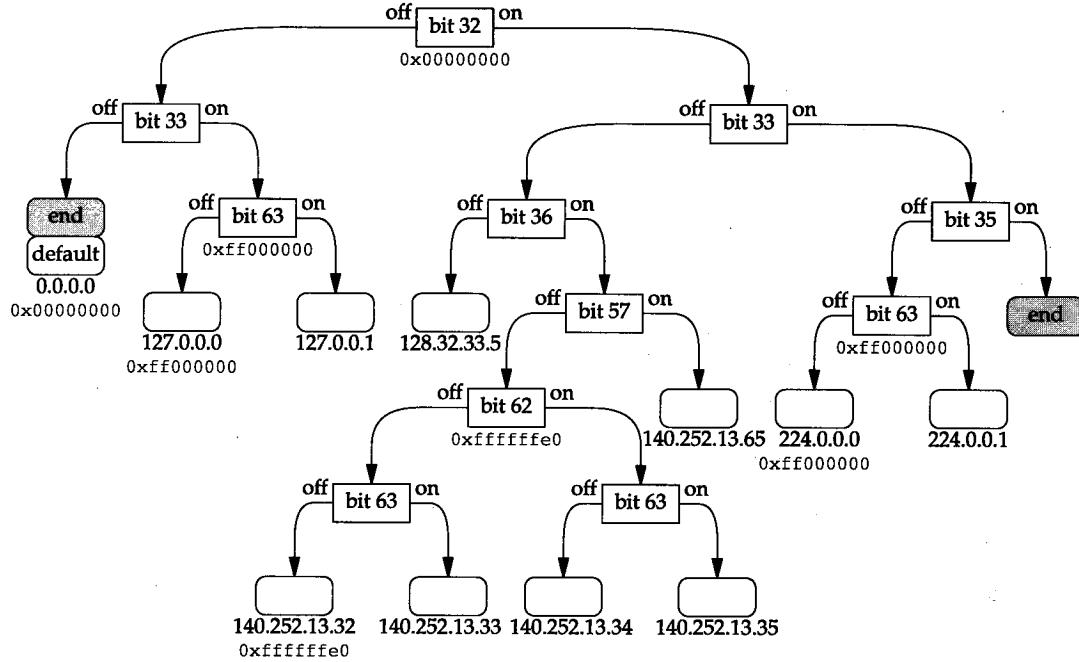


图18-4 对应于图18-2的Net/3路由表

标有“end”的两个阴影框是该树结构中带有特殊标志的叶结点，该标志代表树的端点。左边的那个拥有一个全0键，而右边的拥有一个全1键。左边的两个标有“end”和“default”的框连在一起，这两个框有特殊的意义，它们与重复键有关，具体内容可参考18.9节。

方角框被称为内部结点(internal node)或简称为结点(node)，圆角框被称为叶子。每一个

内部结点对应于测试查找键的一个比特位，其左右各有一个分枝。每一个叶子对应于一个主机地址或者对应于一个网络地址。如果在叶子下面有一个十六进制数，那么这个叶子就对应于一个网络地址，该十六进制数就是叶子的网络掩码。如果在叶子下面没有十六进制的掩码，那么这个叶子就是一个主机地址，其隐含的掩码是0xffffffff。

有一些内部结点也含有网络掩码，在后面的学习中，我们将会了解这些掩码在回溯过程中是如何使用的。图中的每一个结点还包含了一个指向其父结点的指针（没有在图中表示出来），它能使树结构的回溯、删除及非递归操作更加方便。

比特比较是运用在插口地址结构上的，因此，在图18-4中给出的比特位置是从插口地址结构中的起始位置开始算的。图18-5给出了sockaddr_in结构中的比特位置。

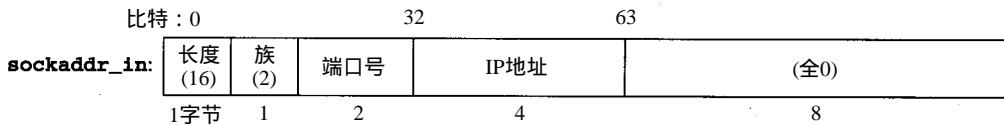


图18-5 Internet插口地址结构的比特位置

IP地址的最高位比特是比特32，最低位是比特63。此外还列出了长度是16，地址族为2(AF_INET)，这两个数值在我们所列举的例子中将会遇到。

为了解释这些例子，还需要给出树中不同IP地址的比特表示形式。它们都被列在图18-6中，该图还给出了下面例子中要用到的一些其他IP地址的比特表示形式。该图采用了加粗的字体来表示图18-4中分支点所对应的比特位置。

现在我们举一些特定的例子来说明路由表的查找过程是如何完成的。

1. 与主机地址匹配的例子

假定主机地址127.0.0.1是查找键——待查找的目的地址。比特32为0，因此，沿树顶点向左分支继续查找，到下一个结点。比特33为1，因此，从该结点右分支继续查找，到下一个结点。比特63为1，因此，从右分支继续查找，到下一个结点。而下一个结点是个叶子，此时查找键(127.0.0.1)与叶子中的地址(127.0.0.1)相比较。它们完全匹配，这样查找函数就可以返回该路由表项。

	32 bit IP地址									点分割表示
比特位置	3333	3333	4444	4444	4455	5555	5555	6666		
	2345	6789	0123	4567	8901	2345	6789	0123		
	0000	1010	0000	0001	0000	0010	0000	0011	10.1.2.3	
	0111	0000	0000	0000	0000	0000	0000	0001	112.0.0.1	
	0111	1111	0000	0000	0000	0000	0000	0000	127.0.0.0	
	0111	1111	0000	0000	0000	0000	0000	0001	127.0.0.1	
	0111	1111	0000	0000	0000	0000	0000	0011	127.0.0.3	
	1000	0000	0010	0000	0010	0001	0000	0101	128.32.33.5	
	1000	0000	0010	0000	0010	0001	0000	0110	128.32.33.6	
	1000	1100	1111	1100	0000	1101	0010	0000	140.252.13.32	
	1000	1100	1111	1100	0000	1101	0010	0001	140.252.13.33	
	1000	1100	1111	1100	0000	1101	0010	0010	140.252.13.34	
	1000	1100	1111	1100	0000	1101	0010	0011	140.252.13.35	
	1000	1100	1111	1100	0000	1101	0100	0001	140.252.13.65	
	1110	0000	0000	0000	0000	0000	0000	0000	224.0.0.0	
	1110	0000	0000	0000	0000	0000	0000	0001	224.0.0.1	

图18-6 图18-2和图18-4中IP地址的比特表示形式

2. 与主机地址匹配的例子

再假定查找键是地址 140.252.13.35。比特 32 为 1，因此，沿树顶点向右分支继续查找。比特 33 为 0，比特 36 为 1，比特 57 为 0，比特 62 为 1，比特 63 为 1，因此，查找在底部标有 140.252.13.35 的叶子处终止。查找键与路由表键完全匹配。

3. 与网络地址匹配的例子

假定查找键是 127.0.0.2。比特 32 为 0，比特 33 为 1，比特 63 为 0，因此，查找在标有 127.0.0.0 的叶子处终止。查找键和路由表键并没有完全匹配，因此，需要进一步看它是不是一个能够匹配的网络地址。对查找键和网络掩码 (0xff000000) 进行逻辑与运算，得到的结果与该路由表键相同，即认为该路由表项能够匹配。

4. 与默认地址匹配的例子

假定查找键是 10.1.2.3。比特 32 为 0，比特 33 为 0，因此，查找在标有“end”和“default”并带有重复键的叶子处终止。在这两个叶子中重复的路由表键是 0.0.0.0。查找键与路由表键值没有完全匹配，因此，需要进一步看它是不是一个能够匹配的网络地址。这种匹配运算要对每个含网络掩码的重复键都试一遍。第一个键（标有 end）没有网络掩码，可以跳过不查。第二个键（默认表项）有一个 0x00000000 的掩码。查找键和这个掩码进行逻辑与运算，所得结果和路由表键(0)相等，即认为该路由表项能够匹配。这样默认路由就被用做匹配路由。

5. 带回溯过程的与网络地址匹配的例子

假定查找键是 127.0.0.3。比特 32 为 0，比特 33 为 1，比特 63 为 1，因此，查找在标有 127.0.0.1 的叶子处终止。查找键和路由表键没有完全匹配。由于这个叶子没有网络掩码，无法进行网络掩码匹配的尝试。此时就要进行回溯。

回溯算法在树中向上移动，每次移动一层。如果遇到的内部结点含有掩码，则对查找关键字和该掩码进行逻辑与运算，得到一个键值，然后以这个键值作为新的查找键，在含该掩码的内部结点为开始的子树中进行另一次查找，看是否能找到匹配的结点。如果找不到，则回溯过程继续沿树上移，直到到达树的顶点。

在这个例子中，查找上移一层到达比特 63 对应的结点，该结点含有一个掩码。于是对查找键和掩码 (0xff000000) 进行逻辑与运算，得到一个新的查找键，其值为 127.0.0.0。然后从该结点开始查找 127.0.0.0。比特 63 为 0，因此，沿左分支到达标有 127.0.0.0 的叶子上。用新的查找键与路由表键相比较，它们是相等的，因此认为这个叶子是匹配的。

6. 多层回溯的例子

假定查找键是 112.0.0.1。比特 32 为 0，比特 33 为 1，比特 63 为 1，因此，查找在标有 127.0.0.1 的叶子处终止。该键与查找键不相等，并且路由表项中没有网络掩码，因此需要进行回溯。

查找过程向上移动一层，到达比特 63 对应的结点，该结点含有一个掩码。对查找关键字和该掩码 (0xff000000) 进行逻辑与运算，然后再从这个结点开始进一步查找。在新的查找键中比特 63 为 0，因此，沿左分支到达标有 127.0.0.0 的叶子。比较之后发现逻辑与运算得到的查找键 (112.0.0.0) 和路由表键并不相等。

因此继续向上回溯一层，从比特 63 对应的结点上移到比特 33 对应的结点。但这个结点没有掩码，再继续向上回溯。到达的下一层是树的顶点（比特 32），它有一个掩码。对查找键 (112.0.0.1) 和该掩码 (0x00000000) 进行逻辑与运算后，从该点开始一个新的查找。在新的查找

键中，比特32为0，比特33也为0，因此，查找在标有“end”和“default”的叶子处结束。通过与重复键列表中的每一项进行比较，发现默认键与新的查找键相匹配，因此采用默认路由。

从这个例子中可以知道，如果在路由表中存在默认路由，那么当回溯最终到达树的顶点时，它的掩码为全0比特，这使得查找向树中最左边叶子的方向进行搜索，最终与默认路由相匹配。

7. 带回溯和克隆过程、并与主机地址相匹配的例子

假定查找键是224.0.0.5。比特32为1，比特331，比特35为0，比特63为1，因此，查找在标有224.0.0.1的叶子处结束。路由表的键值和查找关键字并不相等，并且该路由表项不包含网络掩码，因此要进行回溯。

回溯向上移动一层，到达比特63对应的结点。这个结点含有掩码0xffff000000，因此，对查找键和该掩码进行逻辑与运算，产生一个新的查找键，即224.0.0.0。再从这个结点开始一次新的查找。在新的查找键中比特63为0，于是沿左分支到达标有224.0.0.0的叶子。这个路由表键和逻辑与运算得到的查找键相匹配，因此这个路由表项是匹配的。

该路由上设置了“克隆”标志（见图18-2），因此，以224.0.0.5为地址创建一个新的叶子。新的路由表项是：

Destination	Gateway	Flags	Refs	Use	Interface
224.0.0.5	link#1	UHL	0	0	le0

图18-7从比特35对应的结点开始，给出了图18-4中路由表树右边部分的新的排列。注意，无论何时向树中添加新的叶子，都需要两个结点：一个作为叶子，另一个作为测试某一位比特的内部结点。

新创建的表项就被返回给查找224.0.0.5的调用者。

8. 大图

图18-8是一张比较大的图，它描述了所有涉及到的数据结构。该图的底部来自于图3-32。

现在我们将解释图中的几个要点，在后面，本章还将给出详细的阐述。

- `rt_tables`是指向`radix_node_head`结构的指针数组。每一个地址族都有一个数组单元与之对应。`rt_tables[AF_INET]`指向Internet路由表树的顶点。
- `radix_node_head`结构包含三个`radix_node`结构。这三个结构是在初始化路由树时创建的，中间的是树的顶点。它对应于图18-4中最上端标有“bit 32”的结点框。三个`radix_node`结构中的第一个是图18-4中最左边的叶子（与默认路由共享的重复），第三个结构是最右边的叶子。在一个空的路由表中，就只包含这三个`radix_node`结构，我们将会看到`rn_inithead`函数是如何构建它们的。
- 全局变量`mask_rnhead`也指向一个`radix_node_head`结构。它是包含了所有掩码的一棵独立树的头部结构。观察图18-4中给出的八个掩码可知，有一个掩码重复了四次，有两个掩码重复了一次。通过把掩码放在一棵单独的树中，可以做到对每一个掩码只需要维护它的一个备份即可。

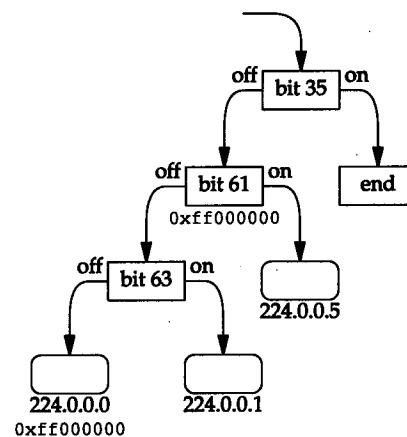


图18-7 插入224.0.0.5路由表项后
图18-6的改动

- 路由表树是用 `rtentry` 结构创建的，在图 18-8 中，有两个 `rtentry` 结构。每一个 `rtentry` 结构包含两个 `radix_node` 结构，因为每次向树中插入一个新的路由时，都需要两个结点：一个是内部结点，对应于某一位测试比特；另一个是叶子，对应于一个主机路由或一个网络路由。在每一个 `rtentry` 结构中，给出了内部结点对应的要测试的那位比特以及叶子中所包含的地址。

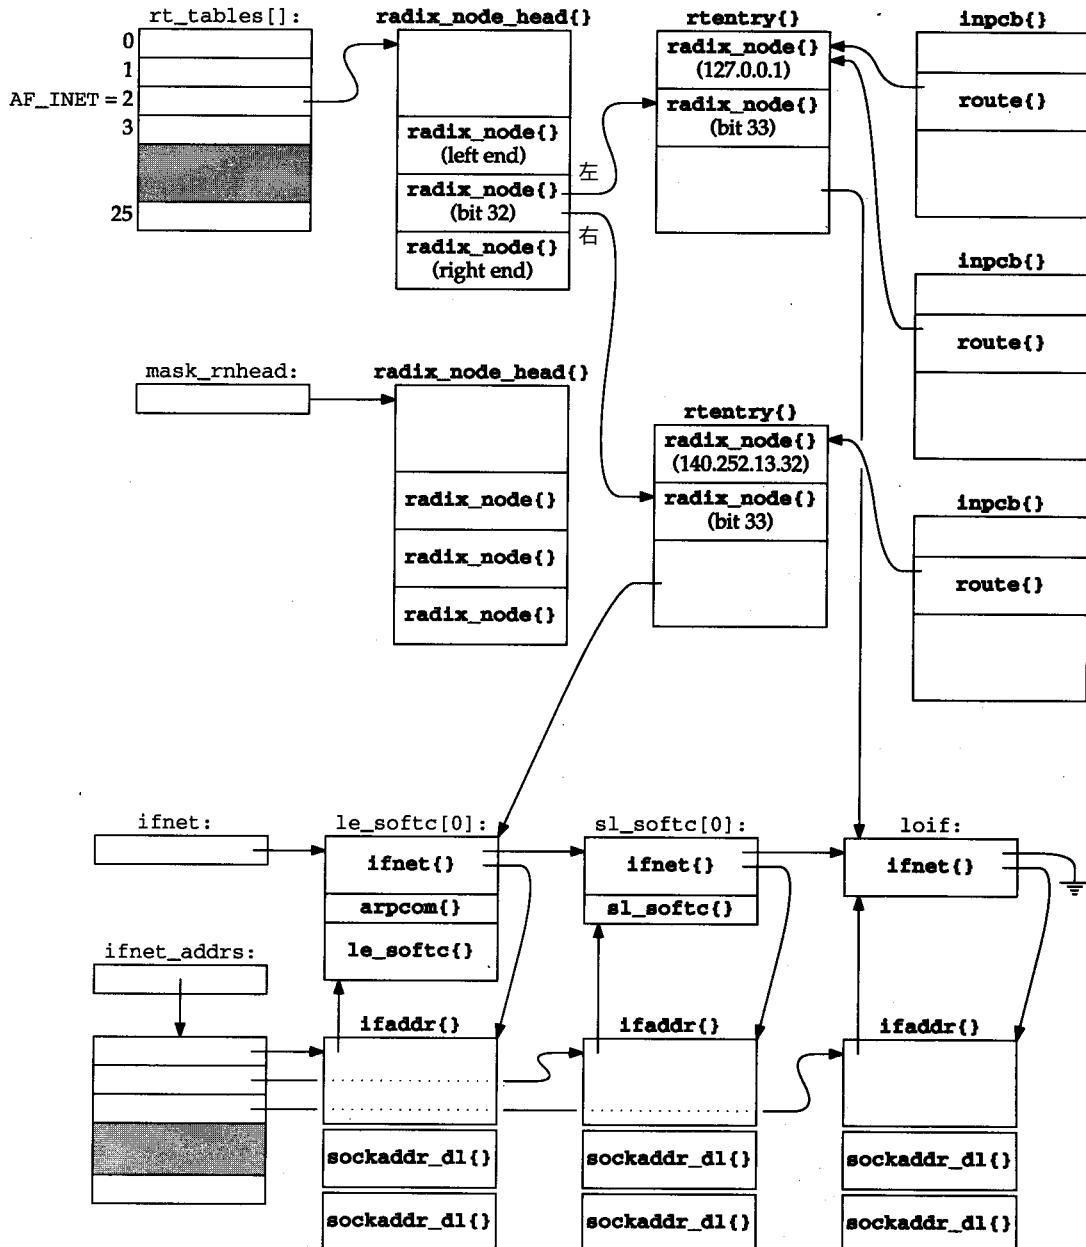


图18-8 路由表中涉及的数据结构

`rtentry` 结构中的其余部分是该路由的一些其他重要信息。虽然我们只给出了该结构中的一个指向 `ifnet` 结构的指针，但在这个结构中还包含了指向 `ifaddr` 结构的指针、该路由的

标志、指向另一个`rtentry`结构的指针(如果该路由是一个非直接路由)和该路由的度量等等。

- 存在于每一个UDP和TCP插口(图22-1)中的协议控制块PCB(见第22章)中包含了一个指向`rtentry`结构的`route`结构。每次发送一个IP数据报时，UDP和TCP输出函数都传递一个指向PCB中`route`结构的指针，作为调用`ip_output`的第三个参数。使用相同路由的PCB都指向相同的路由表项。

18.3 选路插口

在4.3BSD Reno的路由表做了变动后，路由子系统和进程间的交互过程也要做出变动，这就引出了选路插口(routing socket)的概念。在4.3BSD Reno之前，是由进程(如`route`命令)通过发出定长的`ioctl`来修改路由表的。4.3BSD Reno采用新的`PF_ROUTE`域把它改变成一种更为通用的消息传递模式。进程在`PF_ROUTE`域中创建一个原始插口(raw socket)，就能够向内核发送选路消息，以及从内核接收选路消息(如重定向或来自于内核的其他的异步通知)。

图18-9给出了12种不同类型的选路消息。消息类型位于`rt_msghdr`结构(图19-16)中的`rtm_type`字段。进程只能发送其中的5种消息(写入到选路插口中)，但可以接收全部的12种消息。我们将在第19章给出这些选路消息的详细讨论。

<code>rtm_type</code>	发往内核？	从内核发出？	描述	结构类型
<code>RTM_ADD</code>	•	•	添加路由	<code>rt-msghdr</code>
<code>RTM_CHANGE</code>	•	•	改变网关、度量或标志	<code>rt-msghdr</code>
<code>RTM_DELADDR</code>		•	从接口中删除地址	<code>ifa-msghdr</code>
<code>RTM_DELETE</code>	•	•	删除路由	<code>rt-msghdr</code>
<code>RTM_GET</code>	•	•	报告度量及其他路由信息	<code>rt-msghdr</code>
<code>RTM_IFINFO</code>		•	接口打开或关闭等	<code>rt-msghdr</code>
<code>RTM_LOCK</code>	•	•	锁定指明的度量	<code>rt-msghdr</code>
<code>RTM_LOSING</code>		•	内核怀疑某路由无效	<code>rt-msghdr</code>
<code>RTM_MISS</code>		•	查找这个地址失败	<code>rt-msghdr</code>
<code>RTM_NEWWADDR</code>		•	接口中添加了地址	<code>ifa-msghdr</code>
<code>RTM_REDIRECT</code>		•	内核得知要使用不同的路由	<code>rt-msghdr</code>
<code>RTM_RESOLVE</code>		•	请求将目的地址解析成链路层地址	<code>rt-msghdr</code>

图18-9 通过选路插口交换的消息类型

18.4 代码介绍

路由选择中使用的各种结构和函数是通过五个C文件和三个头文件来定义的。图18-10列出了这些文件。

通常，前缀`rn_`表示radix结点函数，这些函数可以对Patricia树进行查找和操作，前缀`raw_`表示路由控制块函数，`rout_`、`rt_`和`rt`这三个前缀表示常用的选路函数。

尽管有的文件和函数以`raw`为前缀，但在所有的选路章节中我们仍使用术语选路控制块(routing control block)而不是原始控制块。这是为了防止与第32章中讨论的原始IP控制块及其函数相混淆。虽然原始控制块及相关函数不仅仅用于Net/3中的选路插口(使用这些结构和函数的原始OSI协议之一)，但是本书中我们只用做`PF_ROUTE`域中的选路插口。

文件	描述
net/radix.h net/raw_cb.h net/route.h	radix结点定义 选路控制块定义 选路结构
net/radix.c net/raw_cb.c net/raw_usrreq.c net/route.c net/rtsock.c	radix结点(Patricia树)函数 选路控制块函数 选路控制块函数 选路函数 选路插口函数

图18-10 本章中讨论的文件

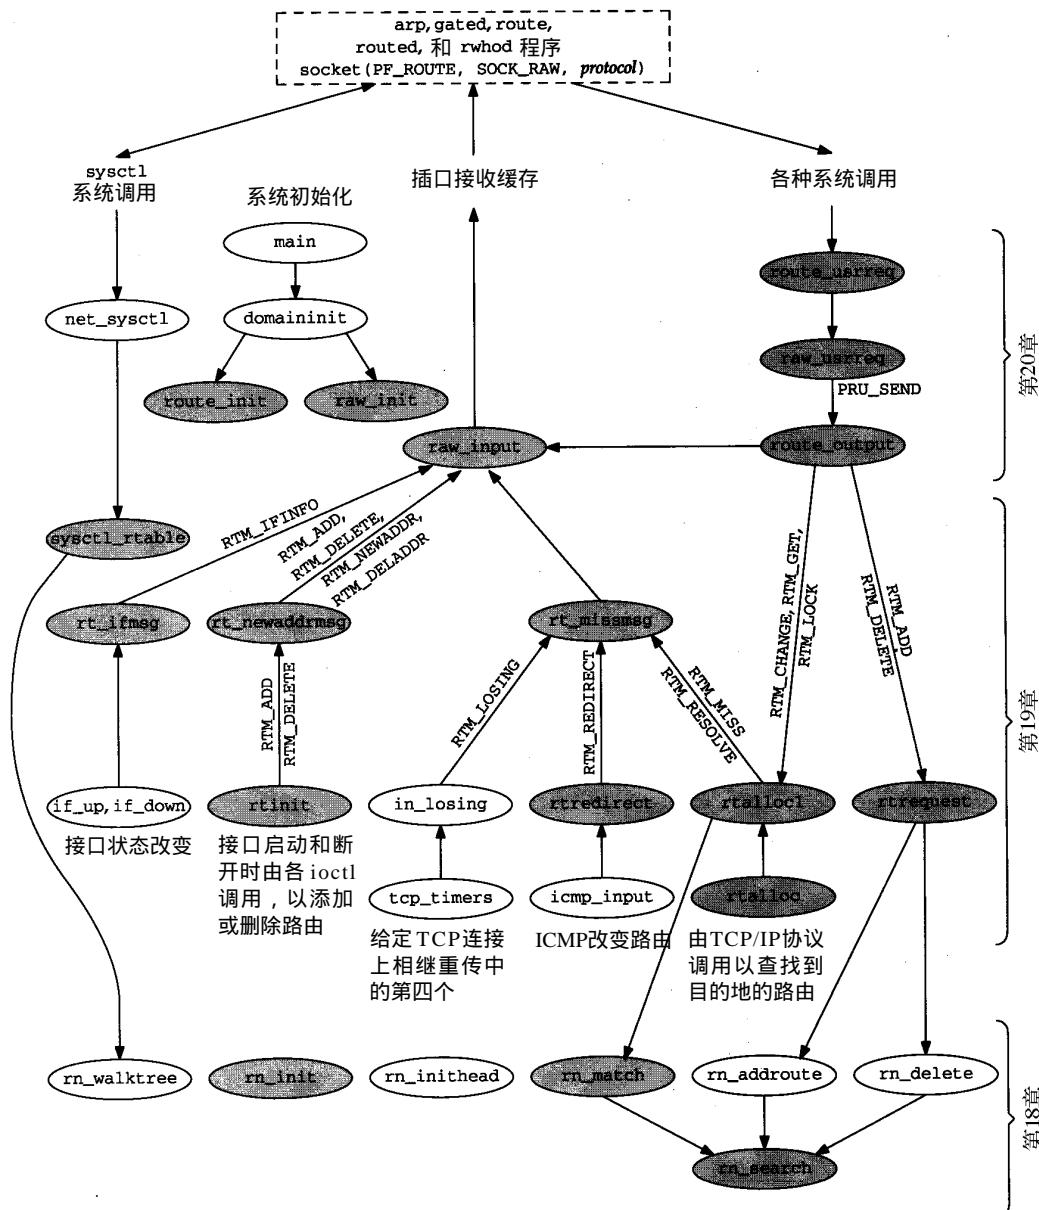


图18-11 各选路函数之间的关系

图18-11给出了一些基本的选路函数，并表示了它们之间的相互关系。其中带阴影的椭圆是在本章和下面两章中要涉及的内容。在图中，我们还给出了每种类型的选路消息（共12种）的产生之处。

`rtalloc` 函数是由 Internet 协议调用的，用于查找到达指定目的地的路由。在 `ip_rtaddr`、`ip_forward`、`ip_output` 和 `ip_setmoptions` 函数中都已出现过 `rtalloc`，在后面介绍的 `in_pcbservice` 和 `tcp_mss` 函数中也将会遇到它。

图18-11还给出了在选路域中创建插口的五个典型程序：

- `arp` 处理 ARP 高速缓存，该 ARP 高速缓存被存储在 Net/3 的 IP 路由表中（见第 21 章）；
- `gated` 和 `routed` 是选路守护进程，它们与其他路由器进行通信。当选路环境发生变化时（指路由器及链路断开或连通），对内核的路由表进行操作；
- `route` 通常是由启动脚本或系统管理员执行的一个程序，用于添加或删除路由；
- `rwhod` 在启动时会调用一个选路 `sysctl` 来测定连接的接口。

当然，任何进程（具有超级用户的权限）都能打开一个选路插口向选路子系统发送或从中接收消息；在图 18-11 中，我们只给出了一些常用的系统程序。

18.4.1 全局变量

图 18-12 列出了在三个有关路由选择的章节中介绍的全局变量。

变 量	数 据 类 型	描 述
<code>rt_tables</code> <code>mask_rnhead</code> <code>rn_mkfreelist</code>	<code>struct radix_node_head []</code> <code>struct radix_node_head *</code> <code>struct radix_mask *</code>	路由表表头指针的数组 指向掩码表表头的指针 可用 <code>radix_mask</code> 结构的链表表头
<code>max_keylen</code> <code>rn_zeros</code> <code>rn_ones</code> <code>maskedKey</code>	<code>int</code> <code>char *</code> <code>char *</code> <code>char *</code>	以字节为单位的路由表键值的最大长度 长为 <code>max_keylen</code> 、值为全零比特的数组 长为 <code>max_keylen</code> 、值为全 1 比特的数组 长为 <code>max_keylen</code> 、掩码过的查找键数组
<code>rtstat</code> <code>rttrash</code>	<code>struct rtstat</code> <code>int</code>	路由选择统计（图 18-13） 未释放的非表中路由的数目
<code>rawcb</code> <code>raw_recvspace</code> <code>raw_sendspace</code>	<code>struct rawcb</code> <code>u_long</code> <code>u_long</code>	选路控制块双向链表头 选路插口接收缓冲区的默认大小，8192 字节 选路插口发送缓冲区的默认大小，8192 字节
<code>route_cb</code> <code>route_dst</code> <code>route_src</code> <code>route_proto</code>	<code>struct route_cb</code> <code>struct sockaddr</code> <code>struct sockaddr</code> <code>struct sockproto</code>	选路插口监听器的数目，每个协议的数目及总的数目 保存选路消息中目的地址的临时变量 保存选路消息中源地址的临时变量 保存选路消息中协议的临时变量

图 18-12 在三个有关选路的章节中介绍的全局变量

18.4.2 统计量

图 18-13 列举了一些路由选择统计量，它们是在全局结构 `rtstat` 中维护的。

在代码的处理中，我们可以发现计数器是怎样增加的。这些计数器在 SNMP 中并未使用。

图 18-14 给出了 `netstat` 命令输出的一些统计数据的样例，该命令用于显示 `rtstat` 结构。

rtstat成员	描 述	在SNMP中的使用
rts_badredirect	无效重定向调用的数目	
rts_dynamic	由重定向创建的路由数目	
rts_newgateway	由重定向修改的路由数目	
rts_unreach	查找失败的次数	
rts_wildcard	由通配符匹配的查找次数(从未使用)	

图18-13 在rtstat 结构中维护的路由选择统计数据

netstat-rs的输出	rtstat 成员
1029 bad routing redirects 0 dynamically created routes 0 new gateways due to redirects 0 destinations found unreachable 0 uses of a wildcard route	rts_badredirect rts_dynamic rts_newgateway rts_unreach rts_wildcard

图18-14 路由选择统计数据样例

18.4.3 SNMP变量

图18-15给出了名为 ipRouteTable 的IP路由表以及相应的内核变量。

IP路由表 , index = <ipRouteDest>		
SNMP变量	变 量	描 述
ipRouteDest	rt_key	IP目的地址。值为0.0.0.0时，代表默认路由
ipRouteIfIndex	rt_ifp , if_index	接口号：ifIndex
ipRouteMetric1	-1	基本的路由度量。其含义取决于选路协议的值(ipRouteProto)。值为-1，表示没有使用
ipRouteMetric2	-1	可选的路由度量
ipRouteMetric3	-1	可选的路由度量
ipRouteMetric4	-1	可选的路由度量
ipRouteNextHop	rt_gateway	下一跳路由器的IP地址
ipRouteType	(见正文)	路由类型：1=其他，2=无效路由，3=直接的，4=间接的
ipRouteProto	(见正文)	路由协议：1=其他，4=ICMP重定向，8=RIP, 13=OSPF, 14=BGP等
ipRouteAge	(未实现)	从路由最后一次被修改或被确定为正确时起的秒数
ipRouteMask	rt_mask	在和ipRouteDest比较前，与目的主机IP地址进行逻辑与运算的掩码
ipRouteMetric5	-1	可选的路由度量
ipRouteInfo	NULL	本选路协议特定的MIB定义的引用

图18-15 IP路由表：ipRouteTable

如果在rt_flags中将标志RTF_GATEWAY置位，则该路由就是远程的，ipRouteType等于4；否则该路由就是直达的，ipRouteType值为3。对于ipRouteProto，如果将标志RTF_DYNAMIC或RTF_MODIFIED置位，则该路由就是由ICMP来创建或修改的，值为4，否则为其他情况，其值为1。最后，如果rt_mask指针为空，则返回的掩码就是全1(即主机路由)。

18.5 Radix结点数据结构

在图18-8中可以发现每一个路由表的表头都是一个radix_node_head结构，而选路树中所有的结点(包括内部结点和叶子)都是radix_node结构。radix_node_head结构如图18-16所示。

```

91 struct radix_node_head {
92     struct radix_node *rnh_treetop;
93     int      rnh_addrsize;          /* (not currently used) */
94     int      rnh_pktsize;          /* (not currently used) */
95     struct radix_node *(*rnh_addaddr) /* add based on sockaddr */
96         (void *v, void *mask,
97          struct radix_node_head * head, struct radix_node nodes[]);
98     struct radix_node *(*rnh_addpkt) /* add based on packet hdr */
99         (void *v, void *mask,
100          struct radix_node_head * head, struct radix_node nodes[]);
101    struct radix_node *(*rnh_deladdr) /* remove based on sockaddr */
102        (void *v, void *mask, struct radix_node_head * head);
103    struct radix_node *(*rnh_delpkt) /* remove based on packet hdr */
104        (void *v, void *mask, struct radix_node_head * head);
105    struct radix_node *(*rnh_matchaddr) /* locate based on sockaddr */
106        (void *v, struct radix_node_head * head);
107    struct radix_node *(*rnh_matchpkt) /* locate based on packet hdr */
108        (void *v, struct radix_node_head * head);
109    int      (*rnh_walktree) /* traverse tree */
110        (struct radix_node_head * head, int (*f) (), void *w);
111    struct radix_node rnh_nodes[3]; /* top and end nodes */
112 };

```

radix.h

图18-16 radix_node_head 结构：每棵选路树的顶点

92 rnh_treetop指向路由树顶端的radix_node结构。可以看到radix_node_head结构的最后一项分配了三个radix_node结构，其中中间的那个被初始化成树的顶点(图18-8)。
93-94 rnh_addrsize和rnih_pktsize目前未被使用。

rnh_addrsize是为了能够方便地将路由表代码导入到系统中去，因为系统的插口地址结构中没有标识其长度的字节。rnih_pktsize是为了能够利用radix结点机制直接检查分组头结构中的地址，而无需把该地址拷贝到某个插口地址结构中去。

95-110 从rnih_addaddr到rnih_walktree是七个函数指针，它们所指向的函数将被调用以完成对树的操作。如图18-17所示，rn_inithead仅初始化了其中的四个指针，剩下的三个指针在Net/3中未被使用。

111-112 图18-18给出了组成树中结点的radix_node结构。在图18-8中，我们可以发现，在radix_node_head中分配了三个这样的radix_node结构，而在每一个rtentry结构中分配了两个radix_node结构。

41-45 前五个成员是内部结点和叶子都有的成员。后面是一个union：如果结点是叶子，那么它定义了三个成员；如果是内部结

成 员	被rn_inithead初始化为
rnih_addaddr	rn_addroute
rnih_addpkt	NULL
rnih_deladdr	rn_delete
rnih_delpkt	NULL
rnih_matchaddr	rn_match
rnih_matchpkt	NULL
rnih_walktree	rn_walktree

图18-17 在radix_node_head 结构中的七个函数指针

点，那么它定义了另外不同的三个成员。由于在 Net/3代码中经常使用 union中的这些成员，因此，用一组#define语句定义它们的简写形式。

41-42 rn_mklist是该结点掩码链表的表头。我们将在 18.9节中描述该字段。rn_p指向该结点的父结点。

43 如果rn_b值大于或者等于零，那么该结点为内部结点；否则就是叶子。对于内部结点来说，rn_b就是要测试的比特位置：例如，在图 18-4中，树的顶结点的rn_b值为32。对于叶子来说，rn_b是负的，它的值等于-1减去网络掩码索引(index of the network mask)。该索引是指掩码中出现的第一个零的比特位置。图 18-19给出了图18-4中掩码的索引。

```
radix.h
40 struct radix_node {
41     struct radix_mask *rn_mklist; /* list of masks contained in subtree */
42     struct radix_node *rn_p; /* parent pointer */
43     short rn_b; /* bit offset; -1-index(netmask) */
44     char rn_bmask; /* node: mask for bit test */
45     u_char rn_flags; /* Figure 18.20 */
46     union {
47         struct { /* leaf only data: rn_b < 0 */
48             caddr_t rn_Key; /* object of search */
49             caddr_t rn_Mask; /* netmask, if present */
50             struct radix_node *rn_Dupedkey;
51         } rn_leaf;
52         struct { /* node only data: rn_b >= 0 */
53             int rn_Off; /* where to start compare */
54             struct radix_node *rn_L; /* left pointer */
55             struct radix_node *rn_R; /* right pointer */
56         } rn_node;
57     } rn_u;
58 };
59 #define rn_dupedkey rn_u.rn_leaf.rn_Dupedkey
60 #define rn_key rn_u.rn_leaf.rn_Key
61 #define rn_mask rn_u.rn_leaf.rn_Mask
62 #define rn_off rn_u.rn_node.rn_Off
63 #define rn_l rn_u.rn_node.rn_L
64 #define rn_r rn_u.rn_node.rn_R
radix.h
```

图18-18 radix_node 结构：路由树的结点

	32 bit IP掩码(比特32-36)										索引	rn_b
.	3333	3333	4444	4444	4455	5555	5555	6666				
	2345	6789	0123	4567	8901	2345	6789	0123				
00000000:	0000	0000	0000	0000	0000	0000	0000	0000	0000	0	-1	
ff000000:	1111	1111	0000	0000	0000	0000	0000	0000	0000	40	-41	
ffffffe0:	1111	1111	1111	1111	1111	1111	1111	1110	0000	59	-60	

图18-19 掩码索引的例子

我们可以发现，其中的全0掩码的索引是特殊处理的：它的索引是0，而不是32。

44 内部结点的rn_bmask是个单字节的掩码，用于检测相应的比特位是0还是1。在叶子中它的值为0。很快我们将会看到如何运用成员rn_bmask和成员rn_off。

45 图18-20给出了成员rn_flags的三个值。

常量	描述
RNF_ACTIVE	该结点是活的(alive)(针对rtfree)
RNF_NORMAL	该叶子含有正常路由(目前未被使用)
RNF_ROOT	该叶子是树的根叶子

图18-20 m_flags 的值

RNF_ROOT标志只有在 radix_node_head 结构中的三个 radix 结点(树的顶结点、左端结点和右端结点)中才能设置。这三个结点不能从路由树中删除。

48-49 对于叶子而言，rn_key 指向插口地址结构，rn_mask 指向保存掩码的插口地址结构。如果 rn_mask 为空，则其掩码为隐含的全 1 值(即，该路由指向某个主机而不是某个网络)。

图18-21例举了一个与图18-4中的叶子 140.252.13.32 相对应的 radix_node 结构的例子。

指向比特63对应的 radix_node{ }

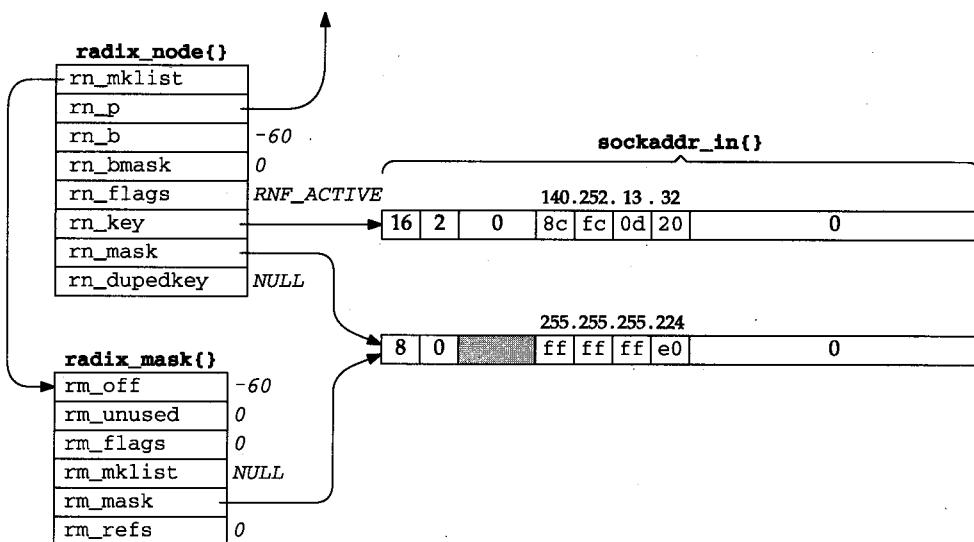


图18-21 与图18-4中的叶子 140.252.13.32 相对应的 radix_node 结构

该例子中还给出了图 18-22 中描述的 radix_mask 结构。我们把它的宽度略微缩小了一些，以区别于 radix_node 结构；这两种结构在后面的很多图例中都会遇到。有关 radix_mask 结构的作用将在 18.9 节中阐述。

值为 -60 的 rn_b 相对应的索引为 59。rn_key 指向一个 sockaddr_in 结构，它的长度值为 16，地址族值为 2(AF_INET)。由 rn_mask 和 rm_mask 指向的掩码结构所含的长度值为 8，地址族值为 0(该族为 AF_UNSPEC，但我们从未使用它)。

50-51 当有多个叶子的键值相同时，使用 rn_dupedkey 指针。具体内容将在 18.9 节中阐述。

52-58 有关 rn_off 的内容将在 18.8 节中阐述。rn_l 和 rn_r 是该内部结点的左、右指针。

图18-22给出了 radix_mask 结构的定义。

76-83 该结构中包含了一个指向其掩码的指针：rm_mask，实际上是一个保存掩码的插口地址结构的指针。每一个 radix_node 结构对应一个 radix_mask 结构的链表，这就允许每

一个结点包含多个掩码：成员 `rn_mklist` 指向链表的第一个结点，然后每个结构的成员 `rm_mklist` 指向链表的下一个结点。该结构的定义同时声明了全局变量 `rn_mkfreelist`，它是可用的 `radix_mask` 结构链表的表头。

```
76 extern struct radix_mask {
77     short    rm_b;           /* bit offset; -1-index(netmask) */
78     char     rm_unused;      /* cf. rn_bmask */
79     u_char   rm_flags;       /* cf. rn_flags */
80     struct radix_mask *rm_mklist; /* more masks to try */
81     caddr_t  rm_mask;        /* the mask */
82     int      rm_refs;        /* # of references to this struct */
83 } *rn_mkfreelist;
```

图18-22 `radix_mask` 结构

18.6 选路结构

访问内核路由信息的关键之处是：

- 1) `rtalloc` 函数，用于查找通往目的地的路由；
- 2) `route` 结构，它的值由 `rtalloc` 函数填写；
- 3) `route` 结构所指向的 `rtentry` 结构。

图18-8给出了UDP和TCP(参见第22章)中使用的协议控制块(PCB)，其中包含一个 `route` 结构，见图18-23。

```
46 struct route {
47     struct rtentry *ro_rt;      /* pointer to struct with information */
48     struct sockaddr ro_dst;    /* destination of this route */
49 };
```

图18-23 `route` 结构

`ro_dst` 被定义成一个一般的插口地址结构，但对于 Internet 协议而言，它就是一个 `sockaddr_in` 结构。注意，对这种结构类型的绝大多数引用都是一个指针，而 `ro_dst` 是该结构的一个实例而非指针。

这里，我们有必要回顾一下图 8-24。从该图可以得知，每次发送 IP 数据报时，这些路由是如何使用的。

- 如果调用者传递了一个 `route` 结构的指针，那么就使用该结构。否则，就要用一个局部 `route` 结构，其值设置为 0(设置 `ro_rt` 为空指针)。UDP 和 TCP 把指向它们的 PCB 中 `route` 结构的指针传递给 `ip_output`。
- 如果 `route` 结构指向一个 `rtentry` 结构(`ro_rt` 指针为非空)，同时所引用的接口仍然有效；而且如果 `route` 结构中的目的地址与 IP 数据报中的目的地址相等，那么该路由就被使用。否则，目的主机的 IP 地址将会设置在插口地址结构 `so_dst` 中，并且调用 `rtalloc` 来查找一条通向该目的主机的路由。在 TCP 链接中，数据报的目的地址始终是路由的目的地址，不会发生变化，但是 UDP 应用可以通过 `sendto` 每次都把数据报发送到不同的目的地。
- 如果 `rtalloc` 返回的 `ro_rt` 是个空指针，则表明找不到路由，并且 `ip_output` 返回一

个差错。

- 如果在rtentry结构中设有RTF_GATEWAY标志，那么该路由为非直接路由(参见图18-2中的G标志)。接口输出函数的目的地址(dst)就变成网关的IP地址，即rt_gateway成员，而不是IP数据报的目的地地址。

图18-24给出了rtentry结构的定义。

```

83 struct rtentry {
84     struct radix_node rt_nodes[2]; /* a leaf and an internal node */
85     struct sockaddr *rt_gateway; /* value associated with rn_key */
86     short rt_flags;             /* Figure 18.25 */
87     short rt_refcnt;           /* #held references */
88     u_long rt_use;             /* raw #packets sent */
89     struct ifnet *rt_ifp;       /* interface to use */
90     struct ifaddr *rt_ifa;      /* interface address to use */
91     struct sockaddr *rt_genmask; /* for generation of cloned routes */
92     caddr_t rt_llinfo;         /* pointer to link level info cache */
93     struct rt_metrics rt_rmx;  /* metrics: Figure 18.26 */
94     struct rtentry *rt_gwroute; /* implied entry for gatewayed routes */
95 };
96 #define rt_key(r) ((struct sockaddr *)((r)->rt_nodes->rn_key))
97 #define rt_mask(r) ((struct sockaddr *)((r)->rt_nodes->rn_mask))

```

route.h

图18-24 rtentry 结构

83-84 在该结构中包含有两个radix_node结构。正如我们在图18-7的例子中所提到的，每次向路由树添加一个新叶子的同时也要添加一个新的内部结点。rt_nodes[0]为叶子，rt_nodes[1]为内部结点。在图18-24最后的两个#define语句提供了访问该叶结点的键和掩码的简写形式。

86 图18-25给出了储存在rt_flags中的各种常量以及在图18-2的“Flags”列中由netstat输出的相应字符。

常量	netstat标志	描述
RTF_BLACKHOLE		无差错的丢弃分组(环回驱动器:图5-27)
RTF_CLONING	C	使用中产生新的路由(由ARP使用)
RTF_DONE	d	内核的证实，表示消息处理完毕
RTF_DYNAMIC	D	(由重定向)动态创建
RTF_GATEWAY	G	目的主机是一个网关(非直接路由)
RTF_HOST	H	主机路由(否则，为网络路由)
RTF_LLINFO	L	当rt_llinfo指针无效时，由ARP设置
RTF_MASK	m	子网掩码存在(未使用)
RTF_MODIFIED	M	(由重定向)动态修改
RTF_PROTO1	1	协议专用的路由标志
RTF_PROTO2	2	协议专用的路由标志(ARP使用)
RTF_REJECT	R	有差错的丢弃分组(环回驱动器:图5-27)
RTF_STATIC	S	人工添加的路由(route程序)
RTF_UP	U	可用路由
RTF_XRESOLVE	X	由外部守护进程解析名字(用于X.25)

图18-25 rt_flags 的值

netstat不输出RTF_BLACKHOLE标志。两个标志为小写字符的常量，RTF_DONE和RTF_MASK，在路由消息中使用，但通常并不储存在路由表项中。

85 如果设置了RTF_GATEWAY标志，那么rt_gateway所含的插口地址结构的指针就指向网关的地址(即网关的IP地址)。同样，rt_gwroute就指向该网关的rtentry。后一个指针在ether_output(图4-15)中用到。

87 rt_refcnt是一个计数器，保存正在使用该结构的引用数目。在19.3节的最后部分将具体描述该计数器。在图18-2中，该计数器在“Refs”列输出。

88 当分配该结构存储空间时，rt_use被初始化为0。在图8-24中，可发现每次利用该路由输出一份IP数据报时，其值会随之递增。该计数器的值在图18-2的“Use”栏中输出。

89-90 rt_ifp和rt_ifa分别指接口结构和接口地址结构。在图6-5中曾指出一个给定的接口可以有多个地址，因此，rt_ifa是必需的。

92 rt_llinfo指针允许链路层协议在路由表项中储存该协议专用的结构指针。该指针通常与RTF_LLINFO标志一起使用。图21-1描述了ARP如何使用该指针。

```
54 struct rt_metrics {
55     u_long rmx_locks;           /* bitmask for values kernel leaves alone */
56     u_long rmx_mtu;            /* MTU for this path */
57     u_long rmx_hopcount;       /* max hops expected */
58     u_long rmx_expire;         /* lifetime for route, e.g. redirect */
59     u_long rmx_recvpipe;        /* inbound delay-bandwidth product */
60     u_long rmx_sendpipe;        /* outbound delay-bandwidth product */
61     u_long rmx_ssthresh;        /* outbound gateway buffer limit */
62     u_long rmx_rtt;             /* estimated round trip time */
63     u_long rmx_rttvar;          /* estimated RTT variance */
64     u_long rmx_pktsent;         /* #packets sent using this route */
65 };
```

route.h

图18-26 rt_metrics 结构

93 图18-26给出了rt_metrics结构，rtentry结构含有该结构。图27-3显示了TCP使用了该结构的六个成员。

54-65 rmx_locks是一个比特掩码，由它告诉内核后面的八个度量中的哪些禁止修改。该比特掩码的值在图20-13中给出。

ARP(参见第21章)把rmx_expire用作每一个ARP路由项的定时器。与rmx_expire的注释不同的是，rm_expire不是用作重定向的。

图18-28概括了我们上面所阐述的各种结构和这些结构之间的关系，以及所引用的各种插口地址结构。图中给出的rtentry是图18-2中到128.32.33.5的路由。包含在rtentry中的另一个radix_node对应于图18-4中位于该结点正上方的测试比特36的内部结点。第一个ifaddr所指的两个sockaddr_dl结构如图3-38所示。另外，从图6-5中也可注意到ifnet结构包含在le_softc结构中，第二个ifaddr结构包含在in_ifaddr结构中。

18.7 初始化：route_init和rtable_init函数

路由表的初始化过程并非是一目了然的，我们需要回顾一下第7章中的domain结构。在描述这些函数调用之前，图18-27给出了各协议族中与domain结构相关的字段。

成 员	OSI值	Internet值	选路值	Unix值	XNS值	注 释
dom_family	<i>AF_ISO</i>	<i>AF_INET</i>	<i>PF_ROUTE</i>	<i>AF_UNIX</i>	<i>AF_NS</i>	
dom_init	0	0	<i>route_init</i>	0	0	
dom_rtattach	<i>rn_inithead</i>	<i>rn_inithead</i>	0	0	<i>rn_inithead</i>	
dom_rtoffset	48	32	0	0	16	
dom_maxrtkey	32	16	0	0	16	比特 字节

图18-27 domain 结构中与路由选择有关的成员

PF_ROUTE域是唯一具有初始化函数的域。同样，只有那些需要路由表的域才有dom_rtattach函数，并且该函数总是rn_inithead。选路域和Unix域并不需要路由表。

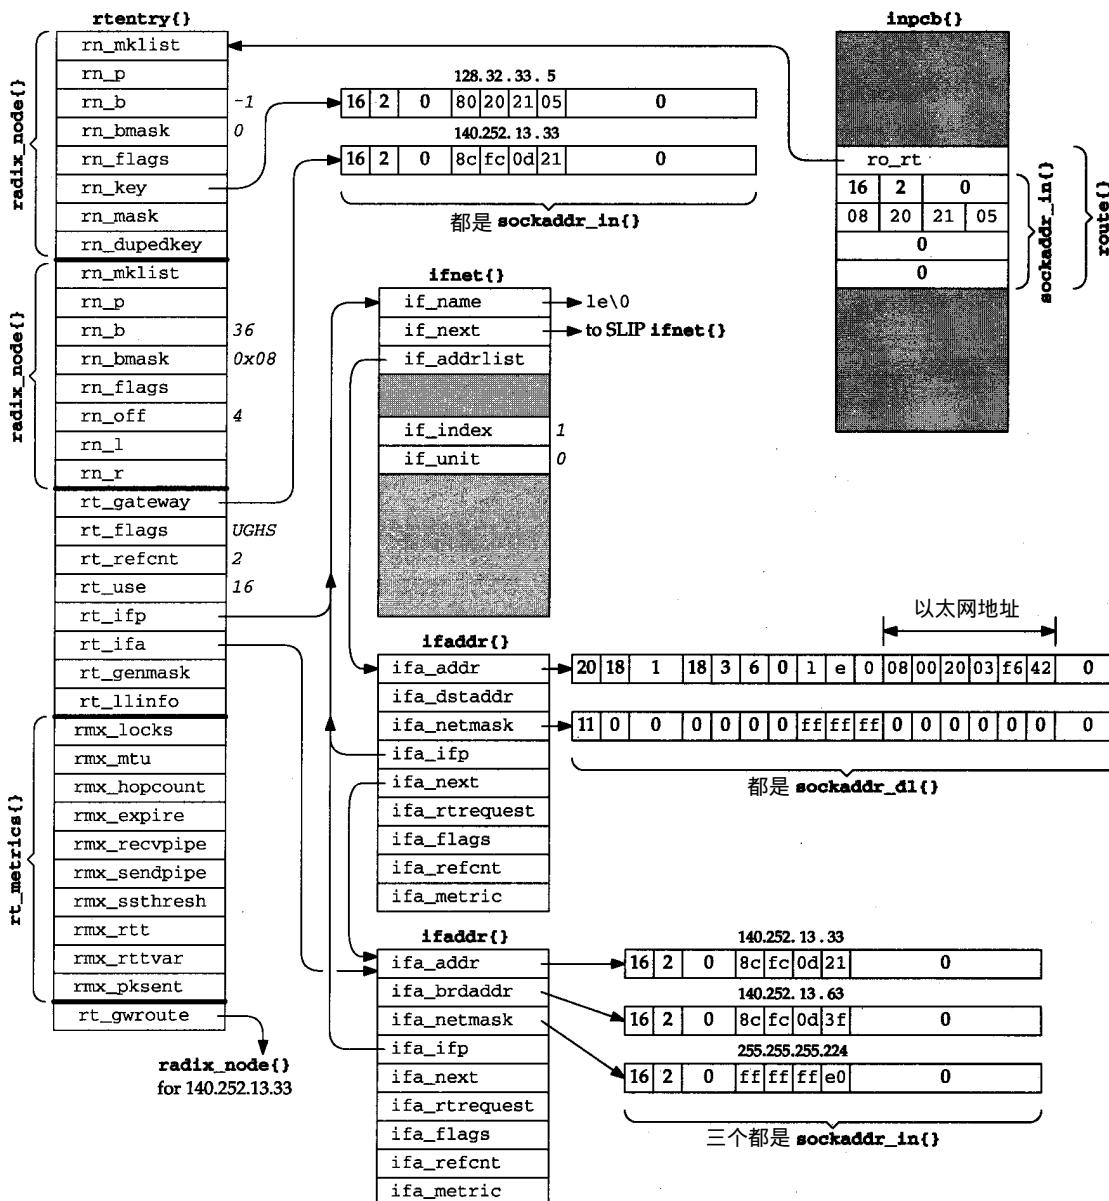


图18-28 选路结构小结

dom_rtoffset成员是以比特为单位的选路过程中被检测的第一个比特的偏移量(从域的插口地址结构的起始处开始计算)。dom_maxrtkey给出了该结构的字节长度。在本章的前一部分的内容中,我们已经知道,sockaddr_in结构中的IP地址是从比特32开始的。dom_maxrtkey成员是协议的插口地址结构的字节长度:sockaddr_in的字节长度为16。

图18-29列出了路由表初始化过程所包含的步骤。

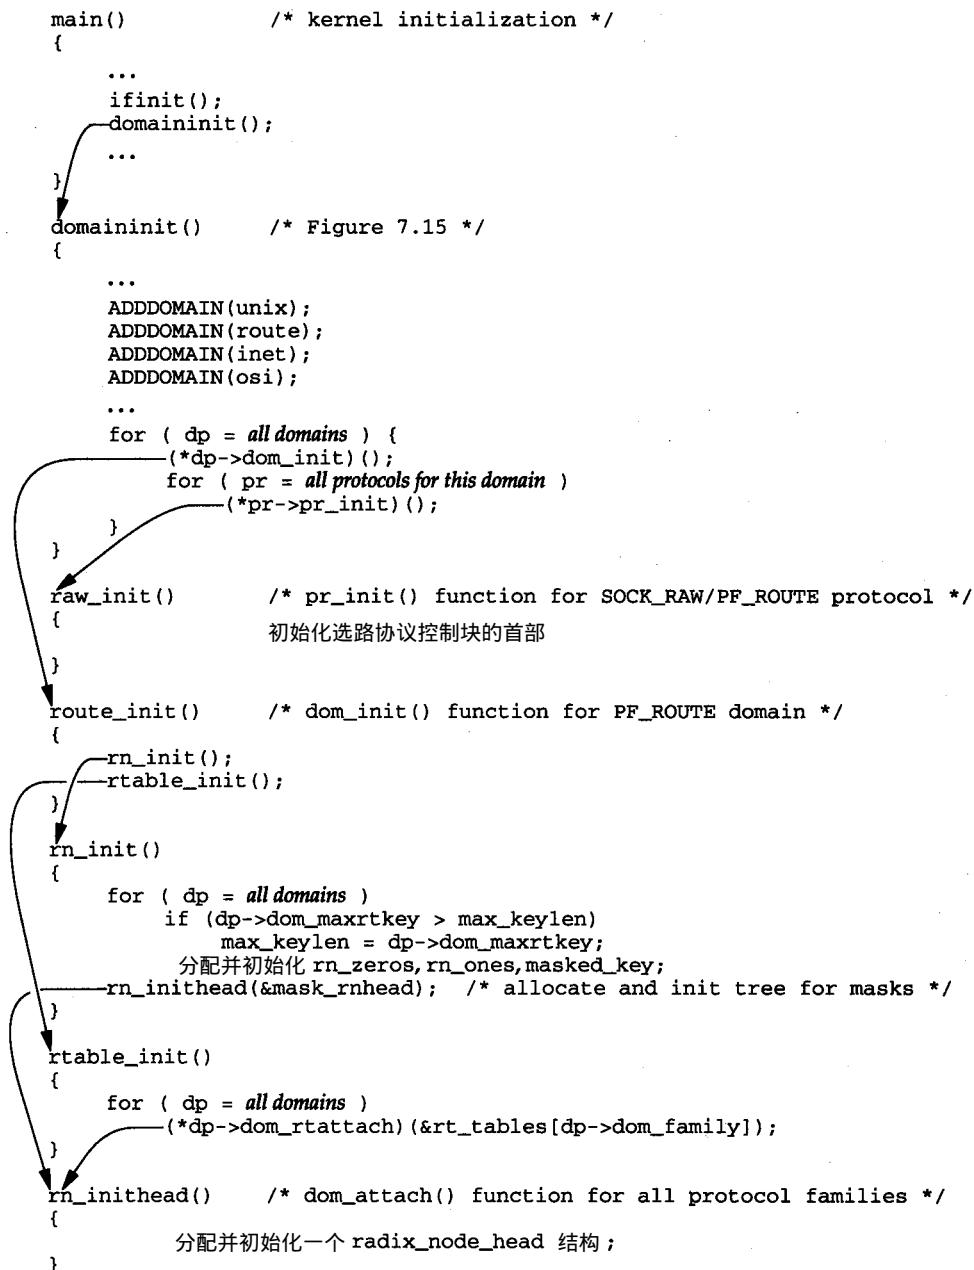


图18-29 初始话路由表时包含的步骤

在系统初始化时,内核的main函数将调用一次domaininit函数。ADD_DOMAIN宏用于

创建一个domain结构的链表，并调用每个域的dom_init函数(如果定义了该函数)。正如图18-27所示，route_init是唯一的一个dom_init函数，其代码如图18-30所示。

```
49 void
50 route_init()
51 {
52     rn_init(); /* initialize all zeros, all ones, mask table */
53     rtable_init((void **) rt_tables);
54 }
```

route.c

图18-30 route_init 函数

在图18-32中的函数rn_init只被调用一次。

在图18-31中的函数rtable_init也只被调用一次。它接着调用所有域的dom_rtattach函数，这些函数为各自所属的域初始化一张路由表。

```
39 void
40 rtable_init(table)
41 void **table;
42 {
43     struct domain *dom;
44     for (dom = domains; dom; dom = dom->dom_next)
45         if (dom->dom_rtattach)
46             dom->dom_rtattach(&table[dom->dom_family],
47                                 dom->dom_rtoffset);
48 }
```

route.c

图18-31 rtable_init 函数：调用每一个域的dom_rtattach 函数

从图18-27中可知，rn_inithead是唯一的一个dom_rtattach函数，关于rn_inithead函数将在下一节中介绍。

18.8 初始化：rn_init和rn_inithead函数

图18-32中的函数rn_init只被route_init调用一次，用于初始化 radix函数使用的一些全局变量。

1. 确定max_keylen

750-761 检查所有domain结构，并将全局变量max_keylen设置为最大的dom_maxrtkey值。在图18-27中最大值是32(对应于AF_ISO)，但是，在一个常用的不含OSI和XNS协议的系统中，max_key为16，即sockaddr_in结构的大小。

2. 分配并初始化rn_zeros、rn_ones和maskedKey

762-769 先分配了一个大小为max_keylen的三倍的缓存，并在全局变量rn_zeros中储存该缓存的指针。R_Malloc是一个调用内核的malloc函数的宏，它指定了M_RTABLE和M_DONTWAIT的类型。我们还会遇到Bcmp、Bcopy、Bzero和Free这些宏，它们对参数进行适当分类，并调用名称相似的内核函数。

该缓存被分解成三个部分，每一部分被初始化成如图18-33所示。

rn_zeros是一个全0比特的数组，rn_ones是一个全1比特的数组，maskedKey数组用于存放被掩码过的查找键的临时副本。

radix.c

```

750 void
751 rn_init()
752 {
753     char *cp, *cplim;
754     struct domain *dom;
755     for (dom = domains; dom; dom = dom->dom_next)
756         if (dom->dom_maxrtkey > max_keylen)
757             max_keylen = dom->dom_maxrtkey;
758     if (max_keylen == 0) {
759         printf("rn_init: radix functions require max_keylen be set\n");
760         return;
761     }
762     R_Malloc(rn_zeros, char *, 3 * max_keylen);
763     if (rn_zeros == NULL)
764         panic("rn_init");
765     Bzero(rn_zeros, 3 * max_keylen);
766     rn_ones = cp = rn_zeros + max_keylen;
767     maskedKey = cplim = rn_ones + max_keylen;
768     while (cp < cplim)
769         *cp++ = -1;
770     if (rn_inithead((void **) &mask_rnhead, 0) == 0)
771         panic("rn_init 2");
772 }

```

radix.c

图18-32 rn_init 函数

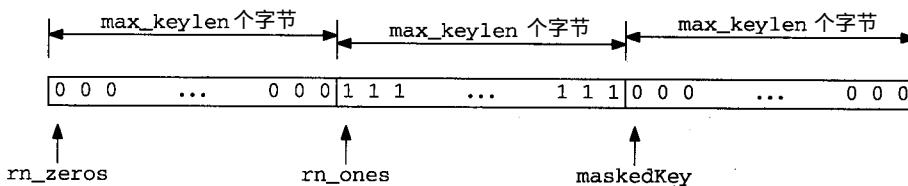


图18-33 rn_zeros、rn_ones 和maskedKey 数组

3. 初始化掩码树

770-772 调用rn_inithead，初始化地址掩码路由树的首部；并使图 18-8中全局变量mask_rnhead指向该radix_node_head结构。

从图18-27可知，对于所有需要路由表的协议，rn_inithead也是它们的dom_attach函数。图 18-34给出的不是该函数的源代码，而是该函数为 Internet协议 创建的radix_node_head结构。

这三个radix_node结构组成了一棵树：中间的那个结构是树的顶点（由rnh_treetop指向它），第一个结构是树的最左边的叶子，最后一个结构是树的最右边的叶子。这三个结点的父指针(rn_p)都指向中间的那个结点。

rnh_nodes[1].rn_b的值32是待测试的比特位置。它来自于 Internet的domain结构中的dom_rtoffset成员(图18-27)。它的字节偏移量及字节掩码被预先计算出来，这样就不需要在处理过程中完成移位和掩码。其中，字节偏移量从插口地址结构起始处开始计算，它被存放在radix_node结构的rn_off成员中(在这个例子中它的值为 4)；字节掩码存放在rn_bmask成员中(在这个例子中为0x80)。无论何时往树中添加 radix_node结构，都要计

算这些值，以便于在转发过程中加快比较的速度。其他的例子有：在图 18-4 中检测比特 33 的两个结点的偏移量和字节掩码分别为 4 和 0x40；检测比特 63 的两个结点的偏移量和字节掩码分别为 7 和 0x01。

两个叶子中的 rn_b 成员的值 -33 是由 -1 减去该叶子的索引而得到的。

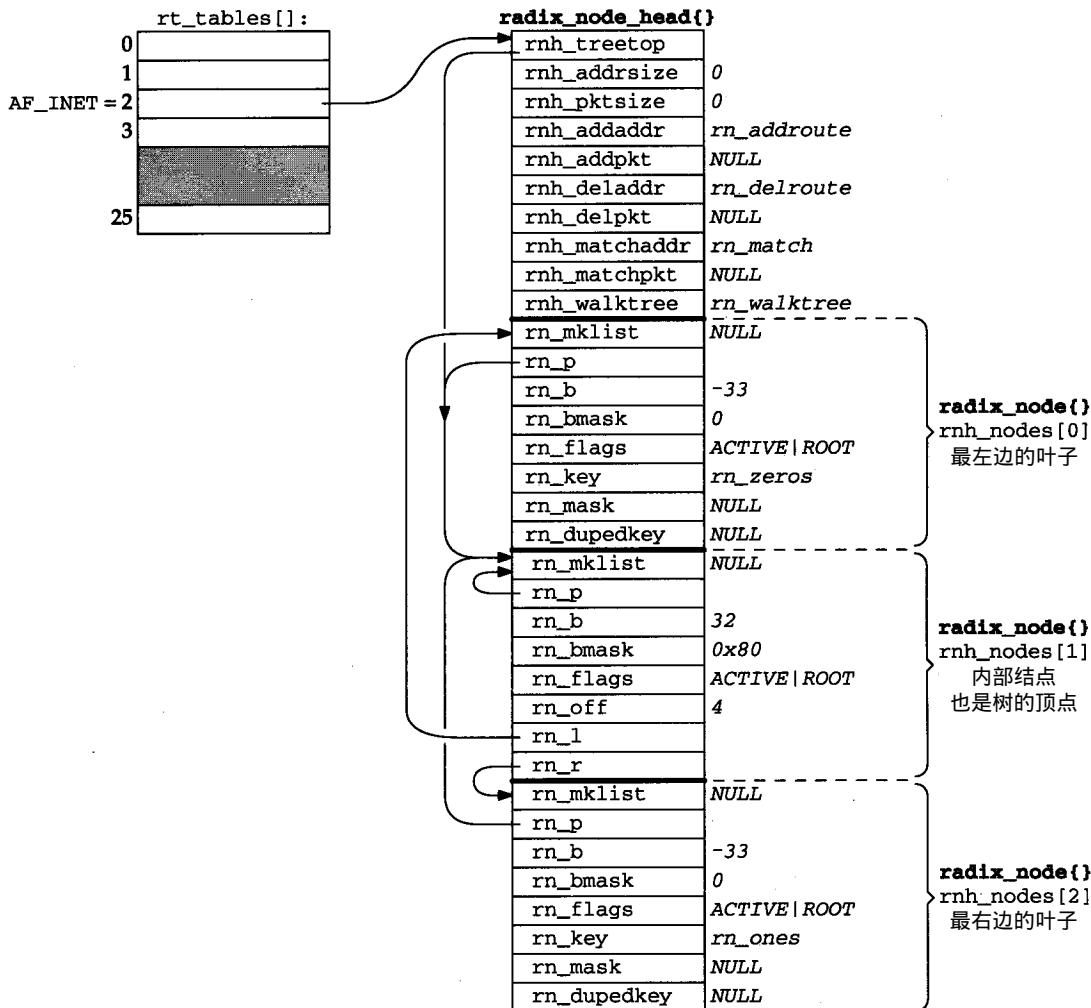


图18-34 `rn_inithead` 为Internet协议创建的 `radix_node_head` 结构

最左边结点的键是全 0 (`rn_zeros`)，最右边结点的键是全 1 (`rn_ones`)。

这三个结点都设置了 RNF_ROOT 标志(我们省略了前缀 RNF_)。这说明它们都是构成树的原始结点之一。它们也是唯一具有该标志的结点。

有一个细节我们没有提到，就是网络文件系统 (NFS) 也使用路由表函数。对于本地主机的每一个装配点 (mount point) 都分配一个 `radix_node_head` 结构，并且具有一个指向这些结构的指针数组 (利用协议族检索)，与 `rt_tables` 数组相似。每次输出装配点时，针对该装配点，把能装配该文件系统的主机的协议地址添加到适当的树中去。

18.9 重复键和掩码列表

在介绍查找路由表项的源代码之前，必须先理解 `radix_node` 结构中的两个字段：一个是 `rn_dupedkey`，它构成了附加的含重复键的 `radix_node` 结构链表；另一个是 `rn_mklist`，它是含网络掩码的 `radix_mask` 结构链表的开始。

先看一下图18-4中树的最左边标有“end”和“default”的两个框。这些就是重复键。最左边设有RNF_ROOT标志的结点(在图18-34中的`rnh_nodes[0]`)有一个为全0比特的键，但是它和默认路由的键相同。如果创建一个255.255.255.255的路由表项(但该地址是受限的广播地址，不会在路由树中出现)，则我们会在树的最右端结点(该结点有一个值为全1比特的键)遇到同样的问题。总的来说，如果每次都有不同的掩码，那么Net/3中的radix结点函数就允许重复任何键。

图18-35给出了两个具有全0比特重复键的结点。在这个图中，我们去掉了 `rn_flags` 中的RNF_前缀，并且省略了非空父指针、左指针和右指针，因为它们与要讨论的内容无关。

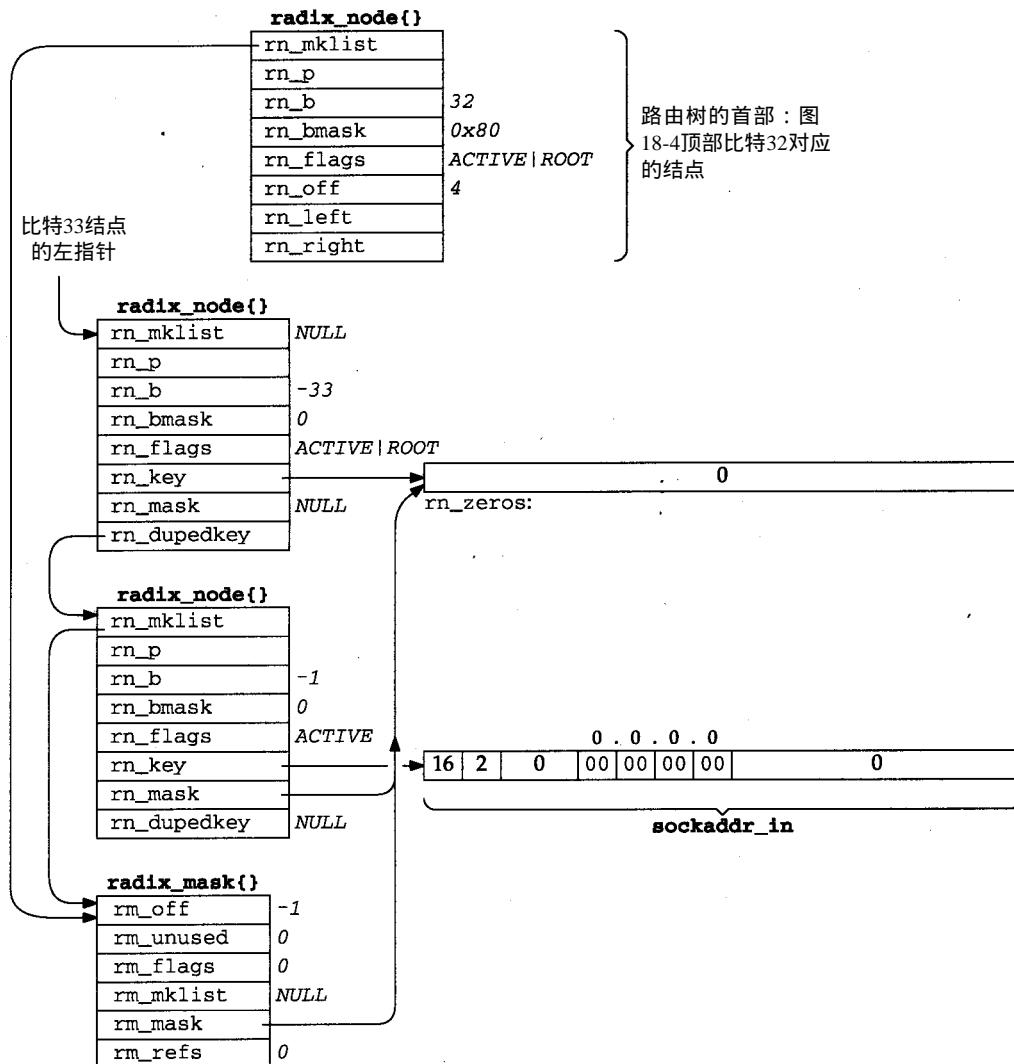


图18-35 值为全0的键的重复结点

图中最上面的结点即为路由树的顶点——图18-4中顶部比特32对应的结点。接下来的两个结点是叶子(它们的rn_b为负值)，其中第一个叶子的rn_dupedkey成员指向第二个结点。第一个叶子是图18-34中的rnh_nodes[0]结构，该结构是树的左边标有“end”的结点——它设有RNF_ROOT标志。它的键被rn_inithead设为rn_zeros。

第二个叶子是默认路由的表项。它的rn_key指向值为0.0.0.0的sockaddr_in结构，并具有一个全0的掩码。由于掩码表中相同的掩码是共享的，因此，该叶子的rn_mask也指向rn_zeros。

通常，键是不共享的，更不会与掩码共享。由于两个标有“end”的结点的rn_key指针(具有RNF_ROOT标志)是由rn_inithead(图18-34)创建的，因此这两个指针例外。左边标有end的结点的键指向rn_zeros，右边标有“end”的结点的键指向rn_ones。

最后一个radix_mask结构，树的顶结点和默认路由对应的叶子都指向这个结构。这个列表是树的顶结点的掩码列表，在查找网络掩码时，回溯算法将使用它。radix_mask结构列表和内部结点一起确定了运用于从该结点开始的子树的掩码。在重复键的例子中，掩码列表和叶子出现在一起，跟着的这个例子也是这样的。

现在我们给出一个特意添加到选路树中的重复键和所得到的掩码列表。在图18-4中有一个主机路由127.0.0.1和一个网络路由127.0.0.0。图中采用了A类网络路由的默认掩码，即0xffff00000。如果我们把跟在A类网络号之后的24 bit分解成一个16 bit子网号和一个8 bit主机号，就可以为子网127.0.0添加一个掩码为0xffffffff00的路由：

```
bsdi $ route add 127.0.0.0 -netmask 0xffffffff00 140 252 13 33
```

虽然在这种情况下使用网络127没什么实际意义，但是我们感兴趣的是所得到的路由表结构。虽然重复键在Internet协议中并不常见(除了前面例子中的默认路由之外)，但是仍需要利用重复键来为所有网络的0号子网提供路由。

在网络号127的这三个路由表项中存在一个隐含的优先规则。如果查找键是127.0.0.1，则它和这三个路由表项都匹配，但是只选择主机路由，因为它是最匹配的：其掩码(0xffffffffffff)含有最多的1。如果查找键是127.0.0.2，它与两个网络路由匹配，但是掩码为0xffffffffffff00的子网0的路由比掩码为0xffff0000的路由更匹配。如果查找键为127.0.2.3，那么只与掩码为0xffff000000的路由表项匹配。

图18-36给出了添加路由之后得到的树结构，从图18-4中对应比特33的内部结点处开始。由于这个重

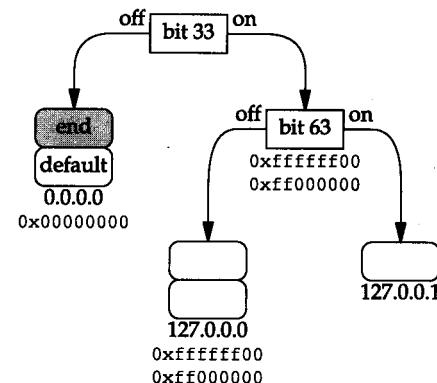


图18-36 反映重复键127.0.0.0的路由树

图18-37给出了所得到的radix_node和radix_mask结构。

首先看一下每一个radix_node的radix_mask结构的链表。最上端结点(比特63)的掩码列表由0xffffffff00及其后的0xffff000000组成。在列表中首先遇到的是更匹配的掩码，这样它就能够更早地被测试到。第二个radix_node(rn_b值为-57的那个)的掩码列表与第一个相同。但是第三个radix_node的掩码列表仅由值为0xffff000000的掩码构成。

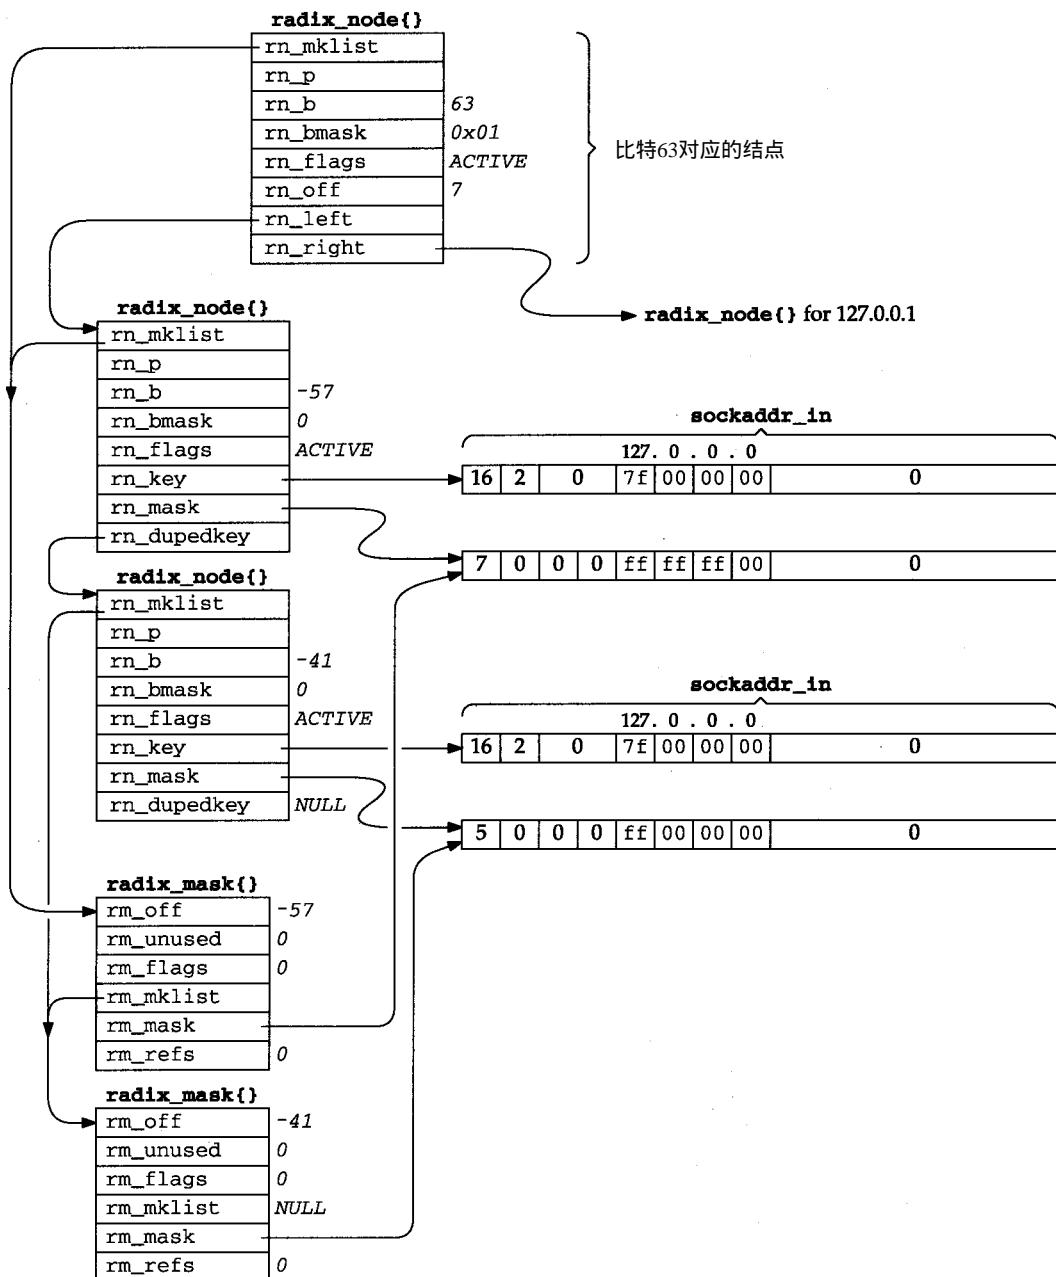


图18-37 网络127.0.0.0的重复键的路由表结构举例

应注意的是，具有相同值的掩码之间可以共享，但是具有相同值的键之间不能共享。这是因为掩码被保存在它们自己的路由树中，可以显式地被共享，而且值相同的掩码经常出现（例如，每个C类网络路由都有相同的掩码 0xffffffff00），但是值相同的键却很不常见。

18.10 rn_match函数

现在我们介绍rn_match函数，在Internet协议中，它被称为rnh_matchaddr函数。在

后面学习中，我们可以看到它将被 `rtalloc1` 函数调用（而 `rtalloc1` 函数将被 `rtalloc` 函数调用）。具体算法如下：

- 1) 从树的顶端开始搜索，直到到达与查找键的比特相应的叶子。检测该叶子，看能否得到一个精确的匹配（图18-38）。
 - 2) 检测该叶结点，看是否能得到匹配的网络地址。
 - 3) 回溯（图18-43）。
- 图18-38给出了`rn_match`的第一部分。

```

135 struct radix_node *
136 rn_match(v_arg, head)
137 void *v_arg;
138 struct radix_node_head *head;
139 {
140     caddr_t v = v_arg;
141     struct radix_node *t = head->rnh_treetop, *x;
142     caddr_t cp = v, cp2, cp3;
143     caddr_t cplim, mstart;
144     struct radix_node *saved_t, *top = t;
145     int off = t->rn_off, vlen = *(u_char *) cp, matched_off;
146
147     /*
148      * Open code rn_search(v, top) to avoid overhead of extra
149      * subroutine call.
150      */
151     for (; t->rn_b >= 0;) {
152         if (t->rn_bmask & cp[t->rn_off])
153             t = t->rn_r;           /* right if bit on */
154         else
155             t = t->rn_l;           /* left if bit off */
156     }
157     /*
158      * See if we match exactly as a host destination
159      */
160     cp += off;
161     cp2 = t->rn_key + off;
162     cplim = v + vlen;
163     for (; cp < cplim; cp++, cp2++)
164         if (*cp != *cp2)
165             goto on1;
166     /*
167      * This extra grot is in case we are explicitly asked
168      * to look up the default. Ugh!
169      */
170     if ((t->rn_flags & RNF_ROOT) && t->rn_dupedkey)
171         t = t->rn_dupedkey;
172     return t;
173 on1:

```

radix.c

图18-38 `rn_match` 函数：沿着树向下搜索，查找严格匹配的主机地址

135-145 第一个参数 `v_arg` 是一个插口地址结构的指针，第二个参数 `head` 是该协议的指向 `radix_node_head` 结构的指针。所有协议都可调用这个函数（图18-17），但调用时使用不同的 `head` 参数。

在变量声明中，`off` 是树的顶结点的 `rn_off` 成员（对 Internet 地址，其值为 4，见图18-34），

vlen是查找键插口地址结构中的长度字段(对Internet地址，其值为16)。

1. 沿着树向下搜索到相应的叶子

146-155 这个循环从树的顶结点开始，然后沿树的左右分支搜索，直到遇到一个叶子为止(*rn_b*小于0)。每次测试相应比特时，都利用了事先计算好的*rn_bmask*中的字节掩码和事先计算好的*rn_off*中的偏移量。对于Internet地址而言，*rn_off*为4、5、6或7。

2. 检测是否精确匹配

156-164 当遇到叶子时，首先检测能否精确匹配。比较插口地址结构中从协议族的*rn_off*值开始的所有字节。图18-39给出了Internet插口地址结构的比较情况。

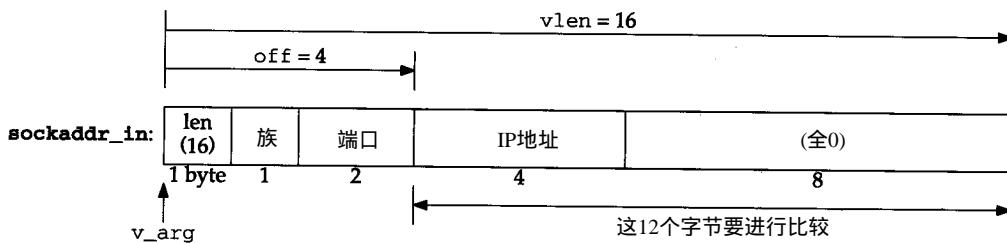


图18-39 比较*sockaddr_in* 结构时的各种变量

如果发现匹配不成功，就立刻跳到on1。

通常，*sockaddr_in*的最后8个字节为0，但是地址解析协议代理(proxy ARP)(21.12节)会设置其中的一个为非零。这就允许一个给定的IP地址有两个路由表项：一个对应于正常IP地址(最后8个字节为0)，另一个对应于相同IP地址的地址解析协议代理(最后8个字节中有一个为非零)。

图18-39中的长度字节在函数的一开始时就赋值给了*vlen*，并且我们还会看到*rtalloc1*将利用*family*成员来选择路由表进行搜索。选路函数未使用*port*成员。

3. 显示地检测默认地址

165-172 图18-35给出了存储在键为0的重复叶子中的默认路由。第一个重复的叶子设有RNF_ROOT标志。因此，如果在匹配的结点中设有RNF_ROOT标志，并且该叶子含有重复键，那么就返回指针*rn_duplicatedkey*的值(即图18-35中含默认路由的结点的指针)。如果路由树中没有默认路由，则查找过程匹配左边标有“end”的叶子(键为全0比特)；或者如果查找时遇到右边标有“end”的叶子(键值为全1比特)，那么返回指针*t*，它指向一个设有RNF_ROOT标志的结点。我们将看到*rtalloc1*会显式地检查匹配结点是否设有这个标志，并判断匹配是否失败。

程序执行到此时，*rn_match*函数已经到达了某个叶子上，但是它并不是查找键的精确匹配。函数的下一部分将检测该叶子是否为匹配的网络地址，如图18-40所示。

173-174 *cp*指向该查找键中那个不相等的字节。*matched_off*被赋值为该字节在插口地址结构中的位置偏移量。

175-183 do while循环反复与所有重复叶子中的每一个具有网络掩码的叶子进行比较。下面我们通过一个例子来看这段代码。假定我们要在图18-4所示的路由表中查找IP地址140.252.13.60。查找会在标有140.252.13.32(比特62和63都为0)的结点处终止，该结点包含一个网络掩码。图18-41给出了图18-40中的for循环开始执行时的结构。

```

173     matched_off = cp - v;
174     saved_t = t;
175     do {
176         if (t->rn_mask) {
177             /*
178              * Even if we don't match exactly as a host,
179              * we may match if the leaf we wound up at is
180              * a route to a net.
181             */
182             cp3 = matched_off + t->rn_mask;
183             cp2 = matched_off + t->rn_key;
184             for (; cp < cplim; cp++)
185                 if ((*cp2++ ^ *cp) & *cp3++)
186                     break;
187             if (cp == cplim)
188                 return t;
189             cp = matched_off + v;
190         }
191     } while (t = t->rn_dupedkey);
192     t = saved_t;

```

radix.c

图18-40 rn_match 函数：检测是否为匹配的网络地址

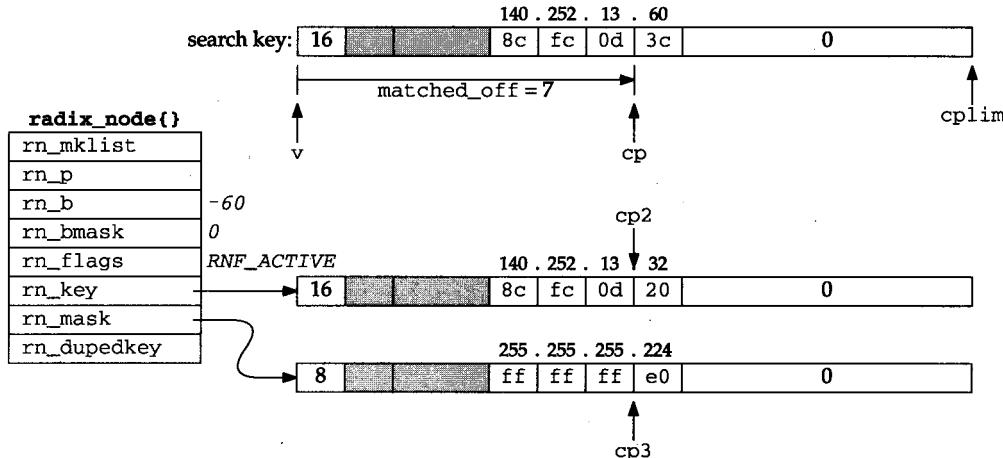


图18-41 比较网络掩码的例子

虽然查找键和路由表键都是 `sockaddr_in` 结构，但是掩码的长度并不相同。该掩码长度是非零字节的最小数目。从该点之后直到 `max_keylen` 之间的所有字节都为 0。

184-190 逐个字节地对查找关键字和路由表键进行异或运算，并将结果同网络掩码进行逻辑与运算。如果所得到的字节出现非零值，就会由于不匹配而终止循环（习题18.1）。如果循环正常终止，那么与网络掩码进行逻辑与运算后的查找键就和路由表项相匹配。程序将返回指向该路由表项的指针。

查看IP地址的第四个字节，我们可以从图 18-42 中看出本例子是如何匹配成功的，以及 IP 地址 140.252.13.188 是如何匹配失败的。采用这两个地址，是因为它们中的比特 57、62 和 63 都为 0，查找都在图 18-41 给出的结点上终止。

第一个例子(140.252.13.60)匹配成功是因为逻辑与运算的结果为 0(并且地址、键和掩码中所有剩余的字节全都为 0)。另一个例子匹配不成功是因为逻辑与运算的结果为非零。

	查找键 = 140.252.13.60	查找键 = 140.252.13.188
查找关键字节 (*cp):	0011 1100 = 3c	1011 1100 = bc
路由表关键字节 (*cp2):	0010 0000 = 20	0010 0000 = 20
异或:	0001 1100	1001 1100
网络掩码字节 (*cp3):	1110 0000 = e0	1110 0000 = e0
逻辑与:	0000 0000	1000 0000

图18-42 用网络掩码进行关键字匹配的例子

191 如果路由表项含有重复键，那么对每一个键都要执行一次该循环体。

rn_match的最后一部分，如图18-43所示，沿路由树向上回溯，以查找匹配的网络地址或默认地址。

```

193     /* start searching up the tree */
194     do {
195         struct radix_mask *m;
196         t = t->rn_p;
197         if (m = t->rn_mklist) {
198             /*
199             * After doing measurements here, it may
200             * turn out to be faster to open code
201             * rn_search_m here instead of always
202             * copying and masking.
203             */
204             off = min(t->rn_off, matched_off);
205             mstart = maskedKey + off;
206             do {
207                 cp2 = mstart;
208                 cp3 = m->rm_mask + off;
209                 for (cp = v + off; cp < cplim;)
210                     *cp2++ = *cp++ & *cp3++;
211                 x = rn_search(maskedKey, t);
212                 while (x && x->rn_mask != m->rm_mask)
213                     x = x->rn_duplicatedkey;
214                 if (x &&
215                     (Bcmp(mstart, x->rn_key + off,
216                           vlen - off) == 0))
217                     return x;
218             } while (m = m->rm_mklist);
219         }
220     } while (t != top);
221     return 0;
222 };

```

radix.c

图18-43 rn_match 函数：沿树向上回溯

193-195 do while 循环沿着路由树一直向上，检测每一层的结点，直至检测到树的顶端为止。

196 指向父结点的指针的值被赋给了指针 t，即向上移动了一层。可见，在每一个结点中包含一个父指针能够简化回溯操作。

197-210 对于回溯到的每一层，只要内部结点的掩码列表非空，就对该层进行检测。

rn_mklist是指向 radix_node结构的链表的指针，链表中的每一个 radix_node结构都包含一个掩码，这些掩码将应用于从该结点开始的子树。程序中的内部 do while 循环将遍历每一个 radix_mask 结构。

利用前面的例子，140.252.13.188，图18-44给出了在最内层的for循环开始时的各种数据结构。这个循环对每个掩码中的字节和对应的查找键的字节进行逻辑与操作，并将结果保存在全局变量 maskedKey 中。该掩码值为 0xfffffff fe0，搜索会从图 18-4 中的叶结点 140.252.13.32 处回溯两层，到达测试比特 62 的结点。

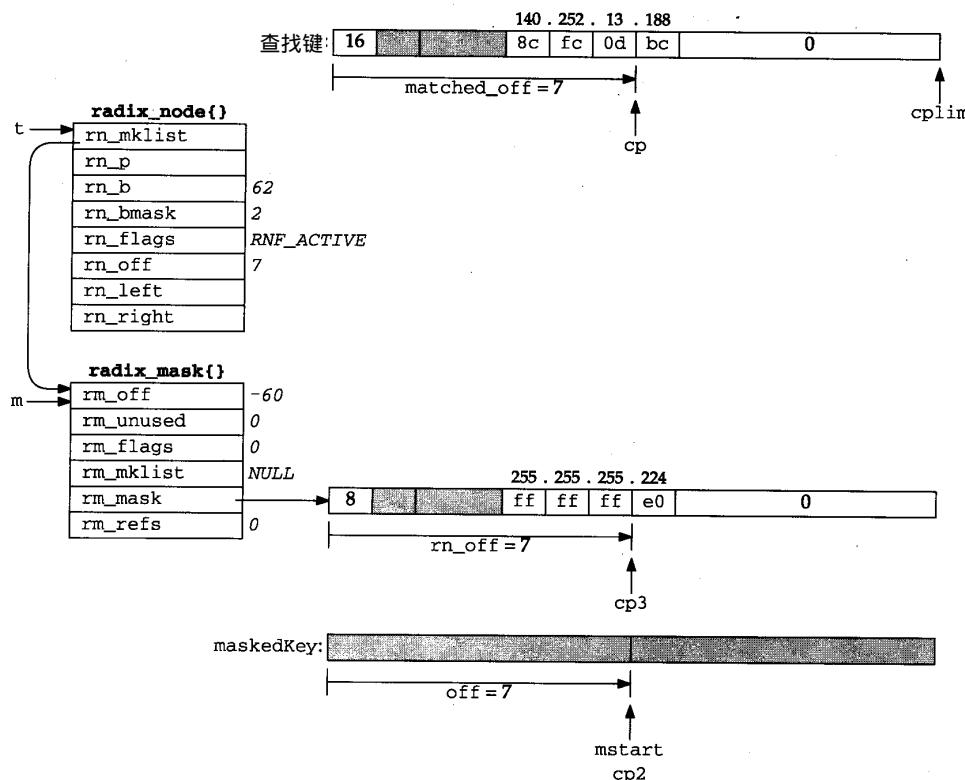


图18-44 利用掩码过的查找键进行再次搜索的准备

for 循环完成后，掩码过程也就完成了，再调用 rn_search(如图18-48所示)，其调用参数以 maskedKey 为查找键，以指针 t 为查找子树的顶点。图 18-45 给出了我们所举例子中的 maskedKey 的值。

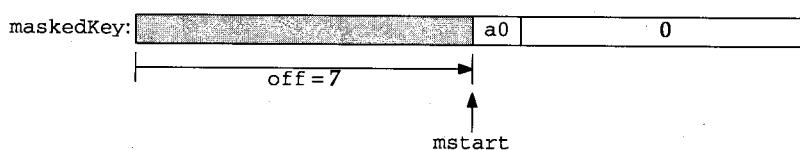
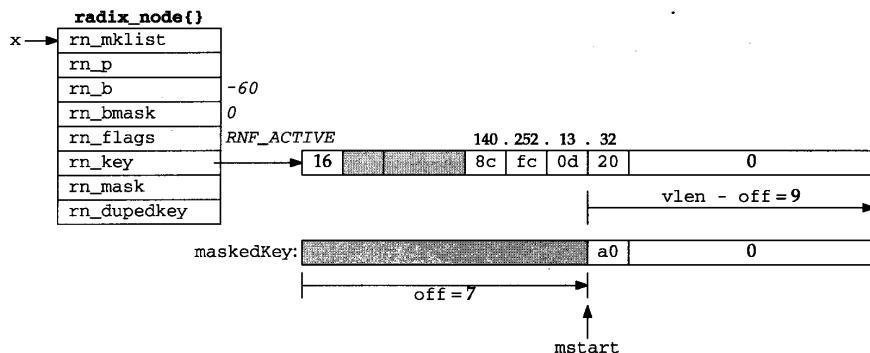
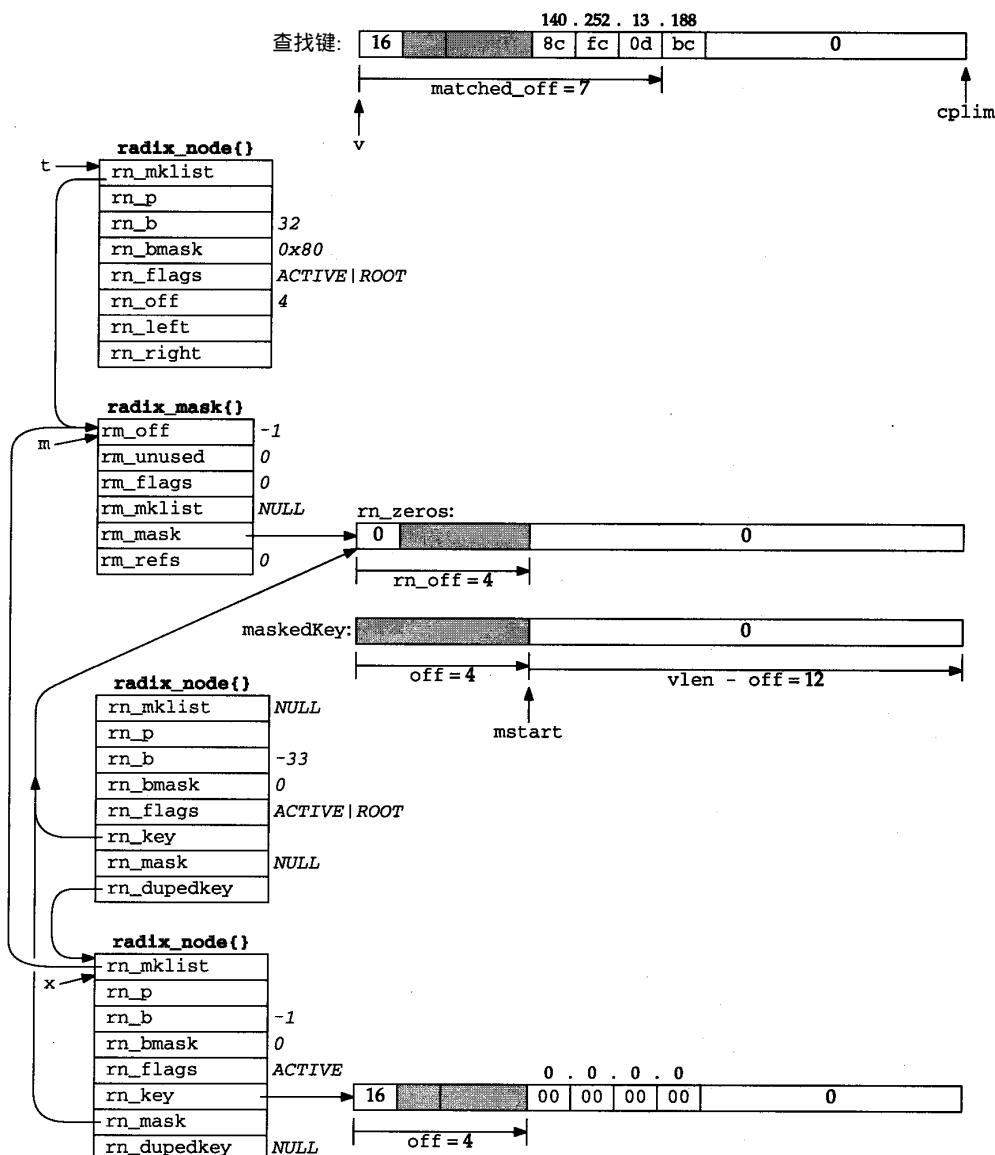


图18-45 调用 rn_search 时的 maskedKey

字节 0xa0 是 0xbc(188，查找键) 和 0xe0(掩码) 逻辑与运算的结果。

211 rn_search 从起点开始沿着树往下搜索，根据查找键来确定沿向左或向右的分支进行搜索，直到到达某个叶子。在这个例子中，查找键有 9 个字节，如图 18-45 所示，所到达的是图 18-4 中标有 140.252.13.32 的那个叶子，这是因为在字节 0xa0 中比特 62 和 63 都为 0。图 18-46 给出了调用 Bcmp 检验是否匹配时的数据结构。

由于这两个 9 字节的字符串不相同，所以这次比较失败。

图18-46 `maskedKey` 和新叶结点之间的比较图18-47 回溯到路由树的顶端和查找默认叶子的 `rn_search`

212-221 该while循环处理各重复键，且处理每个重复键时的掩码不同。唯一被比较的重复键是那个rn_mask指针与m->rm_mask相等的键。下面以图18-36和图18-37为例进行说明。如果查找从比特63的结点处开始，第一次内部do while循环中，m指向radix_mask结构0xfffffffff00。当rn_search返回指向第一个重复叶子127.0.0.0的指针时，该叶子的rm_mask等于m->rm_mask，因此，就调用Bcmp。如果比较失败，m的值就被设置成指向列表中的下一个radix_mask结构(具有掩码0xff000000)的指针，并且对新掩码再次执行do while循环体。rn_search再一次返回指向第一个重复叶子127.0.0.0的指针，但是它的rn_mask并不等于m->rm_mask。While继续进行到下一个重复叶子，它的rn_mask与m->rm_mask恰好相等。

现在回到查找键为140.252.13.188的例子中，由于从检测比特62的结点处开始的搜索失败，因此，沿着树向上继续回溯，直到到达树的顶点，该顶点就是沿树向上的下一个rn_mklist为非空的结点。

图18-47给出了到达树的顶结点时的数据结构。此时，计算maskedKey(为全0)，并且rn_search从这个结点(树的顶结点)处开始，继续沿着树的左分支向下两层到达图18-4中标有“default”的叶子。

当rn_search返回时，x指向rn_b值为-33的radix_node，这是从树的顶端开始沿两个左分支向下之后遇到的第一个叶子。但是x->rn_mask(为空)与m->rm_mask不等，因此，将x->rn_dupedkey赋给x。用于测试的while循环再次执行，但是，此时x->rn_mask等于m->rm_mask，因此该while循环终止。Bcmp对从mstart开始的12个值为0的字节和从x->rn_key加4开始的12个值为0的字节进行比较，结果相等，函数返回指针x，该指针指向默认路由的路由项。

18.11 rn_search函数

在前面一节中，我们已经知道rn_match调用了rn_search来搜索路由表的子树。如图18-48所示。

```

79 struct radix_node *
80 rn_search(v_arg, head)
81 void    *v_arg;
82 struct radix_node *head;
83 {
84     struct radix_node *x;
85     caddr_t v;
86     for (x = head, v = v_arg; x->rn_b >= 0;) {
87         if (x->rn_bmask & v[x->rn_off])
88             x = x->rn_r;           /* right if bit on */
89         else
90             x = x->rn_l;           /* left if bit off */
91     }
92     return (x);
93 }

```

radix.c

radix.c

图18-48 rn_search 函数

这个循环和图18-38中的相似。它在每一个结点上比较查找键中的一位比特，如果该比特

为0，就通向左边的分支，如果该比特为1，就通向右边的分支。在遇到一个叶子时终止搜索，并返回指向该叶子的指针。

18.12 小结

每一个路由表项都由一个键来标识：在IP协议中就是目的IP地址，该IP地址可以是一个主机地址或者是一个具有相应网络掩码的网络地址。一旦键的搜索确定了路由表项，在该表项中的其他信息就会指定一个路由器的IP地址，到目的地址的数据报就会发往该指定地址，还会指明要用到的接口的指针、度量等等。

由Internet协议维护的信息是route结构，该route结构只有两个成员构成：指向路由表项的指针和目的地址。在UDP、TCP和原始IP使用的每个Internet协议控制块中，我们都会遇到由Internet协议维护的route结构。

Patricia树数据结构非常适合于路由表。由于路由表的查找要比添加或者删除路由频繁得多，因此从性能的角度来看，在路由表中使用Patricia树就更加有意义。Patricia树虽然不利于添加和删除这些附加工作，但是加快了查找的速度。[Sklower 1991]给出的radix树方法和Net/1散列表的比较结果表明，用radix树方法构造测试树用比Net/1散列表法快一倍，搜索速度快三倍。

习题

- 18.1 我们说过，在图18-3中，查找键与路由表项匹配的一般条件是，它和路由表掩码的逻辑与运算的结果等于路由表键。但是在图18-40中采用了不同的测试方法。请建立一个逻辑真值表以证明这两种方法等价。
- 18.2 假设某个Net/3系统中的路由表需要20 000个表项(IP地址)。在不考虑掩码的情况下，请估算大约需要多大的存储器？
- 18.3 radix_node结构对路由表键的长度限制是多少？

第19章 选路请求和选路消息

19.1 引言

内核的各种协议并不直接使用前一章提供的函数来访问选路树，而是调用本章提供的几个函数：`rtalloc`和`rtalloc1`是完成路由表查询的两个函数；`rtrequest`函数用于添加和删除路由表项；另外大多数接口在接口连接或断开时都会调用函数`rtinit`。

选路消息在两个方向上传递信息。进程(如`route`命令)或守护进程(`routed`或`gated`)把选路消息写入选路插口，以使内核添加路由、删除路由或修改现有的路由。当有事件发生时，如接口断开、收到重定向等，内核也会发送选路消息。进程通过选路插口来读取它们感兴趣的内容。在本章中，我们将讨论这些选路消息的格式及其含义，关于选路插口的讨论将在下一章进行。

内核还提供了另一种访问路由表的接口，即系统的`sysctl`调用，我们将在本章的结尾部分阐述。该系统调用允许进程读取整个路由表或所有已配置的接口及接口地址。

19.2 `rtalloc`和`rtalloc1`函数

通常，路由表的查找是通过调用`rtalloc`和`rtalloc1`函数来实现的。图19-1给出了`rtalloc`。

```
58 void  
59 rtalloc(ro)  
60 struct route *ro;  
61 {  
62     if (ro->ro_rt && ro->ro_rt->rt_ifp && (ro->ro_rt->rt_flags & RTF_UP))  
63         return; /* XXX */  
64     ro->ro_rt = rtalloc1(&ro->ro_dst, 1);  
65 }
```

图19-1 `rtalloc` 函数

58-65 参数`ro`是一个指针，它指向TCP或UDP所使用的Internet PCB(第22章)中的`route`结构。如果`ro`已经指向了某个`rtentry`结构(即`ro_rt`非空)，而该结构指向一个接口结构且路由有效，则函数立即返回。否则，`rtalloc1`将被调用，调用的第二个参数为1。我们很快会看到该参数的用途。

如图19-2所示，`rtalloc1`调用了`rnh_matchaddr`函数，对于Internet地址来说，该函数就是`rn_match`数(图18-17)。

66-76 第一个参数是一个指针，它指向一个含有待查找地址的插口地址结构。`sa_family`成员用于选择所查找的路由表。

1. 调用`rn_match`

77-78 如果符合下列三个条件，则查找成功。

1) 存在该协议族的路由表；

2) `rn_match`返回一个非空指针；并且

3) 匹配的radix_node结构没有设置RNF_ROOT标志。

注意，树中标有end的两个叶子都设有RNF_ROOT标志。

```

66 struct rtentry *
67 rtalloc1(dst, report)
68 struct sockaddr *dst;
69 int      report;
70 {
71     struct radix_node_head *rnh = rt_tables[dst->sa_family];
72     struct rtentry *rt;
73     struct radix_node *rn;
74     struct rtentry *newrt = 0;
75     struct rt_addrinfo info;
76     int      s = splnet(), err = 0, msgtype = RTM_MISS;

77     if (rnh && (rn = rnh->rn_matchaddr((caddr_t) dst, rnh)) &&
78         ((rn->rn_flags & RNF_ROOT) == 0)) {
79         newrt = rt = (struct rtentry *) rn;
80         if (report && (rt->rt_flags & RTF_CLONING)) {
81             err = rtrequest(RTM_RESOLVE, dst, SA(0),
82                             SA(0), 0, &newrt);
83             if (err) {
84                 newrt = rt;
85                 rt->rt_refcnt++;
86                 goto miss;
87             }
88             if ((rt = newrt) && (rt->rt_flags & RTF_XRESOLVE)) {
89                 msgtype = RTM_RESOLVE;
90                 goto miss;
91             }
92         } else
93             rt->rt_refcnt++;
94     } else {
95         rtstat.rts_unreach++;
96     miss:if (report) {
97         bzero((caddr_t) & info, sizeof(info));
98         info.rti_info[RTAX_DST] = dst;
99         rt_missmsg(msgtype, &info, 0, err);
100    }
101 }
102 splx(s);
103 return (newrt);
104 }
```

route.c

图19-2 rtalloc1 函数

2. 查找失败

94-101 在这三个条件中只要有一个条件没有得到满足，查找就会失败，并且统计值 rts_unreach也要递增。这时，如果调用 rtalloc1的第二个参数(report)为1，就会产生一个选路消息。任何感兴趣的进程都可以通过选路插口读取该消息。选路消息的类型为 RTM_MISS，并且函数返回一个空指针。

79 如果三个条件都满足，则查找成功。指向匹配的 radix_node结构的指针保存在 rt和 newrt中。注意，在rtentry结构的定义中(图18-24)，两个radix_node结构在开头的位置处，如图18-8所示，其中第一个代表一个叶结点。因此， rn_match返回的radix_node结构的指针事实上是一个指向 rtentry结构的指针，该rtentry结构是一个匹配的叶结点。

3. 创建克隆表项

80-82 如果调用的第二个参数非零，而且匹配的路由表项设有 RTF_CLONING标志，则调用rtrequest函数发送RTM_RESOLVE命令来创建一个新的rtentry结构，该结构是查询结果的克隆。ARP将针对多播地址利用这一机制。

4. 克隆失败

83-87 如果rtrequest返回一个差错，newrt就被重新设置成rn_match所返回的表项，并增加它的引用计数。然后程序跳转到miss处，产生一条RTM_MISS消息。

5. 检查是否需要外部转换

88-91 如果rtrequest成功，并且新克隆的表项设有 RTF_XRESOLVE标志，则程序跳至miss处，但这次产生的 RTM_RESOLVE消息。该消息的目的是为了把路由创建的时间通知给用户进程，在IP地址到X.121地址的转换过程中会用到它。

6. 为正常成功查找递增引用计数

92-93 当查找成功但没有设置 RTF_CLONING标志时，该语句将递增路由表项的引用计数。这是本函数正常情况下的处理流程，之后程序返回一个非空的指针。

虽然是这样小的一段程序，但是在rtalloc1的处理过程中有很多选择。该函数有7个不同的流程，如图19-3所示。

	report 参数	RTF_- CLONING 标志	RTM_- RESOLVE 返回	RTF_- XRESOLVE 标志	产生的 路由消息	rt_refcnt	返回值
查找失败	0						空
	1				RTM_MISS		空
查找成功		0				++	ptr
	0					++	ptr
	1	1	OK	0		++	ptr
	1	1	OK	1	RTM_RESOLVE	++	ptr
	1	1	差错		RTM_MISS	++	ptr

图19-3 rtalloc1 处理过程小结

需要解释的是，如果存在默认路由，前两行(找不到路由表项的流程)是不可能出现的。还有，在第5、第6两行中的rt_refcnt也做了递增，因为这两行在调用rtrequest时使用了RTM_RESOLVE参数，递增在rtrequest中完成。

19.3 宏RTFREE和rtfree函数

宏RTFREE，如图19-4所示，仅在引用计数小于等于1时才调用rtfree函数；否则，它仅完成引用计数的递减。

209-213 rtfree函数如图19-5所示。当不存在对rtentry结构的引用时，函数就释放该结构。例如，在图22-7中，当释放一个协议控制块时，如果它指向一个路由表项，则需要调用rtfree。

105-115 首先递减路由表项的引用计数，如果它小于等于0并且该路由不可用，则该表项可以被释放。如果该表项设有RNF_ACTIVE或RNF_ROOT标志，那么这是一个内部差错。因为，如果设有RNF_ACTIVE，那么该结构仍是路由表的一部分；如果设有RNF_ROOT，那么它是一个由rn_inithead创建的标有end的结构。

```

209 #define RTFREE(rt) \
210     if ((rt)->rt_refcnt <= 1) \
211         rtfree(rt); \
212     else \
213         (rt)->rt_refcnt--; /* no need for function call */

```

图19-4 宏RTFREE

```

105 void
106 rtfree(rt)
107 struct rtentry *rt;
108 {
109     struct ifaddr *ifa;
110
111     if (rt == 0)
112         panic("rtfree");
113     rt->rt_refcnt--;
114     if (rt->rt_refcnt <= 0 && (rt->rt_flags & RTF_UP) == 0) {
115         if (rt->rt_nodes->rn_flags & (RNF_ACTIVE | RNF_ROOT))
116             panic("rtfree 2");
117         rttrash--;
118         if (rt->rt_refcnt < 0) {
119             printf("rtfree: %x not freed (neg refs)\n", rt);
120             return;
121         }
122         ifa = rt->rt_ifa;
123         IFAFREE(ifa);
124         Free(rt_key(rt));
125     }
126 }

```

图19-5 rtfree 函数：释放一个rtentry 结构

116 rttrash是一个用于调试的计数器，记录那些不在选路树中但仍未释放的路由表项的数目。当rtrequest开始删除路由时，它被递增，然后在这儿递减。正常情况下，它的值应该是0。

1. 释放接口引用

117-122 先查看引用计数。确认引用计数非负后，IFAFREE将递减ifaddr结构的引用计数。当计数值递减为零时，调用ifafree释放它。

2. 释放选路存储器

123-124 释放由路由表项关键字及其网关所占的存储器。我们会看到rt_setgate把它们分配在存储器的同一个连着的块中。因此，只调用一个Free就可以同时把它们释放。最后还要释放rtentry结构。

路由表引用计数

路由表引用计数(rt_refcnt)的处理与其他许多引用计数的处理不同。我们看到，在图18-2中，大多数路由的引用计数为0，而这些没有引用的路由表项并没有被删除。原因就在rtfree中：只有当RTF_UP标志被删除时，引用计数为0的表项才会被删除。而仅当从选路树中删除路由时，该标志才会被rtrequest删除。

大多数路由是按如下方式使用的。

- 如果到某接口的路由是在配置该接口时自动创建的（典型的，例如以太网接口的配置），则 `rtinit` 用命令参数 `RTM_ADD` 来调用 `rtrequest`，以创建新的路由表项，并设置它的引用计数为 1。然后，`rtinit` 在退出前把该引用计数递减成 0。

对于点到点接口的处理过程也是类似的，所以路由的引用计数也是从 0 开始。

如果路由是由 `route` 命令手工创建的，或者是由选路守护进程创建的，处理过程同样是类似的。`route_output` 用命令参数 `RTM_ADD` 来调用 `rtrequest`，并设置新路由的引用计数为 1。在退出前，`route_output` 把该引用计数递减到 0。

因此，所有新创建的路由都是从引用计数 0 开始的。

- 当 TCP 或 UDP 在插口上发送 IP 数据包时，`ip_output` 调用 `rtalloc`，`rtalloc` 再调用 `rtalloc1`。如图 19-3 所示，如果找到了路由，`rtalloc1` 就会递增其引用计数。

所查找到的路由称为被持路由（held route），因为协议持有指向路由表项的指针，该指针通常被包含在协议控制块中的 `route` 结构里。一个被其他协议持有的 `rtentry` 结构是不能被删除的。所以，在 `rtfree` 中，当引用计数为 0 时，`rtentry` 结构才能被删除。

- 协议通过调用 `RTFREE` 或 `rtfree` 来释放被持路由。在图 8-24 中，当 `ip_output` 检测到目的地址改变时，我们已经使用了这种处理。在第 22 章中，释放持有路由的协议控制块时，我们还会遇到这种处理。

在后面的代码中可能会引起混淆的是，`rtalloc1` 经常被调用以判断路由是否存在，而调用者并非试图持有该路由。因为 `rtalloc1` 递增了该路由的引用计数器，所以调用者就立即递减该计数器。

考虑一个被 `rtrequest` 删除的路由。它的 `RTF_UP` 标志被清除，并且，如果没有被持有（它的引用计数为 0），就要调用 `rtfree`。但 `rtfree` 认为引用计数小于 0 是错的，所以 `rtrequest` 查看它的引用计数，如果小于等于 0，就递增该计数值并调用 `rtfree`。通常，这将使引用计数变成 1，之后，`rtfree` 把引用计数递减到 0，并删除该路由。

19.4 `rtrequest` 函数

`rtrequest` 函数是添加和删除路由表项的关键点。图 19-6 给出了调用它的一些其他函数。

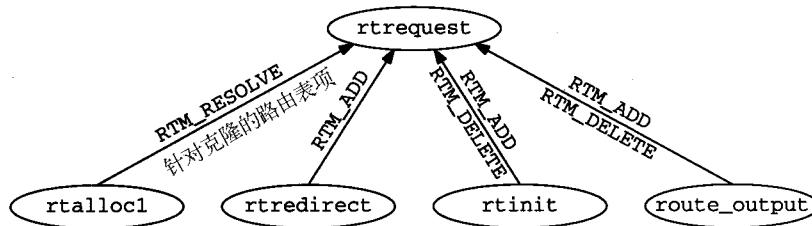


图 19-6 调用 `rtrequest` 的函数

`rtrequest` 是一个 `switch` 语句，每个 `case` 对应一个命令：`RTM_ADD`、`RTM_DELETE` 和 `RTM_RESOLVE`。图 19-7 给出了该函数的开头一段以及 `RTM_DELETE` 命令的处理。

290-307 第二个参数，`dst`，是一个插口地址结构，它指定在路由表中添加或删除的表项。

表项中的 `sa_family` 用于选择路由表。如果 `flags` 参数指出该路由是主机路由（而不是到某个网络的路由），则设置 `netmask` 指针为空，忽略调用者设置的任何值。

```

290 int
291 rtrequest(req, dst, gateway, netmask, flags, ret_nrt)
292 int      req, flags;
293 struct sockaddr *dst, *gateway, *netmask;
294 struct rtentry **ret_nrt;
295 {
296     int      s = splnet();
297     int      error = 0;
298     struct rtentry *rt;
299     struct radix_node *rn;
300     struct radix_node_head *rnh;
301     struct ifaddr *ifa;
302     struct sockaddr *ndst;
303 #define senderr(x) { error = x ; goto bad; }

304     if ((rnh = rt_tables[dst->sa_family]) == 0)
305         senderr(ESRCH);
306     if (flags & RTF_HOST)
307         netmask = 0;
308     switch (req) {
309     case RTM_DELETE:
310         if ((rn = rnh->rnh_deladdr(dst, netmask, rnh)) == 0)
311             senderr(ESRCH);
312         if (rn->rn_flags & (RNF_ACTIVE | RNF_ROOT))
313             panic("rtrequest delete");
314         rt = (struct rtentry *) rn;
315         rt->rt_flags &= ~RTF_UP;
316         if (rt->rt_gwroute) {
317             rt = rt->rt_gwroute;
318             RTFREE(rt);
319             (rt = (struct rtentry *) rn)->rt_gwroute = 0;
320         }
321         if ((ifa = rt->rt_ifa) && ifa->if_a_rtrequest)
322             ifa->if_a_rtrequest(RTM_DELETE, rt, SA(0));
323         rttrash++;
324         if (ret_nrt)
325             *ret_nrt = rt;
326         else if (rt->rt_refcnt <= 0) {
327             rt->rt_refcnt++;
328             rtfree(rt);
329         }
330     break;

```

route.c

图19-7 `rtrequest` 函数：`RTM_DELETE` 命令

1. 从选路树中删除路由

309-315 `rnh_deladdr` 函数（图18-17中的 `rn_delete`）从选路树中删除表项，返回相应 `rtentry` 结构的指针，并清除 `RTF_UP` 标志。

2. 删除对网关路由表项的引用

316-320 如果该表项是一个经过某网关的非直接路由，则 `RTFREE` 递减该网关路由表项的引用计数。如它的引用计数被减为 0，则删除它。设置 `rt_gwroute` 指针为空，并将 `rt` 设置成原来要删除的表项。

3. 调用接口请求函数

321-322 如果该表项定义了 `ifa_rtrequest` 函数，就调用该函数。ARP会使用该函数，例如，在第21章中用它来删除对应的ARP表项。

4. 返回指针或删除引用

323-330 因为该表项在接着的代码里不一定被删除，所以递增全局变量 `rttrash`。如果调用者需要选路树中被删除的 `rtentry` 结构的指针(即如果 `ret_nrt` 非空)，则返回该指针，但此时不能释放该表项：调用者必须在使用完该表项后调用 `rtfree` 来删除它。如果 `ret_nrt` 为空，则该表项被释放：如果它的引用计数小于等于 0，则递增该计数值，并调用 `rtfree`。`break` 语句将使函数退出。

图19-8给出了函数的下一部分，用于处理 `RTM_RESOLVE` 命令。只有 `rtalloc1` 能够携带此命令参数调用本函数。也只有在从一个设有 `RTF_CLONING` 标志的表项中克隆一个新的表项时，`rtalloc1` 才这样用。

```
route.c
331     case RTM_RESOLVE:
332         if (ret_nrt == 0 || (rt = *ret_nrt) == 0)
333             senderr(EINVAL);
334         ifa = rt->rt_ifa;
335         flags = rt->rt_flags & ~RTF_CLONING;
336         gateway = rt->rt_gateway;
337         if ((netmask = rt->rt_genmask) == 0)
338             flags |= RTF_HOST;
339         goto makeroute;
```

```
route.c
```

图19-8 `rtrequest` 函数：`RTM_RESOLVE` 命令

331-339 最后一个参数，`ret_nrt`，在这个命令里的用途不同：它是一个设有 `RTF_CLONING` 标志的路由表项的指针(图19-2)。新的表项具有相同的 `rt_ifa` 指针、相同的 `rt_gateway` 和相同的标志(`RTF_CLONING` 标志被清除)。如果被克隆表项的 `rt_genmask` 指针为空，则新表项是一个主机路由，因此要设置它的 `RTF_HOST` 标志；否则新表项为网络路由，其网络掩码通过复制 `rt_genmask` 得到。在本节的结尾部分，我们给出了克隆带网络掩码的路由的一个例子。这个 `case` 将跳转至下个图中的 `makeroute` 标记处继续进行。

图19-9给出了 `RTM_ADD` 命令的代码。

5. 定位相应的接口

340-342 函数 `ifa_ifwithroute` 为目的(`dst`)查找适当的本地接口，并返回指向该接口的 `ifaddr` 结构的指针。

6. 为路由表项分配存储器

343-348 分配了一个 `rtentry` 结构。在前一章中我们知道，该结构包含了两个选路树的 `radix_node` 结构及其他路由信息。该结构被清零，之后，其标志 `rt_flags` 被设置成调用本函数的 `flags` 参数，同时再设置 `RTF_UP` 标志。

7. 分配并复制网关地址

349-352 `rt_gateway` 函数(图19-11)为路由表(`dst`)及其 `gateway` 分配了存储器，然后将 `gateway` 复制到新分配的存储器中，并设置指针 `rt_key`、`rt_gateway` 和 `rt_gwroute`。

8. 复制目的地址

```

340     case RTM_ADD:
341         if ((ifa = ifa_ifwithroute(flags, dst, gateway)) == 0)
342             senderr(ENETUNREACH);
343
344         makeroute:
345             R_Malloc(rt, struct rtentry *, sizeof(*rt));
346             if (rt == 0)
347                 senderr(ENOBUFS);
348             Bzero(rt, sizeof(*rt));
349             rt->rt_flags = RTF_UP | flags;
350             if (rt_setgate(rt, dst, gateway)) {
351                 Free(rt);
352                 senderr(ENOBUFS);
353             }
354             ndst = rt_key(rt);
355             if (netmask) {
356                 rt_maskedcopy(dst, ndst, netmask);
357             } else
358                 Bcopy(dst, ndst, dst->sa_len);
359
360             rn = rnh->rnh_addaddr((caddr_t)ndst, (caddr_t)netmask,
361                                     rnh, rt->rt_nodes);
362             if (rn == 0) {
363                 if (rt->rt_gwroute)
364                     rtfree(rt->rt_gwroute);
365                 Free(rt_key(rt));
366                 Free(rt);
367                 senderr(EEXIST);
368             }
369             ifa->ifc_refcnt++;
370             rt->rt_ifa = ifa;
371             rt->rt_ifp = ifa->ifc_ifp;
372             if (req == RTM_RESOLVE)
373                 rt->rt_rmx = (*ret_nrt)->rt_rmx; /* copy metrics */
374             if (ifa->ifc_rtrequest)
375                 ifa->ifc_rtrequest(req, rt, SA(ret_nrt ? *ret_nrt : 0));
376             if (ret_nrt) {
377                 *ret_nrt = rt;
378                 rt->rt_refcnt++;
379             }
380             break;
381     bad:
382         splx(s);
383         return (error);
384 }

```

route.c

图19-9 rtrequest 函数：RTM_ADD 命令

353-357 把目的地址(路由表表项dst)复制到rn_key所指向的存储器中。如果提供了网络掩码，则rt_maskedcopy对dst和netmask进行逻辑与运算，得到新的表项。否则，dst就会被复制成新的表项。对dst和netmask进行逻辑与运算是为了确保表中的表项已经和它的掩码进行了与运算。这样，查找表项与表中的表项进行比较时，只需要另外对查找表项和掩码进行逻辑与运算就可以了。例如，下面的这个命令向以太网接口 le0添加了另一个IP地址(一个别名)，其子网为12而不是13。

```
bsdi $ ifconfig le0 inet 140.252.12.63 netmask 0xfffffffffe0 alias
```

该例子中存在的一个问题，我们所指定的全1的主机号是错误的。不过，该表项存入路由表后，我们用netstat验证可知该地址已经和掩码进行过逻辑与运算。

Destination	Gateway	Flags	Refs	Use	Interface
140.252.12.32	link#1	U C	0	0	le0

9. 往选路树中添加表项

358-366 rnh_addaddr函数(图18-17中的rn_addroute)向选路树中添加这个rtentry结构，其中附带了它的目的地址和掩码。如果有差错产生，则释放该结构，并返回EXEXIST(即，该表项已经存在于路由表中了)。

10. 保存接口指针

367-369 递增ifaddr结构的引用计数，并保存ifaddr和ifnet结构的指针。

11. 为新克隆的路由复制度量

370-371 如果命令是RTM_RESOLVE(不是RTM_ADD)，则把被克隆的表项中的整个度量结构复制到新的表项里。如果命令是RTM_ADD，则调用者可在函数返回后设置该度量值。

12. 调用接口请求函数

372-373 如果为该表项定义了ifa_rtrequest函数，则调用该函数。对于RTM_ADD和RTM_RESOLVE命令，ARP都要用该函数来完成一些额外的处理。

13. 返回指针并递增引用计数

374-378 如果调用者需要该新结构的指针，则通过ret_nrt返回该指针，并将引用计数值从0递增到1。

例：克隆的带网络掩码的路由

仅当rtrequest的RTM_RESOLVE命令创建克隆路由时，才使用rt_genmask的值。如果rt_genmask指针非空，则它指向的插口地址结构就成了新创建路由的网络掩码。在我们的路由表中，即图18-2，克隆的路由是针对本地以太网和多播地址的。下面的例子引自[Sklower 1991]，它提供了克隆路由的不同用法。另外一个例子见习题19.2。

考虑一个B类网络，如128.1，它在点到点链路之外。子网掩码是0xffffffff00，其中含8比特的子网号和8比特的主机号。我们要为所有可能的254个子网提供路由表项，这些表项的网关是与本机直接相连的路由器，该路由器知道如何到达与128.1网络相连的链路。

假设该网关不是我们的默认路由器，则最简单的方法就是创建单个表项，该表项以128.1.0.0为目的、以0xfffff0000为掩码。可是，假设128.1网络的拓扑使所有可能的254个子网中的每一个都有不同的运营特性：RTTs、MTUs和时延等。那么如果每个子网都有单独的路由表项，我们就能够看到，无论何时连接断开后，TCP都会刷新该路由表项的统计值，如路由的RTT、RTT变量等(图27-3)。尽管我们可以用route命令手工地为254个子网中的每一个子网都添加路由表项，但更好的方法是采用克隆机制。

由系统管理员先创建一个以128.1.0.0为目的地，以0xfffff0000为网络掩码的表项。再设置其RTF_CLONING标志，并设置genmask为0xffffffff00(与网络掩码不同)。这时，如果在路由表中查找128.1.2.3，而路由表中没有子网128.1.2的表项，那么具有掩码0xfffff0000的网络128.1的表项为最佳匹配。因为该表项设有RTF_CLONING标志，所以要创建一个新的表项，新表项以128.1.2为目的地，以0xffffffff00(genmask的值)为网络掩码。

这样，下一次引用该子网内的主机时，如 128.1.2.88，最佳匹配就是新创建的表项。

19.5 rt_setgate 函数

选路树中的每个叶子都有一个表项 (`rt_key`，也就是在 `rtentry` 结构开头的 `radix_node` 结构的 `rn_key` 成员) 和一个相关联的网关 (`rt_gateway`)。在创建路由表项时，它们都被指定为插口地址结构。`rt_setgate` 为这两个结构分配存储器，如图 19-10 所示。

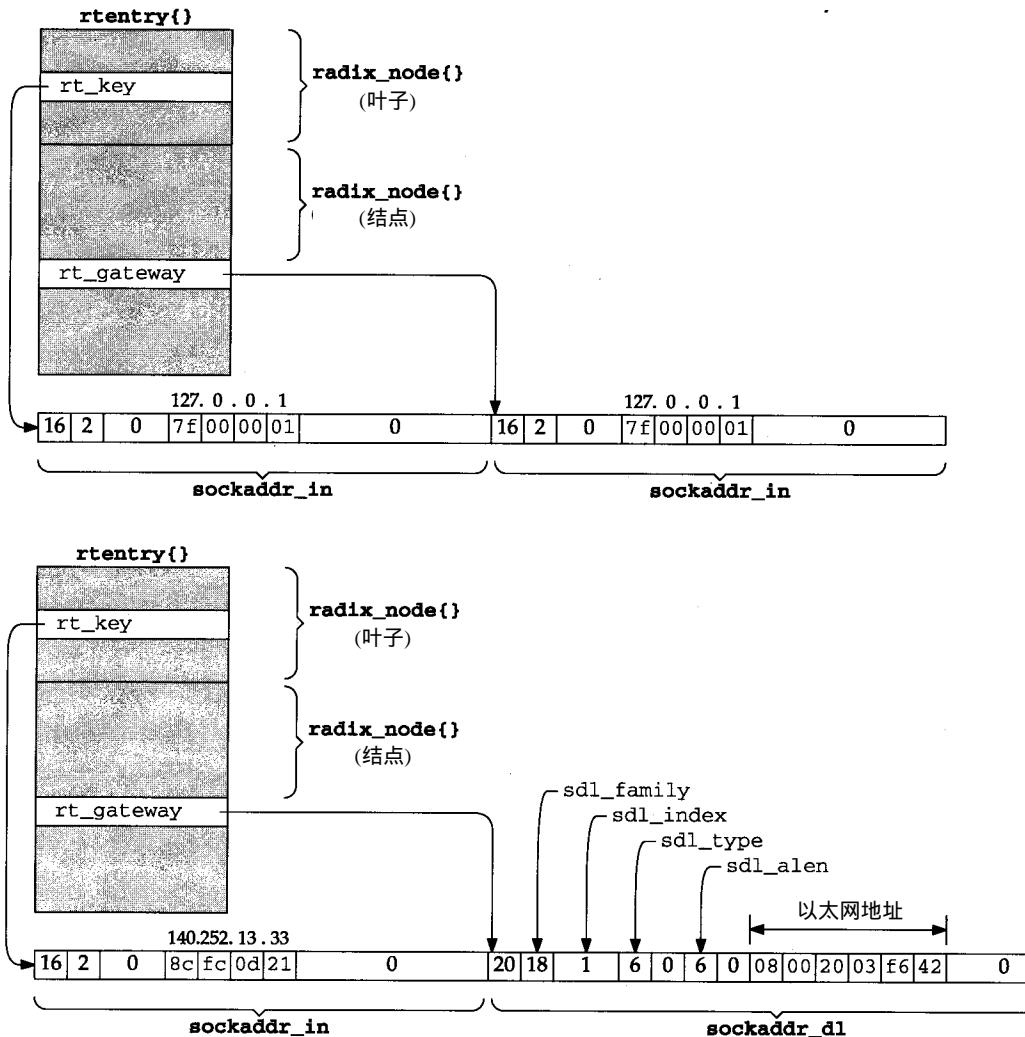


图19-10 路由表表项和相关网关示例

这个例子给出了图 18-2 中的两个表项，它们的表项分别是 127.0.0.1 和 140.252.13.33。前一个的网关成员指向一个 Internet 插口地址结构，后一个的网关成员指向一个含以太网地址的数据链路插口地址。前一个是在系统初始化时，由 `route` 系统将其添加到路由表中的；后一个是由 ARP 创建的。

在图 19-11 中，我们有意识地把两个由 `rt_key` 指向的结构紧挨着画在一起，因为它们是由 `rt_setgate` 一起分配的。

route.c

```

384 int
385 rt_setgate(rt0, dst, gate)
386 struct rtentry *rt0;
387 struct sockaddr *dst, *gate;
388 {
389     caddr_t new, old;
390     int      dlen = ROUNDUP(dst->sa_len), glen = ROUNDUP(gate->sa_len);
391     struct rtentry *rt = rt0;
392
393     if (rt->rt_gateway == 0 || glen > ROUNDUP(rt->rt_gateway->sa_len)) {
394         old = (caddr_t) rt_key(rt);
395         R_Malloc(new, caddr_t, dlen + glen);
396         if (new == 0)
397             return 1;
398         rt->rt_nodes->rn_key = new;
399     } else {
400         new = rt->rt_nodes->rn_key;
401         old = 0;
402     }
403     Bcopy(gate, (rt->rt_gateway = (struct sockaddr *) (new + dlen)), glen);
404     if (old) {
405         Bcopy(dst, new, dlen);
406         Free(old);
407     }
408     if (rt->rt_gwroute) {
409         rt = rt->rt_gwroute;
410         RTFREE(rt);
411         rt = rt0;
412         rt->rt_gwroute = 0;
413     }
414     if (rt->rt_flags & RTF_GATEWAY) {
415         rt->rt_gwroute = rtalloc1(gate, 1);
416     }
417 }

```

route.c

图19-11 rt_setgate 函数

1. 依据插口地址结构设置长度

384-391 dlen是目的插口地址结构的长度，glen是网关插口地址结构的长度。ROUNDUP宏把数值上舍入成4的倍数个字节，但大多数插口地址结构的长度本身就是4的倍数。

2. 分配存储器

392-401 如果还没有给该路由表表项和网关分配存储器，或glen大于当前rt_gateway所指向的结构的长度，则分配一片新的存储器，并使rn_key指向新分配的存储器。

3. 使用分配给表项和网关的存储器

398-401 由于已经给表项和网关分配了一片足够大小的存储器，因此，直接将new指向这个已经存在的存储器。

4. 复制新网关

402 复制新的网关结构，并且设置rt_gateway，使其指向插口地址结构。

5. 从原有的存储器中将表项复制到新存储器中

403-406 如果分配了新的存储器，则在网关字段被复制前，先复制路由表表项dst，并释放原有的存储器片。

6. 释放网关路由指针

407-412 如果该路由表项含有非空的 rt_gwroute指针，则用RTFREE释放该指针所指向的结构，并设置rt_gwroute为空。

7. 查找并保存新的网关路由指针

413-415 如果路由表项是一个非直接路由，则 rtalloc1查找新网关的路由表项，并将它保存在rt_gwroute中。如果非直接路由指定的网关无效，则 rt_setgate并不返回任何差错，但rt_gwroute会是一个空指针。

19.6 rtinit函数

Internet协议添加或删除相关接口的路由时，对 rtinit的调用有四个。

- 在设置点到点接口的目的地址时， in_control调用rtinit两次。第一次调用指定 RTM_DELETE命令，以删除所有现存的到该目的地址的路由(图6-21)；第二次调用指定 RTM_ADD命令，以添加新路由。
- in_ifinit调用rtinit为广播网络添加一条网络路由或为点到点链路(图6-19)添加一条主机路由。如果是给以太网接口添加的路由，则in_ifinit自动设置其RTF_CLONING标志。
- in_ifscrub调用rtinit，以删除一个接口现存的路由。

图19-12给出了rtinit函数的第一部分。cmd参数只能是RTM_ADD或RTM_DELETE。

```
route.c
441 int
442 rtinit(ifa, cmd, flags)
443 struct ifaddr *ifa;
444 int cmd, flags;
445 {
446     struct rtentry *rt;
447     struct sockaddr *dst;
448     struct sockaddr *deldst;
449     struct mbuf *m = 0;
450     struct rtentry *nrt = 0;
451     int error;
452
453     dst = flags & RTF_HOST ? ifa->ifa_dstaddr : ifa->ifa_addr;
454     if (cmd == RTM_DELETE) {
455         if ((flags & RTF_HOST) == 0 && ifa->ifa_netmask) {
456             m = m_get(M_WAIT, MT_SONAME);
457             deldst = mtod(m, struct sockaddr *);
458             rt_maskedcopy(dst, deldst, ifa->ifa_netmask);
459             dst = deldst;
460         }
461         if (rt = rtalloc1(dst, 0)) {
462             rt->rt_refcnt--;
463             if (rt->rt_ifa != ifa) {
464                 if (m)
465                     (void) m_free(m);
466                 return (flags & RTF_HOST ? EHOSTUNREACH
467                               : ENETUNREACH);
468             }
469         }
470         error = rtrequest(cmd, dst, ifa->ifa_addr, ifa->ifa_netmask,
471                           flags | ifa->ifa_flags, &nrt);
472         if (m)
473             (void) m_free(m);
```

route.c

图19-12 rt_init 函数：调用 rtrequest 处理命令

1. 为路由获取目的地址

452 如果是一个到达某主机的路由，则目的地址是点到点链路的另一端。否则，我们处理的就是一个网络路由，其目的地址是接口的单播地址（经ifa_netmask掩码过的）。

2. 用网络掩码给网络地址掩码

453-459 如果要删除路由，则必须在路由表中查找该目的地址，并得到它的路由表项。如果要删除的是一个网络路由且接口拥有相关联的网络掩码，则分配一个 mbuf，用rt_maskedcopy对目的地址和调用参数中的掩码地址进行逻辑与运算，并将结果复制到mbuf中。令dst指向mbuf中掩码过的复制值，它就是下一步要查找的目的地址。

3. 查找路由表项

460-469 rtalloc1在路由表中查找目的地址，如果能找到，则先递减该表项的引用计数（因为rtalloc1递增了该引用计数）。如果路由表中该接口的 ifaddr指针不等于调用者的参数，则返回一个差错。

4. 处理请求

470-473 rt_request执行RTM_ADD或RTM_DELETE命令。当rt_request返回时，如果之前分配了mbuf，则释放它。

图19-13给出了rtinit的后半部分。

```

474     if (cmd == RTM_DELETE && error == 0 && (rt = nrt)) {
475         rt_newaddrmsg(cmd, ifa, error, nrt);
476         if (rt->rt_refcnt <= 0) {
477             rt->rt_refcnt++;
478             rtfree(rt);
479         }
480     }
481     if (cmd == RTM_ADD && error == 0 && (rt = nrt)) {
482         rt->rt_refcnt--;
483         if (rt->rt_ifa != ifa) {
484             printf("rtinit: wrong ifa (%x) was (%x)\n", ifa,
485                   rt->rt_ifa);
486             if (rt->rt_ifa->if_a_rtrequest)
487                 rt->rt_ifa->if_a_rtrequest(RTM_DELETE, rt, SA(0));
488             IFAFREE(rt->rt_ifa);
489             rt->rt_ifa = ifa;
490             rt->rt_ifp = ifa->if_a_ifp;
491             ifa->if_a_refcnt++;
492             if (ifa->if_a_rtrequest)
493                 ifa->if_a_rtrequest(RTM_ADD, rt, SA(0));
494         }
495         rt_newaddrmsg(cmd, ifa, error, nrt);
496     }
497     return (error);
498 }
```

route.c

图19-13 rtint 函数：后半部分

5. 删除成功时产生一个选路消息

474-480 如果删除了一个路由，并且rtrequest返回0和被删除的rtentry结构的指针(nrt中)，就用rt_newaddrmsg产生一个选路插口消息。如果引用计数小于等于0，则递增该引用计数，并用rtfree释放该路由。

6. 成功添加

481-482 如果添加了一个路由，并且 `rtrequest` 返回了0和被添加的 `rtentry` 结构的指针 (`nrt`)，就递减其引用计数(因为 `rtrequest` 递增了该引用计数)。

7. 不正确的接口

483-494 如果新路由表项中接口的 `ifaaddr` 指针不等于调用参数，则表明有差错产生。利用 `rtrequest`，通过调用 `ifa_ifwithroute` 来测定新路由中的 `ifa` 指针(`rtrequest` 函数如图19-9所示)。产生这个差错后，做如下步骤：向控制台输出一条出错消息；如果定义了 `ifa_rtrequest` 函数，就以 `RTM_DELETE` 为参数调用它；释放 `ifaaddr` 结构；设置 `rt_ifa` 指针为调用者指定的值；递增接口的引用计数；如果定义了 `ifa_rtrequest` 函数，就以 `RTM_ADD` 为参数调用它。

8. 产生选路消息

495 用 `rt_newaddrmsg` 为 `RTM_ADD` 命令产生一个选路插口消息。

19.7 `rtredirect` 函数

当收到一个ICMP重定向后，`icmp_input` 调用 `rtredirect` 及 `pfctlinput`(图11-27)。后一个函数又调用 `udp_ctlinput` 和 `tcp_ctlinput`，这两个函数遍历所有的 UDP 和 TCP 协议控制块(PCB)。如果 PCB 连接到一个外部地址，而到该外部地址的方向已经被改变，并且该 PCB 持有到那个外部地址的路由，则调用 `rtfree` 释放该路由。下一次使用这些控制块发送到该外部地址的 IP 数据报时，就会调用 `rtalloc`，并在路由表中查找该目的地址，很可能会找到一条新(改变过方向的)路由。

`rtredirect` 函数的作用是验证重定向中的信息，并立即更新路由表，产生选路插口消息。图19-14给出了 `rtredirect` 函数的前半部分。

147-157 函数的参数包括：`dst`，导致重定向的数据报的目的 IP 地址(图8-18中的 HD)；`gateway`，路由器的 IP 地址，用作该目的的新网关字段(图8-18中的 R2)；`netmask`，空指针；`flags`，设置了 `RTF_GATEWAY` 标志和 `RTF_HOST` 标志；`src`，发送重定向的路由器的 IP 地址(图8-18中的 R1)；`rtp`，空指针。需要指出的是，`icmp_input` 调用本函数时，参数 `netmask` 和 `rtp` 是空指针，但是其他协议调用本函数时，这两个参数未必为空指针。

1. 新路由必须直接相连

158-162 新的网关必须是直接相连的，否则该重定向无效。

2. 查找目的地址的路由表项并验证重定向

163-177 调用 `rtalloc1` 在路由表中查找到目的地址的路由。验证重定向时，下列条件必须为真，否则该重定向无效，并且函数返回一个差错。要注意的一点是，`icmp_input` 会忽略从 `rtredirect` 返回的任何差错。ICMP 也会忽略它，即不会为一个无效的重定向而产生一个差错信息。

- 必须未设置 `RTF_DONE` 标志；
- `rtalloc` 必须已找到一个到 `dst` 的路由表项；
- 发送重定向的路由器的地址(`src`)必须等于当前为目的地址设置的 `rt_gateway`；
- 新网关的接口(由 `ifa_ifwithnet` 返回的 `ifa` 结构)必须等于当前为目的地址设置的接口(`rt_ifa`)，也就是说，新网关必须和当前网关在同一个网络上；并且

- 新网关不能把到这个主机的路由改变为到它自己，也就是说，不能存在与 gateway 相等的带有单播地址或广播地址的连接着的接口。

route.c

```

147 int
148 rtredirect(dst, gateway, netmask, flags, src, rtp)
149 struct sockaddr *dst, *gateway, *netmask, *src;
150 int      flags;
151 struct rteentry **rtp;
152 {
153     struct rteentry *rt;
154     int      error = 0;
155     short   *stat = 0;
156     struct rt_addrinfo info;
157     struct ifaddr *ifa;

158     /* verify the gateway is directly reachable */
159     if ((ifa = ifa_ifwithnet(gateway)) == 0) {
160         error = ENETUNREACH;
161         goto out;
162     }
163     rt = rtalloc1(dst, 0);
164     /*
165      * If the redirect isn't from our current router for this dst,
166      * it's either old or wrong. If it redirects us to ourselves,
167      * we have a routing loop, perhaps as a result of an interface
168      * going down recently.
169      */
170 #define equal(a1, a2) (bcmpl((caddr_t)(a1), (caddr_t)(a2), (a1)->sa_len) == 0)
171     if (!(flags & RTF_DONE) && rt &&
172         (!equal(src, rt->rt_gateway) || rt->rt_ifa != ifa))
173         error = EINVAL;
174     else if (ifa_ifwithaddr(gateway))
175         error = EHOSTUNREACH;
176     if (error)
177         goto done;
178     /*
179      * Create a new entry if we just got back a wildcard entry
180      * or if the lookup failed. This is necessary for hosts
181      * which use routing redirects generated by smart gateways
182      * to dynamically build the routing tables.
183      */
184     if ((rt == 0) || (rt->rt_mask(rt) && rt->rt_mask(rt)->sa_len < 2))
185         goto create;

```

route.c

图19-14 rtredirect 函数：验证收到的重定向

3. 必须创建一个新路由

178-185 如果到达目的地址的路由没有找到，或找到的路由表项是默认路由，则为该目的地址创建一个新的路由。如程序注释所述，对于可访问多个路由器的主机来说，当默认路由器出错时，它可以利用这种机制来获悉正确的路由器。判断是否为默认路由的测试方法是查看该路由表项是否具有相关的掩码以及掩码的长度字段是否小于 2，因为默认路由的掩码是 rn_zeros(图18-35)。

图19-15给出了rtredirect函数的后半部分。

4. 创建新的主机路由

186-195 如果到达目的地址的当前路由是一个网络路由，并且重定向是主机重定向而不是

网络重定向，那么就为该目的地址建立一个主机路由，而不必去管现存的网络路由。我们要提示的是，flags参数总是指明RTF_GATEWAY标志，因为Net/3 ICMP把所有收到的重定向都看成主机重定向。

```

186     /*
187      * Don't listen to the redirect if it's
188      * for a route to an interface.
189     */
190    if (rt->rt_flags & RTF_GATEWAY) {
191        if (((rt->rt_flags & RTF_HOST) == 0) && (flags & RTF_HOST)) {
192            /*
193             * Changing from route to net => route to host.
194             * Create new route, rather than smashing route to net.
195             */
196            create:
197                flags |= RTF_GATEWAY | RTF_DYNAMIC;
198                error = rtrequest((int) RTM_ADD, dst, gateway,
199                                netmask, flags,
200                                (struct rtentry **) 0);
201                stat = &rtstat.rts_dynamic;
202            } else {
203                /*
204                 * Smash the current notion of the gateway to
205                 * this destination. Should check about netmask!!!
206                 */
207                rt->rt_flags |= RTF_MODIFIED;
208                flags |= RTF_MODIFIED;
209                stat = &rtstat.rts_newgateway;
210                rt_setgate(rt, rt_key(rt), gateway);
211            }
212        } else
213            error = EHOSTUNREACH;
214    done:
215        if (rt) {
216            if (rtp && !error)
217                *rtp = rt;
218            else
219                rtfree(rt);
220        }
221    out:
222        if (error)
223            rtstat.rts_badredirect++;
224        else if (stat != NULL)
225            (*stat)++;
226        bzero((caddr_t) & info, sizeof(info));
227        info.rti_info[RTAX_DST] = dst;
228        info.rti_info[RTAX_GATEWAY] = gateway;
229        info.rti_info[RTAX_NETMASK] = netmask;
230        info.rti_info[RTAX_AUTHOR] = src;
231        rt_missmsg(RTM_REDIRECT, &info, flags, error);
232    }

```

route.c

图19-15 rtrequest 函数：后半部分

5. 创建路由

196-201 rtrequest创建一个新路由，并将标志RTF_GATEWAY和RTF_DYNAMIC置位。参数netmask是一个空指针，这是因为新路由是一个主机路由，它的掩码是隐含的全1比特。

`stat`指向一个计数器，它在后面的程序里递增。

6. 改变现存的主机路由

202-211 当到达目的地址的当前路由已经是一个主机路由时，才执行这段代码。此时，不需要创建新的表项，但需要修改现存的表项：设置 `RTF_MODIFIED` 标志，并调用 `rt_setgate` 来修改路由表项的 `rt_gateway` 字段，使其指向新的网关地址。

7. 如果目的地址直接相连，则忽略

212-213 如果到达目的地址的当前路由是一个直接路由（没有设置 `RTF_GATEWAY` 标志），那么该重定向针对的是一个已直接连接的目的地址。此时，函数返回 `EHOSTUNREACH`。

8. 返回指针并递增统计值

214-225 如果找到了路由表项，那么该表项被返回（如果 `rtp` 非空且没有出错）或者用 `rtfree` 释放它。相关的统计值被递增。

9. 产生选路消息

226-232 `rt_addrinfo` 结构清零，并由 `rt_missmsg` 产生一个选路插口消息。`raw_input` 把该消息发送到所有对重定向感兴趣的进程。

19.8 选路消息的结构

选路消息由一个定长的首部和至多 8 个插口地址结构组成。该定长首部是下列三种结构中的一个：

- `rt_msghdr`
- `if_msghdr`
- `ifa_msghdr`

图18-11给出了产生不同消息的函数的概观图，图 18-9 给出了每种消息类型所使用的结构。选路消息三种首部结构的前三个成员的数据类型及其含义是相同的，分别为：消息的长度、版本和类型。这样，消息接受者就可以对消息进行解码了。而且，每种结构都各有一个成员来编码首部之后 8 个可能的插口地址结构：`rtm_addrs`、`ifm_addrs` 和 `ifam_addrs` 成员，它们都是一个比特掩码。

图19-16给出了最常用的结构，即 `rt_msghdr`。`RTM_IFINFO` 消息使用了图 19-17 中的 `if_msghdr` 结构。`RTM_NEWWADDR` 和 `RTM_DELADDR` 消息使用图 19-18 中的 `ifa_msghdr` 结构。

```

139 struct rt_msghdr {
140     u_short rtm_msrlen;           /* to skip over non-understood messages */
141     u_char  rtm_version;         /* future binary compatibility */
142     u_char  rtm_type;            /* message type */
143     u_short rtm_index;           /* index for associated ifp */
144     int     rtm_flags;            /* flags, incl. kern & message, e.g. DONE */
145     int     rtm_addrs;             /* bitmask identifying sockaddrs in msg */
146     pid_t   rtm_pid;              /* identify sender */
147     int     rtm_seq;               /* for sender to identify action */
148     int     rtm_errno;              /* why failed */
149     int     rtm_use;                /* from rtentry */
150     u_long  rtm_inits;             /* which metrics we are initializing */
151     struct rt_metrics rtm_rmx;    /* metrics themselves */
152 };

```

route.h

图19-16 `rt_msghdr` 结构

```

235 struct if_msghdr {
236     u_short ifm_msrlen;           /* to skip over non-understood messages */
237     u_char ifm_version;          /* future binary compatibility */
238     u_char ifm_type;             /* message type */

239     int ifm_addrs;               /* like rtm_addrs */
240     int ifm_flags;                /* value of if_flags */
241     u_short ifm_index;           /* index for associated ifp */
242     struct if_data ifm_data;      /* statistics and other data about if */
243 };

```

图19-17 if_msghdr 结构

```

248 struct ifa_msghdr {
249     u_short ifam_msrlen;           /* to skip over non-understood messages */
250     u_char ifam_version;          /* future binary compatibility */
251     u_char ifam_type;             /* message type */

252     int ifam_addrs;               /* like rtm_addrs */
253     int ifam_flags;                /* value of ifa_flags */
254     u_short ifam_index;           /* index for associated ifp */
255     int ifam_metric;              /* value of ifa_metric */
256 };

```

图19-18 ifa_msghdr 结构

注意，这三种不同结构的前三个成员具有相同的数据结构和含义。

三个变量 rtm_addrs、ifm_addrs 和 ifam_addrs 都是比特掩码，它们定义了首部之后的插口地址结构。图 19-19 给出了比特掩码用到的一些常量。

比特掩码		数组索引		rtsock.c 中的名字	描述
常量	值	常量	值		
RTA_DST	0x01	RTAX_DST	0	dst	目的插口地址结构
RTA_GATEWAY	0x02	RTAX_GATEWAY	1	gate	网关插口地址结构
RTA_NETMASK	0x04	RTAX_NETMASK	2	netmask	网络掩码插口地址结构
RTA_GENMASK	0x08	RTAX_GENMASK	3	genmask	克隆掩码插口地址结构
RTA_IFP	0x10	RTAX_IFP	4	ifpaddr	接口名称插口地址结构
RTA_IFA	0x20	RTAX_IFA	5	ifaaddr	接口地址插口地址结构
RTA_AUTHOR	0x40	RTAX_AUTHOR	6		重定向产生者的插口地址结构
RTA_BRD	0x80	RTAX_BRD	7	brdaddr	广播或点到点的目的地址
		RTAX_MAX	8		rti_info[] 数组的元素个数

图19-19 用来引用 rti_info 数组成员的常量

比特掩码的值可以用常数 1 左移数组下标指定的位数而得到。例如，0x20(RTA_IFA) 是 1 左移五位(RTAX_IFA)。我们会在代码中看到这个过程。

插口地址结构总是按照数组下标递增的次序，一个接一个地出现的。例如，如果掩码是 0x87，则第一个插口地址结构的内容为目的地址，接着是网关地址，网络掩码，最后是广播地址。

内核用图 19-19 中的数组下标来引用 rt_addrinfo 结构，如图 19-20 所示。该结构具有与我们所述相同的比特掩码，以表示哪些地址存在。它的另一个成员指向那些插口地址结构。

```

199 struct rt_addrinfo {
200     int     rti_addrs;           /* bitmask, same as rtm_addrs */
201     struct sockaddr *rti_info[RTAX_MAX];
202 };

```

*route.h*图19-20 *rt_addrinfo* 结构：表示哪些地址存在的掩码和指向这些地址的指针

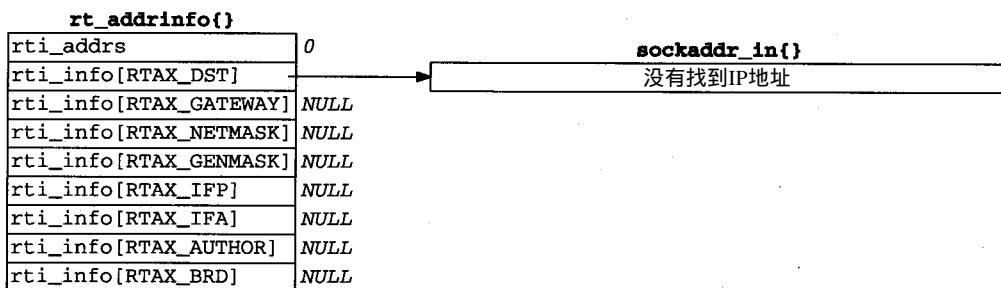
例如，如果 *rti_addrs* 成员中设置了 *RTA_GATEWAY* 比特，则 *rti_info[RTA_GATEWAY]* 成员就是含网关地址的插口地址结构的指针。对于 Internet 协议，该插口地址结构就是含网关的 IP 地址的 *sockaddr_in* 结构。

图19-19中的第五栏给出了文件 *rtsock.c* 中 *rti_info* 数组成员相应的名称。它们的定义形式如下：

```
#define dst info.rti_info[RTAX_DST]
```

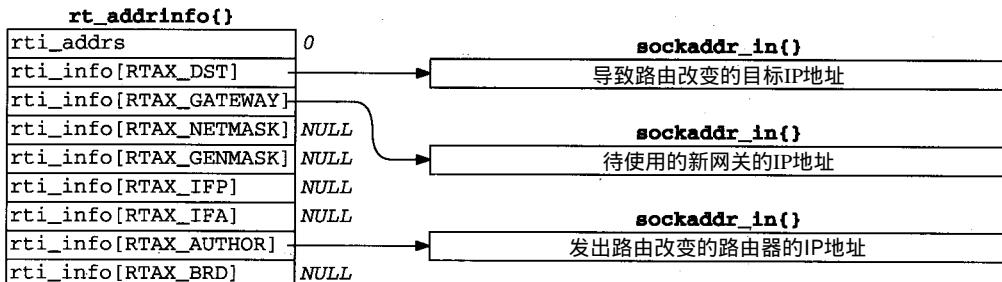
在本章的很多源文件中我们都将遇到这些名称。元素 *RTAX_AUTHOR* 没有命名，因为进程不会向内核传递该元素。

我们已经有两次遇到过 *rt_addrinfo* 结构：在函数 *rtalloc1*(图19-2)和 *rtredirect* 中(图19-14)。图19-21给出了 *rtalloc1* 在路由表查找失败后调用 *rt_missmsg* 时创建的该结构的格式。

图19-21 *rtalloc1* 传递给 *rt_missmsg* 的 *rt_addrinfo* 结构

所有未使用的指针都是空指针，因为该结构在使用前被设置成 0。还要指出的是，*rti_addrs* 成员没有被初始化成相应的比特掩码，因为在内核使用该结构时，*rti_info* 数组中的指针为空就代表不存在该插口地址结构。仅在进程和内核之间传递的消息里该掩码才是必不可少的。

图19-22给出了 *rtredirect* 调用 *rt_missmsg* 时创建的该结构的格式。

图19-22 *rtredirect* 传递给 *rt_missmsg* 的 *rt_addrinfo* 结构

下一节中将介绍该结构是如何被放置在发送到其他进程的消息里的。

图19-23给出了route_cb结构，我们会在下一节中遇到。该结构由四个计数器组成，前三个分别针对IP、XNS和OSI协议，最后一个为“任意”计数器。每个计数器分别记录相应的域中当前存在的选路插口的数目。

203-208 内核跟踪选路插口监听器的数目。这样，当不存在等待消息的进程时，内核就可以避免创建选路消息以及调用raw_input发送该消息。

```
203 struct route_cb {
204     int      ip_count;          /* IP */
205     int      ns_count;          /* XNS */
206     int      iso_count;         /* ISO */
207     int      any_count;         /* sum of above three counters */
208 };
```

route.h

图19-23 route_cb 结构：选路插口监听器的计数器

19.9 rt_missmsg函数

如图19-24所示，rt_missmsg函数使用了图19-21和图19-22中的结构，并调用rt_msg1在mbuf链中为进程创建了相应的变长消息，之后调用raw_input将该mbuf链传递给所有相关的选路插口。

```
516 void
517 rt_missmsg(type, rtinfo, flags, error)
518 int   type, flags, error;
519 struct rt_addrinfo *rtinfo;
520 {
521     struct rt_msghdr *rtm;
522     struct mbuf *m;
523     struct sockaddr *sa = rtinfo->rti_info[RTAX_DST];
524     if (route_cb.any_count == 0)
525         return;
526     m = rt_msg1(type, rtinfo);
527     if (m == 0)
528         return;
529     rtm = mtod(m, struct rt_msghdr *);
530     rtm->rtm_flags = RTF_DONE | flags;
531     rtm->rtm_errno = error;
532     rtm->rtm_addrs = rtinfo->rti_addrs;
533     route_proto.sp_protocol = sa ? sa->sa_family : 0;
534     raw_input(m, &route_proto, &route_src, &route_dst);
535 }
```

rtsock.c

图19-24 rt_missmsg 函数

516-525 如果没有任何选路插口监听器，则函数立即退出。

1. 在mbuf链中创建消息

526-528 rt_msg1(19.12节)在mbuf链中创建相应的消息，并返回该链的指针。利用图19-22中的rt_addrinfo结构，图19-25给出了所得到的mbuf链的一个例子。这些信息之所以要放在一个mbuf链中，是因为raw_input要调用sbappendaddr把该mbuf链添加到插口接收

缓存的尾部。

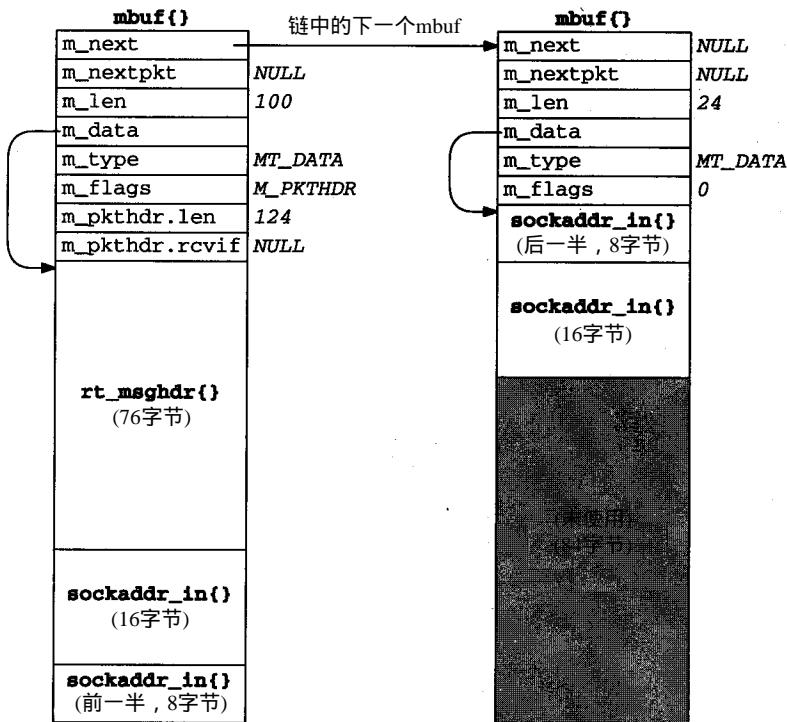


图19-25 由rt_msghdr创建的对应于图19-22的mbuf链

2. 完成消息的创建

529-532 成员`rtm_flags`和`rtm_errno`被设置成调用者传递的值。成员`rtm_addrs`的值是由`rti_addrs`复制而得到的。在图19-21和图19-22中，我们给出的`rti_addrs`值为0，因此，`rt_msghdr`依据`rti_info`数组中的指针是否为空，来计算并保存相应的比特掩码。

3. 设置消息的协议，调用raw_input

533-534 `raw_input`的后三个参数指定了选路消息的协议、源和目的。这三个结构被初始化成：

```
struct sockaddr route_dst = { 2, PF_ROUTE, };
struct sockaddr route_src = { 2, PF_ROUTE, };
struct sockproto route_proto = { PF_ROUTE };
```

内核不会修改前两个结构。第三个结构`sockproto`，我们第一次遇到。图19-26给出了它的定义。

```
128 struct sockproto {
129     u_short sp_family;           /* address family */
130     u_short sp_protocol;        /* protocol */
131 };
```

图19-26 sockproto 结构

该结构的协议族成员一直保持了它的初始值`PF_ROUTE`，但其协议成员的值在每一次调

用raw_input时都要进行设置。当进程调用socket创建选路插口时，第三个参数定义了该进程所感兴趣的协议。raw_input的调用者再把route_proto结构的sp_protocol成员设置成选路消息的协议。在rt_missmsg这种情况下，该成员被设置成目的插口地址结构的sa_family(如果调用者指定了该值)，在图19-21和图19-22中，其值为AF_INET。

19.10 rt_ifmsg函数

在图4-30中我们可以看出，if_up和if_down都调用了图19-27中的rt_ifmsg。在接口连接或断开时，该函数被用来产生一个选路插口消息。

```
540 void
541 rt_ifmsg(ifp)
542 struct ifnet *ifp;
543 {
544     struct if_msghdr *ifm;
545     struct mbuf *m;
546     struct rt_addrinfo info;
547
548     if (route_cb.any_count == 0)
549         return;
550
551     bzero((caddr_t) &info, sizeof(info));
552     m = rt_msghl(RTM_IFINFO, &info);
553     if (m == 0)
554         return;
555
556     ifm = mtod(m, struct if_msghdr *);
557     ifm->ifm_index = ifp->if_index;
558     ifm->ifm_flags = ifp->if_flags;
559     ifm->ifm_data = ifp->if_data; /* structure assignment */
560     ifm->ifm_addrs = 0;
561
562     route_proto.sp_protocol = 0;
563     raw_input(m, &route_proto, &route_src, &route_dst);
564 }
```

rtsock.c

图19-27 rt_ifmsg 函数

547-548 如果没有选路插口监听器，函数立即退出。

1. 在mbuf链中创建消息

549-552 rt_addrinfo结构被设置成0。rt_msghl在一个mbuf链中创建相应的消息。需要注意的是，rt_addrinfo结构中的所有指针都为空，选路消息仅由定长的if_msghdr结构组成，而不含任何地址。

2. 完成消息的创建

553-557 把接口的索引、标志和if_data结构复制到mbuf中的报文里。把ifm_addrs比特掩码设置成0。

3. 设置消息的协议，调用raw_input

558-559 因为该消息可应用于所有的协议，所以其协议被设置成0。并且该消息是关于某接口的，而不是针对特定的目的地。raw_input把该消息传递给相应的监听器。

19.11 rt_newaddrmsg函数

从图19-13中可以看到，在接口上添加或从中删除一个地址时，rtinit要以RTM_ADD或RTM_DELETE为参数调用rt_newaddrmsg。图19-28给出了rt_newaddrmsg函数的前半部分。

```

569 void
570 rt_newaddrmsg(cmd, ifa, error, rt)
571 int cmd, error;
572 struct ifaddr *ifa;
573 struct rtentry *rt;
574 {
575     struct rt_addrinfo info;
576     struct sockaddr *sa;
577     int pass;
578     struct mbuf *m;
579     struct ifnet *ifp = ifa->ifa_ifp;

580     if (route_cb.any_count == 0)
581         return;

582     for (pass = 1; pass < 3; pass++) {
583         bzero((caddr_t) & info, sizeof(info));
584         if ((cmd == RTM_ADD && pass == 1) ||
585             (cmd == RTM_DELETE && pass == 2)) {
586             struct ifa_msghdr *ifam;
587             int ncmsg = cmd == RTM_ADD ? RTM_NEWADDR : RTM_DELADDR;

588             ifaaddr = sa = ifa->ifa_addr;
589             ifpaddr = ifp->if_addrlist->ifa_addr;
590             netmask = ifa->ifa_netmask;
591             brdaddr = ifa->ifa_dstaddr;
592             if ((m = rt_msgh1(ncmsg, &info)) == NULL)
593                 continue;
594             ifam = mtod(m, struct ifa_msghdr *);
595             ifam->ifam_index = ifp->if_index;
596             ifam->ifam_metric = ifa->ifa_metric;
597             ifam->ifam_flags = ifa->ifa_flags;
598             ifam->ifam_addrs = info.rti_addrs;
599         }
    }

```

rtsock.c

图19-28 rt_newaddrmsg 函数的前半部分：创建 ifa_msghdr

580-581 如果没有选路插口监听器，函数立即退出。

1. 产生两个选路消息

582 本函数要产生两个选路报文，一个用于提供有关接口的信息，另一个提供有关地址的信息。因此，for循环执行两次，每次产生一个消息。如果命令是RTM_ADD，则第一个消息的类型是RTM_NEWADDR，第二个消息的类型是RTM_ADD；如果命令是RTM_DELETE，则第一个消息的类型是RTM_DELETE，第二个消息的类型是RTM_DELADDR。RTM_NEWADDR和RTM_DELADDR消息的首部为ifa_msghdr结构，而RTM_ADD和RTM_DELETE消息的首部为rt_msghdr结构。

583 rt_addrinfo结构被设置为0。

2. 产生至多含四个地址的消息

588-591 这四个插口地址结构包含的是有关被添加或删除的接口地址的信息，它们的指针存储于`rti_info`数组中。其中`ifaaddr`、`ifpaddr`、`netmask`和`brdaddr`引用的是名为`info`的`rti_info`数组中的成员，如图19-19所示。`rt_msg1`在mbuf链中创建了相应的消息。注意，`sa`也设置成指向`ifa_addr`结构的指针，我们将在函数的尾部看到选路消息的协议被设置成该插口地址结构的族。

把`ifa_msghdr`结构的其他成员设置成接口的索引、度量和标志。其比特掩码由`rt_msg1`设置。

图19-29给出了`rt_newaddrmsg`的后半部分。该部分用于创建`rt_msghdr`消息，该消息中包含了有关被添加或删除的路由表项的信息。

3. 创建消息

600-609 `rt_mask`、`rt_key`和`rt_gateway`这三个地址结构的指针存放在`rti_info`数组中。`sa`被设置成目的地址的指针，它的族将成为选路消息的协议。`rt_msg1`在mbuf链中创建相应的消息。

设置其余的`rt_msghdr`结构成员。其中，比特掩码由`rt_msg1`设置。

4. 设置消息的协议，调用`raw_input`

616-619 设置消息的协议，并由`raw_input`把消息发送给相应的监听器。函数在完成了两次循环后返回。

```

600     if ((cmd == RTM_ADD && pass == 2) ||
601         (cmd == RTM_DELETE && pass == 1)) {
602         struct rt_msghdr *rtm;
603
604         if (rt == 0)
605             continue;
606         netmask = rt_mask(rt);
607         dst = sa = rt_key(rt);
608         gate = rt->rt_gateway;
609         if ((m = rt_msg1(cmd, &info)) == NULL)
610             continue;
611         rtm = mtod(m, struct rt_msghdr *);
612         rtm->rtm_index = ifp->if_index;
613         rtm->rtm_flags |= rt->rt_flags;
614         rtm->rtm_errno = error;
615         rtm->rtm_addrs = info.rti_addrs;
616         route_proto.sp_protocol = sa ? sa->sa_family : 0;
617         raw_input(m, &route_proto, &route_src, &route_dst);
618     }
619 }
```

rtsock.c

图19-29 `rt_newaddrmsg` 函数的后半部分：创建`rt_msghdr` 消息

19.12 `rt_msg1`函数

前三节的函数都调用`rt_msg1`函数来创建一个相应的选路消息。图 19-25还给出了一个mbuf链，该链是由`rt_msg1`按照图19-22中的`rt_msghdr`和`rt_addrinfo`结构创建的。图19-30给出了本函数的代码。

rtsock.c

```

399 static struct mbuf *
400 rt_msg1(type, rtinfo)
401 int      type;
402 struct rt_addrinfo *rtinfo;
403 {
404     struct rt_msghdr *rtm;
405     struct mbuf *m;
406     int      i;
407     struct sockaddr *sa;
408     int      len, dlen;

409     m = m_gethdr(M_DONTWAIT, MT_DATA);
410     if (m == 0)
411         return (m);
412     switch (type) {

413     case RTM_DELADDR:
414     case RTM_NEWADDR:
415         len = sizeof(struct ifa_msghdr);
416         break;

417     case RTM_IFINFO:
418         len = sizeof(struct if_msghdr);
419         break;

420     default:
421         len = sizeof(struct rt_msghdr);
422     }
423     if (len > MHLEN)
424         panic("rt_msg1");
425     m->m_pkthdr.len = m->m_len = len;
426     m->m_pkthdr.rcvif = 0;
427     rtm = mtod(m, struct rt_msghdr *);
428     bzero((caddr_t) rtm, len);

429     for (i = 0; i < RTAX_MAX; i++) {
430         if ((sa = rtinfo->rti_info[i]) == NULL)
431             continue;
432         rtinfo->rti_addrs |= (1 << i);
433         dlen = ROUNDUP(sa->sa_len);
434         m_copyback(m, len, dlen, (caddr_t) sa);
435         len += dlen;
436     }
437     if (m->m_pkthdr.len != len) {
438         m_free(m);
439         return (NULL);
440     }
441     rtm->rtm_msflen = len;
442     rtm->rtm_version = RTM_VERSION;
443     rtm->rtm_type = type;
444     return (m);
445 }

```

rtsock.c

图19-30 rt_msg1 函数：获取并初始化mbuf

1. 得到mbuf并确定消息首部的长度

399-422 获得一个含分组首部的 mbuf，并将分组消息定长部分的长度存入 len 中。图18-9 中各种类型的消息里，有两个使用 ifa_msghdr 结构，有一个使用 if_msghdr 结构，其余的九个使用 rt_msghdr 结构。

2. 验证结构是否适合 mbuf

423-424 定长结构的大小必须完全适合分组首部 mbuf的数据部分，因为该 mbuf指针将被 mtood转换成一个结构指针，之后通过指针来引用该结构。三个结构中最大的为 if_msghdr，其长度为84，小于MHLLEN(100)。

3. 初始化mbuf分组首部并使结构清零

425-428 初始化分组首部的两个字段，并将 mbuf中的结构设置成0。

4. 将插口地址结构复制到 mbuf链中

429-436 调用者传递了一个 rt_addrinfo结构的指针。与 rti_info中所有非空指针相对应的插口地址结构都被 m_copyback复制到 mbuf里。将数值1左移下标RTX_xxx对应的位数就可以得到相应的 RTA_xxx比特掩码(图19-19)。将每个比特掩码用逻辑或添加到 rti_addrs成员中去，调用者在函数返回时可将它保存为相应的报文结构成员。 ROUNDUP宏将每个插口地址结构的大小上舍入成下一个4的倍数个字节。

437-440 在循环结束时，如果 mbuf分组首部的长度不等于 len，则表明函数m_copyback没能获得所需的 mbuf。

5. 保存长度、版本和类型

441-445 把长度、版本和报文类型保存到报文结构的前三个成员中。再次说明一下，因为所有的三种 xxx_msghdr结构都以相同的成员开始，所以尽管代码中的指针 rtm是一个 rt_msghdr结构的指针，但它可以处理所有这三种情况。

19.13 rt_msg2函数

rt_msg1在mbuf链中创建一个选路消息，调用它的三个函数接着又调用 raw_input，从而把mbuf结构附加到一个或多个插口的接收缓存中去。与 rt_msg1不同，rt_msg2在存储器缓存中创建选路消息，而不是在 mbuf链中创建。并且 rt_msg2有一个walkarg结构的参数，在选路域中处理 sysctl系统调用时，有两个函数使用该参数调用了 rt_msg2。以下是两种调用 rt_msg2的情况：

1) route_output调用它处理RTM_GET命令

2) sysctl_dumpentry和sysctl_iflist调用它处理 sysctl系统调用。

在给出rt_msg2的代码之前，图19-31给出了在第2种情况下使用的walkarg结构的定义。我们在遇到它的各成员时再一一介绍。

```

41 struct walkarg {
42     int      w_op;          /* NET_RT_XXX */
43     int      w_arg;         /* RTF_XXX for FLAGS, if_index for IFLIST */
44     int      w_given;       /* size of process' buffer */
45     int      w_needed;      /* #bytes actually needed (at end) */
46     int      w_tmemsizze;   /* size of buffer pointed to by w_tmem */
47     caddr_t  w_where;       /* ptr to process' buffer (maybe null) */
48     caddr_t  w_tmem;        /* ptr to our malloc'ed buffer */
49 };

```

图19-31 walkarg 结构：选路域内 sysctl 系统调用中使用

图19-32给出了rt_msg2函数的前半部分，它与 rt_msg1的前半部分类似。

```

446 static int
447 rt_msg2(type, rtinfo, cp, w)
448 int type;
449 struct rt_addrinfo *rtinfo;
450 caddr_t cp;
451 struct walkarg *w;
452 {
453     int i;
454     int len, dlen, second_time = 0;
455     caddr_t cp0;
456     rtinfo->rti_addrs = 0;
457 again:
458     switch (type) {
459     case RTM_DELADDR:
460     case RTM_NEWADDR:
461         len = sizeof(struct ifa_msghdr);
462         break;
463     case RTM_IFINFO:
464         len = sizeof(struct if_msghdr);
465         break;
466     default:
467         len = sizeof(struct rt_msghdr);
468     }
469     if (cp0 == cp)
470         cp += len;
471     for (i = 0; i < RTAX_MAX; i++) {
472         struct sockaddr *sa;
473         if ((sa = rtinfo->rti_info[i]) == 0)
474             continue;
475         rtinfo->rti_addrs |= (1 << i);
476         dlen = ROUNDUP(sa->sa_len);
477         if (cp) {
478             bcopy((caddr_t) sa, cp, (unsigned) dlen);
479             cp += dlen;
480         }
481         len += dlen;
482     }

```

*rtsock.c*图19-32 *rt_msg2* 函数：复制插口地址结构

446-455 本函数将选路消息保存在一个存储器缓存中，调用者用 *cp*参数指定该缓存的起始位置。调用者必须保证缓存足够长，以容纳所产生的选路消息。当 *cp*参数为空时，*rt_msg2*不保存任何结果而是处理输入参数，并返回保存结果所需要的字节总数。这样可以帮助调用者确定缓存的大小。我们可以看到 *route_output*就利用了这一机制，它调用本函数两次：第一次确定缓存的大小；在获得了大小无误的缓存后，再次调用本函数以保存结果。

*route_output*调用本函数时，最后一个参数为空，但如果是作为 *sysctl*系统调用处理的一部分被调用时，该参数就不是空指针了。

1. 确定结构的大小

458-470 定长消息结构的大小是根据消息类型来确定的。如果 *cp*指针非空，则把大小等于定长消息结构长度的偏移量添加到 *cp*指针上去。

2. 复制插口地址结构

471-482 for循环查看rti_info数组的每个元素。遇到非空指针时，设置rti_addrs比特掩码中的相应比特，并将该接口地址结构复制到cp中(如果cp指针非空)，并修改长度变量。

图19-33给出了rt_msg2函数的后半部分。其代码用于处理可选参数walkarg结构。

```

483     if (cp == 0 && w != NULL && !second_time) {
484         struct walkarg *rw = w;
485
486         rw->w_needed += len;
487         if (rw->w_needed <= 0 && rw->w_where) {
488             if (rw->w_tmemsize < len) {
489                 if (rw->w_tmem)
490                     free(rw->w_tmem, M_RTABLE);
491                 if (rw->w_tmem = (caddr_t)
492                     malloc(len, M_RTABLE, M_NOWAIT))
493                     rw->w_tmemsize = len;
494             }
495             if (rw->w_tmem) {
496                 cp = rw->w_tmem;
497                 second_time = 1;
498                 goto again;
499             } else
500                 rw->w_where = 0;
501         }
502         if (cp) {
503             struct rt_msghdr *rtm = (struct rt_msghdr *) cp0;
504             rtm->rtm_version = RTM_VERSION;
505             rtm->rtm_type = type;
506             rtm->rtm_msflen = len;
507         }
508         return (len);
509     }

```

rtsock.c

图19-33 rt_msg2 函数：处理可选参数walkarg

483-484 当调用者传递了一个非空的walkarg结构指针且函数第一次执行到这里时，该if语句的判断条件才为真。变量second_time被初始化成0，它将在本if语句中被设置成1，然后程序往回跳转到图19-32中的标号again处。cp为空指针的测试是不必要的，因为当w指针非空时，cp指针一定是空，反之亦然。

3. 检查是否要保存数据

485-486 w_needed将增大，其增量为报文长度的值。该变量的初始值为0减去sysctl函数中用户缓存的长度。例如，如果该缓存为500比特，则w_needed的初始值为-500。只要该变量为负值，则表明缓存内还有剩余空间。在调用进程中，w_where是指向该缓存的指针。w_where为空表明调用进程不想要函数的处理结果，而仅想获得sysctl处理结果的大小。因此，当w_where为空时，rt_msg2没有必要将数据复制给进程，也就是返回给调用者。同样，rt_msg2也没有必要为保存结构而申请缓存，也不需要返回到标号again处再次执行，因为再次执行是为了把结果填入到缓存里。本函数的处理实际上只有五种情况，如图19-34所示。

4. 第一次调用时或消息长度增加时分配缓存

487-493 w_tmemsize是w_tmem所指向的缓存的长度。它被sysctl_rtable初始化成0。

因此，对于给定的sysctl请求，在第一次调用rt_msg2时，必须为它分配一个缓存。同样，当产生的结果的长度增加时，必须释放原有的缓存，并重新分配一个更大的缓存。

调用者	cp	w	w.w_where	second_time	描述
route_output	空	空			希望返回长度
	非空	空			希望返回结果
sysctl_rtable	空	非空	空	0	进程希望返回长度
	空	非空	非空	0	第一次执行，计算长度
	非空	非空	非空	1	第二次执行，保存结果

图19-34 rt_msg2 函数的五种执行情况

5. 返回再执行一次并保存结果

494-499 如果w_tmemszie非空，则表明该缓存已经存在或刚被分配。设置cp指向该缓存，把second_time设置成1，跳转至标号again处。因为second_time的值为1，所以第二次执行到本图的第一个语句时，if语句的判断不再为真。如果w_tmem为空，则表明调用malloc失败，因此，把进程中的缓存指针设置成空指针以阻止返回任何结果。

6. 保存长度、版本和类型

502-509 如果cp非空，则保存消息首部的前三个成员。函数返回报文的长度。

19.14 sysctl_rtable函数

本函数处理选路插口的sysctl系统调用。如图18-11所示，net_sysctl函数调用了该函数。

在解释其源代码之前，图19-35给出了该系统调用关于路由表的一种典型的用法。这个例子来自于arp程序。

```

int      mib[6];
size_t   needed;
char     *buf, *lim, *next;
struct rt_msghdr *rtm;

mib[0] = CTL_NET;
mib[1] = PF_ROUTE;
mib[2] = 0;
mib[3] = AF_INET;           /* address family; can be 0 */
mib[4] = NET_RT_FLAGS;      /* operation */
mib[5] = RTF_LLINFO;        /* flags; can be 0 */

if (sysctl(mib, 6, NULL, &needed, NULL, 0) < 0)
    quit("sysctl error, estimate");

if ((buf = malloc(needed)) == NULL)
    quit("malloc");

if (sysctl(mib, 6, buf, &needed, NULL, 0) < 0)
    quit("sysctl error, retrieval");

lim = buf + needed;
for (next = buf; next < lim; next += rtm->rtm_msflen) {
    rtm = (struct rt_msghdr *)next;
    ... /* do whatever */
}

```

图 19-35

mib数组的前三个元素引导内核调用 `sysctl_rtable`，以处理其余的元素。

`mib[4]`用于指定操作的类型，共支持3种操作类型。

1) `NET_RT_DUMP`：返回`mib[3]`指定的地址族所对应的路由表。如果地址族为0，则返回所有的路由表。

针对每一个路由表项，程序都将返回一个`RTM_GET`选路消息。每个消息可能包含两个、三个或四个插口地址结构。这些地址结构由指针`rt_key`、`rt_gateway`、`rt_netmask`和`rt_genmask`所指向。其中最后两个指针可能为空。

2) `NET_RT_FLAGS`：与前一个命令相同，但`mib[5]`指定了一个`RTF_xxx`标志(图18-25)，程序仅返回那些设置了该标志的表项。

3) `NET_RT_IFLIST`：返回所有已配置接口的信息。如果`mib[5]`的值不是零，则程序仅返回`if_index`为相应值的接口。否则，返回所有`ifnet`链表上的接口。

针对每个接口，将返回一个`RTM_IFINFO`消息，该消息传递了有关接口本身的一些信息。之后用一个`RTM_NEWWADDR`消息传递接口的`if_addrlist`上的每个`ifaddr`结构。如果`mib[3]`的值为非0，则`RTM_NEWWADDR`消息仅返回那些地址族与`mib[3]`相匹配的地址。否则，`mib[3]`为0，将返回所有地址的信息。

这个操作是为了替代`SIOCGIFCONF ioctl`(图4-26)

与该系统调用有关的一个问题是，该系统返回信息的数量是可变的，这种变化取决于路由表项的数目和接口的数目。因此，第一次调用`sysctl`所指定的第三个参数通常是个空指针，也就是说，不需要返回任何选路信息，只要把该信息所占的比特数目返回即可。从图19-35中我们可以看出，进程第一次调用`sysctl`之后调用了`malloc`，接着再调用`sysctl`来获取信息。第二次调用时，通过第四个参数，`sysctl`又返回了该比特数目(该数目与上次相比可能会有变化)。通过该数目我们可以得到指针`lim`，它指向的位置位于返回的最后一个字节之后。进程接着就遍历缓存中的每个消息，利用`rtm_msflen`可找到下一个消息。

图19-36给出了不同的Net/3程序访问路由表和接口列表时指定的这六个mib变量的值。

mib[]	arp	route	netstat	routed	gated	rwhod
0	CTL_NET	CTL_NET	CTL_NET	CTL_NET	CTL_NET	CTL_NET
1	PF_ROUTE	PF_ROUTE	PF_ROUTE	PF_ROUTE	PF_ROUTE	PF_ROUTE
2	0	0	0	0	0	0
3	AF_INET	0	0	AF_INET	0	AF_INET
4	NET_RT_FLAGS	NET_RT_DUMP	NET_RT_DUMP	NET_RT_IFLIST	NET_RT_IFLIST	NET_RT_IFLIST
5	RTF_LLINFO	0	0	0	0	0

图19-36 调用`sysctl` 获取路由表和接口列表的程序举例

前三个程序从路由表中提取路由表项，后三个从接口列表中提取数据。`route`程序仅支持Internet选路协议，所以它指定`mib[3]`的值为`AF_INET`，而`gated`还支持其他协议，所以它对应的`mib[3]`的值为0。

图19-37画出了三个`sysctl_xxx`函数的结构，在后面的几节中会逐个予以阐述。

图19-38给出了`sysctl_rtable`函数。

1. 验证参数

705-719 当进程调用`sysctl`来设置一个路由表中不支持的变量时，使用`new`参数。因此该参数必须是一个空指针。

720-721 namelen必须是3，因为系统调用处理到这儿时，name数组中有三个元素：name[0]，地址族(进程中它被指定为mib[3])；name[1]，操作(mib[4])；以及name[2]，标志(mib[5])。

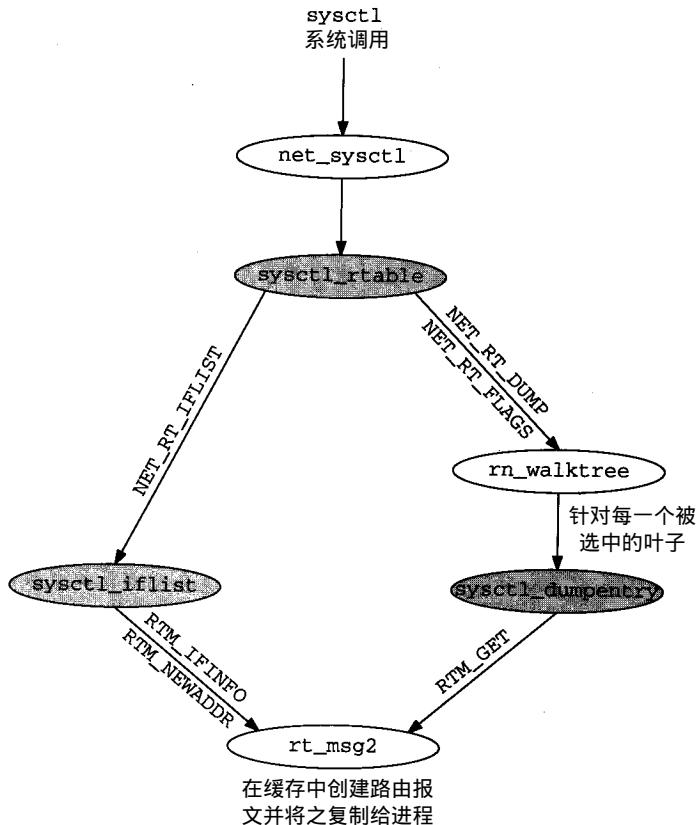


图19-37 支持对选路插口的sysctl 系统调用的函数

```

705 int
706 sysctl_rtable(name, namelen, where, given, new, newlen)           -rtsock.c-
707 int      *name;
708 int      namelen;
709 caddr_t  where;
710 size_t   *given;
711 caddr_t  *new;
712 size_t   newlen;
713 {
714     struct radix_node_head *rnh;
715     int      i, s, error = EINVAL;
716     u_char   af;
717     struct walkarg w;

718     if (new)
719         return (EPERM);
720     if (namelen != 3)
721         return (EINVAL);
722     af = name[0];
723     Bzero(&w, sizeof(w));
  
```

图19-38 sysctl_rtable 函数：处理sysctl 系统调用请求

```

724     w.w_where = where;
725     w.w_given = *given;
726     w.w_needed = 0 - w.w_given;
727     w.w_op = name[1];
728     w.w_arg = name[2];
729
730     s = splnet();
731     switch (w.w_op) {
732
733         case NET_RT_DUMP:
734         case NET_RT_FLAGS:
735             for (i = 1; i <= AF_MAX; i++)
736                 if ((rnhan = rt_tables[i]) && (af == 0 || af == i) &&
737                     (error = rnh->rnhan_walktree(rnh,
738                                         sysctl_dumpentry, &w)))
739                     break;
740             break;
741
742         case NET_RT_IFLIST:
743             error = sysctl_iflist(af, &w);
744         }
745         splx(s);
746         if (w.w_tmem)
747             free(w.w_tmem, M_RTABLE);
748         w.w_needed += w.w_given;
749         if (where) {
750             *given = w.w_where - where;
751             if (*given < w.w_needed)
752                 return (ENOMEM);
753         } else {
754             *given = (11 * w.w_needed) / 10;
755         }
756         return (error);
757     }

```

rtsock.c

图19-38 (续)

2. 初始化walkarg结构

723-728 把walkarg结构(图19-31)设置成0，并初始化下列成员：把w_where设置成调用进程中为结果准备的缓存地址；w_given是该缓存的比特数目(当w_where为空指针时，作为输入参数，该成员没有实际含义，但在输出时它必须被设置成将要返回的结果的长度)；w_needed被设置成缓存的大小的负数；w_op指明操作类型(值为NET_RT_xxx)；w_arg被设置成标志值。

3. 导出路由表

731-738 NET_RT_DUMP和NET_RT_FLAGS操作的处理是相同的：利用一个循环语句遍历所有的路由表(rt_table数组)，如果系统使用了该路由表，并且地址族调用参数为0或地址族调用参数与该路由表的族相匹配，则调用rnhan_walktree函数来处理整个路由表。图18-17所给出的rnhan_walktree函数是通常使用的rnhan_walktree函数。该函数的第二个参数的值是另一个函数的地址，这个函数(sysctl_dumpentry)将被调用以处理选路树的每一个叶子。rnhan_walktree的第三个参数是个任意类型的指针，该指针将传递给sysctl_dumpentry函数。在这里，它指向一个walkarg结构，该结构包含了有关sysctl调用的所有信息。

4. 返回接口列表

739-740 NET_RT_IFLIST 操作调用 sysctl_iflist 函数来处理所有的 ifnet 结构。

5. 释放缓存

743-744 如果由 rt_msg2 分配的缓存里含有选路消息，则释放该缓存。

6. 更新 w_needed

745 rt_msg2 函数把每个消息的长度都加入到 w_needed 中。而该变量被我们初始化成 w_given 的负数，所以它的值可以表示成：

```
w_needed = 0 - w_given + totalbytes
```

式中，totalbytes 表示由 rt_msg2 函数添加的所有消息的长度总和。通过往 w_needed 中加入 w_given 的值，我们就能得到所有消息的字节总数：

```
w_needed = 0 - w_given + totalbytes + w_given
          = totalbytes
```

因为等式中两个 w_given 的值最终相互抵消，所以当进程所指定的 w_where 是个空指针时，就没有必要初始化 w_given 的值。事实上，图 19-35 中的变量 needed 就没有被初始化。

7. 返回报文的实际长度

746-749 如果 where 指针非空，则通过 given 指针返回保存在缓存中的字节数。如果返回的数值小于进程指定的缓存的大小，则返回一个差错，因为返回信息被截短了。

8. 返回报文长度的估算值

750-752 当 where 指针为空时，进程只想获得要返回的字节总数。为了防止在两次 sysctl 调用之间相应的表被增大，我们将该字节总数扩大了 10%。10% 这个增量的确定没有特定的理由。

19.15 sysctl_dumpentry 函数

在前一节中我们阐述了被 sysctl_rtable 调用的 rn_walktree 是如何调用本函数的。图 19-39 给出了本函数的代码。

623-630 每次调用本函数时，第一个参数指向一个 radix_node 结构，同时它也是一个 rtentry 结构的指针，第二个参数指向一个由 sysctl_rtable 初始化了的 walkarg 结构。

1. 检测路由表项的标志

631-632 如果进程指定了标志值(mib[5])，则忽略那些 rt_flags 成员中没有设置该标志的表项。在图 19-36 中，我们可以看到 arp 程序使用这种方法来选择那些设有 RTF_LLINFO 标志的表项，因为 ARP 仅对这些表项感兴趣。

2. 构造选路消息

633-638 rti_info 数组中的下列四个指针是从路由表项中复制而得的： dst、gate、netmask 和 genmask。前两个总是非空的，但另外两个可以是空指针。调用 rt_msg2 是为了构造一个 RTM_GET 消息。

3. 复制消息回传给进程

639-651 如果进程需要返回一个报文，并且 rt_msg2 分配了一个缓存，则将选路报文中的其余部分填写到 w_tmem 所指向的缓存中去，并调用 copyout 复制消息回传给进程。如果复制成功，就增大 w_where，增加的数目等于所复制的字节的数目。

```

623 int
624 sysctl_dumpentry(rn, w)
625 struct radix_node *rn;
626 struct walkarg *w;
627 {
628     struct rtentry *rt = (struct rtentry *) rn;
629     int     error = 0, size;
630     struct rt_addrinfo info;

631     if (w->w_op == NET_RT_FLAGS && !(rt->rt_flags & w->w_arg))
632         return 0;
633     bzero((caddr_t) & info, sizeof(info));
634     dst = rt_key(rt);
635     gate = rt->rt_gateway;
636     netmask = rt->rt_mask(rt);
637     genmask = rt->rt_genmask;
638     size = rt_msg2(RTM_GET, &info, 0, w);
639     if (w->w_where && w->w_tmem) {
640         struct rt_msghdr *rtm = (struct rt_msghdr *) w->w_tmem;

641         rtm->rtm_flags = rt->rt_flags;
642         rtm->rtm_use = rt->rt_use;
643         rtm->rtm_rmx = rt->rt_rmx;
644         rtm->rtm_index = rt->rt_ifp->if_index;
645         rtm->rtm_errno = rtm->rtm_pid = rtm->rtm_seq = 0;
646         rtm->rtm_addrs = info.rti_addrs;
647         if (error = copyout((caddr_t) rtm, w->w_where, size))
648             w->w_where = NULL;
649         else
650             w->w_where += size;
651     }
652     return (error);
653 }

```

*rtsock.c*图19-39 `sysctl_dumpentry` 函数：处理一个路由表项

19.16 `sysctl_iflist`函数

图19-40给出了本函数的代码。本函数由 `sysctl_rtable`直接调用，用来把接口列表返回给进程。

本函数由一个 `for`循环组成，该循环从指针 `ifnet`开始，针对每个接口重复执行。接着用 `while` 循环处理每个接口的 `ifaaddr`结构链表。函数将针对每个接口产生一个 `RTM_IFINFO`选路消息，并且针对每个地址产生一个 `RTM_NEWWADDR`消息。

1. 检测接口索引

654-666 进程可以指定一个非零的标志参数（图19-36中的 `mib[5]`）。函数用接口的 `if_index`值与之比较，只有匹配时，才进行处理。

2. 创建选路消息

667-670 在`RTM_IFINFO`消息中只返回了唯一的一个插口地址结构，即 `ifpaddr`。该 `RTM_IFINFO`消息是由 `rt_msg2`创建的。`info`结构中的 `ifpaddr`指针被设置成0，因为该 `info`结构还要用来产生后面的 `RTM_NEWWADDR`消息。

3. 复制消息回传给进程

671-681 如果进程需要返回消息，则填入 `if_msghdr`结构的其余部分，用 `copyout`给进

程复制该缓存，并增大 w_where。

```

654 int
655 sysctl_iflist(af, w)
656 int      af;
657 struct walkarg *w;
658 {
659     struct ifnet *ifp;
660     struct ifaddr *ifa;
661     struct rt_addrinfo info;
662     int      len, error = 0;
663
664     bzero((caddr_t) & info, sizeof(info));
665     for (ifp = ifnet; ifp = ifp->if_next) {
666         if (w->w_arg && w->w_arg != ifp->if_index)
667             continue;
668         ifa = ifp->if_addrlist;
669         ifpaddr = ifa->ifa_addr;
670         len = rt_msg2(RTM_IFINFO, &info, (caddr_t) 0, w);
671         ifpaddr = 0;
672         if (w->w_where && w->w_tmem) {
673             struct if_msghdr *ifm;
674
675             ifm = (struct if_msghdr *) w->w_tmem;
676             ifm->ifm_index = ifp->if_index;
677             ifm->ifm_flags = ifp->if_flags;
678             ifm->ifm_data = ifp->if_data;
679             ifm->ifm_addrs = info.rti_addrs;
680             if (error = copyout((caddr_t) ifm, w->w_where, len))
681                 return (error);
682             w->w_where += len;
683         }
684         while (ifa = ifa->ifa_next) {
685             if (af && af != ifa->ifa_addr->sa_family)
686                 continue;
687             ifaaddr = ifa->ifa_addr;
688             netmask = ifa->ifa_netmask;
689             brdaddr = ifa->ifa_dstaddr;
690             len = rt_msg2(RTM_NEWADDR, &info, 0, w);
691             if (w->w_where && w->w_tmem) {
692                 struct ifa_msghdr *ifam;
693
694                 ifam = (struct ifa_msghdr *) w->w_tmem;
695                 ifam->ifam_index = ifa->ifa_ifp->if_index;
696                 ifam->ifam_flags = ifa->ifa_flags;
697                 ifam->ifam_metric = ifa->ifa_metric;
698                 ifam->ifam_addrs = info.rti_addrs;
699                 if (error = copyout(w->w_tmem, w->w_where, len))
700                     return (error);
701                 w->w_where += len;
702             }
703         }
704     }

```

rtsock.c

图19-40 sysctl_iflist 函数：返回接口列表及其地址

4. 循环处理每一个地址结构，检测其地址族

682-684 处理接口的每一个 ifaddr 结构。进程也可以指定一个非零地址族（图19-36中的

mib[3])来选择仅处理那些指定族的接口地址。

5. 创建选路消息

685-688 rt_msg2创建的每个 RTM_NEWWADDR 消息中最多可以返回三个插口地址结构：ifaddr、netmask 和 brdaddr。

6. 复制消息回传给进程

689-699 如果进程需要返回消息，则填入 ifa_msghdr 结构的其余部分，用 copyout 给进程复制缓存，并增大 w_where。

701 因为 info 数组还要在下一个接口消息中使用，所以程序将其中的这三个指针设置成 0。

19.17 小结

所有选路消息的格式都是相同的——一个定长的结构，后面跟着若干个插口地址结构。共有三种不同类型的消息，各自具有相应的定长结构，每种定长结构的前三个元素都分别标识消息的长度、版本和类型。每种结构中的比特掩码指定哪些插口地址结构跟在定长结构之后。

这些消息以两种方式在内核与进程之间传递。消息可以在任意一个方向上传递，并且都是通过选路插口每次读或写一个消息。这就使得一个超级用户进程对内核路由表的访问具有完全的读写能力。选路守护进程(如 routed 和 gated)就是这样实现其期望的选路策略的。

另外，任何一个进程都可以用 sysctl 系统调用来读取内核路由表的内容。这种方法不需要涉及选路插口，也不需要特别的权限。最终的结果通常包含许多选路消息，该结果作为系统调用的一部分被返回。由于进程不知道结果的大小，因此，为系统调用提供了一种方法来返回结果的大小而不返回结果本身。

习题

19.1 RTF_DYNAMIC 和 RTF_MODIFIED 标志之间有什么区别？对于一个给定的路由表项，它们可以同时设置吗？

19.2 当用下列命令添加默认路由时会有什么情况发生？

```
bsdi $ route add default -cloning -genmask 255.255.255.255 sun
```

19.3 某路由表包含了 15 个 ARP 表项和 20 个路由，试估算用 sysctl 导出该路由表时需要多少空间。

第20章 选路插口

20.1 引言

一个进程使用选路域 (routing domain) 中的一个插口来发送和接收前一章所描述的选路报文。socket 系统调用需要指定一个 PF_ROUTE 的族类型和一个 SOCK_RAW 的插口类型。

接着，该进程可以向内核发送以下五种选路报文：

- 1) RTM_ADD：增加一条新路由。
- 2) RTM_DELETE：删除一条已经存在的路由。
- 3) RTM_GET：取得有关一条路由的所有信息。
- 4) RTM_CHANGE：改变一条已经存在路由的网关、接口或者度量。
- 5) RTM_LOCK：说明内核不应该修改哪个度量。

除此之外，该进程可以接收其他七个选路报文，这些报文是在发生某些事件时，如接口下线和收到重定向报文等等，由内核生成的。

本章简介选路域、为每个选路插口创建的选路控制块、处理进程产生的报文的函数 (route_output)、发送选路报文给一个或多个进程的函数 (raw_input)、以及不同的支持一个选路插口上所有插口操作的函数。

20.2 routedomain 和 protosw 结构

在描述选路插口函数之前，我们需要讨论有关选路域的其他一些细节；在选路域中支持的 SOCK_RAW 协议；以及每个选路插口所附带的选路控制块。

图20-1列出了称为routedomain的PF_ROUTE域的domain结构。

成 员	值	描 述
dom_family	PF_ROUTE	域的协议族
dom_name	route	名字
dom_init	route_init	域的初始化，图18-30
dom_externalize	0	在选路域中不使用
dom_dispose	0	在选路域中不使用
dom_protosw	routesw	协议交换结构，图20-2
dom_protoswNPROTOSW		指向协议交换结构之后的指针
dom_next		由domaininit填入，图7-15
dom_rtattach	0	在选路域中不使用
dom_rtoffset	0	在选路域中不使用
dom_maxrtkey	0	在选路域中不使用

图20-1 routedomain 结构

与支持多个协议 (TCP、UDP和ICMP等) 的Internet域不一样，在选路域中只支持 SOCK_RAW 类型的一种协议。图 20-2列出了 PF_ROUTE 域的协议转换项。

成 员	routesw[0]	描 述
pr_type	SOCK_RAW	原始插口
pr_domain	&routedomain	选路域部分
pr_protocol	0	
pr_flags	PR_ATOMI / PR_ADDR	插口层标志，协议处理时不使用
pr_input	raw_input	不使用这项，raw_input直接调用
pr_output	route_output	PRU_SEND请求所调用
pr_ctlinput	raw_ctlinput	控制输入函数
pr_ctloutput	0	不使用
pr_usrreq	route_usrreq	对一个进程通信请求的响应
pr_init	raw_init	初始化
pr_fasttimo	0	不使用
pr_slowtimo	0	不使用
pr_drain	0	不使用
pr_sysctl	sysctl_rtable	用于sysctl(8)系统调用

图20-2 选路协议protosw 的结构

20.3 选路控制块

每当采用如下形式的调用创建一个选路插口时，

```
socket(PF_ROUTE, SOCK_RAW, protocol);
```

对协议的用户请求函数(route_usrreq)的一个对应的PRU_ATTACH请求分配一个选路控制块，并且将它链接到插口结构上。protocol参数可以将发送给这个插口上的进程的报文类型限制为一个特定族。例如，如果将protocol参数说明为AF_INET，只有包含了Internet地址的选路报文将被发送给这个进程。protocol参数为0将使得来自内核的所有选路报文都发送给这个插口。

记住我们把这些结构称为选路控制块，而不是原始控制块(raw control block)，是为了避免与第32章中的原始IP控制块相混淆。

图20-3显示了rawcb结构的定义。

```
39 struct rawcb {
40     struct rawcb *rcb_next;      /* doubly linked list */
41     struct rawcb *rcb_prev;
42     struct socket *rcb_socket;  /* back pointer to socket */
43     struct sockaddr *rcb_faddr; /* destination address */
44     struct sockaddr *rcb_laddr; /* socket's address */
45     struct sockproto rcb_proto; /* protocol family, protocol */
46 };
47 #define sotorawcb(so) ((struct rawcb *) (so)->so_pcb)
```

图20-3 rawcb 结构

另外，分配了一个相同名字的全局结构，rawcb，作为这个双向链表的头。图20-4显示了这种情况。

39-47 我们在图19-26中显示了sockproto的结构。它的sp_family成员变量被设置为PF_ROUTE，sp_protocol成员变量被设置为socket系统调用的第三个参数。

`rcb_faddr`成员变量被永久性地设置为指向`route_src`的指针，我们在图19-26中描述了`route_src`。`rcb_laddr`总是空指针。

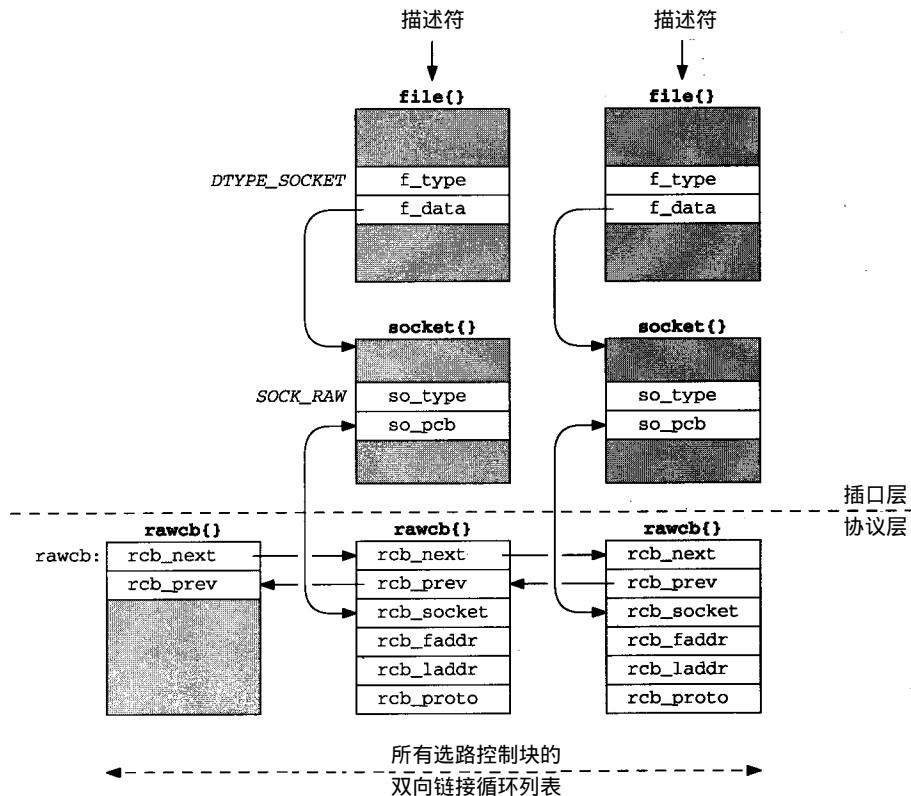


图20-4 原始协议控制块与其他数据结构的关系

20.4 raw_init函数

在图20-5中显示的`raw_init`函数是图20-2中的`protosw`结构的协议初始化函数。我们在图18-29中描述了选路域的完整初始化过程。

38-42 这个函数将头结构的下一个和前一个指针设置为指向自身来对这个双向链表进行初始化。

```

38 void
39 raw_init()
40 {
41     rawcb.rcb_next = rawcb.rcb_prev = &rawcb;
42 }

```

图20-5 raw_init 函数：初始化选路控制块的双向链表

20.5 route_output函数

如同我们在图18-11所显示的，当给协议的用户请求函数发送`PRU_SEND`请求时，就会调

用route_output，这是一个进程向一个选路插口进行写操作所引起的。在图 18-9中，我们给出了内核接受的、由进程发出的五种不同类型的选路报文。

因为这个函数是由一个进程的写操作激活的，来自于该进程的数据（发送给进程的选路报文）被放在一个由 sosend开始的mbuf链中。图20-6显示了大概的处理步骤，假定进程发送了一个RTM_ADD命令，说明三个地址：目的地址、它的网关和一个网络掩码（因此，这是一个网络路由，而不是一个主机路由）。

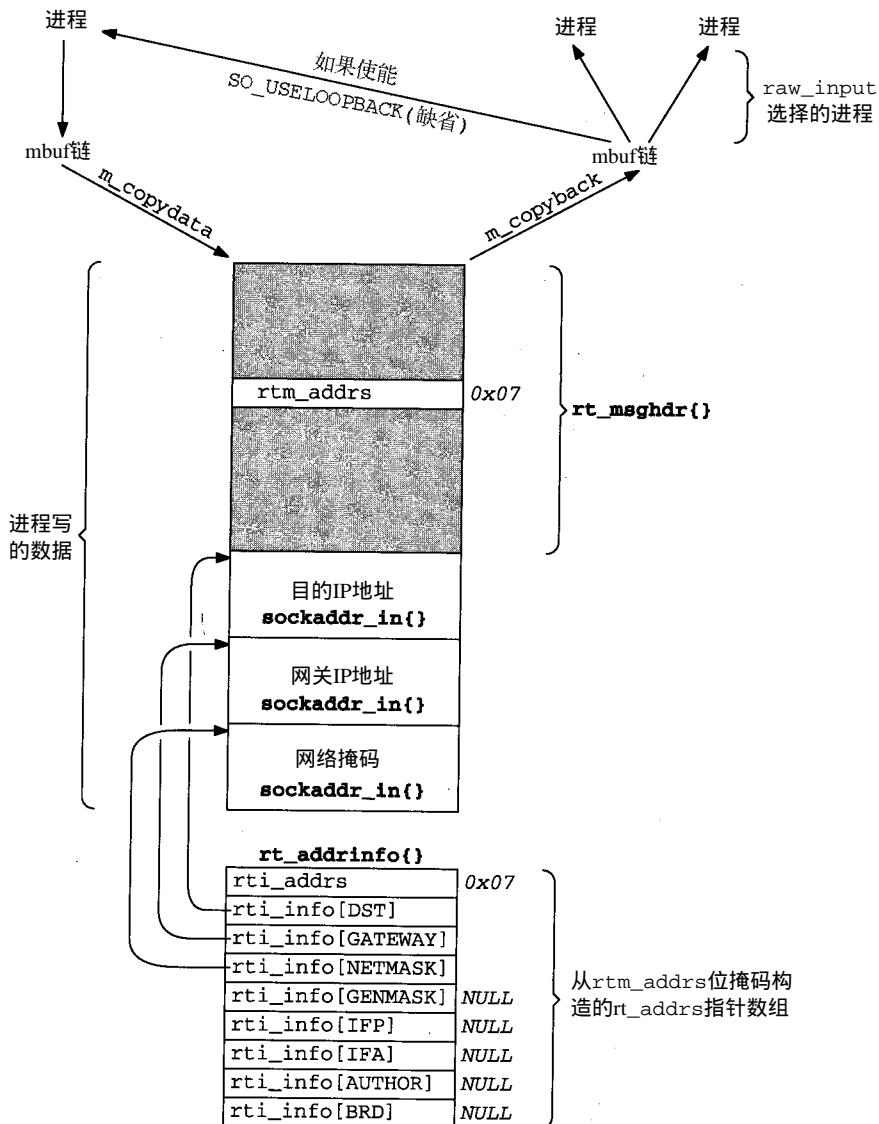


图20-6 一个进程发出的RTM_ADD 命令的处理过程示例

在这个图中有几点需要引起注意，我们在介绍 route_output的源代码时讨论了这里需要注意的大多数情况。另外，为了节省空间，我们省略了 rt_addrinfo结构中每个数组下标的RTAX_前缀。

- 进程通过设置比特掩码 rtm_addrs 来说明在定长的 rt_msghdr 结构之后有哪些插口地

址结构。我们显示了一个值为 0x07 的比特掩码，表示有一个目的地址、一个网关地址和一个网络掩码(图19-19)。RTM_ADD命令需要前两个地址；第三个地址是可选的。另一个可选的地址，genmask说明了用来产生克隆路由的掩码。

- write 系统调用(sosend函数)将来自进程的一个缓存数据复制到内核的一个 mbuf 链中。
- m_copydata 将 mbuf 链中数据复制到 route_output 使用 malloc 获得的一个缓存中。访问存储在单个连续缓存中的结构以及结构后面的若干插口地址结构，比访问一个 mbuf 链更容易。
- route_output 调用 rt_xaddrs 函数取得比特掩码，并且构造一个指向缓存的 rt_addrinfo 结构。route_output 中的代码使用图 19-19 中第五栏显示的名字来引用这些结构。比特掩码也要复制到 rti_addrs 成员中。
- route_output 一般要修改 rt_msghdr 结构。如果发生了一个错误，相应的 errno 值被返回到 rtm_errno 中(例如，如果路由已经存在，则返回 EEXIST)；否则，RTF_DONE 标志与进程提供的 rtm_flags 执行逻辑或操作。
- rt_msghdr 结构以及接着的地址成为 0 个或多个正在读选路插口的进程的输入。首先使用 m_copyback 将缓存转换为一个 mbuf 链。raw_input 经过所有的选路 PCB，并且传递一个复制给对应的进程。我们还显示了一个带有选路插口的进程，如果该进程没有禁止 SO_USELOOPBACK 插口选项，就会收到它写给那个插口的每个报文的一个复制。

为了避免收到它们自己的选路报文的一个复制，有些程序，如 route，将第二个参数置为 0 来调用 shutdown，以防止从选路插口上收到任何数据。

我们分成七个部分分析 route_output 的源代码。图 20-7 显示了这个函数的大概流程。

```
int
route_output()
{
    R_Malloc() to allocate buffer;
    m_copydata() to copy from mbuf chain into buffer;
    rt_xaddrs() to build rt_addrinfo();

    switch (message type) {
        case RTM_ADD:
            rtrequest(RTM_ADD);
            rt_setmetrics();
            break;

        case RTM_DELETE:
            rtrequest(RTM_DELETE);
            break;

        case RTM_GET:
        case RTM_CHANGE:
        case RTM_LOCK:
            rtalloc1();

            switch (message type) {
                case RTM_GET:
                    rt_msg2(RTM_GET);
                    break;

                case RTM_CHANGE:

```

图 20-7 route_output 处理步骤小结

```

    change appropriate fields;
    /* fall through */

    case RTM_LOCK:
        set rmx_locks;
        break;
    }
    break;
}

set rtm_error if error, else set RTF_DONE flag;
m_copyback() to copy from buffer into mbuf chain;
raw_input(); /* mbuf chain to appropriate processes */
}

```

图20-7 (续)

route_output的第一部分显示在图20-8中。

rtsock.c

```

113 int
114 route_output(m, so)
115 struct mbuf *m;
116 struct socket *so;
117 {
118     struct rt_msghdr *rtm = 0;
119     struct rtentry *rt = 0;
120     struct rtentry *saved_nrt = 0;
121     struct rt_addrinfo info;
122     int len, error = 0;
123     struct ifnet *ifp = 0;
124     struct ifaddr *ifa = 0;

125 #define senderr(e) { error = e; goto flush;}
126     if (m == 0 || ((m->m_len < sizeof(long)) ||
127                     (m = m_pullup(m, sizeof(long))) == 0))
128         return (ENOBUFS);
129     if ((m->m_flags & M_PKTHDR) == 0)
130         panic("route_output");
131     len = m->m_pkthdr.len;
132     if (len < sizeof(*rtm) ||
133         len != mtod(m, struct rt_msghdr *)->rtm_msflen) {
134         dst = 0;
135         senderr(EINVAL);
136     }
137     R_Malloc(rtm, struct rt_msghdr *, len);
138     if (rtm == 0) {
139         dst = 0;
140         senderr(ENOBUFS);
141     }
142     m_copydata(m, 0, len, (caddr_t) rtm);
143     if (rtm->rtm_version != RTM_VERSION) {
144         dst = 0;
145         senderr(EPROTONOSUPPORT);
146     }
147     rtm->rtm_pid = curproc->p_pid;
148     info.rti_addrs = rtm->rtm_addrs;
149     rt_xaddrs((caddr_t) (rtm + 1), len + (caddr_t) rtm, &info);

```

图20-8 route_output 函数：初始化处理，从mbuf链中复制报文

```

150     if (dst == 0)
151         senderr(EINVAL);
152     if (genmask) {
153         struct radix_node *t;
154         t = rn_addmask((caddr_t) genmask, 1, 2);
155         if (t && Bcmp(genmask, t->rn_key, *(u_char *) genmask) == 0)
156             genmask = (struct sockaddr *) (t->rn_key);
157     else
158         senderr(ENOBUFS);
159 }

```

rtsock.c

图20-8 (续)

1. 检查mbuf的合法性

113-136 检查mbuf的合法性：它的长度必须至少是一个rt_msghdr结构的大小。从mbuf的数据部分取出第一个长字，里面包含了rtm_msglen的值。

2. 分配缓存

137-142 分配一个缓存来存放整个报文，m_copydata将报文从mbuf链复制到缓存。

3. 检查版本号

143-146 检查报文的版本号。如果将来引入了新版本的选路报文，这个成员变量可以用来对早期版本提供支持。

147-149 进程的ID被复制到rtm_pid，进程提供的比特掩码被复制到该函数的一个内部结构info.rti_addrs。函数rt_xaddrs(在下一节显示)填入info结构的第8个插口地址指针来指示当前包含报文的缓存。

4. 需要的目的地址

150-151 所有的命令都需要一个目的地址。如果info.rti_info[RTAX_DST]项是一个空指针，就需要一个EINVAL。记住dst引用了这个数组成员(图19-19)。

5. 处理可选的genmask

152-159 genmask是可选的，它是在设置了RTF_CLONING标志后(图19-8)，用作所创建路由的网络掩码。rn_addmask将这个掩码加入到掩码树中，并首先在掩码树中查找是否存在与这个掩码相同的条目，如果找到，就引用那个条目。如果在掩码树中找到或者将这个掩码加入到掩码树中，还要再检查一下掩码树中的那个条目是否真等于genmask的值，如果等于，则genmask指针就被替代为掩码树中那个掩码的指针。

图20-9显示了route_output函数处理RTM_ADD和RTM_DELETE的下一部分。

162-163 RTM_ADD命令要求进程说明一个网关。

164-165 rtrequest处理该请求。如果输入的路由是一个主机路由，则netmask指针可以为空。如果一切OK，则saved_nrt返回新的路由表项的指针。

166-172 将rt_metrics结构从调用者缓存中复制到路由表项中。引用计数减1，并且保存genmask指针(可能是一个空指针)。

173-176 处理RTM_DELETE命令非常简单，因为所有的工作都由rtrequest来完成。既然最后一个参数是一个空指针，如果引用计数为0，rtrequest就调用rtfree从路由表中删除指定的项(图19-7)。

下一步的处理过程显示在图20-10中，它显示了RTM_GET、RTM_CHANGE和RTM_LOCK命

令的公共代码。

```
160     switch (rtm->rtm_type) {
161         case RTM_ADD:
162             if (gate == 0)
163                 senderr(EINVAL);
164             error = rtrequest(RTM_ADD, dst, gate, netmask,
165                               rtm->rtm_flags, &saved_nrt);
166             if (error == 0 && saved_nrt) {
167                 rt_setmetrics(rtm->rtm_inits,
168                               &rtm->rtm_rmx, &saved_nrt->rt_rmx);
169                 saved_nrt->rt_refcnt--;
170                 saved_nrt->rt_genmask = genmask;
171             }
172             break;
173         case RTM_DELETE:
174             error = rtrequest(RTM_DELETE, dst, gate, netmask,
175                               rtm->rtm_flags, (struct rtentry **) 0);
176             break;
}
rtsock.c
```

图20-9 route_output 函数：进程RTM_ADD 和RTM_DELETE 命令

```
177     case RTM_GET:
178     case RTM_CHANGE:
179     case RTM_LOCK:
180         rt = rtalloc1(dst, 0);
181         if (rt == 0)
182             senderr(ESRCH);
183         if (rtm->rtm_type != RTM_GET) { /* XXX: too grotty */
184             struct radix_node *rn;
185             extern struct radix_node_head *mask_rnhead;
186
187             if (Bcmp(dst, rt_key(rt), dst->sa_len) != 0)
188                 senderr(ESRCH);
189             if (netmask && (rn = rn_search(netmask,
190                                         mask_rnhead->rnh_treetop)))
191                 netmask = (struct sockaddr *) rn->rn_key;
192             for (rn = rt->rt_nodes; rn; rn = rn->rn_dupedkey)
193                 if (netmask == (struct sockaddr *) rn->rn_mask)
194                     break;
195             if (rn == 0)
196                 senderr(ETOOMANYREFS);
197             rt = (struct rtentry *) rn;
}
rtsock.c
```

图20-10 route_output 函数：RTM_GET 、RTM_CHANGE 和RTM_LOCK 的公共处理部分

6. 查找已经存在的项

177-182 因为三个命令都引用了一个已经存在的项，所以用 rtalloc1函数来查找这个项。如果没有找到，则返回一个 ESRCH。

7. 不允许网络匹配

183-187 对于RTM_CHANGE和RTM_LOCK命令，一个网络匹配是不合适的：需要一个路由表关键字的精确匹配。因此，如果 dst参数不等于路由表关键字，这个匹配就是一个网络匹配，返回一个 ESRCH。

8. 使用网络掩码来查找正确的项

188-193 即使是一个精确的匹配，如果存在网络掩码不同的重复表项，仍然必须查找正确的项。如果提供了一个 netmask参数，就要在掩码表中查找它 (mask_rnhead)。如果找到了，netmask指针就被替代为掩码树中相应掩码的指针。检查重复表项列表的每个叶结点，查找一个rn_mask指针等于netmask的项。这个测试只是比较指针，而不是指针所指向的结构。这是因为所有的掩码都出现在掩码树中，并且每个不同的掩码只有一个副本出现在这个掩码树中。大多数情况下，表项不会重复，因此 for循环只执行一次。如果一个主机路由项被修改了，不应该提供一个网络掩码，因此，netmask和rn_mask都是空指针(两者是相等的)。但是，如果有一个附带掩码的项被修改了，那个掩码必须作为 netmask参数提供。

194-195 如果for循环终止时没有找到一个匹配的网络掩码，就返回 ETOOMANYREFS。

注释XXX表示这个函数必须做所有的工作来找到需要的项。所有这些细节在其他一些类似rtalloc1的函数中都应该被隐藏，rtalloc1检测网络匹配，并且处理掩码参数。

这个函数的下一部分继续处理 RTM_GET命令，显示在图 20-11中。这个命令与

```

198     switch (rtm->rtm_type) {                                     rtsock.c
199         case RTM_GET:
200             dst = rt_key(rtm);
201             gate = rt->rt_gateway;
202             netmask = rt_mask(rtm);
203             genmask = rt->rt_genmask;
204             if (rtm->rtm_addrs & (RTA_IFF | RTA_IFA)) {
205                 if (ifp = rt->rt_ifp) {
206                     ifpaddr = ifp->if_addrlist->ifa_addr;
207                     ifaaddr = rt->rt_ifa->ifa_addr;
208                     rtm->rtm_index = ifp->if_index;
209                 } else {
210                     ifpaddr = 0;
211                     ifaaddr = 0;
212                 }
213             }
214             len = rt_msg2(RTM_GET, &info, (caddr_t) 0,
215                           (struct walkarg *) 0);
216             if (len > rtm->rtm_msflen) {
217                 struct rt_msghdr *new_rtm;
218                 R_Malloc(new_rtm, struct rt_msghdr *, len);
219                 if (new_rtm == 0)
220                     senderr(ENOBUFS);
221                 Bcopy(rtm, new_rtm, rtm->rtm_msflen);
222                 Free(rtm);
223                 rtm = new_rtm;
224             }
225             (void) rt_msg2(RTM_GET, &info, (caddr_t) rtm,
226                           (struct walkarg *) 0);
227             rtm->rtm_flags = rt->rt_flags;
228             rtm->rtm_rmx = rt->rt_rmx;
229             rtm->rtm_addrs = info.rti_addrs;
230             break;

```

图20-11 route_output 函数：RTM_GET 处理过程

route_output 支持的其他命令的区别在于它能够返回比传递给它的更多的数据。例如，只需要输入一个插口地址结构，即目的地址，但至少返回两个插口地址结构，即目的地址和它的网关。参看图 20-6，这就意味着为 m_copydata 复制数据所分配的缓存可能需要扩充大小。

9. 返回目的地址、网关和掩码

198-203 rti_info 数组中存储了四个指针：dst、gate、netmask 和 genmask。后两个可能是空指针。info 结构中的这些指针指向进程将要返回的各个插口地址结构。

10. 返回接口信息

204-213 进程可以在 rtm_flags 比特掩码中设置 RTA_IFP 和 RTA_IFA 掩码。如果设置了一项或两项，就表示进程想要接收这个路由表项所指示的 ifaddr 结构：接口的链路层地址（由 rt_ifp->addrlist 指向）以及这个路由项的协议地址（由 rt_ifa->ifa_addr 指向）的内容。接口索引也会被返回。

11. 构造应答报文

214-224 将第三个指针置为空，调用 rt_msg2 来计算相应于 RTM_GET 的选路报文和 info 结构所指向的地址的长度。如果结果报文的长度超过了输入报文的长度，就会分配一个新的缓存，输入报文被复制到新的缓存中，老的缓存被释放，rtm 被重新设置为指向新缓存。

225-230 再次调用 rt_msg2，这次调用时第三个指针非空，因为在缓存中已经构造了一个结果报文。这次调用填入 rt_msghdr 结构的最后三个成员项。

图 20-12 显示了 RTM_CHANGE 和 RTM_LOCK 命令的处理过程。

12. 改变网关

231-233 如果进程传递了一个 gate 地址，rt_setgate 就被调用来改变这个路由表项的网关。

13. 查找新的接口

234-244 新的网关（如果被改变）可能也需要 rt_ifp 和 rt_ifa 指针。进程可以通过传递一个 ifpaddr 插口地址结构或者一个 ifaaddr 插口地址结构来说明这些新的值。先看第一个，然后再看第二个。如果进程两个结构都没传递，rt_ifp 和 rt_ifa 指针就被忽略。

14. 检验接口是否改变

245-256 如果找到了一个接口（ifa 非空），则该路由的现有 rt_ifa 指针要和新的值进行比较。如果数值已经改变了，则两个针对 rt_ifp 和 rt_ifa 的新值需要存储到路由表的表项中去。在这样做之前，先要用 RTM_DELETE 命令调用该接口的请求函数（如果定义了该函数的话）。这个删除动作是必须的，因为从一种类型的网络到另一种类型的网络，它们的链路层信息可能会有很大的差别（比如说从一个 X.25 网络改变成以太网的路由），同时我们还必须通知输出例程。

15. 更新度量

257-258 rt_setmetrics 修改路由表项的度量。

16. 调用接口请求函数

259-260 如果定义了一个接口请求函数，它就会和 RTM_ADD 命令一起被调用。

17. 保存克隆生成的掩码

261-262 如果进程指定了 genmask 参数，就将在图 20-8 中获得的掩码的指针保存在 rt_genmask 中。

18. 修改加锁度量的比特掩码

266-270 RTM_LOCK命令修改保存在rt_rmx.rmx_locks中的比特掩码。图20-13显示了这个比特掩码中不同比特的值，每个度量一个值。

```

231     case RTM_CHANGE:
232         if (gate && rt_setgate(rt, rt_key(rt), gate))
233             senderr(EDQUOT);
234         /* new gateway could require new ifaddr, ifp; flags may also be
235            different; ifp may be specified by ll sockaddr when protocol
236            address is ambiguous */
237         if (ifpaddr && (ifa = ifa_ifwithnet(ifpaddr)) &&
238             (ifp = ifa->ifp))
239             ifa = ifaof_ifpforaddr(ifaaddr ? ifaaddr : gate,
240                                     ifp);
241         else if ((ifaaddr && (ifa = ifa_ifwithaddr(ifaaddr))) ||
242                   (ifa = ifa_ifwithroute(rt->rt_flags,
243                                         rt_key(rt), gate)))
244             ifp = ifa->ifp;
245         if (ifa) {
246             struct ifaddr *oifa = rt->rt_ifa;
247             if (oifa != ifa) {
248                 if (oifa && oifa->if_a_rtrequest)
249                     oifa->if_a_rtrequest(RTM_DELETE,
250                                           rt, gate);
251                 IFAFREE(rt->rt_ifa);
252                 rt->rt_ifa = ifa;
253                 ifa->if_a_refcnt++;
254                 rt->rt_ifp = ifp;
255             }
256         }
257         rt_setmetrics(rtm->rtm_inits, &rtm->rtm_rmx,
258                       &rt->rt_rmx);
259         if (rt->rt_ifa && rt->rt_ifa->if_a_rtrequest)
260             rt->rt_ifa->if_a_rtrequest(RTM_ADD, rt, gate);
261         if (genmask)
262             rt->rt_genmask = genmask;
263         /*
264          * Fall into
265          */
266     case RTM_LOCK:
267         rt->rt_rmx.rmx_locks &= ~(rtm->rtm_inits);
268         rt->rt_rmx.rmx_locks |=
269             (rtm->rtm_inits & rtm->rtm_rmx.rmx_locks);
270         break;
271     }
272     break;
273 default:
274     senderr(EOPNOTSUPP);
275 }
```

rtsock.c

图20-12 route_output 函数：RTM_CHANGE 和RTM_LOCK 处理过程

路由表项中rt_metrics结构的rmx_locks成员是告诉内核哪些度量不要管的比特掩码。即，rmx_locks指定的那些度量内核不能修改。内核唯一能使用这些度量的地方是和TCP一起，如图27-3所示。rmx_pktsent度量不能被初始化或加锁，但是内核也从来没有引用或修改过这个成员。

进程发出的报文中的rtm_inits值是一个比特掩码，指出哪些度量刚刚被

常量	值	描述
RTV_MTU	0x01	初始化或者锁住 rmx_mtu
RTV_HOPCOUNT	0x02	初始化或者锁住 rmx_hopcount
RTV_EXPIRE	0x04	初始化或者锁住 rmx_expire
RTV_RPIPE	0x08	初始化或者锁住 rmx_recvpipe
RTV_SPIPE	0x10	初始化或者锁住 rmx_sendpipe
RTV_SSTHRESH	0x20	初始化或者锁住 rmx_ssthresh
RTV_RTT	0x40	初始化或者锁住 rmx_rtt
RTV_RTTVAR	0x80	初始化或者锁住 rmx_rttvar

图20-13 对度量初始化或加锁的常量

rt_setmetrics 初始化过。报文中的 rtm_rmx.rmx_locks 值是一个指出哪些度量现在应该加锁的比特掩码。rt_rmx.rmx_locks 的值是一个指出路由表中哪些度量当前被加锁的比特掩码。首先，任何将要初始化的比特 (rtm_inits) 都要解锁。任何既被初始化 (rtm_inits) 又被加锁 (rtm_rmx.rmx_locks) 的比特都必须加锁。

273-275 这个 default 是用于图 20-9 开始的 switch 语句，用来处理进程发出的报文中除了所支持的五个命令以外的其他选路命令。

route_output 的最后一部分显示在图 20-14 中，用来发送应答给 raw_input。

```

276     flush:
277     if (rtm) {
278         if (error)
279             rtm->rtm_errno = error;
280         else
281             rtm->rtm_flags |= RTF_DONE;
282     }
283     if (rt)
284         rtfree(rt);
285     {
286         struct rawcb *rp = 0;
287         /*
288          * Check to see if we don't want our own messages.
289          */
290         if ((so->so_options & SO_USELOOPBACK) == 0) {
291             if (route_cb.any_count <= 1) {
292                 if (rtm)
293                     Free(rtm);
294                 m_freem(m);
295                 return (error);
296             }
297             /* There is another listener, so construct message */
298             rp = sotorawcb(so);
299         }
300         if (rtm) {
301             m_copyback(m, 0, rtm->rtm_msflen, (caddr_t) rtm);
302             Free(rtm);
303         }
304         if (rp)
305             rp->rcb_proto.sp_family = 0; /* Avoid us */
306         if (dst)
307             route_proto.sp_protocol = dst->sa_family;
308         raw_input(m, &route_proto, &route_src, &route_dst);

```

图20-14 route_output 函数：将结果传递给 raw_input

```

309         if (rp)
310             rp->rcb_proto.sp_family = PF_ROUTE;
311     }
312     return (error);
313 }

```

rtsock.c

图20-14 (续)

19. 返回错误或OK

276-282 flush是该函数开头定义的senderr宏所跳转的标号。如果发生了一个错误，错误就在rtm_errno成员中返回；否则，就设置RTF_DONE标志。

20. 释放拥有的路由

283-284 如果拥有一条路由，就要被释放。如果找到，在图20-10的开始位置对rtalloc1的调用拥有这条路由。

21. 没有进程接收报文

285-296 SO_USELOOPBACK插口选项的默认值为真，表示发送进程将会收到它发送给选路插口的每个选路报文的一个复制（如果发送者不接收一个复制的报文，它就不能收到RTM_GET返回的任何信息）。如果没有设置这个选项，并且选路插口的总数小于或等于1，就没有其他进程接收报文，并且发送者不想要一个复制报文。缓存和mbuf链都会被释放，该函数返回。

22. 没有环回复制报文的其他监听者

297-299 至少有一个其他的监听者而不是发送进程不想要一个复制报文。指针rp，默认为空，被设置成指向发送者的选路控制块，它也用来作为发送者不想要复制报文的一个标志。

23. 将缓存转换成mbuf链

300-303 缓存被转换成一个mbuf链（图20-6），然后释放缓存。

24. 避免环回复制

304-305 如果设置了rp，则某个其他的进程可能想要报文，但是发送者不想要一个复制。发送者的选路控制块的sp_family成员被临时设置为0，但是报文的sp_family(route_proto结构，显示在图19-26中）有一个PF_ROUTE的族。这个技巧防止raw_input将结果的一个复制传递给发送进程，因为raw_input不会将一个复制传递给sp_family为0的任何插口。

25. 设置选路报文的地址族

306-308 如果dst是一个非空的指针，则那个插口地址结构的地址族成为选路报文的协议。对于Internet协议，这个值将是PF_INET。通过raw_input，一个复制被传递给合适的监听者。

309-313 如果调用进程的sp_family成员被临时设置为0，它就被复位成正常值，PF_ROUTE。

20.6 rt_xaddrs函数

在将来自进程的选路报文从mbuf链复制到一个缓存以及将来自进程的比特掩码(rt_addr)复制到rt_addrinfo结构的rti_info成员之后，只从route_output中调用一次rt_xaddrs函数（图20-8）。rt_xaddrs的目的是获取这个比特掩码，并且设置rti_info数组的指针，使之指向缓存中相应的地址。图20-15显示了这个函数。

330-340 指针数组被设置成0，因此，所有在比特掩码中不出现的地址结构的指针都将是空。

341-347 测试比特掩码中8个(RTM_MAX)可能比特的每一个（如果设置），将相应于插口地址结构的一个指针存到rti_info数组中。ADVANCE宏以插口地址结构的sa_len字段为参数，

上舍入为4个字节的倍数，相应地增加指针 cp。

```

330 #define ROUNDUP(a) \
331     ((a) > 0 ? (1 + (((a) - 1) | (sizeof(long) - 1))) : sizeof(long))
332 #define ADVANCE(x, n) (x += ROUNDUP((n)->sa_len))
333 static void
334 rt_xaddrs(cp, cplim, rtinfo)
335 caddr_t cp, cplim;
336 struct rt_addrinfo *rtinfo;
337 {
338     struct sockaddr *sa;
339     int i;
340     bzero(rtinfo->rti_info, sizeof(rtinfo->rti_info));
341     for (i = 0; (i < RTAX_MAX) && (cp < cplim); i++) {
342         if ((rtinfo->rti_addrs & (1 << i)) == 0)
343             continue;
344         rtinfo->rti_info[i] = sa = (struct sockaddr *) cp;
345         ADVANCE(cp, sa);
346     }
347 }
```

rtsock.c

图20-15 rt_xaddrs 函数：将指针填入 rti_info 数组

20.7 rt_setmetrics函数

这个函数在 route_output 中调用了两次：增加一条新路由时和改变一条已经存在的路由时。来自进程的选路报文的 rtm_inits 成员说明了进程想要初始化 rtm_rmx 数组中的哪些度量。比特掩码中的比特的值显示在图 20-13 中。

请注意，rtm_addrs 和 rtm_inits 都是来自进程的报文中的比特掩码，前者说明了接下来的插口地址结构，而后者说明哪些度量将被初始化。为了节省空间，在 rtm_addrs 中没有设置比特的插口地址结构也不会出现在选路报文中。但是整个 rt_metrics 总是以定长的 rt_msghdr 结构的形式出现——在 rtm_inits 中没有设置比特的数组成员将被忽略。

图 20-16 显示了 rt_setmetrics 函数。

```

314 void
315 rt_setmetrics(which, in, out)
316 u_long which;
317 struct rt_metrics *in, *out;
318 {
319 #define metric(f, e) if (which & (f)) out->e = in->e;
320     metric(RTV_RPIPE, rmx_recvpipe);
321     metric(RTV_SPIPE, rmx_sendpipe);
322     metric(RTV_SSTHRESH, rmx_ssthresh);
323     metric(RTV_RTT, rmx_rtt);
324     metric(RTV_RTTVAR, rmx_rttvar);
325     metric(RTV_HOPCOUNT, rmx_hopcount);
326     metric(RTV_MTU, rmx_mtu);
327     metric(RTV_EXPIRE, rmx_expire);
328 #undef metric
329 }
```

rtsock.c

图 20-16 rt_setmetrics 函数：设置 rt_metrics 结构中的成员

314-318 which参数总是进程的选路报文的 rtm_inits 成员。in 指向进程的 rt_metrics 结构，而 out 指向将要创建或修改的路由表项的 rt_metrics 结构。

319-329 测试比特掩码中8比特的每一比特，如果该比特被设置，就复制相应的度量。请注意当使用RTM_ADD 创建一个新的路由表项时，route_output 调用了 rtrequest，后者将整个路由表项设置为0(图19-9)。因此，在选路报文中，进程没有说明的任何度量，其默认值都是0。

20.8 raw_input函数

向一个进程发送的所有选路报文——包括由内核产生的和由进程产生的——都被传递给 raw_input，后者选择接收这个报文的进程。图 18-11 总结了调用 raw_input 的四个函数。

当创建一个选路插口时，族总是 PF_ROUTE；而协议，socket 的第三个参数，可能为 0，表示进程想要接收所有的选路报文；或者是一个如同 AF_INET 的值，限制插口只接收包含指定协议族地址的报文。为每个选路插口创建一个选路控制块 (20.3 节)，这两个值分别存储在 rcb_proto 结构的 sp_family 和 sp_protocol 成员中。

图20-17显示了 raw_input 函数。

```

51 void
52 raw_input(m0, proto, src, dst)
53 struct mbuf *m0;
54 struct sockproto *proto;
55 struct sockaddr *src, *dst;
56 {
57     struct rawcb *rp;
58     struct mbuf *m = m0;
59     int    sockets = 0;
60     struct socket *last;
61     last = 0;
62     for (rp = rawcb.rcb_next; rp != &rawcb; rp = rp->rcb_next) {
63         if (rp->rcb_proto.sp_family != proto->sp_family)
64             continue;
65         if (rp->rcb_proto.sp_protocol &&
66             rp->rcb_proto.sp_protocol != proto->sp_protocol)
67             continue;
68         /*
69          * We assume the lower level routines have
70          * placed the address in a canonical format
71          * suitable for a structure comparison.
72          *
73          * Note that if the lengths are not the same
74          * the comparison will fail at the first byte.
75          */
76 #define equal(a1, a2) \
77     (bcm((caddr_t)(a1), (caddr_t)(a2), a1->sa_len) == 0)
78     if (rp->rcb_laddr && !equal(rp->rcb_laddr, dst))
79         continue;
80     if (rp->rcb_faddr && !equal(rp->rcb_faddr, src))
81         continue;
82     if (last) {
83         struct mbuf *n;
84         if (n = m_copy(m, 0, (int) M_COPYALL)) {
85             if (sbappendaddr(&last->so_rcv, src,
86                             n, (struct mbuf *) 0) == 0)

```

图20-17 raw_input 函数：将选路报文传递给0个或多个进程

```

87             /* should notify about lost packet */
88             m_freem(n);
89         else {
90             sorwakeup(last);
91             sockets++;
92         }
93     }
94 }
95 last = rp->rcb_socket;
96 }
97 if (last) {
98     if (sbappendaddr(&last->so_rcv, src,
99                     m, (struct mbuf *) 0) == 0)
100        m_freem(m);
101    else {
102        sorwakeup(last);
103        sockets++;
104    }
105 } else
106     m_freem(m);
107 }

```

raw_usrreq.c

图20-17 (续)

51-61 在我们所看到的四个对 raw_input 的调用中，proto、src 和 dst 参数指向三个全局变量 route_proto、route_src 和 route_dst，这些变量都如同图 19-26 所示的那样被声明和初始化。

1. 比较地址族和协议

62-67 for 循环遍历每个选路控制块来查找一个匹配。控制块里的族（一般是 PF_ROUTE）必须与 sockproto 结构的族相匹配，否则这个控制块就被略过。接下来，如果控制块里的协议（socket 的第三个参数）非空，它必须匹配 sockproto 结构的族；否则，这个报文被略去。因此，以 0 协议创建了一个选路插口的进程将收到所有的选路报文。

2. 比较本地的和外部的地址

68-81 如果指定了的话，这两个测试比较了控制块里的本地地址和外部地址。目前，进程不能设置控制块的 rcb_laddr 或者 rcb_faddr 成员。一般来说，进程使用 bind 设置前者，用 connect 设置后者，但对于 Net/3 中的选路插口这是不可能的。作为替代，我们将看到 route_usrreq 将插口固定地连接到 route_src 插口地址结构，这是可行的，因为它总是这个函数的 src 参数。

3. 将报文添加到插口的接收缓存中

82-107 如果 last 非空，它指向最近看到的应该接收这个报文的 socket 结构。如果这个变量非空，就使用 m_copy 和 sbappendaddr 将这个报文的一个复制添加到那个插口的接收缓存中，并且在这个接收缓存等待的任何进程都会被唤醒。然后，last 被设置成指向在以前的测试中刚刚匹配的插口。使用 last 是为了在只有一个进程接收报文的情况下避免调用 m_copy（一个代价昂贵的操作）。

如果有 N 个进程接收报文，那么前 N-1 个接收一个复制报文，最后一个进程收到的是这个报文本身。

在这个函数里递增的 socket 变量并没有被用到。因为只有当报文被传递给一个进程后它才会被递增，所以，如果在函数的结尾这个变量的值是 0，就表示没有进程接收该报文（但是

变量值没有在任何地方保存)。

20.9 route_usrreq函数

route_usrreq是选路协议的用户请求函数。它被不同的操作调用。图 20-18 显示了这个函数。

```

64 int
65 route_usrreq(so, req, m, nam, control)
66 struct socket *so;
67 int     req;
68 struct mbuf *m, *nam, *control;
69 {
70     int     error = 0;
71     struct rawcb *rp = sotorawcb(so);
72     int     s;

73     if (req == PRU_ATTACH) {
74         MALLOC(rp, struct rawcb *, sizeof(*rp), M_PCB, M_WAITOK);
75         if (so->so_pcb = (caddr_t) rp)
76             bzero(so->so_pcb, sizeof(*rp));
77     }
78     if (req == PRU_DETACH && rp) {
79         int     af = rp->rcb_proto.sp_protocol;
80         if (af == AF_INET)
81             route_cb.ip_count--;
82         else if (af == AF_NS)
83             route_cb.ns_count--;
84         else if (af == AF_ISO)
85             route_cb.iso_count--;
86         route_cb.any_count--;
87     }
88     s = splnet();
89     error = raw_usrreq(so, req, m, nam, control);
90     rp = sotorawcb(so);
91     if (req == PRU_ATTACH && rp) {
92         int     af = rp->rcb_proto.sp_protocol;
93         if (error) {
94             free((caddr_t) rp, M_PCB);
95             splx(s);
96             return (error);
97         }
98         if (af == AF_INET)
99             route_cb.ip_count++;
100        else if (af == AF_NS)
101            route_cb.ns_count++;
102        else if (af == AF_ISO)
103            route_cb.iso_count++;
104        route_cb.any_count++;

105        rp->rcb_faddr = &route_src;
106        soisconnected(so);
107        so->so_options |= SO_USELOOPBACK;
108    }
109    splx(s);
110    return (error);
111 }
```

rtsock.c

图20-18 route_usrreq 函数：处理PRU_xxx请求

1. PRU_ATTACH：分配控制块

64-77 当进程调用socket时，就会发出PRU_ATTACH请求。为一个选路控制块分配内存。MALLOC返回的指针保存在socket结构的so_pcb成员中。如果分配了内存，rawcb结构被设置成0。

2. PRU_DETACH：计数器递减

78-87 close系统调用发出PRU_DETACH请求。如果socket结构指向一个协议控制块，route_cb结构的计数器中有两个被减1：一个是any_count；另一个是基于该协议的计数器。

3. 处理请求

88-90 函数raw_usrreq被调用来进一步处理PRU_xxx请求。

4. 计数器递增

91-104 如果请求是PRU_ATTACH，并且插口指向一个选路控制块，就要检查raw_usrreq是否返回一个错误。然后，route_cb结构的计数器中的两个被递增：一个是any_count，另一个是基于该协议的计数器。

5. 连接插口

105-106 选路控制块里的外部地址被设置成route_src。这将永久地连接到新的插口来接收PF_ROUTE族的选路报文。

6. 默认情况下使能SO_USELOOPBACK

107-111 使能SO_USELOOPBACK插口选项。这是一个默认使能的插口选项——其他所有的选项默认都被禁止。

20.10 raw_usrreq函数

raw_usrreq完成在选路域中用户请求处理的大部分工作。在上一节中它被route_usrreq函数所调用。用户请求的处理被划分成这两个函数，是因为其他的一些协议（例如OSI CLNP）调用raw_usrreq而不是route_usrreq。raw_usrreq并不是想要成为一个协议的pr_usrreq函数，相反，它是一个被不同的pr_usrreq函数调用的公共的子例程。

图20-19显示了raw_usrreq函数的开始和结尾。其中的switch语句体在该图后面的图中单独讨论。

1. PRU_CONTROL请求是不合法的

119-129 PRU_CONTROL请求来自于ioctl系统调用，在路由选择域中不被支持。

2. 控制信息不合法

130-133 如果进程传递控制信息（使用sendmsg系统调用），就会返回一个错误，因为路由选择域中不使用这个可选的信息。

3. 插口必须有一个控制块

134-137 如果socket结构没有指向一个选路控制块，就返回一个错误。如果创建了一个新的插口，调用者（即route_usrreq）有责任在调用这个函数之前分配这个控制块，并且将指针保存在so_pcb成员中。

262-269 这个switch语句的default子句处理case子句没有处理的两个请求：PRU_BIND

和PRU_CONNECT。这两个请求的代码是提供的，但在Net/3中被注释掉了。因此，如果在一个选路插口上发出bind或connect系统调用，就会引起一个内核的告警(panic)。这是一个程序错误(bug)。幸运的是创建这种类型的插口需要有超级用户的权限。

```

119 int raw_usrreq(so, req, m, nam, control) -- raw_usrreq.c
120
121 struct socket *so;
122 int req;
123 struct mbuf *m, *nam, *control;
124 {
125     struct rawcb *rp = sotorawcb(so);
126     int error = 0;
127     int len;
128
129     if (req == PRU_CONTROL)
130         return (EOPNOTSUPP);
131     if (control && control->m_len) {
132         error = EOPNOTSUPP;
133         goto release;
134     }
135     if (rp == 0) {
136         error = EINVAL;
137         goto release;
138     }
139     switch (req) {
140         /* Match cases */
141
142     default:
143         panic("raw_usrreq");
144     }
145     release:
146     if (m != NULL)
147         m_freem(m);
148     return (error);
149 }

```

raw_usrreq.c

图20-19 raw_usrreq 函数体

我们现在讨论单个的case语句。图20-20显示了对PRU_ATTACH和PRU_DETACH请求的处理。

139-148 PRU_ATTACH请求是socket系统调用的一个结果。一个选路插口只能由一个超级用户的进程创建。

149-150 函数raw_attach(图20-24)将控制块链接到双向链接列表中。nam参数是socket的第三个参数，被存储在控制块中。

151-159 PRU_DETACH是由close系统调用发出的请求。对一个空的rp指针的测试是多余的，因为在switch语句之前已经进行过这个测试了。

160-161 raw_detach(图20-25)从双向链接表中删除这个控制块。

图20-21显示了PRU_CONNECT2、PRU_DISCONNECT和PRU_SHUTDOWN请求的处理。

186-188 PRU_CONNECT2请求来自于socketpair系统调用，在路由选择域中不被支持。

189-196 因为一个选路插口总是连接的(图20-18)，所以PRU_DISCONNECT请求在PRU_DETACH请

```

139      /*
140       * Allocate a raw control block and fill in the
141       * necessary info to allow packets to be routed to
142       * the appropriate raw interface routine.
143       */
144     case PRU_ATTACH:
145       if ((so->so_state & SS_PRIV) == 0) {
146         error = EACCES;
147         break;
148       }
149       error = raw_attach(so, (int) nam);
150       break;

151     /*
152      * Destroy state just before socket deallocation.
153      * Flush data or not depending on the options.
154      */
155     case PRU_DETACH:
156       if (rp == 0) {
157         error = ENOTCONN;
158         break;
159       }
160       raw_detach(rp);
161       break;

```

*raw_usrreq.c*图20-20 *raw_usrreq* 函数：PRU_ATTACH 和PRU_DETACH 请求

求之前由close发出。插口必须已经和一个外部地址相连接，这对于一个选路插口来说总是成立的。*raw_disconnect*和*soisdisconnected*完成这个处理。

197-202 当参数指定在这个插口上没有更多的写操作时，*shutdown*系统调用发出PRU_SHUTDOWN请求。*socantsendmore*禁止以后的写操作。

```

186     case PRU_CONNECT2:
187       error = EOPNOTSUPP;
188       goto release;

189     case PRU_DISCONNECT:
190       if (rp->rcb_faddr == 0) {
191         error = ENOTCONN;
192         break;
193       }
194       raw_disconnect(rp);
195       soisdisconnected(so);
196       break;

197     /*
198      * Mark the connection as being incapable of further input.
199      */
200     case PRU_SHUTDOWN:
201       socantsendmore(so);
202       break;

```

*raw_usrreq.c*图20-21 *raw_usrreq* 函数：PRU_CONNECT2 、PRU_DISCONNECT 和PRU_SHUTDOWN 请求

对一个选路插口最常见的请求：PRU_SEND、PRU_ABORT和PRU_SENSE显示在图20-22中。

203-217 当进程向插口写时，*sosend*发出了PRU_SEND请求。如果指定了一个nam参数，

```

203     /*
204      * Ship a packet out. The appropriate raw output
205      * routine handles any massaging necessary.
206      */
207     case PRU_SEND:
208         if (nam) {
209             if (rp->rcb_faddr) {
210                 error = EISCONN;
211                 break;
212             }
213             rp->rcb_faddr = mtod(nam, struct sockaddr *);
214         } else if (rp->rcb_faddr == 0) {
215             error = ENOTCONN;
216             break;
217         }
218         error = (*so->so_proto->pr_output) (m, so);
219         m = NULL;
220         if (nam)
221             rp->rcb_faddr = 0;
222         break;
223     case PRU_ABORT:
224         raw_disconnect(rp);
225         sofree(so);
226         soisdisconnected(so);
227         break;
228     case PRU_SENSE:
229         /*
230          * stat: don't bother with a blocksize.
231          */
232         return (0);

```

raw_usrreq.c

图20-22 raw_usrreq 函数：PRU_SEND、PRU_ABORT 和PRU_SENSE 请求

即进程使用 sendto 或者 sendmsg 指定了一个目的地址，就会返回一个错误，因为 route_usrreq 总是为一个选路插口设置 rcb_faddr。

218-222 m指向的mbuf链中的信息被传递给协议的 pr_output 函数，也就是 route_output。

223-227 如果发出了一个 PRU_ABORT 请求，则该控制块被断开连接，插口被释放，然后被断开连接。

228-232 fstat 系统调用发出 PRU_SENSE 请求。函数返回OK。

图20-23显示了剩下的 PRU_xxx 请求。

```

233     /*
234      * Not supported.
235      */
236     case PRU_RCVOOB:
237     case PRU_RCVD:
238         return (EOPNOTSUPP);
239
240     case PRU_LISTEN:
241     case PRU_ACCEPT:
242     case PRU_SENDOOB:
243         error = EOPNOTSUPP;

```

raw_usrreq.c

图20-23 raw_usrreq 函数：最后部分

```

243     break;
244
245     case PRU_SOCKADDR:
246         if (rp->rcb_laddr == 0) {
247             error = EINVAL;
248             break;
249         }
250         len = rp->rcb_laddr->sa_len;
251         bcopy((caddr_t) rp->rcb_laddr, mtod(nam, caddr_t), (unsigned) len);
252         nam->m_len = len;
253         break;
254
255     case PRU_PEERADDR:
256         if (rp->rcb_faddr == 0) {
257             error = ENOTCONN;
258             break;
259         }
260         len = rp->rcb_faddr->sa_len;
261         bcopy((caddr_t) rp->rcb_faddr, mtod(nam, caddr_t), (unsigned) len);
262         nam->m_len = len;
263         break;

```

raw_usrreq.c

图20-23 (续)

233-243 这五个请求不被支持。

244-261 PRU_SOCKADDR和PRU_PEERADDR请求分别来自于getsockname和getpeername系统调用。前者总是返回一个错误，因为设置本地地址的bind系统调用在路由选择域中不被支持。后者总是返回插口地址结构route_src的内容，这个内容是由route_usrreq作为外部地址设置的。

20.11 raw_attach、raw_detach和raw_disconnect函数

raw_attach函数，显示在图20-24中，被raw_input调用用来完成PRU_ATTACH请求的处理。

```

49 int
50 raw_attach(so, proto)
51 struct socket *so;
52 int      proto;
53 {
54     struct rawcb *rp = sotorawcb(so);
55     int      error;
56
57     /*
58     * It is assumed that raw_attach is called
59     * after space has been allocated for the
60     * rawcb.
61     */
62     if (rp == 0)
63         return (ENOBUFS);
64     if (error = soreserve(so, raw_sendspace, raw_recvspace))
65         return (error);
66     rp->rcb_socket = so;
67     rp->rcb_proto.sp_family = so->so_proto->pr_domain->dom_family;
68     rp->rcb_proto.sp_protocol = proto;
69     insque(rp, &rawcb);
70     return (0);

```

raw_cb.c

图20-24 raw_attach 函数

49-64 调用者必须已经分配了原始的协议控制块。soreserve将发送和接收缓存的高水位标记设置为8192。这对于选路报文应该是绰绰有余了。

65-67 socket结构的一个指针和dom_family(即图20-1中用于选路域的PF_ROUTE)以及proto参数(socket调用的第三个参数)一起被存储到协议控制块中。

68-70 insque将这个控制块加入到由全局变量rawcb作为头指针的双向链接表的前面。

raw_detach函数，显示在图20-25中，被raw_input调用来完成PRU_DETACH请求的处理。

```

75 void
76 raw_detach(rp)
77 struct rawcb *rp;
78 {
79     struct socket *so = rp->rcb_socket;
80     so->so_pcb = 0;
81     soffree(so);
82     remque(rp);
83     free((caddr_t) (rp), M_PCB);
84 }
```

raw_cb.c

图20-25 raw_detach 函数

75-84 socket结构中的so_pcb指针被设置成空，然后释放这个插口。使用remque从双向链接表中删除该控制块，使用free来释放被控制块占用的内存。

raw_disconnect函数，显示在图20-26中，被raw_input调用来完成PRU_DISCONNECT和PRU_ABORT请求的处理。

88-94 如果该插口没有引用一个描述符，raw_detach释放该插口和控制块。

```

88 void
89 raw_disconnect(rp)
90 struct rawcb *rp;
91 {
92     if (rp->rcb_socket->so_state & SS_NOFDREF)
93         raw_detach(rp);
94 }
```

raw_cb.c

图20-26 raw_disconnect 函数

20.12 小结

一个选路插口是PF_ROUTE域中的一个原始插口。选路插口只能被一个超级用户进程创建。如果一个没有权限的进程想要读内核包含的选路信息，可以使用选路域所支持的sysctl系统调用(我们在前一章中描述过)。

在本章中，我们第一次碰到了与插口相联系的协议控制块(PCB)。在选路域中，一个专门的rawcb包含了有关选路插口的信息：本地和外部的地址、地址族和协议。我们将在第22章中看到用于UDP、TCP和原始IP插口的更大的Internet协议控制块(inpcb)。然而概念是相同的：socket结构被插口层使用，而PCB，一个rawcb或一个inpcb，被协议层使用。socket结构指向该PCB，后者也指向前者。

`route_output`函数处理进程可以发出的五个请求。依赖于协议和地址族，`raw_input`将一个选路报文发送给一个或多个选路插口。对一个选路插口的不同的 `PRU_xxx` 请求由 `raw_usrreq` 和 `route_usrreq` 处理。在后面的章节中，我们将碰到另外的 `xxx_usrreq` 函数，每个协议(UDP、TCP和原始IP)对应一个，每个函数都由一个 `switch` 语句组成用来处理每一个请求。

习题

- 20.1 当进程向一个选路插口写一个报文时，列出两种进程可以从 `route_output` 收到返回值的方法。哪种方法更可靠？
- 20.2 因为 `routesw` 结构的 `pr_protocol` 成员为 0，所以当进程对 `socket` 系统调用指定了一个非 0 的 `protocol` 参数时，会发生什么情况？
- 20.3 路由表中的路由(和 ARP 项不同)永远不会超时。试在路由上实现一个超时机制。

第21章 ARP：地址解析协议

21.1 介绍

地址解析协议(ARP)用于实现IP地址到网络接口硬件地址的映射。常见的以太网网络接口硬件地址长度为48 bit。ARP同时也可工作在其他类型的数据链路下，但在本章中，我们只考虑将IP地址映射到48 bit的以太网地址。ARP在RFC 826 [Plummer 1982]中定义。

当某主机要向以太网中另一台主机发送IP数据时，它首先根据目的主机的IP地址在ARP高速缓存中查询相应的以太网地址，ARP高速缓存是主机维护的一个IP地址到相应以太网地址的映射表。如果查到匹配的结点，则相应的以太网地址被写入以太网帧首部，数据报被加入到输出队列等候发送。如果查询失败，ARP会先保留待发送的IP数据报，然后广播一个询问目的主机硬件地址的ARP报文，等收到回答后再将IP数据报发送出去。

以上只是简要描述了ARP协议的基本工作过程，下面我们将结合Net/3中的ARP实现来详细描述其具体细节。卷1的第4章包含了ARP的例子。

21.2 ARP和路由表

Net/3中ARP的实现是和路由表紧密关联的，这也是为什么我们要在描述路由表结构之后再来讲解ARP的原因。图21-1显示了本章中我们描述ARP要用到的一个例子。整个图是与本书中用到的网络实例相对应的，它显示了bsdi主机上当前ARP缓存的相关结构。其中Ifnet、ifaddr和in_ifaddr结构是由图3-32和图6-5简化而来的，所以在图中忽略了在第3章和第6章中描述过的这三个结构中的某些细节。例如，图中没有画出在两个ifaddr结构之后的sockaddr_dl结构——而仅仅是概述了这两个结构中的相关信息。同样，我们也仅仅是概述了三个in_ifaddr结构中的信息。

下面，我们简要概述图中的有关要点。细节部分将随着本章的进行而详细展开。

1) llinfo_arp结构的双向链表包含了每一个ARP已知的硬件地址的少量信息。同名全局变量llinfo_arp是该链表的头结点，图中没有画出第一位的la_prev指针指向最后一项，最后一项的la_next指针指向第一项。该链表由ARP时钟函数每隔5分钟处理一次。

2) 每一个已知硬件地址的IP地址都对应一个路由表结点(rtentry结构)。llinfo_arp结构的la_rt指针成员用来指向相应的rtentry结构，同样地，rtentry结构的rt_llinfo指针成员指向llinfo_arp结构。图中对应主机sun(140.252.13.33)、svr4(140.252.13.34)和bsdi(140.252.13.35)的三个路由表结点各自具有相应的llinfo_arp结构。如图18-2所示。

3) 而在图的最左边第四个路由表结点则没有对应的llinfo_arp结构，该结点对应于本地以太网(140.252.13.32)的路由项。该结点的rt_flags中设置了C比特，表明该结点是被用来复制形成其他结点的。设置接口IP地址功能的in_ifinit函数(图6-19)通过调用rtinit函数来创建该结点。其他三个结点是主机路由结点(H标志)，并由bsdi向其他机器发送数据

时通过ARP间接调用路由相关函数产生的(L标志)。

4) rtentry结构中的rt_gateway指针成员指向一个sockaddr_dl结构变量。如果保存物理地址长度的结构sdl_alen成员为6，那么sockaddr_dl结构就包含相应的硬件地址信息。

5) 路由结点变量的rt_ifp成员的相应指针成员指向对应网络设备接口的ifnet结构。中间的两个路由结点对应的是以太网上的其他主机，这两个结点都指向le_softc[0]。而右边的路由结点对应的是bsdi，指向环回结构loif。因为rt_ifp.if_output指向输出函数，所以目的为本机的数据报被路由至环回接口。

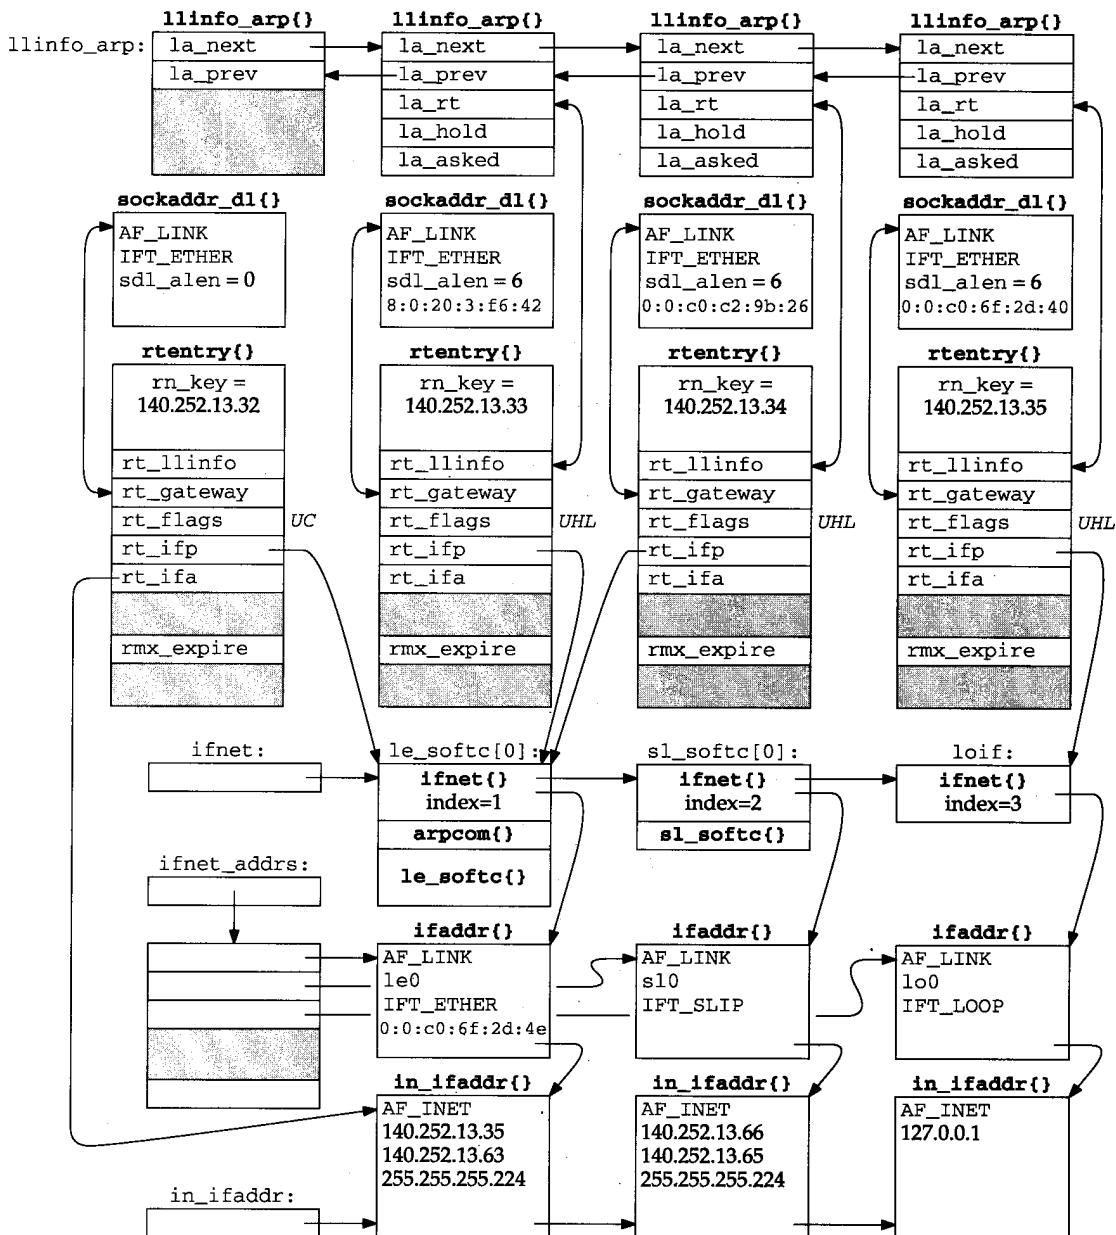


图21-1 ARP与路由表和接口结构的关系

6) 每一个路由结点还有指向相应的 `in_ifaddr` 结构的指针变量（图6-8中指出了 `in_ifaddr` 结构内的第一个成员是一个 `ifaddr` 结构，因此，`rt_ifa` 同样是指向了 `ifaddr` 结构变量）。在本图中，我们只显示一个路由结点的相应指向，其余的路由结点具有同样的性质。而一个接口如 `le0`，可以同时设置多个IP地址，每个IP地址都有对应的 `in_ifaddr` 结构，这就是为什么除了 `rt_ifp` 之外还需要 `rt_ifa` 的原因。

7) `la_hold` 成员是指向 `mbuf` 链表的指针。当要向某个IP传送数据报时，就需要广播一个 ARP请求。当内核等待 ARP回答时，存放该待发数据报的 `mbuf` 链的头结点的地址信息就存放在 `la_hold` 里。当收到 ARP回答后，`la_hold` 指向的 `mbuf` 链表中的 IP 数据被发送出去。

8) 路由表结点中 `rt_metric` 结构的变量 `rmx_expire` 存放的是与对应的 ARP结点相关的定时信息，用来实现删除超时(通常20分钟)的ARP结点。

在4.3BSD Reno中，路由表结构定义有了很大的变化，但4.3BSD Reno和Net/2.4.4BSD中依然定义有ARP缓存，只是去除了作为单独结构的ARP缓存链表，而把ARP信息放在了路由表结点里。

在Net/2中，ARP表是一个结构数组，其中每个元素包含有以下成员：IP地址、以太网地址、定时器、标志和一个指向 `mbuf` 的指针(类似于图21-1中的 `la_hold` 成员)。在Net/3中，我们可以看到，这些信息被分散到多个相互链接的结构里。

21.3 代码介绍

如图21-2所示，共有包含9个ARP函数的一个C文件和两个头文件。

文 件	描 述
<code>net/if_arp.h</code>	<code>arp_hdr</code> 结构的定义
<code>netinet/if_ether.h</code>	多个结构和常量的定义
<code>netinet/if_ether.d</code>	ARP函数

图21-2 本章中讨论的文件

图21-3显示了ARP函数与其他内核函数的关系。该图中还说明了ARP函数与第19章中某些子函数的关系，下面将逐步解释这些关系。

21.3.1 全局变量

本章中将介绍10个全局变量，如图21-4所示。

21.3.2 统计量

保存ARP的统计量有两个全局变量：`arp_inuse` 和 `arp_allocated`，如图21-4所示。前者用来记录当前正在使用的ARP结点数，后者用来记录在系统初始化时分配的ARP结点数。两个统计数都不能由 `netstat` 程序输出，但可以通过调试器来查看。

可以使用命令 `arp -a` 来显示当前ARP缓存的信息，该命令使用 `sysctl` 系统调用，参数如图19-36所示。图21-5显示该命令的一个输出结果。

由于图18-2中对应多播组224.0.0.1的相应路由表项设置了L标志，而同时由于 `arp` 程序查询带有 `RTF_LLINFO` 标志位的ARP结点，所以该程序也输出多播地址。后面我们将解释为什么该表项标识为“incomplete”，而在它上面的表项是“permanent”。

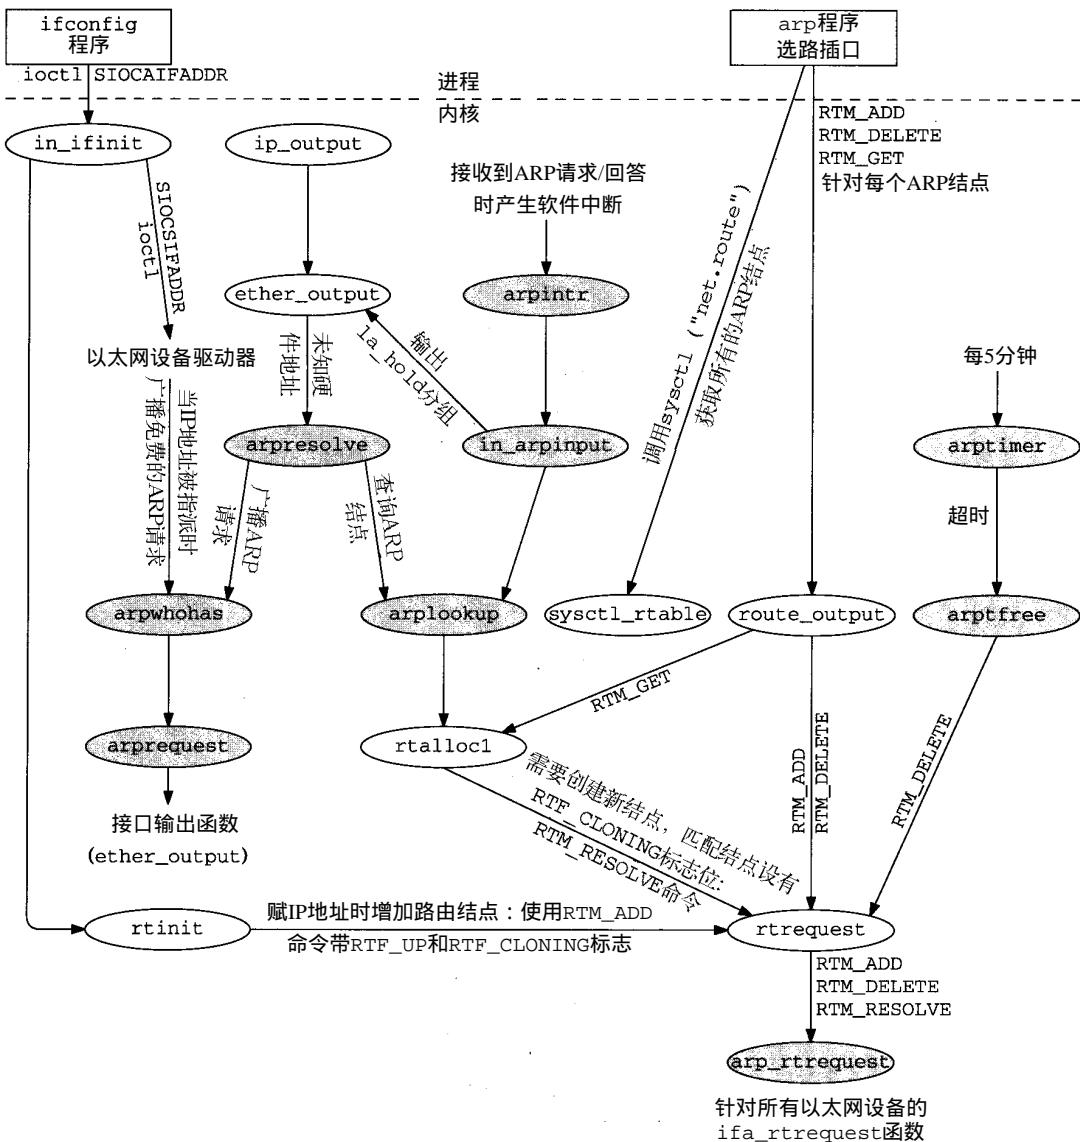


图21-3 ARP函数和内核中其他函数的关系

变 量	数 据 类 型	描 述
llinfo_arp	struct llinfo_arp	llinfo_arp 双向链接表的表头
arpinq	struct ifqueue	来自以太网设备驱动程序的 ARP输入队列
arpt_prune	Int	检查ARP链表的时间间隔的分钟数(5)
arpt_keep	Int	ARP结点的有效时间的分钟数(20)
arpt_down	Int	ARP洪泛算法的时间间隔的秒数(20)
arp_inuse	Int	正在使用的ARP结点数
arp_allocated	Int	已经分配的ARP结点数
arp_maxtries	Int	对一个IP地址发送ARP请求的重试次数(5)
arpinit_done	Int	初始化标志
uselookback	int	对本机使用环回(默认)

图21-4 本章介绍的全局变量

```
bsdi $ arp -a
sun.tuc.noao.edu (140.252.13.33) at 8:0:20:3:f6:42
svr4.tuc.noao.edu (140.252.13.34) at 0:0:c0:c2:9b:26
bsdi.tuc.noao.edu (140.252.13.35) at 0:0:c0:6f:2d:40 permanent
ALL-SYSTEMS.MCAST.NET (224.0.0.1) at (incomplete)
```

图21-5 与图18-2相应的arp -a命令的输出

21.3.3 SNMP变量

在卷1的25.8节中我们讲过，最初的SNMP MIB定义了一个地址映射组，该组对应的是系统的当前ARP缓存信息。在MIB-II中不再使用该组，而用各个网络协议组（如IP组）分别包含地址映射表来替代。注意，从Net/2到Net/3，将单独结构的ARP缓存演化为在路由表中集成的ARP信息是与SNMP的变化并行的。

IP地址映射表，index = <ipNetToMediaIfIndex>.<ipNetToMediaNetAddress>		
名 称	成 员	描 述
ipNetToMediaIfIndex	if_index	相应接口：ifIndex
ipNetToMediaPhysAddress	rt_gateway	硬件地址
ipNetToMediaNetAddress	rt_key	IP地址
ipNetToMediaType	rt_flags	映射类型：1=其他，2=失效，3=动态，4=静态(见正文)

图21-6 IP地址映射表：ipNetToMediaTable

图21-6所示的是MIB-II中的一个IP地址映射表，ipNetToMediaTable，该表保存的值来自于路由表结点和相应的ifnet结构。

如果路由表结点的生存期为0，则被认为是永久的，也即静态的。否则就是动态的。

21.4 ARP 结构

在以太网中传送的ARP分组的格式图21-7所示。

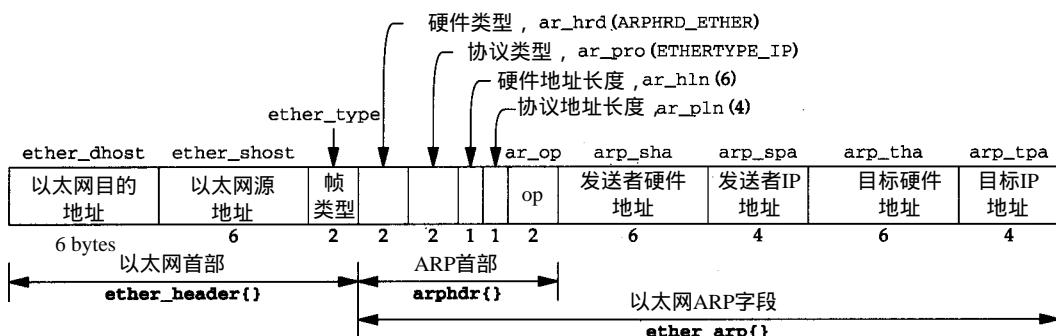


图21-7 在以太网上使用时ARP请求或回答的格式

结构ether_header定义了以太网帧首部；结构arpdr定义了其后的5个字段，其信息用于在任何类型的介质上传送ARP请求和回答；ether_arp结构除了包含arpdr结构外，还包含源主机和目的主机的地址。

结构arpdr的定义如图21-8所示。图21-7显示了该结构中的前4个字段。

```

45 struct arphdr {
46     u_short ar_hrd;           /* format of hardware address */
47     u_short ar_pro;          /* format of protocol address */
48     u_char  ar_hln;          /* length of hardware address */
49     u_char  ar_pln;          /* length of protocol address */
50     u_short ar_op;           /* ARP/RARP operation, Figure 21.15 */
51 };

```

图21-8 arphdr 结构：通用的ARP请求/回答数据首部

图21-9显示了ether_arp结构的定义，其中包含了arphdr结构、源主机和目的主机的IP地址和硬件地址。注意，ARP用硬件地址来表示48 bit以太网地址，用协议地址来表示32 bit IP地址。

```

79 struct ether_arp {
80     struct arphdr ea_hdr;      /* fixed-size header */
81     u_char    arp_sha[6];      /* sender hardware address */
82     u_char    arp_spa[4];      /* sender protocol address */
83     u_char    arp_tha[6];      /* target hardware address */
84     u_char    arp_tpa[4];      /* target protocol address */
85 };

86 #define arp_hrd ea_hdr.ar_hrd
87 #define arp_pro ea_hdr.ar_pro
88 #define arp_hln ea_hdr.ar_hln
89 #define arp_pln ea_hdr.ar_pln
90 #define arp_op  ea_hdr.ar_op

```

图21-9 ether_arp 结构

每个ARP结点中，都有一个llinfo_arp结构，如图21-10所示。所有这些结构组成的链接表的头结点是作为全局变量分配的。我们经常把该链接表称为 ARP高速缓存，因为在图21-1中，只有该数据结构是与ARP结点一一对应的。

```

103 struct llinfo_arp {
104     struct llinfo_arp *la_next;
105     struct llinfo_arp *la_prev;
106     struct rtentry *la_rt;
107     struct mbuf *la_hold;        /* last packet until resolved/timeout */
108     long    la_asked;           /* #times we've queried for this addr */
109 };

110 #define la_timer la_rt->rt_rmx.rmx_expire /* deletion time in seconds */

```

图21-10 llinfo_arp结构

在Net/2及以前的系统中，很容易识别作为ARP高速缓存的数据结构，因为每一个ARP结点的信息都存放在单一的结构中。而Net/3则把ARP信息存放在多个结构中，没有哪个数据结构被称为ARP高速缓存。但是为了讨论方便，我们依然用ARP高速缓存的概念来表示一个ARP结点的信息。

104-106 该双向链接表的前两项由insque和remque两个函数更新。la_rt指向相关的路

由表结点，该路由表结点的 `rt_llinfo` 成员指向 `la_rt`。

107 当 ARP 接收到一个要发往其他主机的 IP 数据报，且不知道相应硬件地址时，必须发送一个 ARP 请求，并等待回答。在等待 ARP 回答时，指向待发数据报的指针存放在 `la_hold` 中。收到回答后，`la_hold` 所指的数据报被发送出去。

108-109 `la_asked` 记录了连续为某个 IP 地址发送请求而没有收到回答的次数。在图 21-24 中，我们可以看到，当这个数值达到某个限定值时，我们就认为该主机是关闭的，并在其后一段时间内不再发送该主机的 ARP 请求。

110 这个定义使用路由结点中 `rt_metrics` 结构的 `rmx_expire` 成员作为 ARP 定时器。当值为 0 时，ARP 项被认为是永久的；当为非零时，值为当结点到期时算起的秒数。

21.5 arpwhohas 函数

`arpwhohas` 函数通常由 `arpresolve` 调用，用于广播一个 ARP 请求。如图 21-11 所示。它还可由每个以太网设备驱动程序调用，在将 IP 地址赋予该设备接口时主动发送一个地址联编信息（图 6-28 中的 `SIOCSIFADDR ioctl`）。主动发送地址联编信息不但可以检测在以太网中是否存在 IP 地址冲突，并且可以使其他机器更新其相应信息。`arpwhohas` 只是简单调用下一部分将要介绍的 `arprequest` 函数。

```
196 void if_ether.c
197 arpwhohas(ac, addr)
198 struct arpcom *ac;
199 struct in_addr *addr;
200 {
201     arprequest(ac, &ac->ac_ipaddr.s_addr, &addr->s_addr, ac->ac_enaddr);
202 }
```

if_ether.c

图 21-11 `arpwhohas` 函数：广播一个 ARP 请求

196-202 `arpcom` 结构（图 3-26）对所有以太网设备是通用的，是 `le_softc` 结构（图 3-20）的一部分。`ac_ipaddr` 成员是接口的 IP 地址的复制，当 `SIOCSIFADDR ioctl` 执行时由驱动程序填写（图 6-28）。`ac_enaddr` 是该设备的以太网地址。

该函数的第二个参数 `addr`，是 ARP 请求的目的 IP 地址。在主动发送动态联编信息时，`addr` 等于 `ac_ipaddr`，所以 `arprequest` 的第二和第三个参数是一样的，即发送 IP 地址和目的 IP 地址在主动发送动态联编信息时是一样的。

21.6 arprequest 函数

`arprequest` 函数由 `arpwhohas` 函数调用，用于广播一个 ARP 请求。该函数建立一个 ARP 请求分组，并将它传送到接口的输出函数。

在分析代码之前，我们先来看一下该函数建立的数据结构。传送 ARP 请求需要调用以太网设备的接口输出函数 `ether_output`。`ether_output` 的一个参数是 `mbuf`，它包含待发送数据，即图 21-7 中以太网类型字段后的所有内容。另外一个参数包含目的地址的端口地址结构。通常情况下，该目的地址是 IP 地址（例如，在图 21-3 中，`ip_output` 调用 `ether_output`）。特殊情况下，端口地址的 `sa_family` 被设为 `AF_UNSPEC`，即告知 `ether_output` 它所带的是一个已填充的以太网帧首部，包含了目的主机的硬件地址，这就

防止了ether_output去调用arpresolve而导致死循环。图21-3中没有显示这种循环，在arprequest下面的接口输出函数是ether_output。如果ether_output再去调用arpresolve，将导致死循环。

图21-12显示了该函数建立的两个数据结构mbuf和sockaddr。另外还有两个函数中用到的指针eh和ea。

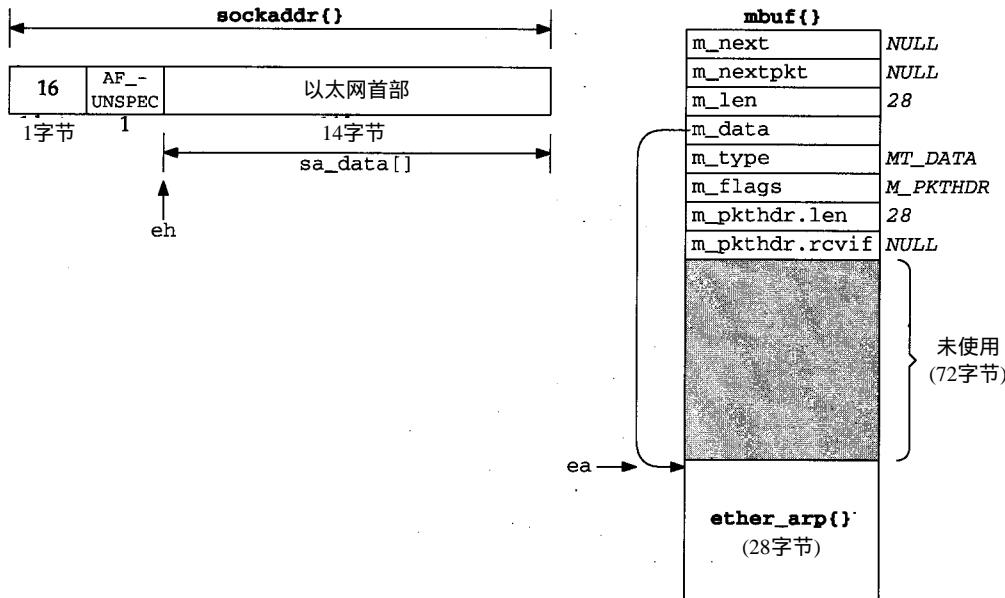


图21-12 arprequest 建立的sockaddr 和mbuf

图21-13给出了arprequest函数的源代码。

```
if_ether.c
```

```

209 static void
210 arprequest(ac, sip, tip, enaddr)
211 struct arpcom *ac;
212 u_long *sip, *tip;
213 u_char *enaddr;
214 {
215     struct mbuf *m;
216     struct ether_header *eh;
217     struct ether_arp *ea;
218     struct sockaddr sa;

219     if ((m = m_gethdr(M_DONTWAIT, MT_DATA)) == NULL)
220         return;
221     m->m_len = sizeof(*ea);
222     m->m_pkthdr.len = sizeof(*ea);
223     MH_ALIGN(m, sizeof(*ea));

224     ea = mtod(m, struct ether_arp *);
225     eh = (struct ether_header *) sa.sa_data;
226     bzero((caddr_t) ea, sizeof(*ea));

227     bcopy((caddr_t) etherbroadcastaddr, (caddr_t) eh->ether_dhost,
228           sizeof(eh->ether_dhost));

```

图21-13 arprequest 函数：创建一个ARP请求并发送

```

229     eh->ether_type = ETHERTYPE_ARP;      /* if_output() will swap */
230     ea->arp_hrd = htons(ARPHRD_ETHER);
231     ea->arp_pro = htons(ETHERTYPE_IP);
232     ea->arp_hln = sizeof(ea->arp_sha); /* hardware address length */
233     ea->arp_pln = sizeof(ea->arp_spa); /* protocol address length */
234     ea->arp_op = htons(ARPOP_REQUEST);
235     bcopy((caddr_t) enaddr, (caddr_t) ea->arp_sha, sizeof(ea->arp_sha));
236     bcopy((caddr_t) sip, (caddr_t) ea->arp_spa, sizeof(ea->arp_spa));
237     bcopy((caddr_t) tip, (caddr_t) ea->arp_tpa, sizeof(ea->arp_tpa));
238     sa.sa_family = AF_UNSPEC;
239     sa.sa_len = sizeof(sa);
240     (*ac->ac_if.if_output) (&ac->ac_if, m, &sa, (struct rtentry *) 0);
241 }

```

if_ether.c

图21-13 (续)

1. 分配和初始化 mbuf

209-223 分配一个分组数据首部的 mbuf，并对两个长度字段赋值。MH_ALIGN将28字节的 ether_arp结构置于mbuf的尾部，并相应地设置m_data指针的值。将该数据结构置于mbuf尾部，是为了允许ether_output预先考虑将14字节的以太网帧首部置于同一mbuf中。

2. 初始化指针

224-226 给ea和eh两个指针赋值，并将ether_arp结构的值赋为0。bzero的惟一目的是将目的硬件地址置0，该结构中其余8个字段已被设成相应的值。

3. 填充以太网帧首部

227-229 目的以太网地址设为以太网广播地址，并将以太网帧类型设为ETHERTYPE_ARP。注意代码中的注释，接口输出函数将该字段从主机字节序转化为网络字节序，该函数还将填充本机的以太网地址。图21-14显示了不同以太网帧类型字段的常量值。

常量	值	描述
ETHERTYPE_IP	0x0800	IP帧
ETHERTYPE_ARP	0x0806	ARP帧
ETHERTYPE_REVARP	0x8035	逆ARP帧
ETHERTYPE_IPTAILERS	0x1000	尾部封装(已废弃)

图21-14 以太网帧类型字段

RARP 将硬件地址映射成 IP 地址，通常在无盘工作站系统引导时使用。一般来说，RARP 部分不属于内核 TCP/IP 实现，所以本书将不作描述，卷 1 的第 5 章讲述了 RARP 的概念。

4. 填充 ARP 字段

230-237 填充了ether_arp的所有字段，除了ARP请求所要询问的目的硬件地址。常量ARPHRD_ETHER的值为1时，表示硬件地址的格式是6字节的以太网地址。为了表示协议地址是4字节的IP地址，arp_pro的值设为图21-14中所指的IP协议地址类型(0x800)。图21-15显示了不同的ARP操作码。本章中，我们将看到前两种。后两种在RARP中使用。

5. 填充 sockaddr，并调用接口输出函数

238-241 接口地址结构的sa_family成员的值设为AF_UNSPEC，sa_member成员的值设为16。调用接口输出函数ether_output。

常量	值	描述
ARPOP_REQUEST	1	解析协议地址的ARP请求
ARPOP_REPLY	2	回答ARP请求
ARPOP_REVREQUEST	3	解析硬件地址的RARP请求
ARPOP_REVREPLY	4	回答RARP请求

图21-15 ARP 操作码

21.7 arpintr函数

在图4-13中，当ether_input函数接收到帧类型字段为ETHERTYPE_ARP的以太网帧时，产生优先级为NETISR_ARP的软件中断，并将该帧挂在ARP输入队列arpintrq的后面。当内核处理该软件中断时，调用arpintr函数，如图21-16所示。

```

319 void                                         if_ether.c
320 arpintr()
321 {
322     struct mbuf *m;
323     struct arphdr *ar;
324     int      s;

325     while (arpintrq.ifq_head) {
326         s = splimp();
327         IF_DEQUEUE(&arpintrq, m);
328         splx(s);
329         if (m == 0 || (m->m_flags & M_PKTHDR) == 0)
330             panic("arpintr");

331         if (m->m_len >= sizeof(struct arphdr) &&
332             (ar = mtod(m, struct arphdr *)) &&
333             ntohs(ar->ar_hrd) == ARPHRD_ETHER &&
334             m->m_len >= sizeof(struct arphdr) + 2*ar->ar_hln + 2*ar->ar_pln)

335             switch (ntohs(ar->ar_pro)) {
336                 case ETHERTYPE_IP:
337                 case ETHERTYPE_IPTRAILERS:
338                     in_arpinput(m);
339                     continue;
340             }

341         m_freem(m);
342     }
343 }
```

if_ether.c

图21-16 arpintr 函数：处理包含ARP请求/回答的以太网帧

319-343 while循环一次处理一个以太网帧，直到处理完队列中的所有帧为止。只有当帧的硬件类型指明为以太网地址，并且帧的长度大于或等于 arphdr结构的长度加上两个硬件地址和两个协议地址的长度时，该帧才能被处理。如果协议地址的类型是 ETHERTYPE_IP或ETHERTYPE_IPTRAILERS时，调用in_arpinput函数，否则该帧将被丢弃。

注意if语句中对条件的检测顺序。共两次检查帧的长度。首先，当帧长大于或等于 arphdr结构的长度时，才去检查帧结构中的其他字段；然后，利用 arphdr中的两个长度字段再次检查帧长。

21.8 in_arpinput 函数

该函数由arpintr调用，用于处理接收到的ARP请求/回答。ARP本身的概念比较简单，但是加上许多规则后，实现就比较复杂，下面先来看一下两种典型情况：

- 1) 如果收到一个针对本机IP地址的请求，则发送一个回答。这是一种普通情况。很显然，我们将继续从那个主机收到数据报，随后也会向它回送报文。所以，如果我们还没有对应它的ARP结点，就应该添加一个ARP结点，因为这时我们已经知道了对方的IP地址和硬件地址。这会优化其后与该主机的通信。
- 2) 如果收到一个ARP回答，那么此时ARP结点是完整的，因此就知道了对方的硬件地址。该地址存放在sockaddr_dl结构中，所有发往该地址的数据报将被发送。
ARP请求是被广播发送的，所以以太网上的所有主机都将看到该请求，当然包括那些非目的主机。回想一下arprequest函数，在发送ARP请求时，帧中包含着请求方的IP地址和硬件地址，这就产生了下面的情况：
- 3) 如果其他主机发送了一个ARP请求或回答，其中发送方的IP地址与本机相同，那么肯定有一个主机配置有误。Net/3将检测到该差错，并向管理员登记一个报文(这里我们不分请求或回答，因为in_arpinout不检查操作类型，但是ARP回答将被单播，只有目的主机才能收到信息)。
- 4) 如果主机收到来自其他主机的请求或回答，对应的ARP结点早已存在，但硬件地址发生了变化，那么ARP结点将被更新。这种情况是这样发生的：其他主机以不同的硬件地址重新启动，而本机的对应ARP结点还未失效。这样，根据机器重启动时主动发送动态联编信息，可以使主机不至于因其他主机重启动后导致的ARP结点失效而不能通信。
- 5). 主机可以被配置为代理ARP服务器。这种情况下，主机可以代其他主机响应ARP请求，在回答中提供其他主机的硬件地址。代理ARP回答中对应目的硬件地址的主机必须能够把IP数据报转发至ARP请求中指定的目的主机。卷1的4.6节讨论了代理ARP。

一个Net/3系统可以配置成代理ARP服务器。这些ARP结点可以通过arp命令添加，该命令中指定IP地址、硬件地址并使用关键词pub。我们将在图21-20中看到该实现，并在21-12节讨论其实现细节。

将in_arpinput的分析分为四部分，图21-17显示了第一部分。

358-375 ether_arp结构的长度由调用者(arp_intr函数)验证，所以ea指针指向接收到的分组。ARP操作码(请求或回答)被拷贝至op字段，但具体值要到后面来验证。发送方和目的方的IP地址拷贝到isaddr和itaddr。

1. 查找匹配的接口和IP地址

376-382 搜索本机的Internet地址链表(in_ifaddr结构的链表，图6-5)。要记住一个接口可以有多个IP地址。收到的数据报中有指向接收接口ifnet结构的指针(在mbuf数据报的头部)，for循环只考虑与接收接口相关的IP地址。如果查询到有IP地址等于目的方IP地址或发送方IP地址，则退出循环。

383-384 如果循环退出时，变量maybe_ia的值为0，说明已经搜索了配置的IP地址整个链表而没有找到相关项。函数跳至out(图21-19)，丢弃mbuf，并返回。这种情况只发生在收到ARP请求的接口虽然已初始化但还没有分配IP地址时。

385 如果退出循环时，`maybe_ia`值不为0，即找到了一个接收端接口，但没有一个IP地址与目的方IP地址或发送方IP地址匹配，则`myaddr`的值设为该接口的最后一个IP地址；否则（正常情况），`myaddr`包含与目的方或发送方的IP地址匹配的本地IP地址。

```
358 static void                                         if_ether.c
359 in_arpinput(m)
360 struct mbuf *m;
361 {
362     struct ether_arp *ea;
363     struct arpcom *ac = (struct arpcom *) m->m_pkthdr.rcvif;
364     struct ether_header *eh;
365     struct llinfo_arp *la = 0;
366     struct rtentry *rt;
367     struct in_ifaddr *ia, *maybe_ia = 0;
368     struct sockaddr_dl *sdl;
369     struct sockaddr sa;
370     struct in_addr isaddr, itaddr, myaddr;
371     int      op;

372     ea = mtod(m, struct ether_arp *);
373     op = ntohs(ea->arp_op);
374     bcopy((caddr_t) ea->arp_spa, (caddr_t) &isaddr, sizeof(isaddr));
375     bcopy((caddr_t) ea->arp_tpa, (caddr_t) &itaddr, sizeof(itaddr));

376     for (ia = in_ifaddr; ia; ia = ia->ia_next)
377         if (ia->ia_ifp == &ac->ac_if) {
378             maybe_ia = ia;
379             if ((itaddr.s_addr == ia->ia_addr.sin_addr.s_addr) ||
380                 (isaddr.s_addr == ia->ia_addr.sin_addr.s_addr))
381                 break;
382         }
383     if (maybe_ia == 0)
384         goto out;
385     myaddr = ia ? ia->ia_addr.sin_addr : maybe_ia->ia_addr.sin_addr; if_ether.c
```

图21-17 `in_arpinput` 函数：查找匹配接口

图21-18显示了`in_arpinput`函数的第二部分，执行分组的验证。

```
386     if (!bcm((caddr_t) ea->arp_sha, (caddr_t) ac->ac_enaddr,           if_ether.c
387             sizeof(ea->arp_sha)))
388         goto out;          /* it's from me, ignore it. */
389     if (!bcm((caddr_t) ea->arp_sha, (caddr_t) etherbroadcastaddr,
390             sizeof(ea->arp_sha))) {
391         log(LOG_ERR,
392             "arp: ether address is broadcast for IP address %x!\n",
393             ntohl(isaddr.s_addr));
394         goto out;
395     }
396     if (isaddr.s_addr == myaddr.s_addr) {
397         log(LOG_ERR,
398             "duplicate IP address %x!! sent from ethernet address: %s\n",
399             ntohl(isaddr.s_addr), ether_sprintf(ea->arp_sha));
400         itaddr = myaddr;
401         goto reply;
402     } if_ether.c
```

图21-18 `in_arpinput` 函数：验证接收到的分组

2. 验证发送方的硬件地址

386-388 如果发送方的硬件地址等于本机接口的硬件地址，那是因为收到了本机发出的请求，忽略该分组。

389-395 如果发送方的硬件地址等于以太网的广播地址，说明出了差错。记录该差错，并丢弃该分组。

3. 检查发送方IP地址

396-402 如果发送方的IP地址等于myaddr，说明发送方和本机正在使用同一个IP地址。这也是一个差错——要么是发送方，要么是本机系统配置出了差错。记录该差错，在将目的IP地址设为myaddr后，程序转至reply(图21-19)。注意该ARP分组本来要送往以太网中其他主机的——该分组本来不是要送给本机的。但是，如果这种形式的IP地址欺骗被检测到，应记录差错，并产生回答。

图21-19显示了in_arpinput函数的第三部分。

```
if_ether.c
403     la = arplookup(isaddr.s_addr, itaddr.s_addr == myaddr.s_addr, 0);
404     if (la && (rt = la->la_rt) && (sdl = SDL(rt->rt_gateway))) {
405         if (sdl->sdl_alen &
406             bcmp((caddr_t) ea->arp_sha, LLADDR(sdl), sdl->sdl_alen))
407             log(LOG_INFO, "arp info overwritten for %x by %s\n",
408                 isaddr.s_addr, ether_sprintf(ea->arp_sha));
409         bcopy((caddr_t) ea->arp_sha, LLADDR(sdl),
410               sdl->sdl_alen = sizeof(ea->arp_sha));
411         if (rt->rt_expire)
412             rt->rt_expire = time.tv_sec + arpt_keep;
413         rt->rt_flags &= ~RTF_REJECT;
414         la->la_asked = 0;
415         if (la->la_hold) {
416             (*ac->ac_if.if_output) (&ac->ac_if, la->la_hold,
417                                     rt_key(rt), rt);
418             la->la_hold = 0;
419         }
420     }
421     reply:
422     if (op != ARPOP_REQUEST) {
423         out:
424         m_free(m);
425         return;
426     }
if_ether.c
```

图21-19 in_arpinput 函数：创建新的ARP结点或更新已有的ARP结点

4. 在路由表中搜索与发送方IP地址匹配的结点

403 arplookup在ARP高速缓存中查找符合发送方的IP地址(isaddr)。当ARP分组中的目的IP地址等于本机IP时，如果要创建新的ARP结点，那么第二个参数是1，如果不需创建新的ARP结点，那么第二个参数是0。如果本机就是目的主机，总是要创建ARP结点的，除非一个查找其他主机的广播分组，这种情况下只是在已有的ARP结点中查询。正如前面提到的，如果主机收到一个对应它自己的ARP请求，则说明以太网中有其他主机将要与它通信，所以应该创建一个对应该主机的ARP结点。

第三个参数是0，意味着不去查找代理ARP结点(后面要证明)。返回值是指向llinfo_

arp结构的指针；如果查不到或没有创建，返回值就是空。

5. 更新已有结点或填充新的结点

404 只有当以下三个条件为真时 if语句才执行：

- 1) 找到一个已有的ARP结点或成功创建一个新的ARP结点(即la非空)；
- 2) ARP结点指向一个路由表结点(rt)；
- 3) 路由表结点的re_gateway字段指向一个sockaddr_dl结构。

对于每一个目的并非本机的广播 ARP请求，如果发送方的 IP地址不在路由表，则第一个条件为假。

6. 检查发送方的硬件地址是否已改变

405-408 如果链路层地址长度(sdl_alen)非0，说明引用的路由表结点是现存的而非新创建的，则比较链路层地址和发送方的硬件地址。如果不同，则说明发送方的硬件地址已经改变，这是因为发送方以不同的以太网地址重新启动了系统，而本机的 ARP结点还未超时。这种情况虽然很少出现，但也必须考虑到。记录差错信息后，程序继续往下执行，更新 ARP结点的硬件地址。

在这个记录报文中，发送方的IP地址必须转换为主机字节序，这是一个错误。

7. 记录发送方硬件地址

409-410 将发送方的硬件地址写入路由表结点中 rt_gateway成员指向的sockaddr_dl结构。sockaddr_dl结构的链路层地址长度(sdl_alen)也被设为6。该赋值对于最近创建的ARP结点是需要的(习题21-3)。

8. 更新最近解析的ARP结点

411-412 在解析了发送方的硬件地址后，执行以下步骤。如果时限是非零的，则将被复位成20分钟(arpt_keep)。arp命令可以创建永久的 ARP结点，即该结点永远不会超时。这些ARP结点的时限值置为0。在图21-24中我们将看到，在发送 ARP请求(非永久性ARP结点)时，时限被设为本地时间，它是非0的。

413-414 清除RTF_REJECT标志，la_asked计数器设为0。我们将看到，在arpresolve中使用最后两个步骤是为了防止ARP洪泛。

415-420 如果ARP中保持有正在等待ARP解析该目的方硬件地址的mbuf，那么将mbuf送至接口输出函数(如图21-1所示)。由于该mbuf是由ARP保持的，即目的地址肯定是在以太网上，所以接口输出函数应该是ether_outout。该函数也调用arpresolve，但这时硬件地址已被填充，所以允许mbuf加入实际的设备输出队列。

9. 如果是ARP回答分组，则返回

421-426 如果该ARP操作不是请求，那么丢弃接收到的分组，并返回。

in_arpinput的剩下部分如图21-20所示，产生一个对应于 ARP请求的回答。只有当以下两种情况时才会产生ARP回答：

- 1) 本机就是该请求所要查找的目的主机；
- 2) 本机是该请求所要查找的目的主机的 ARP代理服务器。

函数执行到这个时刻，已经接收了 ARP请求，但ARP请求是广播发送的，所以目的主机可能是以太网上的任何主机。

10. 本机就是所要查找的目的主机

427-432 如果目的IP地址等于myaddr，那么本机就是所要查找的目的主机。将发送方硬件地址拷贝到目的硬件地址字段(发送方现在变成了目的主机)，arpcom结构中的接口以太网地址拷贝到源硬件地址字段。ARP回答中的其余部分在else语句后处理。

```

427     if (itaddr.s_addr == myaddr.s_addr) {
428         /* I am the target */
429         bcopy((caddr_t) ea->arp_sha, (caddr_t) ea->arp_tha,
430             sizeof(ea->arp_sha));
431         bcopy((caddr_t) ac->ac_enaddr, (caddr_t) ea->arp_sha,
432             sizeof(ea->arp_sha));
433     } else {
434         la = arplookup(itaddr.s_addr, 0, SIN_PROXY);
435         if (la == NULL)
436             goto out;
437         rt = la->la_rt;
438         bcopy((caddr_t) ea->arp_sha, (caddr_t) ea->arp_tha,
439             sizeof(ea->arp_sha));
440         sdl = SDL(rt->rt_gateway);
441         bcopy(LLADDR(sdl), (caddr_t) ea->arp_sha, sizeof(ea->arp_sha));
442     }
443
444     bcopy((caddr_t) ea->arp_spa, (caddr_t) ea->arp_tpa, sizeof(ea->arp_spa));
445     bcopy((caddr_t) & itaddr, (caddr_t) ea->arp_spa, sizeof(ea->arp_spa));
446     ea->arp_op = htons(ARPOP_REPLY);
447     ea->arp_pro = htons(ETHERTYPE_IP); /* let's be sure! */
448     eh = (struct ether_header *) sa.sa_data;
449     bcopy((caddr_t) ea->arp_tha, (caddr_t) eh->ether_dhost,
450         sizeof(eh->ether_dhost));
451     eh->ether_type = ETHERTYPE_ARP;
452     sa.sa_family = AF_UNSPEC;
453     sa.sa_len = sizeof(sa);
454     (*ac->ac_if.if_output) (&ac->ac_if, m, &sa, (struct rtentry *) 0);
455 }

```

if_ether.c

图21-20 in_arpinput函数：形成ARP回答，并发送出去

11. 检测本机是否为目的主机的ARP代理服务器

433-437 即使本机不是所要查找的目的主机，也可能被配置为目的主机的ARP代理服务器。再次调用arplookup函数，将第二个参数设为0，第三个参数设为SIN_PROXY，这将在路由表中查找SIN_PROXY标志为1的结点。如果查找不到(这是通常情况，本机收到了以太网上其他ARP请求的拷贝)，out处的代码将丢弃mbuf，并返回。

12. 产生代理回答

437-442 处理代理ARP请求时，发送方的硬件地址变成目的硬件地址，ARP结点中的以太网地址拷贝到发送方硬件地址。该ARP结点中的硬件地址可以是以太网中任一台主机的硬件地址，只要它可以向目的主机转发IP数据报。通常，提供代理ARP服务的主机会填入自己的硬件地址，当然这不是要求的。代理ARP结点是由系统管理员用arp命令带关键字pub创建的，标明目的IP地址(这是路由表项的关键值)和在ARP回答中返回的以太网地址。

13. 完成构造ARP回答分组

443-444 继续完成ARP回答分组的构建。发送方和目标的硬件地址已经填充好了，现在交换发送方和目标的IP地址。目的IP地址在itaddr中，如果发现以太网中有其他主机使用同一

IP地址，则该值已经被填充了(见图21-18)。

445-446 ARP操作码字段设为ARPOP_REPLY，协议地址类型设为ETHERTYPE_IP。旁边加了注释“你需要确定”，是因为当协议地址类型为ETHERTYPE_IPTRAILERS时arpintr也会调用该函数，但现在跟踪封装(trailer encapsulation)已不再使用了。

14. 用以太网帧头部填充sockaddr

447-452 sockaddr结构用14字节的以太网帧头部填充，如图21-12所示。目的硬件地址变成了以太网目的地址。

453-455 将ARP回答传送至接口输出函数，并返回。

21.9 ARP定时器函数

ARP结点一般是动态的——需要时创建，超时时自动删除。也允许管理员创建永久性结点，前面我们讨论的代理结点就是永久性的。回忆一下图21-1和图21-10中最后的#define语句，路由度量结构中的rmx_expire成员就是用作ARP定时器的。

21.9.1 arptimer函数

如图21-21所示，该函数每5分钟被调用一次。它查看所有ARP结点是否超时。

```
if_ether.c
74 static void
75 arptimer(ignored_arg)
76 void *ignored_arg;
77 {
78     int s = splnet();
79     struct llinfo_arp *la = llinfo_arp.la_next;
80     timeout(arptimer, (caddr_t) 0, arpt_prune * hz);
81     while (la != &llinfo_arp) {
82         struct rtentry *rt = la->la_rt;
83         la = la->la_next;
84         if (rt->rt_expire && rt->rt_expire <= time.tv_sec)
85             arptfree(la->la_prev); /* timer has expired, clear */
86     }
87     splx(s);
88 }
```

```
if_ether.c
```

图21-21 arptimer 函数：每5分钟查看所有ARP定时器

1. 设置下一个时限

80 arp_rtrequest函数使arptimer函数第一次被调用，随后arptimer每隔5分钟(arpt_prune)使自己被调用一次。

2. 查看所有ARP结点

81-86 查看ARP结点链表中的每一个结点。如果定时器值是非零的(不是一个永久结点)，而且时间已经超时，那么arptfree就删除该结点。如果rt_expire是非零的，它的值是从结点超时起到现在的秒数。

21.9.2 arptfree函数

如图21-22所示，arptfree函数由arptimer函数调用，用于从链接llinfo_dl表项的

列表中删除一个超时的ARP结点。

1. 使正在使用的结点无效(不删除)

467-473 如果路由表引用计数器值大于0，而且rt_gateway成员指向一个sockaddr_dl结构，则arptfree执行以下步骤：

- 1) 将链路层地址长度设为0；
- 2) 将la_asked计数器值设为0；
- 3) 清除RTF_REJECT标志。

随后函数返回。因为路由表引用计数器值非零，所以该路由结点不能删除。但是将sdl_alen值设为0，该结点也就无效了。下次要使用该结点时，还将产生一个ARP请求。

```
459 static void if_ether.c
460 arptfree(la)
461 struct llinfo_arp *la;
462 {
463     struct rtentry *rt = la->la_rt;
464     struct sockaddr_dl *sdl;
465     if (rt == 0)
466         panic("arptfree");
467     if (rt->rt_refcnt > 0 && (sdl = SDL(rt->rt_gateway)) &&
468         sdl->sdl_family == AF_LINK) {
469         sdl->sdl_alen = 0;
470         la->la_asked = 0;
471         rt->rt_flags &= ~RTF_REJECT;
472         return;
473     }
474     rtrequest(RTM_DELETE, rt_key(rt), (struct sockaddr *) 0, rt_mask(rt),
475               0, (struct rtentry **) 0);
476 }
```

if_ether.c

图21-22 arptfree 函数：删除或使一个ARP结点无效

2. 删除没有被引用的结点

474-475 rtrequest删除路由结点，在21.13节中，我们将看到它调用了arp_rtrequest。arp_rtrequest函数释放所有该ARP结点保持的mbuf(由la_hold指针所指向)，并删除相应的llinfo_arp结点。

21.10 arpresolve函数

在图4-16中，ether_output函数调用arpresolve函数以获得对应某个IP地址的以太网地址。如果已知该以太网地址，则arpresolve返回值为1，允许将待发IP数据报挂在接口输出队列上。如果不知道该以太网地址，则arpresolve返回值为0，arpresolve函数利用llinfo_arp结构的la_hold成员指针“保持(held)”待发IP数据报，并发送一个ARP请求。收到ARP回答后，再将保持的IP数据报发送出去。

arpresolve应避免ARP洪泛，也就是说，它不应在尚未收到ARP回答时高速重复发送ARP请求。出现这种情况主要有两个原因，第一，有多个IP数据报要发往同一个尚未解析硬件地址的主机；第二，一个IP数据报的每个分片都会作为独立分组调用ether_output。11.9节讨论了一个由分片引起的ARP洪泛的例子及相关的问题。图21-23显示了arpresolve的前半部分。

252-261 dst是一个指向sockaddr_in的指针，它包含目的IP地址和对应的以太网地址（一个6字节的数组）。

```

252 int
253 arpresolve(ac, rt, m, dst, desten)
254 struct arpcom *ac;
255 struct rtentry *rt;
256 struct mbuf *m;
257 struct sockaddr *dst;
258 u_char *desten;
259 {
260     struct llinfo_arp *la;
261     struct sockaddr_dl *sdl;
262     if (m->m_flags & M_BCAST) { /* broadcast */
263         bcopy((caddr_t) etherbroadcastaddr, (caddr_t) desten,
264               sizeof(etherbroadcastaddr));
265         return (1);
266     }
267     if (m->m_flags & M_MCAST) { /* multicast */
268         ETHER_MAP_IP_MULTICAST(&SIN(dst)->sin_addr, desten);
269         return (1);
270     }
271     if (rt)
272         la = (struct llinfo_arp *) rt->rt_llinfo;
273     else {
274         if (la = arplookup(SIN(dst)->sin_addr.s_addr, 1, 0))
275             rt = la->la_rt;
276     }
277     if (la == 0 || rt == 0) {
278         log(LOG_DEBUG, "arpresolve: can't allocate llinfo");
279         m_free(m);
280         return (0);
281     }

```

if_ether.c

图21-23 arpresolve 函数：查找所需的ARP结点

1. 处理广播和多播地址

262-270 如果mbuf的M_BCAST标志置位，则用以太网广播地址填充目的硬件地址字段，函数返回1。如果M_MCAST标志置位，则宏ETHER_MAP_IP_MULTICAST(图12-6)将D类地址映射为相应的以太网地址。

2. 得到指向llinfo_arp结构的指针

271-276 目的地是单播地址。如果调用者传输了一个指向路由表结点的指针，则将la设置为相应的llinfo_arp结构。否则，arplookup根据给定IP的地址搜索路由表。第二个参数是1，告诉arplookup如果搜索不到相应的ARP结点就创建一个新的；第三个参数是0，即意味着不去查找代理ARP结点。

277-281 如果rt或la中有一个是空指针，说明刚才请求分配内存时失败，因为即使不存在已有结点，arplookup已经创建了一个，rt和la都不应是空值。记录一个差错报文，释放分组，函数返回0。

图21-24显示了arpresolve的后半部分。它检查ARP结点是否有效，如无效，则发送一个ARP请求。

```

282     sdl = SDL(rt->rt_gateway);                                if_ether.c
283     /*
284      * Check the address family and length is valid, the address
285      * is resolved; otherwise, try to resolve.
286     */
287     if ((rt->rt_expire == 0 || rt->rt_expire > time.tv_sec) &&
288         sdl->sdl_family == AF_LINK && sdl->sdl_alen != 0) {
289         bcopy(LLADDR(sdl), desten, sdl->sdl_alen);
290         return 1;
291     }
292     /*
293      * There is an arptab entry, but no ethernet address
294      * response yet. Replace the held mbuf with this
295      * latest one.
296     */
297     if (la->la_hold)
298         m_freem(la->la_hold);
299     la->la_hold = m;

300     if (rt->rt_expire) {
301         rt->rt_flags &= ~RTF_REJECT;
302         if (la->la_asked == 0 || rt->rt_expire != time.tv_sec) {
303             rt->rt_expire = time.tv_sec;
304             if (la->la_asked++ < arp_maxtries)
305                 arpwhohas(ac, &(SIN(dst)->sin_addr));
306             else {
307                 rt->rt_flags |= RTF_REJECT;
308                 rt->rt_expire += arpt_down;
309                 la->la_asked = 0;
310             }
311         }
312     }
313     return (0);
314 }

```

if_ether.c

图21-24 arpresolve 函数：检查ARP结点是否有效，如无效，则发送一个ARP请求

3. 检查ARP结点的有效性

282-291 即使找到了一个ARP结点，还需检查其有效性。如以下条件成立，则 ARP结点是有效的：

- 1) 结点是永久有效的(时限值为0)，或尚未超时；
- 2) 由rt_gateway指向的插口地址结构的sdl_family字段为AF_LINK；
- 3) 链路层地址长度值(sdl_alen)不等于0。

arptfree使一个仍被引用的ARP结点失效的方法是将sdl_alen值置0。如果结点是有效的，则将sockaddr_dl中的以太网地址拷贝到desten，函数返回1。

4. 只保持最近的IP数据报

292-299 此时，已经有了ARP结点，但它没有一个有效的以太网地址，因此，必须发送一个ARP请求。将la_hold指针指向mbuf，同时也就释放了刚才la_hold所指的内容。这意味着，在发送ARP请求到收到ARP回答之间，如果有多个发往同一目的地的IP数据报要发送，只有最近的一个IP数据报才被la_hold保留，之前的全部丢弃。NFS就是这样的一个例子，如果NFS要传送一个8500字节的IP数据报，需要将其分割成6个分片。如果每个分片都在发送ARP请求到收到ARP回答之间由ip_output送往ether_output，那么前5个分片将被丢弃，

当收到ARP回答时，只有最后一个分片被保留了下来。这会使 NFS超时，并重发这6个分片。

5. 发送ARP请求，但避免ARP洪泛

300-314 RFC 1122要求ARP避免在收到ARP回答之前以过高的速度对一个以太网地址重发ARP请求。Net/3采用以下方法来避免ARP洪泛：

- Net/3不在同一秒钟内发送多个对应同一目的地的 ARP请求；
- 如果在连续5个ARP请求(也就是5秒钟)后还没有收到回答，路由结点的 RTF_REJECT标志置1，时限设为往后的20秒。这会使ether_output在20秒内拒绝发往该目的地址的IP数据报，并返回EHOSTDOWN或EHOSTUNREACH(如图4-15所示)。
- 20秒钟后，arpresolve会继续发送该目的主机的ARP请求。

如果时限值不等于0(非永久性结点)，则清除RTF_REJECT标志，该标志是在早些时候为避免ARP洪泛而设置的。计数器la_asked记录的是连续发往该目的地址的 ARP请求数。如果计数器值为0或时限值不等于当前时钟(只需看一下当前时钟的秒钟部分)，那么需要再发送一个ARP请求。这就避免了在同一秒钟内发送多个 ARP请求。然后将时限值设为当前时钟的秒钟部分(也就是微秒部分，time_tv_usec被忽略)。

将la_asked所含计数器值与限定值5(arpmxtries)比较，然后加1。如果小于5，则arpwhoahas发送ARP请求；如果等于5，则ARP已经达到了限定值：将RTF_REJECT标志置1，时限值置为往后的20秒钟，la_asked计数器值复位为0。

图21-25显示了一个例子，进一步解释了arpresolve和ether_output为了避免ARP洪泛所采用的算法。

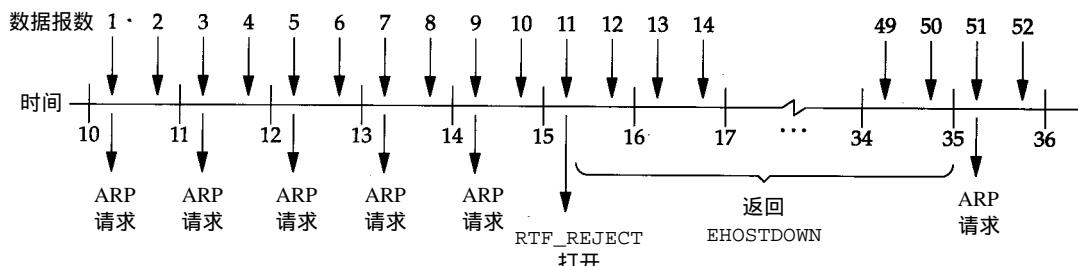


图21-25 避免ARP洪泛所采用的算法

图中总共显示了26秒的时间，从10到36。我们假定有一个进程每隔0.5秒发送一个IP数据报，也就是说，一秒钟内有两个数据报等待发送。数据报依次被标号为1~52。我们还假定目的主机已经关闭，所以收不到ARP回答。ARP将采取以下行动：

- 假定当进程写数据报1时la_asked的值为0。la_hold设为指向数据报1，rt_expire值设为当前时钟(10)，la_asked值变为1，发送ARP请求。函数返回0。
- 进程写数据报2时，丢弃数据报1，la_hold指向数据报2。由于rt_expire值等于当前时钟(10)，所以不发送ARP请求，函数返回，返回值为0。
- 进程写数据报3时，丢弃数据报2，la_hold指向数据报3。由于当前时钟(11)不等于rt_expire(10)，所以将rt_expire设为11。la_asked值为1，小于5，所以发送ARP请求，并将la_asked值置为2。
- 进程写数据报4时，丢弃数据报3，la_hold指向数据报4。由于rt_expire值等于当

前时钟(11)，所以无须其他动作，函数返回0。

- 对于数据报5~10，情况都是一样的。在数据报9到达后，发送ARP请求后，la_asked值被设为5；
- 进程写数据报11时，丢弃数据报10，la_hold指向数据报11。当前时钟(15)不等于rt_expire(14)，所以将rt_expire的值设为15。此时la_asked的值不再小于5，ARP避免洪泛的算法开始作用：RTF_REJECT标志位置1，rt_expire的值被设为35(即往后20秒)，la_asked的值设为0，函数返回0。
- 进程写数据报12时，ether_output注意到RTF_REJECT标志位为1，而且当前时钟小于rt_expire(35)，因此，返回EHOSTDOWN给发送者(通常是ip_output)。
- 从数据报13到50，都返回EHOSTDOWN给发送者。
- 当进程写数据报51时，尽管此时的RTF_REJECT标志位仍然为1，但当前时钟的值(35)不再小于rt_expire(35)，因此不会返回出错信息。调用arpresolve，整个过程重新开始，5秒钟内发送5个ARP请求，然后是20秒钟的等待，直到发送者放弃或目的主机响应ARP请求。

21.11 arplookup函数

arplookup函数调用选路函数rtalloc1在Internet路由表中查找ARP结点。我们已经看到过3次调用arplookup的情况：

- 1) 在in_arpinput中，在接收到ARP分组后，对应源IP地址查找或创建一个ARP结点。
- 2) 在in_arpinput中，接收到ARP请求后，查看是否存在目的硬件地址的代理ARP结点。
- 3) 在arpresolve中，查找或创建一个对应待发送数据报IP地址的ARP结点。

如果arplookup执行成功，则返回一个指向相应llinfo_arp结构的指针，否则返回一个空指针。

arplookup带有三个参数，第一个参数是目的IP地址；第二个参数是个标志，为真时表示若找不到相应结点就创建一个新的结点；第三个参数也是一个标志，为真时表示查找或创建代理ARP结点。

代理ARP结点通过定义一个不同形式的Internet插口地址结构来处理，即sockaddr_inarp结构，如图21-26所示。该结构只在ARP中使用。

```
if_ether.h
111 struct sockaddr_inarp {
112     u_char sin_len;           /* sizeof(struct sockaddr_inarp) = 16 */
113     u_char sin_family;        /* AF_INET */
114     u_short sin_port;
115     struct in_addr sin_addr;  /* IP address */
116     struct in_addr sin_srcaddr; /* not used */
117     u_short sin_tos;          /* not used */
118     u_short sin_other;        /* 0 or SIN_PROXY */
119 };
```

if_ether.h

图21-26 sockaddr_inarp 结构

111-119 前面8个字节与sockaddr_in结构相同，sin_family被设为AF_INET。最后8

个字节有所不同：sin_srcaddr、sin_tos和sin_other成员。当结点作为代理结点时，只用到sin_other成员，并将其设为SIN_PROXY(1)。

图21-27显示了arplookup函数。

```

480 static struct llinfo_arp *
481 arplookup(addr, create, proxy)
482 u_long addr;
483 int create, proxy;
484 {
485     struct rtentry *rt;
486     static struct sockaddr_inarp sin =
487     {sizeof(sin), AF_INET};

488     sin.sin_addr.s_addr = addr;
489     sin.sin_other = proxy ? SIN_PROXY : 0;
490     rt = rtalloc1((struct sockaddr *) &sin, create);
491     if (rt == 0)
492         return (0);
493     rt->rt_refcnt--;
494     if ((rt->rt_flags & RTF_GATEWAY) || (rt->rt_flags & RTF_LLINFO) == 0 ||
495         rt->rt_gateway->sa_family != AF_LINK) {
496         if (create)
497             log(LOG_DEBUG, "arptnew failed on %x\n", ntohs(addr));
498         return (0);
499     }
500     return ((struct llinfo_arp *) rt->rt_llinfo);
501 }

```

if_ether.c

图21-27 arplookup 函数：在路由表中查找ARP结点

1. 初始化sockaddr_inarp结构，准备查找

480-489 sin_addr成员设为将要查找的IP地址。如果proxy参数值不为0，则sin_other成员设为SIN_PROXY；否则设为0。

2. 路由表中查找结点

490-492 rtalloc1在Internet路由表中查找IP地址，如果create参数值不为0，就创建一个新的结点。如果找不到结点，则函数返回值为0(空指针)。

3. 减少路由表结点的引用计数值

493 如果找到了结点，则减少路由表结点的引用计数。因为，此时ARP不再被认为像运输层一样“持有”路由表结点，因此，路由表查找时对rt_refcnt计数的递增，应在这里由ARP取消。

494-499 如果将标志RTF_GATEWAY置位，或者标志RTF_LLINFO没有置位，或者由rt_gateway指向的插口地址结构的地址族字段值不是AF_LINK，说明出了某些差错，返回一个空指针。如果结点是这样创建的，应创建一个记录报文。

记录报文中对arptnew的注释是针对老版本Net/2中创建ARP结点的。

如果rtalloc1由于匹配结点的RTF_CLONING标志置位而创建一个新的结点，那么函数arp_rtrequest(21.13节)也要被rtrequest调用。

21.12 代理ARP

Net/3支持代理ARP，有两种不同类型的代理ARP结点，可以通过arp命令及pub选项将

它们加入到路由表中。添加代理 ARP选项会使`arp_rtrequest`主动发送动态联编信息(如图21-28所示)，因为在创建结点时`RTF_ANNOUNCE`标志位被置1。

代理ARP结点的第一种类型：它允许将网络内的某一主机的IP地址填入到ARP高速缓存内。硬件地址可以设为任意值。这种结点加入到路由表中时使用了直接的掩码`0xffffffffffff`。加掩码的目的是即使插口地址的`SIN_PROXY`标志位为1，在调用图21-27中的`rtalloc1`时能与该结点匹配。于是在调用图21-20中的`arplookup`时也能与该结点匹配，目的地址的`SIN_PROXY`置位。

如果本网中的主机H1不能实现ARP，那么可以使用这种类型的代理ARP结点。作为代理的主机代替H1回答所有的ARP请求，同时提供创建代理ARP结点时设定的硬件地址(比如可以是H1的以太网地址)。这种类型的结点可以通过`arp -a`命令查看，它带有“published”符号。

第二种类型的代理ARP结点用于已经存有路由表结点的主机。内核为该目的地址创建另外一个路由表结点，在这个新的结点中含有链路层的信息(如以太网地址)。该新结点中`sockaddr_inar`结构(图21-26)的`sin_other`成员的`SIN_PROXY`标志置位。回想一下，搜索路由表时是比较12字节的Internet插口地址(图18-39)。只有当该结构的最后8字节非零时，才会用到`SIX_PROXY`标志位。当`arplookup`指定送往`rtalloc1`的结构中的`sin_other`成员中`SIN_PROXY`的值时，只有路由表中那些匹配的结点的`SIN_PROXY`标志置位。

这种类型的代理ARP结点通常指明了作为代理ARP服务器的以太网地址。如果某代理ARP结点是为主机HD创建的，一般有以下步骤：

- 1) 代理服务器收到来自主机HS的查找HD硬件地址的广播ARP请求，主机HS认为HD在本地网上；
- 2) 代理服务器回答请求，并提供本机的以太网地址；
- 3) HS将发往HD的数据报发送给代理服务器；
- 4) 收到发往HD的数据报后，代理服务器利用路由表中关于HD的信息将数据报转发给HD。

路由器`netb`使用这种类型的代理ARP结点，见卷14.6节中的例子。可以通过命令`arp -a`来查看这些带有“published(proxy only)”的结点。

21.13 `arp_rtrequest`函数

图21-3简要显示了ARP函数和选路函数之间的关系。在ARP中，我们将调用两个路由表函数：

- 1) `arplookup`调用`rtalloc1`查找ARP结点，如果找不到匹配结点，则创建一个新的ARP结点。

如果在路由表中找到了匹配结点，且该结点的`RTF_CLONING`标志位没有置位(即该结点就是目的主机的结点)，则返回该结点。如果`RTF_CLONING`标志位被置位，`rtalloc1`以`RTM_RESOLVE`命令为参数调用`rtrequest`。图18-2中的140.252.13.33和140.252.13.34结点就是这么创建的，它们是从140.252.13.32的结点复制而来的。

- 2) `arptfree`以`RTM_DELETE`命令为参数调用`rtrequest`，删除对应ARP结点的路由表结点。

此外，`arp`命令通过发送和接收路由插口上的路由报文来操纵ARP高速缓存。`arp`以命令

RTM_RESOLVE、RTM_DELETE和RT_GET为参数发布路由信息。前两个参数用于调用rtrequest，第三个参数用于调用rtalloc1。

最后，当以太网设备驱动程序获得了赋予该接口的IP地址后，rtinit增加一个网络路由。于是rtrequest函数被调用，参数是RTM_ADD，标志位是RTF_UP和RTF_CLONING。图18-2中140 252 13 32结点就是这么创建的。

在第19章中我们讲过，每一个ifaddr结构都有一个指向函数(ifa_rtrequest成员)的指针，该函数在创建或删除一个路由表结点时被自动调用。在图6-17中，对于所有以太网设备，in_ifinit将该指针指向arp_rtrequest函数。因此，当调用路由函数为ARP创建或删除路由表结点时，总会调用arp_rtrequest。当任意路由表函数被调用时，arp_rtrequest函数的作用是做各种初始化或退出处理所需的工作。例如：当创建新的ARP结点时，arp_rtrequest内要为llinfo_arp结构分配内存。同样，当路由函数处理完一个RTM_DELETE命令后，arp_rtrequest的工作是删除llinfo_arp结构。

图21-28显示了arp_rtrequest函数的第一部分。

```

92 void
93 arp_rtrequest(req, rt, sa)
94 int      req;
95 struct rtentry *rt;
96 struct sockaddr *sa;
97 {
98     struct sockaddr *gate = rt->rt_gateway;
99     struct llinfo_arp *la = (struct llinfo_arp *) rt->rt_llinfo;
100    static struct sockaddr_dl null_sdl =
101        {sizeof(null_sdl), AF_LINK};

102    if (!arpinit_done) {
103        arpinit_done = 1;
104        timeout(arptimer, (caddr_t) 0, hz);
105    }
106    if (rt->rt_flags & RTF_GATEWAY)
107        return;
108    switch (req) {

109    case RTM_ADD:
110        /*
111         * XXX: If this is a manually added route to interface
112         * such as older version of routed or gated might provide,
113         * restore cloning bit.
114         */
115        if ((rt->rt_flags & RTF_HOST) == 0 &&
116            SIN(rt->rt_gateway)->sin_addr.s_addr != 0xffffffff)
117            rt->rt_flags |= RTF_CLONING;
118        if (rt->rt_flags & RTF_CLONING) {
119            /*
120             * Case 1: This route should come from a route to iface.
121             */
122            rt_setgate(rt, rt_key(rt),
123                       (struct sockaddr *) &null_sdl);
124            gate = rt->rt_gateway;
125            SDL(gate)->sdl_type = rt->rt_ifp->if_type;
126            SDL(gate)->sdl_index = rt->rt_ifp->if_index;
127            rt->rt_expire = time.tv_sec;

```

图21-28 arp_rtrequest 函数：RTM_ADD 命令

```

128         break;
129     }
130     /* Announce a new entry if requested. */
131     if (rt->rt_flags & RTF_ANNOUNCE)
132         arprequest((struct arpcom *) rt->rt_ifp,
133                     &SIN(rt_key(rt))->sin_addr.s_addr,
134                     &SIN(rt_key(rt))->sin_addr.s_addr,
135                     (u_char *) LLADDR(SDL(gate)));
136     /* FALLTHROUGH */

```

if_ether.c

图21-28 (续)

1. 初始化ARP timeout函数

92-105 第一次调用arp_rtrequest函数时(系统初始化阶段，在对第一个以太网接口赋IP地址时)，timeout函数在一个时钟滴答内调用arptimer函数。此后，ARP定时器代码每5分钟运行一次，因为arptimer总是要调用timeout的。

2. 忽略间接路由

106-107 如果将标志RTF_GATEWAY置位，则函数返回。RTF_GATEWAY标志表明该路由表结点是间接的，而所有ARP结点都是直接的。

108 一个带有三种可能的switch语句：RTM_ADD、RTM_RESOLVE和RTM_DELETE(后两种在后面的图中显示)。

3. RTM_ADD命令

109 RTM_ADD命令出现在以下两种情况中：执行arp命令手工创建ARP结点或者rtinit函数对以太网接口赋IP地址(图21-3)。

4. 向后兼容

110-117 若标志RTF_HOST没有置位，说明该路由表结点与一个掩码相关(也就是说是网络路由，而非主机路由)。如果掩码不是全1，那么该结点确实是某一接口的路由，因此，将标志RTF_CLONING置位。如注释中所述，这是为了与某些旧版本的路由守护程序兼容。此外，/etc/netstart中的命令：

```
route add -net 224.0.0.0 -interface bsdi
```

为图18-2所示网络创建带有RTF_CLONING标志的路由表结点。

5. 初始化到接口的网络路由结点

118-126 若标志RTF_CLONING(in_ifinit为所有以太网接口设置该标志)置位，那么该路由表结点是由rtinit添加的。rt_setgate为sockaddr_dl结构分配空间，该结构由rt_gateway指针所指。与图21-1中140.252.13.32的路由表结点相关的就是该数据链路插口地址结构。sdl_family和sdl_len成员的值是根据静态定义的null_sd而初始化的，sdl_type(可能是IFT_ETHER)和sdl_index成员的值来自接口的ifnet结构。该结构不包含以太网地址，sdl_alen成员的值为0。

127-128 最后将时限值设为当前时间，也就是结点的创建时间，执行break后返回。对于在系统初始化时创建的结点，它们的rmx_expire值为系统启动的时间。注意，图21-1中该路由表结点没有相应的llinfo_arp结构，所以它不会被arptimer处理。但是要用它的sockaddr_dl结构，对于以太网中特定主机的路由结点来说，要复制的是rt_gateway结构，用RTM_RESOLVE命令参数创建路由表结点时，rtrequest复制该结构。此外，

netstat程序将sdl_index的值输出为link#n，见图18-2。

6. 发送免费ARP请求

130-135 若将标志RTF_ANNOUNCE置位，则该结点是由arp命令带pub选项创建的。该选项有两个分支：(1) sockaddr_inarp结构中sin_other成员的SIN_PROXY标志被置位；(2)标志RTF_ANNOUNCE被置位。因为标志RTF_ANNOUNCE被置位，所以arprequest广播免费ARP请求。注意，第二个和第三个参数是相同的，即该ARP请求中，发送方IP地址和目的方IP地址是一样的。

136 继续执行针对RTM_RESOLVE命令的case语句。

图21-29显示了arp_rtrequest函数的第二部分，处理RTM_RESOLVE命令。当rtalloc1找到一个RTF_CLONING标志位置位的路由表结点且rtalloc1的第二个参数值(arplookup的create参数)不为0时，调用该命令。需要分配一个新的llinfo_arp结构，并将其初始化。

```

137     case RTM_RESOLVE:
138         if (gate->sa_family != AF_LINK ||
139             gate->sa_len < sizeof(null_sdl)) {
140             log(LOG_DEBUG, "arp_rtrequest: bad gateway value");
141             break;
142         }
143         SDL(gate)->sdl_type = rt->rt_ifp->if_type;
144         SDL(gate)->sdl_index = rt->rt_ifp->if_index;
145         if (la != 0)
146             break;           /* This happens on a route change */
147         /*
148          * Case 2: This route may come from cloning, or a manual route
149          * add with a LL address.
150          */
151         R_Malloc(la, struct llinfo_arp *, sizeof(*la));
152         rt->rt_llinfo = (caddr_t) la;
153         if (la == 0) {
154             log(LOG_DEBUG, "arp_rtrequest: malloc failed\n");
155             break;
156         }
157         arp_inuse++, arp_allocated++;
158         Bzero(la, sizeof(*la));

159         la->la_rt = rt;
160         rt->rt_flags |= RTF_LLINFO;
161         insque(la, &llinfo_arp);

162         if (SIN(rt_key(rt))->sin_addr.s_addr ==
163             (IA_SIN(rt->rt_ifa))->sin_addr.s_addr) {
164             /*
165              * This test used to be
166              * if (loif.if_flags & IFF_UP)
167              * It allowed local traffic to be forced
168              * through the hardware by configuring the loopback down.
169              * However, it causes problems during network configuration
170              * for boards that can't receive packets they send.
171              * It is now necessary to clear "useloopback" and remove
172              * the route to force traffic out to the hardware.
173              */
174             rt->rt_expire = 0;

```

图21-29 arp_rtrequest 函数：RTM_RESOLVE 命令

```

175         Bcopy(((struct arpcom *) rt->rt_ifp)->ac_enaddr,
176             LLADDR(SDL(gate)), SDL(gate)->sdl_alen = 6);
177         if (useloopback)
178             rt->rt_ifp = &loif;
179     }
180     break;

```

if_ether.c

图21-29 (续)

7. 验证sockaddr_dl结构

137-144 验证rt_gateway指针所指的sockaddr_dl结构的sa_family和sa_len成员的值。接口类型(可能是IFT_ETHER)和索引值填入新的sockaddr_dl结构。

8. 处理路由变化

145-146 正常情况下，该路由表结点是新创建的，并没有指向一个llinfo_arp结构。如果la指针非空，则在路由已发生了变化时调用arp_rtrequest。此时llinfo_arp已经分配，执行break，函数返回。

9. 初始化llinfo_arp结构

147-158 分配一个llinfo_arp结构，rt_llinfo中存有指向该结构的指针。统计值变量arp_inuse和arp_allocated各加1，llinfo_arp结构置0。将la_hold指针置空，la_asked值置0。

159-161 将rt指针存储于llinfo_arp结构中，置RTF_LLINFO标志位。如图18-2所示，ARP创建的三个结点140.252.13.33、140.252.13.34和140.252.13.35都有L标志，和240.0.0.1一样。arp程序只检查该标志(图19-36)。最后insque将llinfo_arp加入到链接表的首部。

就这样创建了一个ARP结点：rtrequest创建路由表结点(经常为以太网克隆一个特定网络的结点)，arp_rtrequest分配和初始化llinfo_arp结构。剩下只需广播一个ARP请求，在收到回答后填充主机的以太网地址。事件发生的一般次序是：arpresolve调用arplookup，于是arp_rtrequest被调用(中间可能跟有函数调用，见图21-3)。当控制返回到arpresolve时，发送ARP广播请求。

10. 处理发给本机的特例情况

162-173 这是4.4BSD新增的测试特例部分(注释是老版本留下的)。它创建了图21-1中最右边的路由表结点，该结点包含了本机的IP地址(140.252.13.35)。if语句检测它是否等于本机IP地址，如等于，那么这个刚创建的结点代表的是本机。

11. 将结点置为永久性，并设置以太网地址

174-176 时限值设为0，意味着该结点是永久有效的——永远不会超时。从接口的arpcom结构中将硬件地址拷贝至rt_gateway所指的sockaddr_dl结构中。

12. 将接口指针指向环回接口

177-178 若全局变量usrloopback值不为0(默认为1)，则将路由表结点内的接口指针指向环回接口。这意味着，如果有数据报发给自己，就送往环回接口。在4.4BSD以前的版本中，可以通过/etc/netstart文件中的命令：

```
route add 140.252.13.35 127.0.0.1
```

来建立从本机IP地址到环回接口的路由。4.4BSD仍然支持这种方式，但已不是必需的了。当

第一次有数据报发给本机IP地址时，我们刚才看到的代码会自动创建一个这样的路由。此外，这些代码对于一个接口只会执行一次。一旦路由表结点和永久性ARP结点创建好后，它们就不会超时，所以不会再次出现对本机IP地址的RTM_RESOLVE命令。

arp_rtrequest函数的最后部分如图21-30所示，处理RTM_DELETE请求。从图21-3中，我们可以看到，该命令是由arp命令产生的，用于手工删除一个结点；或者在一个ARP结点超时时由arptfree产生。

```

181     case RTM_DELETE:
182         if (la == 0)
183             break;
184         arp_inuse--;
185         remque(la);
186         rt->rt_llinfo = 0;
187         rt->rt_flags &= ~RTF_LLINFO;
188         if (la->la_hold)
189             m_freem(la->la_hold);
190         Free((caddr_t) la);
191     }
192 }
```

if_ether.c

图21-30 arp_rtrequest函数：RTM_DELETE命令

13. 验证la指针

182-183 la指针应该是非空的，也就是说路由表结点必须指向一个llinfo_arp结构；否则，执行break，函数返回。

14. 删除llinfo_arp结构

184-190 统计值变量arp_inuse减1，remque从链表中删除llinfo_arp结构。rt_llinfo指针置0，清除RTF_LLINFO标志。如果该ARP结点保持有mbuf(即该ARP请求未收到回答)，则将mbuf释放。最后释放llinfo_arp结构。

注意，switch语句中没有包含default情况，也没有考虑RTM_GET命令。这是因为arp程序产生的RTM_GET命令全部由route_output函数处理，并不调用rtrequest。此外，见图21-3，在RTM_GET命令产生的对rtalloc1调用中，指定第二个参数是0，所以rtalloc1并不调用rtrequest。

21.14 ARP和多播

如果一个IP数据报要采用多播方式发送，ip_output检测进程是否已将某个特定的接口赋予插口(见图12-40)。如果已经赋值，则将数据报发往该接口，否则，ip_output利用路由表选择输出接口(见图8-24)。因此，对于具有多个多播发送接口的系统来说，IP路由表应指定每个多播组的默认接口。

在图18-2中我们看到，路由表中有一个结点是为网络224.0.0.0创建的，该结点具有“flag”标志。所有以224开头的多播组都以该结点指定的接口(le0)为默认接口。对于其他的多播组(以225~239开头)，可以分别创建新的路由表结点，也可以对某个指定多播组创建一个路由表结点。例如，可以为224.0.11(网络定时协议)创建一个与224.0.0.0不同的路由表结点。如果路由表中没有对应某个多播组的结点，同时进程没有用IP_MULTICAST_IF插口选项指明接口，那么该组的默认接口成为路由表中默认路由的接口。其实图18-2中对应224.0.0.0的路由表结

点并不是必要的，因为默认接口就是 le0。

如果选定的接口是以太网接口，则调用 `arpresolve` 将多播组地址映射为相应的以太网地址。在图 21-23 中，映射通过调用宏 `ETHER_MAP_IP_MULTICAST` 来完成。该宏所做的就是将该多播组地址的低 23 位与一个常量逻辑或（图 12-6），映射不需要 ARP 请求和回答，也不需要进入 ARP 高速缓存。每次需要映射时，调用该宏。

如果多播组是从另外一个结点复制得来的，那么多播组地址会出现在 ARP 缓存里，如图 21-5 所示。因为这些结点将 `RTF_LLINFO` 标志置位。它们不会有 ARP 请求和回答，所以说不是真正的 ARP 结点。它们也没有相应的链路层地址，宏 `ETHER_MAP_IP_MULTICAST` 就可以完成映射。

这些多播组的 ARP 结点的时效与正常的 ARP 结点不同。在为某个多播组创建一个路由表结点时，如图 18-2 中的 224.0.0.1，`rtrequest` 从被克隆的结点中复制 `rt_metrics` 结构（图 19-9）。图 21-28 中，网络路由结点的 `rmx_expire` 值被设为 `RTM_ADD` 命令执行的时间，也即系统初始化的时间。为 224.0.0.1 设置的结点也设置为同样的时间。

这就意味着在下次 `arptimer` 执行时，对应多播组 224.0.0.1 的 ARP 结点总是超时的。所以，当下一次在路由表中查找时就需重新创建该结点。

21.15 小结

ARP 提供了 IP 地址到硬件地址的映射，本章讲述了如何实现这种映射。

Net/3 实现与以往的 BSD 版本有很大不同。ARP 信息被存放在多个结构里面：路由表、数据链路插口地址结构和 `llinfo_arp` 结构。图 21-1 显示了这些结构之间的关系。

发送一个 ARP 请求是很简单的：正确填充相关字段后，将请求广播发送出去就行了。处理请求就要复杂一些，因为每个主机都收到了广播的 ARP 请求。除了响应请求外，`in_arpinput` 还要检测是否有其他主机正与它使用同一个 IP 地址。因为每一个 ARP 请求中包含发送方的 IP 和硬件地址，所以网络上的所有主机都可以通过它来更新自己的 ARP 结点。

在局域网中，ARP 洪泛将是一个问题，Net/3 是第一个考虑这种问题的 BSD 版本。对于同一个目的地，一秒钟内只可发送一个 ARP 请求，如果连续 5 个请求都没有收到回答，必须暂停 20 秒钟才可再发送去往该目的地的 ARP 请求。

习题

- 21.1 图 21-17 中给局部变量 `ac` 赋值时，做过什么假设？
- 21.2 如果我们先 ping 本地以太网的广播地址，之后执行 `arp -a`，就可以发现几乎所有本地以太网上的其他主机的表项都填入到了 ARP 高速缓存中。这是为什么？
- 21.3 查看代码并解释为什么图 21-19 中需要把 `sdl_alen` 的值赋为 6。
- 21.4 在 Net/2 中有一个独立于路由表而存在的 ARP 表，每次调用 `arpresolve` 时，都要在该 ARP 表中查找。试与 Net/3 的方法比较，哪个更有效？
- 21.5 Net/2 中的 ARP 代码显式地设置 ARP 高速缓存中非完整表项的超时为 3 分钟，非完整表项是指正在等待 ARP 回答的表项。但我们从没有提过 Net/3 如何处理该超时，那么 Net/3 何时才认为非完整表项超时？
- 21.6 当 Net/3 系统作为一个路由器并且导致洪泛的分组来自其他主机时，为避免 ARP 洪

泛要做哪些变动？

- 21.7 图21-1中给出的四个rmx_expire变量的值是什么？代码在何处设置该值？
- 21.8 对广播ARP请求的每个主机，本章中引起要创建一个ARP结点的代码需要做哪些变动？
- 21.9 为了验证图21-25中的例子，作者运行了卷1附录C的sock程序，每隔500 ms向本地以太网上一个不存在的主机发送一个UDP数据报（程序的-p选项改为等待的毫秒数）。但是在返回第一个EHOSTDOWN差错之前，仅无差错地发送了10个UDP数据报，而不是图21-25所示的11个，这是为什么？
- 21.10 修改ARP，使得它在等待ARP回答时持有到目的主机的所有分组，而不是持有最近的一个。如何实现这种改变？是否像每个接口的输出队列一样，需要一个限制？是否需要改变数据结构？

第22章 协议控制块

22.1 引言

协议层使用协议控制块(PCB)存放各UDP和TCP插口所要求的多个信息片。Internet协议维护Internet协议控制块(Internet protocol control block)和TCP控制块(TCP control block)。因为UDP是无连接的，所以一个端结点需要的所有信息都可以在Internet PCB中找到；不存在UDP控制块。

Internet PCB含有所有UDP和TCP端结点共有的信息：外部和本地IP地址、外部和本地端号、IP首部原型、该端结点使用的IP选项以及一个指向该端结点目的地址选路表入口的指针。TCP控制块包含了TCP为各连接维护的所有结点信息：两个方向的序号、窗口大小、重传次数等等。

本章我们描述Net/3所用的Internet PCB，在详细讨论TCP时再探讨TCP控制块。我们将研究几个操作Internet PCB的函数，会在描述UDP和TCP时遇到它们。大多数的函数以`in_pcbs`开头。

图22-1总结了协议控制块以及它们与`file`和`socket`结构之间的关系。该图中有几点要考虑：

- 当`socket`或`accept`创建一个插口后，插口层生成一个`file`结构和一个`socket`结构。文件类型是`DTYPE_SOCKET`，UDP端结点的插口类型是`SOCK_DGRAM`，TCP端结点的插口类型是`SOCK_STREAM`。
- 然后调用协议层。UDP创建一个Internet PCB(一个`inpcb`结构)，并把它链接到`socket`结构上：`so_pcbs`成员指向`inpcb`结构，`inp_socket`成员指向`socket`结构。
- TCP做同样的工作，也创建它自己的控制块(一个`tcpcb`结构)，并用指针`inp_ppcb`和`t_inpcb`把它链接到`inpcb`上。在两个UDP`inpcb`中，`inp_ppcb`成员是一个空指针，因为UDP不负责维护它自己的控制块。
- 我们显示的其他四个`inpcb`结构的成员，从`inp_faddr`到`inp_lport`，形成了该端结点的插口对：外部IP地址和端口号，以及本地IP地址和端口号。
- UDP和TCP用指针`inp_next`和`inp_prev`维护一个所有Internet PCB的双向链表。它们在表头分配一个全局`inpcb`结构(命名为`udb`和`tcb`)，在该结构中只使用三个成员：下一个和前一个指针，以及本地端口号。后一个成员中包含了该协议使用的下一个临时端口号。

Internet PCB是一个传输层数据结构。TCP、UDP和原始IP使用它，但IP、ICMP或ICMP不用它。

我们还没有讲过原始IP，但它也用Internet PCB。与TCP和UDP不同，原始IP在PCB中不用端口号成员，原始IP只用本章中提到的两个函数：`in_pcbaalloc`分配PCB，`in_pcbo_detach`释放PCB。第32章将讨论原始IP。

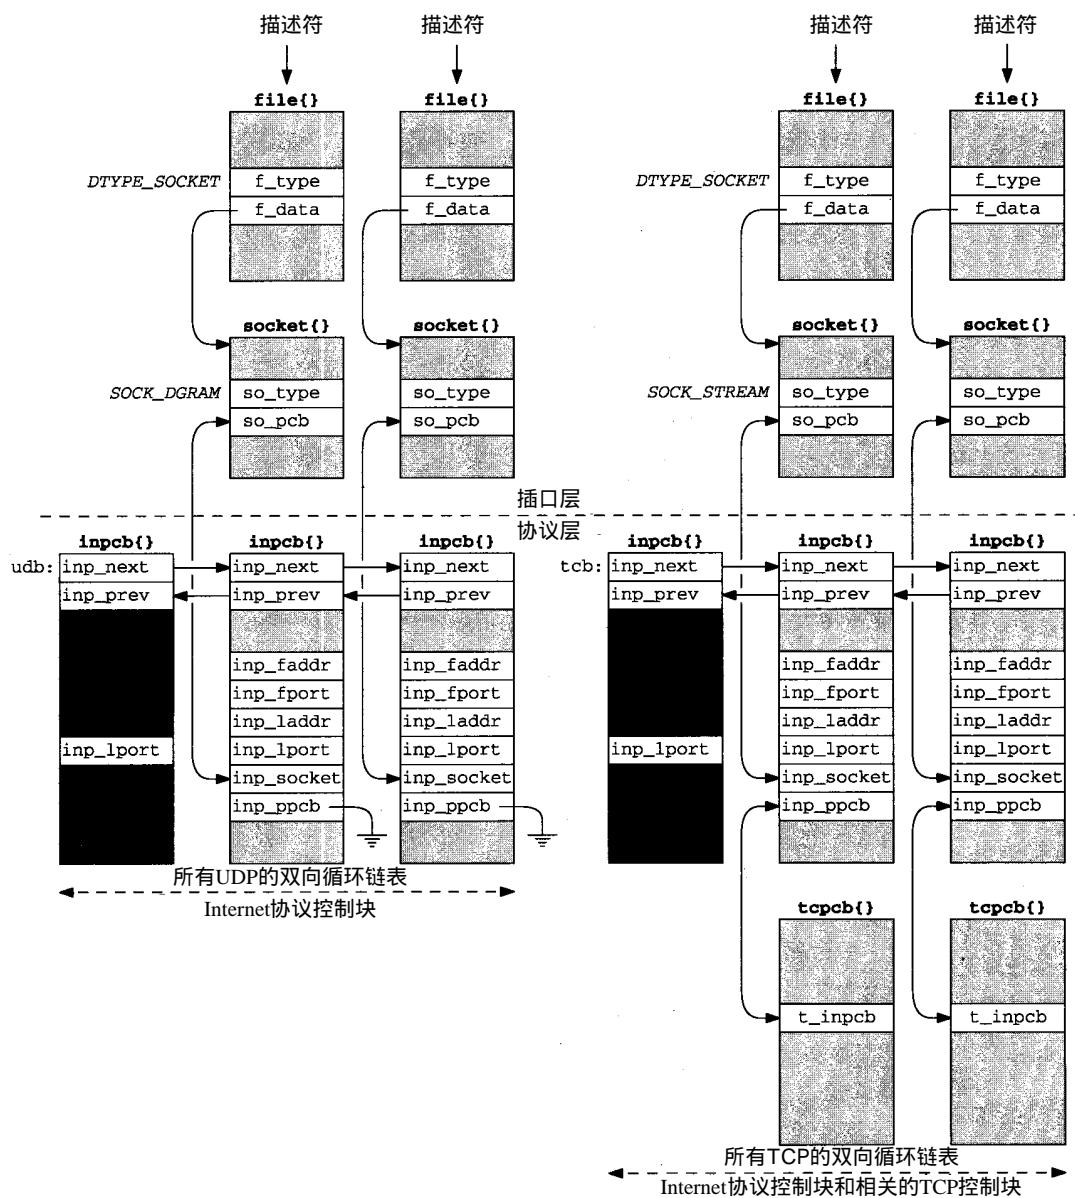


图22-1 Internet协议控制块以及其他结构之间的关系

22.2 代码介绍

所有PCB函数都在一个C文件和一个包含定义的头文件中，如图 22-2所示。

文 件	描 述
<code>netinet/in_pcbs.h</code>	<code>in_pcbs</code> 结构定义
<code>netinet/in_pcbs.c</code>	PCB函数

图22-2 本章中讨论的文件

22.2.1 全局变量

本章只引入一个全局变量，如图 22-3 所示。

变 量	数据类型	描 述
zeroin_addr	struct in_addr	32 bit全零IP地址

图22-3 本章中引入的全局变量

22.2.2 统计量

Internet PCB 和 TCP PCB 都是内核的 malloc 函数分配的 M_PCB 类型。这只是内核分配的大约 60 种不同类型内存的一种。例如，mbuf 的类型是 M_BUF，socket 结构分配的类型是 M_SOCKET。

因为内核保持所分配的不同类型内存缓存的计数器，所以维护着几个 PCB 数量的统计量。vmstat -m 命令显示内核的内存分配统计信息，netstat -m 命令显示的是 mbuf 分配统计信息。

22.3 inpcb 的结构

图 22-4 是 inpcb 结构的定义。这不是一个大结构，只占 84 个字节。

```
42 struct inpcb {
43     struct inpcb *inp_next, *inp_prev; /* doubly linked list */
44     struct inpcb *inp_head;           /* pointer back to chain of inpcb's for
45                                         this protocol */
46     struct in_addr inp_faddr;        /* foreign IP address */
47     u_short inp_fport;              /* foreign port# */
48     struct in_addr inp_laddr;        /* local IP address */
49     u_short inp_lport;              /* local port# */
50     struct socket *inp_socket;      /* back pointer to socket */
51     caddr_t inp_ppcb;              /* pointer to per-protocol PCB */
52     struct route inp_route;         /* placeholder for routing entry */
53     int     inp_flags;              /* generic IP/datagram flags */
54     struct ip inp_ip;              /* header prototype; should have more */
55     struct mbuf *inp_options;       /* IP options */
56     struct ip_moptions *inp_moptions; /* IP multicast options */
57 };

```

in_pcob.h

图 22-4 inpcb 结构

43-45 inp_next 和 inp_prev 为 UDP 和 TCP 的所有 PCB 形成一个双向链表。另外，每个 PCB 都有一个指向协议链表表头的指针 (inp_head)。对 UDP 表上的 PCB，inp_head 总是指向 ubd(图 22-1)；对 TCP 表上的 PCB，这个指针总是指向 tcb。

46-49 下面四个成员：inp_faddr、inp_fport、inp_laddr 和 inp_lport，包含了这个 IP 端结点的插口对：外部 IP 地址和端口号，以及本地 IP 地址和端口号。PCB 中以网络字节序而不是以主机字节序维护这四个值。

运输层的 TCP 和 UDP 都使用 Internet PCB。尽管在这个结构里保存本地和外部 IP 地址很有意义，但端口号并不属于这里。端口号及其大小的定义是由各运输层协议

指定的，不同的运输层可以指定不同的值。[Partridge 1987] 提出了这个问题，其中版本1的RDP采用8 bit的端口号，需要用8 bit的端口号重新实现几个标准内核程序。版本2的RDP [Partridge和Hinden 1990] 采用16 bit端口号。实际上，端口号属于运输层专用控制块，例如TCP的tcpcb。可能会要求采用一种新的 UDP专用的PCB。尽管这个方案可行，但却可能使我们马上要讨论的几个程序复杂化。

50-51 `inp_socket`是一个指向该PCB的socket结构的指针，`inp_ppcb`是一个指针，它指向这个PCB的可选运输层专用控制块。我们在图22-1中看到，`inp_ppcb`和TCP一起指向对应的tcpcb，但UDP不用它。`socket`和`inpcb`之间的链接是双向的，因为有时内核从插口层开始，需要对应的Internet PCB(如用户输出)，而有时内核从PCB开始，需要找到对应的socket结构(如处理收到的IP数据报)。

52 如果IP有一个到外部地址的路由，则它被保存在`ipp_route`入口处。我们将看到，当收到一个ICMP重定向报文时，将扫描所有Internet PCB，找到那些外部IP地址与重定向IP地址匹配的PCB，将其`ipp_route`入口标记成无效。当再次将该PCB用于输出时，迫使IP重新找一条到该外部地址的新路由。

53 `inp_flags`成员中存放了几个标志。图22-5显示了各标志。

<code>inp_flags</code>	描述
<code>INP_HDRINCL</code>	进程提供整个IP首部(只有原始插口)
<code>INP_RECVOPTS</code>	把到达IP选项作为控制信息接收(只有UDP，还没有实现)
<code>INP_RECVRETOPTS</code>	把回答的IP选项作为控制信息接收(只有UDP，还没有实现)
<code>INP_RECVDSTADDR</code>	把IP目的地址作为控制信息接收(只有UDP)
<code>INP_CONTROLOPTS</code>	<code>INP_RECVOPTS / INP_RECVRETOPTS / INP_RECVDSTADDR</code>

图22-5 `inp_flags` 值

54 PCB中维护一个IP首部的备份，但它只使用其中的两个成员，TOS和TTL。TOS被初始化为0(普通业务)，TTL被运输层初始化。我们将看到，TCP和UDP都把TTL的默认值设为64。进程可以用`IP_TOS`或`IP_TTL`插口选项改变这些默认值，新的值记录在`inpcb-inp_ip`结构中。以后，TCP和UDP在发送IP数据报时，却把该结构用作原型IP首部。

55-56 进程也可以用`IP_OPTIONS`插口选项设置外出数据报的IP选项。函数`ip_pcbopts`把调用方选项的备份存放在一个mbuf中，`inp_options`成员是一个指向该mbuf的指针。每次TCP和UDP调用`ip_output`函数时，就把一个指向这些IP首部的指针传给IP，IP将其插到出去的IP数据报中。类似地，`inp_moptions`成员是一个指向用户IP多播选项备份的指针。

22.4 `in_pcbaalloc`和`in_pcbadetach`函数

在创建插口时，TCP、UDP和原始IP会分配一个Internet PCB。系统调用`socket`发布`PRU_ATTACH`请求。在UDP情况下，我们将在图23-33中看到，产生的调用是

```
struct socket *so;
int error;

error = in_pcbaalloc(so, &udb);
```

图22-6是`in_pcbaalloc`函数。

1. 分配PCB，初始化为零

```

36 int
37 in_pcalloc(so, head)
38 struct socket *so;
39 struct inpcb *head;
40 {
41     struct inpcb *inp;
42     MALLOC(inp, struct inpcb *, sizeof(*inp), M_PCB, M_WAITOK);
43     if (inp == NULL)
44         return (ENOBUFS);
45     bzero((caddr_t) inp, sizeof(*inp));
46     inp->inp_head = head;
47     inp->inp_socket = so;
48     insque(inp, head);
49     so->so_pcb = (caddr_t) inp;
50     return (0);
51 }

```

*in_pcalloc.c*图22-6 *in_pcalloc* 函数：分配一个Internet PCB

36-45 *in_pcalloc* 使用宏 *MALLOC* 调用内核的内存分配器。因为这些 PCB 总是作为系统调用的结果分配的，所以总能等到一个。

Net/2和早期的伯克利版本把 Internet PCB 和 TCP PCB 都保存在 mbuf 中。它们的大小分别是 80 和 108 字节。Net/3 版本中的大小变成了 84 和 140 字节，所以 TCP 控制块不再适合存放在 mbuf 中。Net/3 使用内核的内存分配器而不是 mbuf 分配两种控制块。

细心的读者会注意到图 2-6 的例子中，为 PCB 分配了 17 个 mbuf，而我们刚刚讲到 Net/3 不再用 mbuf 存放 Internet PCB 和 TCP PCB。但是，Net/3 的确用 mbuf 存放 Unix 域的 PCB，这就是计数器所指的。*netstat* 输出的 mbuf 统计信息是针对内核为所有协议族分配的 mbuf，而不仅仅是 Internet 协议族。

bzero 把 PCB 设成 0。这非常重要，因为 PCB 中的 IP 地址和端口号必须被初始化成 0。

```

252 int
253 in_pcbdetach(inp)
254 struct inpcb *inp;
255 {
256     struct socket *so = inp->inp_socket;
257     so->so_pcb = 0;
258     soffree(so);
259     if (inp->inp_options)
260         (void) m_free(inp->inp_options);
261     if (inp->inp_route.ro_rt)
262         rtfree(inp->inp_route.ro_rt);
263     ip_freemoptions(inp->inp_moptions);
264     remque(inp);
265     FREE(inp, M_PCB);
266 }

```

*in_pcbdetach.c*图22-7 *in_pcbdetach* 函数：释放一个Internet PCB

2. 把结构链接起来

46-49 *in_head* 成员指向协议的 PCB 表头(udb 或 tcp)，*inp_socket* 成员指向 *socket* 结

构，新的PCB结构被加到协议的双向链表上(`insque`)，`socket`结构指向该PCB。`insque`函数把新的PCB放到协议表的表头里。

在发布PRU_DETACH请求后，释放一个Internet PCB，这是在关闭插口时发生的。图22-7显示了`in_pcbo_detach`函数，最后将调用它。

252-263 `socket`结构中的PCB指针被设成0，`sofree`释放该结构。如果给这个PCB分配的是一个有IP选项的mbuf，则由`m_free`将其释放。如果该PCB中有一个路由，则由`rtfree`将其释放。所有多播选项都由`ip_freeoptions`释放。

264-265 `remque`把该PCB从协议的双向链表中移走，该PCB使用的内存被返回给内核。

22.5 绑定、连接和分用

在研究绑定插口、连接插口和分用进入的数据报的内核函数之前，我们先来看一下内核对这些动作施加的限制规则。

1. 绑定本地IP地址和端口号

图22-8是进程在调用`bind`时可以指定的本地IP地址和本地端口号的六种组合。

前三行通常是服务器的——它们绑定某个特定端口，称为服务器的知名端口(well-known port)，客户都知道这些端口的值。后三行通常是客户的——它们不考虑本地的端口，称为临时端口(ephemeral port)，只要它在客户主机上是唯一的。

大多数服务器和客户在调用`bind`时，都指定通配IP地址。如图22-8所示，在第3行和第6行中，用*表示。

本地IP地址	本地端口	描述
单播或广播 多播 *	非零	一个本地接口，特定端口
	非零	一个本地多播组，特定端口
	非零	任何本地接口或多播组，特定端口
单播或广播 多播 *	0	一个本地接口，内核选择端口
	0	一个多播组，内核选择端口
	0	任何本地接口，内核选择端口

图22-8 `bind`的本地IP地址和本地端口号的组合

如果服务器把某个特定IP地址绑定到某个插口上(也就是说，不是通配地址)，那么进入的IP数据报中，只有那些以该特定IP地址作为目的IP地址的IP数据报——不管是单播、广播或多播——都被交付给该进程。自然地，当进程把某个特定单播或广播IP地址绑定到某个插口上时，内核验证该IP地址与一个本地接口对应。

尽管可能，但很少出现客户程序绑定某个特定IP地址的情况(图22-8中的第4行和第5行)。通常客户绑定通配IP地址(图22-8中的最后一行)，让内核根据自己选择的到服务器的路由来选择外出的接口。

图22-8没有显示如果客户程序试图绑定一个已经被其他插口使用的本地端口号时会发生什么情况。默认情况下，如果一个端口已经被使用，进程是不能绑定它的。如果发生这种情况，则返回EADDRINUSE差错(地址正在被使用)。正在被使用(in use)的定义很简单，就是只要存在一个PCB，就把该端口作为它的本地端口。“正在被使用”的概念是相对于绑定协议的：TCP或UDP，因为TCP端口号与UDP端口号无关。

Net/3允许进程指定以下两个插口选项来改变这个默认行为：

SO_REUSEADDR 允许进程绑定一个正在被使用的端口号，但被绑定的 IP地址(包括通配地址)必须没有被绑定到同一个端口。

例如，如果连到的接口的 IP地址是140.252.1.29，则一个插口可以被绑定到140.252.1.29，端口5555；另一个插口可绑定到127.0.0.1，端口5555；还有一个插口可以绑定到通配IP地址，端口5555。在第二种和第三种情况下调用bind之前，必须先调用setsockopt，设置SO_REUSEADDR选项。

SO_REUSEPORT 允许进程重用IP地址和端口号，但是包括第一个在内的各个IP地址和端口号，必须指定这个插口选项。和SO_REUSEADDR一样，第一次绑定端口号时要指定插口选项。

例如，如果连到的接口具有140.252.1.29的IP地址，并且某个插口绑定到140.252.1.29，端口6666，并指定SO_REUSEPORT插口选项，则另一个插口也可以指定同一个插口选项，并绑定140.252.1.29，端口6666。

本节的后面将讨论在后一个例子中，当到达一个目的地址是140.252.1.29，目的端口是6666的IP数据报时，会发生什么情况。因为这两个插口都被绑定到该端结点上。

SO_REUSEPORT是Net/3新加上的，在4.4BSD中是为支持多播而引入的。在这个版本之前，两个插口是不可能绑定到同一个IP地址和同一个端口号的。

不幸的是，SO_REUSEPORT不是原来的标准多播源程序的内容，所以对它的支持并不广泛。其他支持多播的系统，如Solaris 2.x，让进程指定SO_REUSEADDR来表明允许把多个端口绑定到同一IP地址和相同的端口号。

2. 连接一个UDP插口

我们通常把connect系统调用和TCP客户联系起来，但是UDP客户或UDP服务器也可能调用connect，为插口指定外部IP地址和外部端口号。这就限制插口必须只与某个特定对方交换UDP数据报。

当连接UDP插口时，会有一个副作用：本地IP地址，如果在调用bind时没有指定，会自动被connect设置。它被设成由IP选路指定对方所选择的本地接口地址。

图22-9显示了UDP插口的三种不同的状态，以及函数为终止各状态调用的伪代码。

本地插口	外部插口	描述
localIP.lport	foreignIP.fport	限制到一个对方： socket(), bind(*.lport), connect(foreignIP, fport) socket(), bind(localIP, lport), connect(foreignIP, fport)
localIP.lport	*.*	限制在本地接口上到达的数据报：localIP socket(), bind(localIP, lport)
*.lport	*.*	接收所有发到lport的数据报： socket(), bind(*, lport)

图22-9 UDP插口的本地和外部IP地址和端口号规范

前三个状态叫做已连接的UDP插口(connected UDP socket)，后两个叫做未连接的UDP插口(unconnected UDP socket)。两个没有连接上的UDP插口的区别在于，第一个具有一个完全

指定的本地地址，而第二个具有一个通配本地IP地址。

3. 分用TCP接收的IP数据报

图22-10显示了主机sun上的三个Telnet服务器的状态。前两个插口处于LISTEN状态，等待进入的连接请求，第三个连接到IP地址是140.252.1.11的主机上的端口1500。第一个监听插口处理在接口140.252.1.29上到达的连接请求，第二个监听插口将处理所有其他接口（因为它的本地IP地址是通配地址）。

本地地址	本地端口	外部地址	外部端口	TCP状态
140.252.1.29	23	*	*	LISTEN
*	23	*	*	LISTEN
140.252.1.29	23	140.252.1.11	1500	ESTABLISHED

图22-10 本地端口是23的三个TCP插口

两个具有未指定的外部IP地址和端口号的监听插口都显示了出来，因为插口API不允许TCP服务器限制任何一个值。TCP服务器必须accept客户的连接，并在连接建立完成之后（也就是说，当TCP的三次握手结束之后）被告知客户的IP地址和端口号。只有到这个时候，如果服务器不喜欢客户的IP地址和端口号，才能关闭连接。这并不是对TCP要求的特性，这只是插口API通常的工作方式。

当TCP收到一个目的端口是23的报文段时，它调用in_pcblayout，搜索它的整个Internet PCB表，找到一个匹配。马上我们会研究这个函数，将看到它有优先权，因为它的通配匹配(wildcard match)数最少。为了确定通配匹配数，我们只考虑本地和外部的IP地址，不考虑外部端口号。本地端口号必须匹配，否则我们甚至不考虑PCB。通配匹配数可以是0、1(本地IP地址或外部IP地址)或2(本地和外部IP地址)。

例如，假定到达报文段来自140.252.1.11，端口1500，目的地是140.252.1.29，端口23。图22-11是图22-10中三个插口的通配匹配数。

本地地址	本地端口	外部地址	外部端口	TCP状态	通配匹配数
140.252.1.29	23	*	*	LISTEN	1
*	23	*	*	LISTEN	2
140.252.1.29	23	140.252.1.11	1500	ESTABLISHED	0

图22-11 从{140.252.1.11, 1500}到{140.252.1.29, 23}的到达报文段

第一个插口匹配这四个值，但有一个通配匹配(外部IP地址)。第二个插口也和到达报文段匹配，但有两个通配匹配(本地和外部IP地址)。第三个插口是一个没有通配匹配的完全匹配。Net/3使用第三个插口，它具有最小通配匹配数。

继续这个例子，假定到达报文段来自140.252.1.11，端口1501，目的地是140.252.1.29，端口23。图22-12显示了通配匹配数。

本地地址	本地端口	外部地址	外部端口	TCP状态	通配匹配数
140.252.1.29	23	*	*	LISTEN	1
*	23	*	*	LISTEN	2
140.252.1.29	23	140.252.1.11	1500	ESTABLISHED	

图22-12 从{140.252.1.11, 1501}到{140.252.1.29, 23}的到达报文段

第一个插口匹配有一个通配匹配；第二个插口匹配有两个通配匹配；第三个插口根本不匹配，因为外部端口号不相等（只有当PCB中的外部IP地址不是通配地址时，才比较外部端口号）。所以选择第一个插口。

在这两个例子中，我们没有提到到达TCP报文段的类型：假定图22-11中的报文段包含数据或对一个已经建立的连接的确认，因为它是发送到一个已经建立的插口上的。我们还假定，图22-12中的报文段是一个到达的连接请求（一个SYN），因为它是发送给一个正在监听的插口的。但是`in_pcblockup`的分用代码并不关心这些。如果TCP报文段对交付的插口来说是错误的类型，我们将在后面看到，TCP会处理这种情况。现在，重要的是，分用代码只把IP数据报中的源和目的插口对的值与PCB中的值进行比较。

4. 分用UDP接收的IP数据报

UDP数据报的交付比我们刚才研究的TCP的例子要复杂得多，因为可以把UDP数据报发送到一个广播或多播地址。因为Net/3（以及大多数支持多播的系统）允许多个插口有相同的本地IP地址和端口，所以如何处理多个接收方的情况呢？Net/3的规则是：

1) 把目的地是广播IP地址或多播IP地址的到达UDP数据报交付给所有匹配的插口。这里没有“最好的”匹配的概念（也就是具有最小通配匹配数的匹配）。

2) 把目的地是单播IP地址的到达UDP数据报只交付给一个匹配的插口，就是具有最小通配匹配数的插口。如果有多个插口具有相同的“最小”通配匹配数，那么具体由哪个插口来接收到达数据报依赖于不同的实现。

图22-13显示了四个我们将在后面例子中使用的UDP插口。要使四个UDP插口具有相同的本地端口号需要使用`SO_REUSEADDR`或`SO_REUSEPORT`。前两个插口已经被连接到一个外部IP地址和端口号，后面两个没有任何连接。

本地地址	本地端口	外部地址	外部端口	说 明
140.252.1.29	577	140.252.1.11	1500	已连接，本地IP = 单播
140.252.13.63	577	140.252.13.35	1500	已连接，本地IP = 广播
140.252.13.63	577	*	*	未连接，本地IP = 广播
*	577	*	*	未连接，本地IP = 通配地址

图22-13 四个本地端口为577的UDP插口

考虑目的地是140.252.13.63（位于子网140.252.13上的广播地址），端口577，来自140.252.13.34，端口1500。图22-14显示它被交付给第三和第四个插口。

本地地址	本地端口	外部地址	外部端口	交 付？
140.252.1.29	577	140.252.1.11	1500	不，本地和外部IP不匹配
140.252.13.63	577	140.252.13.35	1500	不，外部IP不匹配
140.252.13.63	577	*	*	交付
*	577	*	*	交付

图22-14 接收从{140.252.13.34, 1500}到{140.252.13.63, 577}的数据报

广播数据报不交付给第一个插口，因为本地IP地址和目的IP地址不匹配，外部IP地址和源IP地址也不匹配。也不把它交付给第二个插口，因为外部IP地址和源IP地址不匹配。

对于下一个例子，考虑目的地是140.252.129（一个单播地址），端口577，来自140.252.1.111，

端口1500。图22-15显示了把该数据报交付给哪个端口。

本地地址	本地端口	外部地址	外部端口	交 付 ?
140.252.1.29	577	140.252.1.11	1500	交付 , 0个通配匹配
140.252.13.63	577	140.252.13.35	1500	不 , 本地和外部IP不匹配
140.252.13.63	577	*	*	不 , 本地IP不匹配
*	577	*	*	不 , 2个通配匹配

图22-15 接收从{140.252.1.11, 1500}到{140.252.1.29, 577}的数据报

该数据报和第一个插口匹配，且没有通配匹配；也和第四个插口匹配，但有两个通配匹配。所以，它被交付给第一个插口，最好的匹配。

22.6 in_pcbl lookup函数

in_pcbl lookup函数有几个作用：

- 1) 当TCP或UDP收到一个IP数据报时，in_pcbl lookup扫描协议的Internet PCB表，寻找一个匹配的PCB，来接收该数据报。这是运输层对收到数据报的分用。
- 2) 当进程执行bind系统调用，为某个插口分配一个本地IP地址和本地端口号时，协议调用in_pcbbind，验证请求的本地地址对没有被使用。
- 3) 当进程执行bind系统调用，请求给它的插口分配一个临时端口号时，内核选了一个临时端口，并调用in_pcbbind检查该端口是否正在被使用。如果正在被使用，就试下一个端口号，以此类推，直到找到一个没有被使用的端口号。
- 4) 当进程显式或隐式地执行connect系统调用时，in_pcbbind验证请求的插口对是唯一的(当在一个没有连接上的插口上发送一个UDP数据报时，会隐式地调用connect，我们将在第23章看到这种情况)。

在第2种、第3种和第4种情况下，in_pcbbind调用in_pcbl lookup。两个选项使该函数的逻辑显得有些混乱。首先，进程可以指定SO_REUSEADDR或SO_REUSEPORT插口选项，表明允许复制本地地址。

其次，有时通配匹配也是允许的(例如，一个到达UDP数据报可以和一个自己的本地IP地址有通配符的PCB匹配，意味着该插口将接收在任何本地接口上到达的UDP数据报)，而其他情况下，一个通配匹配是禁止的(例如，当连接到一个外部IP地址和端口号时)。

在原始的标准IP多播代码中，出现了这样的注释“in_pcbl lookup的逻辑比较模糊，也没有一点说明……”。形容词模糊比较保守。

公开的IP多播码是BSD / 386的，是由Craig Leres从4.4BSD派生而来的。他修改了该函数过载的语义，只对上面的第1种情况使用in_pcbl lookup。第2种和第4种情况由一个新函数in_pcbl conflict处理。情况3由新函数in_uniqueport处理。把原来的功能分成几个独立的函数就显得更清楚了，但在我们描述的Net/3版本中，整个逻辑还是结合在一个函数in_pcbl lookup中。

图22-16显示了in_pcbl lookup函数。

该函数从协议的PCB表的表头开始，并可能会遍历表中的每个PCB。变量match记录了到目前为止最佳匹配的指针入口，matchwild记录在该匹配中的通配匹配数。后者被初始化

成3，比可能遇到的最大通配匹配数还大(任何大于2的值都可以)。每次循环时，wildcard从0开始，计数每个PCB的通配匹配数。

1. 比较本地端口号

第一个比较的是本地端口号。如果PCB的本地端口和lport参数不匹配，则忽略该PCB。

```

405 struct inpcb *
406 in_pcblockup(head, faddr, fport_arg, laddr, lport_arg, flags)
407 struct inpcb *head;
408 struct in_addr faddr, laddr;
409 u_int    fport_arg, lport_arg;
410 int     flags;
411 {
412     struct inpcb *inp, *match = 0;
413     int      matchwild = 3, wildcard;
414     u_short fport = fport_arg, lport = lport_arg;

415     for (inp = head->inp_next; inp != head; inp = inp->inp_next) {
416         if (inp->inp_lport != lport)
417             continue;           /* ignore if local ports are unequal */

418         wildcard = 0;

419         if (inp->inp_laddr.s_addr != INADDR_ANY) {
420             if (laddr.s_addr == INADDR_ANY)
421                 wildcard++;
422             else if (inp->inp_laddr.s_addr != laddr.s_addr)
423                 continue;
424         } else {
425             if (laddr.s_addr != INADDR_ANY)
426                 wildcard++;
427         }

428         if (inp->inp_faddr.s_addr != INADDR_ANY) {
429             if (faddr.s_addr == INADDR_ANY)
430                 wildcard++;
431             else if (inp->inp_faddr.s_addr != faddr.s_addr ||
432                      inp->inp_fport != fport)
433                 continue;
434         } else {
435             if (faddr.s_addr != INADDR_ANY)
436                 wildcard++;
437         }

438         if (wildcard && (flags & INPLOOKUP_WILDCARD) == 0)
439             continue;           /* wildcard match not allowed */

440         if (wildcard < matchwild) {
441             match = inp;
442             matchwild = wildcard;
443             if (matchwild == 0)
444                 break;           /* exact match, all done */
445         }
446     }
447     return (match);
448 }
```

in_pcblockup

图22-16 *in_pcblockup* 函数：搜索所有PCB寻找匹配

2. 比较本地地址

419 - 427 `in_pcblockup` 比较PCB内的本地地址和`laddr`参数。如果有一个是通配地址，另一个不是，则`wildcard`计数器加1。如果都不是通配地址，则它们必须一样；否则忽略这个PCB。如果都是通配地址，则什么也不改变：它们不可比，也不增加`wildcard`计数器。图22-17对四种不同的情况做了小结。

PCB本地IP	<code>laddr</code> 参数	描 述
不是*	*	<code>wildcard++</code>
不是*	不是*	比较IP地址，如果不相等，则略过PCB
*	*	不能比较
*	不是*	<code>wildcard++</code>

图22-17 `in_pcblockup` 做的四种IP地址比较

3. 比较外部地址和外部端口号

428 - 437 这几行完成与我们刚才讲的同样的检查，但是用外部地址而不是本地地址。而且，如果两个外部地址都不是通配地址，则不仅两个IP地址必须相等，而且两个外部端口也必须相等。图22-18对外部IP地址的比较作了总结。

PCB外部IP	<code>faddr</code> 参数	描 述
不是*	*	<code>wildcard++</code>
不是*	不是*	比较IP地址和端口，如果不相等，则略过PCB
*	*	不能比较
*	不是*	<code>wildcard++</code>

图22-18 `in_pcblockup` 做的四种外部IP地址比较

可以对图22-18中的第二行进行另外的外部端口号比较，因为一个PCB不可能具有非通配外部地址，且外部端口号为0。这个限制是由`connect`加上的，我们马上就会看到，该函数要求一个非通配外部IP地址和一个非零外部端口。但是，也可能，并且通常都是具有一个通配本地地址和一个非零本地端口。我们在图22-10和图22-13看到过这种情况。

4. 检查是否允许通配匹配

438 - 439 参数`flags`可以被设成`INPLOOKUP_WILDCARD`，意味着允许匹配中包含通配匹配。如果在匹配中有通配匹配(`wildcard`非零)，并且调用方没有指定这个标志位，则忽略这个PCB。当TCP和UDP调用这个函数分用一个到达数据报时，总是把`INPLOOKUP_WILDCARD`置位，因为允许通配匹配(记住我们用图22-10和图22-13所作的例子)。但是，当这个函数作为`connect`系统调用的一部分而调用时，为了验证一个插口对没有被使用，把`flags`参数设成0。

5. 记录最佳匹配，如果找到确切匹配，则返回

440 - 447 这些语句记录到目前为止找到的最佳匹配。重复一下，最佳匹配是具有最小通配匹配数的匹配。如果一个匹配有一个或两个通配匹配，则记录该匹配，循环继续。但是，如果找到一个确切的匹配(`wildcard`是0)，则循环终止，返回一个指向该确切匹配PCB的指针。

例子——分用收到的TCP报文段

图22-19取自我们在图22-11中的TCP的例子。假定`in_pcblockup`正在分用一个从140.252.1.11即端口1500到140.252.1.29即端口23的数据报。还假定PCB的顺序是图中行的顺序。

`laddr`是目的IP地址，`lport`是目的TCP端口，`faddr`是源IP地址，`fport`是源TCP端口。

PCB值				wildcard
本地地址	本地端口	外部地址	外部端口	
140.252.1.29	23	*	*	1
*	23	*	*	2
140.252.1.29	23	140.252.1.11	1500	0

图22-19 `laddr = 140.252.1.29, lport= 23, faddr = 140.252.1.11, fport= 1500`

当把第一行和到达报文段比较时，`wildcard`是1(外部IP地址)，`flags`被设成`INPLOOKUP_WILDCARD`，所以把`match`设成指向该PCB，`matchwild`设为1。因为还没有找到确切的匹配，所以循环继续。下一次循环中，`wildcard`是2(本地和外部IP地址)，因为比`matchwild`大，所以不记录该入口，循环继续。再次循环时，`wildcard`是0，比`matchwild(1)`小，所以把这个入口记录在`match`中。因为已经找到了一个确切的地址，所以终止循环，把指向该PCB的指针返回给调用方。

如果TCP和UDP只用`in_pcblockup`来分用到达数据报，就可以对它进行简化。首先，没有必要检查`faddr`或`laddr`是否是通配地址，因为它们是收到数据报的源和目的IP地址。参数`flags`以及与相应的检测也可以不要，因为允许通配匹配。

这一节讨论了`in_pcblockup`函数的机制。我们在讨论`in_pcbbind`和`in_pcconnect`如何调用这个函数后，将继续回来讨论它的意义。

22.7 `in_pcbbind`函数

下一个函数`in_pcbbind`，把一个本地地址和端口号绑定到一个插口上。从五个函数中调用它：

- 1) `bind`为某个TCP插口调用(通常绑定到服务器的一个知名端口上)；
- 2) `bind`为某个UDP插口调用(绑定到服务器的一个知名端口上，或者绑定到客户插口的一个临时端口上)；
- 3) `connect`为某个TCP插口调用，如果该插口还没有绑定到一个非零端口上(对TCP客户来说，这是一种典型情况)；
- 4) `listen`为某个TCP插口调用，如果该插口还没有绑定到一个非零端口(这很少见，因为是TCP服务器调用`listen`，TCP服务器通常绑定到一个知名端口上，而不是临时端口)；
- 5) 从`in_pcconnect`(22.8节)调用，如果本地IP地址和本地端口号被置位(当为一个UDP插口调用`connect`，或为一个未连接UDP插口调用`sendto`时，这种情况比较典型)。

在第3种、第4种和第5种情形下，把一个临时端口号绑定到该插口上，不改变本地IP地址(在它已经被置位的情况下)。

称情形1和情形2为显式绑定(explicit bind)，情形3、4和5为隐式绑定(implicit bind)。我们也注意到，尽管在情形2时，服务器绑定到一个知名端口是很正常的，但那些用远程过程调用(RPC)启动的服务器也常常绑定到临时端口上，然后用其他程序注册它们的临时端口，该程序维护在该服务器的RPC程序号与其临时端口之间的映射(例如，卷1的29.4节描述的Sun端口映射器)。

我们分三部分显示 in_pcbbind 函数。图22-20是第一部分。

```

52 int
53 in_pcbbind(inp, nam)
54 struct inpcb *inp;
55 struct mbuf *nam;
56 {
57     struct socket *so = inp->inp_socket;
58     struct inpcb *head = inp->inp_head;
59     struct sockaddr_in *sin;
60     struct proc *p = curproc; /* XXX */
61     u_short lport = 0;
62     int      wild = 0, reuseport = (so->so_options & SO_REUSEPORT);
63     int      error;

64     if (in_ifaddr == 0)
65         return (EADDRNOTAVAIL);
66     if (inp->inp_lport || inp->inp_laddr.s_addr != INADDR_ANY)
67         return (EINVAL);

68     if ((so->so_options & (SO_REUSEADDR | SO_REUSEPORT)) == 0 &&
69         ((so->so_proto->pr_flags & PR_CONNREQUIRED) == 0 || 
70          (so->so_options & SO_ACCEPTCONN) == 0))
71         wild = INPLLOOKUP_WILDCARD;

```

in_pcbbind

图22-20 in_pcbbind 函数：绑定本地地址和端口号

64-67 前两个测试验证至少有一个接口已经被分配了一个 IP地址，且该插口还没有绑定。不能两次绑定一个插口。

68-71 这个if语句有点令人疑问。总的结果是如果 SO_REUSEADDR和SO_REUSEPORT都没有置位，就把wild设置成 INPLLOOKUP_WILDCARD。

对UDP来说，第二个测试为真，因为 PR_CONNREQUIRED对无连接插口为假，对面向连接的插口为真。

第三个测试就是疑问所在 [Torek 1992]。插口标志 SO_ACCEPTCONN只被系统调用 listen置位(15.9节)，该值只对面向连接的服务器有效。在正常情况下，一个 TCP服务器调用socket、bind，然后调用listen。因而，当 in_pcbbind被bind调用时，就清除了这个插口标志位。即使进程调用完 socket后就调用 listen，而不调用 bind，TCP的PRU_LISTEN请求还是调用 in_pcbbind，在插口层设置SO_ACCEPTCONN标志位之前，给插口分配一个临时端口。这意味着 if语句中的第三个测试，测试 SO_ACCEPTCONN是否没有置位，总是为真。因此 if语句等价于

```

if ((so->so_options & (SO_REUSEADDR|SO_REUSEPORT)) == 0 &&
    ((so->so_proto->pr_flags & PR_CONNREQUIRED)==0 || 1)
    wild = INPLLOOKUP_WILDCARD;

```

因为任何与1作逻辑或运算的结果都为真，所以这等价于

```

if ((so->so_options & (SO_REUSEADDR|SO_REUSEPORT)) == 0 )
    wild = INPLLOOKUP_WILDCARD;

```

这样简单且容易理解：如果任何一个 REUSE插口选项被置位， wild就是0。如果没有 REUSE选项被置位，则把 wild设成 INPLLOOKUP_WILDCARD。换言之，当函数在后面调用 in_pcblockup时，只有在没有REUSE选项处于开状态时，才允许通配匹配。

`in_pcbbind` 的下一部分，显示在图 22-22 中，函数处理可选 `nam` 参数。

72-75 只有当进程显式调用 `bind` 时，`nam` 参数才是一个非零指针。对一个隐式的绑定（`connect`、`listen` 或 `in_pcbbind` 的副作用，本节开始的情形 3、4 和 5），`nam` 是一个空指针。当指定了该参数时，它是一个含有 `sockaddr_in` 结构的 mbuf。图 22-21 显示了非空参数 `nam` 的四种情形。

nam 参数		PCB 成员被设成：		说 明
localIP	lport	inp_laddr	inp_iport	
不是 *	0	localIP	临时端口	<code>localIP</code> 必须是本地接口 交付给 <code>in_pcbl lookup</code>
不是 *	非零	localIP	<code>lport</code>	
*	0	*	临时端口	
*	非零	*	<code>lport</code>	交付给 <code>in_pcbl lookup</code>

图 22-21 `in_pcbbind` 的 `nam` 参数的四种情形

76-83 对正确的地址族的测试被注释掉了，但在函数 `in_pcbbind`（图 22-25）中执行了等价的测试。我们希望两者或者都有或者都没有。

85-94 Net/3 测试被绑定的 IP 地址是否是一个多播组。如果是，则 `SO_REUSEADDR` 选项被认为与 `SO_REUSEPORT` 等价。

95-99 否则，如果调用方绑定的本地地址不是通配地址，则 `ifa_ifwithaddr` 验证该地址与一个本地接口对应。

注释“`ye ch`”可能是因为插口地址结构中的端口号必须是 0，因为 `ifa_ifwithaddr` 对整个结构作二进制比较，而不仅仅比较 IP 地址。

这是进程在调用系统调用之前必须把插口地址结构全部置零的几种情况之一。

如果调用 `bind`，并且插口地址结构 (`sin_zero[8]`) 的最后 8 个字节非零，则 `ifa_ifwithaddr` 将找不到请求的接口，`in_pcbbind` 会返回一个错误。

100-105 当调用方绑定了一个非零端口时，也就是说，进程要绑定一个特殊端口号（图 22-21 中的第 2 种和第 4 种情形），就执行下一个 `if` 语句。如果请求的端口小于 1024(`IPPORT_RESERVED`)，则进程必须具有超级用户的优先权限。这不是 Internet 协议的一部分，而是伯克利的习惯。使用小于 1024 的端口号，我们称之为保留端口 (reserved port)，例如，`rcmd` 函数 [Stevens 1990] 使用的端口，`rlogin` 和 `rsh` 客户程序又调用该函数，作为服务器对它们身份认证的一部分。

106-109 然后调用函数 `in_pcbl lookup`（图 22-16），检测是否存在一个具有相同本地 IP 地址和本地端口号的 PCB。第二个参数是通配 IP 地址（外部 IP 地址），第三个参数是一个为 0 的端口号（外部端口号）。第二个参数的通配值导致 `in_pcbl lookup` 忽略该 PCB 的外部 IP 地址和外部端口——只把本地 IP 地址和本地端口号分别和 `sin->sin_addr` 及 `lport` 进行比较。我们前面提到，只有当所有 `REUSE` 插口选项都没有被设置时，才把 `wild` 设成 `INPLLOOKUP_WILDCARD`。

111 调用方的本地 IP 地址值存放在 PCB 中。如果调用方指定，它可以是通配地址。在这种情况下，由内核选择本地 IP 地址，但要等到晚些时候插口连接上时。这就是为什么说本地 IP 地址是根据外部 IP 地址，由 IP 路由选择决定。

in_pcbbind

```

72     if (nam) {
73         sin = mtod(nam, struct sockaddr_in *);
74         if (nam->m_len != sizeof(*sin))
75             return (EINVAL);
76 #ifdef notdef
77         /*
78          * We should check the family, but old programs
79          * incorrectly fail to initialize it.
80          */
81         if (sin->sin_family != AF_INET)
82             return (EAFNOSUPPORT);
83 #endif
84         lport = sin->sin_port; /* might be 0 */
85         if (IN_MULTICAST(ntohl(sin->sin_addr.s_addr))) {
86             /*
87              * Treat SO_REUSEADDR as SO_REUSEPORT for multicast;
88              * allow complete duplication of binding if
89              * SO_REUSEPORT is set, or if SO_REUSEADDR is set
90              * and a multicast address is bound on both
91              * new and duplicated sockets.
92              */
93             if (so->so_options & SO_REUSEADDR)
94                 reuseport = SO_REUSEADDR | SO_REUSEPORT;
95             } else if (sin->sin_addr.s_addr != INADDR_ANY) {
96                 sin->sin_port = 0; /* yeah... */
97                 if (ifa_ifwithaddr((struct sockaddr *) sin) == 0)
98                     return (EADDRNOTAVAIL);
99             }
100            if (lport) {
101                struct inpcb *t;
102                /* GROSS */
103                if (ntohs(lport) < IPPORT_RESERVED &&
104                    (error = suser(p->p_ucred, &p->p_acflag)))
105                    return (error);
106                t = in_pcblockup(head, zeroin_addr, 0,
107                                 sin->sin_addr, lport, wild);
108                if (t && (reuseport & t->inp_socket->so_options) == 0)
109                    return (EADDRINUSE);
110            }
111            inp->inp_laddr = sin->sin_addr; /* might be wildcard */
112        }

```

*in_pcbbind*图22-22 *in_pcbbind* 函数：处理可选的 nam 参数

当调用方显式绑定端口 0，或 nam 参数是一个空指针（隐式绑定）时，*in_pcbbind*的最后一部分处理分配一个临时端口。

113-122 这个协议（TCP或UDP）使用的下一个临时端口号被维护在该协议的 PCB 表的 head : tcb 或 udb。除了协议的 head PCB 中的 inp_next 和 inp_back 指针外，*inpcb* 结构另一个唯一被使用的元素是本地端口号。令人迷惑的是，这个本地端口号在 head PCB 中是主机字节序，而在表中其他 PCB 上，却是网络字节序！使用从 1024 开始的临时端口号（IPPORT_RESERVED），每次加 1，直到 5000(IPPORT_USERRESERVED)，然后又从 1024 重新开始循环。该循环一直执行到 *in_pcbbind* 找不到匹配为止。

1. SO_REUSEADDR 举例

让我们通过一些普通的例子，来了解一下 *in_pcbbind* 与 *in_pcblockup* 及两个 REUSE

插口选项之间的交互。

```

113     if (lport == 0)
114         do {
115             if (head->inp_lport++ < IPPORT_RESERVED ||
116                 head->inp_lport > IPPORT_USERRESERVED)
117                 head->inp_lport = IPPORT_RESERVED;
118             lport = htons(head->inp_lport);
119         } while (in_pcblockup(head,
120                               zeroin_addr, 0, inp->inp_laddr, lport, wild));
121     inp->inp_lport = lport;
122     return (0);
123 }

```

in_pcblockup

图22-23 *in_pcblockup* 函数：选择一个临时端口

- 1) TCP或UDP通常以调用 `socket` 和 `bind` 开始。假定一个调用 `bind` 的 TCP 服务器，指定了通配 IP 地址和它的非零知名端口 23(Telnet 服务器)。还假定该服务器还没有运行，进程没有设置 `SO_REUSEADDR` 插口选项。

`in_pcblockup` 把 `INPLLOOKUP_WILDCARD` 作为最后一个参数，调用 `in_pcblockup`。`in_pcblockup` 中的循环没有找到匹配的 PCB，就假定没有其他进程使用服务器的知名 TCP 端口，返回一个空指针。一切正常，`in_pcblockup`，返回 0。

- 2) 假定和上面相同的情况，但当再次试图启动服务器时，该服务器已经开始运行。

当调用 `in_pcblockup` 时，它发现了本地插口为 `{*, 23}` 的 PCB。因为 `wildcard` 计数器是 0，所以 `in_pcblockup` 返回指向这个入口的指针。因为 `reuseport` 是 0，所以 `in_pcblockup` 返回 `EADDRINUSE`。

- 3) 假定与上面相同的情况，但当第二次试图启动服务器时，指定了 `SO_REUSEADDR` 插口选项。

因为指定了这个插口选项，所以 `in_pcblockup` 在调用 `in_pcblockup` 时，最后一个参数为 0。但本地插口为 `{*, 23}` 的 PCB 仍然匹配，因为 `in_pcblockup` 无法比较两个通配地址(图22-17)，所以 `wildcard` 为 0。`in_pcblockup` 又返回 `EADDRINUSE`，避免启动两个具有相同本地插口的服务器例程，不管是否指定了 `SO_REUSEADDR`。

- 4) 假定有一个 Telnet 服务器已经以本地插口 `{*, 23}` 开始运行，而我们试图以另一个本地插口 `{140.252.13.35, 23}` 启动另一个服务器。

假定没有指定 `SO_REUSEADDR`，调用 `in_pcblockup` 时，最后一个参数为 `INPLLOOKUP_WILDCARD`。当它与含有 `*.23` 的 PCB 比较时，`wildcard` 计数器被设为 1。因为允许通配匹配，所以在扫描完所有 TCP PCB 后，把这个匹配作为最佳匹配。`in_pcblockup` 返回 `EADDRINUSE`。

- 5) 这个例子与上一个相同，但为第二个试图绑定本地插口 `{140.252.13.35, 23}` 的服务器指定了 `SO_REUSEADDR` 插口选项。

现在，`in_pcblockup` 的最后一个参数是 0，因为指定了插口选项。当与本地插口为 `{*, 23}` 的 PCB 比较时，`wildcard` 计数器为 1，但因为最后的 `flags` 参数是 0，所以跳过这个入口，不把它记作匹配。在比较完所有 TCP PCB 后，函数返回一个空指针，`in_pcblockup` 返回 0。

6) 假定当我们试图以本地插口{*, 23}启动第二个服务器时，第一个Telnet服务器以本地插口{140.252.13.35, 23}启动。与前面的例子一样，但这一次我们以相反的顺序启动服务器。

第一个服务器的启动没有问题，假定没有其他插口绑定到端口23。当我们启动第二个服务器时，`in_pcblockup`的最后一个参数是`INPLLOOKUP_WILDCARD`，假定没有指定`SO_REUSEADDR`插口选项。当和具有本地插口{140.252.13.35, 23}的PCB比较时，`wildcard`被设成1，记录这个入口。在比较完所有TCP PCB后，返回指向这个入口的指针。导致`in_pcbbind`返回`EADDRINUSE`。

7) 如果我们启动同一个服务器的两个例程，并且都是非通配本地IP地址，会发生什么情况？假定我们以本地插口{140.252.13.35, 23}启动第一个Telnet服务器，然后试图用本地插口{127.0.0.1, 23}启动第二个服务器，且不指定`SO_REUSEADDR`。

当第二个服务器调用`in_pcbbind`时，它调用`in_pcblockup`，最后一个参数是`INPLLOOKUP_WILDCARD`。当比较具有本地插口{140.252.13.35, 23}的PCB时，因为本地IP地址不相等，所以跳过它。`in_pcblockup`返回一个空指针，`in_pcbbind`返回0。

从这个例子中我们看到，`SO_REUSEADDR`插口选项对非通配IP地址没有影响。事实上，只有当`wildcard`大于0时，也就是说，当PCB入口具有一个通配IP地址，或者绑定的IP地址是一个通配地址时，才检查`in_pcblockup`中的`INPLLOOKUP_WILDCARD`标志位。

8) 作为最后一个例子，假定我们试图启动同一服务器的两个例程，具有相同的非通配本地IP地址127.0.0.1。

启动第二个服务器时，`in_pcblockup`总是返回具有相同本地插口的匹配PCB。不管是否指定`SO_REUSEADDR`插口选项，都发生这种情况，因为对这种比较，`wildcard`计数器总是0。因为`in_pcblockup`返回一个非空指针，所以`in_pcbbind`返回`EADDRINUSE`。

从这些例子中，我们可以指出本地IP地址和`SO_REUSEADDR`插口选项的绑定规则。这些规则如图22-24所示。假定`localIP1`和`localP2`是在本地主机上有效的两个不同的单播或广播IP地址，`localmulticastIP`是一个多播组。我们还假定进程要绑定到一个已经绑定到某个已存在PCB的非零端口号。

我们需要区分单播或多播地址和一个多播地址，因为我们看到，`in_pcbbind`认为对多播地址，`SO_REUSEADDR`与`SO_REUSEPORT`是一样的。

存在PCB	试图绑定	SO_REUSEADDR		描述
		关	开	
<code>LocalIP1</code>	<code>localIP1</code>	错误	错误	每个IP地址和端口一个服务器
<code>localIP1</code>	<code>localIP2</code>	正确	正确	每个本地接口一个服务器
<code>localIP1</code>	*	错误	正确	一个接口一个服务器，其他接口一个服务器
*	<code>localIP1</code>	错误	正确	一个接口一个服务器，其他接口一个服务器
*	*	错误	错误	不能复制本地插口(和第一个例子一样)
<code>localIP1</code>	<code>localIP1</code>	错误	正确	多个多播接收方

图22-24 SO_REUSEADDR 插口选项对绑定本地IP地址的影响

2. SO_REUSEPORT插口选项

Net/3中对`SO_REUSEPORT`的处理改变了`in_pcbbind`的逻辑，只要指定了`SO_REUSEPORT`，就允许复制本地插口。换言之，所有服务器都必须同意共享同一本地端口。

22.8 in_pcconnect函数

函数`in_pcconnect`为插口指定IP地址和外部端口号。有四个函数调用它：

- 1) connect为某个TCP插口(某个TCP客户的请求)调用；
- 2) connect为某个UDP插口(对UDP客户是可选的， UDP服务器很少见)调用；
- 3) 当在一个没有连接上的UDP插口(普通)上输出数据报时从sendto调用；
- 4) 当一个连接请求(一个SYN报文段)到达一个处于LISTEN状态(对TCP服务器是标准的)的TCP插口时，tcp_input调用。

在以上四种情况下，当调用in_pcboconnect时，通常，但不要求，不指定本地IP地址和本地端口。因此，在没有指定的情形下，由in_pcboconnect的一个函数给它们赋一个本地的值。

我们将分四个部分讨论in_pcboconnect函数。图22-25显示了第一部分。

```

130 int
131 in_pcboconnect(inp, nam)
132 struct inpcb *inp;
133 struct mbuf *nam;
134 {
135     struct in_ifaddr *ia;
136     struct sockaddr_in *ifaddr;
137     struct sockaddr_in *sin = mtod(nam, struct sockaddr_in *);
138     if (nam->m_len != sizeof(*sin))
139         return (EINVAL);
140     if (sin->sin_family != AF_INET)
141         return (EAFNOSUPPORT);
142     if (sin->sin_port == 0)
143         return (EADDRNOTAVAIL);
144     if (in_ifaddr) {
145         /*
146          * If the destination address is INADDR_ANY,
147          * use the primary local address.
148          * If the supplied address is INADDR_BROADCAST,
149          * and the primary interface supports broadcast,
150          * choose the broadcast address for that interface.
151         */
152 #define satosin(sa)    ((struct sockaddr_in *) (sa))
153 #define sintosa(sin)   ((struct sockaddr *) (sin))
154 #define ifatoia(ifa)   ((struct in_ifaddr *) (ifa))
155     if (sin->sin_addr.s_addr == INADDR_ANY)
156         sin->sin_addr = IA_SIN(in_ifaddr)->sin_addr;
157     else if (sin->sin_addr.s_addr == (u_long) INADDR_BROADCAST &&
158             (in_ifaddr->ia_ifp->if_flags & IFF_BROADCAST))
159         sin->sin_addr = satosin(&in_ifaddr->ia_broadaddr)->sin_addr;
160 }

```

in_pcbo.c

图22-25 in_pcboconnect 函数：验证参数，检查外部IP地址

1. 确认参数

130-143 nam参数指向一个包含sockaddr_in结构以及外部IP地址和端口号的mbuf。这些建行确认参数并验证调用方不打算连接到端口号为0的端口上。

2. 特别处理到0.0.0.0和255.255.255.255的连接

134-160 对全局变量in_ifaddr的检查证实已配置了一个IP接口。如果外部地址是0.0.0.0(INADDR_ANY)，则用最初的IP接口的IP地址代替0.0.0.0。这就是说，调用进程是连接到这个主机上的一个对等实体的。如果外部IP地址是255.255.255.255(INADDR_BROADCAST)，

而且原来的接口支持广播，则用原来接口的广播地址代替 255.255.255.255。这样，UDP应用程序无需计算它的 IP 地址，就可以在原来的接口上广播——它可以简单地把数据报发送给 255.255.255.255，由内核把这个地址转换成该接口合适的 IP 地址。

下一部分代码，如图 22-26 所示，处理没有指定本地地址的情况。对 TCP 和 UDP 客户程序来说，本节开始的表中的情形 1、2 和 3 是非常普遍的。

```

161     if (inp->inp_laddr.s_addr == INADDR_ANY) {
162         struct route *ro;
163
164         ia = (struct in_ifaddr *) 0;
165         /*
166          * If route is known or can be allocated now,
167          * our src addr is taken from the i/f, else punt.
168
169         ro = &inp->inp_route;
170         if (ro->ro_rt &&
171             (satosin(&ro->ro_dst)->sin_addr.s_addr !=
172              sin->sin_addr.s_addr ||
173              inp->inp_socket->so_options & SO_DONTROUTE)) {
174             RTFREE(ro->ro_rt);
175             ro->ro_rt = (struct rtentry *) 0;
176
177             if ((inp->inp_socket->so_options & SO_DONTROUTE) == 0 && /* XXX */
178                 (ro->ro_rt == (struct rtentry *) 0 ||
179                  ro->ro_rt->rt_ifp == (struct ifnet *) 0)) {
180                 /* No route yet, so try to acquire one */
181                 ro->ro_dst.sa_family = AF_INET;
182                 ro->ro_dst.sa_len = sizeof(struct sockaddr_in);
183                 ((struct sockaddr_in *)&ro->ro_dst)->sin_addr =
184                     sin->sin_addr;
185                 rtalloc(ro);
186
187                 /*
188                  * If we found a route, use the address
189                  * corresponding to the outgoing interface
190                  * unless it is the loopback (in case a route
191                  * to our address on another net goes to loopback).
192
193                 if (ro->ro_rt && !(ro->ro_rt->rt_ifp->if_flags & IFF_LOOPBACK))
194                     ia = ifatoia(ro->ro_rt->rt_ifa);
195                 if (ia == 0) {
196                     u_short fport = sin->sin_port;
197
198                     sin->sin_port = 0;
199                     ia = ifatoia(ifa_ifwithdstaddr(sintosa(sin)));
200                     if (ia == 0)
201                         ia = ifatoia(ifa_ifwithnet(sintosa(sin)));
202                     sin->sin_port = fport;
203                     if (ia == 0)
204                         ia = in_ifaddr;
205                     if (ia == 0)
206                         return (EADDRNOTAVAIL);
207                 }

```

图 22-26 in_pcboconnect 函数：没有指定本地 IP 地址

3. 如果路由不再有效，则释放该路由

164-175 如果PCB中含有一条路由，但该路由的目的地址和已经连接上的外部地址不同，或者SO_DONTROUTE插口选项被置位，则放弃该路由。

为了理解为什么一个PCB会含有一条相关路由，考虑本节开始的表中的情形3：每次在一个未连接上的插口上发送UDP数据报时，就调用in_pcconnect。每次进程调用sendto时，UDP输出函数调用in_pcconnect、ip_output和in_pcbs disconnect。如果在该插口上发送的所有数据报都具有相同的目的IP地址，则第一次通过in_pcconnect时，就分配了一条路由，从此时开始可以使用该路由。但是，因为UDP应用程序可能在每次调用sendto时，都向不同的IP地址发送数据报，所以必须比较目的地址和保存的路由。当目的地址改变时，就放弃该路由。ip_output也作同样的检查，这看起来似乎是多余的。

SO_DONTROUTE插口选项告诉内核旁路掉正常的选路决策，把该IP数据报发到本地连接的接口，该接口的IP网络地址和目的地址的网络部分匹配。

4. 获取路由

176-185 如果没有置位SO_DONTROUTE插口选项，则PCB中没有到目的地的路由，就要调用rtalloc获取一条路由。

5. 确定外出的接口

186-205 这一节代码的意图是让ia指向一个接口地址结构(in_ifaddr, 6.5节)，该结构中包含了该接口的IP地址。如果PCB中的路由仍然有效，或者如果rtalloc找到一条路由，并且该路由不是到回环接口的，则使用相应的接口。否则，调用ifa_withdstaddr和ifa_withnet检查该外部IP地址是否在一个点到点链路的另一端，或者位于一个连到的网络上。两个函数都要求插口地址结构中的端口号为0，以便在调用期间保存在fport中。如果失败，就用原来的IP地址(in_ifaddr)，如果没有配置接口(in_ifaddr为0)，则返回错误。

图22-27显示了in_pcconnect的下一部分，处理目的地址是多播地址的情况。

206-223 如果目的地址是一个多播地址，且进程指定了多播分组的外出接口（用IP_MULTICAST_IF插口选项），则该接口的IP地址被用作本地地址。搜索所有IP接口，找到与插口选项所指定接口的匹配。如果该接口不存在，则返回错误。

224-225 图22-26的开头是处理通配本地地址情形的完整代码。指向本地接口ia的sockaddr_in结构的指针保存在ifaddr中。

in_pcblockup的最后一部分显示在图22-28中。

6. 验证插口对是唯一的

227-233 in_pcblockup验证插口对是唯一的。外部地址和外部端口号是指定给in_pcconnect的参数的值。本地地址是已经绑定到该插口的值，或者是ifaddr中我们刚刚介绍的代码计算出来的值。本地端口可以是0，对TCP客户程序来说这是典型的。我们将在这部分代码的后面看到，为本地端口选择了一个临时端口。

这个测试避免从相同的本地地址和本地端口上建立两个到同一外部地址和外部端口的TCP连接。例如，如果我们与主机sun上的回显服务器建立了一个TCP连接，然后试图从同一本地端口(8888，用-b选项指定)建立另一条到同一服务器的连接，调用in_pcblockup后返回一个匹配，导致connect返回差错EADDRINUSE(我们用卷1附录C的sock程序)。

```
bsdi S sock -b 8888 sun echo &      启动后台的第一个
bsdi S sock -A -b 8888 sun echo      然后再试一次
connect() error: Address already in use
```

```

206      /*
207       * If the destination address is multicast and an outgoing
208       * interface has been set as a multicast option, use the
209       * address of that interface as our source address.
210       */
211     if (IN_MULTICAST(ntohl(sin->sin_addr.s_addr)) &&
212         inp->inp_moptions != NULL) {
213         struct ip_moptions *imo;
214         struct ifnet *ifp;
215
216         imo = inp->inp_moptions;
217         if (imo->imo_multicast_ifp != NULL) {
218             ifp = imo->imo_multicast_ifp;
219             for (ia = in_ifaddr; ia; ia = ia->ia_next)
220                 if (ia->ia_ifp == ifp)
221                     break;
222             if (ia == 0)
223                 return (EADDRNOTAVAIL);
224         }
225         ifaddr = (struct sockaddr_in *) &ia->ia_addr;
226     }

```

*in_pcbo.c*图22-27 *in_pcboconnect* 函数：目的地址是一个多播地址

```

227     if (in_pcbockup(inp->inp_head,
228                      sin->sin_addr,
229                      sin->sin_port,
230                      inp->inp_laddr.s_addr ? inp->inp_laddr : ifaddr->sin_addr,
231                      inp->inp_lport,
232                      0))
233     return (EADDRINUSE);
234
235     if (inp->inp_laddr.s_addr == INADDR_ANY) {
236         if (inp->inp_lport == 0)
237             (void) in_pcbbind(inp, (struct mbuf *) 0);
238         inp->inp_laddr = ifaddr->sin_addr;
239     }
240     inp->inp_faddr = sin->sin_addr;
241     inp->inp_fport = sin->sin_port;
242 }

```

*in_pcbo.c*图22-28 *in_pcboconnect* 函数：验证插口对是唯一的

我们指定 -A 选项，设置 SO_REUSEADDR 插口选项，使 bind 成功，但是 connect 不成功。这是一个人为的例子，因为我们显式地把两个插口都绑定到同一本地端口上 (8888)。在正常情形下，主机 bsdi 上的两个不同客户程序连接到 sun 的回显服务器上，当第二个客户程序调用图22-28中的 in_pcbockup 函数时，本地端口将是 0。

这个测试也避免了两个 UDP 插口从相同的本地端口上连接到同一个外部地址。但这个测试不能避免两个 UDP 插口从同一个本地端口上交替地向同一个外部地址发送数据报，只要它们都不调用 connect。因为 UDP 插口在 sendto 系统调用的过程中，只是临时连接到一个对等实体上。

7. 隐式绑定和分配临时端口

234-238 如果插口的本地地址仍然是通配匹配的，则把它设置成 ifaddr 中保存的值。这是一个隐式绑定：22.7节开始时讲的情形 3、4 和 5。首先，检查本地端口是否已经被绑定，如果没有， in_pcbbind 就把该插口绑定到一个临时端口。调用 in_pcbbind 和给 inp_laddr 赋值的顺序很重要，因为如果本地地址不是通配地址，则 in_pcbbind 会失败。

8. 把外部地址和外部端口存放在 PCB 中

239-240 这个函数的最后一步设置 PCB 的外部 IP 地址和外部端口号成员。如果这个函数成功返回，我们就能保证 PCB 中的插口对——本地的和外部的——都有了特定的值。

IP 源地址与外出接口地址

在 IP 数据报的源地址和用来发送该数据报接口的 IP 地址之间有些微妙的差别。

TCP 和 UDP 把 PCB 成员 in_paddr 用作该 IP 数据报的源地址。它可由进程设成任何被 bind 配置的接口的 IP 地址（在 in_pcbbind 中调用 ifa_ifwithaddr 验证应用程序想要的本地地址）。只有当本地地址是一个通配地址时， in_pcbbind 才给它赋值。而当这种情况发生时，本地地址是根据外出接口分配的（因为目的地址已知）。

但是，外出接口也是根据目的 IP 地址，由 ip_output 确定的。在多接口主机上，当进程显式绑定一个不同于外出接口的本地地址时，源地址有可能是一个本地接口的 IP 地址，且该接口不是外出的接口。这种情况是允许的，因为 Net/3 选择了弱端系统模式（8.4 节）。

22.9 in_pcbservice 函数

ip_pcbservice 把 UDP 插口断连。把外部 IP 地址设成全 0(INADDR_ANY)，外部端口号设成 0，就把外部相关内容删除了。

这是在已经在一个未连接上的 UDP 插口上发送了一个数据报后，在一个连接上的 UDP 插口上调用 connect 时做的。在第一种情况下，调用 sendto 的次序是：UDP 调用 in_pcbservice 把插口临时连接到目的地， udp_output 发送数据报，然后 in_pcbservice 删除临时连接。

当关闭插口时，不调用 in_pcbservice，因为 in_pcbservice 处理释放 PCB。只有当一个不同的地址或端口号要求重用该 PCB 时，才断连。

图 22-29 显示了 in_pcbservice 函数。

```
243 int in_pcbservice(inp)
244     in_pcbservice(inp)
245     struct inpcb *inp;
246 {
247     inp->inp_faddr.s_addr = INADDR_ANY;
248     inp->inp_fport = 0;
249     if (inp->inp_socket->so_state & SS_NOFDREF)
250         in_pcbservice(inp);
251 }
```

in_pcbservice

图 22-29 in_pcbservice 函数：与外部地址和端口号断连

如果该 PCB 不再有文件表引用（SS_NOFDREF 置位），则 in_pcbservice（图 22-7）释放该 PCB。

22.10 in_setsockaddr和in_setpeeraddr函数

getsockname系统调用返回插口的本地协议地址(例如, Internet插口的IP地址和端口号), getpeername系统调用返回外部协议地址。两个系统调用终止时, 都发布一个PRU_SOCKADDR或PRU_PEERADDR请求。然后协议调用in_setsockaddr或in_setpeeraddr。图22-30显示了以上的第一种情况。

in_pcbs.c

```

267 int
268 in_setsockaddr(inp, nam)
269 struct inpcb *inp;
270 struct mbuf *nam;
271 {
272     struct sockaddr_in *sin;
273     nam->m_len = sizeof(*sin);
274     sin = mtod(nam, struct sockaddr_in *);
275     bzero((caddr_t) sin, sizeof(*sin));
276     sin->sin_family = AF_INET;
277     sin->sin_len = sizeof(*sin);
278     sin->sin_port = inp->inp_lport;
279     sin->sin_addr = inp->inp_laddr;
280 }
```

in_pcbs.c

图22-30 in_setsockaddr 函数：返回本地地址和端口号

参数nam是一个指针, 该指针指向一个用来存放结果的mbuf:一个sockaddr_in结构, 系统调用复制给进程的备份。该代码填写插口地址结构的内容, 并把IP地址和端口号从Internet PCB拷贝到sin_addr和sin_port成员中。

图22-31显示了in_setpeeraddr函数。它基本上等同于图22-30中的代码, 但从PCB中拷贝了外部IP地址和端口号。

in_pcbs.c

```

281 int
282 in_setpeeraddr(inp, nam)
283 struct inpcb *inp;
284 struct mbuf *nam;
285 {
286     struct sockaddr_in *sin;
287     nam->m_len = sizeof(*sin);
288     sin = mtod(nam, struct sockaddr_in *);
289     bzero((caddr_t) sin, sizeof(*sin));
290     sin->sin_family = AF_INET;
291     sin->sin_len = sizeof(*sin);
292     sin->sin_port = inp->inp_fport;
293     sin->sin_addr = inp->inp_faddr;
294 }
```

in_pcbs.c

图22-31 in_setpeeraddr 函数：返回外部地址和端口号

22.11 in_pcbsnotify、in_rtchange和in_losing函数

当收到一个ICMP差错时, 调用in_pcbsnotify函数, 把差错通知给合适的进程。通过对所有的PCB搜索一个协议(TCP或UDP), 并把本地和外部IP地址及端口号与ICMP差错返回的值进行比较, 找到“合适的进程”。例如, 当因为一些路由器丢掉了某个TCP报文段而收到

ICMP源抑制差错时，TCP必须找到产生该差错的连接的PCB，放慢在该连接上的传输速度。

在显示该函数之前，我们必须回顾一下它是怎样被调用的。图 22-32总结了处理 ICMP差错时调用的函数。两个有阴影的椭圆是本节描述的函数。

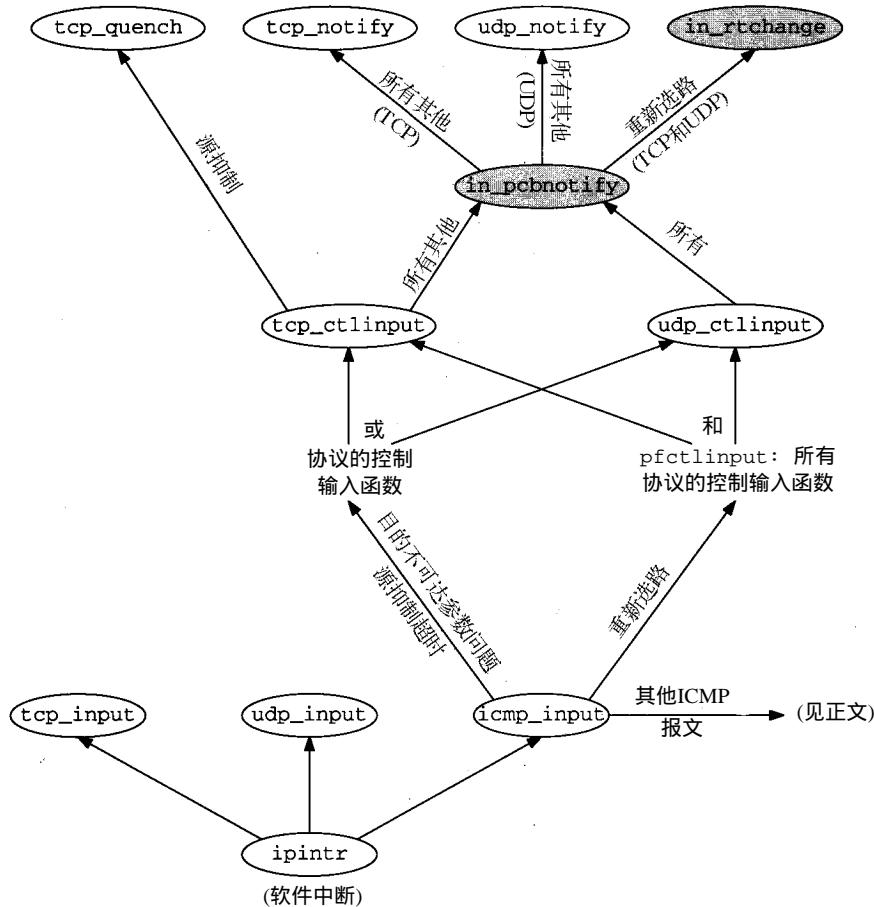


图22-32 ICMP差错处理总结

当收到一个ICMP报文时，调用 `icmp_input`。ICMP的五种报文按差错来划分（图11-1和图11-2）：

- 目的主机不可达；
- 参数问题；
- 重定向；
- 源抑制；
- 超时。

重定向的处理不同于其他四个差错。所有其他的ICMP报文（查询）的处理见第11章。

每个协议都定义了它的控制输入函数，即 `protosw` 结构（7.4节）中的 `pr_ctlinput` 入口。对 TCP 和 UDP，它们分别称为 `tcp_ctlinput` 和 `udp_ctlinput`，我们将在后面几章给出它们的代码。因为收到的 ICMP 差错中包含了引起差错的数据报的 IP 首部，所以引起该差错的协议（TCP 或 UDP）是已知的。这五个 ICMP 差错中的四个将引起对协议的控制输入函数的调用。

重定向的处理不同：调用函数 `pfctlinput`，它继续调用协议族 (Internet) 中所有协议的控制输入函数。TCP和UDP是Internet协议族中仅有的两个具有控制输入函数的协议。

重定向的处理是特殊的，因为它们不仅影响产生重定向的数据报，还将影响所有到该目的地的IP数据报。另一方面，其他四个差错只需由产生差错的协议进行处理。

in_pcbs.c

```

306 int
307 in_pcbsnotify(head, dst, fport_arg, laddr, lport_arg, cmd, notify)
308 struct inpcb *head;
309 struct sockaddr *dst;
310 u_int fport_arg, lport_arg;
311 struct in_addr laddr;
312 int cmd;
313 void (*notify) (struct inpcb *, int);
314 {
315     extern u_char inetctllerrmap[];
316     struct inpcb *inp, *oinp;
317     struct in_addr faddr;
318     u_short fport = fport_arg, lport = lport_arg;
319     int errno;
320
321     if ((unsigned) cmd > PRC_NCMDS || dst->sa_family != AF_INET)
322         return;
323     faddr = ((struct sockaddr_in *) dst)->sin_addr;
324     if (faddr.s_addr == INADDR_ANY)
325         return;
326
327     /*
328      * Redirects go to all references to the destination,
329      * and use in_rtchange to invalidate the route cache.
330      * Dead host indications: notify all references to the destination.
331      * Otherwise, if we have knowledge of the local port and address,
332      * deliver only to that socket.
333      */
334     if (PRC_IS_REDIRECT(cmd) || cmd == PRC_HOSTDEAD) {
335         fport = 0;
336         lport = 0;
337         laddr.s_addr = 0;
338         if (cmd != PRC_HOSTDEAD)
339             notify = in_rtchange;
340     }
341     errno = inetctllerrmap[cmd];
342     for (inp = head->inp_next; inp != head;) {
343         if (inp->inp_faddr.s_addr != faddr.s_addr ||
344             (inp->inp_socket == 0 ||
345              (lport && inp->inp_lport != lport) ||
346              (laddr.s_addr && inp->inp_laddr.s_addr != laddr.s_addr) ||
347              (fport && inp->inp_fport != fport))) {
348             inp = inp->inp_next;
349             continue; /* skip this PCB */
350         }
351         oinp = inp;
352         inp = inp->inp_next;
353         if (notify)
354             (*notify) (oinp, errno);
355     }

```

in_pcbs.c

图22-33 `in_pcbsnotify` 函数：把差错通知传给进程

有关图22-32我们要做的最后一点说明是，TCP在处理源抑制差错时，与其他差错的处理不同，而重定向由 `in_pcbnotify` 特别处理：不管引起差错的是什么协议，都调用 `in_rtchange` 函数。

图22-33显示了 `in_pcbnotify` 函数。当TCP调用它时，第一个参数是 `tcb` 的地址，最后一个参数是函数 `tcp_notify` 的地址。对 UDP来说，这两个参数分别是 `udb` 的地址和函数 `udp_notify` 的地址。

1. 验证参数

306-324 验证 `cmd` 参数和目的地址族。检测外部地址，保证它不是 0.0.0.0。

2. 特殊处理重定向

325-338 如果差错是重定向，则对它的处理是特殊的（差错 `PRC_HOSTDEAD` 是一种旧的差错，由IMP产生。目前的系统再也看不到这种差错了——它是一个历史产物）。外部端口、本地端口和本地地址都被设成全0，这样后面的 `for` 循环就不会比较它们了。对于重定向，我们需要该循环只根据外部IP地址选出接收通知的PCB，因为主机是在这个IP地址上接收到重定向的。而且，为重定向调用的函数是 `in_rtchange`（图22-34），而不是调用方指定的 `notify` 参数。

339 全局数组 `inetctllerrmap` 把协议无关差错码（图11-19中的 `PRC_xxx` 值）映射到它对应的 Unix的 `errno` 值（图11-1的最后一栏）。

3. 为所选的PCB调用通知函数

341-353 这个循环选择要通知的PCB。可以通知多个PCB——该循环在找到匹配后仍然继续。第一个 `if` 语句结合了五个检测，如果这五个中有任一个为真，则跳过该 PCB：(1)如果外部地址不相等；(2)如果该PCB没有对应的 `socket` 结构；(3)如果本地端口不相等；(4)如果本地地址不相等；或(5)如果外部端口不相等。外部地址必须匹配，但只有当对应的参数非零时，才比较其他三个外部和本地参数。当找到一个匹配时，调用 `notify` 函数。

22.11.1 `in_rtchange` 函数

我们看到，当ICMP差错是一个重定向时，`in_pcbnotify` 调用 `in_rtchange` 函数。对所有外部地址与已重定向的 IP 地址匹配的 PCB，都调用该函数。图 22-34 显示了 `in_rtchange` 函数。

```

391 void
392 in_rtchange(inp, errno)
393 struct inpcb *inp;
394 int     errno;
395 {
396     if (inp->inp_route.ro_rt) {
397         rtfree(inp->inp_route.ro_rt);
398         inp->inp_route.ro_rt = 0;
399         /*
400          * A new route can be allocated the next time
401          * output is attempted.
402         */
403     }
404 }
```

in_pcb.c

图22-34 `in_rtchange` 函数：使路由无效

如果该PCB中有路由，则`rtfree`释放该路由，且该PCB成员被标记为空。此时，我们不用重定向返回的路由来更新路由。当这个PCB被再次使用时，`ip_output`会根据内核的选路表重新分配新的路由，而该选路表是在调用`pfctlinput`之前，由重定向报文更新的。

22.11.2 重定向和原始插口

让我们来研究一下重定向、原始插口和缓存在PCB中的路由之间的交互。如果我们运行Ping程序，该程序使用一个原始插口，收到来自被ping的IP地址发来的ICMP重定向差错。Ping程序继续使用原来的路由，而不是已重定向的路由。我们可以从以下过程来看。

我们从位于1402521网络上的`gemini`主机ping位于14025213网络上的`svr4`主机。`gemini`的默认路由是`gateway`，但分组应该被发送到路由器`netb`。图22-35显示了这个安排。

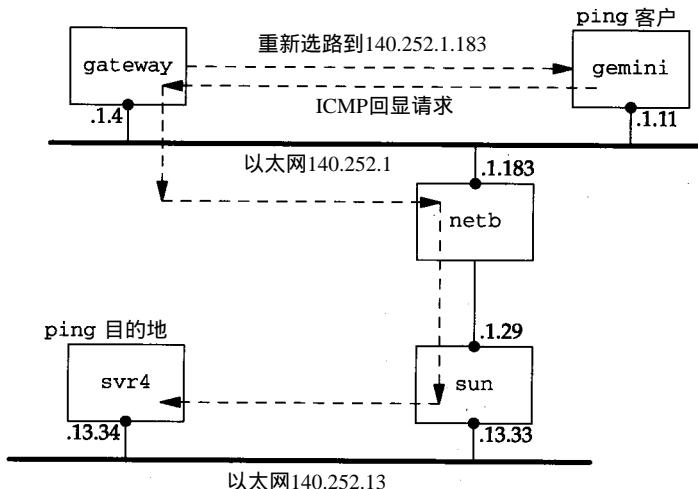


图22-35 ICMP重定向举例

我们希望`gateway`在收到第一个ICMP回显请求时，发一个重定向。

```
gemini $ ping -sv svr4
PING 140.252.13.34: 56 data bytes
ICMP Host redirect from gateway 140.252.1.4
  to netb (140.252.1.183) for svr4 (140.252.13.34)
64 bytes from svr4 (140.252.13.34): icmp_seq=0. time=572. ms
ICMP Host redirect from gateway 140.252.1.4
  to netb (140.252.1.183) for svr4 (140.252.13.34)
64 bytes from svr4 (140.252.13.34): icmp_seq=1. time=392. ms
```

选项`-s`使每隔一秒发送一次ICMP回显请求，选项`-v`打印每个收到的ICMP报文(不仅仅是ICMP回显回答)。

每个ICMP回显请求引出一个重定向，但ping使用的原始插口从来不通知重定向改变它正在使用的路由。第一次计算出来并被保存在PCB中的路由，使IP数据报被发送到路由器`gateway`{140.252.1.4}，应该更新它，使数据报能被发送到路由器`netb`{140.252.1.183}上。我们看到，`gemini`上的内核接收ICMP重定向，但它们被略过了。

如果我们终止ping程序，并重新运行它，我们就再也看不到重定向了：

```
gemini $ ping -sv svr4
```

```
PING 140.252.13.34: 56 data bytes
64 bytes from svr4 (140.252.13.34): icmp_seq=0, time=388. ms
64 bytes from svr4 (140.252.13.34): icmp_seq=1. time=363. ms
```

这个不正常的原因是原始IP插口代码(第32章)没有控制输入函数。只有TCP和UDP有控制输入函数。当收到重定向时，ICMP更新内核的选路表，调用`pfctlinput`(图22-32)。但是因为原始IP协议没有控制输入函数，所以不释放与Ping的原始插口相关的PCB中高速缓存的路由。但是，当我们第二次运行`ping`程序时，根据内核更新后的选路表分配路由，所以我们看不到重定向了。

22.11.3 ICMP差错和UDP插口

插口API令人迷惑的一部分是，不把在UDP插口上收到的ICMP差错传给应用程序，除非该应用程序在该插口上发布`connect`，限制该插口的外部IP地址和端口号。现在我们来看一下`in_pcbsnotify`是如何实施这一限制的。

考虑某个ICMP插口不可达，这大概是 UDP插口上最普通的一种 ICMP差错了。`in_pcbsnotify`的`dst`参数内的外部IP地址和外部端口号是引起ICMP差错的IP地址和端口号。但是，如果该进程已经在该插口上发布`connect`命令，则PCB的`inp_faddr`和`inp_fport`成员都是0，避免`in_pcbsnotify`在该插口上调用`notify`函数。图22-33中的`for`循环将跳过每个UDP PCB。

产生这个限制的原因有两个。首先，如果正在发送的进程有一个未连接上的 UDP插口，则该插口对中唯一的非零元素是本地端口(假定该进程不调用`bind`)。这是`in_pcbsnotify`在分用进入的ICMP差错，并把它传给正确进程时，唯一可用的值。尽管很少发生，但也可能有多个进程都绑定到相同的本地端口上，所以具体由哪个进程接收ICMP差错就不明确了。还有一种可能就是，发送引起ICMP差错数据报的进程已经终止了，而另一个进程又开始运行并使用同一本地端口。这也太可能，因为临时端口是从1024到5000按顺序分配的，只有循环一遍以后才可能重用同一端口号(图22-23)。

这个限制的第二个原因是，内核给进程的差错通知——一个`errno`值——是不够的。考虑某个进程连续三次在一个未连接上的 UDP插口上调用`sendto`函数，向三个不同的目的地发送一个UDP数据报，然后用`recvfrom`等待回答。如果其中一个数据报生成一个ICMP端口不可达差错，且内核将向该进程发布的`recvfrom`返回对应的差错(`ECONNREFUSED`)，那么，`errno`值并没有告诉进程是哪个数据报产生了该差错。内核具有ICMP差错所要求的所有信息，但是插口API并不提供手段把这些信息返回给该进程。

因此，如果进程想要得到在某个 UDP插口上的这些ICMP差错通知，在设计时就必须决定插口只能连接到一个对等实体上。如果在该连接上的插口返回`ECONNREFUSED`差错，毫无疑问就是该对等实体产生的差错。

还有一种远程可能性，会把ICMP差错交付给错误的进程。假设某个进程发送了一个 UDP数据报，引起一个ICMP差错，但它在收到该差错之前终止了。另一个进程在收到该差错之前开始运行，并且绑定到同一个本地端口，连接到相同的外部地址和外部端口上，导致这个新进程接收到前面的ICMP差错。由于UDP缺少内存，所以无法避免这种情况的发生。我们将看到TCP用它的`TIME_WAIT`状态处理这个问题。

在我们前面的例子中，应用程序绕开这个限制的一个办法是使用三个连接上的 UDP插口，

而不是一个未连接上的插口，并在其中任意一个有收到的数据报或差错要读写时，调用 select 函数来确定。

这里我们有一种情形是内核有足够的信息而 API(插口)的信息不足。大多数 Unix 系统V及其他常见的API(TLI)，其逆为真：TLI函数 t_rcvuderr 可以返回对等实体的IP地址、端口号以及一个差错值。但大多数 TCP/IP的SVR4流实现都不为 ICMP 提供手段，把差错传递给一个未连接上的 UDP端节点。

在理想情况下，in_pcbnotify 把ICMP差错交付给所有匹配的 UDP插口，即使唯一的非通配匹配是本地端口。返回给进程的差错将包括产生差错的目的 IP地址和目的UDP端口，允许进程确定该差错是否是它发送的数据报产生的。

22.11.4 in_losing 函数

处理PCB的最后一个函数图 22-36 的 in_losing。当TCP的某个连接的重传定时器连续第三次超时时，调用该函数。

```

361 int
362 in_losing(inp)
363 struct inpcb *inp;
364 {
365     struct rtentry *rt;
366     struct rt_addrinfo info;
367     if ((rt = inp->inp_route.ro_rt)) {
368         inp->inp_route.ro_rt = 0;
369         bzero((caddr_t) & info, sizeof(info));
370         info.rti_info[RTAX_DST] =
371             (struct sockaddr *) &inp->inp_route.ro_dst;
372         info.rti_info[RTAX_GATEWAY] = rt->rt_gateway;
373         info.rti_info[RTAX_NETMASK] = rt_mask(rt);
374         rt_missmsg(RTM_LOSING, &info, rt->rt_flags, 0);
375         if (rt->rt_flags & RTF_DYNAMIC)
376             (void) rtrequest(RTM_DELETE, rt_key(rt),
377                             rt->rt_gateway, rt_mask(rt), rt->rt_flags,
378                             (struct rtentry **) 0);
379     else
380         /*
381          * A new route can be allocated
382          * the next time output is attempted.
383          */
384         rtfree(rt);
385     }
386 }
```

in_pcb.c

图22-36 in_losing 函数：使高速缓存路由信息无效

1. 产生选路报文

361-374 如果PCB中有一个路由，则丢掉该路由。用要失效的高速缓存路由的有关信息填充一个 rt_addrinfo 结构。然后调用 rt_missmsg 函数，从 RTM_LOSING 类型的选路插口中生成一个报文，指明有关该路由的问题。

2. 删除或释放路由

375–384 如果高速缓存路由是由一个重定向生成的 (RTF_DYNAMIC置位)，则用请求 RTM_DELETE调用rtrequest，删除该路由。否则释放高速缓存的路由，这样，当该插口上有下一个输出时，为它重新分配一条到目的地的路由——希望是一条更好的路由。

22.12 实现求精

毫无疑问，这一章我们遇到的最耗时的算法是 in_pcblkup做的对PCB 的线性搜索。22.6节一开始，我们就注意到有四种情况会调用这个函数。可以忽略对 bind和connect的调用，因为TCP和UDP在分用每个收到的IP数据报时，调用它们的次数比调用 in_pcblkup的少得多。

后面几章我们将看到，TCP和UDP试图帮助这个线性搜索，它们都维护一个指向该协议引用的最后一个PCB的指针：一个单入口高速缓存。如果高速缓存的PCB的本地地址、本地端口、外部地址和外部端口与收到的数据报的值匹配，则协议根本就不调用 in_pcblkup。如果协议数据适合分组列模型 [Jain和Routhier 1986]，这个简单的高速缓存效果很好。但是，如果数据不适合这个模型，例如，看起来象联机交易处理系统的数据入口，则单入口高速缓存的效率很低 [McKenney和Dove 1992]。

一个稍好一点的PCB安排的建议是，当引用某个PCB时，把它移到该PCB表的最前面 ([McKenney和Dove 1992] 把这个想法给了Jon Crowcroft；[Partridge和Pink 1993]把它给了Gary Delp)。移动PCB很容易，因为该表是一个双向链表，而且 in_pcblkup的第一个参数是一个指向该表表头的指针。

[McKenney和Dove 1992]把原始的Net/1实现(没有高速缓存)，一种提高的单入口发送-接收高速缓存，“移到最前面”启发算法，以及他们自己的使用散列链的算法做了比较。他们指出，在散列链上维护一个PCB的线性表比其他算法的性能提高了一个数量级。散列链的唯一耗费是需要内存存放散列链的链头，以及计算散列函数。他们也考虑把“移到最前面”启发算法与他们的散列链算法结合，结论是只增加一些散列链，更为简单。

BSD线性搜索和散列表搜索的另一个比较是在[Hutchinson和Peterson 1991]中。他们指出，随着散列表中插口数量的增加，分用一个进入的 UDP数据报所需要的时间是常量，但线性搜索所需要的时间随插口数量的增加而增加。

22.13 小结

每个Internet插口都有一个相关的Internet PCB：TCP、UDP和原始IP。它包含了Internet插口的一般信息：本地和外部IP地址，指向一个路由结构的指针等等。给定协议的所有PCB都放在该协议维护的一个双向链表上。

本章中，我们研究了多个操作PCB的函数，对其中的三个作了详细的讨论：

1) TCP和UDP调用in_pcblkup分用每个进入的数据报。它选择接收数据报的插口，考虑通配匹配。

in_pcbbind也调用这个函数来验证本地地址和本地进程是唯一的；in_pcbbconnect调用这个函数验证本地地址、本地进程、外部地址和外部进程的组合是唯一的。

2) in_pcbbind显式或隐式地把一个本地地址和本地端口号绑定到一个插口。当进程调用bind时，发生显式绑定；当一个TCP客户程序调用connect而不调用bind时，或当一个

UDP进程调用sendto或connect而不调用bind时，发生隐式绑定。

3) in_pcboconnect设置外部地址和外部进程。如果进程还没有设置本地地址，计算一条到外部地址的路由，结果的本地接口成为本地地址。如果进程还没有设置本地端口，in_pcbbind为插口选择一个临时端口。

图22-37对多种TCP和UDP应用程序以及存放在PCB中的本地地址、本地端口、外部地址和外部端口的值做了总结。我们还没有讨论完图22-37中TCP和UDP进程的所有动作，将在后面的章节中继续讨论。

应用 程 序	本地地址： inp_laddr	本地端口： inp_lport	外部地址： inp_faddr	外部端口： inp_fport
T C P 客 户 程 序： connect(foreignIP, fport)	in_pcboconnect 调用 rtalloc 为 foreignIP 分配路由。 本地地址是本地接口	in_pcboconnect 调用 in_pcbbind 选 择临时端口。	foreignIP	fport
TCP客户程序：bind (localIP, lport) connect (foreignIP,fport)	localIP	lport	foreignIP	fport
T C P 客 户 程 序： bind(*, lport) connect (foreignIP, fport)	in_pcboconnect 调用 rtalloc 为 foreignIP 分配路由。 本地地址是本地接口	lport	fport	fport
TCP客户程序：bind (localIP, 0) connect (foreignIP,fport)	localIP	in_pcbbind 选择 临时端口	foreignIP	fport
T C P 服 务 器 程 序： bind(localIP, lport) listen()accept()	localIP	lport	IP首部内的源 地址	T C P 首部内 的源端口地址
TCP服务器程序：bind (*, lport) listen() accept()	IP首部里的目的地 址	lport	foreignIP。发 送完数据报后， 置位为0.0.0.0	T C P 首部内 的源端口地址
U D P 客 户 程 序： sendto(foreignIP,fport)	in_pcboconnect 调用 rtalloc 为 foreignIP 分配路由。 本地地址是本地接口。 在发送完数据报之后， 置位为0.0.0.0	in_pcboconnect 调用 in_pcbbind 选 择临时端口。后面调 用 sendto 时不改变	foreignIP	fport。发 送完数据报后， 置位为0
U D P 客 户 程 序： connect(foreignIP, fport) write()	in_pcboconnect 调用 rtalloc 为 foreignIP 分配路由。 本地地址是本地接 口。后面调用 write 时不改变	in_pcboconnect 调用 in_pcbbind 选 择临时端口。后面调 用 write 时不改变	foreignIP	fport

图22-37 in_pcbbind 和in_pcboconnect 的总结

习题

- 22.1 在图22-23中，当进程请求一个临时端口，而所有临时端口都被使用时，会发生什么情况？
- 22.2 在图22-10中，我们显示了两个有正在监听插口的 Telnet服务器：一个具有特定本地IP地址；另一个的本地IP地址是通配地址。你的系统的 Telnet守护程序允许你指定本地IP地址吗？如果允许，如何指定？
- 22.3 假定某个插口被绑定到本地插口 {140.252.1.29, 8888}，且这是唯一使用本地插口8888的插口。（1）当有另一个插口绑定到 {140.252.1.29, 8888} 时，请执行 in_pcbbind的所有步骤，假定没有任何插口选项。（2）当有另一个插口绑定到通配IP地址，端口8888时，执行 in_pcbbind的所有步骤，假定没有任何插口选项。（3）当有另一个插口绑定到通配 IP 地址，端口 8888 时，且设定了插口选项 SO_REUSEADDR，执行in_pcbbind的所有步骤。
- 22.4 UDP分配的第一个临时端口号是什么？
- 22.5 当进程调用bind时，必须填充sockaddr_in结构中的哪一个元素？
- 22.6 如果进程要bind一个本地广播地址时，会发生什么情况？如果进程要 bind受限广播地址(255.255.255.255)时，会发生什么情况？

第23章 UDP：用户数据报协议

23.1 引言

用户数据报协议，即 UDP，是一个面向数据报的简单运输层协议：进程的每次输出操作只产生一个 UDP 数据报，从而发送一个 IP 数据报。

进程通过创建一个 Internet 域内的 SOCK_DGRAM 类型的插口，来访问 UDP。该类插口默认地称为无连接的 (unconnected)。每次进程发送数据报时，必须指定目的 IP 地址和端口号。每次从插口上接收数据报时，进程可以从数据报中收到源 IP 地址和端口号。

我们在 22.5 节中提到，UDP 插口也可以被连接到一个特殊的 IP 地址和端口号。这样，所有写到该插口上的数据报都被发往该目的地，而且只有来自该 IP 地址和端口号的数据报才被传给该进程。

本章讨论 UDP 的实现。

23.2 代码介绍

9 个 UDP 函数在一个 C 文件中，2 个 UDP 定义的头文件，如图 23-1 所示。

图 23-2 显示了 6 个主要的 UDP 函数与其他内核函数之间的关系。带阴影的椭圆是本章我们讨论的 6 个函数，另外还有其他 3 个函数是这 6 个函数经常调用的。

文 件	描 述
netinet/udp.h	udphdr 结构定义
netinet/udp_var.h	其他 UDP 定义
netinet/udp_usrreq.c	UDP 函数

图 23-1 本章中讨论的文件

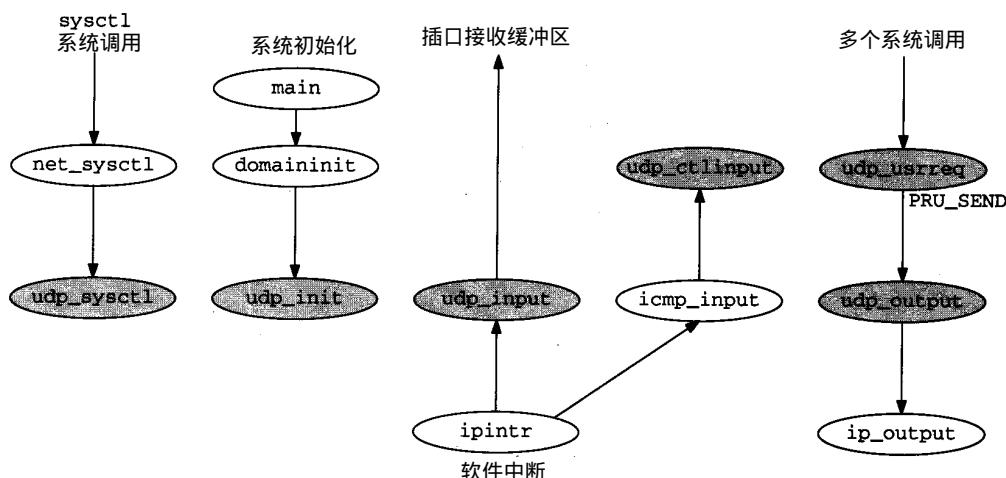


图 23-2 UDP 函数与内核其他函数之间的关系

23.2.1 全局变量

本章引入的全局变量，如图23-3所示。

变 量	数据类型	描 述
udb udp_last_inpcb	Struct inpcb Struct inpcb *	UDP PCB表的表头 指向最近收到的数据报的指针：“向后一个”高速缓存
udpcksum udp_in udpstat	Int Struct sockaddr_in Struct udpstat	用于计算和验证 UDP检验和的标志位 在输入时存放发送方的IP地址 UDP统计(图23-4)
udp_recvspace udp_sendspace	u_long u_long	插口接收缓存的默认大小，41 600字节 插口发送缓存的默认大小，9 216字节

图23-3 本章中引入的全局变量

23.2.2 统计量

全局结构 `udpstat` 维护多种 UDP统计量，如图23-4所示。讨论代码的过程中，我们会看到何时增加这些计数器的值。

udpstat成员	描 述	SNMP使用的
udps_badlen	收到所有数据长度大于分组的数据报个数	•
udps_badsum	收到有检验和错误的数据报个数	•
udps_fullsock	收到由于输入插口已满而没有提交的数据报个数	•
udps_hdrops	收到分组小于首部的数据报个数	•
udps_ipackets	所有收到的数据报个数	•
udps_noport	收到在目的端口没有进程的数据报个数	•
udps_noportbroadcast	收到在目的端口没有进程的广播 / 多播数据报个数	•
udps_opackets	全部输出数据报的个数	•
udps_pcbschemiss	收到的丢失pcb高速缓存的输入数据报个数	•

图23-4 在 `udpstat` 结构中维持的 UDP统计

图23-5显示了执行 `netstat -s` 后输出的统计信息。

netstat -s 输出	udpstat 成员
18,575,142 datagrams received	udps_ipackets
0 with incomplete header	udps_hdrops
18 with bad data length field	udps_badlen
58 with bad checksum	udps_badsum
84,079 dropped due to no socket	udps_noport
446 broadcast/multicast datagrams dropped due to no socket	udps_noportbroadcast
5,356 dropped due to full socket buffers	udps_fullsock
18,485,185 delivered	(见正文)
18,676,277 datagrams output	udps_opackets

图23-5 UDP统计样本

提交的 UDP数据报的个数(输出的倒数第二行)是收到的数据报总数(`udps_ipackets`)减去图23-5中它前面的6个变量。

23.2.3 SNMP变量

图23-6显示了UDP组中的四个简单SNMP变量，这四个变量在实现该变量的 `udpstat` 结构中计数。

图23-7显示了UDP监听器表，称为 `udpTable`。SNMP为这个表返回的值是取自 UDP PCB，而不是 `udpstat` 结构。

SNMP变量	udpstat成员	描述
<code>udpInDatagrams</code>	<code>udps_ipackets</code>	收到的所有提交给进程的数据报个数
<code>udpInErrors</code>	<code>udps_hdrops + udps_badsum+ udps_badlen</code>	收到的由于某些原因不可提交的 UDP数据报个数，这些原因中不包括在目的端口没有应用程序的原因（例如，UDP检验和差错）
<code>udpNoPorts</code>	<code>udps_noport + udps_noportbcast</code>	收到的所有目的端口没有应用进程的数据报
<code>udpOutDatagrams</code>	<code>udps_opackets</code>	发送的数据报的个数

图23-6 UDP组中的简单SNMP变量

UDP监听器表，索引=<udpLocalAddress>.<udpLocalPort>		
SNMP变量	PCB变量	描述
<code>udpLocalAddress</code>	<code>inp_laddr</code>	这个监听器的本地IP
<code>udpLocalPort</code>	<code>inp_lport</code>	这个监听器的本地端口号

图23-7 UDP监听器表：`udpTable`

23.3 UDP的protosw结构

图23-8显示了UDP的协议交换入口

成 员	inetsw[1]	描 述
<code>pr_type</code>	<code>SOCK_DGRAM</code>	UDP提供数据报分组服务
<code>pr_domain</code>	<code>&inetdomain</code>	UDP是Internet域的一部分
<code>pr_protocol</code>	<code>IPPROTO_UDP (17)</code>	出现在IP首部的ip_p字段
<code>pr_flags</code>	<code>PR_ATOMIC / PR_ADDR</code>	插口层标志，协议处理没有使用从IP层接收报文
<code>pr_input</code>	<code>Udp_input</code>	UDP没有使用
<code>pr_output</code>	<code>0</code>	ICMP差错的控制输入函数
<code>pr_ctlinput</code>	<code>udp_ctlinput</code>	响应来自进程的管理请求
<code>pr_ctloutput</code>	<code>ip_ctloutput</code>	响应来自进程的通信请求
<code>pr_usrreq</code>	<code>udp_usrreq</code>	初始化UDP
<code>pr_init</code>	<code>udp_init</code>	UDP没有使用
<code>pr_fasttimo</code>	<code>0</code>	UDP没有使用
<code>pr_slowtimo</code>	<code>0</code>	UDP没有使用
<code>pr_drain</code>	<code>0</code>	UDP没有使用
<code>pr_sysctl</code>	<code>udp_sysctl</code>	对sysctl(8)系统调用

图23-8 UDP的protosw 结构

本章我们描述五个以 `udp_` 开头的函数。另外我们还要介绍第 6 个函数 `udp_output`，它

不在协议交换入口，但当输出一个 UDP数据报时，`udp_usrreq`会调用它。

23.4 UDP的首部

UDP首部定义成一个`udphdr`结构。图23-9是C结构，图23-10是UDP首部的图。

```
39 struct udphdr {
40     u_short uh_sport;           /* source port */
41     u_short uh_dport;          /* destination port */
42     short   uh_ulen;           /* udp length */
43     u_short uh_sum;            /* udp checksum */
44 };

```

udp.h

图23-9 `udphdr` 结构

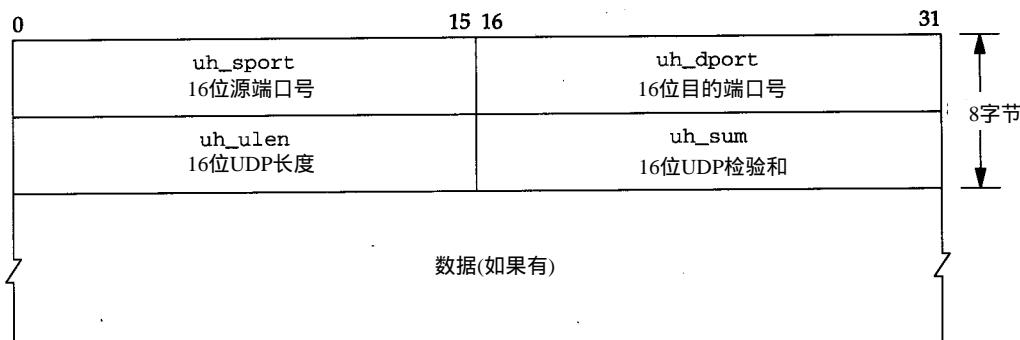


图23-10 UDP首部和可选数据

在源代码中，通常把 UDP首部作为一个紧跟着 UDP 首部的 IP首部来引用。这就是`udp_input`如何处理收到的IP数据报，以及`udp_output`如何构造外出的IP数据报。这种联合的IP/UDP首部是一个`udpiphdr`结构，如图23-11所示。

```
38 struct udpiphdr {
39     struct ipovly ui_i;           /* overlaid ip structure */
40     struct udphdr ui_u;          /* udp header */
41 };
42 #define ui_next    ui_i.ih_next
43 #define ui_prev    ui_i.ih_prev
44 #define ui_x1      ui_i.ih_x1
45 #define ui_pr      ui_i.ih_pr
46 #define ui_len     ui_i.ih_len
47 #define ui_src     ui_i.ih_src
48 #define ui_dst     ui_i.ih_dst
49 #define ui_sport   ui_u.uh_sport
50 #define ui_dport   ui_u.uh_dport
51 #define ui_ulen   ui_u.uh_ulen
52 #define ui_sum    ui_u.uh_sum

```

udp_var.h

图23-11 `udpiphdr` 结构：联合的IP/UDP首部

20字节的IP首部定义成一个`ipovly`结构，如图23-12所示。

不幸的是，这个结构并不是一个真正的如图 8-8所示的IP首部。大小相同(20字节)，但字

段不同。我们将在23.6节讲UDP检验和的计算时回来讨论这个不同之处。

```

38 struct ipovly {
39     caddr_t ih_next, ih_prev; /* for protocol sequence q's */
40     u_char ih_x1;           /* (unused) */
41     u_char ih_pr;           /* protocol */
42     short ih_len;           /* protocol length */
43     struct in_addr ih_src;  /* source internet address */
44     struct in_addr ih_dst;  /* destination internet address */
45 };

```

ip_var.h

图23-12 ipovly 结构

23.5 udp_init函数

domaininit函数在系统初始化时调用 UDP的初始化函数(udp_init，图23-13)。

这个函数所做的唯一的工作是把头部 PCB(udb)的向前和向后指针指向它自己。这是一个双向链表。

udb PCB的其他部分都被初始化成 0，尽管在这个头部 PCB中唯一使用的字段是 inp_lport，它是要分配的下一个UDPI临时端口号。在解习题 22.4时，我们提到，因为这个本地端口号被初始化成 0，所以第一个临时端口号将是 1024。

```

50 void
51 udp_init()
52 {
53     udb.inp_next = udb.inp_prev = &udb;
54 }

```

udp_usrreq.c

udp_usrreq.c

图23-13 udp_init 函数

23.6 udp_output函数

当应用程序调用以下五个写函数中的任意一个时，发生 UDP 输出。这五个函数是：send、sendto、sendmsg、write或writev。如果插口已连接上的，则可任意调用这五个函数，尽管用sendto或sendmsg不能指定目的地址。如果插口没有连接上，则只能调用 sendto和sendmsg，并且必须指定一个目的地址。图 23-14总结了这五个函数，它们在终止时，都调用 udp_output，该函数再调用 ip_output。

五个函数终止调用 sosend，并把一个指向 msghdr结构的指针作为参数传给该函数。要输出的数据被分装在一个 mbuf链上，sosend把一个可选的目的地址和可选的控制信息放到 mbuf中，并发布PRU_SEND请求。

UDP调用函数 udp_output，该函数的第一部分如图 23-15所示。四个参数分别是：inp，指向插口 Internet PCB的指针；m，指向输出 mbuf链的指针；addr，一个可选指针，指向某个 mbuf，存放分装在一个 sockaddr_in结构中的目的地址；control，一个可选指针，指向一个mbuf，其中存放着 sendmsg中的控制信息。

1. 去掉可选控制信息

333-344 m_freem丢弃可选的控制信息，不产生差错。 UDP输出不使用任何控制信息。

注释`xxx`是因为忽略控制信息且不产生错误。其他协议如路由选择域和 TCP，当进程传递控制信息时，都会产生一个错误。

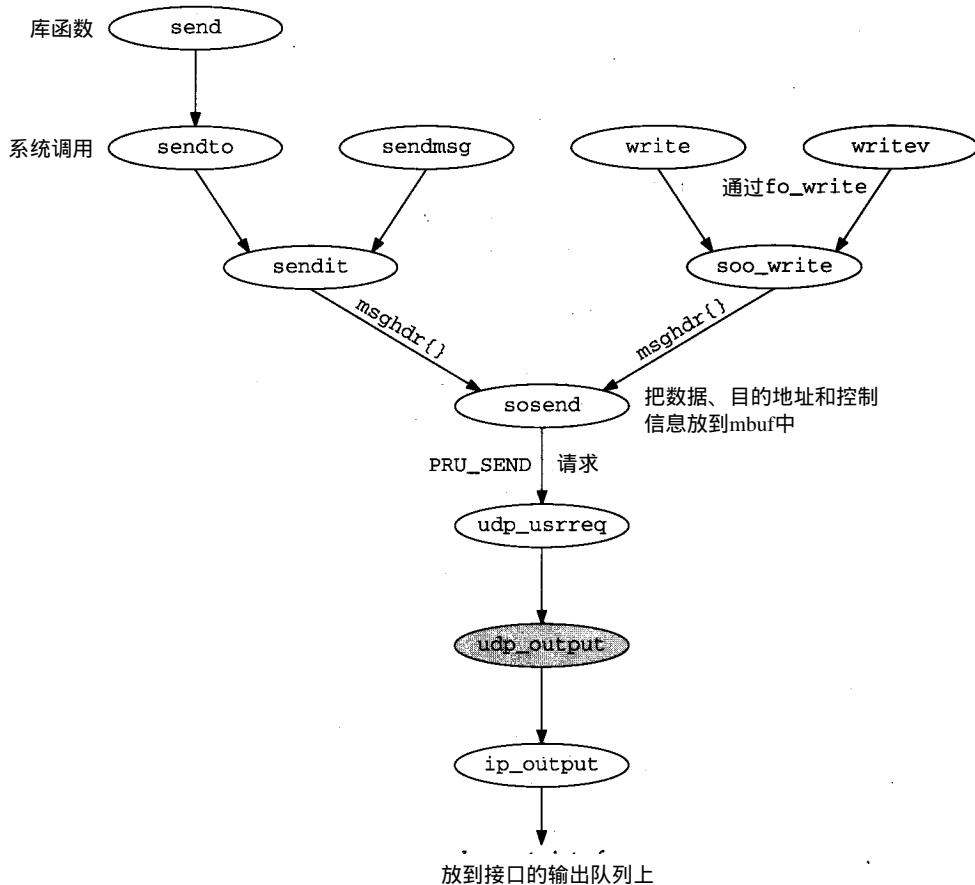


图23-14 五个写函数如何终止调用 `udp_output`

2. 临时连接一个未连接上的插口

345-359 如果调用方为 UDP 数据报指定了目的地址(`addr`非空)，则插口是由 `in_pcbconnect` 临时连接到该目的地址的，并在该函数的最后被断连。在连接之前，要作一个检测，判断插口是否已经连接上。如果已连接上，则返回错误 `EISCONN`。这就是为什么 `sendto` 在已连接上的插口上指定目的地址时，会返回错误。

在临时连接插口之前，`splnet` 停止 IP 的输入处理。这样做的原因是临时连接将改变插口 PCB 中的外部地址、外部端口以及本地地址。如果在临时连接该 PCB 的过程中处理某个收到的 UDP 数据报，可能把该数据报提交给错误的进程。把处理器设置成比 `splnet` 优先，只能阻止软件中断引发执行 IP 输入程序(图1-12)，它不能阻止接口层接收进入的分组，并把它们放到 IP 的输入队列中。

[Partridge 和 Pink 1993] 注意到临时连接插口的这个操作开销很大，用去每个 UDP 传送将近三分之一的时间。

在临时连接之前，PCB 的本地地址被保存在 `laddr` 中，因为如果它是通配地址，它将被

in_pcconnect在调用in_pcbind时改变。

如果进程调用了connect，则应用于目的地址的同一规则也将适用，因为两种情况都将调用in_pcconnect。

— udp_usrreq.c

```

333 int
334 udp_output(inp, m, addr, control)
335 struct inpcb *inp;
336 struct mbuf *m;
337 struct mbuf *addr, *control;
338 {
339     struct udiphdr *ui;
340     int      len = m->m_pkthdr.len;
341     struct in_addr laddr;
342     int      s, error = 0;

343     if (control)
344         m_freem(control); /* XXX */

345     if (addr) {
346         laddr = inp->inp_laddr;
347         if (inp->inp_faddr.s_addr != INADDR_ANY) {
348             error = EISCONN;
349             goto release;
350         }
351         /*
352          * Must block input while temporarily connected.
353          */
354         s = splnet();
355         error = in_pcconnect(inp, addr);
356         if (error) {
357             splx(s);
358             goto release;
359         }
360     } else {
361         if (inp->inp_faddr.s_addr == INADDR_ANY) {
362             error = ENOTCONN;
363             goto release;
364         }
365     }
366     /*
367      * Calculate data length and get an mbuf for UDP and IP headers.
368      */
369     M_PREPEND(m, sizeof(struct udiphdr), M_DONTWAIT);
370     if (m == 0) {
371         error = ENOBUFS;
372         goto release;
373     }

    /* remainder of function shown in Figure 23.20 */

409     release:
410     m_freem(m);
411     return (error);
412 }
```

— udp_usrreq.c

图23-15 udp_output 函数：临时连接一个未连接上的插口

360-364 如果进程没有指定目的地址，并且插口没有连接上，则返回 ENOTCONN。

3. 在前面加上IP/UDP首部

366-373 M_PREPEND在数据的前面为IP和UDP首部分配空间。图1-8是一种情况，假定mbuf链上的第一个mbuf已经没有空间存放首部的28个字节。习题23.1详细给出了其他情况。需要指定标志位 M_DONTWAIT，因为如果插口是临时连接的，则IP处理被阻塞，所以M_PREPEND也应被阻塞。

早期的伯克利版本不正确地指定了这里的M_WAIT。

23.6.1 在前面加上IP/UDP首部和mbuf簇

在M_PREPEND宏和mbuf簇之间有一个微妙的交互。如果sosend把用户数据放到一个簇中，则该簇的最前面的56个字节(max_hdr，图7-17)没有使用，这就为以太网、IP和UDP首部提供了空间。避免M_PREPEND仅仅为存放这些首部而另外再分配一个mbuf。M_PREPEND调用M.LEADINGSPACE来计算在mbuf的前面有多大的空间可以使用：

```
#define M.LEADINGSPACE(m) \
    ((m)->m_flags & M_EXT ? /* (m)->m_data - (m)->m_ext_buf */ 0 : \
     (m)->m_flags & M_PKTHDR ? (m)->m_data - (m)->m_pktdat : \
     (m)->m_data - (m)->m_dat)
```

正确地计算出簇前面可用空间大小的代码被注释掉了，如果数据在簇内，该宏总是返回0。这意味着，当用户数据也在某个簇中时，M_PREPEND总是为协议首部分配一个新的mbuf，而不再使用sosend分配的用于存放首部的空间。

M.LEADINGSPACE中注释掉正确代码的原因是因为该簇可能被共享(2.9节)，而且，如果它被共享，使用簇中数据报前面的空间可能会擦掉其他数据。

UDP数据不共享簇，因为udp_output不保存数据的备份。但是TCP在它的发送缓存内保存数据备份(等待对该数据的确认)，而且如果数据不在簇内，则说明它是共享的。但tcp_output不调用M.LEADINGSPACE，因为sosend只为数据报协议在簇前面留56个字节，所以，tcp_output总是调用MGETHDR为协议首部分配一个mbuf。

23.6.2 UDP检验和计算和伪首部

在讨论udp_output的最后一部分之前，我们描述一下UDP如何填充IP/UDP首部的某些字段，如何计算UDP检验和，以及如何传递IP/UDP首部及数据给IP输出的。这些工作很巧妙地使用了ipovly结构。

图23-16显示了udp_output在由m指向的mbuf链的第一个存储器上构造的28字节IP/UDP首部。没有阴影的字段是udp_output填充的，有阴影的字段是ip_output填充的。这个图显示了首部在线路上的格式。

UDP检验和的计算覆盖了三个区域：(1)一个12字节的伪首部，其中包含IP首部的字段；(2)8字节UDP首部，和(3)UDP数据。图23-17显示了用于检验和计算的12字节伪首部，以及UDP首部。用于计算检验和的UDP首部等价于出现在线路上的UDP首部(图23-16)。

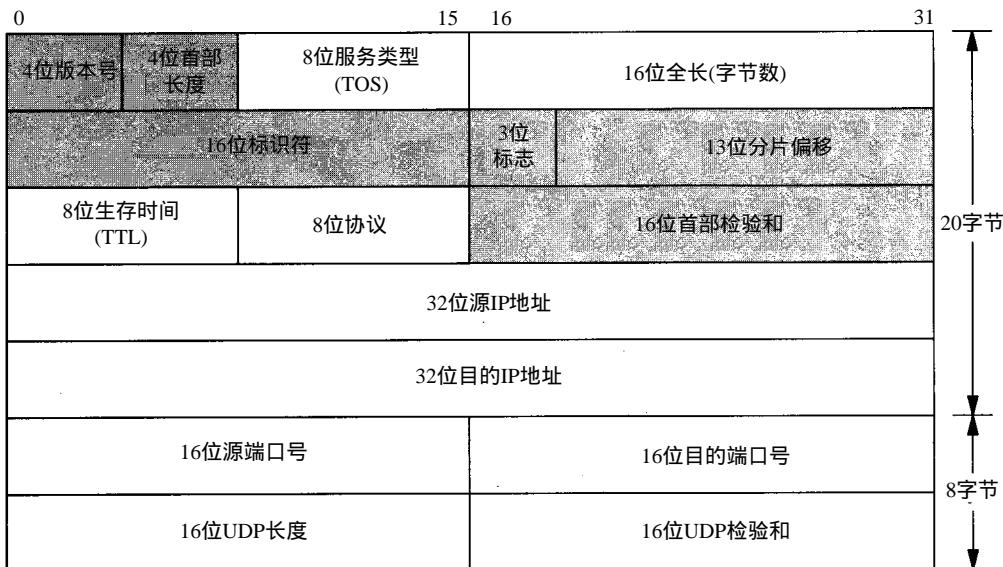


图23-16 IP/UDP首部：UDP填充没有阴影的字段，IP填充有阴影的字段

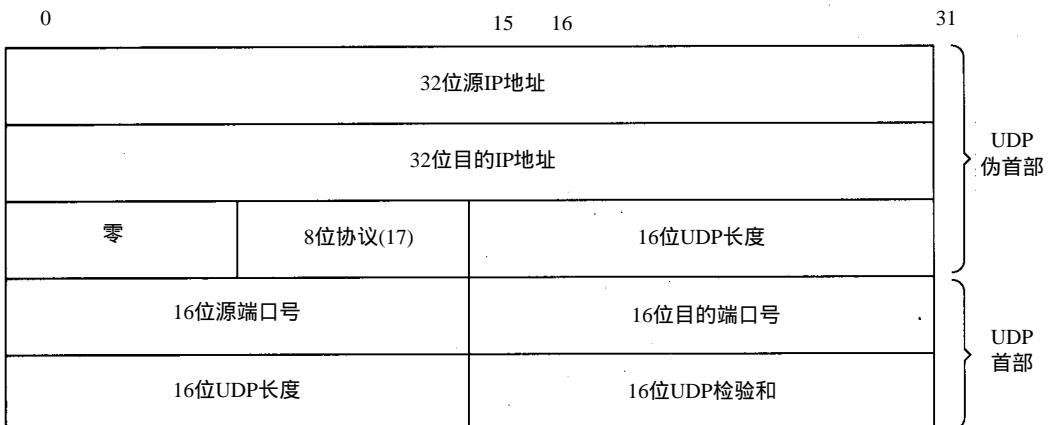


图23-17 检验和计算所使用的伪首部和 UDP首部

在计算UDP检验和时使用以下三个事实：(1)在伪首部(图23-17)中的第三个32 bit字看起来与IP首部(图23-16)中的第三个32 bit字类似：两个8 bit值和一个16 bit值。(2)伪首部中三个32 bit值的顺序是无关的。事实上，Internet检验和的计算不依赖于所使用的16 bit值的顺序(8.7节)。(3)在检验和计算中另外再加上一个全0的32 bit字没有任何影响。

udp_output利用这三个事实，填充 udpiphdr结构(图23-11)的字段，如图23-18所示。该结构包含在由m指向的mbuf链的第一个mbuf中。

在20字节IP首部(5个成员：ui_x1、ui_pr、ui_len、ui_src和ui_dst)中的最后三个32 bit字被用作检验和计算的伪首部。IP首部的前两个32 bit字(ui_next和ui_prev)也用在检验和计算中，但它们被初始化成0，所以不影响最后的检验和。

图23-19总结了我们描述的操作：

- 1) 图23-19中最上面的图是伪首部的协议定义，与图23-17对应。

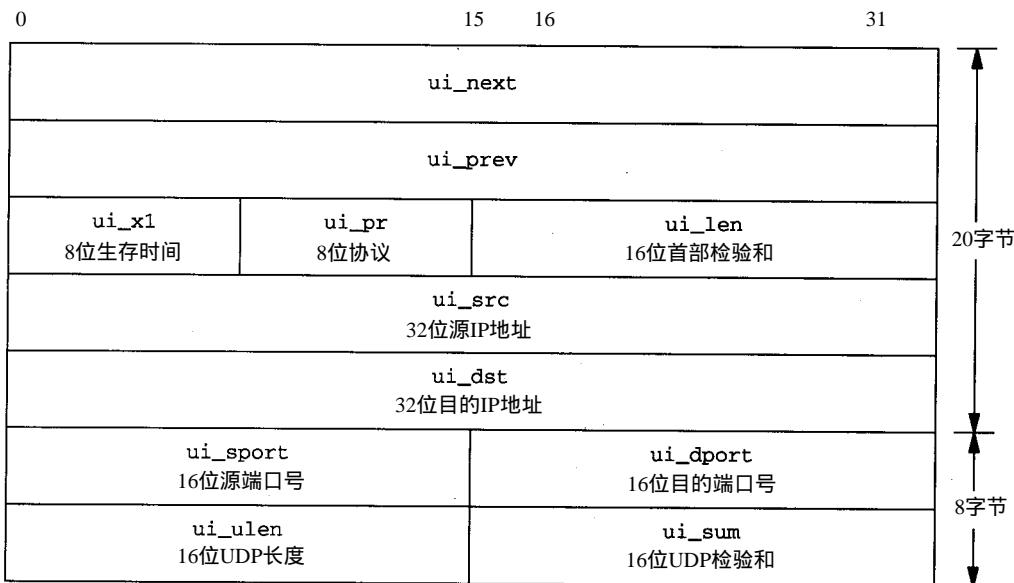


图23-18 udp_output 填充的 udpiphdr

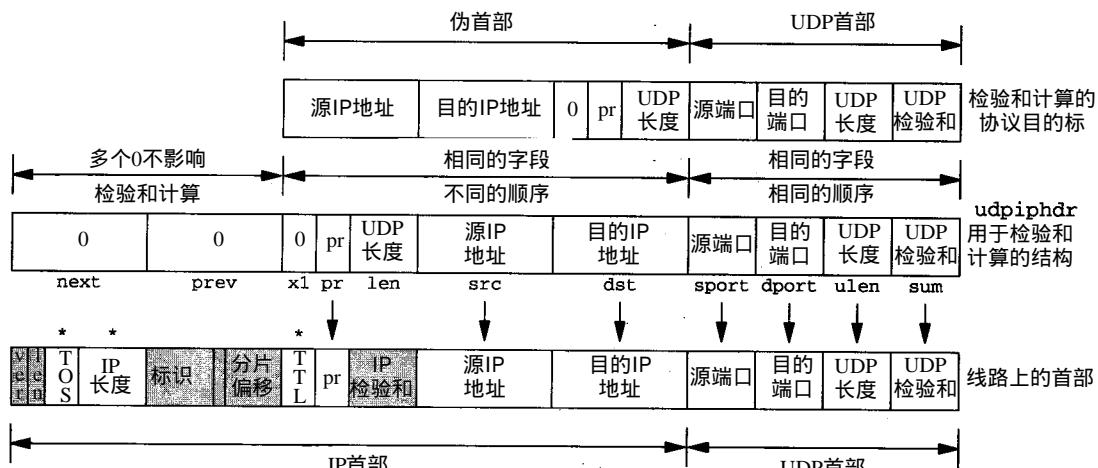


图23-19 填充IP/UDP首部和计算 UDP 检验和的操作

2) 中间的图是源代码使用的 udpiphdr 结构，与图 23-11 对应(为图的可读性，省略了所有成员的前缀 ui_)。这是 udp_output 在 mbuf 链上的第一个 mbuf 中构造的结构，然后被用于计算 UDP 检验和。

3) 下面的图是出现在线路上的 IP/UDP 首部，与图 23-16 对应。上面有箭头的 7 个字段是 udp_output 在检验和计算之前填充的。上面有星号的 3 个字段是 udp_output 在检验和计算之后填充的。其他 6 个有阴影的字段是 ip_output 填充的。

图23-20是udp_output函数的后半部分。

1. 为检验和计算准备伪首部

374-387 把 udpiphdr 结构(图23-18)的所有成员设置成它们相应的值。PCB中的本地和外部插口已经是网络字节序，但必须把 UDP 的长度转换成网络字节序。UDP 的长度是数据报的

字节数(len，可以是0)加上UDP首部的大小(8)。UDP长度字段在UDP检验和计算中出现了两次：ui_len和ui_ulen。有一个是冗余的。

```

374     /*
375      * Fill in mbuf with extended UDP header
376      * and addresses and length put into network format.
377      */
378     ui = mtod(m, struct udphdr *);
379     ui->ui_next = ui->ui_prev = 0;
380     ui->ui_x1 = 0;
381     ui->ui_pr = IPPROTO_UDP;
382     ui->ui_len = htons((u_short) len + sizeof(struct udphdr));
383     ui->ui_src = inp->inp_laddr;
384     ui->ui_dst = inp->inp_faddr;
385     ui->ui_sport = inp->inp_lport;
386     ui->ui_dport = inp->inp_fport;
387     ui->ui_ulen = ui->ui_len;

388     /*
389      * Stuff checksum and output datagram.
390      */
391     ui->ui_sum = 0;
392     if (udpcksum) {
393         if ((ui->ui_sum = in_cksum(m, sizeof(struct udphdr) + len)) == 0)
394             ui->ui_sum = 0xffff;
395     }
396     ((struct ip *) ui)->ip_len = sizeof(struct udphdr) + len;
397     ((struct ip *) ui)->ip_ttl = inp->inp_ip.ip_ttl; /* XXX */
398     ((struct ip *) ui)->ip_tos = inp->inp_ip.ip_tos; /* XXX */
399     udpstat.udps_opackets++;
400     error = ip_output(m, inp->inp_options, &inp->inp_route,
401                       inp->inp_socket->so_options & (SO_DONTROUTE | SO_BROADCAST),
402                       inp->inp_moptions);

403     if (addr) {
404         in_pcbdisconnect(inp);
405         inp->inp_laddr = laddr;
406         splx(s);
407     }
408     return (error);

```

— udp_usrreq.c

图23-20 udp_output 函数：填充首部、计算检验和并传给 IP

2. 计算检验和

388–395 计算检验和时，首先把它设成0，然后调用in_cksum。如果UDP检验和是禁止的（一个坏的想法——见卷1的11.3节），则检验和的结果是0。如果计算的检验和是0，则在首部中保存16个1，而不是0（在求补运算中，全1和全0都是0）。这样，接收方就可以区分没有检验和的UDP分组（检验和字段为0）和有检验和的UDP分组了，后者的检验和值为0（16位的检验和是16个1）。

变量udpcksum（图23-3）通常默认值为1，使能 UDP检验和。对内核的编译可对

4.2BSD兼容，把udpcksum初始化为0。

3. 填充UDP长度、TTL和TOS

396–398 指针ui指向一个指向某个标准IP首部的指针(ip)，UDP设置IP首部内的三个字段。IP长度字段等于UDP数据报中数据的个数加上IP/UDP首部大小28。注意，IP首部的这个字段

以主机字节序保存，不象首部其他多字节字段，是以网络字节序保存的。`ip_output`在发送之前，把它转换成网络字节序。

把IP首部里的TTL和TOS字段的值设成插口PCB中的值。在创建插口时，UDP设置这些默认值，进程可用`setsockopt`改变它们。因为这三个字段——IP长度、TTL和TOS——不是伪首部的内容，UDP检验和计算时也没有用到它们，所以，在计算检验和之后，调用`ip_output`之前，必须设置它们。

4. 发送数据报

400-402 `ip_output`发送数据报。第二个参数`inp_options`，是进程可用`setsockopt`设置的IP选项。这些IP选项是`ip_output`放置到IP首部中的。第三个参数是一个指向高速缓存在PCB中的路由的指针，第四个参数是插口选项。传给`ip_output`的唯一插口选项是`SO_DONTROUTE`(旁路选路表)和`SO_BROADCAST`(允许广播)。最后一个参数是一个指向该插口的多播选项的指针。

5. 断连临时连接的插口

403-407 如果插口是临时连接上的，则`in_pcbservice`断连插口，本地IP地址在PCB中恢复，恢复中断级别到保存的值。

23.7 udp_input函数

进程调用五个写函数之一来驱动UDP输出。图23-14显示的函数都作为系统调用的组成部分被直接调用。另一方面，当IP在它的协议字段指定为UDP的输入队列上收到一个IP数据报时，才发生UDP的输入。IP通过协议交换表(图8-15)中的`pr_input`函数调用函数`udp_input`。因为IP的输入是在软件中断级，所以`udp_input`也在这一级上执行。`udp_input`的目标是把UDP数据报放置到合适的插口的缓存内，唤醒该插口上因输入阻塞的所有进程。

我们对`udp_input`函数的讨论分三个部分：

- 1) UDP对收到的数据报完成一般性的确认；
- 2) 处理目的地是单播地址的UDP数据报：找到合适的PCB，把数据报放到插口的缓存内，
- 3) 处理目的地是广播或多播地址的UDP数据报：必须把数据报提交给多个插口。

最后一步是新的，是为了在Net/3中支持多播，但占用了大约三分之一的代码。

23.7.1 对收到的UDP数据报的一般确认

图23-21是UDP输入的第一部分。

55-65 `udp_input`的两个参数是：`m`，一个指向包含了该IP数据报的mbuf链的指针；`iphlen`，IP首部的长度(包括可能的IP选项)。

1. 丢弃IP选项

67-76 如果有IP选项，则`ip_stripoptions`丢弃它们。正如注释中表明的，UDP应该保存IP选项的一个备份，使接收进程可以通过`IP_RECVOPTS`插口选项访问到它们，但这个还没有实现。

77-88 如果mbuf链上的第一个mbuf小于28字节(IP首部加上UDP首部的大小)，则`m_pullup`重新安排mbuf链，使至少有28个字节连续地存放在第一个mbuf中。

udp_usrreq.c

```

55 void
56 udp_input(m, iphlen)
57 struct mbuf *m;
58 int     iphlen;
59 {
60     struct ip *ip;
61     struct udphdr *uh;
62     struct inpcb *inp;
63     struct mbuf *opts = 0;
64     int      len;
65     struct ip save_ip;
66     udpstat.udps_ipackets++;
67     /*
68      * Strip IP options, if any; should skip this,
69      * make available to user, and use on returned packets,
70      * but we don't yet have a way to check the checksum
71      * with options still present.
72      */
73     if (iphlen > sizeof(struct ip)) {
74         ip_stripoptions(m, (struct mbuf *) 0);
75         iphlen = sizeof(struct ip);
76     }
77     /*
78      * Get IP and UDP header together in first mbuf.
79      */
80     ip = mtod(m, struct ip *);
81     if (m->m_len < iphlen + sizeof(struct udphdr)) {
82         if ((m = m_pullup(m, iphlen + sizeof(struct udphdr))) == 0) {
83             udpstat.udps_hdrops++;
84             return;
85         }
86         ip = mtod(m, struct ip *);
87     }
88     uh = (struct udphdr *) ((caddr_t) ip + iphlen);
89     /*
90      * Make mbuf data length reflect UDP length.
91      * If not enough data to reflect UDP length, drop.
92      */
93     len = ntohs((u_short) uh->uh_ulen);
94     if (ip->ip_len != len) {
95         if (len > ip->ip_len) {
96             udpstat.udps_badlen++;
97             goto bad;
98         }
99         m_adj(m, len - ip->ip_len);
100        /* ip->ip_len = len; */
101    }
102    /*
103     * Save a copy of the IP header in case we want to restore
104     * it for sending an ICMP error message in response.
105     */
106    save_ip = *ip;
107    /*
108     * Checksum extended UDP header and data.
109     */
110    if (udpcksum && uh->uh_sum) {

```

图23-21 `udp_input` 函数：对收到的UDP数据报的一般确认

```

111     ((struct ipovly *) ip)->ih_next = 0;
112     ((struct ipovly *) ip)->ih_prev = 0;
113     ((struct ipovly *) ip)->ih_x1 = 0;
114     ((struct ipovly *) ip)->ih_len = uh->uh_ulen;
115     if (uh->uh_sum = in_cksum(m, len + sizeof(struct ip))) {
116         udpstat.udps_badsum++;
117         m_freem(m);
118         return;
119     }
120 }

```

——udp_usrreq.c

图23-21 (续)

2. 验证UDP长度

与 UDP 数据报相关的两个长度是：IP首部的长度字段(ip_len)和 UDP首部的长度字段(uh_ulen)。前面讲到，ipintr在调用udp_input之前，从ip_len中抽取出IP首部的长度(图10-11)。比较这两个长度，可能有三种可能性：

1) ip_len等于uh_ulen。这是通常情况。

2) ip_len大于uh_ulen。IP首部太大，如图 23-22 所示。代码相信两个长度中小的那个(UDP首部长度)，m_adj从数据报的最后移走多余的数据字节。m_adj的第二个参数是负数，在图 2-20 中我们说，从mbuf链的最后截断数据。在这种情况下，UDP的长度字段出现冲突。如果是这样，假定发送方计算了 UDP的检验和，则不久检验和会检测到这个错误，接收方也会验证检验和，从而丢弃该数据报。IP长度字段必须正确，因为 IP根据接口上收到的数据量验证它，而强制的IP首部检验和覆盖了IP首部的长度字段。

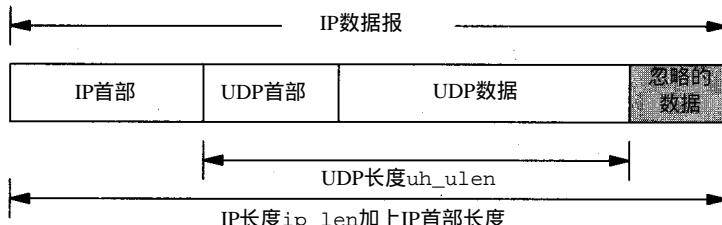


图23-22 UDP长度太小

3) ip_len小于uh_ulen。当 UDP 首部的长度给定时，IP数据报比可能的小。图 23-23 显示了这种情况。这说明数据报有错误，必须丢弃，没有其他的选择：如果 UDP长度字段被破坏，用 UDP检验和是无法检测到的。需要用正确的 UDP长度来计算 UDP检验和。

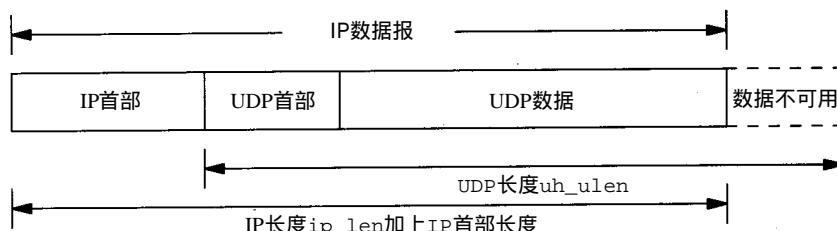


图23-23 UDP长度太大

正如我们提到的，UDP长度是冗余的。在第28章中我们将看到，TCP自己的首部内没有长度字段——它用IP长度字段减去IP和TCP首部的长度，以此确定数据报内数

据的数量。为什么存在 UDP长度字段呢？可能是为了加上少量的差错检测，因为 UDP检验和是可选的。

3. 保存IP首部的备份，验证UDP检验和

102-106 `udp_input` 在验证检验和之前保存 IP首部的备份，因为检验和计算会擦去原始 IP首部的一些字段。

110 只有当的UDP检验和(`udpcksum`)是内核允许的，并且发送方也计算了 UDP检验和(收到的检验和不为0)时，才验证检验和。

这个检测是不正确的。如果发送方计算了一个检验和，就应该验证它，不管外出的检验和是否被计算。变量 `udpcksum` 应该只指定是否计算外出的检验和。不幸的是，许多厂商都复制了这个检测，尽管厂商已经改变它们产品的内核，却默认地允许 UDP检验和。

111-120 在计算检验和之前，IP首部作为 `ipovl_y` 结构(图23-18)引用，所有字段的初始化都是 `udp_output` 在计算 UDP检验和(上一节)时初始化的。

此时，如果数据报的目的地是一个广播或多播 IP地址，将执行特别的代码。我们把这段代码推迟到本节最后。

23.7.2 分用单播数据报

假定数据报的目的地是一个单播地址，图 23-24 显示了执行的代码。

udp_usrreq.c

```

206  /*
207   * Locate pcb for unicast datagram.
208   */
209   inp = udp_last_inpcb;
210   if (inp->inp_lport != uh->uh_dport ||
211       inp->inp_fport != uh->uh_sport ||
212       inp->inp_faddr.s_addr != ip->ip_src.s_addr ||
213       inp->inp_laddr.s_addr != ip->ip_dst.s_addr) {
214
215       inp = in_pcblookup(&udb, ip->ip_src, uh->uh_sport,
216                           ip->ip_dst, uh->uh_dport, INPLOOKUP_WILDCARD);
217
218       if (inp)
219           udp_last_inpcb = inp;
220       udpstat.udpps_pcbcachemiss++;
221   }
222   if (inp == 0) {
223       udpstat.udps_noport++;
224       if (m->m_flags & (M_BCAST | M_MCAST)) {
225           udpstat.udps_noportbcast++;
226           goto bad;
227       }
228       *ip = save_ip;
229       ip->ip_len += iphlen;
230       icmp_error(m, ICMP_UNREACH, ICMP_UNREACH_PORT, 0, 0);
231   }

```

udp_usrreq.c

图23-24 `udp_input` 函数：分用单播数据报

1. 检查“向后一个”高速缓存

206-209 UDP 维护一个指针，该指针指向最后在其上接收数据报的 Internet PCB，`udp_last_inpcb`。在调用 `in_pcblockup` 之前，可能必须搜索 UDP 表上的 PCB，把最近一次接收 PCB 的外部和本地地址以及端口号和收到数据报的进行比较。这称为“向后一个”高速缓存(one-behind cache)[Partridge 和 Pink 1993]。它是根据这样一个假设，即收到的数据报极有可能要发往上一个数据报发往的同一端口 [Mogul 1991]。这个高速缓存技术是在 4.3BSD Tahoe 版本中引入的。

210-213 高速缓存的 PCB 和收到数据报之间的四个比较的次序是故意安排的。如果 PCB 不匹配，则应尽快结束比较。最大的可能性是目的端口号不相同——这就是为什么第一个检测它。不匹配的可能性最小的是本地地址，尤其在只有一个接口的主机，所以它是最后一个检测。

不幸的是，这种“向后一个”高速缓存技术代码，在实际中毫无用处 [Partridge 和 Pink 1993]。最普通的 UDP 服务器类型只绑定它的知名端口，它的本地地址、外部地址和外部端口都是通配地址。最普通的 UDP 客户程序类型并不连接它的 UDP 插口；它用 `sendto` 指定每个数据报的目的地址。因此，大多数时间 PCB 内的 `inp_laddr`、`inp_faddr` 和 `inp_fport` 都是通配的。在高速缓存的比较中，收到数据报的这四个值永远都不是通配的，这意味着只有当指定 PCB 的四个本地和外部值是非通配时，高速缓存入口与收到数据报的比较才可能相等。这种情况只在连接上的 UDP 插口上发生。

在系统 bsdi 上，`udpps_pcblockmiss` 计数器是 41 253，`udps_ipackets` 计数器是 42 485。小于 3% 缓存命中率。

`netstat -s` 命令打印出 `udpstat` 结构(图 23-5)的大多数组字段。不幸的是，Net/3 版本，以及多数厂家的版本都不打印 `udpps_pcblockmiss`。如果你想看它们的值，用调试器检查在运行的内核中的变量。

2. 搜索所有 UDP 的 PCB

214-218 假定与高速缓存的比较失败，则 `in_pcblockup` 寻找一个匹配。指定 `INPLLOOKUP_WILDCARD` 标志，允许通配匹配。如果找到一个匹配，则把指向该 PCB 的指针保存在 `udp_last_inpcb` 中，我们说它高速缓存了最后收到的 UDP 数据报的 PCB。

3. 生成 ICMP 端口不可达差错

220-230 如果没找到匹配的 PCB，UDP 通常产生一个 ICMP 端口不可达差错。首先检测收到的 mbuf 链的 `m_flags`，看看该数据报是否是要发送到一个链路级广播或多播地址。有可能会收到一个发送到链路级广播或多播地址的 IP 数据报，具有单播地址，此时不应该产生 ICMP 端口不可达差错。如果成功产生 ICMP 差错，则把 IP 首部恢复成收到它时的值 (`save_ip`)，也把 IP 长度设置成它原来的值。

链路级广播或多播地址的检测是冗余的。`icmp_error` 也做这个检测。这个冗余检测的唯一好处是，在 `udps_noportbcast` 计数器之外，还维护了 `udps_noport` 计数器。

把 `iphlen` 改回 `ip_len` 是一个错误。`icmp_error` 也会做这项工作，使得 ICMP 差错返回的 IP 首部的 IP 长度字段是 20 字节，这太大了。可以在 Traceroute 程

序(卷1的第8章)中加上几行新程序，在最终到达目的主机后，打印出 ICMP端口不可达差错报文中的这个字段，可以测试系统是否有这个错误。

图23-25是处理单播数据报的代码，把数据报提交给与目的PCB对应的插口。

```

231  /*
232   * Construct sockaddr format source address.
233   * Stuff source address and datagram in user buffer.
234   */
235   udp_in.sin_port = uh->uh_sport;
236   udp_in.sin_addr = ip->ip_src;

237   if (inp->inp_flags & INP_CONTROLOPTS) {
238       struct mbuf **mp = &opts;

239       if (inp->inp_flags & IP_RECVSTADDR) {
240           *mp = udp_saveopt((caddr_t) & ip->ip_dst,
241                             sizeof(struct in_addr), IP_RECVSTADDR);
242           if (*mp)
243               mp = &(*mp)->m_next;
244       }
245 #ifdef notyet
246     /* IP options were tossed above */
247     if (inp->inp_flags & INP_RECVOPTS) {
248         *mp = udp_saveopt((caddr_t) opts_deleted_above,
249                           sizeof(struct in_addr), IP_RECVOPTS);
250         if (*mp)
251             mp = &(*mp)->m_next;
252     }
253     /* ip_srcroute doesn't do what we want here, need to fix */
254     if (inp->inp_flags & INP_RECVRETOPTS) {
255         *mp = udp_saveopt((caddr_t) ip_srcroute(),
256                           sizeof(struct in_addr), IP_RECVRETOPTS);
257         if (*mp)
258             mp = &(*mp)->m_next;
259     }
260 #endif
261   }
262   iphlen += sizeof(struct udphdr);
263   m->m_len -= iphlen;
264   m->m_pkthdr.len -= iphlen;
265   m->m_data += iphlen;
266   if (sbappendaddr(&inp->inp_socket->so_rcv, (struct sockaddr *) &udp_in,
267                     m, opts) == 0) {
268       udpstat.udps_fullsock++;
269       goto bad;
270   }
271   sorwakeup(inp->inp_socket);
272   return;

273 bad:
274     m_freem(m);
275     if (opts)
276         m_freem(opts);
277 }

```

— udp_usrreq.c

图23-25 udp_input 函数：把单播数据报提交给插口

4. 返回源站IP地址和源站端口

231-236 收到的IP数据报的源站IP地址和源站端口被保存在全局 sockaddr_in结构中的

udp_in。在函数的后面，该结构作为参数传给了 sbappendaddr。

采用全局变量保存 IP地址和端口号不出现问题的原因是， udp_input 是单线程的。当 ipintr 调用它时，它在返回之前完整地处理了收到的数据报。而且， sbappendaddr 还把该插口结构从全局变量复制一个 mbuf 中。

5. IP_RECVDSTADDR 插口选项

337-244 常数 INP_CONTROL_OPTS 是三个插口选项的结合，进程可以设置这三个插口选项，通过系统调用 recvmsg 返回插口的控制信息（图 22-5）。IP_RECVDSTADDR 把收到的 UDP 数据报中的目的 IP 地址作为控制信息返回。函数 udp_saveopt 分配一个 MT_CONTROL 类型的 mbuf，并把 4 字节的目的 IP 地址存放在该缓存中。我们在 23.8 节中介绍这个函数。

该插口选项与 4.3BSD Reno 一起出现，是为一般文件传输协议 TFTP 的应用程序设计的，它们不响应发给广播地址的客户程序请求。不幸的是，即使接收应用程序使用这个选项，也很难确定目的 IP 地址是否是一个广播地址（习题 23.6）。

当 4.4BSD 中加上了多播功能后，这个代码只对目的地是单播地址的数据报有效。我们将在图 23-26 看到，对发给多播地址的广播数据报还没有实现这个选项，根本无法达到该选项的目的。

6. 未实现的插口选项

245-260 这段代码被注释掉了，因为它们不起作用。IP_RECVOPTS 插口选项的原意是把收到数据报的 IP 选项作为控制信息返回，而 IP_RECVRETOPTS 插口选项返回源路由信息。三个 IP_RECV 插口选项对 mp 变量的操作构造了一个最多有三个 mbuf 的链表，该链表由 sbappendaddr 放置到插口的缓存。图 23-25 显示的代码只把一个选项作为控制信息返回，所以指向该 mbuf 的 m_next 总是一个空指针。

7. 把数据加到插口的接收队列中

262-272 此时，已经准备好把收到的数据报（m 指向的 mbuf 链）以及一个表示发送方 IP 地址和端口的插口地址结构（udp_in）和一些可选的控制信息（opts 指向的 mbuf，目的 IP 地址）放到插口的接收队列中。这个工作由 sbappendaddr 完成。但在调用这个函数之前，要修正指针和缓存链上的第一个 mbuf，忽略掉 UDP 和 IP 首部。返回之前，调用 sorwakeup 唤醒插口接收队列中的所有睡眠进程。

8. 返回差错

273-276 如果在 UDP 输入处理的过程中遇到错误，udp_input 会跳转到 bad 标号语句，释放所有包含该数据报以及控制信息（如果有的话）的 mbuf 链。

23.7.3 分用多播和广播数据报

现在返回到 udp_input 处理发给广播或多播 IP 地址数据报的这部分代码。如图 23-26 所示。

121-138 正如注释所表明的，这些数据报被提交给匹配的所有插口，而不仅仅是一个插口。我们提到的 UDP 接口不够指的是除非连接上插口，否则进程没有能力在 UDP 插口上接收异步差错（特别是 ICMP 端口不可达差错）。我们 22-11 节讨论这个问题。

139-145 源站的 IP 地址和端口号被保存在全局 sockaddr_in 结构的 udp_in 中，传给 sbappendaddr。更新 mbuf 链的长度和数据指针，忽略 UDP 和 IP 首部。

udp_usrreq.c

```

121     if (IN_MULTICAST(ntohl(ip->ip_dst.s_addr)) ||
122         in_broadcast(ip->ip_dst, m->m_pkthdr.rcvif)) {
123         struct socket *last;
124         /*
125          * Deliver a multicast or broadcast datagram to *all* sockets
126          * for which the local and remote addresses and ports match
127          * those of the incoming datagram. This allows more than
128          * one process to receive multi/broadcasts on the same port.
129          * (This really ought to be done for unicast datagrams as
130          * well, but that would cause problems with existing
131          * applications that open both address-specific sockets and
132          * a wildcard socket listening to the same port -- they would
133          * end up receiving duplicates of every unicast datagram.
134          * Those applications open the multiple sockets to overcome an
135          * inadequacy of the UDP socket interface, but for backwards
136          * compatibility we avoid the problem here rather than
137          * fixing the interface. Maybe 4.5BSD will remedy this?)
138         */
139         /*
140          * Construct sockaddr format source address.
141         */
142         udp_in.sin_port = uh->uh_sport;
143         udp_in.sin_addr = ip->ip_src;
144         m->m_len -= sizeof(struct udiphdr);
145         m->m_data += sizeof(struct udiphdr);
146         /*
147          * Locate pcb(s) for datagram.
148          * (Algorithm copied from raw_intr().)
149         */
150         last = NULL;
151         for (inp = udb.inp_next; inp != &udb; inp = inp->inp_next) {
152             if (inp->inp_lport != uh->uh_dport)
153                 continue;
154             if (inp->inp_laddr.s_addr != INADDR_ANY) {
155                 if (inp->inp_laddr.s_addr !=
156                     ip->ip_dst.s_addr)
157                     continue;
158             }
159             if (inp->inp_faddr.s_addr != INADDR_ANY) {
160                 if (inp->inp_faddr.s_addr !=
161                     ip->ip_src.s_addr ||
162                     inp->inp_fport != uh->uh_sport)
163                     continue;
164             }
165             if (last != NULL) {
166                 struct mbuf *n;
167
168                 if ((n = m_copy(m, 0, M_COPYALL)) != NULL) {
169                     if (sbappendaddr(&last->so_rcv,
170                                     (struct sockaddr *)&udp_in,
171                                     n, (struct mbuf *) 0) == 0) {
172                         m_freem(n);
173                         udpstat.udps_fullsock++;
174                     } else
175                         sorwakeup(last);
176                 }
177             last = inp->inp_socket;

```

图23-26 udp_input 函数：分用广播或多播数据报

```

178     /*
179      * Don't look for additional matches if this one does
180      * not have either the SO_REUSEPORT or SO_REUSEADDR
181      * socket options set. This heuristic avoids searching
182      * through all pcbs in the common case of a non-shared
183      * port. It assumes that an application will never
184      * clear these options after setting them.
185      */
186     if ((last->so_options & (SO_REUSEPORT | SO_REUSEADDR) == 0))
187         break;
188     }
189
190     if (last == NULL) {
191         /*
192          * No matching pcb found; discard datagram.
193          * (No need to send an ICMP Port Unreachable
194          * for a broadcast or multicast datagram.)
195          */
196         udpstat.udps_noportbcst++;
197         goto bad;
198     }
199     if (sbappendaddr(&last->so_rcv, (struct sockaddr *) &udp_in,
200                     m, (struct mbuf *) 0) == 0) {
201         udpstat.udps_fullsock++;
202         goto bad;
203     }
204     sorwakeup(last);
205     return;
206 }
```

udp_usrreq.c

图23-26 (续)

146-164 大的 for 循环扫描每个 UDP PCB，寻找所有匹配 PCB。这种分用不调用 `in_pcblklookup`，因为它只返回一个PCB，而广播或多播数据报可能需要提交给多个PCB。

如果PCB的本地端口和收到数据报的本地端口不匹配，则忽略该入口。如果 PCB的本地端口不是通配地址，则把它和目的 IP地址比较，如果不相等则跳过该入口。如果 PCB内的外部地址不是通配地址，就把它和源站 IP地址比较，如果不匹配，则外部端口也必须和源站端口匹配。最后一个检测假定，如果插口连接到某个外部 IP地址，则它也必须连接到一个外部端口，反之亦然。这与 `in_pcblklookup` 函数的逻辑相同。

165-177 如果这不是第一个匹配(`last`非空)，则把该数据报放到上一个匹配的接收队列中。因为当 `sbappendaddr` 完成后要释放 `mbuf` 链，所以 `m_copy` 先要做个备份。`sorwakeup` 唤醒所有等待这个数据的进程，`last` 保存指向匹配的 `socket` 结构的指针。

使用变量 `last` 避免调用 `m_copy` 函数(因为要复制整个 `mbuf` 链，所以耗费很大)，除非有多个接收方接收该数据报。在通常只有一个接收方的情况下，`for` 循环必须把 `last` 设成指向一个匹配PCB，当循环终止时，`sbappendaddr` 把 `mbuf` 链放到插口的接收队列中——不做备份。

178-188 如果匹配的插口没有设置 `SO_REUSEPORT` 或 `SO_REUSEADDR` 插口选项，则没必要再找其他匹配，终止该循环。在循环的外部，调用 `sbappendaddr` 把数据报放到这个插口的接收队列中。

189-197 如果在循环的最后，`last` 为空，没找到匹配，则并不产生 ICMP差错，因为该数据报是发给广播或多播IP地址。

198-204 最后的匹配入口(可能是唯一的匹配入口)把原来的数据报(m)放到它的接收队列中。在调用sorwakeup后，udp_input返回，因为完成了对广播或多播数据报的处理。

函数的其他部分(图23-24)处理单播数据报。

23.7.4 连接上的UDP插口和多接口主机

在使用连接上的 UDP 插口与多接口主机上的一个进程交换数据报时，有一个微妙的问题。来自对等实体的数据报可能到达时具有不同的源站 IP 地址，不能提交给连接上的插口。

考虑图23-27所示的例子。

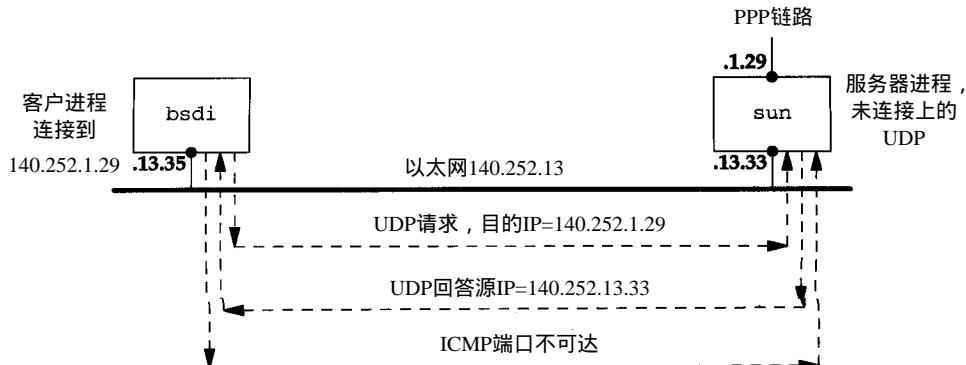


图23-27 连接上的 UDP 插口向一个多接口主机发送数据报的例子

有三个步骤：

1) bsdi 上的客户程序创建一个 UDP 插口，并把它连接到 140.252.1.29，这是 sun 上的 PPP 接口，而不是以太网接口。客户程序在插口上把数据报发给服务器。

Sun 上的服务器接收并收下该数据报，即使到达接口与目的 IP 地址不同(sun 是一个路由器，所以不管它实现的是弱端系统模型或强端系统模型都没有关系)。数据报被提交给在未连接上的 UDP 插口上等待客户请求的服务器。

2) 服务器发一个回答，因为是在一个未连接上的 UDP 插口上发送的，所以由内核根据外出的接口(140.252.13.33)选择回答的目的 IP 地址。请求的目的 IP 地址不作为回答的源站地址。

bsdi 收到回答时，因为 IP 地址不匹配，所以不把它提交给客户程序的连接上的 UDP 接口。

3) 因为无法分用回答，所以 bsdi 产生一个 ICMP 端口不可达差错(假定在 bsdi 上没有其他进程符合接收该数据报的条件)。

这个例子的问题在于，服务器并不把请求中的目的 IP 地址作为回答的源站 IP 地址。如果它这样做，就不存在这个问题了，但这个办法并不简单——见习题23.10。我们将在图28-16中看到，如果一个 TCP 服务器没有明确地把一个本地 IP 地址绑定它的插口上，它就把来自客户的目的 IP 地址用作来自它自己的源 IP 地址。

23.8 udp_saveopt 函数

如果进程指定了 IP_RECVDSTADDR 插口选项，则 udp_input 调用 udp_saveopt，从收到的数据报中接收目的 IP 地址：

```
*mp = udp_saveopt((caddr_t) & ip_dst, sizeof(struct in_addr),
                  IP_RECVSTADDR);
```

图23-28显示了这个函数。

—udp_usrreq.c

```
278 /*
279  * Create a "control" mbuf containing the specified data
280  * with the specified type for presentation with a datagram.
281  */
282 struct mbuf *
283 udp_saveopt(p, size, type)
284 caddr_t p;
285 int     size;
286 int     type;
287 {
288     struct cmsghdr *cp;
289     struct mbuf *m;
290
291     if ((m = m_get(M_DONTWAIT, MT_CONTROL)) == NULL)
292         return ((struct mbuf *) NULL);
293     cp = (struct cmsghdr *) mtod(m, struct cmsghdr *);
294     bcopy(p, CMSG_DATA(cp), size);
295     size += sizeof(*cp);
296     m->m_len = size;
297     cp->cmsg_len = size;
298     cp->cmsg_level = IPPROTO_IP;
299     cp->cmsg_type = type;
300 }
```

—udp_usrreq.c

图23-28 udp_saveopt 函数：用控制信息创建 mbuf

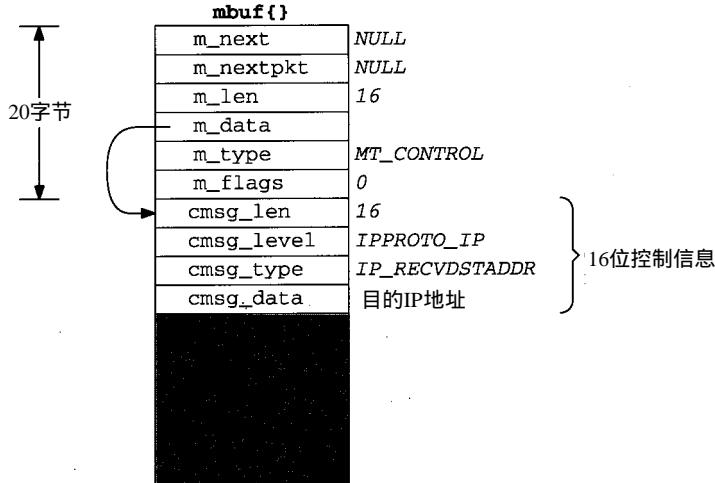


图23-29 把收到的数据报的目的地址作为控制信息保存的 mbuf

276-286 参数包括 *p*，一个指向存储在 mbuf 中的信息的指针(收到的数据报的目的 IP 地址)；*size*，字节数大小(在这个例子中是 4，IP 地址的大小)；以及 *type*，控制信息的类型(IP_RECVSTADDR)。

290-299 分配一个 mbuf，并且因为是在软件中断级执行代码，所以指定 M_DONTWAIT。指针 *cp* 指向 mbuf 的数据部分，是一个指向 cmsghdr 结构(图16-14)的指针。 *bcopy* 把 IP 首部中

的IP地址复制到 cmsghdr 结构的数据部分。然后设置紧跟在 cmsghdr 结构后面的 mbuf 的长度(在本例中设成 16)。图23-29是 mbuf 的最后一个状态。

cmsg_len 字段包含了 cmsghdr 的长度(12)加上 cmsg_data 字段的长度(本例中是 4)。如果应用程序调用 recvmsg 接收控制信息，则它必须检查 cmsghdr 结构，确定 cmsg_data 字段的类型和长度。

23.9 udp_ctlinput 函数

当 icmp_input 收到一个 ICMP 差错(目的主机不可达、参数问题、重定向、源站抑制和超时)时，调用相应协议的 pr_ctlinput 函数：

```
if (ctlfunc = inetsw[ ip_protox[icp->icmp_ip.ip_p] ].pr_ctlinput)
    (*ctlfunc)(code, (struct sockaddr *)&icmps, &icp->icmp_ip);
```

对于 UDP，调用图22-32显示的函数 udp_ctlinput。我们将在图23-30中给出这个函数。
314-322 参数包括 cmd，图11-19的一个PRC_xxx常数；sa，一个指向 sockaddr_in 结构的指针，该结构含有 ICMP 报文的源站 IP 地址；ip，一个指向引起差错的 IP 首部的指针。对于目的站不可达、参数问题、源站抑制和超时差错，ip 指向引起差错的 IP 首部。但当 pf_ctlinput 为重定向(图22-32)调用 udp_ctlinput 时，sa 指向一个 sockaddr_in 结构，该结构中包含要被重定向的目的地址，ip 是一个空指针。最后一种情况没有信息丢失，因为我们在 22.11 节看到，重定向应用于所有连接到目的地址的 TCP 和 UDP 插口。但对其他差错，如端口不可达，需要非空的第三个参数，因为协议跟在 IP 首部后面的协议首部包含了不可达端口。

323-325 如果差错不是重定向，并且 PRC_xxx 的值太大或全局数组 inetctllerrmap 中没有差错码，则忽略该 ICMP 差错。为理解这个检测，我们来看一下对收到的 ICMP 所做的处理：

- 1) icmp_input 把 ICMP 类型和码转换成一个 PRC_xxx 差错码。

- 2) 把 PRC_xxx 差错码传给协议的控制输入函数。

- 3) Internet PCB 协议(TCP 和 UDP)用 inetctllerrmap 把 PRC_xxx 差错码映射到一个 Unix 的 errno 值，这个值被返回给进程。

```
314 void
315 udp_ctlinput(cmd, sa, ip)
316 int     cmd;
317 struct sockaddr *sa;
318 struct ip *ip;
319 {
320     struct udphdr *uh;
321     extern struct in_addr zeroin_addr;
322     extern u_char inetctllerrmap[];
323
324     if (!PRC_IS_REDIRECT(cmd) &&
325         ((unsigned) cmd >= PRC_NCMDS || inetctllerrmap[cmd] == 0))
326         return;
327     if (ip) {
328         uh = (struct udphdr *) ((caddr_t) ip + (ip->ip_hl << 2));
329         in_pcbsnotify(&udb, sa, uh->uh_dport, ip->ip_src, uh->uh_sport,
330                         cmd, udp_notify);
331     } else
332         in_pcbsnotify(&udb, sa, 0, zeroin_addr, 0, cmd, udp_notify);
333 }
```

图23-30 udp_ctlinput 函数：处理收到的ICMP差错

图11-1和图11-2总结了ICMP报文的处理。

回到图 23-30，我们可以看到如何处理响应 UDP数据报的 ICMP源站抑制报文。icmp_input把ICMP报文转换成差错 PRC_QUENCH，并调用udp_ctlinput。但因为在图 11-2中，这个ICMP差错的errno行是空白，所以忽略该差错。

326-331 in_pcbsnotify函数把该ICMP差错通知给恰当的PCB。如果udp_ctlinput的第三个参数非空，则把引起差错数据报的源和目的UDP端口以及源IP地址，传给in_pcbsnotify。

udp_notify函数

in_pcbsnotify函数的最后一个参数是一个指向函数的指针，in_pcbsnotify为每个准备接收差错的PCB调用该函数。对UDP，该函数是udp_notify，如图23-31所示。

301-313 该函数的第二个参数 errno保存在插口的 so_error变量中。通过设置这个插口变量，使插口变成可读，并且如果进程调用 select，插口也可写。然后唤醒插口上所有正在等待接收或发送的进程接收该差错。

```
305 static void                                         udp_usrreq.c
306 udp_notify(inp, errno)
307 struct inpcb *inp;
308 int      errno;
309 {
310     inp->inp_socket->so_error = errno;
311     sorwakeup(inp->inp_socket);
312     sowakeup(inp->inp_socket);
313 }
```

udp_usrreq.c

图23-31 udp_notify函数：通知进程一个异步差错

23.10 udp_usrreq函数

许多操作都要调用协议的用户请求函数。从图 23-14我们看到，在某个 UDP插口上调用五个写函数中的任意一个，都以请求 PRU_SEND调用UDP 的用户请求函数结束。

图23-32显示了udp_usrreq的开始和结束。switch单独在后面的图中给出。图 15-17显示了该函数的参数。

```
417 int                                         udp_usrreq.c
418 udp_usrreq(so, req, m, addr, control)
419 struct socket *so;
420 int      req;
421 struct mbuf *m, *addr, *control;
422 {
423     struct inpcb *inp = sotoinpcb(so);
424     int      error = 0;
425     int      s;

426     if (req == PRU_CONTROL)
427         return (in_control(so, (int) m, (caddr_t) addr,
428                           (struct ifnet *) control));
429     if (inp == NULL && req != PRU_ATTACH) {
430         error = EINVAL;
431         goto release;
432     }
```

图23-32 udp_usrreq 函数体

```

433     /*
434      * Note: need to block udp_input while changing
435      * the udp pcb queue and/or pcb addresses.
436      */
437     switch (req) {

522     default:
523         panic("udp_usrreq");
524     }
525     release:
526     if (control) {
527         printf("udp control data unexpectedly retained\n");
528         m_freem(control);
529     }
530     if (m)
531         m_freem(m);
532     return (error);
533 }
```

udp_usrreq.c

图23-32 (续)

417-428 PRU_CONTROL请求来自 ioctl系统调用。函数 in_control完整地处理该请求。

429-432 在函数的开头定义 inp时，把插口指针转换成 PCB指针。唯一允许 PCB指针为空的时候是创建新插口时(PRU_ATTACH)。

433-436 注释表明，只要在UDP PCB表中增加或删除表项，代码必须由 splnet保护起来。这是因为 udp_usrreq是作为系统调用的一部分来调用的，在它修改 PCB的双重链表时，不能被UDP输入中断(被IP输入作为软件中断调用)。在修改PCB的本地或外部地址或端口时，也必须阻塞UDP输入，避免 in_pcblockup不正确地提交收到的UDP数据报。

我们现在讨论每个case语句。图23-33语句中的PRU_ATTACH请求，来自socket系统调用。

```

438     case PRU_ATTACH:
439         if (inp != NULL) {
440             error = EINVAL;
441             break;
442         }
443         s = splnet();
444         error = in_pcbballoc(so, &udb);
445         splx(s);
446         if (error)
447             break;
448         error = soreserve(so, udp_sendspace, udp_recvspace);
449         if (error)
450             break;
451         ((struct inpcb *) so->so_pcb)->inp_ip.ip_ttl = ip_defttl;
452         break;
453     case PRU_DETACH:
454         udp_detach(inp);
455         break;
```

udp_usrreq.c

图23-33 udp_usrreq 函数：PRU_ATTACH 和PRU_DETACH 请求

438-447 如果插口结构已经指向一个PCB，则返回EINVAL。in_pcbaalloc分配一个新的PCB，把它加到UDP PCB表的前面，把插口结构和PCB链接到一起。

448-450 soreserve为插口的发送和接收缓存保留缓存空间。如图16-7所示，soreserve只是实施系统的限制，并没有真正分配缓存空间。发送和接收缓存的默认大小分别是9216字节(udp_sendspace)和41600字节(udp_recvspace)。前者允许最大9200字节的数据报(在NFS分组中，有8KB的数据)，加上16字节目的地址的sockaddr_in结构。后者允许插口上一次最多有40个1024字节的数据报排队。进程可调用setsockopt改变这些值。

451-452 进程通过setsockopt函数可以改变PCB中原型IP首部的两个字段：TTL和TOS。TTL默认值是64(ip_defttl)，TOS的默认值是0(普通服务)，因为in_pcbaalloc把PCB初始化为0。

453-455 close系统调用发布PRU_DETACH请求，调用图23-34所示的udp_detach函数。本节后面的PRU_ABORT请求也调用这个函数。

```
534 static void
535 udp_detach(inp)
536 struct inpcb *inp;
537 {
538     int     s = splnet();
539     if (inp == udp_last_inpcb)
540         udp_last_inpcb = &udb;
541     in_pcbdetach(inp);
542     splx(s);
543 }
```

*udp_usrreq.c**udp_usrreq.c*

图23-34 udp_detach 函数：删除一个UDP PCB

如果最后收到的PCB指针(“向后一个”缓存)指向一个已分离的PCB，则把缓存的指针设成指向UDP表的表头(udb)。函数in_pcbdetach从UDP表中移走PCB，并释放该PCB。

回到udp_usrreq，PRU_BIND请求是系统调用bind的结果，而PRU_LISTEN请求是系统调用listen的结果。如图23-35所示。

456-460 in_pcbbind完成所有PRU_BIND请求的工作。

461-463 对无连接协议来说，PRU_LISTEN请求是无效的——只有面向连接的协议才使用它。

```
456     case PRU_BIND:
457         s = splnet();
458         error = in_pcbbind(inp, addr);
459         splx(s);
460         break;
461
462     case PRU_LISTEN:
463         error = EOPNOTSUPP;
464         break;
```

*udp_usrreq.c**udp_usrreq.c*

图23-35 udp_usrreq 函数：PRU_BIND 和PRU_LISTEN 请求

前面提到，一个UDP应用程序，客户或服务器(通常是客户)，可以调用connect。它修改插口发送或接收的外部IP地址和端口号。图23-6显示了PRU_CONNECT、PRU_CONNECT2和PRU_ACCEPT请求。

464-474 如果插口已经连接上，则返回 EISCONN。在这个时候，不应该连接上插口，因为在一个已经连接上的 UDP插口上调用 connect，会在生成 PRU_CONNECT请求之前生成 PRU_DISCONNECT请求。否则，由in_pcconnect完成所有工作。如果没有遇到任何错误，soisconnected就把该插口结构标记成已经连接上的。

475-477 socketpair系统调用发布PRU_CONNECT2请求，只适用于Unix域的协议。

478-480 PRU_ACCEPT请求来自系统调用accept，只适用于面向连接的协议。

— udp_usrreq.c

```

464     case PRU_CONNECT:
465         if (inp->inp_faddr.s_addr != INADDR_ANY) {
466             error = EISCONN;
467             break;
468         }
469         s = splnet();
470         error = in_pcconnect(inp, addr);
471         splx(s);
472         if (error == 0)
473             soisconnected(so);
474         break;

475     case PRU_CONNECT2:
476         error = EOPNOTSUPP;
477         break;

478     case PRU_ACCEPT:
479         error = EOPNOTSUPP;
480         break;

```

— udp_usrreq.c

图23-36 udp_usrreq 函数：PRU_CONNECT、PRU_CONNECT2 和PRU_ACCEPT 请求

对于UDP插口，有两种情况会产生PRU_DISCONNECT请求：

- 1) 当关闭了一个连接上的 UDP插口时，在PRU_DETACH之前调用PRU_DISCONNECT。
- 2) 当在一个已经连接上的 UDP插口上发布connect时，soconnect在PRU_CONNECT请求之前发布PRU_DISCONNECT请求。

PRU_DISCONNECT请求如图23-37所示。

— udp_usrreq.c

```

481     case PRU_DISCONNECT:
482         if (inp->inp_faddr.s_addr == INADDR_ANY) {
483             error = ENOTCONN;
484             break;
485         }
486         s = splnet();
487         in_pcbservice(inp);
488         inp->inp_laddr.s_addr = INADDR_ANY;
489         splx(s);
490         so->so_state &= ~SS_ISCONNECTED; /* XXX */
491         break;

```

— udp_usrreq.c

图23-37 udp_usrreq 函数：PRU_DISCONNECT 请求

如果插口没有连接上，则返回ENOTCONN。否则，in_pcbservice把外部IP地址设成0.0.0.0，把外部地址设成0。本地地址也被设成0.0.0.0，因为connect可能已经设置了这个PCB变量。

调用shutdown说明进程数据发送结束，产生PRU_SHUTDOWN请求，尽管对UDP插口来

说，很少有进程发布这个系统调用。图 23-38 显示了 PRU_SHUTDOWN、PRU_SEND 和 PRU_ABORT 请求。

492-494 socantsendmore 设置插口的标志，阻止其他更多输出。

495-496 图23-14显示了五个写函数如何调用 udp_surreq，发布PRU_SEND请求。udp_output发送该数据报，udp_usrreq返回，避免执行release标号语句(图23-32)，因为还不能释放包含数据的mbuf链(m)。IP输出把这个mbuf链加到合适的接口输出队列中，当发送完数据后，由设备驱动器释放mbuf链。

```
492     case PRU_SHUTDOWN:
493         socantsendmore(so);
494         break;
495     case PRU_SEND:
496         return (udp_output(inp, m, addr, control));
497     case PRU_ABORT:
498         soisdisconnected(so);
499         udp_detach(inp);
500         break;
```

— udp_usrreq.c

— udp_usrreq.c

图23-38 udp_usrreq 函数体：PRU_SHUTDOWN、PRU_SEND 和 PRU_ABORT 请求

内核中 UDP 输出的唯一缓冲是在接口的输出队列中。如果插口的发送缓存内有存放数据报和目的地址的空间，则 sosend 调用 udp_usrreq，该函数调用 udp_output。图23-20显示，udp_output继续调用 ip_output，ip_output 为以太网调用 ether_output，把数据报放到接口的输出队列中（如果有空间）。如果进程调用 sendto 的动作比接口快，就可以发送该数据报，ether_output 返回 ENOBUFS，并被返回给进程。

497-500 在 UDP 插口上从不发布 PRU_ABORT 请求。但如果发布，则断连插口，分离 PCB。

PRU_SOCKADDR 和 PRU_PEERADDR 请求分别来自系统调用 getsockname 和 getpeername。这两个请求和 PRU_SENSE 请求一起，如图23-39所示。

```
501     case PRU_SOCKADDR:
502         in_setsockaddr(inp, addr);
503         break;
504     case PRU_PEERADDR:
505         in_setpeeraddr(inp, addr);
506         break;
507     case PRU_SENSE:
508         /*
509          * fstat: don't bother with a blocksize.
510          */
511         return (0);
```

— udp_usrreq.c

— udp_usrreq.c

图23-39 udp_usrreq 函数体：PRU_SOCKADDR、PRU_PEERADDR 和 PRU_SENSE 请求

501-506 函数 in_setsockaddr 和 in_setpeeraddr 从 PCB 中取得信息，并把结果保存在 addr 参数中。

507-511 系统调用 fstat 产生 PRU_SENSE 请求。该函数返回 OK，但并不返回其他信息。我们将在后面看到，TCP 把发送缓存的大小作为 stat 结构的 st_blksize 元素返回。

图23-40显示了其他 7 个 PRU_xxx 请求，UDP 插口不支持。

对最后两个请求的处理略微有些不同，因为 PRU_RCVD不把指向 mbuf的指针(m是一个非空指针)作为参数传递，而PRU_RCVOOB则传递指向协议mbuf的指针来填充。两种情况下，立即返回错误，不终止switch语句的执行，释放mbuf链。调用方用PRU_RCVOOB释放它分配的mbuf。

```

512     case PRU_SENDOOB:
513     case PRU_FASTTIMO:
514     case PRU_SLOWTIMO:
515     case PRU_PROTORCV:
516     case PRU_PROTOSEND:
517         error = EOPNOTSUPP;
518         break;
519
520     case PRU_RCVD:
521     case PRU_RCVOOB:
522         return (EOPNOTSUPP); /* do not free mbuf's */

```

图23-40 udp_usrreq 函数体：不支持的7个请求

udp_usrreq.c

23.11 udp_sysctl函数

UDP的sysctl函数只支持一个选项， UDP检验和标志位。系统管理员可以禁止用sysctl(8)程序使能或禁止 UDP检验和。图 23-41显示了 udp_sysctl函数。该函数调用sysctl_int取得或设置整数udpcksum的值。

```

547 udp_sysctl(name, namelen, oldp, oldlenp, newp, newlen)
548 int      *name;
549 u_int    namelen;
550 void    *oldp;
551 size_t   *oldlenp;
552 void    *newp;
553 size_t   newlen;
554 {
555     /* All sysctl names at this level are terminal. */
556     if (namelen != 1)
557         return (ENOTDIR);
558
559     switch (name[0]) {
560     case UDPCTL_CHECKSUM:
561         return (sysctl_int(oldp, oldlenp, newp, newlen, &udpcksum));
562     default:
563         return (ENOPROTOOPT);
564     }
565     /* NOTREACHED */
566 }

```

图23-41 udp_sysctl 函数

udp_usrreq.c

23.12 实现求精

23.12.1 UDP PCB高速缓存

在22.12节中，我们讲到PCB搜索的一般性质，以及代码是如何线性搜索协议的PCB表的。现在我们把它和图 23-24中UDP使用的“向后一个”高速缓存结合起来。

“向后一个”高速缓存的问题发生在当高速缓存的PCB中有通配值时(本地地址，外部地址

或外部端口)：高速缓存的值永远不和收到的数据报匹配。[Partridge和Pink 1993] 测试的一个解决办法是，修改高速缓存，不比较通配值。也就是说，不再把 PCB中的外部地址和数据报的源地址进行比较，而是只有当 PCB中的外部地址不是通配地址时，才比较这两个值。

这个办法有一个微妙的问题 [Partridge和Pink 1993]。假定有两个插口绑定到本地端口 555 上。其中一个有三个通配成份，而另一个已经连接到外部地址 128.1.2.3，外部端口 1600。如果我们高速缓存第一个 PCB，且有一个数据报来自 128.1.2.3，端口 1600，则不能仅仅因为高速缓存的值具有通配外部地址就不比较外部地址。这叫做高速缓存隐藏 (cache hiding)。在这个例子中，高速缓存的 PCB 隐藏了另一个更好匹配的 PCB。

为解决高速缓存隐藏，当在高速缓存加上或删除一个入口时，要做更多的工作。不能高速缓存那些可能隐藏其他 PCB 的 PCB。但这很简单，因为普通情形是每个本地端口都有一个插口。刚才我们给的例子中，两个插口都绑定到本地端口 555，尽管可能(尤其在一个多接口主机上)，但很少见。

[Partridge和Pink 1993]的另一个提高测试的也是记录最后发送的数据报的 PCB。这是 [Mogul 1991]提出的，指出在所有收到的数据报中，一半都是对最后发送的数据报的回答。在这里高速缓存隐藏也是个问题，所以不高速缓存那些可能隐藏其他 PCB的PCB。

在通用系统上测试 [Partridge和Pink 1993] 的两种高速缓存结果是，100 000个左右收到的 UDP数据报显示出 57% 命中最近收到PCB高速缓存，30%命中最近发送PCB高速缓存。相比于没有高速缓存的版本，`udp_input`使用的CPU时间减少了一半还多。

这两种高速缓存还在某种程度上依赖于位置：刚刚到达的 UDP数据报极大可能来自与最近收到或发送 UDP数据报相同的对等实体上。后者对发送一个数据报并等待回答的请求—应答应用程序很典型。[McKenney和Dove 1992] 显示某些应用程序，如联机交易处理 (OLTP) 系统的数据入口，没有产生 [Partridge和Pink 1993] 观察到的很高的命中率。正如我们在 22.12 节中提到的，对于具有上千个 OLTP连接的系统来说，把 PCB放在哈希链上，相对于最近收到和最近发送高速缓存而言，性能提高了一个数量级。

23.12.2 UDP检验和

提高实现性能的下一个领域是把进程和内核之间的数据复制与检验和计算结合起来。Net/3中，在输出操作中，每个数据都被处理两遍：一次是从进程复制到mbuf中(`uiomove`函数，被`sosend`调用)；另一次是计算UDP检验和(函数`in_cksum`被`udp_output`调用)。输入跟输出一样。

[Partridge和Pink1993] 修改了图 23-14的 UDP输出处理，调用一个 UDP专有函数`udp_sosend`，而不是`sosend`。这个新函数计算 UDP 首部和内嵌的伪首部的检验和(不调用通用的`in_cksum`函数)，然后用特殊函数`in_uiomove`把数据从进程复制到一个 mbuf链上(不是通用函数`uiomove`)，由这个新函数复制数据，更新检验和。采用这个技术，花在复制数据和计算检验和的时间减少了 40% 到45%。

在接收方情况就不同了。UDP 计算UDP首部和伪首部的检验和，移走 UDP首部，把数据报在合适的插口上排队。当应用程序读取数据报时，`soreceive`的一个特殊版本(`udp_soreceive`)在把数据复制到用户高速缓存的同时，计算检验和。但是，如果检验和不正确，在整个数据报被复制到用户高速缓存之前，检测不到错误。对于普通的阻塞插口来说，`udp_soreceive`仅仅等待下一个数据报的到达。但是若插口是无阻塞的，且下一个数据报还没有准备好传给进程，就必须返回差错 `EWOULDBLOCK`。对于无阻塞读的 UDP插口来说，

这意味着插口接口的两个变化：

1) `select`函数可以指示无阻塞 UDP 插口可读，但如果检验和失败，其中一个读函数依然要返回错误 `EWOULDBLOCK`。

2) 因为是在数据报被复制到用户高速缓存之后检测到检验和错误，所以即使读没有返回数据，应用程序的高速缓存也被改变了。

即使是阻塞插口，如果有检验和错误的数据报包含了 100 字节的数据，而下一个没有错误的数据报包含 40 字节的数据，则 `recvfrom` 的返回长度是 40，但跟在用户高速缓存后面的 60 字节没有改变。

[Partridge 和 Pink 1993] 在六台不同计算机上，对单纯复制和有检验和的复制的计时作了比较。结果显示，在许多体系结构的机器上，在复制操作中计算检验和无需额外时间。这种情况是在内存访问速度和 CPU 处理速度正确匹配的系统上的，目前许多 RISC 处理器都符合条件。

23.13 小结

UDP 是一个无连接的简单协议，这是我们为什么在 TCP 之前讨论它的原因。UDP 输出很简单：IP 和 UDP 首部放在用户数据的前面，尽可能填满首部，把结果传递给 `ip_output`。唯一复杂的是 UDP 检验和计算，包括只为计算 UDP 检验和而加上一个伪首部。我们将在第 26 章遇到用于计算 TCP 检验和的伪首部。

当 `udp_input` 收到一个数据报时，它首先完成一个常规确认（长度和检验和）；然后的处理根据目的 IP 地址是单播地址、广播或多播地址而不同。最多把单播数据报提交给一个进程，但多播或广播数据报可能会被提交给多个进程。“向后一个”高速缓存适用于单播，其中维护着一个指向在其上接收数据报的最近 Internet PCB 的指针。但是，我们也看到，由于 UDP 应用程序普遍使用通配地址，所以这个高速缓存技术实际上毫无用处。

调用 `udp_ctlinput` 函数处理收到的 ICMP 报文，`udp_usrreq` 函数处理来自插口层的 PRU_XXX 请求。

习题

- 23.1 列出 `udp_output` 传给 `ip_output` 的 mbuf 链的五种类型（提示：看看 `sosend`）。
- 23.2 当进程为外出的数据报指定了 IP 选项时，上一题会是什么答案？
- 23.3 UDP 客户需要调用 `bind` 吗？为什么？
- 23.4 如果插口没有连接上，并且图 23-15 中调用 `M_PREPEND` 失败，那么在 `udp_output` 里，处理器优先级会发生什么变化？
- 23.5 `udp_output` 不检测目的端口 0。它可能发送一个具有目的端口 0 的 UDP 数据报吗？
- 23.6 假定当把一个数据报发送到一个广播地址时，`IP_RECVSTADDR` 插口选项有效，你如何确定这个地址是否是一个广播地址？
- 23.7 谁释放 `udp_saveopt`（图 23-38）分配的 mbuf？
- 23.8 进程如何断开连接上的 UDP 插口？也就是说，进程调用 `connect` 并与对等实体交换数据报，然后进程要断开插口。允许它调用 `sendto`，并向其他主机发送数据报。
- 23.9 我们在图 22-25 的讨论中，注意到一个用外部 IP 地址 255.255.255.255 调用 `connect` 的 UDP 应用程序，在接口上发送时，是把该接口对应的广播地址作为目的 IP 地址。如果 UDP 应用使用未连接的插口，用目的地址 255.255.255.255 调用 `sendto`，会发生什么情况？

第24章 TCP：传输控制协议

24.1 引言

传输控制协议，即TCP，是一种面向连接的传输协议，为两端的应用程序提供可靠的端到端的数据流传输服务。它完全不同于无连接的、提供不可靠的数据报传输服务的UDP协议。

我们在第23章中详细讨论了UDP的实现，有9个函数、约800行C代码。我们将要讨论的TCP实现包括28个函数、约4500行C代码，因此，我们将TCP的实现分成7章来讨论。

这几章中不包括对TCP概念的介绍，假定读者已阅读过卷1的第17章~第24章，熟悉TCP的操作。

24.2 代码介绍

TCP实现代码包括7个头文件，其中定义了大量的TCP结构和常量和6个C文件，包含TCP函数的具体实现代码。文件如图24-1所示。

文 件	描 述
netinet/tcp.h netinet/tcp_debug.h netinet/tcp_fsm.h netinet/tcp_seg.h netinet/tcp_timer.h netinet/tcp_var.h netinet/tcpip.h	tcp_hdr结构定义 tcp_debug结构定义 TCP有限状态机定义 实现TCP序号比较的宏定义 TCP定时器定义 tcpcb(控制块)和tcpstat(统计)结构定义 TCP+IP首部定义
netinet/tcp_debug.c netinet/tcp_input.c netinet/tcp_output.c netinet/tcp_subr.c netinet/tcp_timer.c netinet/tcp_usrreq.c	支持SO_DEBUG协议端口号调试(第27.10节) tcp_input及其辅助函数(第28和第29章) tcp_output及其辅助函数(第26章) 各种TCP子函数(第27章) TCP定时器处理(第25章) PRU_xxx请求处理(第30章)

图24-1 TCP各章中将讨论的文件

图24-2描述了各TCP函数与其他内核函数之间的关系。带阴影的椭圆分别表示我们将要讨论的9个主要的TCP函数，其中8个出现在protosw结构中(图24-8)，第9个是tcp_output。

24.2.1 全局变量

图24-3列出了TCP函数中用到的全局变量。

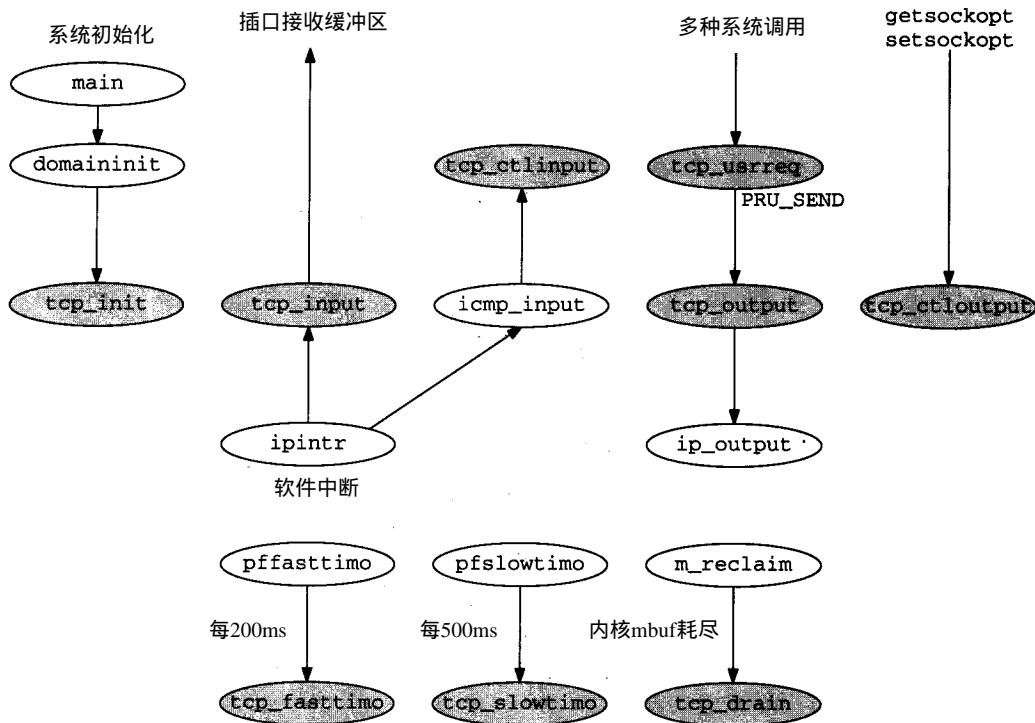


图24-2 TCP函数与其他内核函数间的关系

变 量	数据类型	描 述
tcp	struct inpcb	TCP Internet PCB表头
tcp_last_inpcb	struct inpcb *	指向最后收到报文段的PCB的指针：“后面一个”高速缓存
tcpstat	struct tcpstat	TCP统计数据(图24-4)
tcp_outflags	u_char	输出标志数组，索引为连接状态(图24-16)
tcp_recvspace	u_long	端口接收缓存大小默认值(8192字节)
tcp_sendspace	u_long	端口发送缓存大小默认值(8192字节)
tcp_iss	tcp_seq	TCP发送初始序号(ISS)
tcp_rexmtthresh	int	ACK重复次数的门限值(3)，触发快速重传
tcp_mssdflt	int	默认MSS值(512字节)
tcp_rttdflt	int	没有数据时RTT的默认值(3秒)
tcp_do_rfrc1323	int	如果为真(默认值)，请求窗口大小和时间戳选项
tcp_now	u_long	用于RFC 1323时间戳实现的500 ms计数器
tcp_keepidle	int	保活：第一次探测前的空闲时间(2小时)
tcp_keepintvl	int	保活：无响应时两次探测的间隔时间(75秒)
tcp_maxidle	int	保活：探测之后、放弃之前的时间(10分钟)

图24-3 后续章节中将介绍的全局变量

24.2.2 统计量

全局结构变量 `tcpstat` 中保存了各种 TCP统计量，图 24-4 描述了各统计量的具体含义。在接下来的代码分析过程中，读者会了解到这些计数器数值的变化过程。

tcpstat成员	描述	SNMP使用
tcps_accepts	被动打开的连接数	•
tcps_closed	关闭的连接数(包括意外丢失的连接)	•
tcps_connattempt	试图建立连接的次数(调用connect)	•
tcps_conndrops	在连接建立阶段失败的连接次数(SYN收到之前)	•
tcps_connects	主动打开的连接次数(调用connect成功)	•
tcps_delack	延迟发送的ACK数	•
tcps_drops	意外丢失的连接数(收到SYN之后)	•
tcps_keepdrops	在保活阶段丢失的连接数(已建立或正等待SYN)	•
tcps_keepprobe	保活探测指针发送次数	•
tcps_keeptimeo	保活定时器或连接建立定时器超时次数	•
tcps_pawsdrop	由于PSWS而丢失的报文段数	•
tcps_pcbschemiss	PCB高速缓存匹配失败次数	•
tcps_persisttimeo	持续定时器超时次数	•
tcps_predack	对ACK报文首部预测的正确次数	•
tcps_preddat	对数据报文首部预测的正确次数	•
tcps_rcvackbyte	由收到的ACK报文确认的发送字节数	•
tcps_rcvackpack	收到的ACK报文数	•
tcps_rcvacktoomuch	收到的对未发送数据进行确认的ACK报文数	•
tcps_rcvafterclose	连接关闭后收到的报文数	•
tcps_rcvbadoff	收到的首部长度无效的报文数	•
tcps_rcvbadsum	收到的检验和错误的报文数	•
tcps_rcvbyte	连续收到的字节数	•
tcps_rcvbyteafterwin	在滑动窗口已满时收到的字节数	•
tcps_rcvdupack	收到的重复ACK报文的次数	•
tcps_rcvdupbyte	在完全重复报文中收到的字节数	•
tcps_rcvduppack	内容完全一致的报文数	•
tcps_rcvoobyte	收到失序的字节数	•
tcps_rcvoopack	收到失序的报文数	•
tcps_rcvpack	顺序接收的报文数	•
tcps_rcvpackafterwin	携带数据超出滑动窗口通告值的报文数	•
tcps_rcvpardupbyte	部分内容重复的报文中的重复字节数	•
tcps_rcvparduppack	部分数据重复的报文数	•
tcps_rcvshort	长度过短的报文数	•
tcps_rcvtotal	收到的报文总数	•
tcps_rcvwinprobe	收到的窗口探测报文数	•
tcps_rcwinupd	收到的窗口更新报文数	•
tcps_rexmttimeo	重传超时次数	•
tcps_rttupdated	RTT估算值更新次数	•
tcps_segstimed	可用于RTT测算的报文数	•
tcps_sndacks	发送的纯ACK报文数(数据长度=0)	•
tcps_sndbyte	发送的字节数	•
tcps_sndctrl	发送的控制(SYN、FIN、RST)报文数(数据长度=0)	•
tcps_sndpack	发送的数据报文数(数据长度>0)	•
tcps_sndprobe	发送的窗口探测次数(等待定时器强行加入1字节数据)	•
tcps_sndrexmitbyte	重传的数据字节数	•
tcps_sndrexmitpack	重传的报文数	•
tcps_sndtotal	发送的报文总数	•
tcps_sndurg	只携带URG标志的报文数(数据长度=0)	•
tcps_sndwinup	只携带窗口更新信息的报文数(数据长度=0)	•
tcps_timeoutdrop	由于重传超时而丢失的连接数	•

图24-4 tcpstat 结构变量中保存的TCP统计量

在命令行输入netstat -s，系统将输出当前TCP的统计值。图24-5的例子显示了主机连续运行30天后，各统计计数器的值。由于某些统计量互相关联——一个保存数据分组数目，另一个保存相应的字节数——图中做了一些简化。例如，表中第二行tcps_snd(pack,byte)实际表示了两个统计量，tcps_sndpack和tcps_sndbyte。

tcps_sndbyte值应为3 722 884 824字节，而不是-22 194 928字节，平均每个数据分组有450字节。类似的，tcps_rcvackbyte值应为3 738 811 552字节，而不是-21 264 360字节(平均每个数据分组565字节)。这些数据之所以被错误地显示，是因为netstat程序中调用printf语句时使用了%d(符号整型)，而非%lu(无符号长整型)。所有统计量均定义为无符号长整型，上面两个统计量的值已接近无符号32位长整型的上限($2^{32} - 1 = 4\ 294\ 967\ 295$)。

netstat -s 输出	tcpstat 成员
10,655,999 packets sent 9,177,823 data packets (-22,194,928 bytes) 257,295 data packets (81,075,086 bytes) retransmitted 862,900 ack-only packets (531,285 delayed) 229 URG-only packets 3,453 window probe packets 74,925 window update packets 279,387 control packets	tcps_sndtotal tcps_snd{pack,byte} tcps_sndrexmit{pack,byte} tcps_sndacks,tcps_delack tcps_sndurg tcps_sndprobe tcps_sndwinup tcps_sndctrl
8,801,953 packets received 6,617,079 acks (for -21,264,360 bytes) 235,311 duplicate acks 0 acks for unsent data 4,670,615 packets (324,965,351 bytes) rcvd in-sequence 46,953 completely duplicate packets (1,549,785 bytes) 22 old duplicate packets 3,442 packets with some dup. data (54,483 bytes duped) 77,114 out-of-order packets (13,938,456 bytes) 1,892 packets (1,755 bytes) of data after window 1,755 window probes 175,476 window update packets 1,017 packets received after close 60,370 discarded for bad checksums 279 discarded for bad header offset fields 0 discarded because packet too short	tcps_rcvtotal tcps_rcvack{pack,byte} tcps_rcvdupeack tcps_rcvacktoomuch tcps_rcv{pack,byte} tcps_rcvdup{pack,byte} tcps_pawsdrop tcps_rcvpartdup{pack,byte} tcps_rcvoo{pack,byte} tcps_rcv{pack,byte}afterwin tcps_rcvwinprobe tcps_rcvwindup tcps_rcvclose tcps_rcvafclose tcps_rcvbadsum tcps_rcvbadoff tcps_rcvshort
144,020 connection requests 92,595 connection accepts 126,820 connections established (including accepts) 237,743 connections closed (including 1,061 drops) 110,016 embryonic connections dropped	tcps_connattempt tcps_accepts tcps_connects tcps_closed,tcps_drops tcps_conndrops
6,363,546 segments updated rtt (of 6,444,667 attempts) 114,797 retransmit timeouts 86 connection dropped by rexmit timeout 1,173 persist timeouts 16,419 keepalive timeouts 6,899 keepalive probes sent 3,219 connections dropped by keepalive	tcps_{rttupdated,segstimed} tcps_rexmttimeo tcps_timeoutdrop tcps_persisttimeo tcps_keeptimeo tcps_kepprobe tcps_keepdrops
733,130 correct ACK header predictions 1,266,889 correct data packet header predictions 1,851,557 cache misses	tcps_predack tcps_preddat tcps_pcbscachemiss

图24-5 TCP统计量样本

24.2.3 SNMP变量

图24-6列出了SNMP TCP组中定义的14个SNMP简单变量，以及与它们相对应的tcpstat结构中的统计量。前四项的常量值在Net/3中定义，计数器tcpCurrEstab用于保存TCP PCB表中Internet PCB的数目。

图24-7列出了tcpTable，即TCP监听表(listener table)。

SNMP变量	tcpstat成员或常量	描述
tcpRtoAlgorithm	4	用于计算重传定时时限的算法： 1=其他； 2=RTO为固定值； 3=MIL-STD-1778附录B； 4=Van Jacobson的算法；
tcpRtoMin	1000	最小重传定时时限，以毫秒为单位
tcpRtoMax	64000	最大重传定时时限，以毫秒为单位
tcpMaxConn	-1	可支持的最大TCP连接数(-1表示动态设置)
tcpActiveOpens	tcps_connattempt	从CLOSED转换到SYN SENT的次数
tcpPassiveOpens	tcps_accepts	从LISTEN转换到SYN RCVD的次数
tcpAttemptFails	tcps_conndrops	从SYN_SENT或SYN_RCVD转换到CLOSED的次数+从SYN_RCVD转换到LISTEN的次数
tcpEstabResets	tcps_drops	从ESTABLISHED或CLOSE_WAIT转换到CLOSED的次数
tcpCurrEstab	(见正文)	当前位于ESTABLISHED或CLOSE_WAIT状态的连接数
tcpInSegs	tcps_rcvtotal	收到的报文总数
tcpOutSegs	tcps_sndtotal - tcps_sndrexmitpack	发送的报文总数，减去重传报文数
tcpRetransSegs	tcps_sndrexmitpack	重传的报文总数
tcpInErrs	tcps_rcvbadsum + tcps_rcvbadoff + tcps_rcvshort	收到的出错报文总数
tcpOutRsts	(未实现)	RST标志置位的发送报文数

图24-6 tcp组中的简单SNMP变量

index = <tcpConnLocalAddress>.<tcpConnLocalPort>.<tcpConnRemAddress>.<tcpConnRemPort>		
SNMP变量	PCB变量	描述
tcpConnState	t_state	连接状态：1 = CLOSED, 2 = LISTEN, 3 = SYN_SENT, 4 = SYN_RCVD, 5 = ESTABLISHED, 6 = FIN_WAIT, 7 = FIN_WAIT_2, 8 = CLOSE_WAIT, 9 = LAST_ACK, 10 = CLOSING, 11 = TIME_WAIT, 12 = 删除TCP控制块
tcpConnLocalAddress	inp_laddr	本地IP地址
tcpConnLocalPort	inp_lport	本地端口号
tcpConnRemAddress	inp_faddr	远端IP地址
tcpConnRemPort	inp_fport	远端端口号

图24-7 TCP监听表：tcpTable 中的变量

第一个PCB变量(`t_state`)来自TCP控制块(图24-13)，其他四个变量来自Internet PCB(图22-4)。

24.3 TCP 的`protosw`结构

图24-8列出了TCP `protosw`结构的成员变量，它定义了TCP协议与系统内其他协议间的交互接口。

成员变量	<code>inetsw[2]</code>	描述
<code>pr_type</code>	<code>SOCK_STREAM</code>	TCP提供字节流传输服务
<code>pr_domain</code>	<code>&inetdomain</code>	TCP属于Internet协议族
<code>pr_protocol</code>	<code>IPPROTO_TCP(6)</code>	填充IP首部的 <code>ip_p</code> 字段
<code>pr_flags</code>	<code>PR_CONNREQUIRED / PR_WANTRCVD</code>	插口层标志，协议处理中忽略
<code>pr_input</code>	<code>tcp_input</code>	从IP层接收消息
<code>pr_output</code>	<code>0</code>	TCP协议忽略该成员变量
<code>pr_ctlinput</code>	<code>tcp_ctlinput</code>	处理ICMP错误的控制输入函数
<code>pr_ctloutput</code>	<code>tcp_ctloutput</code>	在进程中响应管理请求
<code>pr_usrreq</code>	<code>tcp_usrreq</code>	在进程中响应通信请求
<code>pr_init</code>	<code>tcp_init</code>	TCP初始化
<code>pr_fasttimo</code>	<code>tcp_fasttimo</code>	快超时函数，每200 ms 调用一次
<code>pr_slowtimo</code>	<code>tcp_slowtimo</code>	慢超时函数，每500 ms 调用一次
<code>pr_drain</code>	<code>tcp_drain</code>	内核mbuf耗尽时调用
<code>pr_sysctl</code>	<code>0</code>	TCP协议忽略该成员变量

图24-8 TCP `protosw` 结构

24.4 TCP的首部

`tcphdr`结构定义了TCP首部。图24-9给出了`tcphdr`结构的定义，图24-10描述了TCP首部。

```

40 struct tcphdr {
41     u_short th_sport;           /* source port */
42     u_short th_dport;           /* destination port */
43     tcp_seq th_seq;            /* sequence number */
44     tcp_seq th_ack;            /* acknowledgement number */
45 #if BYTE_ORDER == LITTLE_ENDIAN
46     u_char   th_x2:4,          /* (unused) */
47             th_off:4;           /* data offset */
48 #endif
49 #if BYTE_ORDER == BIG_ENDIAN
50     u_char   th_off:4,          /* data offset */
51             th_x2:4;           /* (unused) */
52 #endif
53     u_char   th_flags;          /* ACK, FIN, PUSH, RST, SYN, URG */
54     u_short  th_win;            /* advertised window */
55     u_short  th_sum;            /* checksum */
56     u_short  th_urp;            /* urgent offset */
57 };

```

`tcp.h`

`tcp.h`

图24-9 `tcphdr` 结构

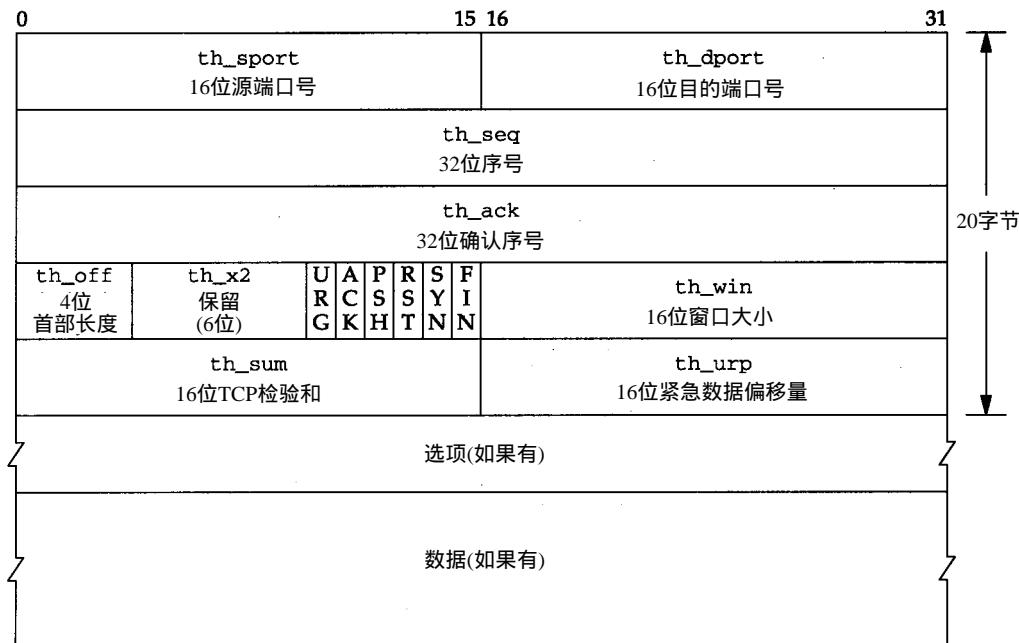


图24-10 TCP首部及可选数据

大多数RFC文档，相关书籍（包括卷1）和接下来要讨论的TCP实现代码，都把称为“紧急指针（urgent pointer）”。更准确的名称应该是“紧急数据偏移量（urgent offset）”，因为这个字段给出的16 bit无符号整数值，与序号字段相加后，得到发送的紧急数据最后一个八位组的32 bit序号（关于该序号应该是紧急数据最后一个字节的序号，或者是紧急数据结束后的第一个字节的序号，一直存在着争议。但就我们目前的讨论而言，这一点无关紧要）。图24-13中，TCP代码把保存紧急数据最后一个八位组的32 bit序号的`snd_up`正确地称为“紧急数据发送指针”。如果将TCP首部的16 bit偏移量也称为“指针”，容易引起误解。在练习26.6中，我们重申了“紧急指针”和“紧急数据偏移量”间的区别。

TCP首部中4 bit的首部长度、接着的6 bit的保留字段和6 bit的码元标志，在C结构中定义为两个4 bit的比特字段，和紧跟的一个8 bit字节。为了处理两个比特字段在8 bit字节中的存放次序，C代码根据不同的主机字节存储顺序使用了`#ifdef`语句。

还请注意，TCP中称4 bit的为“首部长度”，而C代码中称之为“数据偏移量”。两种名称都正确，因为它表示TCP首部的长度，包括可选项，以32 bit为单位，也就是指向用户数据第一个字节的偏移量。

`th_flags`成员变量包括6个码元标志比特，通过图24-11中定义的名称读写。

Net/3中，TCP首部通常意味着“IP首部 + TCP首部”。`tcp_input`处理收到的IP数据报和`tcp_output`构造待发送的IP数据报时都采用了这一思想。图24-12中给出了`tcpiphdr`结构的定义，形式化地描述了组合的IP/TCP首部。

38-58 图23-19给出的`ipovly`结构定义了20字节长度的IP首部。通过前面章节的讨论可知，尽管长度相同（20字节），但这个结构并不是一个真正的IP首部。

th_flags	描述
TH_ACK	确认序号(th_ack)有效
TH_FIN	发送方字节流结束
TH_PUSH	接收方应该立即将数据提交给应用程序
TH_RST	连接复位
TH_SYN	序号同步(建立连接)
TH_URG	紧急数据偏移量(th_urp)有效

图24-11 th_flags 值

```

38 struct tciphdr {
39     struct ipovly ti_i;           /* overlaid ip structure */
40     struct tcphdr ti_t;          /* tcp header */
41 };

42 #define ti_next    ti_i.ih_next
43 #define ti_prev   ti_i.ih_prev
44 #define ti_x1     ti_i.ih_x1
45 #define ti_pr     ti_i.ih_pr
46 #define ti_len    ti_i.ih_len
47 #define ti_src    ti_i.ih_src
48 #define ti_dst    ti_i.ih_dst
49 #define ti_sport  ti_t.th_sport
50 #define ti_dport  ti_t.th_dport
51 #define ti_seq    ti_t.th_seq
52 #define ti_ack    ti_t.th_ack
53 #define ti_x2    ti_t.th_x2
54 #define ti_off    ti_t.th_off
55 #define ti_flags  ti_t.th_flags
56 #define ti_win    ti_t.th_win
57 #define ti_sum    ti_t.th_sum
58 #define ti_urp    ti_t.th_urp

```

图24-12 tciphdr 结构定义：组合的IP/TCP首部

24.5 TCP的控制块

在图22-1中我们看到，除了标准的 Internet PCB外，TCP还有自己专用的控制块，tcp pcb结构，而UDP则不需要专用控制块，它的全部控制信息都已包含在 Internet PCB中。

TCP控制块较大，需占用140字节。从图22-1中可看到，Internet PCB与TCP控制块彼此对应，都带有指向对方的指针。图24-13给出了TCP控制块的定义。

```

41 struct tcp pcb {
42     struct tciphdr *seg_next; /* reassembly queue of received segments */
43     struct tciphdr *seg_prev; /* reassembly queue of received segments */
44     short t_state;           /* connection state (Figure 24.16) */
45     short t_timer[TCPT_NTIMERS]; /* tcp timers (Chapter 25) */
46     short t_rxtshift;        /* log(2) of rexmt exp. backoff */
47     short t_rxtcur;          /* current retransmission timeout (#ticks) */
48     short t_dupacks;         /* #consecutive duplicate ACKs received */
49     u_short t_maxseg;        /* maximum segment size to send */
50     char t_force;            /* 1 if forcing out a byte (persist/OOB) */
51     u_short t_flags;          /* (Figure 24.14) */

```

图24-13 tcp pcb 结构：TCP控制块

```

52     struct tciphdr *t_template;      /* skeletal packet for transmit */
53     struct inpcb *t_inpcb;         /* back pointer to internet PCB */
54 /*
55  * The following fields are used as in the protocol specification.
56  * See RFC783, Dec. 1981, page 21.
57 */
58 /* send sequence variables */
59     tcp_seq snd_una;             /* send unacknowledged */
60     tcp_seq snd_nxt;            /* send next */
61     tcp_seq snd_up;             /* send urgent pointer */
62     tcp_seq snd_w11;            /* window update seg seq number */
63     tcp_seq snd_w12;            /* window update seg ack number */
64     tcp_seq iss;                /* initial send sequence number */
65     u_long snd_wnd;             /* send window */
66 /* receive sequence variables */
67     u_long rcv_wnd;             /* receive window */
68     tcp_seq rcv_nxt;            /* receive next */
69     tcp_seq rcv_up;              /* receive urgent pointer */
70     tcp_seq irs;                /* initial receive sequence number */
71 /*
72  * Additional variables for this implementation.
73 */
74 /* receive variables */
75     tcp_seq rcv_adv;             /* advertised window by other end */
76 /* retransmit variables */
77     tcp_seq snd_max;             /* highest sequence number sent;
78                                * used to recognize retransmits */
79 /* congestion control (slow start, source quench, retransmit after loss) */
80     u_long snd_cwnd;             /* congestion-controlled window */
81     u_long snd_ssthresh;          /* snd_cwnd size threshold for slow start
82                                * exponential to linear switch */
83 /*
84  * transmit timing stuff. See below for scale of srtt and rttvar.
85  * "Variance" is actually smoothed difference.
86 */
87     short t_idle;                /* inactivity time */
88     short t_rtt;                 /* round-trip time */
89     tcp_seq t_rtseq;              /* sequence number being timed */
90     short t_srtt;                /* smoothed round-trip time */
91     short t_rttvar;               /* variance in round-trip time */
92     u_short t_rttmin;              /* minimum rtt allowed */
93     u_long max_sndwnd;            /* largest window peer has offered */
94 /* out-of-band data */
95     char t_oobflags;              /* TCPOOB_HAVEDATA, TCPOOB_HADDATA */
96     char t_iobc;                  /* input character, if not SO_OOBINLINE */
97     short t_softerror;             /* possible error not yet reported */
98 /* RFC 1323 variables */
99     u_char snd_scale;              /* scaling for send window (0-14) */
100    u_char rcv_scale;              /* scaling for receive window (0-14) */
101    u_char request_r_scale;          /* our pending window scale */
102    u_char requested_s_scale;        /* peer's pending window scale */
103    u_long ts_recent;              /* timestamp echo data */
104    u_long ts_recent_age;           /* when last updated */
105    tcp_seq last_ack_sent;          /* sequence number of last ack field */
106 };
107 #define intotcpcb(ip) ((struct tcpcb *)(ip)->inp_ppcb)
108 #define sototcpb(so) (intotcpb(sotoinpcb(so)))

```

tcp_var.h

图24-13 (续)

现在暂不讨论上述成员变量的具体含义，在后续代码中遇到时再详细分析。

图24-14列出了`t_flags`变量的可选值。

<code>t_flags</code>	描述
<code>TF_ACKNOW</code>	立即发送ACK
<code>TF_DELACK</code>	延迟发送ACK
<code>TF_NODELAY</code>	立即发送用户数据，不等待形成最大报文段（禁止Nagle算法）
<code>TF_NOOPT</code>	不使用TCP选项（永不填充TCP选项字段）
<code>TF_SENTEFIN</code>	FIN已发送
<code>TF_RCVD_SCALE</code>	对端在SYN报文中发送窗口变化选项时置位
<code>TF_RCVD_TSTMP</code>	对端在SYN报文中发送时间戳选项时置位
<code>TF_REQ_SCALE</code>	已经/将要在SYN报文中请求窗口变化选项
<code>TF_REQ_TSTMP</code>	已以/将要在SYN中请求时间戳选项

图24-14 `t_flags` 取值

24.6 TCP的状态变迁图

TCP协议根据连接上到达报文的不同类型，采取相应动作，协议规程可抽象为图 24-15所示的有限状态变迁图。读者在本书的扉页前也可找到这张图，以便在阅读有关TCP的章节时参考。

图中的各种状态变迁组成了TCP有限状态机。尽管TCP协议允许从LISTEN状态直接变迁到SYN_SENT状态，但使用SOCKET API编程时这种变迁不可实现（调用`listen`后不可以调用`connect`）。

TCP控制块的成员变量`t_state`保存一个连接的当前状态，可选值如图 24-16所示。

图中还定义了`tcp_outflags`数组，保存了处于对应连接状态时`tcp_output`将使用的输出标志。

图24-16还列出了与符号常量相对应的数值，因为在代码中将利用它们之间的数值关系。例如，有下面两个宏定义：

```
#define TCPS_HAVERCVDSYN(s) ((s)>=TCPS_SYN_RECEIVED)
#define TCPS_HAVERCVDFIN(s) ((s)>=TCPS_TIME_WAIT)
```

类似地，连接未建立时，即`t_state`小于`TCPS_ESTABLISHED`时，`tcp_notify`处理ICMP差错的方式也不同。

`TCPS_HAVERCVDSYN`的命名是正确的，但`TCPS_HAVERCVDFIN`则可能引起误解，因为在`CLOSE_WAIT`、`CLOSING`和`LAST_ACK`状态也会收到FIN。我们将在第29章中遇到该宏。

半关闭

当进程调用`shutdown`且第二个参数设为1时，称为“半关闭”。TCP发送FIN，但允许进程在同一端口上继续接收数据（卷1的18.5节中举例介绍了TCP的半关闭）。

例如，尽管图 24-15 中只在`ESTABLISHED`状态标注了“数据传输”，但如果进程执行了“半关闭”，则连接变迁到`FIN_WAIT_1`状态和其后的`FIN_WAIT_2`状态，在这两个特定状态中，进程仍然可以接收数据。

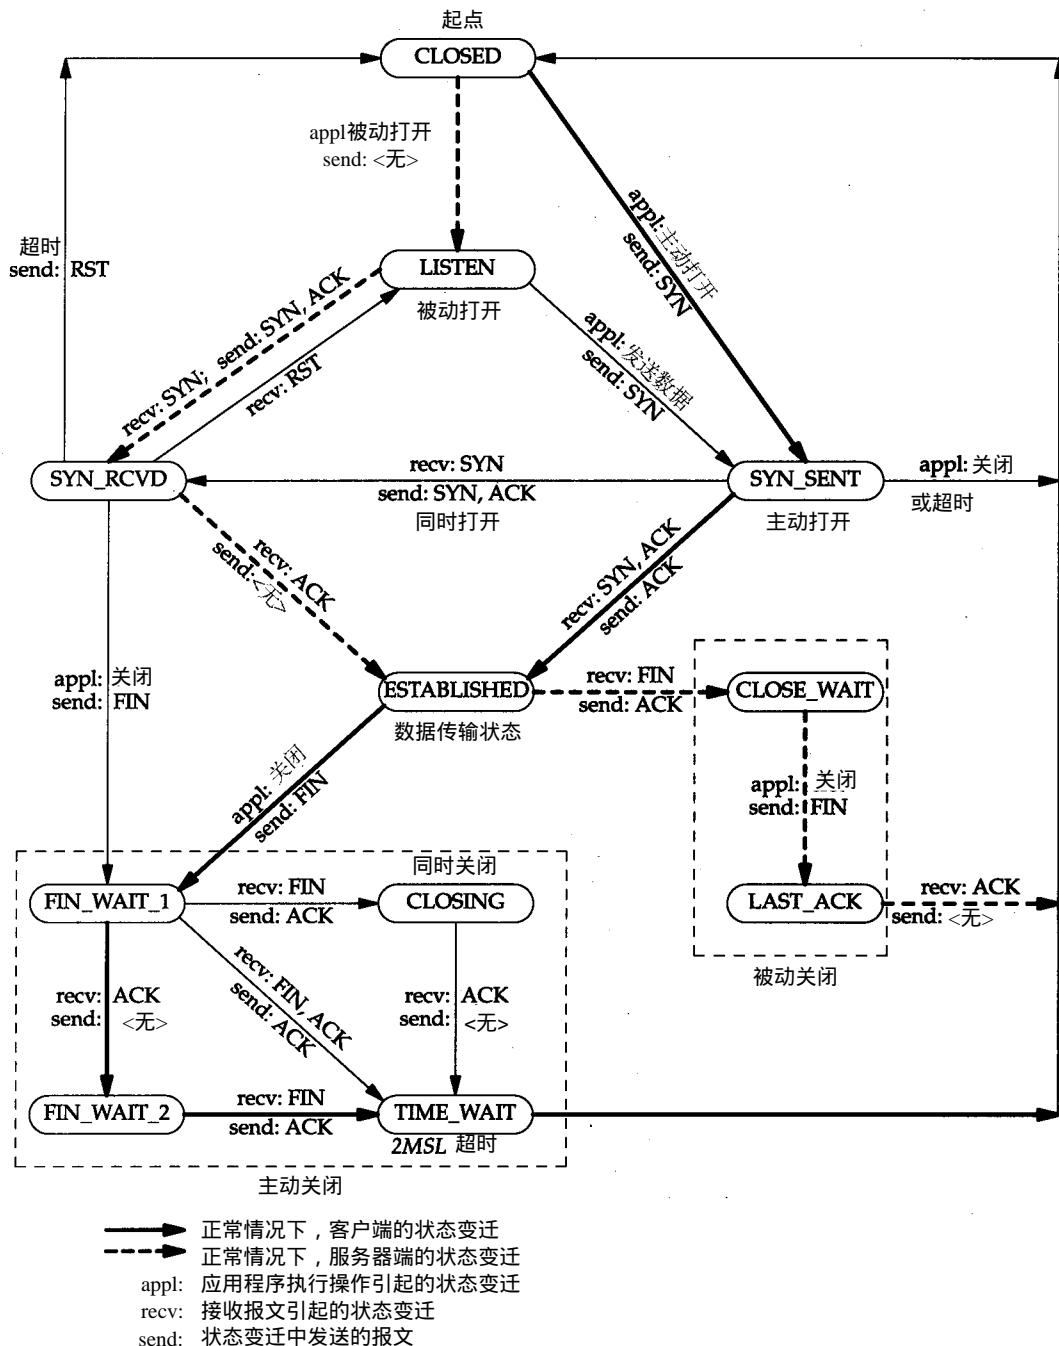


图24-15 TCP状态变迁图

24.7 TCP的序号

TCP连接上传输的每个数据字节，以及SYN、FIN等控制报文都被赋予一个32 bit的序号。TCP首部的序号字段(图24-10)填充了报文段第一个数据字节的32 bit的序号，确认号字段填充

了发送方希望接收的下一序号，确认已正确接收了所有序号小于等于确认号减 1 的数据字节。换言之，确认号是 ACK发送方等待接收的下一序号。只有当报文首部的 ACK标志置位时，确认序号才有效。读者将看到，除了在主动打开首次发送 SYN时(SYN_SENT状态，参见图 24-16中的tcp_outflags[2])或在某些RST报文段中，ACK标志总是被置位的。

t_state	值	描 述	tcp_outflags[]
TCPS_CLOSED	0	关闭	TH_RST TH_ACK
TCPS_LISTEN	1	监听连接请求(被动打开)	0
TCPS_SYN_SENT	2	已发送SYN(主动打开)	TH_SYN
TCPS_SYN_RECEIVED	3	已发送并接收SYN；等待ACK	TH_SYN TH_ACK
TCPS_ESTABLISHED	4	连接建立(数据传输)	TH_ACK
TCPS_CLOSE_WAIT	5	已收到FIN，等待应用程序关闭	TH_ACK
TCPS_FIN_WAIT_1	6	已关闭，发送FIN；等待ACK和FIN	TH_FIN TH_ACK
TCPS_CLOSING	7	同时关闭；等待ACK	TH_FIN TH_ACK
TCPS_LAST_ACK	8	收到的FIN已关闭；等待ACK	TH_FIN TH_ACK
TCPS_FIN_WAIT_2	9	已关闭，等待FIN	TH_ACK
TCPS_TIME_WAIT	10	主动关闭后2MSL等待状态	TH_ACK

图24-16 t_state 取值

由于TCP连接是全双工的，每一端都必须为两个方向上的数据流维护序号。TCP控制块中(图24-13)有13个序号：8个用于数据发送(发送序号空间)，5个用于数据接收(接收序号空间)。

图24-17给出了发送序号空间中4个变量间的关系：snd_wnd、snd_una、snd_nxt和snd_max。这个例子列出了数据流的第1~第11字节。

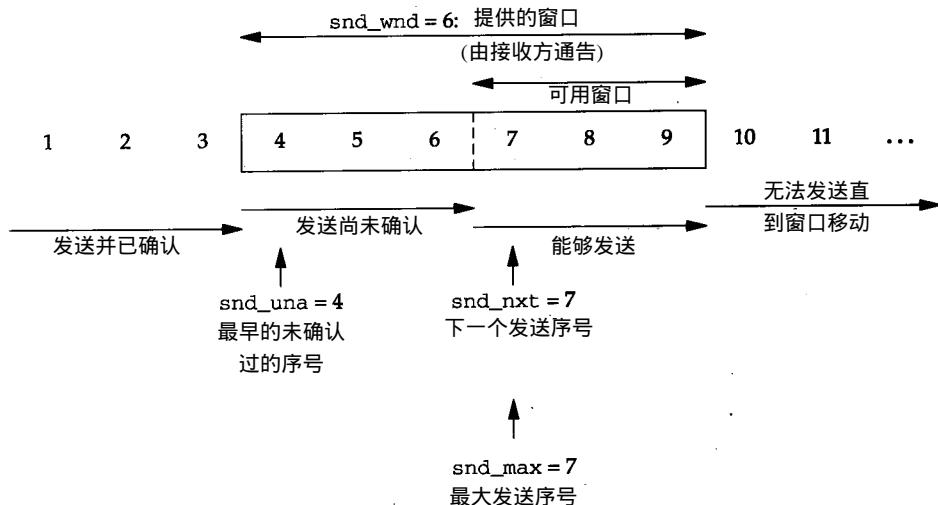


图24-17 发送序号空间举例

一个有效的ACK序号必须满足：

$\text{snd_una} < \text{确认序号} \leq \text{snd_max}$

图24-17的例子中，一个有效 ACK的确认号必须是 5、6或7。如果确认号小于或等于 snd_una ，则是一个重复的ACK。它确认了已确认过的八位组，否则 snd_una 不会递增超过那些序号。

`tcp_output`中有多处用到下面的测试，如果正发送的是重传数据，则表达式为真：

`snd_nxt < snd_max`

图24-18给出了图24-17中连接的另一端：接收序号空间，图中假定还未收到序号为4、5、6的报文，标出了三个变量`rcv_nxt`、`rcv_wnd`和`rcv_adv`。

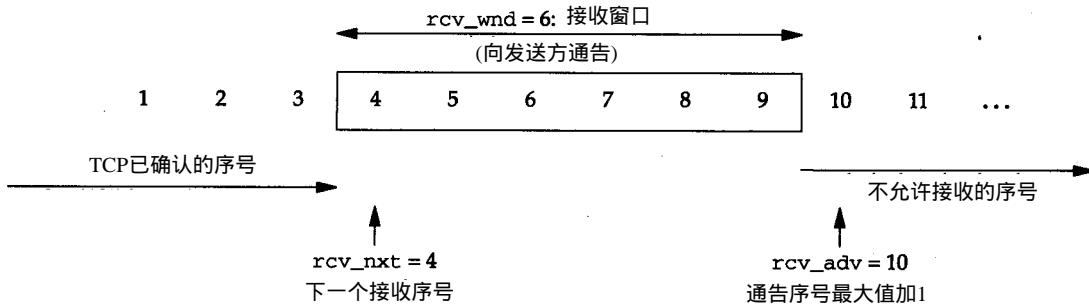


图24-18 接收序号空间举例

如果接收报文段中携带的数据落在接收窗口内，则该报文段是一个有效报文段。换言之，下面两个不等式中至少要有一个为真。

`rcv_nxt <= 报文段起始序号 < rcv_nxt + rcv_wnd`
`rcv_nxt <= 报文段终止序号 < rcv_nxt + rcv_wnd`

报文段起始序号就是TCP首部的序号字段，`ti_seq`。终止序号是序号字段加上TCP数据长度后减1。

例如，图24-19中的TCP报文段，携带了图24-17中发送的三个字节，序号分别是4、5和6。

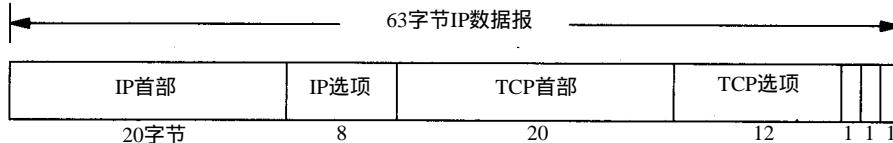


图24-19 TCP报文段在IP数据报中传输

假定IP数据报中有8字节的IP任选项和12字节的TCP任选项。图12-20列出了各有关变量的取值。

变 量	值	描 述
<code>ip_hl</code>	7	IP首部+IP任选项长度，以32 bit为单位(=28字节)
<code>ip_len</code>	63	IP数据报长度，以字节为单位(20+8+20+12+3)
<code>ti_off</code>	8	TCP首部+TCP任选项长度，以32 bit为单位(=32字节)
<code>ti_seq</code>	4	用户数据第一个字节的序号
<code>ti_len</code>	3	TCP数据的字节数： <code>ip_len - (ip_hl * 4) - (ti_off * 4)</code>
	6	用户数据最后一个字节的序号： <code>ti_seq + ti_len - 1</code>

图24-20 图24-19中各变量的取值

`ti_len`并非TCP首部的字段，而是在对接收到的首部计算检验和及完成验证之后，根据图24-20中的算式得到的结果，存储到外加的IP结构中(图24-12)。图中最后一个值并不存储到变量中，而是在需要时直接从其他值中通过计算得到。

1. 序号取模运算

TCP必须处理的一个问题是序号来自有限的 32位取值空间：0~4 294 967 295。如果某个TCP连接传输的数据量超过 2^{32} 字节，序号从4 294 967 295回绕到0，将出现重复序号。

即使传输数据量小于 2^{32} 字节，仍可能遇到同样的问题，因为连接的初始序号并不一定从0开始。各数据流方向上的初始序号可以是0~4 294 967 295之间的任何值。这个问题使序号复杂化。例如，序号1可能大于序号4 294 967 295。

在tcp.h中，TCP序号定义为unsigned long

```
typedef u_long tcp_seq;
```

图24-21定义了4个用于序号比较的宏。

<pre>40 #define SEQ_LT(a,b) ((int)((a)-(b)) < 0) 41 #define SEQ_LEQ(a,b) ((int)((a)-(b)) <= 0) 42 #define SEQ_GT(a,b) ((int)((a)-(b)) > 0) 43 #define SEQ_GEQ(a,b) ((int)((a)-(b)) >= 0)</pre>	<i>tcp_seq.h</i> <i>tcp_seq.h</i>
--	--------------------------------------

图24-21 TCP序号比较宏

2. 举例——序号比较

下面这个例子说明了TCP序号的操作方式。假定序号只有3 bit，0~7。图24-22列出了全部8个序号和相应的二进制补码（为求二进制补码，将二进制码中的所有0变为1，所有1变为0，最后再加1）。给出补码形式，是因为 $a - b = a + (b$ 的补码)。

x	二进制码	二进制补码	0-x	1-x	2-x
0	000	000	000	001	010
1	001	111	111	000	001
2	010	110	110	111	000
3	011	101	101	110	111
4	100	100	100	101	110
5	101	011	011	100	101
6	110	010	010	011	100
7	111	001	001	010	011

图24-22 3 bit序号举例

表中最后三栏分别是0-x、1-x和2-x。在这三栏中，如果定义计算结果是带符号整数（注意图24-21中的四个宏，计算结果全部强制转换为int），那么最高位为1表示值小于0（SEQ_LT宏），最高位为0且值不为0表示大于0（SEQ_GT宏）。最后三栏中以横线分隔开四个负值和四个非正值。

请注意图24-22中的第四栏（标注“0-x”），可看出0小于1、2、3和4（最高位比特为1），而0大于5、6和7（最高位比特为0且结果非0）。图24-23显示了这种关系。

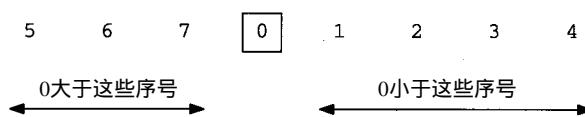


图24-23 3 bit的TCP序号的比较

图24-22中的第五栏(1-x)也存在类似的关系，如图24-24所示。

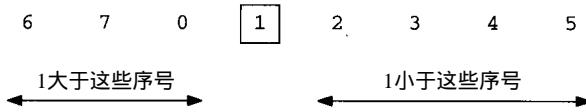


图24-24 3 bit的TCP序号的比较

图24-25是上面两图的另一种表示形式，使用圆环强调了序号的回绕现象。

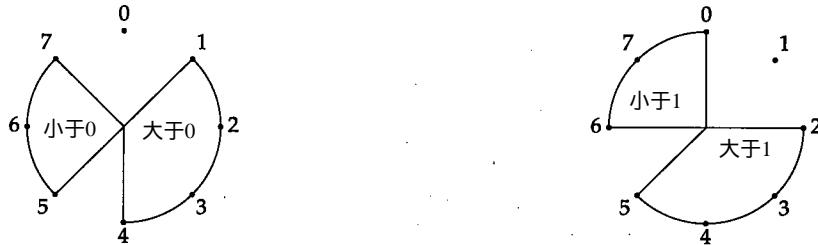


图24-25 图24-23和图24-24的另一种表示形式

就TCP而言，通过序号比较来确定给定序号是新序号或重传序号。例如，在图 24-24的例子中，如果TCP正等待的序号为1，但到达序号为6，通过前面介绍的计算可知 6小于1，从而判定这是重传的数据，可予以丢弃。但如果到达序号为5，因为5大于1，TCP判定这是新数据，予以保存，并继续等待序号为2、3和4的八位组(假定序号为5的数据字节落在接收窗口内)。

图24-26扩展了图24-25中左边的圆环，用TCP 32 bit的序号替代了3 bit的序号。

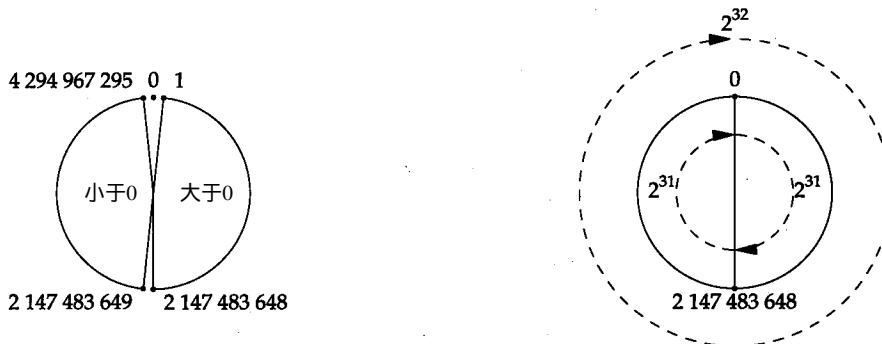


图24-26 与序号0比较：采用32 bit序号

图24-26右边的圆环强调了32 bit序号空间的一半有 2^{31} 个可用数字。

24.8 tcp_init函数

系统初始化时，domaininit函数调用TCP的初始化函数：tcp_init(图24-27)。

1. 设定初始发送序号

初始发送序号(ISS)，tcp_iss，被初始化为1。请注意，代码注释指出，这是错误的。后面讨论TCP的“平静时间(quiet time)”时，将简单介绍这一选择的原因。请读者自行与图 7-23 中IP标识符的初始化做比较，后者使用了当天的时钟。

```

43 void
44 tcp_init()
45 {
46     tcp_iss = 1;           /* wrong */
47     tcb.inp_next = tcb.inp_prev = &tcb;
48     if (max_protohdr < sizeof(struct tciphdr))
49         max_protohdr = sizeof(struct tciphdr);
50     if (max_linkhdr + sizeof(struct tciphdr) > MHLEN)
51         panic("tcp_init");
52 }

```

*tcp_subr.c*图24-27 `tcp_init` 函数

2. TCP Internet PCB链表初始化

PCB首部(`tcb`)的`previous`指针和`next`指针都指向自己，这是一个空的双向链表。`tcb` PCB的其余成员均初始化为 0(所有未明确初始化的全局变量均设为 0)。事实上，除链表外，在该 PCB首部中只用了一个字段 `inp_lport`：下一个分配的TCP临时端口号。TCP使用的第一 个临时端口号应为 1024，练习22.4的解答中给出了原因。

3. 计算最大协议首部长度

到目前为止，讨论过的协议首部的长度最大不超过 40字节，`max_protohdr`设为40(组合的IP/TCP首部长度，不带任何可选项)。图7-17定义了该变量。如果 `max_linkhdr` (通常为 16)加40后大于放入单个 mbuf中带首部的数据报的数据长度 (100字节，图2-7中的MHLEN)，内核将告警。

MSL和平静时间的概念

TCP协议要求如果主机崩溃，且没能保存打开 TCP连接上最后使用的序号，则重启后在一个MSL(2分钟，平静时间)内，不能发送任何 TCP报文段。目前，基本没有 TCP实现能够在系统崩溃或操作员关机时保存这些信息。

MSL是最大报文段生存时间(maximum segment lifetime)，指任何报文段被丢弃前在网络中能够存在的最大时间。不同的实现可选择不同的 MSL。连接主动关闭后，将在 CLOSE_WAIT状态等待2个MSL时间(图24-15)。

RFC 793(Postel 1981c)建议MSL设定为2分钟，但Net/3实现中MSL设为30秒(图25-3中定义的常量TCPTV_MSL)。

如果报文段在网络中出现延迟，协议会出现问题 (RFC 793称之为漫游重复(wandering duplicate))。假定Net/3系统启动时 `tcp_iss`置为1(图24-27)，经过一段时间，在序号刚刚回绕时系统崩溃。后面 25.5节中将介绍，`tcp_iss`每秒增加128 000，即重启后需经过9.3小时序号才会回绕。此外，每发送一个 `connect`，`tcp_iss`将增加64 000，因此序号回绕时间必然早于9.3小时。下面的例子说明了老的报文段怎样被错误地发送到现在的连接上。

1) 一个客户和服务器建立了一个连接。客户的端口号是 1024，发送了一个序号为2的报文段。该报文段在传送途中陷入路径循环，未能到达服务器。这个报文段成为“漫游重复”报文段。

- 2) 客户重发该报文段，序号依旧为2。重发报文段到达服务器。
- 3) 客户关闭连接。
- 4) 客户主机崩溃。
- 5) 客户主机在崩溃后40秒重启，TCP初始化tcp_iss为1。
- 6) 同一客户和同一服务器之间立即建立了一条新的连接，使用了同样的端口号：客户端口号为1024，服务器方依然是其预知的端口号。客户发送的SYN中初始序号置为1。这条新的使用同样端口对的连接称为原有连接的化身(incarnation)。
- 7) 步骤1中的漫游重复报文段最终到达服务器，并被认为是新建连接中的合法报文段，尽管它实际上属于原有连接。

图24-28列出了上述步骤发生的时间顺序。

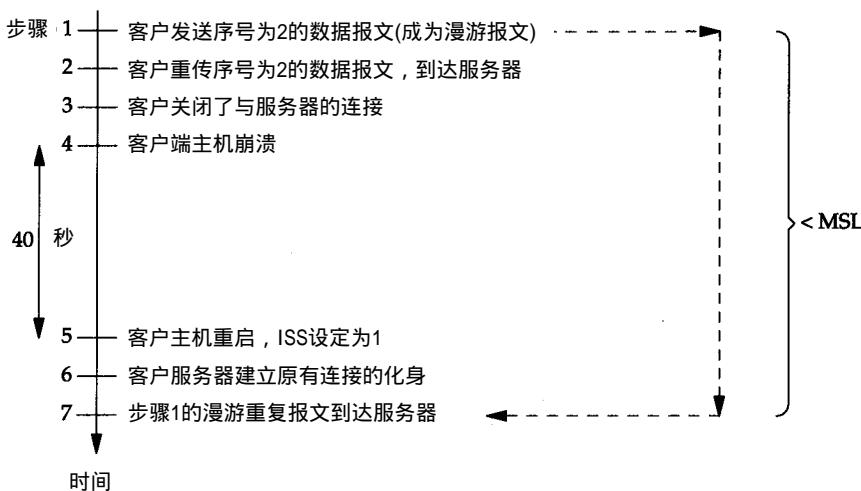


图24-28 示例：旧报文段到达原有连接的化身

即使系统重启后，TCP通过当前时钟计算ISS，问题同样存在。无论原有连接的ISS设为多少，由于序号会回绕，完全有可能重启后新建连接的ISS接近等于重启前原有连接最后使用的序号。

除了保存重启前所有已建连接的序号，解决这个问题的唯一方法就是重启后TCP在MSL内保持平静(不发送任何报文段)。尽管问题有可能出现，但绝大多数TCP中并未实现相应的解决方法，因为多数主机仅重启时间就要长于MSL。

24.9 小结

本章概要介绍了接下来的6章中将要讨论的TCP源代码。TCP为每条连接建立自己的控制块，保存该连接的所有变量和状态信息。

定义了TCP的状态变迁图，TCP在哪些条件下从一个状态变迁到另一个状态，每次变迁过程中发送和接收了哪些报文段。状态变迁图还显示了连接建立和终止的过程。在后续TCP讨论中会经常引用该图。

TCP连接上传输的每个数据字节都有相应的序号，TCP在连接控制块中维护多个序号：有些用于发送，有些用于接收(TCP工作于全双工方式)。由于序号来自有限的32 bit空间，会从

最大值回绕到0。本章解释了如何使用小于和大于测试来比较序号，在后续的TCP代码中将不断遇到序号的比较。

最后介绍了最简单的TCP函数，`tcp_init`，完成对Internet PCB的TCP链表的初始化。此外，还讨论了初始发送序号的选取问题。

习题

- 24.1 研究图24-5中的统计数据，计算每条连接上发送和接收的平均字节数。
- 24.2 在`tcp_init`中，内核告警是否合理？
- 24.3 执行`netstat -a` 了解你的系统当前有多少个活跃的TCP端点。

第25章 TCP的定时器

25.1 引言

从本章起，我们开始详细讨论TCP的实现代码，首先熟悉一下在绝大多数TCP函数里都会遇到的各种定时器。

TCP为每条连接建立了七个定时器。按照它们在一条连接生存期内出现的次序，简要介绍如下。

- 1) “连接建立(connection establishment)”定时器在发送SYN报文段建立一条新连接时启动。如果没有在75秒内收到响应，连接建立将中止。
- 2) “重传(retransmission)”定时器在TCP发送数据时设定。如果定时器已超时而对端的确认还未到达，TCP将重传数据。重传定时器的值(即TCP等待对端确认的时间)是动态计算的，取决于TCP为该连接测量的往返时间和该报文段已被重传的次数。
- 3) “延迟ACK(delayed ACK)”定时器在TCP收到必须被确认但无需马上发出确认的数据时设定。TCP等待200 ms后发送确认响应。如果，在这200 ms内，有数据要在该连接上发送，延迟的ACK响应就可随着数据一起发送回对端，称为捎带确认。
- 4) “持续(persist)”定时器在连接对端通告接收窗口为0，阻止TCP继续发送数据时设定。由于连接对端发送的窗口通告不可靠(只有数据才会被确认，ACK不会被确认)，允许TCP继续发送数据的后续窗口更新有可能丢失。因此，如果TCP有数据要发送，但对端通告接收窗口为0，则持续定时器启动，超时后向对端发送1字节的数据，判定对端接收窗口是否已打开。与重传定时器类似，持续定时器的值也是动态计算的，取决于连接的往返时间，在5秒到60秒之间取值。
- 5) “保活(keepalive)”定时器在应用进程选取了插口的SO_KEEPALIVE选项时生效。如果连接的连续空闲时间超过2小时，保活定时器超时，向对端发送连接探测报文段，强迫对端响应。如果收到了期待的响应，TCP可确定对端主机工作正常，在该连接再次空闲超过2小时之前，TCP不会再进行保活测试。如果收到的是其他响应，TCP可确定对端主机已重启。如果连续若干次保活测试都未收到响应，TCP就假定对端主机已崩溃，尽管它无法区分是主机故障(例如，系统崩溃而尚未重启)，还是连接故障(例如，中间的路由器发生故障或电话线断了)。
- 6) FIN_WAIT_2定时器。当某个连接从FIN_WAIT_1状态迁移到FIN_WAIT_2状态(图24-15)，并且不能再接收任何新数据时(意味着应用进程调用了close，而非shutdown，没有利用TCP的半关闭功能)，FIN_WAIT_2定时器启动，设为10分钟。定时器超时后，重新设为75秒，第二次超时后连接被关闭。加入这个定时器的目的是为了避免如果对端一直不发送FIN，某个连接会永远滞留在FIN_WAIT_2状态。
- 7) TIME_WAIT定时器，一般也称为2MSL定时器。2MSL指两倍的MSL，24.8节定义的最大报文段生存时间。当连接转移到TIME_WAIT状态，即连接主动关闭时，定时器启动。卷1

的18.6节详细说明了需要2MSL等待状态的原因。连接进入 TIME_WAIT状态时，定时器设定为1分钟(Net/3选用30秒的MSL)，超时后，TCP控制块和Internet PCB被删除，端口号可重新使用。

TCP包括两个定时器函数：一个函数每200 ms调用一次(快速定时器)；另一个函数每500 ms调用一次(慢速定时器)。延迟ACK定时器与其他6个定时器有所不同：如果某个连接上设定了延迟ACK定时器，那么下一次200 ms定时器超时后，延迟的ACK必须被发送(ACK的延迟时间必须在0~200 ms之间)。其他的定时器每500 ms递减一次，计数器减为0时，就触发相应的动作。

25.2 代码介绍

当某个连接的TCP控制块中的TF_DELACK标志(图24-14)置位时，允许该连接使用延迟ACK定时器。TCP控制块中的t_timer数组包括4个(TCPT_NTIMERS)计数器，用于实现其他的6个定时器。图25-1列出了数组的索引。下面简单地介绍这6个计数器是如何实现除延迟ACK定时器外的其余6个定时器的。

常量	值	描述
TCPT_REXMT	0	重传定时器
TCPT_PERSIST	1	持续定时器
TCPT_KEEP	2	保活定时器或连接建立定时器
TCPT_2MSL	3	2MSL定时器或FIN_WAIT_2定时器

图25-1 t_timer 数组索引

t_timer中的每条记录，保存了定时器的剩余值，以500 ms为计时单位。如果等于零，则说明对应的定时器没有设定。由于每个定时器都是短整型，所以定时器的最大值只能设定为16 383.5秒，约为4.5小时。

	建连 定时器	重传 定时器	延迟ACK 定时器	持续 定时器	保活 定时器	FIN WAIT_2	2MSL
t_timer[TCPT_REXMT]		•					
t_timer[TCPT_PERSIST]	•			•			
t_timer[TCPT_KEEP]			•		•		
t_timer[TCPT_2MSL]						•	
t_flags & TF_DELACK							
tcp_keepidle (2小时)					•		
tcp_keepintvl (75秒)					•		
tcp_maxidle (10分钟)					•		
2 * TCPTV_MSL (60秒)	•						•
TCPTV_KEEP_INIT (75秒)							

图25-2 七个TCP定时器的实现

请注意，图25-1中利用4个“定时计数器”实现了6个TCP“定时器”，这是因为有些定时器彼此间是互斥的。下面我们首先区分一下计数器与定时器。TCPT_KEEP计数器同时实现了保活定时器和连接建立定时器，因为这两个定时器永远不会同时出现在同一条连接上。类似地，2MSL定时器和FIN_WAIT_2定时器都由TCPT_2MSL计数器实现，因为一条连接在同一

时间内只可能处于其中的一种状态。图 25-2的第一行小结了7个TCP定时器的实现方式，第二行和第三行列出了其中4个定时器初始化时用到的3个全局变量(图24-3)和2个常量(图25-3)。注意，有2个全局变量同时被多个定时器使用。前面已讨论过，延迟 ACK定时器直接受控于TCP的200 ms定时器，在本章后续部分将讨论其他2个定时器的时间长度是如何设定的。

图25-3列出了Net/3实现中基本的定时器取值。

常量	500ms的时钟滴答数	秒数	描述
<i>TCPTV_MSL</i>	60	30	MSL，最大报文段生存时间
<i>TCPTV_MIN</i>	2	1	重传定时器最小值
<i>TCPTV_REXMTMAX</i>	128	64	重传定时器最大值
<i>TCPTV_PERSMIN</i>	10	5	持续定时器最小值
<i>TCPTV_PERSMAX</i>	120	60	持续定时器最大值
<i>TCPTV_KEEP_INIT</i>	150	75	连接建立定时器取值
<i>TCPTV_KEEP_IDLE</i>	14400	7200	第一次保活测试前连接的空闲时间(2小时)
<i>TCPTV_KEEPINTVL</i>	150	75	对端无响应时保活测试间的间隔时间
<i>TCPTV_SRTTBASE</i>	0		特殊取值，意味着目前无连接 RTT样本
<i>TCPTV_SRTTDFLT</i>	6	3	连接无RTT样本时的默认值

图25-3 TCP实现中基本的定时器取值

图25-4列出了在代码中会遇到的其他定时器常量。

常量	值	描述
<i>TCP_LINGERTIME</i>	120	用于SO_LINGER插口选项的最大时间，以秒为单位
<i>TCP_MAXRXTSHIFT</i>	12	等待某个ACK的最大重传次数
<i>TCPTV_KEEPCNT</i>	8	对端无响应时，最大保活测试次数

图25-4 定时器常量

图25-5中定义的TCPT_RANGESET宏，给定时器设定一个给定值，并确认该值在指定范围内。

```
102 #define TCPT_RANGESET(tv, value, tvmin, tvmax) { \
103     (tv) = (value); \
104     if ((tv) < (tvmin)) \
105         (tv) = (tvmin); \
106     else if ((tv) > (tvmax)) \
107         (tv) = (tvmax); \
108 }
```

tcp_timer.h

tcp_timer.h

图25-5 TCPT_RANGESET 宏

从图25-3可知，重传定时器和持续定时器都有最大值和最小值限制，因为它们的取值都是基于测量的往返时间动态计算得到的，其他定时器均设为常值。

本章中将不讨论图25-4中列出的一个特殊定时器：插口的拖延定时器(linger timer)，这是由插口选项SO_LINGER设置的。这是一个插口级的定时器，由系统函数close使用(15.15节)。在图30-12中读者将看到，插口关闭时，TCP会首先检查该选项是否置位，拖延时间是否为0。

如果上述条件满足，将不采用TCP正常的关闭过程，连接直接被复位。

25.3 tcp_canceltimers函数

图25-6中定义了tcp_canceltimers函数。连接进入TIME_WAIT状态时，tcp_input在设定2MSL定时器之前，调用该函数。4个定时计数器清零，相应地关闭了重传定时器、持续定时器、保活定时器和FIN_WAIT_2定时器。

```
107 void
108 tcp_canceltimers(tp)
109 struct tcpcb *tp;
110 {
111     int     i;
112     for (i = 0; i < TCPT_NTIMERS; i++)
113         tp->t_timer[i] = 0;
114 }
```

tcp_timer.c

图25-6 tcp_canceltimers 函数

25.4 tcp_fasttimo函数

图25-7定义了tcp_fasttimo函数。该函数每隔200 ms被pr_fasttimo调用一次，用于操作延迟ACK定时器。

```
41 void
42 tcp_fasttimo()
43 {
44     struct inpcb *inp;
45     struct tcpcb *tp;
46     int      s = splnet();

47     inp = tcb.inp_next;
48     if (inp)
49         for (; inp != &tcb; inp = inp->inp_next)
50             if ((tp = (struct tcpcb *) inp->inp_ppcb) &&
51                 (tp->t_flags & TF_DELACK)) {
52                 tp->t_flags &= ~TF_DELACK;
53                 tp->t_flags |= TF_ACKNOW;
54                 tcpstat.tcps_delack++;
55                 (void) tcp_output(tp);
56             }
57     splx(s);
58 }
```

tcp_timer.c

图25-7 tcp_fasttimo 函数，每200 ms 调用一次

函数检查TCP链表中每个具有对应TCP控制块的Internet PCB。如果TCP_DELACK标志置位，清除该标志，并置位TF_ACKNOW标志。调用tcp_output，由于TF_ACKNOW标志已置位，ACK被发送。

为什么TCP的PCB链表中的某个Internet PCB会没有相应的TCP控制块(第50行的判断)？读者将在图30-11中看到，创建插口时(PRU_ATTACH请求响应socket系统调用)，首先创建

Inertnet PCB，之后才创建TCP控制块。两个操作间有可能会插入高优先级的时钟中断(图1-13)，该中断有可能调用tcp_fasttimo函数。

25.5 tcp_slowtimo函数

图25-8定义了tcp_slowtimo函数，每隔500ms被pr_slowtimo调用一次。它操作其他6个定时器：连接建立定时器、重传定时器、持续定时器、保活定时器、FIN_WAIT_2定时器和2MSL定时器。

```

64 void
65 tcp_slowtimo()
66 {
67     struct inpcb *ip, *ipnxt;
68     struct tcpcb *tp;
69     int      s = splnet();
70     int      i;

71     tcp_maxidle = TCPTV_KEEPCNT * tcp_keepintvl;
72     /*
73      * Search through tcb's and update active timers.
74      */
75     ip = tcb.inp_next;
76     if (ip == 0) {
77         splx(s);
78         return;
79     }
80     for (; ip != &tcb; ip = ipnxt) {
81         ipnxt = ip->inp_next;
82         tp = intotcpcb(ip);
83         if (tp == 0)
84             continue;
85         for (i = 0; i < TCPT_NTIMERS; i++) {
86             if (tp->t_timer[i] && --tp->t_timer[i] == 0) {
87                 (void) tcp_usrreq(tp->t_inpcb->inp_socket,
88                                     PRU_SLOWTIMO, (struct mbuf *) 0,
89                                     (struct mbuf *) i, (struct mbuf *) 0);
90                 if (ipnxt->inp_prev != ip)
91                     goto tpgone;
92             }
93         }
94         tp->t_idle++;
95         if (tp->t_rtt)
96             tp->t_rtt++;
97     tpgone:
98     ;
99 }
100    tcp_iss += TCP_ISSINCR / PR_SLOWHZ; /* increment iss */
101    tcp_now++; /* for timestamps */
102    splx(s);
103 }
```

tcp_timer.c

图25-8 tcp_slowtimo 函数，每隔500 ms调用一次

71 tcp_maxidle初始化为10分钟，这是TCP向对端发送连接探测报文段后，收到对端主机响应前的最长等待时间。如图25-6所示，FIN_WAIT_2定时器也使用了这一变量。它的初始化语句可放到tcp_init中，因为其值可在系统初启时设定(见习题25.2)。

1. 检查所有TCP控制块中的所有定时器

72-89 检查TCP链表中每个具有对应TCP控制块的Internet PCB，测试每个连接的所有定时计数器，如果非0，计数器减1。如果减为0，则发送PRU_SLOWTIMO请求。后面会介绍该请求将调用tcp_timers函数。

tcp_usrreq的第四个入口参数是指向 mbuf的指针。不过，在不需要 mbuf指针的场合，这个参数实际被用于完成其他功能。tcp_slowtimo函数中利用它传递索引 i，指出超时的是哪一个时钟。代码中把 i强制转换为 mbuf指针是为了避免编译错误。

2. 检查TCP控制块是否已被删除

90-93 在检查控制块中的定时器之前，先将指向下一个 Internet PCB的指针保存在 ipnxt中。每次PRU_SLOWTIMO请求返回后，tcp_slowtimo会检查TCP链表中的下一个PCB是否仍指向当前正处理的PCB。如果不是，则意味着控制块已被删除——也许2MSL定时器超时或重传定时器超时，并且TCP已放弃当前连接——控制转到tpgone，跳过当前控制块的其余定时器，并移至下一个PCB。

3. 计算空闲时间

94 当一个报文段到达当前连接，tcp_input清零控制块中的t_idle。从连接收到最后一个报文段起，每隔500ms t_idle递增一次。空闲时间统计主要有三个目的：(1)TCP在连接空闲2小时后发送连接探测报文段；(2)如果连接位于FIN_WAIT_2状态，且空闲10分钟后又空闲75秒，TCP将关闭该连接；(3)连接空闲一段时间后，tcp_output将返回慢启动状态。

4. 增加RTT计数器

95-96 如果需要测量某个报文段的 RTT，tcp_output在发送该报文段时，初始化t_rtt计数器为1。它每500 ms递增一次，直至收到该报文段的确认。在tcp_slowtimo函数中，如果连接正对某个报文段计时，即t_rtt计数器非零，则递增t_rtt。

5. 递增初始发送序号

100 tcp_iss在tcp_init中初始化为1。每500 ms tcp_iss增加64 000: 128 000 (TCP_ISSINCR) 除以2 (PR_SLOWHZ)。尽管看上去tcp_iss每秒钟仅递增两次，但实际速率可达每8微妙增加1。后面将介绍，无论主动打开或被动打开，只要建立了一条连接，tcp_iss就会增加64 000。

RFC 793规定初始发送序号应该约每4微妙增加一次，或每秒钟250 000次。Net/3实现的增加速率只有规定的一半。

6. 递增RFC 1323规定的时间戳值

101 tcp_now在系统重启时初始化为0，每500 ms递增一次，用于实现RFC 1323中定义的时间戳[Jacobson, Barden和Borman 1992]。26.6节中将详细介绍这一功能。

75-79 请注意，如果主机上没有打开的连接 (tcp_inp_next为空)，则tcp_iss和tcp_now的递增将停止。这种状况只可能发生在系统初启时，因为在一个联网的 UNIX系统中几乎不可能没有若干活跃的TCP服务器。

25.6 tcp_timers函数

tcp_timers函数在4个TCP定时计数器中的任何一个减为0时由TCP的PRU_SLOWTIMO请求处理代码调用(图30-10)：

```
case PRU_SLOWTIMO:
    tp = tcp_timers(tp, (int)nam);
```

整个函数的结构是一个 switch语句，每个定时器对应一个 case语句，如图25-9所示。

```
120 struct tcpcb *
121 tcp_timers(tp, timer)
122 struct tcpcb *tp;
123 int      timer;
124 {
125     int      rexmt;
126     switch (timer) {
127         /* switch cases */
128     }
129     return (tp);
130 }
```

tcp_timer.c

图25-9 tcp_timers 函数：总体框架

下面我们介绍其中3个定时计数器(5个TCP定时器)，重传定时器留待25.11节中再讨论。

25.6.1 FIN_WAIT_2和2MSL定时器

TCP的TCP2_2MSL定时计数器实现了两种定时器。

1) FIN_WAIT_2定时器。当tcp_input从FIN_WAIT_1状态迁移到FIN_WAIT_2状态，并且插口不再接收任何新数据(意味着应用进程调用了close，而不是shutdown，从而无法利用TCP的半关闭功能)时，FIN_WAIT_2定时器设定为10分钟(tcp_maxidle)。这样可以防止连接永远停留在FIN_WAIT_2状态。

2) 2MSL定时器。当TCP转移到TIME_WAIT状态，2MSL定时器设定为60秒。

图25-10列出了处理2MSL定时器的case语句——在该定时器减为0时执行。

```
127     /*
128      * 2 MSL timeout in shutdown went off. If we're closed but
129      * still waiting for peer to close and connection has been idle
130      * too long, or if 2MSL time is up from TIME_WAIT, delete connection
131      * control block. Otherwise, check again in a bit.
132      */
133     case TCPT_2MSL:
134         if (tp->t_state != TCPS_TIME_WAIT &&
135             tp->t_idle <= tcp_maxidle)
136             tp->t_timer[TCPT_2MSL] = tcp_keepintvl;
137         else
138             tp = tcp_close(tp);
139     break;
```

tcp_timer.c

图25-10 tcp_timers 函数：2MSL定时器超时

1. 2MSL定时器

127-139 图25-10中的条件判断逻辑较为复杂，因为TCPT_2MSL计数器的两种不同用法混在了一起(习题25.4)。首先看TIME_WAIT状态，定时器60秒超时后，将调用tcp_close并释

放控制块。图 25-11 给出了典型的时间顺序，列出了 2MSL 定时器超时后的一系列函数调用。从图中可看出，如果某个定时器被设定为 N 秒 ($2 \times N$ 滴答)，由于定时计数器的第一次递减将发生在其后的 0~500 ms 之间，定时器将在其后 $2 \times N - 1$ 和 $2 \times N$ 个滴答之间的某个时刻超时。

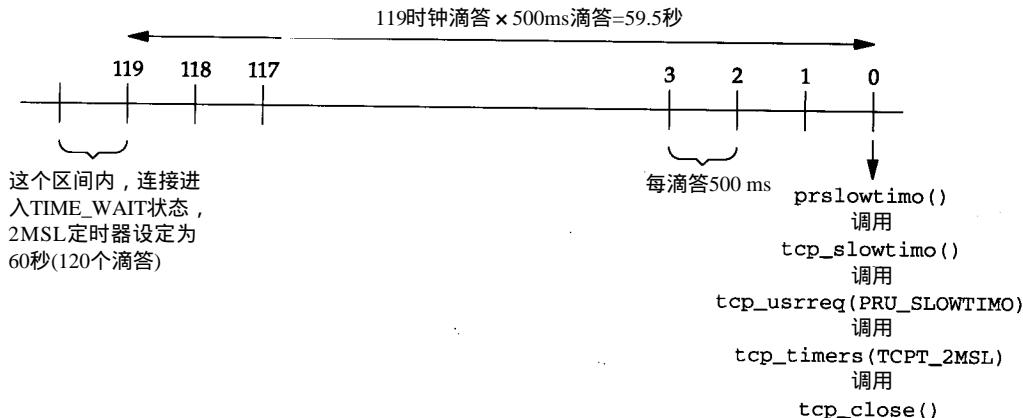


图 25-11 TIME_WAIT 状态下 2MSL 定时器的设定与超时

2. FIN_WAIT_2 定时器

127-139 如果连接状态不是 TIME_WAIT，TCPT_2MSL 计数器表示 FIN_WAIT_2 定时器。只要连接的空闲时间超过 10 分钟 (tcp_maxidle)，连接就会被关闭。但如果连接的空闲时间小于或等于 10 分钟，FIN_WAIT_2 定时器将被设为 75 秒。图 25-12 给出了典型的时间顺序。

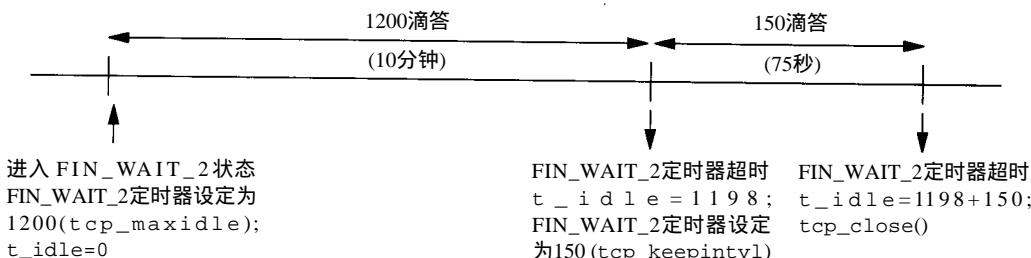


图 25-12 FIN_WAIT_2 定时器，避免永久滞留于 FIN_WAIT_2 状态

连接接收到一个 ACK 后，从 FIN_WAIT_1 状态迁移到 FIN_WAIT_2 状态（图 24-15）， t_{idle} 被置为 0，FIN_WAIT_2 定时器设为 1200 (tcp_maxidle)。图 25-12 中，向上的箭头指着 10 分钟定时起始时刻的右侧，强调定时计数器的第一次递减发生在定时器设定后的 0~500 ms 之间。1199 个滴答后，定时器超时。从图 25-8 中可知，在四个定时计数器递减并做超时判定之后， t_{idle} 才会增加，因此 t_{idle} 等于 1198（我们假定连接在 10 分钟内一直空闲）。因为条件表达式“1198 小于或等于 1200”为真，FIN_WAIT_2 定时器设为 150 (tcp_keepintvl)。定时器 75 秒后再次超时，假定连接一直空闲， t_{idle} 应为 1348，条件表达式为假，tcp_close() 被调用。

第一次 10 分钟定时后加入另一个 75 秒定时是因为除非持续空闲时间超过 10 分钟，否则处于 FIN_WAIT_2 状态的连接不会被关闭。如果第一个 10 分钟定时器还未超时，测试 t_{idle} 值是没有意义的，但只要过了这段时间，每隔 75 秒就会进行一次测试。由于有可能收到重复的报文段，即一个重复的 ACK 使得连接从 FIN_WAIT_1 状态迁移到 FIN_WAIT_2 状态，因此每收到一个报文段，10 分钟等待将重新开始（因为 t_{idle} 重设为 0）。

处于FIN_WAIT_2状态的连接在10分钟空闲后将被关闭，这一点并不符合协议规范，但在实际中是可行的。处于FIN_WAIT_2状态，应用进程调用close，连接上的所有数据都已发送并被确认，FIN已被对端确认，TCP等待对端应用进程调用close。如果对端进程永远不关闭它的连接，本地TCP将一直滞留在FIN_WAIT_2状态。应定义计数器保存由于这种原因而终止的连接数，从而了解这种状况出现的频率。

25.6.2 持续定时器

图25-13给出了处理持续定时器超时的case语句。

```
tcp_timer.c
210      /*
211       * Persistence timer into zero window.
212       * Force a byte to be output, if possible.
213       */
214     case TCPT_PERSIST:
215         tcpstat.tcpst_persisttimo++;
216         tcp_setpersist(tp);
217         tp->t_force = 1;
218         (void) tcp_output(tp);
219         tp->t_force = 0;
220         break;
```

tcp_timer.c

图25-13 tcp_timers 函数：持续定时器超时

强制发送窗口探测报文段

210-220 持续定时器超时后，由于对端已通告接收窗口为0，TCP无法向对端发送数据。此时，tcp_setpersist计算持续定时器的下一个设定值，并存储在TCPT_PERSIST计数器中。t_force标志置位，强制tcp_output发送1字节数据。

图25-14给出了局域网环境下，持续定时器的典型值，假定连接的重传时限为1.5秒(见卷1的图22-1)。



图25-14 持续定时器取值的时间表：探测对端接收窗口

一旦持续定时器取值达到60秒，TCP将每隔60秒发送一次窗口探测报文段。由于持续定时器取值的下限为5秒，上限为60秒，因此定时器头两次均设定为5秒，而不是1.5秒和3秒。从图中可知，定时器采用了指数退避策略，新的取值等于原有值乘以2，25.9节中将介绍这一算法的实现。

25.6.3 连接建立定时器和保活定时器

TCP的TCPT_KEEP计数器实现了两个定时器：

1) 当应用进程调用connect，连接转移到SYN_SENT状态(主动打开)，或者当连接从LISTEN状态迁移到SYN_RCVD状态(被动打开)时，SYN发送之后，将连接建立定时器设定为75秒(TCPTV_KEEP_INIT)。如果75秒内连接未能进入ESTABLISHED状态，则该连接被丢弃。

2) 收到一个报文段后，tcp_input将复位连接的保活定时器，重设为2小时(tcp_keepidle)，并清零连接的t_idle计数器。上述操作适用于系统中所有的TCP连接，无论是否置位了插口的保活选项。如果保活定时器超时(收到最后一个报文段2小时后)，并且置位了插口的保活选项，则TCP将向对端发送连接探测报文段。如果定时器超时，且未置位插口选项，则TCP将只复位定时器，重设为2小时。

图25-15给出了处理TCP的TCPT_KEEP计数器的case语句。

```

221      /*
222      * Keep-alive timer went off; send something
223      * or drop connection if idle for too long.
224      */
225      case TCPT_KEEP:
226          tcpstat.tcpstat_keeptimeo++;
227          if (tp->t_state < TCPS_ESTABLISHED)
228              goto dropit;           /* connection establishment timer */

229          if (tp->t_inpcb->inp_socket->so_options & SO_KEEPALIVE &&
230              tp->t_state <= TCPS_CLOSE_WAIT) {
231              if (tp->t_idle >= tcp_keepidle + tcp_maxidle)
232                  goto dropit;
233              /*
234              * Send a packet designed to force a response
235              * if the peer is up and reachable:
236              * either an ACK if the connection is still alive,
237              * or an RST if the peer has closed the connection
238              * due to timeout or reboot.
239              * Using sequence number tp->snd_una-1
240              * causes the transmitted zero-length segment
241              * to lie outside the receive window;
242              * by the protocol spec, this requires the
243              * correspondent TCP to respond.
244              */
245          tcpstat.tcpstat_keepprobe++;
246          tcp_respond(tp, tp->t_template, (struct mbuf *) NULL,
247                      tp->rcv_nxt, tp->snd_una - 1, 0);
248          tp->t_timer[TCPT_KEEP] = tcp_keepintvl;
249      } else
250          tp->t_timer[TCPT_KEEP] = tcp_keepidle;
251      break;
252
253      dropit:
254          tcpstat.tcpstat_keepdrops++;
255          tp = tcp_drop(tp, ETIMEDOUT);
256      break;

```

tcp_timer.c

图25-15 tcp_timer 函数：保活时钟超时处理

1. 连接建立定时器75秒后超时

221-228 如果状态小于ESTABLISHED(图24-16)，TCPT_KEEP计数器代表连接建立定时器。定时器超时后，控制转到dropit，调用tcp_drop终止连接，给出差错代码ETIMEDOUT。我们将看到，ETIMEDOUT是默认差错码——例如，连接收到了某个差错报告，比如ICMP的主机不可达，返回应用进程的差错码将变为EHOSTUNREACH，而非默认差错码。

我们将在图30-4中看到，TCP发送SYN的同时初始化了两个定时器：正在讨论的连接建立定时器，设定为75秒，和重传定时器，保证对端无响应时可重传SYN。图25-16给出了这两个

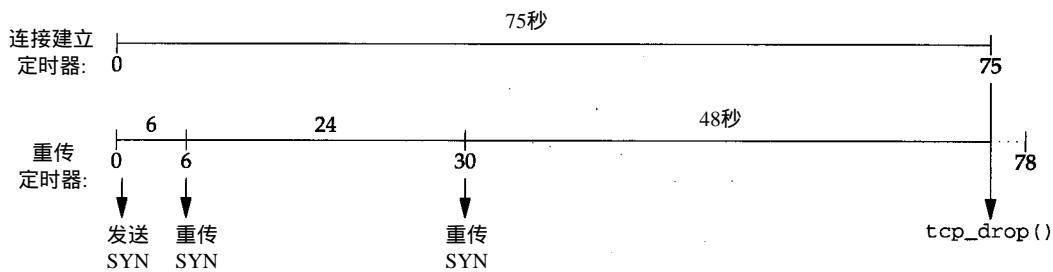


图25-16 SYN发送后：连接建立定时器和重传定时器

定时器。

对于一个新连接，重传定时器初始化为6秒(图25-19)，后续值分别为24秒和48秒，25.7节中将详细讨论定时器取值的计算方法。重传定时器使得SYN报文段在0秒、6秒和30秒处连续三次被重传。在75秒处，也就是重传定时器再次超时之前3秒钟，连接建立定时器超时，调用tcp_drop()终止连接。

2. 保活定时器在2小时空闲后超时

229-230 所有连接上的保活定时器在连续2小时空闲后超时，无论连接是否选取了插口的SO_KEEPALIVE选项。如果插口选项置位，并且连接处于ESTABLISHED状态或CLOSE_WAIT状态(图24-15)，TCP将发送连接探测报文段。但如果应用进程调用了close(状态大于CLOSE_WAIT)，即使连接已空闲了2小时，TCP也不会发送连接探测报文段。

3. 无响应时丢弃连接

231-232 如果连接总的空闲时间大于或等于2小时(tcp_keepidle)加10分钟(tcp_maxidle)，连接将被丢弃。也就是说，对端无响应时，TCP最多发送9个连接探测报文段，间隔75秒(tcp_keepintvl)。TCP在确认连接已死亡之前必须发送多个连接探测报文段的一个原因是，对端的响应很可能是不带数据的纯ACK报文段，TCP无法保证此类报文段的可靠传输，因此，连接探测报文段的响应有可能丢失。

4. 进行保活测试

233-248 如果TCP进行保活测试的次数还在许可范围之内，tcp_respond将发送连接探测报文段。报文段的确认字段(tcp_respond的第四个参数)填入rcv_nxt，期待接收的下一序号；序号字段填入snd_una - 1，即对端已确认过的序号(图24-17)。由于这一特定序号落在接收窗口之外，对端必然会发送ACK，给定它所期待的下一序号。

图25-17小结了保活定时器的用法

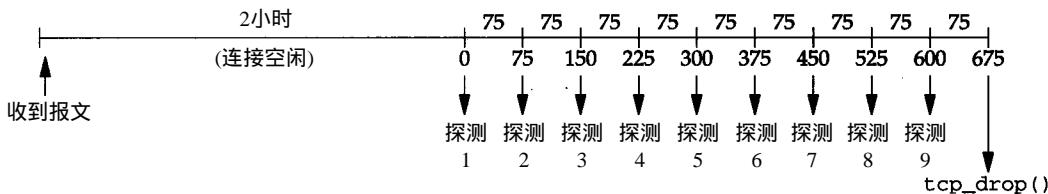


图25-17 保活定时器小结：判定对端是否可达

从0秒起，每隔75秒连续9次发送连接探测报文段，直至600秒。675秒时(定时器2小时超时后的11.25分钟)连接被丢弃。请注意，尽管常量TCPTV_KEEPCNT(图25-4)的值设为8，却发

送了9次报文段，这是因为代码首先完成定时器递减、与0比较并做可能的处理后才递增变量 `t_idle`(图25-8)。当 `tcp_input` 接收了一个报文段，就会复位保活定时器为 14400(`tcp_keepidle`)，并清零 `t_idle`。下一次调用 `tcp_slowtimo` 时，定时器减为 14339 而 `t_idle` 增为 1。约2小时后，定时器从 1 减为 0 时将调用 `tcp_timers`，而此时 `t_idle` 的值将为 14339。图25-18列出了每次调用 `tcp_timers` 时 `t_idle` 的取值。

图25-15中的代码一直等待 `t_idle` 大于或等于 15600 (`tcp_keepidle+tcp_maxidle`)，这一事件只可能发生在图25-17中的675秒处，即连续发送了9次连接探测报文段之后。

5. 复位保活定时器

249-250 如果插口选项未置位，或者连接状态大于 CLOSE_WAIT，连接的保活定时器将复位，重设为2小时(`tcp_keepidle`)。

遗憾的是，计数器 `tcp_kepdrops`(253行)不加区分地统计 TCPT_KEEP 定时计数器的两种不同用法所造成的连接丢弃：连接建立计数器和保活计数器。

25.7 重传定时器的计算

到目前为止，讨论过的定时器的取值都是固定的：延迟 ACK 200ms，连接建立定时器 75 秒，保活定时器 2 小时等等。最后两个定时器——重传定时器和持续定时器——的取值依于连接上测算得到的 RTT。在讨论实现定时器时限计算和设定的代码之前，首先应理解连接 RTT 的测算方法。

TCP的一个基本操作是在发送了需对端确认的报文段后，设置重传定时器。如果在定时器时限范围内未收到 ACK，该报文段被重发。TCP要求对端确认所有数据报文段，不携带数据的报文段则无需确认(例如纯ACK报文段)。如果估算的重传时间过小，响应到达前即超时，造成不必要的重传；如果过大，在报文段丢失之后，发送重传报文段之前将等待一段额外的时间，降低了系统的效率。更为复杂的是，主机间的往返时间动态改变，且变化范围显著。

Net/3中TCP计算重传时限(RTO)时不仅要测量数据报文段的往返时间(`nticks`)，还要记录已平滑的RTT估计器(`srtt`)和已平滑的RTT平均偏差估计器(`rttvar`)。平均偏差是标准方差的良好近似，计算较为容易，无需标准方差的求平方根运算。[\[Jacobson 1988b\]](#)讨论了RTT测算的其他细节，给出下面的公式：

$$\begin{aligned} \text{delta} &= \text{nticks} - \text{srtt} \\ \text{srtt} &= \text{srtt} + g \times \text{delta} \\ \text{rttvar} &= \text{rttvar} + h / (\text{delta} / \text{srtt} - \text{rttvar}) \\ \text{RTO} &= \text{srtt} + 4 \times \text{rttvar} \end{aligned}$$

`delta` 是最新测量的往返时间(`nticks`)与当前已平滑的 RTT 估计器(`srtt`)间的差值。`g` 是用到 RTT 估计器的增益，设为 1/8。`h` 是用到平均偏差估计器的增益，设为 1/4。这两个增益和 `RTO` 计算中的乘数 4 有意取为 2 的乘方，从而无需乘、除法，只需简单的移位操作就能够完成运算。

探测次数	图25-17中 的时间	<code>t_idle</code>
1	0	14399
2	75	14549
3	150	14699
4	225	14849
5	300	14999
6	375	15149
7	450	15299
8	525	15449
9	600	15599
	675	15749

图25-18 调用 `tcp_timers` 处理保活定时器时 `t_idle` 的取值

[Jacobson 1988b]规定RTO算式应使用 $2 \times rttvar$ ，但经过进一步的研究，[Jacobson 1990d]更正为 $4 \times rttvar$ ，即Net/1实现中采用的算式。

下面首先介绍TCP重传定时器计算中用到的各种变量和算式，它们在TCP代码中出现的频率很高。图25-19列出了控制块中与重传定时器有关的变量。

tcp pcb的成员	单 位	tcp_newtcp cb 初始值	秒 数	描 述
t_srtt	滴答 $\times 8$	0		已平滑的RTT估计器： $srtt \times 8$
t_rttvar	滴答 $\times 4$	24	3	已平滑的RTT平均偏差估计器： $rttvar \times 4$
t_rxtcur	滴答	12	6	当前重传时限：RTO
t_rttmin	滴答	2	1	重传时限最小值
t_rxtshift	不用	0		tcp_backoff[] 数组索引(指数退避)

图25-19 用于重传定时器计算的控制块变量

tcp_backoff数组将在25.9节末尾定义。tcp_newtcp cb函数设定这些变量的初始值，实现代码将在下一节详细讨论。对变量t_rxtshift中的shift及其上限TCP_MAXRXTSHIFT的命名并不十分准确。它指的并不是比特移位，而是如图25-19中所声明的，指数组索引。

TCP时限计算中不易理解的地方是已平滑的RTT估计器和已平滑的RTT平均偏差估计器(t_rtt和t_rttvar)在C代码中都定义为整型，而不是浮点型。这样可以避免内核中的浮点运算，代价是增加了代码的复杂性。

为了区分缩放前和缩放后(scaled)的变量，斜体变量srtt和rttvar表示前面公式中未缩放的变量，t_srtt和t_rttvar表示TCP控制块中缩放后的变量。

图25-20列出了将遇到的四个常量，它们分别定义了t_srtt的缩放因子和t_rttvar的缩放因子，分别为8和4。

常 量	值	描 述
<i>TCP_RTT_SCALE</i>	8	相乘： $t_{srtt} = srtt \times 8$
<i>TCP_RTT_SHIFT</i>	3	移位： $t_{srtt} = srtt << 3$
<i>TCP_RTTVAR_SCALE</i>	4	相乘： $t_{rttvar} = rttvar \times 4$
<i>TCP_RTTVAR_SHIFT</i>	2	移位： $t_{rttvar} = rttvar << 2$

图25-20 RTT均值与偏差的乘法与移位

25.8 tcp_newtcp cb算法

图25-21定义了tcp_newtcp cb，分配一个新的TCP控制块并完成初始化。创建新的插口时，TCP的PRU_ATTACH请求将调用它(图30-2)。调用者已事先为该连接分配了一个Internet PCB，并在入口参数inp中包含指向该结构的指针。我们在这里给出函数代码，是因为它初始化了TCP的定时器变量。

167-175 内核函数malloc分配控制块所需内存，bzero清零新分配的内存块。

176 变量seg_next和seg_prev指向未按正常次序到达当前连接的报文段的重组队列。我们将在27.9节中详细讨论这一重组队列。

tcp_subr.c

```

167 struct tcpcb *
168 tcp_newtcpcb(inp)
169 struct inpcb *inp;
170 {
171     struct tcpcb *tp;
172     tp = malloc(sizeof(*tp), M_PCB, M_NOWAIT);
173     if (tp == NULL)
174         return ((struct tcpcb *) 0);
175     bzero((char *) tp, sizeof(struct tcpcb));
176     tp->seg_next = tp->seg_prev = (struct tciphdr *) tp;
177     tp->t_maxseq = tcp_mssdfilt;
178     tp->t_flags = tcp_do_rfc1323 ? (TF_REQ_SCALE | TF_REQ_TSTMP) : 0;
179     tp->t_inpcb = inp;
180     /*
181      * Init srtt to TCPTV_SRTTBASE (0), so we can tell that we have no
182      * rtt estimate. Set rttvar so that srtt + 2 * rttvar gives
183      * reasonable initial retransmit time.
184      */
185     tp->t_srtt = TCPTV_SRTTBASE;
186     tp->t_rttvar = tcp_rttdfilt * PR_SLOWHZ << 2;
187     tp->t_rttmin = TCPTV_MIN;
188     TCPT_RANGESET(tp->t_rxtcur,
189                   ((TCPTV_SRTTBASE >> 2) + (TCPTV_SRTTDFLT << 2)) >> 1,
190                   TCPTV_MIN, TCPTV_REXMTMAX);
191     tp->snd_cwnd = TCP_MAXWIN << TCP_MAX_WINSHIFT;
192     tp->snd_ssthresh = TCP_MAXWIN << TCP_MAX_WINSHIFT;
193     inp->inp_ip.ip_ttl = ip_defttl;
194     inp->inp_ppcb = (caddr_t) tp;
195     return (tp);
196 }

```

tcp_subr.c

图25-21 tcp_newtcpcb 函数：创建并初始化一个新的TCP控制块

177-179 发送报文段的最大长度，`t_maxseq`，默认为512(`tcp_mssdfilt`)。收到对端MSS选项后，它将被`tcp_mss`函数更改(新连接建立后，TCP也会向对端发送MSS选项)。如果配置要求系统实现 RFC 1313规定的可变窗口和时间戳功能 (图24-3中的全局变量`tcp_do_rfc1313`，默认值为1)，`TF_REQ_SCALE`和`TF_REQ_TSTMP`两个标志将被置位。TCP控制块中的`t_inpcb`指针将指向由调用者传来的Internet PCB。

180-185 初始化图 25-19中列出的四个变量 `t_srtt`、`t_rttvar`、`t_rttmin`和`t_rxtcur`。首先，已平滑的RTT估计器被设为0(`TCPTV_SRTTBASE`)，这个取值非常特殊，指明连接上还不存在RTT估计器。首次进行RTT测量时，`tcp_xmit_timer`函数将判定已平滑的RTT估计器是否等于0，以采取相应动作。

186-187 已平滑的RTT平均偏差估计器`t_rttvar`定义为24：3(`tcp_rttdfilt`，图24-3)乘以2(`PR_SLOWHZ`)后左移2 bit(即乘以4)。由于`t_rttvar`是变量`rttvar`的4倍，也就等于6个滴答，即3秒钟。`RTO`的最小值，`t_rttmin`，为2个滴答。

188-190 变量`t_rxtcu`保存了当前 `RTO`值，以滴答为单位，最小值为 2个滴答(`TCPTV_MIN`)，最大值为128个滴答(`TCPTV_REXMTMAX`)。`TCPT_RANGESET`的第二个参数，表达式计算后等于12个滴答，即6秒钟，是连接的第一个`RTO`值。

理解上述C表达式和RTT缩放值的概念并不是一件容易的事，下面的讨论可能会对您有所

帮助。首先从原始的计算公式开始，并将缩放后的变量替代其中缩放前的变量。下面的算式用于计算第一个RTO，以乘数2替代了乘数4。

$$RTO = srtt + 2 \times rttvar$$

使用乘数2而非4是最初4.3BSD Tahoe实现的一个遗留问题[Paxson 1994]。

把下面两个缩放后的变量代入上式：

$$\begin{aligned} t_srtt &= 8 \times srtt \\ t_rttvar &= 4 \times rttvar \end{aligned}$$

得到：

$$RTO = \frac{t_srtt}{8} + 2 \times \frac{t_rttvar}{4} = \frac{\frac{t_srtt}{4}}{2} + t_rttvar$$

也就是图25-21代码中TCPT_RANGESET第二个参数的表达式，只不过用常量——值为6个滴答的TCPTV_SRTTDFLT乘以4后(缩放运算)代替了变量t_rttvar。

191-192 拥塞窗口(snd_cwnd)和慢起动门限(snd_ssthresh)初始化为1 073 725 440(约为1 G字节)，如是配置了动态窗口选项，这已是TCP窗口大小的上限(卷1的21.6节详细讨论了慢起动和避免拥塞策略)，即TCP首部窗口字段的最大值(65535，TCP_MAXWIN)乘以 2^{14} ，14是窗口缩放因子的最大值(TCP_MAX_WINSHIFT)。后面将看到，连接上发送或接收了一个SYN时，tcp_mss复位snd_cwnd为1。

193-194 Internet PCB中的IP TTL的默认值初始化为64(ip_defttl)，而PCB则指向新的TCP控制块。

代码中没有明确初始化的其他变量，如移位变量t_rxtshift，均为0，这是因为控制块内存分配后已由bzero清零。

25.9 tcp_setpersist函数

接下来要讨论的函数是tcp_setpersist，它用到了TCP的重传超时算法。从图25-13中可知，持续定时器超时后，将调用此函数。当TCP有数据要发送，而连接对端通告接收窗口为0时，持续定时器启动。图25-22给出了函数实现代码，计算并存储定时器的下个取值。

```
493 void tcp_output.c
494 tcp_setpersist(tp)
495 struct tcpcb *tp;
496 {
497     t = ((tp->t_srtt >> 2) + tp->t_rttvar) >> 1;
498     if (tp->t_timer[TCPT_REXMT])
499         panic("tcp_output REXMT");
500     /*
501      * Start/restart persistance timer.
502     */
503     TCPT_RANGESET(tp->t_timer[TCPT_PERSIST],
504                   t * tcp_backoff[tp->t_rxtshift],
505                   TCPTV_PERSMIN, TCPTV_PERSMAX);
506     if (tp->t_rxtshift < TCP_MAXRXTSHIFT)
507         tp->t_rxtshift++;
508 }
```

tcp_output.c

图25-22 tcp_setpersist 函数：计算并存储持续定时器的下一次取值

1. 确认重传定时器未设定

493-499 持续定时器设定之前，首先检查确认重传定时器未启动，这是因为两个定时器彼此互斥：如果数据已被发送，说明对端通告的接收窗口必然非零，但持续时钟仅当对端通告零接收窗口时才会设定。

2. 计算RTO

500-505 函数起始处，计算RTO值并存储到变量 t 中。使用的计算公式为

$$RTO = srtt + 2 \times rttvar$$

与上小节结束时讨论过的公式相同。通过变量替换可得到

$$RTO = \frac{\frac{t_srtt}{4} + t_rttvar}{2}$$

即变量 t 的计算式。

3. 指数退避算法

506-507 RTO计算中还用到了指数退避算法，将上式计算得到的RTO与tcp_backoff数组中的某个值相乘：

```
int tcp_backoff[ TCP_MAXRXTSHIFT + 1 ] =
    {1, 2, 4, 8, 16, 32, 64, 64, 64, 64, 64, 64 };
```

tcp_output第一次为连接设置持续定时器的代码是：

```
tp->t_rxtshift=0;
tcp_setpersist(tp);
```

因此，第一次调用tcp_setpersist时， $t_rxtshift=0$ 。由于tcp_backoff[0]=1，持续时限等于 t 。TCP_T_RANGESET宏确保RTO值位于5秒~60秒之间。 $t_rxtshift$ 每次增加1，直到最大值12(TCP_MAXRXTSHIFT)，tcp_backoff[12]是数组的最后一个元素。

25.10 tcp_xmit_timer函数

下一个讨论的函数，tcp_xmit_timer，在得到了一个RTT测量值，从而更新已平滑的RTT估计器(srtt)和平均偏差(rttvar)时被调用。

参数rtt传递了得到的RTT测量值。它的值为nticks+1(与25.7节中的符号一致)，可以通过下面两种方法之一得到。

如果收到的报文段中存在时间戳选项，RTT测量值应等于当前时间(tcp_now)减去时间戳值。我们将在26.6节中讨论时间戳选项，现在只需了解tcp_now每500ms递增一次(图25-8)。发送报文段时，tcp_now做为时间戳被发送，连接对端在相应的ACK中回显该时间戳。

如果未使用时间戳，可以对数据报文计时。从图25-8可知，连接上的计数器t_rtt每500ms递增一次。在25.5节也曾提到，该计数器初始化为1，因此收到ACK时，该计数器中的值即为RTT测量值加1(以滴答为单位)。

tcp_input中调用tcp_xmit_timer的典型代码如下：

```
if (ts_present)
    tcp_xmit_timer(tp, tcp_now - ts_ecr + 1);
else if (tp->rtt && SEQ_GT(ti->ti_ack, tp->t_rtseq))
    tcp_xmit_timer(tp, tp->t_rtt);
```

如果报文段中存在时间戳(ts_present)，RTT测量值等于当前时间(tcp_now)减去回显

的时间戳(`ts_ecr`)再加1，RTT估计器将被更新(后面将介绍加1的原因)。

如果不存在时间戳，但收到的ACK报文确认了一个正在计时的数据报文，这种情况下RTT估计器也将被更新。每个TCP控制块(`t_rtt`)中只存在一个RTT计数器，因此，在一条连接上只可能对一个特定数据报文计时。这个报文发送时的起始序号存储在`t_rtseq`中，与收到的ACK比较，可以确定该报文对应ACK返回的时间。如果收到的确认序号(`ti_ack`)大于正在计时的数据报文起始序号(`t_rtseq`)，`t_rtt`即为RTT新的样本，从而更新RTT估计器。

在支持RFC 1323的时间戳功能之前，`t_rtt`是TCP测量RTT的唯一方法。但这个变量还用作确认报文段是否被计时的标志(图25-8)：如果`t_rtt`大于0，则`tcp_slowtimo`每隔500ms完成`t_rtt`的加1操作；因此，`t_rtt`非零时，它等于所用的滴答数再加1。我们将看到，`tcp_xmit_timer`函数中对得到的第二个参数减1，以纠正上述偏差。因此，使用时间戳时，向`tcp_xmit_timer`传送的第二个参数必须加1，以保持一致。

序号的大于判定是因为ACK是累积的：如果TCP发送并计时的报文序号为1~1024(`t_rtseq`等于1)，然后立即发送(但未计时)下一个报文序号为1025~2048，接着收到一个ACK报文，其`ti_ack`等于2049，它确认了序号1~2048，即同时确认了第一个计时报文和第二个未计时报文。注意，如果使用了RFC 1323定义的时间戳，则不存在序号比较问题。如果对端发送了时间戳选项，意味着它填入了回应时间(`ts_ecr`)，从而可直接计算RTT。

图25-23给出了函数更新RTT估算值的部分代码。

tcp_input.c

```

1310 void
1311 tcp_xmit_timer(tp, rtt)
1312 struct tcpcb *tp;
1313 short    rtt;
1314 {
1315     short    delta;
1316
1317     tcpstat.tcp_ps_rttupdated++;
1318     if (tp->t_srtt != 0) {
1319         /*
1320          * srtt is stored as fixed point with 3 bits after the
1321          * binary point (i.e., scaled by 8). The following magic
1322          * is equivalent to the smoothing algorithm in rfc793 with
1323          * an alpha of .875 (srtt = rtt/8 + srtt*7/8 in fixed
1324          * point). Adjust rtt to origin 0.
1325          */
1326     delta = rtt - 1 - (tp->t_srtt >> TCP_RTT_SHIFT);
1327     if ((tp->t_srtt += delta) <= 0)
1328         tp->t_srtt = 1;
1329     /*
1330      * We accumulate a smoothed rtt variance (actually, a
1331      * smoothed mean difference), then set the retransmit
1332      * timer to smoothed rtt + 4 times the smoothed variance.
1333      * rttvar is stored as fixed point with 2 bits after the
1334      * binary point (scaled by 4). The following is
1335      * equivalent to rfc793 smoothing with an alpha of .75
1336      * (rttvar = rttvar*3/4 + |delta| / 4). This replaces
1337      * rfc793's wired-in beta.
1338      */

```

图25-23 `tcp_xmit_timer` 函数：利用新的RTT测量值计算已平滑的RTT估计器

```

1338     if (delta < 0)
1339         delta = -delta;
1340     delta -= (tp->t_rttvar >> TCP_RTTVAR_SHIFT);
1341     if ((tp->t_rttvar += delta) <= 0)
1342         tp->t_rttvar = 1;
1343 } else {
1344     /*
1345      * No rtt measurement yet - use the unsmoothed rtt.
1346      * Set the variance to half the rtt (so our first
1347      * retransmit happens at 3*rtt).
1348      */
1349     tp->t_srtt = rtt << TCP_RTT_SHIFT;
1350     tp->t_rttvar = rtt << (TCP_RTTVAR_SHIFT - 1);
1351 }
```

tcp_input.c

图25-23 (续)

1. 更新已平滑的RTT估计器

1310-1325 前面已介绍过，*tcp_newtcpcb*初始化已平滑的RTT估计器(*t_srtt*)为0，指明连接上不存在RTT估计器。*delta*是RTT测量值与当前已平滑的RTT估计器间的差值，以未缩放的滴答为单位。*t_srtt*除以8，单位从缩放后的滴答转换为未缩放的滴答。

1326-1327 已平滑的RTT估计器用以下公式进行更新：

$$srtt = srtt + g \times \Delta$$

由于增益 $g=1/8$ ，公式变为

$$8 \times srtt = 8 \times srtt + \Delta$$

也就是

$$t_{srtt} = t_{srtt} + \Delta$$

1328-1342 已平滑的RTT平均偏差估计器的计算公式如下：

$$rttvar = rttvar + h(|\Delta| - rttvar)$$

将 $h=1/4$ 和缩放后的 $t_{rttvar}=4 \times rttvar$ 代入，得到：

$$\frac{t_{rttvar}}{4} = \frac{t_{rttvar}}{4} + \frac{|\Delta| - \frac{t_{rttvar}}{4}}{4}$$

也就是：

$$t_{rttvar} = t_{rttvar} + |\Delta| - \frac{t_{rttvar}}{4}$$

最后一个表达式即为C代码中的表达式。

2. 第一次测量RTT时初始化平滑的估计器值

1343-1350 如果是首次测量某连接的RTT值，已平滑的RTT估计器初始化为测量得到的样本值。下面的计算用到了参数*rtt*，前面已介绍过*rtt*等于测量到的RTT值加1(*nticks+1*)，而前面公式中用到的*delta*是从*rtt*中减1得到的。

$$srtt = nticks + 1$$

或

$$\frac{t_{srtt}}{8} = nticks + 1$$

也就是

$$t_{srtt} = (nticks + 1) \times 8$$

平均偏差等于测量到的 RTT 值的一半：

$$rttvar = \frac{srtt}{2}$$

也就是

$$\frac{t_{rttvar}}{4} = \frac{nticks + 1}{2}$$

或者

$$t_{rttvar} = (nticks + 1) \times 2$$

代码中的注释指出，已平滑的平均偏差的这种初始取值使得 RTO 的初始值等于 $3 \times srtt$ 。因为

$$RTO = srtt + 4 \times rttvar$$

替换掉 rttvar，得到：

$$RTO = srtt + 4 \times \frac{srtt}{2}$$

也就是：

$$RTO = 3 \times srtt$$

图25-24给出了tcp_xmit_timer函数最后一部分的代码。

```

1352     tp->t_rtt = 0;
1353     tp->t_rxtshift = 0;
1354
1355     /*
1356      * the retransmit should happen at rtt + 4 * rttvar.
1357      * Because of the way we do the smoothing, srtt and rttvar
1358      * will each average +1/2 tick of bias. When we compute
1359      * the retransmit timer, we want 1/2 tick of rounding and
1360      * 1 extra tick because of +/-1/2 tick uncertainty in the
1361      * firing of the timer. The bias will give us exactly the
1362      * 1.5 tick we need. But, because the bias is
1363      * statistical, we have to test that we don't drop below
1364      * the minimum feasible timer (which is 2 ticks).
1365
1366     TCPT_RANGESET(tp->t_rxtcur, TCP_REXMTVAL(tp),
1367                   tp->t_rttmin, TCPTV_REXMTMAX);
1368
1369     /*
1370      * We received an ack for a packet that wasn't retransmitted;
1371      * it is probably safe to discard any error indications we've
1372      * received recently. This isn't quite right, but close enough
1373      * for now (a route might have failed after we sent a segment,
1374      * and the return path might not be symmetrical).
1375     */
1376     tp->t_softerror = 0;
1377 }
```

tcp_input.c

图25-24 tcp_xmit_timer 函数：最后一部分

1352-1353 RTT计数器(t_rtt)和重传移位计数器(t_rxtshift)同时复位为0，为下一个报文的发送和计时做准备。

1354-1366 连接的下一个RTO(*t_rxtcur*)计算用到宏

```
#define TCP_REXMTVAL(tp) \
(((tp)->t_srtt >> TCP_RTT_SHIFT) + (tp)->t_ttvar)
```

其实，这就是我们很熟悉的公式

$$RTO = srtt + 4 \times rttvar$$

用tcp_xmit_timer更新过的缩放后的变量替代上式中的 *srtt*和 $rttvar$ ，得到宏的表达式：

$$RTO = \frac{t_{srtt}}{8} + 4 \times \frac{t_{rttvar}}{4} = \frac{t_{srtt}}{8} + t_{rttvar}$$

此外，*RTO*取值应在规定范围之内，最小值为连接上设定的最小 RTO(*t_rttmin*，*t_newtcpcb*初始化为2个滴答)，最大值为128个滴答(TCPTV_REXMTMAX)。

3. 清除软错误变量

1367-1374 由于只有当收到了已发送的数据报文的确认时，才会调用tcp_xmit_timer，如果连接上发生了软错误(*t_softerror*)，该错误将被丢弃。下一节中将详细讨论软错误。

25.11 重传超时：tcp_timers函数

我们现在回到tcp_timers函数，讨论25.6节中未涉及的最后一个case语句：处理重传定时器。如果在RTO内没有收到对端对一个已发送数据报的确认，则执行此段代码。

图25-25小结了重传定时器的操作。假定tcp_output计算的报文首次重传时限为1.5秒，这是LAN的典型值(参见卷1的图21-1)。

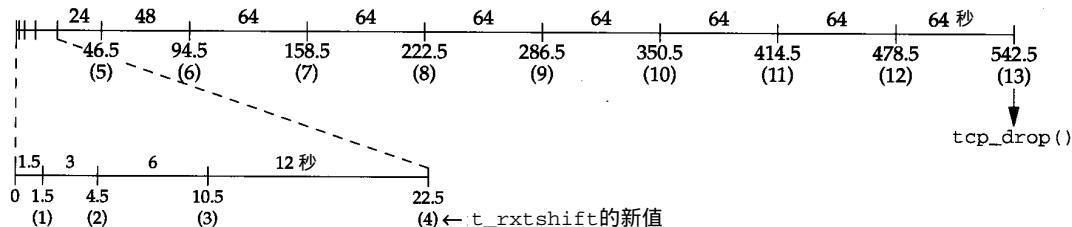


图25-25 发送数据时重传定时器小结

x轴为时间轴，以秒为单位，标注依次为：0、1.5、4.5等等。这些数字的下方，给出了代码中用到的*t_rxtshift*的值。连续13次重传后，总共为542.5秒(约9分钟)，TCP将放弃并丢弃连接。

RFC 793建议在建立新连接时，无论主动打开或被动打开，应定义一个参数规定TCP发送数据的总时限，也就是TCP在放弃发送并丢弃连接之前试图传输给定数据报文的总时间。推荐的默认值为5分钟。

RFC 1122要求应用程序必须为连接指定一个参数，限定 TCP总的重传次数或者TCP试图发送数据的总时间。这个参数如果设为“无限”，那么TCP永不会放弃，还可能不允许终端用户终止连接。

在代码中可看到，Net/3不支持应用程序的上述控制权：TCP放弃传输之前的重传次数是固定的(12)，所用的总时间取决于RTT。

图25-26给出了重传超时 case语句的前半部分。

```

140      /*
141       * Retransmission timer went off. Message has not
142       * been acked within retransmit interval. Back off
143       * to a longer retransmit interval and retransmit one segment.
144       */
145     case TCPT_REXMT:
146     if (++tp->t_rxtshift > TCP_MAXRXTSHIFT) {
147         tp->t_rxtshift = TCP_MAXRXTSHIFT;
148         tcpstat.tcpst_timeoutdrop++;
149         tp = tcp_drop(tp, tp->t_softerror ?
150                       tp->t_softerror : ETIMEDOUT);
151         break;
152     }
153     tcpstat.tcpst_rexmttimeo++;
154     rexmt = TCP_REXMTVAL(tp) * tcp_backoff[tp->t_rxtshift];
155     TCPT_RANGESET(tp->t_rxtcur, rexmt,
156                   tp->t_rttmin, TCPTV_REXMTMAX);
157     tp->t_timer[TCPT_REXMT] = tp->t_rxtcur;
158     /*
159      * If losing, let the lower level know and try for
160      * a better route. Also, if we backed off this far,
161      * our srtt estimate is probably bogus. Clobber it
162      * so we'll take the next rtt measurement as our srtt;
163      * move the current srtt into rttvar to keep the current
164      * retransmit times until then.
165      */
166     if (tp->t_rxtshift > TCP_MAXRXTSHIFT / 4) {
167         in_losing(tp->t_inpcb);
168         tp->t_rttvar += (tp->t_srtt >> TCP_RTT_SHIFT);
169         tp->t_srtt = 0;
170     }
171     tp->snd_nxt = tp->snd_una;
172     /*
173      * If timing a segment in this window, stop the timer.
174      */
175     tp->t_rtt = 0;

```

tcp_timer.c

图25-26 `tcp_timers` 函数：重传定时器超时，前半部分

1. 递增移位计数器

146 重传移位计数器(`t_rxtshift`)在每次重传时递增，如果大于12(`TCP_MAXRXTSHIFT`)，连接将被丢弃。图25-25给出了`t_rxtshift`每次重传时的取值。请注意两种丢弃连接的区别，由于收不到对端对已发送数据报文的确认而造成的丢弃连接，和由于保活定时器的作用，在长时间空闲且收不到对端响应时丢弃连接。两种情况下，TCP都会向应用进程报告ETIMEDOUT差错，除非连接收到了一个软错误。

2. 丢弃连接

147-152 软错误指不会导致TCP终止已建立的连接或正试图建立的连接的错误，但系统会记录出现的软错误，以备TCP将来放弃连接时参考。例如，如果TCP重传SYN报文段，试图建立新的连接，但未收到响应，TCP将向应用进程报告ETIMEDOUT差错。但如果在重传期间，收到一个ICMP“主机不可达”差错代码，`tcp_notify`会在`t_softerror`中存储这一软错误。如果TCP最终决定放弃重传，返回给应用进程的差错代码将为EHOSTUNREACH，而不是

ETIMEDOUT，从而向应用进程提供了更多的信息。如果TCP发送SYN后，对端的响应为RST，这是个硬错误，连接立即被终止，返回差错代码ECONNREFUSED(图28-18)。

3. 计算新的RTO

153-157 利用TCP_RXTIMEVAL宏实现指数退避，计算新的RTO值。代码中，给定报文第一次重传时t_rxtshift等于1，因此，RTO值为TCP_RXTIMEVAL计算值的两倍。新的RTO值存储在t_rxtcur中，供连接的重传定时器——t_timer[TCPT_RXTIME]——使用，tcp_input在启动重传定时器时会用到它(图28-12和图29-6)。

4. 向IP询问更换路由

158-167 如果报文段已重传4次以上，in_losing将释放缓存中的路由(如果存在)，tcp_output再次重传该报文时(图25-27中case语句的结尾处)，将选择一条新的，也许好一些的路由。从图25-25可看到，每次重传定时器超时时，如果重传时限已超过22.5秒，将调用in_losing。

5. 清除RTT估计器

168-170 代码中，已平滑的RTT估计器(t_srtt)被置为0(t_newtcpcb中曾将其初始化为0)，强迫tcp_xmit_timer将下一个RTT测量值做为已平滑的RTT估计器，这是因为报文段重传次数已超过4次，意味着TCP的已平滑的RTT估计器可能已失效。若重传定时器再次超时，进入case语句后，将利用TCP_RXTIMEVAL计算新的RTO值。由于t_srtt被置为0，新的计算值应与本次重传中的计算值相同，再利用指数退避算法加以修正(图25-28中，在42.464秒处的重传很好地说明了上面讨论的概念)。

再次计算RTO时，利用公式

$$RTO = \frac{t_{srtt}}{8} + t_{rttvar}$$

由于t_srtt等于0，RTO取值不变。如果报文的重传定时器再次超时(图25-28中从84.064秒到217.84秒)，case语句再次被执行，t_srtt等于0，t_rttvar不变。

6. 强迫重传最早的未确认数据

171 下一个发送序号(snd_nxt)被置为最早的未确认的序号(snd_una)。回想图24-17中，snd_nxt大于snd_una。把snd_nxt回移，将重传最早的未确认过的报文。

7. Karn算法

172-175 RTT计数器，t_rtt，被置为0。Karn算法认为由于该报文即将重传，对该报文的计时也就失去了意义。即使收到了ACK，也无法区分它是对第一次报文，还是对第二次报文的确认。[Karn and Partridge 1987]和卷1的21.3节中都介绍了这一算法。因此，TCP只对未重传报文计时，利用t_rtt计数器得到样本值，并据此修正RTT估计器。在后面的图29-6中将看到，如何使用RFC1323的时间戳功能取代Karn算法。

25.11.1 慢起动和避免拥塞

图25-27给出了case语句的后半部分，实现慢起动和避免拥塞，并重传最早的未确认过的报文。

由于重传定时器超时，网络中很可能发生了拥塞。这种情况下，需要用到TCP的拥塞避免算法。如果最终收到了对端发送的确认，TCP采用慢起动算法以较慢的速率继续进行数据

传输。卷1的20.6节和21.6节详细讨论了这两种算法。

176-205 win被置为现有窗口大小(接收方通告的窗口大小snd_wnd和发送方拥塞窗口大小snd_cwnd，两者之中的较小值)的一半，以报文为单位，而非字节(因此除以t_maxseg)，最小值为2。它的值等于网络拥塞时现有窗口大小的一半，也就是慢起动门限，t_ssthresh(以字节为单位，因此乘以t_maxseq)。拥塞窗口的大小，snd_cwnd，被置为只容纳1个报文，强迫执行慢起动。上述做法假定造成网络拥塞的原因之一是本地数据发送太快，因此在拥塞发生时，必须降低发送窗口大小。

这段代码放在一对括号中，是因为它是在4.3BSD和Net/1实现之间添加的，并要求有自己的局部变量(win)。

206 连续重复ACK计数器，t_dupacks(用于29.4节中将介绍的快速重传算法)被置为0。我们将在第29章中介绍它在TCP快速重传和快速恢复算法中的用途。

208 tcp_output重新发送包含最早的未确认序号的报文，即由于重传定时器超时引发了报文重传。

```

176      /*
177      * Close the congestion window down to one segment
178      * (we'll open it by one segment for each ack we get).
179      * Since we probably have a window's worth of unacked
180      * data accumulated, this "slow start" keeps us from
181      * dumping all that data as back-to-back packets (which
182      * might overwhelm an intermediate gateway).
183      *
184      * There are two phases to the opening: Initially we
185      * open by one mss on each ack. This makes the window
186      * size increase exponentially with time. If the
187      * window is larger than the path can handle, this
188      * exponential growth results in dropped packet(s)
189      * almost immediately. To get more time between
190      * drops but still "push" the network to take advantage
191      * of improving conditions, we switch from exponential
192      * to linear window opening at some threshold size.
193      * For a threshold, we use half the current window
194      * size, truncated to a multiple of the mss.
195      *
196      * (the minimum cwnd that will give us exponential
197      * growth is 2 mss. We don't allow the threshold
198      * to go below this.)
199      */
200      {
201          u_int    win = min(tp->snd_wnd, tp->snd_cwnd) / 2 / tp->t_maxseg;
202          if (win < 2)
203              win = 2;
204          tp->snd_cwnd = tp->t_maxseg;
205          tp->snd_ssthresh = win * tp->t_maxseg;
206          tp->t_dupacks = 0;
207      }
208      (void) tcp_output(tp);
209      break;

```

tcp_timer.c

图25-27 tcp_timer 函数：重传定时器超时，后半部分

25.11.2 精确性

TCP维护的这些估计器的精确性如何呢？首先应指出，因为 RTT以500 ms为测量单位，是非常不精确的。已平滑的RTT估计器和平均偏差的精确性要高一些（缩放因子为8和4），但也不够，LAN的RTT是毫秒级，横跨大陆的RTT约为60ms左右。这些估计器仅仅给出了RTT的上限，从而在设定重传定时器时，可以不考虑由于重传时限过小而造成不必要的重传。

[Brakmo, O’Malley, and Peterson 1994]描述的TCP实现，能够提供高精度的RTT样本。他们的做法是，发送报文段时记录系统时钟读数（精度比以500 ms为测量单位要高得多），收到ACK时再次读取系统时钟，从而得到高精度的RTT。

Net/3支持的时间戳功能(26.6节)本来可以提供较高精度的RTT，但Net/3将时间戳的精度也定为500 ms。

25.12 一个RTT的例子

下面讨论一个具体的例子，说明上述计算是如何进行的。我们从主机 bsd1 向 vangogh.cs.berkeley.edu 发送12288字节的数据。在发送过程中，故意断开工作中的 PPP链路，之后再恢复，看看TCP如何处理报文的超时与重传。为发送数据，我们运行自己的 sock程序(参见卷1的附录C)，加-D选项，置位插口的SO_DEBUG选项(27.10节)。传输结束后，运行 trpt(8)程序检查留在内核的环形缓存中的调试记录，之后打印 TCP控制块中我们感兴趣的时钟变量。

图25-28列出了各变量在不同时刻的值。我们用 M : N 表示序号 M~N - 1 已被发送。本例中的每个报文段都携带了 512 字节的数据。符号“ ACK M ”表示 ACK 报文的确认字段为 M。标注“ 实际差值(ms) ” 栏列出了 RTT 定时器打开时刻和关闭时刻间的时间差值。标注“ rtt (参数) ” 栏列出了调用 tcp_xmit_timer 时第二个参数的值：RTT 定时器打开时刻和关闭时刻间的滴答数再加1。

tcp_newtcpcb 函数完成 t_srtt、t_rttvar 和 t_rxmtcur 的初始化，时刻 0.0 对应的即为变量初始值。

第一个计时报文是最初的SYN报文，365 ms后收到了对端的ACK，调用tcp_xmit_timer，rtt 参数值为2。由于这是第一个RTT测量值($t_{srtt}=0$)，执行图25-23中的else语句，计算RTT估计器初始值。

携带1~512字节的数据报文是第二个计时报文，1.259秒时收到对应的ACK，RTT估计器被更新。

从接下来的三个报文可看出，连续报文是如何被确认的。1.260秒时发送携带513~1024字节的报文，并启动定时器。之后又发送了携带1025~1526字节的报文，在2.206秒时收到了对端的ACK，同时确认了已发送的两个报文。RTT估计器被更新，因为ACK确认了正计时报文的起始序号(513)。

2.206秒时发送携带1537~2048字节的报文，并启动定时器。3.132秒时收到对应的ACK，RTT估计器被更新。

对3.132秒时发送的报文段计时，重传定时器设为5个滴答($t_{rxmtshift}$ 的当前值)。这时，路由器 sun 和 netb 间的 PPP 链路中断，几分钟后恢复正常。重传定时器在 6.064 秒超时，执行图25-26中的代码更新 RTT 变量。 $t_{rxmtshift}$ 从 0 增至 1， $t_{rxmtcur}$ 置为 10 个滴答(指数退

避），重传最早的未确认过的序号（`snd_una=3073`）。5秒钟后，定时器再次超时，`t_rxtshift`递增为2，重传定时器设为20个滴答。

发送时间	发送	接收	RTT 定时器	实际时间差 (ms)	rtt 参数	t_srtt (8个滴答)	t_rttvar (4个滴答)	t_rxtcur (滴答)	t_rxtshift
0.0	SYN		on			0	24	12	
0.365			off	365	2	16	4	6	
0.365	ACK	SYN,ACK	on						
0.415			off						
1.259	1:513		on						
			off	844	2	15	4	5	
1.260	513:1025		on						
1.261	1025:1537		off						
2.206	ack 1537		on						
2.207			off	946	3	16	4	6	
2.209	1537:2049		on						
3.132	2049:2561		off						
3.132	2561:3073		on						
3.132	3073:3585		off	926	3	16	3	5	
3.133	3585:4097		on						
3.736			off						
3.736	4097:4609		on						
3.737	4609:5121		off						
3.739	ack 2049		on						
3.739	5121:5633		off						
3.740	5633:6145		on						
6.064	3073:3585		off			16	3	10	1
11.264	3073:3585		off			16	3	20	2
21.664	3073:3585		off			16	3	40	3
42.464	3073:3585		off			0	5	80	4
84.064	3073:3585		off			0	5	128	5
150.624	3073:3585		off			0	5	128	6
217.184	3073:3585		off			0	5	128	7
217.944	ack 6145		on						
217.944	6145:6657		off						
217.945	6657:7169		on						
218.834	ack 6657		off	890	3	24	6	9	
218.836	7169:7681		on						
219.209	7681:8193		off						
219.209	ack 7169		on						
219.760	8193:8705		off						
219.760	ack 7681		on						
219.760	8705:9217		off	926	2	22	7	9	
220.103	9217:9729		on						
220.103	9729:10241		off						
220.105	10241:10753		on						
220.106	ack 8705		off						
220.821	10753:11265		on						
220.821	11265:11777		off	1061	3	22	6	8	
221.310	ack 9729		on						
221.310	ack 10241		off						
221.312	11777:12289		on						
221.312	ack 10753		off						
221.674	ack 11265		on						
221.955			off	1134	3	22	5	7	

图25-28 实例中的RTT变量值和估计器

42.464秒时，重传定时器再次超时，`t_srtt`清零，`t_rttvar`置为5。我们在图25-26的讨论中提到过，此时`t_rxtcur`运算得到的结果相同（因此，下一次运算的结果应为160）。但

由于`t_srtt`重置为0，下一次更新RTT估计器时(218.834秒)，与建立一条新的连接相类似，得到的RTT测量值将成为新的已平滑的RTT估计器。

之后继续进行数据传输，并且又多次更新了RTT估计器。

25.13 小结

内核每隔200 ms和500 ms，分别调用`tcp_fasttimo`函数和`tcp_slowtimo`函数。这两个函数负责维护TCP为连接建立的各种定时器。

TCP为每条连接维护下列7个定时器：

- 连接建立定时器；
- 重传定时器；
- 延迟ACK定时器；
- 持续定时器；
- FIN_WAIT_2定时器；
- 2MSL定时器；

延迟ACK定时器与其他6个定时器不同，设置它时意味着下一次TCP200 ms定时器超时时，延迟的ACK报文必须被发送。其他6个定时器都是计数器，每次TCP 500 ms定时器超时时，计数器减1。任何一个计数器减为0时，触发TCP完成相应动作：丢弃连接、重传报文、发送连接探测报文等等，这些内容本章中都有详细讨论。由于某些定时器是彼此互斥的，代码用4个计数器实现了这6个定时器，复杂性有所增加。

本章还介绍了重传定时器取值的标准计算方法。TCP为每条连接维护两个RTT估计器：已平滑的RTT估计器(`srtt`)和已平滑的RTT平均偏差估计器(`rttvar`)。尽管算法简单清楚，但由于使用了缩放因子(在不使用内核浮点运算的情况下保证足够的精度)，使得代码较为复杂。

习题

25.1 TCP快速超时处理函数的效率如何？(提示：参考图24-5中列出的延迟ACK的次数)
有没有另外的实现方式？

25.2 为什么在`tcp_slowtimo`函数，而不是在`tcp_init`函数中初始化`tcp_maxidle`？

25.3 `tcp_slowtimo`递增`t_idle`，前面已介绍过`t_idle`用于计数从连接上收到最后一个报文起到当前为止的滴答数。TCP是否需要计数从连接上发送最后一个报文段起计时的空闲时间？

25.4 重写图25-10中的代码，分离TCP`_2MSL`计数器两种不同用法的处理逻辑。

25.5 图25-12中，连接进入`FIN_WAIT_2`状态75秒后收到一个重复的ACK。会发生什么？

25.6 应用程序设置`SO_KEEPALIVE`选项时连接已空闲了1小时。第一次连接探测报文在何时发送，1小时后还是2小时后？

25.7 为什么`tcp_rttdflt`是一个全局变量，而非局部量？

25.8 重写与习题25.6有关的代码，实现另一种结果。

第26章 TCP 输出

26.1 引言

函数tcp_output负责发送报文段，代码中有很多地方都调用了它。

tcp_usrreq在多种请求处理中调用了这一函数：处理PRU_CONNECT，发送初始SYN；处理PRU_SHUTDOWN，发送FIN；处理PRU_RCVD，应用进程从插口接收缓存中读取若干数据后可能需要发送新的窗口大小通告；处理PRU_SEND，发送数据；处理PRU_SENDOOB，发送带外数据。

- tcp_fasttimo调用它发送延迟的ACK；
- tcp_timers在重传定时器超时时，调用它重传报文段；
- tcp_timers在持续定时器超时时，调用它发送窗口探测报文段；
- tcp_drop调用它发送RST；
- tcp_disconnect调用它发送FIN；
- tcp_input在需要输出或需要立即发送ACK时调用它；
- tcp_input在收到一个纯ACK报文段且本地有数据发送时调用它（纯ACK报文段指不携带数据，只确认已接收数据的报文段）；
- tcp_input在连续收到3个重复的ACK时，调用它发送一个单一报文段（快速重传算法）；

tcp_input首先确定是否有报文段等待发送。除了存在需要发往连接对端的数据外，TCP输出还受到其他许多因素的控制。例如，对端可能通告接收窗口为零，阻止TCP发送任何数据；Nagle算法阻止TCP发送大量小报文段；慢启动和避免拥塞算法限制TCP发送的数据量。相反，有些函数置位一些特殊标志，强迫tcp_output发送报文段，如TF_ACKNOW标志置位意味着必须立即发送一个ACK。如果tcp_output确定不发送某个报文段，数据（如果存在）将保留在插口的发送缓存中，等待下一次调用该函数。

26.2 tcp_output概述

tcp_output函数很大，我们将分14个部分予以讨论。图26-1给出了函数的框架结构。

1. 是否等待对端的ACK？

61 如果发送的最大序号(snd_max)等于最早的未确认过的序号(snd_una)，即不等待对端发送ACK，idle为真。图24-17中，idle应为假，因为序号4~6已发送但还未被确认，TCP在等待对端发送对上述序号的确认。

2. 返回慢启动

62-68 如果TCP不等待对端发送ACK，而且在一个往返时间内也没有收到对端发送的其他报文段，设置拥塞窗口为仅能容纳一个报文段(t_maxseg字节)，从而在发送下一个报文段时，

强迫执行慢启动算法。如果数据传输中出现了显著的停顿（“显著”指停顿时间超过 RTT），说明与先前测量 RTT 时相比，网络条件已发生了变化。Net/3 假定出现了最坏情况，因而返回慢起动状态。

```
tcp_output.c
```

```

43 int
44 tcp_output(tp)
45 struct tcpcb *tp;
46 {
47     struct socket *so = tp->t_inpcb->inp_socket;
48     long    len, win;
49     int     off, flags, error;
50     struct mbuf *m;
51     struct tciphdr *ti;
52     u_char  opt[MAX_TCPOPTLEN];
53     unsigned optlen, hdrlen;
54     int     idle, sendalot;

55     /*
56      * Determine length of data that should be transmitted
57      * and flags that will be used.
58      * If there are some data or critical controls (SYN, RST)
59      * to send, then transmit; otherwise, investigate further.
60      */
61     idle = (tp->snd_max == tp->snd_una);
62     if (idle && tp->t_idle >= tp->t_rxtcur)
63     /*
64      * We have been idle for "a while" and no acks are
65      * expected to clock out any data we send --
66      * slow start to get ack "clock" running again.
67      */
68     tp->snd_cwnd = tp->t_maxseg;

69 again:
70     sendalot = 0; /* set nonzero if more than one segment to output */

    /* look for a reason to send a segment; */
    /* goto send if a segment should be sent */

218 /*
219  * No reason to send a segment, just return.
220  */
221 return (0);

222 send:

    /* form output segment, call ip_output() */

489 if (sendalot)
490     goto again;
491 return (0);
492 }
```

```
tcp_output.c
```

图26-1 `tcp_output` 函数：框架结构

3. 发送多个报文段

69-70 控制跳转至 `send` 后，调用 `ip_output` 发送一个报文段。但如果 `ip_output` 确定有

多个报文段需要发送，`sendalot`置为1，函数将试图发送另一个报文段。因此，`ip_output`的一次调用能够发送多个报文段。

26.3 决定是否应发送一个报文段

某些情况下，在报文段准备好之前已调用了`tcp_output`。例如，当插口层从插口的接收缓存中移走数据，传递给用户进程时，会生成`PRU_RCVD`请求。尽管不一定，但完全有可能因为应用进程取走了大量数据，而使得TCP有必要发送新的窗口通告。`tcp_output`的前半部分确定是否存在需要发往对端的报文段。如果没有，则函数返回，不执行发送操作。

图26-2给出了判定“是否有报文段发送”测试代码的第一部分。

```

71     off = tp->snd_nxt - tp->snd_una;
72     win = min(tp->snd_wnd, tp->snd_cwnd);
73
74     flags = tcp_outflags[tp->t_state];
75     /*
76      * If in persist timeout with window of 0, send 1 byte.
77      * Otherwise, if window is small but nonzero
78      * and timer expired, we will send what we can
79      * and go to transmit state.
80      */
81     if (tp->t_force) {
82         if (win == 0) {
83             /*
84              * If we still have some data to send, then
85              * clear the FIN bit. Usually this would
86              * happen below when it realizes that we
87              * aren't sending all the data. However,
88              * if we have exactly 1 byte of unsent data,
89              * then it won't clear the FIN bit below,
90              * and if we are in persist state, we wind
91              * up sending the packet without recording
92              * that we sent the FIN bit.
93              *
94              * We can't just blindly clear the FIN bit,
95              * because if we don't have any more data
96              * to send then the probe will be the FIN
97              * itself.
98              */
99             if (off < so->so_snd.sb_cc)
100                 flags &= ~TH_FIN;
101             win = 1;
102         } else {
103             tp->t_timer[TCPT_PERSIST] = 0;
104             tp->t_rxtshift = 0;
105         }
    }

```

tcp_output.c

图26-2 `tcp_output` 函数：强迫数据发送

71-72 `off`指从发送缓存起始处算起指向第一个待发送字节的偏移量，以字节为单位。它指向的第一个字节为`snd_una`(已发送但还未被确认的字节)。

`win`是对端通告的接收窗口大小(`snd_wnd`)与拥塞窗口大小(`snd_cwnd`)间的最小值。

7.3 图24-16给出了tcp_outflags数组，数组值取决于连接的当前状态。flags包括下列标志比特的组合：TH_ACK、TH_FIN、TH_RST和TH_SYN，分别表示需向对端发送的报文段类型。其他两个标志比特，TH_PUSH和TH_URG，如果需要，在报文段发送之前加入，与前4个标志比特是逻辑或的关系。

7.4-105 t_force标志非零表示持续定时器超时，或者有带外数据需要发送。这两种条件下，调用tcp_output的代码均为：

```
tp->t_force = 1;
error = tcp_output(tp);
tp->t_force = 0;
```

从而强迫TCP发送数据，尽管在正常情况下不会执行任何发送操作。

如果win等于0，连接处于持续状态(因为t_force非零)。如果此时插口的发送缓存中还存在数据，则FIN标志被清除。win必须置为1，以强迫发送一个字节的数据。

如果win非零，即有带外数据需要发送，则持续定时器复位，指数退避算法的索引，t_rxtshift被置为0。

图26-3给出了tcp_output的下一模块，计算发送的数据量。

```
106     len = min(so->so_snd.sb_cc, win) - off;                               tcp_output.c
107     if (len < 0) {
108         /*
109          * If FIN has been sent but not acked,
110          * but we haven't been called to retransmit,
111          * len will be -1. Otherwise, window shrank
112          * after we sent into it. If window shrank to 0,
113          * cancel pending retransmit and pull snd_nxt
114          * back to (closed) window. We will enter persist
115          * state below. If the window didn't close completely,
116          * just wait for an ACK.
117         */
118         len = 0;
119         if (win == 0) {
120             tp->t_timer[TCPT_REXMT] = 0;
121             tp->snd_nxt = tp->snd_una;
122         }
123     }
124     if (len > tp->t_maxseg) {
125         len = tp->t_maxseg;
126         sendalot = 1;
127     }
128     if (SEQ_LT(tp->snd_nxt + len, tp->snd_una + so->so_snd.sb_cc))
129         flags &= ~TH_FIN;
130     win = sbspace(&so->so_rcv);                                              tcp_output.c
```

图26-3 tcp_output 函数：计算发送的数据量

1. 计算发送的数据量

106 len等于发送缓存中比特数和win(对端通告的接收窗口与拥塞窗口间的最小值，强迫TCP发送数据时也可能等于1字节)，两者间的最小值减去off。减去off是因为发送缓存中的许多字节已发送过，正等待对端的确认。

2. 窗口缩小检查

107-117 造成 len 小于零的一种可能情况是接收方缩小了窗口，即接收方把窗口的右界移向左侧，下面的例子说明了这种情况。开始时，接收方通告接收窗口大小为6字节，TCP发送报文段，携带字节4、5和6。紧接着，TCP又发送一个报文段，携带字节7、8和9。图26-4显示了两个报文段发送后本地的状态。

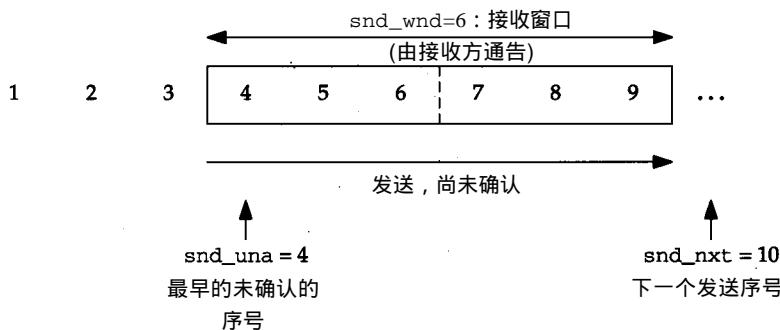


图26-4 发送4~9字节后的本地发送缓存

之后，收到一个ACK，确认序号字段为7(确认所有序号小于7的数据，包括字节6)，但窗口字段为1。接收方缩小了接收窗口，此时本地的状态如图26-5所示。

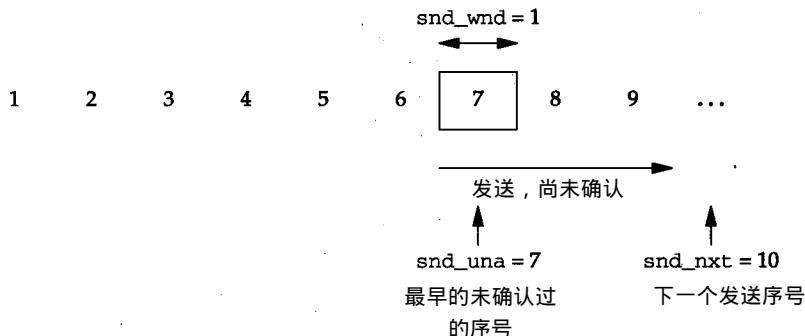


图26-5 收到4~7字节的确认后，本地发送缓存

窗口缩小后，执行图26-2和图26-3中的计算，得到：

```
off = sndNxt - sndUna = 10 - 7 = 3
win = 1
len = min(so_snd.sb_cc, win) - off = min(3, 1) - 3 = -2
```

假定发送缓存仅包含字节7、8和9。

RFC 793和RFC 1122都非常不赞成缩小窗口。尽管如此，具体实现必须考虑这一问题并加以处理。这种做法遵循了在 RFC 791中首次提出的稳健性原则：“对接收报文段的假设尽量少一些，对发送报文段的限制尽量多一些”。

造成 len 小于0的另一种可能情况是，已发送过FIN，但还未收到确认(见习题26.2)。图26-6给出了这种情况。

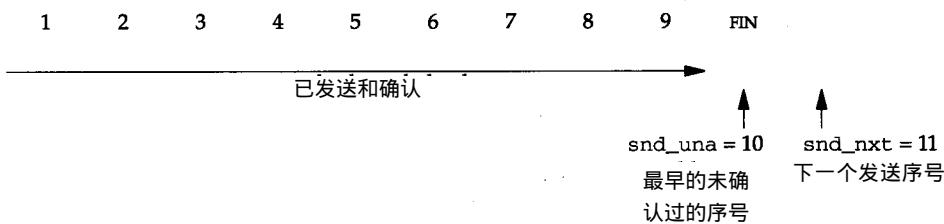


图26-6 字节1~9已发送并收到对端确认，之后关闭连接

图26-6是图26-4的继续，假定字节7~9已被确认，`snd_una`的当前值为10。应用进程随后关闭连接，向对端发送FIN。在本章后续部分将看到，TCP发送FIN时，`snd_nxt`将增加1(因为FIN也需要序号)，在本例中，`snd_nxt`将等于11，而FIN的序号为10。执行图26-2和图26-3中的计算，得到：

```
off = snd_nxt - snd_una = 11 - 10 = 1
win = 6
len = min(so_snd.sb_cc, win) - off = min(0, 6) - 1 = -1
```

我们假定接收方通告接收窗口大小为6。这个假定无关紧要，因为发送缓存中待发送的字节数(0)小于它。

3. 进入持续状态

118-122 `len`被置为0。如果对端通告的接收窗口大小为0，则重传定时器将被置为0，任何等待的重传将被取消。令`snd_nxt`等于`snd_una`，指针返回发送窗口的最左端，连接将进入持续状态。如果接收方最终打开了接收窗口，则TCP将从发送窗口的最左端开始重传。

4. 一次发送一个报文段

124-127 如果需要发送的数据超过了报文段的容量，`len`置为最大报文段长度，`sendalot`置为1。如图26-1所示，这将使`tcp_output`在报文段发送完毕后进入另一次循环。

5. 如果发送缓存不空，关闭FIN标志

128-129 如果本次输出操作未能清空发送缓存，FIN标志必须被清除(防止该标志在`flags`中被置位)。图26-7举例说明了这一情况。

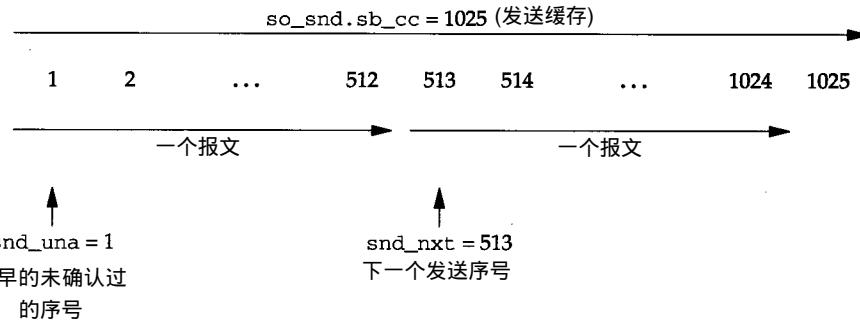


图26-7 实例：FIN置位时，发送缓存不空

这个例子中，第一个512字节的报文段已发送(还未被确认)，TCP正准备发送第二个报文段(512~1024字节)。此时，发送缓存中仍有1字节的数据(1025字节)，应用进程关闭了连接。

len=512(一个报文段) , 图26-3中的C表达式变为 :

SEQ_LT (1025, 1026)

如果表达式为真 , 则 FIN标志被清除 ; 否则 , TCP无法向对端发送序号为 1025的字节。

6. 计算接收窗口大小

130 win设定为本地接收缓存中可用空间的大小 , 即 TCP向对端通告的接收窗口的大小。请注意 , 这是第二次用到这个变量。在函数前一部分中 , 它等于允许 TCP发送的最大数据量 , 但从现在起 , 它等于本地向对端通告的接收窗口的大小。

糊涂窗口综合症(简写为SWS , 详见卷1第22.3节)指连接上交换的都是短报文段 , 而不是最大长度报文段。这种现象的出现是由于接收方通告的接收窗口过小 , 或者发送方传输了许多小报文段 , 因此 , 避免糊涂窗口综合症 , 需要发送方和接收方的共同努力。图 26-8给出了发送方避免糊涂窗口综合症的做法。

```

131  /*
132   * Sender silly window avoidance. If connection is idle
133   * and can send all data, a maximum segment,
134   * at least a maximum default-sized segment do it,
135   * or are forced, do it; otherwise don't bother.
136   * If peer's buffer is tiny, then send
137   * when window is at least half open.
138   * If retransmitting (possibly after persist timer forced us
139   * to send into a small window), then must resend.
140   */
141  if (len) {
142      if (len == tp->t_maxseg)
143          goto send;
144      if ((idle || tp->t_flags & TF_NODELAY) &&
145          len + off >= so->so_snd.sb_cc)
146          goto send;
147      if (tp->t_force)
148          goto send;
149      if (len >= tp->max_sndwnd / 2)
150          goto send;
151      if (SEQ_LT(tp->snd_nxt, tp->snd_max))
152          goto send;
153  }

```

tcp_output.c

tcp_output.c

图26-8 tcp_output 函数 : 发送方避免糊涂窗口综合症

7. 发送方避免糊涂窗口综合症的方法

142-143 如果待发送报文段是最大长度报文段 , 则发送它。

144-146 如果无需等待对端的ACK(idle为真) , 或者Nagle算法被取消(TF_NODELAY为真) , 并且TCP正在清空发送缓存 , 则发送数据。Nagle算法(详见卷1第19.4节)的思想是 : 如果某个连接需要等待对端的确认 , 则不允许 TCP发送长度小于最大长度的报文段。通过设定插口选项TCP_NODELAY , 可以取消这个算法。对于正常的交互式连接 (如Telnet或Rlogin) , 即使连接上存在未确认过的数据 , 代码中的 if语句也为假 , 因为默认条件下TCP会采用Nagle算法。

147-148 如果由于持续定时器超时 , 或者有带外数据 , 强迫 TCP执行发送操作 , 则数据将被发送。

149-150 如果接收方的接收窗口已至少打开了一半 , 则发送数据。这个限制条件是为了处

理对端一直发送小窗口通告，甚至小于报文段长度的情况。变量 `max_sndwnd` 由 `tcp_input` 维护，等于连接对端发送的所有窗口通告中的最大值。实际上，TCP 试图猜测对端接收缓存的大小，并假定对端永远不会减小其接收缓存。

151-152 如果重传定时器超时，则必须发送一个报文段。`snd_max` 是已发送过的最高序号，从图 25-26 可知，重传定时器超时后，`snd_nxt` 将被设为 `snd_una`，即 `snd_nxt` 会指向窗口的左侧，从而小于 `snd_max`。

图 26-9 给出了 `tcp_output` 的下一部分，确定 TCP 是否必须向对端发送新的窗口通告，称之为“窗口更新”。

```
154  /*
155   * Compare available window to amount of window
156   * known to peer (as advertised window less
157   * next expected input). If the difference is at least two
158   * max size segments, or at least 50% of the maximum possible
159   * window, then want to send a window update to peer.
160   */
161  if (win > 0) {
162      /*
163       * "adv" is the amount we can increase the window,
164       * taking into account that we are limited by
165       * TCP_MAXWIN << tp->rcv_scale.
166       */
167      long    adv = min(win, (long) TCP_MAXWIN << tp->rcv_scale) -
168          (tp->rcv_adv - tp->rcv_nxt);
169
170      if (adv >= (long) (2 * tp->t_maxseg))
171          goto send;
172      if (2 * adv >= (long) so->so_rcv.sb_hiwat)
173          goto send;
174 }
```

tcp_output.c

图 26-9 `tcp_output` 函数：判定是否需要发送窗口更新报文

154-168 表达式

`min (win, (long) TCP_MAXWIN << tp->rcv_scale)`

等于插口接收缓存可用空间大小 (`win`) 和连接上所允许的最大窗口大小之间的最小值，即 TCP 当前能够向对端发送的接收窗口的最大值。表达式

`(tp->rcv_adv - tp->rcv_nxt)`

等于 TCP 最后一次通告的接收窗口中剩余空间的大小，以字节为单位。两者相减得到 `adv`，窗口已打开的字节数。`tcp_input` 顺序接收数据时，递增 `rcv_nxt`。`tcp_output` 在通告窗口边界向右移动时，递增 `rcv_adv`（代码见图 26-32）。

回想图 24-18，假定收到了字节 4、5 和 6，并提交给应用进程。图 26-10 给出了此时 `tcp_output` 中接收缓存的状态。

`adv` 等于 3，因为接收空间中还有 3 个字节（字节 10、11 和 12）等待对端填充。

169-170 如果剩余的接收空间能够容纳两个或两个以上的报文段，则发送窗口更新报文。在收到最大长度报文段后，TCP 将确认收到的所有其他报文段：“确认所有其他报文段 (ACK-every-other-segment)” 的属性（马上就会看到具体的实例）。

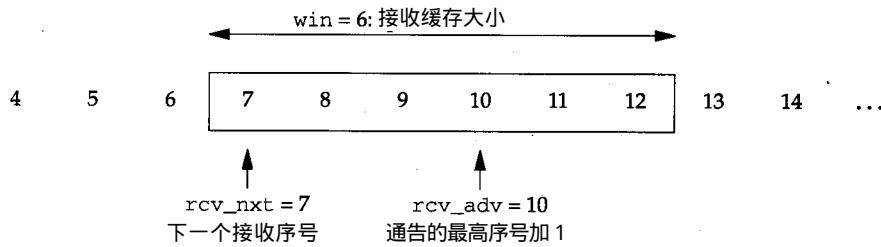


图26-10 收到字节4、5和6后，图24-18中连接的状态变化

171-172 如果可用空间大于插口接收缓存的一半，则发送窗口更新报文。

图26-11给出了tcp_output下一部分的代码，判定输出标志是否置位，要求TCP发送相应报文段。

```

174     /*
175      * Send if we owe peer an ACK.
176      */
177     if (tp->t_flags & TF_ACKNOW)
178         goto send;
179     if (flags & (TH_SYN | TH_RST))
180         goto send;
181     if (SEQ_GT(tp->snd_up, tp->snd_una))
182         goto send;
183     /*
184      * If our state indicates that FIN should be sent
185      * and we have not yet done so, or we're retransmitting the FIN,
186      * then we need to send.
187      */
188     if (flags & TH_FIN &&
189         ((tp->t_flags & TF_SENTFIN) == 0 || tp->snd_nxt == tp->snd_una))
190         goto send;

```

tcp_output.c

图26-11 tcp_output 函数：是否需要发送特定报文段

174-178 如果TF_ACKNOW置位，要求立即发送ACK，则发送相应报文段。有多种情况可导致TF_ACKNOW置位：200 ms延迟ACK定时器超时，报文段未按顺序到达（用于快速重传算法），三次握手时收到了SYN，收到了窗口探测报文，收到了FIN。

179-180 如果输出标志flags要求发送SYN或RST，则发送相应报文段。

181-182 如果紧急指针，snd_up，超出了发送缓存的起始边界，则发送相应报文段。紧急指针由PRU_SENDOOB请求处理代码（图30-9）负责维护。

183-190 如果输出标志flags要求发送FIN，并且满足下列条件：FIN未发送过或者FIN等待重传，则发送相应报文段。FIN发送后，函数将置位TF_SENTFIN标志。

到目前为止，tcp_output还没有真正发送报文段，图26-12给出了函数返回前的最后一段代码。

191-217 如果发送缓存中存在需要发送的数据（so_snd.sb_cc非零），并且重传定时器和持续定时器都未设定，则启动持续定时器。这是为了处理对端通告的接收窗口过小，无法接收最大长度报文段，而且也没有特殊原因需要发送立即发送报文段的情况。

218-221 由于不需要发送报文段，tcp_output返回。

```

191  /*
192   * TCP window updates are not reliable, rather a polling protocol
193   * using 'persist' packets is used to ensure receipt of window
194   * updates. The three 'states' for the output side are:
195   *   idle           not doing retransmits or persists
196   *   persisting     to move a small or zero window
197   *   (re)transmitting and thereby not persisting
198   *
199   * tp->t_timer[TCPT_PERSIST]
200   *     is set when we are in persist state.
201   * tp->t_force
202   *     is set when we are called to send a persist packet.
203   * tp->t_timer[TCPT_REXMT]
204   *     is set when we are retransmitting
205   * The output side is idle when both timers are zero.
206   *
207   * If send window is too small, there is data to transmit, and no
208   * retransmit or persist is pending, then go to persist state.
209   * If nothing happens soon, send when timer expires:
210   * if window is nonzero, transmit what we can,
211   * otherwise force out a byte.
212   */
213 if (so->so_snd.sb_cc && tp->t_timer[TCPT_REXMT] == 0 &&
214     tp->t_timer[TCPT_PERSIST] == 0) {
215     tp->t_rxtshift = 0;
216     tcp_setpersist(tp);
217 }
218 /*
219  * No reason to send a segment, just return.
220 */
221 return (0);

```

*tcp_output.c*图26-12 *tcp_output* 函数：进入持续状态

举例

应用进程向某个空闲的连接写入 100字节，接着又写入 50字节。假定报文段大小为 512字节。在第一次写入操作时，由于连接空闲，且 TCP正在清空发送缓存，图 26-8中的代码(144~146行)被执行，发送一个报文段，携带 100字节的数据。

在第二次写入 50字节时，图 26-8中的代码被执行，但未发送报文段：待发送数据不能构成一个最大长度报文段，连接未空闲（假定TCP正在等待第一个报文段的 ACK），默认时采用 Nagle算法，*t_force*未置位，并且假定正常情况下接收窗口大小为 4096，50不满足大于等于2048的条件。这 50字节的数据将暂留在发送缓存中，也许会一直等到第一个报文段的 ACK到达。由于对端可能延迟发送 ACK，最后50字节数据发送前的延迟有可能会更长。

这个例子说明采用 Nagle算法时，如果待发送数据无法构成最大长度报文段，如何计算它的延时。参见习题26.12。

举例

本例说明TCP的“确认所有其他报文段”属性。假定连接的报文段大小为 1024字节，接收缓存大小为4096字节。本地不发送数据，只接收数据。

发向对端的对 SYN 的 ACK 报文中，通告接收窗口大小为 4096，图 26-13 给出了两个变量 `rcv_nxt` 和 `rcv_adv` 的初始值。接收缓存为空。

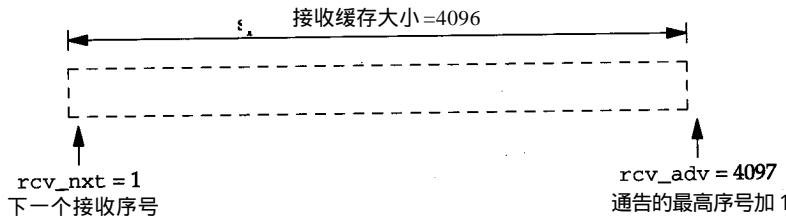


图 26-13 接收方通告接收窗口大小为 4096

对端发送 1~1024 字节的报文段，`tcp_input` 处理报文段后，设置连接的延迟 ACK 标志，把 1024 字节的数据放入插口的接收缓存中（图 26-13）。更新 `rcv_nxt`，如图 26-14 所示。

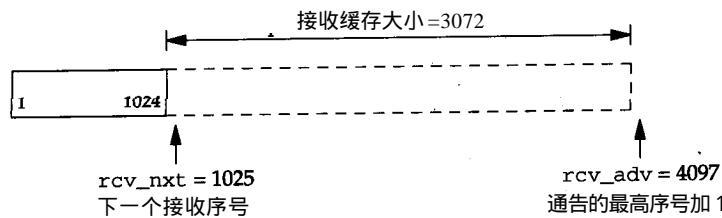


图 26-14 图 26-13 所示的连接在收到 1~1024 字节后的状态变迁

应用进程从插口的接收缓存中读取 1024 字节的数据。从图 30-6 中可看到，生成的 PRU_RCVD 请求在处理过程中会调用 `tcp_output`，因为应用进程从接收缓存读取数据后，可能需要发送窗口更新报文。当 `tcp_output` 被调用时，`rcv_nxt` 和 `rcv_adv` 的值与图 26-14 相同，唯一的区别是接收缓存的可用空间增加至 4096，因为应用进程从中读取了第一个 1024 字节的数据。把上述具体数值代入图 26-9 中的算式，得到：

$$\begin{aligned} \text{adv} &= \min(4096, 65535) - (4097 - 1025) \\ &= 1024 \end{aligned}$$

`TCP_MAXWIN` 等于 65535，我们假定接收窗口大小偏移量为 0。由于窗口的增加值小于两个最大报文段长度（2048），无需发送窗口更新报文。但由于延迟 ACK 标志置位，如果 200ms 定时器超时，将发送 ACK。

当 TCP 收到下一个 1025~2048 字节的报文段时，`tcp_input` 处理后，设定连接的延迟 ACK 标志（这个标志已置位），把 1024 字节的数据放入插口的接收缓存中，更新 `rcv_nxt`，如图 26-15 所示。

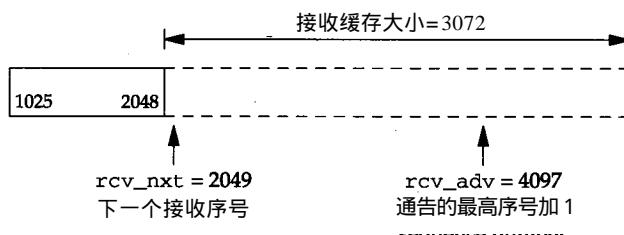


图 26-15 图 26-14 所示的连接收到 1025~2048 字节后的状态变迁

应用进程读取1024~2048字节的数据，调用tcp_output。rcv_nxt和rcv_adv的值与图26-15相同，尽管应用进程读取1024字节的数据后，接收缓存的可用空间增加至4096。把上述具体数值代入图26-9的算式中，得到：

$$\begin{aligned} \text{adv} &= \min(4096, 65535) - (4097 - 2049) \\ &= 2048 \end{aligned}$$

它等于两个报文段的长度，因此发送窗口更新报文，确认序号字段为2049，通告窗口字段为4096，表示接收方希望接收序号2049~6145的数据。我们在后面将看到，函数发送完窗口更新报文后，将更新rcv_adv的值为6145。

本例说明了如果数据接收时间少于200ms延迟定时器时限，在有两个或两个以上报文段到达，而且应用进程连续读取数据引起了接收窗口的不断变化时，将发送ACK，确认所有接收到的报文段。如果有数据到达，但应用进程没有从插口的接收缓存中读取数据，则“确认所有其他报文段”的属性不会出现。相反，发送方只能看到多个延迟ACK，每个ACK的窗口字段均较前一个要小，直到接收缓存被填满，接收窗口缩小为0。

26.4 TCP选项

TCP首部可以有任选项。由于tcp_output的下一部分代码将试图确定哪些选项需要发送，并据此组织将发送的报文段，下面我们将暂时离开函数代码，转而讨论这些选项。

图26-16列出了Net/3支持的选项格式。

选项表结束：	kind=0		
	1字节		
无操作：	kind=1		
	1字节		
最大报文段长度：	kind=2	len=4	最大报文段长度(MSS)
	1字节	1字节	2字节
窗口缩放因子：	kind=3	len=3	位移值
	1字节	1字节	1字节
时间戳：	kind=8	len=10	时间戳值
	1字节	1字节	4字节
			时间戳回显应答
			4字节

图26-16 Net/3支持的TCP选项

所有选项以1字节的kind字段开头，确定选项类型。头两个选项(kind=0或kind=1)只有1个字节。其余3个选项都是多字节的，带有len字段，位于kind字段之后，存储选项的长度。长度

其中包括*kind*字段和*len*字段。

多字节整数——MSS和两个时间戳——遵照网络字节序存储。

最后两个选项，窗口大小和时间戳，是新增的，因此许多系统都不支持。为了与以前的系统兼容，应遵循下列原则：

1) TCP主动打开时(发送不带ACK的SYN)，可以在初始SYN中同时发送这两个选项，或发送其中的任何一个。如果全局变量 `tcp_do_rfc1323` 非零(默认值等于1)，则Net/3同时支持这两个选项。此项功能由 `tcp_newtcpcb` 函数实现。

2) 只有对端返回的SYN中包含同样的选项时，才可以使用这些选项。图28-20和图29-2中的代码实现此类处理。

3) TCP被动打开时，如果收到的SYN中包含了这两个选项，而且也希望使用这些选项，则发向对端的响应(带有ACK的SYN)中必须包含它们，如图26-23所示。

由于系统必须忽略它不了解的选项，因此新增的选项只有当连接双方都了解这一选项，且同时希望支持它时才会被使用。

27.5节将讨论如何处理MSS选项。下面两节将总结Net/3处理两个新选项的做法：窗口大小和时间戳。

还有其他可能的选项。*kinds*等于4、5、6和7，称为选择性ACK和回显选项，在RFC 1072[Jacobson and Braden 1998]中定义。图26-16中并未给出这些选项，因为回显选项已被时间戳选项所代替，选择性ACK选项目前还未形成正式标准，未在RFC 1323中出现。此外，处理TCP交易的T/TCP建议(RFC 1644[Braden 1994]和卷1的24.7节)规定了其他3个选项，*kinds*分别为11、12和13。

26.5 窗口大小选项

窗口大小选项，在RFC 1323中定义，避免了TCP首部窗口大小字段只有16 bit的限制(图24-10)。如果网络带宽较高或延时较长(如，RTT较长)，则需要较大的窗口，称为长肥管道(long fat pipe)。卷1的第24.3节举例说明了现代网络需要较大的窗口，以获取最大的TCP吞吐量。

图26-16中的偏移量最小值为0(无缩放)，最大值为14，即窗口最大可设定为1 073 725 440(65535×2^{14})字节。Net/3内部实现时，利用32 bit，而非16 bit整数表示窗口大小。

窗口大小选项只能出现在SYN中，因此，连接建立后，每个传输方向上的缩放因子是固定不变的。

TCP控制块中的两个变量 `snd_scale` 和 `rcv_scale`，分别规定了发送窗口和接收窗口的偏移量。它们的默认值均为0，无缩放。每次收到对端发送的窗口通告时，16 bit的窗口大小值被左移 `snd_scale` 比特，得到真正的32 bit的对端接收窗口大小(图28-6)。每次准备向对端发送窗口通告时，内部的32 bit窗口大小值被右移 `rcv_scale` 比特，得到可填入TCP首部窗口字段的16 bit值。

TCP发送SYN时，无论是主动打开或被动打开，都是根据本地插口接收缓存大小选取 `rcv_scale` 值，填充窗口大小选项的偏移量字段。

26.6 时间戳选项

RFC 1323中还定义了时间戳选项。发送方在每个报文段中放入时间戳，接收方在ACK中

将时间戳发回。对于每个收到的 ACK，发送方根据返回的时间戳计算相应的 RTT样本值。

图26-17总结了时间戳选项所用到的变量。

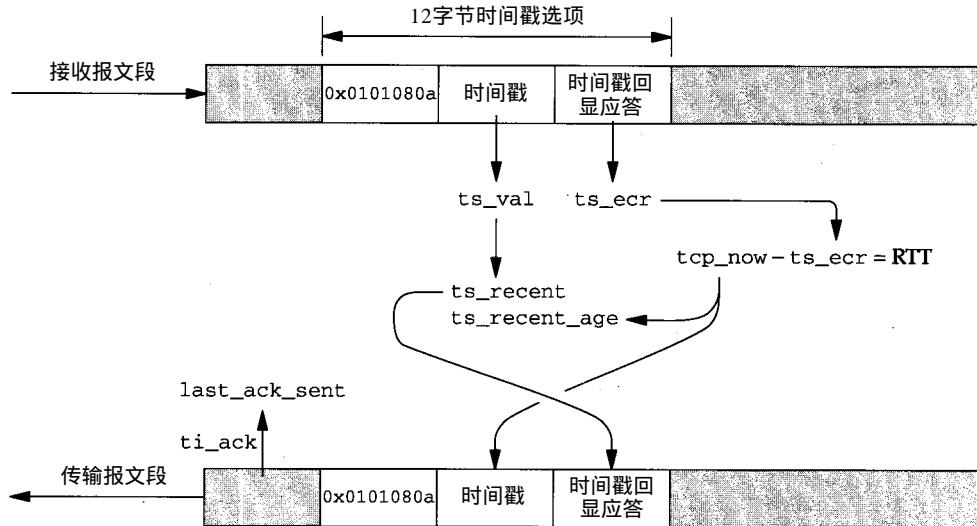


图26-17 时间戳选项中用到的变量小结

全局变量 `tcp_now` 是一个时间戳时钟。内核初启时它初始化为 0，之后每 500 ms 增加1(图 25-8)。为实现时间戳选项，TCP控制块中定义了下面3个变量：

- `ts_recent` 等于对端发送的最新的有效时间戳 (后面很快会介绍什么是“有效的”时间戳)。
 - `ts_recent_age` 是最近一次 `tcp_recent` 被更新时的 `tcp_now` 值。
 - `last_ack_sent` 是最近一次发送报文段时确认字段 (`ti_ack`) 的值(图26-32)。除非 ACK被延迟，正常情况下，它等于 `rcv_nxt`，下一个等待接收的序号。
- `tcp_input` 函数中的两个局部变量 `ts_val` 和 `ts_ecr`，保存时间戳选项的两个值：
- `ts_val` 是对端发送的数据中携带的时间戳。
 - `ts_ecr` 是由收到的报文段确认的本地发送报文段中携带的时间戳。

发送报文段中，时间戳选项的前 4 个字节为 `0x0101080a`，这是 RFC 1323附录A中建议的填充值。第一和第二字节都等于 1，为 NOP；第三字节为 `kind` 字段，等于 8；第四字节为 `len` 字段，等于 10。在选项之前添加两个 NOP后，紧接着的两个 32 bit 时间戳和后续数据都可按照 32 bit 边界对齐。此外，图 26-17 中还给出了接收到的时间戳选项，同样采用了推荐的 12字节格式(Net/3通常生成的格式)。不过，处理接收选项的应用进程代码(图28-10)，并不要求必须使用此格式。图 26-16 中定义的 10字节格式中，没有两个前导的 NOP，对端接收处理代码一样工作正常(参见习题28.4)。

从发送报文段至收到其 ACK间的RTT等于 `tcp_now` 减 `ts_ecr`，单位为 500ms滴答，因为这是Net/3时间戳的单位。

时间戳选项还可以支持TCP执行PAWS：防止序号回绕(protection against wrapped sequence number)。28.7节将详细讨论这一算法。PAWS中会用到 `ts_recent_age` 变量。

`tcp_output` 向输出报文段中填充时间戳选项时，复制 `tcp_now` 到时间戳字段，复制

`ts_recent` 到时间戳回显字段(图26-24)。如果连接采用了时间戳选项，则必须为所有输出报文段执行这一操作，除非 RST 标志置位。

26.6.1 哪个时间戳需要回显，RFC 1323 算法

TCP 通过时间戳的有效性测试决定是否更新 `ts_recent`，因为这个变量会被填充到时间戳回显字段中，也就决定了对端发送的哪个时间戳需要回显。RFC 1323 规定了下面的测试条件：

```
ti_seq <= last_ack_sent < ti_seq + ti_len
```

图26-18中的C代码实现它。

```
if (ts_present && SEQ_LEQ(ti->ti_seq, tp->last_ack_sent) &&
    SEQ_LT(tp->last_ack_sent, ti->ti_seq + ti->ti_len)) {
    tp->ts_recent_age = tcp_now;
    tp->ts_recent = ts_val;
}
```

图26-18 判定接收时间戳是否有效的典型代码

如果收到的报文段中携带时间戳选项，则变量 `ts_present` 为真。我们在 `tcp_input` 中两次遇到这段代码：图 28-11 首部预测代码中的测试；和图 28-35 正常输入处理中的测试。

为了理解测试条件的具体含义，图 26-19 给出了 5 种不同的实例，分别对应于连接上收到的 5 种不同的报文段。每个例子中，`ti_len` 都等于 3。

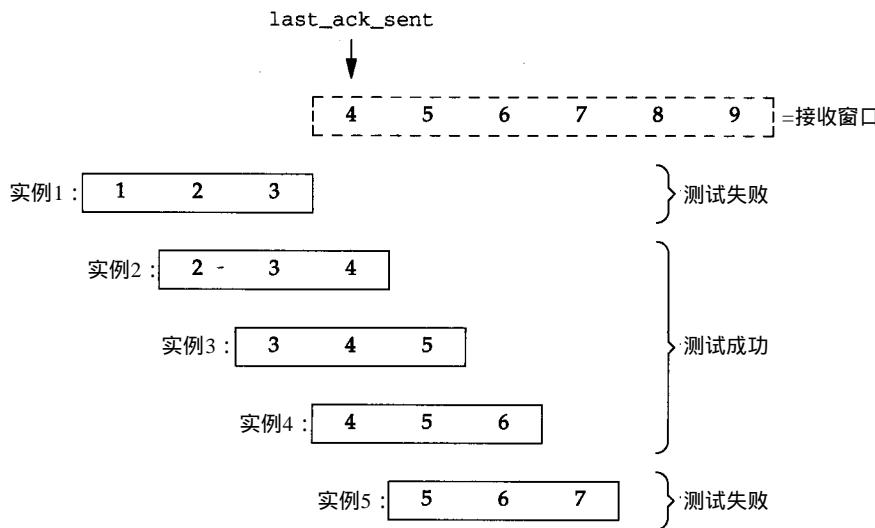


图26-19 举例：收到 5 个不同报文段时的接收窗口

接收窗口左边界序号从 4 开始。实例 1 中，报文段中携带的全部是重复数据。图 28-11 中的 `SEQ_LEQ` 测试为真，但 `SEQ_LT` 测试失败。对于实例 2、3 和 4，由于收到其中任何一个报文段，接收窗口左边界都会增加，`SEQ_LEQ` 和 `SEQ_LT` 测试都为真，尽管实例 2 中包含 2 个重复

数据，实例 3 中也包含 1 个重复数据。实例 5，由于它无法增加接收窗口左边界，所以 SEQ_LT 测试失败。这是一个未来报文段，而非等待的下一个报文段，意味着它前面的报文段丢失或报文段序列错误。

不幸的是，这个用于判定是否更新 ts_recent 的测试条件存在问题 [Braden 1993]，考虑下面的例子。

1) 假定图 26-19 中的连接开始时收到了一个报文段，携带字节 1、2 和 3。因为 last_ack_sent 等于 1，报文段的时间戳被保存到 ts_recent 中。发送 ACK，确认序号为 4，last_ack_sent 设为 4 (recv_nxt 的值)，得到如图 26-19 所示的接收窗口。

2) ACK 丢失。

3) 对端超时后重传前一个报文段，携带字节 1、2 和 3，即为图 26-19 中实例 1 的报文段。由于图 26-18 中的 SEQ_LT 测试失败，ts_recent 不会更新为重传报文段中的值。

4) TCP 发送一个重复的 ACK，确认序号为 4，但时间戳回显字段填入的 ts_recent，即从步骤 1 的原始报文段中获取的时间戳值。接收方利用这个值计算 RTT 时，将（不正确地）计入原始传输、丢失的 ACK、定时器超时、重传和重复 ACK，得到它们的总时延。

为了使对端能够正确地计算 RTT，重发 ACK 中应该携带重传报文中的时间戳值。

图 26-18 中的测试在收到的报文长度为 0 时，由于无法移动接收窗口左边界，同样不能更新 ts_recent。此外，这个错误的测试条件还会造成生存时间过长的（大于 24 天，参见 28.7 节中讨论的 PAWS 限制）、单方向的（数据流只在一个方向上存在，从而数据发送方总是输出相同的 ACK）连接。

26.6.2 哪个时间戳需要回显，正确的算法

Net/3 源代码中使用了图 26-18 所示的算法。[Braden 1993] 定义了正确的算法，如图 26-20 所示。

```
if (ts_present && TSTMP_GEQ(ts_val, tp->ts_recent) &&
    SEQ_LT(ti->ti_seq, tp->last_ack_sent)) {
```

图 26-20 判定接收时间戳是否有效的正确代码

它不关心接收窗口左侧是否移动，只确认新的时间戳 (ts_val) 大于等于前一个时间戳 (ts_recent)，并且接收到的报文段的起始序号不大于窗口的左边界。图 26-19 中实例 5 的报文仍旧无法通过新的测试，因为这是一个乱序报文。

宏 TSTMP_GEQ 与图 24-21 中的 SEQ_GEQ 相同。它用于处理时间戳，因为时间戳是 32 bit 的无符号整数，与序号一样存在回绕的问题。

26.6.3 时间戳与延迟 ACK

正确理解延迟 ACK 是如何影响时间戳和 RTT 计算是很重要的。回想图 26-17，TCP 把 ts_recent 填入到发送报文段的时间戳回显字段中，对端据此计算新的 RTT 样本值。如果 ACK 被延迟，对端计算时应把延迟时间也考虑在内，否则会造成频繁重传。下面的例子中，我们使用图 26-20 中的代码，不过图 26-18 的代码也能正确处理延迟 ACK。

考虑图 26-21 所示的接收窗口收到携带字节 4 和 5 的报文段时的变化。

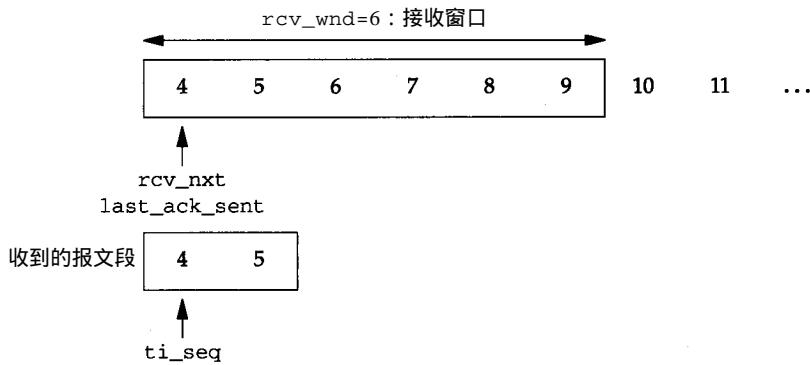


图26-21 当字节4和5到达时的接收序号空间

由于`ti_seq`小于等于`last_ack_sent`, `ts_recent`被更新。`recv_nxt`增加2。

假定对这两个字节的ACK被延迟,而且在延迟ACK发送之前,收到了下一个按序到达的报文段,如图26-22所示。

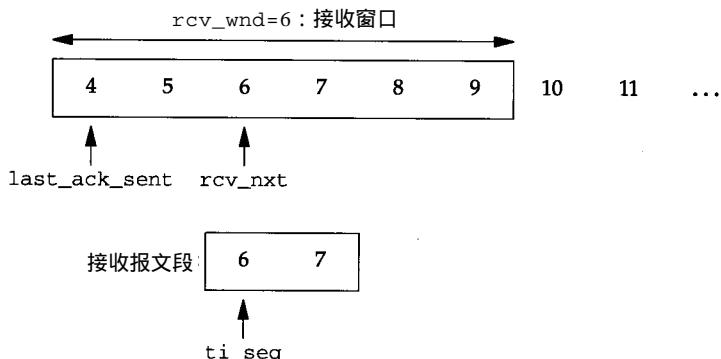


图26-22 当字节6和7到达时的接收序号空间

这一次`ti_seq`大于`last_ack_sent`,因此,不会更新`ts_recent`。这样做是有目的的。假定TCP现在发送确认序号4~7的ACK,对端据此了解存在延迟ACK,因为时间戳回显字段填入的是携带序号4和5的报文段的时间戳值(图26-24)。图26-22还说明了除非使用了延迟ACK,否则,`recv_nxt`应该等于`last_ack_sent`。

26.7 发送一个报文段

`tcp_output`接下来的代码负责发送报文段——填充TCP报文首部的所有字段,并传递给IP层准备发送。

图26-23给出了这段代码的第一部分,发送SYN报文段,携带MSS选项和窗口大小选项。
223-234 TCP选项字段构建时用到数组`opt`,整数`optlen`记录累积的字节数(因为一次可发送多个选项)。如果SYN标志置位,`snd_nxt`复位为初始发送序号(`iss`)。如果主动打开,则创建TCP控制块时在PRU_CONNECT请求处理中对`iss`赋值;如果被动打开,则`tcp_input`创建TCP控制块的同时对`iss`赋值。两种情况下,`iss`都等于全局变量`tcp_iss`。

235 查看标志`TF_NOOPT`。但事实上,这个标志永远都不会置位,因为没有代码实现置位操

作。因此，SYN报文段中必然存在MSS选项。

Net/1版的tcp_newtcpcb中，初始化t_flags为0的代码旁有一条注释“发送选项！”。TF_NOOPT标志很可能是在早期的Net/1版本中遗留下来的问题。早期版本发送MSS选项时与其他主机系统不兼容，只好默认设置不发送这一选项。

```
tcp_output.c
223  /*
224   * Before ESTABLISHED, force sending of initial options
225   * unless TCP set not to do any options.
226   * NOTE: we assume that the IP/TCP header plus TCP options
227   * always fit in a single mbuf, leaving room for a maximum
228   * link header, i.e.
229   * max_linkhdr + sizeof (struct tciphdr) + optlen <= MHLEN
230   */
231 optlen = 0;
232 hdrlen = sizeof(struct tciphdr);
233 if (flags & TH_SYN) {
234     tp->snd_nxt = tp->iss;
235     if ((tp->t_flags & TF_NOOPT) == 0) {
236         u_short mss;
237
238         opt[0] = TCPOPT_MAXSEG;
239         opt[1] = 4;
240         mss = htons((u_short) tcp_mss(tp, 0));
241         bcopy((caddr_t) &mss, (caddr_t) (opt + 2), sizeof(mss));
242         optlen = 4;
243
244         if ((tp->t_flags & TF_REQ_SCALE) &&
245             ((flags & TH_ACK) == 0 || (tp->t_flags & TF_RCVD_SCALE))) {
246             *((u_long *) (opt + optlen)) = htonl(TCPOPT_NOP << 24 |
247                                         TCPOPT_WINDOW << 16 |
248                                         TCPOLEN_WINDOW << 8 |
249                                         tp->request_r_scale);
250             optlen += 4;
251         }
252     }
}
tcp_output.c
```

图26-23 tcp_output 函数：发送第一个SYN时加入选项

1. 构造MSS选项

236-241 opt[0]等于2(TCPOPT_MAXSEG)，opt[1]等于4，即MSS选项长度，以字节为单位。函数tcp_mss计算准备向对端发送的MSS值，27.5节将讨论这个函数。bcopy把16 bit的MSS存储到opt[2]和opt[3]中(习题26.5)。注意，Net/3总是在建立连接的SYN中发送MSS。

2. 是否发送窗口大小选项

242-244 即使TCP请求窗口大小功能，也只有在主动打开(TH_ACK未置位)时，或者被动打开但对端SYN中已包含了窗口大小选项时，才会发送这一选项。回想图 25-21中TCP控制块创建时，如果全局变量tcp_dofc1323非零(默认值)，那么t_flags就等于TF_REQ_SCALE | TF_REQ_TSTMP。

3. 构造窗口大小选项

245-249 由于窗口大小选项占用3个字节(图26-16)，在它前面加入1字节的NOP，强迫其长

度为4字节，从而后续数据都可以按照4字节边界对齐。如果主动打开，则在PRU_CONNECT请求处理代码中计算request_r_scale。如果被动打开，则tcp_input在收到SYN时计算窗口大小因子。

RFC 1323规定如果TCP支持缩放窗口，即使自己的偏移量为0，也应该发送窗口大小选项。因为这个选项有两个目的：通知对端自己支持此选项；通告本地的偏移量。即使TCP计算得到的本地偏移量为0，对端可能希望使用不同的值。

图26-24给出了tcp_output的下一部分，完成在外报文段中构造选项。

```

253  /*
254   * Send a timestamp and echo-reply if this is a SYN and our side
255   * wants to use timestamps (TF_REQ_TSTMP is set) or both our side
256   * and our peer have sent timestamps in our SYN's.
257   */
258   if ((tp->t_flags & (TF_REQ_TSTMP | TF_NOOPT)) == TF_REQ_TSTMP &&
259       (flags & TH_RST) == 0 &&
260       ((flags & (TH_SYN | TH_ACK)) == TH_SYN ||

261       (tp->t_flags & TF_RCVD_TSTMP))) {
262       u_long *lp = (u_long *) (opt + optlen);

263       /* Form timestamp option as shown in appendix A of RFC 1323. */
264       *lp++ = htonl(TCPOPT_TSTAMP_HDR);
265       *lp++ = htonl(tcp_now);
266       *lp = htonl(tp->ts_recent);
267       optlen += TCPOLEN_TSTAMP_APPA;
268   }
269   hdrlen += optlen;

270   /*
271   * Adjust data length if insertion of options will
272   * bump the packet length beyond the t_maxseg length.
273   */
274   if (len > tp->t_maxseg - optlen) {
275       len = tp->t_maxseg - optlen;
276       sendalot = 1;
277   }

```

tcp_output.c

图26-24 tcp_output 函数：完成发送选项构造

4. 是否需要发送时间戳

253-261 如果下列3个条件均为真，则发送时间戳选项：(1)TCP当前配置要求支持时间戳选项；(2)正在构造的报文段不包含RST标志；(3)主动打开(flags中SYN标志置位，ACK标志未置位)，或者TCP收到了对端发送的时间戳(TF_RCVS_TSTMP)。与MSS和窗口大小选项不同，只要连接双方都同意支持它，时间戳可加入到任意报文段中。

5. 构造时间戳选项

263-267 时间戳选项(26.6节)占用12字节(TCPOLEN_TSTAMP_APPA)。头4个字节为0x0101080a(常量TCPOPT_TSTAMP_HDR)，如图26-17所示。时间戳值等于tcp_now(系统初启到现在的500ms滴答数)。时间戳回显字段值等于由tcp_input设定的ts_recent。

6. 选项加入后是否会造成报文段长度越界

270-277 加入选项后，TCP首部长度会增加optlen字节。如果发送数据的长度(len)大于

MSS减去选项长度(optlen)，则必须相应地减少数据量，并置位 sendalot标志，强迫函数发送完当前报文段后进入另一个循环(图26-1)。

MSS和窗口大小选项只出现在SYN报文段中。由于Net/3不在SYN中添加用户数据，因此数据长度的调整对这两个选项不起作用。但如果存在时间戳选项，它可以出现在所有报文段中，从而降低了一次可发送的数据量。最大长度报文段可携带的数据从通告的MSS降至MSS减去12字节。

图26-25给出了tcp_output下一部分代码，更新部分统计值，并为IP和TCP首部分配mbuf。它在输出报文段携带有用户数据(len大于0)时执行。

```

278     /*          —tcp_output.c
279      * Grab a header mbuf, attaching a copy of data to
280      * be transmitted, and initialize the header from
281      * the template for sends on this connection.
282      */
283     if (len) {
284         if (tp->t_force && len == 1)
285             tcpstat.tcp_sndprobe++;
286         else if (SEQ_LT(tp->snd_nxt, tp->snd_max)) {
287             tcpstat.tcp_sndrexmitpack++;
288             tcpstat.tcp_sndrexmitbyte += len;
289         } else {
290             tcpstat.tcp_sndpack++;
291             tcpstat.tcp_sndbyte += len;
292         }
293         MGETHDR(m, M_DONTWAIT, MT_HEADER);
294         if (m == NULL) {
295             error = ENOBUFS;
296             goto out;
297         }
298         m->m_data += max_linkhdr;
299         m->m_len = hdrlen;
300         if (len <= MHLEN - hdrlen - max_linkhdr) {
301             m_copydata(so->so_snd.sb_mb, off, (int) len,
302                         mtod(m, caddr_t) + hdrlen);
303             m->m_len += len;
304         } else {
305             m->m_next = m_copy(so->so_snd.sb_mb, off, (int) len);
306             if (m->m_next == 0)
307                 len = 0;
308         }
309     /*
310      * If we're sending everything we've got, set PUSH.
311      * (This will keep happy those implementations that
312      * give data to the user only when a buffer fills or
313      * a PUSH comes in.)
314      */
315     if (off + len == so->so_snd.sb_cc)
316         flags |= TH_PUSH;

```

图26-25 tcp_output 函数：更新统计值，为IP和TCP首部分配mbuf

7. 更新统计值

284-292 如果t_force非零，且用户数据只有1字节，可知是一个窗口探测报文。如果snd_nxt小于snd_max，则是一个重传报文。其他的都是正常的数据传输报文。

8. 为IP和TCP首部分配mbuf

293-297 MGETHDR为带有数据分组头部的 mbuf分配内存，mbuf中保存IP和TCP的头部及可能的数据(若空间允许)。尽管tcp_output调用通常作为系统调用的一部分(如，write)，它也可在软件中断级由tcp_input调用，或作为定时器处理的一部分。因此，定义了M_DONTWAIT。如果返回错误，控制跳转至“out”处。它位于函数的末尾，如图 26-32所示。

9. 向mbuf中复制数据

298-308 如果数据少于44字节(100-40-16，假定没有TCP选项)，数据由m_copydata直接从插口的发送缓存中复制到新的数据组头部 mbuf中。若数据量较大，m_copy创建新的mbuf链表，复制插口发送缓存中的数据，最后与前面创建的数据组头部 mbuf链接。回想2.9节中介绍过的m_copy函数，如果数据本身已是一个簇，m_copy将不复制，只引用这个簇。

10. 置位PSH标志

309-316 如果TCP发送了从发送缓存得到的所有数据，则 PSH标志被置位。如同注释中提到的，这是因为有些接收系统只有在收到 PSH标志或者接收缓存已满时，才会向应用程序递交收到的数据。我们在tcp_input中将看到，Net/3绝不会为了等待PSH标志，而把数据滞留在接收缓存中。

图26-26给出了tcp_output下一部分的代码，从在len等于0时执行的else语句开始，处理不携带用户数据的TCP报文段。

```

317     } else {                                /* len == 0 */
318         if (tp->t_flags & TF_ACKNOW)
319             tcpstat.tcpssndacks++;
320         else if (flags & (TH_SYN | TH_FIN | TH_RST))
321             tcpstat.tcpssndctrl++;
322         else if (SEQ_GT(tp->snd_up, tp->snd_una))
323             tcpstat.tcpssndurg++;
324         else
325             tcpstat.tcpssndwinup++;
326
326         MGETHDR(m, M_DONTWAIT, MT_HEADER);
327         if (m == NULL) {
328             error = ENOBUFS;
329             goto out;
330         }
331         m->m_data += max_linkhdr;
332         m->m_len = hdrlen;
333     }
334     m->m_pkthdr.rcvif = (struct ifnet *) 0;
335     ti = mtod(m, struct tciphdr *);
336     if (tp->t_template == 0)
337         panic("tcp_output");
338     bcopy((caddr_t) tp->t_template, (caddr_t) ti, sizeof(struct tciphdr));

```

tcp_output.c
tcp_output.c

图26-26 tcp_output 函数：更新统计值，为IP和TCP首部分配mbuf

11. 更新统计值

318-325 需要更新的统计值有：TF_ACKNOW和长度为0说明是一个纯ACK报文段。如果SYN、FIN或RST中任何一个置位，即为控制报文段。如果紧急指针超过 snd_una，是为了

通知对端紧急指针的位置。如果上述条件均为假，则是窗口更新报文段。

12. 得到存储IP和TCP首部的mbuf

326-335 为带有数据包组首部的 mbuf分配内存，以保存IP和TCP的首部。

13. 向mbuf中复制IP和TCP首部模板

336-338 bcopy把IP和TCP首部模板从 t_template 复制到 mbuf中。这个模板由 tcp_template 创建。

图26-27给出了tcp_output下一部分的代码，填充TCP首部剩余的字段。

```

339     /*
340      * Fill in fields, remembering maximum advertised
341      * window for use in delaying messages about window sizes.
342      * If resending a FIN, be sure not to use a new sequence number.
343      */
344     if (flags & TH_FIN && tp->t_flags & TF_SENDFIN &&
345         tp->snd_nxt == tp->snd_max)
346         tp->snd_nxt--;
347     /*
348      * If we are doing retransmissions, then snd_nxt will
349      * not reflect the first unsent octet. For ACK only
350      * packets, we do not want the sequence number of the
351      * retransmitted packet, we want the sequence number
352      * of the next unsent octet. So, if there is no data
353      * (and no SYN or FIN), use snd_max instead of snd_nxt
354      * when filling in ti_seq. But if we are in persist
355      * state, snd_max might reflect one byte beyond the
356      * right edge of the window, so use snd_nxt in that
357      * case, since we know we aren't doing a retransmission.
358      * (retransmit and persist are mutually exclusive...)
359      */
360     if (len || (flags & (TH_SYN | TH_FIN)) || tp->t_timer[TCPT_PERSIST])
361         ti->ti_seq = htonl(tp->snd_nxt);
362     else
363         ti->ti_seq = htonl(tp->snd_max);
364     ti->ti_ack = htonl(tp->rcv_nxt);
365     if (optlen) {
366         bcopy((caddr_t) opt, (caddr_t) (ti + 1), optlen);
367         ti->ti_off = (sizeof(struct tcphdr) + optlen) >> 2;
368     }
369     ti->ti_flags = flags;

```

tcp_output.c

图26-27 tcp_output 函数：置位 ti_seq、ti_ack 和 ti_flags

14. 如果FIN将重传，递减 snd_nxt

339-346 如果TCP已经发送过FIN，则发送序列空间如图 26-28所示。因此，如果 TH_FIN 置位，则 TF_SENDFIN 也置位，并且 snd_nxt 等于 snd_max，可知FIN等待重传。不久将看到（图26-31），发送FIN时，snd_nxt会递增1（由于FIN也要占用一个序号），因此，这里的代码递减 snd_nxt。

15. 设置报文段的序号字段

347-363 报文段的序号字段通常等于 snd_nxt，但在满足下列条件时，应等于 snd_max：如果(1) 不传输数据(len等于0)；(2) SYN标志和FIN标志都未置位；(3) 持续定时器未置位。

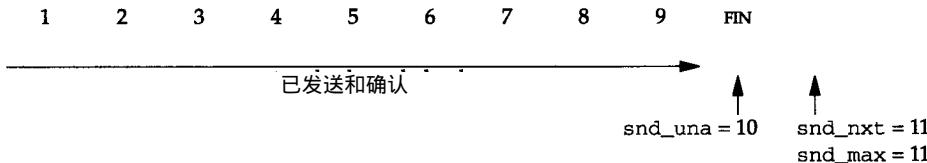


图26-28 FIN发送后的发送序列空间

16. 设置报文段的确认字段

364 报文段的确认字段通常等于 `recv_nxt`，期待接收的下一个序号。

17. 如果存在首部选项，设置首部长度字段

365-368 如果存在TCP选项(`optlen`大于0)，代码把选项内容复制到TCP首部，TCP首部4 bit的首部长度字段(图24-10的`th_off`)等于TCP首部的固定长度(20字节)加上选项总长度后除以4。这个字段是以32 bit为单位的首部长度值，包括TCP选项。

369 TCP首部的标志字段根据变量 `flags` 设定。

图26-29给出了下一部分的代码，填充TCP首部其他字段，并计算TCP检验和。

```
tcp_output.c
370  /*
371   * Calculate receive window. Don't shrink window,
372   * but avoid silly window syndrome.
373   */
374  if (win < (long) (so->so_rcv.sb_hiwat / 4) && win < (long) tp->t_maxseg)
375      win = 0;
376  if (win > (long) TCP_MAXWIN << tp->recv_scale)
377      win = (long) TCP_MAXWIN << tp->recv_scale;
378  if (win < (long) (tp->recv_adv - tp->recv_nxt))
379      win = (long) (tp->recv_adv - tp->recv_nxt);
380  ti->ti_win = htons((u_short) (win >> tp->recv_scale));
381  if (SEQ_GT(tp->snd_up, tp->snd_nxt)) {
382      ti->ti_urp = htons((u_short) (tp->snd_up - tp->snd_nxt));
383      ti->ti_flags |= TH_URG;
384  } else
385      /*
386       * If no urgent pointer to send, then we pull
387       * the urgent pointer to the left edge of the send window
388       * so that it doesn't drift into the send window on sequence
389       * number wraparound.
390       */
391      tp->snd_up = tp->snd_una; /* drag it along */
392  /*
393   * Put TCP length in extended header, and then
394   * checksum extended header and data.
395   */
396  if (len + optlen)
397      ti->ti_len = htons((u_short) (sizeof(struct tcphdr) +
398                               optlen + len));
399  ti->ti_sum = in_cksum(m, (int) (hdrlen + len));
```

tcp_output.c

图26-29 `tcp_output` 函数：填充其他TCP首部字段并计算检验和

18. 通告的窗口大小应大于最大报文段长度

370-375 计算向对端通告的窗口大小(ti_win)时，应考虑如何避免糊涂窗口综合症。回想图26-3结尾处，win等于插口的接收缓存大小。如果win小于接收缓存大小的1/4(so_rcv.sb_hiwat)，并且小于一个最大报文段长度，则通告的窗口大小设为0，从而在后续测试中防止窗口缩小。也就是说，如果可用空间已达到接收缓存大小的1/4，或者等于最大报文段长度，将向对端发送窗口更新通告。

19. 遵守连接的通告窗口大小的上限

376-377 如果win大于连接规定的最大值，应将其减少为最大值。

20. 不要缩小窗口

378-379 回想图26-10中，rcv_adv减去rcv_nxt等于最近一次向发送方通告的窗口大小中的剩余空间。如果win小于它，应将其设定为该值，因为不允许缩小窗口。有时尽管剩余的可用空间小于最大报文段长度(因此，win在代码起始处被置为0)，但还可以容纳一些数据，就会出现这种情况。卷1中的图22-3举例说明了这一现象。

21. 设置紧急数据偏移量

381-383 如果紧急指针(snd_up)大于snd_nxt，则TCP处于紧急方式。TCP首部的紧急数据偏移量字段设定为以报文段起始序号为基准的紧急指针的16 bit偏移量，并且置位URG标志。无论所指向的紧急数据是否包含在当前处理的报文段中，TCP都会发送紧急数据偏移量和URG标志。

图26-30举例说明了如何计算紧急数据偏移量，假定应用进程执行了

```
send(fd, buf, 3, MSG_OOB);
```

并且调用send时发送缓存为空。这种做法表明基于Berkeley的系统认为紧急指针应指向带外数据后的第一个字节。回想图24-10中，我们区分了数据流中32 bit的紧急指针(snd_up)，和TCP首部中的16 bit紧急数据偏移量(ti_urp)。

这里有个小错误。无论是否采用窗口大小选项，如果发送缓存大于65535，并且几乎为空，则应用进程发送带外数据时，从snd_nxt算起的紧急指针的偏移量有可能超过65535。但偏移量是一个16 bit的无符号整数，如果计算结果超过65535，高位16 bit被丢弃，发送到对端的数据必然是错误的。解决办法参见习题26.6。

384-391 如果TCP不处于紧急方式，则紧急指针移向窗口的最左端(snd_una)。

392-399 TCP长度存储在伪首部中以计算TCP检验和。

到目前为止，TCP首部的所有字段已填充完毕，而且从t_template复制IP和TCP首部模板时(图26-26)，对伪首部中用到的IP首部部分字段预先做了初始化(见图23-19中UDP检验和的计算)。

图26-31给出了tcp_output下一部分的代码，SYN或FIN标志置位时更新序号，并启动重传定时器。

22. 保存起始序号

400-405 如果TCP不处于持续状态，则起始序号保存在startseq中。图26-31中的代码在对报文段计时时用到这一变量。

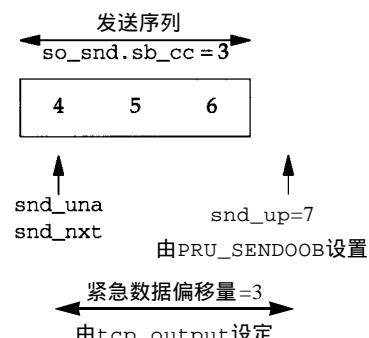


图26-30 紧急指针与紧急数据偏移量计算举例

```

400  /*
401   * In transmit state, time the transmission and arrange for
402   * the retransmit. In persist state, just set snd_max.
403   */
404   if (tp->t_force == 0 || tp->t_timer[TCPT_PERSIST] == 0) {
405     tcp_seq startseq = tp->snd_nxt;

406     /*
407      * Advance snd_nxt over sequence space of this segment.
408      */
409     if (flags & (TH_SYN | TH_FIN)) {
410       if (flags & TH_SYN)
411         tp->snd_nxt++;
412       if (flags & TH_FIN) {
413         tp->snd_nxt++;
414         tp->t_flags |= TF_SENDFIN;
415       }
416     }
417     tp->snd_nxt += len;
418     if (SEQ_GT(tp->snd_nxt, tp->snd_max)) {
419       tp->snd_max = tp->snd_nxt;
420       /*
421        * Time this transmission if not a retransmission and
422        * not currently timing anything.
423        */
424       if (tp->t_rtt == 0) {
425         tp->t_rtt = 1;
426         tp->t_rtseq = startseq;
427         tcpstat.tcpst_segstimed++;
428       }
429     }
430     /*
431      * Set retransmit timer if not currently set,
432      * and not doing an ack or a keepalive probe.
433      * Initial value for retransmit timer is smoothed
434      * round-trip time + 2 * round-trip time variance.
435      * Initialize counter which is used for backoff
436      * of retransmit time.
437      */
438     if (tp->t_timer[TCPT_REXMT] == 0 &&
439         tp->snd_nxt != tp->snd_una) {
440       tp->t_timer[TCPT_REXMT] = tp->t_rxtdur;
441       if (tp->t_timer[TCPT_PERSIST]) {
442         tp->t_timer[TCPT_PERSIST] = 0;
443         tp->t_rxtdshift = 0;
444       }
445     }
446   } else if (SEQ_GT(tp->snd_nxt + len, tp->snd_max))
447     tp->snd_max = tp->snd_nxt + len;

```

*tcp_output.c*图26-31 *tcp_output* 函数：更新序号并启动重传定时器

23. 增加snd_nxt

406-417 由于SYN和FIN都占用一个序号，其中任一标志置位，*snd_nxt*都必须增加。FIN发送过后，*TF_SENDFIN*将置位。之后，*snd_nxt*增加发送的数据字节数(*len*)，可以为0。

24. 更新*snd_max*

418-419 如果*snd_nxt*的最新值大于*snd_max*，则不是重传报文。*snd_max*值被更新。

420-428 如果连接目前还没有RTT值($t_{rtt}=0$)，则定时器启动($t_{rtt}=1$)，计时报文段的起始序号保存在 t_{rtseq} 中。`tcp_input`利用它确定计时报文段ACK的到达时间，从而更新RTT。根据25.10节中的讨论，代码应为：

```
if (tp->t_rtt && SEQ_GT(ti->ti_ack, tp->t_rtseq))
    tcp_xmit_timer(tp, tp->t_rtt);
```

25. 设定重传定时器

430-440 如果重传定时器还未启动，并且报文段中有数据，则重传定时器时限设定为 t_{rxtcur} 。前面已经介绍过，通过测量RTT样本值，`tcp_xmit_timer`将更新 t_{rxtcur} 。但如果 snd_nxt 等于 snd_una (此时 snd_nxt 中已加入了 len)，则是一个纯ACK报文段，而只有在发送数据报文段时才需要启动重传定时器。

441-444 如果持续定时器已启动，则关闭它。对于给定连接，可以在任何时候启动重传定时器或者持续定时器，但两者不允许同时存在。

26. 持续状态

446-447 由于 t_{force} 非零，而且持续定时器已设定，可知连接处于持续状态(与图26-31起始处的`if`语句配对的`else`语句)。需要时，更新 snd_max 。处于持续状态时， len 应等于1。

`tcp_output`的最后一部分，在图 26-32 中给出，输出报文段准备完毕，调用`ip_output`发送数据报。

tcp_output.c

```
448     /*
449      * Trace.
450      */
451     if (so->so_options & SO_DEBUG)
452         tcp_trace(TA_OUTPUT, tp->t_state, tp, ti, 0);
453
454     /*
455      * Fill in IP length and desired time to live and
456      * send to IP level. There should be a better way
457      * to handle ttl and tos; we could keep them in
458      * the template, but need a way to checksum without them.
459      */
460     m->m_pkthdr.len = hdrlen + len;
461     ((struct ip *) ti)->ip_len = m->m_pkthdr.len;
462     ((struct ip *) ti)->ip_ttl = tp->t_inpcb->inp_ip.ip_ttl; /* XXX */
463     ((struct ip *) ti)->ip_tos = tp->t_inpcb->inp_ip.ip_tos; /* XXX */
464     error = ip_output(m, tp->t_inpcb->inp_options, &tp->t_inpcb->inp_route,
465                       so->so_options & SO_DONTROUTE, 0);
466     if (error) {
467         out:
468             if (error == ENOBUFS) {
469                 tcp_quench(tp->t_inpcb, 0);
470                 return (0);
471             }
472             if ((error == EHOSTUNREACH || error == ENETDOWN)
473                 && TCPS_HAVERCVDSYN(tp->t_state)) {
474                 tp->t_softerror = error;
475                 return (0);
476             }
477         return (error);
478     }
```

图26-32 `tcp_output` 函数：调用`ip_output` 发送报文段

```

478     tcpstat.tcp_sndtotal++;

479     /*
480      * Data sent (as far as we can tell).
481      * If this advertises a larger window than any other segment,
482      * then remember the size of the advertised window.
483      * Any pending ACK has now been sent.
484      */
485     if (win > 0 && SEQ_GT(tp->rcv_nxt + win, tp->rcv_adv))
486         tp->rcv_adv = tp->rcv_nxt + win;
487     tp->last_ack_sent = tp->rcv_nxt;
488     tp->t_flags &= ~(TF_ACKNOW | TF_DELACK);

489     if (sendalot)
490         goto again;
491     return (0);
492 }

```

tcp_output.c

图26-32 (续)

27. 为插口调试添加路由记录

448-452 如果选用了SO_DEBUG选项，`tcp_trace`会在TCP的循环路由缓存中添加一条记录，27.10节将详细讨论这个函数。

28. 设置IP长度、TTL和TOS

453-462 IP首部的3个字段必须由传输层设置：IP长度、TTL和TOS，图23-19底部用星号强调了这3个特殊字段。

注意，注释的内容为“XXX”，这是因为尽管对于给定连接，TTL和TOS通常常量，可以保存在首部模板中，无需每次发送报文段时都明确赋值。只有当TCP检验和计算完毕后，这两个字段才能填入IP首部，因此只能这样实现。

29. 向IP传递数据报

463-464 `ip_output`发送携带TCP报文段的数据报。TCP的插口选项和SO_DONTROUTE逻辑与，从而能向IP层传送的插口选项只有一个：SO_DONTROUTE。尽管`ip_output`还测试另一个选项SO_BROADCAST，但即使设定了它，与SO_DONTROUTE的逻辑与也会将其关闭。也就是说，应用进程不允许向一个广播地址发送connect，即使它设定了SO_BROADCAST选项。

467-470 如果接口队列已满，或者IP请求分配mbuf失败，则返回差错码ENOBUFS。`tcp_quench`把拥塞窗口设定为只能容纳一个最大报文段长度，强迫连接执行慢起动。注意，出现上述情况时，TCP仍旧返回0(OK)，而非错误，即使数据报实际已丢弃。这与`udp_output`(图23-20)不同，后者返回一个错误。TCP将通过超时重传该数据报(数据报文段)，希望那时在接口输出队列中会有可用空间或者能申请到更多的mbuf。如果TCP报文段不包含数据，对端由于未收到ACK而引发超时时，将重传由丢失的ACK所确认的数据。

471-475 如果连接已收到一个SYN，但找不到至目的地的路由，则记录连接上出现了一个软错误。

当`tcp_output`被`tcp_usrreq`调用，做为应用进程系统调用的一部分时(参见第30章，PRU_CONNECT、PRU_SEND、PRU_SENDOOB和PRU_SHUTDOWN请求)，应用进程将接收`tcp_output`的返回值。其他调用`tcp_output`的函数，如`tcp_input`、快超时函数和慢超时函数，忽略其返回值(因为这些函数不向应用进程返回差错码)。

30. 更新rcv_adv和last_ack_sent

479-486 如果报文段中通告的最高序号(rcv_nxt加上win)大于rcv_adv，则保存新的值。

回想图26-9中利用rcv_adv确定最后一个报文段发送后新增的可用空间，以及图26-29中利用它确定TCP没有缩小窗口。

487 报文段确认字段的值保存在last_ack_sent中，tcp_input利用它处理时间戳选项(图26-6)。

488 由于所有延迟的ACK都已被发送，TF_ACKNOW和TF_DELACK标志被清除。

31. 是否还有数据需要发送

489-490 如果sendalot标志置位，控制跳回到again处(图26-1)。如果发送缓存中的数据超过一个最大长度报文段的容量(图26-3)，或者由于加入TCP选项，降低了最大长度报文段的数据容量，无法在一个报文段中将缓存中的数据发送完毕时，控制将折回。

26.8 tcp_template函数

创建插口时，将调用tcp_newtcpcb(见前一章)为TCP控制块分配内存，并完成部分初始化。当在插口上发送或接收第一个报文段时(主动打开，PRU_CONNECT请求，或者在监听的插口上收到了一个SYN)，tcp_template为连接的IP和TCP的首部创建一个模板，从而减少了报文段发送时tcp_output的工作量。

图26-33给出了tcp_template函数。

```

59 struct tciphdr *
60 tcp_template(tp)
61 struct tcpcb *tp;
62 {
63     struct inpcb *inp = tp->t_inpcb;
64     struct mbuf *m;
65     struct tciphdr *n;
66
67     if ((n = tp->t_template) == 0) {
68         m = m_get(M_DONTWAIT, MT_HEADER);
69         if (m == NULL)
70             return (0);
71         m->m_len = sizeof(struct tciphdr);
72         n = mtod(m, struct tciphdr *);
73     }
74     n->ti_next = n->ti_prev = 0;
75     n->ti_x1 = 0;
76     n->ti_pr = IPPROTO_TCP;
77     n->ti_len = htons(sizeof(struct tciphdr) - sizeof(struct ip));
78     n->ti_src = inp->inp_laddr;
79     n->ti_dst = inp->inp_faddr;
80     n->ti_sport = inp->inp_lport;
81     n->ti_dport = inp->inp_fport;
82     n->ti_seq = 0;
83     n->ti_ack = 0;
84     n->ti_x2 = 0;
85     n->ti_off = 5;           /* 5 32-bit words = 20 bytes */
86     n->ti_flags = 0;
87     n->ti_win = 0;
88     n->ti_sum = 0;
89     n->ti_urp = 0;
90     return (n);
91 }
```

图26-33 tcp_template 函数：创建IP和TCP首部的模板

1. 分配mbuf

59-72 IP和TCP的首部模板在一个 mbuf中组建，指向这个 mbuf的指针存储在TCP控制块的 `t_template` 成员变量中。由于这个函数可在软件中断级被 `tcp_input` 调用，`M_DONTWAIT` 标志置位。

2. 初始化首部字段

73-88 除下列字段外，IP和TCP首部的其他字段均置为0：`ti_pr` 等于TCP的IP协议值(6)；`ti_len` 等于20，TCP首部的默认值；`ti_off` 等于5，TCP首部长度，以32 bit为单位；此外，还要从Internet PCB中把源IP地址、目的IP地址和TCP端口号复制到TCP首部模板中。

3. 用于TCP检验和计算的伪首部

73-88 由于预先对IP和TCP首部中许多字段做了初始化，简化了TCP检验和的计算，方法与23.6节中讨论过的UDP首部检验和的计算方式相同。参考图23-19中的`udpiphdr`结构，请读者自己思考为什么 `tcp_template` 将 `ti_next` 和 `ti_prev` 等字段初始化为0。

26.9 `tcp_respond` 函数

函数 `tcp_respond` 尽管也调用 `ip_output` 发送IP数据报，但用途不同。主要在下面两种情况下调用它：

- 1) `tcp_input` 调用它生成RST报文段，携带或不携带ACK；
- 2) `tcp_timers` 调用它发送保活探测报文。

在这两种特殊情况下，TCP调用 `tcp_respond`，取代 `tcp_output` 中复杂的逻辑。但请注意，下一章中讨论的 `tcp_drop` 函数调用 `tcp_output` 来生成RST报文段。并非所有的RST报文段都由 `tcp_respond` 生成。

图26-34给出了 `tcp_respond` 的前半部分。

```

104 void
105 tcp_respond(tp, ti, m, ack, seq, flags)
106 struct tcpcb *tp;
107 struct tciphdr *ti;
108 struct mbuf *m;
109 tcp_seq ack, seq;
110 int flags;
111 {
112     int tlen;
113     int win = 0;
114     struct route *ro = 0;
115     if (tp) {
116         win = sbspace(&tp->t_inpcb->inp_socket->so_rcv);
117         ro = &tp->t_inpcb->inp_route;
118     }
119     if (m == 0) { /* generate keepalive probe */
120         m = m_gethdr(M_DONTWAIT, MT_HEADER);
121         if (m == NULL)
122             return;
123         tlen = 0; /* no data is sent */
124         m->m_data += max_linkhdr;
125         *mtod(m, struct tciphdr *) = *ti;

```

图26-34 `tcp_respond` 函数：前半部分

```

126         ti = mtod(m, struct tciphdr *);
127         flags = TH_ACK;
128     } else {           /* generate RST segment */
129         m_freem(m->m_next);
130         m->m_next = 0;
131         m->m_data = (caddr_t) ti;
132         m->m_len = sizeof(struct tciphdr);
133         tlen = 0;
134 #define xchg(a,b,type) { type t; t=a; a=b; b=t; }
135         xchg(ti->ti_dst.s_addr, ti->ti_src.s_addr, u_long);
136         xchg(ti->ti_dport, ti->ti_sport, u_short);
137 #undef xchg
138     }

```

tcp_subr.c

图26-34 (续)

104-110 图26-35列出了3种不同情况下调用tcp_respond时其参数的变化。

	参 数					
	tp	ti	m	ack	seq	flags
生成不带ACK的RST	tp	ti	m	0	ti_ack	TH_RST
生成带ACK的RST	tp	ti	m	ti_seq + ti_len	0	TH_RST TH_ACK
生成保活探测	tp	t_template	NULL	rcv_nxt	snd_una	0

图26-35 *tcp_respond* 的参数

tp是指向TCP控制块的指针(可能为空)；ti是指向IP和TCP首部模板的指针；m是指向mbuf的指针，其中的报文段引发RST。最后3个参数是确认字段、序号字段和待生成报文段的标志字段。

113-118 如果tcp_input收到一个不属于任何连接的报文段，则有可能生成RST。例如，收到的报文段中没有指明任何现存连接(如，SYN指明的端口上没有正在监听的服务器)。这种情况下，tp为空，使用win和ro的初始值。如果tp不空，则通告窗口大小将等于接收缓存中的可用空间，指向缓存路由的指针保存在ro中，在后面调用tcp_input时会用到。

1. 保活定时器超时后发送保活探测

119-127 参数m是指向接收报文段的mbuf链表的指针。但保活探测报文只有当保活定时器超时时才会被发送，收到的TCP报文段不可能引发此项操作，因此m为空，由m_gethdr分配保存IP和TCP首部的mbuf。TCP数据长度tlen，设为0，因为保活探测报文不包含任何用户数据。

有些基于4.2BSD的较老的系统不响应保活探测报文，除非它携带数据。通过配置，在编译内核时定义TCP_COMPAT_42，Net/3能够在保活探测报文中携带一个字节的无效数据，以引出这些系统的响应。这种情况下，tlen设为1，而非0。无效字节不会造成不良后果，因为它不是对方正等待(而是一个对方已接收并确认过)的字节，对端将丢弃它。

利用赋值语句把ti指向的TCP首部模板结构复制到mbuf的数据部分，之后指针ti将被重

新设定，指向 mbuf 中的首部模板。

2. 发送 RST 报文段

128-138 接收到的报文段有可能会引发 `tcp_input` 发送 RST。发送 RST 时，保存输入报文段的 mbuf 可以重用。因为 `tcp_respond` 生成的报文段中只包含 IP 首部和 TCP 首部，因此，除第一个 mbuf 之外（数据分组首部），`m_free` 将释放链表中其余的所有 mbuf。另外，IP 首部和 TCP 首部中的源 IP 地址和目的 IP 地址及端口号应互换。

图 26-36 给出了 `tcp_respond` 的后半部分。

```

139     ti->ti_len = htons((u_short) (sizeof(struct tcphdr) + tlen));
140     tlen += sizeof(struct tcphdr);
141     m->m_len = tlen;
142     m->m_pkthdr.len = tlen;
143     m->m_pkthdr.rcvif = (struct ifnet *) 0;
144     ti->ti_next = ti->ti_prev = 0;
145     ti->ti_x1 = 0;
146     ti->ti_seq = htonl(seq);
147     ti->ti_ack = htonl(ack);
148     ti->ti_x2 = 0;
149     ti->ti_off = sizeof(struct tcphdr) >> 2;
150     ti->ti_flags = flags;
151     if (tp)
152         ti->ti_win = htons((u_short) (win >> tp->recv_scale));
153     else
154         ti->ti_win = htons((u_short) win);
155     ti->ti_urp = 0;
156     ti->ti_sum = 0;
157     ti->ti_sum = in_cksum(m, tlen);
158     ((struct ip *) ti)->ip_len = tlen;
159     ((struct ip *) ti)->ip_ttl = ip_defttl;
160     (void) ip_output(m, NULL, ro, 0, NULL);
161 }
```

tcp_subr.c

图 26-36 `tcp_respond` 函数：后半部分

139-157 为计算 TCP 检验和，IP 和 TCP 首部字段必须被初始化。这些语句与 `tcp_template` 初始化 `t_template` 字段的方式类似。序号和确认字段由调用者提供，最后调用 `ip_output` 发送数据分组。

26.10 小结

本章讨论了生成大多数 TCP 报文段的通用函数 (`tcp_output`) 及生成 RST 报文段和保活探测的特殊函数 (`tcp_respond`)。

TCP 是否发送报文段取决于许多因素：报文段中的标志、对端通告的窗口大小、待发送的数据量以及连接上是否存在未确认的数据等等。因此，`tcp_output` 中的逻辑决定了是否发送报文段（函数的前半部分），如果需要发送，如何填充 TCP 首部的字段（函数后半部分）。报文段发送之后，还需要更新 TCP 控制块中的相应变量。

`tcp_output` 一次只生成一个报文段，但它在结尾处会测试是否还有剩余数据等待发送，如果有，控制将折回，并试图发送下一个报文段。这样的循环会一直持续到数据全部发送完毕，或者有其他停止传输的条件出现（接收方的窗口通告）。

TCP报文段中可以携带选项。Net/3支持的选项规定了最大报文段长度、窗口大小缩放因子和一对时间戳。头两个选项只能出现在SYN报文段中，而时间戳选项(如果连接双方都支持)能够出现在所有报文段中。因为窗口大小和时间戳是新增的选项，如果主动打开的一端希望使用这些选项，则必须在自己发送的SYN中添加它们，并且只有在对端发回的SYN也包含了同样的选项时才能使用。

习题

- 26.1 图26-1中，如果发送数据过程中出现停顿，TCP将返回慢启动状态，而空闲时间被设定为从最后一次收到报文段到现在的时间。为什么TCP不将空闲时间设定为从最后一次发送报文到现在的时间？
- 26.2 图26-6中，我们说如果FIN已发送，但还未被确认且没有重传，此时len小于0。如果FIN已重传，情况会怎样？
- 26.3 Net/3总在主动打开时发送窗口大小和时间戳选项。为什么需要全局变量
`tcp_do_rfcl 13223`
- 26.4 图25-28中的例子未使用时间戳，RTT估算值被更新了8次。如果使用了时间戳，RTT估算值会被更新几次？
- 26.5 图26-23中，调用`bcopy`把收到的MSS存储在变量mss中。为什么不对指向`opt[2]`的指针做强制转换，变为不带符号的短整型指针，并利用赋值语句完成这一操作？
- 26.6 在图26-29后面，我们讨论了代码的一个错误，可能会导致发送一个错误的紧急数据偏移量。提出你的解决方案。(提示：一个TCP报文中能够发送的最大数据量是多少？)
- 26.7 图26-32中，我们提到不会向应用进程返回差错代码ENOBUFS，因为(1)如果丢弃的是数据报文，重传定时器超时后数据将被重传；(2)如果丢弃的是纯ACK报文，对端收不到ACK时会重传对应的数据报文。如果丢弃的是RST报文，情况会怎样？
- 26.8 解释卷1图20-3中PSH标志的设定。
- 26.9 为什么图26-36使用`ip_defttl`作为TTL的值，而图26-32却使用PCB？
- 26.10 如果应用进程规定的IP选项是用于TCP连接的，图26-25中分配的mbuf会出现什么情况？实现一个更好的方案。
- 26.11 `tcp_output`函数很长(包括注释约500行)，看上去效率不高，其中许多代码用于处理特殊情况。假定函数只用于处理准备好的最大长度报文，且没有特殊情况：无IP选项，无特殊标志如SYN、FIN或URG。实际执行的约有多少行C代码？报文递交给`ip_output`之前会调用多少函数？
- 26.12 26.3节结尾的例子中，应用程序向连接写入100字节，接着又写入50字节。如果应用程序为两个缓存各调用一次`writenv`，而不是调用`write`两次，有何不同？如果两个缓存大小分别为200和300，而不是100和50，调用`writenv`时又有何不同？
- 26.13 在时间戳选项中发送的时间戳来自于全局变量`tcp_now`，它每500ms递增一次。修改TCP代码，使用更精确的时间戳值。

第27章 TCP的函数

27.1 引言

本章介绍多个TCP函数，它们为下两章进一步讨论TCP的输入打下了基础：

- `tcp_drain`是协议的资源耗尽处理函数，当内核的 mbuf用完时被调用。实际上，不做任何处理。
- `tcp_drop`发送RST来丢弃连接。
- `tcp_close`执行正常的TCP连接关闭操作：发送FIN，并等待协议要求的4次报文交换以终止连接。卷1的18.2节讨论了连接关闭时双方需要交换的4个报文。
- `tcp_mss`处理收到的MSS选项，并在TCP发送自己的MSS选项时计算应填入的MSS值。
- `tcp_ctlinput`在收到对应于某个TCP报文段的ICMP差错时被调用，它接着调用`tcp_notify`处理ICMP差错。`tcp_quench`专门负责处理ICMP的源站抑制差错。
- `TCP_REASS宏`和`tcp_reass`函数管理连接重组队列中的报文段。重组队列处理收到的乱序报文段，某些报文段还可能互相重复。
- `tcp_trace`向内核的TCP调试循环缓存中添加记录(插口选项`SO_DEBUG`)。运行`trpt(8)`程序可以打印缓存内容。

27.2 `tcp_drain`函数

`tcp_drain`是所有TCP函数中最简单的。它是协议的`pr_drain`函数，在内核的mbuf用完时，由`m_reclaim`调用。图10-32中，`ip_drain`丢弃其重组队列中的所有数据报分片，而UDP则不定义自己的资源耗尽处理函数。尽管TCP也占用mbuf——位于接收窗口内的乱序报文段——但Net/3实现的TCP并不丢弃这些mbuf，即使内核的mbuf已用完。相反，`tcp_drain`不做任何处理，假定收到的(但次序差错)的TCP报文段比IP分片重要。

27.3 `tcp_drop`函数

`tcp_drop`在整个系统中多次被调用，发送RST报文段以丢弃连接，并向应用进程返回差错。它与关闭连接(`tcp_disconnect`函数)不同，后者向对端发送FIN，并遵守TCP状态变迁图所规定的连接终止步骤。

图27-1列出了调用`tcp_drop`的7种情况和相应的`errno`参数。

图27-2给出了`tcp_drop`函数。

202-213 如果TCP收到了一个SYN，连接被同步，则必须向对端发送RST。`tcp_drop`把状态设为CLOSED，并调用`tcp_output`。从图24-16可知，CLOSED状态的`tcp_outflags`数组中包含RST标志。

214-216 如果`errno`等于ETIMEDOUT，且连接上曾收到过软差错(如EHOSTUNREACH)，

软差错代码将取代内容不确定的 ETIMEDOUT，做为返回的插口差错。

217 `tcp_close`结束插口关闭操作。

函数	errno	描述
<code>tcp_input</code>	<code>ENOBUFS</code>	监听服务器收到SYN，但内核无法为 <code>t_template</code> 分配所需的mbuf
<code>tcp_input</code>	<code>ECONNREFUSED</code>	收到的RST是对本地发送的SYN的响应
<code>tcp_input</code>	<code>ECONNRESET</code>	在现存连接上收到了RST
<code>tcp_timers</code>	<code>ETIMEDOUT</code>	重传定时器连续超时13次，仍未收到对端的ACK(图25-25)
<code>tcp_timers</code>	<code>ETIMEDOUT</code>	连接建立定时器超时(图25-16)，或者保活定时器超时，且连续9次发送窗口探测报文段，对方均无响应
<code>tcp_usrreq</code>	<code>ECONNABORTED</code>	<code>PRU_ABORT</code> 请求
<code>tcp_usrreq</code>	0	关闭插口，设定 <code>SO_LINGER</code> 选项，且拖延时间为0

图27-1 调用`tcp_drop` 函数和`errno` 参数

```

202 struct tcpcb *
203 tcp_drop(tp, errno)
204 struct tcpcb *tp;
205 int     errno;
206 {
207     struct socket *so = tp->t_inpcb->inp_socket;
208
209     if (TCPS_HAVERCVDSYN(tp->t_state)) {
210         tp->t_state = TCPS_CLOSED;
211         (void) tcp_output(tp);
212         tcpstat.tcps_drops++;
213     } else
214         tcpstat.tcps_conndrops++;
215     if (errno == ETIMEDOUT && tp->t_softerror)
216         errno = tp->t_softerror;
217     so->so_error = errno;
218     return (tcp_close(tp));
219 }

```

tcp_subr.c

图27-2 `tcp_drop` 函数

27.4 `tcp_close`函数

通常情况下，如果应用进程被动关闭，且在 LAST_ACK状态时收到了ACK，`tcp_input`将调用`tcp_close`关闭连接；或者当2MSL定时器超时，插口从 TIME_WAIT状态迁移到CLOSED状态时，`tcp_timers`也会调用`tcp_close`。它也可以在其他状态被调用，一种可能是发生了差错，如上一小节讨论过的情况。`tcp_close`释放连接占用的内存(IP和TCP首部模板、TCP控制块、Internet PCB和保存在连接重组队列中的所有乱序报文段)，并更新路由特性。

我们分3部分讲解这个函数，前两部分讨论路由特性，最后一部分介绍资源释放。

27.4.1 路由特性

`rt_metrics`结构(图18-26)中保存了9个变量，有6个用于TCP。其中8个变量可通过

route(8)命令读写(第9个, rmx_pkts未使用):图27-3列出了这些变量。此外,运行route命令时,加入-lock选项,可以设置rmx_locks成员变量(图20-13)中对应的RTV_xxx比特,告诉内核不要更新对应的路由参数。

关闭TCP插口时,如果下列条件满足:连接上传输的数据量足够生成有效的统计值,并且变量未被锁定,tcp_close将更新3个路由参数——已平滑的RTT估计器、已平滑的RTT平均偏差估计器和慢起动门限。

rt_metrics成员	tcp_close是否保存该成员	tcp_mss是否使用该成员	route(8)附加参数
rmx_expire			-expire
rmx_hopcount			-hopcount
rmx_mtu		•	-mtu
rmx_recvpipe		•	-recvpipe
rmx_rtt	•	•	-rtt
rmx_rttvar	•	•	-rttvar
rmx_sendpipe		•	-sendpipe
rmx_ssthresh	•	•	-ssthresh

图27-3 TCP用到的rt_metrics 结构中的变量

图27-4给出了tcp_close的第一部分。

1. 判断是否发送了足够的数据量

234-248 默认的发送缓存大小为8192字节(sb_hiwat),因此首先比较初始发送序号和连接上已发送的最大序号,测试是否已传输了131 072字节(16个完整的缓存)的数据。此外,插口还必须有一条非默认路由的缓存路由(参见习题19.2)。

请注意,如果传输的数据量在 $N \times 2^{32}(N>1)$ 和 $N \times 2^{32}+131072(N>1)$ 之间,则因为序号可能回绕,比较时也许会出现问题,尽管可能性不大。但目前很少有连接会传输4 G的数据。

尽管Internet上存在大量的默认路由,缓存路由对于维护有效的路由表还是很有用的。如果主机长期与另外某个主机(或网络)交换数据,即使默认路由可用,也应运行route命令向路由表中添加源站选路和目的选路的路由,从而在整条连接上维护有效的路由信息(参见习题19.2)。这些信息在系统重启时丢失。

250 管理员可以锁定图27-3中的变量,防止内核修改它们。因此,代码在更新这些变量之前,必须先检查其锁定状态。

2. 更新RTT

251-264 t_srtt的单位为8个滴答(图25-19),而rmx_rtt的单位为微秒。因此,首先必须实现单位换算,t_srtt乘以1 000 000(RTM_RTTUNIT),除以2(滴答/秒)再乘以8,得到RTT的最新值。如果rmx_rtt值已存在,它被更新为最新值与原有值和的一半,即两者的平均值。如果不存在,最新值将直接赋给rmx_rtt变量。

3. 更新平均偏差

265-273 更新平均偏差的算法与更新RTT的类似,也需要把单位为4个滴答的t_rttvar换算为以微秒为单位。

```

225 struct tcpcb *
226 tcp_close(tp)
227 struct tcpcb *tp;
228 {
229     struct tcphdr *t;
230     struct inpcb *inp = tp->t_inpcb;
231     struct socket *so = inp->inp_socket;
232     struct mbuf *m;
233     struct rtentry *rt;
234
235     /* If we sent enough data to get some meaningful characteristics,
236      * save them in the routing entry. 'Enough' is arbitrarily
237      * defined as the sendpipesize (default 8K) * 16. This would
238      * give us 16 rtt samples assuming we only get one sample per
239      * window (the usual case on a long haul net). 16 samples is
240      * enough for the srtt filter to converge to within 5% of the correct
241      * value; fewer samples and we could save a very bogus rtt.
242      */
243
244     /* Don't update the default route's characteristics and don't
245      * update anything that the user "locked".
246      */
247     if (SEQ_LT(tp->iss + so->so_snd.sb_hiwat * 16, tp->snd_max) &&
248         (rt = inp->inp_route.ro_rt) &&
249         ((struct sockaddr_in *) rt_key(rt))->sin_addr.s_addr != INADDR_ANY) {
250         u_long i;
251
252         if ((rt->rt_rmx.rmx_locks & RTV_RTT) == 0) {
253             i = tp->t_srtt *
254                 (RTM_RTTUNIT / (PR_SLOWHZ * TCP_RTT_SCALE));
255             if (rt->rt_rmx.rmx_rtt && i)
256                 /*
257                  * filter this update to half the old & half
258                  * the new values, converting scale.
259                  * See route.h and tcp_var.h for a
260                  * description of the scaling constants.
261                  */
262                 rt->rt_rmx.rmx_rtt =
263                     (rt->rt_rmx.rmx_rtt + i) / 2;
264             else
265                 rt->rt_rmx.rmx_rtt = i;
266         }
267         if ((rt->rt_rmx.rmx_locks & RTV_RTTVAR) == 0) {
268             i = tp->t_rttvar *
269                 (RTM_RTTUNIT / (PR_SLOWHZ * TCP_RTTVAR_SCALE));
270             if (rt->rt_rmx.rmx_rttvar && i)
271                 rt->rt_rmx.rmx_rttvar =
272                     (rt->rt_rmx.rmx_rttvar + i) / 2;
273             else
274                 rt->rt_rmx.rmx_rttvar = i;
275         }

```

*tcp_subr.c*图27-4 *tcp_close* 函数：更新RTT和平均偏差

图27-5给出了*tcp_close*的下一部分代码，更新路由的慢起动门限。

274-283 满足下列条件时，慢起动门限被更新：(1)它被更新过(*rmx_ssthresh*非零)；(2)管理员规定了*rmx_sendpipe*，而*snd_ssthresh*的最新值小于*rmx_sendpipe*的一半。如同代码注释中指出的，TCP不会更新*rmx_ssthresh*值，除非因为数据分组丢失而不得不

这样做。从这个角度出发，除非十分必要，TCP不会修改门限值。

```

274     /*
275      * update the pipelimit (ssthresh) if it has been updated
276      * already or if a pipesize was specified & the threshold
277      * got below half the pipesize. I.e., wait for bad news
278      * before we start updating, then update on both good
279      * and bad news.
280     */
281     if ((rt->rt_rmx.rmx_locks & RTV_SSTHRESH) == 0 &&
282         (i = tp->snd_ssthresh) && rt->rt_rmx.rmx_ssthresh ||
283         i < (rt->rt_rmx.rmx_sendpipe / 2)) {
284     /*
285      * convert the limit from user data bytes to
286      * packets then to packet data bytes.
287     */
288     i = (i + tp->t_maxseg / 2) / tp->t_maxseg;
289     if (i < 2)
290         i = 2;
291     i *= (u_long) (tp->t_maxseg + sizeof(struct tciphdr));
292     if (rt->rt_rmx.rmx_ssthresh)
293         rt->rt_rmx.rmx_ssthresh =
294             (rt->rt_rmx.rmx_ssthresh + i) / 2;
295     else
296         rt->rt_rmx.rmx_ssthresh = i;
297     }
298 }
```

tcp_subr.c

图27-5 tcp_close 函数：更新慢启动门限

284-290 变量snd_ssthresh以字节为单位，除以MSS(t_maxseg)得到报文段数，加上 $1/2t_maxseg$ 是为了保证总报文段容量必定大于 snd_ssthresh字节。报文段数的下限为2个报文段。

291-297 MSS加上IP和TCP首部大小(40)，再乘以报文段数，利用得到的结果来更新rmx_ssthresh，采用的算法与图27-4中的相同(新值的1/2加上原有值的1/2)。

27.4.2 资源释放

图27-6给出了tcp_close的最后一部分，释放插口占用的内存资源。

```

299     /* free the reassembly queue, if any */
300     t = tp->seg_next;
301     while (t != (struct tciphdr *) tp) {
302         t = (struct tciphdr *) t->ti_next;
303         m = REASS_MBUF((struct tciphdr *) t->ti_prev);
304         remque(t->ti_prev);
305         m_free(m);
306     }
307     if (tp->t_template)
308         (void) m_free(dtom(tp->t_template));
309     free(tp, M_PCB);
310     inp->inp_ppcb = 0;
```

图27-6 tcp_close 函数：释放连接资源

```

311     soisdisconnected(so);
312     /* clobber input pcb cache if we're closing the cached connection */
313     if (inp == tcp_last_inpcb)
314         tcp_last_inpcb = &tcb;
315     in_pcbdetach(inp);
316     tcpstat.tcps_closed++;
317     return ((struct tcpcb *) 0);
318 }

```

tcp_subr.c

图27-6 (续)

1. 释放重组队列占用的 mbuf

299-306 如果连接重组队列中还有报文段，则丢弃它们。重组队列用于存放收到位于接收窗口内、但次序差错的报文段。在等待接收的正常序列报文段到达之前，它们会一直保存在重组队列中；之后，报文段被重组并递交给应用程序。27.9节会详细讨论这一过程。

2. 释放首部模板和TCP控制块

307-309 调用 `m_free` 释放 IP 和 TCP 首部模板，调用 `free` 释放 TCP 控制块，调用 `sodisconnected` 发送 PRU_DISCONNECT 请求，标记插口已断开连接。

3. 释放PCB

310-318 如果插口的 Internet PCB 保存在 TCP 的高速缓存中，则把 TCP 的 PCB 链表表头赋给 `tcp_last_inpcb`，以清空缓存。接着调用 `in_pcbdetach` 释放 PCB 占用的内存。

27.5 tcp_mss函数

`tcp_mss` 被两个函数调用：

1) `tcp_output`，准备发送 SYN 时调用，以添加 MSS 选项；

2) `tcp_input`，收到的 SYN 报文段中包含 MSS 选项时调用；

`tcp_mss` 函数检查到达目的地的缓存路由，计算用于该连接的 MSS。

图27-7给出了`tcp_mss`第一部分的代码，如果 PCB 中没有到达目的地的路由，则设法得到所需的路由。

```

1391 int
1392 tcp_mss(tp, offer)
1393 struct tcpcb *tp;
1394 u_int    offer;
1395 {
1396     struct route *ro;
1397     struct rtentry *rt;
1398     struct ifnet *ifp;
1399     int        rtt, mss;
1400     u_long    bufsize;
1401     struct inpcb *inp;
1402     struct socket *so;
1403     extern int tcp_mssdflt;

1404     inp = tp->t_inpcb;
1405     ro = &inp->inp_route;
1406     if ((rt = ro->ro_rt) == (struct rtentry *) 0) {

```

图27-7 `tcp_mss` 函数：如果 PCB 中没有路由，则设法得到所需路由

```

1407     /* No route yet, so try to acquire one */
1408     if (inp->inp_faddr.s_addr != INADDR_ANY) {
1409         ro->ro_dst.sa_family = AF_INET;
1410         ro->ro_dst.sa_len = sizeof(ro->ro_dst);
1411         ((struct sockaddr_in *) &ro->ro_dst)->sin_addr =
1412             inp->inp_faddr;
1413         rtalloc(ro);
1414     }
1415     if ((rt = ro->ro_rt) == (struct rtentry *) 0)
1416         return (tcp_mssdfilt);
1417     }
1418     ifp = rt->rt_ifp;
1419     so = inp->inp_socket;

```

tcp_input.c

图27-7 (续)

1. 如果需要，就获取路由

1391-1417 如果插口没有高速缓存路由，则调用 `rtalloc` 得到一条。与外出路由相关的接口指针存储在 `ifp` 中。外出接口是非常重要的，因为其 MTU 会影响 TCP 通告的 MSS。如果无法得到所需路由，函数就立即返回默认值 512 (`tcp_mssdfilt`)。

图27-8给出了`tcp_mss`的下一部分代码，判断得到的路由是否有相应的参数表。如果有，则变量`t_rttmin`、`t_srtt`和`t_rttvar`将初始化为参数表中的对应值。

```

1420     /*
1421      * While we're here, check if there's an initial rtt
1422      * or rttvar. Convert from the route-table units
1423      * to scaled multiples of the slow timeout timer.
1424      */
1425     if (tp->t_srtt == 0 && (rtt = rt->rt_rmx.rmx_rtt)) {
1426         /*
1427          * XXX the lock bit for RTT indicates that the value
1428          * is also a minimum value; this is subject to time.
1429          */
1430         if (rt->rt_rmx.rmx_locks & RTV_RTT)
1431             tp->t_rttmin = rtt / (RTM_RTTUNIT / PR_SLOWHZ);
1432             tp->t_srtt = rtt / (RTM_RTTUNIT / (PR_SLOWHZ * TCP_RTT_SCALE));

1433         if (rt->rt_rmx.rmx_rttvar)
1434             tp->t_rttvar = rt->rt_rmx.rmx_rttvar /
1435                 (RTM_RTTUNIT / (PR_SLOWHZ * TCP_RTTVAR_SCALE));
1436         else
1437             /* default variation is +- 1 rtt */
1438             tp->t_rttvar =
1439                 tp->t_srtt * TCP_RTTVAR_SCALE / TCP_RTT_SCALE;

1440             TCPT_RANGESET(tp->t_rxcur,
1441                             ((tp->t_srtt >> 2) + tp->t_rttvar) >> 1,
1442                             tp->t_rttmin, TCPTV_REXMTMAX);
1443     }

```

tcp_input.c

图27-8 `tcp_mss` 函数：判断路由是否有相应的 RTT 参数表

2. 初始化已平滑的 RTT 估计器

1420-1432 如果连接上不存在 RTT 样本值(`t_srtt=0`)，并且 `rmx_rtt` 非零，则将后者赋

给已平滑的RTT估计器`t_srtt`。如果路由参数表锁定标志的`RTV_RTT`比特置位，表明连接的最小RTT(`t_rttmin`)也应初始化为`rmx_rtt`。前面介绍过，`tcp_newtcpcb`把`t_rttmin`初始化为2个滴答。

`rmx_rtt`(以微秒为单位)转换为`t_srtt`(以8个滴答为单位)，这是图27-4的反变换。注意，`t_rttmin`等于`t_srtt`的1/8，因为前者没有除以缩放因子`TCP_RTT_SCALE`。

3. 初始化已平滑的RTT平均偏差估计器

1433-1439 如果存储的`rmx_rttvar`(以微秒为单位)值非零，将其转换为`t_rttvar`(以4个滴答为单位)。但如果为零，则`t_rttvar`等于`t_rtt`，即偏差等于均值。已平滑的RTT平均偏差估计器默认设置为±1 RTT。由于`t_rttvar`的单位为4个滴答，而`t_rtt`的单位为8个滴答，`t_srtt`值也必须做相应转换。

4. 计算初始RTO

1440-1442 计算当前的RTO，并存储在`t_rxcur`中，采用下列算式更新：

$$RTO = srtt + 2 \times rttvar$$

计算第一个RTO时，乘数取2，而非4，上式与图25-21中用到的算式相同。将缩放关系代入，得到：

$$RTO = \frac{t_{srtt}}{8} + 2 \times \frac{t_{rttvar}}{4} = \frac{\frac{t_{srtt}}{4} + t_{rttvar}}{2}$$

即为TCPPT_RANGESET的第二个参数。

图27-9给出了`tcp_mss`的下一部分，计算MSS。

```
1444  /*
1445   * if there's an mtu associated with the route, use it
1446   */
1447   if (rt->rt_rmx.rmx_mtu)
1448     mss = rt->rt_rmx.rmx_mtu - sizeof(struct tciphdr);
1449   else {
1450     mss = ifp->if_mtu - sizeof(struct tciphdr);
1451 #if (MCLBYTES & (MCLBYTES - 1)) == 0
1452     if (mss > MCLBYTES)
1453       mss &= ~(MCLBYTES - 1);
1454 #else
1455     if (mss > MCLBYTES)
1456       mss = mss / MCLBYTES * MCLBYTES;
1457 #endif
1458     if (!in_localaddr(inp->inp_faddr))
1459       mss = min(mss, tcp_mssdflt);
1460   }
```

tcp_input.c

tcp_input.c

图27-9 `tcp_mss` 函数：计算mss

5. 从路由表中的MTU得到MSS

1444-1450 如果路由表中的MTU有值，则将其赋给`mss`。如果没有，则`mss`初始值等于外出接口的MTU值减去40(IP和TCP首部默认值)。对于以太网，MSS初始值应为1460。

6. 减小MSS，令其等于MCLBYTES的倍数

1451-1457 如果`mss`大于`MCLBYTES`，则减小`mss`的值，令其等于最接近的

MCLBYTES(mbuf簇大小)的整数倍。如果 MCLBYTES 值(通常等于 1024 或 2048)与 MCLBYTES 值减 1 逻辑与后等于 0，说明 MCLBYTES 等于 2 的倍数。例如，1024(0x400)逻辑与 1023(0x3ff) 等于 0。

代码通过清零 mss 的若干低位比特，将 mss 减小到最接近的 MCLBYTES 的倍数：如果 mbuf 簇大小为 1024，mss 与 1023 的二进制补码(0xfffffffcc00)逻辑与，低位的 10 bit 被清零。对于以太网，mss 将从 1460 减至 1024。如果 mbuf 簇大小为 2048，与 2047 的二进制补码(0xfffffff8000)逻辑与，低位的 11 bit 被清零。对于令牌环，MTU 大小为 4464，上述运算将 mss 从 4424 减为 4096。如果 MCLBYTES 不是 2 的倍数，代码用 mss 整数除以 MCLBYTES 后，再乘上 MCLBYTES，从而将 mss 减小到最接近的 MCLBYTES 的倍数。

7. 判断目的地是本地地址还是远端地址

1458-1459 如果目的 IP 不是本地地址(`in_localaddr` 返回零)，且 mss 大于 512(`tcp_mssdflt`)，则将 mss 设为 512。

IP 地址是否为本地地址取决于全局变量 `subnetsarelocal`，内核编译时把符号变量 `SUBNETSARELOCAL` 的值赋给它。默认值为 1，意味着如果给定 IP 地址与主机任一接口的 IP 地址具有相同的网络 ID，则被认为是一个本地地址。如果为 0，则给定 IP 地址必须与主机任一接口的 IP 地址具有相同的网络号和子网号，才会被认为是一个本地地址。

对于非本地地址，将 MSS 最小化是为了避免 IP 数据报经广域网时被分片。绝大多数 WAN 链路的 MTU 只有 1006，这是从 ARPANET 遗留下来的一个问题。在卷 1 的 11.7 节中讨论过，现代的多数 WAN 支持 1500，甚至更大的 MTU。感兴趣的读者还可阅读卷 1 的 24.2 节中讨论的路由 MTU 发现特性(RFC 1191，[Mogul and Deering 1990])。Net/3 不支持路由 MTU 发现。

图 27-10 给出了 `tcp_mss` 最后一部分的代码。

8. 对端的 MSS 用作上限

1461-1472 如果 `tcp_mss` 被 `tcp_input` 调用，参数 `offer` 非零，等于对端通告的 `mss` 值。如果 `mss` 大于对端通告的值，则将 `offer` 赋给它。例如，如果函数计算得到的 `mss` 等于 1024，但对端通告的值只有 512，则 `mss` 必须被设定为 512。相反，如果 `mss` 等于 536(即输出 MTU 等于 576)，而对端通告的值为 1460，TCP 仍旧使用 536。只要不超过对端通告的值，`mss` 可以取小于它的任何一个值。如果 `tcp_mss` 被 `tcp_output` 调用，`offer` 等于 0，用于发送 MSS 选项。注意，尽管 `mss` 的上限可变，其下限固定为 32。

1473-1483 如果 `mss` 小于 `tcp_newtcpcb` 中设定的默认值 `t_maxseg`(512)，或者如果 TCP 正在处理收到的 MSS 选项(`offer` 非零)，则需执行下列步骤。首先，如果路由的 `rmx_sendpipe` 有值，则采用它作为发送缓存的高端(high-water)标志(图 16-4)。如果缓存小于 `mss`，则使用较小的值。除非是应用程序有意把发送缓存定得很小，或者管理员将 `rmx_sendpipe` 定得很小，这种情况一般不会发生，因为发送缓存的上限默认值为 8192，大于绝大多数的 `mss`。

9. 增加缓存大小，令其等于最近的 MSS 整数倍

1484-1489 增加缓存大小，令其等于最近的 `mss` 整数倍，上限为 `sb_max`(Net/3 中定义为 262 144，即 256×1024)。插口发送缓存的上限设定为 `sbreserve`。例如，上限默认值等于

8192，但对于以太网上的本地TCP传输，其mbuf簇大小为2048(假定mss等于1460)，代码把上限值增加到8760(等于 6×1460)。但对于非本地的连接，mss等于512，上限值保持8192不变。

tcp_input.c

```

1461  /*
1462   * The current mss, t_maxseg, was initialized to the default value
1463   * of 512 (tcp_mssdfult) by tcp_newtcpcb().
1464   * If we compute a smaller value, reduce the current mss.
1465   * If we compute a larger value, return it for use in sending
1466   * a max seg size option, but don't store it for use
1467   * unless we received an offer at least that large from peer.
1468   * However, do not accept offers under 32 bytes.
1469   */
1470  if (offer)
1471      mss = min(mss, offer);
1472  mss = max(mss, 32);           /* sanity */
1473  if (mss < tp->t_maxseg || offer != 0) {
1474      /*
1475       * If there's a pipesize, change the socket buffer
1476       * to that size. Make the socket buffers an integral
1477       * number of mss units; if the mss is larger than
1478       * the socket buffer, decrease the mss.
1479       */
1480  if ((bufsize = rt->rt_rmx.rmx_sendpipe) == 0)
1481      bufsize = so->so_snd.sb_hiwat;
1482  if (bufsize < mss)
1483      mss = bufsize;
1484  else {
1485      bufsize = roundup(bufsize, mss);
1486      if (bufsize > sb_max)
1487          bufsize = sb_max;
1488      (void) sbreserve(&so->so_snd, bufsize);
1489  }
1490  tp->t_maxseg = mss;
1491  if ((bufsize = rt->rt_rmx.rmx_recvpipe) == 0)
1492      bufsize = so->so_rcv.sb_hiwat;
1493  if (bufsize > mss) {
1494      bufsize = roundup(bufsize, mss);
1495      if (bufsize > sb_max)
1496          bufsize = sb_max;
1497      (void) sbreserve(&so->so_rcv, bufsize);
1498  }
1499 }
1500 tp->snd_cwnd = mss;
1501 if (rt->rt_rmx.rmx_ssthresh) {
1502     /*
1503      * There's some sort of gateway or interface
1504      * buffer limit on the path. Use this to set
1505      * the slow start threshold, but set the
1506      * threshold to no less than 2*mss.
1507      */
1508     tp->snd_ssthresh = max(2 * mss, rt->rt_rmx.rmx_ssthresh);
1509 }
1510 return (mss);
1511 }
```

tcp_input.c

图27-10 tcp_mss 函数：结束处理

1490 由于t_maxseg已小于默认值(512)，或者由于收到了对端发送的MSS选项，所以应更

新它。

1491-1499 对接收缓存的处理与发送缓存相同。

10. 初始化拥塞窗口和慢起动门限

1500-1509 拥塞窗口的值，`snd_cwnd`，等于一个最大报文段长度。如果路由表中的`rmx_ssthresh`非零，慢起动门限(`snd_ssthresh`)初始化为该值，但应保证其下限为两个最大报文段长度。

1510 函数最后返回mss。`tcp_input`忽略这一返回值(图28-10，因为它已收到对端的MSS选项)，但图26-23中，`tcp_output`将它用作MSS通告。

举例

下面通过一个连接建立的实例说明 `tcp_mss` 的操作过程。连接建立过程中，它会被调用两次：发送SYN时和收到对端带有MSS选项的SYN时。

1) 创建插口，`tcp_newtcpcb`初始化`t_maxseg`为512。

2) 应用进程调用 `connect`。为了在SYN报文段中加入MSS选项，`tcp_output`调用`tcp_mss`，参数`offer`等于零。假定目的IP为本地以太网地址，mbuf簇大小为2048，执行图27-9中的代码后，`mss`等于1460。由于`offer`等于零，图27-10中的代码不修改`mss`值，函数返回1460。因为1460大于默认值(512)而且未收到对端的MSS选项，缓存大小不变。`tcp_output`发送MSS选项，通告MSS大小为1460。

3) 对端发送响应SYN，通告`mss`大小为1024。`tcp_input`调用`tcp_mss`，参数`offer`等于1024。图27-9的代码逻辑仍旧设定`mss`为1460，但在图27-10起始处的`min`语句将`mss`减小为1024。因为`offer`非零，缓存大小增加至最近的1024的整数倍(等于8192)。`t_maxseg`更新为1024。

初看上去，`tcp_mss`的逻辑存在问题：TCP向对端通告`mss`大小为1460，之后从对端收到的`mss`只有1024。尽管TCP只能发送1024字节的报文段，对端却能够发送1460字节的报文段。读者可能会认为发送缓存应等于1024的倍数，而接收缓存则应等于1460的倍数。但图27-10中的代码却将两个缓存大小都设为对端通告的`mss`的倍数。这是因为尽管TCP通告`mss`为1460，但对端通告的`mss`仅为1024，对端有可能不会发送1460字节的报文段，而将发送报文段限制为1024字节。

27.6 `tcp_ctlinput`函数

回想图22-32中，`tcp_ctlinput`处理5种类型的ICMP差错：目的地不可达、数据报参数错、源站抑制、数据报超时和重定向。所有重定向差错会上交给相应的TCP或UDP进行处理。

对于其他4种差错，仅当它们是被TCP报文段引发的，才会调用`tcp_ctlinput`进行处理。

图27-11给出了`tcp_ctlinput`函数，它与图23-30的`udp_ctlinput`函数类似。

365-366 在逻辑上，`tcp_ctlinput`与`udp_ctlinput`的唯一区别是如何处理ICMP源站抑制差错。因为`inetctllerrmap`等于0，UDP忽略源站抑制差错。TCP检查源站抑制差错，并把`notify`函数的默认值`tcp_notify`改为`tcp_quench`。

tcp_subr.c

```

355 void
356 tcp_ctlinput(cmd, sa, ip)
357 int cmd;
358 struct sockaddr *sa;
359 struct ip *ip;
360 {
361     struct tcphdr *th;
362     extern struct in_addr zeroin_addr;
363     extern u_char inetctllerrmap[];
364     void (*notify) (struct inpcb *, int) = tcp_notify;

365     if (cmd == PRC_QUENCH)
366         notify = tcp_quench;
367     else if (!PRC_IS_REDIRECT(cmd) &&
368             ((unsigned) cmd > PRC_NCMDS || inetctllerrmap[cmd] == 0))
369         return;
370     if (ip) {
371         th = (struct tcphdr *) ((caddr_t) ip + (ip->ip_hl << 2));
372         in_pcbnotify(&tcb, sa, th->th_dport, ip->ip_src, th->th_sport,
373                     cmd, notify);
374     } else
375         in_pcbnotify(&tcb, sa, 0, zeroin_addr, 0, cmd, notify);
376 }

```

*tcp_subr.c*图27-11 *tcp_ctlinput* 函数

27.7 *tcp_notify*函数

*tcp_notify*被*tcp_ctlinput*调用，处理目的地不可达、数据报参数错、数据报超时和重定向差错。与 UDP的差错处理函数相比，它要复杂得多，因为 TCP必须灵活地处理连接上收到的各种软差错。图 27-12给出了*tcp_notify*函数。

tcp_subr.c

```

328 void
329 tcp_notify(inp, error)
330 struct inpcb *inp;
331 int error;
332 {
333     struct tcpcb *tp = (struct tcpcb *) inp->inp_ppcb;
334     struct socket *so = inp->inp_socket;

335     /*
336      * Ignore some errors if we are hooked up.
337      * If connection hasn't completed, has retransmitted several times,
338      * and receives a second error, give up now. This is better
339      * than waiting a long time to establish a connection that
340      * can never complete.
341      */
342     if (tp->t_state == TCPS_ESTABLISHED &&
343         (error == EHOSTUNREACH || error == ENETUNREACH ||
344          error == EHOSTDOWN)) {
345         return;
346     } else if (tp->t_state < TCPS_ESTABLISHED && tp->t_rxtshift > 3 &&
347                 tp->t_softerror)
348         so->so_error = error;
349 }

```

图27-12 *tcp_notify* 函数

```

349     else
350         tp->t_softerror = error;
351         wakeup((caddr_t) & so->so_timeo);
352         sorwakeups(so);
353         sowakeup(so);
354 }

```

tcp_subr.c

图27-12 (续)

328-345 如果连接状态为 ESTABLISHED，则忽略 EHOSTUNREACH、ENETUNREACH 和 EHOSTDOWN 差错代码。

处理这3个差错是4.4BSD中新增的功能。Net/2及早期版本在连接的软差错变量 (*t_softerror*) 中记录这些差错，如果连接最终失败，则向应用进程返回相应的差错码。回想一下，*tcp_xmit_timer* 在收到一个 ACK，确认未发送过的报文段时，复位 *t_softerror* 为零。

346-353 如果连接还未建立，而且 TCP 已经至少4次重传了当前报文段，*t_softerror* 中已存在差错记录，则最新的差错将被保存在插口的 *so_error* 变量中，从而应用进程可以调用 *select* 对插口进行读写。如果上述条件不满足，当前差错将仍旧保存在 *t_softerror* 中。我们在 *tcp_drop* 函数中讨论过，如果连接最终由于超时而被丢弃，*tcp_drop* 会把 *t_softerror* 赋给插口差错变量 *errno*。任何在插口上等待接收或发送数据的应用进程会被唤醒，并得到相应的差错代码。

27.8 *tcp_quench* 函数

tcp_quench 的函数代码在图 27-13 中给出。TCP 在两种情况下调用它：当连接上收到源站抑制差错时，由 *tcp_input* 调用。当 *ip_output* 返回 ENOBUFS 差错代码时，由 *tp_output* 调用。

```

381 void
382 tcp_quench(inp, errno)
383 struct inpcb *inp;
384 int      errno;
385 {
386     struct tcpcb *tp = intotcpcb(inp);
387     if (tp)
388         tp->snd_cwnd = tp->t_maxseg;
389 }

```

*tcp_subr.c*图27-13 *tcp_quench* 函数

拥塞窗口设定为最大报文段长度，强迫 TCP 执行慢起动。慢起动门限不变（与 *tcp_timers* 处理重传超时的思想相同），因此，窗口大小将成指数地增加，直至达到 *snd_ssthresh* 门限或发生拥塞。

27.9 *TCP_REASS* 宏和 *tcp_reass* 函数

TCP 报文段有可能乱序到达，因此，在数据上交给应用进程之前，TCP 必须设法恢复正确

的报文段次序。例如，如果接收方的接收窗口大小为4096，等待接收的下一个序号为0。收到的第一个报文段携带0~1023字节的数据(次序正确)，第二个报文段携带了2048~3071字节的数据，很明显，第二个报文段到达的次序差错。如果乱序报文段位于接收窗口内，TCP并不丢弃它，而是将其保存在连接的重组队列中，继续等待中间缺失的报文段(携带1024~2047字节的报文段)。这一节我们将讨论处理TCP重组队列的代码，为后两章讨论tcp_input打下基础。

如果假定某个mbuf中包含IP首部、TCP首部和4字节的用户数据(回想图2-14的左半部分)，如图27-14所示。此外还假定数据的序号依次为7、8、9和10。

图24-12中定义的tcpiphdr结构里包含了ipovly和tcpiphdr两个结构，tcpiphdr结构在图24-12中给出。图27-14只列出了与重组有关的一些变量：ti_next、ti_prev、ti_len、ti_dport和ti_seq。头两个指针指向由给定连接所有乱序报文段组成的双向链表。链表头保存在连接的TCP控制块中：结构的头两个成员变量为seg_next和seg_prev。ti_next和ti_prev指针与IP首部的头8个字节重复，只要数据报到达了TCP，就不再需要这些内容。ti_len等于TCP数据的长度，TCP计算检验和之前首先计算并存储这个字段。

27.9.1 TCP_REASS宏

tcp_input收到数据后，就调用图27-15中的宏TCP_REASS，把数据放入连接的重组队列。TCP_REASS只在一种情况下被调用：参见图29-22。

54-63 tp是指向连接TCP控制块的指针，ti是指接报文段的tcpiphdr结构的指针。如果下列3个条件均为真：

- 1) 报文段到达次序正确(序号ti_seq等于连接上等待接收的下一序号，rcv_nxt)；并且
- 2) 连接的重组队列为空(seg_next指向自己，而不是某个mbuf)；并且
- 3) 连接处于ESTABLISHED状态。

则执行下列步骤：设定延迟ACK标志；更新rcv_nxt，增加报文段携带的数据长度；如果报文段TCP首部中FIN标志置位，则flags参数中增加TH_FIN标志；更新两个统计值；数据放入插口的接收缓存；唤醒所有在插口上等待接收的应用进程。

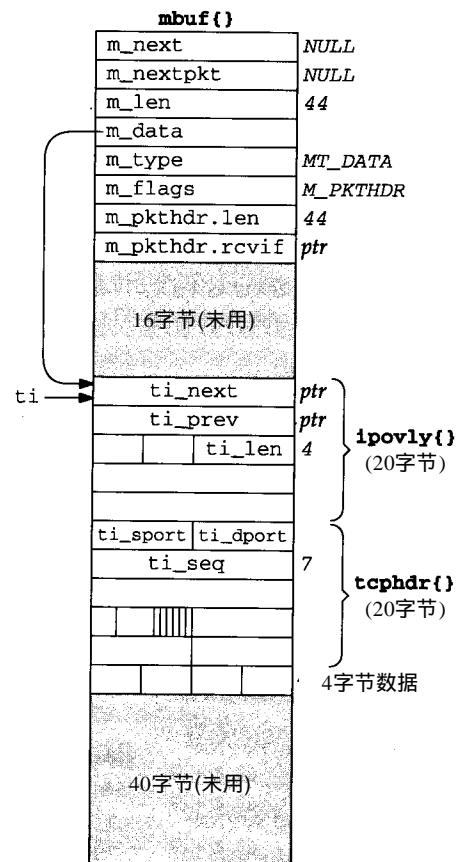


图27-14 举例：带有4字节数据的IP和TCP首部

```

53 #define TCP_REASS(tp, ti, m, so, flags) { \
54     if ((ti)->ti_seq == (tp)->rcv_nxt && \
55         (tp)->seg_next == (struct tciphdr *) (tp) && \
56         (tp)->t_state == TCPS_ESTABLISHED) { \
57         tp->t_flags |= TF_DELACK; \
58         (tp)->rcv_nxt += (ti)->ti_len; \
59         flags = (ti)->ti_flags & TH_FIN; \
60         tcpstat.tcps_rcvpack++; \
61         tcpstat.tcps_rcvbyte += (ti)->ti_len; \
62         sbappend(&(so)->so_rcv, (m)); \
63         sorwakeup(so); \
64     } else { \
65         (flags) = tcp_reass((tp), (ti), (m)); \
66         tp->t_flags |= TF_ACKNOW; \
67     } \
68 }

```

tcp_input.c

图27-15 TCP_REASS 宏：向连接的重组队列中添加数据

必须满足前述3个条件的原因是：首先，如果数据次序差错，则必须将其放入重组队列，直至收到了中间缺失的报文段，才能把数据提交给应用进程。第二，即使当前数据到达次序正确，但如果重组队列中已存在乱序数据，则新的数据有可能就是所需的缺失数据，从而能够向应用进程同时提交多个报文段中的数据；第三，尽管允许请求建立连接的 SYN报文段中携带数据，但这些数据在连接进入 ESTABLISHED状态之前，必须保存在重组队列中，不允许直接提交给应用进程。

64-67 如果这3个条件不是同时满足，则TCP_REASS宏调用TCP_REASS函数，向重组队列中添加数据。由于收到的报文段如果不是乱序报文段，就有可能是所需的缺失报文段，因此，置位TF_ACKNOW，要求立即发送ACK。TCP的一个重要特性是收到乱序报文段时，必须立即发送ACK，这有助于快速重传算法(29.4节)的实现。

在讨论TCP_REASS函数代码之前，需要先了解图 27-14中TCP首部的两个端口号，*ti_sport*和*ti_dport*，所起的作用。其实，只要找到了TCP控制块并调用了TCP_REASS，就不再需要它们了。因此，TCP报文段放入重组队列时，可以把对应mbuf的地址存储在这两个端口号变量中。对于图 27-14中的报文段，无需这样做，因为IP和TCP的首部都存储在mbuf的数据部分，可直接使用*dtom*宏。但我们在2.6节讨论*m_pullup*时曾指出，如果IP和TCP的首部保存在簇中(如图2-16所示，对于最大长度报文这是很正常的)，*dtom*宏将无法使用。我们在该节中曾提到，TCP把从TCP首部指向mbuf的后向指针(back pointer)存储在TCP的两个端口号字段中。

图27-16举例说明了这一技术的用法，利用它处理连接上的两个乱序报文段，每个报文段都存储在一个mbuf簇中。乱序报文段双向链表的表头是连接的TCP控制块中的*seg_next*成员变量。为简化起见，图中未标出*seg_prev*指针和指向链表最后一个报文段的*ti_next*指针。

接收窗口等待接收的下一个序号为1(*rcv_nxt*)，但我们假定这个报文段丢失了。接着又收到了两个报文段，携带1461~4380字节的数据，这是两个乱序报文段。TCP调用*m_devget*把它们放入mbuf簇中，如图2-16所示。

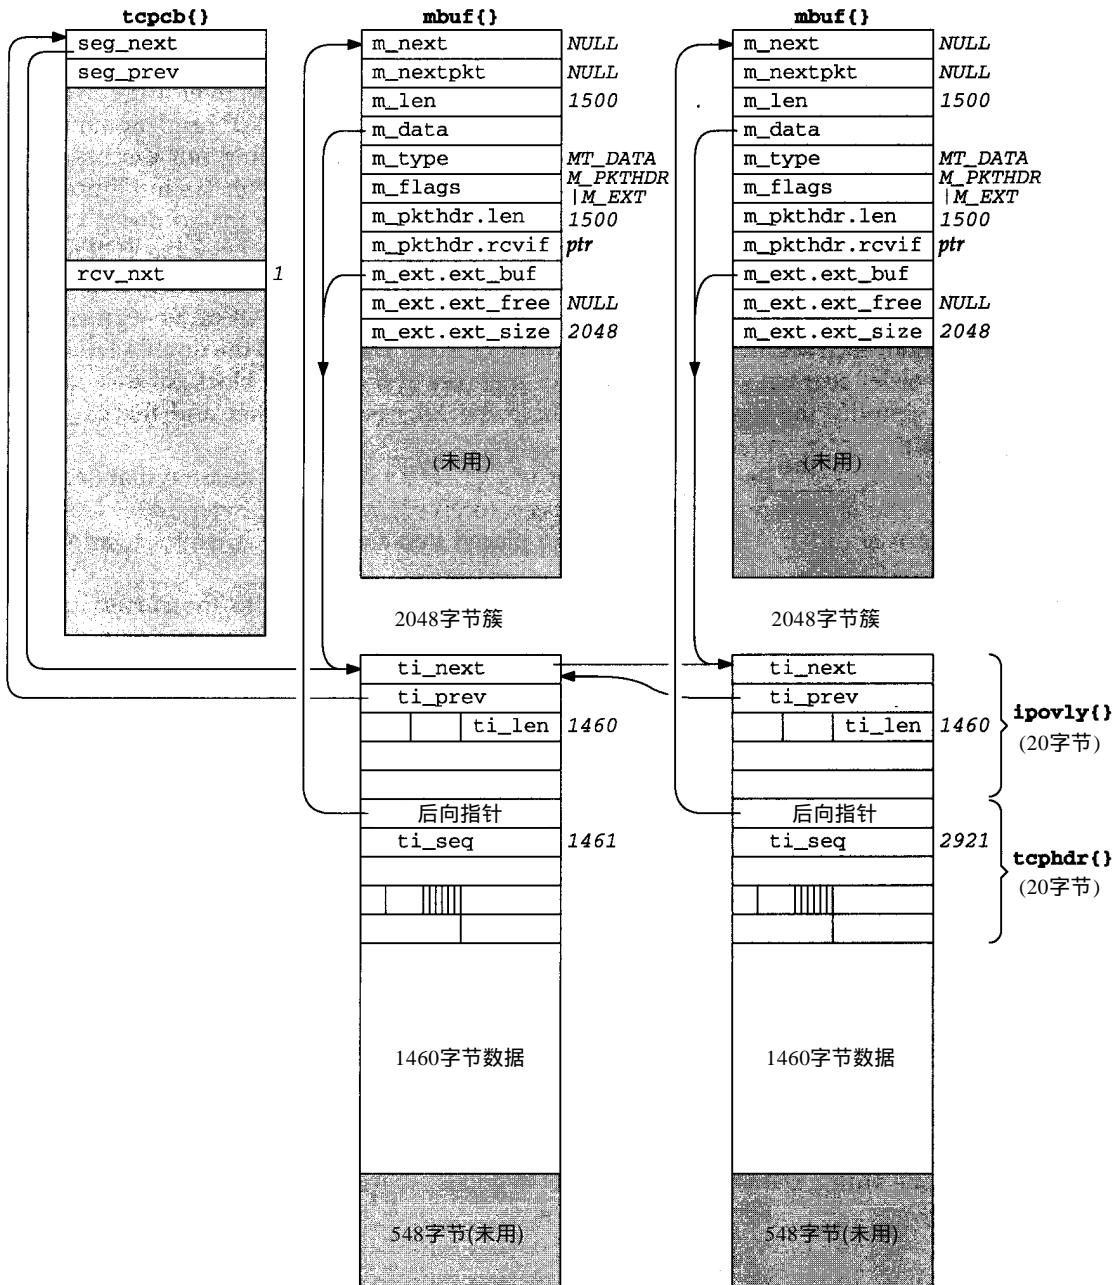


图27-16 两个乱序TCP报文段存储在mbuf簇中

TCP首部的头32 bit存储指向对应 mbuf的指针，下面介绍的 TCP_REASS函数将用到这个后向指针。

27.9.2 TCP_REASS函数

图27-17给出了TCP_REASS函数的第一部分。参数包括：tp，指向TCP控制块的指针；ti，指向接收报文段IP和TCP首部的指针；m，指向存储接收报文段的mbuf链表的指针。前

面曾提到过， t_i 既可以指向由 m 所指向的mbuf的数据区，也可以指向一个簇。

```
tcp_input.c
69 int
70 tcp_reass(tp, ti, m)
71 struct tcpcb *tp;
72 struct tciphdr *ti;
73 struct mbuf *m;
74 {
75     struct tciphdr *q;
76     struct socket *so = tp->t_inpcb->inp_socket;
77     int      flags;

78     /*
79      * Call with ti==0 after become established to
80      * force pre-ESTABLISHED data up to user socket.
81      */
82     if (ti == 0)
83         goto present;

84     /*
85      * Find a segment that begins after this one does.
86      */
87     for (q = tp->seg_next; q != (struct tciphdr *) tp;
88          q = (struct tciphdr *) q->ti_next)
89     if (SEQ_GT(q->ti_seq, ti->ti_seq))
90         break;
```

图27-17 TCP_RECV 函数：第一部分

69-83 后面将看到，TCP收到一个对SYN的确认时，tcp_input将调用TCP_REASS，并传递一个空的ti指针(图28-20和图29-2)。这意味着连接已建立，可以把SYN报文段中携带的数据(TCP_REASS已将其放入重组队列)提交给应用程序。连接未建立之前，不允许这样做。标志“present”位于图27-23中。

84-90 遍历从 `seg_next` 开始的乱序报文段双向链表，寻找序号大于接收报文段序号 (`ti_seq`) 的第一个报文段。注意，`for` 循环体中只包含一个 `if` 语句。

图27-18的例子中，新报文段到达时重组队列中已有两个报文段。图中标出了指针 q ，指向链表的下一个报文段，带有字节 10~15。此外，图中还标出了两个指针 ti_next 和 ti_prev ，起始序号(ti_seq)、长度(ti_len)和数据字节的序号。由于这些报文段较小，每个报文段很可能存储在单一的 mbuf 中，如图27-14所示。

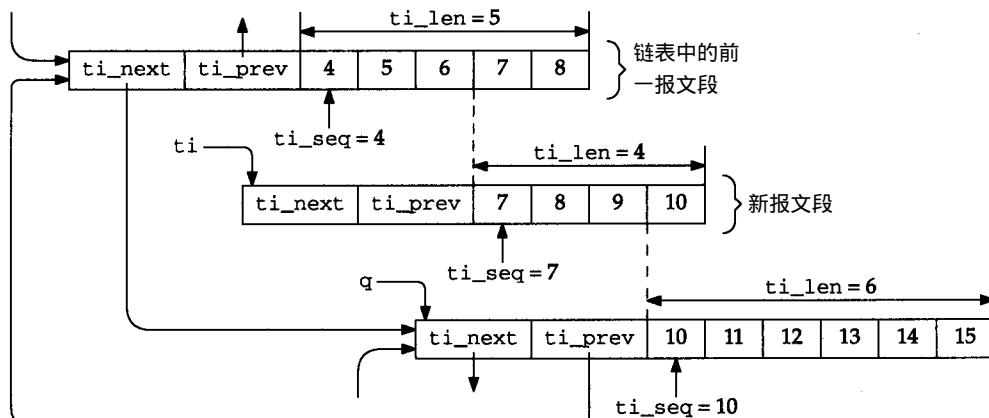


图27-18 存储重复报文段的重组队列举例

图27-19给出了TCP_REASS下一部分的代码

```

91  /*
92   * If there is a preceding segment, it may provide some of
93   * our data already. If so, drop the data from the incoming
94   * segment. If it provides all of our data, drop us.
95   */
96  if ((struct tciphdr *) q->ti_prev != (struct tciphdr *) tp) {
97      int i;
98      q = (struct tciphdr *) q->ti_prev;
99      /* conversion to int (in i) handles seq wraparound */
100     i = q->ti_seq + q->ti_len - ti->ti_seq;
101     if (i > 0) {
102         if (i >= ti->ti_len) {
103             tcpstat.tcps_rcvduppack++;
104             tcpstat.tcps_rcvdupbyte += ti->ti_len;
105             m_freem(m);
106             return (0);
107         }
108         m_adj(m, i);
109         ti->ti_len -= i;
110         ti->ti_seq += i;
111     }
112     q = (struct tciphdr *) (q->ti_next);
113 }
114 tcpstat.tcps_rcvoopack++;
115 tcpstat.tcps_rcvoobyte += ti->ti_len;
116 REASS_MBUF(ti) = m;           /* XXX */

```

tcp_input.c

图27-19 TCP_REASS 函数：第二部分

91-107 如果双向链表中`q`指向的报文段前还存在报文段，则该报文段有可能与新报文段重复，因此，挪动指针`q`，令其指向`q`的前一个报文段(图27-18中携带字节4~8的报文段)，计算重复的字节数，并存储在变量`i`中：

```

i = q->ti_seq + q->ti_len - ti->ti_seq;
= 4 + 5 - 7
= 2

```

如果`i`大于0，则链表中原有报文段与新报文段携带的数据间存在重复，如例子中给出的报文段。如果重复的字节数(`i`)大于或等于新报文段的大小，即新报文段中所有的数据都已包含在原有报文段中，新报文段是重复报文段，应予以丢弃。

108-112 如果只有部分数据重复(如图27-18所示)，`m_adj`丢弃新报文段起始`i`字节的数据，并相应更新新报文段的序号和长度。挪动`q`指针，指向链表中的下一个报文段。图27-20给出了图27-18中各报文段和变量此时的状态。

116 mbuf的地址`m`存储在TCP首部的源端口号和目的端口号中，也就是我们在本节前面曾提到的后向指针，防止TCP首部被存放在mbuf簇中，而无法使用`dtom`宏。宏`REASS_MBUF`定义为：

```
#define REASS_MBUF(ti) (*(struct mbuf **)&((ti)->ti_t))
```

`ti_t`是一个`tcphdr`结构(图24-12)，最初的两个成员变量是两个16bit的端口号。请注意图27-19中的注释“XXX”，其中隐含了这样一个假定，指针能够存放在两个端口号占用的32bit空间中。

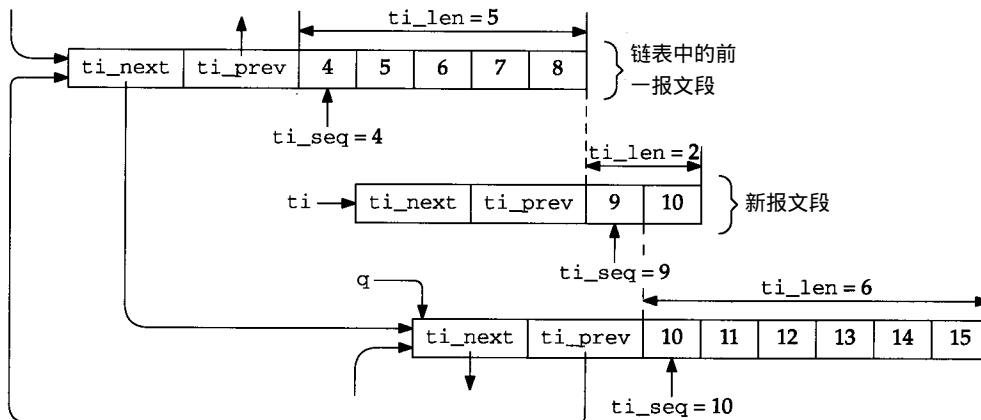


图27-20 删除新报文段中的字节7和8后，更新图27-18

图27-21给出了tcp_reass的第三部分，删除重组队列下一报文段中可能的重复字节。

117-135 如果还有后续报文段，则计算新报文段与下一报文段间重复的字节数，并存储在变量*i*中。还是以图27-18中的报文段为例，得到：

```
i = 9 + 2 - 10
= 1
```

因为序号10的字节同时存在于两个报文段中。

根据*i*值的大小，有可能出现3种情况：

- 1) 如果*i*小于等于0，无重复。
- 2) 如果*i*小于下一报文段的字节数(*q->ti_len*)，则有部分重复，调用*m_adj*，从该报文段中丢弃起始的*i*字节。
- 3) 如果*i*大于等于下一报文段的字节数，则出现完全重复，从链表中删除该报文段。

136-139 代码最后调用*insque*，把新报文段插入连接的重组双向链表中。图27-22给出了图27-18中各报文段和变量此时的状态。

```
tcp_input.c
117  /*
118   * While we overlap succeeding segments trim them or,
119   * if they are completely covered, dequeue them.
120   */
121  while (q != (struct tcphdr *) tp) {
122      int i = (ti->ti_seq + ti->ti_len) - q->ti_seq;
123      if (i <= 0)
124          break;
125      if (i < q->ti_len) {
126          q->ti_seq += i;
127          q->ti_len -= i;
128          m_adj(REASS_MBUF(q), i);
129          break;
130      }
131      q = (struct tcphdr *) q->ti_next;
132      m = REASS_MBUF((struct tcphdr *) q->ti_prev);
133      remque(q->ti_prev);
```

图27-21 TCP_REASS 函数：第三部分

```

134         m_free(m);
135     }
136
137     /*
138      * Stick new segment in its place.
139      */
140     insque(ti, q->ti_prev);

```

tcp_input.c

图27-21 (续)

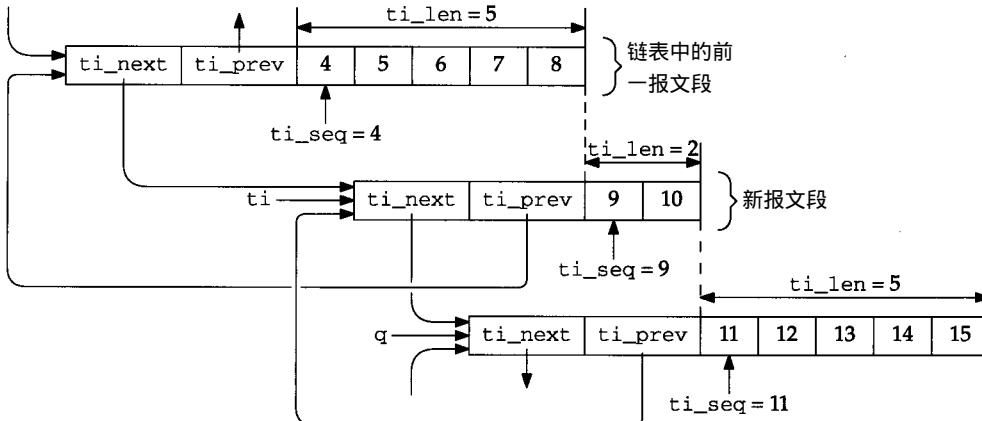


图27-22 丢弃所有重复字节后，更新图 27-20

图27-23给出了tcp_reass最后一部分的代码，如果可能，向应用进程递交数据。

```

140 present:
141 /*
142  * Present data to user, advancing rcv_nxt through
143  * completed sequence space.
144  */
145 if (TCPS_HAVERCVDSYN(tp->t_state) == 0)
146     return (0);
147 ti = tp->seg_next;
148 if (ti == (struct tciphdr *) tp || ti->ti_seq != tp->rcv_nxt)
149     return (0);
150 if (tp->t_state == TCPS_SYN_RECEIVED && ti->ti_len)
151     return (0);
152 do {
153     tp->rcv_nxt += ti->ti_len;
154     flags = ti->ti_flags & TH_FIN;
155     remque(ti);
156     m = REASS_MBUF(ti);
157     ti = (struct tciphdr *) ti->ti_next;
158     if (so->so_state & SS_CANTRCVMORE)
159         m_free(m);
160     else
161         sbappend(&so->so_rcv, m);
162 } while (ti != (struct tciphdr *) tp && ti->ti_seq == tp->rcv_nxt);
163 sор wakeup(so);
164 return (flags);
165 }

```

tcp_input.c

图27-23 tcp_reass 函数：第四部分

145-146 如果连接还没有收到SYN(连接处于LISTEN状态或SYN_SENT状态)，不允许向应用进程提交数据，函数返回。当函数被宏 `TCP_REASS` 调用时，返回值 0 被赋给宏的参数 `flags`。这种做法带来的副作用是可能会清除 FIN标志。当宏 `TCP_REASS` 被图29-22的代码调用时，如果接收报文段包含了 SYN、FIN和数据(尽管不常见，但却是有效的报文段)，会出现这种情况。

147-149 `ti` 设定为链表的第一个报文段。如果链表为空，或者第一个报文段的起始序号 (`ti->ti_seq`) 不等于连接等待接收的下一序号 (`rcv_nxt`)，则函数返回 0。如果第二个条件为真，说明在等待接收的下一序号与已收到的数据之间仍然存在缺失报文段。例如，图 27-22 中，如果携带 4 ~ 8 字节的报文段是链表的起始报文段，但 `rcv_nxt` 等于 2，字节 2 和 3 仍旧缺失，因此，不能把 4 ~ 15 字节提交给应用进程。返回值 0 将清除 FIN标志(如果该标志设定)，这是因为还有未收到的数据，所以暂时不能处理 FIN。

150-151 如果连接处于SYN_RCVD状态，且报文段长度非零，则函数返回 0。如果两个条件均为真，说明插口在监听过程中收到了携带数据的 SYN报文段。数据将保存在连接队列中，等待三次握手过程结束。

152-164 循环从链表的第一个报文段开始(从前面的测试条件可知，它携带数据的次序已经正确)，把数据放入插口的接收缓存，并更新 `rcv_nxt`。当链表为空，或者链表下一报文段的序号又出现差错，即当前处理报文段与下一报文段间存在缺失报文段时，循环结束。此时，`flags` 变量(函数的返回值)等于 0 或者为 `TH_FIN`，取决于放入插口接收缓存的最后一个报文段中是否带有 FIN标志。

在所有 mbuf 都放入插口的接收缓存后，`sorwakeup` 唤醒所有在插口上等待接收数据的应用进程。

27.10 `tcp_trace` 函数

图26-32中，在向IP递交报文段之前，`tcp_output` 调用了 `tcp_trace` 函数：

```
if (so->so_options & SO_DEBUG)
    tcp_trace(TA_OUTPUT, tp->t_state, tp, ti, 0);
```

在内核的环形缓存中添加一条记录，这些记录可通过 `trpt` (8) 程序读取。此外，如果内核编译时定义了符号 `TCPDEBUG`，并且变量 `tcpconsdebug` 非零，则信息将输出到系统控制台。

任何进程都可以设定 TCP 的插口选项 `SO_DEBUG`，要求 TCP 把信息存储到内核的环形缓存中。但只有特权进程或系统管理员才能运行 `trpt`，因为它必须读取系统内存才能获取这些信息。

尽管可以为任何类型的插口设定 `SO_DEBUG` 选项(如 UDP 或原始 IP)，但只有 TCP 才会处理它。

这些信息被保存在 `tcp_debug` 结构中，如图27-24所示。

35-43 `tcp_debug` 很大(196字节)，因为它包含了其他两个结构：保存 IP 和 TCP 首部的 `tcpiphdr` 和完整的 TCP 控制块 `tcpcb`。由于保存了 TCP 控制块，其中的任何变量都可通过 `trpt` 打印出来。也就是说，如果 `trpt` 标准输出中没有包含读者感兴趣的信息，可修改源代码以打印控制块中任何想要的信息(Net/3版支持这种修改)。图25-28中的 RTT 变量就是通过这种方式得到的。

```

35 struct tcp_debug {
36     n_time td_time;           /* iptime(): ms since midnight, UTC */
37     short td_act;            /* TA_xxx value (Figure 27.25) */
38     short td_ostate;          /* old state */
39     caddr_t td_tcb;          /* addr of TCP connection block */
40     struct tciphdr td_ti;    /* IP and TCP headers */
41     short td_req;            /* PRU_xxx value for TA_USER */
42     struct tcpcb td_cb;      /* TCP connection block */
43 };
53 #define TCP_NDEBUG 100
54 struct tcp_debug tcp_debug[TCP_NDEBUG];
55 int     tcp_debx;

```

tcp_debug.h

图27-24 tcp_debug 结构

53-55 图27-24还定义了数组 `tcp_debug`，也就是前面提到的环形缓存。数组指针 `(tcp_debx)` 初始化为零，该数组约占 20 000 字节。

内核只调用了 `tcp_trace` 4 次，每次调用都会在结构的 `td_act` 变量中存入一个不同的值，如图27-25所示。

td_act	描述	参考
TA_DROP	当输入报文段被丢弃时，被 <code>tcp_input</code> 调用	图29-27
TA_INPUT	输入处理完毕后，调用 <code>tcp_output</code> 之前	图29-26
TA_OUTPUT	调用 <code>ip_output</code> 发送报文段之前	图26-32
TA_USER	PRU_xxx 请求处理完毕后，被 <code>tcp_usrreq</code> 调用	图30-1

图27-25 td_act 值及相应的tcp_trace 调用

图27-26给出了 `tcp_trace` 函数的主要部分，我们忽略了直接输出到控制台的那部分代码。

48-133 在函数被调用时，`ostate` 中保存了连接的前一个状态，与连接的当前状态（保存在控制块中）相比较，可了解连接的状态变迁状况。图 27-25 中，`TA_OUTPUT` 不改变连接状态，但其他3个调用则会导致状态的转移。

```

48 void
49 tcp_trace(act, ostate, tp, ti, req)
50 short act, ostate;
51 struct tcpcb *tp;
52 struct tciphdr *ti;
53 int req;
54 {
55     tcp_seq seq, ack;
56     int len, flags;
57     struct tcp_debug *td = &tcp_debug[tcp_debx++];
58     if (tcp_debx == TCP_NDEBUG)
59         tcp_debx = 0; /* circle back to start */
60     td->td_time = iptime();
61     td->td_act = act;

```

tcp_debug.c

图27-26 tcp_trace 函数：在内核的环形缓存中保存信息

```

62     td->td_ostate = ostate;
63     td->td_tcb = (caddr_t) tp;
64     if (tp)
65         td->td_cb = *tp;           /* structure assignment */
66     else
67         bzero((caddr_t) & td->td_cb, sizeof(*tp));
68     if (ti)
69         td->td_ti = *ti;           /* structure assignment */
70     else
71         bzero((caddr_t) & td->td_ti, sizeof(*ti));
72     td->td_req = req;

73 #ifdef TCPDEBUG
74     if (tcpconsdebug == 0)
75         return;

/* output information on console */

132 #endif
133 }

```

tcp_debug.c

图27-26 (续)

输出举例

图27-27列出了tcpdump输出的前4行，反映25.12节例子中的三次握手过程和发送的第一个数据报文段(卷1附录A提供了tcpdump输出格式的细节)。

```

1 0.0          bsdi.1025 > vangogh.discard: S 20288001:20288001(0)
                           win 4096 <mss 512>
2 0.362719 (0.3627)    vangogh.discard > bsdi.1025: S 3202722817:3202722817(0)
                           ack 20288002 win 8192
                           <mss 512>
3 0.364316 (0.0016)    bsdi.1025 > vangogh.discard: . ack 1 win 4096
4 0.415859 (0.0515)    bsdi.1025 > vangogh.discard: . 1:513(512) ack 1 win 4096

```

图27-27 反映图25-28实例的tcpdump 输出

图27-28列出了与之对应的trpt的输出。

图27-28的输出与正常的trpt输出相比略有一些不同：32 bit的数字序号显示为无符号整数(trpt将其差错地打印为有符号整数)；有些trpt按16进制输出的值被改为10进制；为了编制图25-28，作者人为地把从t_rtt到t_rxtcur的值加入到trpt中。

```

953738 SYN_SENT: output 20288001:20288005(4) @0 (win=4096)
<SYN> -> SYN_SENT
rcv_nxt 0, rcv_wnd 0
snd_una 20288001, snd_nxt 20288002, snd_max 20288002
snd_wl1 0, snd_wl2 0, snd_wnd 0
REXMT=12 (t_rxtshift=0), KEEP=150

```

图27-28 反映图25-28实例的trpt 输出

```

t_rtt=1, t_srtt=0, t_rttvar=24, t_rxtcur=12

953739 CLOSED: user CONNECT -> SYN_SENT
    rcv_nxt 0, rcv_wnd 0
    snd_una 20288001, snd_nxt 20288002, snd_max 20288002
    snd_wl1 0, snd_wl2 0, snd_wnd 0
    REXMT=12 (t_rxtshift=0), KEEP=150
    t_rtt=1, t_srtt=0, t_rttvar=24, t_rxtcur=12

954103 SYN_SENT: input 3202722817:3202722817(0) @20288002 (win=8192)
    <SYN,ACK> -> ESTABLISHED
    rcv_nxt 3202722818, rcv_wnd 4096
    snd_una 20288002, snd_nxt 20288002, snd_max 20288002
    snd_wl1 3202722818, snd_wl2 20288002, snd_wnd 8192
    KEEP=14400
    t_rtt=0, t_srtt=16, t_rttvar=4, t_rxtcur=6

954103 ESTABLISHED: output 20288002:20288002(0) @3202722818 (win=4096)
    <ACK> -> ESTABLISHED
    rcv_nxt 3202722818, rcv_wnd 4096
    snd_una 20288002, snd_nxt 20288002, snd_max 20288002
    snd_wl1 3202722818, snd_wl2 20288002, snd_wnd 8192
    KEEP=14400
    t_rtt=0, t_srtt=16, t_rttvar=4, t_rxtcur=6

954153 ESTABLISHED: output 20288002:20288514(512) @3202722818 (win=4096)
    <ACK> -> ESTABLISHED
    rcv_nxt 3202722818, rcv_wnd 4096
    snd_una 20288002, snd_nxt 20288514, snd_max 20288514
    snd_wl1 3202722818, snd_wl2 20288002, snd_wnd 8192
    REXMT=6 (t_rxtshift=0), KEEP=14400
    t_rtt=1, t_srtt=16, t_rttvar=4, t_rxtcur=6

```

图27-28 (续)

在时刻953 738，发送SYN。注意，代码中的时间变量有8位数字，以毫秒为单位，这里只输出了低6位。输出的结束序号(20 288 005)是差错的。SYN中确实携带了4字节的内容，但并非数据，而是MSS选项。重传定时器设定为6秒(REXMT)，保活定时器为75秒(KEEP)，这些定时器值均以500 ms滴答为单位。t_rtt等于1，意味对该报文段计时，测量RTT样本值。

发送SYN是为了响应应用进程的connect调用。一毫秒后，这次系统调用的信息被写入内核的环形缓存。尽管是因为应用进程调用了connect，才导致发送SYN报文段，但TCP在处理完PRU_CONNECT请求后，才调用tcp_trace，环形缓存中实际写入了两条记录。此外，应用进程调用connect时，连接状态为CLOSED，发送完SYN后，状态变迁至SYN_SENT，这也是两条记录仅有的不同之处。

第三条记录，时刻954 103，与第一条记录相隔365 ms (tcpdump显示时间差为362.7ms)，即为图25-28中“实际时间差(ms)”一栏的填充值。收到带有SYN和ACK的报文段后，连接状态从SYN_SENT转移到ESTABLISHED。因为计时报文段已得到确认，更新RTT估计器值。

第四条记录反映了三次握手过程中的第三个报文段：确认对端的SYN。因为是纯ACK报文段，不用对它计时(rtt等于0)，它在时刻954 103被发送。connect系统调用返回，应用进程接着调用write发送数据，产生TCP输出。

第五条记录反映了这个数据报文段，在时刻954 153，三次握手结束后50 ms，被发送。它携带50字节的数据，起始序号为20 288 002。重传定时器设为3秒，需要计时。

应用进程继续调用write发送数据。尽管不再显示更多记录，但很明显，接下来的3条记

录也都是在TCP处理完PRU_SEND请求后写入环形缓存的。第一次PRU_SEND请求，生成我们已看到的第一个512字节的输出报文段，其他3次请求不会引发TCP输出报文段，此时连接正处于慢起动状态。只生成4条记录是因为，图25-28的例子中的TCP发送缓存大小只有4096，mbuf簇大小为1024。一旦发送缓存被占满，应用进程就进入休眠状态。

27.11 小结

本章介绍了各种TCP函数，为后续章节打下基础。

TCP连接正常关闭时，向对端发送FIN，并等待4次报文交换过程结束。它被丢弃时，只需发送RST。

路由表中的每条记录都包含8个变量，其中有3个在连接关闭时更新，有6个用于新连接的建立，从而内核能够跟踪与同一目标之间建立的正常连接的某些特性，如RTT估计器值和慢起动门限。系统管理员可以设置或锁定部分变量，如MTU、接收管道大小和发送管道大小，这些特性会影响到达该目标的连接的性能。

TCP对收到的ICMP差错有一定的容错性——不会导致TCP终止已建立的连接。Net/3处理ICMP差错的方式与早期的Berkeley版本不同。

TCP报文段可能乱序到达，并包含重复数据，TCP必须处理这些异常现象。TCP为每条连接维护一个重组队列，保存乱序报文段，处理之后再提交给应用进程。

最后介绍了选定插口选项SO_DEBUG时，内核中保存的信息。除某些程序如tcpdump之外，这些内容也是很有用的调试工具。

习题

- 27.1 为什么图27-1中最后一行的errno等于0？
- 27.2 rmx_rtt中存储的最大值是多少？
- 27.3 为了保存某个给定主机的路由信息（图27-3），我们用手工在本地的路由表中添加一条到达该主机的路由。之后，运行FTP客户程序，向这台主机发送足够多的数据，如图27-4所要求的。但终止FTP客户程序后，检查路由表，到达该主机的所有变量依旧为0。出了什么问题？

第28章 TCP的输入

28.1 引言

TCP输入处理是系统中最长的一部分代码，函数 `tcp_input` 约有1100行代码。输入报文段的处理并不复杂，但非常繁琐。许多实现，包括 Net/3，都完全遵循RFC 793中定义的输入事件处理步骤，它详细定义了如何根据连接的当前状态，处理不同的输入报文段。

当收到的数据报的协议字段指明这是一个 TCP报文段时，`ipintr`(通过协议转换表中的 `pr_input` 函数)会调用 `tcp_input` 进行处理。`tcp_input` 在软件中断一级执行。

函数非常长，我们将分两章讨论。图 28-1列出了 `tcp_input` 中的处理框架。本章将结束对 RST报文段处理的讲解，从下一章开始介绍 ACK报文段的处理。

头几个步骤是非常典型的：对输入报文段做有效性验证(检验和、长度等)，以及寻找连接的PCB。尽管后面还有大量代码，但通过“首部预测(header prediction)”(28.4节)，算法却有可能完全跳过后续的逻辑。首部预测算法是基于这样的假定：一般情况下，报文段既不会丢失，次序也不会错误，因此，对于给定连接，TCP总能猜到下一个接收报文段的内容。如果算法起作用，函数直接返回，这是 `tcp_input` 中最快的一条执行路径。

如果算法不起作用，函数在“`dodata`”处结束，测试几个标志，并且若需要对接收报文段作出响应，则调用 `tcp_output`。

```
void
tcp_input()
{
    checksum TCP header and data;
findpcb:
    locate PCB for segment;
    if (not found)
        goto dropwithreset;
    reset idle time to 0 and keepalive timer to 2 hours;
process options if not LISTEN state;
    if (packet matched by header prediction) {
        completely process received segment;
        return;
    }

    switch (tp->t_state) {
case TCPS_LISTEN:
        if SYN flag set, accept new connection request;
        goto trimthenstep6;

case TCPS_SYN_SENT:
        if ACK of our SYN, connection completed;
trimthenstep6:
        trim any data not within window;
```

图28-1 TCP输入处理步骤小结

```

    goto step6;
}

process RFC 1323 timestamp;
check if some data bytes are within the receive window;
trim data segment to fit within window;

if (RST flag set) {
    process depending on state;
    goto drop;
}                                /* Chapter 28 finishes here */

if (ACK flag set) {               /* Chapter 29 starts here */
    if (SYN_RCVD state)
        simultaneous open complete;
    if (duplicate ACK)
        fast recovery algorithm;
    update RTT estimators if segment timed;
    open congestion window;
    remove ACKed data from send buffer;
    change state if in FIN_WAIT_1, CLOSING, or LAST_ACK state;
}

step6:
    update window information;
    process URG flag;

dodata:
    process data in segment, add to reassembly queue;
    if (FIN flag is set)
        process depending on state;
    if (SO_DEBUG socket option)
        tcp_trace(TA_INPUT);
    if (need output || ACK now)
        tcp_output();
    return;

dropafterack:
    tcp_output() to generate ACK;
    return;

dropwithreset:
    tcp_respond() to generate RST;
    return;

drop:
    if (SO_DEBUG socket option)
        tcp_trace(TA_DROP);
    return;
}

```

图28-1 (续)

函数结尾处有3个标注，处理出现差错时控制会跳转到这些地方：dropafterack、dropwithreset和drop。标注中出现的“drop”指丢弃当前处理的报文段，而非丢弃连接。不过，当控制跳转到dropwithreset时，将发送RST，从而丢弃连接。

函数仅有的另一个分支是首部预测算法后的switch语句，如果连接处于LISTEN或SYN_SENT状态时收到了一个有效的SYN报文段，它负责分别进行处理。trimthenstep6

处的代码结束后，跳转到 step 6，继续执行正常的流程。

28.2 预处理

图28-2的代码包含一些声明，并对收到的TCP报文段进行预处理。

1. 从第一个mbuf中获取IP和TCP首部

170-204 参数iphlen等于IP首部长度，包括可能的IP选项。如果长度大于20字节，可知存在IP选项，调用ip_stripoptions丢弃这些选项。TCP忽略除源选路之外的所有IP选项，源选路选项由IP特别保存(9.6节)，TCP能够读取其内容(图28-7)。如果簇中第一个mbuf的容量小于IP/TCP首部大小(40字节)，则调用m_pullup，试着把最初的40字节移入第一个mbuf中。

```

170 void
171 tcp_input(m, iphlen)
172 struct mbuf *m;
173 int iphlen;
174 {
175     struct tcphdr *ti;
176     struct inpcb *inp;
177     caddr_t optp = NULL;
178     int optlen;
179     int len, tlen, off;
180     struct tcpcb *tp = 0;
181     int tiflags;
182     struct socket *so;
183     int todrop, acked, ourfinisacked, needoutput = 0;
184     short ostate;
185     struct in_addr laddr;
186     int dropsocket = 0;
187     int iss = 0;
188     u_long tiwin, ts_val, ts_ecr;
189     int ts_present = 0;

190     tcpstat.tcps_rcvtotal++;
191     /*
192      * Get IP and TCP header together in first mbuf.
193      * Note: IP leaves IP header in first mbuf.
194      */
195     ti = mtod(m, struct tcphdr *);
196     if (iphlen > sizeof(struct ip))
197         ip_stripoptions(m, (struct mbuf *) 0);
198     if (m->m_len < sizeof(struct tcphdr)) {
199         if ((m = m_pullup(m, sizeof(struct tcphdr))) == 0) {
200             tcpstat.tcps_rcvshort++;
201             return;
202         }
203         ti = mtod(m, struct tcphdr *);
204     }

```

tcp_input.c

图28-2 `tcp_input` 函数：变量声明及预处理

图28-3给出了函数下一部分的代码，验证TCP检验和及偏移字段。

2. 验证TCP检验和

205-217 tlen指TCP报文段的长度，即IP首部后的字节数。前面介绍过，IP已经从

`ip_len`中减去了IP的首部长度，因此，变量 `len` 就等于整个IP数据报的长度，即包括伪首部在内的需要计算检验和的数据长度。根据 TCP检验和计算的要求，填充伪首部中的各个字段，如图23-19所示。

```

205  /*
206   * Checksum extended TCP header and data.
207   */
208   tlen = ((struct ip *) ti)->ip_len;
209   len = sizeof(struct ip) + tlen;
210   ti->ti_next = ti->ti_prev = 0;
211   ti->ti_x1 = 0;
212   ti->ti_len = (u_short) tlen;
213   HTONS(ti->ti_len);
214   if (ti->ti_sum = in_cksum(m, len)) {
215     tcpstat.tcp_ps_rcvbadsum++;
216     goto drop;
217   }
218   /*
219   * Check that TCP offset makes sense,
220   * pull out TCP options and adjust length.      XXX
221   */
222   off = ti->ti_off << 2;
223   if (off < sizeof(struct tcphdr) || off > tlen) {
224     tcpstat.tcp_ps_rcvbadoff++;
225     goto drop;
226   }
227   tlen -= off;
228   ti->ti_len = tlen;

```

tcp_input.c

图28-3 `tcp_input` 函数：验证TCP检验和及偏移字段

3. 验证TCP偏移字段

218-228 TCP的偏移字段，`ti_off`，是以32 bit为单位的TCP首部长度值，包括所有的TCP选项。把它乘以4(得到TCP报文段中第一个数据字节所在位置的偏移量)，并验证其有效性。偏移量必须大于等于标准TCP首部的大小(20字节)，并且小于等于TCP报文段的长度。

从TCP长度变量 `tlen` 中减去首部长度，得到报文段中携带的数据字节数(可能为0)，并把这个值赋给 `tlen`，以及TCP首部的变量 `ti_len`。函数中会多次用到这个值。

图28-4给出了函数下一部分的代码：处理特定的TCP选项。

```

229   if (off > sizeof(struct tcphdr)) {
230     if (m->m_len < sizeof(struct ip) + off) {
231       if ((m = m_pullup(m, sizeof(struct ip) + off)) == 0) {
232         tcpstat.tcp_ps_rcvshort++;
233         return;
234       }
235       ti = mtod(m, struct tciphdr *);
236     }
237     optlen = off - sizeof(struct tcphdr);
238     optp = mtod(m, caddr_t) + sizeof(struct tciphdr);
239     /*
240      * Do quick retrieval of timestamp options (*options

```

图28-4 `tcp_input` 函数：处理特定的TCP选项

```

241     * prediction?"). If timestamp is the only option and it's
242     * formatted as recommended in RFC 1323 Appendix A, we
243     * quickly get the values now and not bother calling
244     * tcp_dooptions(), etc.
245     */
246     if ((optlen == TCPOLEN_TSTAMP_APPA ||
247         (optlen > TCPOLEN_TSTAMP_APPA &&
248          optp[TCPOLEN_TSTAMP_APPA] == TCPOPT_EOL)) &&
249         *(u_long *) optp == htonl(TCPOPT_TSTAMP_HDR) &&
250         (ti->ti_flags & TH_SYN) == 0) {
251         ts_present = 1;
252         ts_val = ntohl(*(u_long *) (optp + 4));
253         ts_ecr = ntohl(*(u_long *) (optp + 8));
254         optp = NULL;           /* we've parsed the options */
255     }
256 }
```

tcp_input.c

图28-4 (续)

4. 把IP和TCP首部及选项放入第一个mbuf

230-236 如果首部长度大于20，说明存在TCP选项。必要时调用m_pullup，把标准IP首部、标准TCP首部的所有TCP选项放入簇中的第一个mbuf中。因为3部分数据最大只能为80字节(20+20+40)，因此，必定能够放入第一个存储数据分组首部的mbuf中。

此处能够造成m_pullup失败的惟一原因是IP数据分组的字节数小于20加上TCP首部长度，而且已通过TCP检验和的验证，我们认为m_pullup不可能失败。但有一点，图28-2中调用的m_pullup，将共享计数器tcps_rcvshort，因此，查看tcps_rcvshort并不能说明哪一个调用失败。不管怎样，从图24-5可知，即使收到九百万个TCP报文段之后，这个计数器仍旧为0。

5. 快速处理时间戳选项

237-255 optlen等于首部中TCP选项的长度，optp是指向第一个选项字节的指针。如果下列3个条件均为真，说明只存在时间戳选项，而且格式正确：

- 1) TCP选项长度等于12(TCPOLEN_TSTAMP_APPA)；或TCP选项长度大于12，但optp[12]等于选项结束字节。
- 2) 选项的头4个字节等于0x0101080a(TCPOPT_TSTAMP_HDR，在26.6节曾讨论过)。
- 3) SYN标志未置位(说明连接已建立，如果报文段中出现时间戳选项，意味着连接双方都同意使用这一选项)。

如果上述条件全部满足，则ts_present置为1；从接收报文段首部获取两个时间戳值，分别赋给ts_val和ts_ecr；optp置为空，因为所有选项已处理完毕。这种辨认时间戳的方法可以避免调用通用选项处理函数tcp_dooptions，从而使后者能够专门处理只出现在SYN报文段中的各种选项(MSS和窗口大小选项)。如果连接双方同意使用时间戳，那么在建立的连接上交换的几乎所有报文段中都可能带有时间戳选项，因此，必须加快其处理速度。

图28-5给出了函数下一部分的代码，寻找报文段的Internet PCB。

6. 保存输入标志，把字段转换为主机字节序

257-264 接收报文段中的标志(SYN、FIN等)被保存在本地变量tiflags中，因为函数在处理过程中会多次引用这些标志。TCP首部的两个16 bit字段和两个32 bit序号被转换回主机字

节序，而两个 16 bit 端口号则不做处理，依旧为网络字节序，因为 Internet PCB 中的端口号是依照网络字节序存储的。

```

257     tiflags = ti->ti_flags;
258     /*
259      * Convert TCP protocol specific fields to host format.
260      */
261     NTOHL(ti->ti_seq);
262     NTOHL(ti->ti_ack);
263     NTOHS(ti->ti_win);
264     NTOHS(ti->ti_urp);

265     /*
266      * Locate pcb for segment.
267      */
268     findpcb:
269     inp = tcp_last_inpcb;
270     if (inp->inp_lport != ti->ti_dport ||
271         inp->inp_fport != ti->ti_sport ||
272         inp->inp_faddr.s_addr != ti->ti_src.s_addr ||
273         inp->inp_laddr.s_addr != ti->ti_dst.s_addr) {
274         inp = in_pcblockup(&tcb, ti->ti_src, ti->ti_sport,
275                            ti->ti_dst, ti->ti_dport, INPLLOOKUP_WILDCARD);
276     if (inp)
277         tcp_last_inpcb = inp;
278     ++tcpstat.tcps_pcblockmiss;
279 }
```

tcp_input.c

图28-5 *tcp_input* 函数：寻找报文段的 Internet PCB

7. 寻找Internet PCB

265-279 TCP的缓存(tcp_last_inpcb)中保存了收到的最后一个报文段的PCB地址，采用的技术与UDP相同。TCP使用一对插口来识别连接，寻找PCB时插口对中4个元素的比较次序与udp_input相同。如果与TCP缓存中的记录不匹配，则调用in_pcblockup，把新的PCB放入缓存。

TCP中不会出现我们在 UDP中曾遇到过的问题：由于高速缓存中存在通配项 (wildcard entry)，导致匹配成功率很低。因为只有处于监听状态的服务器，才可能在其插口中保存通配项。连接一旦建立，插口对的4个元素将全部填入确定值。从图 24-5可知，高速缓存命中率能够达到80%。

图28-6给出了函数下一部分的代码。

```

280     /*
281      * If the state is CLOSED (i.e., TCB does not exist) then
282      * all data in the incoming segment is discarded.
283      * If the TCB exists but is in CLOSED state, it is embryonic,
284      * but should either do a listen or a connect soon.
285      */
286     if (inp == 0)
287         goto dropwithreset;
288     tp = intotcpinp(inp);
```

tcp_input.c

图28-6 *tcp_input* 函数：判断是否应丢弃报文段

```

289     if (tp == 0)
290         goto dropwithreset;
291     if (tp->t_state == TCPS_CLOSED)
292         goto drop;
293     /* Unscale the window into a 32-bit value. */
294     if ((tiflags & TH_SYN) == 0)
295         tiwin = ti->ti_win << tp->snd_scale;
296     else
297         tiwin = ti->ti_win;

```

tcp_input.c

图28-6 (续)

8. 丢弃报文段并生成 RST

280-287 如果没有找到PCB，则丢弃输入报文段，并发送RST作为响应。例如，TCP收到了一个SYN，但报文段指定的服务器并不存在，则直接向对端发送RST。回想一下，出现这种情况时UDP的处理方式，它将发送一个ICMP端口不可达差错。

288-290 如果PCB存在，但对应的TCP控制块不存在，可能插口已关闭(tcp_close释放TCP之后，才释放PCB)，则丢弃输入报文段，并发送RST作为响应。

9. 丢弃报文段且不发送响应

291-292 如果TCP控制块存在，但连接状态为CLOSED，说明插口已创建，且得到了本地地址和本地端口号，但还未调用connect或者listen。报文段被丢弃，且不发送任何响应。举例来说，如果客户向服务器发送的连接请求报文段到达时，服务器已调用了bind，但还未调用listen。这种情况下，客户连接请求将超时，导致重传SYN。

10. 不改变通告窗口大小

293-297 如果需要支持窗口大小选项，连接双方都必须在连接建立时通过窗口大小选项规定窗口缩放因子。如果报文段中包含SYN，说明此时窗口缩放因子还未定义，因此，直接把TCP首部的窗口字段值复制给tiwin；否则，首部中的16 bit数值应根据窗口缩放因子左移，得到32 bit的数值。

图28-7给出了函数的下一部分代码，如果选取了插口的SO_DEBUG选项，或者插口正处于监听状态，则完成一些相应的预处理工作。

```

298     so = inp->inp_socket;
299     if (so->so_options & (SO_DEBUG | SO_ACCEPTCONN)) {
300         if (so->so_options & SO_DEBUG) {
301             ostate = tp->t_state;
302             tcp_saveti = *ti;
303         }
304         if (so->so_options & SO_ACCEPTCONN) {
305             so = sonewconn(so, 0);
306             if (so == 0)
307                 goto drop;
308             /*
309             * This is ugly, but ....
310             *
311             * Mark socket as temporary until we're
312             * committed to keeping it. The code at
313             * 'drop' and 'dropwithreset' check the

```

tcp_input.c

图28-7 tcp_input 函数：处理调试选项和监听状态的插口

```

314         * flag dropsocket to see if the temporary
315         * socket created here should be discarded.
316         * We mark the socket as discardable until
317         * we're committed to it below in TCPS_LISTEN.
318         */
319     dropsocket++;
320     inp = (struct inpcb *) so->so_pcb;
321     inp->inp_laddr = ti->ti_dst;
322     inp->inp_lport = ti->ti_dport;
323 #if BSD>=43
324     inp->inp_options = ip_srcroute();
325 #endif
326     tp = intotcpinp(inp);
327     tp->t_state = TCPS_LISTEN;
328
329     /* Compute proper scaling value from buffer space */
330     while (tp->request_r_scale < TCP_MAX_WINSHIFT &&
331           TCP_MAXWIN << tp->request_r_scale < so->so_rcv.sb_hiwat)
332         tp->request_r_scale++;
333 }

```

tcp_input.c

图28-7 (续)

11. 如果选定了插口调试选项，则保存连接状态及IP和TCP首部

300-303 如果SO_DEBUG选项置位，则保存当前连接状态(*ostate*)及IP和TCP首部(*tcp_saveti*)。函数结束时，这些信息将作为参数传给*tcp_trace*(图29-26)。

12. 如果监听插口收到了报文段，则创建新的插口

304-319 如果有报文段到达处于监听状态的插口(*listen*置位SO_ACCEPTCONN)，则调用*sonewconn*创建新的插口。发出PRU_ATTACH协议请求(图30-2)，分配Internet PCB和TCP控制块。在TCP最终接受连接请求之前，还需做更多的处理(如一个最基本的问题，报文段中是否包含SYN)，如果发现差错，置位*dropsocket*标志，控制跳转至标注“*drop*”和“*dropwithreset*”，丢弃新的插口。

320-326 *inp*和*tp*将指向新建的插口。本地地址和本地端口号直接从接收报文段TCP首部的目的地址和目的端口号字段中复制。如果输入数据报中有源选路的路由，TCP调用*ip_srcroute*，得到指向保存数据报源选路选项的mbuf的指针，并赋给*inp_options*。TCP向连接发送数据时，*tcp_output*会把源选路选项传给*ip_output*，使用与之相同的逆向路由。

327 新插口的状态设为LISTEN。如果接收报文段中包含SYN，控制将转到图28-16中的代码，完成连接建立请求的处理。

13. 计算窗口缩放因子

328-331 窗口缩放因子取决于接收缓存的大小。如果接收缓存大于通告窗口的最大值(65535，TCP_MAXWIN)，则左移65535，直到结果大于接收缓存大小，或者窗口缩放因子已等于最大值(14，TCP_MAX_WINSHIFT)。注意，窗口缩放因子的选取基于监听插口的接收缓存，也就是说，应用进程调用*listen*进入监听状态之前，应首先设定SO_RCVBUF插口选项，或者继承*tcp_recvspace*中的默认值。

窗口缩放因子最大值等于14，而 65535×2^{14} 等于1 073 725 440，已远远大于接收

缓存的最大值(Net/3中为2626 144)，因此，在窗口缩放因子远小于14时，循环即终止。
参见习题28.1和28.2。

图28-8给出了TCP输入处理下一部分的代码。

```
tcp_input.c
334  /*
335   * Segment received on connection.
336   * Reset idle time and keepalive timer.
337   */
338   tp->t_idle = 0;
339   tp->t_timer[TCPT_KEEP] = tcp_keepidle;

340  /*
341   * Process options if not in LISTEN state,
342   * else do it below (after getting remote address).
343   */
344   if (optp && tp->t_state != TCPS_LISTEN)
345     tcp_dooptions(tp, optp, optlen, ti,
346                   &ts_present, &ts_val, &ts_ecr);
tcp_input.c
```

图28-8 `tcp_input` 函数：复位空闲时间和保活定时器，处理应用进程选项

14. 复位空闲时间和保活定时器

334-339 由于连接上收到了报文段，`t_idle`重设为0。保活定时器复位为2小时。

15. 如果不处于监听状态，处理TCP选项

340-346 如果TCP首部中有选项，并且连接状态不等于LISTEN，调用`tcp_dooptions`进行处理。前面介绍过，如果连接已建立，接收报文段中只存在时间戳选项，并且时间戳选项格式符合RFC 1323附录A的建议，这种情况在图28-4中已处理过，而且`optp`被置为空。如果插口处于监听状态，TCP把对端地址保存在PCB中之后，才会调用`tcp_dooptions`，这是因为处理MSS选项时需要了解到达对端的路由，具体代码如图28-17所示。

28.3 `tcp_dooptions`函数

函数处理Net/3支持的5个TCP选项(图26-4)：EOL、NOP、MSS、窗口大小和时间戳。图28-9给出了函数的第一部分。

```
tcp_input.c
1213 void
1214 tcp_dooptions(tp, cp, cnt, ti, ts_present, ts_val, ts_ecr)
1215 struct tcpcb *tp;
1216 u_char *cp;
1217 int cnt;
1218 struct tcphdr *ti;
1219 int *ts_present;
1220 u_long *ts_val, *ts_ecr;
1221 {
1222   u_short mss;
1223   int opt, optlen;

1224   for (; cnt > 0; cnt -= optlen, cp += optlen) {
1225     opt = cp[0];
1226     if (opt == TCPOPT_EOL)
```

图28-9 `tcp_dooptions` 函数：处理EOL和NOP选项

```

1227         break;
1228     if (opt == TCPOPT_NOP)
1229         optlen = 1;
1230     else {
1231         optlen = cp[1];
1232         if (optlen <= 0)
1233             break;
1234     }
1235     switch (opt) {
1236     default:
1237         continue;

```

tcp_input.c

图28-9 (续)

1. 获取选项类型的长度

1213-1229 代码遍历TCP首部选项，遇到EOL(选项终止)时终止循环，函数返回；遇到NOP时，将其长度置为1，因为它后面不带长度字段(图26-16)，控制转到switch语句的default子句，对其不做处理。

1230-1234 所有其他选项的长度保存在optlen中。

所有新增的Net/3不支持的TCP选项都被忽略。这是因为：

1) 将来定义的所有新选项都将带有长度字段(NOP和EOL是仅有的两个不带长度字段的选项)，而for语句的每次循环都跳过optlen字节。

2) switch语句的default子句忽略所有未知选项。

图28-10给出了tcp_dooptions最后一部分的代码，处理MSS、窗口大小和时间戳选项。

2. MSS选项

1238-1246 如果长度不等于4(TCPOLEN_MAXSEG)，或者报文段不带SYN标志，则忽略该选项。否则，复制两个MSS字节到本地变量，转换为主机字节序，调用tcp_mss完成处理。tcp_mss负责更新TCP控制块中的变量t_maxseg，即发向对端的报文段中允许携带的最大字节数。

3. 窗口大小选项

1247-1254 如果长度不等于4(TCPOLEN_WINDOW)，或者报文段不带SYN标志，则忽略该选项。Net/3置位TF_RCVD_SCALE，说明收到了一个窗口大小选项请求，并在requested_s_scale中保存缩放因子。由于cp[2]只有一个字节，因此，不存在边界问题。当连接转移到ESTABLISHED状态时，如果连接双方都同意支持窗口大小选项，则使用这一功能。

4. 时间戳选项

1255-1273 如果长度不等于10(TCPOLEN_TIMESTAMP)，则忽略该选项。否则，ts_present指向的标志被置位1，两个时间戳值分别保存在ts_val和ts_ecr所指向的变量中。如果收到的报文段带有SYN标志，Net/3置位TF_RCVD_TSTMP，说明收到了一个时间戳请求。ts_recent等于收到的时间戳值，ts_recent_age等于tcp_now，从系统初启到目前的时间，以500ms滴答为单位。

图28-10 `tcp_dooptions` 函数：处理MSS、窗口大小选项和时间戳选项

28.4 首部预测

下面接着图28-8中的代码，继续介绍`tcp_input`函数。

首部预测最初由Van Jacobson提出，出现在4.3BSD Reno版中。除了下面要讨论的代码外，只有[Jacobson 1990b]还介绍过该算法，核心内容来自3张给出实现代码的幻灯片。

首部预测算法通过处理两种常见现象，简化单向数据传输的实现。

- 1) 如果TCP发送数据，连接上等待接收的下一个报文段是对已发送数据的ACK。
- 2) 如果TCP接收数据，连接上等待接收的下一个报文段是顺序到达的数据报文段。

两种情况下，通过若干测试，判定收到的报文段是否是等待接收的报文段。如果是，则立即处理，比起本章接下来和下一章介绍的通用处理要快得多。

[Partridge 1993]介绍了一种基于 Van Jacobson的研究成果，速度更快的TCP首部预测算法实现。

图28-11给出了首部预测的第一部分代码。

```

347  /*
348   * Header prediction: check for the two common cases
349   * of a uni-directional data xfer. If the packet has
350   * no control flags, is in-sequence, the window didn't
351   * change and we're not retransmitting, it's a
352   * candidate. If the length is zero and the ack moved
353   * forward, we're the sender side of the xfer. Just
354   * free the data acked & wake any higher-level process
355   * that was blocked waiting for space. If the length
356   * is non-zero and the ack didn't move, we're the
357   * receiver side. If we're getting packets in order
358   * (the reassembly queue is empty), add the data to
359   * the socket buffer and note that we need a delayed ack.
360   */
361 if (tp->t_state == TCPS_ESTABLISHED &&
362     (tiflags & (TH_SYN | TH_FIN | TH_RST | TH_URG | TH_ACK)) == TH_ACK &&
363     (!ts_present || TSTMP_GEQ(ts_val, tp->ts_recent)) &&
364     ti->ti_seq == tp->rcv_nxt &&
365     tiwin && tiwin == tp->snd_wnd &&
366     tp->snd_nxt == tp->snd_max) {
367
368   /*
369    * If last ACK falls within this segment's sequence numbers,
370    * record the timestamp.
371    */
372   if (ts_present && SEQ_LEQ(ti->ti_seq, tp->last_ack_sent) &&
373       SEQ_LT(tp->last_ack_sent, ti->ti_seq + ti->ti_len)) {
374     tp->ts_recent_age = tcp_now;
375     tp->ts_recent = ts_val;
376   }

```

tcp_input.c

图28-11 *tcp_input* 函数：首部预测，第一部分

1. 判定收到的报文段是否是等待接收的报文段

347-366 下列6个条件必须全真，才能说明收到的报文段是连接正等待接收的数据报文段或ACK报文段：

1) 连接状态等于ESTABLISHED。

2) 下列4个控制标志必须不设定：SYN、FIN、RST、或URG。但ACK标志必须置位。换言之，TCP的6个控制标志中，ACK标志必须置位，前面列出的4个标志必须清除，PSH标志置位与否无关紧要(连接处于ESTABLISHED状态时，除非RST标志置位，一般情况下，ACK都会置位)。

3) 如果报文段带有时间戳选项，则最新时间戳值(*ts_val*)必须大于或等于连接上以前收到的时间戳值(*ts_recent*)。本质上说，这就是PAWS测试，28.7节将详细介绍PAWS。如果*ts_val*小于*ts_recent*，则新报文段是乱序报文段，因为它的发送时间早于连接上收到的上一个报文段。由于对端通常把时钟值填充到时间戳字段(Net/3的全局变量*tcp_now*)，收到的时间戳正常情况下应该是一个单调递增的序列。

并非每个顺序到达报文段中的时间戳都会增加。事实上，Net/3系统每500 ms增加一次时

钟值(tcp_now) , 在这段时间间隔中 , 完全可能发送多个报文段。假定利用时间戳和序号构成一个64 bit的数值 , 序号放在低32 bit , 时间戳放在高32 bit , 对于每个顺序报文段 , 这个64 bit的值都至少会增加1(应考虑取模算法)。

4) 报文段的起始序号(ti_seq)必须等于连接上等待接收的下一个序号(recv_nxt)。如果这个条件为假 , 那么收到的报文段是重传报文段或是乱序报文段。

5) 报文段通告的窗口大小必须非零(tiwin) , 必须等于当前发送窗口(snd_wnd)。也就是说 , 无需更新当前发送窗口。

6) 下一个发送序号(snd_nxt)必须等于已发送的最大序号(snd_max) , 也就是说 , 上一个发送报文段不是重传报文段。

2. 根据接收的时间戳更新ts_recent

367-375 如果存在时间戳选项 , 并且时间戳值满足图 26-18 中的测试条件 , 则把收到的时间戳值(ts_val)赋给ts_recent , 并在ts_recent_age中保存当前时钟(tcp_now)。

前面讨论过图 26-18 中的时间戳有效性测试条件所存在的问题 , 并在图 26-20 中给出了正确的测试条件。但在首部预测算法的实现中 , 图 26-20 中的TSTMP_GEQ 测试是多余的 , 因为图 28-11 起始处的 if 语句己完成了这一测试

图 28-12 给出了首部预测的下一部分代码 , 用于单向数据的发送方 : 处理输出数据的 ACK。

```

376     if (ti->ti_len == 0) {
377         if (SEQ_GT(ti->ti_ack, tp->snd_una) &&
378             SEQ_LEQ(ti->ti_ack, tp->snd_max) &&
379             tp->snd_cwnd >= tp->snd_wnd) {
380             /*
381             * this is a pure ack for outstanding data.
382             */
383             ++tcpstat.tcps_predack;
384             if (ts_present)
385                 tcp_xmit_timer(tp, tcp_now - ts_ecr + 1);
386             else if (tp->t_rtt &&
387                     SEQ_GT(ti->ti_ack, tp->t_rtseq))
388                 tcp_xmit_timer(tp, tp->t_rtt);

389             acked = ti->ti_ack - tp->snd_una;
390             tcpstat.tcps_rcvackpack++;
391             tcpstat.tcps_rcvackbyte += acked;
392             sbdrop(&so->so_snd, acked);
393             tp->snd_una = ti->ti_ack;
394             m_freem(m);

395             /*
396             * If all outstanding data is acked, stop
397             * retransmit timer, otherwise restart timer
398             * using current (possibly backed-off) value.
399             * If process is waiting for space,
400             * wakeup/selwakeup/signal. If data
401             * is ready to send, let tcp_output
402             * decide between more output or persist.
403             */
404             if (tp->snd_una == tp->snd_max)
405                 tp->t_timer[TCPT_REXMT] = 0;

```

图 28-12 tcp_input 函数 : 首部预测 , 发送方处理

```

406     else if (tp->t_timer[TCPT_PERSIST] == 0)
407         tp->t_timer[TCPT_REXMT] = tp->t_rxtcur;
408
409         if (so->so_snd.sb_flags & SB_NOTIFY)
410             sowakeup(so);
411         if (so->so_snd.sb_cc)
412             (void) tcp_output(tp);
413     return;
}

```

tcp_input.c

图28-12 (续)

3. 纯ACK测试

376-379 如果下列4个条件全真，则收到的是一个纯ACK报文段。

- 1) 报文段不携带数据(ti_len等于0)。
- 2) 报文段的确认字段(ti_ack)大于最大的未确认序号(snd_una)。由于测试条件是“大于”，而非“大于等于”，也就是要求收到的ACK必须确认未曾确认过的数据。
- 3) 报文段的确认字段(ti_ack)小于等于已发送的最大序号(snd_max)。
- 4) 拥塞窗口大于等于当前发送窗口(snd_wnd)，要求窗口完全打开，连接不处于慢起动或拥塞避免状态。

4. 更新RTT值

384-388 如果报文段携带时间戳选项，或者报文段中的确认序号大于某个计时报文段的起始序号，则调用 `tcp_xmit_timer` 更新RTT值。

5. 从发送缓存中删除被确认的字节

389-394 acked等于接收报文段确认字段所确认的字节数，调用 `sbdrop` 从发送缓存中删除这些字节。更新最大的未确认过的序号(snd_una)为报文段的确认字段值，释放保存接收报文段的mbuf链表(由于数据长度等于0，实际只有一个保存首部的mbuf)。

6. 终止重传定时器

395-407 如果接收报文段确认了所有已发送数据(snd_una等于snd_max)，则关闭重传定时器。若条件不满足，且持续定时器未设定，则重启重传定时器，时限设为 t_rxtcur。

前面介绍过，`tcp_output`发送报文段时，只有重传定时器未启动，才会设定它。如果连续发送两个报文段，发送第一个报文段时定时器启动，发送第二个报文段时定时器不变。但如果只收到第一个报文段的确认，则重传定时器必须重启，防止第二个报文段丢失。

7. 唤醒等待进程

408-409 如果发送缓存修改后，有必要唤醒等待的应用进程，则调用 `sowakeup`。从图16-5可知，如果有应用进程正在等待缓存空间，或者设定了与缓存有关的 `select` 选项，或者正等待插口上的SIGIO，则SB_NOTIFY为真。

8. 生成更多的输出

410-411 如果发送缓存中有数据，则调用 `tcp_output`，因为发送窗口已经向右移动。snd_una已增加，但snd_wnd未变化，因此，图24-17中的整个窗口将向右移动。

图28-13给出了头部预测的下一部分代码，接收方收到顺序到达的数据时进行的各种处理。

9. 测试收到报文段是否是连接等待接收的下一个报文段

414-416 如果下列4个条件均为真，则收到的报文段是连接上等待接收的下一报文段，并且插口缓存中的剩余空间能够容纳到达的数据。

- 1) 报文段的数据量(ti_len)大于0，即图28-12起始处if语句的else子句。
- 2) 确认字段(ti_ack)等于最大的未确认序号，即报文段未确认任何数据。
- 3) 连接乱序报文段的重组队列为空(seq_next等于tp)。
- 4) 接收缓存能够容纳报文段数据。

10. 完成接收数据的处理

423-435 等待接收序号(rcv_nxt)递增收到的数据字节数。从 mbuf链中丢弃IP首部、TCP首部和所有TCP选项，将剩余的mbuf链附加到插口的接收缓存，调用 sorwakeup唤醒接收进程。注意，代码没有调用TCP_REASS宏，因为宏代码中的条件判定已经包含在首部预测的测试条件中。设定延迟ACK标志，输入处理结束。

```

414         } else if (ti->ti_ack == tp->snd_una &&
415                 tp->seg_next == (struct tciphdr *) tp &&
416                 ti->ti_len <= sbspace(&so->so_rcv)) {
417             /*
418             * this is a pure, in-sequence data packet
419             * with nothing on the reassembly queue and
420             * we have enough buffer space to take it.
421             */
422             ++tcpstat.tcps_preddat;
423             tp->rcv_nxt += ti->ti_len;
424             tcpstat.tcps_rcvpack++;
425             tcpstat.tcps_rcvbyte += ti->ti_len;
426             /*
427             * Drop TCP, IP headers and TCP options then add data
428             * to socket buffer.
429             */
430             m->m_data += sizeof(struct tciphdr) + off - sizeof(struct tcphdr);
431             m->m_len -= sizeof(struct tciphdr) + off - sizeof(struct tcphdr);
432             sbappend(&so->so_rcv, m);
433             sorwakeup(so);
434             tp->t_flags |= TF_DELACK;
435             return;
436     }
437 }
```

tcp_input.c

图28-13 *tcp_input* 函数：首部预测的接收方处理

统计量

首部预测能在多大程度上改善系统性能？让我们做个简单的实验，跨越 LAN(bdsi和svr4间的双向通信)的数据传输，和跨越 WAN(vangogh.cs.berkeley.edu和ftp.uu.net之间的双向通信)的数据传输。运行netstat，得到类似于图24-5的输出，列出了两种情况下的首部预测寄存器的值。

跨越LAN传输时，无数据分组丢失，只有一些重复的ACK。利用首部预测处理的报文段可占到97%~100%。跨越WAN时，比例有所降低，约为83%~99%之间。

请注意，首部预测的应用限定于单独的连接，无论主机是否收到了额外的TCP流量，PCB

缓存必须在主机范围内共享。即使 TCP流量的丢失造成了 PCB缓存缺失，但如果给定连接上的数据分组未丢失，这条连接上的首部预测仍能工作。

28.5 TCP输入：缓慢的执行路径

下面讨论首部预测失败时的处理代码，`tcp_input`中较慢的一条执行路径。图 28-14给出了下一部分代码，为输入报文段的处理完成一些准备工作。

```

438     /*
439      * Drop TCP, IP headers and TCP options.
440      */
441     m->m_data += sizeof(struct tciphdr) + off - sizeof(struct tcphdr);
442     m->m_len -= sizeof(struct tciphdr) + off - sizeof(struct tcphdr);

443     /*
444      * Calculate amount of space in receive window,
445      * and then do TCP input processing.
446      * Receive window is amount of space in rcv queue,
447      * but not less than advertised window.
448      */
449     {
450         int      win;

451         win = sbspace(&so->so_rcv);
452         if (win < 0)
453             win = 0;
454         tp->rcv_wnd = max(win, (int) (tp->rcv_adv - tp->rcv_nxt));
455     }

```

tcp_input.c

图28-14 `tcp_input` 函数：丢弃IP和TCP首部

1. 丢弃IP和TCP首部，包括TCP选项

438-442 更新数据指针和mbuf链表中的第一个mbuf的长度，以跳过IP首部、TCP首部和所有TCP选项。因为off等于TCP首部长度，包括TCP选项，因此，表达式中减去了标准TCP首部的大小(20字节)。

2. 计算接收窗口

443-455 `win`等于插口接收缓存中可用的字节数，`rcv_adv`减去`rcv_nxt`等于当前通告的窗口大小，接收窗口等于上述两个值中较大的一个，这是为了保证接收窗口不小于当前通告窗口的大小。此外，如果最后一次窗口更新后，应用进程从插口接收缓存中取走了数据，`win`可能大于通告窗口，因此，TCP最多能够接收`win`字节的数据(即使对端不会发送超过通告窗口大小的数据)。

因为函数后面的代码必须确定通告窗口中能放入多少数据(如果有)，所以现在必须计算通告窗口的大小。落在通告窗口之外的接收数据被丢弃：落在窗口左侧的数据是已接收并确认过的数据，落在窗口右侧的数据是暂不允许对端发送的数据。

28.6 完成被动打开或主动打开

如果连接状态等于LISTEN或者SYN_SENT，则执行本节给出的代码。连接处于这两个状态时，等待接收的报文段为SYN，任何其他报文段将被丢弃。

28.6.1 完成被动打开

连接状态等于 LISTEN时，执行图 28-15中的代码，其中变量 tp和inp指向图 28-7所创建的新的插口，而非服务器的监听插口。

```
tcp_input.c
456     switch (tp->t_state) {
457         /*
458          * If the state is LISTEN then ignore segment if it contains an RST.
459          * If the segment contains an ACK then it is bad and send an RST.
460          * If it does not contain a SYN then it is not interesting; drop it.
461          * Don't bother responding if the destination was a broadcast.
462          * Otherwise initialize tp->rcv_nxt, and tp->irs, select an initial
463          * tp->iss, and send a segment:
464          *   <SEQ=ISS><ACK=RCV_NXT><CTL=SYN,ACK>
465          * Also initialize tp->snd_nxt to tp->iss+1 and tp->snd_una to tp->iss
466          * Fill in remote peer address fields if not previously specified.
467          * Enter SYN_RECEIVED state, and process any other fields of this
468          * segment in this state.
469         */
470     case TCPS_LISTEN: {
471         struct mbuf *am;
472         struct sockaddr_in *sin;
473
474         if (tiflags & TH_RST)
475             goto drop;
476         if (tiflags & TH_ACK)
477             goto dropwithreset;
478         if ((tiflags & TH_SYN) == 0)
479             goto drop;
    }
    
```

tcp_input.c

图28-15 *tcp_input* 函数：检测监听插口上是否收到了 SYN

1. 丢弃RST、ACK或非SYN

473-478 如果接收报文段中带有 RST标志，则丢弃它。如果带有 ACK，则丢弃它并发送 RST作为响应(建立连接的最初的SYN报文段是少数几个不允许携带 ACK的报文段之一)。如果未带有SYN，则丢弃它。*case*子句的后续代码处理连接处于 LISTEN状态时收到了SYN的状况。新的连接状态等于 SYN_RCVD。

图28-16给出了*case*语句接下来的代码。

```
tcp_input.c
479     /*
480      * RFC1122 4.2.3.10, p. 104: discard bcast/mcast SYN
481      * in_broadcast() should never return true on a received
482      * packet with M_BCAST not set.
483     */
484     if (m->m_flags & (M_BCAST | M_MCAST) ||
485         IN_MULTICAST(ti->ti_dst.s_addr))
486         goto drop;
487
488     am = m_get(M_DONTWAIT, MT_SONAME); /* XXX */
489     if (am == NULL)
490         goto drop;
491     am->m_len = sizeof(struct sockaddr_in);
    
```

图28-16 *tcp_input* 函数：处理监听插口上收到的SYN报文段

```

491     sin = mtod(am, struct sockaddr_in *);
492     sin->sin_family = AF_INET;
493     sin->sin_len = sizeof(*sin);
494     sin->sin_addr = ti->ti_src;
495     sin->sin_port = ti->ti_sport;
496     bzero((caddr_t) sin->sin_zero, sizeof(sin->sin_zero));
497
498     laddr = inp->inp_laddr;
499     if (inp->inp_laddr.s_addr == INADDR_ANY)
500         inp->inp_laddr = ti->ti_dst;
501     if (in_pcbconnect(inp, am)) {
502         inp->inp_laddr = laddr;
503         (void) m_free(am);
504         goto drop;
505     }
506     (void) m_free(am);

```

tcp_input.c

图28-16 (续)

2. 如果是广播报文段或多播报文段，则丢弃它

479-486 如果数据报被发送到广播地址或多播地址，则丢弃它，TCP只支持点到点的应用。前面介绍过，根据数据帧携带的目的硬件地址，ether_input置位M_BCAST和M_MCAST标志，IN_MULTICAST宏可判定IP地址是否为D类地址。

注释引用了in_broadcast，因为Net/1代码(它不支持多播)在此处调用了这个函数，以检测目的IP地址是否为广播地址。Net/2中改为根据目的硬件地址，通过ether_input设定M_BCAST和M_MCAST标志。

Net/3只测试目的硬件地址是否为广播地址，而且不调用in_broadcast测试目的IP地址是否为广播地址。它假定除非目的硬件地址是广播地址，否则，目的IP地址绝不可能是广播地址，从而避免调用in_broadcast。另外，如果Net/3真的收到了一个数据帧，其目的硬件地址为单播地址，而目的IP地址为广播地址，将执行图28-16中的代码处理此种报文段。

目的地址参数IN_MULTICAST需要被转换为主机字节序。

3. 为客户端的IP地址和端口号分配mbuf

487-496 分配一个mbuf，保存sockaddr_in结构，其中带有客户端的IP地址和端口号。IP地址从IP首部的源地址字段中复制，端口号从TCP首部的源端口号字段中复制。这个结构用于把服务器的PCB连到客户，之后mbuf被释放。

注释中的“XXX”，是因为获取mbuf的消耗等同于之后调用in_pcbconnect的消耗。不过此处的代码位于tcp_input中较慢的一条执行路径。从图24-5可知，不足%2的接收报文段的处理中会用到这段处理代码。

4. 设定PCB中的本地地址

497-499 laddr是绑定在插口上的本地地址。如果服务器没有为插口绑定一个确定地址(正常情况下)，IP首部的目的地址将成为PCB中的本地地址。注意，不管数据报是在哪个端口收到的，都将保存IP首部中的目的地址。

注意，laddr不会是通配地址，因为图28-7中的代码已将收到报文段中的目的IP

地址赋给了它。

5. 填充PCB中的对端地址

500-505 调用in_pcconnect，把服务器的PCB与客户相连，填充PCB中的对端地址和对端口号。之后，释放mbuf。

图28-17给出了函数下一部分的代码，结束case语句的处理。

```
tcp_input.c
506     tp->t_template = tcp_template(tp);
507     if (tp->t_template == 0) {
508         tp = tcp_drop(tp, ENOBUFS);
509         dropsocket = 0; /* socket is already gone */
510         goto drop;
511     }
512     if (optp)
513         tcp_dooptions(tp, optp, optlen, ti,
514                         &ts_present, &ts_val, &ts_ecr);
515     if (iss)
516         tp->iss = iss;
517     else
518         tp->iss = tcp_iss;
519     tcp_iss += TCP_ISSINCR / 2;
520     tp->irs = ti->ti_seq;
521     tcp_sendseqinit(tp);
522     tcp_rcvseqinit(tp);
523     tp->t_flags |= TF_ACKNOW;
524     tp->t_state = TCPS_SYN_RECEIVED;
525     tp->t_timer[TCPTV_KEEP] = TCPTV_KEEP_INIT;
526     dropsocket = 0; /* committed to socket */
527     tcpstat.tcps_accepts++;
528     goto trimthenstep6;
529 }
```

tcp_input.c

图28-17 `tcp_input` 函数：完成LISTEN状态下收到SYN报文段的处理

6. 分配并初始化IP和TCP首部模板

506-511 调用tcp_template创建IP和TCP首部的模板。图28-7中调用sonewconn时，为新连接分配了PCB和TCP控制块，但未分配首部模板。

7. 处理所有的TCP选项

512-514 如果存在TCP选项，则调用tcp_dooptions进行处理。图28-8中曾调用过一次tcp_dooptions，但只处理非LISTEN状态时的TCP选项。现在，插口处于监听状态，PCB中的对端地址已填入(tcp_mss函数中会用到对端地址)，调用tcp_dooptions：获取到达对端的路由；查看对端主机是本地结点还是远端结点(选择MSS时，需考虑到对端的网络ID和子网ID)。

8. 初始化ISS

515-519 通常情况下，初始发送序号复制自全局变量tcp_iss，之后增加64 000(TCP_ISSINCR除以2)。如果局部变量iss非零，则使用iss取代tcp_iss，初始化连接的发送序号。

出现以下事件序列时，会用到iss：

- 服务器的IP地址为128.1.2.3，端口号为27。

- IP地址等于192.3.4.5的客户与前述服务器建立了连接，客户端口号等于3000。服务器的插口对为{128.1.2.3, 27, 192.3.4.5, 3000}。
- 服务器主动关闭了连接，上述插口对的状态转移到TIME_WAIT。连接处于这种状态时，最后收到的序号保存在TCP控制块中。假设序号等于100 000。
- 连接离开TIME_WAIT状态之前，收到来自于同一客户主机、同一端口号(192.3.4.5, 3000)的新的SYN，TCP寻找处于TIME_WAIT状态的连接所对应的PCB，而不是监听服务器的PCB。假定新SYN报文段的序号等于200 000。
- 因为连接状态不等于LISTEN，所以将不执行刚讨论过的图28-17中的代码，而是执行图28-28中的代码。我们将看到，其中包含了下列处理逻辑：如果新SYN报文段的序号(200 000)大于客户最后发来的序号(100 000)，那么：(1)局部变量iss等于100 000加上128 000；(2)处于TIME_WAIT状态的连接被完全关闭(PCB和TCP控制块被删除)；(3)控制跳转到findpcb(图28-5)。
- 寻找服务器监听插口的PCB(假定监听服务器还在运行)，执行本节中介绍的代码。图28-17中的代码将使用局部变量iss(现在等于228 000)初始化新连接的tcp_iss。

RFC 1122中定义的这种处理逻辑，允许同一个客户和服务器重用同样的插口连接对，只要服务器主动关闭原有连接。它也解释了为什么只要有进程调用connect，全局变量tcp_iss就递增64 000(图30-4)：为了确保在某个客户不断地重建与同一个服务器的连接的情况下，即使前一次连接上没有传输数据，甚至500 ms定时器都未超时(定时器超时处理代码会增加tcp_iss)，新建连接仍可以使用较大的ISS。

9. 初始化控制块中的序号变量

520-522 图28-17中，初始接收序号复制自SYN报文段中的序号字段(irs)。下面两个宏初始化了TCP控制块中的相关变量。

```
#define tcp_rcvseqinit(tp) \
    (tp)->rcv_adv = (tp)->rcv_nxt = (tp)->irs + 1

#define tcp_sendseqinit(tp) \
    (tp)->snd_una = (tp)->snd_nxt = (tp)->snd_max = (tp)->snd_up = \
    (tp)->iss
```

因为SYN占据一个序号，所以第一个宏表达式需加1。

10. 确认SYN并更新状态

523-525 因为对于SYN的确认必须立即发送，所以置位TF_ACKNOW标志。连接状态转移到SYN_RECV，连接建立定时器设为75秒(TCPTV_KEEP_INIT)。因为TF_ACKNOW置位，函数结束时将调用tcp_output。从图24-16可知，此种tcp_outflags会导致发送携带SYN和ACK的报文段。

526-528 现在，TCP结束了从图28-7开始的新插口的创建，drop插口标志被清除。控制跳转到trimthenstep6处，完成SYN报文段的处理。前面介绍过，SYN报文段能够携带数据，尽管只有等连接进入ESTABLISHED状态后，数据才会被提交给应用程序。

28.6.2 完成主动打开

图28-18给出了连接进入SYN_SENT状态后，处理代码的第一部分。TCP等待接收SYN。

```

530      /*
531       * If the state is SYN_SENT:
532       * if seg contains an ACK, but not for our SYN, drop the input.
533       * if seg contains an RST, then drop the connection.
534       * if seg does not contain SYN, then drop it.
535       * Otherwise this is an acceptable SYN segment
536       * initialize tp->rcv_nxt and tp->irs
537       * if seg contains ack then advance tp->snd_una
538       * if SYN has been acked change to ESTABLISHED else SYN_RCVD state
539       * arrange for segment to be acked (eventually)
540       * continue processing rest of data/controls, beginning with URG
541     */
542 case TCPS_SYN_SENT:
543   if ((tiflags & TH_ACK) &&
544       (SEQ_LEQ(ti->ti_ack, tp->iss) ||
545        SEQ_GT(ti->ti_ack, tp->snd_max)))
546     goto dropwithreset;
547   if (tiflags & TH_RST) {
548     if (tiflags & TH_ACK)
549       tp = tcp_drop(tp, ECONNREFUSED);
550     goto drop;
551   }
552   if ((tiflags & TH_SYN) == 0)
553     goto drop;

```

tcp_input.c

图28-18 tcp_input 函数：判定收到的SYN是否是所需的响应

1. 验证收到的ACK

530-546 当应用进程主动打开，TCP发送SYN时，从图30-4可知，连接的 iss 将等于全局变量 `tcp_iss`，宏 `tcp_sendseqinit`(前一节结尾给出了定义)被执行。假设ISS等于365，图28-19给出了 `tcp_output` 发送SYN后的发送序号变量。

`tcp_sendseqinit` 初始化图28-19中的4个变量为365，接着图26-31中的代码在发送SYN之后，把其中两个增至366。因此，如果图28-18中的接收报文段包含ACK，并且确认字段小于等于 `iss(365)`，或者大于 `snd_max(366)`，ACK无效，丢弃报文段并发送RST作为响应。注意，连接处于 SYN_SENT 状态时，收到的报文段中无需携带 ACK。它可以只包括SYN，这种情况称为同时打开(simultaneous open)(图24-15)。

2. 处理并丢弃RST报文段

547-551 如果接收报文段中带有RST，则丢弃它。但首先应查看ACK标志，因为如果报文段同时携带了有效的ACK(已验证过)和RST，则说明对端拒绝本次连接请求，通常是因为服务器进程未运行。这种情况下，`tcp_drop`设定插口的 `so_error` 变量，并向调用 `connect` 的应用进程返回差错。

3. 判定SYN标志是否置位

552-553 如果收到报文段中的SYN标志未置位，则丢弃它。

这个 `case` 语句的其余代码用于处理本地发送连接请求后，收到对端响应的 SYN 报文段(及可选的ACK)的情况。图28-20给出了 `tcp_input` 下一部分的代码，继续处理SYN。

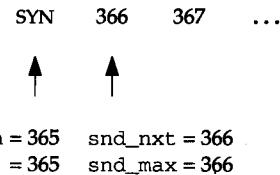


图28-19 ISS等于365的SYN发送后的发送序号变量

```

554     if (tiflags & TH_ACK) {
555         tp->snd_una = ti->ti_ack;
556         if (SEQ_LT(tp->snd_nxt, tp->snd_una))
557             tp->snd_nxt = tp->snd_una;
558     }
559     tp->t_timer[TCPT_REXMT] = 0;
560     tp->irs = ti->ti_seq;
561     tcp_rcvseqinit(tp);
562     tp->t_flags |= TF_ACKNOW;
563     if (tiflags & TH_ACK && SEQ_GT(tp->snd_una, tp->iss)) {
564         tcpstat.tcps_connects++;
565         soisconnected(so);
566         tp->t_state = TCPS_ESTABLISHED;
567         /* Do window scaling on this connection? */
568         if ((tp->t_flags & (TF_RCVD_SCALE | TF_REQ_SCALE)) ==
569             (TF_RCVD_SCALE | TF_REQ_SCALE)) {
570             tp->snd_scale = tp->requested_s_scale;
571             tp->rcv_scale = tp->request_r_scale;
572         }
573         (void) tcp_reass(tp, (struct tcphdr *) 0,
574                           (struct mbuf *) 0);
575         /*
576          * if we didn't have to retransmit the SYN,
577          * use its rtt as our initial srtt & rtt var.
578          */
579         if (tp->t_rtt)
580             tcp_xmit_timer(tp, tp->t_rtt);
581     } else
582         tp->t_state = TCPS_SYN RECEIVED;

```

*tcp_input.c*图28-20 *tcp_input* 函数：发送连接请求后，收到对端响应的 SYN

4. 处理ACK

554-558 如果报文段中有 ACK，令 *snd_una* 等于报文段的确认字段。以图 28-19 为例，*snd_una* 应更新为 366，因为确认字段惟一有效的值就是 366。如果 *snd_nxt* 小于 *snd_una*(在图28-19的例子中不可能发生)，令 *snd_nxt* 等于 *snd_una*。

5. 关闭连接建立定时器

559 连接建立定时器被关闭。

此处代码有错误。连接建立定时器只有在ACK标志置位时才能被关闭，因为收到一个不带ACK的SYN报文段，只是说明连接双方同时打开，而不意味着对端已收到了SYN。

6. 初始化接收序号

560-562 初始接收序号从接收报文段的序号字段中复制。*tcp_rcvseqinit*宏(上一节结束时给出了定义)初始化 *rcv_adv* 和 *rcv_nxt* 为接收序号加 1。置位 *TF_ACKNOW* 标志，从而在函数结尾处调用 *tcp_output*，发送报文段携带的确认字段应等于 *rcv_nxt*(图26-27)，确认刚收到的SYN。

563-564 如果接收报文段带有 ACK，并且 *snd_una* 大于连接的ISS，主动打开处理完毕，连接进入ESTABLISHED状态。

第二个测试条件其实是多余的。图 28-20 起始处，如果 ACK 标志置位，*snd_una* 将等于接收报文段的确认字段值。另外，图 28-18 中紧跟着 case 语句的 if 语句验证了收到的确认字段大于 ISS。所以，此处只要 ACK 置位，就可以确保 *snd_una* 大于 ISS。

7. 连接建立

565-566 soisconnected 设定插口进入连接状态，TCP连接的状态转移到ESTABLISHED。

8. 查看窗口大小选项

567-572 如果TCP在本地SYN中加入窗口大小选项，并且收到的SYN中也包含了这一选项，使用窗口缩放功能，设定 `snd_scale` 和 `rcv_scale`。因为 `tcp_newtcpcb` 初始化TCP控制块为0，所以，如果不使用窗口大小选项，这两个变量的默认值为0。

9. 向应用进程提交队列中的数据

573-574 由于数据可能在连接未建立之前到达，调用 `tcp_reass` 把数据放入接收缓存，第二个参数为空。

测试条件其实不必要的。因为 TCP刚收到带有 ACK的SYN报文段，状态从SYN_SENT转移到ESTABLISHED。即使有数据出现在SYN中，也会被暂时搁置，直到函数快结束，控制转到 `dodata` 标注时才会被处理。如果 TCP收到不带 ACK的SYN(同时打开)，即使报文段携带数据，也会被暂时搁置，等到收到了ACK，连接从SYN_RCVD转移到ESTABLISHED之后，才会被处理。

尽管SYN中可以携带数据，并且Net/3能够正确处理这样的报文段，但Net/3自己不会产生这样的报文段。

10. 更新RTT估计器值

575-580 如果确认的SYN正被计时，`tcp_xmit_timer` 将根据得到的对SYN报文段的测量值初始化RTT估计器值。

TCP在此处忽略收到的时间戳选项，只查看 `t_rtt` 计数器。TCP主动打开时，在第一个SYN中加入时间戳选项(图26-24)，如果对端也同意采用时间戳，就会在它响应的SYN中回应收到的时间戳(参见图28-10，Net/3在SYN中回应收到的时间戳)。因此，TCP在此处可以使用收到的时间戳，而不用 `t_rtt`，但因为两者的精度相同(500ms)，在这一点上时间戳并无优势可言。使用时间戳，而非 `t_rtt` 计数器的真正好处在于高速网络中同时发送大量数据时，能提供更多的RTT测量值和更好的估计器值(希望如此)。

11. 同时打开

581-582 如果TCP在SYN_SENT状态收到不带ACK的SYN，则称为同时打开，连接转移到SYN_RCVD状态。

图28-21给出了函数的下一部分代码，处理SYN中可能携带的数据。图28-17结尾处，代码跳转至 `trimthenstep6` 标注处，这里也有类似的情况。

```

583     trimthenstep6:
584         /*
585          * Advance ti->ti_seq to correspond to first data byte.
586          * If data, trim to stay within window,
587          * dropping FIN if necessary.
588         */

```

图28-21 `tcp_input` 函数：接收SYN的通用处理

```

589         ti->ti_seq++;
590         if (ti->ti_len > tp->rcv_wnd) {
591             todrop = ti->ti_len - tp->rcv_wnd;
592             m_adj(m, -todrop);
593             ti->ti_len = tp->rcv_wnd;
594             tiflags &= ~TH_FIN;
595             tcpstat.tcpstat_rcvpackafterwin++;
596             tcpstat.tcpstat_rcvbyteafterwin += todrop;
597         }
598         tp->snd_w11 = ti->ti_seq - 1;
599         tp->rcv_up = ti->ti_seq;
600         goto step6;
601     }

```

tcp_input.c

图28-21 (续)

584-589 报文段序号加1，以计入SYN。如果SYN带有数据，*ti_seq*现在应等于数据第一个字节的序号。

12. 丢弃落在接收窗口外的数据

590-597 *ti_len*等于报文段中的数据字节数。如果它大于接收窗口，超出部分的数据(*ti_len*减去*rcv_wnd*)将被*m_adj*丢弃。函数参数为负值，所以，将从mbuf链尾部起逆向删除数据(图2-20)。更新*ti_len*，等于数据删除后mbuf中剩余的数据量。清除FIN标志，这是因为FIN可能跟在最后一个数据字节之后，落在接收窗口外而被丢弃。

如果SYN是对本地连接请求的响应，且携带的数据过多，则说明对端收到的SYN报文段中带有窗口通告，但对端忽略了通告的窗口大小，并禁止不规范的行为。但如果主动打开的SYN报文段中带有大量数据，则说明对端还未收到窗口通告，所以不得不猜测SYN中能够携带多少数据。

13. 强制更新窗口变量

598-599 *snd_w11*等于接收序号减1。从图29-15中可看到，这将强制更新3个窗口变量：*snd_wnd*、*snd_w11*和*snd_w12*。接收紧急指针(*rcv_up*)等于接收序号。控制跳转到标注step6处，与RFC 793定义的步骤相对应，我们将在图29-15中详细讨论。

28.7 PAWS：防止序号回绕

图28-22给出了*tcp_input*下一部分的代码，处理可能出现的序号回绕：RFC 1323中定义的PAWS算法。请回想一下我们在26.6节关于时间戳的讨论。

```

602     /*
603      * States other than LISTEN or SYN_SENT.
604      * First check timestamp, if present.
605      * Then check that at least some bytes of segment are within
606      * receive window. If segment begins before rcv_nxt,
607      * drop leading data (and SYN); if nothing left, just ack.
608      *
609      * RFC 1323 PAWS: If we have a timestamp reply on this segment
610      * and it's less than ts_recent, drop it.
611      */
612     if (ts_present && (tiflags & TH_RST) == 0 && tp->ts_recent &&

```

*tcp_input.c*图28-22 *tcp_input* 函数：处理时间戳选项

```

613     TSTMP_LT(ts_val, tp->ts_recent)) {
614         /* Check to see if ts_recent is over 24 days old. */
615         if ((int) (tcp_now - tp->ts_recent_age) > TCP_PAWS_IDLE) {
616             /*
617              * Invalidate ts_recent. If this segment updates
618              * ts_recent, the age will be reset later and ts_recent
619              * will get a valid value. If it does not, setting
620              * ts_recent to zero will at least satisfy the
621              * requirement that zero be placed in the timestamp
622              * echo reply when ts_recent isn't valid. The
623              * age isn't reset until we get a valid ts_recent
624              * because we don't want out-of-order segments to be
625              * dropped when ts_recent is old.
626             */
627             tp->ts_recent = 0;
628         } else {
629             tcpstat.tcps_rcvduppack++;
630             tcpstat.tcps_rcvdupbyte += ti->ti_len;
631             tcpstat.tcps_pawsdrop++;
632             goto dropafterack;
633         }
634     }

```

tcp_input.c

图28-22 (续)

1. 基本PAWS测试

602-613 如果存在时间戳，则调用 `tcp_dooptions` 设定 `ts_present`。如果下列3个条件全真，则丢弃报文段：

- 1) RST标志未置位(参见习题28.8)。
- 2) TCP曾收到过对端发送的有效的时间戳(`ts_recent`非零)；并且
- 3) 当前报文段中的时间戳(`ts_val`)小于原先收到的时间戳。

PAWS算法基于这样的假定：对于高速连接，32 bit时间戳值回绕的速度远小于32 bit序号回绕的速度。习题28.6说明，即使是最高的时钟计数器更新频率(每毫秒加1)，时间戳的符号位也要24天才会回绕一次。而在千兆级网络中，序号可能17秒就回绕一次(卷1的24.3节)。因此，如果报文段时间戳小于从同一个连接收到的最近一次的时间戳，说明是个重复报文段，应被丢弃(还需进行后续的时间戳过期测试)。尽管因为序号已过时，`tcp_input`也可将其丢弃，但PAWS算法能够有效地处理序号回绕速率很高的高速网。

注意，PAWS算法是对称的：它不仅丢弃重复的数据报文段，也丢弃重复的ACK。PAWS处理所有收到的报文段，前面介绍过，首部预测代码也采用了PAWS测试(图28-11)。

2. 检查过期时间戳

614-627 尽管可能性不大，PAWS测试还是会失败，因为连接有可能长时间空闲。收到的报文段并非重复报文段，但连接空闲时间过长，造成时间戳值回绕，从而小于从同一个连接收到的最近一次的时间戳。

无论何时，`ts_recent`保存接收报文段中的时间戳值，`ts_recent_age`记录当前时间(`tcp_now`)。如果`ts_recent`的最后一次更新发生在24天之前，则将其清零，不是一个有效的时间戳值。常量 `TCP_PAWS_IDLE` 定义为 $(24 \times 24 \times 60 \times 60 \times 2)$ ，最后的乘数2指每秒钟2个滴答。这种情况下，不丢弃接收报文段，因为问题是时间戳过期，而非重复报文段。参见习

题28.6和28.7。

图28-23举例说明了时间戳过期问题。连接左侧的系统是一个非Net/3的TCP实现，以RFC 1323中规定的最高速度，每毫秒更新一次时钟。连接右侧是Net/3实现。

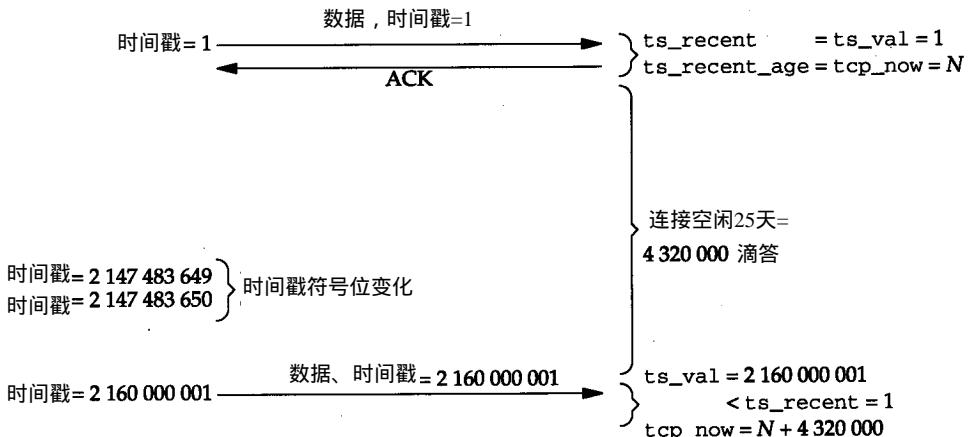


图28-23 过期时间戳举例

第一个数据报文段中携带的时间戳值等于1，所以 ts_recent 等于1， ts_recent_age 等于当前时间(tcp_now)，如图28-11和图28-35所示。连接空闲25天，在此期间 tcp_now 增加了4 320 000 ($25 \times 24 \times 60 \times 60 \times 1000$)，对端的时间戳值增加了2 160 000 000 ($25 \times 24 \times 60 \times 60 \times 1000$)，时间戳值的符号位改变，即2 147 483 649大于1，而2 147 483 650小于1(回想图24-26)。因此，当收到的数据报文段中的时间戳等于2 160 000 001时，调用TSTMP_LT宏进行比较，收到的时间戳小于 $ts_recent(1)$ ，PAWS测试失败。但因为 tcp_now 减去 ts_recent_age 大于24天，说明造成失败的原因是连接空闲时间过长，报文段被接受。

3. 丢弃重复报文段

6.28-6.33 如果PAWS算法测试说明收到的是一个重复报文段，确认之后丢弃该报文段（所有重复报文段都必须被确认），不更新本地时间戳变量。

图24-5中， $tcp_pawsdrop$ (22)远小于 $tcp_rcvdupack$ (46 953)。这可能是因为目前只有很少的系统支持时间戳，导致绝大多数重复报文段直到TCP输出处理中才被发现和丢弃，而非PAWS。

28.8 裁剪报文段使数据在窗口内

本节讨论如何调整收到的报文段，确保它只携带能够放入接收窗口内的数据：

- 丢弃接收报文段起始处的重复数据；并且
- 从报文段尾部起，丢弃超出接收窗口的数据。

从而只剩下可放入接收窗口的新数据。图28-24给出的代码，用于判定报文段起始处是否存在重复数据。

1. 查看报文段前部是否存在重复数据

6.35-6.36 如果接收报文段的起始序号(ti_seq)小于等待接收的下一序号($recv_nxt$)，则

`todrop`大于0，报文段前部有重复数据。这些数据已被确认并提交给应用进程(图24-18)。

```
635     todrop = tp->recv_nxt - ti->ti_seq;                               tcp_input.c
636     if (todrop > 0) {
637         if (tiflags & TH_SYN) {
638             tiflags &= ~TH_SYN;
639             ti->ti_seq++;
640             if (ti->ti_urp > 1)
641                 ti->ti_urp--;
642             else
643                 tiflags &= ~TH_URG;
644             todrop--;
645     }                                         tcp_input.c
```

图28-24 `tcp_input` 函数：查看报文段起始处的重复数据

2. 丢弃重复SYN

637-645 如果SYN标志置位，它必然指向报文段的第一个数据序号，现已知是重复数据。清除SYN，报文段的起始序号加1，以越过重复的SYN。此外，如果接收报文段中的紧急指针大于1(`ti_urp`)，则必须将其减1，因为紧急数据偏移量以报文段起始序号为基准。如果紧急指针等于0或者1，则不做处理，为防止出现等于1的情况，清除URG标志。最后，`todrop`减1(因为SYN占用一个序号)。

图28-25继续处理报文段前部的重复数据。

```
646     if (todrop >= ti->ti_len) {                                         tcp_input.c
647         tcpstat.tcp_rcvduppack++;
648         tcpstat.tcp_rcvdupbyte += ti->ti_len;
649         /*
650          * If segment is just one to the left of the window,
651          * check two special cases:
652          * 1. Don't toss RST in response to 4.2-style keepalive.
653          * 2. If the only thing to drop is a FIN, we can drop
654          *     it, but check the ACK or we will get into FIN
655          *     wars if our FINs crossed (both CLOSING).
656          * In either case, send ACK to resynchronize,
657          * but keep on processing for RST or ACK.
658         */
659         if ((tiflags & TH_FIN && todrop == ti->ti_len + 1)
660             )
661             {
662                 todrop = ti->ti_len;
663                 tiflags &= ~TH_FIN;
664                 tp->t_flags |= TF_ACKNOW;
665             }
666             /*
667              * Handle the case when a bound socket connects
668              * to itself. Allow packets with a SYN and
669              * an ACK to continue with the processing.
670              */
671             if (todrop != 0 || (tiflags & TH_ACK) == 0)
672                 goto dropafterack;
673             }
674         }
675         tcpstat.tcp_rcvpartduppack++;
676         tcpstat.tcp_rcvpartdupbyte += todrop;
```

图28-25 `tcp_input` 函数：处理完全重复的报文段

```

676         }
677         m_adj(m, todrop);
678         ti->ti_seq += todrop;
679         ti->ti_len -= todrop;
680         if (ti->ti_urp > todrop)
681             ti->ti_urp -= todrop;
682         else {
683             tiflags &= ~TH_URG;
684             ti->ti_urp = 0;
685         }
686     }

```

tcp_input.c

图28-25 (续)

3. 判定报文段数据是否完全重复

646-648 如果报文段前部重复的数据字节数大于等于报文段大小，则是一个完全重复的报文段。

4. 判定重复FIN

649-663 接下来测试FIN是否重复，图28-26举例说明了这一情况。

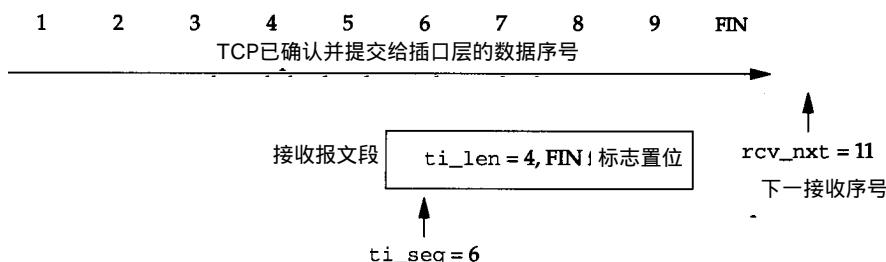


图28-26 举例：带有FIN标志的重复报文段

图28-26的例子中，`todrop`等于5，大于等于`ti_len`(4)。因为FIN置位，并且`todrop`等于`ti_len`加1，所以清除FIN标志，`todrop`重设为4，置位`TF_ACKNOW`，函数结束时立即发送ACK。这个例子也适用于其他报文段，如果`ti_seq`加上`ti_len`等于10。

代码的注释提到了4.2BSD实现中的保活定时器，Net/3省略了相关处理(if语句中的另一项测试)。

5. 生成重复ACK

664-672 如果`todrop`非零(报文段携带的全部是重复数据)，或者ACK标志未置位，则丢弃报文段，调用`dropafterack`生成ACK。出现这种情况，一般是因为对端未收到ACK，导致报文段重发。TCP生成新的ACK。

6. 处理同时打开或半连接

664-672 代码还处理同时打开，以及插口与自己建立连接的情况，将在下一节中详细讨论。如果`todrop`等于0(完全重复报文段中不包含数据)，且ACK标志置位，则继续下一步的处理。

`if`语句是4.4BSD版中新加的。早期的基于Berkeley的系统只是简单地跳转到`dropafterack`，即不处理同时打开，也不处理与自己建立连接的情况。

即使做了改进，这段代码仍有错误，我们在本节结束时将谈到这一点。

7. 收到部分重复报文段时，更新统计值

673-676 当todrop小于报文段长度时，执行else语句：报文段携带数据中只有部分重複。

8. 删除重复数据，更新紧急指针

677-685 调用m_adj，从mbuf链的首部开始删除重复数据，并相应地调整起始序号和长度。如果紧急指针指向的数据仍在 mbuf中，也需做相应的调整。否则，紧急指针清零，并清除URG标志。

图28-27给出了函数下一部分的代码，处理应用进程终止后到达的数据。

```
687  /*
688   * If new data is received on a connection after the
689   * user processes are gone, then RST the other end.
690   */
691  if ((so->so_state & SS_NOFDREF) &&
692      tp->t_state > TCPS_CLOSE_WAIT && ti->ti_len) {
693      tp = tcp_close(tp);
694      tcpstat.tcpstat_rcvafterclose++;
695      goto dropwithreset;
696 }
```

tcp_input.c

图28-27 tcp_input 函数：处理应用进程终止后到达的数据

687-696 如果找不到插口的描述符，说明应用进程已关闭了连接（连接状态等于图24-16中大于CLOSE_WAIT的5个状态中的任何一个），若接收报文段中有数据，则连接被关闭。报文段被丢弃，输出RST做为响应。

因为TCP支持半关闭功能，如果应用进程意外终止（也许被某个信号量终止），做为进程终止的一部分，内核将关闭所有打开的描述符，TCP将发送FIN。连接转移到FIN_WAIT_1状态。因为FIN的接收者无法知道对端执行的是完全关闭，还是半关闭。如果它假定是半关闭，并继续发送数据，那么将收到图28-27中发送的FIN。

图28-28给出了函数下一部分的代码，从接收报文段中删除落在通告窗口右侧的数据。

```
697  /*
698   * If segment ends after window, drop trailing data
699   * (and PUSH and FIN); if nothing left, just ACK.
700   */
701  todrop = (ti->ti_seq + ti->ti_len) - (tp->rcv_nxt + tp->rcv_wnd);
702  if (todrop > 0) {
703      tcpstat.tcpstat_rcvpackafterwin++;
704      if (todrop >= ti->ti_len) {
705          tcpstat.tcpstat_rcvbyteafterwin += ti->ti_len;
706          /*
707           * If a new connection request is received
708           * while in TIME_WAIT, drop the old connection
709           * and start over if the sequence numbers
710           * are above the previous ones.
711           */
712      if (tiflags & TH_SYN &&
713          tp->t_state == TCPS_TIME_WAIT &&
```

tcp_input.c

图28-28 tcp_input 函数：删除落在窗口右侧的数据

```

714     SEQ_GT(ti->ti_seq, tp->rcv_nxt)) {
715         iss = tp->rcv_nxt + TCP_ISSINCR;
716         tp = tcp_close(tp);
717         goto findpcb;
718     }
719     /*
720      * If window is closed can only take segments at
721      * window edge, and have to drop data and PUSH from
722      * incoming segments. Continue processing, but
723      * remember to ack. Otherwise, drop segment
724      * and ack.
725     */
726     if (tp->rcv_wnd == 0 && ti->ti_seq == tp->rcv_nxt) {
727         tp->t_flags |= TF_ACKNOW;
728         tcpstat.tcpstat_rcvwinprobe++;
729     } else
730         goto dropafterack;
731     } else
732         tcpstat.tcpstat_rcvbyteafterwin += todrop;
733     m_adj(m, -todrop);
734     ti->ti_len -= todrop;
735     tiflags &= ~(TH_PUSH | TH_FIN);
736 }

```

tcp_input.c

图28-28 (续)

9. 计算落在通告窗口右侧的字节数

697-703 todrop等于接收报文段中落在通告窗口右侧的字节数。例如，在图 28-29 中，todrop等于(6+5)减去(4+6)，即等于1。

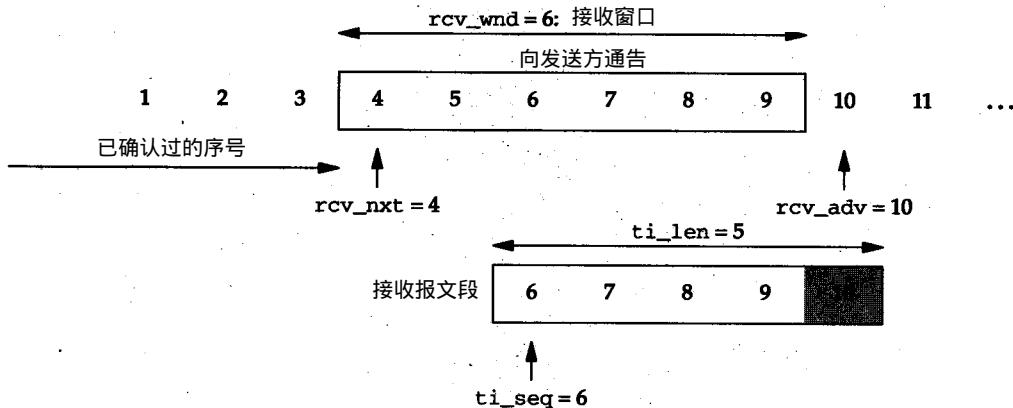


图28-29 举例：接收报文段部分数据落在窗口右侧

10. 如果连接处于TIME_WAIT状态，查看有无新的连接请求

704-718 如果todrop大于等于报文段长度，则丢弃整个报文段。如果下列3个条件全真：

- 1) SYN标志置位；并且
- 2) 连接处于TIME_WAIT状态；并且
- 3) 新的起始序号大于连接上最后收到的序号；

说明对端要求在已被关闭且正处于 TIME_WAIT 状态的连接上重建连接。RFC 1122 允许这种情况，但要求新连接的ISS必须大于最后收到的序号(*rcv_nxt*)。TCP在*rcv_nxt*的基础上增加

128 000(TCP_ISSINCR)，得到执行图28-17中的代码时所使用的ISS。调用tcp_close释放处于TIME_WAIT状态的原有连接的PCB和TCP控制块。控制跳转到findpcb(图28-5)，寻找监听服务器的PCB(假定服务器仍在运行)。然后执行图28-7中的代码，为新连接创建新的插口，最后执行图28-16和图28-17中的代码，完成新连接请求的处理。

11. 判定是否为窗口探测报文段

719-728 如果接收窗口已关闭(recv_wnd等于0)，且接收报文段中的数据从窗口最左端开始(recv_nxt)，说明是对端发送的窗口探测报文段。TCP立即发送响应ACK，其中包含等待接收的序号。

12. 丢弃完全落在窗口之外的其他报文段

729-730 如果报文段整个落在窗口之外，且并非窗口探测报文段，则丢弃该报文段，并发送携带等待接收序号的ACK，作为响应。

13. 处理携带部分有效数据的报文段

731-735 通过m_adj，从mbuf链中删除落在窗口右侧的数据，并更新ti_len。如果接收报文段是对端发送的窗口探测报文段，m_adj将丢弃mbuf链中的所有数据，并将ti_len设为0，最后清除FIN和PSH标志。

何时丢弃ACK

图28-25中的代码有错误，在几种情况下，本应继续进行报文段处理，控制却跳转到dropafterack[Carlson 1993; Lanciani 1993]。系统实际运行时，如果连接双方重组队列中都存在缺失报文段，并都进入持续状态，将造成死锁，因为双方都将丢弃正常的ACK。

纠正的方法是简化图28-25起始处的代码。控制不再跳转到dropafterack，如果收到了完全重复报文段，则关闭FIN标志，并在函数结束时强迫立即发送ACK。删除图28-25中的646~676行的代码，而代之以图28-30中的代码。此外，新代码还更正了原代码中的另一个错误(习题28.9)。

```

if (todrop > ti->ti_len ||  
    todrop == ti->ti_len && (tiflags & TH_FIN) == 0) {  
  
    /*  
     * Any valid FIN must be to the left of the window.  
     * At this point the FIN must be a duplicate or  
     * out of sequence; drop it.  
     */  
    tiflags &= ~TH_FIN;  
  
    /*  
     * Send an ACK to resynchronize and drop any data.  
     * But keep on processing for RST or ACK.  
     */  
    tp->t_flags |= TF_ACKNOW;  
    todrop = ti->ti_len;  
    tcpstat.tcpstat_rcvdupbyte += todrop;  
    tcpstat.tcpstat_rcvdupack++;  
  
} else {  
    tcpstat.tcpstat_rcvpartduppack++;  
    tcpstat.tcpstat_rcvpartdupbyte += todrop;  
}

```

图28-30 图28-28中646~676行代码的修正

28.9 自连接和同时打开

读者应首先理解插口与自己建立连接的步骤。接着会看到在 4.4BSD中，如何巧妙地通过一行代码修正图28-25中的错误，从而不仅能够处理自连接，还能处理 4.4BSD以前的版本中都无法正确处理的同时打开。

应用进程创建一个插口，并通过下列系统调用建立自连接：`socket`，`bind`绑定到一个本地端口(假定为 3000)，之后`connect`试图与同一个本地地址和同一个端口号建立连接。如果`connect`成功，则插口已建立了与自己的连接：向这个插口写入的所有数据，都可以在同一插口上读出。这有点类似于全双工的管道，但只有一个，而非两个标识符。尽管很少有应用进程会这样做，但实际上它是一种特殊的同时打开，两者的状态变迁图相同。如果系统不允许插口建立自连接，那么它也很可能无法正确处理同时打开，而后者是 RFC 1122所要求的。有些人对于自连接能成功感到非常惊诧，因为只用了一个 Internet PCB和一个TCP控制块。不过，TCP是全双工的、对称的协议，它为每个方向上的数据流保留一份专有数据。

图28-31给出了应用进程调用`connect`时的发送序号空间，SYN已发送，连接状态为`SYN_SENT`。

插口收到SYN后，执行图28-18和图28-20中的代码，但因为SYN中未包含ACK，连接状态转移到`SYN_RCVD`。从状态变迁图(图24-15)可知，与同时打开类似。图 28-32给出了接收序号空间。图 28-20置位`TF_ACKNOW`，`tcp_output`生成的报文段将包含SYN和ACK(图24-16中的`tcp_outflags`)。SYN序号等于153，而确认序号等于154。

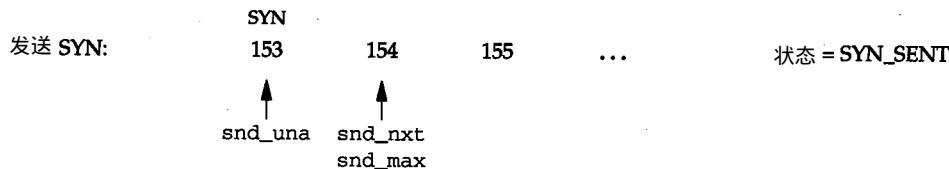


图28-31 自连接：SYN发送后的发送序号空间

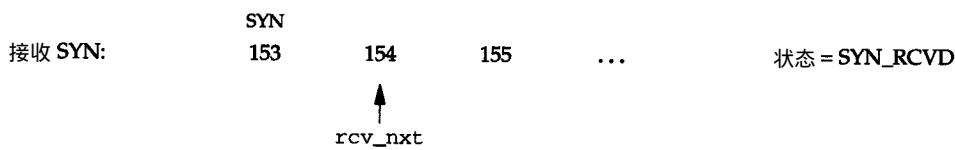


图28-32 自连接：收到的SYN处理完毕后的接收序号空间

与图28-20处理的正常情况相比，发送序号空间没有变化，只是连接状态等于`SYN_SENT`。图28-33给出了收到同时带有SYN和ACK的报文段时，接收序号空间的状态。

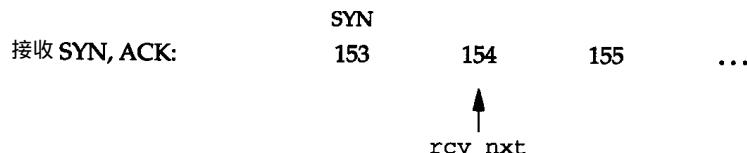


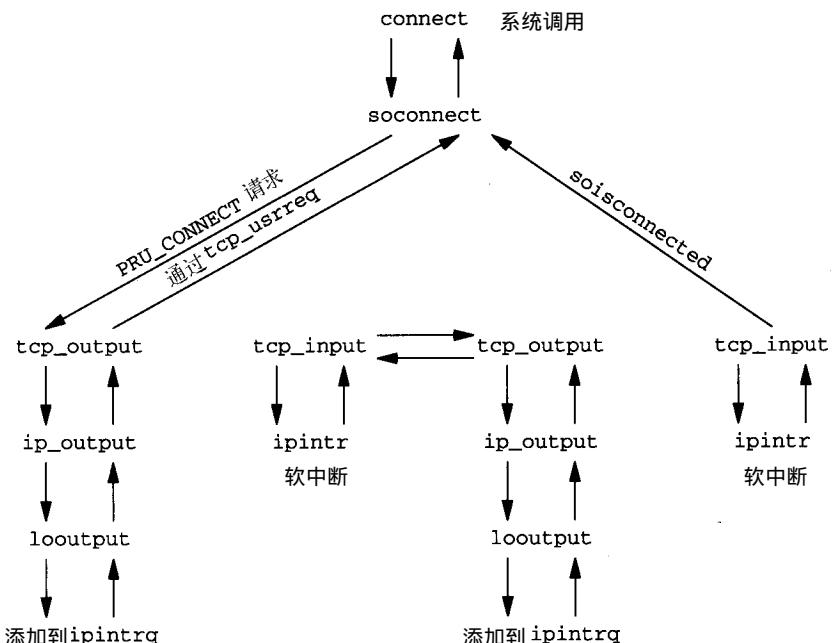
图28-33 收到带有SYN和ACK报文段时，接收序号空间的状态

因为连接状态等于 SYN_RCVD，将执行图29-2中的代码处理收到的报文段，而不用我们在本章前面讨论过的处理主动打开或被动打开的代码。但在此之前，首先遇到的是图 28-24中的代码，而且从测试结果看似乎是一个重复 SYN：

```
todrop = rcv_nxt - rcv_seq
= 154 - 153
= 1
```

因为SYN标志置位，清除该标志，`ti_seq`等于154，`todrop`等于0。但因为`todrop`等于报文段长度(0)，图28-25开始处的测试条件为真，从而判定是一个重复报文段，执行注释为“处理绑定插口自连接的情况”的代码。早期的TCP实现直接跳到`dropafterack`，略过了SYN_RCVD状态的处理逻辑，不可能建立连接。相反，即使`todrop`等于0，且ACK标志置位（本例中两个条件都成立），Net/3仍旧继续处理收到的报文段，从而进入函数后面对SYN_RCVD状态的处理，连接转移到ESTABLISHED状态。

图28-34给出了自连接处理中函数调用的情况，是非常有意思的。



动作	发送 SYN	处理 SYN	发送 SYN, ACK	处理 SYN, ACK
起始状态	CLOSED	SYN_SENT	SYN_RCVD	SYN_RCVD
结束状态	SYN_SENT	SYN_RCVD	SYN_RCVD	ESTABLISHED

图28-34 自连接处理中的函数调用序列

操作顺序从左至右，首先应用进程调用`connect`，发出PRU_CONNECT请求，经协议栈发送SYN。因为报文段发向主机自己的IP地址，直接通过环回接口加入到`ipintrq`，并生成一个软中断。

系统在软中断处理中调用`ipintr`，`ipintr`调用`tcp_input`，`tcp_input`再调用

`tcp_output`，经协议栈发送带有ACK的SYN。这个报文段也经由环回接口加入到`ipintrq`，并生成一个软中断。系统调用`ipintr`处理软中断，`ipintr`调用`tcp_input`，连接进入ESTABLISHED状态。

28.10 记录时间戳

图28-35给出了`tcp_input`下一部分的代码，处理收到的时间戳选项。

```
737  /*
738   * If last ACK falls within this segment's sequence numbers,
739   * record its timestamp.
740   */
741   if (ts_present && SEQ_LEQ(ti->ti_seq, tp->last_ack_sent) &&
742       SEQ_LT(tp->last_ack_sent, ti->ti_seq + ti->ti_len +
743               ((tiflags & (TH_SYN | TH_FIN)) != 0))) {
744       tp->ts_recent_age = tcp_now;
745       tp->ts_recent = ts_val;
746   }
```

tcp_input.c

图28-35 `tcp_input` 函数：记录时间戳

737-746 如果收到的报文段中带有时间戳，时间戳值保存在`ts_recent`中。我们在26.6节曾讨论过Net/3的处理代码有错误。如果FIN和SYN标志均未置位，表达式

`((tiflags & (TH_SYN|TH_FIN)) != 0)`

等于0；如果有一个置位，则等于1。

28.11 RST处理

图28-36给出了处理RST标志的switch语句，取决于当前的连接状态。

1. SYN_RCVD状态

759-761 插口差错代码设定为ECONNREFUSED，控制向前跳转若干行，关闭插口。在两种状况下，连接进入此状态。一般地讲，连接收到SYN后，从LISTEN转移到SYN_RCVD状态。TCP发送带有ACK的SYN做为响应，但接着却收到了对端的RST。此时，so引用的插口是在图28-7中调用`sonewconn`新创建的。因为`dropsocket`为真，在标注`drop`处，插口被丢弃，监听插口不受影响。这也是图24-15中状态从SYN_RCVD转回LISTEN的原因。

另一种情况是，应用进程调用`connect`后，出现同时打开，状态也转移到SYN_RCVD。收到RST后，向应用进程返回插口差错。

```
747  /*
748   * If the RST bit is set examine the state:
749   *   SYN_RECEIVED state:
750   *     If passive open, return to LISTEN state.
751   *     If active open, inform user that connection was refused.
752   *     ESTABLISHED, FIN_WAIT_1, FIN_WAIT2, CLOSE_WAIT states:
753   *     Inform user that connection was reset, and close tcb.
754   *     CLOSING, LAST_ACK, TIME_WAIT states
755   *     Close the tcb.
756   */

```

图28-36 `tcp_input` 函数：处理RST标志

```

757     if (tiflags & TH_RST)
758         switch (tp->t_state) {
759             case TCPS_SYN_RECEIVED:
760                 so->so_error = ECONNREFUSED;
761                 goto close;
762             case TCPS_ESTABLISHED:
763             case TCPS_FIN_WAIT_1:
764             case TCPS_FIN_WAIT_2:
765             case TCPS_CLOSE_WAIT:
766                 so->so_error = ECONNRESET;
767                 close:
768                 tp->t_state = TCPS_CLOSED;
769                 tcpstat.tcpstat_drops++;
770                 tp = tcp_close(tp);
771                 goto drop;
772             case TCPS_CLOSING:
773             case TCPS_LAST_ACK:
774             case TCPS_TIME_WAIT:
775                 tp = tcp_close(tp);
776                 goto drop;
777         }

```

tcp_input.c

图28-36 (续)

2. 其他状态

762-777 如果在ESTABLISHED、FIN_WAIT_1、FIN_WAIT_2或CLOSE_WAIT状态收到RST，则返回差错代码ECONNRESET。如果状态为CLOSING、LAST_ACK或TIME_WAIT，由于应用进程已关闭插口，无需返回差错代码。

如果允许RST终止处于TIME_WAIT状态的连接，那么TIME_WAIT状态也就没有必要。RFC 1337 [Braden 1992]讨论了这一点，及其他取消TIME_WAIT状态的可能状况，建议不允许RST永久终止处于TIME_WAIT状态的连接。参见习题28.10中的例子。

图28-37给出了函数下一部分的代码，验证SYN是否出错，ACK是否存在。

```

778     /*
779      * If a SYN is in the window, then this is an
780      * error and we send an RST and drop the connection.
781      */
782     if (tiflags & TH_SYN) {
783         tp = tcp_drop(tp, ECONNRESET);
784         goto dropwithreset;
785     }
786     /*
787      * If the ACK bit is off we drop the segment and return.
788      */
789     if ((tiflags & TH_ACK) == 0)
790         goto drop;

```

tcp_input.c

图28-37 tcp_input 函数：处理带有多余SYN或者缺少ACK的报文段

778-785 如果SYN标志依旧置位，说明出现了差错，连接被丢弃，返回差错代码ECONNRESET。

786–790 如果ACK标志未置位，则报文段被丢弃。我们将在下一章讨论函数剩余部分的代码，其中假定ACK标志均置位。

28.12 小结

本章详细介绍了TCP输入处理的前半部分，下一章将继续讨论函数剩余的部分。

本章介绍了如何验证报文段检验和，处理各种TCP选项，处理发起和结束连接建立的SYN报文段，从报文段头尾两个方向删除无效数据，及处理RST标志。

首部预测算法处理正常情况的数据流是非常有效的，执行速度最快。尽管我们讨论的多数处理逻辑用于覆盖所有可能发生的情况，但多数报文段都是正常的，只需很少的处理步骤。

习题

- 28.1 假定Net/3中插口缓存最大等于262 444，基于图28-7的算法，得到的窗口缩放因子是多少？
- 28.2 假定Net/3中插口缓存最大等于262 444，如果往返时间等于60ms，可能的最大吞吐量是多少？(提示：见卷1的图24-5及带宽的解)
- 28.3 为什么图28-10中，调用`bcopy`获取时间戳值？
- 28.4 我们在26.6节中提到，TCP要求的时间戳选项格式与RFC 1323附录A中定义的不同。尽管TCP能够正确处理时间戳，但由于采用与标准不同的格式，会付出什么代价？
- 28.5 处理`PRU_ATTACH`请求时会分配PCB和TCP控制块，为什么不接着调用`tcp_template`分配首部模板？而是直至收到了SYN，在图28-17中才进行这一操作。
- 28.6 阅读RFC 1323，理解为什么图28-22中选取24天做为空闲时间的界限？
- 28.7 在图28-22中，如果连接空闲时间超过24天，`tcp_now-ts_recent_age`与`TCP_PAWS_IDLE`的比较，会出现符号位回绕的问题。Net/3中采取500ms做为时间戳单位，会在什么时间出现问题？
- 28.8 阅读RFC 1323，回答为什么图28-22中PAWS测试不包括RST报文段？
- 28.9 客户发送了SYN，服务器响应SYN/ACK。客户转移到ESTABLISHED状态，并发送响应ACK。但这个ACK丢失，服务器重发SYN/ACK。描述一下客户收到重发的SYN/ACK时的处理步骤。
- 28.10 客户和服务器已建立了连接，服务器主动关闭。连接正常终止，服务器上的插口对转移到TIME_WAIT状态。在服务器的2MSL定时器超时前，同一客户(客户端的同一个插口对)向服务器发送SYN，但起始序号小于连接上最后收到的序号。会发生什么？

第29章 TCP的输入(续)

29.1 引言

本章从前一章结束的地方开始，继续介绍 TCP输入处理。回想一下图 28-37中最后的测试条件，如果ACK未置位，输入报文段被丢弃。

本章处理 ACK标志，更新窗口信息，处理 URG标志及报文段中携带的所有数据，最后处理FIN标志，如果需要，则调用 `tcp_output`。

29.2 ACK处理概述

在本章中，我们首先讨论 ACK的处理，图29-1给出了ACK处理的框架。SYN_RCVD状态需要特殊处理，紧跟着是其他状态的通用处理代码（前一章已讨论过在 LISTEN和SYN_SENT状态下收到 ACK时的处理逻辑）。接着是对 TCPS_FIN_WAIT_1、TCPS_CLOSING和TCPS_LAST_ACK状态的一些特殊处理，因为在这些状态下收到 ACK会导致状态的转移。此外，在TIME_WAIT状态下收到ACK还会导致2MSL定时器的重启。

```
switch (tp->t_state) {  
  
    case TCPS_SYN_RECEIVED:  
        complete processing of passive open and process  
        simultaneous open or self-connect;  
        /* fall into ... */  
  
    case TCPS_ESTABLISHED:  
    case TCPS_FIN_WAIT_1:  
    case TCPS_FIN_WAIT_2:  
    case TCPS_CLOSE_WAIT:  
    case TCPS_CLOSING:  
    case TCPS_LAST_ACK:  
    case TCPS_TIME_WAIT:  
        process duplicate ACK;  
        update RTT estimators;  
        if all outstanding data ACKed, turn off retransmission timer;  
        remove ACKed data from socket send buffer;  
        switch (tp->t_state) {  
            case TCPS_FIN_WAIT_1:  
                if (FIN is ACKed) {  
                    move to FIN_WAIT_2 state;  
                    start FIN_WAIT_2 timer;  
                }  
                break;  
            case TCPS_CLOSING:  
                if (FIN is ACKed) {  
                    ...  
                }  
                break;  
        }  
    }  
}
```

图29-1 ACK处理框架

```

        move to TIME_WAIT state;
        start TIME_WAIT timer;
    }
    break;

case TCPS_LAST_ACK:
    if (FIN is ACKed)
        move to CLOSED state;
    break;

case TCPS_TIME_WAIT:
    restart TIME_WAIT timer;
    goto dropafterack;
}
}

```

图29-1 (续)

29.3 完成被动打开和同时打开

图29-2给出了如何处理SYN_RCVD状态下收到的ACK报文段。如前一章中提到过的，这也将完成被动打开(一般情况)，或者是同时打开及自连接(特殊情况)的连接建立过程。

1. 验证收到的ACK

801-806 如果收到的ACK确认了已发送的SYN，它必须大于snd_una (tcp_sendseqinit将 snd_una设定为连接的ISS，SYN报文段的序号)，且小于等于 snd_max。如果条件满足，则插口进入连接状态ESTABLISHED。

```

791  /*
792   * Ack processing.
793   */
794  switch (tp->t_state) {

795      /*
796       * In SYN RECEIVED state if the ack ACKs our SYN then enter
797       * ESTABLISHED state and continue processing, otherwise
798       * send an RST.
799       */
800  case TCPS_SYN_RECEIVED:
801      if (SEQ_GT(tp->snd_una, ti->ti_ack) ||
802          SEQ_GT(ti->ti_ack, tp->snd_max))
803          goto dropwithreset;
804      tcpstat.tcp_connects++;
805      soisconnected(so);
806      tp->t_state = TCPS_ESTABLISHED;
807      /* Do window scaling? */
808      if ((tp->t_flags & (TF_RCVD_SCALE | TF_REQ_SCALE)) ==
809          (TF_RCVD_SCALE | TF_REQ_SCALE)) {
810          tp->snd_scale = tp->requested_s_scale;
811          tp->rcv_scale = tp->request_r_scale;
812      }
813      (void) tcp_reass(tp, (struct tciphdr *) 0, (struct mbuf *) 0);
814      tp->snd_w11 = ti->ti_seq - 1;
815      /* fall into ... */

```

tcp_input.c

图29-2 tcp_input 函数：在SYN_RCVD 状态收到ACK

在收到三次握手的最后一个报文段后，调用 `soisconnected` 唤醒被动打开的应用进程（一般为服务器）。如果服务器在调用 `accept` 上阻塞，则该调用现在返回。如果服务器调用 `select` 等待连接可读，则连接现在已经可读。

2. 查看窗口大小选项

807-812 如果TCP曾发送窗口大小选项，并且收到了对方的窗口大小选项，则在 TCP控制块中保存发送缩放因子和接收缩放因子。另外，TCP控制块中的 `snd_scale` 和 `rcv_scale` 的默认值为0（无缩放）。

3. 向应用进程提交队列中的数据

813 现在可以向应用进程提交连接重组队列中的数据，调用 `tcp_reass`，第二个参数为空。重组队列中的数据可能是SYN报文段中携带的，它同时将连接状态变迁为 SYN_RCVD。

814 `snd_w11` 等于收到的序号减1，从图29-15可知，这样将导致更新3个窗口变量。

29.4 快速重传和快速恢复的算法

图29-3给出了ACK处理的下一部分代码，处理重复 ACK，并决定是否起用TCP的快速重传和快速恢复算法 [Jacobson 1990c]。两个算法各自独立，但一般都在一起实现 [Floyd 1994]。

- 快速重传算法用于连续出现几次（一般为3次）重复ACK时，TCP认为某个报文段已丢失并且从中推断出丢失报文段的起始序号，丢失报文段被重传。RFC 1122中的4.2.2.21节提到了这一算法，建议TCP收到乱序报文段后，立即发送ACK。我们看到，在图27-15中，Net/3正是这样做的。这个算法最早出现在4.3BSD Tahoe版及后续的Net/1实现中，丢失报文段被重传之后，连接执行慢起动。
- 快速恢复算法认为采用快速重传算法之后（即丢失报文段已重传），应执行拥塞避免算法，而非慢起动。这样，如果拥塞不严重，还能保证较大的吞吐量，尤其窗口较大时。这个算法最早出现在4.3BSD Reno版和后续的Net/2实现中。

Net/3同时实现了快速重传和快速恢复算法，下面将做简单介绍。

在图24-17节中，我们提到有效的ACK必须满足下面的不等式：

`snd_una < 确认字段 <= snd_max`

第一步只与 `snd_una` 做比较，之后在图29-5中再进行不等式第二部分的比较。分开比较的原因是为了能对收到的ACK完成下列5项测试：

- 1) 如果确认字段小于等于 `snd_una`；并且
- 2) 接收报文段长度为0；并且
- 3) 窗口通告大小未变；并且
- 4) 连接上部分发送数据未被确认（重传定时器非零）；并且
- 5) 接收报文段的确认字段是TCP收到的最大的确认序号（确认字段等于 `snd_una`）。

之后可确认报文段是完全重复的ACK（测试项1、2和3在图29-3中，测试4和5在图29-4的起始处）。

TCP统计连续收到的重复ACK的个数，保存在变量 `t_dupacks` 中，次数超过门限 (`tcp_rexmtthresh`, 3) 时，丢失报文段被重传。这也就是卷1第21.7节中介绍的快速重传算法。它与图27-15中的代码互相配合：当TCP收到乱序报文段时，立即生成一个重复的ACK，

告诉对端报文段有可能丢失和等待接收的下一个序号值。快速重传算法是为了让 TCP立即重传看上去已经丢失的报文段，而不是被动地等待重传定时器超时。卷1第21.7节举例详细说明了这个算法是如何工作的。

```

816      /*
817      * In ESTABLISHED state: drop duplicate ACKs; ACK out-of-range
818      * ACKs. If the ack is in the range
819      * tp->snd_una < ti->ti_ack <= tp->snd_max
820      * then advance tp->snd_una to ti->ti_ack and drop
821      * data from the retransmission queue. If this ACK reflects
822      * more up-to-date window information we update our window information.
823      */
824  case TCPS_ESTABLISHED:
825  case TCPS_FIN_WAIT_1:
826  case TCPS_FIN_WAIT_2:
827  case TCPS_CLOSE_WAIT:
828  case TCPS_CLOSING:
829  case TCPS_LAST_ACK:
830  case TCPS_TIME_WAIT:
831
832      if (SEQ_LEQ(ti->ti_ack, tp->snd_una)) {
833          if (ti->ti_len == 0 && tiwin == tp->snd_wnd) {
834              tcpstat.tcps_rcvdupack++;
835              /*
836              * If we have outstanding data (other than
837              * a window probe), this is a completely
838              * duplicate ack (ie, window info didn't
839              * change), the ack is the biggest we've
840              * seen and we've seen exactly our rexmt
841              * threshold of them, assume a packet
842              * has been dropped and retransmit it.
843              * Kludge snd_nxt & the congestion
844              * window so we send only this one
845              * packet.
846              *
847              * We know we're losing at the current
848              * window size so do congestion avoidance
849              * (set ssthresh to half the current window
850              * and pull our congestion window back to
851              * the new ssthresh).
852              *
853              * Dup acks mean that packets have left the
854              * network (they're now cached at the receiver)
855              * so bump cwnd by the amount in the receiver
856              * to keep a constant cwnd packets in the
857              * network.
858          */
859      }

```

tcp_input.c

图29-3 tcp_input 函数：判定完全重复的ACK报文段

另一方面，重复ACK的接收方也能确认某个数据分组已“离开了网络”，因为对端已收到了一个乱序报文段，从而开始发送重复的ACK。快速恢复算法要求连续收到几个重复ACK后，TCP应该执行拥塞避免算法(如降低速度)，而不一定必需等待连接两端间的管道清空(慢起动)。“离开了网络”指数据分组已被对端接收，并加入到连接的重组队列中，不再滞留在传输途中。

如果前述5项测试条件只有前3项为真，说明ACK是重复报文段，统计值`tcp_ps_rcvdu`加1，而连续重复ACK计数器(`t_dupacks`)复位为0。如果仅有第一项测试条件为真，则计数器`t_dupacks`复位为0。

图29-4给出了快速重传算法其余的代码，当所有5个测试条件全部满足时，根据已连续收到的重复ACK数目的不同，运用快速重传算法处理收到的报文段。

- 1) `t_dupacks`等于3(`tcp_ps_rcvdu`)，则执行拥塞避免算法，并重传丢失报文段。
- 2) `t_dupacks`大于3，则增大拥塞窗口，执行正常的TCP输出。
- 3) `t_dupacks`小于3，不做处理。

```
tcp_input.c
858         if (tp->t_timer[TCPT_REXMT] == 0 ||  
859             ti->ti_ack != tp->snd_una)  
860             tp->t_dupacks = 0;  
861         else if (++tp->t_dupacks == tcp_ps_rcvdu)  
862             tcp_seq onxt = tp->snd_nxt;  
863             u_int win =  
864                 min(tp->snd_wnd, tp->snd_cwnd) / 2 /  
865                 tp->t_maxseg;  
866  
867             if (win < 2)  
868                 win = 2;  
869             tp->snd_ssthresh = win * tp->t_maxseg;  
870             tp->t_timer[TCPT_REXMT] = 0;  
871             tp->t_rtt = 0;  
872             tp->snd_nxt = ti->ti_ack;  
873             tp->snd_cwnd = tp->t_maxseg;  
874             (void) tcp_output(tp);  
875             tp->snd_cwnd = tp->snd_ssthresh +  
876                 tp->t_maxseg * tp->t_dupacks;  
877             if (SEQ_GT(onxt, tp->snd_nxt))  
878                 tp->snd_nxt = onxt;  
879             goto drop;  
880         } else if (tp->t_dupacks > tcp_ps_rcvdu) {  
881             tp->snd_cwnd += tp->t_maxseg;  
882             (void) tcp_output(tp);  
883             goto drop;  
884         }  
885     } else  
886         tp->t_dupacks = 0;  
887     break; /* beyond ACK processing (to step 6) */  
888 }
```

tcp_input.c

图29-4 `tcp_input` 函数：处理重复的ACK

1. 连续收到的重复ACK次数已达到门限值3

861-868 `t_dupacks`等于3(`tcp_ps_rcvdu`)时，在变量`onxt`中保存`snd_nxt`值，令慢起动门限(`ssthresh`)等于当前拥塞窗口大小的一半，最小值为两个最大报文段长度。这与图25-27中重传定时器超时处理中的慢起动门限设定操作类似，但我们将看到，超时处理中把拥塞窗口设定为一个最大报文段长度，快速重传算法并不这样做。

2. 关闭重传定时器

869-870 关闭重传定时器。为防止TCP正对某个报文段计时，`t_rtt`清零。

3. 重传缺失报文段

871-873 从连续收到的重复 ACK报文段中可判断出丢失报文段的起始序号(重复ACK的确认字段)，将其赋给 `snd_nxt`，并将拥塞窗口设定为一个最大报文段长度，从而 `tcp_output` 将只发送丢失报文段(参见卷1的图21-7中的63号报文段)。

4. 设定拥塞窗口

874-875 拥塞窗口等于慢起动门限加上对端高速缓存的报文段数。“高速缓存”指对端已收到的乱序报文段数，且为这些报文段发送了重复的 ACK。除非对端收到了丢失的报文段(刚刚发送)，这些缓存报文段中的数据不会被提交给应用进程。卷1的图21-10和图21-11给出了快速重传算法起作用时，拥塞窗口和慢起动门限的变化情况。

5. 设定 `snd_nxt`

876-878 比较下一发送序号(`snd_nxt`)的先前值(`onxt`)和当前值，将两者中最大的一个重新赋还给 `snd_nxt`，因为重传报文段时，`tcp_output` 会改变 `snd_nxt`。一般情况下，`snd_nxt` 将等于原来保存的值，意味着只有丢失报文段被重传，下一次调用 `tcp_output` 时，将继续发送序列中的下一报文段。

6. 连续收到的重复 ACK数超过门限 3

879-883 因为 `t_dupacks` 等于 3 时，已重传了丢失的报文段，再次收到重复 ACK说明又有另一个报文段离开了网络。拥塞窗口大小加 1，调用 `tcp_output` 发送序列中的下一报文段，并丢弃重复的 ACK(参见卷1的图21-7的67号、69号和71号报文段)。

884-885 如果收到的报文段中带有重复的 ACK，且长度非零或者通告窗口大小发生变化，则执行这些语句。此时，前面提到的 5 个测试条件中只有第一个为真，连续收到的重复 ACK数被清零。

7. 略过 ACK处理的其余部分

886 `break` 语句在下列 3 种情况下被执行：(1)前述 5 个测试条件中只有第一个条件为真；(2)只有前 3 个条件为真；(3)重复 ACK 次数小于门限值 3。任何一种情况下，尽管收到的是重复 ACK，将执行 `break` 语句，控制跳到图 29-2 中 `switch` 语句的结尾处，在标注 `step6` 处继续执行。

为了理解前面的窗口操作步骤，请看下面的例子。假定对端接收窗口只能容纳 8 个报文段，而本地报文段 1~8 已发送。报文段 1 丢失，其余报文段均正常到达且被确认。收到对报文段 2、3 和 4 的确认后，重传丢失的报文段(1)。尽管在收到后续的对报文段 5~8 的确认后，TCP 希望能够发送报文段 9，以保证高的吞吐率。但窗口大小等于 8，禁止发送报文段 9 及其后续报文段。因此，每当再次收到一个重复的 ACK，就暂时把拥塞窗口加 1，因为收到重复的 ACK 告诉 TCP 又有一个报文段已在对端离开了网络。最终收到对报文段 1 的确认后，下面将介绍的代码会减少拥塞窗口大小，令其等于慢起动门限。卷1的图21-10举例说明了这一过程，重复 ACK 到达时，增加拥塞窗口大小，之后收到新的 ACK 时，再相应地减少拥塞窗口。

29.5 ACK处理

图29-5中的代码继续处理ACK。

```

888     /*
889      * If the congestion window was inflated to account
890      * for the other side's cached packets, retract it.
891      */
892     if (tp->t_dupacks > tcprexmtthresh &&
893         tp->snd_cwnd > tp->snd_ssthresh)
894         tp->snd_cwnd = tp->snd_ssthresh;
895     tp->t_dupacks = 0;

896     if (SEQ_GT(ti->ti_ack, tp->snd_max)) {
897         tcpstat.tcps_rcvacktoomuch++;
898         goto dropafterack;
899     }
900     acked = ti->ti_ack - tp->snd_una;
901     tcpstat.tcps_rcvackpack++;
902     tcpstat.tcps_rcvackbyte += acked;

```

*tcp_input.c*图29-5 *tcp_input* 函数：继续ACK处理

1. 调整拥塞窗口

888-895 如果连续收到的重复 ACK数超过了门限值 3，说明这是在收到了 4个或 4个以上的重复 ACK后，收到的第一个非重复的 ACK。快速重传算法结束。因为从收到的第 4个重复 ACK开始，每收到一个重复 ACK就会导致拥塞窗口加 1，如果它已超过了慢起动门限，令其等于慢起动门限。连续收到的重复 ACK计数器清零。

2. 检查ACK的有效性

896-899 前面介绍过，有效的ACK必须满足下列不等式：

```
snd_una < 确认字段 <= snd_max
```

如果确认字段大于 `snd_max`，可对端正在确认了 TCP尚未发送的数据。可能的原因是，对于高速连接，某个失踪的 ACK再次出现时，序号已回绕，从图 24-5可知，这是极为罕见的（因为实际的网络不可能那么快）。

3. 计算确认的字节数

900-902 经过前面的测试，已知这是一个有效的 ACK。`acked`等于确认的字节数。

图29-6给出了ACK处理的下一部分代码，完成RTT测算和重传定时器的操作。

4. 更新RTT测算值

903-915 如果(1)时间戳选项存在；或者(2)TCP对某个报文段计时，且收到的确认字段大于该报文段的起始序号，则调用 `tcp_xmit_timer`更新RTT测算值。注意，使用时间戳时，`tcp_xmit_timer`的第二个参数等于当前时间(`tcp_now`)减去收到的时间戳回显(`ts_ecr`)加1(因为函数处理中减了1)。

由于延迟ACK的存在，在前面的测试不等式中应采用大于号。例如，假定 TCP发送了一个报文段，携带字节 1~1024，并对其计时，接着又发送了一个报文段，携带字节 1025~2048。如果收到的确认字段等于 2049，因为 2049大于1(计时报文段的起始序号)，TCP将更新RTT测算值。

5. 是否确认了所有已发送数据

916-924 如果收到报文段的确认字段(`ti_ack`)等于TCP的最大发送序号(`snd_max`)，说明所有已发送数据都已被确认。关闭重传定时器，并置位 `needoutput`标志，从而在函数结束

时强迫调用 `tcp_output`。这是因为在此之前，有可能因为发送窗口已满，TCP拒绝了等待发送的数据，而现在收到了新的 ACK，确认了全部已发送数据，发送窗口能够向右移动（图 29-8 中的 `snd_una` 被更新），允许发送更多的数据。

```
tcp_input.c
```

```

903     /*
904      * If we have a timestamp reply, update smoothed
905      * round-trip time. If no timestamp is present but
906      * transmit timer is running and timed sequence
907      * number was acked, update smoothed round-trip time.
908      * Since we now have an rtt measurement, cancel the
909      * timer backoff (cf., Phil Karn's retransmit alg.).
910      * Recompute the initial retransmit timer.
911      */
912     if (ts_present)
913         tcp_xmit_timer(tp, tcp_now - ts_ecr + 1);
914     else if (tp->t_rtt && SEQ_GT(ti->ti_ack, tp->t_rtseq))
915         tcp_xmit_timer(tp, tp->t_rtt);

916     /*
917      * If all outstanding data is acked, stop retransmit
918      * timer and remember to restart (more output or persist).
919      * If there is more data to be acked, restart retransmit
920      * timer, using current (possibly backed-off) value.
921      */
922     if (ti->ti_ack == tp->snd_max) {
923         tp->t_timer[TCPT_REXMT] = 0;
924         needoutput = 1;
925     } else if (tp->t_timer[TCPT_PERSIST] == 0)
926         tp->t_timer[TCPT_REXMT] = tp->t_rxtcur;

```

```
tcp_input.c
```

图29-6 `tcp_input` 函数：RTT测算值和重传定时器

6. 存在未确认的数据

925-926 由于发送缓存中还存在未被确认的数据，如果持续定时器未设定，则启动重传定时器，时限等于 `t_rxtcur` 的当前值。

Karn算法和时间戳

注意，时间戳的运用取消了 Karn 算法的部分规定（卷1的21.3节）：如果重传定时器超时，则报文段被重传，收到对重传报文段的确认时，不应据此更新 RTT 测算值（重传确认的二义性问题）。在图 25-26 中，我们看到当发生重传时，遵从 Karn 算法，`t_rtt` 被设为 0。如果时间戳不存在，且收到的是对重传报文段的确认，则图 29-6 中的代码不会更新 RTT 测算值，因为此时 `t_rtt` 等于 0。但如果时间戳存在，则不查看 `t_rtt` 值，允许利用收到的时间戳回显字段更新 RTT 测算值。根据 RFC 1323，时间戳的运用不存在二义性，因为 `ts_ecr` 的值复制自被确认的报文段。Karn 算法中关于重传报文段时应采用指数退避的策略依旧有效。

图29-7给出了ACK处理的下一部分代码，更新拥塞窗口。

```
tcp_input.c
```

```

927     /*
928      * When new data is acked, open the congestion window.
929      * If the window gives us less than ssthresh packets

```

图29-7 `tcp_input` 函数：响应收到的ACK，打开拥塞窗口

```

930     * in flight, open exponentially (maxseg per packet).
931     * Otherwise open linearly: maxseg per window
932     * (maxseg^2 / cwnd per packet), plus a constant
933     * fraction of a packet (maxseg/8) to help larger windows
934     * open quickly enough.
935     */
936 {
937     u_int    cw = tp->snd_cwnd;
938     u_int    incr = tp->t_maxseg;
939
940     if (cw > tp->snd_ssthresh)
941         incr = incr * incr / cw + incr / 8;
942     tp->snd_cwnd = min(cw + incr, TCP_MAXWIN << tp->snd_scale);
943 }

```

tcp_input.c

图29-7 (续)

1. 更新拥塞窗口

927-942 慢起动和拥塞避免的一条原则是收到 ACK后将增大拥塞窗口。默认情况下，每收到一个 ACK(慢起动)，拥塞窗口将加1。但如果当前拥塞窗口大于慢起动门限，增加值等于1除以拥塞窗口大小，并加上一个常量。表达式

$\text{incr} * \text{incr} / \text{cw}$

等于

$\text{t_maxseg} * \text{t_maxseg} / \text{snd_cwnd}$

即1除以拥塞窗口，因为 snd_cwnd 的单位为字节，而非报文段。表达式的常量部分等于最大报文段长度的 $1/8$ 。此外，拥塞窗口的上限等于连接发送窗口的最大值。算法的举例参见卷 1 的21.8节。

添加一个常量(最大报文段长度的 $1/8$)是错误的[Floyd 1994]。但它一直存在于BSD源码中，从4.3BSD到4.4BSD和Net/3，应将其删除。

图29-8给出了 *tcp_input* 下一部分的代码，从发送缓存中删除已确认的数据。

```

943     if (acked > so->so_snd.sb_cc) {
944         tp->snd_wnd -= so->so_snd.sb_cc;
945         sbdrop(&so->so_snd, (int) so->so_snd.sb_cc);
946         ourfinisacked = 1;
947     } else {
948         sbdrop(&so->so_snd, acked);
949         tp->snd_wnd -= acked;
950         ourfinisacked = 0;
951     }
952     if (so->so_snd.sb_flags & SB_NOTIFY)
953         sowakeup(so);
954     tp->snd_una = ti->ti_ack;
955     if (SEQ_LT(tp->snd_nxt, tp->snd_una))
956         tp->snd_nxt = tp->snd_una;

```

*tcp_input.c**tcp_input.c*图29-8 *tcp_input* 函数：从发送缓存中删除已确认的数据

2. 从发送缓存中删除已确认的字节

943-946 如果确认字节数超过发送缓存中的字节数，则从 snd_wnd 中减去发送缓存中的字

节数，并且可知本地发送的 FIN已被确认。调用 `sbdrop` 从发送缓存中删除所有字节。能够以这种方式检查对 FIN报文段的确认，是因为 FIN在序号空间中只占一个字节。

947-951 如果确认字节数小于或等于发送缓存中的字节数，`ourfinisacked` 等于0，并从发送缓存中丢弃 `acked` 字节的数据。

3. 唤醒等待发送缓存的进程

951-956 调用 `sowakeup` 唤醒所有等待发送缓存的应用进程，更新 `snd_una` 保存最老的未被确认的序号。如果 `snd_una` 的新值超过了 `snd_nxt`，则更新后者，因为这说明中间的数据也被确认。

图29-9举例说明了为什么 `snd_nxt` 保存的序号有可能小于 `snd_una`。假定传输了两个报文段，第一个携带字节 1~512，而第二个携带字节 513~1024。

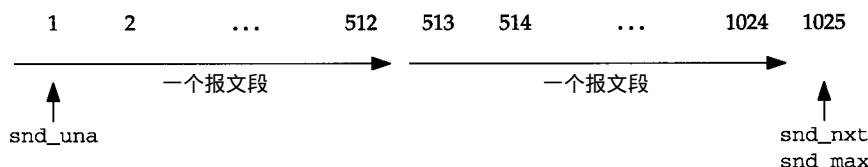


图29-9 连接上发送了两个报文段

确认返回前，重传定时器超时。图 25-26中的代码将 `snd_nxt` 设定为 `snd_una`，进入慢起动状态，调用 `tcp_output` 重传携带 1~512字节的报文段。`tcp_output` 将 `snd_nxt` 增加为 513，如图29-10所示。

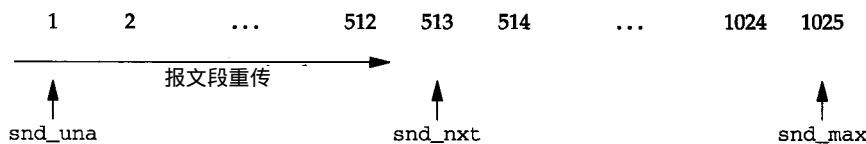


图29-10 重传定时器超时后的连接(接图29-9)

此时，确认字段等于 1025的ACK到达(或者是最初发送的两个报文段或者是 ACK在网络中被延迟)。这个ACK是有效的，因为它小于等于 `snd_max`，但它也将小于更新后的 `snd_una` 值。

一般性的ACK处理现在已结束，图29-11中的 `switch`语句接着处理了4种特殊情况。

```
957     switch (tp->t_state) {                                     tcp_input.c
958         /*
959          * In FIN_WAIT_1 state in addition to the processing
960          * for the ESTABLISHED state if our FIN is now acknowledged
961          * then enter FIN_WAIT_2.
962          */
963     case TCPS_FIN_WAIT_1:
964         if (ourfinisacked) {
965             /*
966              * If we can't receive any more
967              * data, then closing user can proceed.
968              * Starting the timer is contrary to the

```

图29-11 `tcp_input` 函数：在FIN_WAIT_1状态时收到了ACK

```

969             * specification, but if we don't get a FIN
970             * we'll hang forever.
971             */
972         if (so->so_state & SS_CANTRCVMORE) {
973             soisdisconnected(so);
974             tp->t_timer[TCPT_2MSL] = tcp_maxidle;
975         }
976         tp->t_state = TCPS_FIN_WAIT_2;
977     }
978     break;

```

tcp_input.c

图29-11 (续)

4. 在FIN_WAIT_1状态时收到了ACK

958-971 此时，应用进程已关闭了连接，TCP已发送了FIN，但还有可能收到对在FIN之前发送的报文段的确认。因此，只有在收到FIN的确认后，连接才会转移到FIN_WAIT_2状态。图29-8中，ourfinisacked标志已置位，这取决于确认的字节数是否超过发送缓存中的数据量。

5. 设定FIN_WAIT_2定时器

972-975 我们在25.6节中介绍了Net/3如何设定FIN_WAIT_2定时器，以防止在FIN_WAIT_2状态无限等待。只有当应用进程完全关闭了连接（如close系统调用，或者在应用进程被某个信号量终止时与close类似的内核调用），而不是半关闭时（如已发送了FIN，但应用进程仍在连接上接收数据），定时器才会启动。

图29-12给出了在CLOSING状态收到ACK时的处理代码。

```

979         /*
980         * In CLOSING state in addition to the processing for
981         * the ESTABLISHED state if the ACK acknowledges our FIN
982         * then enter the TIME-WAIT state, otherwise ignore
983         * the segment.
984         */
985     case TCPS_CLOSING:
986         if (ourfinisacked) {
987             tp->t_state = TCPS_TIME_WAIT;
988             tcp_canceltimers(tp);
989             tp->t_timer[TCPT_2MSL] = 2 * TCPTV_MSL;
990             soisdisconnected(so);
991         }
992     break;

```

*tcp_input.c*图29-12 *tcp_input* 函数：在CLOSING状态收到ACK

6. 在CLOSING状态收到ACK

979-992 如果收到的ACK是对FIN的确认（而非之前发送的数据报文段），则连接转移到TIME_WAIT状态。所有等待的定时器都被清除（如等待的重传定时器），TIME_WAIT定时器被启动，时限等于两倍的MSL。

图29-13给出了在LAST_ACK状态收到ACK的处理代码。

```

993      /*
994      * In LAST_ACK, we may still be waiting for data to drain
995      * and/or to be acked, as well as for the ack of our FIN.
996      * If our FIN is now acknowledged, delete the TCB,
997      * enter the closed state, and return.
998      */
999      case TCPS_LAST_ACK:
1000         if (ourfinisacked) {
1001             tp = tcp_close(tp);
1002             goto drop;
1003         }
1004         break;

```

*tcp_input.c*图29-13 *tcp_input* 函数：在LAST_ACK状态收到ACK

7. 在LAST_ACK状态收到ACK

993-1004 如果FIN已确认，连接将转移到CLOSED状态。*tcp_close*将负责这一状态变迁，并同时释放Internet PCB和TCP控制块。

图29-14给出了在TIME_WAIT状态收到ACK的处理代码。

```

1005      /*
1006      * In TIME_WAIT state the only thing that should arrive
1007      * is a retransmission of the remote FIN. Acknowledge
1008      * it and restart the finack timer.
1009      */
1010      case TCPS_TIME_WAIT:
1011         tp->t_timer[TCPT_2MSL] = 2 * TCPTV_MSL;
1012         goto dropafterack;
1013     }
1014 }

```

*tcp_input.c*图29-14 *tcp_input* 函数：在TIME_WAIT状态收到ACK

8. 在TIME_WAIT状态收到ACK

1005-1014 此时，连接两端都已发送过FIN，且两个FIN都已被确认。但如果TCP对远端FIN的确认丢失，对端将重传FIN(带有ACK)。TCP丢弃报文段并重传ACK。此外，TIME_WAIT定时器必须被重传，时限等于两倍的MSL。

29.6 更新窗口信息

TCP控制块中还有两个窗口变量我们未曾提及：*snd_w11*和*snd_w12*。

- *nd_w11*记录最后接收报文段的序号，用于更新发送窗口(*snd wnd*)。
- *snd_w12*记录最后接收报文段的确认序号，用于更新发送窗口。

到目前为止，只在连接建立时(主动打开、被动打开或同时打开)遇到过这两个变量，*snd_w11*被设定为*ti_seq*减1。当时说是为了保证窗口更新，下面的代码将证明这一点。

如果下列3个条件中的任一个被满足，则应根据接收报文段中的通告窗口值(*tiwin*)更新发送窗口(*snd wnd*)：

- 1) 报文段携带了新数据。因为*snd_w11*保存了用于更新窗口的最后接收报文段的起始序

号，如果 `snd_wl1 < ti_seq`，说明此条件为真。

2) 报文段未携带新数据(`snd_wl1`等于`ti_seq`)，但报文段确认了新数据。因为 `snd_wl2` 保存了用于更新窗口的最后接收报文段的确认序号，如果 `snd_wl2 < ti_ack`，说明此条件为真。

3) 报文段未携带新数据，也未确认新数据，但通告窗口大于当前发送窗口。

这些测试条件的目的是为了防止旧的报文段影响发送窗口，因为发送窗口并非绝对的序号序列，而是从 `snd_una` 算起的偏移量。

图29-15给出了更新发送窗口的代码。

```

1015 step6:
1016     /*
1017      * Update window information.
1018      * Don't look at window if no ACK: TAC's send garbage on first SYN.
1019      */
1020     if ((tiflags & TH_ACK) &&
1021         (SEQ_LT(tp->snd_wl1, ti->ti_seq) || tp->snd_wl1 == ti->ti_seq &&
1022         (SEQ_LT(tp->snd_wl2, ti->ti_ack) ||
1023          tp->snd_wl2 == ti->ti_ack && tiwin > tp->snd_wnd))) {
1024         /* keep track of pure window updates */
1025         if (ti->ti_len == 0 &&
1026             tp->snd_wl2 == ti->ti_ack && tiwin > tp->snd_wnd)
1027             tcpstat.tcp_ps_rcvwinupd++;
1028
1029         tp->snd_wnd = tiwin;
1030         tp->snd_wl1 = ti->ti_seq;
1031         tp->snd_wl2 = ti->ti_ack;
1032         if (tp->snd_wnd > tp->max_sndwnd)
1033             tp->max_sndwnd = tp->snd_wnd;
1034         needoutput = 1;
1035     }

```

tcp_input.c

图29-15 `tcp_input` 函数：更新窗口信息

1. 是否需要更新发送窗口

`1015-1023` `if` 语句检查报文段的 ACK 标志是否置位，且前述 3 个条件中是否有一个被满足。前面介绍过，在 LISTEN 状态或 SYN_SENT 状态收到 SYN 后，控制将跳转到 `step6`，而在 LISTEN 状态收到的 SYN 不带 ACK。

注释中的 TAC 指“终端接入控制器 (terminal access controller)”，是 ARPANET 上的 Telnet 客户。

`1024-1027` 如果收到一个纯窗口更新报文段 (长度为 0，ACK 未确认新数据，但通告窗口增加)，统计值 `tcp_ps_rcvwinupd` 递增。

2. 更新变量

`1028-1033` 更新发送窗口，保存新的 `snd_wl1` 和 `snd_wl2` 值。此外，如果新的通告窗口是 TCP 从对端收到的所有窗口通告中的最大值，则新值被保存在 `max_sndwnd` 中。这是为了猜测对端接收缓存的大小，在图 26-8 中用到了此变量。更新 `snd_wnd` 后，发送窗口可用空间增加，从而能够发送新的报文段，因此，`needoutput` 标志置位。

29.7 紧急方式处理

TCP输入处理的下一部分是 URG标志置位时的报文段。如图 29-16 所示。

```

1035  /*
1036   * Process segments with URG.
1037   */
1038  if ((tiflags & TH_URG) && ti->ti_urp &&
1039      TCPS_HAVERCVDFIN(tp->t_state) == 0) {
1040  /*
1041   * This is a kludge, but if we receive and accept
1042   * random urgent pointers, we'll crash in
1043   * soreceive. It's hard to imagine someone
1044   * actually wanting to send this much urgent data.
1045   */
1046  if (ti->ti_urp + so->so_rcv.sb_cc > sb_max) {
1047      ti->ti_urp = 0;          /* XXX */
1048      tiflags &= ~TH_URG; /* XXX */
1049      goto dodata;         /* XXX */
1050  }

```

tcp_input.c

图29-16 tcp_input 函数：紧急方式的处理

1. 是否需要处理URG标志

1035-1039 只有满足下列条件的报文段才会被处理：URG标志置位，紧急数据偏移量(ti_urp)非零，连接还未收到 FIN。只有当连接的状态等于 TIME_WAIT时，宏TCPS_HAVERCVDFIN才会为真，因此，连接处于任何其他状态时，URG都会被处理。在后面的注释中提到，连接处于 CLOSE_WAIT、CLOSING、LAST_ACK和TIME_WAIT等几个状态时，URG标志会被忽略，这种说法是错误的。

2. 忽略超出的紧急指针

1040-1050 如果紧急数据偏移量加上接收缓存中已有的数据超过了插口缓存可容纳的数据量，则忽略紧急标志。紧急数据偏移量被清零，URG标志被清除，剩余的紧急方式处理逻辑被忽略。

图29-17给出了tcp_input下一部分的代码，处理紧急指针。

```

1051  /*
1052   * If this segment advances the known urgent pointer,
1053   * then mark the data stream. This should not happen
1054   * in CLOSE_WAIT, CLOSING, LAST_ACK or TIME_WAIT states since
1055   * a FIN has been received from the remote side.
1056   * In these states we ignore the URG.
1057   *
1058   * According to RFC961 (Assigned Protocols),
1059   * the urgent pointer points to the last octet
1060   * of urgent data. We continue, however,
1061   * to consider it to indicate the first octet
1062   * of data past the urgent section as the original
1063   * spec states (in one of two places).
1064   */
1065  if (SEQ_GT(ti->ti_seq + ti->ti_urp, tp->rcv_up)) {

```

图29-17 tcp_input 函数：处理收到的紧急指针

```

1066         tp->recv_up = ti->ti_seq + ti->ti_urp;
1067         so->so_oobmark = so->so_rcv.sb_cc +
1068             (tp->recv_up - tp->recv_nxt) - 1;
1069         if (so->so_oobmark == 0)
1070             so->so_state |= SS_RCVATMARK;
1071         sohasoutofband(so);
1072         tp->t_oobflags &= ~(TCPOOB_HAVEDATA | TCPOOB_HADDATA);
1073     }
1074     /*
1075      * Remove out-of-band data so doesn't get presented to user.
1076      * This can happen independent of advancing the URG pointer,
1077      * but if two URG's are pending at once, some out-of-band
1078      * data may creep in... ick.
1079      */
1080     if (ti->ti_urp <= ti->ti_len
1081 #ifdef SO_OOBINLINE
1082         && (so->so_options & SO_OOBINLINE) == 0
1083 #endiff
1084         )
1085         tcp_pulloutofband(so, ti, m);
1086     } else {
1087         /*
1088          * If no out-of-band data is expected, pull receive
1089          * urgent pointer along with the receive window.
1090          */
1091         if (SEQ_GT(tp->recv_nxt, tp->recv_up))
1092             tp->recv_up = tp->recv_nxt;
1093     }

```

tcp_input.c

图29-17 (续)

1051-1065 如果接收报文段的起始序号加上紧急数据偏移量超过了当前接收紧急指针，说明已收到了一个新的紧急指针。例如，图 26-30 中的携带 3 字节的报文段到达接收方，如图 29-18 所示。

一般情况下，收到的紧急指针(*recv_up*)等于*recv_nxt*。这个例子中，因为 if 语句为真(4加3大于4)，*recv_up*的新值等于7。

3. 计算收到的紧急指针

1066-1070 计算插口接收缓存中带外数据的分界点，应计入接收缓存中已有的数据(*so_rcv.sb_cc*)。在上面的例子中，假定接收缓存为空，*so_oobmark*等于2：序号为6的字节被认为是带外数据。如果这个带外数据标记等于0，说明插口正处在带外数据分界点上。如果发送带外数据的*send*系统调用给定长度为1，并且这个报文段到达对端时接收缓存为空，就会发生这一现象，同时也再次重申了 Berkeley 系统认为紧急指针应指向带外数据后的第一个字节。

4. 向应用进程通告 TCP 的紧急方式

1071-1072 调用 *sohasoutofband* 告知应用进程有带外数据到达了插口，清除两个标志

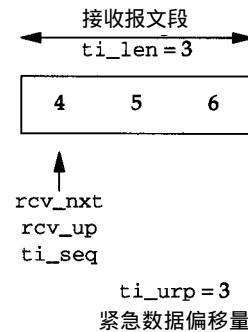


图29-18 图26-30中发送的报文段到达接收方

TCPOOB_HAVEDATA和TCPOOB_HADDATA，它们用于图30-8中的PRU_RCVOOB请求处理。

5. 从正常的数据流中提取带外数据

1074-1085 如果紧急数据偏移量小于等于接收报文段中的字节数，说明带外数据包含在报文段中。TCP的紧急方式允许紧急数据偏移量指向尚未收到的数据。如果定义了SO_OOBINLINE常量(正常情况下，Net/3定义了此常量)，而且未选用对应的插口选项，则接收进程将从正常的数据流中提取带外数据，并保存在t_iobc变量中。完成这一功能的函数，是我们将在下一节介绍的tcp_pullofband。

注意，无论紧急指针指向的字节是否可读，TCP都将通知接收进程发送方已进入紧急方式。这是TCP紧急方式的一个特性。

6. 如果不处于紧急方式，调整接收紧急指针

1086-1093 在接收方未处理紧急指针时，如果rcv_nxt大于接收紧急指针，则rcv_up向右移动，并等于rcv_nxt。这使接收紧急指针一直指向接收窗口的左侧，确保在收到URG标志时，图29-17起始处的宏SEQ_GT能够得出正确的结果。

如果要实现习题26.6中提出的方案，也必须相应修改图29-16和图29-17中的代码。

29.8 tcp_pullofband函数

图29-17中的代码调用了这个函数，如果：

- 1) 接收报文段中带有紧急方式标志；并且
- 2) 带外数据包含在接收报文段中(如，紧急指针指向接收报文段)；并且
- 3) 未选用SO_OOBINLINE选项。

函数从正常的数据流(保存接收报文段的mbuf链)中提取带外字节，并保存在连接TCP控制块中的t_iobc变量中。应用进程通过recv系统调用，置位MSG_OOB标志，读取这个变量：图30-8中的PRU_RCVOOB请求。图29-19给出了函数代码。

tcp_input.c

```

1282 void
1283 tcp_pullofband(so, ti, m)
1284 struct socket *so;
1285 struct tcphdr *ti;
1286 struct mbuf *m;
1287 {
1288     int      cnt = ti->ti_urp - 1;
1289     while (cnt >= 0) {
1290         if (m->m_len > cnt) {
1291             char    *cp = mtod(m, caddr_t) + cnt;
1292             struct tcpcb *tp = sototcpcb(so);
1293             tp->t_iobc = *cp;
1294             tp->t_oobflags |= TCPOOB_HAVEDATA;
1295             bcopy(cp + 1, cp, (unsigned) (m->m_len - cnt - 1));
1296             m->m_len--;
1297             return;
1298         }
1299         cnt -= m->m_len;

```

图29-19 tcp_pullofband 函数：将带外数据保存在t_iobc 变量中

```

1300     m = m->m_next;
1301     if (m == 0)
1302         break;
1303     }
1304     panic("tcp_pulloutofband");
1305 }
```

tcp_input.c

图29-19 (续)

1282-1289 考虑图29-20中的例子。紧急数据偏移量等于3，因此紧急指针等于7，带外字节的序号等于6。接收报文段携带了5字节的数据，全部保存在一个mbuf中。

变量cnt等于2，因为m_len(等于5)大于2，执行if语句为真部分的代码。

1290-1298 cp指向序号为6的字节，它被放入保存带外字节的变量 t_iobc 中。置位 TCPOOB_HAVEDATA 标志，调用 bcopy 将接下来的两个字节(序号7和8)左移1字节，如图29-21所示。

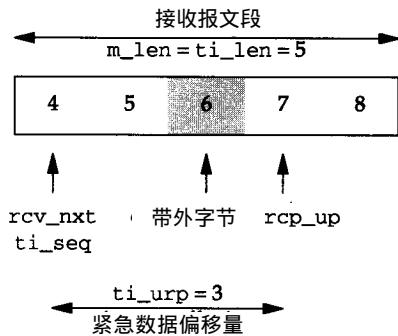


图29-20 携带带外字节的报文段

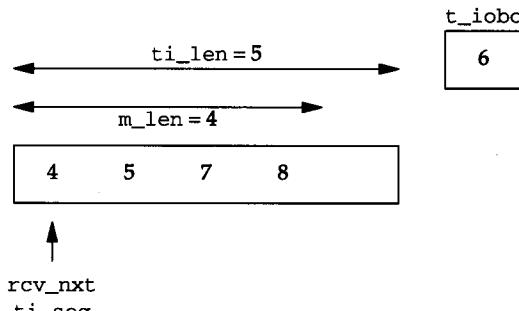


图29-21 移走带外数据后的结果(接图29-20)

注意，数字7和8指数据字节的序号，而不是其内容。mbuf的长度从5减为4，但ti_len仍等于5不变，这是为了按序把报文段放入插口的接收缓存。TCP_REASS宏和tcp_reass函数(在下一节调用)都会给recv_nxt增加ti_len，本例中ti_len必须等于5，因为下一个等待接收的序号等于9。还请注意，函数没有对第一个mbuf中的数据分组首部长度(m_pkthdr.len)减1，这是因为负责把数据添加到插口接收缓存的sbappend不使用此长度值。

跳至链中的下一个mbuf

1299-1302 如果带外数据未保存在此mbuf中，则从cnt中减去mbuf中的字节数，处理链中的下一个mbuf。因为只有当紧急数据移量指向接收报文段时，才会调用此函数，所以，如果链已结束，不存在下一个mbuf，则执行break语句，跳转到标注panic处。

29.9 处理已接收的数据

tcp_input接着提取收到的数据(如果存在)，将其添加到插口接收缓存，或者放入插口的乱序重组队列中。图29-22给出了完成此项功能的代码。

```

1094     dodata:                                /* XXX */
1095     /*
1096      * Process the segment text, merging it into the TCP sequencing queue,
1097      * and arranging for acknowledgment of receipt if necessary.
1098      * This process logically involves adjusting tp->rcv_wnd as data
1099      * is presented to the user (this happens in tcp_usrreq.c,
1100      * case PRU_RCVD). If a FIN has already been received on this
1101      * connection then we just ignore the text.
1102     */
1103     if ((ti->ti_len || (tiflags & TH_FIN)) &&
1104         TCPS_HAVERCVDFIN(tp->t_state) == 0) {
1105         TCP_REASS(tp, ti, m, so, tiflags);
1106         /*
1107          * Note the amount of data that peer has sent into
1108          * our window, in order to estimate the sender's
1109          * buffer size.
1110         */
1111         len = so->so_rcv.sb_hiwat - (tp->rcv_adv - tp->rcv_nxt);
1112     } else {
1113         m_freem(m);
1114         tiflags &= ~TH_FIN;
1115     }

```

*tcp_input.c*图29-22 *tcp_input* 函数：把收到的数据放入插口接收队列

1094-1105 报文段数据将被处理，如果：

- 1) 接收数据的长度大于0，或者FIN标志置位；并且
- 2) 连接还未收到FIN；

则调用宏TCP_REASS处理数据。如果数据次序正确(如，连接等待接收的下一序号)，置位延迟ACK标志，增加rcv_nxt，并把数据添加到插口的接收缓存中。如果数据次序错误，宏会调用tcp_reass函数，把数据加入到连接的重组队列中(新到数据有可能填充队列中的缺口，从而将已排队的数据添加到插口的接收缓存中)。

前面介绍过，宏的最后一个参数(tiflags)是可修改的。特别地，如果数据次序错误，tcp_reass令tiflags等于0，清除FIN标志(如果它已置位)。这也就是为什么即使报文段中没有数据，只要FIN置位，if语句也为真。

考虑下面的例子。连接建立后，发送方立即发送报文段：一个携带字节1~1024，另一个携带字节1025~2048，还有一个未带数据的FIN。第一个报文段丢失，因此，第二个报文段到达时(字节1025~2048)，接收方将其放入乱序重组队列，并立即发送ACK。当第三个带有FIN标志的报文段到达时，图29-22中的代码被执行。即使数据长度等于0，因为FIN置位，导致调用TCP_REASS，它接着调用tcp_reass。因为ti_seq(2049，FIN的序号)不等于rcv_nxt(1)，tcp_reass返回0(图27-23)。在TCP_REASS宏中，tiflags被设为0，从而清除了FIN标志，阻止后续代码(图29-10)继续处理FIN。

猜测对端发送缓存大小

1106-1111 计算len，实际上是在猜测对端发送缓存的大小。考虑下面的例子。插口接收缓存大小等于8192(Net/3的默认值)，因此，TCP在SYN中通告窗口大小为8192。之后收到第一个报文段，携带字节1~1024。图29-23给出了在TCP_REASS增加rcv_nxt以反应收到的数据后接收空间的状态。

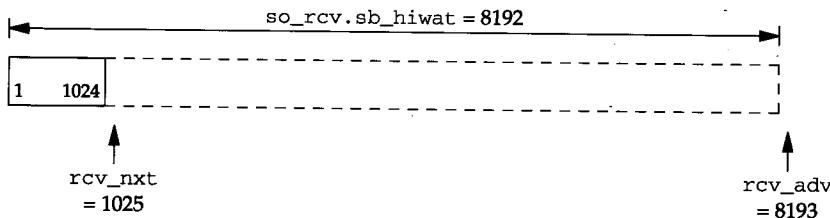


图29-23 大小为8192的接收窗口收到字节1~1024后的状态

此时，经计算，len等于1024。对端向接收窗口发送更多数据后，len值将增加，但绝对不会超过对端发送缓存的大小。前面介绍过，图29-15中对变量max_sndwnd的计算，是在猜测对端接收缓存的大小。

事实上，变量len从未被使用。它是从Net/1遗留下来的，len计算后被存储到TCP控制块的max_rcvd变量中：

```
if (len > tp->max_rcvd)
    tp->max_rcvd = len;
```

但即使在Net/1中，变量max_rcvd也未被使用。

1112-1115 如果len等于0，且FIN标志未置位，或者连接上已收到了FIN，则丢弃保存接收报文段的mbuf链，并清除FIN。

29.10 FIN处理

tcp_input的下一步，在图29-24中给出，处理FIN标志。

```
tcp_input.c
1116  /*
1117   * If FIN is received ACK the FIN and let the user know
1118   * that the connection is closing.
1119   */
1120  if (tiflags & TH_FIN) {
1121      if (TCPS_HAVERCVDFIN(tp->t_state) == 0) {
1122          socantrcvmore(so);
1123          tp->t_flags |= TF_ACKNOW;
1124          tp->recv_nxt++;
1125      }
1126      switch (tp->t_state) {
1127          /*
1128           * In SYN_RECEIVED and ESTABLISHED states
1129           * enter the CLOSE_WAIT state.
1130           */
1131      case TCPS_SYN_RECEIVED:
1132      case TCPS_ESTABLISHED:
1133          tp->t_state = TCPS_CLOSE_WAIT;
1134          break;
tcp_input.c
```

图29-24 tcp_input 函数：FIN处理，前半部分

1. 处理收到的第一个FIN

1116-1125 如果接收报文段 FIN置位，并且是连接上收到的第一个 FIN，则调用socantrcvmore，把插口设为只读，置位 TF_ACKNOW，从而立即发送ACK(无延迟)。

rcv_nxt加1，越过FIN占用的序号。

1126 FIN处理的其余部分是一个大的switch语句，根据连接的状态进行转换。注意，连接处于CLOSED、LISTEN和SYN_SENT状态时，不处理FIN，因为处于这3个状态时，还未收到对端发送的SYN，无法同步接收序号，也就无法验证FIN序号的有效性。此外，连接处于CLOSING、CLOSE_WAIT和LAST_ACK状态时，也不处理FIN，因为在这3个状态下收到的FIN必然是一个重复报文段。

2. SYN_RCVD和ESTABLISHED状态

1127-1134 如果连接处于SYN_RCVD或ESTABLISHED状态，收到FIN后，新的状态为CLOSE_WAIT。

尽管在SYN_RCVD状态下收到FIN是合法的，但却极为罕见。图24-15的状态图未列出这一状态变迁。它意味着处于LISTEN状态的插口收到一个同时带有SYN和FIN的报文段。或者，正在监听的插口收到了SYN，连接转移到SYN_RCVD状态，但在收到ACK之前，先收到了FIN(从分析可知，FIN未携带有效的ACK，否则，图29-2中的代码会使连接转移到ESTABLISHED状态)。

图29-25给出了FIN处理的下一部分。

```

1135      /*
1136      * If still in FIN_WAIT_1 state FIN has not been acked so
1137      * enter the CLOSING state.
1138      */
1139      case TCPS_FIN_WAIT_1:
1140          tp->t_state = TCPS_CLOSING;
1141          break;
1142
1143          /*
1144          * In FIN_WAIT_2 state enter the TIME_WAIT state,
1145          * starting the time-wait timer, turning off the other
1146          * standard timers.
1147          */
1148      case TCPS_FIN_WAIT_2:
1149          tp->t_state = TCPS_TIME_WAIT;
1150          tcp_canceltimers(tp);
1151          tp->t_timer[TCPT_2MSL] = 2 * TCPTV_MSL;
1152          soisdisconnected(so);
1153          break;
1154
1155          /*
1156          * In TIME_WAIT state restart the 2 MSL time_wait timer.
1157          */
1158      case TCPS_TIME_WAIT:
1159          tp->t_timer[TCPT_2MSL] = 2 * TCPTV_MSL;
1160      }

```

tcp_input.c

图29-25 *tcp_input* 函数：FIN处理，后半部分

3. FIN_WAIT_1状态

1135-1141 因为报文段的ACK处理已结束，如果处理FIN时，连接处于FIN_WAIT_1状态，意味着连接两端同时关闭连接——两端发送的两个FIN在网络中交错。连接进入CLOSING状态。

4. FIN_WAIT_2状态

1142-1148 收到FIN将使连接进入TIME_WAIT状态。当在FIN_WAIT_1状态收到携带ACK和FIN的报文段时(典型情况),尽管图24-15显示连接直接从FIN_WAIT_1转移到TIME_WAIT状态,但在图29-11中处理ACK时,连接实际已进入FIN_WAIT_2状态。此处的FIN处理再将连接转到TIME_WAIT状态。因为ACK在FIN之前处理,所以连接总会经过FIN_WAIT_2状态,尽管是暂时性的。

5. 启动TIME_WAIT定时器

1149-1152 关闭所有等待的TCP定时器,并启动TIME_WAIT定时器,时限等于MSL(如果接收报文段中包含ACK和FIN,图29-11中的代码会启动FIN_WAIT_2定时器)。插口断开连接。

6. TIME_WAIT状态

1153-1159 如果在TIME_WAIT状态时收到FIN,说明这是一个重复报文段。与图29-14中的处理类似,启动TIME_WAIT定时器,时限等于两倍的MSL。

29.11 最后的处理

图29-26给出了tcp_input函数中首部预测失败时,较慢的执行路径中最后一部分的代码,以及标注dropafterack。

```

1161     if (so->so_options & SO_DEBUG)                               tcp_input.c
1162         tcp_trace(TA_INPUT, ostate, tp, &tcp_saveti, 0);
1163     /*
1164      * Return any desired output.
1165      */
1166     if (needoutput || (tp->t_flags & TF_ACKNOW))
1167         (void) tcp_output(tp);
1168     return;
1169 dropafterack:
1170     /*
1171      * Generate an ACK dropping incoming segment if it occupies
1172      * sequence space, where the ACK reflects our state.
1173      */
1174     if (tiflags & TH_RST)
1175         goto drop;
1176     m_freem(m);
1177     tp->t_flags |= TF_ACKNOW;
1178     (void) tcp_output(tp);
1179     return;

```

tcp_input.c

图29-26 tcp_input 函数 : 最后的处理

1. SO_DEBUG插口选项

1161-1162 如果选用了SO_DEBUG插口选项,则调用tcp_trace向内核的环形缓存中添加记录。回想一下,图28-7中的代码同时保存了原有连接状态,IP和TCP的首部,因为函数有可能改变这些值。

2. 调用tcp_output

1163-1168 如果needoutput标志置位(图29-6和图29-15),或者需要立即发送ACK,则调用tcp_output。

3. dropafterack

1169-1179 只有当RST标志未置位时，才会生成ACK(带有RST的报文段不会被确认)，释放保存接收报文段的mbuf链，调用tcp_output立即发送ACK。

图29-27结束tcp_input函数。

```

1180 dropwithreset:
1181 /*
1182     * Generate an RST, dropping incoming segment.
1183     * Make ACK acceptable to originator of segment.
1184     * Don't bother to respond if destination was broadcast/multicast.
1185 */
1186 if ((tiflags & TH_RST) || m->m_flags & (M_BCAST | M_MCAST) ||
1187     IN_MULTICAST(ti->ti_dst.s_addr))
1188     goto drop;
1189 if (tiflags & TH_ACK)
1190     tcp_respond(tp, ti, m, (tcp_seq) 0, ti->ti_ack, TH_RST);
1191 else {
1192     if (tiflags & TH_SYN)
1193         ti->ti_len++;
1194     tcp_respond(tp, ti, m, ti->ti_seq + ti->ti_len, (tcp_seq) 0,
1195                 TH_RST | TH_ACK);
1196 }
1197 /* destroy temporarily created socket */
1198 if (dropsocket)
1199     (void) soabort(so);
1200 return;

1201 drop:
1202 /*
1203     * Drop space held by incoming segment and return.
1204 */
1205 if (tp && (tp->t_inpcb->inp_socket->so_options & SO_DEBUG))
1206     tcp_trace(TA_DROP, ostate, tp, &tcp_saveti, 0);
1207 m_freem(m);
1208 /* destroy temporarily created socket */
1209 if (dropsocket)
1210     (void) soabort(so);
1211 return;
1212 }

```

tcp_input.c

图29-27 tcp_input 函数：最后的处理

4. dropwithreset

1180-1188 除了接收报文段也有RST,或者接收报文段是多播和广播报文段的情况之外,应发送RST。绝不允许因为响应RST而发送新的RST,这将引起RST风暴(两个端点间连续不断地交换RST)。

此处的代码存在与图 28-16同样的错误：它不检查接收报文段的目的地址是否为广播地址。

类似地，IN_MULTICAST的目的地址参数应转换为主机字节序。

5. RST报文段的序号和确认序号

1189-1196 RST报文段的序号字段值、确认字段值和ACK标志取决于接收报文段中是否带有ACK。

图29-28总结了生成RST报文段中的这些字段。

接收到的报文段	生成的RST报文段		
	序号值	确认序号	输出标志
带有ACK	接收到的确认字段	0	TH_RST
不带ACK	0	接收到的序号字段	TH_RST TH_ACK

图29-28 生成RST报文段各字段的值

正常情况下，除了起始的SYN(图24-16)，所有报文段都带有ACK。tcp_respond的第四个参数是确认序号，第五个参数是序号。

6. 拒绝连接

1192-1193 如果SYN置位，则ti_len必须加1，从而生成RST的确认字段比收到的SYN报文段的起始序号大1。如果到达的SYN请求与不存在的服务器建立连接，会执行这一段代码。此时，由于图28-6中的代码找不到请求的Internet PCB，控制跳转到dropwithreset。但为了使发送的RST能被对端接受，报文段必须确认SYN(图28-18)。卷1的18.14节举例说明了这种类型的RST。

最后请注意，tcp_respond利用保存接收报文段的第一个mbuf构造RST，并且释放链上的其他mbuf。当第一个mbuf最终到达设备驱动程序后，它也会被丢弃。

7. 释放临时创建的插口

1197-1199 如果在图28-7中为监听的服务器创建了临时的插口，但图28-16中的代码发现接收报文段有错误，它会置位drop_socket。如果出现了这种情况，插口在此处被释放。

8. 丢弃(不带ACK或RST)

1201-1206 如果接收报文段被丢弃，且不生成ACK或RST，则调用tcp_trace。如果SO_DEBUG置位且生成了ACK，则tcp_output将向内核的环形缓存中添加一条跟踪记录。如果SO_DEBUG置位且生成了RST，系统不会为RST添加新的跟踪记录。

1207-1211 释放保存接收报文段的mbuf链。如果dropsocket非零，则释放临时创建的插口。

29.12 实现求精

为了加速TCP处理而进行的优化与UDP类似(23.12节)。应利用复制数据计算检验和，并避免在处理中多次遍历数据。[Dalton et al. 1993]讨论了这些修订。

连接数增加时，对TCP PCB的线性搜索也是一个处理瓶颈。[McKenney and Dove 1992]讨论了这个问题，利用哈希表替代了线性搜索。

[Partridge 1993]介绍了Van Jacobson开发的一个用于研究目的的协议实现，极大地减少了TCP的输入处理。接收数据分组首先由IP进行处理(RISC系统中约有25条指令)，之后由分用器(demultiplexer)寻找PCB(约10条指令)，最后由TCP处理(约30条指令)。这30条指令完成了首部预测，并计算伪首部检验和。如果数据报文段通过了首部预测，且应用进程正等待接收数据，则复制数据到应用进程缓存，计算TCP检验和并完成验证(一次遍历中完成数据复制和检验和计算)。如果TCP首部预测失败，则执行TCP输入处理中较慢的路径。

29.13 首部压缩

下面介绍TCP首部压缩。尽管首部压缩不是TCP输入处理的一部分，但需要彻底了解TCP

的工作机制后，才能很好地理解首部压缩。RFC 1144[Jacobson 1994a]中详细定义了首部压缩，因为Van Jacobson首先提出了这一算法，通常也称为VJ首部压缩。本节的目的不是详细讨论首部压缩的源代码(RFC 1144给出了实现代码，其中有很好的注释，程序量与tcp_output差不多)，而是概括性地介绍一下算法的思想。请注意区分首部预测(28.4节)和首部压缩。

29.13.1 引言

多数的SLIP和PPP实现支持首部压缩。尽管首部压缩，在理论上，适用于任何数据链路，但主要还是面向慢速串行链路。首部压缩只处理TCP报文段——与其他的IP协议无关(如ICMP、IGMP、UDP等等)。它能够把IP/TCP组合首部从正常的40字节压缩到只有3字节，从而降低了交互性应用，如远程登录或Telnet中TCP报文段的大小，从典型的41字节减少到只剩4字节——大大提高了慢速串行链路的效率。

串行链路的两端，每端都维护着两个连接状态表，一个用于数据报的发送，另一个用于数据报的接收。每张表最多保存256条记录，但典型的只有16条，即同一时间内最多允许16条不同的TCP连接执行首部压缩算法。每条记录中保存一个8 bit的连接ID(限制记录数最多只能为256)、某些标志和最近接收/发送的数据报的未被压缩的首部。96 bit的插口对可惟一确定一条连接——源端IP地址和TCP端口号、目的IP地址和TCP端口号——这些信息都保存在未压缩的首部中。图29-29举例说明了这些表的结构。

因为TCP连接是全双工的，在两个方向的数据流上都可执行首部压缩算法。连接两端必须同时实现压缩和解压缩。同一条连接在两端的表中都会出现，如图29-29所示。在这个例子上部的两张表中，连接ID等于1的表项的源端IP地址都等于128.1.2.3，源端TCP端口号都等于1500，目的IP地址等于192.3.4.5，目的TCP端口号都等于25。在底部的两张表中，连接ID等于2的记录保存了同一条连接反方向数据流的信息。

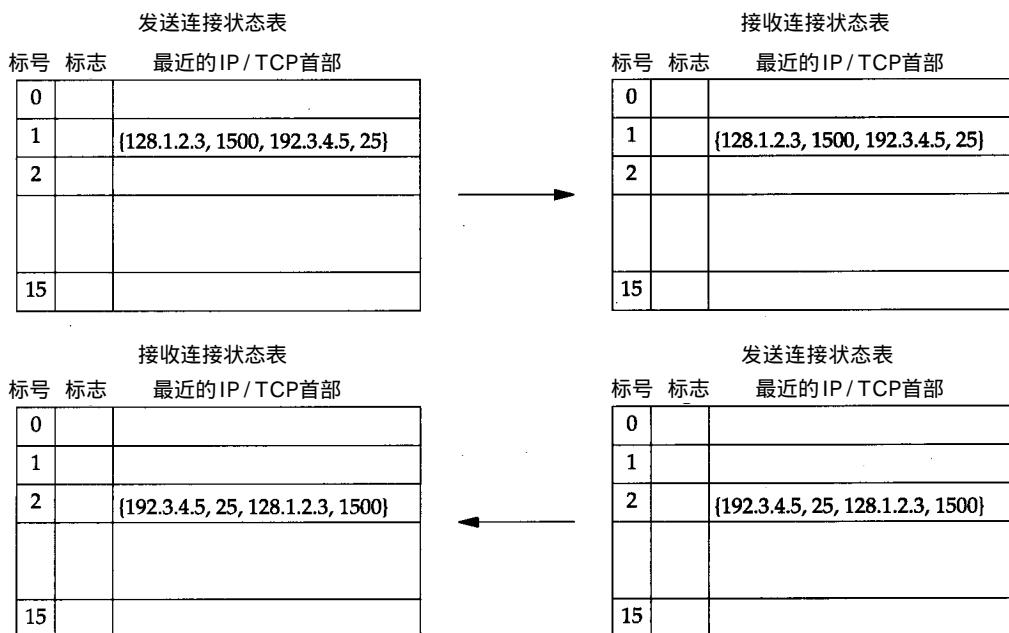


图29-29 链路(如SLIP链路)两端的一组连接状态表

我们在图29-29中利用数组表示这些表，但在源代码中，表项定义为一个结构，连接状态表定义为这些结构组成的环形链表，最近一次用过的结构位于表头。

因为连接两端都保存了最近用过的未压缩的数据报首部，所以只需在链路上传送当前数据报与前一数据报不同的字段（及一个特殊的前导字节，指明后续的是哪一个字段）。因为某些首部字段在相邻的数据报之间不会变化，而其他的首部字段变化也很小，这种差分处理是压缩算法的核心。首部压缩只适用于 IP和TCP首部——TCP报文段的数据部分不变。

图29-30给出了发送方利用首部压缩算法，在串行链路上发送IP数据报时采取的步骤。

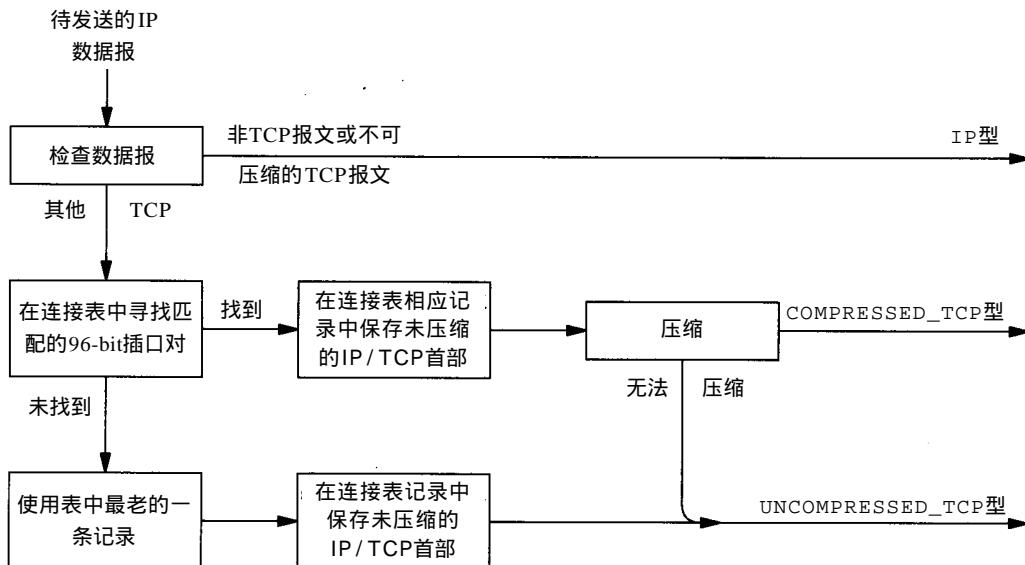


图29-30 发送方采用首部压缩时的步骤

接收方必须能够识别下面3种类型的数据报：

1) IP型数据报，前导字节的高位4比特等于4。这也是IP首部中正常的IP版本号(图8-8)，说明链路上发送的是正常的、未压缩的数据报。

2) COMPRESSED_TCP型数据报，前导字节的最高位置为1，类似于IP版本号介于8和15之间(剩余的7bit由压缩算法使用)，说明链路上发送的是压缩过的首部和未压缩的数据，接下来我们还会谈到这种类型的数据报。

3) UNCOMPRESSED_TCP型数据报，前导字节的高位4比特等于7，说明链路上发送的是正常的、未压缩的数据报，但IP的协议字段(等于6，对TCP)被替换为连接ID，接收方可据此从连接状态表中找到正确的记录。

接收方查看数据报的第一个字节，即前导字节，确定其类型，实现代码参见图5-13。图5-16中，发送方调用sl_compress_tcp确认TCP报文段是可压缩的，函数返回值与数据报首字节逻辑或后，结果依然保存在首字节中。

图29-31列出了链路上传送的前导字节，其中4位“-”表示正常的IP首部长度字段。7位“C、I、P、S、A、W和E”指明后续的是哪些可选字段，后面会简单地介绍这些字母的含义。



图29-31 链路上传送的前导字节

图29-32给出了使用压缩算法之后，不同类型的完整的IP数据报。

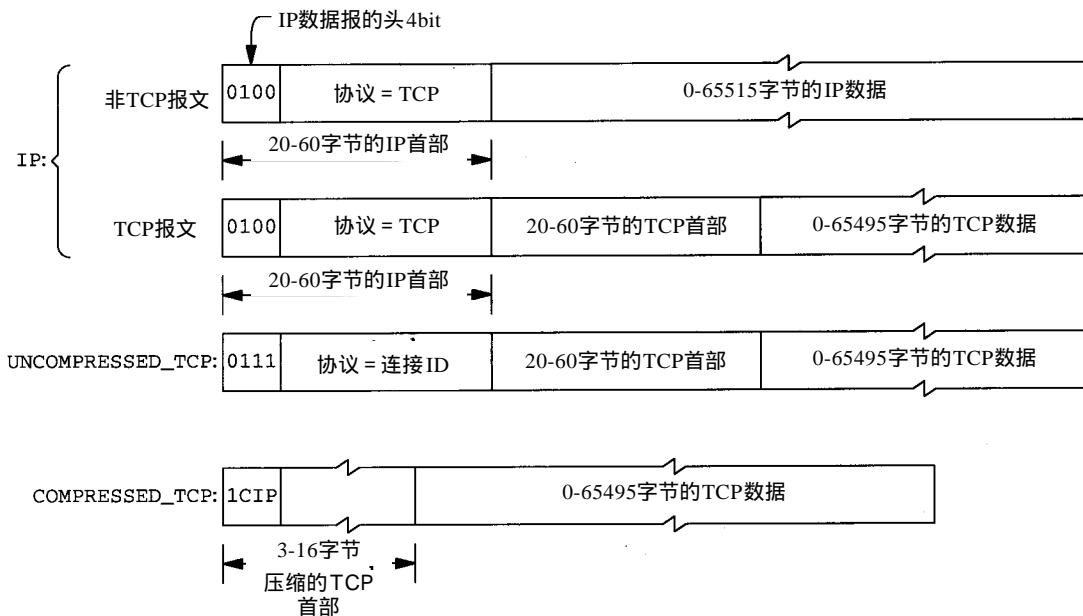


图29-32 采用首部压缩后的不同类型的IP数据报

图中给出了两个IP型数据报：一个携带了非TCP报文段（如UDP、ICMP或IGMP协议报文段），另一个携带了TCP报文段。这是为了说明做为IP型数据报发送的TCP报文段与做为UNCOMPRESSED_TCP型数据报发送的TCP报文段间的差异：前导字节的高位4比特互不相同，类似于IP首部的协议字段。

如果IP数据报的协议字段不等于TCP，或者协议是TCP，但下列条件之一为真，都不会采用首部压缩算法。

- 数据报是一个IP分片：分片偏移量非零或者分片标志置位；
- SYN、FIN或RST中的任何一个置位；
- ACK标志未置位。

上述3个条件中只要有一个为真，都将作为IP型数据报发送。

此外，即使数据报携带了可压缩的TCP报文段，压缩算法也可能失败，生成UNCOMPRESSED_TCP型的数据报。可能因为当前数据报与连接上发送的上一个数据报比较时，有些特殊字段发生了变化，而正常情况下，对于给定的连接，它们应该不变，从而导致压缩算法无法反映存在的变化。例如，TOS字段，分片标志位。此外，如果某些字段数值的

差异超过65535，压缩算法也会失败。

29.13.2 首部字段的压缩

下面介绍如何压缩图29-33中给出的IP和TCP的首部字段，阴影字段指对于给定连接，正常情况下不会发生变化的字段。



图29-33 组合的IP和TCP首部：阴影字段通常不变化

如果连接上发送的前一个报文段与当前报文段之间，有阴影字段发生变化，则压缩算法失败，报文段被直接发送。图中未列出IP和TCP选项，但如果它们存在，且这些选项字段发生了变化，则报文段也不压缩，而被直接发送（习题29.7）。

如果阴影字段均未变化，即使算法只传输非阴影字段，也会节省50%的传输容量。VJ首部压缩甚至做得更好，图29-34给出了压缩后的IP/TCP首部格式。

最小的压缩后的IP/TCP首部只有3个字节：第一个字节（标志比特），加上16 bit的TCP检验和。为了防止可能的链路错误，一般不改动TCP检验和（SLIP不提供链路层的检验和，尽管PPP提供一个）。



图29-34 压缩后的IP/TCP首部格式

其他的6个字段：*connid*、*urgoff*、*Δwin*、*Δack*、*Δseq*和*Δipid*，都是可选的。图29-34的最左侧列出了各字段压缩后所需的字节数。读者可能认为压缩后的首部最大应占用 19字节，但实际上压缩后的首部中4 bit的SAWU绝不可能同时置位，因此，压缩首部最大为16字节，后面我们还会详细讨论这个问题。

第一个字节的最高位比特必须设为1，说明这是COMPRESSED_TCP型的数据报。其余7 bit中的6个规定了后续首部中存在哪些可选字段，图29-35小结了这7 bit的用法。

标志比特	描述	结构变量	标志等于0说明	标志等于1说明
C	连接ID		连接ID不变	connid=连接ID
I	IP标识符	ip_id	ip_id已加1	Δipid=IP标识符差值
P	TCP推标志		PSH标志清除	PSH标志置位
S	TCP序号	th_seq	th_seq不变	Δseq=TCP序号差值
A	TCP确认序号	th_ack	th_ack不变	Δack=TCP确认序号差值
W	TCP窗口	th_win	th_win不变	Δwin=TCP窗口字段差值
U	TCP紧急数据偏移量	th_urg	URG标志未置位	urgoff=紧急数据偏移量

图29-35 压缩首部中的7个标志比特

- C 如果C比特等于0，则当前报文段与前一报文段(无论是压缩的或非压缩的)具有相同的连接ID。如果等于1，则*connid*将等于连接ID，其值位于0~255之间。
- I 如果I比特等于0，当前报文段的IP标识符较前一报文段加1(典型情况)。如果等于1，*Δipid*等于*ip_id*的当前值减去它的前一个值。

- P 这个比特复制自 TCP报文段中的 PSH标志位。因为 PSH标志不同于其他的正常方式，必须在每个报文段中明确地定义这一标志。
- S 如果S比特等于0，TCP序号不变。如果等于1， Δseq 等于th_seq的当前值减去它的前一个值。
- A 如果A比特等于0，TCP确认序号不变(典型情况)。如果等于1，ack等于th_ack的当前值减去它的前一个值。
- W 如果W比特等于0，TCP窗口大小不变。如果等于1， Δwin 等于th_win的当前值减去它的前一个值。
- U 如果U比特等于0，报文段的URG标志未置位，紧急数据偏移量不变(典型情况)。如果等于1，说明URG标志置位，urgoff等于th_urg的当前值。如果URG标志未置位时，紧急数据偏移量发生改变，报文段将被直接发送(这种现象通常发生在紧急数据传送完毕后的第一个报文段)。

通过字段的当前值减去它的前一个值，得到需传输的差值。正常情况下，得到的是一个小正数(Δwin 是个例外)。

请注意，图29-34中有5个字段的长度可变，可占用0、1或3字节。

0字节：对应标志未置位，此字段不存在；

1字节：发送值在1~255之间，只需占用1字节；

3字节：如果发送值等于0或者在256~65535之间，则需要用3个字节才能表示：第一个字节全0，后两个字节保存实际值。这种方法一般用于3个16 bit的值：urgoff、win和ipid。但如果两个32 bit字段 Δack 和 seq 的差值小于0或者大于65535，报文段将被直接发送。

如果把图29-33中不带阴影的字段与图29-34中可能的传输字段进行比较，会发现有些字段永远不会被传输。

- IP总长度字段不会被传输，因为绝大多数链路层向接收方提供接收数据分组的长度。
- 因为IP首部中被传输的惟一字段是16 bit的IP标识符，IP检验和被忽略。因为它只在一段链路上保护IP首部，每次转发都会被重新计算。

29.13.3 特殊情况

算法检查输入报文段，如果出现两种特定情况，则用前导字节的低位4比特——SAWU——的两种特殊组合，分别加以表示。因为紧急数据很少出现，如果报文段中URG标志置位，并且与前一报文段相比，序号与窗口字段都发生了变化(意味着低位4比特应为1011或1111)，此种报文段会跳过压缩算法，被直接发送。因此，如果低位4比特等于1011(称为*SA)或1111(称为*S)，就说明出现了下面两种特定情况：

*SA 序号与确认序号都增加，差值等于前一报文段的数据量，窗口大小与紧急数据偏移量不变，URG标志未置位。采用这种表示法可以避免传送 Δseq 和 Δack 。

如果对端回送终端数据，那么两个传输方向上的数据报文段中都会经常出现这一现象。卷1的图19-3和图19-4，举例说明了远程登录应用中出现的这种类型的数据。

*S 序号增加，差值等于前一报文段的数据量，确认序号、窗口大小与紧急数据偏移量均不变，URG标志未置位。采用这种表示法可以避免传送 seq 。

这种类型的数据通常出现在单向数据传输(如FTP)的发送方。卷1的图20-1、图20-2

和图20-3举例说明了这种类型的数据传输。此外，如果对端不回送终端数据，那么在数据发送方的数据报文段中也会出现这种现象。

29.13.4 实例

下面的两个例子，在图1-17中的bsdi和slip两个系统间，利用SLIP链路传输数据。这条SLIP链路在两个传输方向上都采用了头部压缩算法。在主机bsdi上运行tcpdump程序(卷1的附录A)，保存所有数据帧的备份。这个程序还支持一个选项，能够输出压缩后的头部，列出图29-34中的所有字段。

在主机间已建立了两条连接：一条远程登录连接，另一条是从bsdi到slip的文件传输(FTP)。图29-36列出了两条连接上不同类型数据帧出现的次数。

帧 类型	远程登录		FTP	
	输入	输出	输入	输出
IP	1	1	5	5
UNCOMPRESSED_TCP	3	2	2	3
COMPRESSED_TCP				
特殊情况 *SA	75	75	0	0
特殊情况 *S	25	1	1	325
一般情况	9	93	337	13
总数	113	172	345	346

图29-36 远程登录和FTP连接上，不同类型数据帧出现的次数

远程登录连接中，在两个传输方向上，*SA都出现了75次，从而证明了在对端回显终端流量时，这一特定情况在两个传输方向上都会经常出现。FTP连接中，在数据的发送方，*S出现了325次，也证明了对于单向数据传输，这一特定情况会经常出现在数据的发送方。

FTP连接中，IP型的数据帧出现了10次，对应于4个带有SYN的报文段，和6个带有FIN的报文段。FTP使用了两条连接：一条用于传输交互式命令，另一条用于文件传输。

UNCOMPRESSED_TCP型数据帧一般对应于连接建立后的第一个报文段，即同步连接ID的报文段。这两个例子中还有少量的其他类型的报文段，主要用于服务类型设定(Net/3中的远程登录及FTP客户及服务器都是在连接建立后才设定TOS字段)。

字节数	远程登录		FTP	
	输入	输出	输入	输出
3	102	44	2	250
4		94		78
5	7	12	5	2
6		6	325	5
7		13	2	1
8				1
9			4	1
总数	109	169	338	338

图29-37 压缩首部大小的分布

图29-37给出了压缩首部大小的分布情况，后4栏中压缩首部的平均大小为分别等于3.1、4.1、6.0和3.3字节，与原来的40字节相比，大大提高了系统的传输效率，尤其对于交互式连接，效果更加明显。

在FTP输入一栏中，压缩首部大小为6字节的报文段有325个，其中绝大多数只携带了值等于256的 Δack 字段，因为256大于255，所以必须用3个字节表示。SLIPMTU等于296，因此，TCP采用了256的MSS。在FTP输出一栏中，压缩首部大小为3字节的报文段有250个，其中绝大多数都代表* S 类的特定情况(只有序号发生变化)，差值等于256。但因为* S 的序号差值默认为前一报文段的数据量，所以只需传输前导字节和TCP检验和。在FTP输出一栏中，78个压缩首部大小为4字节的报文段也属于同一情况，只不过IP标识符也发生了变化(习题29.8)。

29.13.5 配置

对给定的SLIP或PPP链路，首部压缩必须被选定后才能起作用。配置SLIP链路接口时，一般可设定两个标志：首部压缩标志和自动首部压缩标志。配置命令是ifconfig，分别带选项link0和link2。正常情况下，由客户端(拨号主机)决定是否采用首部压缩算法，服务器(客户通过拨号接入的主机或终端服务器)只选择是否置位自动首部压缩标志。如果客户选用了首部压缩算法，它的TCP首先发送一个UNCOMPRESSED_TCP型的数据报，规定连接ID。如果服务器收到这个数据报，它也开始采用首部压缩算法(服务器处于自动方式)；如果未收到这个数据报，服务器绝不会在这条链路上采用首部压缩。

PPP允许在链路建立时，连接双方共同协商传输选项，其中的一个选项即是否支持首部压缩算法。

29.14 小结

本章结束了我们对TCP输入处理的详细介绍。首先介绍了如果连接在SYN_RCVD状态时收到了ACK，该如何处理，即如何完成被动打开、同时打开或自连接。

快速重传算法指TCP在连续收到的重复ACK数超过规定的门限值后，能够检测到丢失的报文段并进行重发，即使重传定时器还未超时。Net/3结合了快速重传算法与快速恢复算法，执行拥塞避免算法而非慢起动，尽量保证发送方到接收方的数据流不中断。

ACK处理负责从插口的发送缓存中丢弃已确认的数据，并且在收到的ACK会改变连接当前状态时，对一些TCP状态做特殊处理。

处理接收报文段的URG标志，如果置位，则通过TCP紧急方式的处理，提取带外数据。这一操作是非常复杂的，因为应用进程可以利用正常的数据流缓存，或者特殊的带外数据缓存接收带外数据，而且TCP收到URG时，紧急指针所指向的数据可能还未到达。

TCP输入处理结束时，会调用TCP_REASS，提取报文段中的数据放入插口的接收缓存或重组队列，处理FIN标志，并且在接收报文段需要响应时，调用tcp_output输入响应报文段。

TCP首部压缩是用于SLIP和PPP链路的一种技术，能够把IP和TCP首部长度从40字节减少到约为3~6字节(典型情况)。这是因为对于给定连接，相邻两个报文段之间，首部的多数字段不会改变，即使有些字段的值发生了变化，其差值也很小，从而可以通过前导字节中的标志比特，指明哪些字段发生了变化，在后续部分只传输这些字段的当前值与前一报文段间的差值。

习题

- 29.1 客户与服务器建立连接，不考虑报文段丢失，哪一个应用进程，客户或服务器，首先完成连接建立过程？
- 29.2 Net/3系统中，监听服务器收到了一个 SYN，它同时携带了 50字节的数据。会发生什么？
- 29.3 继续前一个习题，假定客户没有重传 50字节的数据，而是在对服务器 SYN/ACK报文段的确认中置位FIN标志，会发生什么？
- 29.4 Net/3客户向服务器发送 SYN，服务器响应 SYN/ACK，其中还携带了 50字节的数据和FIN标志。列出客户端TCP的处理步骤。
- 29.5 卷1的图18-19和RFC 793的图14，都给出了出现同时关闭时，连接双方交换的 4个报文段。但如果连接两端都是 Net/3系统，出现同时关闭时，或者一个 Net/3系统的自连接关闭时，彼此将交换 6个报文段，而不是 4个，多余出两个报文段是因为连接两端各自收到对端的 FIN后，将向对端重发 FIN。问题出在什么地方，如何解决？
- 29.6 RFC 793第72页建议，如果发送缓存中的数据已被对端确认，“应给用户一个确认，指明缓存中已发送且被确认的数据（例如，发送缓存返回时应带有‘OK’响应）”。Net/3是否提供了这种机制？
- 29.7 RFC 1323中定义的选项对TCP首部压缩有何影响？
- 29.8 Net/3对IP标识符字段的赋值方式，对 TCP首部压缩有何影响？

第30章 TCP的用户需求

30.1 引言

本章介绍TCP的用户请求处理函数 `tcp_usrreq`，它被协议的 `pr_usrreq` 函数调用，处理各种与 TCP 插口有关的系统调用。此外，还将介绍 `tcp_ctloutput`，应用进程调用 `setsockopt` 设定 TCP 插口选项时，会用到它。

30.2 `tcp_usrreq` 函数

TCP的用户请求函数用于处理多种操作。图 30-1 给出了 `tcp_usrreq` 函数的基本框架，其中 `switch` 的语句体部分将在后续部分逐一展开。图 15-17 中列出了函数的参数，其具体含义取决于所处理的用户请求。

```
tcp_usrreq.c
45 int
46 tcp_usrreq(so, req, m, nam, control)
47 struct socket *so;
48 int     req;
49 struct mbuf *m, *nam, *control;
50 {
51     struct inpcb *inp;
52     struct tcpcb *tp;
53     int     s;
54     int     error = 0;
55     int     ostate;

56     if (req == PRU_CONTROL)
57         return (in_control(so, (int) m, (caddr_t) nam,
58                             (struct ifnet *) control));
59     if (control && control->m_len) {
60         m_freem(control);
61         if (m)
62             m_freem(m);
63         return (EINVAL);
64     }
65     s = splnet();
66     inp = sotoinpcb(so);
67     /*
68      * When a TCP is attached to a socket, then there will be
69      * a (struct inpcb) pointed at by the socket, and this
70      * structure will point at a subsidiary (struct tcpcb).
71      */
72     if (inp == 0 && req != PRU_ATTACH) {
73         splx(s);
74         return (EINVAL);          /* XXX */
75     }
76     if (inp) {
77         tp = intotcpcb(inp);
```

图30-1 `tcp_usrreq` 函数体

```

78         /* WHAT IF TP IS 0? */
79         ostate = tp->t_state;
80     } else
81         ostate = 0;
82     switch (req) {
83
84             /* switch cases */
85
86
87     default:
88         panic("tcp_usrreq");
89     }
90     if (tp && (so->so_options & SO_DEBUG))
91         tcp_trace(TA_USER, ostate, tp, (struct tciphdr *) 0, req);
92     splx(s);
93     return (error);
94 }
```

tcp_usrreq.c

图30-1 (续)

1. in_control处理ioctl请求

45-58 PRU_CONTROL请求来自于 ioctl系统调用，函数in_control负责处理这一请求。

2. 控制信息无效

59-64 如果试图调用 sendmsg，为TCP插口配置控制信息，代码将释放 mbuf，并返回EINVAL差错代码，声明这一操作无效。

65-66 函数接着执行splnet。这种做法极为保守，因为并非在所有情况下都需要锁定，只是为了防止在case语句中单个地调用splnet。我们在图23-15中曾提到，调用splnet设定处理器的优先级，唯一的作用是阻止软中断执行IP输入处理(它会接着调用tcp_input)，但却无法阻止接口层接收输入数据分组并放入到IP的输入队列中。

通过指向插口结构的指针，可得到指向 Internet PCB的指针。只有在应用进程调用socket系统调用，发出PRU_ATTACH请求时，该指针才允许为空。

67-81 如果inp非空，当前连接状态将保存在ostate中，以备函数结束时可能会调用tcp_trace。

下面我们开始讨论单独的case语句。应用进程调用socket系统调用，或者监听服务器收到连接请求(图28-7)，调用sonewconn函数时，都会发出PRU_ATTACH请求，图30-2给出了这一请求的处理代码。

```

83     /*
84      * TCP attaches to socket via PRU_ATTACH, reserving space,
85      * and an internet control block.
86      */
87     case PRU_ATTACH:
88         if (inp) {
89             error = EISCONN;
90             break;
91         }
92         error = tcp_attach(so);
93         if (error)
94 }
```

tcp_usrreq.c

图30-2 *tcp_usrreq* 函数：PRU_ATTACH 和PRU_DETACH 请求

```

94         break;
95     if ((so->so_options & SO_LINGER) && so->so_linger == 0)
96         so->so_linger = TCP_LINGERTIME;
97     tp = sototcpb(so);
98     break;

99     /*
100      * PRU_DETACH detaches the TCP protocol from the socket.
101      * If the protocol state is non-embryonic, then can't
102      * do this directly: have to initiate a PRU_DISCONNECT,
103      * which may finish later; embryonic TCB's can just
104      * be discarded here.
105      */
106    case PRU_DETACH:
107        if (tp->t_state > TCPS_LISTEN)
108            tp = tcp_disconnect(tp);
109        else
110            tp = tcp_close(tp);
111        break;

```

tcp_usrreq.c

图30-2 (续)

3. PRU_ATTACH请求

83-94 如果插口结构已经指向某个PCB，则返回EISCONN差错代码。调用tcp_attach完成处理：分配并初始化Internet PCB和TCP控制块。

95-96 如果选用了SO_LINGER插口选项，且拖延时间为0，则将其设为120(TCP_LINGERTIME)。

为什么在PRU_ATTACH请求发出之前，就可以设定插口选项？尽管不可能在调用socket之前就设定插口选项，但sonewconn也会发送PRU_ATTACH请求。它在把监听插口的so_options复制到新建插口之后，才会发送PRU_ATTACH请求。此处的代码防止新建连接从监听插口中继承拖延时间为0的SO_LINGER选项。

请注意，此处的代码有错误。常量TCP_LINGERTIME在tcp_timer.h中初始化为120，该行的注释为“最多等待2分钟”。但SO_LINGER值也是内核tsleep函数(由soclose调用)的最后一个参数，从而成为内核的timeout函数的最后一个参数，单位为滴答，而非秒。如果系统的滴答频率(hz)等于100，则拖延时间将变为1.2秒，而非2分钟。

97 现在，tp已指向插口的TCP控制块。这样，如果选定了SO_DEBUG插口选项，函数结束时就可以输出所需信息。

4. PRU_DETACH请求

99-111 close系统调用在PRU_DISCONNECT请求失败后，将发送PRU_DETACH请求。如果连接尚未建立(连接状态小于ESTABLISHED)，则无需向对端发送任何信息。但如果连接已建立，则调用tcp_disconnect初始化TCP的连接关闭过程(发送所有缓存中的数据，之后发送FIN)。

代码if语句的测试条件要求状态大于LISTEN，这是不正确的。因为如果连接状态等于SYN_SENT或者SYN_RCVD，两者都大于LISTEN，此时tcp_disconnect会直接调用tcp_close。实际上，这个case语句可以简化为直接调用tcp_disconnect。

图30-3给出了bind和listen系统调用的处理代码。

```

112      /*
113       * Give the socket an address.
114       */
115     case PRU_BIND:
116         error = in_pcbbind(inp, nam);
117         if (error)
118             break;
119         break;

120     /*
121      * Prepare to accept connections.
122      */
123     case PRU_LISTEN:
124         if (inp->inp_lport == 0)
125             error = in_pcbbind(inp, (struct mbuf *) 0);
126         if (error == 0)
127             tp->t_state = TCPS_LISTEN;
128         break;

```

tcp_usrreq.c

图30-3 *tcp_usrreq* 函数：PRU_BIND 和PRU_LISTEN 请求

112-119 PRU_BIND请求的处理只是简单地调用 in_pcbbind。

120-128 对于 PRU_LISTEN请求，如果插口还未绑定在某个本地端口上，则调用 in_pcbbind自动为其分配一个。这种情况十分少见，因为多数服务器会明确地绑定一个知名端口，尽管RPC(远端过程调用)服务器一般是绑定在一个临时端口上，并通过 Port Mapper向系统注册该端口(卷1的29.4节介绍了Port Mapper)。连接状态变迁到LISTEN，完成了listen调用的主要目的：设定插口的状态，以便接收到达的连接请求(被动打开)。

图30-4给出了connect系统调用的处理代码：客户发起的主动打开。

```

129     /*
130      * Initiate connection to peer.
131      * Create a template for use in transmissions on this connection.
132      * Enter SYN_SENT state, and mark socket as connecting.
133      * Start keepalive timer, and seed output sequence space.
134      * Send initial segment on connection.
135      */
136     case PRU_CONNECT:
137         if (inp->inp_lport == 0) {
138             error = in_pcbbind(inp, (struct mbuf *) 0);
139             if (error)
140                 break;
141         }
142         error = in_pcbbconnect(inp, nam);
143         if (error)
144             break;

145         tp->t_template = tcp_template(tp);
146         if (tp->t_template == 0) {
147             in_pcbbdisconnect(inp);
148             error = ENOBUFS;

```

图30-4 *tcp_usrreq* 函数：PRU_CONNECT 请求

```

149         break;
150     }
151     /* Compute window scaling to request. */
152     while (tp->request_r_scale < TCP_MAX_WINSHIFT &&
153           (TCP_MAXWIN << tp->request_r_scale) < so->so_rcv.sb_hiwat)
154         tp->request_r_scale++;
155     soisconnecting(so);
156     tcpstat.tcps_connattempt++;
157     tp->t_state = TCPS_SYN_SENT;
158     tp->t_timer[TCPT_KEEP] = TCPTV_KEEP_INIT;
159     tp->iss = tcp_iss;
160     tcp_iss += TCP_ISSINCR / 2;
161     tcp_sendseqinit(tp);
162     error = tcp_output(tp);
163     break;

```

tcp_usrreq.c

图30-4 (续)

5. 分配临时端口

129-141 如果插口还未绑定在某个本地端口上，调用 `ip_pcbbind` 自动为其分配一个。对于客户端，这是很常见的，因为客户一般不关心本地端口值。

6. 连接PCB

142-144 调用 `in_pcbservice`，获取到达目的地的路由，确定外出接口，验证插口对不重复。

7. 初始化IP和TCP首部

145-150 调用 `tcp_template` 分配 mbuf，保存 IP 和 TCP 的首部，并初始化两个首部，填入尽可能多的信息。会造成函数失败的唯一原因是内核耗尽了 mbuf。

8. 计算窗口缩放因子

151-154 计算用于接收缓存的窗口缩放因子：左移 $65535(\text{TCP_MAXWIN})$ ，直到它大于或等于接收缓存的大小(`so_rcv.sb_hiwat`)。得到的位移次数(0~14之间)，就是需要在SYN中发送的缩放因子值(图28-7处理被动打开时，有相同的代码)。应用进程必须在调用 `connect` 之前，设定 `SO_RECVBUF` 插口选项，TCP才会在SYN中添加窗口大小选项，否则，将使用接收缓存大小的默认值(图24-3中的`tcp_recvspace`)。

9. 设定插口和连接的状态

155-158 调用 `soisconnecting`，置位插口状态变量中恰当的比特，设定 TCP 连接状态为 `SYN_SENT`，从而在后续的 `tcp_output` 调用中发送 SYN(参见图24-16的 `tcp_outlags` 值)。连接建立定时器启动，时限初始化为 7 秒。`tcp_output` 还会启动 SYN 的重传定时器，如图25-16所示。

10. 初始化序号

159-161 令初始序号等于全局变量 `tcp_iss`，之后令 `tcp_iss` 增加 $64\ 000$ (`TCP_ISSINCR` 除以 2)。在监听服务器收到 SYN 并初始化 ISS 时(图28-17)，对 `tcp_iss` 的相同的操作。接着调用 `tcp_sendseqinit` 初始化发送序号。

11. 发送初始SYN

162 调用 `tcp_output` 发送初始 SYN，以建立连接。如果 `tcp_output` 返回错误(例如，mbuf 耗尽或没有到达目的地的路由)，该差错代码将成为 `tcp_usrreq` 的返回值，报告给应用进程。

图30-5给出了PRU_CONNECT2、PRU_DISCONNECT和PRU_ACCEPT请求的处理代码。

164-169 PRU_CONNECT2请求，来自于socketpair系统调用，对TCP协议无效。

170-183 close系统调用会发送PRU_DISCONNECT请求。如果连接已建立，应调用tcp_disconnect，发送FIN，执行正常的TCP关闭操作。

```

164      /*
165      * Create a TCP connection between two sockets.
166      */
167      case PRU_CONNECT2:
168          error = EOPNOTSUPP;
169          break;
170
171      /*
172      * Initiate disconnect from peer.
173      * If connection never passed embryonic stage, just drop;
174      * else if don't need to let data drain, then can just drop anyway,
175      * else have to begin TCP shutdown process: mark socket disconnecting,
176      * drain unread data, state switch to reflect user close, and
177      * send segment (e.g. FIN) to peer. Socket will be really disconnected
178      * when peer sends FIN and acks ours.
179      *
180      * SHOULD IMPLEMENT LATER PRU_CONNECT VIA REALLOC TCPCB.
181      */
182      case PRU_DISCONNECT:
183          tp = tcp_disconnect(tp);
184          break;
185
186      /*
187      * Accept a connection. Essentially all the work is
188      * done at higher levels; just return the address
189      * of the peer, storing through addr.
190      */
191      case PRU_ACCEPT:
192          in_setpeeraddr(inp, nam);
193          break;

```

tcp_usrreq.c

图30-5 tcp_usrreq 函数：PRU_CONNECT2 、PRU_DISCONNECT 和PRU_ACCEPT 请求

请注意以“应该实现”起头的注释，这是因为无法接着使用出现错误的插口。

例如，客户调用connect，并得到一个错误，它就无法在同一个插口上再次调用connect，而必须首先关闭插口，调用socket创建新的插口，在新的插口上才能再次调用connect。

184-191 与accept系统调用有关的工作全部由插口层和协议层完成。PRU_ACCEPT请求只简单地向应用进程返回对端的IP地址和端口号。

图30-6给出了PRU_SHUTDOWN、PRU_RCVD和PRU_SEND请求的处理代码。

12. PRU_SHUTDOWN请求

192-200 应用进程调用shutdown，禁止更多的输出时，soshutdown会发送PRU_SHUTDOWN请求。调用socantsendmore置位插口的标志，禁止继续发送报文段。接着调用tcp_usrclosed，根据图24-15的状态变迁图，设定正确的连接状态。tcp_output发送FIN之前，如果发送缓存中仍有数据，会首先发送等待数据。

```

192     /*
193      * Mark the connection as being incapable of further output.
194      */
195     case PRU_SHUTDOWN:
196         socantsendmore(so);
197         tp = tcp_usrclosed(tp);
198         if (tp)
199             error = tcp_output(tp);
200         break;
201
202     /*
203      * After a receive, possibly send window update to peer.
204      */
205     case PRU_RCVD:
206         (void) tcp_output(tp);
207         break;
208
209     /*
210      * Do a send by putting data in output queue and updating urgent
211      * marker if URG set. Possibly send more data.
212      */
213     case PRU_SEND:
214         sbappend(&so->so_snd, m);
215         error = tcp_output(tp);
216         break;

```

*tcp_usrreq.c*图30-6 *tcp_usrreq* 函数：PRU_SHUTDOWN、PRU_RCVD 和PRU_SEND 请求

13. PRU_RCVD请求

201-206 应用进程从插口的接收缓存中读取数据后，*soreceive*会发送这个请求。此时接收缓存已扩大，也许会有足够的空间，让TCP发送更大的窗口通告。*tcp_output*会决定是否需要发送窗口更新报文段。

14. PRU_SEND请求

207-214 图23-14中给出的5个写函数，都以这一请求结束。调用*sbappend*，向插口的发送缓存中添加数据(它将一直保存在缓存中，直到被确认)，并调用*tcp_output*发送新报文段(如果条件允许)。

图30-7给出了PRU_ABORT和PRU_SENSE请求的处理代码。

```

215     /*
216      * Abort the TCP.
217      */
218     case PRU_ABORT:
219         tp = tcp_drop(tp, ECONNABORTED);
220         break;
221
222     case PRU_SENSE:
223         ((struct stat *) m)->st_blksize = so->so_snd.sb_hiwat;
224         (void) splx(s);
225         return (0);

```

*tcp_usrreq.c*图30-7 *tcp_usrreq* 函数：PRU_ABORT 和PRU_SENSE 请求

15. PRU_ABORT请求

215-220 如果插口是监听插口(如服务器)，并且存在等待建立的连接，例如已发送初始

SYN或已完成三次握手过程，但还未被服务器 `accept` 的连接，调用 `soclose` 会导致发送 PRU_ABORT 请求。如果连接已同步，`tcp_drop` 将发送 RST。

16. PRU_SENSE 请求

221-224 `fstat` 系统调用会生成 PRU_SENSE 请求。TCP 返回发送缓存的大小，保存在 `stat` 结构的成员变量 `st_blksize` 中。

图30-8给出了PRU_RCVOOB的处理代码。当应用进程置位 MSG_OOB标志，试图读取带外数据时，`soreceive`会发送这一请求。

```
tcp_usrreq.c
225     case PRU_RCVOOB:
226         if ((so->so_oobmark == 0 &&
227             (so->so_state & SS_RCVATMARK) == 0) ||
228             so->so_options & SO_OOBINLINE ||
229             tp->t_oobflags & TCPOOB_HADDATA) {
230             error = EINVAL;
231             break;
232         }
233         if ((tp->t_oobflags & TCPOOB_HAVEDATA) == 0) {
234             error = EWOULDBLOCK;
235             break;
236         }
237         m->m_len = 1;
238         *mtod(m, caddr_t) = tp->t_iobc;
239         if (((int) nam & MSG_PEEK) == 0)
240             tp->t_oobflags ^= (TCPOOB_HAVEDATA | TCPOOB_HADDATA);
241         break;
```

tcp_usrreq.c

图30-8 `tcp_usrreq` 函数：PRU_RCVOOB 请求

17. 能否读取带外数据

225-232 如果下列3个条件有一个为真，应用进程读取带外数据的努力就会失败。

1) 如果插口的带外数据分界点 (`so_oobmark`) 等于0，并且插口的 `SS_RCVATMARK` 标志未设定；或者

2) 如果 `SO_OOBINLINE` 插口选项设定；或者

3) 如果连接的 `TCPOOB_HADDATA` 标志设定(例如，连接的带外数据已被读取)。

如果上述3个条件中任何一个为真，则返回差错代码 `EINVAL`。

18. 是否有带外数据到达

233-236 如果上述3个条件全假，但 `TCPOOB_HAVEDATA` 标志置位，说明尽管 TCP 已收到了对端发送的紧急方式通告，但尚未收到序号等于紧急指针减1的字节(图29-17)，此时返回差错代码 `EWOULDBLOCK`，有可能因为发送方发送紧急数据通告时，紧急数据偏移量指向了尚未发送的字节。卷1的图26-7举例说明了这种情况，发送方的数据传输被对端的零窗口通告停止时，常出现这种现象。

19. 返回带外数据字节

237-238 `tcp_pULLoutofband` 向应用进程返回存储在 `t_iobc` 中的一个字节的带外数据。

20. 更新标志

239-241 如果应用进程已读取了带外数据(而不是仅大致了解带外数据的情况，`MSG_PEEK` 标志置位)，TCP 清除 `HAVE` 标志，并置位 `HAD` 标志。`case` 语句执行到此处时，通过前面的代码可

以肯定，HAVE标志已置位，而HAD标志被清除。置位HAD标志的目的是防止应用进程试图再次读取带外数据。一旦HAD标志置位，在收到新的紧急指针之前，它不会被清除(图29-17)。

代码使用了让人费解的异或运算，而不是简单的

```
tp->t_oobflags = TCPOOB_HADDATA;
```

是为了能够在t_oobflags中定义更多的比特。但Net/3中，实际只用到了上面提及的两个标志比特。

图30-9中的PRU_SENDOOB请求，是在应用进程写入数据并置位MSG_OOB时，由sosend发送的。

```

242     case PRU_SENDOOB:
243         if (sbspace(&so->so_snd) < -512) {
244             m_freem(m);
245             error = ENOBUFS;
246             break;
247         }
248         /*
249          * According to RFC961 (Assigned Protocols),
250          * the urgent pointer points to the last octet
251          * of urgent data. We continue, however,
252          * to consider it to indicate the first octet
253          * of data past the urgent section.
254          * Otherwise, snd_up should be one lower.
255          */
256         sbappend(&so->so_snd, m);
257         tp->snd_up = tp->snd_una + so->so_snd.sb_cc;
258
259         tp->t_force = 1;
260         error = tcp_output(tp);
261         tp->t_force = 0;
262
263         break;

```

tcp_usrreq.c

图30-9 *tcp_usrreq* 函数：PRU_SENDOOB 请求

21. 确认发送缓存中有足够空间并添加新数据

242-247 发送带外数据时，允许应用进程写入数据后，待发送数据量超过发送缓存大小，超出量最多为512字节。插口层的限制要宽松一些，写入带外数据后，最多可超出发送缓存1024字节(图16-24)。调用sbappend向发送缓存末端添加数据。

22. 计算紧急指针

248-257 紧急指针(snd_up)指向写入的最后一个字节之后的字节。图26-30举例说明了这一点，假定发送缓存为空，应用进程写入3字节的数据，且置位了MSG_OOB标志。这是考虑到若应用进程置位MSG_OOB标志，且写入的数据量超过1字节，如果接收方为伯克利系统，则只有最后一个字节会被认为是带外数据。

23. 强制TCP输出

258-261 令t_force等于1，并调用tcp_output。即使收到了对端的零窗口通告，TCP也会发送报文段，URG标志置位，紧急指针偏移量非零。卷1的图26-7说明了如何向一个关闭的接收窗口发送紧急报文段。

图30-10给出了最后3个请求的处理。

```

262     case PRU_SOCKADDR:
263         in_setsockaddr(inp, nam);
264         break;
265
266     case PRU_PEERADDR:
267         in_setpeeraddr(inp, nam);
268         break;
269
270         /*
271          * TCP slow timer went off; going through this
272          * routine for tracing's sake.
273          */
274
275     case PRU_SLOWTIMO:
276         tp = tcp_timers(tp, (int) nam);
277         req |= (int) nam << 8; /* for debug's sake */
278         break;

```

tcp_usrreq.c

图30-10 *tcp_usrreq* 函数：*PRU_SOCKADDR*、*PRU_PEERADDR* 和*PRU_SLOWTIMO* 请求

262-267 getsockname和getpeername系统调用分别发送 PRU_SOCKADDR 和 PRU_PEERADDR 请求。调用 in_setsockaddr 和 in_setpeeraddr 函数，从 PCB 中获取需要信息，存储在 addr 参数中。

268-275 执行 *tcp_slowtimo* 函数会发送 PRU_SLOWTIMO 函数。如同注释所指出的，*tcp_slowtimo* 不直接调用 *tcp_timers* 的唯一原因是能够函数结尾处调用 *tcp_trace*，跟踪记录定时器超时事件(图30-1)。为了在记录中指明是 4 个 TCP 定时器中的哪一个超时，*tcp_slowtimo* 通过 nam 参数传递了 *t_timer* 数组(图25-1)的指针，并左移 8 位后与请求值(req)逻辑或。*trpt* 程序了解这种做法，并据此完成相应的处理。

30.3 *tcp_attach* 函数

tcp_attach 函数，在处理 PRU_ATTACH 请求(例如，插口系统调用，或者监听插口上收到了新的连接请求)时，由 *tcp_usrreq* 调用。图 30-11 给出了它的代码。

1. 为发送缓存和接收缓存分配资源

361-372 如果还未给插口的发送和接收缓存分配空间，*sbsreserve* 将两者都设为 8192，即全局变量 *tcp_sendspace* 和 *tcp_recvspace* 的默认值(图 24-3)。

这些默认值是否够用，取决于连接两个传输方向上的 MSS，后者又取决于 MTU。

例如，[Comer and Lin 1994] 论证了，如果发送缓存小于 3 倍的 MSS，则会出现异常，严重降低系统性能。某些实现定义的默认值很大，如 61 444 字节，已考虑到这些默认值对性能的影响，尤其对较大的 MTU(如 FDDI 和 ATM) 更是如此。

2. 分配 Internet PCB 和 TCP 控制块

373-377 *in_pcbaalloc* 分配 Internet PCB，而 *tcp_newtcpcb* 分配 TCP 控制块，并将其与对应的 PCB 相连。

378-384 如果 *tcp_newtcpcb* 调用 *malloc* 时失败，则执行注释为“XXX”的代码。前面已介绍过，PRU_ATTACH 请求是插口系统调用或监听插口收到新的连接请求(*soneconn*)的结果。对于后一种情况，插口标志 *SS_NOFDREF* 置位。如果此标志置位，*in_pcbaalloc* 调用 *sofree* 时会释放插口结构。但我们在 *tcp_input* 中看到，除非该函数已完成接收报文段

的处理(图29-27中的`dropsocket`标志)，否则，不应释放插口结构。因此，调用`in_pcbo_detach`时，应将`SS_NOFDREF`标志的当前值保存在变量`nofd`中，并在`tcp_attach`返回前重设该标志。

385-386 TCP连接状态初始化为CLOSED。

```

361 int
362 tcp_attach(so)
363 struct socket *so;
364 {
365     struct tcpcb *tp;
366     struct inpcb *inp;
367     int      error;
368
369     if (so->so_snd.sb_hiwat == 0 || so->so_rcv.sb_hiwat == 0) {
370         error = soreserve(so, tcp_sendspace, tcp_recvspace);
371         if (error)
372             return (error);
373     }
374     error = in_pcbo_detach(so, &tcb);
375     if (error)
376         return (error);
377     inp = sotoinpcb(so);
378     tp = tcp_newtcpcb(inp);
379     if (tp == 0) {
380         int      nofd = so->so_state & SS_NOFDREF; /* XXX */
381         so->so_state &= ~SS_NOFDREF; /* don't free the socket yet */
382         in_pcbo_detach(inp);
383         so->so_state |= nofd;
384         return (ENOBUFS);
385     }
386     tp->t_state = TCPS_CLOSED;
387 }
```

tcp_usrreq.c

图30-11 `tcp_attach` 函数：创建新的TCP插口

30.4 `tcp_disconnect`函数

图30-12给出的`tcp_disconnect`函数，准备断开TCP连接。

1. 连接未同步

396-402 如果连接还未进入ESTABLISHED状态(如LISTEN、SYN_SENT或SYN_RCVD)，`tcp_close`只释放PCB和TCP控制块。无需向对端发送任何报文段，因为连接尚未同步。

2. 硬性断开

403-404 如果连接已同步，且`SO_LINGER`插口选项置位，拖延时间(`SO_LINGER`)设为零，则调用`tcp_drop`丢弃连接。连接不经过`TIME_WAIT`，直接更新为CLOSED，向对端发送RST，释放PCB和TCP控制块。调用`close`会发送PRU_DISCONNECT请求，丢弃仍在发送或接收缓存中的任何数据。

如果`SO_LINGER`插口选项置位，且拖延时间非零，则调用`soclose`进行处理。

3. 平滑断开

405-406 如果连接已同步，且`SO_LINGER`选项未设定，或者选项设定且拖延时间不为零，

则执行TCP正常的连接终止步骤。soisdisconnecting设定插口状态。

```

396 struct tcpcb *
397 tcp_disconnect(tp)
398 struct tcpcb *tp;
399 {
400     struct socket *so = tp->t_inpcb->inp_socket;
401     if (tp->t_state < TCPS_ESTABLISHED)
402         tp = tcp_close(tp);
403     else if ((so->so_options & SO_LINGER) && so->so_linger == 0)
404         tp = tcp_drop(tp, 0);
405     else {
406         soisdisconnecting(so);
407         sbflush(&so->so_rcv);
408         tp = tcp_usrclosed(tp);
409         if (tp)
410             (void) tcp_output(tp);
411     }
412     return (tp);
413 }
```

tcp_usrreq.c

图30-12 tcp_disconnect 函数：准备断开TCP连接

4. 丢弃滞留的接收数据

407 调用sbflush，丢弃所有滞留在接收缓存中的数据，因为应用进程已关闭了插口。发送缓存中的数据仍保留，tcp_output将试图发送剩余的数据。我们说“试图”，因为不能保证数据还能成功地被发送。在收到并确认这些数据之前，对端可能已崩溃，即使对端的TCP模块能够接收并确认这些数据，在应用程序读取数据之前，系统也可能崩溃。因为本地进程已关闭了插口，即使TCP放弃发送仍滞留在发送缓存中的数据（因为重传定时器最终超时），也无法向应用进程通告错误。

5. 改变连接状态

408-410 tcp_usrclosed基于连接的当前状态，促使其进入下一状态。通常情况下，连接将转移到FIN_WAIT_1状态，因为连接关闭时一般都处于ESTABLISHED状态。后面会看到，tcp_usrclosed通常返回当前控制块的指针(tp)。因为状态必须先同步才会执行此处的代码，所以总需要调用tcp_output发送报文段。如果连接从ESTABLISHED转移到FIN_WAIT_2，将发送FIN。

30.5 tcp_usrclosed函数

图30-13给出的这个函数，在PRU_SHUTDOWN处理中，由tcp_disconnect调用。

1. 未收到SYN时的简单关闭

429-434 如果连接上还未收到SYN，则无需发送FIN。新的状态等于CLOSED，tcp_close将释放Internet PCB和TCP控制块。

2. 转移到FIN_WAIT_1状态

435-438 如果连接当前状态等于SYN_RCVD和ESTABLISHED，新的状态将等于FIN_WAIT_1，再次调用tcp_output时，将发送FIN(图24-16中的tcp_outflags值)。

3. 转移到LAST_ACK状态

439-441 如果连接当前状态等于 CLOSE_WAIT , 新状态等于 LAST_ACK , 则再次调用 tcp_output 时 , 将发送 FIN。

443-444 如果连接当前状态等于 FIN_WAIT_2 或 TIME_WAIT , soisdisconnected 将正确地标注插口的状态。

```
tcp_usrreq.c
424 struct tcpcb *
425 tcp_usrclosed(tp)
426 struct tcpcb *tp;
427 {
428     switch (tp->t_state) {
429         case TCPS_CLOSED:
430         case TCPS_LISTEN:
431         case TCPS_SYN_SENT:
432             tp->t_state = TCPS_CLOSED;
433             tp = tcp_close(tp);
434             break;
435         case TCPS_SYN_RECEIVED:
436         case TCPS_ESTABLISHED:
437             tp->t_state = TCPS_FIN_WAIT_1;
438             break;
439         case TCPS_CLOSE_WAIT:
440             tp->t_state = TCPS_LAST_ACK;
441             break;
442     }
443     if (tp && tp->t_state >= TCPS_FIN_WAIT_2)
444         soisdisconnected(tp->t_inpcb->inp_socket);
445     return (tp);
446 }
```

tcp_usrreq.c

图30-13 tcp_usrclosed 函数：基于连接关闭的处理进程，将连接转移到下一状态

30.6 tcp_ctloutput函数

tcp_ctloutput 函数被 getsockopt 和 setsockopt 函数调用 , 如果它们的描述符参数指明了一个 TCP 插口 , 且 level 不是 SOL_SOCKET 。图 30-14 列出了 TCP 支持的两个插口选项。

选 项 名	变 量	存 取	描 述
TCP_NODELAY	t_flags	读、写	Nagel 算法(图 26-8)
TCP_MAXSEG	t_maxseg	读、写	TCP 将发送的最大报文段长度

图30-14 TCP支持的插口选项

图 30-15 给出了函数的第一部分。

```
tcp_usrreq.c
284 int
285 tcp_ctloutput(op, so, level, optname, mp)
286 int      op;
287 struct socket *so;
288 int      level, optname;
```

图30-15 tcp_ctloutput 函数：第一部分

```

289 struct mbuf **mp;
290 {
291     int      error = 0, s;
292     struct inpcb *inp;
293     struct tcpcb *tp;
294     struct mbuf *m;
295     int      i;

296     s = splnet();
297     inp = sotoinpcb(so);
298     if (inp == NULL) {
299         splx(s);
300         if (op == PRCO_SETOPT && *mp)
301             (void) m_free(*mp);
302         return (ECONNRESET);
303     }
304     if (level != IPPROTO_TCP) {
305         error = ip_ctloutput(op, so, level, optname, mp);
306         splx(s);
307         return (error);
308     }
309     tp = intotcpcb(inp);

```

tcp_usrreq.c

图30-15 (续)

296-303 函数执行时，处理器优先级设为 `splnet`，`inp`指向插口的Internet PCB。如果`inp`为空，且操作类型是设定插口选项，则释放 `mbuf`并返回错误。

304-308 如果 `level`(`getsockopt`和`setsockopt`系统调用的第二个参数)不等于 `IPPROTO_TCP`，说明操作的是其他协议(如IP)。例如，可以创建一个TCP插口，并设定其IP源选路插口选项。此时应由IP处理这个插口选项，而不是TCP。`ip_ctloutput`处理命令。

309 如果是对TCP选项进行操作，`tp`将指向TCP控制块。

函数的剩余部分是一个 `switch`语句，有两个分支：一个处理 `PRCO_SETOPT`(图30-16中给出)，另一个处理 `PRCO_GETOPT`(图30-17中给出)。

```

310     switch (op) {
311         case PRCO_SETOPT:
312             m = *mp;
313             switch (optname) {
314                 case TCP_NODELAY:
315                     if (m == NULL || m->m_len < sizeof(int))
316                         error = EINVAL;
317                     else if (*mtod(m, int *) &= TF_NODELAY);
318                         tp->t_flags |= TF_NODELAY;
319                     else
320                         tp->t_flags &= ~TF_NODELAY;
321                     break;
322
323                 case TCP_MAXSEG:
324                     if (m && (i = *mtod(m, int *)) > 0 && i <= tp->t_maxseg)
325                         tp->t_maxseg = i;
326                     else
327                         error = EINVAL;
328                     break;

```

*tcp_usrreq.c*图30-16 `tcp_ctloutput` 函数：设定插口选项

```

328     default:
329         error = ENOPROTOOPT;
330         break;
331     }
332     if (m)
333         (void) m_free(m);
334     break;

```

tcp_usrreq.c

图30-16 (续)

315-316 m是一个mbuf，保存了setsockopt的第四个参数。对于两个TCP插口选项，mbuf中都必须是整数。如果任何一个mbuf指针为空，或者mbuf中的数据长度小于整数大小，则返回错误。

1. TCP_NODELAY选项

317-321 如果整数值非零，则置位TF_NODELAY标志，从而取消图26-8中的Negal算法。如果整数值等于0，则使用Negal算法(默认值)，并清除TF_NODELAY标志。

2. TCP_MAXSEG选项

322-327 应用进程只能减少MSS。TCP插口创建时，tcp_newtcpcb初始化t_maxseg为默认值512。当收到对端SYN中包含的MSS选项时，tcp_input调用tcp_mss，t_maxseg最高可等于外出接口的MTU(减去40字节，IP和TCP首部的默认值)，以太网等于1460。因此，调用插口之后，连接建立之前，应用进程只能以默认值512为起点，减少MSS。连接建立后，应用进程可以从tcp_mss选取的任何值起，减少MSS。

4.4BSD是伯克利版本中第一次支持MSS做为插口选项，以前的版本只允许利用getsockopt读取MSS值。

3. 释放mbuf

332-333 释放mbuf链。

图30-17给出了PRCO_GETOPT命令的处理。

```

335     case PRCO_GETOPT:
336         *mp = m = m_get(M_WAIT, MT_SOOPTS);
337         m->m_len = sizeof(int);

338         switch (optname) {
339             case TCP_NODELAY:
340                 *mtod(m, int *) = tp->t_flags & TF_NODELAY;
341                 break;
342             case TCP_MAXSEG:
343                 *mtod(m, int *) = tp->t_maxseg;
344                 break;
345             default:
346                 error = ENOPROTOOPT;
347                 break;
348         }
349         break;
350     }
351     splx(s);
352     return (error);
353 }

```

*tcp_usrreq.c**tcp_usrreq.c*图30-17 *tcp_ctloutput* 函数：读取插口选项

3.3.5-3.3.7 两个TCP插口选项都向应用进程返回一个整数值，因此，调用 `m_get` 得到一个 `mbuf`，其长度等于整数长度。

3.3.9-3.3.11 `TCP_NODELAY` 返回 `TF_NODELAY` 标志的当前状态：如果标志未置位（使用 Nagel 算法），则等于 0；如果标志置位，则等于 `TF_NODELAY`。

3.4.2-3.4.4 `TCP_MAXSEG` 选项返回 `t_maxseg` 的当前值。前面讨论 `PRCO_SETOPT` 命令时曾提到，返回值取决于插口是否已进入连接状态。

30.7 小结

`tcp_usrreq` 函数处理逻辑很简单，因为绝大多数处理都由其他函数完成。`PRU_xxx` 请求是独立于协议的系统调用与 TCP 协议处理间的桥梁。

`tcp_ctlsockopt` 函数也很简单，因为 TCP 只支持两个插口选项：使用或取消 Nagel 算法，设置或读取最大报文段长度。

习题

- 30.1 现在，我们已经结束了对 TCP 的讨论，如果某个客户执行了正常的 `socket`、`connect`、`write`（向服务器请求）和 `read`（读取服务器响应），分别列出客户端和服务器端的处理步骤及 TCP 状态变迁。
- 30.2 如果应用进程设定 `SO_LINGER` 插口选项，且拖延时间等于 0，之后调用 `close`，我们给出了如何调用 `tcp_disconnect`，从而发送 RST。如果应用进程设定了这个插口选项，且拖延时间等于 0，之后进程被某个信号杀死（`kill`），而非调用 `close`，会发生什么？还会发送 RST 报文段吗？
- 30.3 图 25-4 中描述 `TCP_LINGERTIME` 时，称之为“`SO_LINGER` 插口选项的最大秒数”。根据图 30-2 中的代码，这个说法正确吗？
- 30.4 某个 Net/3 客户调用 `socket` 和 `connect`，主动与服务器建立连接，使用了客户的默认路由。客户主机向服务器发送了 1129 个报文段。假定到达目的地的路由未变，为了这条连接，客户主机需要搜索多少次路由表？解释你的结论。
- 30.5 找到卷 1 的附录 C 中提到的 `sock` 程序。把该程序做为服务器运行，读取数据前有停顿（`-p`），且有较大的接收缓存。之后在另一个系统中运行同一个程序，但做为客户。通过 `tcpdump` 查看数据。确认 TCP “确认所有其他报文段”的属性未出现，服务器送出的 ACK 全部是延迟 ACK。
- 30.6 修改 `SO_KEEPALIVE` 插口选项，从而能够配置每个连接的参数。
- 30.7 阅读 RFC 1122，了解为什么它建议 TCP 应该允许 RST 报文段携带数据。修改 Net/3 代码以实现此功能。

第31章 BPF：BSD 分组过滤程序

31.1 引言

BSD分组过滤程序(BPF)是一种软件设备，用于过滤网络接口的数据流，即给网络接口加上“开关”。应用进程打开`/dev/bpf0`、`/dev/bpf1`等等后，可以读取BPF设备。每个应用进程一次只能打开一个BPF设备。

因为每个BPF设备需要8192字节的缓存，系统管理员一般限制BPF设备的数目。

如果`open`返回`EBUSY`，说明该设备已被使用，应用进程应该试着打开下一BPF设备，直到`open`成功为止。

通过若干`ioctl`命令，可以配置BPF设备，把它与某个网络接口相关连，并安装过滤程序，从而能够选择性地接收输入的分组。BPF设备打开后，应用进程通过读写设备来接收分组，或将分组放入网络接口队列中。

我们将一直使用“分组”，尽管“帧”可能更准确一些，因为BPF工作在数据链路层，在发送和接收的数据帧中包含了链路层的首部。

BPF设备工作的前提是网络接口必须能够支持BPF。第3章中提到以太网、SLIP和环回接口的驱动程序都调用了`bpfattach`，用于配置读取BPF设备的接口。本节中，我们将介绍BPF设备驱动程序是如何组织的，以及数据分组在驱动程序和网络接口之间是如何传递的。

BPF一般情况下用作诊断工具，查看某个本地网络上的流量，卷1附录A介绍的`tcpdump`程序是此类工具中最好的一个。通常情况下，用户感兴趣的是一组指定主机间交互的分组，或者某个特定协议，甚至某个特定TCP连接上的数据流。BPF设备经过适当配置，能够根据过滤程序的定义丢弃或接受输入的分组。过滤程序的定义类似于伪机器指令，BPF的细节超出了本书的讨论范围，感兴趣的读者请参阅`bpf(4)`和[McCanne and Jacobson 1993]。

31.2 代码介绍

下面将要介绍的有关BPF设备驱动程序的代码，包括两个头文件和一个C文件，在图31-1中给出。

文 件	描 述
<code>net/bpf.h</code>	BPF常量
<code>net/bpfdesc.h</code>	BPF结构
<code>net/bpf.c</code>	BPF设备支持

图31-1 本章讨论的文件

31.2.1 全局变量

本章用到的全局变量在图31-2中给出。

变 量	数 据 类 型	描 述
bpf_iflist	struct bpf_if *	支持BPF的接口组成的链表
bpf_dtab	struct bpf_d []	BPF描述符数组
bpf_bufsize	int	BPF缓存大小默认值

图31-2 本章用到的全局变量

31.2.2 统计量

图31-3列出了bpf_d结构中为每个活动的BPF设备维护的两个统计量。

bpf_d成员变量	描 述
bd_rcount	从网络接口接收的分组的数目
bd_dcount	由于缓存空间不足而丢弃的分组的数目

图31-3 本章讨论的统计值

本章的其余内容分为4个部分：

- BPF接口结构；
- BPF设备描述符；
- BPF输入处理；和
- BPF输出处理。

31.3 bpf_if结构

BPF维护一个链表，包括所有支持BPF的网络接口。每个接口都由一个bpf_if结构描述，全局指针bpf_iflist指向表中的第一个结构。图31-4给出了BPF接口结构。

```

67 struct bpf_if {
68     struct bpf_if *bif_next;      /* list of all interfaces */
69     struct bpf_d *bif_dlist;      /* descriptor list */
70     struct bpf_if **bif_driverp;  /* pointer into softc */
71     u_int    bif_dlt;            /* link layer type */
72     u_int    bif_hdrlen;         /* length of header (with padding) */
73     struct ifnet *bif_ifp;        /* corresponding interface */
74 };

```

*bpfdesc.h**bpfdesc.h*

图31-4 bpf_if 结构

67-79 bif_next指向链表中的下一个BPF接口结构。bif_dlist指向另一个链表，包括所有已打开并配置过的BPF设备。

70 如果某个网络接口已配置了BPF设备，即被加上了开关，则bif_driverp将指向ifnet结构中的bpf_if指针。如果网络接口还未加上开关，*bif_driverp为空。为某个网络接口配置BPF设备时，*bif_driverp将指向bif_if结构，从而告诉接口可以开始向BPF传递分组。

71 接口类型保存在bif_dlt中。图31-5中列出了前面提到的几个接口所分别对应的常量值。

bif_dlt	描 述
<i>DLT_EN10MB</i>	10 Mb以太网接口
<i>DLT_SLIP</i>	SLIP接口
<i>DLT_NULL</i>	环回接口

图31-5 bif_dlt 值

72-74 BPF接受的所有分组都有一个附加的BPF首部。bif_hdrlen等于头部大小。最后，bif_ifp指向对应接口的ifnet结构。

图31-6给出了每个输入分组中附加的bpf_hdr结构。

```
122 struct bpf_hdr {
123     struct timeval bh_tstamp; /* time stamp */
124     u_long bh_caplen;        /* length of captured portion */
125     u_long bh_dataLEN;       /* original length of packet */
126     u_short bh_hdrlen;      /* length of bpf header (this struct plus
127                               alignment padding) */
128 };
```

图31-6 bpf_hdr 结构

122-128 bh_tstamp记录了分组被捕捉的时间。bh_caplen等于BPF保存的字节数，bh_dataLEN等于原始分组中的字节数。bh_hdrlen等于bpf_hdr的大小加上所需填充字节的长度。它用于解释从BPF设备中读取的分组，应该等同于接收接口的bif_hdrlen。

图31-7给出了bpf_if结构是如何与前述3个接口(le_softc[0]、sl_softc[0]和loif)的ifnet结构建立连接的。

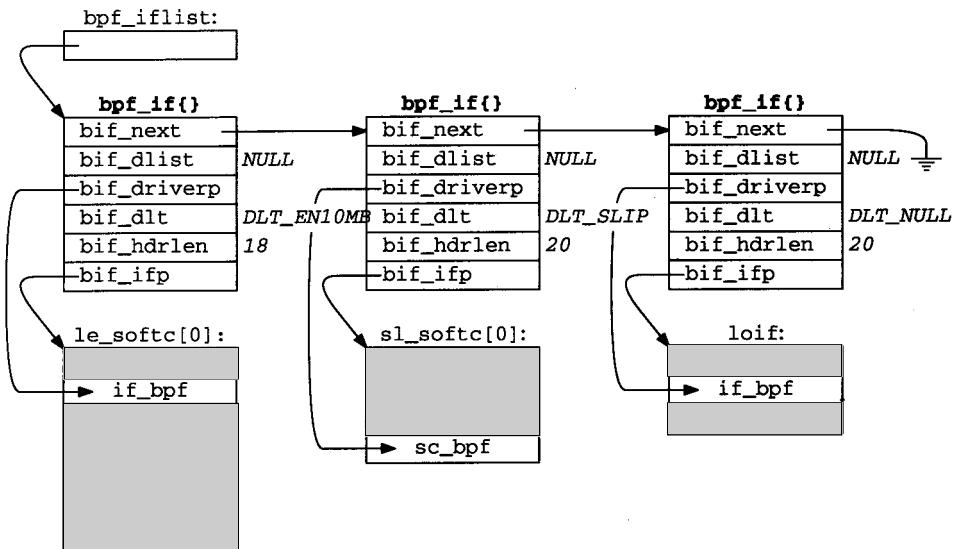


图31-7 bpf_if 和ifnet 结构

注意，bif_driverp指向网络接口的if_bpff和sc_bpff指针，而不是接口结构。

SLIP设备使用sc_bpff，而不是if_bpff。这可能是因为SLIP BPF代码完成时，

if_bpf成员变量还未加入到ifnet结构中。Net/2中的ifnet结构不包括if_bpf成员。

按照各接口驱动程序调用bpfattach时给出的信息，对3个接口初始化链路类型和首部长度成员变量。

第3章介绍了bpfattach被以太网、SLIP和环回接口的驱动程序调用。每个设备驱动程序初始化调用bpfattach时，将构建BPF接口结构链表。图31-8给出了该函数。

```

1053 void
1054 bpfattach(driverp, ifp, dlt, hdrlen)
1055 caddr_t *driverp;
1056 struct ifnet *ifp;
1057 u_int dlt, hdrlen;
1058 {
1059     struct bpf_if *bp;
1060     int i;
1061     bp = (struct bpf_if *) malloc(sizeof(*bp), M_DEVBUF, M_DONTWAIT);
1062     if (bp == 0)
1063         panic("bpfattach");
1064     bp->bif_dlist = 0;
1065     bp->bif_driverp = (struct bpf_if **) driverp;
1066     bp->bif_ifp = ifp;
1067     bp->bif_dlt = dlt;
1068     bp->bif_next = bpf_iflist;
1069     bpf_iflist = bp;
1070     *bp->bif_driverp = 0;
1071     /*
1072      * Compute the length of the bpf header. This is not necessarily
1073      * equal to SIZEOF_BPF_HDR because we want to insert spacing such
1074      * that the network layer header begins on a longword boundary (for
1075      * performance reasons and to alleviate alignment restrictions).
1076      */
1077     bp->bif_hdrlen = BPF_WORDALIGN(hdrlen + SIZEOF_BPF_HDR) - hdrlen;
1078     /*
1079      * Mark all the descriptors free if this hasn't been done.
1080      */
1081     if (!D_ISFREE(&bpf_dtab[0]))
1082         for (i = 0; i < NBPFFILTER; ++i)
1083             D_MARKFREE(&bpf_dtab[i]);
1084     printf("bpf: %s%d attached\n", ifp->if_name, ifp->if_unit);
1085 }
```

bpf.c

图31-8 bpfattach 函数

1053-1063 每个支持BPF的设备驱动程序都将调用bpfattach。第一个参数是保存在bif_driverp的指针(图31-4给出)，第二个参数指向接口的ifnet结构，第三个参数确认数据链路层类型，第四个参数传递分组中的数据链路首部大小，为接口分配一个新的bpf_if结构。

1. 初始化bpf_if结构

1064-1070 bpf_if结构根据函数的参数进行初始化，并插入到 BPF接口链表，bpf_iflist，的表头。

2. 计算BPF首部大小

1071-1077 设定bif_hdrlen大小，强迫网络层首部(如IP首部)从一个长字的边界开始。这样可以提高性能，避免为BPF加入不必要的对齐限制。图31-9列出了在前述3个接口上，各自捕捉到的BPF分组的总体结构。

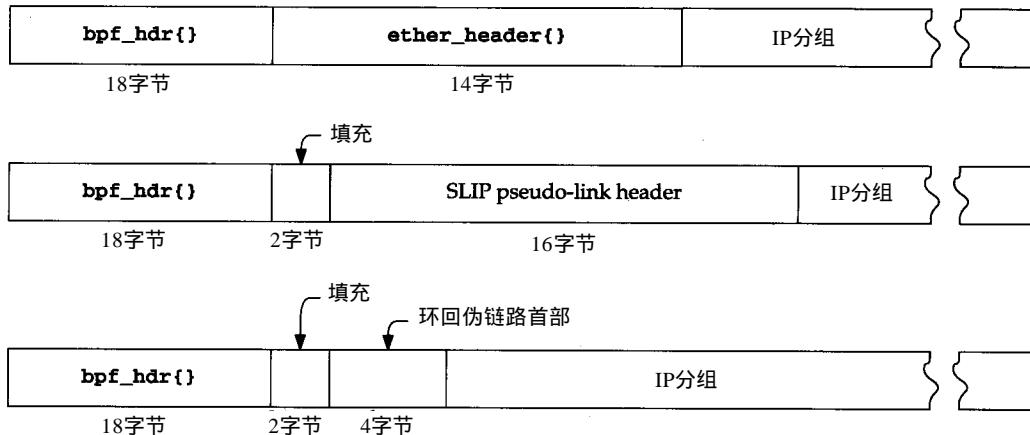


图31-9 BPF分组结构

ether_header结构在图4-10中给出，SLIP伪链路首部在图5-14中给出，而环回接口伪链路首部在图5-28中给出。

请注意，SLIP和环回接口分组需要填充2字节，以强迫IP首部按4字节对齐。

3. 初始化bpf_dtab表

1078-1083 代码初始化图31-10中给出的BPF描述符表。注意，仅在第一次调用bpfattach时进行初始化，后续调用将跳过初始化过程。

4. 打印控制台信息

1084-1085 系统向控制台输出一条短信息，宣告接口已配置完毕，可以支持BPF。

31.4 bpf_d结构

为了能够选择性地接收输入报文，应用进程首先打开一个BPF设备，调用若干`ioctl`命令规定BPF过滤程序的条件，指明接口、读缓存大小和超时时限。每个BPF设备都有一个相关的`bpf_d`结构，如图31-10所示。

45-46 如果同一网络接口上配置了多个BPF设备，与之相应的`bpf_d`结构将组成一个链表。`bd_next`指向链表中的下一个结构。

分组缓存

47-52 每个`bpf_d`结构都有两个分组缓存。输入分组通常保存在`bd_sbuf`所对应的缓存(存储缓存)中。另一个缓存要么对应于`bd_fbuf`(空闲缓存)，意味着缓存为空；或者对应于`bd_hbuf`(暂留缓存)，意味着缓存中有分组等待应用进程读取。`bd_slen`和`bd_hlen`分别记

录了保存在存储缓存和暂留缓存中的字节数。

```

45 struct bpf_d {
46     struct bpf_d *bd_next;      /* Linked list of descriptors */
47     caddr_t bd_sbuf;          /* store slot */
48     caddr_t bd_hbuf;          /* hold slot */
49     caddr_t bd_fbuf;          /* free slot */
50     int    bd_slen;           /* current length of store buffer */
51     int    bd_hlen;           /* current length of hold buffer */
52     int    bd_bufsize;         /* absolute length of buffers */
53     struct bpf_if *bd_bif;    /* interface descriptor */
54     u_long  bd_rtout;         /* Read timeout in 'ticks' */
55     struct bpf_insn *bd_filter; /* filter code */
56     u_long  bd_rcount;        /* number of packets received */
57     u_long  bd_dcount;        /* number of packets dropped */
58     u_char  bd_promisc;       /* true if listening promiscuously */
59     u_char  bd_state;         /* idle, waiting, or timed out */
60     u_char  bd_immediate;    /* true to return on packet arrival */
61     u_char  bd_pad;           /* explicit alignment */
62     struct selinfo bd_sel;   /* bsd select info */
63 };

```

bpfdesc.h

图31-10 *bpf_d* 结构

如果存储缓存已满，它将被连接到 *bd_hbuf*，而空闲缓存将被连接到 *bd_sbuf*。当暂留缓存清空时，它会被连接到 *bd_fbuf*。宏 *ROTATE_BUFFERS* 负责把存储缓存连接到 *bd_hbuf*，空闲缓存连接到 *bd_sbuf*，并清空 *bd_fbuf*。存储缓存满或者应用进程不想再等待更多的分组时调用该宏。

bd_bufsize 记录与设备相连的两个缓存的大小，其默认值等于 *4096(BPF_BUFSIZE)* 字节。修改内核代码可以改变默认值大小，或者通过 *BIOCSETLEN* 命令改变某个特定 BPF 设备的 *bd_bufsize*。*BIOCGLEN* 命令返回 *bd_bufsize* 的当前值，其最大值不超过 *32768 (BPF_MAXBUFSIZE)* 字节，最小值为 *32 (BPF_MINBUFSIZE)* 字节。

53-57 *bd_bif* 指向 BPF 设备所对应的 *bpf_if* 结构。*BIOCSETIF* 命令可指明设备。*bd_rtout* 是等待分组时，延迟的滴答数。*bd_filter* 指向 BPF 设备的过滤程序代码。两个统计值，应用进程可通过 *BIOCGSTATS* 命令读取，分别保存在 *bd_rcount* 和 *bd_dcount* 中。

58-63 *bd_promisc* 通过 *BIOCPRMISC* 命令置位，从而使接口工作在混杂 (promiscuous) 状态。*bd_state* 未使用。*bd_immediate* 通过 *BIOCIMMEDIATE* 命令置位，促使驱动程序收到分组后即返回，不再等待暂留缓存填满。*bd_pad* 填弃 *bpf_d* 结构，从而与长字边界对齐。*bd_sel* 保存的 *selinfo* 结构，可用于 *select* 系统调用。我们不准备介绍如何对 BPF 设备使用 *select* 系统调用，16.13 节已介绍了 *select* 的一般用法。

31.4.1 *bpfopen* 函数

应用进程调用 *open*，试图打开一个 BPF 设备时，该调用将被转到 *bpfopen*(图 31-11)。
256-263 系统编译时，BPF 设备的数目受到 *NBPFILTER* 的限制。如果设备的最小设备号大

于NBPFILTER，则返回ENXIO，这是因为系统管理员创建的 /dev/bpf_x项数大于NBPFILTER的值。

```

256 int
257 bpfopen(dev, flag)
258 dev_t    dev;
259 int     flag;
260 {
261     struct bpf_d *d;
262
263     if (minor(dev) >= NBPFILTER)
264         return (ENXIO);
265
266     /* Each minor can be opened by only one process. If the requested
267      * minor is in use, return EBUSY.
268      */
269     d = &bpf_dtab[minor(dev)];
270     if (!D_ISFREE(d))
271         return (EBUSY);
272
273     /* Mark "free" and do most initialization. */
274     bzero((char *) d, sizeof(*d));
275     d->bd_bufsize = bpf_bufsize;
276
277     return (0);
278 }
```

图31-11 bpfopen 函数

分配bpf_d结构

同一时间内，一个应用进程只能访问一个BPF设备。如果bpf_d结构已被激活，则返回EBUSY。应用程序，如tcpdump，收到此返回值时，会自动寻找下一个设备。如果该设备已存在，最小设备号所指定的bpf_dtab表中的项被清除，分组缓存大小复位为默认值。

31.4.2 bpfioctl函数

设备打开后，可通过ioctl命令进行配置。图31-12总结了与BPF设备有关的ioctl命令。图31-13给出了bpfiocctl函数，只列出BIOCSETF和BIOCSETIF的处理代码，其他未涉及到的ioctl命令则被忽略。

命 令	第三个参数	函 数	描 述
<i>FIONREAD</i>	u_int	bpfioctl	返回暂留缓存和存储缓存中的字节数
<i>BIOCGBLEN</i>	u_int	bpfioctl	返回分组缓存大小
<i>BIOCSBLEN</i>	u_int	bpfioctl	设定分组缓存大小
<i>BIOCSETF</i>	struct bpf_program	bpf_setf	安装BPF程序
<i>BIOCFLUSH</i>		reset_d	丢弃挂起分组
<i>BIOCPRMISC</i>		ifpromisc	设定混杂方式
<i>BIOCGLDT</i>	u_int	bpfioctl	返回bif_dlt
<i>BIOCGETIF</i>	struct ifreq	bpf_ifname	返回所属接口的名称
<i>BIOCSETIF</i>	struct ifreq	bpf_setif	为网络接口添加设备
<i>BIOCSRTIMEOUT</i>	struct timeval	bpfioctl	设定“读”操作的超时时限
<i>BIOCGRTIMEOUT</i>	struct timeval	bpfioctl	返回“读”操作的超时时限
<i>BIOCGSTATS</i>	struct bpf_stat	bpfioctl	返回BPF统计值
<i>BIOCIMMEDIATE</i>	u_int	bpfioctl	设定立即方式
<i>BIOCVERSION</i>	struct bpf_version	bpfioctl	返回BPF版本信息

图31-12 BPF ioctl 命令

```

501 int
502 bpfiocctl(dev, cmd, addr, flag)
503 dev_t dev;
504 int cmd;
505 caddr_t addr;
506 int flag;
507 {
508     struct bpf_d *d = &bpf_dtab[minor(dev)];
509     int s, error = 0;
510     switch (cmd) {
511         /*
512          * Set link layer read filter.
513          */
514     case BIOCSETF:
515         error = bpf_setf(d, (struct bpf_program *) addr);
516         break;
517         /*
518          * Set interface.
519          */
520     case BIOCSETIF:
521         error = bpf_setif(d, (struct ifreq *) addr);
522         break;
523     default:
524         error = EINVAL;
525         break;
526     }
527     return (error);
528 }

```

/* other ioctl commands from Figure 31.12 */

bpfc

图31-13 bpfiocctl 函数

501-509 与bpfopen类似，通过最小设备号从bpf_dtab表中选取相应的bpf_d结构。整个命令处理是一个大的switch/case语句。我们给出了两个命令，BIOCSETF和BIOCSETIF，以及default子句。

510-522 bpf_setf函数安装由addr指向的过滤程序，bpf_setif建立起指定名称接口与bpf_d结构间的对应关系。本书中没有给出bpf_setf的实现代码。

668-673 如果命令未知，则返回EINVAL。

图31-14的例子中，bpf_setif已把bpf_d结构连接到LANCE接口上。

图中，bif_dlist指向bpf_dtab[0]，以太网接口描述符链表中的第一个也是仅有的一个描述符。在bpf_dtab[0]中，bd_sbuf和bd_hbuf成员分别指向存储缓存和暂留缓存。两个缓存大小都等于4096(bd_bufsize)字节。bd_bif回指接口的bpf_if结构。

ifnet结构(le_softc[0])中的if_bpfc也指向bpf_if结构。如图4-19和图4-11所示，如果if_bpfc非空，则驱动程序开始调用bpf_tap，向BPF设备传递分组。

图31-15接着图31-10，给出了打开第二个BPF设备，并连接到同一个以太网网络接口后的各结构变量的状态。

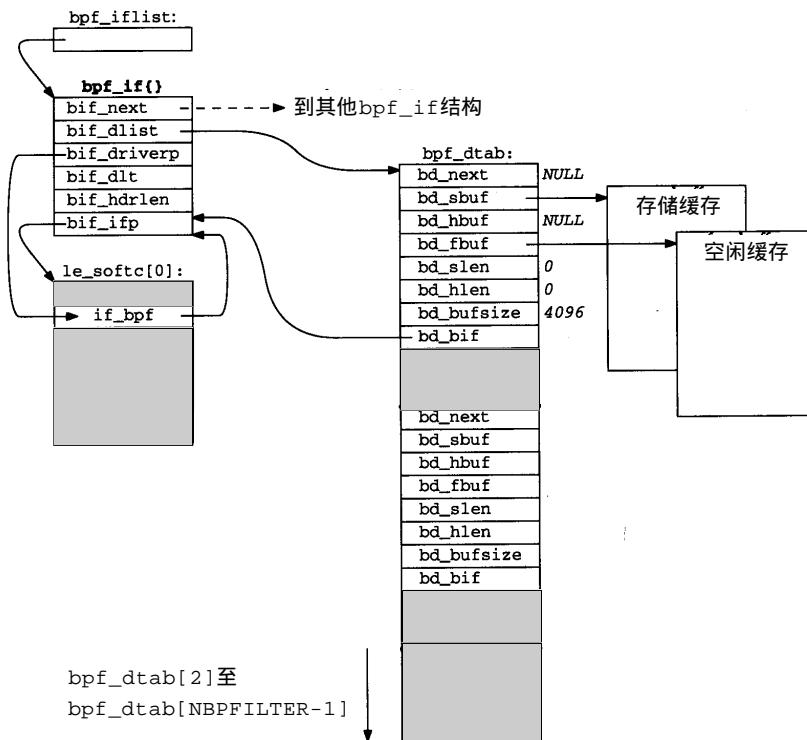


图31-14 连接到以太网接口的BPF设备

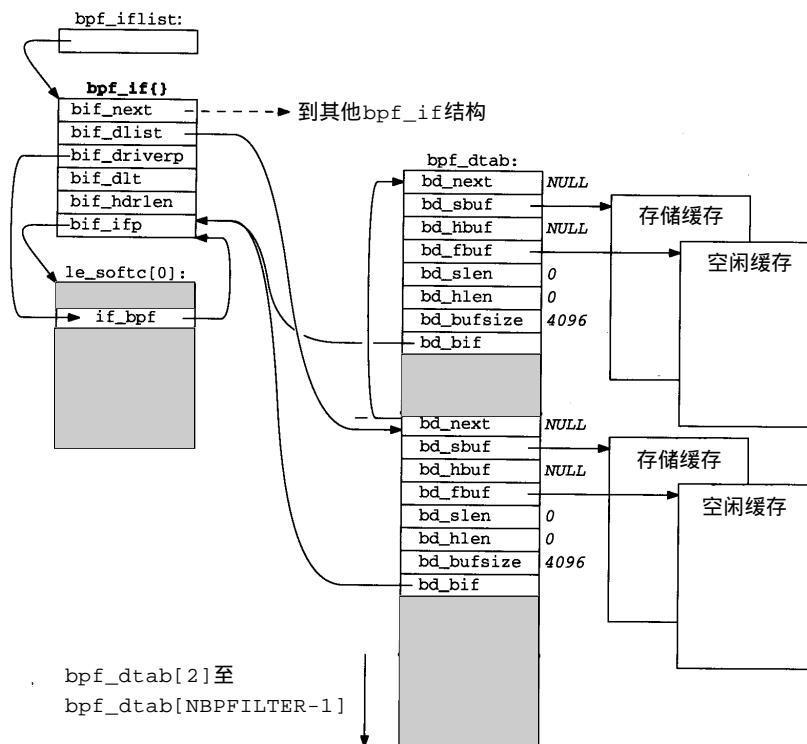


图31-15 连接到以太网接口的两个BPF设备

第二个BPF设备打开时，在`bpf_dtab`表中分配一个新的`bpf_d`结构，本例中为`bpf_dtab[1]`。因为第二个BPF设备也连接到同一个以太网接口，`bif_dlist`指向`bpf_dtab[1]`，并且`bpf_dtab[1].bd_next`指向`bpf_dtab[0]`，即以太网上对应的第一个BPF描述符。系统为新的描述符结构分别分配存储缓存和暂留缓存。

31.4.3 bpf_setif函数

`bpf_setif`函数，负责建立BPF描述符与网络接口间的连接，如图31-16所示。

bpf.c

```

721 static int
722 bpf_setif(d, ifr)
723 struct bpf_d *d;
724 struct ifreq *ifr;
725 {
726     struct bpf_if *bp;
727     char    *cp;
728     int      unit, s, error;

729     /*
730     * Separate string into name part and unit number. Put a null
731     * byte at the end of the name part, and compute the number.
732     * If the a unit number is unspecified, the default is 0,
733     * as initialized above. XXX This should be common code.
734     */
735     unit = 0;
736     cp = ifr->ifr_name;
737     cp[sizeof(ifr->ifr_name) - 1] = '\0';
738     while (*cp++) {
739         if (*cp >= '0' && *cp <= '9') {
740             unit = *cp - '0';
741             *cp++ = '\0';
742             while (*cp)
743                 unit = 10 * unit + *cp++ - '0';
744             break;
745         }
746     }
747     /*
748     * Look through attached interfaces for the named one.
749     */
750     for (bp = bpf_iflist; bp != 0; bp = bp->bif_next) {
751         struct ifnet *ifp = bp->bif_ifp;

752         if (ifp == 0 || unit != ifp->if_unit
753             || strcmp(ifp->if_name, ifr->ifr_name) != 0)
754             continue;
755         /*
756         * We found the requested interface.
757         * If it's not up, return an error.
758         * Allocate the packet buffers if we need to.
759         * If we're already attached to requested interface,
760         * just flush the buffer.
761         */
762         if (((ifp->if_flags & IFF_UP) == 0)
763             return (ENETDOWN);

```

图31-16 `bpf_setif` 函数

```

764     if (d->bd_sbuf == 0) {
765         error = bpf_allocbufs(d);
766         if (error != 0)
767             return (error);
768     }
769     s = splimp();
770     if (bp != d->bd_bif) {
771         if (d->bd_bif)
772             /*
773              * Detach if attached to something else.
774              */
775         bpf_detachd(d);

776         bpf_attachd(d, bp);
777     }
778     reset_d(d);
779     splx(s);
780     return (0);
781 }
782 /* Not found. */
783 return (ENXIO);
784 }

```

bpf.c

图31-16 (续)

721-746 bpf_setif的第一部分完成ifreq结构(图4-23)中接口名的正文与数字部分的分离，数字部分保存在unit中。例如，如果ifr_name的头4字节为“s1\0”，代码执行完毕后，将等于“s1\0\0”，且unit等于1。

1. 寻找匹配的ifnet结构

747-754 for循环用于在支持BPF的接口(bpf_iflist中)中查找符合ifreq定义的接口。

755-768 如果未找到匹配的接口，则返回ENETDOWN。如果接口存在，bpf_allocate为bpf_d分配空闲缓存和存储缓存，如果它们还未被分配的话。

2. 连接bpf_d结构

769-777 如果BPF设备还未与网络接口建立连接关系，或者连接的网络接口不是ifreq中指定的接口，则调用bpf_detachd丢弃原先的接口(如果存在)，并调用bpf_attachd将其连接到新的接口上。

778-784 reset_d复位分组缓存，丢弃所有在应用进程中等待的分组。函数返回0，说明处理成功；或者ENXIO，说明未找到指定接口。

31.4.4 bpf_attachd函数

图31-17给出的bpf_attachd函数，建立起BPF描述符与BPF设备和网络接口间的对应关系。

```

189 static void
190 bpf_attachd(d, bp)
191 struct bpf_d *d;
192 struct bpf_if *bp;
193 {
194     /*
195      * Point d at bp, and add d to the interface's list of listeners.

```

bpf.c

图31-17 bpf_attachd 函数

```

196     * Finally, point the driver's bpf cookie at the interface so
197     * it will divert packets to bpf.
198     */
199     d->bd_bif = bp;
200     d->bd_next = bp->bif_dlist;
201     bp->bif_dlist = d;
202
203 }                                         bpf.c

```

图31-17 (续)

189-203 首先，令`bd_bif`指向网络接口的BPF接口结构。接着，`bpf_d`结构被插入到与设备对应的`bpf_d`结构链表的头部。最后，改变网络接口中的BPF指针，指向当前BPF结构，从而促使接口向BPF设备传递分组。

31.5 BPF的输入

一旦BPF设备打开并配置完毕，应用进程就通过`read`系统调用从接口中接收分组。BPF过滤程序复制输入分组，因此，不会干扰正常的网络处理。输入分组保存在与BPF设备相连的存储缓存和暂留缓存中。

31.5.1 `bpf_tap`函数

下面列出了图4-11中LANCE设备驱动程序调用`bpf_tap`的代码，并利用这一调用介绍`bpf_tap`函数。图4-11中的调用如下：

```
bpf_tap(le->sc_if.if_bpf, buf, len + sizeof(struct ether_header));
```

图31-18给出了`bpf_tap`函数。

```

869 void                                         bpf.c
870 bpf_tap(arg, pkt, pktlen)
871 caddr_t arg;
872 u_char *pkt;
873 u_int pktlen;
874 {
875     struct bpf_if *bp;
876     struct bpf_d *d;
877     u_int selen;
878     /*
879     * Note that the ipl does not have to be raised at this point.
880     * The only problem that could arise here is that if two different
881     * interfaces shared any data. This is not the case.
882     */
883     bp = (struct bpf_if *) arg;
884     for (d = bp->bif_dlist; d != 0; d = d->bd_next) {
885         ++d->bd_rcount;
886         selen = bpf_filter(d->bd_filter, pkt, pktlen, pktlen);
887         if (selen != 0)
888             catchpacket(d, pkt, pktlen, selen, bcopy);
889     }
890 }                                         bpf.c

```

图31-18 `bpf_tap` 函数

869-882 第一个参数是指向 bpf_if 结构的指针，由 bpfattach 设定。第二个参数是指向进入分组的指针，包括以太网首部。第三个参数等于缓存中包含的字节数，本例中，等于以太网首部(14字节)大小加上以太网帧的数据部分。

向一个或多个BPF设备传递分组

883-890 for 循环遍历连接到网络接口的 BPF 设备链表。对每个设备，分组被递交给 bpf_filter。如果过滤程序接受了分组，它返回捕捉到的字节数，并调用 catchpacket 复制分组。如果过滤程序拒绝了分组，slen 等于 0，循环继续。循环终止时，bpf_tap 返回。这一机制确保了同一网络接口上对应了多个 BPF 设备时，每个设备都能拥有一个独立的过滤程序。

环回驱动程序调用 bpf_mtap，向 BPF 传递分组。这个函数与 bpf_tap 类似，然而是在 mbuf 链，而不是在一个内存的连续区域中复制分组。本书中不介绍这个函数。

31.5.2 catchpacket 函数

图31-18中，过滤程序接受了分组后，将调用 catchpacket，图31-19给出了这个函数。

```

946 static void
947 catchpacket(d, pkt, pktlen, snaplen, cpfn)
948 struct bpf_d *d;
949 u_char *pkt;
950 u_int pktlen, snaplen;
951 void (*cpfn) (const void *, void *, u_int);
952 {
953     struct bpf_hdr *hp;
954     int totlen, curlen;
955     int hdrlen = d->bd_bif->bif_hdrlen;
956     /*
957      * Figure out how many bytes to move. If the packet is
958      * greater or equal to the snapshot length, transfer that
959      * much. Otherwise, transfer the whole packet (unless
960      * we hit the buffer size limit).
961      */
962     totlen = hdrlen + min(snaplen, pktlen);
963     if (totlen > d->bd_bufsize)
964         totlen = d->bd_bufsize;
965     /*
966      * Round up the end of the previous packet to the next longword.
967      */
968     curlen = BPF_WORDALIGN(d->bd_slen);
969     if (curlen + totlen > d->bd_bufsize) {
970         /*
971          * This packet will overflow the storage buffer.
972          * Rotate the buffers if we can, then wakeup any
973          * pending reads.
974          */
975         if (d->bd_fbuf == 0) {
976             /*
977              * We haven't completed the previous read yet,
978              * so drop the packet.
979              */
980             ++d->bd_dcount;
981     }

```

图31-19 catchpacket 函数

```

981         return;
982     }
983     ROTATE_BUFFERS(d);
984     bpf_wakeup(d);
985     curlen = 0;
986 } else if (d->bd_immediate)
987 {
988     /* Immediate mode is set. A packet arrived so any
989      * reads should be woken up.
990     */
991     bpf_wakeup(d);
992 /*
993  * Append the bpf header.
994 */
995 hp = (struct bpf_hdr *) (d->bd_sbuf + curlen);
996 microtime(&hp->bh_tstamp);
997 hp->bh_datalen = pktlen;
998 hp->bh_hdrlen = hdrlen;
999 /*
1000  * Copy the packet data into the store buffer and update its length.
1001 */
1002 (*cpfn) (pkt, (u_char *) hp + hdrlen, (hp->bh_caplen = totlen - hdrlen));
1003 d->bd_slen = curlen + totlen;
1004 }

```

bpf.c

图31-19 (续)

946-955 `catchpacket`的参数包括：`d`，指向BPF设备结构的指针；`pkt`，指向进入分组的通用指针；`pktlen`，分组被接收时的长度；`snaplen`，从分组中保存下来的字节数；`cpfn`，函数指针，把分组从`pkt`中复制到一块连续内存中。如果分组已经保存在连续内存中，则`cptn`等于`bcopy`。如果分组被保存在mbuf中(`pkt`指向mbuf链表中的第一个mbuf，如环回驱动程序)，则`cptn`等于`bpf_mcopy`。

956-964 除了链路层首部和分组，`catchpacket`为每个分组添加`bpf_hdr`。从分组中保存的字节数等于`snaplen`和`pktlen`中较小的一个。处理过的分组和`bpf_hdr`必须能放入分组缓存中(`bd_bufsize`字节)。

1. 分组能否放入缓存

965-985 `curlen`等于存储缓存中已有的字节数加上所需的填充字节，以保证下一分组能从长字边界处开始存放。如果进入分组无法放入剩余的缓存空间，说明存储缓存已满。如果空闲缓存不可用(如应用进程正从暂留缓存中读取数据)，则进入分组被丢弃。如是空闲缓存可用，则调用`ROTATE_BUFFERS`宏轮转缓存，并通过`bpf_wakeup`唤醒所有等待输入数据的应用进程。

2. 立即方式处理

986-991 如果设备处于立即方式，则唤醒所有等待进程以处理进入分组——内核中没有分组的缓存。

3. 添加BPF首部

992-1004 当前时间(`microtime`)、分组长度和首部长度均保存在`bpf_hdr`中。调用`cptf`所指的函数，把分组复制到存储缓存，并更新存储缓存的长度。因为在把分组从设备缓存传送到某个mbuf链表之前，`bpf_tab`已由`leread`直接调用，接收时间戳近似等于实际的接收

时间。

31.5.3 bpfread函数

内核把针对BPF设备的read转交给bpfread处理。通过BIOCSRTIMEOUT命令，BPF支持限时读取。这个“特性”也可通过select系统调用实现，但至少tcpdump还是采用了BIOCSRTIMEOUT，而非select。应用进程提供一个读缓存，能够与设备的暂留缓存大小相匹配。BICOGBLEN命令返回缓存大小。一般情况下，读操作在存储缓存已满时返回。内核轮转缓存，把存储缓存转给暂留缓存，后者在read系统调用时被复制到应用进程提供的读缓存，同时BPF设备继续向存储缓存中存放进入分组。图31-20给出了bpfread。

```

344 int
345 bpfread(dev, uio)
346 dev_t    dev;
347 struct uio *uio;
348 {
349     struct bpf_d *d = &bpf_dtab[minor(dev)];
350     int      error;
351     int      s;

352     /*
353     * Restrict application to use a buffer the same size as
354     * as kernel buffers.
355     */
356     if (uio->uio_resid != d->bd_bufsize)
357         return (EINVAL);

358     s = splimp();
359     /*
360     * If the hold buffer is empty, then do a timed sleep, which
361     * ends when the timeout expires or when enough packets
362     * have arrived to fill the store buffer.
363     */
364     while (d->bd_hbuf == 0) {
365         if (d->bd_immediate && d->bd_slen != 0) {
366             /*
367             * A packet(s) either arrived since the previous
368             * read or arrived while we were asleep.
369             * Rotate the buffers and return what's here.
370             */
371             ROTATE_BUFFERS(d);
372             break;
373         }
374         error = tsleep((caddr_t) d, PRINET | PCATCH, "bpf", d->bd_rtout);
375         if (error == EINTR || error == ERESTART) {
376             splx(s);
377             return (error);
378         }
379         if (error == EWOULDBLOCK) {
380             /*
381             * On a timeout, return what's in the buffer,
382             * which may be nothing. If there is something
383             * in the store buffer, we can rotate the buffers.
384             */
385         if (d->bd_hbuf)

```

图31-20 bpfread 函数

```

386             /*
387              * We filled up the buffer in between
388              * getting the timeout and arriving
389              * here, so we don't need to rotate.
390              */
391             break;
392         if (d->bd_slen == 0) {
393             splx(s);
394             return (0);
395         }
396         ROTATE_BUFFERS(d);
397         break;
398     }
399 }
400 /*
401 * At this point, we know we have something in the hold slot.
402 */
403 splx(s);

404 /*
405 * Move data from hold buffer into user space.
406 * We know the entire buffer is transferred since
407 * we checked above that the read buffer is bpf_bufsize bytes.
408 */
409 error = uiomove(d->bd_hbuf, d->bd_hlen, UIO_READ, uio);

410 s = splimp();
411 d->bd_fbuf = d->bd_hbuf;
412 d->bd_hbuf = 0;
413 d->bd_hlen = 0;
414 splx(s);

415 return (error);
416 }

```

bpf.c

图31-20 (续)

344-357 通过最小设备号在**bpf_dtab**中寻找相应的BPF设备。如果读缓存不能匹配BPF设备缓存的大小，则返回**EINVAL**。

1. 等待数据

358-364 因为多个应用进程能够从同一个BPF设备中读取数据，如果有某个进程已先读取了数据，**while**循环将强迫读操作继续。如果暂留缓存中存在数据，循环被跳过。这与两个应用进程通过两个不同的BPF设备过滤同一个网络接口的情况(见习题31.2)是不同的。

2. 立即方式

365-373 如果设备处于立即方式，且存储缓存中有数据，则轮回缓存，**while**循环被终止。

3. 无可用的分组

374-384 如果设备不处于立即方式，或者存储缓存中没有数据，则应用进程进入休眠状态，直到某个信号到达，读定时器超时，或者有数据到达暂留缓存。如果有信号到达，则返回**EINTR**或**ERESTART**。

记住，应用进程不会见到**ERESTART**，因为**syscall**函数将处理这一错误，且不会向应用进程返回这一错误。

4. 查看暂留缓存

385-391 如果定时器超时，且暂留缓存中存在数据，则循环终止。

5. 查看存储缓存

392-399 如果定时器超时，且存储缓存中没有数据，则 `read` 返回 0。应用进程执行限时读取时，必须考虑到这种情况。如果定时器超时，且存储缓存中存在数据，则把存储缓存转给暂留缓存，循环终止。

如果 `tsleep` 返回正常且存在数据，同时 `while` 循环测试失败，则循环终止。

6. 分组可用

400-416 循环终止时，暂留缓存中已有数据。`uiomove` 从暂留缓存中移出 `bd_hlen` 个字节，交给应用进程。把暂留缓存转给空闲缓存，清除缓存计数器，函数返回。`uiomove` 调用前的注释指出，`uiomove` 通常能向应用进程复制 `bd_hlen` 字节的数据，因为前面已检查过读缓存大小，确保它大于 BPF 设备缓存的最大值，即 `bd_bufsize`。

31.6 BPF 的输出

最后，我们讨论如何向带有 BPF 设备的网络接口输出队列中添加分组。首先，应用进程必须构造完整的数据链路帧。对以太网而言，包括源和目的主机的硬件地址和数据帧类型(图4-8)。内核在把它放入接口的输出队列前不会修改链路帧。

bpfwrite 函数

内核把应用进程的 `write` 系统调用转给图 31-21 给出的 `bpfwrite` 处理，数据帧被传给 BPF 设备。

```

437 int
438 bpfwrite(dev, uio)
439 dev_t    dev;
440 struct uio *uio;
441 {
442     struct bpf_d *d = &bpf_dtab[minor(dev)];
443     struct ifnet *ifp;
444     struct mbuf *m;
445     int      error, s;
446     static struct sockaddr dst;
447     int      datlen;

448     if (d->bd_bif == 0)
449         return (ENXIO);

450     ifp = d->bd_bif->bif_ifp;
451     if (uio->uio_resid == 0)
452         return (0);

453     error = bpf_movein(uio, (int) d->bd_bif->bif_dlt, &m, &dst, &datlen);
454     if (error)
455         return (error);

456     if (datlen > ifp->if_mtu)
457         return (EMSGSIZE);

458     s = splnet();
459     error = (*ifp->if_output) (ifp, m, &dst, (struct rtentry *) 0);
460     splx(s);

```

图31-21 `bpfwrite` 函数

```

461      /*
462      * The driver frees the mbuf.
463      */
464      return (error);
465 }

```

bpf.c

图31-21 (续)

1. 检查设备号

437-449 通过最小的设备号选择 BPF设备，它必须已连接到某个网络接口。如果还没有，则返回 ENXIO。

2. 向mbuf链中复制数据

450-457 如果write给出的写入数据长度等于0，则立即返回0。bpf_movein从应用进程复制数据到一个mbuf链表，并基于由bif_dlt传递的接口类型计算去除了链路层首部后的分组长度，并在datlen中返回该值。它还在dst中返回一个已初始化过的sockaddr结构。对以太网而言，这个地址结构的类型应该等于AF_UNSPEC，说明mbuf链中保存了外出数据帧的数据链路层首部。如果分组大于接口的MTU，则返回EMSGSIZE。

3. 分组排队

458-465 调用ifnet结构中指定的if_output函数，得到的mbuf链被提交给网络接口。对于以太网，if_output等于ether_output。

31.7 小结

本章中，我们讨论了如何配置BPF设备，如何向BPF设备递交进入数据帧，及如何在一个BPF设备上传送外出数据帧。

一个网络接口可以有多个BPF设备，每个BPF设备都有自己的过滤程序。存储缓存和暂留缓存最大限度地减少了应用进程为了处理进入数据帧而调用read的次数。

本章中只介绍了BPF的一些主要特性。有关BPF设备过滤程序代码的详细情况和其他一些特性，感兴趣的读者请参阅源代码和Net/3手册。

习题

- 31.1 为什么在分组存入BPF缓存之前，就能在catchpacket中调用bpf_wakeup？
- 31.2 图31-20中，我们提到可能会有两个进程在同一BPF设备上等待数据。图31-11中，我们指出同一时间只能有一个应用进程可以打开一个特定的BPF设备。为什么这两种说法都正确呢？
- 31.3 如果BIOCSETIF命令中指定的设备不支持BPF，会发生什么现象？

第32章 原始IP

32.1 引言

应用进程在Internet域中创建一个SOCK_RAW类型的插口，就可以利用原始IP层。一般有下列3种用法：

- 1) 应用进程可利用原始插口发送和接收ICMP和IGMP报文。

Ping程序利用这种类型的插口，发送ICMP回显请求和接收ICMP回显应答。

有些选路守护程序，利用这一特性跟踪通常由内核处理的ICMP重定向报文段。我们在19.7节中提到，Net/3处理重定向报文段时，会在需重定向的插口上生成RTM_REDIRECT消息，从而无需利用原始插口的这一功能。

这个特性还用于实现基于ICMP的协议，如路由通告和路由请求（卷1的9.6节），它们需用到ICMP，不过最好由应用进程，而不是内核完成相应处理。

多播路由守护程序利用原始IGMP插口，发送和接收IGMP报文。

- 2) 应用进程可利用原始插口构造自己的IP首部。路由跟踪程序利用这一特性生成自己的UDP数据报，包括IP和UDP首部。

- 3) 应用进程可利用原始插口读写内核不支持的IP协议的IP数据报。

gated程序利用这一特性支持基于IP的路由协议：EGP、HELLO和OSPF。

这种类型的原始插口还可用于设计基于IP的新的运输层协议，而无需增加对内核的支持。调试应用进程代码比调试内核代码容易得多。

本章介绍原始IP插口的实现。

32.2 代码介绍

图32-1给出的C文件中包含了5个原始IP处理函数。

文件	描述
netinet/raw_ip.c	原始IP处理函数

图32-1 本章讨论的文件

图32-2给出了5个原始IP函数与其他内核函数间的关系。

带阴影的椭圆表示我们在本章中将要讨论的5个函数。请注意，原始IP函数名中的前缀“rip”表示“原始IP(Raw IP)”，而不是“选路信息协议(Routing Information Protocol)”，后者的缩写也是RIP。

32.2.1 全局变量

本章中用到4个全局变量，如图32-3所示。

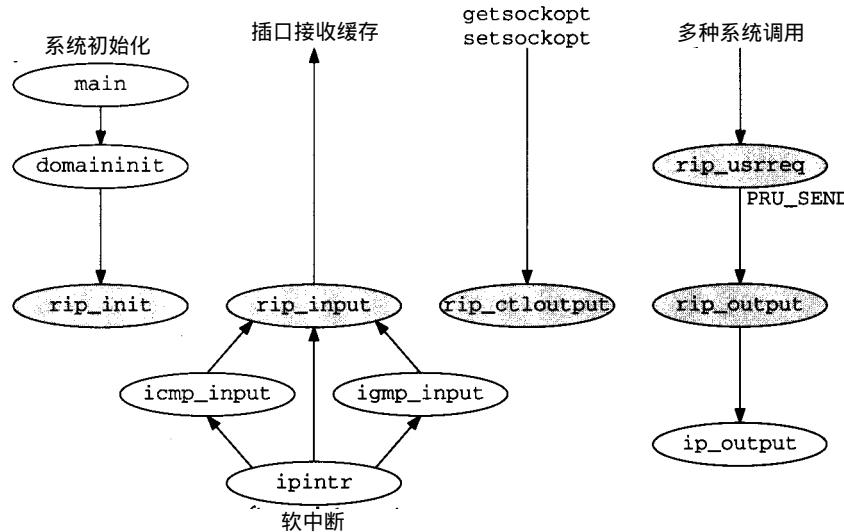


图32-2 原始IP函数与其他内核函数间的关系

变 量	数据类型	描 述
rawinpcb	struct inpcb	原始IP的Internet PCB链表表头
ripsrc	struct sockaddr_in	在输入中包含发送方的IP地址
rip_recvspace	u_long	插口接收缓存大小默认值，8192字节
rip_sendspace	u_long	插口发送缓存大小默认值，8192字节

图32-3 本章介绍的全局变量

32.2.2 统计量

原始IP在ipstat结构(图8-4)中维护两个计数器，如图 32-4所示。

ipstat成员变量	描 述	SNMP变量使用
ips_noproto ips_rawout	协议类型未知或不支持的数据报数目 生成的原始IP数据报总数	•

图32-4 ipstat 结构中维护的原始IP统计量

图8-6给出了如何在SNMP中使用ips_noproto计数器。图8-5给出了这两个计数器输出值的例子。

32.3 原始IP的protosw结构

与所有其他协议不同，inetsw数组有多条记录都可以读写原始IP。inetsw结构中有4个记录的插口类型都等于SOCK_RAW，但协议类型则各不相同：

- IPPROTO_ICMP(协议值1)；
- IPPROTO_IGMP(协议值2)；
- IPPROTO_RAW(协议值255)；和

- 原始IP通配记录(协议值0)。

其中ICMP和IGMP，前面已介绍过(图11-12和图13-9)。四项记录间的区别总结如下：

- 如果应用进程创建了一个原始插口(SOCK_RAW)，协议值非零(socket的第三个参数)，并且如果协议值等于 IPPROTO_ICMP、 IPPROTO_IGMP或 IPPROTO_RAW，则会使用对应的protosw记录。
- 如果应用进程创建了一个原始插口(SOCK_RAW)，协议值非零，但内核不支持该协议，pffindproto会返回协议值为0的通配记录，从而允许应用进程处理内核不支持的IP协议，而无需修改内核代码。

我们在7.8节中提到，ip_protox数组中的所有未知记录都指向 IPPROTO_RAW，它的协议转换类型如图32-5所示。

成 员	inetsw[3]	描 述
pr_type	SOCK_RAW	原始插口
pr_domain	& inetdomain	属于Internet域的原始IP
pr_protocol	IPPROTO_RAW(255)	出现在IP首部的ip_p字段
pr_flags	PR_ATOMIC/PR_ADDR	插口层标志，不用于协议处理
pr_input	rip_input	从IP层接收报文段
pr_output	0	原始IP不使用
pr_ctlinput	0	原始IP不使用
pr_ctloutput	rip_ctlinput	响应应用进程的管理请求
pr_usrreq	rip_usrreq	响应应用进程的通信请求
pr_init	0	原始IP不使用
pr_fasttimo	0	原始IP不使用
pr_slowtimo	0	原始IP不使用
pr_drain	0	原始IP不使用
pr_sysctl	0	原始IP不使用

图32-5 原始IP的protosw 结构

本章中我们将介绍3个以rip_开头的函数，此外还大致提一下rip_output函数，它没有出现在协议转换记录中，但输出原始IP报文段时，rip_usrreq将会调用它。

第五个原始IP函数，rip_init，只出现在通配处理记录中。初始化函数只能调用一次，所以它既可以出现在 IPPROTO_RAW记录中，也可以放在通配记录中。

不过，图32-5中并没有说明其他协议(ICMP和IGMP)，在它们自己的protosw结构中也用到了一些原始IP函数。图32-6对4个SOCK_RAW协议各自protosw结构的相关成员变量做了一个比较。为了强调指出彼此间的区别，不同之处都用黑体字标出。

protosw 记录	SOCK_RAW 协议类型			
	IPPROTO_ICMP (1)	IPPROTO_IGMP (2)	IPPROTO_RAW (255)	通配(0)
pr_input	icmp_input	igmp_input	rip_input	rip_input
pr_output	rip_output	rip_output	rip_output	rip_output
pr_ctloutput	rip_ctloutput	rip_ctloutput	rip_ctloutput	rip_ctloutput
pr_usrreq	rip_usrreq	rip_usrreq	rip_usrreq	rip_usrreq
pr_init	0	igmp_init	0	0
pr_sysctl	icmp_sysctl	0	0	0
pr_fasttimo	0	igmp_fasttimo	0	0

图32-6 原始插口的协议散转值的比较

不同BSD版本中，原始IP的实现各有不同。`ip_protox`表中，协议号等于`IPPROTO_RAW`记录通常都用做通配记录以支持未知的IP协议，而协议号等于0的记录通常做为默认记录，从而允许应用进程读写内核不支持的IP协议数据报。

应用进程使用`IPPROTO_RAW`记录，最早见于Van Jacobson开发的Traceout，这是第一个需要自己写IP首部(改变TTL字段)的应用进程。为了支持Traceout，修订了4.3BSD和Net/1，包括修改`rip_output`，在收到协议号等于`IPPROTO_RAW`的数据报时，假定应用进程提交了一个完整的IP数据报，包括IP首部。在Net/2中，引入了`IP_HDRINCL`插口选项，简化了`IPPROTO_RAW`的用法，允许应用进程利用通配记录发送自己的IP首部。

32.4 rip_init函数

系统初始化时，`domaininit`函数调用原始IP初始化函数`rip_init`(图32-7)。

```
47 void
48 rip_init()
49 {
50     rawinpcb.inp_next = rawinpcb.inp_prev = &rawinpcb;
51 }
```

图32-7 rip_init 函数

这个函数执行的唯一操作是令PCB首部(rawinpcb)中的前向和后向指针都指向自己，实现一个空的双向链表。

只要某个`socket`系统调用创建了`SOCK_RAW`类型的插口，下面将介绍的原始IP`PRU_ATTACH`函数就创建一个Internet PCB，并插入到rawinpcb链表中。

32.5 rip_input函数

因为`ip_protox`数组中保存的所有关于未知协议记录都指向`IPPROTO_RAW`(图7-8)，且后者的`pr_input`函数指向`rip_input`(图32-6)，所以只要某个接收IP数据报的协议号内核无法识别，就会调用此函数。但从图32-2可看出，ICMP和IGMP都可能调用`rip_input`，只要满足下列条件：

- `icmp_input`调用`rip_input`处理所有未知的ICMP报文类型和所有非响应的ICMP报文。
- `igmp_input`调用`rip_input`处理所有IGMP分组。

上述两种情况下，调用`rip_input`的一个原因是允许创建了原始插口的应用进程处理新增的ICMP和IGMP报文，内核可能不支持它们。

图32-8给出了`rip_input`函数。

```
59 void
60 rip_input(m)
61 struct mbuf *m;
62 {
63     struct ip *ip = mtod(m, struct ip *);
64     struct inpcb *inp;
```

图32-8 rip_input 函数

```

65     struct socket *last = 0;
66     ripsrc.sin_addr = ip->ip_src;
67     for (inp = rawinpcb.inp_next; inp != &rawinpcb; inp = inp->inp_next) {
68         if (inp->inp_ip.ip_p && inp->inp_ip.ip_p != ip->ip_p)
69             continue;
70         if (inp->inp_laddr.s_addr &&
71             inp->inp_laddr.s_addr == ip->ip_dst.s_addr)
72             continue;
73         if (inp->inp_faddr.s_addr &&
74             inp->inp_faddr.s_addr == ip->ip_src.s_addr)
75             continue;
76         if (last) {
77             struct mbuf *n;
78             if (n = m_copy(m, 0, (int) M_COPYALL)) {
79                 if (sbappendaddr(&last->so_rcv, &ripsrc,
80                                 n, (struct mbuf *) 0) == 0)
81                     /* should notify about lost packet */
82                     m_freem(n);
83                 else
84                     sorwakeup(last);
85             }
86         }
87         last = inp->inp_socket;
88     }
89     if (last) {
90         if (sbappendaddr(&last->so_rcv, &ripsrc,
91                         m, (struct mbuf *) 0) == 0)
92             m_freem(m);
93         else
94             sorwakeup(last);
95     } else {
96         m_freem(m);
97         ipstat.ips_noproto++;
98         ipstat.ips_delivered--;
99     }
100 }

```

raw_ip.c

图32-8 (续)

59-66 IP数据报中的源地址被保存在全局变量 `ripsrc` 中，只要找到了匹配的 PCB，`ripsrc` 将做为参数传给 `sbappendaddr`。与 UDP不同，原始IP没有端口号的概念，因此 `sockaddr_in` 结构中的 `sin_port` 总等于0。

2. 在所有原始IP PCB中寻找一个或多个匹配的记录

67-88 原始IP处理PCB表的方式与 UDP和TCP不同。前面介绍过，这两个协议维护一个指针，总是指向最近收到的报文段(单报文段缓存)，并调用通用函数 `in_pcblklookup` 寻找一个最佳匹配(如果收到的数据报不同于缓存中的记录)。由于原始IP数据报可能发送到多个插口上，所以无法使用 `in_pcblklookup`，因此，必须遍历原始PCB链表中的所有PCB。这一点类似于UDP处理广播报文段和多播报文段的方式(图23-26)。

3. 协议比较

68-69 如果PCB中的协议字段非零，并且与IP首部的协议字段不匹配，则PCB被忽略。也说明协议值等于0(socket的第三个参数)的原始插口能够匹配所有收到的原始IP报文段。

4. 比较本地和远端IP地址

70-75 如果PCB中的本地地址非零，并且与IP首部的目的IP地址不匹配，则PCB被忽略。如果PCB中的远端地址非零，并且与IP首部的源IP地址不匹配，PCB被忽略。

上述3种测试说明应用进程能够创建一个协议号等于0的原始插口，即不绑定到本地地址，也不与远端地址建立连接，可以接收经`rip_input`处理的所有数据报。

代码71行和74行都有同样的错误：相等测试，实际应为不相等测试。

5. 递交接收数据报的复制报文段以备处理

76-94 `sbappendaddr`向应用进程提交一个接收数据报的复制报文段。变量`last`的使用与图23-26中的用法类似：因为`sbappendaddr`把报文段放入到适当队列中后将释放所有`mbuf`，如果有多个进程接收数据报的复制报文段，`rip_input`必须调用`m_copy`保存一份复制报文段。但如果只有一个应用进程接收数据报，则无需复制。

6. 无法上交的数据报

95-99 如果无法为数据报找到相匹配的插口，则释放`mbuf`，递增`ips_noproto`，递减`ips_delivered`。IP在调用`rip_input`之前已经递增过后一个计数器（图8-15）。由于数据报实际上没有上交给运输层，因此，必须递减`ips_delivered`，确保两个SNMP计数器，`ipInDiscards`和`ipInDelivers`（图8-16），的正确性。

本节开始时，我们提到，`icmp_input`会为未知报文类型或非响应报文调用`rip_input`，意味着如果收到ICMP主机不可达报文，且`rip_input`找不到可匹配的原始插口PCB，`ips_noproto`会递增。这也说明为什么图8-5中的计数器值较大。在前面对该计数器的描述中提到“未知或不支持的协议”，这种说法是不正确的。

如果收到的IP数据报带有的协议字段，既无法为内核辩识，也无法由某个应用进程通过原始插口处理，Net/3不会生成差错代码等于2（协议不可达）的ICMP目的不可达报文。RFC 1122建议出现此种情况时应该生成ICMP差错报文（参见习题32.4）。

32.6 `rip_output`函数

图32-6中，ICMP、IGMP和原始IP都调用`rip_output`实现原始IP输出。应用进程调用5个写函数之一：`send`、`sendto`、`sendmsg`、`write`和`writev`，系统将输出报文段。如果插口已建立连接，就可以任意调用上述5个函数，尽管`sendto`和`sendmsg`中不能规定目的地址。如果插口没有建立连接，则只能调用`sendto`和`sendmsg`，且必须规定目的地址。

图32-9给出了`rip_output`函数。

1. 内核填充IP首部

119-128 如果`IP_HDRINCR`插口选项未定义，`M_PREPEND`为IP首部分配空间，并填充IP首部各字段。此处未填充的字段留待`ip_output`初始化（图8-22）。协议字段等于PCB中保存的值，并且是图32-10中`socket`系统调用的第三个参数。

TOS等于0，TTL等于255。内核为原始IP插口填充各首部字段时，通常都使用这些固定值。这与UDP和TCP不同，应用进程能够通过插口选项设定`IP_TTL`和`IP_TOS`值。

129 应用程序通过`IP_OPTIONS`插口选项设定的所有IP选项，都通过`opts`变量传给`ip_output`函数。

2. 调用者填充IP首部：`IP_HDRINCR`插口选项

130-133 如果选用了IP_HDRINCR插口选项，调用者在数据报前提供完整的IP首部。如果应用进程提供的ID字段等于0，对此类IP首部需做的唯一修改是ID字段。IP数据报的ID字段可以等于0。此处，rip_output对ID字段的赋值可以简化应用进程的处理，直接设ID字段等于0，rip_output向内核请求内核变量ip_id的当前值，做为IP报文段的ID值。

134-136 令opts为空，忽略应用进程通过IP_OPTIONS可能设定的任何IP选项。如果调用者构建了自己的IP首部，其中肯定已包括了调用者希望加入的IP选项。flags变量中必须有IP_RAWOUTPUT标志，告诉ip_output不要修改IP首部。

```

105 int                                         raw_ip.c
106 rip_output(m, so, dst)
107 struct mbuf *m;
108 struct socket *so;
109 u_long dst;
110 {
111     struct ip *ip;
112     struct inpcb *inp = sotoinpcb(so);
113     struct mbuf *opts;
114     int flags = (so->so_options & SO_DONTROUTE) | IP_ALLOWBROADCAST;
115
116     /*
117      * If the user handed us a complete IP packet, use it.
118      * Otherwise, allocate an mbuf for a header and fill it in.
119      */
120     if ((inp->inp_flags & INP_HDRINCL) == 0) {
121         M_PREPEND(m, sizeof(struct ip), M_WAIT);
122         ip = mtod(m, struct ip *);
123         ip->ip_tos = 0;
124         ip->ip_off = 0;
125         ip->ip_p = inp->inp_ip.ip_p;
126         ip->ip_len = m->m_pkthdr.len;
127         ip->ip_src = inp->inp_laddr;
128         ip->ip_dst.s_addr = dst;
129         ip->ip_ttl = MAXTTL;
130         opts = inp->inp_options;
131     } else {
132         ip = mtod(m, struct ip *);
133         if (ip->ip_id == 0)
134             ip->ip_id = htons(ip_id++);
135         opts = NULL;
136         /* XXX prevent ip_output from overwriting header fields */
137         flags |= IP_RAWOUTPUT;
138         ipstat.ips_rawout++;
139     }
140     return (ip_output(m, opts, &inp->inp_route, flags, inp->inp_moptions));

```

raw_ip.c

图32-9 rip_output 函数

137 计数器ips_rawout递增。执行Traceroute时，Traceroute每发送一个变量就会导致此变量加1。

rip_output的操作在不同版本中也有所变化。在Net/3中使用IP_HDRINCL插口选项时，rip_output对IP首部所做的唯一修改就是填充ID字段，如果应用进程将其定为0。因为IP_RAWOUTPUT标志置位，Net/3中的ip_output函数不改动IP首

部。但在Net/2中，即使IP_HDRINCL插口选项设定时，它也会修改IP首部中特定字段：IP版本号等于4，分片偏移量等于0，分片标志被清除。

32.7 rip_usrreq函数

协议的用户请求处理函数能够完成多种操作。与UDP和TCP的用户请求处理函数类似，rip_usrreq是一个很大的switch语句，每个PRU_xxx请求，都有一个对应的case子句。

图32-10给出的PRU_ATTACH请求，来自socket系统调用。

```

194 int
195 rip_usrreq(so, req, m, nam, control)
196 struct socket *so;
197 int     req;
198 struct mbuf *m, *nam, *control;
199 {
200     int     error = 0;
201     struct inpcb *inp = sotoinpcb(so);
202     extern struct socket *ip_mrouter;
203     switch (req) {
204         case PRU_ATTACH:
205             if (inp)
206                 panic("rip_attach");
207             if ((so->so_state & SS_PRIV) == 0) {
208                 error = EACCES;
209                 break;
210             }
211             if ((error = soreserve(so, rip_sendspace, rip_recvspace)) ||
212                 (error = in_pcbaalloc(so, &rawinpcb)))
213                 break;
214             inp = (struct inpcb *) so->so_pcb;
215             inp->inp_ip.ip_p = (int) nam;
216             break;

```

raw_ip.c

raw_ip.c

图32-10 rip_usrreq 函数：PRU_ATTACH 请求

194-206 每次socket函数被调用时，都会创建新的socket结构，此时还没有指向某个Internet PCB。

1. 确认超级用户

207-210 只有超级用户才能创建原始插口，这是为了防止普通用户向网络发送自己的IP数据报。

2. 创建Internet PCB，保留缓存空间

211-215 为输入和输出队列保留所需空间，调用in_pcbaalloc分配新的Internet PCB，添加到原始IP PCB链表中(rawinpcb)，并与socket结构建立对应关系。rip_usrreq的nam参数就是socket系统调用的第三个参数：协议。它被保存在PCB中，因为rip_input需用它上交收到的数据报，rip_output也要把它填入到外出数据报的协议字段中（如果IP_HDRINCL未设定）。

原始IP插口与远端IP地址建立的连接，与UDP插口和远端IP地址建立的连接相类似。它固定了原始插口只能接收来自于特定地址的数据报，如我们在rip_input中所看到的。原始IP

与UDP一样，是一个无连接协议，下面两种情况下会发送 PRU_DISCONNECT请求：

- 1) 关闭建立连接的原始插口时，在 PRU_DETACH之前会先发送 PRU_DISCONNECT请求。
- 2) 如果对一个已建立连接的原始插口调用 connect，soconnect在发送PRU_CONNECT请求前会先发送PRU_DISCONNECT请求。

图32-11给出了PRU_DISCONNECT、PRU_ABORT和PRU_DETACH请求。

```

217     case PRU_DISCONNECT:                                raw_ip.c
218         if ((so->so_state & SS_ISCONNECTED) == 0) {
219             error = ENOTCONN;
220             break;
221         }
222         /* FALLTHROUGH */
223
223     case PRU_ABORT:
224         soisdisconnected(so);
225         /* FALLTHROUGH */
226
226     case PRU_DETACH:
227         if (inp == 0)
228             panic("rip_detach");
229         if (so == ip_mrouter)
230             ip_mrouter_done();
231         in_pcbdetach(inp);
232         break;

```

raw_ip.c

图32-11 rip_usrreq 函数：PRU_DISCONNECT 、PRU_ABORT 和PRU_DETACH 请求

217-222 如果处理PRU_DISCONNECT请求的插口没有进入连接状态，则返回错误。

223-225 尽管禁止在一个原始插口上发送 PRU_ABORT请求，这个 case语句实际上是 PRU_DISCONNECT请求处理的延续。插口转入断开状态。

226-230 close系统调用发送 PRU_DETACH请求，这个 case语句还将结束 PRU_DISCONNECT请求的处理。如果 socket结构用于多播选路(ip_mrouter)，则调用 ip_mrouter_done取消多播选路。一般情况下，mrouted (8)守护程序会通过 DVMPR_DONE插口选项取消多播选路，因此，这个条件用于防止 mrouted (8) 在没有正确设定插口选项之前就异常终止了。

231 调用in_pcbdetach释放Internet PCB，并从原始IP PCB表(rawinpcb)中删除。

通过PRU_BIND请求，可以把原始IP插口绑定到某个本地IP地址上，如图32-12所示。我们在rip_input中指出，插口将只能接收发向该地址的数据报。

233-250 应用进程向sockaddr_in结构填充本地IP地址。下列3个条件必须全真，否则将返回差错代码EADDRNOTAVAIL：

- 1) 至少配置了一个IP接口；
- 2) 地址族应等于AF_INET(或者AF_IMPLINK，历史上人为造成的不一致)；和
- 3) 如果绑定的IP地址不等于0.0.0.0，它必须对应于某个本地接口。调用者的sockaddr_in中的端口号必须等于0，否则，ifa_ifwithaddr将返回错误。

本地IP地址保存在PCB中。

```

233     case PRU_BIND:
234     {
235         struct sockaddr_in *addr = mtod(nam, struct sockaddr_in *);
236         if (nam->m_len != sizeof(*addr)) {
237             error = EINVAL;
238             break;
239         }
240         if ((ifnet == 0) ||
241             ((addr->sin_family != AF_INET) &&
242              (addr->sin_family != AF_IMPLINK)) ||
243             (addr->sin_addr.s_addr &&
244              ifa_ifwithaddr((struct sockaddr *) addr) == 0)) {
245             error = EADDRNOTAVAIL;
246             break;
247         }
248         inp->inp_laddr = addr->sin_addr;
249         break;
250     }

```

raw_ip.c

图32-12 rip_usrreq 函数：PRU_BIND 请求

应用进程还可以在原始 IP插口与某个特定远端IP地址间建立连接。我们在 rip_input 中指出，这样可以限制应用进程只能接收源 IP地址等于连接对端IP地址的数据报。应用进程可以同时调用 bind 和 connect，或者两者都不调用，取决于它希望 rip_input 对接收数据报采用的过滤方式。图 32-13 给出了 PRU_CONNECT 请求的处理逻辑。

如果调用者的 sockaddr_in 初始化正确，且至少配置了一个 IP接口，则指定的远端地址将存储在 PCB 中。注意，这一处理和 UDP 插口建立与远端 IP 地址的连接有所不同。对于 UDP，in_pcbconnect 申请到达远端地址的一条路由，并把外出接口视为本地地址（图 22-9）。对于原始 IP，只有远端 IP 地址存储到 PCB 中，除非应用进程还调用了 bind，rip_input 将只比较远端地址。

```

251     case PRU_CONNECT:
252     {
253         struct sockaddr_in *addr = mtod(nam, struct sockaddr_in *);
254         if (nam->m_len != sizeof(*addr)) {
255             error = EINVAL;
256             break;
257         }
258         if (ifnet == 0) {
259             error = EADDRNOTAVAIL;
260             break;
261         }
262         if ((addr->sin_family != AF_INET) &&
263             (addr->sin_family != AF_IMPLINK)) {
264             error = EAFNOSUPPORT;
265             break;
266         }
267         inp->inp_faddr = addr->sin_addr;
268         soisconnected(so);
269         break;
270     }

```

raw_ip.c

图32-13 rip_usrreq 函数：PRU_CONNECT 请求

应用进程结束发送数据后，调用 shutdown，生成PRU_SHUTDOWN请求，尽管应用进程很少为原始IP插口调用 shutdown。图32-14给出了PRU_CONNECT2和PRU_SHUTDOWN请求的处理逻辑。

```
271     case PRU_CONNECT2:
272         error = EOPNOTSUPP;
273         break;
274         /*
275          * Mark the connection as being incapable of further input.
276          */
277     case PRU_SHUTDOWN:
278         socantsendmore(so);
279         break;
```

raw_ip.c

图32-14 PRU_CONNECT2 和PRU_SHUTDOWN 请求

271-273 原始IP插口不支持PRU_CONNECT2请求。

274-279 socantsendmore置位插口标志，禁止所有输出。

图23-14中，我们给出了5个写函数如何调用协议的pr_usrreq函数，发送PRU_SEND请求。图32-15给出了这个请求的处理逻辑。

```
280     /*
281      * Ship a packet out. The appropriate raw output
282      * routine handles any massaging necessary.
283      */
284     case PRU_SEND:
285     {
286         u_long dst;
287
288         if (so->so_state & SS_ISCONNECTED) {
289             if (nam) {
290                 error = EISCONN;
291                 break;
292             }
293             dst = inp->inp_faddr.s_addr;
294         } else {
295             if (nam == NULL) {
296                 error = ENOTCONN;
297                 break;
298             }
299             dst = mtod(nam, struct sockaddr_in *)->sin_addr.s_addr;
300         }
301         error = rip_output(m, so, dst);
302         m = NULL;
303         break;
304     }
```

raw_ip.c

图32-15 rip_usrreq 函数：PRU_SEND 请求

280-303 如果插口处于连接状态，则调用者不能指定目的地址 (nam参数)。如果插口未建立连接，则需要指明目的地址。不管哪种情况，只要条件满足，dst将等于目的IP地址。rip_output发送数据报。令mbuf指针m为空，防止函数结束时释放mbuf链。因为接口输出

例程发送数据报之后会释放 mbuf链(记住，rip_output向ip_output提交mbuf链，ip_output把它加入到接口的输出队列中)。

图32-16给出了rip_usrreq的最后一部分代码。由fstat系统调用生成的PRU_SENSE请求，没有返回值。PRU_SOCKADDR和PRU_PEERADDR请求分别由getsockname和getpeername系统调用生成。原始IP插口不支持其余请求。

319-324 函数in_setsockaddr和in_setpeeraddr能够从PCB中读取信息，在nam参数中返回结果。

```

304     case PRU_SENSE:
305         /*
306          * fstat: don't bother with a blocksize.
307         */
308         return (0);
309
310         /*
311          * Not supported.
312         */
313     case PRU_RCVOOB:
314     case PRU_RCVD:
315     case PRU_LISTEN:
316     case PRU_ACCEPT:
317     case PRU_SENDOOB:
318         error = EOPNOTSUPP;
319         break;
320
321     case PRU_SOCKADDR:
322         in_setsockaddr(inp, nam);
323         break;
324
325     case PRU_PEERADDR:
326         in_setpeeraddr(inp, nam);
327         break;
328
329     default:
330         panic("rip_usrreq");
331     }
332     if (m != NULL)
333         m_freem(m);
334     return (error);
335 }
```

raw_ip.c

图32-16 rip_usrreq 函数：剩余的请求

32.8 rip_ctloutput函数

setsockopt和getsockopt函数会调用rip_ctloutput，它处理一个IP插口选项和8个用于多播选路的插口选项。

图32-17给出了rip_ctloutput函数的第一部分。

```

144 int
145 rip_ctloutput(op, so, level, optname, m)
146 int     op;
147 struct socket *so;
```

图32-17 rip_usrreq 函数：处理 IP_HDRINCL 插口选项

```

148 int      level, optname;
149 struct mbuf **m;
150 {
151     struct inpcb *inp = sotoinpcb(so);
152     int      error;
153
154     if (level != IPPROTO_IP)
155         return (EINVAL);
156
157     switch (optname) {
158
159     case IP_HDRINCL:
160         if (op == PRCO_SETOPT || op == PRCO_GETOPT) {
161             if (*m == 0 || *m == 0 || (*m)->m_len < sizeof(int))
162                 return (EINVAL);
163             if (op == PRCO_SETOPT) {
164                 if (*mtod(*m, int *) & INP_HDRINCL)
165                     inp->inp_flags |= INP_HDRINCL;
166                 else
167                     inp->inp_flags &= ~INP_HDRINCL;
168                 (void) m_free(*m);
169             }
170             return (0);
171         }
172         break;

```

raw_ip.c

图32-17 (续)

144-172 保存新选项值或者选项当前值的 mbuf至少要能容纳一个整数。对于 setsockopt 系统调用，如果 mbuf中的整数值非零，则设定该标志，否则清除它。对于 getsockopt 系统调用，mbuf中的返回值要么等于0，要么是非零的选项值。函数返回，以避免 switch语句结束时处理其他IP选项。

图32-18给出了 rip_ctloutput 函数的最后一部分，处理8个多播选路插口选项。

raw_ip.c

```

173     case DVMRP_INIT:
174     case DVMRP_DONE:
175     case DVMRP_ADD_VIF:
176     case DVMRP_DEL_VIF:
177     case DVMRP_ADD_LGRP:
178     case DVMRP_DEL_LGRP:
179     case DVMRP_ADD_MRT:
180     case DVMRP_DEL_MRT:
181
182     /* shown in Figure 14.9 */
183
184     }
185     return (ip_ctloutput(op, so, level, optname, m));
186 }

```

raw_ip.c

图32-18 rip_usrreq 函数：处理多播选路插口选项

173-188 这8个插口选项只对 setsockopt 系统调用有效，它们由图 14-9讨论的

ip_mrouter_cmd 函数处理。

189 所有其他IP插口选项，如设定IP选项的 IP_OPTIONS，则由 ip_ctloutput 处理。

32.9 小结

原始插口为IP主机提供3种功能。

- 1) 用于发送和接收ICMP和IGMP报文。
- 2) 支持应用进程构建自己的IP首部。
- 3) 允许应用进程支持基于IP的其他协议。

原始IP较为简单——只填充IP首部的有限几个字段——但它允许应用进程提供自己的IP首部。例如，调试程序就能发送任何类型的IP数据报。

原始IP输入提供了3种处理方式，能够选择性地接收进入的IP数据报。应用进程基于下列因素选择接收数据报：(1) 协议字段；(2) 源IP地址(由connect指明)；(3) 目的IP地址(由bind指明)。应用进程可以任意组合上述3种过滤条件。

习题

- 32.1 假定 IP_HDRINCL 插口选项未设定。如果 socket 的第三个参数等于 0，rip_output 填入IP首部协议字段(ip_p)的值是多少？如果 socket 的第三个参数等于 IPPROTO_RAW(255)，rip_output 填入该段(ip_p)的值又是多少？
- 32.2 应用进程创建了一个原始插口，协议值等于 IPPROTO_RAW(255)。应用进程在这个插口上将收到什么类型的IP数据报？
- 32.3 应用进程创建了一个原始插口，协议值等于 0。应用进程在这个插口上将收到什么类型的IP数据报？
- 32.4 修改 rip_input，在适当情况下发送代码等于 2(协议不可达)的ICMP目的不可达报文。请注意，不要为 rip_input 正处理的ICMP或IGMP数据报生成一个差错。
- 32.5 如果应用进程希望生成自己的IP数据报，自己填充IP首部字段，可使用 IP_HDRINCL 选项置位的原始IP插口，或者采用BPF(第31章)，两种方法的区别是什么？
- 32.6 什么时候应用进程应该读取原始IP插口？什么时候读取BPF？

附录A 部分习题的解答

第1章

- 1.2 SLIP驱动程序执行 `spltty`(图1-13) , 其优先级必须低于或等于 `splimp` , 且高于 `spynet`。因此 , SLIP驱动程序由于中断而被阻塞。

第2章

- 2.1 `M_EXT`标志是mbuf自身的一个属性 , 而不是mbuf中保存的数据报的属性。
- 2.2 调用者请求大于100字节(`MHLEN`)的连续空间。
- 2.3 不可行 , 因为多个mbuf都可指向簇(2.9节)。此外 , 簇中也没有用于后向指针的空间(习题2.4)。
- 2.4 在`<sys/mbuf.h>`定义的宏`MCLALLOC`和`MCLFREE`中 , 我们看到引用计数器是一个名为`mclrefcnt`的数组。它在内核初始化时被分配 , 代码文件为 `machdep.c`。

第3章

- 3.3 采用很大的交互式队列 , 并不符合建立队列的目的 , 新的交互式流量跟在原有流量之后 , 会造成附加时延。
- 3.4 因为`sl_softc`结构都是全局变量 , 内核初始化时都被置为0。
- 3.5

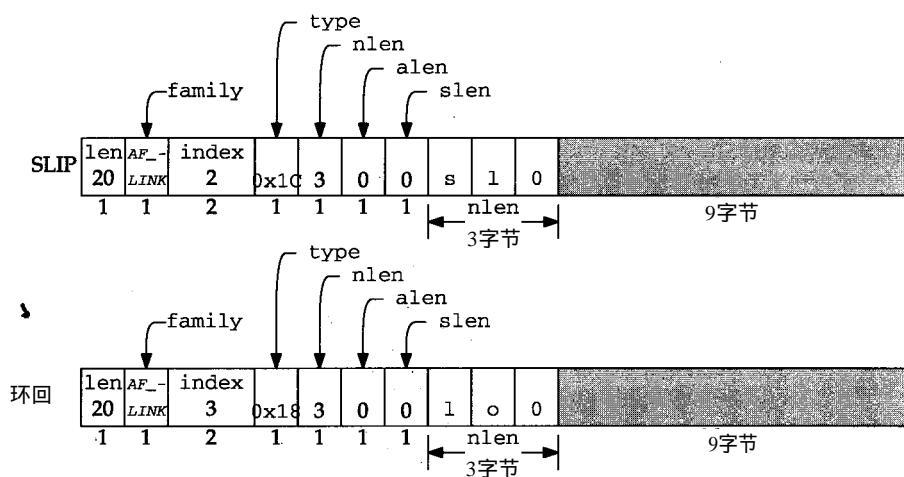


图 A-1

第4章

- 4.1 `leread`必须查看数据报 , 确认把数据报提交给 BPF之后 , 是否需要将其丢弃。因为

BPF开关会造成接口处于一种混杂模式，数据报的目的地有可能是以太网中的其他主机，BPF处理完毕后，必须将其丢弃。

如果接口没有加开关，则必须在 `ether_input` 中完成这一测试。

- 4.2 如果测试反过来，广播标志永远不会置位。

如果第二个 `if` 前没有 `else`，所有广播分组都会带上多播标志。

第5章

5.1 环回接口不需要输入函数，因为它接收的所有分组都直接来自于 `looutput`，后者实际完成了输入功能。

5.2 堆栈分配快于动态存储器分配。对 BPF 处理，性能是首要考虑的因素，因为对每个进入数据报都会执行该代码。

5.5 缓存溢出的第一个字节被丢弃，`SC_ERROR` 置位，`sinput` 重设簇指针，从缓存起始处开始收集字符。因为 `SC_ERROR` 置位，`sinput` 收到 SLIP END 字符后，丢弃当前接收的数据帧。

5.6 如果检验和无效或者 IP 首部长度与实际数据报长度不匹配，数据报被丢弃。

5.7 因为 `ifp` 指向 `le_softc` 结构的第一个成员，

```
sc = (struct le_softc*) ifp;
```

`sc` 初始化正确。

5.8 这是非常困难的。某些路由器在开始丢弃数据报时，可能会发送 ICMP 源站抑制报文段，但 Net/3 实现中的 UDP 插口丢弃这些报文段（图 23-30）。应用程序可以使用与 TCP 所采用的相同技术：根据确认的数据报估算往返时间，确认可用的带宽和时延。

第6章

6.1 IP 子网出现之前（RFC 950 [Mogul 和 Postel 1985]），IP 地址的网络和主机部分都以字节为界。`in_addr` 结构的定义如下：

```
struct in_addr {
    union {
        struct { u_char s_b1, s_b2, s_b3, s_b4; } S_un_b;
        struct { u_short s_w1, s_w2; } S_un_w;
        u_long S_addr;
    } S_un;
#define s_addr S_un.S_addr           /* should be used for all code */
#define s_host S_un.S_un_b.s_b2     /* OBSOLETE: host on imp */
#define s_net  S_un.S_un_b.s_b1     /* OBSOLETE: network */
#define s_imp   S_un.S_un_w.s_w2    /* OBSOLETE: imp */
#define s_imphno S_un.S_un_b.s_b4   /* OBSOLETE: imp # */
#define s_lh    S_un.S_un_b.s_b3   /* OBSOLETE: logical host */
};
```

图 A-2

Internet 地址读写单位既可以是 8 bit 字节，也可以是 16 bit 单字，或 32 bit 双字。宏 `s_host`、`s_net`、`s_imp` 等等，它们的名字明确地反应出早期 TCP/IP 网络的结构。子网和超网概念的引入，淘汰了这种以字节和单字区分的做法。

- 6.2 返回指向结构 `sl_softc[0]` 的指针。

- 6.3 接口输出函数，如 `ether_output`，只有一个指向接口 `ifnet` 结构的指针，而没有指向 `ifaddr` 的指针。在 `arpcom` 结构(最后一次为接口设定的 IP 地址)中使用 IP 地址可以避免从 `ifaddr` 地址链表中寻找所需地址。
- 6.4 只有超级用户进程才能创建原始 IP 插口。通过 UDP 插口，任何用户进程能够查看接口配置，但内核仍拥有超级用户特权，能够修改接口地址。
- 6.5 有 3 个函数循环处理网络掩码，一次处理一个字节。它们是 `ifa_ifwithnet`、`ifaof_ifpforaddr` 和 `rt_maskedcopy`。较短的网络掩码能够提高这些函数的性能。
- 6.6 与远端系统建立 Telnet 连接。Net/2 系统不应该转交这些数据报，而其他系统不会接受到达环回接口之外的非环回接口的环回数据报。

第7章

- 7.1 下列调用返回指向 `inetsw[6]` 的指针：

```
pffindproto(PF_INET, 0, SOCK_RAW);
```

第8章

- 8.1 可能不会。系统不可能响应任意的广播报文，因为没有可供响应的源地址。
- 8.4 因为数据报已经损坏，无法知道首部中的地址是否正确。
- 8.5 如果应用程序选取的源地址与指定的外出接口的地址不同，则无法发送到下一跳路由器。如果下一跳路由器发现数据报源地址与其到达的子网地址不符，则不会执行下一步的转发操作。这是尽量减少终端系统复杂性带来的后果，RFC 1122 指出了这一问题。
- 8.6 新主机认为广播报文来自于某个没有划分子网的网络中的主机，并试图将数据报发回给源主机。网络接口开始广播 ARP 请求，向网络请求该广播地址，当然，这一请求永远不会收到响应。
- 8.7 减少 TTL 的操作出现在小于等于 1 的测试之后，是为了避免收到的 TTL 等于 0，减 1 后将等于 255，从而引起操作差错。
- 8.8 如果两个路由器彼此认为对方是某个数据报的下一跳路由器，则形成环路。除非该环路被打破，原始数据报在两个路由器间来回传递，并且每个路由器都向源主机发送 ICMP 重定向报文段，如果该主机与路由器处于同一个网络中。路由更新时，不同路由器中的路由表暂时存在的不一致现象，会造成这种环路。
 原始报文段的 TTL 最终减为 0，数据报被丢弃。这是 TTL 存在一个主要原因。
- 8.9 不会检查 4 个以太网广播地址，因为它们不属于接收接口。但应检查有限的广播地址，说明带有 SLIP 链路的系统采用有限的广播地址，即使不知道对端地址，也能与对端通信。
- 8.10 只对数据报的第一个分片(分片偏移量等于 0)生成 ICMP 差错报文。无论是主机字节序，还是网络字节序，0 的表示都相同，因此无需转换。

第9章

- 9.1 RFC 1122 建议如果数据报中的选项彼此冲突，处理方式由各实现代码自己决定。Net/3 能正确处理第一个源路由选项，但因为它会更新数据报首部的 `ip_dst`，第二条源路由处理将出现差错。
- 9.2 网络中的主机也可以用做到达网络其他主机的中继。如果目的主机不可直接到达，

源主机可在数据报中加入路由，首先到达中继主机，接着到达最终的目的主机。路由器不会丢弃数据报，因为目的地址指向中继主机，后者将处理路由并把数据报转发给最终目的主机。目的主机把路由反转，同样利用中继主机转发响应。

- 9.3 采用与前一个习题同样的原则。我们选取一个能够同时与源主机和目的主机通信的中继路由器，并构造源路由，穿过中继路由器到达目的地址。中继路由器必须与目的地址处于同一个网络，通信中无需默认路由。
- 9.4 如果源路由是仅有的 IP 选项，NOP 选项使得所有 IP 地址以 4 字节边界对齐，从而能够优化存储器中的地址读取操作。这种对齐技术也适用于多个 IP 选项，如果每个 IP 选项都通过 NOP 填充，保证按 4 字节边界对齐。
- 9.5 不应混淆非标准时间值和标准时间值，最大的标准时间值等于 $86\ 399\ 399(24 \times 60 \times 60 \times 1000 - 1)$ ，需要 28 bit 才能表示。由于时间值有 32 bit，从而避免了高位比特的混淆问题。
- 9.6 源路由选项代码在处理过程中可能会改变 ip_dst。保存目的地址，从保证时间戳处理使用原始目的地址。

第10章

10.2 重装后，只有第一个分片的选项上交给运输层协议。

10.3 因为数据长度($204 + 20$)大于208(图2-16)。

图10-11中的m_pullup把头40字节复制到一个单独的mbuf中，如图2-18所示。

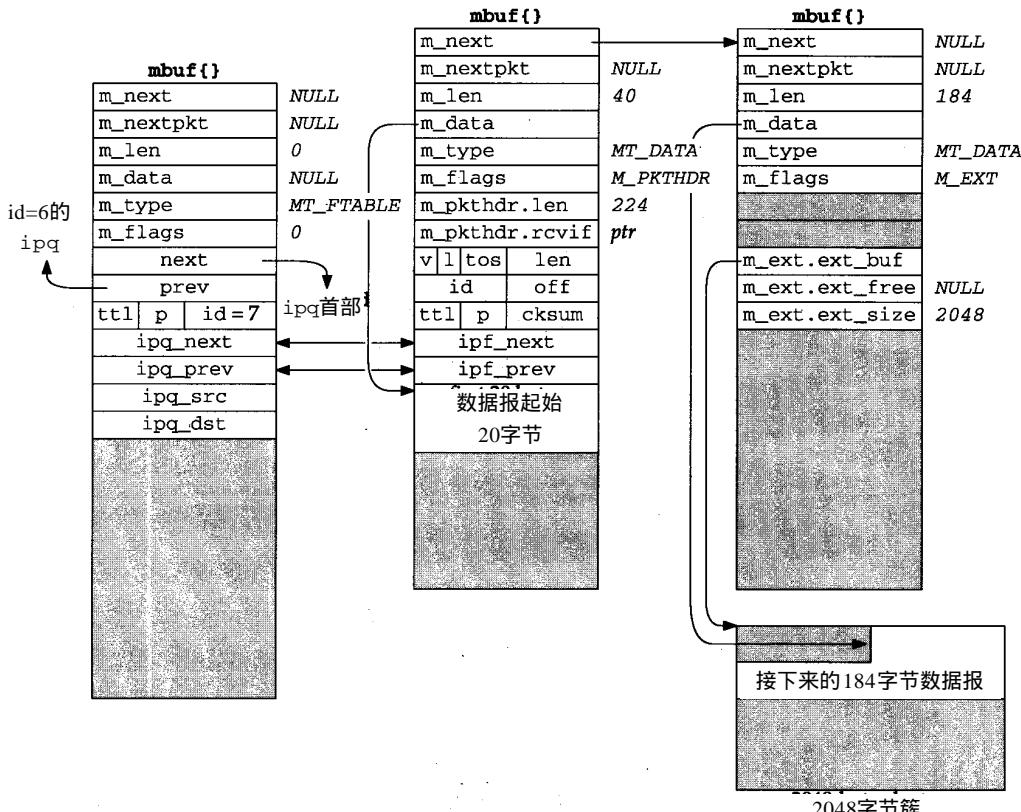


图 A-3

10.5 平均每个数据报收到的分片数等于

$$\frac{72786-349}{16557} = 4.4$$

平均每个输出数据报新建的平均分片数等于

$$\frac{796084}{260484} = 3.1$$

10.6 图10-11中，数据报最初被做为分片处理。当 `ip_offset` 左移时，保留的比特位被丢弃。得到的数据报被视为分片或一个完整的数据报，取决于 MF和分片偏移量的值。

第11章

- 11.1 输出响应使用收到请求的接口的源地址。主机可能无法辩识 0.0.0.0 是一个有效的广播地址，因此，有可能忽略请求。推荐的广播地址等于 255.255.255.255。
- 11.2 假定主机发送了一个链路层的广播数据报，其源 IP 地址是另一台主机的地址，且数据报有差错，如内容差错的选项。所有主机都能接收并检测出差错，因为这是一个链路层的广播报文，而且选项的处理先于最终目的地的检测。许多发现差错的主机向数据报的源 IP 地址发送 ICMP 报文，即使原数据报属于链路层广播。另一台主机将收到大量假的 ICMP 差错。这就是为什么不允许为链路层广播而发送 ICMP 差错报文。
- 11.3 第一个例子中，这种重定向报文不会诱骗主机向另一个子网中的某个主机发送报文段。这台主机可能被误认为是路由器，但它确实记录收到的流量。RFC 1009 规定路由器只能向位于同一个子网的其他路由器发送重定向报文。即使主机忽略了这些要求把数据报转发到另一个子网的报文段，但如果报文段发送者与主机处于同一个子网中，它们就会被接受。第二个例子，为了防止出现上述现象，要求主机只接受它（错误地）选定的原始路由器的重定向报文，即假定这个错误的路由器是管理员指定的默认路由器。
- 11.4 通过向 `rip_input` 传递报文段，进程级的守护程序能够正确响应，一些依赖于这种行为的老系统能够继续得到支持。
- 11.5 ICMP 差错只针对 IP 数据报的第一个分片。因为第一个分片的偏移量值必等于 0，字段的字节表示顺序是无关紧要的。
- 11.6 如果收到 ICMP 请求的接口还未配置 IP 地址，则 `ia` 将为空，且不生成响应。
- 11.7 Net/3 处理与时间戳响应一起到达的数据。
- 11.10 高位比特被保留，并必须设为 0。如果它必须被发送，则 `icmp_error` 将丢弃数据报。
- 11.11 返回值被丢弃，因为 `icmp_send` 不返回差错。更重要的是，ICMP 报文处理过程中生成的差错将被丢弃，以避免进入死循环，不断生成差错报文。

第12章

- 12.1 在太网中，IP 广播地址 255.255.255.255 转换为以太网的广播地址 ff:ff:ff:ff:ff:ff，网络中的所有以太网接口都会接收这样的数据帧。没有运行 IP 软件的系统必须主动接

收并丢弃这种广播报文。

数据报需发送给多播组 224.0.0.1 中的所有主机，转换后的以太网多播地址为 01:00:5e:00:00:01，只有明确要求其接口接收 IP 多播报文的系统才会收到它。没有运行 IP 或者在链路层不兼容的系统不会收到这些报文段，因为以太网接口的硬件已直接丢弃了这些报文段。

- 12.2 一种替代方案是通过文本名规定接口，如同 `ifreq` 结构和 `ioctl` 命令存取接口信息采取的方式一样。`ip_setmoptions` 和 `ip_getmoptions` 可以调用 `ifunit`，取代 `INADDR_TO_IFP`，寻找指向接口 `ifnet` 结构的指针。
- 12.3 多播组高位 4 bit 通常为 1110，因此，只有 5 个有意义的比特被匹配函数丢弃。
- 12.4 完整的 `ip_moptions` 结构必须能放入单个 `mbuf` 中，从而限制结构最大只能等于 108 字节（记住 20 字节的 `mbuf` 首部）。`IP_MAX_MEMBERSHIPS` 可以大一些，但必须小于等于 $25(4+1+1+2+(4 \times 25)=108)$ 。
- 12.5 数据报重复，在 IP 输入队列中有两份复制的数据报。多播应用程序必须能识别并丢弃重复的数据报。
- 12.6

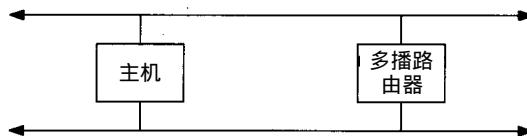


图 A-4

- 12.8 应用进程可以创建第二个插口，并通过第二个插口请求 `IP_MAX_MEMBERSHIPS`。
- 12.9 为 `mbuf` 首部的 `m_flags` 成员变量定义一个新的 `mbuf` 标志 `M_LOCAL`。`ip_output` 处理环回数据报时置位该标志，从而取代检验和。如果该标置位，`ipintr` 就跳过检验和验证。SunOS 5.X 提供完成此功能的选项 (`ip_local_cksum`，卷 1 的 531 页)。
- 12.10 存在 $2^{23} - 1$ (8 388 607) 个独立的以太网 IP 多播地址。记住保留的 IP 组 224.0.0.0。
- 12.11 这个假设正确，因为 `in_addmulti` 拒绝所有新增请求，如果接口没有调用 `ioctl` 函数，说明如果 `if_ioctl` 为空，则永不会调用 `in_delmulti`。
- 12.12 `mbuf` 永远不会被释放，说明 `ip_getmoptions` 包含了一个存储器泄露。
`ip_getmoptions` 由 `ip_ctloutput` 调用，调用语句如下：
`ip_getmoptions(IP_ADD_MEMBERSHIP, 0, mp)`

会引发 `ip_getmoptions` 中的一个差错。

第13章

- 13.1 要求环回接口响应 ICMP 请求是没有必要的，因为本地主机是环回网络中唯一的系统，它已经知道自己的成员状态。
- 13.2 `max_linkhdr + sizeof(struct ip) + IGMP_MINLEN = 16 + 20 + 8 = 44 < 100`
- 13.3 报告成员状态时出现随机延迟的主要原因是为了最大限度地减少出现在多播网络中的报告数（理想情况下应等于 1）。一个点到点网络只包括两个接口，因此，无需延迟

以减少响应的数量。一个接口(假定是一个多播路由器)发出请求，另一个接口响应。另一个原因是避免过多的成员状态报告淹没接口的输出队列。大量IGMP成员状态报文可能会超出输出队列关于数据报和字节的限制。例如，在SLIP驱动程序中，如果输出队列已满或设备过忙，就会丢弃队列中所有等待的数据报(图5-16)。

第14章

- 14.1 5个，分别对应网络A~E。
- 14.2 `grp1st_member`只被`ip_mforward`调用，但在协议处理过程中，`ip_mforward`又将被`ipintr`或者`ip_output`调用，`ip_output`可以由插口层间接调用。缓存是一个共享数据区，在更新时必须加以保护。`add_lgrp`和`del_lgrp`在更新成员列表时，通过`splx`保护此共享数据结构。
- 14.3 SIOCDELMULTI命令只影响以太网接口的多播列表，不改变IP多播组列表，因此，接口仍然保留为组中成员。只要依旧是接口IP组列表中的一员，接口将继续接收属于该组的多播数据报。
- 14.4 只有虚接口才能成为多播树的父接口。如果分组在隧道上接收，那么对应的物理接口不可能成为父接口，`ip_mforward`丢弃分组。

第15章

- 15.1 插口可以在分支上共享，或通过UNIX域插口传给应用进程([Stevens])。
- 15.2 `accept`返回后，结构的`sa_len`成员大于缓存大小。对固定长度的Internet地址而言，这不是问题，但它有可能用于可变长度的地址，例如OSI协议支持的地址格式。
- 15.4 只有`so_qlen`不等于0时，才会调用`soqremque`。如果`soqremque`返回一个空指针，说明插口队列代码必然出现了内核无法处理的问题。
- 15.5 复制的目的在于结构锁定时仍可调用`bzero`清零，并可在`splx`后接着调用`dom Dispose`和`sbrealse`，从而最大程度地减少了CPU停留在`splimp`的时间，即网络中断被阻塞的时间。
- 15.6 宏`sbspace`返回0，从而`sbappendaddr`和`sbappendcontrol`函数(由UDP调用)将拒绝向队列添加新报文段。TCP调用`sbappend`，后者假定调用者已事先检查过可用空间。即使`sbspace`返回0，TCP也会调用`sbappend`，但放入接收队列中的数据还不能提交给应用进程，因为`SS_CANTRCVMORE`标志阻止`read`系统调用返回任何数据。

第16章

- 16.1 如果给`uio_resid`赋值，它将成为一个大负数。`sosend`拒绝带有`EINVAL`的报文段。
Net/2不检查负值，`sosend`起始处的注释说明了这个问题(图16-23)。
- 16.2 不。向簇中填充的字节数少于`MCLBYTES`只可能出现在报文段尾部，此时剩余的字节数小于`MCLBYTES`。此时，`resid`等于0，循环在394行`break`语句处终止，还未

到达测试条件 `spce>0`。

- 16.5 应用进程阻塞，直到缓存解锁。本例中，只有在另一个进程检查缓存或向协议层传送数据时，缓存才会被锁定；而在应用进程等待缓存可用空间时不会加锁，后者有可能等待无限长的时间。
- 16.6 如果发送缓存包括许多 mbuf，每个都包括若干字节的数据，那么当 mbuf 分配大块存储器时，`sb_cc`很可能大大低于 `sb_hiwat` 规定的限制。如果内核不限制每个缓存可拥有的 mbuf 的数量，应用进程就能轻易地造成存储器枯竭。
- 16.7 `recvit` 分别由 `recvfrom` 和 `recvmsg` 调用。只有 `recvmsg` 处理控制信息。它把完整的 `msghdr` 结构，包括控制信息长度，复制给应用进程。至于地址信息，`recvmsg` 把 `namelenp` 参数设为空，因为它可从 `msg_namelen` 中得到所需长度。当 `recvfrom` 调用 `recvit` 时，`namelenp` 非空，因为函数需要从 `*namelenp` 中得到所需长度。
- 16.8 `MSG_EOR` 由 `soreceive` 清除，因此，它不可能在 `M_EOR` mbuf 被处理前，被 `soreceive` 返回。
- 16.9 `select` 检查描述符时，实际上存在一种竞争。如果某个选定事件发生在 `selscan` 查看描述符之后，但在 `select` 调用 `tsleep` 之前，该事件不会被发现，应用进程将保持睡眠状态，直到下一个选定事件发生。

第17章

- 17.1 简化在内核和应用进程间复制数据的代码。`copyin` 和 `copyout` 可用于单个的 mbuf，但需要 `uiomove` 处理多个 mbuf。
- 17.2 代码工作正确，因为 `linger` 结构的第一个成员是所要求的整数标志。

第18章

- 18.1 做一个 8 行的表格，每行对应一种查找键、路由表键和路由表掩码中比特的组合方式：

行	1 查找键	2 路由表键	3 路由表掩码	1 & 3	2 == 4?	1 ^ 2	6 & 3
1	0	0	0	0	是	0	0=是
2	0	0	1	0	是	0	0=是
3	0	1	0	0	否	1	0=是
4	0	1	1	0	否	1	1=否
5	1	0	0	0	是	1	0=是
6	1	0	1	1	否	1	1=否
7	1	1	0	0	否	0	0=是
8	1	1	1	1	是	0	0=是

图 A-5

标注为“`2 == 4 ?`”和标注为“`6 & 3`”的两栏，值应相等。第一眼看上去，似乎并不完全相同，但我们可以略过第 3 行和第 7 行，因为这两行中路由表比特等于 1，而

在路由表掩码中的对应比特也等于 1。构建路由表时，键值与掩码逻辑与，保证掩码中的等于 0 每一比特位，键值中的对应比特位也等于 0。

可以从另一个角度理解图 18-40 中的异或和逻辑与操作，异或结果等于 1 的条件是查找键比特不同于路由表键值中对应的比特位。之后的逻辑与操作忽略所有与掩码中等于 0 的比特相对应的比特。如果结果依然非零，则查找键与路由表键值不匹配。

- 18.2 `rtentry` 结构的大小等于 120 字节，其中包括两个 `radix_node` 结构。每条记录还要求两个 `sockaddr_in` 结构(图18-28)，有 152 字节。总数约为 3 兆字节。
- 18.3 因为 `rn_b` 是一个短整数，假定短整数占 16 bit，因此，每个键值最多有 32767 bit(4095 字节)。

第19章

- 19.1 图19-15 中，如果重定向报文创建了新的路由，将置位 `RTF_DYNAMIC` 标志；如果重定向报文修改了现有路由的网关字段，则置位 `RTF_MODIFIED` 标志。如果重定向报文新建了一条路由，之后另一个重定向报文又修改了它，则两个标志都会置位。
- 19.2 在每个可通过默认路由到达的主机上创建一条主机路由。TCP 能够对每个主机维护并更新路由矩阵(图27-3)。
- 19.3 每个 `rt_msghdr` 结构需要 76 字节。主机路由中包括还两个 `sockaddr_in` 结构(目的地和网关)，因此，报文段大小为 108 字节。每条 ARP 记录的报文段为 112 字节：一个 `sockaddr_in` 和一个 `sockaddr_dl`。总长度等于 $(15 \times 112 + 20 \times 108)$ 即 3840 字节。一条网络路由(非主机路由)还需要另外的 8 个字节存放网络掩码(数据大小等于 116 字节，而非 108 字节)，因此，如果 20 条路由全部为网络路由，总长度等于 4000 字节。

第20章

- 20.1 返回值放入报文段的 `rtm_errno` 成员变量中(图20-14)，同时也做为 `write` 的返回值(图20-22)。后者更可靠，因为前者可能会因为 mbuf 短缺，而丢弃响应报文段(图 20-17)。
- 20.2 对 `SOCK_RAW` 型的插口，`pffindproto` 函数(图7-20)将返回协议值等于 0(通配)的记录，如果没有找到可匹配的记录。

第21章

- 21.1 它基于假定 `ifnet` 结构位于 `arpcom` 的开头，事实也是如此(图3-20)。
- 21.2 发送 ICMP 的回显请求不需要 ARP，因为目的地址是广播地址。但 ICMP 的回显响应一般都是点对点的，因此，发送者必须通过 ARP 确定目的以太网地址。本地主机收到 ARP 请求时，`in_arpinput` 应答并为另一主机创建一条记录。
- 21.3 如果创建了一条新的 ARP 记录，图 19-8 中的 `rtrequest` 从源记录中复制 `rt_gateway` 值，本例中为 `sockaddr_dl` 结构。图 21-1 中，我们看到该记录的 `sdl_alen` 值等于 0。
- 21.4 Net/3 中，如果 `arpresolve` 的调用者提供了指向路由表表项的指针，则不会再调用 `arplookup`，通过 `rt_gateway` 指针可得到所需的以太网地址(假定它还未超

时)。这样可以避免通常意义上的任何类型的查询。第 22 章中，我们将看到 TCP 和 UDP 在自己的协议控制块中保存指向路由表的指针，TCP 不再需要搜索路由表(连接的目的 IP 地址不会变化)，在目的地址不变时 UDP 也不需这样做。

- 21.5 如果 ARP 记录不完整，则它在记录创建后 0~5 分钟超时。arpresolve 发送 ARP 请求时，令 `rt_expire` 等于当前时间。下一次执行 arpresolve 时，如果记录还没有解析，则删除它。
- 21.6 ether_output 返回 EHOSTUNREACH，而非 EHOSTDOWN，从而 ip_forward 将发送 ICMP 主机不可达差错报文。
- 21.7 图 21-28 中，为 140.252.13.35 创建记录时，值等于当前时间。它不会改变。140.252.13.33 和 140.252.13.34 记录的值复制自 140.252.13.32，因为 rtrequest 根据 140.252.13.32 复制前两条记录。之后，arpresolve 发送 ARP 请求时，把这两条记录的值更新为当前时间，最后由 in_arpinput 将其更新为收到 ARP 响应的时间加上 20 分钟。
- 21.8 修改图 21-19 开始处的 arplookup，第二个参数永远等于 1(创建标志)。
- 21.9 在下一秒的后半秒发送第一个数据报。因此，第一个和第二个数据报都会导致发送 ARP 请求，间隔约为 500 ms，因为内核的 `time.tv_sec` 变量在这两个数据报发送时的值不同。
- 21.10 每个待发送的数据报都是一个 mbuf 链，`m_nextpkt` 指针指向每个链的第一个 mbuf，用于构成等待传输的 mbuf 链表。

第 22 章

- 22.1 无限循环等待某个端口变为可用，假定允许应用进程打开足够多的描述符，绑定所有临时端口。
- 22.2 极少有服务器支持此选项。[Cheswick 和 Bellovin 1994] 提到为什么它可用于实现防火墙系统。
- 22.4 udb 结构初始化为 0，因此，`udb.inp_lport` 从 0 开始。第一次调用 `ip_pcbbin` 时，它增加为 1，因为小于 1024，所以被设定为 1024。
- 22.5 一般情况下，调用者把地址族 (`sa_family`) 设为 AF_INET，但我们在图 22-20 的注释中看到，最好不进行关于地址族的测试。调用者设定长度变量 (`sa_len`)，但我们在图 15-20 中看到，函数 `sockargs` 将其做为 `bind` 的第 3 个参数，对于 `sockaddr_in` 结构，应等于 16，通常都使用 C 的 `sizeof` 操作符。
本地 IP 地址 (`sin_addr`) 可以指明为通配地址或某个本地 IP 地址。本地端口号 (`sin_port`)，可以等于 0(告诉内核选择一个临时端口) 或非 0，如果应用进程希望指明端口号。通常情况下，TCP 或 UDP 服务器指明一个通配 IP 地址，端口号等于 0。
- 22.6 应用进程可以 `bind` 一个本地广播地址，因为 `ifa_ifwithaddr`(图 22-22) 的调用成功。它被用做在该接口上发送的 IP 数据报的源地址。C.2 节中指出，RFC 1122 不允许这种做法。但试图绑定 255.255.255.255 时会失败，因为 `ifa_ifwithaddr` 不接受该地址。

第23章

- 23.1 `sosend` 把用户数据放入单个的 mbuf 中，如果其长度小于等于 100 字节；放入两个 mbuf 中，如果长度小于等于 207 字节；否则，放入多个 mbuf 中，每个都带有一个簇。此外，如果长度小于 100 字节，`sosend` 调用 `MH_ALIGN`，希望能在 mbuf 起始处为协议首部保留空间。因为 `udp_output` 调用 `M_PREPEND`，下述 5 种情况都是可能的：
(1) 如果用户数据长度小于等于 72 字节，一个 mbuf 就可以存放 IP 首部、UDP 首部和数据；
(2) 如果长度位于 73 字节和 100 字节之间，`sosend` 为用户数据分配一个 mbuf，`M_PERPEND` 为 IP 和 TCP 首部再分配一个 mbuf；
(3) 如果长度位于 101 字节和 207 字节之间，`sosend` 为用户数据分配两个 mbuf，`M_PREPEND` 为 IP 和 TCP 首部再分配一个 mbuf；
(4) 如果长度位于 208 字节和 `MCLBYTES` 之间，`sosend` 为用户数据分配一个带簇的 mbuf，`M_PERPEND` 为 IP 和 TCP 首部再分配一个 mbuf；
(5) 如果长度超出，则 `sosend` 分配足够多的 mbuf 和簇，以存放数据（最大数据长度 65507 字节，需分配 64 个带 1024 字节簇的 mbuf），`M_PERPEND` 为 IP 和 TCP 首部再分配一个 mbuf。
- 23.2 IP 选项提交给 `ip_output`，后者调用 `ip_insertoptions` 在输出 IP 数据报中插入 IP 选项。它接着分配一个新的 mbuf，存放带有 IP 选项的 IP 首部，如果第一个 mbuf 指向一个簇（UDP 输出不可能出现这种情况），或者第一个 mbuf 中没有足够的剩余空间存放新增选项。上个习题中给出的第一种情况下，选项大小将决定 `ip_insertoptions` 是否分配另一个 mbuf：如果用户数据长度小于 `100 - 28 - optlen`（IP 选项占用的字节数），说明 mbuf 足够存放 IP 首部、IP 选项、UDP 首部和数据。
第 2、3、4 和 5 种情况下，第一个 mbuf 都由 `M_PREPEND` 分配，只存放 IP 和 UDP 首部。`M_PREPEND` 调用 `M_PREPEND`，接着调用 `MH_ALIGN`，把 28 字节的首部移到 mbuf 尾部，因此，第一个 mbuf 中必定有空间存放最大为 40 字节的 IP 选项。
- 23.3 不。函数 `in_pcbconnect` 只有在应用程序调用 `connect`，或者在一个未连接的 UDP 插口上发送第一个数据报时，才会被调用。因为本地地址是通配地址，本地端口号等于 0，所以 `in_pcbconnect` 给本地端口号赋一个临时端口（通过调用 `in_pcbbind`），并根据到达目的地的路由设定本地地址。
- 23.4 处理器优先级仍为 `splnet` 不变，没有还原为初始值，这是代码的一个差错。
- 23.5 不。`in_pcbconnect` 不允许与等于 0 的端口建立连接。即使应用进程没有直接调用 `connect`，也会间接地执行 `connect`，因此，`in_pcbconnect` 总会被调用。
- 23.6 应用程序必须调用 `ioctl`，命令为 `SIOCGIFCONF`，返回所有已配置的 IP 接口信息。之后，在 `ioctl` 返回的所有 IP 地址和广播地址中寻找接收数据报中的目的地址（也可不用 `ioctl`，19.14 节中介绍的 `sysctl` 系统调用也能够返回所有配置接口的信息）。
- 23.7 `recvit` 释放带有控制信息的 mbuf。
- 23.8 为了断开一个已建立连接的 UDP 插口，调用 `connect`，传递一个无效的地址参数，如 0.0.0.0，端口号等于 0。因为插口已经建立了连接，`soconnect` 调用 `sodisconnect`，后者调用 `udp_usrreq`，发送 `PRU_DISCONNECT` 请求，令远端地址等于 0.0.0.0，远端端口号等于 0。这样，接下来调用 `sendto` 时可以指明目的地。

址。由于指明地址无效，`sodisconnect`发送的PRU_CONNECT请求失败。实际上，我们不希望`connect`成功，只是要执行PRU_DISCONNECT请求，而且通过`connect`来执行这一请求的做法是唯一可行的方案，因为插口API没有提供`disconnect`函数。

手册中关于`connect(2)`的描述通常包括下述说明：“可通过把数据报插口连接到一个无效地址，如空地址，来断开其当前连接。”但没有明确指出调用`connect`时，如果传送的地址无效，会返回一个差错。“空地址”的含义也易造成混淆，它指IP地址0.0.0.0，而非`bind`的第二个参数的空指针。

- 23.9 因为`in_pcbbind`能够建立UDP插口与远端IP地址间的临时连接，情况与应用进程调用`connect`类似：如果某接口的目的IP地址与该接口的广播地址对应，则从该接口发送数据报。
- 23.10 服务器必须设定`IP_RECVDSTADDR`插口选项，并调用`recvmsg`从客户请求中获取目的IP地址。为了成为响应报文段中的源地址，必须将其绑定在插口上。由于一个插口只能`bind`一次，服务器每次响应时都必须创建新的插口。
- 23.11 注意，`ip_output`(图8-22)中，IP不修改调用者传递的DF比特。需要定义新的插口选项，促使`udp_output`在把数据报传递给IP之前，设定DF比特。
- 23.12 不。它只被`udp_input`使用，且应为该函数的局部变量。

第24章

- 24.1 状态为ESTABLISHED的连接总数为126 820。除以发送和接收的总字节数，得到每个方向上的平均字节数，约为30 000字节。
- 24.2 `tcp_output`中，保存IP和TCP首部的`mbuf`还有空间容纳链路层首部(`max_linkhdr`)。试图通过`bcopy`把IP和TCP首部原型复制到`mbuf`中是行不通的，因为有可能会把40字节的首部分散在两个`mbuf`中。尽管40字节的首部必须放入单个`mbuf`中，但链路层首部不存在这样的限制。不过这样做会降低性能，因为后续处理不得不为链路层首部再次分配`mbuf`。
- 24.3 在作者的bsdi系统中，计数器等于16，其中15个是标准系统守护程序(Telnet、Rlogin、FTP，等等)。而vangogh.cs.berkeley.edu系统，一个约有20个用户的中等规模的多用户系统，计数器约为60。对于大型的带有150个用户的多用户系统(world.std.com)，则有417个TCP端点和809个UDP端点。

第25章

- 25.1 图24-5中，2 592 000秒(30天)中出现了531 285次延迟ACK，平均每5秒钟有一次延迟ACK，或者说每25次调用`tcp_fasttimo`，才会有一次延迟ACK。这说明在代码检查所有TCP控制块，判定延迟ACK标志是否置位时，96%(25次中有24次)的时间都未置位。对于习题24.3中给出的大型的多用户系统，意味着需查看超过400个的TCP控制块，每秒钟查询5次。
另一种解决方案是在需要延迟ACK时，设定全局标志。只有当全局标志置位时，才检查控制块列表。或者为需要延迟ACK的控制块单独建立并维护一个列表。例如，

图13-14中的变量igmp_timers_are_running。

- 25.2 这样使得变量tcp_keepintvl绑定在运行中的内核上，下次调用tcp_slowtimo时，内核可以改变tcp_maxidle的值。
- 25.3 t_idle中保存的实际上是从最后一次接收或发送报文段后算起的时间。因为TCP的输出必须被对端确认，与收到数据报文段相同，收到ACK也将清零t_idle。
- 25.4 图A-6给出代码的一种可能的重写方式。

```
case TCPT_2MSL:
    if (tp->t_state == TCPS_TIME_WAIT)
        tp = tcp_close(tp);
    else {
        if (tp->t_idle <= tcp_maxidle)
            tp->t_timer[TCPT_2MSL] = tcp_keepintvl;
        else
            tp = tcp_close(tp);
    }
break;
```

图 A-6

- 25.5 如果收到了重复的ACK，t_idle等于150，但被复位为0。FIN_WAIT_2时钟超时后，t_idle将等于1048(1198-150)，因此，定时器被设定为150个滴答。定时器再次超时，t_idle应等于1198+150，导致连接被关闭。重复ACK令时间延长，直到连接被关闭。
- 25.6 第一次连接探测报文段将在1小时后发送。应用进程设定该选项时，实际只置位了socket结构中的SO_KEEPALIVE选项。由于设定了该选项，定时器将于1小时后超时，图25-15中的代码将发送第一次连接探测报文段。
- 25.7 tcp_rttdflt用于为每条TCP连接初始化RTT估计器的值。如果需要，主机可通过更改全局变量，改变默认设置。如果通过#define将其定义为常量，则只有通过重新编译内核文件才能改变默认值。

第26章

- 26.1 事实上，TCP并没有刻意计算从连接上最后一次发送报文段算起的时间，因为连接上的计时器t_idle一直在起作用。
- 26.2 图25-26中，snd_nxt被设定为snd_una，len等于0。
- 26.3 如果运行Net/3系统，但对端主机却无法处理某个新选项（例如，对端拒绝建立连接，即使被要求忽略无法辨识的选项）。遇到这种情况时，通过在内核中改变这个全局变量的值，可以禁止某一个或两个选项。
- 26.4 时间戳选项能够在每次收到对新数据的ACK时，更新RTT估计器值。因此，使用时间戳选项后，RTT估计器值将被更新16次，是不使用该选项时更新次数的两倍。注意，在时刻217.944时，收到了对6145的ACK，RTT估计器值被更新，但这个新的计算值并不准确——或者是在时刻3.740发送的携带5633~6144字节的数据段，或者是收到的对6145的ACK，在网络中延迟了200秒。
- 26.5 这种存储器引用时，无法确保2字节的MSS值能够正确地对齐。

- 26.6 (该解决方案来自于 Dave Borman)一个数据段能够携带的 TCP数据量的最大值为 65495字节，即65535减去IP和TCP首部的最小值(40)。因此，紧急数据偏移量可取值范围中有39个值是无意义的：65496~65535，包括65535。无论何时，只要发送方得到一个超过65495的紧急数据偏移量，则将其替换为65535，并置位URG标志。从而迫使接收方进入紧急模式，并告知接收方紧急数据偏移量所指向的数据尚未被发送。发送方将持续发送紧急数据偏移量等于65535、且URG标志置位的数据报文段，直到紧急数据偏移量小于等于65495，说明真正的紧急数据偏移量的开始。
- 26.7 我们提到，数据段的传输是可靠的(重传机制)，而ACK则有可能丢失。RST报文段的传输同样也是不可靠的。如果连接上收到了一个假报文段(例如，不属于本连接的报文段，或者一个不属于任何连接的报文段)，则传送RST报文段。如果RST报文段被`ip_output`丢弃，当对端重传导致发送RST报文段的数据报文段时，将再次生成RST报文段。
- 26.8 应用程序执行了8次写入1024字节的操作。头4次调用`sosend`时，`tcp_output`被调用，报文段被发送。因为这4个报文段都包含了发送缓存中最后一个字节的数据，每个报文段的PSH标志都置位(图26-25)。第二个缓存装满后，应用进程进行下一次写操作，调用`sosend`时被挂起。收到对端通告窗口大小等于0的ACK后，丢弃发送缓存中已被确认的4096字节的数据，应用进程被唤醒，又连续执行了4次写操作，发送缓存再次被填满。但只有当接收方通告窗口大小不等于0时，才能继续发送数据。条件满足时，接下来的4个报文段被发送，但只有最后一个报文段的PSH标志置位，因为前3个报文段并未清空发送缓存。
- 26.9 如果正在发送的报文段不属于任何连接，传给`tcp_respond`的`tp`参数可以是空指针。代码只有在指针为空时，才会查看`tp`，并代之以默认值。
- 26.10 `tcp_output`通常调用`MGETHDR`，分配一个仅能容纳IP和TCP首部的mbuf，参见图26-25和图26-26。在新的mbuf的前部，代码只预留了链路层首部(`max_linkhdr`)大小的空间。如果使用了IP选项，而且选项的大小超过了`max_linkhdr`，`ip_insertoptions`会自动分配另一个mbuf。但如果IP选项的大小小于等于`max_linkhdr`，则`ip_insertoptions`也会占用mbuf首部的空间，从而导致`ether_output`仅为链路层首部分配另一个mbuf(假定以太网输出)。为了避免多余的mbuf，图26-25和图26-26中的代码，可以在报文段中携带IP选项时调用`MH_ALIGN`。
- 26.11 约有80行代码，假定采用了RFC 1323中的时间戳选项，且报文段被计时。宏`MGETHDR`调用了宏`MALLOC`，后者可能调用函数`malloc`。函数`m_copy`也会被调用，但一个完整大小的报文段可能需要一个簇，因此，不复制mbuf，而是保存一个对簇的引用。`m_copy`中调用`MGET`，可能会导致对`malloc`的调用。函数`bcopy`复制模板，而`in_cksum`计算TCP的检验和。
- 26.12 调用`writev`没有区别，因为处理逻辑由`sosend`实现。因为数据大小等于150字节，小于`MINCLSIZE`(208)，所以为头100个字节分配了一个mbuf。并且因为协议支持数据的分段，`PRU_SEND`请求被发送。接着为剩余的50字节再分配一个mbuf，并发送相应的`PRU_SEND`请求(对于`PR_ATOMIC`协议，如`UDP`，`writev`只

生成一条“记录”，即只发送一个PRU_SEND请求。）

如果两个缓存的长度分别等于200和300，总长度超过了MINCLSIZE，则分配一个mbuf簇，且只发送一次PRU_SEND请求。TCP只生成一个500字节的报文段。

第27章

- 27.1 表中前6行记录的差错，都是由于接收报文段或者定时器超时引起的异步差错。通过在so_error中保存非零的差错代码，应用进程能够在下一次读/写操作中收到差错信息。但如果调用来自tcp_disconnect，说明应用进程调用了close，或者应用进程终止时系统自动关闭其所拥有的描述符。无论是哪一种情况，描述符被关闭，应用进程不可能再通过读/写操作来获取差错代码。此外，因为应用进程必须明确设定插口选项，强迫RST置位，此时返回一个差错代码并不能向应用进程提供有用的信息。
- 27.2 假定它是32 bit的u_long，最大值小于4298秒(1.2小时)。
- 27.3 路由表中的统计数据由tcp_close更新，但只有当连接进入CLOSED状态时，它才会被调用。因为FTP客户终止向对端发送数据（执行主动关闭），本地连接端点进入TIME_WAIT状态。必须经过2MSL后，路由表统计值才会被更新。

第28章

- 28.1 0、1、2和3。
- 28.2 34.9Mb/s。对于更高的速率，连接两端需要更大的缓存。
- 28.3 通常，tcp_dooption不知道两个时间戳值是否按32 bit边界对齐。图28-4中的代码，在指定情况下，能够确认时间戳值按32 bit边界对齐，从而避免调用bcopy。
- 28.4 图28-4中实现“选项预测”代码，只能处理系统推荐的格式。如果连接对端未采用系统推荐的格式，会导致为每个接收到的报文段调用tcp_dooptions，降低了处理速度。
- 28.5 如果在每次创建插口时，而非每次连接建立时，调用tcp_template，则系统中的每个监听服务器都会拥有一个tcp_template，而该结构可能永远不会被使用。
- 28.6 时间戳时钟频率应该在1 b/ms 和1 b/s之间(Net/3采用了2 b/s)。如果采用最高的时钟频率1 b/ms，32 bit的时间戳将在 $2^{31} / (24 \times 60 \times 60 \times 1000)$ 天，即24.8天后发生符号位回绕。
- 28.7 如果频率为每500 ms 1 bit，32 bit的时间戳将在 $2^{31} / (24 \times 60 \times 60 \times 2)$ 天，即12 427天，约34年后才会出现符号位回绕。
- 28.8 对RST报文段的处理应优先于时间戳，而且，RST报文段中最好不携带时间戳选项（图26-24中的tcp_input代码确保了这一点）。
- 28.9 因为客户端状态为ESTABLISHED，处理将在图28-24的代码处结束。todrop等于1，因为recv_nxt在收到第一个SYN时已递增过。SYN标志被清除（因为这是一个重复报文段），ti_seq递增，todrop减为0。因为todrop和ti_len都等于0，执行图28-25起始处的if语句，并跳过下一个if语句，直接调用m_adj。但下一章中介绍tcp_input后续代码时，将谈到在某些情况下不会调用tcp_output，本题即是一例。因此，客户端会不响应重复的SYN/ACK。服务器端超时后，再次发送SYN/ACK

(图28-17中介绍了某个被动打开的插口收到 SYN时，定时器的设置），这个重发的SYN/ACK报文段同样被忽略。我们现在讨论的其实是图 28-25代码中的另一个差错，图28-30中给出的代码同样也纠正了这一差错。

- 28.10 客户发出的SYN到达服务器，并被交给处于 TIME_WAIT状态的插口。图 28-24中的代码关闭SYN标志，图28-25中的代码跳转至`dropafterack`，丢弃该报文段，但生成一个 ACK，确认字段等于`rcv_nxt`(图26-27)。它被称作“再同步(resynchronization) ACK”报文段，因为其目的是告诉对端本地希望接收的下一序号。客户端收到此 ACK后(客户处于SYN_SENT状态)，发现它的确认字段所携带的序号不等于自己期待得到的序号后(图28-18)，向服务器发送RST报文段。RST报文段的ACK标志被清除，且序号等于再同步ACK报文段中确认字段携带的序号(图29-28)。服务器收到此RST报文段后，其TIME_WAIT状态提前终止，相应插口被关闭(图28-36)。客户端6秒钟后超时，重传SYN报文段。假定监听服务器进程在服务器主机上运转正常，新的连接将建立。由于TIME_WAIT状态的这种防护作用，新连接建立时，下一个SYN报文段携带的序号既可以高于前一连接上最后收到的序号(图28-28中的测试)，也可以低于该序号。

第29章

- 29.1 假定RTT等于2秒钟。服务器被动打开，客户端在时刻 0主动打开。服务器在时刻 1收到客户发出的SYN，并作出响应，发送自己的SYN和对客户SYN的ACK。客户端在时刻 2收到服务器的响应报文段，图 28-20中的代码调用`soisconnected`(唤醒客户进程)，完成主动打开过程，并向服务器发送ACK响应。服务器在时刻 3收到客户的ACK，图29-2中的代码完成服务器端的被动打开过程，控制返回给服务器进程。一般情况下，客户进程比服务器进程提早 1/2 RTT时间得到控制。
- 29.2 假定SYN的序号等于 1000，50字节数据的序号等于 1001~1050。`tcp_input`处理此SYN报文段时，首先执行图28-15中的起始case语句，令`rcv_nxt`等于1001，接着跳到step6。图29-22中的代码调用`cp_reass`，把数据放入插口的重组队列中。但数据还不能放入插口的接收缓存(图27-23)，因此，`rcv_nxt`还是等于 1001。在调用`tcp_output`生成ACK响应时，`rcv_nxt` (1001)被放入ACK报文段的确认字段。也就是说，SYN被确认，但与之同时到达的50字节的数据没有被确认。因此，客户端不得不重发50字节的数据，所以，在完成主动打开的SYN报文段中携带数据是没有意义的。
- 29.3 客户端的ACK/FIN报文段到达时，服务器处于 SYN_RCVD状态，因此，图 29-2中的`tcp_input`代码将结束对 ACK的处理。连接转移到 ESTABLISHED状态，`tcp_reass`把已在重组队列中的数据放入接收缓存，`rcv_nxt`递增为 1051。`tcp_input`继续执行，图29-24中的代码负责处理FIN标志，此时`TF_ACKNOW`标志置位，`rcv_nxt`等于1052。`socantrcvmove`设定插口的状态，使服务器在读取50字节的数据之后，得到“文件结束”指示。服务器的插口也转移到CLOSE_WAIT状态。调用`tcp_output`，确认客户端的FIN(因为`rcv_nxt`等于1052)。假定服务器进程在收到“文件结束”指示后，关闭其插口，服务器也将向

客户发送FIN，并等待回应。

在这个例子中，这了从客户端向服务器传送50字节的数据，双方需3个来回，共发送6个报文段。为了减少所需的报文段数，应采用“用于交易的TCP扩展[Braden 1994]”。

- 29.4 收到服务器响应时，客户插口处于 SYN_SENT状态。图28-20中的代码处理该报文段，连接转移到ESTABLISHED状态，控制跳转到step6，由图29-22中的代码继续处理数据。TCP_REASS把数据添加到插口的接收缓存，并递增 `rcv_nxt`。之后，图29-24中的代码开始处理FIN，再次递增 `rcv_nxt`，连接转移到CLOSE_WAIT状态。在调用 `tcp_output` 时，`rcv_nxt` 同时确认了SYN、50字节的数据和FIN。随后的客户进程首先读取50字节的数据，接着是“文件结束”指示，并可能关闭其插口。客户端连接进入 LAST_ACK状态，向服务器发送FIN报文段，并等待其响应报文段。
- 29.5 问题出在图24-16中的 `tcp_outflags[TCPS_CLOSING]`。它设定了 `TH_FIN` 标志，而状态变迁图(图24-15)并未规定 FIN应被重传。解决问题的方法是，从该状态的 `tcp_outflags` 中除去 `TH_FIN` 标志。这个问题没有什么危害——只不过多交换两个报文段——而且同时关闭或者在关闭后紧接着自连接的情况是非常罕见的。
- 29.6 没有。系统调用 `write` 返回OK，只说明数据已复制到插口的缓存中。在数据得到对端确认时，Net/3不再通知应用进程。如果需要得到此类信息，应设计并实现应用级的确认机制。
- 29.7 RFC 1323的时间戳选项，造成“首部压缩”失效。因为只要时间戳变化，即 TCP选项发生了改变，报文段发送时就不会被压缩。窗口大小选项无效，因为 TCP首部中值的长度仍为16 bit。
- 29.8 IP 中ID字段的取值来自一个全局变量，只要发送一个IP数据报，该变量递增一次。这种方式导致在同一 TCP连接上两个连续TCP报文段间的ID差值大于1的可能性大大增加。一旦ID差值大于1，图29-34中的 `ipid` 字段将被发送，增大了压缩首部的大小。一个更好的解决方案是，TCP自己维护一个计数器，用于ID的赋值。

第30章

- 30.2 是的，仍会发送RST报文段。应用进程终止的处理中包括关闭它打开的所有描述符。同一个函数(`soclose`)最终会被调用，无论是应用进程明确地关闭了插口描述符，还是隐含地进行了关闭(首先被终止)。
- 30.3 不。这个常量只有在监听插口设定 `SO_LINGER` 选项，且延迟时间等于0时，才会被用到。正常情况下，插口选项的这种设定方式会导致在连接关闭时发送 RST报文段(图30-12)，但图30-2中对于接收连接请求的监听插口，把该值从0改为120(滴答)。
- 30.4 如果这是第一次使用默认路由，则为两次；否则为一次。当创建插口时，`in_pcbaalloc` 将Internet PCB置为0，从而将PCB结构中的 `route` 结构设为0。发送第一个报文段(SYN)时，`tcp_output` 调用 `ip_output`。因为 `ro_rt` 指针为空，因此向 `ro_dst` 填充IP数据报的目的地址，并调用 `rtalloc`。在该连接的PCB中，`route` 结构的 `ro_rt` 变量中保存默认路由。当 `ip_output` 调用 `ether_output` 时，后者检查路由表中的 `rt_gwroute` 变量是否为空。如果是，则调用 `rtalloc1`。假

定路由没有改变，该连接每次调用 `tcp_output` 时，都会使用保存的 `ro_rt` 指针，以避免多余的路由表查询。

第31章

- 31.1 因为在 `bpf_wakeup` 调用唤醒任何沉睡进程之前，`catchpacket` 肯定会结束。
- 31.2 打开BPF设备的应用进程可能调用 `fork`，导致多个应用进程都有权访问同一个BPF设备。
- 31.3 只有支持BPF的设备才会出现在 BPF接口表(`bpf_iflist`)中，因此，如果无法找到指定接口，`bpf_setif` 将返回ENXIO。

第32章

- 32.1 在第一个例子中等于 0，第二个例子中等于 255。这些值都是 RFC 1700 [Reynolds 和 Postel 1994] 中的保留值，不应出现在数据报中。也就是说，如果某个插口创建时的协议号设定为 `IPPROTO_RAW`，则必须设定其 `IP_HDRINCL` 插口选项，且写入到该插口的数据报必须拥有一个有效的协议值。
- 32.2 因为 IP 协议值 255 是保留值，不会出现在网络中传送的数据报中。但这又是一个非零的协议值，`rip_input` 的 3 项测试中的第一项测试将忽略所有协议值不等于 255 的数据报。因此，应用进程无法在该插口上收到任何数据报。
- 32.3 即使该协议值是一个保留值，不会出现在网络中传送的数据报中，但 `rip_input` 的 3 项测试中的第一项测试保证此类型的插口能够接收任何协议类型的数据报。如果应用进程调用了 `connect` 或者 `bind`，或者两者都调用，对于此种原始插口而言，对输入的唯一限制是 IP 报的源地址和目的地址。
- 32.4 因为 `ip_protos` 数组(图 7-22)保存了有关内核所能支持的协议类型的信息，只有在该协议既没有相关的原始监听插口，而且指针 `inetsw[ip_protos[ip->ip_p]].pr_input` 等于 `rip_input` 时，才会生成 ICMP 差错报告。
- 32.5 两种情况下，应用进程都必须自己构造 IP 首部，以及其后的内容(UDP 报文段，TCP 报文段或任何其他的报文段)。对于原始 IP 插口，输出时同样调用 `sendto`，通过 Internet 插口地址结构指明目的 IP 地址。调用 `ip_output`，并依据给定的目的 IP 地址执行正常的 IP 选路。
BPF 要求应用进程提供完整的数据链路层首部，例如以太网首部。输出时，需调用 `write`，因为无法指明目的地址。数据分组被直接交给接口输出函数，跳过 `ip_output` 函数(图 31-20)。应用进程通过 `BIOCSETIF` `ioctl`(图 31-16) 选择外出接口。因为未执行 IP 选路，数据帧只能发给是直接相连的网络上的另一个主机(除非应用进程重复 IP 选路函数，并将数据帧发给直接相联网络上的某个路由器，由路由器根据目的 IP 地址完成转发)。
- 32.6 原始 IP 插口只能接收具有内核不处理的协议类型的数据报，例如，应用进程无法在原始插口上接收 TCP 报文段或 UDP 报文段。
BPF 能够接收到达指定接口的所有数据帧，无论它们是否是 IP 数据报。`BIOCPRMISCI` `ioctl` 使接口处于一种混杂状态，甚至能够接收不是发给本主机的数据报。

附录B 源代码的获取

URL：统一资源定位符

本附录列出源代码所在的网址和下载方式。例如，常见的“匿名FTP”地址表示如下：

`ftp://ftp.cdrom.com/pub/bsd-sources/4.4BSD-Lite.tar.gz`

即主机为`ftp.cdrom.com`。通过匿名FTP客户登录后，从目录`pub/bsd-sources`下载文件`4.4BSD-Lite.tar.gz`。后缀`.tar`说明文件以标准的`tar(1)`格式存储，`.gz`说明文件由GNU`gzip(1)`程序压缩。

4.4BSD-Lite

有多种方式可得到4.4BSD-Lite的正式版代码。完整的4.4BSD-Lite正式版代码可通过Walnut Creek CD-ROM公司得到，网址为

`ftp://ftp.cdrom.com/pub/bsd-sources/4.4BSD-Lite.tar.gz`

或者直接得到其光碟版。联系电话为18007869907或+1510 674 0783。

O'Reilly & Associates出版的CD-ROM，包括全套的4.4BSD手册和4.4BSD-Lite正式版代码。联系电话为1 800 889 8989或者+1 707 829 0515。

运行4.4BSD-Lite 网络软件的操作系统

4.4BSD-Lite正式版不是一个完整的操作系统。为了测试本书中介绍的网络软件，需要内置4.4BSD-Lite正式版的操作系统，或者支持4.4BSD-Lite的操作系统。

作者使用的操作系统是Berkeley Software Design Inc.生产的商用系统，联系电话为1 800 ITS BSD8，+1 719 260 8114，或者`info@bsdi.com`。

还有些免费的操作系统，已内置了4.4BSD-Lite，如NetBSD、386BSD和FreeBSD。详情请见Walnut Creek CD-ROM(`ftp.cdrom.com`)或者`comp.os.386bsd` Usenet新闻组。

RFC

所有RFC都是免费的，通过电子邮件或匿名FTP服务器可从英特网上得到所需文档。向上述地址发送电子邮件：

```
To: rfc-info@ISI.EDU.  
Subject: getting rfc's  
help: ways_to_get_rfcs
```

回复邮件中会列出通过电子邮件或匿名FTP服务器获取RFC不同方法的详细说明。

记住，首先应先下载最新的RFC索引，从中查找所需的RFC，确认所需的RFC没有被新的RFC更新或取代。

GNU软件

利用GNU Indent程序对本书出现的所有源代码进行格式调整，并利用GNU Gzip程序对文件做了压缩。这些程序可在下列站点找到：

<ftp://prep.ai.mit.edu/pub-gnu/indent-1.9.1.tar.gz>
<ftp://prep.ai.mit.edu/pub-gnu/gzip-1.2.2.tar>

文件名中的数字随版本的不同而不同。此外还有用于其他操作系统的Gzip程序，如MS-DOS。

英特网上还有许多其他站点也提供GNU资源，prep.ai.mit.edu主机的问候词中列出了这些站点的名称。

PPP软件

有些PPP实现是免费的。[comp.protocols.ppp FAQ](http://comp.protocols.ppp.FAQ)的第5部分提供了很多有价值的信息。

<http://cs.uni-bonn.de/ppp/part5.html>

mouted软件

mouted软件的最新版本和其他多播应用程序可从Xerox Palo Alto研究中心的站点得到：

<ftp://parcftp.xerox.com/pub/net-research/>

ISODE软件

ISODE软件包中的SNMP代理实现与Net/3兼容。详细信息参见ISODE论坛的网站：

<http://www.isode.com/>